

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO DE INFORMÁTICA
PROGRAMA DE PÓS-GRADUAÇÃO EM COMPUTAÇÃO

FRANCISCO JOSÉ CARVALHO COSTA

**Algoritmos Não Supervisionados no
Entendimento da Relação Entre a Saúde
Mental e o Rendimento Acadêmico: Uma
Comparação de Modelos de Clusterização**

Dissertação apresentada como requisito parcial
para a obtenção do grau de Mestre em Ciência da
Computação

Orientador: Prof. Dr. Cláudio Fernando Resin
Geyer

Porto Alegre
2026

CIP — CATALOGAÇÃO NA PUBLICAÇÃO

Costa, Francisco José Carvalho

Algoritmos Não Supervisionados no Entendimento da Relação Entre a Saúde Mental e o Rendimento Acadêmico: Uma Comparação de Modelos de Clusterização / Francisco José Carvalho Costa. – Porto Alegre: PPGC da UFRGS, 2026.

107 f.: il.

Dissertação (mestrado) – Universidade Federal do Rio Grande do Sul. Programa de Pós-Graduação em Computação, Porto Alegre, BR-RS, 2026. Orientador: Cláudio Fernando Resin Geyer.

1. Aprendizado não supervisionado. 2. Clusterização. 3. Avaliação de algoritmos. 4. Saúde mental. 5. Educação. I. Geyer, Cláudio Fernando Resin. II. Título.

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

Reitora: Prof^ª. Marcia Barbosa

Vice-Reitora: Prof. Pedro Costa

Pró-Reitora Adjunta de Pós-Graduação: Prof^ª. Claudia Wasserman

Diretor do Instituto de Informática: Prof. Luciano Paschoal Gaspary

Coordenador do PPGC: Prof. Gabriel Luca Nazar

Bibliotecária-chefe do Instituto de Informática: Alexsander Borges Ribeiro

*“Keep it simple, as simple as possible,
but not simpler.”*

— ALBERT EINSTEIN

AGRADECIMENTOS

Deus certamente me ouviu! Eu sonhei com esse dia mesmo sem saber o que um mestrado significaria. Cresci vendo e sabendo que a educação mudaria minha vida e mudou. Obrigado a Deus e aos meus orixás, aos meus guias. Obrigado pelos caminhos abertos e pelos olhos atentos daqueles que nunca dormem. Obrigado, Mãe, ou Dona Magna, para muitos, por ser minha professora de vida e ter certamente alimentado todos os meus sonhos. Gratidão pelo apoio sempre "acelerado e sensato" da minha irmã Alana, e pelo feliz brilho do sorriso de Isabela. Tia Nonata, Hyvilla, Vitória, Luziana, Cleidiane, Bola e Hygor. Gratidão a Deus pelos meus padrinhos Serrate e Chico velho, e também pelo tênis novo que Adélia me deu sabendo que o início de um sonho leva ao lugar certo. Obrigado, Pai, por me lembrar que sou corajoso. Certamente minha avó Sebastiana é um dos meus maiores exemplos. Tia Maria, obrigado por me encorajar a voltar sempre que pensei em fugir, e a minha Prima Paula pelas noites de passeio e fugas até o aeroporto de São Paulo.

Aos meus amigos, gratidão por não deixarem eu me perder, Marcos Filho, Matheus k., Dyego Marques, Athyrson e Edisaac. Obrigado por tudo o que fizeram nessa caminhada.

Obrigado ao meu orientador, Geyer, pela paciência, por todas as vezes que me acordou pra vida e por ter aceitado me acompanhar nessa Jornada. Obrigado ao meu orientador Atila, por dizer que era possível, ao Baluz e a todos os que me fizeram ver a vida com mais coragem.

A turma do kisuke não pode ser esquecida: Diego Rodrigues, Samila, Rafael, Jorge Luis, Obrigado, meu povo! Obrigado, Sui, por dizer que no fim de tudo eu seria mais que mestre. Obrigado Bianca Tobá, por todas as horas de ouvido alugadas. Falta meu povo do crossfit.

Obrigado ao Ricardo, por ter me mostrado qual o verdadeiro significado da palavra companheirismo. Lola, obrigado pelas horas de discussão sobre os meus artigos! Gratidão, Erika, por ter sido e sempre ser uma parceria de vida, uma irmã. Obrigado Ana Paula, pelo sabor da vida.

LISTA DE ABREVIATURAS E SIGLAS

ACM	Association for Computing Machinery
AI	Artificial Intelligence
AMSP	Academic Motivation and Student Performance
ARI	Adjusted Rand Index
BIBTeX	Bibliographic TeX
CES-D	Center for Epidemiologic Studies Depression Scale
CHI	Calinski–Harabasz Index
CNN	Convolutional Neural Network
COVID-19	Coronavirus Disease 2019
DBI	Davies–Bouldin Index
DBSCAN	Density-Based Spatial Clustering of Applications with Noise
DM	Data Mining
EC	Critérios de Exclusão
EDC	Educational Data Clustering
EDM	Educational Data Mining
FCM	Fuzzy C-Means
Fog	Fog Computing
GPA	Grade Point Average
GPU	Graphics Processing Unit
HDBSCAN	Hierarchical Density-Based Spatial Clustering of Applications with Noise
HFCA	Heuristic Fuzzy C-Means Algorithm
HSNMF	Hypergraph Semi-orthogonal Nonnegative Matrix Factorization
IC	Critérios de Inclusão
IEEE	Institute of Electrical and Electronics Engineers

JSPE	Jefferson Scale of Physician Empathy
KDD	Knowledge Discovery in Databases
K-Means	K-Means Clustering Algorithm
LE	Label Encoding
MBI	Maslach Burnout Inventory
MBI-CY	Maslach Burnout Inventory – Cynicism
MBI-EA	Maslach Burnout Inventory – Academic Efficacy
MBI-EX	Maslach Burnout Inventory – Emotional Exhaustion
ML	Machine Learning
MOODLE	Modular Object-Oriented Dynamic Learning Environment
NaN	Not a Number
NMF	Nonnegative Matrix Factorization
OHE	One-Hot Encoding
OPTICS	Ordering Points To Identify the Clustering Structure
PCA	Principal Component Analysis
PICOC	Population, Intervention, Comparison, Outcome, Context
PSP	PlayStation Portable
QCAE	Questionnaire of Cognitive and Affective Empathy
RQ	Research Question
RSL	Revisão Sistemática de Literatura
SAS	Statistical Analysis System
SPSS	Statistical Package for the Social Sciences
SSE	Sum of Squared Errors
STAI-T	State-Trait Anxiety Inventory – Trait
StArt	State of the Art through Systematic Review
SW	Silhouette Width

TPU Tensor Processing Unit

UX User Experience

LISTA DE FIGURAS

Figura 2.1 Fluxograma de algoritmos de Machine Learning.....	23
Figura 2.2 Tipos de Machine learning [HUANG, 2022]	25
Figura 2.3 Fluxo dos algoritmos de Machine Learning.....	31
Figura 2.4 Kmeans Cluster.....	32
Figura 2.5 Curva de Elbow	32
Figura 2.6 Fluxograma K-mode.....	34
Figura 2.7 Funções de definição K-prototype	36
Figura 2.8 Algoritmo DBSCAN	38
Figura 2.9 Pseudocódigo DBSCAN.....	39
Figura 2.10 Pseudocódigo OPTICS	40
Figura 5.1 Teste de elbow - k inicial	73
Figura 5.2 Cenários 1 e 2	75
Figura 5.3 Cenários 3 e 4	75
Figura 5.4 Cenários 5 e 6	76
Figura 5.5 Cenários 7 e 8	76
Figura 5.6 Cenários 9 e 10	78
Figura 5.7 Cenários 11 e 12	78
Figura 5.8 Cenários 13 e 14	79
Figura 5.9 Cenários 15 e 16	79
Figura 5.10 Cenários 18 e 19	81
Figura 5.11 Cenários 20 e 21	82
Figura 5.12 Cenários 22 e 23	82
Figura 5.13 Cenários 24 e 25	83
Figura 5.14 Cenários 26 e 27	83
Figura 5.15 Cenários 28 e 29	84
Figura 5.16 Cenários 30 e 31	84
Figura 5.17 Cenários 32 e 33	85
Figura 5.18 Cenários 35 e 36	88
Figura 5.19 Cenários 37 e 38	88
Figura 5.20 Cenários 39 e 40	89
Figura 5.21 Cenários 41 e 42	89
Figura 5.22 Cenários 43 e 44	90
Figura 5.23 Cenários 45 e 46	90
Figura 5.24 Cenários 47 e 48	91
Figura 5.25 Cenários 49 e 50	91
Figura 5.26 Cenário 51.....	92
Figura 6.1 Distribuição do desempenho acadêmico (<i>Last_GPA</i>) por cluster	97
Figura 6.2 Médias de variáveis de estresse e desempenho (<i>Last_GPA</i>) por cluster	98

LISTA DE TABELAS

Tabela 3.1	Descrição PICOC	46
Tabela 3.2	Strings de busca utilizadas nas bases de dados ACM/IEEE e Scopus.....	48
Tabela 3.3	Artigos selecionados.....	52
Tabela 3.4	Métricas de avaliação utilizadas nos estudos analisados	53
Tabela 3.5	Síntese comparativa dos estudos selecionados	55
Tabela 3.6	Comparação entre trabalhos relacionados e a dissertação.....	59
Tabela 4.1	Dataset of Jordanian university students	62
Tabela 4.2	Estudantes Estados Unidos.....	63
Tabela 4.3	Dataset Estudantes Malasia	64
Tabela 4.4	Configurações dos algoritmos por cenário com e sem redução de dimensionalidade (PCA)	68
Tabela 5.1	Métricas comparativas entre algoritmos utilizando One-Hot Encoding (OHE).....	75
Tabela 5.2	Métricas comparativas entre algoritmos utilizando Label Encoding (LE)....	77
Tabela 5.3	Métricas comparativas entre algoritmos utilizando One-Hot Encoding (OHE) sem redução de dimensionalidade (PCA)	78
Tabela 5.4	Métricas comparativas entre algoritmos utilizando Label Encoding (LE) sem redução de dimensionalidade (PCA)	80
Tabela 5.5	Métricas comparativas entre algoritmos utilizando One-Hot Encoding (OHE) com redução de dimensionalidade (PCA).....	81
Tabela 5.6	Métricas comparativas entre algoritmos utilizando Label Encoding (LE) com redução de dimensionalidade (PCA).....	83
Tabela 5.7	Métricas comparativas entre algoritmos utilizando Label Encoding (LE) sem redução de dimensionalidade	85
Tabela 5.8	Métricas comparativas entre algoritmos utilizando One-Hot Encoding (OHE) sem redução de dimensionalidade.....	86
Tabela 5.9	Métricas comparativas entre algoritmos utilizando One-Hot Encoding (OHE) com redução de dimensionalidade (PCA).....	87
Tabela 5.10	Métricas comparativas entre algoritmos utilizando Label Encoding (LE) com redução de dimensionalidade (PCA).....	89
Tabela 5.11	Métricas comparativas entre algoritmos sem redução de dimensionalidade (Sem PCA)	91
Tabela 5.12	Métricas comparativas entre algoritmos utilizando One-Hot Encoding (OHE) com redução de dimensionalidade (PCA).....	92
Tabela 5.13	Métricas comparativas entre algoritmos utilizando Label Encoding (LE) com redução de dimensionalidade (PCA).....	93
Tabela 5.14	Métricas comparativas entre algoritmos sem redução de dimensionalidade (Sem PCA)	93
Tabela 6.1	Médias das variáveis de estresse e desempenho acadêmico por cluster.....	96

SUMÁRIO

RESUMO	12
ABSTRACT	13
1 INTRODUÇÃO	14
1.1 Definição do Problema.....	15
1.2 Motivação.....	16
1.3 Objetivos e Contribuições	18
2 REFERENCIAL TEÓRICO	20
2.1 Educational Data Mining	20
2.1.1 EDM e implicações na saúde mental	22
2.1.2 Machine Learning	22
2.1.3 Classificação do Machine Learning	24
2.1.4 CLUSTERIZAÇÃO	26
2.1.5 Profiling	27
2.1.6 K-Means.....	29
2.1.7 K-Mode	32
2.1.8 K-Prototype.....	35
2.1.9 DBSCAN	37
2.1.10 OPTICS.....	39
2.1.11 Agglomerative Clustering	41
2.1.12 Clusterização hierárquica aglomerativa	42
3 TRABALHOS RELACIONADOS	44
3.1 Revisão Sistemática de Literatura.....	44
3.2 Metodologia da pesquisa	45
3.2.1 Questões de pesquisa	46
3.2.2 Desenvolvimento da estratégia de pesquisa.....	47
3.2.3 Seleção de estudos	49
3.2.3.1 Critérios de inclusão	49
3.2.4 Critérios de exclusão	50
3.2.5 Extração de dados	50
3.2.6 Resultados	51
3.2.7 Modelos de Clusterização	55
3.2.8 Desafios e Limitações Identificados.....	57
3.3 Considerações Sobre o Capítulo	59
4 METODOLOGIA	60
4.1 Levantamento de dados	60
4.1.1 Dicionário de Dados	61
4.2 Pré-processamento de dados	64
4.3 Clustering analysis	65
4.4 Escolha do algoritmo	67
4.4.1 Configuração de execução dos algoritmos.....	68
4.4.2 Redução de dimensionalidade e encoding de dados no pré-processamento de dados	68
4.5 Métricas para avaliação	69
4.5.1 Índices de validação interna.....	70
4.5.2 Cenários de avaliação.....	70
4.5.3 Avaliação e interpretação dos clusters	71
4.6 Considerações sobre o capítulo.....	72

5 RESULTADOS E AVALIAÇÃO	73
5.1 Experimentos e Avaliação de Resultados.....	73
5.2 BLOCO 1: Dataset Estudantes Estados Unidos	75
5.3 BLOCO 2: Dataset of Jordanian university students psychological health impacted by using e-learning tools during COVID-19	81
5.4 BLOCO 3: Dataset of Malaysian University Students	87
6 DISCUSSÕES.....	95
6.1 Distribuição do desempenho acadêmico por cluster.....	95
6.2 Considerações sobre o capítulo.....	99
7 CONCLUSÕES E TRABALHOS FUTUROS	100
7.1 Contribuições.....	101
7.1.1 Trabalhos Futuros	102
REFERÊNCIAS.....	103

RESUMO

Nas últimas décadas, o crescimento exponencial do volume e da complexidade dos dados educacionais impulsionou o uso de técnicas de aprendizado de máquina para apoiar a análise e a tomada de decisão em contextos acadêmicos. Nesse cenário, as técnicas de aprendizado não supervisionado, especialmente as baseadas em clusterização, têm se destacado pela capacidade de identificar padrões ocultos e relações subjacentes entre variáveis de natureza diversa, sem a necessidade de rótulos previamente definidos.

Este trabalho propõe uma análise comparativa do desempenho de diferentes algoritmos de clusterização aplicados a conjuntos de dados educacionais compostos por variáveis acadêmicas, psicológicas e sociodemográficas de estudantes universitários.

Para a execução dos experimentos, foram utilizados algoritmos amplamente empregados na literatura, Representando abordagens de clusterização baseadas em particionamento (K-Means, K-Modes e K-Prototypes) e em densidade (DBSCAN). Os dados foram submetidos a um pré-processamento, incluindo a transformação de variáveis categóricas por meio da técnica One-Hot Encoding (OHE), padronização e tratamento de inconsistências. A execução dos algoritmos foi realizada em ambiente Google Colab, com implementação em Python e uso de bibliotecas especializadas como Scikit-Learn e NumPy.

Os resultados evidenciaram diferenças relevantes entre os algoritmos quanto à precisão dos agrupamentos, à robustez diante de ruído e à capacidade de interpretar relações entre atributos. Dentre os cenários testados, o K-means aplicado à redução de dimensionalidade apresentou o melhor desempenho global, equilibrando qualidade de agrupamento e estabilidade estatística.

A pesquisa aponta que o uso de métodos de clusterização no contexto educacional, representa uma ferramenta promissora para a descoberta de padrões de comportamento, perfil e desempenho, podendo subsidiar políticas de apoio acadêmico e estratégias pedagógicas personalizadas.

Palavras-chave: Aprendizado não supervisionado. Clusterização. Avaliação de algoritmos. Saúde mental. Educação.

ABSTRACT

In recent decades, the exponential growth in the volume and complexity of educational data has driven the use of machine learning techniques to support analysis and decision-making in academic contexts. In this scenario, unsupervised learning techniques, particularly those based on clustering, have stood out for their ability to identify hidden patterns and underlying relationships among variables of different natures, without the need for predefined labels.

This study proposes a comparative analysis of the performance of different clustering algorithms applied to educational datasets composed of academic, psychological, and sociodemographic variables from university students.

For the experiments, widely used algorithms in the literature were employed, such as K-Means, DBSCAN, and K-Modes, representing partition-based and density-based approaches. The data underwent a preprocessing stage, which included the transformation of categorical variables using the One-Hot Encoding (OHE) technique, as well as standardization and inconsistency handling. The execution of the algorithms was carried out in the Google Colab environment, implemented in Python with the support of specialized libraries such as Scikit-Learn and NumPy.

The results revealed significant differences among the algorithms in terms of clustering accuracy, robustness to noise, and ability to interpret relationships between attributes. Among the tested scenarios, K-Means applied with dimensionality reduction achieved the best overall performance, balancing clustering quality and statistical stability.

The findings suggest that the use of clustering methods in the educational context represents a promising approach for discovering patterns of behavior, profile, and performance, potentially supporting academic assistance policies and personalized pedagogical strategies.

Keywords:

. Unsupervised learning. Clustering. Algorithm evaluation. Mental health. Education.

1 INTRODUÇÃO

A Mineração de dados educacionais (EDM), como uma ferramenta de abrangência interdisciplinar, consiste no uso de diferentes ferramentas matemáticas e computacionais como o aprendizado de máquina, a mineração de dados além de aspectos psicopedagógicos. A EDM também utiliza conjuntos de dados construídos em meios educacionais para desenvolver sistemas de recomendações para serem aplicados em questões da educação [Dol e Jawandhiya 2023].

Logo, A EDM pode ser entendida como a coleta de dados em ambientes educacionais para serem classificados e analisados conforme a necessidade. Desta forma, os dados também podem ser usados para predição e análise de performance de estudantes em diversas áreas do conhecimento, identificação de fatores que podem levar alunos à evasão.

São diversos os sistemas educacionais que podem ser utilizados para coleta dos mais variados tipos de dados de estudantes e muitas vezes em grandes volumes. Dos tipos de informações que podem ser coletadas, os sistemas acadêmicos podem disponibilizar histórico acadêmico, informações de desempenho dos alunos, dados de matrícula, além de informações de dados dos instrutores [Dol e Jawandhiya 2023].

Os dados podem ser coletados de fontes digitais educacionais como cursos online, sistemas de gerenciamento de aprendizagem como o MOODLE e o conjunto de dados obtido pode ser utilizado para extração de insights e padrões significativos que podem ajudar a melhorar o desempenho de alunos e a reconhecer padrões de comportamento e modos de aprendizagem [Dol e Jawandhiya 2023].

Usando métodos de Data Mining (DM) e dados de fontes educacionais, é possível entender melhor os estudantes e as formas ou ambientes em que aprendem e, deste modo, desenvolver modelos de ML para melhorar a experiência dos estudantes e aprimorar a efetividade das atividades institucionais. Neste contexto, a EDM se volta para questões educacionais ao analisar dados gerados no cotidiano educacional usando diferentes métodos de aquisição [Dutt, Ismail e Herawan 2017] .

Na área de mineração de dados, a técnica de clusterização é amplamente utilizada para particionar um conjunto de dados composto por n pontos em um espaço de m dimensões em k grupos distintos. O objetivo é que os elementos pertencentes a um mesmo grupo apresentem maior similaridade entre si do que em relação aos elementos de ou-

tros grupos. Em essência, o processo de clusterização é conduzido com base no grau de similaridade ou dissimilaridade existente entre os objetos analisados [Cao et al. 2012].

Existem diversas técnicas de mineração de dados que podem ser focadas em questões educacionais como clusterização, regressões, algoritmos genéticos, regras de associação, redes neurais, dentre outros que podem ser aplicados na busca por conhecimento em datasets educacionais. Neste direcionamento, vários modelos de mineração dentro das mais variadas técnicas vêm sendo apresentados pela literatura e muitas vezes são focados em predição de evasão ou em falha no processo de educação formal do aluno em disciplinas específicas [Dol e Jawandhiya 2023].

Dentre as formas de aplicação da Mineração de dados na educação, das quais destacam-se para discussão na literatura a predição da evasão e a predição e avaliação de performance, a evasão é um sério problema que pode ser analisado com a ajuda da mineração de dados. Quando se trata da evasão de estudantes, muitos fatores podem colaborar com a desistência dos alunos, tais como questões econômicas, sociais, familiares, além da condição educacional e psicológica dos estudantes [Ribeiro e Canedo 2020].

Um fator relevante que vem sendo discutido pela literatura é a relação entre a condição de saúde mental e seus possíveis impactos no rendimento acadêmico dos estudantes. Variados estudos têm surgido na literatura para entender e prever a evasão e a performance dos alunos por meio de técnicas de Mineração de dados [Ribeiro e Canedo 2020], contudo, pouco se relaciona, em matéria de EDM, a saúde mental e seus impactos no cotidiano educacional.

Neste contexto, o objetivo deste trabalho é comparar diferentes algoritmos de clusterização para entender como eles podem ajudar na visualização dos impactos da saúde mental dos estudantes no desempenho acadêmico. Para isto, foi necessária a execução de experimentos com diferentes algoritmos de clusterização visando comparar diferentes técnicas utilizando de dados educacionais já utilizados em pesquisas anteriores e fornecidos por bases públicas.

1.1 Definição do Problema

. Diante da evolução tecnológica, várias técnicas computacionais se integraram ao processo de exploração e análise de dados educacionais e dentre elas o DM, envolvendo o uso de Aprendizado de Máquina, a exemplo dos algoritmos de clusterização para reconhecer padrões e características comuns entre os dados [Dutt, Ismail e Herawan 2017].

Nesta pesquisa, tendo em vista a larga aplicabilidade e a diversidade dos algoritmos de clusterização, evidencia-se a problemática de como os algoritmos de clusterização e suas diferenciações podem auxiliar no entendimento da correlação de fatores emocionais e o desempenho acadêmico.

Numa avaliação comparativa, que algoritmo poderia apresentar um bom desempenho ao agrupar dados de educacionais? Ao utilizar um conjunto de dados em contexto específico, pode ser difícil definir uma técnica de clusterização genérica que melhor se adeque àquela necessidade [Rodriguez et al. 2019].

Apesar da larga aplicação dos modelos não supervisionados em áreas como educação [Ezugwu et al. 2022], os algoritmos mais usados para avaliar questões de saúde mental são os supervisionados. O estado da arte da presente pesquisa evidencia uma abrangente discussão de questões educacionais focadas no rendimento acadêmico e no estresse dos estudantes, contudo não apresenta avaliações de como as arquiteturas de clusterização não supervisionadas podem auxiliar no entendimento da relação entre o rendimento e a condição de saúde mental dos estudantes.

Além disso, a performance das diferentes técnicas de clusterização pode variar significativamente conforme o tipo de dados e aplicações, tendo em vista que os algoritmos operam em dimensões diferentes e muitas vezes lidam com dados incompletos e ruídos. Assim, muitos métodos de clusterização têm sido desenvolvidos de modo a abranger os mais variados problemas e conseguir lidar com os mais variados tipos de dados de forma apropriada [Hooshyar et al. 2020].

Deste modo, que algoritmo pode apresentar melhor desempenho ao agrupar dados de estudantes que sofrem com ansiedade e como isso poderia ajudar a entender se a saúde mental tem impactado o rendimento acadêmico? A depender da estrutura explícita no conjunto de dados, a eficácia de cada modelo vai mudar, sendo necessário identificar diferentes características e avaliar o desempenho daquela determinada prática de clusterização relacionada ao contexto em que está sendo aplicada [Wegmann et al. 2021].

1.2 Motivação

Na EDM, uma técnica relevante para auxiliar na análise de dados é a clusterização. Sendo discutida como uma das técnicas mais relevantes do ML não supervisionado, a clusterização pode agrupar dados conforme a sua similaridade, reduzir significativamente o volume de dados em grupos distintos e facilitar na exploração dos dados. A análise de

clusters consegue transformar dados diversificados e ocultos em formas reais de análise para servir base para tomada de decisão e por isso é possível avaliar o desempenho e as possibilidades de aplicação dos mais diferentes algoritmos de clusterização [Liu et al. 2022].

Uma das aplicações da clusterização na educação é a do agrupamento de estudantes baseado no perfil acadêmico, seja por rendimento ou pelas características comportamentais em suas rotinas de estudos, por exemplo [Wulandari et al. 2020] e [Francis e Babu 2019]

Quando se trata de perfil acadêmico é importante compreender tal perfil como um padrão nas formas de construir conhecimento ou mesmo do comportamento acadêmico do estudante, pode também envolver padrões de cognição e outros comportamentos relacionados ao cotidiano acadêmico [Phan, Boato e Natale 2018].

Contudo, ao considerar os diferentes perfis de estudantes presentes nas universidades e que eles apresentam diferentes formas de reagir a estímulos sociais, é importante destacar que: situações que exigem comportamentos interpessoais específicos podem expor os estudantes a situações de estresse e ao desenvolver transtornos mentais, além de outras dificuldades comportamentais [Fogaça et al. 2022].

Historicamente, a presença de transtornos mentais é cada vez mais comum no ensino superior desde os anos 2000 [Leão 2018]. Ao considerar a saúde mental como uma premissa básica da aprendizagem, estudantes de graduação formam uma parcela diretamente afetada pela exaustão emocional e a baixa perspectiva de realização profissional [Santos et al. 2021].

Apesar do avanço das pesquisas em Mineração de Dados Educacionais e da crescente aplicação de técnicas de aprendizado de máquina na análise de fenômenos educacionais, observa-se que poucos estudos em Mineração de Dados Educacionais (EDM) exploram conjuntamente a relação entre saúde mental e desempenho acadêmico por meio de técnicas de aprendizado não supervisionadas. A maioria das abordagens identificadas na literatura concentra-se em métodos supervisionados ou na análise isolada de variáveis acadêmicas, ou psicológicas, evidenciando uma lacuna quanto à investigação de padrões latentes que emergem da interação entre esses fatores.

Neste sentido, a motivação deste trabalho é apresentar uma avaliação de diferentes técnicas de clusterização, a fim de estudar, por meio de aprendizado de máquina não supervisionado aplicado a dados educacionais, como essas técnicas podem auxiliar na

compreensão da relação entre questões de saúde mental e rendimento acadêmico, agregando novos olhares para questões acadêmicas e sociais oriundas de diferentes realidades.

1.3 Objetivos e Contribuições

Diante da crescente variedade de algoritmos de clusterização diferentes em diferentes pacotes de manipulação e observação estatística de dados, o principal objetivo deste trabalho é avaliar o uso de algoritmos de clusterização na análise da correlação da saúde mental e o rendimento acadêmico de estudantes, ao comparar diferentes técnicas de clusterização. Mesmo com a diversidade de algoritmos disponíveis em linguagens de programação ou frameworks como R, Python, Matlab, Stata, SAS and IBM SPSS, novos algoritmos continuam sendo desenvolvidos e acessivelmente distribuídos de forma acelerada [Gao et al. 2023].

Todavia, a popularização do uso de técnicas de clusterização para identificação de subgrupos homogêneos, a pouca orientação sobre a escolha de modelos, ou mesmo abordagens que possam auxiliar de forma mais clara na utilização de algoritmos de agrupamento em problemas do campo de estudo da psicologia como a saúde mental geram a necessidade de mais estudos focados no assunto, bem como o entendimento abordagens de clusterização [Gao et al. 2023]. Deste modo, para auxiliar no desenvolvimento desta pesquisa, foram estabelecidos os seguintes objetivos específicos:

- Identificar algoritmos de clusterização não supervisionados usados na análise de dados educacionais e saúde mental de estudantes.
- Identificar métricas de avaliação de algoritmos de clusterização que podem ser usadas em conjuntos de dados não rotulados.
- Apresentar uma avaliação do desempenho de algoritmos não supervisionados utilizando conjuntos dados de educacionais de estudos já consolidados.
- Comparar o desempenho de diferentes algoritmos de clusterização usando o mesmo pipeline de dados.
- Entender como o pré-processamento de dados pode interferir no desempenho de algoritmos não supervisionados utilizando bases não rotuladas.

Como contribuição adicional, este trabalho visa apresentar uma discussão sobre o desempenho de seis algoritmos de clusterização utilizando três conjuntos de dados em diferentes cenários de avaliação.

Os cenários de avaliação concentram-se no pré-processamento de dados utilizando técnicas de redução e aumento de dimensionalidade de dados, submetendo os algoritmos a diferentes contextos de agrupamento de dados.

A metodologia deste trabalho também se destaca como uma contribuição, pois contribui na avaliação da viabilidade do uso de algoritmos não supervisionados como uma abordagem para entender ligações entre diferentes variáveis e perfis no que diz respeito ao rendimento acadêmico [Mechelen et al. 2018].

Não obstante, é importante ressaltar que mesmo com a variedade de algoritmos já existentes, isto não é fator limitante para o surgimento de novas formas de performar a clusterização, o que desvela o questionamento sobre qual opção poderia ser melhor aplicável em determinado contexto, o que apresenta uma questão ou mesmo a necessidade de uma avaliação comparativa [Mechelen et al. 2018].

Diante disso, este trabalho está organizado da seguinte forma: o Capítulo 2 apresenta os conceitos teóricos fundamentais que embasam a pesquisa; o Capítulo 3 discute os trabalhos relacionados e o estado da arte; o Capítulo 4 descreve a metodologia adotada; o Capítulo 5 apresenta os resultados obtidos a partir dos experimentos realizados; no Capítulo 6, os achados são analisados e discutidos à luz da literatura; e, por fim, o Capítulo 7 apresenta as conclusões e indica possibilidades para trabalhos futuros.

2 REFERENCIAL TEÓRICO

O objetivo deste capítulo é apresentar os conceitos essenciais das grandes áreas que baseiam o estudo apresentado neste trabalho: Machine Learning, Data Mining e saúde mental. No contexto do presente trabalho, o conceito de Machine Learning centra-se na discussão sobre Aprendizado de Máquinas como um campo da análise de dados em que os algoritmos performam seu funcionamento de forma autônoma, não necessitando de total intervenção humana para o seu funcionamento e apresenta uma discussão mais focada no aprendizado não supervisionado.

No presente trabalho, o termo Data Mining refere-se à aplicação de algoritmos não supervisionados de Aprendizado de Máquina para a descoberta de padrões e informações relevantes em bases de dados educacionais. Já a abordagem sobre saúde mental contempla a revisão e compreensão de conceitos, contextos e impactos desse tema na vida de estudantes, de modo a estabelecer a fundamentação teórica necessária para analisar as relações entre indicadores educacionais e aspectos de bem-estar psicológico dos estudantes.

2.1 Educational Data Mining

A International Educational Data Mining define o EDM como uma disciplina emergente foca no desenvolvimento de métodos que explorem dados de fontes educacionais e aplicam tais métodos no entendimento dos contextos sociais e de aprendizagem e de estudantes. A análise dos dados gerados pelo uso de diferentes sistemas educacionais visa o aperfeiçoamento dos modelos de aprendizagem e o melhor desempenho acadêmico do estudante e sua experiência de aprendizagem [Dutt, Ismail e Herawan 2017].

Por sua vez, o Data mining, também conhecido como descoberta de conhecimento em bases de dados ou Knowledge Discovery in Databases (KDDs), é uma abordagem já consolidada em estudos e aplicações focadas no comércio e em ciências cotidianas e sua aplicação em contextos educacionais é, todavia, limitada [Dutt, Ismail e Herawan 2017]. Ainda, o EDM pode ser definido como uma aplicação das técnicas de mineração de dados em ambientes de dados provenientes de sistemas e contextos educacionais [Chango et al. 2022].

Um exemplo de aplicação e também de ferramenta de pré-processamento de dados da EDM é a clusterização. A abordagem não supervisionada de reconhecimento de

padrões do aprendizado de máquinas refere-se à coleta de objetos semelhantes para formar um grupo ou aglomerado. Pode também ser usada como uma ferramenta de análise de estatística de dados por meio de ML, além de DM [Dutt, Ismail e Herawan 2017].

Quando tal abordagem é aplicada à análise dados derivados de fontes educacionais, é denominada como Clusterização de Dados Educacionais ou Educational Data Clustering (EDC). Levando em consideração que o âmbito educacional envolve, de forma mais abrangente, a figura do estudante, do professor e o ambiente como atores do processo educacional, é importante relevar que interação entre esses atores gera grandes volumes de dados que podem ser analisadas por meio da clusterização para a mineração de informações que pode ser valiosas e contribuir com o processo educacional [Dutt, Ismail e Herawan 2017].

Quando se trata da observação sobre EDM em aplicações científicas, Slater et al. (2017) apresentam ferramentas de software amplamente utilizadas, acessíveis e relevantes para a realização de tarefas de pesquisa, quando se trata do entendimento do comportamento de estudantes [Ihantola et al. 2015] realizaram releitura de processos de mineração de dados aplicados à forma como estudantes pensam a soluções ao programarem e apontam como principal limitação a escassez de conjuntos de dados publicamente disponíveis, evidenciando a limitação da realização de estudos de replicação no assunto (EDM) [Mihaescu e Popescu 2021].

Outro exemplo de aplicação relevante do EDM é a análise visual de dados educacionais e a mineração de textos educacionais. Contudo, mesmo com a diversidade de aplicações e sistemas existentes em EDM, é importante a avaliação dos sistemas disponíveis, todavia tal cenário só pode ser possível com a disponibilidade de dados disponíveis publicamente [Mihaescu e Popescu 2021].

Neste sentido, a EDM pode ser compreendida como o uso de técnicas para resolver problemas utilizando grandes conjuntos de dados relacionados às questões educacionais. Logo, a EDM envolve todo o fluxo ou processo de aquisição de dados e a utilização de modelos para a descoberta de padrões acerca de atores educacionais. Este cenário pode ser uma forma relevante de entendimento do comportamento dos estudantes além de mediação da melhoria no desempenho dos estudantes e, de forma geral, mitigação de problemas relacionados à evasão [Batoool et al. 2023].

2.1.1 EDM e implicações na saúde mental

O ambiente educacional é parte integrante da composição social dos seres humanos de forma geral. Todavia, diante do crescimento social acelerado, cresce também a pressão emergente da necessidade de sobrevivência, além de um cenário de constante competição social que ocasiona o adoecimento mental e afeta comportamentos e emoções em um movimento que cresce cada vez mais ano após ano [Luo 2021]. A saúde mental é imprescindível para saúde e bem-estar em suas formas mais amplas. De forma particular entre estudantes universitários, questões ligadas à saúde mental podem muitas vezes levar a condições extremas como automutilação e suicídio [Guo et al. 2022].

É neste sentido que a inovação de ideias e conceitos que possam ser combinados com a tecnologia da informação, para promover o desenvolvimento de sistemas inteligentes relacionados à saúde mental podem ser uma possível abordagem de intervenção frente a problemas desse [Guo et al. 2022].

O EDM pode ser entendido como a coleta de dados de sistemas educacionais, a classificação desses dados e sua análise para predição de performance além de identificar fatores que podem demonstrar sinais de evasão e ainda entender e conhecer o perfil dos estudantes e seus padrões de aprendizagem [Dol e Jawandhiya 2023], [Meedech, Iam-On e Boongoen 2015].

2.1.2 Machine Learning

O aprendizado de máquinas (Machine Learning) é um objeto da inteligência artificial focado na solução de problemas utilizando exemplos - conjuntos de dados - prévios. Ao utilizar de históricos de dados para aprender padrões não visíveis nos conjuntos de dados, ML utiliza os padrões descobertos para desenvolver diferentes tarefas como a classificação e predição de eventos relacionados a um dado problema.

Em uma diferenciação simples, os sistemas de AI precisam de conhecimento previamente estabelecido para sustentar suas funcionalidades, enquanto ML produz tal conhecimento. Neste sentido, os sistemas de ML são incorporados aos fluxos e componentes de dados para que as informações descobertas ajudem a tornar os processos mais fluidos e eficientes [Alloghani et al. 2020].


De modo geral, cada conjunto de dados possui suas particularidades que necessitam de modelos de ML específicos para soluções de problemas com boa resposta e acurá-

cia. Além disso, é preciso levar em consideração que cada algoritmo funciona com lógica específica, além de necessidades computacionais diferentes para cada algoritmo [Orlandi 2023].

Os métodos de ML são úteis na descoberta de correlações e padrões em conjuntos de dados complexos. Em geral, os problemas de ML podem ser separados em fase de treino e predição/teste [Poh, Ubeynarayana e Goh 2018].

Na fase de treino, o algoritmo é alimentado com um grupo de dados que serão futuramente atualizados e, com o modelo treinado, fase de predição utiliza do algoritmo já treinado para o deploy do modelo, que consiste no uso de novos dados para a produção da saída possível cada tipo de algoritmo [Verbraeken et al. 2020] assim como descrito na Figura 2.1.

Figura 2.1: Fluxograma de algoritmos de Machine Learning.



2.1.3 Classificação do Machine Learning

Além das diferentes aplicações do ML e das diferentes características que podem ser agregadas aos conjuntos de dados, o ML também pode ser caracterizado conforme as diferentes técnicas aplicadas na construção de cada modelo. As técnicas de ML podem ser classificadas segundo a descrição do esquema apresentado na imagem 1, assim como com as considerações de [Verbraeken et al. 2020] e [Huang et al. 2022].

Supervised learning: Supervised learning ou Aprendizado Supervisionado, é uma abordagem ou técnica de ML que foca em definir a função que mapeia as entradas de dados para a construção da saída esperada, deste modo, a função pode ser utilizada para predição utilizando uma nova entrada de dados [Verbraeken et al. 2020]. O Supervised Learning é visto como uma abordagem orientada a tarefas onde os dados são rotulados para atingir o objetivo esperado. Tal técnica é útil quando algum padrão do conjunto de dados já conhecido, de forma que a predição seja mais específica desconsiderando relações/padrões indesejados [Meijer, Zanting e Verloop 2002] e [Huang et al. 2022].

Unsupervised learning: O Aprendizado não Supervisionado ou Unsupervised learning é uma técnica de ML que objetiva uma função que possa descrever a estrutura dos dados e cria conjuntos de entradas não classificadas de dados. Como nesta técnica, os dados não são rotulados, o algoritmo visa construir uma saída limpa e com boa acurácia [Verbraeken et al. 2020].


Dessa forma, o *Unsupervised Learning* encontra uma estrutura em dados não rotulados sem a necessidade de interação humana na etapa de treinamento, o que torna o uso do Unsupervised learning em problemas relacionados a grandes volumes de dados ou em questões onde o rótulo de dados não está disponível. Dos diferentes tipos de técnicas de Unsupervised learning, as mais conhecidas são as técnicas clustering and dimensionality reduction (redução de dimensionalidade) [Huang et al. 2022] e [Barlow 1989].

Semi-supervised learning: ao contrário da usabilidade do Aprendizado não supervisionado, o Semi-supervised learning (Aprendizado semi-supervisionado), normalmente é aplicável em pequenos volumes de dados rotulados em conjunto com um grande volume de dados rotulados. A saída do algoritmo normalmente assume que elementos ou instâncias que compartilham características ou atributos semelhantes (Data points) compartilham da mesma classe de dados.

Reinforcement learning: Nesta abordagem, ao aprendizado acontece por meio do ambiente, o modelo (algoritmo de ML) aprende acordo com as ações do agente ambiente.

Ao contrário do aprendizado supervisionado, o aprendizado não precisa de pares de entrada e saída rotulados, o foco da técnica é encontrar um balanço entre a exploração de ambientes desconhecidos e a exploração do conhecimento atual [Huang et al. 2022].

Figura 2.2: Tipos de Machine learning [HUANG, 2022]



As técnicas de ML definem como cada algoritmo ou modelo se comporta ao resolver determinado problema tendo em vista as características dos dados e o objetivo que se quer alcançar. Se tratando de técnicas, pode-se destacar uma variada gama de tipos de problemas que podem ser resolvidos com ML segundo o objetivo proposto, como se segue:

- **Deteção de anomalias:** É normalmente utilizado para detecção de outliers ou tipos de dados que se diferenciam de forma significativa do conjunto da parte majoritária dos dados. Tal solução pode ser utilizada em detecção de fraudes financeiras e mapeamento de questões de saúde.
- **Classificação:** É definida como um problema de categorização ou classificação de dados não conhecidos de acordo com suas características. Tais categorias são definidas conforme o treinamento de dados, sendo um paradigma de natureza do aprendizado supervisionado, seu equivalente seria a clusterização, como não supervisionado.
- **Agrupamento ou clusterização:** agrupa os dados de acordo com suas semelhanças, normalmente utilizado em conjuntos de dados não rotulados, a prática é amplamente aplicada em paradigmas de ML não supervisionados. Principalmente utilizado para reconhecer padrões não perceptíveis, a clusterização é utilizada em reconhecimento de padrões, pesquisas de mercado, análise de imagens e em análise de crimes.
- **Redução de dimensionalidade:** é utilizado em problemas de redução das variáveis presentes no conjunto de dados (redução de classes). Como exemplo clássico, o

Principal Component Analysis (PCA), é um método para identificação de correlação entre features de forma construir um conjunto de dados de menor dimensão em relação ao conjunto inicial, preservando ao máximo a variação dos dados [Celebi e Kingravi 2012].

- Representação: foca na busca pelas representações adequadas de dados de entrada, objetivando a detecção de características, classificação, agrupamento, codificação ou fatoração de matrizes, por exemplo, o que implica também em redução de dimensionalidade.
- Regressão: Foco na identificação de variáveis que descrevem possíveis relações de dependência de uma variável de resposta em um grupo de variáveis explicativas. A determinação de como uma variante dependente de outra altera seu valor quando outras se alteram [Fitzmaurice 2016].

Dentre os aspectos relacionados aos diferentes paradigmas de ML, esta pesquisa visa apresentar aplicações do conceito de Aprendizado não Supervisionado. Deste modo, é relevante discutir a técnicas de ML em seu viés teórico e apresentar exemplos de algoritmos citados na literatura que culminem com os objetivos da pesquisa, o qual é o caso dos algoritmos de clusterização.

2.1.4 CLUSTERIZAÇÃO

Aprofundando a conceituação de cluster, este conceito é largamente discutido pela literatura e a definição mais comum é da clusterização como a atividade de agrupar dados semelhantes. Todavia, tal denominação varia entre autores e o conceito de similaridade pode ser agregado de várias formas, como matematicamente, ao calcular a distância entre um ponto (dado) e outro, por exemplo [Wegmann et al. 2021]

Os algoritmos de clusterização são adequados para lidar com conjunto de dados com sentido, até então desconhecido, e podem ser base para construção de conhecimentos futuros. Seguindo a formalização de [Jain e Dubes 1988], a clusterização pode ser definida segundo três propriedades, sendo elas:

- As instâncias no mesmo cluster devem ser o mais semelhantes possível;
- As instâncias, nos diferentes clusters, devem ser tão diferentes quanto possíveis;
- As medidas de similaridade e dissimilaridade devem ser claras e ter um significado prático.

Neste sentido, o principal objetivo dos algoritmos de clusterização é fomentar uma técnica para construir grupos de dados similares em um conjunto de dados não rotulado [Ghosal et al. 2020]. Além de se mostrar mais complexa e desafiadora que problemas de classificação por métodos supervisionados, a análise de clusters pode ser usada com os mais diversos propósitos, dentre os quais se pode destacar o desenvolvimento de conhecimento em domínios industriais, transporte, ciências médicas, setor energético, setor de vendas e educação.

2.1.5 Profiling

Na presente pesquisa, a discussão é focada na aplicação da clusterização no campo educacional utilizando da segmentação como uma forma de conhecer características relacionadas a estudantes pertencentes a um mesmo grupo (de características similares) e assim estabelecer diferentes perfis de estudantes, tendo em vista que os algoritmos de clusterização são uma forma de agrupar dados conforme a sua similaridade, seja por recursos ou características [Ezugwu et al. 2022].

Todavia, é importante salientar que o conceito de perfil discutido nesta pesquisa é o perfil acadêmico do estudante, que pode ser entendido como um padrão ligado à cognição, motivação ou mesmo ao comportamento que o estudante apresenta [Phan e Ngu 2021]. Ademais, o perfil acadêmico pode ser compreendido através do contexto histórico do estudante, o que pode envolver suas falhas, sua curiosidade e sensibilidade intelectual, gostos pessoais, projetos de vida e estágios de engajamento ou desengajamento [Phan e Ngu 2021].

Logo, ao segmentar um conjunto de dados é possível conhecer as características comuns entre os componentes de cada cluster. No contexto da análise de clusters, a segmentação é usada nos mais variados campos para criar clusters baseados em determinados atributos. Ainda no contexto da segmentação, um dos grandes exemplos de uso é a da segmentação de clientes, ao organizar dados de clientes em clusters distintos.

Além de ser útil no conhecimento do perfil socioeconômico dos clientes, a segmentação também é uma forma de conhecer os destinos mais procurados por determinado perfil de turistas, assim como para agrupar estudantes por rendimento e acadêmico, afinidade com a área de conhecimento e possibilidade de sucesso ou falha em determinado curso [Ghosal et al. 2020].

Além disso, a segmentação pode ajudar na recomendação de conteúdos ou mesmo de programas estudantis que possam aprimorar seus conhecimentos; para o mercado, a indicação de produtos e serviços que possam se adequar ao perfil dos consumidores [Ghosal et al. 2020].

Apesar da larga variabilidade de algoritmos de clusterização evidenciados pela literatura, é preciso entender que um algoritmo pode ser orientado para um conjunto de aplicações ou campos específicos. Deste modo, os algoritmos apresentam suas próprias particularidades de metodologia para agrupar o conjunto de dados e toda essa variedade de técnicas pode ser agrupada em cinco sub-conjuntos, tais como partitional clustering, heirarchical clustering, density based clustering, grid based clustering, model based clustering [Ghosal et al. 2020].

Cada algoritmo independente do tipo é capaz de explorar estruturas implícitas na distribuição dos conjuntos dados e definir as regras para agrupar os dados com certo grau de similaridade. O processo resulta em um conjunto de clusters baseado no critério adotado por cada algoritmo sem nenhum conhecimento preliminar acerca dos dados, onde em um contexto ideal cada cluster é baseado no maior nível de similaridade das instâncias pertencentes a ele e o mais diferente possível de instâncias extra-cluster [Ahmed, Seraj e Islam 2020].

Todavia, é preciso avaliar a qualidade dos agrupamentos e mensurar os níveis de similaridade e dissimilaridade nos clusters. Além da diversidade de algoritmos, diferentes índices avaliam o nível de validade dos clusters resultantes e ajudam a entender se a segmentação resolve o problema inicial, o que explica a necessidade da avaliação [Wegmann et al. 2021].

De forma geral, os índices de avaliação são divididos em internos, usados quando o conjunto de dados não dispõe de rótulos; e os externos, quando o conjunto de dados possui o conjunto de rótulos; e os índices relativos, que fazem parte do conjunto de índices internos (Wegmann et al.,2021). Tendo em vista o grande número de algoritmos de tipos de avaliação, é importante que a qualidade do cluster seja avaliada para garantir que o agrupamento é aceitável, além disso, garantir a eficiência em termos de performance [Renjith, Sreekumar e Jathavedan 2020].

No presente trabalho, a abordagem de EDM que será aplicada é a clusterização. Como forma de dar suporte na percepção da relação entre a saúde mental e o rendimento acadêmico. Para dar continuidade à discussão, serão apresentados conceitos, descrições

matemáticas e computacionais além de contextos de aplicação de diferentes algoritmos de clusterização que foram utilizados no desenvolvimento do presente trabalho.

2.1.6 K-Means

Nos últimos anos, a clusterização como ferramenta de análise de dados se desenvolveu de forma considerável. Tido como um dos mais populares algoritmos de clusterização, o k-means é um algoritmo baseado em partição (partition-based clustering). A abordagem foi inicialmente proposta por [MacQueen 1967] e, mesmo que sua utilização compreenda um pouco mais de meio século, o K-means continua sendo amplamente utilizado e vem sendo aprimorado com o passar dos anos mesmo com o surgimento de novos algoritmos [Ashabi, Sahibuddin e Haghighi 2020].

De modo geral o k-means é considerado um algoritmo baseado em método de partição e vem sendo largamente utilizado em questões do mundo real. Grande parte dos algoritmos tipo k-means consideram apenas as similaridades entre os objetos nos agrupamentos formados, de forma a minimizar a dispersão ou dissimilaridade dentro do cluster [Ashabi, Sahibuddin e Haghighi 2020].

No tocante ao seu funcionamento, o k-means visa obter um conjunto de n objetos de um conjunto de dados de forma que cada grupo ou cluster tenha o máximo de similaridade entre si e a maior dissimilaridade possível em relação a objetos de outros clusters. O k-means separa os componentes de um conjunto de dados de modo que cada objeto do conjunto fique próximo do ponto central ou da média (mean) dos pontos pertencentes [Ashabi, Sahibuddin e Haghighi 2020].

Computacionalmente, o algoritmo escolhe um conjunto de k instâncias do conjunto de dados aleatoriamente e repetidamente executa duas etapas: a primeira de alocação de cada instância do conjunto no cluster mais próximo, depois disso, classifica os objetos e então revisa a distância de cada objeto em relação a média ou centróide (mean) de cada conjunto. Desta forma, o algoritmo gera um número k de clusters de forma que cada conjunto seja o mais diferente possível de outros clusters.

Em suma, número k de clusters é gerado com a maior distinção possível de um cluster para outro, o que implica em maior distanciamento dos centróides e dos clusters de forma geral. A técnica de clusterização adotada no k-means pode ser compreendida em cinco etapas que vão desde a divisão inicial do conjunto em sub-sets de dados até o estabelecimento dos centróides de cada cluster e o k ótimo (número de clusters) estabelece

a maior separação/ distância. [Ashabi, Sahibuddin e Haghighi 2020]; [Chong et al. 2021], como se segue:


- O grupo é dividido em k subconjuntos enquanto aguarda a predefinição do valor exato para k .
- Escolhe um valor de k como centróides. Assinala cada ponto mais próximo ao mesmo centróide
- Aloca a instância do conjunto de dados no cluster de centróide mais próximo de acordo com a distância euclidiana.
- Aponta a média dos objetos ou centróides nos clusters. O valor médio das instâncias é usado como centróide em cada cluster Repete a execução dos terceiro e quarto passos até que o mesmo subset de dados faça parte do mesmo cluster consecutivas vezes
- Todos esses passos compreendem o funcionamento do modelo tradicional do k -means, como ilustrado no fluxograma da Figura 2.3. De modo mais aprofundado, se tratando de linhas de código, a Figura 2.4 estabelece um pseudocódigo do funcionamento de um modelo mais tradicional do k -means.

Todos esses passos compreendem o funcionamento do modelo tradicional do k -means, como ilustrado no fluxograma da Figura 2.4. De modo mais aprofundado, se tratando de linhas de código, a Figura 2.4 estabelece um pseudocódigo do funcionamento de um modelo mais tradicional do k -means.

Na primeira etapa do processo de clusterização, quando se trata do estabelecimento do valor de k pode ser difícil identificar um número ótimo de clusters iniciais. Endossado por tal limitação, existem vários métodos, algoritmos, que podem auxiliar no estabelecimento do k inicial como o método de elbow, também conhecido como a curva de elbow. O método trabalha usando a métrica de distância ao utilizar o quadrado da distância entre um subset e seu centróide de modo a determinar uma série de valores para k , como um teste para os melhores valores de k [Afolabi 2023]

Durante o processo de execução, o algoritmo realiza iterações sobre o conjunto de dados considerando diferentes valores de K . A *Soma dos Erros Quadrados* (SSE – *Sum of Squared Errors*) é empregada como métrica de desempenho, sendo utilizada para determinar o número ideal de agrupamentos. Em seguida, constrói-se o gráfico $K \times$ SSE, no qual se observa a relação entre o número de clusters e o erro total. O “ponto de cotovelo” é identificado como o ponto em que ocorre uma mudança significativa na

Figura 2.3: Fluxo dos algoritmos de Machine Learning.



taxa de redução da SSE, indicando o valor de K que oferece o melhor equilíbrio entre compacidade dos grupos e simplicidade do modelo [Afolabi 2023]. Como no exemplo da Figura 2.5.

Quando se trata de aprendizado de máquinas, é preciso considerar o crescimento da presença de algoritmos não supervisionados em problemas práticos do cotidiano e a clusterização é o mais importante entre as técnicas de aprendizado não supervisionado. Ao dividir os dados em subconjuntos, é possível a compreensão de informações que muitas vezes não ficam visíveis e podem ser úteis no processamento de pipeline de dados [Serra-Burriel e Ames 2021].

Ainda, a clusterização é uma técnica que apresenta como dificuldade natural a limitação ao definir um cluster com boas configurações de similaridade em datasets não triviais. Tal limitação não se resume apenas à escolha do algoritmo, mas também das configurações de agrupamento geradas no caso de métodos de agrupamento não determinísticos [Serra-Burriel e Ames 2021].

Figura 2.4: Kmeans Cluster


Algorithm 1 k-means clustering

```

1: Initialise Cluster Centers
2: for each iteration  $l$  do
3:   Compute  $r_{nk}$ :
4:   for each data point  $x_n$  do
5:     Assign each data point to a cluster:
6:     for each cluster  $k$  do
7:       if  $k == \operatorname{argmin} \|x_n - \mu_k^{l-1}\|$  then
8:          $r_{nk} = 1$ 
9:       else
10:         $r_{nk} = 0$ 
11:       end if
12:     end for
13:   end for
14:   for each cluster  $k$  do
15:     Update cluster centers as the mean of each cluster:
16:      $\mu_k^l = \frac{\sum_n r_{nk} x_n}{\sum_n r_{nk}}$ 
17:   end for
18: end for

```

Figura 2.5: Curva de Elbow



Para possibilitar a comparação entre diferentes configurações e que características as compreendem, existem diversos índices de avaliação da qualidade da de clusterização. Cada índice de qualidade quantifica o quão bem uma configuração se conforma a algumas propriedades desejáveis [Serra-Burriel e Ames 2021]. Cada tipo de índice avalia uma configuração ou cenário distinto em relação ao modelo utilizado e o tipo de dado envolvido como se discute nos próximos capítulos desta pesquisa.

2.1.7 K-Mode

K-Mode Algoritmo é mais um exemplo de algoritmo baseado em partição, a execução desta técnica é baseada na transferência de um objeto de um cluster para outro a partir de um determinado ponto. O K-Mode é uma extensão do k-means e usa uma função

de simples de dissimilaridade de correspondência em vez de usar a distância euclidiana. Na técnica de clusterização abordada pelo K-modes, a moda é normalmente usada para representar os centroides ao invés da média em cada iteração do algoritmo [Goyal e Aggarwal 2017].

Em relação à execução do algoritmo, é esperada como entrada o número de cluster que se deseja obter e um conjunto de dados e apresenta como saída o conjunto de clusters, o k-modes é dividido em quatro etapas de funcionamento [Goyal e Aggarwal 2017] como se segue:

- Forma um conjunto de k clusters selecionando objetos arbitrariamente e escolhe um centroide (moda) inicial para cada cluster.
- Faz a assinatura do objeto de dado para o cluster mais próximo calculando por meio do cálculo de moda.
- Atualiza o cluster conforme a alocação dos objetos em cada k e calcula a moda de k mais recente de cada cluster.
- Re-executa os passos dois e três até que a estrutura de cada cluster não se altere mais.

A descrição das etapas de clusterização do k-mode evidencia sua semelhança com o k-means enquanto extensão de tal técnica. Todavia, o k-mode performa bem em cenários de execução com dados categóricos, cenário este que não se aplica muito bem ao k-means. Ainda, o k-mode performa com rapidez e é famoso por sua simplicidade e ser linearmente escalável conforme o conjunto de dados [Goyal e Aggarwal 2017].


De forma geral, a clusterização é performada buscando estabelecer o maior grau de similaridade entre os componentes de cada cluster e o maior nível de dissimilaridade entre clusters distintos. A similaridade ou dissimilaridade entre objetos distintos de mesmo cluster é, geralmente, observada pelas diferenças entre os valores de atributos observados. Em cenários de clusterização, essas diferenças são normalmente observadas com auxílio de métricas de cálculo de distância entre pontos.

Quando se trata do cálculo de distância para construção de clusters, são normalmente usadas as métricas de Minkowski, o que inclui a distância euclidiana e função de Manhattan em casos específicos. Porém, métricas de Minkowski só é aplicável em casos de agrupamento de dados de tipos numéricos, o que cria uma limitação para o agrupamento de dados categóricos.

Apesar dessa limitação, a clusterização de dados categóricos é possível por meio de algoritmos que utilizem outras métricas de distanciamento, como é o caso do k-mode. Neste sentido, as técnicas de similaridade e dissimilaridade são importantes para a garantia da performance de clusterização de atributos categóricos [Zafar e Rani 2021]. De modo genérico, a utilização da similaridade ou dissimilaridade usada para agrupar dados categóricos seguindo o fluxograma da Figura 2.6.

A correspondência simples é a abordagem técnica para comparação entre dois valores de tipo categórico, onde a correspondência idêntica entre dois objetos corresponde a zero (0) uma vez que entre dois atributos diferentes gera um valor um (1). A abordagem técnica de correspondência simples tem sido utilizada em muitos algoritmos de agrupamento categórico o que inclui o k-modes e seus variantes [Zafar e Rani 2021].

Figura 2.6: Fluxograma K-mode



Logo, o k-mode é um algoritmo largamente utilizado para clusterização de atributos categóricos. O algoritmo utiliza a métrica mais adequada para garantir a qualidade do agrupamento. A extensão do k-means se adapta ao cenário de clusterização com dados categóricos, sem a necessidade de transformação de dados ou técnicas de encoding [Huang 1998].

Por fim, com base nas adaptações no modelo base do k-means para formulação do k-mode, o algoritmo performa a clusterização usando (1) uma medida simples de dissimilaridade de correspondência para objetos categóricos, (2) modos em vez de médias para clusters e (3) um método baseado em frequência para atualizar modos no processo de agrupamento de k-means para minimizar a função de custo de agrupamento [Huang 1998].

2.1.8 K-Prototype

Funcionando como uma abordagem mista que pode auxiliar na clusterização de dados categóricos, o algoritmo K-Prototype foi proposto por Huang em 1998 [Huang 1998] e objetiva a alocação de objetos semelhantes e de tipos mistos em cluster [Goyal e Aggarwal 2017]. Mesmo se tratando de uma abordagem para agrupamento de dados mistos, o K-Prototypes [Huang 1998] pode apresentar como limitação a formação de clusters que contenham objetos com similaridade relativamente baixa, em função da combinação das medidas de distância para atributos numéricos e categóricos.

O k-prototype é um método de clusterização que performa melhor em pequenos ou médios conjuntos de dado. Quando se trata de dados em larga escala, a abordagem pode não ser efetiva devido ao alto nível de complexidade computacional, o que requer um total de $n * k$ iterações de cálculo de distância [Hernández et al. 2023].

O K-prototype integra a lógica de clusterização do k-means e a do k-mode para agrupar dados de tipo misto (categóricos e numéricos). Neste sentido, o algoritmo usa a distância euclidiana para e medidas de dissimilaridade. No fluxograma da Figura 6 é possível acompanhar as rotinas de funcionamento do K-prototype e visualizar a aplicação das funções similaridade e dissimilaridade (2) em consonância com o cálculo de distância euclidiana (1)

De modo mais específico, o K-prototype, assim como o k-means e o k-mode, também precisa que o número inicial de clusters estabelecido, e segue a rotina de execução apresentada no algoritmo abaixo [Dake, Gyimah e Buabeng-Andoh 2023]:

- Passo 1: Leitura do conjunto de dados a ser agrupado definindo as variáveis categóricas e numéricas do conjunto.
- Passo 2: Seleciona o número necessário de atributos com base na relevância para a aplicação de cluster.

Figura 2.7: Funções de definição K-prototype

$$\text{Dist}_{qp} = \sqrt{\sum_{i=1}^n (q_i - p_i)^2}. \quad (1)$$

$$D(x_{j,f}, y_{i,f}) = \frac{(m_{x_{j,f}} + m_{y_{i,f}})}{(m_{x_{j,f}} \times m_{y_{i,f}})} \times \delta(x_{j,f}, y_{i,f})$$

and

$$\delta(x_{j,f}, y_{i,f}) = \begin{cases} 0 & \text{if } x_{j,f} = y_{i,f} \\ 1 & \text{if } x_{j,f} \neq y_{i,f} \end{cases}, \quad (2)$$

- Passo 3: Especifique o número de clusters K para iniciar.
- Passo 4: Escolha dos centroides de cada cluster: médias pelo K-means e moda pelo K-modes.
- Passo 5: Faz o cálculo de dissimilaridade para atributos categóricos e calcula a distância para dados numéricos.
- Passo 6: Calcule a distância euclidiana e a diferença de dissimilaridade para cada cluster K e atribua o valor do objeto ao cluster com a menor diferença geral.
- Passo 8: repete os passos 5 e 6 até que a atribuição de objetos esteja completa.
- Passo 9: Após o processo de clusterização, são calculadas a taxa de dissimilaridade para os valores categóricos e a soma dos erros quadrados para os atributos numéricos.
- Passo 10: Retorna o conjunto de dados clusterizado.

Neste sentido, K-prototype objetiva a criação de clusters que diminuam a distância total dentro do cluster. A abordagem utiliza médias para variáveis numéricas e modas para variáveis categóricas e deste modo gera um conjunto inicial de protótipos aleatórios e depois escolhe o protótipo mais próximo com base na distância.

No contexto do K-Prototypes, os protótipos são basicamente representantes de cada cluster. Eles funcionam como “centros” que resumem as características do cluster para os dois tipos de dados. Para variáveis numéricas, o protótipo armazena a média dos valores de todos os pontos do cluster naquela variável e para variáveis categóricas, o protótipo armazena a moda (valor mais frequente) de todos os pontos do cluster naquela variável. Assim, cada protótipo é atualizado a cada iteração até que a distância total dentro de cada cluster seja menor possível [Pasin e Gonenc 2023].

2.1.9 DBSCAN

Outra abordagem de agrupamento discutida nesta pesquisa é a da clusterização baseada em densidade. Density Based Spatial Clustering of Applications with Noise ou DBSCAN, é um algoritmo baseado em densidade que tem como característica a formação de conjuntos de qualquer formato no conjunto de dados. Sendo insensível a ruídos, DBSCAN pode identificar outliers e separá-los do cluster que os contenham.

Ainda, como característica geral, o DBSCAN estabelece maior densidade para cada classe nos resultados da clusterização e que a densidade dentro da classe seja maior do que a densidade na borda da classe(cluster), desta forma, a densidade do ruído é menor que a da borda e a partir das características da distribuição dos dados, o algoritmo utiliza a diferença de densidade para identificar regiões de densidade distinta e marcar os resultados da clusterização.

Em linhas de código, o DBSCAN necessita que o usuário estabeleça os parâmetros globais de distância de vizinhança e de limiar para sua execução. O parâmetro ‘eps’ é o raio do círculo em volta de um ponto, ele define até que ponto o algoritmo deve procurar vizinhos para adicionar ao cluster, logo, a distância da vizinhança define o raio da faixa de vizinhança do ponto amostral.


O limite de procura pode ser alterado quando se altera o número mínimo do de pontos dentro da faixa estabelecida pelo raio de vizinhança a serem marcados como ponto central. Neste sentido, quando um ponto qualquer do conjunto é escolhido, um raio (epsilon) é estabelecido em torno dele, o que estabelece a faixa de vizinhança em volta dele.

A quantidade de pontos incluídas na circunferência estabelecida define o ponto central quando o número de pontos for maior ou igual ao limiar (minPts), levando em consideração que é o número mínimo de vizinhos que um ponto precisa ter dentro desse raio para ser considerado um ponto central (core point), como apresentado na **Figura 2.8**.

A abordagem localiza todos os clusters no conjunto de dados de forma sistemática, ao identificar os core points e expandir cada um deles até que todos os pontos alcançáveis por densidade (density-reachable) sejam incluídos. Quando o processo é iniciado em um ponto arbitrário p , o algoritmo identifica sua vizinhança e, caso esse ponto seja classificado como central (core point), um novo cluster é iniciado.

Quando não há mais core points na vizinhança, a construção daquele agrupamento é encerrada, e os pontos remanescentes são verificados para determinar se algum deles pode originar um novo cluster. Por fim, os pontos que não são atribuídos a nenhum

Figura 2.8: Algoritmo DBSCAN



agrupamento são considerados outliers. [Hahsler, Piekenbrock e Doran 2019] como se segue nas etapas a baixo [Deng 2020]. Definição de parâmetros:

- Definição de parâmetros: O raio mínimo ϵ e o limiar mínimo de densidade $minPts$ são estabelecidos.
- Leitura dos dados: A leitura dos dados é feita de forma sequencial e os dados são armazenados em uma estrutura chamada `pointList` que contem informações sobre cada ponto.
- Determinação do central (core point):
 - Faz a leitura de cada ponto da `pointList` (na ordem) e se o ponto ainda não pertencer a nenhum cluster), então calcula-se a distância entre esse ponto e todos os outros. Quando a distância entre dois pontos for menor ou igual ao raio mínimo, o algoritmo adiciona os dois pontos (sem duplicatas) a um array ou, se a distância for maior, o ponto é ignorado e passa-se para o próximo.
 - Ao fim, se o número total de pontos for maior ou igual ao limiar mínimo, todos os elementos são marcados como agrupados e armazenados como um novo cluster.
 - Se o ponto já estava marcado, ele é ignorado e o processo continua para o próximo.
 - Esse processo é repetido até que todo o conjunto de dados seja percorrido.
- Mesclagem dos clusters: os clusters armazenados são comparados entre si. Se existirem elementos em comum, os clusters correspondentes tornam-se um novo cluster. Esse processo se repete até que nenhum novo cluster seja formado.

- Saída: o algoritmo gera como resultado os clusters formados e os pontos de ruído (que não pertencem a nenhum cluster).

Para facilitar na compreensão dos fatos, a **Figura 2.9** apresenta uma representação da execução do algoritmo em linhas de código.

Figura 2.9: Pseudocódigo DBSCAN

Algorithm 1 DBSCAN

Require: dataset D , adjacent area radius EPS , minimum number of points in the neighborhood $MinPts$

Ensure: Clusters C

```

1: Set all points as unmarked
2: Do
3:   Choose one unmarked points  $X$  randomly
4:   Mark  $X$  as marked
5:   if the number of points in adjacent area radius  $EPS$  of  $X \geq MinPts$  then
6:     Produce a new cluster  $C$  and put  $P$  into  $C$ 
7:     Let  $P$  be the set of points within  $EPS$  of  $X$  neighborhood radius
8:     for  $P$  for each pointx do
9:       if  $x$  is unmarked then
10:        Set  $X$  as marked
11:        if the number of points in  $X$  adjacent area radius  $EPS > MinPts$  then
12:          put them all to  $X$ 
13:          if  $X$  does not belong to any cluster then
14:            Put  $X$  to  $C$ 
15:          end if
16:        end if
17:      end if
18:    end for
19:    Output  $C$ 
20:  else
21:    Marks  $X$  as noise points
22:  end if
23: repeat
24:   Above procedure
25: until there are no unmarked points

```

Tido como uma das abordagens de clusterização baseada em densidade mais citada na literatura), o DBSCAN [Ester et al. 1996] é provavelmente o algoritmo de clusterização baseado em densidade mais utilizado atualmente na comunidade científica e performa a formação teórica de, que mesmo em suas extensões e revisões, os pontos atribuídos ao mesmo cluster sejam alcançáveis por densidade (density-reachable) entre si [Deng 2020].

2.1.10 OPTICS

Outra abordagem algorítmica de clusterização abordada nesta pesquisa é a do Ordering Points To Identify the Clustering Structure, o OPTICS, um algoritmo de agrupamento hierárquico, mas que se baseia em densidade. Semelhante ao DBSCAN, ele usa os conceitos de eps (distância de vizinhança) e minPts (mínimo de pontos) e é capaz de detectar agrupamentos significativos em diferentes densidades, sem exigir que o usuário defina previamente o número de clusters.

Em relação à rotina de funcionamento, o OPTICS inicia o processo incluindo um ponto aleatório do conjunto de dados à lista ordenada e em seguida expande iterativamente o cluster adicionando um ponto dentro da vizinhança- de um ponto do cluster, de modo que este novo ponto esteja o mais próximo possível dos pontos já adicionados. Tal processo funciona como um ciclo que se repete ate que todo o cluster seja incluído na ordem. Deste modo, a abordagem calcula a distância de alcançabilidade (reachability dis-

tance) para cada ponto e uma vez que o raio de alcance de ponto é estabelecido, é possível construir um modelo de alcançabilidade para os agrupamentos 'onde', em tempo linear (PATWARY, 2013). A execução do OPTICS pode ser vista com mais detalhes na **Figura 2.10**

Figura 2.10: Pseudocódigo OPTICS

Algorithm 1 The OPTICS algorithm. Input: A set of points X and the input parameters, generating distance, ε and the minimum number of points required to form a cluster, $minpts$. Output: An order of points, O , the core distances, and the reachability distances.

```

1: procedure OPTICS( $X, \varepsilon, minpts, O$ )
2:    $pos \leftarrow 0$ 
3:   for each unprocessed point  $x \in X$  do
4:     mark  $x$  as processed
5:      $N \leftarrow \text{GETNEIGHBORS}(x, \varepsilon)$ 
6:      $\text{SETCOREDISTANCE}(x, N, \varepsilon, minpts)$ 
7:      $O[pos] \leftarrow x; pos \leftarrow pos + 1$ 
8:      $\text{RD}[x] \leftarrow \text{NULL}$ 
9:     if  $\text{CD}[x] \neq \text{NULL}$  then
10:       $\text{UPDATE}(x, N, Q)$ 
11:      while  $Q \neq \text{empty}$  do
12:         $y \leftarrow \text{EXTRACTMIN}(Q)$ 
13:        mark  $y$  as processed
14:         $N' \leftarrow \text{GETNEIGHBORS}(y, \varepsilon)$ 
15:         $\text{SETCOREDISTANCE}(y, N', \varepsilon, minpts)$ 
16:         $O[pos] \leftarrow y; pos \leftarrow pos + 1$ 
17:        if  $\text{CD}[y] \neq \text{NULL}$  then
18:           $\text{UPDATE}(y, N', Q)$ 

```

Logo, o OPTICS uma abordagem para construção de clusters baseada em densidade hierárquica apresentada por Michael Ankerst, Markus M. Breunig, Hans-Peter Kriegel e Jörg Sander e teve como concepção inicial o uso do DBSCAN e busca sanar uma das maiores limitação do algoritmo base que é a performace com clusters proveniente de dados que possuem densidade variada [Verma et al. 2012].

É neste contexto que o OPTICS ordenada cada ponto do dataset em um conjunto linearmente ordenado e, deste modo, faz com que a aproximação entre pontos mais próximos sejam vizinhos. Ainda, uma distância é armazenada para ponto, o que representa a densidade, a chamada distância de alcançabilidade (reachability distance), que representa a densidade necessária para que dois pontos pertençam ao mesmo cluster. Por este motivo, é necessário que os parâmetros de limite de densidade nos clusters Para tornar o processo eficiente, define-se ainda um limite de densidade mínima, de modo a ignorar clusters que não são considerados relevantes [Verma et al. 2012].

2.1.11 Agglomerative Clustering

Métodos de clusterização hierárquico tem como características a clusterização de dados em duas diferentes direções: bottom-up (aglomerativa) e top-down (divisiva). Mesmo dividindo características comuns em termos conceituais, as abordagens podem demonstrar diferentes soluções aos problemas propostos. De forma geral, a abordagem divisiva é mais robusta nos estágios iniciais em comparação às técnicas de agrupamento aglomerativo que, por sua vez, são mais compreensíveis e mais amplamente utilizados.

O Agglomerative Clustering é um método hierárquico e aglomerativo (bottom-up) de agrupamento. Ele constrói uma árvore de clusters chamada dendrograma, onde cada nível da árvore representa uma fusão entre dois grupos [Tokuda, Comin e Costa 2022].

Em relação à forma como o algoritmo funciona, o processo de clusterização no Agglomerative Clustering segue os passos abaixo [Shetty e Singh 2021]:

- Inicialização: o processo inicia considerando que cada observação do conjunto de dados representa, individualmente, um cluster. Dessa forma, para um conjunto composto por n pontos, são formados inicialmente n clusters distintos, cada um contendo exatamente um elemento. Essa etapa estabelece a base do método aglomerativo, permitindo que a estrutura hierárquica seja construída progressivamente por meio da fusão sucessiva desses clusters elementares.
- Escolha da métrica de distância: Define como será quantificada a “distância” entre pares de pontos ou entre clusters ao longo do processo de agrupamento. Métricas como a distância Euclidiana ou Manhattan são comumente utilizadas, e a seleção da métrica influencia diretamente a forma como a semelhança entre as observações é avaliada e, consequentemente, a estrutura final dos clusters.
- Iterações: Em cada iteração se estabelecem dois clusters mais próximos segundo a métrica + critério de ligação e a partir desses dois clusters, um novo cluster é criado, então esse processo se repete até 1 cluster contendo todos os pontos.
- Formação dos agrupamentos finais

Deste modo, a escolha do critério de formação do cluster por aglomeração define também a forma de agrupamento hierárquico. Tal forma ou critério é, normalmente, baseado em distância entre os clusters. Um exemplo de critério de agrupamento é a abordagem de ligação única, que utiliza como parâmetro a menor distância entre pontos em dois clusters. Outra abordagem, porém, é a da minimização da dispersão dos pontos den-

tro de cada cluster como um critério, o que dá origem a métodos como o agrupamento aglomerativo de Ward [Tokuda, Comin e Costa 2022].

2.1.12 Clusterização hierárquica aglomerativa

Os métodos de **clusterização hierárquica** têm como característica principal a formação de grupos a partir de duas abordagens distintas: *bottom-up* (aglomerativa) e *top-down* (divisiva). Embora compartilhem princípios conceituais semelhantes, essas abordagens podem gerar resultados diferentes dependendo do tipo de dado e do critério de ligação adotado.

De modo geral, a abordagem divisiva tende a ser mais robusta nas etapas iniciais do processo de agrupamento, enquanto a abordagem aglomerativa apresenta maior facilidade de interpretação visual e é a mais amplamente utilizada em aplicações práticas.

O **Agglomerative Clustering** é um algoritmo de natureza hierárquica e aglomerativa (*bottom-up*). Ele constrói uma estrutura em forma de árvore de agrupamentos, chamada **dendrograma**, na qual cada nível representa uma fusão entre dois clusters [Tokuda, Comin e Costa 2022].

De acordo com [Shetty e Singh 2021], o processo de clusterização no Agglomerative Clustering pode ser descrito pelas seguintes etapas:

- **Inicialização:** cada ponto do conjunto de dados é considerado inicialmente como um cluster individual. Assim, se há n observações, há n clusters no início do processo;
- **Escolha da métrica de distância:** define como será medida a distância entre pontos ou clusters. As métricas mais comuns são a distância Euclidiana e a distância Manhattan, embora outras possam ser utilizadas conforme o contexto dos dados;
- **Iterações sucessivas:** a cada iteração, o algoritmo identifica os dois clusters mais próximos de acordo com a métrica de distância e o critério de ligação escolhido. Esses dois clusters são então fundidos, e o processo se repete até restar apenas um único cluster contendo todos os pontos;
- **Formação dos grupos finais:** o resultado final é determinado pela altura de corte do dendrograma, que define o número de grupos desejado. A escolha do critério de ligação influencia diretamente a forma final dos clusters, pois define como é medida a distância entre eles.

Entre os principais critérios de ligação, destaca-se a **ligação simples** (*single linkage*), que considera a menor distância entre os pontos de dois clusters, e o **método de Ward**, que busca minimizar a variância interna dos grupos, resultando em clusters mais compactos e homogêneos [Tokuda, Comin e Costa 2022].

3 TRABALHOS RELACIONADOS

Para a elaboração desta pesquisa, foi realizada uma revisão sistemática de literatura para identificar trabalhos relacionados, onde foram levantados tópicos como objetivos, questões e estratégia de pesquisa, em torno dos conceitos de algoritmos de clusterização não supervisionados e suas aplicações em contextos saúde mental e rendimento acadêmico de estudantes.

A definição das questões de pesquisa auxiliou na identificação de: modelos de Aprendizado de Máquina utilizados para análise da relação entre questões de saúde mental e rendimento acadêmico, para tomada de decisão, os tipos de técnicas que estão sendo empregadas no preparo dos dados, formulação de modelos, métricas de avaliação, tipos de dados utilizados e outras tecnologias envolvidas no processo de clustering analysis, além de trazerem maior clareza a respeito das limitações envolvidas na análise da relação entre o rendimento acadêmico e a saúde mental de estudantes.

3.1 Revisão Sistemática de Literatura

Visando maior clareza a respeito das abordagens de modelos de Aprendizado de Máquina, em especial os não supervisionados, envolvidos no processo de análise da relação entre rendimento acadêmico e questões de saúde mental, foi uma busca na literatura usando uma adaptação da metodologia de desenvolvimento da Revisão Sistemática da Literatura (RSL), contemplando uma série de artigos científicos relacionados ao tema deste trabalho.

Para orientar a condução da pesquisa, foram definidas três questões norteadoras relacionadas ao uso de modelos de aprendizado de máquina no contexto da saúde mental. A RSL foi dividida em três grandes fases: planejamento, condução e apresentação dos resultados.

Na fase de planejamento, etapa fundamental de qualquer revisão sistemática, são definidas as questões de pesquisa que conduzem toda a metodologia adotada [Kitchenham, Mendes e Travassos 2007]. Nessa etapa, estabelecem-se as perguntas de pesquisa e as strings de busca utilizadas nos motores de pesquisa, bem como é realizada a identificação da necessidade da revisão e o desenvolvimento do protocolo de revisão.

As buscas feitas nos motores de pesquisa apresentaram o conjunto de estudos que engloba vários formatos de síntese de pesquisa e diferentes meios de veiculação como

artigos completos, resumos científicos, journals, publicações em revistas científicas. As buscas foram feitas nos bancos de dados da IEEE Xplore³, na base de dados IEEE, a pesquisa foi realizada utilizando a pesquisa de metadados padrão, na base de dados SCOPUS e ACM. Como forma de seleção, foram utilizados diferentes critérios de inclusão e exclusão para a avaliação de qualidade e ponderação tanto da relevância quanto da importância dos estudos para a pesquisa.

De modo geral, é importante destacar que o principal objetivo da revisão sistemática realizada foi identificar estudos primários que relatam modelos de aprendizado de máquina e seu uso em estudos que analisem a relação entre saúde mental e o rendimento acadêmico de estudante e, desta forma, conhecer o estado da arte sobre o assunto estudado.

A RSL serviu como suporte para entender os diferentes tipos de abordagens de avaliação e preparação de dados no estágio de pré-processamento, além das diferentes configurações de conjunto de dados: Volume, tipificação, rotulados ou não rotulados; além das limitações que envolvem o presente ambiente de pesquisa, observando pontos como:

- Identificar modelos de aprendizado de máquinas e suas diferentes abordagens,
- Identificação de métricas conforme o tipo de dado e volume de dados analisado,
- Verificar se há uma análise comparativa dos modelos de Aprendizado de Máquina utilizado,
- Identificar como é feita a análise da correlação entre a saúde mental dos estudantes e seu rendimento acadêmico

3.2 Metodologia da pesquisa

O presente estudo foi desenvolvido na configuração de uma Revisão Sistemática de Literatura e apresenta uma discussão de sínteses de pesquisas relacionadas ao assunto investigado. Neste sentido, o presente trabalho segue a busca de evidências científicas utilizando das diretrizes evidenciadas nos estudos de Petersen et al. (2015) para o desenvolvimento de Mapeamento Sistemático e nas fases de elaboração de Revisão Sistemática de Literatura (RSL) de (Kitchenham Charters, 2007).

Logo, o desenvolvimento da presente RSL seguiu as etapas de (A) planning the review, (B) conducting the review, (C) reporting the review. De modo inicial, para estabe-

lecimento da concepção da ideia de pesquisa, a fase de planejamento compreendeu a (I) identificação das necessidades da pesquisa, (II) especificação das questões de pesquisa e o (III) desenvolvimento do protocolo de revisão.

De modo geral, pode-se destacar como necessidades da pesquisa, os ambientes de busca de dados, as terminologias envolvidas na busca de artigos para análise e demais delimitações que ajudem o estudo a alcançar os seus objetivos. No protocolo de revisão foram elencados os temas para discussão, delimitação das perspectivas da discussão, estratégia de levantamento de estudos primários, objetivos a serem alcançados, e estratégias a serem utilizadas

3.2.1 Questões de pesquisa

Em relação aos questionamentos que norteiam o estudo e de modo a conhecer cenários de aplicação, evidências científicas acerca da computação fog e suas repercussões na agricultura, foram desenvolvidas Questões de Pesquisa (RQ) seguindo o critério PICOC que aborda a Population, Intervention, Comparison, Outcome, Context (Petticrew Roberts, 2008), como descritos na **tabela 3.1**.

Tabela 3.1: Descrição PICOC

Critério	Descrição
Population (População/Problema)	Estudantes e dados relacionados à saúde mental e rendimento acadêmico.
Intervention (Intervenção/Exposição)	Uso de algoritmos de clusterização para analisar a correlação entre saúde mental e desempenho acadêmico.
Comparison (Comparação/Controle)	Comparação entre diferentes técnicas de clusterização (ex.: K-Means, DBSCAN, HDBSCAN, Agglomerative, etc.).
Outcome (Desfechos/-Resultados)	Identificação de padrões, impacto das técnicas utilizadas, classificação de correlações e recomendações para futuras aplicações em contextos educacionais e de saúde.
Context (Contexto)	Pesquisa acadêmica, análise de dados em ambiente educacional e de saúde mental.

As questões de pesquisa integram um papel relevante na pesquisa pois norteiam o desenvolvimento do estudo e estabelecem de maneira mais direta os objetivos da pesquisa. A lista de RQs e seus descritores envolvem:

RQ1: Which clustering algorithms and techniques are being applied to identify patterns and correlations between students' mental health indicators and academic performance?

RQ2: What are the methodological and technical challenges in applying unsupervised clustering algorithms to analyze mental health and academic achievement data?

RQ3: How can the application of clustering techniques contribute to better identification of homogeneous student groups, supporting targeted interventions in mental health and academic support.

Q1 identifica:

- Algoritmos de clusterização e técnicas de mineração de dados aplicadas à análise de saúde mental e desempenho acadêmico.
- Métodos de visualização de padrões e correlações entre variáveis.
- Tipos de dados utilizados, como questionários, registros escolares e métricas psicológicas.
- Flexibilidade e adaptabilidade dos métodos em diferentes contextos estudantis.

Q2 identifica:

- Cenários de aplicação e limitações das técnicas de clusterização.
- Métricas de avaliação de desempenho dos algoritmos, como silhouette, Davies-Bouldin, precisão e recall.
- Comparação com técnicas estatísticas ou de aprendizado supervisionado.
- Eficiência computacional e escalabilidade dos métodos.

Q3 identifica:

- Barreiras técnicas, como volume, variedade e qualidade dos dados e complexidade computacional.
- Impacto de vieses e variabilidade nos resultados.
- Limitações de generalização entre diferentes populações de estudantes.

3.2.2 Desenvolvimento da estratégia de pesquisa

Na fase de condução são desenvolvidas as estratégias de condução que evidenciam a necessidade de (I) identificação da pesquisa, (II) Seleção de estudos, (III) extração de dados. Neste sentido, nesta etapa foi estabelecida a estratégia de pesquisa que identificou estudos primários para maior compreensão do assunto abordado.

Além da identificação de outras revisões de literatura, a elaboração de uma lista de descritores – palavras-chave, e seus respectivos sinônimos para serem usados na busca do acervo de literatura sobre o tema de pesquisa. Deste modo, a busca de estudos foi feita nas bases de dados ACM Digital Library¹, IEEE Xplore², e SCOPUS³ que são bases de dados da área de ciência da computação e engenharia e elencou estudos sobre algoritmos de clusterização não supervisionados e suas implicações na análise de dados educacionais em contextos de saúde mental e rendimento acadêmico.

As bases de dados selecionadas são reconhecidas por sua relevância no meio acadêmico e cada uma delas possui características específicas de busca, o que motivou a definição de uma “string de busca” adequada a cada motor de busca.

Nesta pesquisa, a busca foi construída a partir dos descritores e sinônimos relacionados à saúde mental e ao desempenho acadêmico de estudantes. Os principais descritores utilizados foram: “mental health”, “academic performance”, “student achievement” e “clustering analysis”.

A partir desses termos, foram elaboradas as strings de busca que permitiram a coleta estruturada das informações relevantes nas bases de dados. As strings de busca foram especificadas a partir da generalização:

(“mental health” and “academic performance” or “student performance” and “clustering analysis”).

Tabela 3.2: Strings de busca utilizadas nas bases de dados ACM/IEEE e Scopus

Base de Dados	String de Busca
ACM / IEEE	("All Metadata":Mental Health Of Students) AND ("All Metadata":academic performance) OR ("All Metadata":student performance) AND ("All Metadata":clustering algorithm) OR ("All Metadata":clustering analysis) AND ("All Metadata":comparative study)
SCOPUS	ALL ("clustering analysis") AND ALL ("mental health"OR "psychological issue*") AND ALL ("academic performance"OR "student* performance")

Diferentes formas de pesquisas foram usadas para a busca tendo em vista as características de montagem da busca avançada em cada uma das bases usando a combinação de operadores lógicos como “AND”, “OR” e “NOT”, na combinação dos sinônimos preestabelecidos.

Visando selecionar um grupo de estudos que tratassem do tema investigado, quando o motor de busca disponibilizava a delimitação de áreas de conhecimento e tipos de pesquisa, os campos foram dados como ciência da computação e engenharias e relacionados

diretamente a saúde mental e rendimento acadêmico, com palavras-chave como “unsupervised learning, clustering analysis, mental health, academic performance ” também setados na plataforma de busca.

O objetivo foi não envolver assuntos que pudessem tratar de educação e saúde mental sob outras formas de discussão. De modo geral, as buscas também tinham como delimitadores a coleta estudos que publicados em jornais e revistas de veiculação científica, com foco em ciência ou engenharia da computação a partir do ano de 2020.

Nas bases de dados ACM e IEEE, as delimitações de ano e área do conhecimento eram estabelecidas em campos para marcação ou preenchimento no próprio motor de busca. Os resultados foram exportados através do BibTex que foi utilizado na etapa de seleção de estudos. Os resultados da busca somam um total de 499 artigos, que por base de dados são dados em 40 resultados da base ACM, 377 NA IEEE, 82 na base SCOPUS

O objetivo foi não envolver assuntos que pudessem tratar de educação e saúde mental sob outras formas de discussão. De modo geral, as buscas também tinham como delimitadores a coleta de estudos publicados em jornais e revistas de veiculação científica, com foco em ciência ou engenharia da computação a partir do ano de 2019.

3.2.3 Seleção de estudos

Na etapa de seleção de estudos, foram estabelecidos os critérios de inclusão (IC) e exclusão (EC), de modo que o grupo de estudos selecionado pudesse responder às questões de pesquisa e aproximar o estudo de seus objetivos. Os critérios de inclusão focam na identificação de estudos que atendam às necessidades estabelecidas e se mostrem mais relevantes para a perspectiva dos pesquisadores. Para a classificação dos estudos nos IC ou EC foram analisados os resumos, título e palavras-chave. Neste sentido, o conjunto de critérios estabelecido foi:

3.2.3.1 Critérios de inclusão

Critérios de Inclusão (IC):

- **IC1:** Os resultados devem estar no idioma inglês ou português.
- **IC2:** Os resultados devem conter as palavras da string de busca no título, palavras-chave ou resumo.
- **IC3:** O resultado deve estar na área de engenharia ou ciência da computação.

- **IC5:** O estudo deve ser publicado em revistas acadêmicas ou conferências.
- **IC6:** O estudo deve ser um artigo completo.
- **IC7:** O resultado deve estar disponível na íntegra e disponível gratuitamente.

3.2.4 Critérios de exclusão

Como forma de eliminar ruídos, os critérios de exclusão foram estabelecidos para garantir a presença de artigos não teóricos ou de revisão, publicados em língua inglesa ou portuguesa, e remover estudos que abordassem as palavras-chave ou sinônimos definidos, mas que não apresentassem o tipo de discussão adequado ao viés da pesquisa.

Critérios de Exclusão (EC):

- **EC1:** Artigos com idiomas diferentes do inglês e do português.
- **EC2:** No caso de estudos semelhantes ou duplicados, apenas o mais recente será considerado.
- **EC3:** Trabalhos não relacionados ao tema e ao objetivo proposto na pesquisa.
- **EC4:** Publicações sem um resumo (*abstract*).
- **EC5:** Artigos muito curtos (com 3 ou 4 páginas apenas).

3.2.5 Extração de dados

Esta etapa apresenta a seleção sistemática dos dados coletados nas bases de dados, usando dos critérios de inclusão e exclusão para a filtragem de artigos mais relevantes entre os estudos levantados. Para auxiliar na execução desta etapa, foi utilizada a ferramenta Start que automatizou a exibição das informações e seleção de artigos. Inicialmente, o protocolo de revisão foi elaborado na ferramenta e nele foram descritos os objetivos, questões de pesquisa, sinônimos de palavras-chave, critérios de seleção, que formam a fase de planejamento.

Após a formulação do protocolo na ferramenta, os dados extraídos das bases de dados foram importados para a StArt conforme a Sting de busca e os resultados de cada motor de busca. Os dados extraídos das bases de dados foram exportados em formato BibTex (.bib), contudo a plataforma aceita outros formatos de exportação como Medline, Ris, Cochrane. Mesmo importados de maneiras separadas, os dados de todas as bases são

exibidos em uma única lista que possibilita aos pesquisadores a classificação de artigos usando os critérios de seleção e a classificação do estudo quanto a sua relevância de muito pouco até muito relevante.

Na lista de seleção, a ferramenta de apoio sugere além da prioridade, conforme o número de incidências de palavras-chave, o score de artigos, o que pode facilitar na seleção inicial. Tendo em vista a separação da etapa de seleção em “seleção e extração”, a etapa inicial elenca todos os artigos coletados nos motores de busca e conforme as informações como título, palavras-chave e resumo são selecionadas classificadas em “incluídas” ou “excluídas”, vale ressaltar que as métricas de seleção são os critérios definidos no planejamento e condução.

3.2.6 Resultados

Abordando as questões de pesquisa e apresentando interesses de pesquisa relacionados ao uso de algoritmos de clusterização em cenários de saúde mental de estudantes e rendimento acadêmico, este tópico detalha os resultados sistemáticos da Revisão da Literatura sobre o assunto pesquisado. Foram abordadas três questões de pesquisa (Q1, Q2 e Q3), e neste tópico será apresentada uma discussão dos artigos na Tabela 3.3.

A revisão sistemática da literatura buscou identificar características e abordagens computacionais voltadas à análise da relação entre saúde mental e desempenho acadêmico de estudantes, com ênfase no uso de técnicas de clusterização, aprendizado não supervisionado e modelagem de dados comportamentais. Os estudos selecionados exploram diferentes métodos algorítmicos, incluindo K-Means, DBSCAN, Fuzzy C-Means, K-Medoids e HSNMF, aplicados em bases educacionais e psicológicas.

Além disso, destacam-se contribuições recentes que combinam inteligência artificial e aprendizado de máquina para detectar padrões ocultos de comportamento, engajamento e bem-estar emocional em contextos acadêmicos. Dessa forma, esta revisão procura compreender como as técnicas de análise de dados e clusterização têm sido utilizadas para revelar correlações entre o estado psicológico dos estudantes e seu rendimento acadêmico, apontando avanços, limitações e tendências metodológicas relevantes para a área.

Embora cada estudo apresente resultados satisfatórios em seu contexto, poucos realizam comparações diretas entre diferentes algoritmos de clusterização, limitando a

Tabela 3.3: Artigos selecionados

Autor(es)	Título do Artigo	Ano	Algoritmo(s) de Clusterização
Zhang et al.	Application of K-Means Clustering Algorithm in Analyzing College Students' Mental Health	2022	K-Means
Rahim et al.	Analyzing Factors of Mental Health Problems among Malaysian University Students using Clustering Analysis	2023	K-Means, Hierarchical
Li et al.	AI-Driven Analysis of Student Psychological Traits and Their Impact on Academic Performance	2024	K-Means, DBSCAN
Singh & Kumar	Data Analysis on Students' Performance Based on Health Status using Genetic Algorithm and Clustering Algorithms	2023	Genetic Algorithm + K-Means
Thiru Radhakrishnan et al.	Detection of Behavioral Health Challenges in High School Students	2024	Deep Encoder + K-Means
Davide Porello et al.	Early Detection of Mental and Behavioral Health Issues from High-School Academic Performance	2023	DBSCAN + Spectral
Lei Lu	A Comprehensive Study on the Relationship between User Experience of Mobile Learning Platforms and Academic Anxiety among College Students	2025	K-Medoids (Incremental Centroids)
Ma & Liu	HSNMF enables accurate and effective analysis for the college students' psychological health education data and student life data	2025	HSNMF (Hypergraph Semi-orthogonal Nonnegative Matrix Factorization)
Haiyan Han	Fuzzy Clustering Algorithm for University Students' Psychological Fitness and Performance Detection	2023	Heuristic Fuzzy C-Means (HFCA)
Haiyan Ji	Psychological Analysis Using Artificial Intelligence Algorithms of Online Course Learning of College Students During COVID-19	2024	K-Means

análise a uma única abordagem ou métrica de avaliação. Nesse sentido, nota-se uma lacuna importante na literatura: a falta de estudos comparativos.

Nas publicações apresentadas e selecionadas, observam-se conceitos relacionados ao Aprendizado de Máquina e Análise Estatística, aplicados ao estudo da saúde mental e do rendimento acadêmico de estudantes. A maioria dos trabalhos faz uso de técnicas de clusterização para identificar padrões de comportamento e correlações entre fatores

psicológicos (como ansiedade, estresse e engajamento) e o desempenho escolar ou universitário.

Embora diversos artigos mencionem o uso de linguagens e ferramentas computacionais como Python, Scikit-Learn e TensorFlow, poucos detalham a adoção de infraestruturas de Big Data ou de ambientes distribuídos para o processamento das bases utilizadas. De modo geral, os estudos concentram-se em aspectos metodológicos, explorando algoritmos como K-Means, DBSCAN, Fuzzy C-Means, HSNMF e K-Medoids, com o objetivo de aprimorar a precisão e a interpretabilidade dos agrupamentos.

Em trabalhos mais recentes, observa-se uma tendência voltada à avaliação comparativa do desempenho relativo dos principais algoritmos quando aplicados a conjuntos de dados educacionais que combinam variáveis acadêmicas e psicológicas, buscando compreender de forma mais ampla os fatores que influenciam o comportamento e o desempenho dos estudantes.

Assim, o presente trabalho busca preencher essa lacuna, propondo uma comparação entre múltiplos modelos de clusterização, avaliando-os sob critérios de eficácia, interpretabilidade e robustez na segmentação de estudantes segundo desempenho acadêmico e indicadores emocionais.

Essa análise permitirá compreender quais algoritmos apresentam melhor adequação a esse tipo de dado e quais métricas (internas ou externas) melhor refletem a qualidade dos agrupamentos no contexto educacional. Em relação à avaliação feita nos estudos, o conjunto de métricas abordas em ada estudo está destacada na tabela 3.4

Tabela 3.4: Métricas de avaliação utilizadas nos estudos analisados

Nº	Autor(es)	Métrica(s) de Avaliação
1	Liu et al. (2024a)	Silhouette Coefficient
2	Isa et al.	Davies–Bouldin Index (DBI), Calinski–Harabasz Index (CHI)
3	Liu et al. (2024b)	Silhouette Score, Adjusted Rand Index (ARI)
4	V.Preetha	Silhouette Score
5	Thiru Radhakrishnan et al.	Clustering Loss (intra/inter-cluster distance), F1-Score
6	Davide Porello et al.	Precision, Recall, F1-Score
7	Lei Lu	Variance, Euclidean Distance, Cluster Compactness
8	Ma & Liu	Silhouette Coefficient, Calinski–Harabasz (CHI), Davies–Bouldin Index (DBI)
9	Haiyan Han	Accuracy, Engagement Ratio, Prediction Ratio
10	Haiyan Ji	Sum of Squared Errors (SSE), Euclidean / Manhattan Distances

Com base nas observações levantadas na revisão, algumas observações sobre as métricas de desempenho algorítmico foram levantadas, como se segue:

- Variabilidade das métricas de avaliação entre estudos (Silhouette, DBI, CHI, ARI);
- Escassez de experimentos comparativos entre algoritmos no mesmo conjunto de dados;
- Falta de integração entre variáveis psicológicas (ansiedade, engajamento) e acadêmicas (notas, frequência) em um mesmo modelo de clusterização;
- Limitações na reprodutibilidade, devido à ausência de bases de dados públicas e replicáveis;
- Reduzida atenção à interpretação prática dos clusters sob a ótica da psicologia educacional.

Ainda que as métricas utilizadas variem entre os estudos, nota-se uma maior ênfase em abordagens baseadas em Silhouette Coefficient, Calinski–Harabasz (CHI) e Davies–Bouldin (DBI), as quais avaliam a compactação e separabilidade dos agrupamentos. A predominância de métricas internas de avaliação da qualidade dos agrupamentos centradas na avaliação da compactação e separabilidade dos clusters, apresentam maior pertinência para estudos que não dispõem de rótulos ou variáveis externas de validação, sendo particularmente adequadas em contextos não supervisionados, como os do presente estudo.

Para conhecer o estado da arte relacionado ao uso de algoritmos de clusterização no contexto da relação da saúde mental e o rendimento acadêmico, a Tabela 3.5 elenca fatores relacionados aos aspectos metodológicos dos estudos selecionados na revisão de literatura. O conjunto de trabalhos evidencia abordagens de clusterização, métricas aplicadas para avaliação dos modelos.

Além disso, são apresentados elementos relacionados aos tipos de dados empregados e ao uso de técnicas de clusterização em dados acadêmicos. A síntese apresenta uma visão integrada da literatura recente, permitindo identificar tendências, semelhanças e lacunas no estado da arte relacionado a saúde mental, desempenho acadêmico e o uso de aprendizado de máquina neste contexto.

Tabela 3.5: Síntese comparativa dos estudos selecionados

Publicação	Ano	Autor(es)	Clusterização	Métricas Internas	Métricas Externas	Análise Comparativa	Avaliação de Algoritmos	Dados Acadêmicos	Dados Psicológicos / Emocionais	Deep Learning	Fuzzy / Heurístico	Genetic Algorithm	Interpretação Psicológica	Aplicação Educacional
Application of K-Means Clustering Algorithm in Analyzing College Students' Mental Health	2022	Liu <i>et al.</i>	X	X	—	—	X	X	X	—	—	—	X	X
Analyzing Factors of Mental Health Problems among Malaysian University Students using Clustering Analysis	2022	Isa <i>et al.</i>	X	X	—	—	X	X	X	—	—	—	X	X
AI-Driven Analysis of Student Psychological Traits and Their Impact on Academic Performance	2024	Liu <i>et al.</i>	X	X	X	X	X	X	X	—	—	—	X	X
Data Analysis on Students' Performance Based on Health Status using Genetic Algorithm and Clustering Algorithms	2023	V.Preetha <i>et al.</i>	X	X	—	X	X	X	X	—	—	X	X	X
Detection of Behavioral Health Challenges in High School Students	2024	Radhakrishnan <i>et al.</i>	X	X	X	X	X	X	X	X	—	—	X	X
Early Detection of Mental and Behavioral Health Issues from High-School Academic Performance	2023	Porello <i>et al.</i>	X	X	X	X	X	X	X	X	—	—	X	X
HSNMF enables accurate and effective analysis for the college students' psychological health education data and student life data	2025	Ma & Liu	X	X	—	X	X	X	X	—	—	—	X	X
Fuzzy Clustering Algorithm for University Students' Psychological Fitness and Performance Detection	2023	Han	X	X	X	X	X	X	X	—	X	—	X	X
A Comprehensive Study on the Relationship between User Experience of Mobile Learning Platforms and Academic Anxiety among College Students	2025	Lu	X	X	—	—	—	X	X	—	—	—	X	X
Psychological Analysis Using Artificial Intelligence Algorithms of Online Course Learning of College Students During COVID-19	2024	Ji	X	X	—	—	—	X	X	—	—	—	X	X

3.2.7 Modelos de Clusterização

O artigo de [Liu et al. 2024] apresenta um modelo de análise da saúde mental de estudantes universitários utilizando o algoritmo K-Means. O estudo busca agrupar estudantes com base em indicadores emocionais e acadêmicos, como níveis de estresse, satisfação e desempenho escolar. Os autores demonstram que a técnica permite visualizar padrões de comportamento psicológico entre grupos de alunos, mas apontam como limitação a sensibilidade à escolha inicial dos centróides e a ausência de uma comparação com outros algoritmos de clusterização.

No estudo conduzido por [Isa et al. 2022] Os pesquisadores empregam o K-Means e Hierarchical Clustering para identificar fatores de risco de saúde mental entre universitários da Malásia. O estudo aplica métricas internas, como Davies–Bouldin Index (DBI) e Calinski–Harabasz Index (CHI), para avaliar a qualidade dos agrupamentos. Apesar de utilizar mais de um algoritmo, o trabalho não compara diretamente seus desempenhos, servindo apenas como análise descritiva. Ainda assim, evidencia que estudantes com altos níveis de ansiedade apresentam queda significativa no rendimento acadêmico.

Na pesquisa de [Liu et al. 2024], os autores propõem uma abordagem híbrida de aprendizado não supervisionado, combinando K-Means e DBSCAN para agrupar estudantes de acordo com traços psicológicos e desempenho acadêmico. O modelo é avaliado com métricas internas (Silhouette) e externas (Adjusted Rand Index – ARI), o que permite uma análise mais robusta da qualidade dos clusters. Os autores destacam que a integração de diferentes métodos melhora a coerência dos agrupamentos, mostrando o potencial da análise comparativa entre algoritmos.

Outro exemplo de aplicação de aplicação de modelos não supervisionados em cenários saúde mental e desempenho acadêmico é o estudo de [Preetha 2021], que propõe uma estratégia híbrida que integra Algoritmos Genéticos ao K-Means para otimizar o processo de agrupamento de dados relacionados à saúde e ao desempenho dos estudantes. Essa integração visa resolver o problema de convergência prematura e sensibilidade à inicialização. O artigo realiza uma comparação experimental entre o método híbrido e o K-Means tradicional, mostrando ganhos em eficiência e estabilidade, embora o custo computacional aumente.

Outra contribuição relevante para o conhecimento do presente estado da arte, é o estudo de [Radhakrishnan et al. 2024], que apresenta um modelo de Deep Clustering, combinando redes neurais convolucionais (CNN) com K-Means, aplicado à detecção de problemas comportamentais em estudantes do ensino médio. O modelo aprende representações latentes de características psicológicas e acadêmicas antes de realizar o agrupamento. Os autores utilizam métricas como F1-score e distância intra/inter-cluster para validar os resultados, obtendo desempenho de 93% de acurácia. Apesar dos bons resultados, o estudo ressalta a necessidade de validação cruzada com bases maiores.

De forma semelhante, [Porello et al. 2023] utiliza DBSCAN, Spectral Clustering e PCA para analisar dados temporais de desempenho e comportamento estudantil, identificando perfis “estáveis”, “em risco” e “críticos”.

O estudo realiza uma análise comparativa entre os métodos, utilizando Precision, Recall e F1-score como métricas de avaliação. Os resultados mostram, que o Spectral Clustering apresentou melhor equilíbrio entre precisão e generalização. O estudo de [Ma e Liu 2025] apresenta um modelo avançado de fatoração matricial chamado HSNMF (Hypergraph Semi-orthogonal Nonnegative Matrix Factorization), aplicado a dados de saúde psicológica e vida acadêmica de estudantes.

O modelo permite identificar relações de alta ordem entre variáveis e agrupar indivíduos com padrões emocionais semelhantes. Foram utilizadas métricas internas (Silhouette, CHI e DBI) para avaliar o desempenho do modelo, demonstrando melhores resultados em comparação a métodos convencionais de NMF e clusterização espectral.

A utilização do Heuristic Fuzzy C-Means (HFCA), como uma variação do algoritmo Fuzzy C-Means aplicada à análise de aptidão psicológica e desempenho acadêmico, é proposta por [Han 2023]. O modelo introduz heurísticas para ajustar dinamicamente o grau de pertinência dos clusters, o que melhora a estabilidade e a precisão. O estudo compara o HFCA com versões tradicionais do FCM, apresentando métricas de acurácia e engajamento superiores a 96%, embora o método exija maior tempo de processamento.

Na análise feita por [Lu 2025], a observação é conduzida com base na relação entre experiência do usuário (UX) em plataformas móveis de aprendizagem e ansiedade utilizando o algoritmo K-Medoids. O modelo se baseia em distâncias e variâncias internas para definir agrupamentos, permitindo compreender como fatores de interface e design influenciam o estresse e a motivação dos alunos. Apesar de eficiente para dados categóricos, o estudo não compara o desempenho do K-Medoids com outros algoritmos.

Por fim, [Ji 2024] investiga o impacto psicológico do ensino remoto durante a pandemia de COVID-19 aplicando o K-Means a dados coletados por questionários.

Foram utilizados critérios de erro quadrático médio (SSE) e distância euclidiana para formar os agrupamentos. O estudo identificou clusters que refletem diferentes níveis de estresse e adaptação ao ensino online, sugerindo que alunos com maior isolamento social tendem a apresentar desempenho inferior.

3.2.8 Desafios e Limitações Identificados

Apesar dos avanços apresentados nas publicações analisadas, ainda persistem barreiras técnicas e conceituais que impactam a eficácia dos modelos de clusterização aplicados à análise de saúde mental e desempenho acadêmico.

A primeira barreira está associada ao volume, variedade e qualidade dos dados utilizados. Grande parte dos estudos baseia-se em amostras pequenas, homogêneas e autorrelatadas, o que reduz a robustez estatística dos resultados. A ausência de bases de dados padronizadas e abertas impede a reprodutibilidade e dificulta comparações diretas entre métodos.

Além disso, o aumento do número de variáveis comportamentais e psicológicas eleva significativamente a complexidade computacional dos algoritmos, especialmente em modelos híbridos ou baseados em Deep Learning. Essa complexidade pode comprometer a escalabilidade e a eficiência quando aplicados a grandes populações estudantis.

Outro desafio importante é o impacto de vieses e da variabilidade dos dados sobre os resultados. Como muitos estudos dependem de questionários subjetivos e autodeclarações, há risco de distorções nas respostas e inconsistências entre grupos.

Além disso, diferenças culturais, socioeconômicas e de contexto educacional influenciam as variáveis psicológicas analisadas, introduzindo possível viés amostral e comprometendo a validade externa dos modelos.

Mesmo algoritmos robustos, como HSNMF e HFCA, podem gerar agrupamentos artificialmente homogêneos se os dados de entrada refletirem vieses de coleta ou amostragem.

Por fim, as pesquisas enfrentam limitações de generalização entre diferentes populações estudantis. Modelos treinados em amostras locais, frequentemente restritas a uma única instituição ou país, apresentam baixa transferibilidade para outros contextos.

Fatores como idioma, carga horária, metodologia de ensino e diferenças culturais afetam diretamente o comportamento emocional e o desempenho acadêmico, tornando os resultados contexto-dependentes.

Essa limitação reforça a necessidade de novos estudos que utilizem bases multiculturais e multidimensionais, integrando dados de diferentes fontes (acadêmicos, psicológicos e digitais) para ampliar a validade dos modelos e reduzir o risco de generalizações indevidas.

Em síntese, os estudos revisados apontam avanços significativos, mas revelam que a eficácia dos modelos de clusterização depende fortemente da qualidade e diversidade dos dados, da mitigação de vieses e da capacidade de generalização dos resultados. Superar essas barreiras é essencial para o desenvolvimento de sistemas mais confiáveis, interpretáveis e aplicáveis à análise da relação entre saúde mental e desempenho acadêmico.

3.3 Considerações Sobre o Capítulo

Neste capítulo foi evidenciado o estado da arte relacionado à aplicação de modelos de clusterização na análise da saúde mental e do desempenho acadêmico de estudantes. Por meio de uma revisão sistemática de literatura, foram descritas as abordagens utilizadas, os algoritmos empregados e as métricas de avaliação aplicadas para medir a qualidade dos agrupamentos.

Tabela 3.6: Comparação entre trabalhos relacionados e a dissertação

Autores	Clust.	Métr. Int.	Comp. Alg.	Dados Psic.	Dados Acad.	Deep Learn.	GA/Fuzzy	Prot. Comp. Sist.
Liu et al. (2022)	S	S	N	S	N	N	N	N
Isa et al. (2022)	S	N	N	S	N	N	N	N
Liu et al. (2024)	S	S	S	S	S	S	N	N
Preetha (2023)	S	S	N	S	S	N	S	N
Radhakrishnan et al. (2024)	N	N	N	S	S	S	N	N
Porello et al. (2023)	S	N	N	S	S	N	N	N
Lu (2025)	S	S	N	S	S	N	N	N
Ma & Liu (2025)	S	S	N	S	S	N	N	N
Han (2023)	S	N	N	S	N	N	S	N
Ji (2024)	S	N	N	S	S	S	N	N
Dissertação	S	S	S	S	S	N	N	S

4 METODOLOGIA

Para atingir os objetivos da pesquisa, a avaliação de modelos de Machine Learning não supervisionados, no contexto da relação entre saúde mental e rendimento acadêmico, foi focada na análise comparativa do desempenho entre diferentes tipos de algoritmos de clusterização de diferentes categorias, tais como Clusterização Baseada em Centroides, Clusterização baseada em Densidades, Clusterização baseada em Distribuições e Clusterização Hierárquica.

Além da avaliação dos algoritmos, a presente proposta é baseada no levantamento bibliográfico e na análise de trabalhos relacionados para construção do conhecimento do estado da arte do problema proposto. O modelo geral de desenvolvimento da pesquisa segue as etapas de levantamento de dados, o restabelecimento de métricas para avaliação e comparação dos algoritmos segundo as métricas estabelecidas como destacado na discussão a seguir.

4.1 Levantamento de dados

Tendo em vista restrições éticas relacionadas à pesquisa científica no Brasil, a presente pesquisa será baseada no uso de datasets públicos disponibilizados em bases de dados online. Tendo em vista os objetivos da pesquisa, foram utilizados três datasets que contêm informações de estudantes como gênero e idade e dados sobre a rotina de estudos e indicadores de saúde mental.

O primeiro dataset analisado contém informações sobre 352 estudantes dos Estados Unidos sobre gênero, idade, nível educacional, rotina de estudos, condição de saúde mental e rendimento acadêmico (notas); os dados estão disponíveis na base Kaggle e contêm 18 variáveis observadas (Tabela 4.2).

O segundo dataset é disponibilizado no Mendeley Data e faz parte da pesquisa “Dataset of Jordanian university students’ psychological health impacted by using e-learning tools during COVID-19” que foi publicada em 2020 e contém informação sobre 775 estudantes acerca de impactos na saúde mental, informações sociodemográficas, idade, gênero e médias de notas de disciplinas durante a pandemia (Tabela 4.1).

O terceiro conjunto de dados partiu de uma pesquisa da International Islamic University Malaysia; o dataset foi base para o estudo “Fuzzy clustering algorithm for university students’ psychological fitness and performance detection”. Tratando-se de um

estudo baseado em saúde mental e rendimento acadêmico, contém informação de 885 estudantes e está disponível no Kaggle (Tabela 4.3).

Após a extração dos dados nas bases indicadas, a execução dos algoritmos e das técnicas de pré-processamento, foi realizada em ambiente Jupyter Notebook hospedado na nuvem, por meio da plataforma Google Colab, onde os códigos foram estruturados em células.

A plataforma oferece suporte à manipulação de dados em linguagem Python, além de permitir o uso de outras linguagens, com integração facilitada a GPUs e TPUs para aceleração do processamento. Essas características motivaram a escolha do Google Colab como ferramenta de apoio ao desenvolvimento dos experimentos da pesquisa. Adicionalmente, a plataforma é gratuita para uso básico e possibilita o armazenamento dos notebooks diretamente no Google Drive, o que favorece a acessibilidade e a continuidade dos trabalhos.

4.1.1 Dicionário de Dados

O dicionário de dados foi elaborado com o objetivo de padronizar a interpretação das variáveis presentes no dataset utilizado na pesquisa. As variáveis foram categorizadas conforme sua natureza, permitindo maior organização no processo de tratamento e análise dos dados.

Tabela 4.1: Dataset of Jordanian university students

Campo	Descrição	Tipo de dado	Categoria	Valores possíveis
ID	Identificador único do respondente	Inteiro	Identificação	1, 2, 3...
Start time	Data e hora de início do questionário	Data/Hora	Controle de coleta	Timestamp
Completion time	Data e hora de conclusão do questionário	Data/Hora	Controle de coleta	Timestamp
Email	Endereço de e-mail do participante	Texto	Identificação	Texto
Name	Nome do participante	Texto	Identificação	Texto
Gender	Gênero do respondente	Categórico	Sociodemográfico	Male, Female, Other
Level/Year	Ano/período acadêmico do estudante	Categórico	Acadêmico	Freshman, Sophomore, Junior...
Age	Faixa etária do respondente	Categórico	Sociodemográfico	18-24, +30...
Your cumulative average (GPA)	Média acadêmica acumulada do estudante	Categórico	Acadêmico	70-79, 80-89, +90
Before COVID-19: Which of the following digital tools do you usually use?	Ferramenta digital utilizada antes da pandemia	Categórico	Tecnológico	Mobile phone, Laptop, Other
Staying home for long periods of time leads to lethargy and laziness.	Percepção sobre efeitos do isolamento prolongado	Categórico	Psicossocial	Strongly Disagree, Disagree, Uncertain, Agree, Strongly Agree
Prolonged use of e-learning tools often leads to boredom, nervousness, and tension.	Percepção sobre desgaste emocional do ensino remoto	Categórico	Psicossocial	Strongly Disagree, Disagree, Uncertain, Agree, Strongly Agree
The psychological element is a key factor in the success of the educational process.	Importância do fator psicológico no processo educacional	Categórico	Educacional	Strongly Disagree, Disagree, Uncertain, Agree, Strongly Agree

Tabela 4.2: Estudantes Estados Unidos

Campo	Descrição	Tipo de dado	Categoria	Valores possíveis
Gender	Gênero do respondente	Catégorico	Sociodemográfico	Male, Female
Age	Faixa etária do participante	Catégorico	Sociodemográfico	18 years or less, 19 to 24 years
Educational Level	Nível educacional do participante	Catégorico	Acadêmico	High School, College - Bachelor's
Little interest or pleasure in doing things	Frequência de falta de interesse ou prazer nas atividades	Inteiro	Saúde mental	0, 1, 2, 3, 4
Feeling down, depressed, or hopeless	Frequência de sentimentos depressivos ou desesperança	Inteiro	Saúde mental	0, 1, 2, 3, 4
Trouble falling or staying asleep, or sleeping too much	Problemas relacionados ao sono	Inteiro	Saúde mental	0, 1, 2, 3, 4
Feeling tired or having little energy	Frequência de fadiga ou baixa energia	Inteiro	Saúde mental	0, 1, 2, 3, 4
Poor appetite or overeating	Alterações de apetite ou alimentação excessiva	Inteiro	Saúde mental	0, 1, 2, 3, 4
Feeling bad about yourself or that you are a failure or not have let yourself or your family down	Percepção negativa sobre si mesmo ou sentimento de fracasso	Inteiro	Saúde mental	0, 1, 2, 3, 4
Trouble concentrating on things, such as reading the newspaper or watching television	Dificuldade de concentração em atividades cotidianas	Inteiro	Saúde mental	0, 1, 2, 3, 4
Moving or speaking so slowly that other people could have noticed Or being so restless that you have been moving around a lot more than usual	Alterações psicomotoras percebidas pelo participante	Inteiro	Saúde mental	0, 1, 2, 3, 4
Thoughts that you would be better off dead or of hurting yourself in some way	Pensamentos autodestrutivos ou de automutilação	Inteiro	Saúde mental	0, 1, 2, 3, 4
Do you have part-time or full-time job?	Situação de trabalho do participante	Catégorico	Socioeconômico	No, Part time, Full time
Which of the following best describes your term-time accommodation?	Tipo de acomodação durante o período letivo	Catégorico	Socioeconômico	Home (with parents), University hall of residence
How many hours do you spend studying each day?	Quantidade média de horas de estudo por dia	Catégorico	Acadêmico	1 - 2 hours, 2 - 4 hours
How many of the electronic gadgets do you have in your home or your student accommodation/mess/hall?	Quantidade de dispositivos eletrônicos disponíveis	Catégorico	Tecnológico	1 - 3, 4 - 6
How many hours do you spend on social media per day?	Tempo médio diário gasto em redes sociais	Catégorico	Comportamental	1 - 2 Hours, More than 4 Hours
Your Last Semester GPA	Média acadêmica do último semestre	Numérico	Acadêmico	Valores decimais

Tabela 4.3: Dataset Estudantes Malasia

Campo	Descrição	Tipo de dado	Categoria	Valores possíveis
id	Identificador único do participante	Inteiro	Identificação	Valores inteiros
age	Idade do participante	Inteiro	Sociodemográfico	Valores inteiros
year	Ano acadêmico do participante	Inteiro	Acadêmico	1, 2, 3, 4...
sex	Sexo do participante	Catégorico	Sociodemográfico	1, 2
glang	Idioma principal do participante	Catégorico	Sociodemográfico	Valores catégoricos
part	Participação em atividade específica do estudo	Binário	Comportamental	0, 1
job	Situação empregatícia do participante	Binário	Socioeconômico	0, 1
stud_h	Quantidade de horas de estudo	Inteiro	Acadêmico	Valores inteiros
health	Autoavaliação de saúde geral	Inteiro	Saúde	Escala numérica
psyt	Indicador psicológico do participante	Binário	Saúde mental	0, 1
jspe	Escore da Jefferson Scale of Physician Empathy	Númérico	Saúde mental	Valores numéricos
qcae_cog	Escore de empatia cognitiva (QCAE)	Númérico	Saúde mental	Valores numéricos
qcae_aff	Escore de empatia afetiva (QCAE)	Númérico	Saúde mental	Valores numéricos
amsp	Escore AMSP do participante	Númérico	Saúde mental	Valores numéricos
errec_mean	Média de reconhecimento emocional	Númérico	Cognitivo	Valores decimais
cesd	Escore da escala CES-D para sintomas depressivos	Númérico	Saúde mental	Valores numéricos
stai_t	Escore de ansiedade traço (STAI-T)	Númérico	Saúde mental	Valores numéricos
mbi_ex	Escore de exaustão emocional (MBI)	Númérico	Burnout	Valores numéricos
mbi_cy	Escore de cinismo/despersonalização (MBI)	Númérico	Burnout	Valores numéricos
mbi_ea	Escore de eficácia acadêmica/profissional (MBI)	Númérico	Burnout	Valores numéricos

4.2 Pré-processamento de dados

O pré-processamento de dados é a etapa de preparação do dado para o processamento pelo algoritmo ou abordagem escolhida. A preparação dos dados pode ser compreendida como a etapa de limpeza do dado e a conversão de diferentes tipos de dados em tipos que possam ser interpretados pelo modelo escolhido.

É nesta etapa que a redução de atributos pode ser feita para identificação de que dados podem ser utilizados na etapa de clusterização, limpeza de dados e codificação de rótulos. Muitas vezes, dados brutos possuem uma grande quantidade de atributos e pode ser necessária a redução de atributos para seguir efetivamente no processo de agrupamento [Dewi e Dwidasmara 2021].

Ainda nesta etapa, os conjuntos de dados utilizados na pesquisa foram analisados com o objetivo de identificar possíveis falhas, inconsistências ou limitações relacionadas ao tipo de dado, que pudessem impactar negativamente a execução dos algoritmos de clusterização. Considerando que cada algoritmo empregado na pesquisa apresenta características próprias, mas também pontos em comum, o pré-processamento foi realizado de forma padronizada para cada conjunto de dados. Em cada um dos três conjuntos analisados, foram construídos novos subconjuntos a partir da preparação necessária para sua utilização nos modelos, conforme descrito nos tópicos a seguir:

- Contagem de campos vazios e NaN (Not a Number) ou nulos: Para cada resultado observado a partir da contagem de numos e vazios, uma possível forma de tratamento de campos vazios poderia ser adotada. No cenário desta pesquisa, não foram encontrados campos vazios ou *NaN* em quantidade significativa; portanto, preferiu-se eliminar os poucos registros com dados faltantes.
- Mudança de tipificação quando não estabelecido de forma clara pelo conjunto de dados: quando o tipo de dado no campo não era estabelecido ou mesmo poderia ser, por exemplo, campos que representam variáveis categóricas, mas estavam codificados como texto livre foram convertidos para tipo categórico adequado.
- Mitigação da limitação dos algoritmos em relação ao tipo de dados: de modo a comparar o impacto de diferentes representações das variáveis categóricas no processo de agrupamento, quando a abordagem de agrupamento utilizada não suportava, por exemplo, um tipo categórico de dados como entrada de dados, duas estratégias de encoding de dados foram aplicadas. Nesta pesquisa, foram utilizadas as abordagens de One-Hot Ecoding e o Label Encoding para transformar dados categóricos em correspondentes numéricos.
- Redução de dimensionalidade: visando proporcionar a avaliação dos algoritmos em diferentes cenários de volumetria de dados, os algoritmos executaram o agrupamento de dados usando o conjunto de dados inteiro, com todos os seus atributos, mas também com a redução das dimensões do conjunto original com o apoio de uma técnica de redução de dimensionalidade, a Análise de Componentes Principais (PCA).

4.3 Clustering analysis

O processo de clusterização pode ser realizado em quatro etapas distintas que compõem desde a coleta de dados até a análise do resultado obtido, sendo: (1) Extração e seleção de features (características); (2) Formulação do modelo ou algoritmo conforme o problema a ser resolvido; (3) Avaliação do algoritmo e análise da validade do modelo de ML obtido; (4) Apresentação das concepções obtidas a partir da clusterização. Para a presente pesquisa, as etapas do Clustering Analysis (clusterização) serão as mesmas para todos os algoritmos selecionados.

Uma vez focada na comparação do desempenho, a etapa (3), avaliação, precisa da garantia da integridade das métricas utilizadas, com isso as etapas anteriores precisam ser desenvolvidas de forma homogênea (mesmas etapas de pré-processamento de dados, mesmos conjuntos de dados, mesmas métricas).

Nesta pesquisa, foram aplicados diversos algoritmos de clusterização para analisar a correlação entre indicadores de saúde mental e o rendimento acadêmico de estudantes. O processo metodológico seguiu as etapas principais abaixo:

- **Determinação da Tendência de Clusterização:** Antes de aplicar os algoritmos, verificou-se a existência de estrutura clusterizada nos dados para garantir que não se tratava de uma distribuição aleatória, utilizando técnicas de análise exploratória e medidas de tendência de agrupamento.
- **Definição do Número de Clusters:** Para os algoritmos que exigem o número pré-definido de clusters, como K-Means, Agglomerative Clustering e K-Prototypes, foi empregada a análise de índices como o método do cotovelo e o coeficiente de silhueta para determinar o número adequado de agrupamentos.
- **Aplicação dos Algoritmos de Clusterização:** Foram testados múltiplos algoritmos, incluindo K-Means, K-Prototypes, DBSCAN, Agglomerative Clustering e OPTICS, para comparar a performance em relação à identificação dos grupos naturais presentes nos dados.
- **Avaliação da Qualidade dos Clusters:** Como não há rótulos pré-existent, a avaliação foi realizada com métricas internas, tais como o Índice de Silhueta, o Índice de Calinski-Harabasz e o Índice de Davies-Bouldin, que indicam a coesão e separação dos clusters sem a necessidade de informações externas.
- **Comparação e Seleção do Melhor Algoritmo:** Os resultados foram comparados para determinar qual método apresentou melhor desempenho em termos de agrupamento coerente e útil para interpretar a relação entre saúde mental e desempenho acadêmico.
- **Dos Resultados:** Por fim, os clusters identificados foram analisados para verificar padrões e correlações significativas entre os níveis de estresse e faixas de notas acadêmicas, buscando validar se grupos com características semelhantes de saúde mental apresentavam comportamentos acadêmicos semelhantes.

4.4 Escolha do algoritmo

Para a escolha dos algoritmos, este estudo considerou a análise de textos científicos relacionados ao uso de algoritmos de clusterização no contexto educacional. Com base em observações feitas em artigos já analisados, alguns algoritmos já conhecidos pela literatura foram escolhidos, sendo estes: kmeans, que é um algoritmo baseado em partição (partitioning-based); o Kmodes e o k-Prototypes que são variações do Kmeans para o processamento de dados categoricos que podem ser aplicados diretamente sem a necessidade de tratamento de dados mais aprofundado; o DBSCAN e OPTICS, ambos baseados em densidade (density based); agglomerative lustering, que é baseado em métodos espectrais [Hooshyar et al. 2020].

4.4.1 Configuração de execução dos algoritmos

Tabela 4.4: Configurações dos algoritmos por cenário com e sem redução de dimensionalidade (PCA)

Cenário	Algoritmo	Codificação	Redução	Principais parâmetros
1	K-Means	OHE	Com PCA	n_clusters=2, init='k-means++', n_init=10, random_state=42
2	K-Means	LE	Com PCA	n_clusters=2, init='k-means++', n_init=10, random_state=42
3	DBSCAN	OHE	Com PCA	eps=0.5, min_samples=10
4	DBSCAN	LE	Com PCA	eps=0.5, min_samples=10
5	Agglomerative	OHE	Com PCA	n_clusters=2, metric='euclidean'
6	Agglomerative	LE	Com PCA	n_clusters=2, metric='euclidean'
7	OPTICS	LE	Com PCA	min_samples=5, max_eps=0.5
8	OPTICS	OHE	Com PCA	min_samples=5, max_eps=0.5
9	K-Means	OHE	Sem PCA	n_clusters=2, init='k-means++', n_init=10, random_state=42
10	K-Means	LE	Sem PCA	n_clusters=2, init='k-means++', n_init=10, random_state=42
11	DBSCAN	OHE	Sem PCA	eps=0.5, min_samples=10
12	DBSCAN	LE	Sem PCA	eps=0.5, min_samples=10
13	Agglomerative	OHE	Sem PCA	n_clusters=2, metric='euclidean'
14	Agglomerative	LE	Sem PCA	n_clusters=2, metric='euclidean'
15	OPTICS	LE	Sem PCA	min_samples=5, max_eps=0.5
16	OPTICS	OHE	Sem PCA	min_samples=5, max_eps=0.5

4.4.2 Redução de dimensionalidade e encoding de dados no pré-processamento de dados

Grande parte dos algoritmos utilizados nesta pesquisa não foi desenvolvida para operar diretamente com variáveis categóricas. No entanto, todos os conjuntos de dados analisados neste estudo contêm esse tipo de variável, uma vez que se referem a informações relacionadas à rotina, ao perfil de estudantes universitários e às suas características sociodemográficas e pessoais, incluindo aspectos de descrição física.

Com o objetivo de possibilitar a execução dos algoritmos utilizando os conjuntos de dados necessários para a construção das observações propostas pela pesquisa, foi necessário adaptar variáveis categóricas para o formato numérico. Na aplicação da técnica

One-Hot Encoding (OHE), cada categoria é transformada em uma coluna binária, assumindo valores 0 ou 1. Por exemplo, nos atributos “cor do cabelo” e “autodefinição de raça”, em vez de cada linha conter o valor textual da categoria, cada possível categoria se torna uma nova coluna, sendo preenchida com 1 quando a ocorrência corresponde àquela descrição e com 0 quando não.

Todavia, sempre que uma coluna ‘cor dos olhos’ vira uma nova coluna, por exemplo, geravam-se novas colunas para cada cor presente nas linhas do dataset, o que gerou um grande volume de colunas e maior dimensionamento do conjunto de dados, podendo gerar, possivelmente, maior custo computacional para a execução do algoritmo. Como forma de contornar essa limitação, o PCA, um algoritmo para reduzir a dimensionalidade do conjunto em dois grandes componentes principais foi utilizado na análise, gerando um novo cenário de avaliação dos algoritmos. Essas componentes são combinações lineares das variáveis originais.

A 1ª componente (PCA 1) é a direção no espaço dos dados que explica a maior parte da variância (ou seja, é a "linha" ao longo da qual os dados estão mais espalhados). A 2ª componente (PCA 2) é a direção ortogonal à 1ª que explica a segunda maior parte da variância.

4.5 Métricas para avaliação

Para garantir a integridade dos agrupamentos e verificar se a estrutura formada reflete corretamente a distribuição dos dados, é necessário recorrer a índices de validação de clusters. Esses índices podem ser classificados em **internos** e **externos**, conforme a natureza das informações utilizadas em sua avaliação [Sinaga e Yang 2020].

Os **índices externos** são aplicados quando os rótulos verdadeiros das classes são conhecidos, permitindo comparar diretamente os clusters formados com as categorias reais. Já os **índices internos** são utilizados em situações onde os rótulos não estão disponíveis, avaliando a qualidade dos clusters com base em propriedades internas do próprio conjunto de dados, como a coesão e a separação entre grupos [Sinaga e Yang 2020].

Considerando que os dados utilizados nesta pesquisa não possuem rótulos de classe, optou-se pelo uso de **índices internos de validação**. Esses indicadores permitem avaliar a consistência da clusterização de forma autônoma, analisando quão compactos e distintos são os grupos formados pelos algoritmos.

4.5.1 Índices de validação interna

As métricas de avaliação adotadas foram:

- **Davies–Bouldin Index (DBI):** mede a relação entre a dispersão dos clusters e a distância entre eles. Valores menores indicam agrupamentos mais coesos e bem separados;
- **Silhouette Width (SW):** avalia simultaneamente a separação e a coesão dos clusters. Valores próximos de 1 indicam boa formação de grupos, enquanto valores negativos indicam sobreposição;
- **Calinski–Harabasz Index (CH):** analisa a razão entre a variância entre clusters e a variância interna de cada cluster. Valores mais altos representam melhor definição dos agrupamentos. Quanto maior o valor do índice Calinski-Harabasz, melhor é a qualidade do agrupamento. Um valor alto indica que os clusters são densos e bem separados.

Essas métricas foram escolhidas por fornecerem uma visão complementar da qualidade dos agrupamentos, permitindo uma análise equilibrada entre compacidade, separação e variância dos clusters formados pelos diferentes algoritmos.

A avaliação foi feita com base nos resultados, rótulos de clusters, provenientes da clustrização pelos algoritmos, aplicado aos três conjuntos de dados. Para auxiliar na comparação da qualidade dos clusters gerados, os algoritmos escolhidos foram executados com os mesmos conjuntos de dados e o mesmo pré-processamento de dados. As métricas foram dispostas em gráficos e tabelas a fim de proporcionar melhor visualização e interpretação dos dados.

4.5.2 Cenários de avaliação

As análises foram realizadas em três blocos principais, representando distintos grupos de informações sobre características sociais e comportamentais dos estudantes, bem como indicadores de saúde mental e níveis de estresse.

Para cada bloco, foram conduzidos quatro cenários de avaliação, variando-se as técnicas de codificação e pré-processamento conforme descrito a seguir:

- Aplicação de *One-Hot Encoding (OHE)* combinada com redução de dimensionalidade via *Principal Component Analysis (PCA)*.
- Aplicação de *Label Encoding (LE)* combinada com redução de dimensionalidade via *Principal Component Analysis (PCA)*.
- Transformação dos dados utilizando apenas *One-Hot Encoding (OHE)*, sem redução de dimensionalidade.
- Transformação dos dados utilizando apenas *Label Encoding (LE)*, sem redução de dimensionalidade.

4.5.3 Avaliação e interpretação dos clusters

Após a execução dos algoritmos de clusterização, realizou-se a etapa de **avaliação e interpretação dos agrupamentos** com base na análise dos *centroides* e nas médias das variáveis associadas a cada cluster. O objetivo dessa análise foi compreender as características predominantes em cada grupo e identificar padrões que justificassem a formação dos clusters.

A análise dos clusters permitiu a observação das variáveis como notas, índices de estresse, número mais elevados ou reduzidos de estudantes com melhores notas em determinados grupos, possibilitando uma interpretação descritiva dos perfis formados, observando a presença ou não de maior prevalência de estudantes com maior, ou menor pontuação em índices de estresse nesses grupos. Essa abordagem é essencial em estudos exploratórios, pois transforma a estrutura numérica dos agrupamentos em informações interpretáveis, permitindo relacionar os resultados de clusterização a fatores como níveis de estresse, hábitos de estudo e desempenho acadêmico.

Além da análise tabular, foram empregadas **visualizações gráficas**, como mapas de calor (*heatmaps*) e *boxplots*, a fim de representar visualmente as diferenças entre clusters e reforçar a interpretação dos resultados. Essas representações contribuíram para avaliar a separação estatística e atender melhor os perfis construídos na clusterização dos grupos, fornecendo base para uma análise comparativa e interpretativa dos resultados.

4.6 Considerações sobre o capítulo

O presente capítulo apresentou as etapas metodológicas adotadas para o desenvolvimento da pesquisa, descrevendo os procedimentos de coleta, preparação e tratamento dos dados, bem como as ferramentas e técnicas utilizadas na execução dos experimentos. Foram detalhados os processos de pré-processamento aplicados aos conjuntos de dados, além da apresentação das fontes e da estrutura dos dados analisados, assim como dos critérios de avaliação dos algoritmos empregados.

5 RESULTADOS E AVALIAÇÃO

Neste capítulo, são apresentados os resultados obtidos por meio das análises comparativas dos algoritmos e a plotagem dos gráficos correspondentes a cada cluster nos diferentes cenários de avaliação considerados na pesquisa.


Foram conduzidos três blocos principais de experimentos, cada um voltado à análise de um conjunto específico de dados educacionais, bem como informações sobre saúde mental e rendimento acadêmico.

O objetivo desta seção é discutir o desempenho dos algoritmos em cada cenário, destacando as métricas obtidas para cada modelo em relação ao conjunto de dados e processamento aplicado na preparação do dataset.

5.1 Experimentos e Avaliação de Resultados

Os experimentos de avaliação dos algoritmos resultaram em 51 cenários de avaliação de avaliação, levando em consideração a característica dos dados e a tipificação, além de ajustes de parâmetros com auxílio de técnicas de heurística visual usada em aprendizado de máquina para escolher o número de clusters em algoritmos como o K-Means e suas variantes. O método de elbow retornou como número inicial o valor de 2 clusters para o parametro inicial no k-means, construído instancia do modelo com $n \text{ clusters}=2$, sendo este o parametro para todos os algoritmos baseados em centroídes ou que precisassem da instancia inicial.

Figura 5.1: Teste de elbow - k inicial



O mesmo parametro foi utilizado para os todos algoritmos dos blocos de avaliação (Bloco 1, Bloco 2 e Bloco 3), tem como parametro inicial o número de centroides. O número de $k = 2$ embasou todas avaliações, levando em consideração o uso do mesmo pipeline de dados para todos os experimentos.

No conjunto de experimentos, foram utilizados os algoritmos K-Means, DBSCAN, Agglomerative Clustering, OPTICS, K-Modes e K-Prototypes, aplicados a diferentes configurações de codificação e redução de dimensionalidade.

Os quatro primeiros algoritmos operam essencialmente com dados numéricos e contínuos, o que exige um processo prévio de transformação das variáveis categóricas (via encoding) e, em alguns casos, a redução da dimensionalidade para evitar redundâncias e correlações excessivas.

O algoritmo K-Modes se diferencia de outras técnicas de clusterização abordadas por ser projetado especificamente para dados categóricos, utilizando medidas de dissimilaridade baseadas em coincidência de modos (em vez de distâncias euclidianas). Dessa forma, o K-Modes dispensa tanto o uso de técnicas de encoding (como One-Hot Encoding ou Label Encoding) quanto a aplicação de PCA, pois lida diretamente com os valores categóricos originais do conjunto de dados. A utilização desta técnica neste bloco teve como objetivo oferecer uma avaliação comparativa mais realista do comportamento dos agrupamentos quando se evita a conversão dos dados em representações numéricas artificiais.

Além da análise de desempenho dos algoritmos, realizada na clusterização de dados com redução de dimensionalidade com PCA, este bloco apresenta a avaliação dos algoritmos sem redução de dimensionalidade. Ou seja, os conjuntos de dados foram pré-processados apenas por técnicas de tratamento de variáveis categóricas, nas quais cada categoria é convertida em uma ou mais colunas representadas numericamente usando técnicas de encoding de dados, além de tratamento de variáveis nulas ou vazias.

Conforme descrito na metodologia, foram aplicadas duas abordagens de codificação: Label Encoding (LE) e One-Hot Encoding (OHE). Os resultados obtidos a partir dessas transformações são apresentados nas Figuras 8 a 16, que ilustram o comportamento dos algoritmos nos diferentes cenários de análise.

Neste capítulo, portanto, são discutidos os resultados obtidos com a aplicação dos diferentes algoritmos de clusterização sobre os conjuntos de dados estudantis.

5.2 BLOCO 1: Dataset Estudantes Estados Unidos

Tabela 5.1: Métricas comparativas entre algoritmos utilizando One-Hot Encoding (OHE)

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 1 - K-Means (OHE) - Com redução de dimensão	0.468652	454.479972	0.789558
Cenário 3 - DBSCAN (OHE)	0.177203	12.418430	3.465520
Cenário 5 - Agglomerative (OHE)	0.452142	415.828864	0.795888
Cenário 8 - OPTICS (OHE) - Sem redução de dimensão	-0.162629	13.682369	2.241270

Figura 5.2: Cenários 1 e 2




Figura 5.3: Cenários 3 e 4




Figura 5.4: Cenários 5 e 6





Figura 5.5: Cenários 7 e 8



De acordo com as observações apresentadas na **Tabela 5.1**, observa-se que o K-Means combinado com OHE e redução de dimensionalidade (PCA) apresentou o melhor desempenho geral entre os algoritmos avaliados. Esse cenário obteve o maior valor de Silhouette (0,4686), indicando maior coesão interna e melhor separação entre os grupos, bem como o maior índice de Calinski-Harabasz (454,47), reforçando a qualidade dos agrupamentos formados. Além disso, apresentou o menor valor de Davies-Bouldin (0,7896), o que confirma que os clusters resultantes são compactos e bem separados.

O Agglomerative Clustering (OHE) também apresentou desempenho satisfatório, com métricas próximas às do K-Means, sugerindo que a estrutura hierárquica conseguiu capturar padrões relevantes nos dados codificados com OHE. Já o DBSCAN e o OPTICS, embora adequados para detectar agrupamentos de densidade variável, tiveram valores de Silhouette negativos ou baixos e índices Davies-Bouldin mais elevados, o que indica

difículdade em identificar fronteiras claras de clusterização nesse tipo de representação de dados.

De modo geral, o uso do OHE aliado à redução de dimensionalidade via PCA favoreceu algoritmos baseados em distância euclidiana, como o K-Means e o Agglomerative, provavelmente por minimizar redundâncias e correlações entre as variáveis codificadas.

Tabela 5.2: Métricas comparativas entre algoritmos utilizando Label Encoding (LE)

Cenário	Silhouette	Calinski-Harabasz	Davies-Bouldin
Cenário 2 - KMeans (LE) - Com redução de dimensão	0.186609	93.072299	1.893468
Cenário 4 - DBSCAN (LE)	0.217571	51.605367	2.810863
Cenário 6 - Agglomerative (LE)	0.422529	351.914603	0.913902
Cenário 7 - OPTICS (LE) sem redução de dimensão	0.017529	25.879147	1.148245

De acordo com os resultados apresentados na **Tabela 5.2**, observa-se que o Agglomerative Clustering associado ao Label Encoding (LE) e à redução de dimensionalidade (PCA) apresentou o melhor desempenho geral entre os algoritmos avaliados. Esse cenário obteve os valores mais expressivos em todas as métricas: Silhouette de 0,4225, Calinski–Harabasz de 351,91 e Davies–Bouldin de 0,9139, indicando alta coesão interna, boa separação entre os clusters e baixa sobreposição entre grupos. Esses resultados sugerem que o modelo hierárquico conseguiu capturar de forma mais eficiente as relações latentes nos dados após a redução de dimensionalidade.

Por outro lado, o K-Means com LE e PCA apresentou desempenho inferior, com Silhouette de 0,1866, o que aponta para clusters menos definidos. Tal comportamento é esperado, dado que o K-Means utiliza distâncias euclidianas, que podem ser distorcidas por variáveis codificadas ordinalmente. Já os métodos baseados em densidade, DBSCAN e OPTICS, apresentaram Silhouette muito baixos (0,2175 e 0,0175, respectivamente) e Davies–Bouldin mais elevados, indicando baixa separabilidade e alta dispersão interna. Esses resultados demonstram que tais algoritmos não foram eficazes para esse tipo de dado, principalmente na ausência de redução de dimensionalidade.

De modo geral, os resultados evidenciam que o uso do PCA em conjunto com o Agglomerative Clustering proporcionou agrupamentos mais consistentes e interpretáveis, enquanto o Label Encoding isoladamente não favoreceu a formação de clusters bem definidos, especialmente para algoritmos sensíveis à escala e à natureza ordinal dos atributos.

Tabela 5.3: Métricas comparativas entre algoritmos utilizando One-Hot Encoding (OHE) sem redução de dimensionalidade (PCA)

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 9 - K-Means (OHE) - Sem PCA	0.138162	54.572118	2.471546
Cenário 11 - DBSCAN (OHE)	NaN	NaN	NaN
Cenário 13 - Agglomerative (OHE)	0.113566	42.373642	2.601852
Cenário 16 - OPTICS (OHE) - Sem PCA	-0.091971	6.299681	1.128770

Figura 5.6: Cenários 9 e 10





Figura 5.7: Cenários 11 e 12



A Tabela apresenta os resultados das métricas de avaliação dos algoritmos de clus-
terização aplicados sobre o conjunto de dados transformado por meio do One-Hot Enco-
ding (OHE), sem a utilização da redução de dimensionalidade com auxilio do PCA.

De modo geral, é possível perceber que o K-Means (Cenário 9) obteve o melhor
desempenho relativo entre os métodos avaliados, apresentando Silhouette de 0,1381 e

Figura 5.8: Cenários 13 e 14





Figura 5.9: Cenários 15 e 16



Calinski–Harabasz de 54,57. Embora esses valores indiquem alguma estrutura de agrupamento, eles ainda são significativamente inferiores aos obtidos nos cenários com PCA, evidenciando que a ausência de redução de dimensionalidade dificulta a formação de clusters bem definidos. O Davies–Bouldin de 2,47 reforça essa conclusão, apontando alta sobreposição entre os grupos.

O Agglomerative Clustering (Cenário 13) apresentou métricas próximas (Silhouette = 0,1136 e DB = 2,60), o que demonstra desempenho ligeiramente inferior, porém consistente com o comportamento esperado desse tipo de algoritmo em dados de alta dimensionalidade gerados pelo OHE.

Já os métodos baseados em densidade (DBSCAN e OPTICS) apresentaram resultados insatisfatórios. O DBSCAN (Cenário 11) não produziu valores numéricos válidos nas métricas, o que indica que o modelo não conseguiu identificar agrupamentos significativos, possivelmente classificando a maior parte das amostras como ruído. O OPTICS (Cenário 16), por sua vez, obteve Silhouette negativo (-0,0919), CH de apenas 6,30 e

DB de 1,13, indicando que os clusters formados são instáveis e pouco coerentes com a estrutura real dos dados.

De forma geral, os resultados sugerem que, quando se utiliza o One-Hot Encoding sem redução de dimensionalidade, há um aumento substancial na dispersão dos dados, o que compromete a eficiência dos algoritmos de clusterização baseados em distância. Esse comportamento reforça a importância do uso do PCA ou de outras técnicas de redução para mitigar o efeito da explosão dimensional introduzida pelo OHE e favorecer a formação de agrupamentos mais consistentes.

Tabela 5.4: Métricas comparativas entre algoritmos utilizando Label Encoding (LE) sem redução de dimensionalidade (PCA)

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 10 - K-Means (LE) - Sem PCA	0.186152	93.219441	1.888538
Cenário 12 - DBSCAN (LE) - Sem PCA	NaN	NaN	NaN
Cenário 14 - Agglomerative (LE) - Sem PCA	0.143338	69.956278	2.042853
Cenário 15 - OPTICS (LE) - Sem PCA	NaN	NaN	NaN

De acordo com as observações apresentadas na Tabela 5.4, o K-Means combinado com Label Encoding (LE) apresentou o melhor desempenho geral entre os algoritmos avaliados neste cenário sem a aplicação de redução de dimensionalidade. O modelo alcançou Silhouette = 0,186, Calinski–Harabasz = 93,21 e Davies–Bouldin = 1,89, evidenciando formação de agrupamentos válidos, ainda que com baixo nível de separação e coesão interna quando comparado aos cenários com PCA. Esses resultados mostram que, mesmo com as possíveis limitações do Label Encoding, que atribui valores numéricos arbitrários sequenciais às categorias, o K-Means foi capaz de identificar padrões mínimos de agrupamento nos dados.

O Agglomerative Clustering (LE) também conseguiu gerar clusters, mas com desempenho inferior (Silhouette = 0,143; Davies–Bouldin = 2,04), o que indica maior sobreposição entre grupos e fronteiras menos definidas. Apesar disso, o método hierárquico ainda conseguiu capturar alguma estrutura relacional entre as observações codificadas numericamente.

Em contrapartida, os algoritmos DBSCAN e OPTICS não geraram clusters válidos, resultando em valores NaN nas métricas. Isso ocorre porque ambos dependem fortemente da densidade local dos pontos no espaço vetorial, e o Label Encoding, por sua natureza ordinal e semântica limitada, não preserva distâncias consistentes entre categorias. Como consequência, o modelo interpretou todos os pontos como ruído (outliers) ou

como pertencentes a um único cluster, impossibilitando o cálculo das métricas de desempenho.


De forma geral, os resultados reforçam que, em dados categóricos tratados apenas com Label Encoding e sem redução de dimensionalidade, os algoritmos baseados em partição (como o K-Means) continuam sendo os mais estáveis e capazes de produzir agrupamentos interpretáveis, enquanto os métodos baseados em densidade (DBSCAN e OPTICS) são inadequados para esse tipo de representação sem transformações adicionais.

5.3 BLOCO 2: Dataset of Jordanian university students psychological health impacted by using e-learning tools during COVID-19

Tabela 5.5: Métricas comparativas entre algoritmos utilizando One-Hot Encoding (OHE) com redução de dimensionalidade (PCA)

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 18 - K-Means (OHE) - Com PCA	0.490757	1050.142103	0.771250
Cenário 20 - DBSCAN (OHE) - Com PCA	0.240672	33.235057	1.710853
Cenário 22 - Agglomerative (OHE) - Com PCA	0.454441	800.657647	0.772847
Cenário 25 - OPTICS (OHE) - Com PCA	-0.139821	10.985070	2.058497

Figura 5.10: Cenários 18 e 19



De acordo com as observações apresentadas na Tabela 5.5, o algoritmo K-Means combinado com One-Hot Encoding (OHE) e redução de dimensionalidade via PCA apresentou o melhor desempenho geral entre os métodos avaliados. Esse cenário (Cenário 18) obteve o maior valor de Silhouette (0,4908) e o maior índice de Calinski–Harabasz (1050,14), indicando alta coesão intra-cluster e boa separação entre grupos. O valor redu-

Figura 5.11: Cenários 20 e 21





Figura 5.12: Cenários 22 e 23



zido de Davies–Bouldin (0,77) reforça essa conclusão, evidenciando clusters compactos e bem definidos no espaço reduzido.

O Agglomerative Clustering (OHE) também apresentou desempenho consistente, com valores próximos aos do K-Means (Silhouette = 0,4544; DB = 0,77), sugerindo que a estrutura hierárquica do modelo foi eficaz para capturar relações latentes entre variáveis codificadas. Por outro lado, os algoritmos DBSCAN e OPTICS, ambos baseados em densidade, tiveram resultados inferiores, com Silhouette mais baixos e Davies–Bouldin mais elevados. Isso indica que, neste conjunto de dados, a distribuição dos pontos após o OHE e o PCA não formou regiões densas bem separadas, dificultando a detecção de fronteiras nítidas entre os agrupamentos.

De forma geral, os resultados sugerem que, quando aplicada a codificação OHE combinada com redução de dimensionalidade, os métodos baseados em partição (como o K-Means) produzem clusters mais coerentes e estáveis do que os métodos baseados em densidade.

Figura 5.13: Cenários 24 e 25




Figura 5.14: Cenários 26 e 27




Tabela 5.6: Métricas comparativas entre algoritmos utilizando Label Encoding (LE) com redução de dimensionalidade (PCA)

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 19 - K-Means (LE) - Com PCA	0.331983	387.321310	1.164303
Cenário 21 - DBSCAN (LE) - Com PCA	0.340603	71.233297	3.939732
Cenário 23 - Agglomerative (LE) - Com PCA	0.337892	345.527703	1.216761
Cenário 24 - OPTICS (LE) - Com PCA	-0.203173	9.595557	3.815332

Conforme os resultados da Tabela 5.6, o K-Means com Label Encoding (LE) também apresentou o melhor desempenho dentro desse grupo, com Silhouette de 0,332, Calinski–Harabasz de 387,32 e Davies–Bouldin de 1,16. Apesar de inferiores aos valores obtidos com OHE, esses resultados demonstram boa separação relativa entre clusters, mesmo considerando atributos categóricos representados por valores numéricos ordinais sequenciais (LE), o que poderia enviesar a análise.

Figura 5.15: Cenários 28 e 29





Figura 5.16: Cenários 30 e 31



O Agglomerative Clustering (LE) manteve desempenho do apresentado pelo K-means, reforçando a tendência observada no bloco anterior: modelos hierárquicos são capazes de capturar bem as relações entre observações, ainda que com menor definição nos limites dos clusters no presente cenário. Já os algoritmos DBSCAN e OPTICS apresentaram desempenho significativamente inferior, com Silhouette negativo no caso do OPTICS ($-0,203$) e Davies–Bouldin acima de $3,8$, indicando baixa separabilidade e alta sobreposição entre clusters.

Contudo, pode-se observar que a codificação usando Label Encoding, mesmo aliada à redução de dimensionalidade, produziu agrupamentos menos discriminativos na presente análise do que o One-Hot Encoding, especialmente quando aplicada a algoritmos baseados em densidade.

Figura 5.17: Cenários 32 e 33




Tabela 5.7: Métricas comparativas entre algoritmos utilizando Label Encoding (LE) sem redução de dimensionalidade

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 29 - DBSCAN (LE)	0.161782	24.287487	0.743636
Cenário 32 - OPTICS (LE) sem redução de dimensão	0.102021	16.766000	0.785411
Cenário 27 - KMeans (LE) - Sem redução de dimensão	0.060530	50.964866	3.762939
Cenário 31 - Agglomerative (LE)	0.032006	27.612419	4.180528

Nos experimentos com Label Encoding (LE) tabela 5.7, o algoritmo que apresentou melhor desempenho foi o DBSCAN (Cenário 29). Ele obteve o maior valor de Silhouette (0,1618) e o menor índice de Davies–Bouldin (0,74), indicando a melhor separação entre os grupos e boa coesão interna. Apesar de o valor do Silhouette ainda ser relativamente baixo, ele mostra que o DBSCAN conseguiu identificar padrões de densidade mais consistentes em comparação aos demais métodos.

O OPTICS (Cenário 32) apresentou resultados parecidos, com Silhouette de 0,10 e Davies–Bouldin de 0,78. Embora esse valor de Silhouette indique uma separação fraca entre os clusters, o desempenho foi estável dentro do contexto do Label Encoding, que tende a distorcer as distâncias entre categorias. O OPTICS manteve uma boa compactação dos grupos (16,76) e se mostrou capaz de lidar com variações de densidade, mesmo com as limitações desse tipo de codificação.

Por outro lado, o K-Means (Cenário 27) e o Agglomerative (Cenário 31) tiveram desempenho inferior. O K-Means apresentou Silhouette de apenas 0,06 e índice Davies–Bouldin de 3,76, o que indica clusters pouco definidos e sobreposição entre grupos. Já o Agglomerative teve Silhouette ainda menor (0,03) e Davies–Bouldin de 4,18, sugerindo que praticamente não houve estrutura clara nos agrupamentos.

Esses resultados evidenciam que os algoritmos baseados em distância euclidiana, como K-Means e Agglomerative, aplicados no experimento, não se ajustaram bem ao Label Encoding. Em contraste, os métodos baseados em densidade, como DBSCAN e OPTICS, foram mais adequados, conseguindo identificar maior estrutura na clusterização dos dados mesmo com limitações na representação categórica pelo label encoding.

Tabela 5.8: Métricas comparativas entre algoritmos utilizando One-Hot Encoding (OHE) sem redução de dimensionalidade

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 33 - OPTICS (OHE) sem redução de dimensão	0.040544	11.556754	0.926125
Cenário 28 - DBSCAN (OHE)	0.045146	15.560777	0.941949
Cenário 30 - Agglomerative (OHE)	0.104295	61.541253	3.189348
Cenário 26 - KMeans (OHE) - Sem redução de dimensão	0.103930	81.927753	3.024936
Cenário 25 - OPTICS (OHE) com redução de dimensão	-0.093582	12.746055	2.165689

Nos experimentos com One-Hot Encoding (OHE), **Tabela 5.8**, sem redução de dimensionalidade os melhores resultados foram obtidos pelos algoritmos OPTICS (Cenário 33) e DBSCAN (Cenário 28). O OPTICS apresentou Silhouette de 0,04 e Davies–Bouldin de 0,92, enquanto o DBSCAN obteve Silhouette de 0,045 e Davies–Bouldin de 0,94. Embora esses valores sejam baixos, eles indicam uma leve separação entre os clusters e uma estrutura de densidade mais coerente do que nos experimentos com Label Encoding. A Compactness menor nesses cenários (entre 11 e 15) mostra que os pontos dentro dos grupos estão mais próximos entre si, sugerindo uma coesão interna razoável.

Os algoritmos K-Means (Cenário 26) e Agglomerative (Cenário 30) apresentaram métricas mais altas de Davies–Bouldin (3,02 e 3,18, respectivamente) e valores de Compactness muito maiores, o que indica dispersão e sobreposição entre os clusters. Apesar de ambos terem mostrado Silhouette em torno de 0,10 — ligeiramente melhor que os métodos baseados em densidade —, a separação entre os grupos ainda é fraca, e os resultados sugerem que o aumento da dimensionalidade causado pelo OHE afeta negativamente algoritmos que dependem de distância euclidiana.

Já o OPTICS (Cenário 25), que utilizou OHE com redução de dimensionalidade via PCA, apresentou Silhouette negativo (-0,09), o que indica agrupamento incorreto e ausência de estrutura clara. Mesmo com uma boa compactação (12,74), o índice Davies–Bouldin de 2,16 confirma que o modelo não conseguiu formar clusters distintos após a redução de variáveis. Isso sugere que o PCA, nesse contexto, pode ter eliminado atributos importantes para a separação natural dos grupos.

De forma geral, os resultados mostram que os métodos baseados em densidade se saíram melhor em ambos os tipos de codificação avaliados. Tanto no Label Encoding quanto no One-Hot Encoding, os algoritmos DBSCAN e OPTICS apresentaram métricas mais equilibradas, com valores menores de Davies–Bouldin e níveis de coesão e separação mais adequados entre os clusters. Esses resultados sugerem que, para este conjunto de dados, a estrutura de agrupamento não segue um formato esférico, o que favorece métodos capazes de identificar regiões de maior densidade em vez de depender de distâncias lineares fixas.

Por outro lado, os algoritmos K-Means e Agglomerative apresentaram maior sensibilidade às transformações de codificação. No caso do Label Encoding, a conversão de categorias em valores numéricos criou relações artificiais entre atributos; e no One-Hot Encoding, o aumento do número de dimensões ampliou as distâncias entre os pontos, prejudicando a definição dos grupos. Isso explica o desempenho inferior dessas abordagens quando comparadas aos métodos de densidade.

Em síntese, para este conjunto de dados, DBSCAN e OPTICS se mostraram as abordagens mais adequadas, pois mantiveram resultados mais consistentes independentemente da codificação aplicada, demonstrando maior robustez frente à natureza e à distribuição das variáveis analisadas.

5.4 BLOCO 3: Dataset of Malaysian University Students

De acordo com os resultados apresentados na Tabela 5.9, o K-Means com codificação OHE e redução de dimensionalidade via PCA apresentou o melhor desempenho geral entre os algoritmos avaliados neste cenário. O modelo alcançou valores de Silhouette = 0,332 e Calinski–Harabasz = 513,55, indicando formação de clusters bem definidos e separados. O índice Davies–Bouldin = 1,17 reforça a compactação interna satisfatória dos grupos, ainda que próximo ao desempenho do método Agglomerative.

Tabela 5.9: Métricas comparativas entre algoritmos utilizando One-Hot Encoding (OHE) com redução de dimensionalidade (PCA)

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 34 - K-Means (OHE) - Com PCA	0.332061	513.548655	1.175168
Cenário 36 - DBSCAN (OHE) - Com PCA	0.108937	18.846377	14.986917
Cenário 38 - Agglomerative (OHE) - Com PCA	0.324663	471.915586	1.173812

Figura 5.18: Cenários 35 e 36





Figura 5.19: Cenários 37 e 38



De acordo com os resultados apresentados na Tabela 5.9, o K-Means com codificação OHE e redução de dimensionalidade via PCA apresentou o melhor desempenho geral entre os algoritmos avaliados neste cenário. O modelo alcançou valores de Silhouette = 0,332 e Calinski–Harabasz = 513,55, indicando formação de clusters bem definidos e separados. O índice Davies–Bouldin = 1,17 reforça a compactação interna satisfatória dos grupos, ainda que próximo ao desempenho do método Agglomerative.

O Agglomerative Clustering (OHE) também apresentou métricas consistentes (Silhouette = 0,325; Davies–Bouldin = 1,17), demonstrando que estruturas hierárquicas mantêm boa coerência após a redução dimensional. Por outro lado, o DBSCAN (OHE) exibiu resultados inferiores (Silhouette = 0,108; Davies–Bouldin = 14,98), evidenciando baixa densidade local e dificuldade na separação dos grupos em espaços transformados pelo PCA. De forma geral, o K-Means se mostrou mais robusto e estável frente à transformação OHE combinada com redução de dimensionalidade.

Figura 5.20: Cenários 39 e 40




Figura 5.21: Cenários 41 e 42




Tabela 5.10: Métricas comparativas entre algoritmos utilizando Label Encoding (LE) com redução de dimensionalidade (PCA)

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 35 - K-Means (LE) - Com PCA	0.152166	175.239334	2.185978
Cenário 37 - DBSCAN (LE) - Com PCA	0.272086	36.981595	3.724398
Cenário 39 - Agglomerative (LE) - Com PCA	0.381788	599.701183	1.054012

Na **Tabela 5.10**, observa-se que o Agglomerative Clustering com Label Encoding (LE) apresentou o melhor desempenho entre os algoritmos analisados neste cenário. Com Silhouette = 0,382, Calinski–Harabasz = 599,70 e Davies–Bouldin = 1,05, o modelo demonstrou alto nível de coesão interna e separabilidade entre clusters, superando inclusive o K-Means, que teve valores mais modestos (Silhouette = 0,152; Davies–Bouldin = 2,18).

Figura 5.22: Cenários 43 e 44





Figura 5.23: Cenários 45 e 46



Os resultados sugerem que a estrutura hierárquica do Agglomerative se adapta melhor à codificação ordinal do LE, conseguindo identificar relações mais sutis entre as variáveis transformadas numericamente.

O DBSCAN (LE), embora tenha apresentado Silhouette moderado (0,272), mostrou Davies–Bouldin elevado (3,72), indicando baixa separabilidade de fronteiras. Assim, o desempenho do Agglomerative mostra que métodos hierárquicos podem melhorar seus resultados com uso do PCA, mesmo com dados codificados por Label Encoding para casos de dados categóricos.

Figura 5.24: Cenários 47 e 48




Figura 5.25: Cenários 49 e 50





Tabela 5.11: Métricas comparativas entre algoritmos sem redução de dimensionalidade (Sem PCA)

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 40 - OPTICS (LE) - Sem PCA	-0.207989	11.268413	4.690813
Cenário 41 - OPTICS (OHE) - Sem PCA	-0.153867	8.645611	2.747291
Cenário 42 - K-Prototypes - Sem PCA	0.102914	107.781691	2.780591

De acordo com as observações apresentadas na **Tabela 5.11**, o algoritmo K-Prototypes apresentou o melhor desempenho geral entre os métodos avaliados sem a aplicação de técnicas de redução de dimensionalidade. Com Silhouette = 0,1029, Calinski–Harabasz = 107,78 e Davies–Bouldin = 2,78, o modelo conseguiu formar agrupamentos válidos, ainda que com baixa separabilidade. O resultado confirma a adequação do K-Prototypes para conjuntos de dados mistos (numéricos e categóricos), visto que o algoritmo combina

Figura 5.26: Cenário 51



as propriedades do K-Means (para atributos contínuos) e do K-Modes (para categóricos), eliminando a necessidade de transformações como encoding ou PCA.

Por outro lado, os algoritmos OPTICS (LE) e OPTICS (OHE) apresentaram Silhouette negativos e baixos índices de Calinski–Harabasz, indicando ausência de estrutura de clusters bem definida. Isso sugere que, sem pré-processamento de dimensionalidade, a distribuição de densidades locais não foi suficiente para formar regiões densas de agrupamento, resultando em alta dispersão dos dados e métricas incompatíveis com um particionamento significativo.

De modo geral, os resultados demonstram que, na ausência de redução de dimensionalidade, o K-Prototypes se destaca por sua capacidade de lidar diretamente com dados heterogêneos, enquanto métodos baseados em densidade, como o OPTICS, mostram desempenho limitado nesse tipo de representação. Essa constatação reforça a importância de selecionar algoritmos compatíveis com a natureza dos dados e o tipo de codificação utilizada no pré-processamento.

Tabela 5.12: Métricas comparativas entre algoritmos utilizando One-Hot Encoding (OHE) com redução de dimensionalidade (PCA)

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 43 - K-Means (OHE) - Com PCA	0.332061	513.548655	1.175168
Cenário 45 - DBSCAN (OHE) - Com PCA	0.108937	18.846377	14.986917
Cenário 47 - Agglomerative (OHE) - Com PCA	0.324663	471.915586	1.173812

O K-Means (OHE) apresentou o melhor desempenho geral, com o maior Silhouette (0,33) e o maior índice de Calinski–Harabasz (513,55), além de um baixo Davies–Bouldin (1,17), indicando agrupamentos compactos e bem separados. O Agglome-

relative obteve valores muito próximos, o que reforça que métodos hierárquicos também se beneficiam da redução de dimensionalidade.

Já o DBSCAN apresentou desempenho inferior, sugerindo que a projeção via PCA reduziu sua sensibilidade à densidade local, dificultando a formação de clusters definidos.

Tabela 5.13: Métricas comparativas entre algoritmos utilizando Label Encoding (LE) com redução de dimensionalidade (PCA)

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 44 - K-Means (LE) - Com PCA	0.152166	175.239334	2.185978
Cenário 46- DBSCAN (LE) - Com PCA	0.272086	36.981595	3.724398
Cenário 48 - Agglomerative (LE) - Com PCA	0.381788	599.701183	1.054012

O Agglomerative (LE) obteve as melhores métricas, com Silhouette = 0,38, Calinski–Harabasz = 599,70 e Davies–Bouldin = 1,05, demonstrando agrupamentos bem estruturados após o PCA. O resultado confirma que o PCA atenua a limitação do Label Encoding, que atribui valores ordinais sem relação semântica direta. O K-Means apresentou desempenho regular e o DBSCAN, embora tenha identificado clusters, manteve índices baixos de separabilidade, refletindo menor qualidade de agrupamento.

Sem redução de dimensionalidade, apenas o K-Prototypes conseguiu formar agrupamentos válidos, alcançando Silhouette = 0,15 e Calinski–Harabasz = 170,25. Esse resultado mostra sua capacidade de lidar com dados mistos sem necessidade de transformações adicionais. Os métodos baseados em densidade (OPTICS) apresentaram Silhouette negativos e baixa coesão interna, indicando ausência de estrutura de clusters bem definida.

Tabela 5.14: Métricas comparativas entre algoritmos sem redução de dimensionalidade (Sem PCA)

Cenário	Silhouette	Calinski–Harabasz	Davies–Bouldin
Cenário 49 - OPTICS (LE) - Sem PCA	-0.207989	11.268413	4.690813
Cenário 50 - OPTICS (OHE) - Sem PCA	-0.153867	8.645611	2.747291
Cenário 51 - K-Prototypes - Sem PCA	0.148597	170.245933	2.210313

De modo geral, os resultados obtidos demonstram que a aplicação do PCA contribuiu significativamente para a qualidade dos agrupamentos, independentemente do tipo de codificação nas variáveis categóricas.

Nos cenários com redução de dimensionalidade, tanto o K-Means quanto o Agglomerative Clustering apresentaram resultados mais satisfatórios, evidenciando maior

coesão interna e melhor separação entre grupos, ou seja, maior similaridade entre os pontos do mesmo cluster.

Isso indica que a redução de dimensionalidade favorece algoritmos baseados em distância, eliminando ruídos e redundâncias que dificultam a formação de clusters em espaços de alta dimensionalidade.

Comparando as técnicas de codificação, o One-Hot Encoding (OHE) apresentou desempenho mais estável, especialmente em conjunto com o K-Means, enquanto o Label Encoding (LE) se mostrou mais sensível à escala dos atributos, porém ainda produziu bons resultados quando associado ao Agglomerative. Esse comportamento reforça que o PCA consegue atenuar os efeitos negativos da codificação ordinal, tornando os dados mais adequados para métodos hierárquicos.

Nos cenários sem redução de dimensionalidade, o desempenho geral foi inferior, com métricas de Silhouette mais baixas e índices de Davies–Bouldin mais elevados, refletindo baixa separabilidade entre os agrupamentos. Os algoritmos baseados em densidade, como DBSCAN e OPTICS, apresentaram limitações evidentes, muitas vezes sem gerar clusters válidos. Por outro lado, o K-Prototypes destacou-se como o único método capaz de formar agrupamentos consistentes nesse contexto, demonstrando sua eficiência em lidar diretamente com dados mistos, sem necessidade de transformações adicionais.

Em síntese, os resultados indicam que:

O uso do PCA pode melhorar substancialmente a estrutura dos agrupamentos, principalmente quando se trata de representações de alta dimensionalidade (muitas colunas no dataset).

K-Means (OHE) e Agglomerative (LE) são os algoritmos com melhor equilíbrio entre as métricas de desempenho neste bloco de avaliação.

Já o K-Prototypes se mostra a alternativa mais aplicável quando se trata de uma solução mais simples no pré-processamento e na manutenção das variáveis originais.

As diferenças de desempenho estão diretamente relacionadas à natureza da codificação, quando se trata do processamento de variáveis categóricas: o OHE distribui as categorias em um espaço binário de maior dimensionalidade, o que tende a beneficiar algoritmos baseados em distância, como o K-Means; já o LE, ao representar categorias de forma ordinal, facilita a formação de hierarquias mais consistentes, o que explica a vantagem observada no Agglomerative. Assim, conclui-se que o PCA atua como um fator equilibrador entre as codificações, reduzindo redundâncias e tornando os agrupamentos mais coesos, mas o tipo de algoritmo ainda influencia diretamente o resultado final.

6 DISCUSSÕES

O presente capítulo apresenta a análise e a discussão dos resultados obtidos no cenário que demonstrou o melhor desempenho algorítmico, com base na comparação entre as diferentes técnicas de clusterização aplicadas aos conjuntos de dados utilizados neste estudo.

Além disso, são apresentadas visualizações complementares, elaboradas com o apoio de tabelas e de outros recursos estatísticos, com o objetivo de aprofundar a compreensão das características do cenário que obteve o melhor resultado na avaliação - o Cenário 1.

6.1 Distribuição do desempenho acadêmico por cluster

Como é possível identificar na tabela 4.2, as variáveis relacionadas a estresse e saúde mental são estabelecidas no dataset como, *Feeling_depressed*, *tired_w_energy*, *Feeling_bad concentrating_issues*, *slow_restless*, *better_dead_hurt*, *aleep_issues*, *food_issues*, e *Last_GPA* para identificar o desempenho acadêmico baseado nas notas dos estudantes.

Entre o desempenho geral dos algoritmos avaliados, o cenário 18 (ver tabela 5.5), apresenta resultados que indicam maior coesão interna e melhor separação entre os clusters formados. No cenário 18 é possível perceber, pela avaliação, melhor separação inter-cluster ou o quão distantes estão os diferentes clusters uns dos outros, além de maior compacidade. De forma mais detalhada, o *Silhouette* 0.490757, *Calinski–Harabasz* 1050.142103 e *Davies–Bouldin* 0.771250, demonstram que o K- Means combinado com OHE e redução de dimensionalidade (PCA) apresentou o melhor resultado possível utilizando o conjunto de dados.

Embora o rendimento acadêmico tenha sido considerado desde o início do estudo, a forma de representação dessa variável difere entre os cenários analisados, em função da disponibilidade de informação no conjunto de dados. No Cenário 1, que também apresentou desempenho consistente, o rendimento acadêmico encontra-se representado por valores numéricos contínuos, o que possibilita análises quantitativas baseadas em medidas de posição e dispersão, tais como medianas e intervalos interquartis.

Já no Cenário 18, o rendimento acadêmico está disponível exclusivamente por meio de faixas de GPA, caracterizando-se como uma variável categórica ordinal. Dessa

forma, mesmo que se realizasse uma conversão numérica, a ausência de granularidade contínua inviabilizaria uma interpretação métrica adequada. Assim, o Cenário 1 foi utilizado como apoio para a representação gráfica da análise quantitativa complementar, enquanto o Cenário 18 permaneceu como referência principal para a avaliação da qualidade dos agrupamentos, garantindo coerência metodológica e respeito à natureza dos dados em cada cenário.

A Tabela 6.1 apresenta as médias das variáveis relacionadas ao estresse e ao desempenho acadêmico (*Last_GPA*) para os dois clusters identificados pelo algoritmo K-Means no cenário com codificação OHE e redução de dimensionalidade (PCA).

Neste sentido, nota-se que o **Cluster 0** apresenta valores médios mais elevados em todas as variáveis de estresse, destacando-se *tired_w_energy* (3.45), *Feeling_bad* (3.21) e *aleep_issues* (3.33). Esse grupo também apresenta o menor desempenho acadêmico médio (*Last_GPA* = 2.86).

Por outro lado, o **Cluster 1** apresenta valores consistentemente menores nas variáveis de estresse e maior média de desempenho acadêmico (*Last_GPA* = 3.16), indicando um perfil emocionalmente mais equilibrado e com melhor rendimento.

Esses resultados reforçam a hipótese de que maiores níveis de sintomas de estresse e cansaço estão associados a pior desempenho acadêmico, padrão confirmado pelas análises de correlação e pelas representações gráficas anteriores.


Tabela 6.1: Médias das variáveis de estresse e desempenho acadêmico por cluster

Variável	Cluster 0	Cluster 1
Feeling_depressed	2.98	1.58
tired_w_energy	3.45	2.29
Feeling_bad	3.21	1.75
concentrating_issues	2.85	1.63
slow_restless	2.27	1.36
better_dead_hurt	2.07	1.14
aleep_issues	3.33	2.30
food_issues	3.28	1.99
Last_GPA	2.86	3.16

A Figura 6.1 apresenta a distribuição do desempenho acadêmico (*Last_GPA*) para cada cluster identificado no cenário analisado. É perceptível, desta forma, que o **Cluster 1** apresenta mediana mais alta de desempenho (aproximadamente 3,4), enquanto o **Cluster 0** concentra valores menores e maior dispersão, com alguns casos extremos próximos de 1,0.

Esse resultado reforça o padrão já observado nas correlações e nas médias das variáveis de estresse, indicando que o grupo com *maior incidência de sintomas emocionais e físicos* também apresenta *pior desempenho acadêmico médio*. Dessa forma, o boxplot confirma visualmente a tendência de relação inversa entre estresse e rendimento estudantil.

Figura 6.1: Distribuição do desempenho acadêmico (*Last_GPA*) por cluster




A Figura 6.2 apresenta a média das variáveis associadas ao estresse e ao desempenho acadêmico (*Last_GPA*) para cada um dos dois clusters formados pelo algoritmo K-Means. O **Cluster 0** concentra as maiores médias nas variáveis de estresse, como *Feeling_depressed* (2.98), *tired_w_energy* (3.45) e *Feeling_bad* (3.21), indicando um grupo de indivíduos com níveis mais elevados de sintomas emocionais e físicos. Esse mesmo cluster apresentou o menor desempenho acadêmico médio (*Last_GPA* = 2.86).

Por outro lado, o **Cluster 1** apresentou médias mais baixas nas variáveis de estresse e maior desempenho acadêmico (*Last_GPA* = 3.16), representando um grupo com menor carga emocional e possivelmente melhor equilíbrio psicológico.

Esse contraste reforça a correlação inversa entre estresse e desempenho, evidenciada anteriormente pelas correlações negativas entre as variáveis, e sugere que níveis elevados de sintomas emocionais estão associados a piores resultados acadêmicos.

Diante das observações e análises feitas junto aos diferentes conjuntos de dados, é possível perceber que a preparação dos dados exerce papel fundamental no desempenho

Figura 6.2: Médias de variáveis de estresse e desempenho (*Last_GPA*) por cluster



dos algoritmos. Métricas isoladas não são suficientes para estabelecer a avaliação, outras medidas precisam ser utilizadas como suporte para a avaliação.

Mesmo com a garantia de boa separação de dados, conforme mostrado nos resultados do k-means, a métrica de similaridade, o silhouette score muitas vezes se mostra baixo, abaixo de 0.50. Neste sentido, é notável a necessidade da busca por possíveis outliers no conjunto formado pelos clusters. Neste sentido, na análise de clusters para casos específicos é necessário compreender o comportamento do algoritmo frente a saída de dados e buscar a adaptação de parâmetros ou mesmo teste com outros algoritmos.

Observando as métricas de avaliação, é possível perceber que o DBSCAN tem maior sensibilidade ao tipo de dados analisado. Se tratando de conjuntos que em sua maioria são categóricos. Além dos algoritmos baseados em densidade, as extensões do k-means, o k-mode e o k-prototype se comportaram de forma satisfatória.

A variação nas métricas de Silhouette, Calinski-Harabasz e Davies-Bouldin permitiu identificar tendências mais refinadas na formação dos clusters.

Nos cenários do K-Means (19–30), observou-se que os clusters formados mantêm boa coesão e separação, com índices de Silhouette variando entre 0,45 e 0,50, Calinski-Harabasz entre 400 e 460 e Davies-Bouldin entre 0,75 e 0,80. Estes números indicam consistência do K-Means em diferentes configurações de codificação. Nos cenários de DBSCAN (31–51), houve maior variação: a Silhouette ficou entre 0,18 e 0,23, enquanto o Calinski-Harabasz variou de 12 a 55 e o Davies-Bouldin entre 2,8 e 3,5. A presença

de ruído nos clusters, especialmente em alguns cenários (por exemplo, cenários 34 e 42), mostra a sensibilidade deste algoritmo a parâmetros e à densidade dos dados.

Comparando os métodos de codificação, o One-Hot Encoding se destacou em K-Means, garantindo clusters mais compactos, enquanto no DBSCAN, o Label Encoding apresentou ligeira redução na quantidade de pontos de ruído, embora ainda não atingisse o desempenho do K-Means.

Estes resultados indicam que, mesmo variando cenários e configurações, K-Means se mantém mais robusto para identificar padrões de interação entre ansiedade e depressão, enquanto DBSCAN exige ajustes cuidadosos de parâmetros e continua sensível à presença de ruído. A escolha da codificação e a redução de dimensionalidade demonstram impacto direto na definição dos clusters.

6.2 Considerações sobre o capítulo

O presente capítulo apresentou uma discussão sobre a correlação observável entre as variáveis de estresse e o desempenho acadêmico, permitindo identificar perfis distintos entre os clusters formados. As observações endossam o papel de importância da etapa de preparação dos dados e sua influência no desempenho dos algoritmos

Além disso, o capítulo apresenta observações das características internas de cada cluster formado por meio das médias das variáveis e nas representações gráficas (heat-maps e boxplots) possibilitando uma interpretação detalhada dos clusters, evidenciando a relação inversa entre estresse e desempenho.

7 CONCLUSÕES E TRABALHOS FUTUROS

O crescimento acelerado da geração de dados em larga escala gera também a necessidade de novas formas de análise de dados e compreensão das informações que esses dados carregam. Uma forma eficaz e bastante utilizada de descoberta de conhecimento em bases de dados é da clusterização. Neste estudo, é possível perceber que uma parcela da grande quantidade de abordagens de clusterização pode apresentar grandes variações e diferenças consideráveis ao processar um conjunto de dados.

Outra observação considerável é a da necessidade de avaliação dos algoritmos de clusterização para cenários poucos explorados quando se trata de correlação de questões como a saúde mental e o rendimento acadêmico. Todos os conjuntos de dados observados tem maior número de atributos categóricos, o que exige maior atenção ao preparo dos dados.

O objetivo deste trabalho foi realizar um estudo de avaliação comparativa do desempenho de diferentes técnicas de aprendizado não supervisionado, com foco em algoritmos de clusterização aplicados a dados educacionais compostos por variáveis acadêmicas, psicológicas e sociodemográficas de estudantes universitários. A proposta buscou identificar padrões ocultos entre grupos de estudantes, capazes de auxiliar na compreensão de aspectos relacionados ao desempenho, comportamento e perfil acadêmico.

Foram implementados e avaliados seis algoritmos amplamente discutidos na literatura: K-Means, DBSCAN, Agglomerative Clustering, OPTICS, K-Modes e K-Prototypes, representando abordagens distintas de agrupamento, baseadas em partição e densidade. O pré-processamento dos dados envolveu a aplicação da técnica *One-Hot Encoding* (OHE), padronização e tratamento de inconsistências, garantindo a homogeneidade necessária para o processamento computacional. Todos os experimentos foram realizados em ambiente Google Colab, utilizando Python e bibliotecas como *Scikit-Learn* e *NumPy*, assegurando a reprodutibilidade e a integridade das análises.

Os experimentos comparativos indicaram diferenças expressivas no desempenho dos algoritmos quanto à capacidade de formar grupos coerentes, à resistência a ruídos e à interpretabilidade dos resultados. O K-Means aplicado à redução de dimensionalidade destacou-se por apresentar o melhor equilíbrio entre precisão, estabilidade e qualidade dos agrupamentos, validando a hipótese de que a integração de técnicas de pré-processamento e redução de dimensionalidade pode aprimorar o desempenho das abordagens não supervisionadas.

Além disso, é notável que a inclusão de variáveis de natureza psicológica e sociodemográfica enriqueceu a análise, permitindo identificar padrões que vão além dos aspectos puramente acadêmicos. Essa ampliação de escopo contribui para uma visão mais holística do estudante, capaz de orientar a criação de estratégias pedagógicas personalizadas e políticas institucionais de apoio ao aprendizado.

Os resultados obtidos confirmam que a aplicação de algoritmos de aprendizado não supervisionado em contextos educacionais é tecnicamente viável e cientificamente relevante, permitindo a extração de informações de alto valor para a gestão e o planejamento acadêmico. Ainda que o estudo tenha alcançado seus objetivos e respondido à hipótese proposta, reconhece-se que as variações nos parâmetros de cada algoritmo, bem como o tamanho e a natureza das amostras, podem influenciar diretamente os resultados e merecem exploração mais aprofundada em futuras pesquisas.

7.1 Contribuições

Este trabalho apresentou contribuições significativas tanto do ponto de vista metodológico quanto aplicado. Entre as principais realizações e avanços obtidos, destacam-se:

- Análise comparativa de técnicas de aprendizado não supervisionado aplicadas a dados educacionais, fornecendo uma visão detalhada sobre as vantagens e limitações de cada algoritmo;
- Avaliação empírica do impacto da redução de dimensionalidade na precisão dos agrupamentos e na estabilidade estatística dos modelos;
- Desenvolvimento de um fluxo metodológico de pré-processamento padronizado, combinando normalização, codificação categórica (*OHE*) e preparação para uso em algoritmos de clusterização;
- Identificação de padrões latentes em dados multidimensionais de estudantes, contribuindo para o entendimento de relações entre desempenho, comportamento e perfil sociodemográfico;
- Análise experimental da eficiência do K-Means com redução de dimensionalidade, que se mostrou o modelo mais equilibrado entre custo computacional e desempenho geral.

É notável que este trabalho também reforça o papel das técnicas não supervisionadas como instrumentos promissores para descoberta de conhecimento em ambientes

educacionais, evidenciando o potencial da mineração de dados no apoio a decisões pedagógicas e estratégias institucionais.

7.1.1 Trabalhos Futuros

Embora os objetivos propostos tenham sido alcançados e as hipóteses confirmadas, há espaço para a ampliação e o aprofundamento das análises realizadas. Entre as possibilidades de trabalhos futuros, destacam-se:

- Inclusão de novos conjuntos de dados com maior volume e diversidade de variáveis, permitindo testar a escalabilidade e a generalização dos modelos;
- Exploração de técnicas híbridas que combinem métodos supervisionados e não supervisionados, a fim de integrar classificação e agrupamento em um mesmo fluxo analítico: criação de um modelo de recomendação.
- Aplicação das metodologias propostas em contextos reais de instituições de ensino, com o objetivo de testar a aplicabilidade prática dos resultados no acompanhamento de estudantes e no planejamento pedagógico;
- Implementação em ambientes distribuídos e de *Big Data*, para possibilitar o processamento em larga escala de informações educacionais e viabilizar análises contínuas e em tempo real.

Em perspectiva, espera-se que as contribuições apresentadas sirvam de base para o desenvolvimento de novas abordagens de análise educacional orientadas por dados, estimulando o uso da inteligência artificial como aliada na melhoria da qualidade do ensino e na personalização da aprendizagem.

REFERÊNCIAS

- AFOLABI, A. **Implementing K-Means Clustering**. 2023. Acesso em: 15 jan. 2025. Disponível em: <https://www.researchgate.net/publication/371371018_Implementing_K-Means_Clustering>.
- AHMED, M.; SERAJ, R.; ISLAM, S. M. S. The k-means algorithm: A comprehensive survey and performance evaluation. **Electronics**, MDPI, v. 9, n. 8, p. 1295, 2020.
- ALLOGHANI, M. et al. A systematic review on supervised and unsupervised machine learning algorithms for data science. **Supervised and unsupervised learning for data science**, Springer, p. 3–21, 2020.
- ASHABI, A.; SAHIBUDDIN, S. B.; HAGHIGHI, M. S. The systematic review of k-means clustering algorithm. In: **Proceedings of the 2020 9th international conference on networks, communication and computing**. [S.l.: s.n.], 2020. p. 13–18.
- BARLOW, H. B. Unsupervised learning. **Neural computation**, MIT Press One Rogers Street, Cambridge, MA 02142-1209, USA journals-info ..., v. 1, n. 3, p. 295–311, 1989.
- BATOOL, S. et al. Educational data mining to predict students' academic performance: A survey study. **Education and Information Technologies**, Springer, v. 28, n. 1, p. 905–971, 2023.
- CAO, F. et al. A dissimilarity measure for the k-modes clustering algorithm. **Knowledge-Based Systems**, Elsevier, v. 26, p. 120–127, 2012.
- CELEBI, M. E.; KINGRAVI, H. A. Deterministic initialization of the k-means algorithm using hierarchical clustering. **International Journal of Pattern Recognition and Artificial Intelligence**, World Scientific, v. 26, n. 07, p. 1250018, 2012.
- CHANGO, W. et al. A review on data fusion in multimodal learning analytics and educational data mining. **Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery**, Wiley Online Library, v. 12, n. 4, p. e1458, 2022.
- CHONG, B. et al. K-means clustering algorithm: a brief review. **Academic Journal of Computing & Information Science**, Francis Academic Press, v. 4, n. 5, p. 37–40, 2021.
- DAKE, D. K.; GYIMAH, E.; BUABENG-ANDOH, C. University students behaviour modelling using the k-prototype clustering algorithm. **Mathematical Problems in Engineering**, Wiley Online Library, v. 2023, n. 1, p. 5507814, 2023.
- DENG, D. Dbscan clustering algorithm based on density. In: IEEE. **2020 7th international forum on electrical engineering and automation (IFEEA)**. [S.l.], 2020. p. 949–953.
- DEWI, N. P. M. N. U.; DWIDASMARA, I. B. G. U. Implementation of k-modes algorithm for clustering of stress causes in university students. **Jurnal Elektronik Ilmu Komputer Udayana p-ISSN**, v. 2301, p. 5373, 2021.
- DOL, S. M.; JAWANDHIYA, P. M. Classification technique and its combination with clustering and association rule mining in educational data mining—a survey. **Engineering Applications of Artificial Intelligence**, Elsevier, v. 122, p. 106071, 2023.

- DUTT, A.; ISMAIL, M. A.; HERAWAN, T. A systematic review on educational data mining. **Ieee Access**, Ieee, v. 5, p. 15991–16005, 2017.
- ESTER, M. et al. A density-based algorithm for discovering clusters in large spatial databases with noise. In: **kdd**. [S.l.: s.n.], 1996. v. 96, n. 34, p. 226–231.
- EZUGWU, A. E. et al. Prairie dog optimization algorithm. **Neural Computing and Applications**, Springer, v. 34, n. 22, p. 20017–20065, 2022.
- FITZMAURICE, G. M. Regression. **Diagnostic histopathology**, Elsevier, v. 22, n. 7, p. 271–278, 2016.
- FOGAÇA, F. F. S. et al. Avaliando ansiedade e habilidades sociais de universitários durante a pandemia da covid-19. **Research, Society and Development**, v. 11, n. 14, p. e292111436137–e292111436137, 2022.
- FRANCIS, B. K.; BABU, S. S. Predicting academic performance of students using a hybrid data mining approach. **Journal of medical systems**, Springer, v. 43, n. 6, p. 162, 2019.
- GAO, C. X. et al. An overview of clustering methods with guidelines for application in mental health research. **Psychiatry Research**, Elsevier, v. 327, p. 115265, 2023.
- GHOSAL, A. et al. A short review on different clustering techniques and their applications. **Emerging technology in modelling and graphics**, Springer, p. 69–83, 2020.
- GOYAL, M.; AGGARWAL, S. A review on k-mode clustering algorithm. **International Journal of Advanced Research in Computer Science**, v. 8, n. 7, 2017.
- GUO, T. et al. Multimodal educational data fusion for students' mental health detection. **IEEE Access**, IEEE, v. 10, p. 70370–70382, 2022.
- HAHSLER, M.; PIEKENBROCK, M.; DORAN, D. dbscan: Fast density-based clustering with r. **Journal of Statistical Software**, v. 91, p. 1–30, 2019.
- HAN, H. Fuzzy clustering algorithm for university students' psychological fitness and performance detection. **Heliyon**, Elsevier, v. 9, n. 8, 2023.
- HERNÁNDEZ, H. et al. Application of the k-prototype clustering approach for the definition of geostatistical estimation domains. **Mathematics**, MDPI, v. 11, n. 3, p. 740, 2023.
- HOOSHYAR, D. et al. Clustering algorithms in an educational context: An automatic comparative approach. **IEEE Access**, IEEE, v. 8, p. 146994–147014, 2020.
- HUANG, L. et al. Machine learning in sustainable ship design and operation: A review. **Ocean Engineering**, Elsevier, v. 266, p. 112907, 2022.
- HUANG, Z. Extensions to the k-means algorithm for clustering large data sets with categorical values. **Data mining and knowledge discovery**, Springer, v. 2, n. 3, p. 283–304, 1998.

IHANTOLA, P. et al. Educational data mining and learning analytics in programming: Literature review and case studies. **Proceedings of the 2015 ITiCSE on working group reports**, p. 41–63, 2015.

ISA, N. et al. Analyzing factors of mental health problems among malaysian university students using clustering analysis. In: IEEE. **2022 3rd International Conference on Artificial Intelligence and Data Sciences (AiDAS)**. [S.l.], 2022. p. 164–169.

JAIN, A. K.; DUBES, R. C. **Algorithms for clustering data**. [S.l.]: Prentice-Hall, Inc., 1988.

Jl, H. Psychological analysis using artificial intelligence algorithms of online course learning of college students during covid-19. **Journal of the Knowledge Economy**, Springer, v. 16, n. 1, p. 3996–4018, 2024.

LEÃO, A. M. Prevalência e fatores associados à depressão e ansiedade entre estudantes universitários da área da saúde. 2018.

LIU, Y. et al. A survey of deep graph clustering: Taxonomy, challenge, application, and open resource. **arXiv preprint arXiv:2211.12875**, 2022.

LIU, Z. et al. Application of k-means clustering algorithm in analyzing college students' mental health. **2024 3rd International Conference on Artificial Intelligence and Autonomous Robot Systems (AIARS)**, p. 175–180, 2024.

LU, L. A comprehensive study on the relationship between user experience of mobile learning platforms and academic anxiety among college students. **International Journal of Interactive Mobile Technologies**, v. 19, n. 3, 2025.

LUO, M. Research on students' mental health based on data mining algorithms. **Journal of Healthcare Engineering**, Wiley Online Library, v. 2021, n. 1, p. 1382559, 2021.

MA, Y.; LIU, L. Hsnmf enables accurate and effective analysis for the college students' psychological health education data and student life data. In: FRONTIERS. **Frontiers in Education**. [S.l.], 2025. v. 10, p. 1624827.

MACQUEEN, J. Multivariate observations. In: **Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability**. [S.l.: s.n.], 1967. v. 1, p. 281–297.

MECHELEN, I. V. et al. Benchmarking in cluster analysis: A white paper. **arXiv preprint arXiv:1809.10496**, 2018.

MEEDECH, P.; IAM-ON, N.; BOONGOEN, T. Prediction of student dropout using personal profile and data mining approach. In: SPRINGER. **Intelligent and Evolutionary Systems: The 19th Asia Pacific Symposium, IES 2015, Bangkok, Thailand, November 2015, Proceedings**. [S.l.], 2015. p. 143–155.

MEIJER, P. C.; ZANTING, A.; VERLOOP, N. How can student teachers elicit experienced teachers' practical knowledge? tools, suggestions, and significance. **Journal of Teacher education**, Sage Publications Sage CA: Thousand Oaks, CA, v. 53, n. 5, p. 406–419, 2002.

MIHAESCU, M. C.; POPESCU, P. S. Review on publicly available datasets for educational data mining. **Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery**, Wiley Online Library, v. 11, n. 3, p. e1403, 2021.

ORLANDI, F. C. Mitigando o impacto de dados non-iid em federated learning com entropia. 2023.

PASIN, O.; GONENC, S. An investigation into epidemiological situations of covid-19 with fuzzy k-means and k-prototype clustering methods. **Scientific Reports**, Nature Publishing Group UK London, v. 13, n. 1, p. 6255, 2023.

PHAN, H. P.; NGU, B. H. Introducing the concept of consonance-disconsonance of best practice: a focus on the development of ‘student profiling’. **Frontiers in Psychology**, Frontiers Media SA, v. 12, p. 557968, 2021.

PHAN, Q.-T.; BOATO, G.; NATALE, F. G. D. Accurate and scalable image clustering based on sparse representation of camera fingerprint. **IEEE Transactions on Information Forensics and Security**, IEEE, v. 14, n. 7, p. 1902–1916, 2018.

POH, C. Q.; UBEYNARAYANA, C. U.; GOH, Y. M. Safety leading indicators for construction sites: A machine learning approach. **Automation in construction**, Elsevier, v. 93, p. 375–386, 2018.

PORELLO, D. et al. Early detection of mental and behavioral health issues from high-school academic performance. In: IEEE. **2023 International Conference on Machine Learning and Applications (ICMLA)**. [S.l.], 2023. p. 376–383.

PREETHA, V. Data analysis on student’s performance based on health status using genetic algorithm and clustering algorithms. In: IEEE. **2021 5th International Conference on Computing Methodologies and Communication (ICCMC)**. [S.l.], 2021. p. 836–842.

RADHAKRISHNAN, T. et al. Detection of behavioral health challenges in high school students. In: IEEE. **2024 International Conference on Machine Learning and Applications (ICMLA)**. [S.l.], 2024. p. 55–62.

RENJITH, S.; SREEKUMAR, A.; JATHAVEDAN, M. An extensive study on the evolution of context-aware personalized travel recommender systems. **Information Processing & Management**, Elsevier, v. 57, n. 1, p. 102078, 2020.

RIBEIRO, R. C.; CANEDO, E. D. Using data mining techniques to perform school dropout prediction: a case study. In: SPRINGER. **17th international conference on information technology–new generations (ITNG 2020)**. [S.l.], 2020. p. 211–217.

RODRIGUEZ, M. Z. et al. Clustering algorithms: A comparative approach. **PloS one**, Public Library of Science San Francisco, CA USA, v. 14, n. 1, p. e0210236, 2019.

SANTOS, F. A. d. L. et al. Relationship of anxiety and stress in academic performance in evaluations under active methodology. **Research, Society and Development**, v. 10, n. 9, p. e15810917843, 2021. Disponível em: <<https://rsdjournal.org/index.php/rsd/article/view/17843>>.

- SERRA-BURRIEL, M.; AMES, C. Machine learning-based clustering analysis: foundational concepts, methods, and applications. In: **Machine Learning in Clinical Neuroscience: Foundations and Applications**. [S.l.]: Springer, 2021. p. 91–100.
- SHETTY, P.; SINGH, S. Hierarchical clustering: a survey. **International Journal of Applied Research**, v. 7, n. 4, p. 178–181, 2021.
- SINAGA, K. P.; YANG, M.-S. Unsupervised k-means clustering algorithm. **IEEE access**, IEEE, v. 8, p. 80716–80727, 2020.
- TOKUDA, E. K.; COMIN, C. H.; COSTA, L. d. F. Revisiting agglomerative clustering. **Physica A: Statistical mechanics and its applications**, Elsevier, v. 585, p. 126433, 2022.
- VERBRAEKEN, J. et al. A survey on distributed machine learning. **Acm computing surveys (csur)**, Acm New York, NY, USA, v. 53, n. 2, p. 1–33, 2020.
- VERMA, M. et al. A comparative study of various clustering algorithms in data mining. **International Journal of Engineering Research and Applications (IJERA)**, Citeseer, v. 2, n. 3, p. 1379–1384, 2012.
- WEGMANN, M. et al. A review of systematic selection of clustering algorithms and their evaluation. **arXiv preprint arXiv:2106.12792**, 2021.
- WULANDARI, D. A. N. et al. An educational data mining for student academic prediction using k-means clustering and naïve bayes classifier. **Jurnal PILAR Nusa Mandiri**, Universitas Bina Sarana Informatika, v. 16, n. 2, p. 125–132, September 2020. ISSN 1978-1946. Sistem Informasi Kampus Kota Bogor, Kampus Kota Pontianak, Universitas Bina Sarana Informatika. Disponível em: <<https://ejournal.nusamandiri.ac.id/index.php/pilar/article/view/1751>>.
- ZAFAR, A.; RANI, K. S. Novel initialization strategy for k-modes clustering algorithm. In: SPRINGER. **Proceedings of International Conference on Big Data, Machine Learning and Applications: BigDML 2019**. [S.l.], 2021. p. 89–100.