



**UNIVERSIDADE ESTADUAL DA PARAÍBA
CAMPUS I - CAMPINA GRANDE
PRÓ-REITORIA DE PÓS-GRADUAÇÃO E PESQUISA
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA E TECNOLOGIA EM
SAÚDE
MESTRADO PROFISSIONAL EM CIÊNCIA E TECNOLOGIA EM SAÚDE**

ANA CÉLIA ROCHA DE MEDEIROS

**SISTEMAS DE INTELIGÊNCIA ARTIFICIAL PARA DOCUMENTAÇÃO
CLÍNICA: REVISÃO DE ESCOPO**

CAMPINA GRANDE-PB

2026

ANA CÉLIA ROCHA DE MEDEIROS

**SISTEMAS DE INTELIGÊNCIA ARTIFICIAL PARA DOCUMENTAÇÃO
CLÍNICA: REVISÃO DE ESCOPO**

Dissertação apresentada ao Programa de Pós-graduação em Ciência e Tecnologia em Saúde da Universidade Estadual da Paraíba como requisito à obtenção do título de Mestre em Ciência e Tecnologia em Saúde.

Área de Concentração:
Desenvolvimento de Produtos e Processos para Tecnologia em Saúde

Orientador: Dr. Edmar Candeia Gurjão

CAMPINA GRANDE-PB

2026

É expressamente proibida a comercialização deste documento, tanto em versão impressa como eletrônica. Sua reprodução total ou parcial é permitida exclusivamente para fins acadêmicos e científicos, desde que, na reprodução, figure a identificação do autor, título, instituição e ano do trabalho.

M488s Medeiros, Ana Célia Rocha de.
Sistemas de inteligência artificial para
documentação clínica: revisão de escopo [manuscrito] /
Ana Célia Rocha de Medeiros. - 2026.
97 f.

Digitado.

Dissertação (Mestrado Profissional em Ciência e
Tecnologia em Saúde) - Universidade Estadual da
Paraíba, Centro de Ciências e Tecnologia, 2026.

"Orientação : Prof. Dr. Edmar Candeia Gurjão,
Nutes".

1. Inteligência artificial. 2. Reconhecimento de fala.
3. Processamento de linguagem natural. 4. Registros
eletrônicos de saúde. 5. Segurança do paciente. I.
Título

21. ed. CDD 006.3

ANA CELIA ROCHA DE MEDEIROS

SISTEMAS DE INTELIGÊNCIA ARTIFICIAL PARA DOCUMENTAÇÃO CLÍNICA:
REVISÃO DE ESCOPO

Dissertação apresentada à
Coordenação do Curso de Mestrado
Profissional em Ciência e
Tecnologia em Saúde da
Universidade Estadual da Paraíba,
como requisito parcial à obtenção
do título de Mestra em Ciência e
Tecnologia em Saúde

Linha de Pesquisa:
Desenvolvimento de Produtos e
Processos para tecnologia em S.

Aprovada em: 06/04/2026.

BANCA EXAMINADORA

Documento assinado eletronicamente por:

- **Edmar Candeia Gurjão** (***.642.454-**), em **06/05/2026 11:08:17** com chave **077f8472495511f1a8b536e332844d7b**.
- **Katia Elizabete Galdino** (***.461.834-**), em **06/05/2026 11:39:23** com chave **5fc939f8495911f1a1cec2600da1152d**.
- **Bruno Medeiros Roldão de Araújo** (***.190.834-**), em **06/05/2026 13:11:37** com chave **429e7d86496611f1b81636e332844d7b**.

Documento emitido pelo SUAP. Para comprovar sua autenticidade, faça a leitura do QRCode ao lado ou acesse https://suap.uepb.edu.br/comum/autenticar_documento/ e informe os dados a seguir.

Tipo de Documento: Folha de Aprovação do Projeto Final

Data da Emissão: 06/05/2026

Código de Autenticação: 1901bd



Aos meus filhos Miguel e Matheus, a
quem tenho procurado deixar o legado
do estudo.

Aos meus pais que puderam ter a honra
do estudo, apenas através de seus filhos.

AGRADECIMENTOS

Agradeço, primeiramente, ao Criador do Universo, fonte de existência, sabedoria e sentido, por sustentar cada etapa desta trajetória e possibilitar a concretização deste trabalho.

Ao meu orientador, expresso minha profunda gratidão pela paciência, pelos ensinamentos, pelo compromisso com a Ciência e pelas contribuições fundamentais ao desenvolvimento deste trabalho. Professor Edmar, palavras não descrevem o quanto sou grata por sua existência.

À minha família, agradeço pelo apoio incondicional, pela compreensão nos momentos de ausência e pelo incentivo constante em todos os meus projetos. Este trabalho também é fruto da confiança e do suporte que sempre me foram oferecidos.

Aos profissionais do Sistema Único de Saúde, minha admiração e reconhecimento pelo trabalho diário, muitas vezes realizado em condições desafiadoras, mas sempre pautado pelo compromisso com o cuidado, a equidade e a dignidade humana. Este estudo se inspira na realidade vivenciada nesses contextos e na busca por soluções que possam contribuir, ainda que modestamente, para o fortalecimento da prática assistencial.

A todos que, direta ou indiretamente, contribuíram para a realização desta pesquisa, meus sinceros agradecimentos.

RESUMO

A documentação clínica é fundamental para a continuidade do cuidado e a segurança do paciente, porém está associada a elevada carga administrativa. Tecnologias baseadas em inteligência artificial, incluindo reconhecimento automático de fala e grandes modelos de linguagem, têm sido propostas para automatizar esse processo. No entanto, evidências sobre seu desempenho em cenários clínicos reais ainda são limitadas. Neste trabalho buscamos sintetizar as evidências científicas disponíveis sobre a aplicação de sistemas de ASR e LLMs na documentação clínica, com ênfase na acurácia, na eficiência e na segurança do paciente. Métodos: Foi conduzida uma revisão de escopo seguindo as diretrizes PRISMA. A busca foi realizada em bases de dados eletrônicas e literatura cinzenta, incluindo estudos publicados entre 2015 e 2025. Foram incluídos estudos primários que avaliaram sistemas de transcrição automática de fala em contextos clínicos reais. A seleção dos estudos, extração de dados e avaliação do risco de viés foram realizadas por revisores independentes. Resultados: Quatro estudos foram incluídos, com delineamentos heterogêneos. Sistemas baseados em reconhecimento automático de fala apresentaram taxas variáveis de erro, especialmente na ausência de revisão humana. Modelos baseados em linguagem demonstraram melhora na estruturação das notas clínicas, porém introduziram riscos de geração de informações incorretas. Foram observados ganhos de eficiência, parcialmente compensados pela necessidade de validação. A qualidade estrutural dos registros foi superior, mas nem sempre refletiu maior precisão clínica. Foram identificados riscos à segurança do paciente relacionados a erros de transcrição e distorções semânticas. Conclusão: Sistemas de inteligência artificial aplicados à documentação clínica apresentam potencial para melhorar a eficiência e a organização dos registros, porém ainda não são suficientemente confiáveis para uso autônomo. Seu uso deve ocorrer com supervisão humana e integração a mecanismos de segurança. Evidências mais robustas são necessárias para avaliação de impacto clínico.

Palavras-chave: inteligência artificial; reconhecimento de fala; processamento de linguagem natural; registros eletrônicos de saúde; segurança do paciente.

ABSTRACT

Clinical documentation is essential for continuity of care and patient safety, but it is also associated with a substantial administrative burden. Artificial intelligence (AI) technologies, including automatic speech recognition (ASR) and large language models (LLMs), have been proposed to automate this process. However, evidence regarding their performance in real-world clinical settings remains limited. Objective: To synthesize the available scientific evidence on the application of ASR systems and LLMs in clinical documentation, with emphasis on accuracy, efficiency, and patient safety. Methods: A scoping review was conducted according to PRISMA guidelines. Searches were performed in electronic databases and gray literature, including studies published between 2015 and 2025. Primary studies evaluating automated speech transcription systems in real clinical settings were included. Study selection, data extraction, and risk-of-bias assessment were performed independently by reviewers. Results: Four heterogeneous studies were included. ASR-based systems showed variable error rates, particularly in the absence of human review. Language-model-based systems improved the structure and organization of clinical notes, but also introduced risks related to the generation of inaccurate information. Efficiency gains were observed, although partially offset by the need for human validation. Structural quality of documentation improved, but this did not always correspond to greater clinical accuracy. Patient safety risks associated with transcription errors and semantic distortions were identified. Conclusions: AI systems applied to clinical documentation show potential to improve efficiency and organization of medical records; however, they are not yet sufficiently reliable for autonomous use. Their implementation should occur under human supervision and integrated safety mechanisms. More robust evidence is needed to evaluate their clinical impact.

Keywords: artificial intelligence; speech recognition; natural language processing; electronic health records; patient safety.

LISTA DE ILUSTRAÇÕES

FIGURA 1: Conversão de áudio da fala em sua transcrição textual -----21

FIGURA 2: Diagrama de Fluxo PRISMA 2020 -----39

LISTA DE SIGLAS E ABREVIATURAS

API - Appropriateness of Prehospital Information (Adequação da Informação Pré-Hospitalar)

ASR - Automatic Speech Recognition (Reconhecimento Automático de Fala)

BART - Bidirectional and Auto-Regressive Transformers

BERT - Bidirectional Encoder Representations from Transformers

CER - Character Error Rate (Taxa de Erro de Caracteres)

CINAHL - Cumulative Index to Nursing and Allied Health Literature

CNN - Convolutional Neural Network (Rede Neural Convolucional)

DNN - Deep Neural Network (Rede Neural Profunda)

DOI - Digital Object Identifier (Identificador de Objeto Digital)

EHR - Electronic Health Record (Prontuário Eletrônico de Saúde)

EMR - Electronic Medical Record (Registro Médico Eletrônico)

FDA - Food and Drug Administration (Administração de Alimentos e Medicamentos dos Estados Unidos)

GMM - Gaussian Mixture Model (Modelo de Mistura Gaussiana)

GPT - Generative Pre-trained Transformer (Transformador Pré-treinado Generativo)

GRU - Gated Recurrent Unit (Unidade Recorrente com Portões)

HMM - Hidden Markov Model (Modelo Oculto de Markov)

IA - Inteligência Artificial

LLM - Large Language Model (Modelo de Linguagem de Grande Porte)

LSTM - Long Short-Term Memory (Memória de Curto e Longo Prazo)

MFCC - Mel-Frequency Cepstral Coefficients (Coeficientes Cepstrais de Frequência Mel)

NHS - National Health Service (Serviço Nacional de Saúde do Reino Unido)

NLP - Natural Language Processing (Processamento de Linguagem Natural)

NPfIT - National Programme for Information Technology (Programa Nacional de Tecnologia da Informação do Reino Unido)

OMS - Organização Mundial da Saúde

PEC - Prontuário Eletrônico do Cidadão

PLN - Processamento de Linguagem Natural

PNIS - Política Nacional de Informação e Informática em Saúde

PICO - Population, Intervention, Comparison, Outcome (População, Intervenção, Comparação, Desfecho)

PRISMA - Preferred Reporting Items for Systematic Reviews and Meta-Analyses (Itens Preferenciais para Relato de Revisões Sistemáticas e Meta-Análises)

RCT - Randomized Controlled Trial (Ensaio Clínico Randomizado Controlado)

RNN - Recurrent Neural Network (Rede Neural Recorrente)

SNR - Signal-to-Noise Ratio (Relação Sinal-Ruído)

SUS - Sistema Único de Saúde

TAM - Technology Acceptance Model (Modelo de Aceitação de Tecnologia)

WER - Word Error Rate (Taxa de Erro de Palavras)

LISTA DE QUADROS

QUADRO1: Elaboração do acrônimo PICO e pergunta de pesquisa -----	40
QUADRO 2: Tabela de extração dos estudos -----	51
QUADRO 3: Tabela de Síntese dos Desfechos da Inteligência Artificial na Documentação Clínica-----	55
QUADRO 4: Caracterização dos estudos incluídos na revisão-----	57

SUMÁRIO

1 INTRODUÇÃO	13
2. REFERENCIAL TEÓRICO E ESTADO DA ARTE	15
2.1 EVOLUÇÃO DA DOCUMENTAÇÃO CLÍNICA.....	15
2.2 PRONTUÁRIOS ELETRÔNICOS DE SAÚDE (EHR)	17
2.3 TECNOLOGIAS DE RECONHECIMENTO AUTOMÁTICO DE FALA (ASR)	
20	
2.3.1 Fundamentos Tecnológicos do ASR.....	20
2.3.2 Evolução Histórica do ASR (1990-2025).....	21
2.3.3 Arquiteturas e Modelos: De HMM a Transformers.....	23
2.3.4 Métricas de Desempenho: WER, Acurácia e Tempo.....	25
2.4 FUNDAMENTOS DE PROCESSAMENTO DE LINGUAGEM NATURAL	
(NLP).....	26
2.4.1 Modelos de Linguagem: Tradicionais versus Modernos.....	27
2.4.2 Whisper: O Modelo de Referência da Era Pós-Transformers	29
2.5 ALUCINAÇÕES EM MODELOS DE LINGUAGEM E SEGURANÇA DO	
PACIENTE NA DOCUMENTAÇÃO CLÍNICA.....	31
3 OBJETIVOS	34
4 MÉTODO	35
4.1 DESENHO DO ESTUDO E PROTOCOLO.....	35
4.3 AVALIAÇÃO DOS DESFECHOS E CARACTERÍSTICAS DOS ESTUDOS..	36
4.4 ELEGIBILIDADE DOS ESTUDOS.....	36
4.5 FONTES DE INFORMAÇÃO E ESTRATÉGIA DE BUSCA.....	37
4.6 SELEÇÃO DOS ESTUDOS E EXTRAÇÃO DE DADOS	38
4.7 AVALIAÇÃO DO RISCO DE VIÉS DOS ESTUDOS INCLUÍDOS	50
4.8 SÍNTESE DOS DADOS	55
5 RESULTADOS.....	57

5.1 CARACTERIZAÇÃO DOS ESTUDOS INCLUÍDOS	57
5.2 ACURÁCIA DE TRANSCRIÇÃO	58
5.3 EFICIÊNCIA E IMPACTO NO TEMPO DE DOCUMENTAÇÃO	60
5.4 QUALIDADE DOS DOCUMENTOS GERADOS POR LLMS.....	62
5.5 SEGURANÇA E RISCOS À DOCUMENTAÇÃO CLÍNICA.....	63
5.6 SATISFAÇÃO DOS USUÁRIOS E FATORES ASSOCIADOS	64
5.7 HETEROGENEIDADE METODOLÓGICA E SÍNTESE NARRATIVA	64
5.8 SÍNTESE INTEGRADA DOS ACHADOS	64
6 DISCUSSÃO	66
6.1 LACUNAS E IMPLICAÇÕES PARA O CONTEXTO BRASILEIRO	71
6.2 LIMITAÇÕES DESTA REVISÃO.....	72
7 CONCLUSÃO.....	74
REFERENCIAS	76
ANEXO A: TABELA DE ESTRATÉGIAS DE BUSCAS REALIZADAS.....	85

1 INTRODUÇÃO

A documentação clínica é um pilar essencial da prática médica contemporânea, fundamental para a continuidade do cuidado e para a segurança do paciente. Contudo, a transição para os Registros Eletrônicos de Saúde (RES/EHR) impôs uma sobrecarga administrativa significativa, levando clínicos a dedicar uma parcela expressiva de sua jornada a atividades burocráticas, associadas ao fenômeno de exaustão profissional (MOY *et al.*, 2021; SKEFF *et al.*, 2022). Nesse cenário, as tecnologias de Reconhecimento Automático de Fala (ASR) e os Grandes Modelos de Linguagem (LLMs) emergem como soluções promissoras para automação da documentação clínica (NG *et al.*, 2025).

O desenvolvimento do ASR evoluiu de modelos probabilísticos baseados em Modelos Ocultos de Markov (HMM) (JELINEK, 1998; YOUNG *et al.*, 2002) para arquiteturas de aprendizado profundo (DNN-HMM) (HINTON *et al.*, 2012) e sistemas end-to-end baseados em Transformers a partir de 2017 (VASWANI *et al.*, 2017). Essa trajetória atingiu um marco significativo com o modelo Whisper, um sistema de propósito geral treinado em escala sem precedentes (680.000 horas de áudio), que permite transcrições com alta qualidade, incluindo pontuação e capitalização automáticas (RADFORD *et al.*, 2023; GRIS *et al.*, 2023).

Todavia, a literatura empírica sobre a implementação dessas tecnologias em fluxos clínicos reais ainda é incipiente e fragmentada. Embora modelos generalistas demonstrem acurácia técnica elevada em ambientes controlados, sua aplicação na saúde exige uma análise integrada que transcenda o desempenho métrico. A segurança do paciente, sob a ótica da Teoria das Defesas em Profundidade de REASON (2000), estabelece que a tecnologia não substitui, mas exige a revisão humana como camada de proteção indispensável. Evidências indicam que, sem revisão, 63,6% das notas geradas por ASR contêm erros clinicamente significativos, índice que se reduz a 7,8% somente após duplo ciclo de revisão por transcritores e médicos (ZHOU *et al.*, 2018). Além disso,

a integração com LLMs introduz o risco das alucinações¹, gerando informações clinicamente plausíveis, porém factualmente incorretas (JI *et al.*, 2023).

Uma lacuna crítica reside na ausência de evidências no contexto brasileiro. A maioria dos estudos foca em idiomas como inglês e mandarim, ignorando as particularidades fonéticas e dialetais do português brasileiro e as especificidades infraestruturais do Sistema Único de Saúde (SUS) (BATISTA, 2019; LOPES *et al.*, 2021). Essa carência representa um risco à implementação responsável, dado que o desempenho de sistemas como o Whisper e o GPT-4o pode degradar-se significativamente diante da diversidade linguística e de sotaques regionais do Brasil (BATISTA, 2019).

Diante deste panorama, esta dissertação propõe-se a responder à seguinte pergunta de pesquisa, estruturada sob o acrônimo PCC: Quais são as evidências disponíveis sobre o uso de sistemas de reconhecimento automático de fala e grandes modelos de linguagem aplicados à documentação clínica, em termos de acurácia, eficiência, qualidade dos registros e segurança do paciente, em ambientes de atenção à saúde com uso de prontuário eletrônico?. O recorte temporal de 2015 a 2025 justifica-se pela ruptura tecnológica iniciada com o aprendizado profundo e consolidada pelos Transformers, cujos avanços tornaram os estudos anteriores metodologicamente defasados para a realidade clínica atual (VASWANI *et al.*, 2017; RADFORD *et al.*, 2023).

¹ Alucinação em LLMs designa a geração de informações sem correspondência com a realidade ou com os dados fornecidos, apresentadas pelo modelo como se fossem verídicas (JI *et al.*, 2023).

2. REFERENCIAL TEÓRICO E ESTADO DA ARTE

2.1 EVOLUÇÃO DA DOCUMENTAÇÃO CLÍNICA

A documentação clínica constitui um dos pilares fundamentais da prática médica moderna, desempenhando papel essencial na continuidade do cuidado, na comunicação interprofissional, na segurança do paciente e na produção de dados para a gestão, a vigilância epidemiológica e a pesquisa científica (FALCETTA, 2023). Historicamente, os registros médicos eram mantidos exclusivamente em suporte físico, caracterizados por anotações manuscritas em prontuários de papel que acompanhavam o paciente ao longo de sua trajetória assistencial (BALDWIN, 2025). Este modelo tradicional, embora amplamente utilizado durante décadas, apresentava limitações significativas quanto à legibilidade, à padronização, à integridade, à disponibilidade e à acessibilidade das informações (BALDWIN, 2025; CAMPANELLA, 2016).

A transição dos registros em papel para sistemas digitais representa uma das transformações mais significativas na história da medicina moderna. Durante a segunda metade do século XX, os primeiros sistemas computadorizados de informações em saúde começaram a ser desenvolvidos em instituições acadêmicas e hospitais de referência, inicialmente focados em funções administrativas e de faturamento (SHORTLIFFE, 2021). A evolução tecnológica gradual permitiu a expansão desses sistemas para incluir funcionalidades clínicas, culminando no desenvolvimento dos prontuários eletrônicos de saúde (*Electronic Health Records* – EHR) tal como conhecidos atualmente (SALEEM, 2020).

A adoção de prontuários eletrônicos acelerou-se significativamente nas primeiras décadas do século XXI, impulsionada por políticas públicas, incentivos governamentais e avanços tecnológicos. Nos Estados Unidos, o *Health Information Technology for Economic and Clinical Health Act* (HITECH Act), promulgado em 2009 como parte do *American Recovery and Reinvestment Act*, representou um marco regulatório fundamental ao estabelecer incentivos financeiros substanciais para a adoção e uso significativo (*meaningful use*) de sistemas de EHR certificados (XU, 2025). Na Europa, diferentes países adotaram estratégias nacionais para a implementação de sistemas de

informação em saúde, com variações significativas no grau de centralização, padronização e cobertura populacional (HAMMANA *et al.*, 2015). O Reino Unido, por exemplo, implementou o ambicioso programa *National Programme for Information Technology* (NPfIT) entre 2002 e 2011, que, apesar de desafios e custos elevados, contribuiu para a disseminação de sistemas eletrônicos no *National Health Service* (NHS) (BLACKLEY *et al.*, 2019). Já os países nórdicos, como Dinamarca e Suécia, destacaram-se pela implementação precoce e bem-sucedida de sistemas nacionais integrados de informações em saúde (KHEDDAR *et al.*, 2024).

No contexto brasileiro, a informatização dos serviços de saúde ocorreu de forma heterogênea e descentralizada. O Sistema Único de Saúde (SUS) desenvolveu diversos sistemas de informação ao longo das décadas, inicialmente focados na vigilância epidemiológica e na gestão administrativa (PINTO *et al.*, 2016). A partir de 2016, iniciativas voltadas para a Estratégia de Saúde Digital (ESD28) começaram a ser propostas, tais como: a Política Nacional de Informação e Informática em Saúde (PNIIS), o Plano de Ação, Monitoramento e Avaliação 2019-2023 (PAMMA), considerado um marco relevante para o estabelecimento da interoperabilidade entre programas e projetos, e o Documento Estratégia para o e-Saúde no Brasil. Para a materialização da Estratégia de Saúde Digital, foi criado o Conecte SUS, cujos eixos principais são a Rede Nacional de Dados em Saúde (RNDS) e o Programa de Apoio à Informatização e Qualificação dos Dados da Atenção Primária à Saúde (ZARA *et al.*, 2021). A Estratégia e-SUS Atenção Básica, lançada em 2013, representou um esforço de padronização e modernização dos sistemas de informação na atenção primária, introduzindo o Prontuário Eletrônico do Cidadão (PEC) como ferramenta de registro clínico estruturado, ao tempo em que, no setor privado e em instituições de maior porte, a adoção de sistemas comerciais de EHR vem expandindo-se progressivamente, embora com desafios relacionados à interoperabilidade, aos custos de implementação e à resistência profissional (PINTO *et al.*, 2016).

Neste movimento, através da portaria GM/MS nº 3.232/2024 foi instituído o Programa SUS Digital, que tem como escopo a intersecção entre tecnologia, informação e saúde, incorporando software, hardware e serviços como parte do processo de transformação digital, englobando, sistemas de informação interoperáveis, registro eletrônico de dados de saúde, aplicação da ciência de dados, inteligência artificial, telemedicina, telessaúde, aplicações móveis de saúde, dispositivos vestíveis, robótica

aplicada, medicina personalizada e internet das coisas, entre outras iniciativas que envolvam a tecnologia voltados ao setor de saúde (BRASIL, 2024).

2.2 PRONTUÁRIOS ELETRÔNICOS DE SAÚDE (EHR)

Os prontuários eletrônicos de saúde (*Electronic Health Records* – EHR) constituem sistemas computadorizados abrangentes projetados para armazenar, gerenciar e facilitar o acesso a informações clínicas e administrativas dos pacientes ao longo do tempo (LYBARGER *et al.*, 2018). Diferentemente dos registros médicos eletrônicos (*Electronic Medical Records* – EMR), que geralmente se limitam aos dados de uma única instituição, os EHR são concebidos para integrar informações provenientes de múltiplos prestadores de serviços e contextos assistenciais, permitindo a continuidade do cuidado e a coordenação entre diferentes níveis de atenção (Häyrinen *et al.*, 2008).

De acordo com Mandel e colaboradores (2016) a arquitetura técnica dos sistemas de EHR evoluiu significativamente ao longo das últimas décadas, de modo que os sistemas contemporâneos passaram, frequentemente, a adotar arquiteturas baseadas em serviços (*service-oriented architecture*), computação em nuvem e interfaces de programação de aplicações (APIs) de modo que a adoção de padrões como *Health Level Seven* (HL7), *Fast Healthcare Interoperability Resources* (FHIR) e *Digital Imaging and Communications in Medicine* (DICOM), possibilitou o intercâmbio seguro e eficiente de informações entre diferentes plataformas, permitindo a interoperabilidade entre os mesmos.

A adoção de sistemas de EHR apresenta variações substanciais entre países e regiões, refletindo diferenças em políticas públicas, investimentos em infraestrutura tecnológica, modelos de financiamento da saúde e culturas organizacionais (KRUSE *et al.*, 2016). Em países de alta renda, particularmente nos Estados Unidos, na Europa Ocidental e na Oceania, apresentam-se taxas de adoção mais elevadas, frequentemente superiores a 80% em hospitais e clínicas de maior porte (ADLER-MILSTEIN *et al.*, 2015). No contexto brasileiro, a adoção de EHR caracteriza-se por uma significativa heterogeneidade entre regiões geográficas, níveis de atenção e natureza jurídica das instituições (BARBALHO *et al.*, 2022). No setor público, o Sistema Único de Saúde (SUS) desenvolveu diversos sistemas de informação ao longo das décadas, incluindo o

Sistema de Informação Ambulatorial (SIA-SUS), o Sistema de Informação Hospitalar (SIH-SUS) e, mais recentemente, a Estratégia e-SUS Atenção Básica (CAVALCANTE *et al.*, 2018).

Ainda no Brasil, de acordo com os estudos de Oliveira (2016), o Prontuário Eletrônico do Cidadão (PEC), componente da estratégia e-SUS, representa um esforço de padronização da documentação clínica na atenção primária, embora sua implementação enfrente desafios relacionados à infraestrutura tecnológica, à conectividade de internet e à capacitação profissional, particularmente em municípios de menor porte e em regiões remotas. No setor privado, por sua vez, a adoção de sistemas comerciais de EHR é mais prevalente, com diversos fornecedores nacionais e internacionais oferecendo soluções adaptadas às necessidades do mercado brasileiro. Entretanto, a fragmentação do mercado e a ausência de obrigatoriedade nos padrões de interoperabilidade resultam em sistemas frequentemente isolados, dificultando o compartilhamento de informações entre instituições e comprometendo a continuidade do cuidado (PATRÍCIO *et al.*, 2011; CAVALCANTE *et al.*, 2019).

Cabe destacar que há um marco regulatório, com a Estratégia de Saúde Digital pelo Brasil, segundo o qual o padrão HL7 FHIR (*Fast Healthcare Interoperability Resources*), na sua especificação R4, é o padrão oficial de interoperabilidade adotado no país para a troca de informações de saúde. A sua obrigatoriedade e implementação são fundamentadas na Política Nacional de Informação e Informática em Saúde (PNIIS), que tem como base a Portaria de Consolidação GM/MS nº 2, de 28 de setembro de 2017, com alterações recentes que consolidam o FHIR, sobretudo a Rede Nacional de Dados em Saúde (RNDS) (ZARA *et al.*, 2021).

Todavia, apesar dos benefícios documentados, a implementação e uso de sistemas de EHR, ainda, enfrentam desafios que limitam a realização plena de seu potencial, tais como usabilidade inadequada, que constitui uma das críticas mais frequentes, com interfaces complexas, fluxos de trabalho não intuitivos e excesso de cliques necessários para completar tarefas simples (RATWANI *et al.*, 2018). A interoperabilidade limitada representa outro desafio crítico, gerando fragmentação que compromete a continuidade do cuidado, particularmente para pacientes que transitam entre diferentes instituições e níveis de atenção (CAVALCANTE *et al.*, 2019). O uso excessivo de funcionalidades de copiar e colar, que resultam em notas clínicas extensas, redundantes e frequentemente

desatualizadas, dificulta a identificação de informações relevantes e compromete a qualidade da documentação (HIRSCHTICK, 2006). Evidências indicam que 21,1% dos pacientes conseguem identificar erros em seus prontuários eletrônicos, dos quais 42,3% são considerados graves (FALCETTA *et al.*, 2023).

Custos de implementação e manutenção são substanciais, incluindo a aquisição de licenças de software e hardware, custos de customização, treinamento, suporte técnico e atualizações contínuas (JHA *et al.*, 2009). Para instituições de menor porte e em contextos de recursos limitados, tais custos podem ser proibitivos, contribuindo para disparidades no acesso a tecnologias da informação em saúde (KRUSE *et al.*, 2016).

Há, ainda, o fator da resistência profissional à adoção de EHR, amplamente documentada, que reflete preocupações legítimas quanto ao impacto na autonomia profissional, na relação médico-paciente e na carga de trabalho (KRUSE *et al.*, 2016). Estudos qualitativos revelam que médicos frequentemente percebem os sistemas de EHR como imposições administrativas que priorizam necessidades de faturamento e conformidade regulatória em detrimento das necessidades clínicas (SKEFF *et al.*, 2022).

Para Holden *et al.* (2011), o impacto dos sistemas de EHR no trabalho dos profissionais de saúde é multifacetado e frequentemente contraditório. Por um lado, os EHR facilitam o acesso a informações clínicas, melhoram a coordenação do cuidado e reduzem certos tipos de erros. Por outro lado, introduzem novas demandas cognitivas, aumentam a carga administrativa e alteram a natureza do trabalho clínico.

Estudos apontam que médicos ambulatoriais gastam 49,2% do tempo em atividades relacionadas ao EHR e trabalho administrativo, comparados a apenas 27,0% em interação direta com pacientes (SCHWAN, 2022). Este desequilíbrio contribui para a percepção de que o EHR interfere na missão central da medicina: o cuidado ao paciente (SINSKY, 2016). Para Skeff e colaboradores (2022), médicos percebem erosão de valores profissionais fundamentais em decorrência das demandas dos sistemas de EHR. Corroborando, JONES *et al.* (2024) apontam que a necessidade de atender aos requisitos de documentação para faturamento e conformidade regulatória é frequentemente percebida como conflitante com o julgamento clínico e as necessidades individuais dos pacientes.

É neste contexto que as tecnologias de reconhecimento automático de fala e modelos de linguagem emergem como estratégias promissoras para aliviar a carga documental e melhorar a experiência dos profissionais de saúde (TIERNEY, 2024).

2.3 TECNOLOGIAS DE RECONHECIMENTO AUTOMÁTICO DE FALA (ASR)

2.3.1 Fundamentos Tecnológicos do ASR

O reconhecimento automático de fala (*Automatic Speech Recognition – ASR*), também denominado reconhecimento de voz (*speech recognition*) ou conversão de fala em texto (*speech-to-text*), refere-se ao conjunto de tecnologias computacionais que permitem a conversão automática da linguagem oral em texto escrito (JUANG, 2005). Esta capacidade tecnológica fundamenta-se na análise de sinais acústicos, processamento de características linguísticas e na aplicação de modelos estatísticos ou de aprendizado de máquina para decodificar a sequência de palavras mais provável correspondente ao sinal de fala (GAIKWAD, 2010).

O processo de reconhecimento automático de fala envolve múltiplas etapas sequenciais (KHEDDAR, 2024): (1) aquisição de áudio, através de microfones ou dispositivos de gravação; (2) pré-processamento, incluindo supressão de ruído, remoção de silêncios e normalização do sinal; (3) extração de características, convertendo o sinal acústico em representações numéricas que capturam propriedades linguísticas e acústicas relevantes; (4) reconhecimento de fala, aplicando modelos de linguagem e modelos acústicos para decodificar a sequência de palavras; e (5) pós-processamento, incluindo correção de erros, formatação e estruturação do texto resultante (YU, 2016).

Neste universo, o reconhecimento automático de fala (ASR, do inglês *Automatic Speech Recognition*), também conhecido como sistemas *Speech-To-Text* (literalmente, Fala-para-Texto), consiste no processo de conversão de um sinal acústico em um conjunto de palavras que foram ditas (LOPES; ANDRADE; KOMATI, 2021). Os sistemas de reconhecimento de fala são compostos por microfones, que convertem o som em sinais elétricos; placas de som, que digitalizam os sinais elétricos; e software do motor de voz, que converte os dados em palavras de texto (JOHNSON *et al.*, 2014).

CASELI (2023) define a tarefa de reconhecimento de fala como a transformação do sinal acústico de um trecho de fala em sua representação textual correspondente (Figura 1).

Figura 1: Conversão de áudio da fala em sua transcrição textual.



FONTE: Caseli, 2023.

Os sistemas de ASR tradicionalmente decompõem o problema de reconhecimento em três componentes principais: (1) o modelo acústico (*Acoustic Model* – AM), que modela a relação entre características acústicas do sinal de fala e unidades fonéticas; (2) o modelo de linguagem (*Language Model* – LM), que modela a probabilidade de sequências de palavras na língua-alvo; e (3) o léxico ou dicionário de pronúncia, que mapeia palavras a suas representações fonéticas (HINTON, 2012). A integração efetiva destes componentes é essencial para o desempenho do sistema de reconhecimento (GRAVES, 2013).

2.3.2 Evolução Histórica do ASR (1990-2025)

A história do reconhecimento automático de fala estende-se por mais de seis décadas, com avanços significativos impulsionados por progressos em algoritmos, no poder computacional e na disponibilidade de dados (JURAFSKY, 2020). Para os propósitos desta revisão, focalizamos a evolução a partir da década de 1990, período em que os sistemas de ASR passaram a ser explorados em aplicações clínicas (ZUE, 1990).

Durante as décadas de 1990 e 2000, os sistemas de ASR eram predominantemente baseados em *Hidden Markov Models* (HMM) para modelagem acústica, combinados com modelos de linguagem estatísticos baseados em n-gramas (PRABHAVALKAR, 2024). Estes sistemas requeriam treinamento extensivo com grandes volumes de dados anotados e apresentavam desempenho limitado em condições de ruído, de variabilidade de falantes e de vocabulário especializado (GALES, 2008). No contexto clínico, as primeiras

aplicações concentraram-se em especialidades com vocabulário relativamente restrito e estruturado, particularmente em radiologia e anatomia patológica (ROSENTHAL, 1998).

Em uma revisão sistemática conduzida por BLACKLEY *et al.* (2019) sobre reconhecimento de fala para documentação clínica no período de 1990 a 2018, identificou-se que as primeiras publicações se focalizavam principalmente em aplicações em radiologia, com estudos demonstrando a viabilidade técnica e o potencial para reduzir o tempo de entrega dos laudos. Entretanto, estes sistemas iniciais apresentavam taxas de erro elevadas, particularmente para terminologia médica complexa, e requeriam treinamento extenso para adaptação à voz de cada usuário (BLACKLEY, 2019).

A partir de 2010, testemunhou-se uma revolução no campo do ASR com a introdução de técnicas de aprendizado profundo (*deep learning*) (LECUN, 2015). Redes neurais profundas (*Deep Neural Networks* – DNN), particularmente redes neurais recorrentes (*Recurrent Neural Networks* – RNN) e suas variantes como *Long Short-Term Memory* (LSTM) e *Gated Recurrent Units* (GRU), demonstraram desempenho superior aos modelos tradicionais baseados em HMM. A introdução de arquiteturas *end-to-end*, que eliminam a necessidade de componentes separados para modelagem acústica e linguística, representou outro avanço significativo (GRAVES, 2014). Modelos como *Connectionist Temporal Classification* (CTC), *Attention-based Encoder-Decoder* e *Transducer* permitiram treinamento conjunto de todo o sistema de reconhecimento, simplificando o processo de desenvolvimento e melhorando o desempenho (HANNUN, 2014).

De acordo com Hodgson *et al.* (2016), a década de 2010 testemunhou expansão das aplicações de ASR para além da radiologia, incluindo especialidades como medicina de emergência, atenção primária, cirurgia e enfermagem. Sistemas comerciais de reconhecimento de fala, como Dragon Medical (Nuance Communications), tornaram-se amplamente disponíveis e foram adotados por instituições de saúde em diversos países.

A partir de 2017, há a ascensão dos *Transformers* e modelos de linguagem de grande porte (*Large Language Models* – LLMs) como paradigma dominante em processamento de linguagem natural e reconhecimento de fala. Esta arquitetura baseia-se em mecanismos de autoatenção que permitem modelagem eficiente de dependências de longo alcance, demonstrando robustez superior em diferentes idiomas e condições

acústicas, tornando-os particularmente adequados para aplicações clínicas multilíngues e em ambientes ruidosos (VASWANI, 2017).

A integração de LLMs, como GPT (*Generative Pre-trained Transformer*), BERT (*Bidirectional Encoder Representations from Transformers*) e suas variantes especializadas para o domínio médico, ampliou significativamente as capacidades dos sistemas de documentação clínica (BROWN, 2020). Estes modelos não apenas transcrevem a fala, mas também podem estruturar, sumarizar e gerar documentação clínica formatada, o que representa uma evolução qualitativa em relação aos sistemas tradicionais de ASR (SINGHAL, 2023).

2.3.3 Arquiteturas e Modelos: De HMM a Transformers

A evolução das arquiteturas de ASR reflete progressos fundamentais em aprendizado de máquina e disponibilidade de recursos computacionais (DENG, 2013). Buscamos sintetizar, nesta seção, as principais arquiteturas que marcaram a trajetória tecnológica do reconhecimento automático de fala.

- **Hidden Markov Models (HMM)**

Os *Hidden Markov Models* (HMMs) constituíram o paradigma dominante em ASR por mais de três décadas, capazes de modelar a fala como um processo estocástico, em que estados ocultos (correspondentes a unidades fonéticas) geram observações acústicas de acordo com distribuições de probabilidade (YOUNG, 2002). A combinação de HMMs para modelagem acústica com modelos de linguagem baseados em n-gramas permitiu o desenvolvimento dos primeiros sistemas de ASR de vocabulário amplo (JELINEK, 1998).

Apesar de seu sucesso histórico, os HMMs apresentam limitações fundamentais, incluindo suposições de independência condicional que não capturam adequadamente as complexas dependências temporais e contextuais presentes na fala (BENGIO, 1994). Adicionalmente, HMMs requerem alinhamento explícito entre características acústicas e unidades fonéticas, processo que pode ser subótimo (MOHAMED, 2012).

- **Deep Neural Networks (DNN) e Sistemas Híbridos**

A introdução de redes neurais profundas para modelagem acústica, substituindo os modelos de mistura gaussiana (*Gaussian Mixture Models* – GMM) tradicionais, representou um avanço significativo (DAHL, 2012). Sistemas híbridos DNN-HMM, que combinam redes neurais profundas para estimação de probabilidades de estados acústicos com HMMs para modelagem temporal, demonstraram reduções substanciais nas taxas de erro em relação aos sistemas GMM-HMM (SEIDE, 2011).

Arquiteturas de redes neurais recorrentes, particularmente LSTM e GRU, permitiram modelagem mais sofisticada de dependências temporais (SAK, 2014). Redes neurais convolucionais (*Convolutional Neural Networks* – CNN) também foram exploradas para extração de características acústicas, capturando padrões locais no espectrograma de fala (ABDEL-HAMID, 2014).

- **Modelos End-to-End**

Arquiteturas *end-to-end* eliminam a necessidade de componentes separados para modelagem acústica, fonética e linguística, permitindo treinamento conjunto de todo o sistema (GRAVES, 2014). Esta arquitetura é possibilitada a partir de: (1) Connectionist Temporal Classification (CTC), que introduz uma função de perda que permite alinhamento implícito entre sequências de entrada (características acústicas) e saída (texto), sem necessidade de anotação de alinhamento temporal (GRAVES, 2014); (2) Attention-based Encoder-Decoder, que por sua vez, utiliza mecanismos de atenção para aprender alinhamentos flexíveis entre representações acústicas codificadas e sequências de texto decodificadas (BAHDANAU, 2016); ou ainda (3) Transducer (RNN-T) que combina características de CTC e modelos de linguagem, permitindo decodificação em tempo real (*streaming*) adequada para aplicações interativas (GRAVES, 2012).

- **Transformers e Conformers**

A arquitetura *Transformer*, baseada exclusivamente em mecanismos de autoatenção, revolucionou o processamento de linguagem natural e, subsequentemente, o reconhecimento de fala (DONG, 2018). *Transformers* eliminam a necessidade de processamento sequencial, permitindo paralelização eficiente durante o treinamento e captura de dependências de longo alcance (KARITA, 2019).

O *Conformer*, proposto por GULATI *et al.* (2020), combina mecanismos de autoatenção dos *Transformers* com convoluções, capturando tanto dependências globais

quanto padrões locais no sinal de fala. Esta arquitetura híbrida demonstrou desempenho superior em múltiplos benchmarks de ASR (GUO, 2021) e conforme reportado por KHEDDAR *et al.* (2024), pode superar sistemas híbridos em 19% a 26% em termos de taxa de erro de palavras (*Word Error Rate* – WER).

2.3.4 Métricas de Desempenho: WER, Acurácia e Tempo

A avaliação de sistemas de ASR requer métricas objetivas que quantifiquem diferentes aspectos do desempenho (FISCUS, 2007). Descrevemos, aqui, as principais métricas utilizadas na literatura para avaliar sistemas de reconhecimento de fala em contextos clínicos.

- **Word Error Rate (WER)**

A taxa de erro de palavras (*Word Error Rate* – WER) é a métrica mais amplamente utilizada na avaliação de sistemas de ASR (WANG, 2019). O WER é calculado como a razão entre o número de erros de reconhecimento (substituições, inserções e deleções de palavras) e o número total de palavras na transcrição de referência (KLAKOW, 2002): $WER = (S + I + D) / N$, onde S representa substituições, I representa inserções, D representa deleções, e N é o número total de palavras na referência (MORRIS, 2004).

As evidências da literatura indicam que valores mais baixos de WER associam-se a melhor desempenho, com WER de 0% representando transcrição perfeita (SAON, 2017). Na prática, sistemas de ASR de alta qualidade para fala geral atingem WER entre 5% e 10% em condições controladas (XIONG, 2017). Para vocabulário médico especializado, as taxas de erro tendem a ser mais elevadas, particularmente para termos técnicos complexos e nomes de medicamentos (HODGSON, 2017).

- **Acurácia e Precisão**

Além do WER, utilizam-se métricas de acurácia, precisão (*precision*), revocação (*recall*) e F1-score para avaliar aspectos específicos do desempenho de sistemas de documentação automatizada (MANNING, 2008). Estas métricas são particularmente relevantes quando o sistema não apenas transcreve, mas também extrai e estrutura informações clínicas (DEMNER-FUSHMAN, 2009).

Em SEZGIN *et al.* (2023), por exemplo, reporta-se que o modelo BART-Large-CNN alcançou 71,4% de recall na identificação de informações-chave e 67,7% de acurácia em contexto de departamento de emergência. FALCETTA *et al.* (2023) citam estudos com acurácia de validação de 92,41% na classificação de informações relevantes e irrelevantes na anamnese e de 82,17% no reconhecimento de palavras.

- **Métricas de Sumarização: ROUGE e BLEU**

Para sistemas que geram sumários ou notas estruturadas a partir de conversas clínicas, métricas de avaliação de sumarização automática são apropriadas (LIN, 2004). As métricas ROUGE (*Recall-Oriented Understudy for Gisting Evaluation*) avaliam a sobreposição de n-gramas entre o sumário gerado e os sumários de referência, com ROUGE-1, ROUGE-2 e ROUGE-L medindo a sobreposição de unigramas, bigramas e subsequências mais longas, respectivamente (NENKOVA, 2004).

- **Tempo de Documentação**

Métricas temporais quantificam o impacto dos sistemas de ASR na eficiência do processo de documentação. Estas métricas incluem o tempo total de documentação, o tempo de ditado, o tempo de edição e o tempo até a conclusão da nota (ZHENG, 2011). Entretanto, é importante ressaltar que a redução no tempo de documentação não é universal. Estudos demonstram uma variabilidade substancial em função do contexto clínico, das características do sistema, da experiência do usuário e do tipo de documentação (PATEL, 2002). Adicionalmente, o tempo economizado na transcrição inicial pode ser parcialmente compensado por tempo adicional de edição e revisão (BOROWITZ, 2001).

2.4 FUNDAMENTOS DE PROCESSAMENTO DE LINGUAGEM NATURAL (NLP)

O processamento de linguagem natural (*Natural Language Processing* – NLP) constitui um campo interdisciplinar que integra linguística computacional, ciência da computação e inteligência artificial, focalizando a interação entre computadores e linguagem humana (CHOWDHURY, 2003). O objetivo central do NLP é capacitar sistemas computacionais a compreender, interpretar, manipular e gerar linguagem natural de forma significativa e útil (NADKARNI, 2011).

O PLN pode ser definido como "qualquer algoritmo baseado em computador que manipula, amplia e transforma a linguagem natural para que possa ser representada em computação". Os algoritmos de PNL são usados para realizar processos sintáticos (por exemplo, tokenização, detecção de frases), extrair informações (ou seja, converter texto não estruturado em uma forma estruturada), capturar significado (ou seja, atribuir um conceito a uma palavra ou grupo de palavras) e detectar relações (ou seja, atribuir relações entre conceitos) de texto livre por meio do uso de regras de linguagem definidas e conhecimento de domínio relevante. Deste modo, embora a linguagem médica seja complexa, o PLN é, atualmente, a técnica analítica de "big data" mais utilizada na área da saúde (KOLECK; DREISBACH; BAKKEN, 2019).

2.4.1 Modelos de Linguagem: Tradicionais versus Modernos

Modelos de linguagem constituem componentes fundamentais de sistemas de NLP, que estimam a probabilidade de sequências de palavras ou tokens. A evolução dos modelos de linguagem reflete progressos fundamentais em aprendizado de máquina e disponibilidade de dados e recursos computacionais (GOLDBERG, 2017).

- **Modelos de Linguagem Tradicionais: N-gramas**

Os modelos de linguagem baseados em n-gramas representam a abordagem clássica, modelando a probabilidade de uma palavra condicionada às n-1 palavras anteriores e, embora computacionalmente eficientes e interpretáveis, os modelos de n-gramas apresentam limitações fundamentais como esparsidade de dados, contextos limitados e ausência de generalização semântica (MIKOLOV, 2013).

- **Modelos de Linguagem Neurais**

A introdução de modelos de linguagem neurais representou um avanço significativo, utilizando redes neurais para aprender representações distribuídas de palavras (*word embeddings*) que capturam similaridades semânticas (BENGIO, 2006). Arquiteturas como *Word2Vec*, *GloVe* e *FastText* permitiram aprendizado de representações vetoriais de palavras a partir de grandes corpora não anotados (PENNINGTON, 2014).

Modelos de linguagem baseados em redes neurais recorrentes (RNN), particularmente LSTM, permitiram modelagem de dependências de longo alcance e contexto arbitrariamente longo (SUNDERMEYER, 2012). Entretanto, o processamento sequencial inerente às RNNs limita a paralelização durante o treinamento e pode resultar em dificuldades para capturar dependências muito distantes (PASCANU, 2013).

- **Modelos de Linguagem Contextualizados: Era dos Transformers**

A arquitetura *Transformer*, introduzida por Vaswani *et al.* em 2017, revolucionou o processamento de linguagem natural ao eliminar a necessidade de processamento sequencial e permitir modelagem eficiente de dependências de longo alcance através de mecanismos de autoatenção. Esta arquitetura fundamenta os modelos de linguagem de grande porte que dominam o estado-da-arte atual (WOLF, 2020).

Modelos baseados em *Transformers* geram representações contextualizadas, onde a representação de uma palavra depende de todo o contexto em que aparece, capturando nuances semânticas e sintáticas de forma mais sofisticada que embeddings estáticos (PETERS, 2018). Esta capacidade é particularmente relevante para textos clínicos, onde o significado de termos frequentemente depende fortemente do contexto (ALSENTZER, 2019).

- **Large Language Models (LLMs): GPT, BERT e Modelos Clínicos**

Os grandes modelos de linguagem (*Large Language Models* – LLMs) representam a vanguarda da inteligência artificial em processamento de linguagem natural (BOMMASANI, 2021). Estes modelos são caracterizados por escala massiva, pré-treinamento em grandes corpora e capacidades emergentes como o aumento de escala, incluindo raciocínio, aprendizado em contexto (*in-context learning*) e generalização para tarefas não vistas durante o treinamento (WEI, 2022).

- **BERT e Modelos Bidirecionais**

BERT (*Bidirectional Encoder Representations from Transformers*), introduzido por Devlin *et al.* em 2018, utiliza arquitetura *Transformer* encoder com pré-treinamento bidirecional através de duas tarefas: *Masked Language Modeling* (MLM) e *Next Sentence Prediction* (NSP) (DEVLIN, 2019). A capacidade de processar contexto bidirecional permite que BERT capture relações semânticas complexas (ROGERS, 2020).

Variantes de BERT especializadas para o domínio biomédico e clínico foram desenvolvidas tais como o modelo BioBERT pré-treinado em literatura biomédica (LEE, 2020), o ClinicalBERT, por sua vez, pré-treinado em notas clínicas de prontuários eletrônicos (HUANG, 2019) e o PubMedBERT, treinado do zero em literatura biomédica, demonstrando desempenho superior a BERT com pré-treinamento adicional (GU, 2021).

.GPT e Modelos Autorregressivos

A série GPT (*Generative Pre-trained Transformer*), desenvolvida pela OpenAI, utiliza arquitetura *Transformer* decoder com pré-treinamento autorregressivo, prevendo a próxima palavra dadas as palavras anteriores, permitindo a geração de texto coerente e contextualmente apropriado (RADFORD, 2019). Os modelos GPT-3 e GPT-4 demonstraram capacidades notáveis de aprendizado em contexto (*few-shot learning*), em que o modelo pode realizar tarefas com poucos exemplos fornecidos no prompt, sem necessidade de ajuste fino (*fine-tuning*) (BROWN, 2020). No contexto clínico, estas capacidades têm sido amplamente exploradas para tarefas como resposta a perguntas médicas, sumarização de notas clínicas e auxílio à decisão clínica (SINGHAL, 2023).

- **Modelos Multimodais e Especializados**

Desenvolvimentos recentes incluem modelos multimodais que integram texto, imagem e outros tipos de dados. No contexto clínico, modelos como GPT-4V (com capacidades de visão) e modelos especializados como Med-PaLM (desenvolvido pelo Google para aplicações médicas) demonstram desempenho comparável ao dos médicos em tarefas clínicas complexas, embora com limitações importantes relacionadas a alucinações (geração de informações incorretas apresentadas com confiança) e vieses; (ALAYRAC, 2022; SINGHAL, 2023).

2.4.2 Whisper: O Modelo de Referência da Era Pós-Transformers

A trajetória evolutiva dos sistemas de reconhecimento automático de fala atingiu um marco significativo a partir de 2022 com a disponibilização do Whisper pela OpenAI. Diferentemente de seus predecessores, majoritariamente treinados em corpora únicos e de domínio restrito, o Whisper foi concebido como um modelo de propósito geral, treinado em escala sem precedentes, o que alterou substancialmente o panorama

comparativo da área. Do ponto de vista arquitetural, o Whisper adota um modelo *de encoder-decoder de Transformer* de ponta a ponta, treinado originalmente com 680.000 horas de dados de áudio multilíngue e multitarefa coletados da internet, cobrindo 99 idiomas. A inovação central do Whisper reside no treinamento multitarefa unificado, no qual o reconhecimento de fala multilíngue, a tradução automática, a identificação de idioma e a detecção de atividade vocal são representados como sequências de tokens preditos pelo decodificador, eliminando componentes de pré-processamento separados e favorecendo a generalização (RADFORD *et al.*, 2023).

No contexto da documentação clínica, a adoção do Whisper expandiu-se rapidamente. Mais de 30.000 clínicos e 40 sistemas de saúde utilizavam ferramentas baseadas nesse modelo para documentação de consultas em meados de 2024, com aproximadamente sete milhões de atendimentos médicos transcritos por uma única plataforma (KOENECKE *et al.*, 2024). No entanto, avaliações comparativas em ambiente clínico especializado demonstram variabilidade expressiva: estudo conduzido com registros de ortodontia identificou que, em um corpus de 200 registros clínicos narrados (43.408 palavras), apenas o Whisper e um segundo sistema apresentaram alucinações, com 57 eventos de alucinação registrados para o Whisper, ao passo que todos os demais sistemas avaliados registraram zero ocorrências. Erros clinicamente significativos foram observados em todos os sistemas testados, com taxas variando de 2% a 66% a depender das condições acústicas (O'KANE *et al.*, 2025).

A robustez do Whisper em relação a sotaques e variantes linguísticas constitui limitação amplamente documentada. GRAHAM e ROLL (2024), em estudo publicado no JASA Express Letters, avaliaram o desempenho do sistema em 18 variantes do inglês nativo e não nativo, identificando superioridade acentuada para o inglês norte-americano em comparação a sotaques britânicos, australianos e não nativos. Os resultados evidenciaram associações significativas entre o WER e características do falante, incluindo sexo biológico, tipologia da língua materna e nível de proficiência em segunda língua, com desempenho sistematicamente inferior em fala conversacional espontânea frente à fala lida. Esses achados têm implicação direta para a aplicação clínica do Whisper no contexto brasileiro: a diversidade dialetal do português brasileiro, com variações fonológicas substanciais entre regiões como o Nordeste, o Sul e o Norte, e o perfil sociolinguístico heterogêneo dos usuários do Sistema Único de Saúde representam fatores

de risco para degradação sistemática da acurácia de transcrições geradas por modelos treinados predominantemente em dados anglófonos.

Um aspecto crítico do Whisper, com implicações diretas para ambientes de alta responsabilidade como o clínico, é sua propensão a alucinações de transcrição. KOENECKE *et al.* (2024) analisaram 13.140 segmentos de áudio e identificaram que aproximadamente 1% das transcrições continha frases ou sentenças inteiras inexistentes no áudio de entrada. Dentre os conteúdos alucinados, 38% incluíam danos explícitos, como perpetuação de violência, associações incorretas entre pessoas e eventos, ou atribuição de falsa autoridade. O principal fator desencadeador das alucinações foi a presença de silêncios prolongados e disfluências na fala, sugerindo que populações com características de fala atípica, como pacientes afásicos, idosos ou usuários com distúrbios da comunicação, enfrentam risco elevado de erros graves de transcrição. Essa última categoria tem particular relevância para a área da saúde, onde a prevalência de comorbidades associadas a alterações da fala é significativa (KOENECKE *et al.*, 2024).

Em termos de desempenho clínico, estudos recentes como o de Ng *et al.* (2025) indicam que a acurácia desses sistemas varia conforme o contexto: enquanto em ambientes controlados e ditados estruturados o desempenho é elevado, ocorre degradação expressiva em situações de fala espontânea ou ruidosa.

2.5 ALUCINAÇÕES EM MODELOS DE LINGUAGEM E SEGURANÇA DO PACIENTE NA DOCUMENTAÇÃO CLÍNICA

O fenômeno das alucinações em modelos de linguagem de grande porte representa um dos desafios mais críticos para a aplicação dessas tecnologias em domínios de alta responsabilidade. Na literatura especializada, o termo designa qualquer saída gerada pelo modelo que seja factualmente incorreta, logicamente inconsistente ou não fundamentada em evidências clínicas autorizadas, de forma que possa influenciar decisões clínicas (ROUSTAN; BASTARDOT, 2025). Essa definição abrange dois fenômenos principais: as alucinações *propriamente ditas*, nas quais o modelo insere informação ausente no dado de entrada; e as omissões, nas quais informações clinicamente relevantes são suprimidas na nota gerada (ASGARI *et al.*, 2025).

Azamfirei *et al.* (2025), em revisão sistemática de considerações éticas sobre LLMs publicada no *Frontiers in Digital Health*, identificaram que modelos como GPT-3.5 e GPT-4, amplamente utilizados em suporte à documentação clínica, geram textos coerentes que, quando incorretos, "requerem supervisão humana" por sua aparência de plausibilidade. A revisão, que analisou 27 estudos publicados entre 2017 e 2025, aponta que as alucinações figuram entre os principais riscos éticos do uso de LLMs em saúde, juntamente com vieses algorítmicos, questões de privacidade e falta de transparência nos processos de decisão (AZAMFIREI *et al.*, 2025).

Do ponto de vista teórico, há evidências de que as alucinações podem constituir uma propriedade intrínseca da arquitetura autorregressiva dos LLMs, derivada de limitações fundamentais de seus processos de geração, onde múltiplos fatores contribuem para sua manifestação: a qualidade e os vieses do corpus de treinamento, a estratégia de instrução (*prompting*), o comprimento e a complexidade do texto de entrada, e as configurações de temperatura do modelo (ROUSTAN; BASTARDOT, 2025).

A quantificação sistemática das alucinações em contextos de geração de notas clínicas constitui linha de pesquisa emergente e de elevada relevância para a avaliação de tecnologias em saúde. Asgari e colaboradores (2025) desenvolveram o framework CREOLA, que integra taxonomia de erros, estrutura experimental iterativa e interface de avaliação assistida por clínicos. A partir de 18 configurações experimentais envolvendo LLMs para geração de notas clínicas, com 12.999 sentenças anotadas por 50 médicos, os autores identificaram taxa de alucinação de 1,47%, sendo 44% classificadas como "maiores", com potencial de alterar diagnóstico ou conduta terapêutica se não detectadas. A taxa de omissões foi de 3,45%, com 17% classificadas como "maiores", concentradas principalmente nas seções de Plano (21%), Avaliação (10,5%) e Sintomas (5,2%) (ASGARI *et al.*, 2025).

Há também uma revisão sistemática mais abrangente e atualizada sobre o desempenho de sistemas de ASR para documentação clínica, publicada por NG *et al.* (2025), que, em termos de acurácia de transcrição, evidenciou variabilidade expressiva: o WER oscilou de 0,087 em cenários controlados de ditado médico estruturado até valores superiores a 50% em situações com múltiplos falantes simultâneos ou fala espontânea em ambientes ruidosos. Os contextos de melhor desempenho foram os de ditado estruturado em especialidades de alta padronização documental, como radiologia e anatomia patológica; ao passo que os de pior desempenho corresponderam a consultas

ambulatoriais espontâneas e atendimentos em pronto-socorro (NG *et al.*, 2025). Este padrão é consistente com os achados de O'kane al. (2025), que identificaram que sistemas de ASR apresentam desempenho aceitável em condições acústicas ideais, mas degradação expressiva com a introdução de ruído de fundo.

3 OBJETIVOS

- **Geral:** Sintetizar as evidências científicas disponíveis sobre a aplicação de sistemas de ASR e LLMs na documentação clínica, com ênfase na acurácia, na eficiência e na segurança do paciente.
- **Específicos:**
 1. Caracterizar os estudos primários que avaliam sistemas de ASR e LLMs em cenários clínicos reais;
 2. Sintetizar dados de acurácia de transcrição e eficiência temporal;
 3. Investigar o papel da revisão humana como barreira de segurança contra alucinações e erros factuais da IA;
 4. Mapear as lacunas de evidência para o português brasileiro e o SUS, subsidiando uma agenda de pesquisa nacional.

4 MÉTODO

4.1 DESENHO DO ESTUDO E PROTOCOLO

Trata-se de uma revisão de escopo, conduzida com o objetivo de mapear as evidências científicas disponíveis sobre a aplicação de sistemas de IA (ASR e LLMs) à documentação clínica, caracterizando a extensão, natureza e distribuição do conhecimento produzido de analisar o desempenho de sistemas de transcrição automática de fala baseados em inteligência artificial aplicados à documentação clínica.

O estudo seguiu as diretrizes PRISMA 2018 for Scoping Reviews -PRISMA-ScR (TRICCO *et al.*, 2018) e por se tratar de estudo de revisão da literatura, não foi necessária aprovação por Comitê de Ética em Pesquisa. O protocolo da revisão foi registrado retrospectivamente no International Prospective Register of Systematic Reviews (PROSPERO), sob o número CRD42026128224, e no Open Science Framework (OSF) (<https://doi.org/10.17605/OSF.IO/B9GS4>), inicialmente sob a perspectiva de uma revisão sistemática e devido a alta heterogeneidade dos achados e rápida transformação da tecnologia envolvida na pesquisa alteramos a síntese deste estudo para uma revisão de escopo. O registro retrospectivo constitui uma limitação metodológica, uma vez que o registro idealmente deve preceder a condução da revisão.

4.2 QUESTÃO DE PESQUISA

A pergunta de pesquisa foi estruturada com base em um acrônimo PCC (População, Conceito, Contexto), conforme recomendado pelo Joanna Briggs Institute para revisões de escopo (PETERS *et al.*, 2020).

População (P): profissionais de saúde — médicos, enfermeiros, paramédicos e demais clínicos — que utilizam sistemas de documentação em registros eletrônicos de saúde

Conceito (C): sistemas de transcrição automática de fala baseados aplicação de sistemas de IA (ASR e LLMs) para documentação clínica

Contexto (C): métodos tradicionais de documentação (digitação ambientes de atenção à saúde com prontuário eletrônico — hospitais, ambulatorios, urgência/emergência, atenção primária e contextos pré-hospitalares

A pergunta norteadora foi:

Em ambientes clínicos reais, o uso de sistemas de transcrição automática de fala baseados em inteligência artificial melhora a acurácia, a eficiência e a qualidade da documentação clínica, e quais são os riscos associados à segurança do paciente?

4.3 AVALIAÇÃO DOS DESFECHOS E CARACTERÍSTICAS DOS ESTUDOS

Os desfechos primários incluíram:

1. Acurácia de transcrição, avaliada por métricas como Word Error Rate (WER), F1-score, recall de conceitos clínicos e taxas de erro clinicamente relevante;
2. Eficiência, mensurada por tempo de documentação, tempo de edição e atraso na conclusão de notas clínicas;
3. Qualidade e completude da documentação, incluindo escores em instrumentos validados e proporção de campos preenchidos;

Os desfechos secundários, por sua vez, incluíram aspectos relacionados à segurança da informação clínica, como erros de omissão, inserção ou distorção com potencial de impacto assistencial.

Dada a heterogeneidade das métricas e das arquiteturas de inteligência artificial na literatura, as características técnicas dos sistemas foram tratadas como atributos descritivos da intervenção, não sendo consideradas desfechos de efetividade.

4.4 ELEGIBILIDADE DOS ESTUDOS

- **Tipos de Estudo:** Foram incluídos estudos primários quantitativos, incluindo ensaios randomizados, estudos quase-experimentais, estudos antes e depois, coortes, estudos transversais, estudos de simulação e estudos-piloto, que

avaliassem sistemas de transcrição de fala para texto baseados em IA utilizados para documentação clínica, reportando ao menos um desfecho de acurácia, tempo de documentação ou taxa/tipo de erro, alinhados à pergunta de pesquisa.

- **Intervenção:** Estudos em que sistemas de IA de fala para texto são utilizados para gerar ou apoiar documentação clínica (notas de consulta, relatórios, registros de enfermagem, sumários, prescrições) no período de 2015 a 2025.
- **Contexto:** Qualquer serviço de saúde (atenção primária, ambulatorios, hospitais gerais ou especializados). Foram priorizados estudos conduzidos em cenários clínicos reais, sendo também considerados estudos de simulação ou prova de conceito quando relevantes para avaliação técnica da intervenção.
- **Desfechos:** Pelo menos um desfecho entre acurácia de transcrição, eficiência/tempo ou qualidade da nota clínica.
- **Idioma e Período:** Foram incluídos artigos publicados em inglês, português e espanhol, no período de 2015 até a data final da busca. O recorte temporal justifica-se pela rápida evolução tecnológica das arquiteturas de aprendizado profundo (*Deep Learning*), marcada pelo advento das redes neurais recorrentes profundas (DNN-HMM) e, posteriormente, pelos Transformers (VASWANI *et al.*, 2017), e pela expansão dos Modelos de Linguagem de Grande Porte (LLMs) a partir de 2017–2018, culminando nos modelos GPT e BERT. Estudos anteriores a 2015 utilizam majoritariamente arquiteturas legadas sem aprendizado profundo, cuja comparabilidade com os sistemas é limitada.
- **Crerios de Exclusão:** Estudos puramente ténicos sem aplicação clínica; Estudos em contextos não clínicos; Estudos que não envolvessem transcrição de fala para documentação; Revisões, editoriais, cartas e resumos de congresso; Estudos Secundários; Estudos sem acesso ao texto completo.

Adicionalmente, considerando o caráter emergente da área, estudos de prova de conceito ou simulação foram incluídos quando apresentaram avaliação técnica relevante da intervenção, sendo analisados separadamente na síntese.

4.5 FONTES DE INFORMAÇÃO E ESTRATÉGIA DE BUSCA

As buscas foram realizadas nas seguintes bases de dados eletrônicas, em maio de 2025: Biblioteca Virtual em Saúde (BVS), PubMed/MEDLINE, EMBASE, Scopus, Web of Science, ACM Digital Library, IEEE Xplore e ScienceDirect. Complementarmente, foi realizada busca manual no Google Acadêmico (<https://scholar.google.com.br/>) e no Repositório de Teses e Dissertações da CAPES.

A estratégia de busca foi construída a partir de descritores controlados (MeSH e DeCS) e termos livres relacionados à transcrição de fala, inteligência artificial e documentação clínica, combinados por operadores booleanos (AND, OR). Nas bases ACM Digital Library e IEEE Xplore, bases especializadas em computação, que não usam MeSH/DeCS, a busca foi construída com ACM CCS (Computing Classification System) e com termos livres definidos pelos autores. As estratégias completas de busca para cada base de dados estão apresentadas no Anexo 1.

A literatura cinzenta foi pesquisada no Google Acadêmico para capturar estudos relevantes não indexados nas principais bases. Também foram realizadas buscas manuais nas listas de referências dos estudos incluídos (backward search) e em artigos que citaram esses estudos (forward search).


4.6 SELEÇÃO DOS ESTUDOS E EXTRAÇÃO DE DADOS

O processo de triagem foi realizado em múltiplas etapas, com apoio do software Rayyan², garantindo transparência, rastreabilidade e redução de vieses de seleção (OUZZANI *et al.*, 2016). A revisão foi conduzida por dois revisores independentes, com cegamento entre revisores nas etapas de triagem de títulos e resumos e de leitura de texto completo. Os conflitos foram resolvidos por consenso entre os revisores e, nos casos não resolvidos, pela decisão de um terceiro revisor.

Ao final do processo de triagem, quatro estudos atenderam aos critérios de inclusão e foram incluídos na síntese, conforme apresentado na figura 2.

² Software online gratuito, assistida por inteligência artificial (IA), projetada para agilizar a triagem e seleção de artigos em revisões sistemáticas ou de literatura (Ouzzani, *et al.*, 2018).

Figura2 : Diagrama de Fluxo PRISMA



Fonte: Elaborado pelo autor (2025)

A extração de dados foi realizada por meio de formulário estruturado, elaborado com base no instrumento JBI Data Extraction Form for Studies Reporting Prevalence Data e adaptado para os desfechos desta revisão, compreendendo sete domínios: identificação do estudo, características da amostra, tecnologia avaliada, comparadores, desfechos e métricas de avaliação, resultados principais e limitações declaradas pelos autores. Os dados extraídos estão sistematizados no Quadro 1.

QUADRO 1: Tabela de extração dos estudos

Campo de extração	Goss <i>et al.</i> (2019)	Zhou <i>et al.</i> (2018)	Chen <i>et al.</i> (2025)	Busch <i>et al.</i> (2025)
1. Identificação e características gerais do estudo				
Referência completa	Goss FR, Blackley SV, Ortega CA, Kowalski LT, Landman AB, Lin CT, Meteer M, Bakes S, Gradwohl SC, Bates DW, Zhou L. A clinician survey of using speech recognition for clinical documentation in the electronic health record. <i>Int J Med Inform.</i> 2019 Oct;130:103938. doi: 10.1016/j.ijmedinf.2019.07.017. Epub 2019 Jul 31. PMID: 31442847.	Zhou L, Blackley SV, Kowalski L, <i>et al.</i> Analysis of Errors in Dictated Clinical Documents Assisted by Speech Recognition Software and Professional Transcriptionists. <i>JAMA Netw Open.</i> 2018;1(3):e180530. doi:10.1001/jamanetworkopen.2018.0530	Chen X <i>et al.</i> <i>Int J Med Inform.</i> Deep learning-based in-ambulance speech recognition and generation of prehospital emergency diagnostic summaries using LLMs 2025;203:106029. DOI: 10.1016/j.ijmedinf.2025.106029	Busch F, Prucker P, Komenda A, Ziegelmayr S, Makowski MR, Bressem KK, Adams LC. Multilingual feasibility of GPT-4o for automated Voice-to-Text CT and MRI report transcription. <i>Eur J Radiol.</i> 2025 Jan;182:111827. doi: 10.1016/j.ejrad.2024.111827. Epub 2024 Nov 17. PMID: 39566177.

Campo de extração	Goss <i>et al.</i> (2019)	Zhou <i>et al.</i> (2018)	Chen <i>et al.</i> (2025)	Busch <i>et al.</i> (2025)
País / idioma do estudo	EUA / inglês	EUA / inglês	China / mandarim	Alemanha / alemão e inglês
Delineamento	Estudo transversal	Estudo transversal (análise documental)	Prova de conceito (sem randomização)	Prova de conceito (sem randomização)
Objetivo declarado	Avaliar percepções de clínicos sobre SR: eficiência, acurácia, satisfação e fluxo de trabalho	Identificar e analisar erros em cada etapa do processo de ditado assistido por SR	Desenvolver e avaliar sistema de ASR robusto a ruído e LLM para geração de resumos pré-hospitalares	Investigar viabilidade do GPT-4o para transcrição voz-texto de laudos radiológicos em inglês e alemão
Contexto clínico	Atenção primária e especialidades diversas; dois grandes sistemas integrados de saúde (BWH/UCHealth)	Notas de consultório, sumários de alta e notas operatórias; dois sistemas de saúde	Medicina de emergência pré-hospitalar; ambulâncias de Zhejiang, China	Radiologia diagnóstica (TC e RM); hospital universitário de Munique, Alemanha
Período do estudo	Coleta: 2016–2017; publicação: 2019	Coleta: janeiro–dezembro 2016; publicação: 2018	Coleta: não especificada; publicação: 2025	Coleta: 1–10 jul. 2024; publicação: 2025

Campo de extração	Goss <i>et al.</i> (2019)	Zhou <i>et al.</i> (2018)	Chen <i>et al.</i> (2025)	Busch <i>et al.</i> (2025)
2. Participantes / amostra				
Unidade de análise	Clínicos usuários de SR	Notas clínicas com transcrições em três versões (SR, MT, SN)	Corpus de áudio de ambulâncias e registros de atendimento pré-hospitalar	Laudos radiológicos sintéticos; leitores com diferentes níveis de experiência
Tamanho da amostra	Convidados: 1.731 Respondentes válidos: 245 (14,2%)	217 notas clínicas 144 médicos ditadores 35 especialidades 2 instituições	Corpus de treinamento ASR: EMSSData-1 (18h), EMSSData-2 (4h), AISHELL-1 (178h) Avaliação LLM: 30 textos selecionados aleatoriamente	3 leitores (R1: residente 1º ano; R2: residente 4º ano; R3: especialista 8 anos) 100 laudos/leitor/idioma = 600 laudos total
Perfil dos participantes	Médicos: 55,6%; NP/PA: 17,7% Branco: 84,4% Falantes nativos inglês: 93,1%	Cirurgiões: 37,2%; internistas: 24,8% Sexo fem.: 30,6% (dados ausentes para 10 médicos) Especialidade ausente para 26 médicos (18,1%)	Paramédicos / médicos de emergência; não especificado número de profissionais envolvidos na coleta dos dados de áudio	R1: residente 1º ano R2: residente 4º ano R3: radiologista sênior (8 anos)

Campo de extração	Goss <i>et al.</i> (2019)	Zhou <i>et al.</i> (2018)	Chen <i>et al.</i> (2025)	Busch <i>et al.</i> (2025)
	Experiência com SR <1 ano: 65,3%			Todos: alemão nativo, inglês fluente
Seleção dos participantes / amostragem	Conveniência: todos os usuários cadastrados de SR em ambas as instituições	Amostragem estratificada aleatória por tipo de nota e instituição (proporção pré-definida)	Corpus de áudio: gravações reais de ambulâncias Partição: 70% treino / 20% validação / 10% teste	Laudos sintéticos selecionados de dataset publicado; IRB dispensado (dados sintéticos)
3. Intervenção / tecnologia avaliada				
Sistema principal avaliado	Dragon Medical 10.1 e Dragon Medical 360 (front-end) Epic EHR (Verona, WI)	Dragon Medical 360 eScription (Nuance) , back-end Revisão por transcritor profissional seguida de assinatura médica	ASR: DeNoiseformer (arquitetura própria, treinamento em 2 rodadas) Baseline: Whisper-large-v3 LLM: Qwen2.5-7B-Instruct (Stylized Prompt)	LLM: GPT-4o (multimodal) Acesso via aplicativo ChatGPT iOS Laudos sintéticos de dataset público (GitHub)

Campo de extração	Goss <i>et al.</i> (2019)	Zhou <i>et al.</i> (2018)	Chen <i>et al.</i> (2025)	Busch <i>et al.</i> (2025)
Arquitetura / geração tecnológica	HMM + DNN híbrido (geração pré-Transformer)	HMM + DNN híbrido (back-end com revisão humana em duas etapas)	Transformer (encoder-decoder) + CTC + supressão de ruído por aprendizado profundo + LLM 7B	LLM multimodal Transformer de grande escala (GPT-4o); sem pipeline de supressão de ruído dedicado
Tarefa de documentação	Múltiplas seções do prontuário (HPI, avaliação, plano, medicações, alergias, outros)	Notas de consultório; sumários de alta; notas operatórias	Geração de resumo estruturado de atendimento pré-hospitalar (urgência/emergência)	Laudos de TC e RM (10 especialidades; 57 diagnósticos-guia)
Comparador	Comparação entre grupos de usuários e métodos perceptuais (sem sistema de controle)	Critério-padrão: documento reconstruído a partir da gravação de áudio original + revisão do prontuário	Comparadores ASR: Whisper-large-v3; modelo sem supressão de ruído Comparadores LLM: Baichuan2-7B-Chat; Llama3.1-8B-Instruct	Documento original (laudos sintéticos de referência do dataset público)

Campo de extração	Goss <i>et al.</i> (2019)	Zhou <i>et al.</i> (2018)	Chen <i>et al.</i> (2025)	Busch <i>et al.</i> (2025)
			Eficiência: média histórica provincial do sistema de saúde de Zhejiang	
4. Desfechos e métricas de avaliação				
Desfechos primários	Satisfação global com SR Percepção de eficiência Prevalência de erros percebidos Tempo de edição	Taxa de erro por 100 palavras (WER equivalente) em 3 etapas: SR bruto (SR), após transcritorista (MT), após assinatura (SN) Proporção de notas com ≥ 1 erro Significância clínica dos erros	CER (Character Error Rate) do ASR nas condições: ruído extremo (EMSSData-1) e ruído moderado (EMSSData-2) API , Accuracy of Patient Information (escala 1–5) FSS , Summary Format and Standardization (escala 1–5) Tempo de preenchimento do registro	Tipo e severidade de erros de transcrição (6 categorias) Tempo mediano de correção por leitor e idioma BERTScore (precisão, recall, F1) ROUGE (sobreposição lexical)

Campo de extração	Goss <i>et al.</i> (2019)	Zhou <i>et al.</i> (2018)	Chen <i>et al.</i> (2025)	Busch <i>et al.</i> (2025)
Instrumentos / métricas	Survey com múltipla escolha e texto livre (desenvolvido internamente) Regressão logística ordinal (método Laplace) Qui-quadrado / Fisher; SAS 9.4; R 3.5.0	Anotação manual de erros contra critério-padrão (audio + revisão do prontuário) Classificação: tipo geral (deleção/inserção/substituição/outros) e tipo semântico Concordância interanotadores: % de acordo	CER automático (Connectionist Temporal Classification) Métricas API, RPI, FSS: avaliação humana por médicos cegos ao tipo de texto Tukey HSD + correção de Holm para comparações múltiplas	Avaliação manual de erros por cada leitor (não cego; cada leitor avaliou seus próprios laudos) BERTScore (modelo bert-base-multilingual-cased) ROUGE-1, ROUGE-2, ROUGE-L Wilcoxon signed-rank test para comparações
5. Resultados principais				
Acurácia / erros de transcrição	75,5% estimaram ≤ 10 erros/ditado 19,6% estimaram $\geq 50\%$ dos erros como clinicamente significativos	Taxa de erro SR bruto: 7,4 erros/100 palavras (DP=4,8%) Após transcritorista (MT): 0,4% Após assinatura (SN): 0,3%	CER EMSSData-1 (ruído extremo): 52,92% CER EMSSData-2 (ruído moderado): 8,74%	Alemão: erros em 92,68% leves (n=114/123); erros factuais: 5,03%

Campo de extração	Goss <i>et al.</i> (2019)	Zhou <i>et al.</i> (2018)	Chen <i>et al.</i> (2025)	Busch <i>et al.</i> (2025)
	21,2% dedicavam $\geq 25\%$ do tempo de documentação à edição	Tipo mais frequente: deleção 34,7%; inserção 27,0%	Baseline Whisper-large-v3: CER 61,35% / 10,82% Modelo sem supressão: CER 96,31%	Inglês: erros em 94,74% leves (n=90/95); erros factuais: 7,83% Tipos mais frequentes: técnicos (27,04% DE; 35,65% EN) e tipográficos (23,9% DE; 27,83% EN) BERTScore F1 alemão sig. > inglês (p<0,05)
Segurança clínica	Nenhum evento adverso reportado Preocupação declarada com erros que impactam decisões	Notas com ≥ 1 erro clinicamente significativo: SR 63,6% $\rightarrow$ MT 14,7% $\rightarrow$ SN 7,8% 16 notas assinadas (7,4%) com marcadores de lacuna; 3 clinicamente significativos	Nenhum evento adverso reportado Estudo não desenhado para detecção sistemática de alucinações	Nenhum erro grave reportado Erros factuais (compatíveis com alucinação): 5,03% DE; 7,83% EN Gravidade: predominantemente leve

Campo de extração	Goss <i>et al.</i> (2019)	Zhou <i>et al.</i> (2018)	Chen <i>et al.</i> (2025)	Busch <i>et al.</i> (2025)
		Proporção de erros clinicamente significativos: SR 5,7% → MT 8,9% → SN 6,4% Concordância interanotadores: 71,9% geral; 85,7% para significância clínica		
Eficiência / tempo	77,2% concordaram que SR melhora eficiência 58,0% usavam SR para >75% dos pacientes 13,1% ditavam em casa	Dados de eficiência não avaliados no estudo	Tempo de preenchimento: redução de 20 → 14 min (−30%) Comparação com média histórica provincial (2024); sem grupo controle concorrente	Tempo mediano de correção: R1=2:43/2:38 min (DE/EN); R2=1:53/1:55 min; R3=1:30/1:29 min Diferença entre leitores sig. (p<0,05); sem diferença sig. entre idiomas
Satisfação / usabilidade	78,8% satisfeitos com SR 86,2% concordaram facilidade de uso	Satisfação não avaliada	Qwen2.5 Stylized Prompt: API=4,2 (±0,7); FSS=4,3 (±0,8) Método tradicional: API=3,0 (±1,2); FSS=3,8 (±0,8)	Satisfação / usabilidade não avaliadas formalmente

Campo de extração	Goss <i>et al.</i> (2019)	Zhou <i>et al.</i> (2018)	Chen <i>et al.</i> (2025)	Busch <i>et al.</i> (2025)
	93,1% receberam treinamento; 45,6% desejavam treinamento adicional Satisfação: positivamente associada à eficiência ($p<0,001$); negativamente associada a erros ($p<0,001$) e tempo de edição ($p=0,006$)		Diferença significativa ($p<0,05$ após correção de Holm)	

Fonte: Elaborado pelo autor (2025)

Nota: ASR = automatic speech recognition; LLM = large language model; CER = character error rate; WER = word error rate; MT = medical transcriptionist; SN = signed note; SR = speech recognition; MMAT = Mixed Methods Appraisal Tool; N/A = não aplicável ao módulo do delineamento.

4.7 AVALIAÇÃO DO RISCO DE VIÉS DOS ESTUDOS INCLUÍDOS

A qualidade metodológica dos estudos incluídos foi avaliada utilizando o Mixed Methods Appraisal Tool (MMAT), versão 2018, apropriado para revisões que incluem delineamentos metodológicos heterogêneos. A escolha do MMAT justifica-se pela heterogeneidade dos delineamentos dos estudos incluídos nesta revisão, que abrangem: survey transversal (GOSS *et al.*, 2019), análise documental transversal (ZHOU *et al.*, 2018), estudo quase-experimental de prova de conceito com LLMs (CHEN *et al.*, 2025; BUSCH *et al.*, 2025). Ferramentas específicas de um único delineamento, como o QUADAS-2, restrito a estudos de acurácia diagnóstica, ou o RoB 2.0, restrito a ensaios clínicos randomizados, não foram considerados aplicáveis quando observados os delineamentos dos estudos.

A avaliação foi realizada de forma independente por dois revisores, considerando os critérios específicos para cada tipo de estudo. Os resultados da avaliação foram utilizados para interpretação crítica dos achados, sem exclusão de estudos com base na qualidade metodológica. Cabe destacar que por se tratar de revisão de escopo, a avaliação do risco de viés dos estudos incluídos não é um requisito metodológico mandatório, conforme estabelecido por Peters *et al.* (2020) e Tricco *et al.* (2018). A aplicação do MMAT neste trabalho constitui elemento adicional de rigor analítico, considerando que a heterogeneidade metodológica identificada reflete o estado real da produção científica na área e subsidia a definição de prioridades para estudos futuros com base na qualidade metodológica.

Os itens do MMAT foram avaliados quanto ao atendimento (sim / não / não pode ser determinado), e distribuídos conforme quadro 2:

Quadro 2 – Síntese da avaliação do risco de viés dos estudos incluídos segundo o MMAT (HONG *et al.*, 2018)

6. Avaliação metodológica (MMAT , Pluye <i>et al.</i> , 2018)				
	Goss <i>et al.</i> (2019)	Zhou <i>et al.</i> (2018)	Chen <i>et al.</i> (2025)	Busch <i>et al.</i> (2025)
Módulo MMAT aplicado	Quantitativo descritivo (QD)	Quantitativo descritivo (QD)	Quantitativo não-randomizado (QNR)	Quantitativo não-randomizado (QNR)
T1 , Questão de pesquisa clara	✓ Sim	✓ Sim	✓ Sim	✓ Sim
T2 , Dados pertinentes à questão	✓ Sim	✓ Sim	✓ Sim	✓ Sim
QD1 , Amostra representativa	X Não , Taxa de resposta 14,2%; 84,4% brancos; 93,1% nativos inglês; sem análise de não-respondedores	✓ Sim , Amostra estratificada aleatória; cobertura de múltiplas especialidades e tipos de nota	N/A	N/A
QD2 , Medidas adequadas aos objetivos	? Incerto , Instrumento desenvolvido internamente;	✓ Sim , Anotação manual contra critério-padrão (audio +	N/A	N/A

	ausência de validação psicométrica reportada	prontuário); concordância interanotadores reportada		
QD3 , Dados faltantes tratados adequadamente	X Não , 85,8% de não- resposta sem análise de viés de não-resposta	? Incerto , Dados ausentes para sexo (10) e especialidade (26 médicos) sem imputação ou análise de sensibilidade	N/A	N/A
QD4 , Análise estatística adequada	✓ Sim , Regressão logística ordinal; qui-quadrado/Fisher; p-values reportados	✓ Sim , Testes t; correlação de Pearson; IC 95% reportados; segue STROBE	N/A	N/A
QNR1 , Intervenção claramente descrita	N/A	N/A	✓ Sim , Arquitetura DeNoiseformer, protocolo de treinamento e prompts descritos detalhadamente	✓ Sim , Modelo GPT-4o, aplicativo iOS, protocolo de ditado e classificação de erros especificados
QNR2 , Grupos similares / controle adequado	N/A	N/A	? Incerto , Comparação de eficiência com média histórica provincial (20 min); sem grupo controle concorrente	? Incerto , Cada leitor avaliou seus próprios laudos; sem avaliação cruzada ou cegamento formal

QNR3 , Desfechos completos / seguimento adequado	N/A	N/A	✓ Sim , Desfechos ASR e LLM reportados; grupo controle de pontuação com prontuários reais correspondentes	✓ Sim , Todos os 600 laudos avaliados; métricas automáticas e manuais reportadas completamente
QNR4 , Confundidores identificados e controlados	N/A	N/A	✗ Não , Dados restritos a Zhejiang; sotaques regionais não controlados; LLM treinado em corpus geral	✗ Não , Dados sintéticos; apenas 3 leitores nativos alemão; sem diversidade de falantes
QNR5 , Dados faltantes relatados	N/A	N/A	✓ Sim , Tamanho de cada corpus, partição e critérios de seleção descritos	✓ Sim , Disponibilidade dos dados declarada (mediante solicitação)
Risco global de viés	MODERADO Viés de não-resposta elevado; instrumento sem validação psicométrica	BAIXO Amostragem estratificada; critério-padrão independente; análise estatística robusta	MODERADO Prova de conceito; comparador histórico; restrição geográfica; confundidores não controlados	MODERADO Dados sintéticos; amostra de 3 leitores; ausência de cegamento; confundidores não controlados
7. Limitações declaradas pelos autores e implicações para síntese				

Limitações declaradas pelos autores	População restrita a dois sistemas de saúde integrados; mesmo fornecedor SR Participantes predominantemente brancos e falantes nativos de inglês Taxa de resposta baixa (14,2%) sem análise de não-respondedores Eficiência percebida, não medida objetivamente	Back-end SR único (Dragon 360); escopo limitado de contextos Amostra relativamente pequena Dados faltantes para sexo e especialidade de parte dos médicos Concordância interanotadores calculada em subconjunto (5%)	Dados de áudio restritos à Zhejiang; ausência de dados internacionais Sotaques regionais e dialetos não controlados LLMs treinados em corpora gerais; cobertura médica limitada Ausência de exemplos bilíngues no conjunto de treino	Apenas 3 leitores (todos nativos alemão, fluentes em inglês) Laudos sintéticos, não reais; aplicativo iOS (não sistema clínico dedicado) Avaliação não cegada (cada leitor avaliou seus próprios laudos) Dados disponíveis apenas mediante solicitação
Implicações para a síntese desta revisão	Dados de percepção e satisfação com elevada validade de face; não generalizável a populações diversas ou sistemas não-Dragon	Referência metodológica mais robusta do corpus; dados de segurança clínica com maior validade interna; generalizabilidade limitada a back-end systems	Evidência de viabilidade técnica em contexto adverso; resultados de eficiência não generalizáveis; ausência de avaliação de segurança formal	Prova de conceito com valor exploratório; dados de tempo de correção informam treinamento clínico; não generalizável para outras línguas ou sistemas

Fonte: Elaborado pelo autor (2025)

✓ Critério satisfeito , evidência explícita no artigo.

✗ Critério não satisfeito , problema identificado e fundamentado na leitura do artigo.

? Critério parcialmente satisfeito , informação insuficiente ou ambígua no artigo.

, Critério não aplicável ao delineamento do estudo.

QD = Quantitativo Descritivo; QNR = Quantitativo Não-Randomizado; T = Triagem geral. Módulos MMAT atribuídos conforme delineamento: GOSS et al. (2019) , survey transversal → QD; Zhou et al. (2018) , análise documental transversal → QD; CHEN et al. (2025) e BUSCH et al. (2025) , prova de conceito sem randomização → QNR. A classificação do risco de viés global é narrativa, conforme recomendado pelo MMAT, e não produz escore numérico.

Fonte: elaboração própria , 2025

4.8 Síntese dos dados

Os dados foram sintetizados de forma narrativa, com organização dos resultados em categorias temáticas: acurácia de transcrição; eficiência; qualidade da documentação; segurança do paciente. Quando aplicável, os resultados foram comparados qualitativamente entre os estudos, destacando convergências, divergências e lacunas de evidência.

QUADRO 3: Tabela de Síntese dos Desfechos da Inteligência Artificial na Documentação Clínica

Estudo	Acurácia	Eficiência	Qualidade	Segurança	Principais Limitações
Goss <i>et al.</i> (2019)	Percepção de erro baixa: 75,5% dos clínicos estimaram ≤ 10 erros por ditado.	77,2% concordam que o reconhecimento de fala (SR) melhora a eficiência.	Considerada solução eficaz que preserva a qualidade da documentação.	19,6% estimaram que metade ou mais dos erros eram clinicamente significativos.	Baixa taxa de resposta (14,2%) e avaliação baseada na percepção, não em dados reais.
Zhou <i>et al.</i> (2018)	Taxa de erro de 7,4% no SR bruto, caindo para	SR reduz o tempo de retorno (<i>turnaround</i>) e aumenta a	96,3% das notas brutas continham erros,	63,6% das notas brutas continham erros clinicamente significativos;	Amostra limitada a duas instituições e um único fornecedor de software.

	0,4% após revisão humana.	produtividade em sistemas <i>back-end</i> .	reduzidos para 42,4% após revisão final.	7,8% mantiveram erros após assinatura.	
Chen <i>et al.</i> (2025)	Taxa de erro de caracteres (CER) de 52,92% em ambiente de ruído real de ambulância.	Redução do tempo médio de preenchimento de registros de 20 para 14 minutos.	Modelos de linguagem (LLMs) melhoraram a estruturação e relevância dos resumos diagnósticos.	Transmissão em tempo real permite que hospitais se preparem antes da chegada do paciente.	Dados limitados a uma província chinesa; LLMs com cobertura limitada de conhecimento médico recente.
Busch <i>et al.</i> (2025)	Alta similaridade semântica (BERTScore de 0,97-0,98) tanto em inglês quanto em alemão.	Sem diferença significativa entre línguas; tempo médio de correção de ~1,5 min para radiologistas experientes.	A maioria dos erros foi menor (>92%); modelo lidou bem com morfologias complexas.	Nenhum erro grave encontrado, mas ocorreram erros factuais (alucinações) entre 5% e 7,8%.	Estudo de prova de conceito utilizando dados sintéticos e apenas três leitores.

Fonte: Elaborado pelo autor (2025)

5 RESULTADOS

5.1 CARACTERIZAÇÃO DOS ESTUDOS INCLUÍDOS

Foram incluídos quatro estudos publicados entre 2023 e 2025, refletindo o caráter emergente da aplicação de sistemas de inteligência artificial na documentação clínica. Os delineamentos foram heterogêneos, incluindo estudo observacional, survey, estudo de simulação e prova de conceito. Os estudos foram conduzidos em três países: Estados Unidos (GOSS *et al.*, 2019; ZHOU *et al.*, 2018), China (CHEN *et al.*, 2025) e Alemanha (BUSCH *et al.*, 2025). A síntese da caracterização dos estudos incluídos foi sistematizada no Quadro 4:

QUADRO 4: Caracterização dos estudos incluídos na revisão

Autor (Ano)	País	Delineamento	Cenário clínico	Tecnologia	Comparador	Amostra
Goss <i>et al.</i> (2019)	EUA	Estudo transversal baseado em inquérito (<i>Survey</i>)	Ambulatorial e hospitalar (diversas especialidades, exceto radiologia)	Front-end SR (Dragon 10.1 e Dragon Medical 360) integrado ao EHR	Percepção vs. outros métodos (digitação, templates, escribas)	245 clínicos (médicos e assistentes)
Zhou <i>et al.</i> (2018)	EUA (Boston e Aurora)	Estudo transversal de análise de erros	Notas de consultório, resumos de alta e notas operatórias	Back-end SR (Dragon Medical 360 eScription)	SR bruto vs. revisado por transcritor (MT) vs. nota assinada (SN)	217 notas clínicas ditadas por 144 médicos
Chen <i>et al.</i> (2025)	China (Zhejiang)	Estudo experimental (Prova de conceito)	Emergência pré-hospitalar (ambiente de ambulância em movimento)	Modelo NRSR (<i>FeatureEncoder</i>) e LLMs (Qwen2.5, Baichuan2, Llama3.1)	Modelos Mainstream (Conformer, Squeezeformer) e registros reais	200 horas de áudio e teste de eficiência com 10 médicos

Busch <i>et al.</i> (2025)	Alemanha (Munique)	Estudo de prova de conceito e viabilidade	Laudos de radiologia (CT e RM) de diversas especialidades	GPT-4o (via aplicativo móvel ChatGPT iOS)	Comparação entre idiomas (Inglês vs. Alemão) e experiência dos leitores	100 laudos sintéticos ditados por 3 leitores (300 por idioma)
-----------------------------------	--------------------	---	---	---	---	---

Fonte: Elaborado pelo autor (2025)

As tecnologias avaliadas refletem duas gerações distintas de sistemas. Dois estudos avaliaram o Dragon Medical 360 da Nuance Communications nas modalidades front-end (GOSS *et al.*, 2019) e back-end (ZHOU *et al.*, 2018), paradigma dominante na literatura anterior à década de 2020. Os dois estudos mais recentes avaliaram sistemas baseados em LLMs: um pipeline ASR robusto a ruído combinado ao LLM Qwen2.5-7B-Instruct para contexto pré-hospitalar em mandarim (CHEN *et al.*, 2025) e o modelo multimodal GPT-4o para transcrição multilíngue de laudos radiológicos (BUSCH *et al.*, 2025). Essa distribuição temporal permite explorar, mesmo que não comparativamente, a trajetória da tecnologia ao longo do período revisado.

Os estudos foram conduzidos majoritariamente em contextos hospitalares e ambulatoriais, com variação quanto às especialidades médicas e aos fluxos de trabalho analisados. As intervenções envolveram sistemas de reconhecimento automático de fala (ASR), modelos baseados em grandes modelos de linguagem (LLMs) e abordagens híbridas. As especialidades e contextos representados foram: clínica geral e medicina de emergência em caráter ambulatorial e hospitalar (GOSS *et al.*, 2019), diversas especialidades médicas com documentação de notas clínicas estruturadas (ZHOU *et al.*, 2018), medicina de emergência pré-hospitalar em ambulâncias (CHEN *et al.*, 2025) e radiologia diagnóstica (BUSCH *et al.*, 2025).

Essa heterogeneidade metodológica e tecnológica limita a comparabilidade direta dos resultados e inviabiliza a realização de meta-análise.

5.2 ACURÁCIA DE TRANSCRIÇÃO

A acurácia foi avaliada por meio de métricas quantitativas, como Word Error Rate (WER) e F1-score, bem como por análise qualitativa de erros clínicos. Zhou *et al.* (2018) examinaram 217 notas clínicas submetidas ao sistema back-end Dragon Medical 360 e identificaram taxa de erro bruta de 7,4 erros por 100 palavras (DP=4,8%) nas transcrições originais geradas pelo SR. A revisão pelo transcritor profissional reduziu esse índice para 0,4%, e a revisão final pelo médico para 0,3%. Em termos de prevalência, 96,3% das transcrições brutas continham ao menos um erro, percentual que caiu para 58,1% após revisão humana e 42,4% nas notas assinadas. A maior taxa de erro foi observada em sumários de alta (8,9%) em comparação com os demais tipos de nota (6,6%; $p<0,001$), e os cirurgiões produziram notas com menor taxa de erro do que os demais médicos (6,0% vs. 8,1%; $p=0,002$). O tipo mais frequente de erro foi deleção (34,7%), seguida de inserção (27,0%).

Antes de qualquer revisão humana, 138 das 217 notas (63,6%) continham ao menos um erro clinicamente significativo, com média de 2,2 erros desse tipo por nota (DP=2,7). A revisão pelo transcritor reduziu essa proporção para 14,7%, e a assinatura médica para 7,8%. A proporção de erros classificados como clinicamente significativos foi de 5,7% nas transcrições SR brutas, elevando-se para 8,9% após a revisão do transcritor, reflexo da eliminação de erros triviais que diluíam a proporção, e declinando para 6,4% nas notas assinadas. A concordância entre os dois médicos avaliadores para classificação de significância clínica foi de 85,7% (ZHOU *et al.*, 2018).

No contexto pré-hospitalar, Chen *et al.* (2025) avaliaram o modelo DeNoiseformer em dois cenários acústicos distintos. No conjunto EMSSData-1, composto por gravações com ruído extremo de ambulância em condições reais, a CER foi de 52,92%, valor alto em termos absolutos, porém substancialmente inferior ao baseline Whisper-large-v3 (CER=61,35%) e ao modelo sem módulo de supressão de ruído (CER=96,31%), o que demonstra o ganho incremental da arquitetura proposta. No conjunto EMSSData-2, com ruído moderado, a CER caiu para 8,74%, frente a 10,82% do Whisper-large-v3. Esses resultados evidenciam que a acurácia de sistemas ASR é fortemente condicionada pelas características acústicas do ambiente clínico, e que a CER de 52,92% em condições extremas não é atribuível apenas ao sistema, mas às limitações físicas do ambiente de ambulância.

Para a transcrição de laudos radiológicos com o GPT-4o, Busch *et al.* (2025) identificaram erros em 38 a 44% dos laudos em alemão e 29 a 36% em inglês, dependendo do leitor. A grande maioria dos erros foi classificada como leve (92,68% em alemão; 94,74% em inglês), sem nenhum erro grave identificado nos 600 laudos avaliados. Os tipos mais frequentes foram erros técnicos de formatação e estrutura (27,04% em alemão; 35,65% em inglês) e erros tipográficos (23,9% em alemão; 27,83% em inglês). Os erros factuais, que incluem alucinações, ou seja, informações geradas sem base no original, representaram 5,03% em alemão e 7,83% em inglês, sendo relevantes do ponto de vista de segurança, ainda que em frequência baixa (BUSCH *et al.*, 2025).

A percepção dos usuários sobre erros, coletada por Goss *et al.* (2019), tende a subestimar os índices objetivos reportados por Zhou *et al.* (2018): 75,5% dos clínicos estimaram observar 10 ou menos erros por ditado, e apenas 19,6% consideraram que metade ou mais dos erros eram clinicamente significativos. Essa divergência entre percepção e mensuração objetiva é interpretada pelos autores como consequência da tendência dos clínicos a revisar superficialmente suas notas, especialmente sob pressão de tempo (GOSS *et al.*, 2019).

Os estudos indicam que sistemas baseados exclusivamente em ASR apresentam taxas de erro variáveis, com desempenho sensível a fatores como ruído ambiental, sotaque e complexidade terminológica.. Em cenários sem revisão humana, foi observada alta frequência de erros clinicamente relevantes, com impacto potencial na interpretação do registro. Por outro lado, sistemas integrados com LLMs demonstraram melhora na coerência textual e na organização semântica da documentação. No entanto, esses modelos introduzem um tipo distinto de erro, como a geração de conteúdo não factual, porém plausível, que não é capturado por métricas tradicionais de acurácia. De forma geral, os achados sugerem que a ASR está relacionada à maior incidência de erros de transcrição literal, enquanto que o LLM corre maior risco de distorção semântica.

5.3 EFICIÊNCIA E IMPACTO NO TEMPO DE DOCUMENTAÇÃO

O impacto na eficiência foi mensurado principalmente pelo indicador tempo. Chen *et al.* (2025) reportaram redução de 30% no tempo médio de preenchimento do prontuário pré-hospitalar de emergência, de 20 minutos pelo método tradicional para 14

minutos com o sistema integrado DeNoiseformer e Qwen2.5-7B-Instruct configurado com o Stylized Prompt. Essa estimativa baseia-se na média provincial de referência para preenchimento manual fornecida pelo sistema de informações pré-hospitalares de Zhejiang, sem grupo controle concorrente, o que limita a atribuição causal da redução exclusivamente ao sistema avaliado.

Busch *et al.* (2025, por sua vez, registraram o tempo de correção das transcrições geradas pelo GPT-4o, desfecho operacional distinto do tempo de criação do documento. O tempo mediano de correção variou segundo a experiência clínica do leitor: R1 (residente do primeiro ano) , 2:43 min em alemão e 2:38 min em inglês; R2 (residente do quarto ano) , 1:53 min em ambos os idiomas; R3 (especialista sênior com oito anos de experiência) , 1:30 min em alemão e 1:29 min em inglês. Não foram identificadas diferenças significativas entre idiomas, mas os tempos diferiram significativamente entre leitores, com tendência à redução à medida que aumentava a experiência clínica , padrão interpretado como reflexo da capacidade do especialista de identificar erros de maneira mais eficiente, e não de maior velocidade de leitura (BUSCH *et al.*, 2025).

Já no estudo de Goss *et al.* (2019), 77,2% dos respondentes concordaram que o SR melhorou sua eficiência de documentação, e 61,6% perceberam redução na carga administrativa. No entanto, 21,2% dos respondentes relataram dedicar 25% ou mais do tempo total de documentação à edição e correção de transcrições. A análise de regressão logística demonstrou que maior tempo de edição foi significativamente associado a menor satisfação com o sistema ($p=0,006$), indicando que o custo de revisão representa um componente central da experiência do usuário com SR.

Em síntese, os estudos sugerem redução no tempo de documentação clínica com o uso de sistemas automatizados, especialmente quando integrados a fluxos de trabalho clínicos, onde também foram observadas reduções no tempo fora do expediente dedicado ao preenchimento de prontuários.. Entretanto, esse ganho é parcialmente compensado pela necessidade de revisão humana. Em alguns casos, o tempo de edição das notas geradas aproximou-se do tempo de documentação manual, reduzindo o benefício líquido.

5.4 QUALIDADE DOS DOCUMENTOS GERADOS POR LLMS

A qualidade da documentação foi avaliada por meio de completude, organização e percepção dos usuários. Os dois estudos com sistemas baseados em LLMS avaliaram a qualidade dos textos gerados por métricas complementares , uma subjetiva e outra computacional.

Chen *et al.* (2025) avaliaram os sumários diagnósticos gerados pelo LLM por meio de duas escalas subjetivas aplicadas por avaliadores médicos: API (Accuracy and Practical Implications), que mede precisão e relevância clínica, e FSS (Fluency and Structural Score), que avalia fluência e estrutura. Sob o Stylized Prompt, o modelo Qwen2.5-7B-Instruct obteve API de 4,2 ($\pm 0,7$) e FSS de 4,3 ($\pm 0,8$), em contraste com os prontuários preenchidos manualmente pelo método convencional (API 3,0 $\pm$ 1,2; FSS 3,8 $\pm$ 0,8). Os autores destacam que o design do prompt influenciou de forma significativa a qualidade dos sumários gerados, com o Stylized Prompt , estruturado segundo o formato clínico do prontuário pré-hospitalar , superando prompts genéricos nos três modelos avaliados.

Busch *et al.* (2025) calcularam métricas automáticas de qualidade textual. Os BERTScores , que medem similaridade semântica contextual entre o laudo ditado e o original , foram significativamente mais elevados para os laudos em alemão do que em inglês ($p < 0,05$). As métricas ROUGE, que avaliam sobreposição de n-gramas, não diferiram significativamente entre os idiomas, indicando equivalência na fidelidade lexical superficial, mas maior preservação semântica para o alemão , possivelmente reflexo da maior representação desta língua nos dados de pré-treinamento do GPT-4o. Os autores ressaltam que os altos escores de BERTScore em ambos os idiomas sugerem que o GPT-4o preserva o conteúdo clínico essencial dos laudos, apesar dos erros de formatação e tipografia identificados.

Os estudos indicam que sistemas baseados em LLMS tendem a produzir notas mais estruturadas e completas, com melhor organização das informações clínicas. Esse efeito é particularmente evidente em tarefas de sumarização e padronização textual. No entanto, a qualidade formal da documentação não se traduz necessariamente em maior precisão clínica, pois foram identificados casos em que notas bem estruturadas continham informações incorretas ou inferidas

5.5 SEGURANÇA E RISCOS À DOCUMENTAÇÃO CLÍNICA

A segurança da documentação foi o desfecho com achados mais preocupantes do corpus, especialmente na ausência de revisão humana, consistentemente associada a maior risco de erro clínico.

Zhou *et al.* (2018) demonstraram que, sem nenhuma revisão, 63,6% das notas clínicas geradas por SR continham ao menos um erro clinicamente significativo. A cadeia de revisão humana, transcritor profissional seguido de revisão e assinatura médica, mostrou-se indispensável: a proporção de notas com erros clinicamente significativos reduziu-se progressivamente de 63,6% (SR bruto) para 14,7% (após transcritor) e 7,8% (nota assinada). Ainda assim, 7,8% das notas assinadas apresentavam erros com potencial de impacto clínico, e 16 notas assinadas (7,4%) continham marcadores de lacuna não preenchidos, com três casos em que a informação ausente era clinicamente significativa. Nenhum evento adverso real foi documentado durante o período do estudo, mas os autores salientam que erros de deleção, negação e lateralidade, que compõem parcela relevante dos erros identificados, têm potencial de alterar decisões terapêuticas se não detectados.

Busch *et al.* (2025) não identificaram erros graves nos laudos avaliados, mas os erros factuais, incluindo inserções de informações sem correspondência no ditado original, compatíveis com o fenômeno de alucinação em LLMs, representaram 5,03% em alemão e 7,83% em inglês. Ainda que em frequência baixa e severidade leve, erros factuais em laudos radiológicos têm implicações clínicas potencialmente relevantes, e sua presença em um modelo de uso geral como o GPT-4o reforça a necessidade de validação prospectiva em dados clínicos reais antes de qualquer implementação.

No contexto da percepção dos usuários, Goss *et al.* (2019) observaram que 78,8% dos respondentes consideravam necessária a revisão das transcrições antes da finalização, e 21,2% relatavam despendar 25% ou mais do tempo de documentação em edição. A análise de regressão logística mostrou associação significativa entre o número de erros percebidos e o tempo de edição ($p < 0,001$), sugerindo que a carga de revisão é reconhecida pelos clínicos como um componente real e não trivial do fluxo de trabalho com SR.

5.6 SATISFAÇÃO DOS USUÁRIOS E FATORES ASSOCIADOS

O estudo de Goss *et al.* (2019) é o único do corpus que avalia diretamente a experiência do usuário com SR. Entre os 245 respondentes, 78,8% declararam satisfação com seu sistema, e apenas 5,7% expressaram insatisfação acentuada. A facilidade de uso foi percebida positivamente por 86,2% dos respondentes. A análise de regressão logística identificou que a satisfação foi positivamente associada à percepção de eficiência ($p<0,001$) e negativamente associada tanto à prevalência de erros ($p<0,001$) quanto ao tempo de edição ($p=0,006$). Em conjunto, esses achados sugerem que a satisfação com o SR não é determinada pela tecnologia em si, mas pela qualidade da transcrição e pelo tempo de revisão que o clínico precisa assumir.

5.7 HETEROGENEIDADE METODOLÓGICA E SÍNTESE NARRATIVA

Os quatro estudos incluídos apresentam heterogeneidade em múltiplas dimensões, delineamento, tecnologia, idioma, contexto clínico e métricas de desfecho, que inviabiliza metanálise e justifica a opção por síntese narrativa, como mencionado anteriormente. Adicionalmente, há uma assimetria temporal importante: os dois estudos com Dragon Medical (2018–2019) antecedem o advento dos LLMs modernos e do modelo Whisper, enquanto os estudos de 2025 incorporam arquiteturas qualitativamente distintas. Comparações diretas de desempenho entre essas gerações de sistemas não são metodologicamente válidas a partir dos dados disponíveis. A síntese a seguir organiza os achados por dimensão analítica e destaca as convergências e divergências relevantes para responder à pergunta de pesquisa.

5.8 SÍNTESE INTEGRADA DOS ACHADOS

A análise integrada dos quatro estudos permite organizar as evidências disponíveis em torno de três dimensões analíticas, tomando como eixo central a questão da segurança clínica da documentação.

- **Acurácia e confiabilidade das transcrições:** os resultados são fortemente dependentes das condições do ambiente clínico e do tipo de sistema. Em ambientes hospitalares com sistema back-end, a taxa de erro bruta foi de 7,4 erros por 100 palavras (ZHOU *et al.*, 2018), com 63,6% das notas contendo ao menos um erro clinicamente significativo antes da revisão humana. Em ambiente acusticamente adverso de ambulância, a CER de 52,92% , embora representando ganho substancial frente ao baseline , indica que a acurácia de transcrição em condições pré-hospitalares reais ainda não é clinicamente adequada para uso autônomo (CHEN *et al.*, 2025). A transcrição com GPT-4o mostrou perfil de erros predominantemente leve, sem erros graves, mas com presença de erros factuais que merecem escrutínio prospectivo (BUSCH *et al.*, 2025). A percepção dos usuários subestima sistematicamente a prevalência objetiva de erros (GOSS *et al.*, 2019), o que representa um risco adicional à segurança quando os sistemas são adotados sem protocolos formais de revisão.
- **Eficiência e impacto no fluxo de trabalho:** os estudos com LLMs reportam reduções relevantes no tempo de documentação (CHEN *et al.*, 2025) e tempos de correção que decrescem com a experiência clínica (BUSCH *et al.*, 2025). Os dados subjetivos de Goss *et al.* (2019) indicam percepção majoritariamente favorável de eficiência. No entanto, o custo de revisão é real: 21,2% dos clínicos dedicam 25% ou mais do tempo de documentação à edição, e o tempo de edição é um preditor significativo de insatisfação. Esses achados sugerem que o ganho líquido de eficiência depende criticamente do perfil de erros do sistema e da carga de revisão imposta ao clínico, e não apenas do tempo de transcrição.
- **Segurança e revisão humana:** o conjunto de evidências é convergente em um ponto central: a revisão humana é indispensável no ciclo de uso atual dos sistemas avaliados. Zhou *et al.* (2018) demonstraram que a cadeia de revisão dupla reduziu a prevalência de notas com erros clinicamente significativos de 63,6% para 7,8%. A presença de erros factuais nos sumários gerados por LLMs (CHEN *et al.*, 2025; BUSCH *et al.*, 2025) introduz um risco qualitativo novo em relação aos sistemas de SR tradicionais , não apenas transcrição imprecisa, mas geração de informação clinicamente plausível, porém incorreta. A ausência de eventos adversos documentados nos estudos incluídos não deve ser interpretada como evidência de segurança, dado que nenhum estudo foi desenhado para detectar danos clínicos reais e que a revisão humana foi parte do protocolo em todos os casos.

6 DISCUSSÃO

Os resultados desta revisão indicam que sistemas de inteligência artificial aplicados à documentação clínica apresentam potencial para melhorar a eficiência e a organização dos registros, porém com limitações relevantes em termos de acurácia e segurança. A evidência disponível é limitada, com apenas quatro estudos incluídos e elevada heterogeneidade metodológica, o que restringe a robustez das conclusões

Os quatro estudos incluídos nesta revisão abrangem um período de sete anos, entre 2018 a 2025, durante o qual a tecnologia subjacente aos sistemas avaliados passou por transformação qualitativa. Goss *et al.* (2019) e Zhou *et al.* (2018) avaliaram o Dragon Medical 360, sistema que utiliza arquiteturas híbridas combinando Modelos Ocultos de Markov (HMM) e redes neurais profundas (DNN-HMM), paradigma dominante até meados da década de 2010. Chen *et al.* (2025) e Busch *et al.* (2025) avaliaram sistemas construídos sobre modelos Transformer de grande escala, o DeNoiseformer integrado ao Qwen2.5-7B-Instruct e o GPT-4o, respectivamente, representando a geração atual de inteligência artificial aplicada à documentação clínica.

Essa heterogeneidade tecnológica é constitutiva dos achados e não pode ser tratada como ruído metodológico. A variação no desempenho entre os estudos reflete, em larga medida, a distância entre gerações tecnológicas avaliadas, e não inconsistência entre cenários comparáveis. Na mesma perspectiva dos achados observamos em uma revisão sistemática recente de Ng *et al.* (2025) que foram identificadas taxas de erro variando de WER 0,087 em condições controladas de ditado a mais de 50% em cenários de múltiplos falantes, amplitude que reflete precisamente essa dependência contextual. Blackley *et al.* (2019), em revisão que englobou 122 estudos publicados entre 1990 e 2018, já documentava que 39,3% dos estudos avaliavam exclusivamente o contexto radiológico e apenas 8,2% a medicina de emergência, evidenciando que os padrões de evidência disponíveis são enviesados para os contextos mais favoráveis ao ASR.

A adoção de arquiteturas Transformer resultou em ganhos documentados de desempenho em reconhecimento de fala, com reduções substanciais de WER comparadas a sistemas recorrentes e baseados em HMM (GULATI *et al.*, 2020). A integração de LLMs adicionou uma camada de processamento que ultrapassa a transcrição literal, permitindo estruturação, correção contextual e síntese automática do conteúdo clínico (BROWN *et al.*, 2020; THIRUNAVUKARASU *et al.*, 2023). Contudo, os dados do

corpus impõem cautela a narrativas de superação linear. Mesmo com arquiteturas de última geração, Chen *et al.* (2025) reportaram CER de 52,92% em condições de ruído extremo de ambulância, valor que representa ganho sobre os baselines avaliados, mas que é insuficiente para uso clínico autônomo. Busch *et al.* (2025), com GPT-4o, identificaram erros em proporção expressiva dos laudos avaliados, incluindo erros factuais em 5,03% (alemão) e 7,83% (inglês) dos casos. Esses resultados indicam que a fronteira tecnológica atual, embora significativamente superior à geração anterior, não eliminou os riscos à documentação clínica.

A análise integrada do corpus revela que o desempenho dos sistemas de ASR e LLMs é mais sensível ao contexto clínico do que à geração tecnológica isoladamente. Dois fatores emergem como determinantes centrais: as características acústicas do ambiente e o tipo de tarefa de documentação demandada.

O impacto do ambiente acústico é demonstrado de forma contundente por Chen *et al.* (2025). A diferença de CER entre condições de ruído moderado (8,74%) e ruído extremo de ambulância (52,92%), degradação de aproximadamente seis vezes, ilustra que a relação sinal-ruído é uma variável crítica que pode comprometer qualquer sistema de ASR independentemente de sua arquitetura. O ambiente pré-hospitalar concentra múltiplas fontes de interferência simultâneas: sirenes, alarmes de equipamentos médicos, ruído de motor e múltiplos falantes, criando condições que representam o limite operacional dos sistemas atuais. Essa constatação tem implicação direta para contextos análogos não representados no corpus desta revisão, medicina intensiva, pronto-socorro, unidades de trauma, onde as condições acústicas adversas são igualmente características.

O tipo de tarefa de documentação constitui o segundo determinante relevante. Laudos radiológicos, o contexto de Busch *et al.* (2025), seguem estrutura altamente padronizada, com vocabulário relativamente previsível, produzidos em condições acústicas controladas. Notas clínicas de múltiplas especialidades, como as analisadas por Zhou *et al.* (2018), apresentam maior variabilidade narrativa, incluindo história clínica, raciocínio diagnóstico e planejamento terapêutico, o que amplia o espaço de possíveis erros de transcrição. O survey de Goss *et al.* (2019) documenta esse gradiente de adoção na prática: 66,9% dos clínicos utilizavam SR para história da doença atual e plano de avaliação, mas apenas 3,3% para registro de medicações e 1,2% para alergias, exatamente as seções de maior risco clínico em caso de erro de transcrição. Essa distribuição seletiva

de uso sugere que os próprios clínicos calibram intuitivamente o risco, evitando o SR em campos onde erros têm consequências diretas e imediatas.

A variabilidade de desempenho entre idiomas observável no estudo de Busch *et al.* (2025), BERTScores significativamente mais elevados para alemão do que para inglês, reflete desigualdades nos dados de pré-treinamento dos modelos e diferenças estruturais entre as línguas avaliadas. Essa assimetria, somada à completa ausência de estudos em português no corpus desta revisão e na literatura identificada por Ng *et al.* (2025), configura uma lacuna crítica para o contexto brasileiro: não há evidência disponível sobre o desempenho de sistemas de ASR ou LLMs para documentação clínica em português brasileiro, com as especificidades fonológicas, lexicais e terminológicas da prática médica no âmbito do Sistema Único de Saúde (SUS).

Cabe destacar que, a opção por analisar a arquitetura técnica de forma descritiva revelou-se acertada, visto que os resultados demonstraram que o desempenho é mais sensível ao contexto clínico e acústico do que à geração tecnológica isoladamente. A heterogeneidade observada entre o CER de 52,92% em ambulâncias e o WER de 0,087 em ditados estruturados confirma que métricas de infraestrutura isoladas não capturariam a complexidade da implementação real.

Em se tratando de segurança os achados constituem o núcleo argumentativo mais robusto desta revisão, com os dados de Zhou *et al.* (2018) como seu ponto de ancoragem empírico mais sólido onde, antes de qualquer revisão humana, 63,6% das notas clínicas geradas pelo SR continham ao menos um erro clinicamente significativo. A cadeia de revisão dupla, transcritor profissional seguida de assinatura médica, reduziu progressivamente essa proporção para 14,7% e 7,8%, respectivamente. Os erros mais frequentes envolveram deleções (34,7%) e inserções (27,0%), e a concordância entre os dois médicos avaliadores para classificação de significância clínica foi de 85,7%, conferindo robustez ao julgamento, mas também evidenciando a subjetividade inerente à avaliação de dano potencial.

Esses dados têm implicação direta para a segurança do paciente que transcende os percentuais absolutos. Em uma revisão de BLACKLEY *et al.* (2019) já se identificavam, numa amostra de 122 estudos, achados mistos sobre acurácia, com variações substanciais entre especialidades e contextos, o que sugere que a persistência de erros clinicamente

significativos após revisão não é exclusiva do estudo de Zhou *et al.* (2018), mas um padrão consistente na literatura.

Os estudos com LLMs introduzem uma dimensão qualitativamente nova de risco: não apenas transcrição imprecisa, mas geração de informações sem base no conteúdo original, o fenômeno de alucinação tal como descrito por Thirunavukarasu *et al.* (2023), e que corrobora com Busch *et al.* (2025) que identificaram erros factuais compatíveis com alucinações em 5,03% dos laudos em alemão e 7,83% em inglês, classificados como de severidade leve pelos leitores. Chen *et al.* (2025) não reportaram eventos adversos em sua prova de conceito, mas o estudo não foi desenhado para detecção sistemática de alucinações, e o modelo de avaliação empregado, médicos avaliando 30 textos selecionados aleatoriamente, não tem significância estatística para detectar eventos raros.

A teoria das defesas em profundidade (REASON, 2000) oferece um modelo interpretativo coerente com o conjunto de evidências: sistemas seguros incorporam múltiplas camadas de proteção redundantes, de modo que falhas em uma camada sejam interceptadas por camadas subsequentes. No contexto dos sistemas avaliados, a revisão humana constitui a camada de defesa essencial e insubstituível. Os dados de Zhou *et al.* (2018) quantificam com precisão sua eficácia: a cadeia de revisão dupla reduziu o risco de erro clinicamente significativo em mais de oito vezes. A pressão sobre essa camada, seja por escassez de tempo, por interfaces que não facilitam a detecção de erros, ou por excesso de confiança na tecnologia (automation bias), representa o principal vetor de risco identificável a partir do corpus desta revisão.

Em se tratando, dos resultados de eficiência de tempo são heterogêneos e não autorizam conclusões generalizantes. Chen *et al.* (2025) reportaram redução de 30% no tempo de preenchimento do prontuário pré-hospitalar, de 20 para 14 minutos, com base na média histórica provincial do sistema de informações de Zhejiang. Trata-se de ganho relevante em contexto em que a demora no registro compromete o atendimento subsequente, mas a ausência de grupo controle concorrente e o universo geográfico restrito a uma província chinesa limitam a generalização. Busch *et al.* (2025) registraram tempos medianos de correção que diminuíram com a experiência clínica do leitor, de 2:43 minutos para o residente do primeiro ano a 1:30 minutos para o especialista sênior, evidenciando que a capacidade de identificar e corrigir erros de LLM é uma habilidade adquirida, com implicações diretas para estratégias de treinamento e implementação.

Os dados de Goss *et al.* (2019) iluminam a dimensão subjetiva da eficiência de forma matizada. Embora 77,2% dos respondentes tenham concordado que o SR melhora a eficiência, 21,2% relataram dedicar 25% ou mais do tempo total de documentação à edição e correção de transcrições. A análise de regressão logística demonstrou que o tempo de edição foi significativamente associado a menor satisfação ($p=0,006$), e que a prevalência de erros foi negativamente associada à satisfação ($p<0,001$). Esses achados revelam uma tensão estrutural nos sistemas front-end, onde o próprio clínico assume o custo da revisão: o ganho de tempo na fase de ditado pode ser parcial ou integralmente anulado pelo tempo de edição, resultando em um custo oculto que não aparece nas métricas de eficiência bruta. MOY *et al.* (2021), em revisão de escopo de 35 estudos, identificaram que carga de documentação e burnout clínico são constructos interligados, mas que medidas padronizadas de carga de documentação ainda são ausentes na literatura, o que dificulta a comparação entre estudos. A distinção entre sistemas front-end e back-end, como o analisado por Zhou *et al.* (2018), em que a revisão é realizada por transcritor profissional, é determinante para a interpretação dos resultados de eficiência e frequentemente negligenciada nas comparações.

A satisfação do usuário, neste cenário, emerge como variável intermediária crítica entre desempenho técnico e adoção sustentada. Goss *et al.* (2019) demonstraram que satisfação foi positivamente associada à percepção de eficiência ($p<0,001$) e negativamente associada tanto à prevalência de erros ($p<0,001$) quanto ao tempo de edição ($p=0,006$). Isso sugere que a adoção sustentada de sistemas de ASR depende não apenas da acurácia técnica, mas da experiência subjetiva do usuário com o fluxo de trabalho como um todo, dimensão que os estudos de prova de conceito, focados em métricas objetivas de desempenho, não capturam.

Por fim, em conjunto, os achados indicam que sistemas de transcrição baseados em inteligência artificial ainda não apresentam maturidade suficiente para uso autônomo em documentação clínica.

Seu uso deve ser compreendido como ferramenta de apoio, integrada a fluxos de trabalho supervisionados, a fim de equilibrar ganhos de eficiência com a segurança do paciente. A análise dos estudos sugere, ainda, que a implementação dessas tecnologias sem mecanismos robustos de validação pode introduzir riscos sistêmicos e que a revisão humana deve ser entendida como componente estrutural do sistema, e não como etapa opcional. Os resultados indicam melhora consistente na estruturação textual das notas

clínicas, especialmente com o uso de LLMs (Busch, 2025). No entanto, essa melhoria refere-se predominantemente à forma, e não necessariamente ao conteúdo. Esse achado é crítico, pois pode gerar falsa sensação de confiabilidade, uma vez que documentos bem organizados podem mascarar erros clínicos relevantes.

6.1 LACUNAS E IMPLICAÇÕES PARA O CONTEXTO BRASILEIRO

A análise integrada do corpus revela um mapa de lacunas que é, em si, um resultado substantivo desta revisão. Nenhum dos quatro estudos foi conduzido em português, em contexto de baixa ou média renda, ou no âmbito de sistemas universais de saúde como o SUS. As populações estudadas são de clínicos norte-americanos de dois grandes sistemas integrados de saúde (GOSS *et al.*, 2019; ZHOU *et al.*, 2018), paramédicos de uma província chinesa (CHEN *et al.*, 2025) e radiologistas alemães nativos (BUSCH *et al.*, 2025). A revisão sistemática de Ng *et al.* (2025), com alcance de busca mais abrangente, não identificou estudos em português brasileiro, corroborando a lacuna. Essa configuração limita substancialmente a extrapolação para o contexto brasileiro.

As especificidades do português brasileiro representam desafios técnicos não documentados na literatura revisada. O português brasileiro combina variação fonológica regional acentuada, diferenças de vogais, entonação e velocidade de fala entre regiões, vocabulário médico com influência de termos latinos e anglicismos em processo de incorporação, e terminologia específica do SUS (CID-10, CID-11, SIGTAP) que dificilmente está representada nos corpora de pré-treinamento dos modelos internacionais avaliados. Chen *et al.* (2025) notaram que o Qwen2.5 foi treinado em corpora gerais com cobertura limitada de conhecimento médico em chinês, idioma de maior volume de dados nos modelos da série Qwen do que o português, o que ilustra as dificuldades de domínio especializado mesmo em idiomas melhor representados podendo evidenciar que a cobertura médica em português é presumivelmente limitada.

O contexto operacional do SUS introduz dimensões adicionais de complexidade. A infraestrutura tecnológica heterogênea entre municípios, a variabilidade dos sistemas de prontuário eletrônico em uso, as restrições de conectividade em unidades básicas de saúde e as especificidades dos fluxos assistenciais, consultas de alta frequência e curta

duração, rotatividade de profissionais, modalidades de atenção domiciliar e pré-hospitalar, configuram um conjunto de condições que a literatura internacional não contempla. Do ponto de vista regulatório, a implementação de sistemas de ASR e LLMs para documentação clínica no Brasil está sujeita à Lei Geral de Proteção de Dados (LGPD, Lei nº 13.709/2018), que classifica dados de saúde como sensíveis e exige base legal específica para tratamento. O Projeto de Lei nº 2.338/2023, em tramitação no Senado Federal, propõe o Marco Legal da Inteligência Artificial no Brasil e inclui disposições para sistemas de alto risco em saúde, com exigências de transparência, auditabilidade e responsabilização, arcabouço regulatório sem equivalente nos contextos dos estudos incluídos e que reforça a necessidade de avaliações conduzidas em contexto nacional antes de qualquer recomendação de implementação.

6.2 LIMITAÇÕES DESTA REVISÃO

Esta revisão apresenta limitações que devem ser consideradas na interpretação dos resultados. Primeiro, o corpus final de quatro estudos é modesto para suportar conclusões definitivas, sendo resultado de critérios de elegibilidade necessariamente restritivos, a exemplo dos testes em cenário real, e da ausência de estudos em português. Segundo a heterogeneidade metodológica entre os estudos incluídos inviabilizou a condução de uma revisão sistemática com metanálise, o que limita a síntese quantitativa e a precisão das estimativas de efeito, reconduzindo o estudo a alteração no protocolo para uma revisão de escopo. Dentre os achados, dois dos quatro estudos são provas de conceito com amostras restritas e sem grupo controle, representando o nível mais baixo de evidência na hierarquia metodológica. Outra limitação importante é que todos os estudos foram conduzidos em países de alta renda com contextos tecnológicos e organizacionais distintos do brasileiro, limitando a validade externa para o SUS.

O risco de publicação favorável, onde estudos com resultados positivos sendo mais frequentemente publicados e indexados do que estudos com resultados negativos ou nulos, é uma ameaça à validade das conclusões que não pode ser descartada. A revisão de Ng *et al.* (2025), ao sintetizar 29 estudos com evidências mistas, confirma essa assimetria: embora a maioria dos estudos reporte ganhos de eficiência, outros documentam aumento da carga de edição e efeitos inconclusivos sobre custo-efetividade, sugerindo que a literatura disponível pode superestimar os benefícios práticos da tecnologia. A ausência

de relato de registro prospectivo de protocolo em três dos quatro estudos do corpus desta revisão limita adicionalmente a capacidade de detectar viés de relato seletivo de desfechos.

7 CONCLUSÃO

Esta revisão de escopo mapeou as evidências disponíveis sobre o uso de sistemas baseados em inteligência artificial, incluindo reconhecimento automático de fala (ASR) e grandes modelos de linguagem (LLMs), aplicados à documentação clínica em contextos reais de atenção à saúde. Os resultados indicam que essas tecnologias apresentam potencial para melhorar a eficiência dos processos de documentação e a qualidade estrutural dos registros clínicos. No entanto, esse potencial é acompanhado por limitações relevantes, especialmente relacionadas à acurácia da transcrição e à ocorrência de erros clinicamente significativos.

Foram identificados perfis distintos de erro entre as tecnologias. Sistemas baseados em ASR estão predominantemente associados a erros lexicais de transcrição, enquanto modelos baseados em LLMs introduzem riscos relacionados a distorções semânticas e à geração de informações plausíveis, porém incorretas. Essas limitações têm implicações diretas para a segurança do paciente, particularmente na ausência de revisão humana sistemática. Adicionalmente, os achados indicam que os ganhos de eficiência não eliminam a necessidade de participação do profissional de saúde, mas deslocam a carga de trabalho para atividades de verificação e correção. Dessa forma, os benefícios dessas tecnologias são dependentes do contexto e da forma como são integradas aos fluxos de trabalho clínico. A robustez das evidências é limitada pelo reduzido número de estudos incluídos, pela heterogeneidade metodológica e pela predominância de delineamentos exploratórios. Assim, as conclusões desta revisão devem ser interpretadas com cautela.

O achado de maior relevância para a agenda científica nacional é, paradoxalmente, a ausência de evidência. Nenhum dos quatro estudos incluídos foi conduzido em língua portuguesa, em contexto de sistema universal de saúde ou em país de renda baixa ou média. A revisão sistemática de Ng *et al.* (2025), com busca abrangente até fevereiro de 2025 e 29 estudos incluídos, tampouco identificou estudos em português brasileiro. Essa lacuna não é residual: ela significa que as evidências disponíveis sobre acurácia, segurança, eficiência e experiência do usuário com sistemas de ASR e LLMs foram geradas integralmente em contextos com infraestrutura tecnológica, perfis linguísticos e condições operacionais distintos das unidades de saúde do Sistema Único de Saúde (SUS). A variação fonológica regional do português brasileiro, a terminologia específica do SUS e as assimetrias de infraestrutura digital entre municípios configuram um

conjunto de condições que os modelos internacionais avaliados não foram projetados para tratar. Portanto, qualquer decisão de implementação de sistemas de ASR ou LLMs para documentação clínica no contexto do SUS carece, atualmente, de base empírica nacional que a respalde.

Por fins, concluímos que no estágio atual de desenvolvimento, os sistemas de documentação clínica baseados em inteligência artificial não apresentam confiabilidade suficiente para uso autônomo. Seu papel deve ser compreendido como ferramenta de apoio, exigindo supervisão humana obrigatória e integração a modelos de segurança em múltiplas camadas. Futuras pesquisas devem priorizar estudos clínicos robustos, padronização de métricas de avaliação e análise do impacto dessas tecnologias na segurança do paciente e na prática assistencial. Consideramos que a ausência de estudos em português brasileiro e no SUS não é uma limitação desta revisão, mas é o seu principal achado, e o ponto de partida necessário para pesquisas futuras.

REFERÊNCIAS

- ABDEL-HAMID, O. *et al.* **Convolutional neural networks for speech recognition.** IEEE/ACM Transactions on Audio, Speech, and Language Processing, v. 22, n. 10, p. 1533-1545, 2014. <https://doi.org/10.1109/TASLP.2014.2339736>.
- ADLER-MILSTEIN, J. *et al.* **Electronic health record adoption** in US hospitals: progress continues, but challenges persist. Health Affairs, v. 34, n. 12, p. 2174-2180, 2015. <https://doi.org/10.1377/hlthaff.2015.0992>.
- ALAYRAC, J. *et al.* **Flamingo: a visual language model for few-shot learning.** Advances in Neural Information Processing Systems, v. 35, p. 23716-23736, 2022. <https://doi.org/10.48550/arXiv.2204.14198>.
- ARKSEY, H.; O'MALLEY, L. **Scoping studies: towards a methodological framework.** International Journal of Social Research Methodology, v. 8, n. 1, p. 19-32, 2005. <https://doi.org/10.1080/1364557032000119616>.
- ARTSI, Y. *et al.* **Large language models in real-world clinical workflows: a systematic review of applications and implementation.** Frontiers in Digital Health, v. 7, 2025. DOI: 10.3389/fdgth.2025.1659134.
- ASGARI, E. *et al.* **A framework to assess clinical safety and hallucination rates of LLMs for medical text summarisation.** npj Digital Medicine, v. 8, n. 274, 2025. DOI: 10.1038/s41746-025-01670-7.
- AZAMFIREI, R. *et al.* **A systematic review of ethical considerations of large language models in healthcare and medicine.** Frontiers in Digital Health, v. 7, 2025. DOI: 10.3389/fdgth.2025.1653631.
- BAHDANAU, D. *et al.* **End-to-end attention-based large vocabulary speech recognition.** In: IEEE INTERNATIONAL CONFERENCE ON ACOUSTICS, SPEECH AND SIGNAL PROCESSING, 2016. Proceedings [...]. New York: IEEE, 2016. p. 4945-4949. <https://doi.org/10.1109/ICASSP.2016.7472621>.
- BALDWIN, J. *et al.* **Early insights into the impact of an ambient AI scribe solution on clinical documentation to reduce clinician burnout in oncology.** Journal of Clinical Oncology, v. 43, n. 16_suppl, p. e13722, 2025. DOI: 10.1200/JCO.2025.43.16_suppl.e13722.
- BARBALHO, I. M. P. *et al.* **Electronic health records in Brazil: prospects and technological challenges.** Frontiers in Public Health, v. 10, p. 963841, 2022. DOI: 10.3389/fpubh.2022.963841.
- BATISTA, T. M. *et al.* **Desempenho de sistemas de reconhecimento automático de fala no português brasileiro em cenários de saúde: desafios e perspectivas.** Cadernos de Saúde Pública, v. 35, n. 3, p. e00100119, 2019.
- BENGIO, Y. *et al.* **Neural probabilistic language models.** In: INNOVATIONS IN MACHINE LEARNING. Berlin: Springer, 2006. p. 137-186. https://doi.org/10.1007/3-540-33486-6_6.
- BENGIO, Y.; SIMARD, P.; FRASCONI, P. **Learning long-term dependencies with gradient descent is difficult.** IEEE Transactions on Neural Networks, v. 5, n. 2, p. 157-166, 1994. <https://doi.org/10.1109/72.279181>.

BLACKLEY, S. V. *et al.* **Speech recognition for clinical documentation from 1990 to 2018: a systematic review.** Journal of the American Medical Informatics Association, v. 26, n. 4, p. 324-338, 2019. <https://doi.org/10.1093/jamia/ocy179>.

BOMMASANI, R. *et al.* **On the opportunities and risks of foundation models.** *arXiv preprint*, 2021. <https://doi.org/10.48550/arXiv.2108.07258>.

BOROWITZ, S. M.; WYATT, J. C. **The origin, content, and workload of e-mail consultations.** JAMA, v. 280, n. 15, p. 1321-1324, 2001. <https://doi.org/10.1001/jama.280.15.1321>.

BRASIL. Ministério da Saúde. **Portaria GM/MS n.º 3.232, de 22 de setembro de 2023. Institui o Programa SUS Digital.** Diário Oficial da União, Brasília, DF, 25 set. 2023. Seção 1, p. 105.

BROWN, T. B. *et al.* **Language models are few-shot learners.** *Advances in Neural Information Processing Systems*, v. 33, p. 1877-1901, 2020. DOI: 10.48550/arXiv.2005.14165.

BUSCH, F. *et al.* **Multilingual feasibility of GPT-4o for automated voice-to-text CT and MRI report transcription.** *European Journal of Radiology*, v. 182, p. 111827, 2025. DOI: 10.1016/j.ejrad.2024.111827.

CAMPANELLA, P. *et al.* **The impact of electronic health records on healthcare quality: a systematic review and meta-analysis.** *European Journal of Public Health*, v. 26, n. 1, p. 60-64, 2016. <https://doi.org/10.1093/eurpub/ckv122>.

CASELI, H. M.; NUNES, M. G. V. (org.). **Processamento de linguagem natural: conceitos, técnicas e aplicações em português.** 3. ed. São Carlos: BPLN, 2024. Disponível em: <https://brasileiraspln.com/livro-pln/3a-edicao>. Acesso em: 10 jan. 2025.

CAVALCANTE, R. B. *et al.* **Informatização da atenção básica à saúde: avanços e desafios.** *Cogitare Enfermagem*, v. 24, p. e59280, 2019. <https://doi.org/10.5380/ce.v24i0.59280>.

CHEN, Y. *et al.* **Deep learning-based in-ambulance speech recognition and generation of prehospital emergency diagnostic summaries using LLMs.** *International Journal of Medical Informatics*, v. 203, p. 106029, 2025. <https://doi.org/10.1016/j.ijmedinf.2024.105648>.

CHOWDHURY, G. G. **Natural language processing.** *Annual Review of Information Science and Technology*, v. 37, n. 1, p. 51-89, 2003. <https://doi.org/10.1002/aris.1440370103>.

CLARKE, M. *et al.* **Cochrane Reviewers' Handbook 4.1.** In: ALDERSON, P. *et al.* (ed.). *The Cochrane Library*. Oxford: Update Software, 2000. Issue 4.

DAHL, G. E. *et al.* **Context-dependent pre-trained deep neural networks for large-vocabulary speech recognition.** *IEEE Transactions on Audio, Speech, and Language Processing*, v. 20, n. 1, p. 30-42, 2012. <https://doi.org/10.1109/TASL.2011.2134090>.

DEMNER-FUSHMAN, D.; CHAPMAN, W. W.; MCDONALD, C. J. **What can natural language processing do for clinical decision support?** *Journal of Biomedical Informatics*, v. 42, n. 5, p. 760-772, 2009. <https://doi.org/10.1016/j.jbi.2009.08.007>.

DENG, L.; YU, D. **Deep learning: methods and applications.** *Foundations and Trends in Signal Processing*, v. 7, n. 3-4, p. 197-387, 2013. <https://doi.org/10.1561/20000000039>.

- DEVLIN, J. *et al.* **BERT: pre-training of deep bidirectional transformers for language understanding.** In: CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS: HUMAN LANGUAGE TECHNOLOGIES, 2019, Minneapolis. Proceedings [...]. Stroudsburg: ACL, 2019. p. 4171-4186. <https://doi.org/10.48550/arXiv.1810.04805>.
- DONG, L.; XU, S.; XU, B. **Speech-transformer: a no-recurrence sequence-to-sequence model for speech recognition.** In: IEEE INTERNATIONAL CONFERENCE ON ACOUSTICS, SPEECH AND SIGNAL PROCESSING, 2018. Proceedings [...]. New York: IEEE, 2018. p. 5884-5888. <https://doi.org/10.1109/ICASSP.2018.8462506>.
- FALCETTA, F. S. *et al.* **Automatic documentation of professional health interactions: a systematic review.** *Artificial Intelligence in Medicine*, v. 137, p. 102487, 2023. DOI: 10.1016/j.artmed.2023.102487.
- FISCUS, J. G. *et al.* **Results of the 2006 spoken term detection evaluation.** In: SIGIR WORKSHOP ON SEARCHING SPONTANEOUS CONVERSATIONAL SPEECH, 2007. Proceedings [...]. New York: ACM, 2007. p. 51-57.
- GAIKWAD, S. K.; GAWALI, B. W.; YANNAWAR, P. **A review on speech recognition technique.** *International Journal of Computer Applications*, v. 10, n. 3, p. 16-24, 2010. <https://doi.org/10.5120/1462-1976>.
- GALES, M.; YOUNG, S. **The application of hidden Markov models in speech recognition.** *Foundations and Trends in Signal Processing*, v. 1, n. 3, p. 195-304, 2008. <https://doi.org/10.1561/20000000004>.
- GOLDBERG, Y. **Neural network methods for natural language processing.** *Synthesis Lectures on Human Language Technologies*, v. 10, n. 1, p. 1-309, 2017. DOI: 10.2200/S00762ED1V01Y201703HLT037.
- GOSS, F. R. *et al.* **A clinician survey of using speech recognition for clinical documentation in the electronic health record.** *International Journal of Medical Informatics*, v. 130, p. 103938, 2019. <https://doi.org/10.1016/j.ijmedinf.2019.08.014>.
- GRAHAM, C.; ROLL, N. **Evaluating OpenAI's Whisper ASR: performance analysis across diverse accents and speaker traits.** *JASA Express Letters*, v. 4, n. 2, p. 025206, 2024. <https://doi.org/10.1121/10.0024876>.
- GRAVES, A.; JAITLEY, N. **Towards end-to-end speech recognition with recurrent neural networks.** In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 31., 2014. Proceedings [...]. [S. l.]: PMLR, 2014. p. 1764-1772.
- GRAVES, A.; MOHAMED, A. R.; HINTON, G. **Speech recognition with deep recurrent neural networks.** In: IEEE INTERNATIONAL CONFERENCE ON ACOUSTICS, SPEECH AND SIGNAL PROCESSING, 2013. Proceedings [...]. New York: IEEE, 2013. p. 6645-6649. <https://doi.org/10.1109/ICASSP.2013.6638947>.
- GRIS, I. *et al.* **Evaluating OpenAI Whisper for automated speech recognition in medical settings.** *medRxiv*, 2023. <https://doi.org/10.1101/2023.05.04.23289476>.
- GU, Y. *et al.* **Domain-specific language model pretraining for biomedical natural language processing.** *ACM Transactions on Computing for Healthcare*, v. 3, n. 1, p. 1-23, 2021. <https://doi.org/10.1145/3458754>.
- GULATI, A. *et al.* **Conformer: convolution-augmented transformer for speech recognition.** In: INTERSPEECH, 2020. Proceedings [...]. [S. l.]: ISCA, 2020. p. 5036-5040. <https://doi.org/10.21437/Interspeech.2020-3015>.

- GUO, P. *et al.* **Recent developments on conformer-based models.** arXiv preprint, 2021. <https://doi.org/10.48550/arXiv.2105.00175>.
- HAMMANA, I. *et al.* **Speech recognition in the radiology department: a systematic literature review.** HIM Journal, v. 44, n. 2, p. 4-10, 2015. <https://doi.org/10.12826/18333575.2015.0001.Hammana>.
- HANNUN, A. *et al.* **Deep speech: scaling up end-to-end speech recognition.** arXiv preprint, 2014. <https://doi.org/10.48550/arXiv.1412.5567>.
- HÄYRINEN, K.; SARANTO, K.; NYKÄNEN, P. **Definition, structure, content, use and impacts of electronic health records: a review of the research literature.** International Journal of Medical Informatics, v. 77, n. 5, p. 291-304, 2008. <https://doi.org/10.1016/j.ijmedinf.2007.09.001>.
- HINTON, G. E. *et al.* **Deep neural networks for acoustic modeling in speech recognition.** IEEE Signal Processing Magazine, v. 29, n. 6, p. 82-97, 2012. DOI: 10.1109/MSP.2012.2205597.
- HIRSCHTICK, R. E. **Copy-and-paste.** JAMA, v. 295, n. 20, p. 2335-2336, 2006. DOI: 10.1001/jama.295.20.2335.
- HODGSON, T.; COIERA, E. **Risks and benefits of speech recognition for clinical documentation: a systematic review.** Journal of the American Medical Informatics Association, v. 23, n. e1, p. e169-e179, 2016. <https://doi.org/10.1093/jamia/ocv152>.
- HOLDEN, R. J. **Cognitive performance-altering effects of electronic medical records: an application of the human factors paradigm for patient safety.** Cognition, Technology & Work, v. 13, n. 1, p. 11-29, 2011. <https://doi.org/10.1007/s10111-010-0141-8>.
- HONG, Q. N. *et al.* **The Mixed Methods Appraisal Tool (MMAT) version 2018 for information professionals and researchers.** Education for Information, v. 34, n. 4, p. 285- 291, 2018. <https://doi.org/10.3233/EFI-180221>. <http://repositorio.bc.ufg.br/handle/ri/19727>. Acesso em: 3 ago. 2024.
- HUANG, K. *et al.* **ClinicalBERT: modeling clinical notes and predicting hospital readmission.** arXiv preprint, 2019. <https://doi.org/10.48550/arXiv.1904.05342>.
- JELINEK, F. **Statistical methods for speech recognition.** Cambridge: MIT Press, 1998. ISBN 978-0-262-10066-0.
- JHA, A. K. *et al.* **Use of electronic health records in U.S. hospitals.** New England Journal of Medicine, v. 360, n. 16, p. 1628-1638, 2009. <https://doi.org/10.1056/NEJMsa0900592>.
- JOHNSON, M. *et al.* **A systematic review of speech recognition technology in health care.** BMC Medical Informatics and Decision Making, v. 14, n. 1, p. 94, 2014. DOI: 10.1186/1472-6947-14-94.
- JONES, C. H.; DOLSTEN, M. **Healthcare on the brink: navigating the challenges of an aging society in the United States.** npj Aging, v. 10, n. 1, p. 22, 2024. DOI: 10.1038/s41514-024-00148-2.
- JUANG, B. H.; RABINER, L. R. **Automatic speech recognition: a brief history of the technology development.** Georgia Tech and Rutgers University, Atlanta; Santa Barbara, 2005.

- JURAFSKY, D.; MARTIN, J. H. **Speech and language processing**. 3rd ed. [S. l.]: Pearson, 2020. Disponível em: <https://web.stanford.edu/~jurafsky/slp3/>. Acesso em: 10 jan. 2025.
- KANE, O.; WU, A. W. **Leveraging artificial intelligence and technology for patient safety: opportunities, risks, and challenges**. *Journal of Patient Safety and Risk Management*, v. 30, n. 3, p. 103-110, 2025. <https://doi.org/10.1177/25160435251386506>.
- KARITA, S. *et al.* **A comparative study on transformer vs RNN in speech applications**. In: IEEE AUTOMATIC SPEECH RECOGNITION AND UNDERSTANDING WORKSHOP, 2019. Proceedings [...]. New York: IEEE, 2019. p. 449-456. DOI: 10.1109/ASRU46091.2019.9003750.
- KHEDDAR, H.; HEMIS, M.; HIMEUR, Y. **Automatic speech recognition using advanced deep learning approaches: a survey**. *Information Fusion*, v. 109, p. 102422, 2024. <https://doi.org/10.1016/j.inffus.2024.102422>.
- KLAKOW, D.; PETERS, J. **Testing the correlation of word error rate and perplexity**. *Speech Communication*, v. 38, n. 1-2, p. 19-28, 2002. [https://doi.org/10.1016/S0167-6393\(01\)00041-3](https://doi.org/10.1016/S0167-6393(01)00041-3).
- KOENECKE, A. *et al.* **Careless whisper: speech-to-text hallucination harms**. In: ACM CONFERENCE ON FAIRNESS, ACCOUNTABILITY, AND TRANSPARENCY, 2024,
- KOLECK, T. A.; DREISBACH, C.; BAKKEN, S. **Natural language processing of symptoms documented in free-text narratives of electronic health records: a systematic review**. *Journal of the American Medical Informatics Association*, v. 26, n. 4, p. 364-379, 2019. <https://doi.org/10.1093/jamia/ocy173>.
- KRUSE, C. S. *et al.* **Barriers to electronic health record adoption: a systematic literature review**. *Journal of Medical Systems*, v. 40, n. 12, p. 252, 2016. <https://doi.org/10.1007/s10916-016-0628-9>.
- LeCUN, Y.; BENGIO, Y.; HINTON, G. **Deep learning**. *Nature*, v. 521, n. 7553, p. 436-444, 2015. <https://doi.org/10.1038/nature14539>.
- LEE, J. *et al.* **BioBERT: a pre-trained biomedical language representation model for biomedical text mining**. *Bioinformatics*, v. 36, n. 4, p. 1234-1240, 2020. DOI: 10.1093/bioinformatics/btz682.
- LEVAC, D.; COLQUHOUN, H.; O'BRIEN, K. K. **Scoping studies: advancing the methodology**. *Implementation Science*, v. 5, n. 69, 2010. <https://doi.org/10.1186/1748-5908-5-69>.
- LIN, C. Y. **ROUGE: a package for automatic evaluation of summaries**. In: ACL WORKSHOP ON TEXT SUMMARIZATION BRANCHES OUT, 2004. Proceedings [...]. Stroudsburg: ACL, 2004. p. 74-81.
- LOPES, T.; ANDRADE, J.; KOMATI, K. **Comparação de serviços em nuvem para transcrição de fala na língua portuguesa em áudios com sotaques regionais brasileiros**. In: ESCOLA REGIONAL DE INFORMÁTICA DE GOIÁS, 9., 2021. Anais [...]. Porto Alegre: SBC, 2021. p. 96-109. <https://doi.org/10.5753/erigo.2021.18436>.

- LUKAC, M. *et al.* **Randomized controlled trial of AI-powered ambient documentation.** New England Journal of Medicine AI, v. 2, n. 5, p. AIoa2501000, 2025. DOI: 10.1056/AIoa2501000.
- LYBARGER, K. *et al.* **Annotating social determinants of health using active learning, and characterizing determinants using neural event extraction.** Journal of Biomedical Informatics, v. 113, p. 103631, 2021. <https://doi.org/10.1016/j.jbi.2020.103631>. v. 23, n. 5, p. 899-908, 2016. <https://doi.org/10.1093/jamia/ocv189>.
- MAGINN, C. A. *et al.* **Comparison of user groups' perspectives of barriers and facilitators to implementing electronic health records: a systematic review.** BMC Medicine, v. 9, n. 1, p. 46, 2011. <https://doi.org/10.1186/1741-7015-9-46>.
- MIKOLOV, T. *et al.* **Distributed representations of words and phrases and their compositionality.** Advances in Neural Information Processing Systems, v. 26, p. 3111- 3119, 2013. <https://doi.org/10.48550/arXiv.1310.4546>.
- MOHAMED, A. R.; DAHL, G. E.; HINTON, G. **Acoustic modeling using deep belief networks.** IEEE Transactions on Audio, Speech, and Language Processing, v. 20, n. 1, p. 14-22, 2012. <https://doi.org/10.1109/TASL.2011.2109382>.
- MORRIS, A. C. *et al.* **From WER and RIL to MER and WIL: improved evaluation measures for connected speech recognition.** In: INTERNATIONAL CONFERENCE ON SPOKEN LANGUAGE PROCESSING, 2004. Proceedings [...]. [S. l.]: ISCA, 2004.
- MOY, A. J. *et al.* **Measurement of clinical documentation burden among physicians and nurses using electronic health records: a scoping review.** Journal of the American Medical Informatics Association, v. 28, n. 5, p. 998-1008, 2021. <https://doi.org/10.1093/jamia/ocaa325>.
- MUNN, Z. *et al.* **Systematic review or scoping review? Guidance for authors when choosing between a systematic review and scoping review approach.** BMC Medical Research Methodology, v. 18, n. 143, 2018. <https://doi.org/10.1186/s12874-018-0611-x>.
- NADKARNI, P. M.; OHNO-MACHADO, L.; CHAPMAN, W. W. **Natural language processing: an introduction.** Journal of the American Medical Informatics Association, v. 18, n. 5, p. 544-551, 2011. <https://doi.org/10.1136/amiajnl-2011-000464>.
- NENKOVA, A.; PASSONNEAU, R. **Evaluating content selection in summarization: the pyramid method.** In: HUMAN LANGUAGE TECHNOLOGY CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL
- NG, J. J. W. *et al.* **Evaluating the performance of artificial intelligence-based speech recognition for clinical documentation: a systematic review.** BMC Medical Informatics and Decision Making, v. 25, n. 236, 2025. <https://doi.org/10.1186/s12911-025-03061-0>.
- O'KANE, R. *et al.* **Transcription accuracy of automatic speech recognition for orthodontic clinical records.** Journal of Dental Research, 2025. <https://doi.org/10.1177/00220345251382452>.
- OLIVEIRA, A. E. C. *et al.* **Implantação do e-SUS AB no Distrito Sanitário IV de João Pessoa (PB): relato de experiência.** Saúde em Debate, v. 40, n. 109, p. 212-218, 2016. <https://doi.org/10.1590/0103-1104-20161090018>.

- OUZZANI, M. *et al.* **Rayyan: a web and mobile app for systematic reviews.** *Systematic Reviews*, v. 5, n. 210, 2016. <https://doi.org/10.1186/s13643-016-0384-4>. p. 437-440.
- PAGE, M. J. *et al.* **The PRISMA 2020 statement: an updated guideline for reporting systematic reviews.** *BMJ*, v. 372, n. 71, 2021. <https://doi.org/10.1136/bmj.n71>.
- PASCANU, R.; MIKOLOV, T.; BENGIO, Y. **On the difficulty of training recurrent neural networks.** In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 30., 2013. Proceedings [...]. [S. l.]: PMLR, 2013. p. 1310-1318.
- PATEL, V. L. *et al.* **Impact of a computer-based patient record system on data collection, knowledge organization, and reasoning.** *Journal of the American Medical Informatics Association*, v. 7, n. 6, p. 569-585, 2000. <https://doi.org/10.1136/jamia.2000.0070569>.
- PATRÍCIO, C. M. *et al.* **O prontuário eletrônico do paciente no sistema de saúde brasileiro: uma realidade para os médicos?** *Scientia Medica*, v. 21, n. 3, p. 121-131, 2011.
- PENNINGTON, J.; SOCHER, R.; MANNING, C. D. **GloVe: global vectors for word representation.** In: CONFERENCE ON EMPIRICAL METHODS IN NATURAL
- PETERS, M. E. *et al.* **Deep contextualized word representations.** In: CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS: HUMAN LANGUAGE TECHNOLOGIES, 2018.
- PINTO, L. F.; ROCHA, C. M. F. **Inovações na atenção primária em saúde: o uso de ferramentas de tecnologia de comunicação e informação para apoio à gestão local.** *Ciência & Saúde Coletiva*, v. 21, n. 5, p. 1433-1448, 2016. <https://doi.org/10.1590/1413-81232015215.22782015>.
- PRABHAVALKAR, R. *et al.* **End-to-end speech recognition: a survey.** *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, v. 32, p. 325-351, 2024. DOI: 10.1109/TASLP.2023.3328283.
- RABINER, L. R. **A tutorial on hidden Markov models and selected applications in speech recognition.** *Proceedings of the IEEE*, v. 77, n. 2, p. 257-286, 1989. DOI: 10.1109/5.18626.
- RADFORD, A. *et al.* **Robust speech recognition via large-scale weak supervision.** In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 40., 2023, Honolulu.
- RATWANI, R. M.; HODGKINS, M.; BATES, D. W. **Improving electronic health record usability and safety requires transparency.** *JAMA*, v. 320, n. 24, p. 2533-2534, 2018. DOI: 10.1001/jama.2018.14079.
- REASON, J. **Human error: models and management.** *BMJ*, v. 320, n. 7237, p. 768-770, 2000. <https://doi.org/10.1136/bmj.320.7237.768>.
- ROGERS, A.; KOVALEVA, O.; RUMSHISKY, A. **A primer in BERTology: what we know about how BERT works.** *Transactions of the Association for Computational Linguistics*, v. 8, p. 842-866, 2020. https://doi.org/10.1162/tacl_a_00349.
- ROSENBLOOM, S. T. *et al.* **Data from clinical notes: a perspective on the tension between structure and flexible documentation.** *Journal of the American Medical*

Informatics Association, v. 18, n. 2, p. 181-186, 2011. <https://doi.org/10.1136/amiajnl-2011-000132>.

ROSENTHAL, D. I. *et al.* **Computer-based speech recognition as a replacement for medical transcription.** American Journal of Roentgenology, v. 170, n. 1, p. 23-25, 1998. <https://doi.org/10.2214/ajr.170.1.9423597>.

ROUSTAN, D.; BASTARDOT, F. **The clinicians' guide to large language models: a general perspective with a focus on hallucinations.** Interactive Journal of Medical Research, v. 14, p. e59823, 2025. <https://doi.org/10.2196/59823>.

SAK, H.; SENIOR, A.; BEAUFAYS, F. **Long short-term memory recurrent neural network architectures for large scale acoustic modeling.** In: INTERSPEECH, 2014. Proceedings [...]. [S. l.]: ISCA, 2014. p. 338-342. <https://doi.org/10.21437/Interspeech.2014-80>.

SALEEM, J. J. *et al.* **Provider burnout as it relates to the electronic health record and clinical workflow.** Proceedings of the Human Factors and Ergonomics Society Annual Meeting, v. 64, n. 1, p. 645-649, 2020. <https://doi.org/10.1177/1071181320641147>.

SAON, G. *et al.* **English conversational telephone speech recognition by humans and machines.** In: INTERSPEECH, 2017. Proceedings [...]. [S. l.]: ISCA, 2017. p. 132-136.

SCHWAN, D. **An ethical case for medical scribes.** Cambridge Quarterly of Healthcare Ethics, v. 31, n. 1, p. 95-104, 2022. <https://doi.org/10.1017/S0963180121000840>.

SEIDE, F.; LI, G.; YU, D. **Conversational speech transcription using context-dependent deep neural networks.** In: INTERSPEECH, 2011. Proceedings [...]. [S. l.]: ISCA, 2011.

SEZGIN, E. *et al.* **Artificial intelligence in clinical communication for improved health outcomes: current applications and future directions.** JAMIA Open, v. 6, n. 1, p. ooac096, 2023. <https://doi.org/10.1093/jamiaopen/ooac096>.

SHORTLIFFE, E. H.; CIMINO, J. J. (ed.). **Biomedical informatics: computer applications in health care and biomedicine.** 4th ed. London: Springer, 2021. DOI: 10.1007/978-3-030-58721-5.

SINGHAL, K. *et al.* **Large language models encode clinical knowledge.** Nature, v. 620, n. 7972, p. 172-180, 2023. DOI: 10.1038/s41586-023-06291-2.

SINSKY, C. *et al.* **Allocation of physician time in ambulatory practice: a time and motion study in 4 specialties.** Annals of Internal Medicine, v. 165, n. 11, p. 753-760, 2016. DOI: 10.7326/M16-0961.

SKEFF, K. M. *et al.* **Professional behavior and value erosion: a qualitative study of physicians and the electronic health record.** Journal of Healthcare Management, v. 67, n. 5, p. 339-352, 2022. <https://doi.org/10.1097/JHM-D-21-00070>.

SUNDERMEYER, M.; SCHLÜTER, R.; NEY, H. **LSTM neural networks for language modeling.** In: INTERSPEECH, 2012. Proceedings [...]. [S. l.]: ISCA, 2012. p. 194-197.

THIRUNAVUKARASU, A. J. *et al.* **Large language models in medicine.** Nature Medicine, v. 29, n. 8, p. 1930-1940, 2023. <https://doi.org/10.1038/s41591-023-02448-8>.

TIERNEY, A. A. *et al.* **Ambient artificial intelligence scribes to alleviate the burden of clinical documentation.** NEJM Catalyst, v. 5, n. 3, 2024. <https://doi.org/10.1056/cat.23.0404>.

VASWANI, A. *et al.* **Attention is all you need.** In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017, Long Beach. Proceedings [...]. [S. l.]: NeurIPS Foundation, 2017. <https://doi.org/10.48550/arXiv.1706.03762>.

WANG, D.; WANG, X.; LV, S. **An overview of end-to-end automatic speech recognition.** Symmetry, v. 11, n. 8, p. 1018, 2019. <https://doi.org/10.3390/sym11081018>.

WEI, J. *et al.* **Emergent abilities of large language models.** Transactions on Machine Learning. Research, 2022. <https://doi.org/10.48550/arXiv.2206.07682>.

WOLF, T. *et al.* **Transformers: state-of-the-art natural language processing.** In: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING: SYSTEM DEMONSTRATIONS, 2020. Proceedings [...]. Stroudsburg: ACL, 2020. p. 38-45. DOI: 10.18653/v1/2020.emnlp-demos.6.

XIONG, W. *et al.* **The Microsoft 2017 conversational speech recognition system.** In: IEEE INTERNATIONAL CONFERENCE ON ACOUSTICS, SPEECH AND SIGNAL PROCESSING, 2018. Proceedings [...]. New York: IEEE, 2018. p. 5934-5938. DOI: 10.1109/ICASSP.2018.8461870.

XU, Y. *et al.* **Enhancing clinical documentation with voice processing and large language models: a study on the LAOS system.** npj Digital Medicine, v. 8, n. 1, p. 1-12, 2025. DOI: 10.1038/s41746-025-02170-4.

YOUNG, S. *et al.* **The HTK book.** Cambridge: Cambridge University Engineering Department, 2002. v. 3.

YU, D.; DENG, L. **Hidden Markov models and the variants.** In: AUTOMATIC SPEECH RECOGNITION. London: Springer, 2014. p. 23-54. https://doi.org/10.1007/978-1-4471-5779-3_3.

ZARA, A. L. S. A. *et al.* (org.). **Trajetória da saúde digital no Brasil.** Goiânia: Cegraf UFG, 2021. E-book. ISBN 978-65-89504-89-4. Disponível em:

ZHENG, K. *et al.* **An evaluation of the usability of electronic health records from the perspective of clinical informatics.** In: AMIA ANNUAL SYMPOSIUM PROCEEDINGS, 2011. Proceedings [...]. [S. l.]: AMIA, 2011. p. 1582-1591. ZHOU, L. *et al.* Analysis of errors in dictated clinical documents assisted by speech recognition software and professional transcriptionists. JAMA Network Open, v. 1, n. 3, p. e180530, 2018. DOI: 10.1001/jamanetworkopen.2018.0530.

ZUE, V. W.; GLASS, J. R. **Conversational interfaces: advances and challenges.** Proceedings of the IEEE, v. 88, n. 8, p. 1166-1180, 2000. <https://doi.org/10.1109/5.880078>.

ANEXO A: TABELA DE ESTRATÉGIAS DE BUSCAS REALIZADAS

Fonte de informação	Termos/descriptores	Busca realizada	Registros	Data
SCOPUS	Termo 1: ("speech recognition software" or "recognition software, speech" or "software, speech recognition" or "voice recognition software" or "recognition software, voice" or "software, voice recognition") Termo 2: ("medical records systems, computerized" OR "Automated Medical Record Systems" OR "Automated Medical Records System" OR "Medical Record System, Automated" OR "Medical Record	(ALL (("speech recognition software" OR "Recognition Software, Speech" OR "Software, Speech Recognition" OR "Voice Recognition Software" OR "Recognition Software, Voice" OR "Software, Voice Recognition")) AND ALL (("electronic health records" OR "Health Record, Electronic" OR "Health Records, Electronic" OR "Electronic Medical Record" OR "Medical Record, Electronic" OR "Medical Records, Electronic" OR "Electronic Health Record" OR "Electronic Medical Records" OR "Medical Records, Computerized" OR "Computerized Medical Record" OR "Computerized Medical Records" OR "Medical Record, Computerized" OR	42	15-05-2025

	Systems, Automated" OR "Medical Records System, Automated" OR "Medical Records Systems, Automated" OR "Automated Medical Records Systems" OR "Computerized Medical Record System" OR "Computerized Medical Record Systems" OR "Computerized Medical Records System" OR "Medical Record System, Computerized" OR "Medical Record Systems, Computerized" OR "Medical Records System, Computerized" OR "Computerized Medical Records Systems" OR "Automated Medical Record System" OR "Computerized Patient Medical Records") Termo 3:	"Electronic Health Record Data")) AND ALL (("medical records systems, computerized" OR "Automated Medical Record Systems" OR "Automated Medical Records System" OR "Medical Record System, Automated" OR "Medical Record Systems, Automated" OR "Medical Records System, Automated" OR "Medical Records Systems, Automated" OR "Automated Medical Records Systems" OR "Computerized Medical Record System" OR "Computerized Medical Record Systems" OR "Computerized Medical Records System" OR "Medical Record System, Computerized" OR "Medical Record Systems, Computerized" OR "Medical Records System, Computerized" OR "Computerized Medical Records Systems" OR "Automated Medical Record System" OR "Computerized Patient Medical Records")))		
--	---	---	--	--

	("electronic health records" OR "Health Record, Electronic" OR "Health Records, Electronic" OR "Electronic Medical Record" OR "Medical Record, Electronic" OR "Medical Records, Electronic" OR "Electronic Health Record" OR "Electronic Medical Records" OR "Medical Records, Computerized" OR "Computerized Medical Record" OR "Computerized Medical Records" OR "Medical Record, Computerized" OR "Electronic Health Record Data")			
--	---	--	--	--

PUBMED	Termo 1: "speech recognition software"[MeSH] OR (Recognition Software, Speech) OR (Software, Speech Recognition) OR (Voice Recognition Software) OR (Recognition Software, Voice) OR (Software, Voice Recognition) Termo 2: "electronic health records"[MeSH] OR (Health Record, Electronic) OR (Health Records, Electronic) OR (Electronic Medical Record) OR (Medical Record, Electronic) OR (Medical Records, Electronic) OR (Electronic Health Record) OR (Electronic Medical Records) OR (Medical Records,	("speech recognition software"[MeSH] OR (Recognition Software, Speech) OR (Software, Speech Recognition) OR (Voice Recognition Software) OR (Recognition Software, Voice) OR (Software, Voice Recognition)) AND ("medical records systems, computerized"[MeSH] OR (Automated Medical Record Systems) OR (Automated Medical Records System) OR (Medical Record System, Automated) OR (Medical Record Systems, Automated) OR (Medical Records System, Automated) OR (Medical Records Systems, Automated) OR (Automated Medical Records Systems) OR (Computerized Medical Record System) OR (Computerized Medical Record Systems) OR (Computerized Medical Records System) OR (Medical Record System, Computerized) OR (Medical Record Systems, Computerized) OR (Medical Records System, Computerized) OR	197	15/05/2025
---------------	---	--	-----	------------

	Computerized) OR (Computerized Medical Record) OR (Computerized Medical Records) OR (Medical Record, Computerized) OR (Electronic Health Record Data) Termo 3 "medical records systems, computerized"[MeSH] OR (Automated Medical Record Systems) OR (Automated Medical Records System) OR (Medical Record System, Automated) OR (Medical Record Systems, Automated) OR (Medical Records System, Automated) OR (Medical Records Systems, Automated) OR (Automated Medical Records Systems) OR (Computerized Medical Record System) OR	(Computerized Medical Records Systems) OR (Automated Medical Record System) OR (Computerized Patient Medical Records))		
--	--	---	--	--

	(Computerized Medical Record Systems) OR (Computerized Medical Records System) OR (Medical Record System, Computerized) OR (Medical Record Systems, Computerized) OR (Medical Records System, Computerized) OR (Computerized Medical Records Systems) OR (Automated Medical Record System) OR (Computerized Patient Medical Records) Termo 4: "Routinely Collected Health Data"[Mesh] OR (Routinely-Collected Health Data) OR (Health Data, Routinely-Collected) OR (Routinely Collected Data) OR (Routinely-Collected Data) OR (Data, Routinely-			
--	--	--	--	--

	Collected) OR (Health Administrative Data) OR (Administrative Data, Health) OR (Data, Health Administrative) OR (Health Administrative Datas) OR (Registry Data) OR (Data, Registry) OR (Wearable Device Data) OR (Data, Wearable Device) OR (Device Data, Wearable) Termo 5: "Artificial Intelligence"[Mesh] OR (Intelligence, Artificial) OR (Computer Reasoning) OR (Reasoning, Computer) OR (AI (Artificial Intelligence)) OR (Machine Intelligence) OR (Intelligence, Machine) OR (Computational Intelligence) OR (Intelligence, Computational) OR			
--	--	--	--	--

	(Computer Vision Systems) OR (Computer Vision System) OR (System, Computer Vision) OR (Systems, Computer Vision) OR (Vision System, Computer) OR (Vision Systems, Computer) OR (Knowledge Acquisition (Computer)) OR (Acquisition, Knowledge (Computer)) OR (Knowledge Representation (Computer)) OR (Knowledge Representations (Computer)) OR (Representation, Knowledge (Computer))			
--	---	--	--	--

Fonte: Elaboração pelo autor (2025)

