



**UNIVERSIDADE FEDERAL DE PERNAMBUCO
CENTRO DE TECNOLOGIA E GEOCIÊNCIAS
PROGRAMA DE PÓS-GRADUAÇÃO DE ENGENHARIA MECÂNICA**

**IDENTIFICAÇÃO DE REGIÕES DE GORDURA EM MAMAS ATRAVÉS DE
IMAGENS TERMOGRÁFICAS**

Yurgymann Hansley da Silva de Medeiros

Orientadora: Rita de Cássia Fernandes de Lima
Coorientador: Marcus Costa de Araújo

RECIFE - PE
2025

YURGYMANN HANSLEY DA SILVA DE MEDEIROS

Identificação de regiões de gordura em mamas através de imagens termográficas

Monografia apresentada para o Curso de Pós Graduação em Engenharia Mecânica da Universidade Federal de Pernambuco para obtenção do título de Mestre em Engenharia Mecânica.

Área de concentração: Energia

Orientador: Profa. Dra. Rita de Cássia Fernandes de Lima

Coorientador: Prof. Dr. Marcus Costa de Araújo

Coordenador: Prof. Dr. Darlan Karlo Elisiário de Carvalho

Recife – PE

2025

Catálogo de Publicação na Fonte. UFPE - Biblioteca Central

Medeiros, Yurgymann Hansley da Silva de.

Identificação de regiões de gordura em mamas através de imagens termográficas / Yurgymann Hansley da Silva de Medeiros. - Recife, 2026.

134f.: il.

Dissertação (Mestrado) - Universidade Federal de Pernambuco, Centro de Tecnologia e Geociências, Programa de Pós-Graduação em Engenharia Mecânica, 2026.

Orientação: Rita de Cássia Fernandes de Lima.

Coorientação: Marcus Costa de Araújo.

Inclui Referências e Apêndices.

1. Termografia por infravermelho; 2. Obesidade; 3. Aprendizado de máquina; 4. Adiposidade mamária; 5. Avaliação de gordura mamária. I. Lima, Rita de Cássia Fernandes de. II. Araújo, Marcus Costa de. III. Título.

UFPE-Biblioteca Central

YURGYMANN HANSLEY DA SILVA DE MEDEIROS

Identificação de regiões de gordura em mamas através de imagens termográficas

Dissertação apresentada ao Programa de Pós-Graduação em Engenharia Mecânica da Universidade Federal de Pernambuco, Centro de Tecnologia e Geociências, como requisito parcial para a obtenção do título de Mestre ou Doutor em Engenharia Mecânica. Área de concentração: Energia.

Aprovada em: 03/03/2026.

BANCA EXAMINADORA

Profa. Dra. Rita de Cássia Fernandes de Lima (Orientadora)
Universidade Federal de Pernambuco

Prof. Dr. Marcus Costa de Araújo (Coorientador)
Universidade Federal de Pernambuco

Profa. Dra. Luciete Alves Bezerra (Examinadora Interna)
Universidade Federal de Pernambuco

Profa. Dra. Máira Araújo de Santana (Examinadora Externa)
Universidade Federal de Pernambuco

AGRADECIMENTOS

É com imensa gratidão e satisfação que expresso meus sinceros agradecimentos a todos que contribuíram, direta ou indiretamente, para a realização e conclusão deste trabalho.

Primeiramente, agradeço à minha mãe, Telma Lúcia da Silva, por todo o suporte, carinho e amor, especialmente nos momentos mais difíceis desta jornada. Aos meus irmãos Harryson Hansley da Silva de Medeiros e Yorhan Hansley da Silva de Medeiros, e à minha irmã Khrys Kathyllen da Silva de Medeiros, expresso minha profunda gratidão pelo apoio emocional, incentivo constante e por estarem ao meu lado ao longo de toda esta trajetória acadêmica.

A todos os amigos que estiveram presentes em minha caminhada, agradeço pela amizade, inspiração e pelos momentos especiais compartilhados ao longo desta trajetória. Ao Matheus Torres, cuja amizade surgiu de forma inesperada e manteve-se sólida e verdadeira ao longo dos anos. Ao Robson Viegas, meu melhor amigo, com quem compartilho uma parceria que, mesmo após anos, permanece firme, sustentada pelo apoio mútuo, respeito e lealdade, independentemente da distância ou da correria da vida. E especialmente à Maria Eloyse, de grande significado em minha vida, cuja presença e apoio ultrapassam o que palavras conseguem descrever, guardo profunda consideração e gratidão.

Agradeço também à minha orientadora, Profa. Dra. Rita de Cássia Fernandes de Lima, e ao meu coorientador, Prof. Dr. Marcus Costa de Araújo, pela condução dedicada, pelos ensinamentos, pela paciência e pelas valiosas contribuições ao longo de todo o desenvolvimento desta pesquisa. A orientação de vocês foi essencial para a construção e amadurecimento deste trabalho. Estendo meus agradecimentos às professoras Luciete Alves Bezerra e Maira Araújo de Santana, integrantes da banca examinadora, cujas observações, sugestões e apontamentos foram de grande relevância para o aprimoramento e finalização desta dissertação. Suas contribuições foram fundamentais para o fortalecimento científico deste estudo.

À Universidade Federal de Pernambuco, expresso meu reconhecimento por proporcionar o ambiente necessário ao aprendizado, à pesquisa e ao desenvolvimento deste trabalho. Por fim, agradeço a todos que, de alguma forma, contribuíram para a concretização desta dissertação. Que este estudo possa colaborar, ainda que modestamente, para o avanço do conhecimento na área.

RESUMO

A termografia por infravermelho (Infrared Thermography - IRT) é um método amplamente utilizado em estudos biomédicos por sua capacidade de detectar variações térmicas na superfície da pele, indicando possíveis condições patológicas e mudanças na composição corporal. No contexto da obesidade, existem estudos que afirmam a viabilidade desta prática em capturar padrões térmicos relacionados à distribuição da gordura subcutânea onde é apontado que pacientes com maior adiposidade apresentaram temperaturas mais baixas, enquanto aquelas com menor gordura exibiram temperaturas mais altas, particularmente na região do tronco e do abdômen. A partir desse enfoque, o presente trabalho tem como foco a identificação de regiões de gordura em mamas por meio de imagens termográficas, com o intuito de verificar a viabilidade desta ferramenta no prognóstico e avaliação de obesidade. Assim, o estudo envolveu a seleção de registros do Banco de Imagens Termográficas de Mama da UFPE, obtidas de pacientes em ambiente monitorado, para garantir a consistência dos dados, posteriormente analisadas por meio de softwares para modelagem térmica e tridimensional das regiões de interesse. Esta pesquisa enfatiza a comparação entre os resultados obtidos e outros métodos de análise do percentual de massa adiposa corporal para verificar o potencial da IRT como uma alternativa eficaz para acompanhar o diagnóstico e a progressão da obesidade, auxiliando na formulação do tratamento. Dessa forma, este trabalho, impulsionado pelo Programa de Ações Estratégicas Transversais da Pós-Graduação (PAET-PG), contribuiu para a expansão do uso da termografia infravermelha (IRT) no campo da biomecânica, reforçando a relevância desse método como ferramenta complementar na avaliação da saúde metabólica. Os resultados obtidos evidenciaram a capacidade das ferramentas computacionais empregadas em identificar padrões térmicos associados à presença de tecido adiposo, com consistência entre as regiões segmentadas e os métodos estatísticos aplicados. A proposta demonstrou que a utilização de técnicas de segmentação e análise térmica de imagens termográficas permite a identificação de possíveis regiões de gordura no corpo humano, viabilizando o monitoramento contínuo de pacientes e contribuindo para o aprimoramento de estratégias clínicas e terapêuticas voltadas ao envelhecimento saudável e ao controle da obesidade.

Palavras-chave: Termografia por infravermelho, obesidade, aprendizado de máquina, adiposidade mamária, avaliação de gordura mamária.

ABSTRACT

Infrared Thermography (IRT) is a method widely used in biomedical studies due to its ability to detect thermal variations on the skin surface, indicating possible pathological conditions and changes in body composition. In the context of obesity, several studies support the feasibility of this approach in capturing thermal patterns related to the distribution of subcutaneous fat, reporting that patients with higher adiposity present lower temperatures, whereas those with lower fat levels exhibit higher temperatures, particularly in the trunk and abdominal regions. From this perspective, the present work focuses on the identification of adipose tissue regions in the breast through thermographic images, aiming to verify the feasibility of this tool in the assessment and monitoring of obesity. The study will initially involve the selection of thermographic images from the Breast Thermographic Image Database of Federal University of Pernambuco (UFPE), obtained from patients in a monitored environment to ensure data consistency. These images will subsequently be analyzed using software for thermal and three-dimensional modeling of the regions of interest. This research emphasizes the comparison between the obtained results and other methods for analyzing body fat percentage in order to verify the potential of IRT as an effective alternative for monitoring the progression of obesity, thereby assisting in treatment planning. Therefore, this work, supported by the Strategic Transversal Actions Program for Graduate Studies (PAET-PG), contributed to expanding the use of infrared thermography in the field of biomechanics, reinforcing its relevance as a complementary tool in metabolic health assessment. The obtained results demonstrated the ability of the computational tools employed to identify thermal patterns associated with adipose tissue, showing consistency between the segmented regions and the applied statistical methods. The proposed approach demonstrated that the use of segmentation and thermal analysis techniques of thermographic images enables the identification of potential fat regions in the human body, allowing continuous monitoring of patients and contributing to the improvement of clinical and therapeutic strategies aimed at healthy aging and obesity control.

Keywords: Infrared thermography, obesity, machine learning, breast adiposity, breast fat assessment.

LISTA DE ILUSTRAÇÕES

Figura 1. Percentual de mulheres com alta e baixa densidade de tecido mamário conforme faixa etária	21
Figura 2. Comparação entre as imagens térmicas em Celsius para a mão e abdômen de pacientes magras (a, c) e com sobrepeso (b, d).	25
Figura 3. Exemplos de segmentações automáticas de mamas de diferentes voluntárias.	27
Figura 4. Simulação 2D da mama (esquerda) e comparação entre os perfis de temperatura (direita).	28
Figura 5. Principais eixos do tecido adiposo que impactam na saúde metabólica: localização (A), mecanismo de expansão (B) e fenótipo metabólico (C).	34
Figura 6. Localização e distribuição dos tipos de gordura na região do abdômen (A) e posicionamento de fita métrica para medição da gordura visceral (B).	36
Figura 7. Estrutura anatômica da mama.	37
Figura 8. Comparação entre uma mama jovem e uma mama envelhecida.	38
Figura 9. Posicionamento usual dos eletrodos para a análise corporal por bioimpedância. ...	43
Figura 10. Comparação entre um homem com menor quantidade de massa adiposa (A) e uma mulher com maior quantidade de massa adiposa (B) registrados através de DXA.....	45
Figura 11. Exemplo de digitalização de camadas para diferentes regiões de uma mama por meio de tomografia computadorizada (A) e suas respectivas segmentações (B).	46
Figura 12. Esquematização do método de medição utilizando uma câmera termográfica [4]. Para o registro são consideradas as temperaturas do objeto observado [2], da atmosfera [3] e a parcela refletida pelo ao meio adjacente [1].	50
Figura 13. Diferentes termogramas para a região das mãos de paciente após processo de resfriamento. Da esquerda para a direita, tem-se os registros: imediatamente após o resfriamento; 3,5 min após o resfriamento; e 30 min após o resfriamento.	51
Figura 14. Fluxograma com a visão geral idealizada para a metodologia deste trabalho.	57
Figura 15. Imagem IRT para as Voluntária 2 (à esquerda) e Voluntária 3 (à direita).....	59
Figura 16. Exemplo de imagem carregada no código desenvolvido apresentando informações de posição e valor da temperatura para um dado ponto (pixel).	61
Figura 17. Região extraída para valores superiores ao limiar (esquerda) e imagem original (direita).	61
Figura 18. Seleção da ROI na máscara da elipse (esquerda) e segmentação obtida para a ROI (direita).	62
Figura 19. Segmentações obtidas para diferentes limiares aplicados na mama direita da Voluntária 3.	69
Figura 20. Relações gráficas da divisão dos clusters pelo método automático (à esquerda) e dispersão dos dados no QQ-Plot com linha de referência (à direita) para a mama direita da Voluntária 3.	71
Figura 21. Comparações gráficas entre a distribuição das temperaturas (à direita) e dos percentuais (à esquerda) obtidas para as participantes analisadas utilizando os limiares empregados.	73
Figura 22. Distribuições percentuais obtidas pelos limiares de percentis para as ROIs estudadas.	74

LISTA DE TABELAS

Tabela 1. Percentual de brasileiros adultos com sobrepeso entre os anos de 2003 a 2022.	19
Tabela 2. Faixas de percentuais do tecido glandular mamário com relação à diferentes faixas etárias.....	39
Tabela 3. Classificação do IMC pela Organização Mundial da Saúde (OMS).	40
Tabela 4. Relação entre idade e percentual médio de tecido mamário não glandular (%) em mulheres.	62
Tabela 5. Relação dos resultados de correlação entre ROIs para as pessoas estudadas.	67
Tabela 6. Relação dos limiares de temperatura e respectivos percentuais para a Voluntária 3.	71
Tabela 7. Relação dos resultados obtidos por GMM para as ROIs da Voluntária 3.	72

LISTA DE ABREVIATURAS E SIGLAS

2D	Bidimensional(is)
ABD	Abdômen
AD	Teste de normalidade de Anderson-Darling
ANOVA	Analysis of Variance (análise de variância)
AVGA	Áreas Visíveis de Gordura Acumulada
ASR	Age-Standardized Rate
BAT	Brown Adipose Tissue (tecido adiposo marrom)
BHTE	Bioheat Transfer Equation (equação de biotransferência de calor)
BIA	Bioelectric Impedance Analyzer (análise de bioimpedância elétrica)
baPWV	Brachial-ankle Pulse Wave Velocity
CFD	Computational Fluid Dynamics (dinâmica dos fluidos computacional)
CNN	Convolutional Neural Network (rede neural convolucional)
DXA	Dual-energy X-ray Absorptiometry (Absorciometria por Raios-X de Dupla Energia)
DWNN	Deep-Wavelet Neural Network
EM	Expectation-Maximization
FPA	Focal Plane Array (matriz de plano focal)
GMM	Gaussian Mixture Model (modelo de mistura de gaussianas)
HC - UFPE	Hospital das Clínicas da Universidade Federal de Pernambuco
IDE	Integrated Development Environment
IL-6	Interleucina-6
IFC	Índice de Forma Corporal (Body Shape Index – ABSI)
IMC	Índice de Massa Corporal
IRT	Infrared Thermograph (Termografia por Infravermelho - TIV)
KDE	Kernel Density Estimation (Estimativa de Densidade Kernel)
KS	Teste de normalidade de Kolmogorov-Smirnov
LF	Teste de Lilliefors
MD	Mama Direita
ME	Mama Esquerda
MMs	Mamas
MVF	Método dos Volumes Finitos

NC	Neck Circumference (Circunferência do Pescoço)
PSF	Python Software Foundation
RM	Ressonância Magnética (Magnetic Resonance Imaging – MRI)
ROI	Region of Interest (região de interesse)
SW	Teste de normalidade de Shapiro-Wilk
TAS	Tecido Adiposo Subcutâneo
TAT	Tecido Adiposo associado a Tumores
TAV	Tecido Adiposo Visceral
TC	Tomografia Computadorizada
TDLUs	Terminal Duct Lobular Units
TNF- α	Tumor Necrosis Factor-alpha (fator de necrose tumoral alfa)
UCP1	Uncoupling Protein 1 (proteína desacoplada 1)
WAT	White Adipose Tissue (tecido adiposo branco)
WC	Waist Circumference (Circunferência da Cintura – CC)
WHO	World Health Organization (Organização Mundial da Saúde – OMS)
WHR	Waist-to-Hip Ratio (Relação Cintura-Quadril - RQC)
WHtH	Waist-to-Height Ratio (Relação Cintura-Altura – RCA)

LISTA DE SÍMBOLOS

Z	Impedância complexa
R	Perda de energia associada a água e eletrólitos no corpo
X_c	Reactância capacitiva
L	Comprimento da secção transversal (m)
A	Área da secção transversal (m ²)
V	Volumen (m ³)
FFM	Fat-Free Mass
FM	Fat Mass
TBW	Total Body Water
W_{tBody}	Body Weight
Fat%	Percentual de gordura corporal
I_0	Intensidade inicial do feixe incidente (Wm ⁻²)
I	Intensidade transmitida (Wm ⁻²)
μ	Coefficiente linear de atenuação do material (cm ⁻¹)
t	Espessura do material (cm)
∇	Operador nabla
ρ_t	Densidade do tecido (kgm ⁻³)
c_t	Calor específico do tecido (Jkg ⁻¹ K ⁻¹)
k_t	Condutividade térmica do tecido (Wm ⁻¹ K ⁻¹)
T	Temperatura do tecido (K)
t	Tempo (s)
ωt	Taxa perfusão sanguínea (ml/s/ml)
ρ_b	Densidade do sangue (kgm ⁻³)
c_b	Calor específico do sangue (Jkg ⁻¹ K ⁻¹)
T_a	Temperatura do sangue arterial entrando no tecido (K)
Q_m (Wm ⁻³)	Taxa volumétrica de geração de calor da produção de calor metabólico
Ω	Domínio espacial do problema
T	Intervalo de tempo de integração
W_{tot}	Radiação que um corpo negro emitiria à temperatura do objeto (Wm ⁻²)
T_{ref}	Temperatura refletida (K)

T_{atm}	Temperatura da atmosfera (K)
ε	Emissividade do objeto
τ	Transmitância da atmosfera na trajetória objeto
W_{ref}	Radiação do meio adjacente que é refletida pela superfície ($\text{Wm}^{-1}\text{K}^{-1}$)
W_{atm}	Radiação emitida pela atmosfera ($\text{Wm}^{-1}\text{K}^{-1}$)
$\bar{y}$	Média amostral
$F(x)$	Função de distribuição empírica dos dados amostrais
$F_0(x)$	Função de distribuição acumulada teórica da normal
$F^*(x)$	Função de Distribuição Hipotética
$F_n(x)$	Função de Distribuição Empírica
$\sup_x$	“Supremo” (maior diferença absoluta observada).

SUMÁRIO

1. INTRODUÇÃO	16
1.3. OBJETIVOS	18
1.3.1. Objetivo Geral	18
1.3.2. Objetivos Específicos	18
2. REVISÃO BIBLIOGRÁFICA	19
3. FUNDAMENTAÇÃO TEÓRICA	31
3.1. DISTRIBUIÇÃO DA GORDURA CORPORAL	31
3.2. ANATOMIA MAMÁRIA	36
3.3. MÉTODOS DE MEDIÇÃO DA ADIPOSIDADE CORPORAL	40
3.3.1. Índice de Massa Corporal (IMC) e medidas antropométricas	40
3.3.2. Análise cutânea por dobras subcutâneas	41
3.3.3. Análise por Bioimpedância (Bioelectric Impedance Analyzer - BIA)	42
3.3.4. Absorciometria Bifotônica de Raios-X (DXA)	45
3.3.5. Tomografia Computadorizada (TC)	46
3.3.6. Ressonância Magnética (RM)	48
3.3.7. Termografia por Infravermelho (Infrared Thermography - IRT)	49
3.4. MODELOS MATEMÁTICOS ESTATÍSTICOS PARA ANÁLISE TERMOGRÁFICA	52
3.4.1. Testes de Normalidade	52
3.4.1.1. Teste de Shapiro-Wilk (SW)	52
3.4.1.2. Teste de Anderson-Darling (AD)	53
3.4.1.3. Teste de Kolmogorov-Smirnov (KS)	54
3.4.2. Testes de Correlação Estatística	55
3.4.3. Métodos para Visualização da Distribuição de Dados	56
4. METODOLOGIA	57
4.1. ESTIMATIVA DA ADIPOSIDADE POR LIMIAR DE TEMPERATURA	60
4.2. ANÁLISE ESTATÍSTICA	63
5. RESULTADOS E DISCUSSÃO	65
5.1. RESULTADOS OBTIDOS PELOS TESTES ESTATÍSTICOS	65
5.2. RESULTADOS OBTIDOS POR LIMIARES E SEGMENTAÇÃO	68
5.3. DISCUSSÃO DOS RESULTADOS OBTIDOS	75
5.4. SUGESTÕES PARA TRABALHOS FUTUROS	76
REFERÊNCIAS	77
APÊNDICE A – CÓDIGO PARA EXTRAÇÃO DAS ROIS E SEGMENTAÇÃO	90
APÊNDICE B – CÓDIGO PARA TESTES DE NORMALIDADE	102
APÊNDICE C – CÓDIGO PARA TESTE DE CORRELAÇÃO MANN-WHITNEY	106
APÊNDICE D – CÓDIGO PARA TESTE DE CORRELAÇÃO SPEARMAN	108
APÊNDICE E – CÓDIGO PARA GRÁFICOS DE PORCENTAGENS DOS LIMIAR	110
APÊNDICE F – IMAGENS TERMOGRÁFICAS DAS PARTICIPANTES	117

APÊNDICE G – RELAÇÃO DOS DADOS COLETADOS POR LIMIAR	122
APÊNDICE H – DISTRIBUIÇÕES PERCENTUAIS POR LIMITARES	134

1. INTRODUÇÃO

A integração de uma série de características presentes na sociedade proporcionadas pela globalização (como fatores tecnológicos, culturais e econômicos, por exemplo) impactam diretamente em um aumento da expectativa de vida global. Porém, ao contrário do que se é possível imaginar, esse fenômeno não apenas acarretou consequências positivas na população, mas também trouxe à tona novos desafios relacionados a aspectos como a própria saúde dos indivíduos (Silva, 2021). O novo estilo de vida estabelecido nesse processo é fortemente moldado pela expansão da uniformidade cultural, sustentada por preceitos dentre os quais se pode destacar a automatização acelerada, o consumismo através do *marketing* agressivo e a influência da mídia para urbanização.

Essas novas condições sociais resultaram em um cotidiano predominantemente monótono, onde muitas vezes as características psicológica e comportamental do cidadão são atenuadas por reações em resposta a tal tipo de rotina como o estresse, o sedentarismo e a ansiedade devido à digitalização e à jornada de trabalho repetitiva presentes (Bezerra, 2007). Um dos grandes problemas causados por essa mudança no estilo de vida e hábitos alimentares é a obesidade, que emerge mundialmente como um grande desafio de saúde pública, com impacto significativo na qualidade de vida e na morbidade associada a condições crônicas, como doenças cardiovasculares, diabetes e câncer (Kothari, 2020).

A Organização Mundial de Saúde (OMS), do inglês *World Health Organization*, afirma que entre os anos de 1990 e 2022 a ocorrência de obesidade em adultos mais que dobrou enquanto em adolescentes esse fator quadruplicou. Além disso, ela ressalta também que a condição dessa doença crônica de depósitos excessivos de gordura atinge proporções epidêmicas em escala global representando um desafio evidente para a saúde pública, não apenas impactando negativamente na qualidade de vida e na morbidade como também aumentando a frequência de diabetes e riscos de câncer (WHO, 2024).

Embora a obesidade seja comum entre jovens e adultos, há um pico principalmente na meia-idade seguido de um declínio em idades avançadas, pois obesos têm maior risco de desenvolver doenças crônicas que podem reduzir sua expectativa de vida (Rodrigues, 2021). A composição corporal do ser humano varia conforme seu envelhecimento, havendo uma redistribuição da gordura corporal para regiões centrais, como o abdômen e o tronco, muitas vezes associadas a riscos crescentes de doenças metabólicas e oncológicas (Snehalatha Thanaraj e Sangamithirai, 2020). Em mulheres, especialmente, durante esse processo há um aumento na proporção de tecido adiposo nas mamas devido à involução glandular, o que pode

influenciar na progressão de condições como o câncer de mama (Viera, 2016).

Além dos métodos tradicionais para medição da gordura corporal como a análise por bioimpedância, a implementação da termografia tem apresentado uma ascensão significativa na área da biomecânica devido à sua segurança, precisão e capacidade de fornecer dados em tempo real (Snehalatha, Thanaraj e Sangamithirai, 2020). Na oncologia (especialidade médica que estuda e trata o câncer) por exemplo, a termografia pode ser utilizada para identificar padrões térmicos que podem indicar alterações no metabolismo tecidual, como crescimento tumoral ou processos inflamatórios associados ao próprio microambiente tumoral (Amalric et al., 1984).

Além disso, conforme mencionado por Kothari et al. (2020), a termografia por infravermelho (do inglês, *Infrared Thermograph* - IRT) permite mapear a atividade metabólica de tecidos adiposos específicos, como o tecido adiposo branco e marrom (WAT, *white adipose tissue*, e BAT, *brown adipose tissue*, respectivamente), que apresentam características térmicas distintas e relevantes para o estudo da obesidade. Enquanto o WAT é o principal tecido adiposo do corpo humano, composto por adipócitos uniloculares e tendo como função o armazenamento de energia, o BAT, formado por adipócitos multiloculares, dispõe especialmente da função de produção de calor (termogênese) em resposta ao frio, por exemplo (Jalil, 2019).

Este estudo se dedica ao desenvolvimento de um algoritmo em linguagem de programação Python para a análise da temperatura em mamas de mulheres de diferentes faixas etárias. O intuito é, a partir da segmentação de regiões de interesse em imagens termográficas, encontrar faixas de temperatura específicas para visualizar possíveis áreas de gordura. Com as informações obtidas haveria então a possibilidade de analisar a eficácia da termografia como ferramenta para estimar o percentual de gordura corporal por meio da razão encontrada nesse procedimento.

Dessa forma, este trabalho se propõe a contribuir para o avanço da tecnologia aplicada à saúde, utilizando a termografia como uma ferramenta para a análise de massa adiposa no corpo humano através da utilização de técnicas computacionais por meio de um *software* gratuito. A relevância do estudo está na possibilidade de integrar abordagens computacionais e biomecânicas, acrescentando a essa temática um possível potencial no auxiliar tanto em diagnósticos clínicos quanto em pesquisas científicas no que diz respeito à obesidade, proporcionando uma ferramenta para a análise detalhada e personalizada da distribuição de gordura em diferentes pacientes.

1.3. OBJETIVOS

1.3.1. Objetivo Geral

Investigar a aplicação da termografia infravermelha como ferramenta de diagnóstico e monitoramento da obesidade através de limiares de temperatura.

1.3.2. Objetivos Específicos

- Analisar as correlações entre as variações de temperatura e o possível identificação de massa adiposa das mamas utilizando imagens termográficas.
- Desenvolver um algoritmo capaz de segmentar as regiões de gordura em mamas e estimar o percentual de gordura corporal a partir de imagens termográficas.
- Determinar se há uma correlação entre os dados das regiões das mamas e abdômen das pacientes por meio da implementação de métodos estatísticos.
- Testar as métricas a serem usadas para o estabelecimento dos limiares de temperaturas.
- Analisar a eficácia da termografia como ferramenta de monitoramento para avaliação contínua do sobrepeso em mulheres.

2. REVISÃO BIBLIOGRÁFICA

Multifatorial em sua origem, a obesidade envolve fatores biológicos, sociais, culturais e ambientais, exigindo abordagens que considerem sua complexidade e os sistemas estruturais que influenciam a saúde (Ministério da Saúde, 2024). Essa complexidade pode ser refletida no aumento progressivo do sobrepeso entre adultos no Brasil como apresentado na Tabela 1 a seguir, cuja prevalência passou de 42,9% em 2003 para 64,2% em 2022, evidenciando o agravamento do problema ao longo das últimas décadas (WHO, 2024).


Tabela 1. Percentual de brasileiros adultos com sobrepeso entre os anos de 2003 a 2022.

Período	2022	2021	2020	2019	2018
Percentual (%)	64,2	63,0	61,9	60,7	59,5
Variação	(61,7 – 66,6)	(60,8 – 65,2)	(60,0 – 63,7)	(59,1 – 62,3)	(58,1 – 61,0)
Período	2017	2016	2015	2014	2013
Percentual (%)	58,3	57,1	55,9	54,7	53,5
Variação	(57,1 – 59,6)	(56,0 – 58,3)	(54,9 – 57,0)	(53,7 – 55,8)	(52,5 – 54,5)
Período	2012	2011	2010	2009	2008
Percentual (%)	52,3	51,1	49,9	48,8	47,7
Variação	(51,3 – 53,3)	(50,1 – 52,1)	(49,0 – 50,9)	(47,8 – 49,8)	(46,7 – 48,7)
Período	2007	2006	2005	2004	2003
Percentual (%)	46,6	45,6	44,7	43,7	42,9
Variação	(45,6 – 47,7)	(44,6 – 46,7)	(43,6 – 45,7)	(42,7 – 44,8)	(41,8 – 44,0)

Fonte: Adaptado de *World Health Organization* – WHO (2024)

A partir do que foi apresentado na Tabela 1 é possível observar que a população brasileira que possui sobrepeso teve um aumento constante nos últimos anos, totalizando um acréscimo por volta de 50% nas duas primeiras décadas do Século 21. O Gráfico 1 a seguir complementa a informação anterior ao evidenciar a relação entre a idade da população e a taxa de mortalidade por obesidade no Brasil, no período de 2010 a 2021 (Ministério da Saúde, 2024). Observa-se uma forte associação entre o avanço da idade e o aumento da taxa de mortalidade por obesidade, gradiente etário bem definido. As taxas permanecem baixas nas faixas mais jovens e aumentam progressivamente a partir da meia-idade, tornando-se mais elevadas entre indivíduos com 60 anos ou mais. Esse padrão sugere que os efeitos cumulativos da obesidade ao longo da vida, associados ao maior risco de comorbidades crônicas, contribuem para o aumento da mortalidade em idades mais avançadas.

Gráfico 1. Taxa de mortalidade por obesidade segundo a faixa etária entre os anos de 2010 a 2021.




Fonte: Ministério da Saúde (2024)

Nesse sentido, o avanço da idade e o aumento da adiposidade corporal também exercem impacto direto sobre tecidos específicos do organismo, como a mama. No contexto da saúde mamária, há uma alteração importante na estrutura da mama ao longo da vida de uma mulher. Enquanto jovem, possui-se inicialmente um aspecto mais denso devido a maior presença de tecidos glandulares e pouca ou quase nenhuma presença de tecido adiposo no interior da glândula, onde se encontra o lobo mamário (Viana, 2016). Após o desenvolvimento completo (atingido durante a gravidez), há a perda da elasticidade dos tecidos que levam a um aumento gradual e progressivo do tecido adiposo intraglandular, um processo conhecido como lipossustituição, onde o corpo naturalmente substitui o tecido glandular responsável pela produção e armazenamento do leite por tecidos adiposos (Kothari et al, 2020).

A variação do tecido mamário de baixa densidade (maior presença de gordura) em função da faixa etária é observada na Figura 1, onde Viana (2016) apresenta o percentual de mulheres para cada densidade e descreve que tais alterações se acentuam na menopausa, quando os lóbulos e os ductos lactíferos são atrofiados, sendo substituídos pelo tecido adiposo (lipossustituição). Em faixas etárias mais jovens, predomina a alta densidade mamária, enquanto o avanço da idade promove um aumento progressivo da baixa densidade, tornando-se dominante a partir da meia-idade e praticamente exclusiva nas faixas etárias mais avançadas. Isso evidencia a influência direta do envelhecimento na composição estrutural da mama, apontando o aumento significativo do tecido adiposo intraglandular com a idade.

Figura 1. Percentual de mulheres com alta e baixa densidade de tecido mamário conforme faixa etária.



Fonte: Viana (2016)

Na literatura, os padrões da distribuição de gordura são muitas vezes observados por meio de análises computacionais a partir de diversas fontes para registro da região desejada, sejam essas por raios-X, tomografia computadorizada convencional ou ressonância magnética (Mangine et al., 2022; Nelson et al., 2008). Contudo, esses métodos ainda apresentam carência de detalhes finos na resolução espacial para identificar tecidos ou sua disponibilidade e custo limitam a aplicação generalizada (Nelson et al., 2008). Porém, quando coletados dados físicos suficientes, a determinação da percentagem de gordura corporal e da distribuição regional podem ser obtidas utilizando modelos de testes estatísticos e métodos quantitativos, fornecendo informações adicionais sobre as características metabólicas do indivíduo e uma possível correlação entre elas e o estilo de vida presente (Hogling et al., 2020).

Já a termografia por infravermelho, mesmo sendo inferior quanto ao processo de reconstrução tridimensional quando comparada às práticas anteriormente citadas, pode ser de grande influência na precisão do diagnóstico de doenças como o câncer (Queiroz, 2022). Assim, conforme Reis et al. (2023), a termografia pode auxiliar como ferramenta na identificação, não apenas de possíveis agentes tumorais presentes como também nas regiões de depósitos de gordura e na análise de sua distribuição, como no caso de mulheres de idade avançada, pois há um maior contraste de temperaturas quando comparado às pacientes mais novas o que deve proporcionar resultados mais precisos.

Este capítulo reúne e analisa resultados de estudos predecessores semelhantes, os principais conceitos relacionados ao sobrepeso e à obesidade, bem como sua evolução epidemiológica e impactos na saúde.

Corpos cuja temperatura se apresenta superior ao zero absoluto emitem radiação térmica, predominantemente no infravermelho, mas, em altas temperaturas, podem emitir no espectro visível, como metais incandescentes. A emissão de energia térmica segue a equação de Stefan-Boltzmann, considerando fatores como emissividade, área superficial e temperatura do objeto. Objetos também absorvem radiação do ambiente, resultando em uma taxa líquida de troca térmica (HALLIDAY; RESNICK; WALKER, 2016). A pele humana emite radiação infravermelha com comprimentos de onda entre 2-20 μm , e câmeras termográficas, sensíveis a esse espectro, convertem a radiação em valores de temperatura, criando imagens digitais que mapeiam a distribuição térmica, apresentadas em tons de cinza ou falsas cores, também chamadas de pseudocores (BORCHARTT et al., 2013).

Inspirado por essa ideia, Reis et al. (2022) investigam os efeitos térmicos da gordura corporal em adolescentes ao observar a relação entre Índice de Massa Corporal (IMC) e temperatura da pele em adolescentes. O estudo revelou que indivíduos com maior IMC apresentam temperaturas cutâneas mais baixas, especialmente na região abdominal. Já em outro trabalho, Reis et al. (2023) examinou como o tecido adiposo influencia as temperaturas superficiais em adolescentes masculinos. Com base na análise de mais de 200 estudantes, o estudo conclui que há uma correlação negativa entre o percentual de gordura corporal e a temperatura da pele em diversas regiões do corpo, reforçando a relação entre gordura corporal e termorregulação.

Ainda nesse segmento, Snekhalatha, Thanaraj e Sangamithirai (2020) propuseram um sistema de diagnóstico assistido por computador para detectar obesidade com base em imagens termográficas. O trabalho contou com 100 sujeitos (metade com peso ideal e outra metade apresentando obesidade) entre os 45 anos, além de imagens das regiões de seus abdômens, antebraços e pernas capturadas em um ambiente controlado, com temperatura a cerca de 20°C e umidade média de 47,5%. Ao utilizar redes neurais convolucionais (*Convolutional Neural Networks* - CNNs) e dados como IMC, foi possível treinar e validar um sistema de detecção de obesidade baseado em *deep learning*, observando que a CNN personalizada e um método clássico de CNN comparado tiveram precisão de 92%. Por outro lado, o modelo de pré-treino alcançou 79%, concluindo-se que a região do abdômen exibia a maior diferença de temperatura elevada de 4,7% entre pessoas normais e obesas quando em comparação com outras regiões analisadas.

Os estudos de Tay et al. (2020) e Laffaye et al. (2019), abordam a eficácia da termografia por infravermelho na quantificação da atividade do tecido adiposo corporal. Tay et al. (2020) extraíram informações de termografia infravermelha (IRT) das regiões do pescoço e deltoide de


17 homens por volta dos 25 anos de idade para capturar a produção de calor no tecido adiposo marrom (tipo de gordura presente no corpo capaz de ajudar na regulação da temperatura corporal e a queimar calorias) com medição do gasto energético por meio da calorimetria do corpo inteiro, tanto em condições termoneutras quanto de exposição ao frio ao longo do tempo segmentadas por um algoritmo baseado na linguagem de programação MATLAB, demonstrando como a exposição ao frio pode aumentar a termogênese. Já Laffaye et al. (2019) analisaram 79 mulheres entre 16 e 29 anos em medições termográficas da pele e composição estimada por analisador de bioimpedância, criando dois modelos de regressão multivariados para prever a massa de gordura corporal dessas pessoas de forma não invasiva: um com e outro sem características antropométricas (idade, massa corporal, altura). O modelo completo (com características antropométricas) apresentou uma precisão de 73,9% da massa de gordura no tronco e 70,4% da gordura corporal total enquanto o modelo reduzido (sem características antropométricas) obteve uma precisão de 52,5% para a massa de gordura no tronco e 51,5% da gordura corporal total.

Há também a possibilidade da análise corporal por uma perspectiva térmica de condicionamento físico, conforme apontado nos trabalhos desenvolvidos por Mendes et al. (2022) e Korman et al. (2024). No artigo escrito por Mendes (2022) foi observada a relação entre temperatura cutânea e composição corporal em militares fisicamente ativos por meio de uma câmera infravermelha FLIR®, onde os voluntários do Curso de Bacharelado em Educação Física foram submetidos a avaliações de composição corporal seguidas da medição da temperatura da pele após um a dois dias, obtendo-se uma relação diretamente proporcional entre massa magra e a temperatura mais elevadas da pele, enquanto o maior acúmulo de gordura corporal esteve diretamente proporcional aos níveis mais baixos de temperatura superficial.

Korman et al. (2024) avaliaram as correlações entre temperatura da pele e composição corporal em atletas durante exercícios extenuantes. Foi observado que o tecido adiposo possui propriedades isolantes que reduzem a transferência de calor para a superfície da pele e, durante os exercícios testes, o fluxo sanguíneo na pele diminui devido à constrição dos vasos, o que pode afetar a temperatura da pele. Além disso, os grupos com maior gordura localizada nos membros estudados apresentaram diferenças mais pronunciadas de temperatura superficial durante e após o exercício, sugerindo que a gordura local tem um impacto direto no resfriamento inicial e na velocidade de reaquecimento. Assim, ambos trabalhos destacam a relação inversamente proporcional entre maior temperatura da pele e maior percentual de gordura, concluindo que as menores concentrações de gordura facilitaram a troca de calor com o meio, tornando a temperatura da pele mais elevada nessas regiões.

Ainda nesse sentido, Chudecka e Lubkowska (2015) procuraram comparar perfis térmicos entre indivíduos de ambos os sexos, todos estudantes (por volta dos 20 anos de idade) e atletas competitivos com IMC dentro da faixa normal. O objetivo dos autores era utilizar a termografia para criar um mapa térmico padrão de jovens saudáveis e fisicamente ativos, determinando as distribuições e faixas de temperatura corporal ao considerar fatores com o IMC, área de superfície corporal e a distribuição de gordura em diferentes regiões do corpo. As relações da parte do corpo e sua respectiva temperatura foram ordenadas no Gráfico 2.

Gráfico 2. Relação da temperatura (em Celsius) para diferentes partes do corpo por sexo.




Fonte: Adaptado de Chudecka e Lubkowska (2015)

A partir dos resultados, elas constataram que as temperaturas corporais médias mais altas foram observadas na região do tronco, enquanto as mais baixas foram registradas nas extremidades, especialmente nas pernas. Além disso, houve diferenças significativas entre os gêneros, com mulheres apresentando médias mais altas no tórax e temperaturas menores em outras áreas, em comparação aos homens.

Outros trabalhos ainda buscaram se aprofundar no entendimento da relação entre a distribuição de massa adiposa no corpo humano e sua respectiva temperatura superficial, como foi o caso de Salamunes, Stadnik e Neves (2017). Eles avaliaram mulheres adultas com peso normal ou sobrepeso através da Termografia por Infravermelho (TIV) e um método de medição da composição corporal por Absorciometria (ou densitometria óssea) por Raios-X de Dupla Energia (*Dual-energy X-ray Absorptiometry* - DXA), para medir temperatura da pele, gordura

corporal e massa magra, constatando que gordura localizada pode diminuir a temperatura local externa. Adicionalmente, Jalil et al. (2019) em seu estudo reforça tal ideia ao realizar um processo semelhante para avaliar variações de temperatura num mesmo grupo de pessoas durante um teste oral de tolerância à glicose. Os resultados mostraram diferenças significativas na termogênese entre os grupos, com temperaturas médias mais altas em mulheres magras (Figura 2).

Figura 2. Comparação entre as imagens termográficas em Celsius para a mão e abdômen de pacientes magras (a, c) e com sobrepeso (b, d).



Fonte: Jalil et al (2019)


Enquanto Jalil trata resposta fisiológica, Salamunes, Stadnik e Neves tratam da relação estática entre gordura e temperatura, se complementando ao sugerirem que o tecido adiposo não apenas atua como isolante térmico em repouso, mas também pode influenciar o metabolismo termogênico, especialmente em condições de sobrepeso. Esses resultados demonstram a relevância da termografia como ferramenta auxiliar na investigação de respostas metabólicas.

Lubkowska e Chudecka (2021) expandem as observações termográficas das regiões do corpo humano, desta vez explorando a relação entre a temperatura da superfície das mamas e o conteúdo de tecido adiposo em mulheres saudáveis. Elas mostraram que mulheres mais jovens apresentam temperaturas mamárias mais altas do que as mais velhas, destacando o impacto não

só do peso com também do envelhecimento na termorregulação mamária.

No que diz respeito ao quesito da saúde, há maior risco de mortalidade por causas em geral na população com IMC elevado. Porém, o maior risco não é apenas exclusivo de altos valores de IMC ($> 35 \text{ kg/m}^2$) como também é muito presente nas faixas mais baixas ($< 20 \text{ kg/m}^2$). Entre pacientes com câncer, essa relação é menos pronunciada do que em outros subgrupos, com um risco ligeiramente maior em indivíduos com alto IMC (Nowak et al., 2024). O Gráfico 3 dispõe taxas mundiais padronizadas por idade (*ASR, Age-Standardized Rate*) de incidência e mortalidade de câncer por 100 mil habitantes. Foram considerados fatores com a idade e sexo na incidência dos 15 tipos de câncer mais comuns na população global, para o ano de 2022 (GCO). Assim, é possível afirmar que os maiores percentuais de mortalidade nessa categoria são causados por ocorrências de câncer na região do tronco do corpo.

Gráfico 3. Taxa de incidência e mortalidade por câncer para cada 100 mil habitantes no mundo.




Fonte: Adaptado de Global Cancer Observatory – GCO

Kothari (2020) em seu artigo procura traçar uma relação do impacto do tecido adiposo na progressão do câncer de mama, destacando sua influência na modulação do microambiente tumoral. Sua pesquisa explora mecanismos bioquímicos e celulares, incluindo a produção de estrogênio e citocinas pelo tecido adiposo, e sugere estratégias para inibir interações entre adipócitos e células tumorais, contribuindo para avanços terapêuticos. Outros fatores como

variações hormonais podem afetar significativamente a termorregulação cutânea em diferentes fases hormonais da vida feminina, englobando também o ciclo menstrual, a menopausa e até mesmo o uso de hormônios exógenos, produzidos fora do corpo e usados em terapia hormonal (Silva, 2021).

Queiroz (2022) apresenta que o processo biológico pelo qual novos vasos sanguíneos se formam a partir daqueles já existentes (neoformação vascular ou angiogênese) permite células anormais que sofreram mutações genéticas (células neoplásicas) e adquiriram a capacidade de crescer possam se multiplicar de maneira descontrolada. Formam assim uma neoplasma, mais conhecido como tumor. Nesse cenário, células malignas induzem um acúmulo e a formação de novos vasos em sua vizinhança e, uma vez que há um maior fluxo sanguíneo na região, nota-se também uma concentração mais elevada de calor em tal local. Impulsionada por motivos como este, Queiroz propôs integrar uma ferramenta capaz de classificar patologias mamárias por meio matrizes de temperatura obtidas utilizando o *software* FLIR Tools a partir das imagens termográficas. Durante sua análise, as imagens passam por um processo de segmentação computacional automática, conforme visto na Figura 3, seguido de medidas de avaliação de acurácia para então efetuar uma classificação não-supervisionada.

Figura 3. Exemplos de segmentações automáticas de mamas de diferentes voluntárias.




Fonte: Queiroz (2022)

Bezerra (2007) em seu estudo também utiliza simulações computacionais para comparar os dados obtidos por termografia com os valores calculados pela Equação de Biotransferência de Calor (*Bioheat Transfer Equation* - BHTE), através de ferramentas como o FLUENT, que aplica o Método dos Volumes Finitos (MVF). Sua análise se baseia em simulações

bidimensionais e tridimensionais simplificadas das geometrias das mamas onde. Na Figura 4 se observa a distribuição de temperaturas em um corte transversal na modelagem 2D da mama esquerda de uma paciente com tumor maligno e o perfil de temperaturas medido pela câmera termográfica utilizada. A autora apontou que as temperaturas superiores apresentadas na simulação mostram o comportamento no interior da mama enquanto a câmera apenas capta a radiação infravermelha emitida pela superfície da pele.

Figura 4. Simulação 2D da mama (esquerda) e comparação entre os perfis de temperatura (direita).



Fonte: Bezerra (2007)

Barbosa (2022) analisou sistemas inteligentes baseados em redes neurais convolucionais (*Convolutional Neural Networks* - CNNs) no apoio ao diagnóstico de tumores cancerígenos. Assim, ele desenvolveu um sistema de rede *Deep-Wavelet Neural Network* (DWNN) aplicado ao problema de detecção e classificação de lesões de mama em imagens termográficas e comparou seus resultados com outras CNNs. Sua ferramenta atingiu 99% acurácia ao detectar e 97,3% em classificar as anomalias mamárias, conseguindo um valor médio em torno de 0,97 para o índice de desempenho (índice de kappa) da ferramenta aplicada.

A importância da termografia como ferramenta diagnóstica para avaliar o fluxo sanguíneo e identificar condições patológicas nas mamas é reforçada por Hobbins (1984). Com base em mais de 7.000 casos, Hobbins demonstrou que a termografia pode detectar padrões anormais associados ao câncer de mama antes mesmo dos tumores se tornarem palpáveis, provando sua eficácia como método pré-diagnóstico.

King, Cayce e Herrin (2017) investigaram a relação entre a temperatura abdominal e a epilepsia focal, recrutando 100 pacientes dos quais metade era saudável enquanto a outra

apresentava a doença mencionada. Foram realizados registros por termografia infravermelha para medir a temperatura abdominal a partir de uma câmera infravermelha Med-Hot Modelo MH-7315R FLIR em condições monitoradas. Os resultados comparativos mostraram que pacientes com epilepsia apresentaram temperaturas mais baixas no quadrante superior esquerdo do abdômen em comparação com os controles, mas não houve diferenças significativas na temperatura abdominal total entre os grupos, o que não confirma a hipótese para casos gerais.

O trabalho de Fletcher et al. (2017) destaca a importância do microambiente do tecido adiposo no desenvolvimento do câncer de mama, sendo enfatizada a interação entre adipócitos e células epiteliais no ambiente tumoral, explorando fatores secretados pelo tecido adiposo tumoral que promovem a proliferação e migração celular. Dessa forma os autores destacam que o tecido adiposo associado a tumores (TAT) não é apenas um depósito de gordura inerte, mas sim um componente dinâmico que interage diretamente com as células tumorais. Assim, sendo responsável por liberar fatores bioativos, como citocinas e adipocinas, que influenciam o microambiente tumoral, favorecendo a angiogênese, a invasão tumoral e a inflamação crônica. Esses processos criam condições ideais para a progressão do câncer, aumentando o risco de metástase, processo pelo qual células cancerígenas se espalham de seu local de origem para outras partes do corpo, piorando o prognóstico. Dessa forma, é evidente que a estrutura mamária é sensível à diversos fatores que podem influenciar em sua temperatura superficial.

Já Nelson et al. (2008) afirmam que, durante a puberdade feminina, a proliferação glandular nas mamas confere ramificações envolvidas por gordura e conforme o envelhecimento (sobretudo após a menopausa) ocorre a substituição progressiva do tecido glandular mamário por gordura, evidenciado por um aspecto mais flácido do tecido. Isso abre possibilidade para análises comparativas entre as mamas com outras regiões do corpo para verificar a relação da distribuição e concentração de gordura nesses locais. No que diz respeito à validação matemática, Hogling et al. (2020) verificaram mulheres pós cirurgia bariátrica e constataram que o percentual de gordura corporal é um determinante independente da saúde metabólica, com impacto maior do que o IMC. Na análise, foram utilizados como métodos estatísticos principais a análise descritiva para normalidade, testes *t-Student* e Mann-Whitney, correlações de Pearson e Spearman, e regressão linear múltipla. Em outra perspectiva, Mangine, McDougale e Feito (2022), analisaram como a composição corporal se relaciona com o desempenho em praticantes de um treino de alta intensidade aplicado em competições de *CrossFit*. O teste de Shapiro-Wilk apontou que a distribuição das variáveis observadas não seguia normalidade, portanto os autores recorreram a métodos alternativos (transformação logarítmica e análise de variância, ANOVA) para realizar observações comparativas entre os

grupos através de testes não paramétricos. Foi então possível demonstrar que existe uma correlação significativa entre composição corporal e performance no treino, sendo essa relação modulada pelo nível competitivo dos participantes (o melhor desempenho se relacionou ao menor percentual de gordura corporal).

Ainda nesse sentido, Shim et al. (2023) analisaram exames de 517 mulheres e segmentaram o volume total da mama, o volume glandular e a densidade percentual tanto na mama inteira quanto em cada quadrante. Por meio de testes estatísticos *t-Student* com ajuste de modelos de regressão foram comparadas médias entre grupos etários e pelo ajuste de modelos de regressão, os modelos obtidos estimaram variações dos parâmetros em função da idade, reforçando que a densidade mamária diminui com o envelhecimento. Entre outros achados foi destacado que o volume da região mamária apresentou leve aumento conforme o avanço da idade, enquanto o volume glandular e a densidade percentual reduziam significativamente.

Assim, a literatura demonstra que a termografia é uma ferramenta promissora, acessível e não invasiva para investigar a composição corporal e o tecido adiposo, além de auxiliar no rastreamento de doenças metabólicas e oncológicas. A gordura corporal exerce influência direta sobre a temperatura da pele, funcionando como marcador indireto de risco e a aplicação de testes estatísticos em conjunto com a análise das segmentações é fundamental para validar a relação entre os achados. Adicionalmente, embora o presente trabalho não utilize simulações numéricas, os estudos previamente apresentados evidenciam que alterações internas no organismo, como a presença de tumores ou estágios avançados de formações císticas (na região mamária por exemplo), podem influenciar diretamente na temperatura superficial da pele. Dessa forma, a composição da gordura corporal e/ou a presença de tumores podem atuar como elementos interferentes nos padrões térmicos observados, sendo relevantes para uma avaliação científica mais precisa e confiável.

3. FUNDAMENTAÇÃO TEÓRICA

Neste capítulo são apresentados os principais conceitos e fundamentos teóricos que sustentam o desenvolvimento desta dissertação, abrangendo desde aspectos biológicos e anatômicos relacionados à distribuição da gordura corporal até os métodos de quantificação e análise estatística empregados na interpretação de imagens termográficas. A fundamentação contempla uma revisão detalhada sobre a composição e distribuição da gordura no corpo humano, destacando as diferenças entre os compartimentos adiposos subcutâneo e visceral, bem como os fatores que influenciam sua variabilidade entre indivíduos. Em seguida, são abordados os aspectos anatômicos e fisiológicos da glândula mamária, com ênfase na estrutura e nas funções dos tecidos, além das características térmicas observáveis por meio da termografia infravermelha. Por fim, discute-se a importância dos métodos de medição da adiposidade corporal, tanto diretos quanto indiretos, e os princípios matemáticos e estatísticos aplicados à análise dos dados obtidos. Assim, para melhor organização, este capítulo foi estruturado em quatro seções principais: distribuição da gordura corporal, anatomia mamária, métodos de medição da adiposidade corporal e modelos matemáticos estatísticos para análise termográfica.

3.1. DISTRIBUIÇÃO DA GORDURA CORPORAL

A compreensão da distribuição da gordura corporal tem papel central na avaliação do risco metabólico e cardiovascular em adultos uma vez que diferentes padrões de acúmulo adiposo exercem efeitos distintos sobre a saúde (WHO, 2024). Wang et al. (2024) retomam conceitos anatômicos fundamentais ao destacar que a gordura corporal não é uniformemente distribuída, apresentando variações regionais que influenciam o metabolismo sistêmico. Além do trabalho mencionado, Oliveira et al. (2022) acrescentam que a gordura troncular (no abdome e tórax) está fortemente associada à inflamação crônica de baixo grau e à disfunção endotelial, enquanto a gordura periférica (em membros inferiores) pode ter efeito inverso, favorecendo o metabolismo lipídico e melhorando a sensibilidade à insulina. Oliveira et al. (2022) afirmam também que a maior proporção de gordura nos membros inferiores está associada à redução da pressão arterial sistólica, do colesterol total e do uso de medicamentos anti-hipertensivos.

Já Masoudi et al. (2020) procuraram investigar a distinção entre os principais compartimentos de gordura abdominal, o tecido adiposo visceral (TAV) e o tecido adiposo subcutâneo (TAS), ressaltando suas diferenças estruturais, funcionais e implicações clínicas. Os autores reafirmam que a distribuição da gordura corporal não é homogênea e o acúmulo de

tecido adiposo em tal região representa um importante marcador de risco metabólico. Tal ideia reforça a observação de Zwick et al. (2018), mencionando este componente corporal como multifuncional e heterogêneo, com propriedades específicas que variam de acordo com sua localização anatômica, composição celular e estímulos fisiológicos.

O tecido adiposo visceral (TAV) localiza-se profundamente na cavidade abdominal, envolvendo órgãos vitais como fígado, intestinos e pâncreas, sendo considerado o tipo de gordura mais perigoso por possuir alta atividade metabólica além de secretar citocinas inflamatórias e hormônios que favorecem resistência à insulina, inflamação sistêmica e risco cardiovascular (Masoudi et al., 2020). Pequenas variações em seu volume afetam significativamente o metabolismo e a regulação energética. Segundo Wang et al. (2024), o TAV libera grandes quantidades de citocinas pró-inflamatórias, como interleucina-6 (IL-6) e fator de necrose tumoral alfa (TNF- α), além de adipocinas associadas a inflamações crônicas. Essa atividade prejudica o endotélio e aumenta a rigidez arterial, medida pela velocidade da onda de pulso (baPWV). Wang et al. também afirmam que a correlação entre TAV e baPWV é mais forte que com outros índices de adiposidade, como IMC e gordura subcutânea, o que aponta para a obesidade abdominal ser mais prejudicial que a generalizada.

Em contraste, o tecido adiposo subcutâneo (TAS) presente, de modo geral, sob a pele admite funções de reserva energética, isolamento térmico e proteção contra traumas, sendo metabolicamente menos ativo que o tecido adiposo visceral (TAV) e exercendo menor influência sobre inflamação sistêmica e risco cardiovascular (Masoudi et al., 2020). Apesar de expandir com o excesso calórico, o TAS é considerado fisiologicamente mais benigno. No entanto, Wang et al. (2024) ressaltam que, embora o TAS tenha papel protetor em relação ao metabolismo energético, o seu acúmulo excessivo, sobretudo em regiões abdominais, ainda pode se associar a riscos moderados, especialmente quando acompanhado por aumento do TAV.

O tecido adiposo é considerado um órgão endócrino metabólico dinâmico, fundamental na regulação energética e na homeostase (capacidade do corpo de manter um ambiente interno estável) (Maneck et al., 2021). Além da classificação por localização, esse tecido corporal é comumente subdividido em três categorias: Tecido Adiposo Branco, Tecido Adiposo Bege e Tecido Adiposo Marrom.

- **Tecido adiposo branco:** É o mais abundante no corpo com a função de armazenar energia na forma de triglicerídeos (gorduras, lipídios, encontradas no sangue, essenciais como reserva de energia no corpo). O tecido adiposo branco (WAT no inglês, *White Adipose Tissue*) é composto por adipócitos uniloculares, com uma grande gota lipídica e poucas mitocôndrias, distribuindo-se em depósitos subcutâneos e viscerais, que

diferem em função e impacto metabólico (Zwick et al., 2018). No ambiente subcutâneo, esse tecido atua como isolante térmico e reserva energética, enquanto na área visceral é mais metabolicamente ativo e secreta adipocinas e citocinas inflamatórias. O WAT apresenta alta plasticidade, aumentando por hipertrofia ou hiperplasia e, embora fisiológica, isso a torna prejudicial em casos de obesidade, favorecendo resistência à insulina, inflamação crônica e distúrbios metabólicos (Sakers et al., 2022).

- **Tecido adiposo marrom:** É especializado na termogênese adaptativa, produzindo calor corporal em resposta ao frio ou à superalimentação, contendo adipócitos multiloculares, ricos em mitocôndrias e proteínas que convertem energia em calor em vez de ATP (Maneck et al., 2021). Abundante em recém-nascidos, esse tecido diminui com a idade, mas persiste em adultos em regiões como a supraclavicular, cervical e perirrenal, sendo altamente vascularizado e ativado pelo sistema nervoso simpático por meio da sinalização β -adrenérgica, que promove a oxidação de ácidos graxos e o gasto energético (Zwick et al., 2018). Diferente do tecido branco, o tecido adiposo marrom (do inglês, *Brown Adipose Tissue* - BAT) atua na regulação térmica e no equilíbrio metabólico. A pesquisa de Sakers et al. (2022), intitulada “*Adipose-tissue plasticity in health and disease*”, destaca o potencial terapêutico deste tecido no combate à obesidade e a distúrbios metabólicos, devido à sua capacidade de aumentar o consumo calórico e melhorar a homeostase da glicose.
- **Tecido adiposo bege:** É um tipo intermediário entre o tecido branco e o marrom, combinando características estruturais e funcionais de ambos. Nesse caso, as células que compõem o tecido adiposo conhecidas como adipócitos, que armazenam energia na forma de gordura, surgem no tecido branco subcutâneo sob estímulos como frio, exercício físico ou também pela ativação β -adrenérgica, em um processo chamado “*browning*” (Sakers et al., 2022). Esses adipócitos são multiloculares, ricos em mitocôndrias e expressam a proteína UCP1 (*uncoupling protein 1*), conferindo-lhes capacidade termogênica semelhante à do tecido marrom (Maneck et al., 2021). A origem do tecido bege (do inglês “*Brite Adipose Tissue*”) pode ocorrer pela transdiferenciação de adipócitos brancos maduros ou pela diferenciação de precursores específicos, sendo um processo reversível que depende de estímulos hormonais ou ambientais (Zwick et al., 2018). Maneck et al. (2021), representa o tecido bege exemplo de plasticidade metabólica do organismo, funcionando como mecanismo adaptativo para aumentar o gasto energético e dissipar calor, auxiliando na regulação do peso corporal e na proteção contra a obesidade.


A Figura 5 ilustra três eixos principais de variação do tecido adiposo que influenciam diretamente a saúde metabólica: localização (A), mecanismo de expansão (B) e fenótipo metabólico (C).

De acordo com Sakers et al., 2022, na Fig. 5A se observa a diferença entre a gordura visceral (localizada na cavidade abdominal, em torno dos órgãos internos) e a subcutânea (sob a pele, especialmente nas coxas e quadris). A gordura visceral está associada a maior risco metabólico, enquanto a subcutânea é considerada mais protetora.

Já a Fig. 5B apresenta os mecanismos de expansão do tecido adiposo: hipertrofia, quando há aumento do tamanho dos adipócitos, e hiperplasia, quando ocorre aumento no número dessas células Sakers et al., 2022. A hipertrofia está relacionada a efeitos metabólicos negativos, enquanto a hiperplasia é considerada mais saudável.

Por fim, a Fig. 5C compara o tipo de função metabólica dos adipócitos, onde o tecido branco atua principalmente no armazenamento de energia, enquanto os tecidos bege e marrom são especializados na queima de energia por termogênese (Maneck et al., 2021). Na Figura 5, os elementos situados à direita em cada painel representam perfis mais saudáveis ou protetores do ponto de vista metabólico, enquanto os elementos à esquerda estão associados a maior risco metabólico.

Figura 5. Principais eixos do tecido adiposo que impactam na saúde metabólica: localização (A), mecanismo de expansão (B) e fenótipo metabólico (C).



Fonte: Adaptado de Sakers et al. (2022)

Assim, a heterogeneidade na distribuição do tecido adiposo corporal reflete não apenas fatores genéticos e hormonais, mas também aspectos relacionados à idade, ao sexo e aos hábitos de vida. Fundamentados em estudos prévios, Wang et al. (2024) argumentam que a redistribuição da gordura com o avanço da idade, caracterizada pelo aumento da gordura central e redução da periférica, pode contribuir para o aumento progressivo da rigidez arterial em adultos aparentemente saudáveis. Conforme o trabalho de Frank et al. (2019), o envelhecimento do corpo humano está ligado a uma perda de gordura subcutânea, caracterizada pelo deslocamento progressivo do acúmulo de gordura do compartimento subcutâneo para o visceral mesmo quando o peso corporal total permanece estável, fenômeno esse associado a alterações hormonais, inflamatórias e estruturais do tecido adiposo. Frank et al. (2019) e Wang et al. (2024) ainda enfatizam que o acúmulo de TAV cresce continuamente até a sétima década de vida, enquanto o índice de massa corporal (IMC) atinge o seu pico mais cedo por volta dos 40-50 anos em homens e 60-70 anos em mulheres.

Desse modo, mesmo sem aumento substancial do peso, o envelhecimento está associado a um rearranjo da gordura corporal em direção a um perfil mais visceral, o que eleva o risco de doenças metabólicas e cardiovasculares. Wang et al. (2024) afirmam que o TAS aumenta com a idade, sobretudo em mulheres, devido à ação estrogênica, o que explica o maior acúmulo subcutâneo nelas, enquanto homens têm mais gordura visceral, evidenciando também um dimorfismo sexual que reflete diferenças hormonais e metabólicas.


No que diz respeito às diferenças entre os sexos, Oliveira et al. (2022) descrevem que pessoas do sexo feminino tendem a acumular mais gordura na região inferior do corpo, enquanto homens concentram o armazenamento lipídico no tronco, principalmente na cavidade abdominal. Essa diferença tem forte base hormonal: os estrogênios favorecem o depósito gluteofemoral e protegem as mulheres contra doenças cardiovasculares durante o período reprodutivo, enquanto os andrógenos promovem a acumulação visceral nos homens, contribuindo para um risco cardiovascular mais elevado (Karastergiou et al., 2012). Ademais, a ação dos hormônios sexuais sobre a expressão gênica em tecidos adiposos é destacada por Oliveira et al. (2022) e Karastergiou et al (2012) como um mecanismo-chave para explicar o dimorfismo, uma vez que estrogênios e andrógenos modulam a atividade de enzimas e receptores envolvidos na lipólise, na diferenciação de adipócitos e na secreção de adipocinas.

Contudo, após a menopausa, a redução dos níveis de estrogênio provoca uma redistribuição da gordura feminina em direção ao tronco, aumentando o risco de eventos cardiovasculares e metabólicos (Oliveira et al., 2022).

3.2. ANATOMIA MAMÁRIA

A distribuição da gordura no corpo humano não ocorre de maneira uniforme, variando conforme fatores genéticos, hormonais e metabólicos o que confere a cada região corporal um papel fisiológico distinto (Silva et al., 2006). Essa diferenciação é relevante porque embora alguns métodos de medição de gordura corporal sejam amplamente usados, como o IMC por exemplo, eles não distinguem os tipos e localizações de tecido adiposo, podendo mascarar os efeitos específicos da gordura visceral (Borga, 2018). Entre essas regiões, o abdômen se destaca como uma das mais investigadas devido à coexistência de dois importantes compartimentos de gordura: o tecido adiposo subcutâneo. Na Figura 6 a seguir, LeWine (2024), aborda de maneira ilustrativa esses tecidos adiposos para a região do abdômen humano (A) e o posicionamento da fita métrica para a medição da gordura visceral ou o acompanhamento do aumento ou redução da região (B). Conforme Silva et al. (2006), a variação estrutural do corpo ilustra de forma clara como a disposição anatômica da gordura influencia diretamente suas funções metabólicas e seu impacto sobre a saúde. No artigo produzido pelos autores é descrito também que a gordura abdominal pode ser avaliada indiretamente por meio do perímetro da cintura (indicador da massa adiposa visceral) e da relação cintura-quadril para indicar a proporção entre gordura central e periférica, estando associada à resistência à insulina.


Figura 6. Localização e distribuição dos tipos de gordura na região do abdômen (A) e posicionamento de fita métrica para medição da gordura visceral (B).



Fonte: Adaptado de LeWine (2024)

Embora a região abdominal e o tronco humano sejam frequentemente abordados como referências na análise da adiposidade, outras estruturas anatomicamente próximas, como as mamas, apresentam uma composição bastante distinta. De acordo com Viana (2016), apesar de também integrarem a região torácica, as mamas possuem uma arquitetura própria, constituída por tecidos epiteliais, conjuntivos e adiposos organizados de modo singular, o que lhes confere comportamento fisiológico e térmico diferenciado em relação ao abdômen e às demais partes do tronco. A Figura 7 apresenta de forma ilustrativa o perfil da anatomia da mama, apontando o posicionamento de cada componente de sua estrutura (Maia, Freitas e Monteiro, 2006).

Figura 7. Estrutura anatômica da mama.




Fonte: Maia, Freitas e Monteiro (2006)

Conforme a Figura 7, é possível observar que a estrutura da mama é envolvida por uma cápsula mamária, composta por tecido conjuntivo que a separa da musculatura peitoral e permite sua mobilidade. Além disso, a mama se posiciona entre a segunda ou terceira costela sendo estendida até a dobra inframamária próxima da sexta ou sétima costela e internamente é dividida em lóbulos e lóbulos menores chamados ácinos, que são as unidades produtoras de leite (Romrell e Bland, 1994). Cada lóbulo se conecta ao mamilo por meio dos ductos lactíferos, que convergem e desembocam na papila mamária. O tecido conjuntivo que sustenta a mama é composto por ligações conhecidas como ligamentos de Cooper, que mantêm sua forma e firmeza. Entre a cápsula e a parede torácica há uma fina camada de gordura chamada bolsa retromamária, responsável pela mobilidade da glândula (Maia, Freitas e Monteiro, 2006).

Bernardes (2011) aponta que a pele da mama possui três camadas principais - epiderme, derme e tecido subcutâneo - e apresenta três regiões únicas: papila mamária (mamilo), aréola e periferia. A papila contém as aberturas dos ductos lactíferos; a aréola circunda o mamilo e abriga pequenas glândulas (tubérculos de Morgagni ou Montgomery); e a periferia é formada por pele mais fina e lisa. Em conjunto, essas estruturas determinam a forma e o volume da mama, além de influenciarem a distribuição de temperatura em sua superfície, aspecto importante em estudos de termografia e modelagem anatômica (Romrell e Bland, 1994).

Esse diferencial em sua composição reflete não apenas a função biológica das mamas, mas também a forma como o tecido adiposo se distribui e interage com os demais componentes locais (Ohmaru et al., 2023). Nesse sentido, outro fator importante como o processo de envelhecimento afeta esse órgão. Lin et al. (2023) destacam que as flutuações hormonais associadas ao envelhecimento afetam diretamente a estrutura e a função da mama, o que proporciona uma degeneração progressiva das unidades ducto-lobulares terminais (*Terminal Duct Lobular Units*, TDLUs) - estruturas funcionais responsáveis pela produção de leite - acompanhada de redução do tecido epitelial e aumento da proporção de tecido adiposo. Dessa forma, a Figura 8 apresenta as mudanças na morfologia da glândula mamária durante o envelhecimento. Com o avanço da idade, a epiderme da mama feminina tende a se tornar mais fina, a elasticidade da glândula mamária diminui e a matriz mamária sofre ptose (a flacidez gradual na região) à medida que é substituída por tecido gorduroso (Lin et al., 2023).

Figura 8. Comparação entre uma mama jovem e uma mama envelhecida.



Fonte: Adaptado de Lin et al. (2023)

De acordo com Mokhtary, Karakatsanis e Valchis (2021), mulheres mais jovens tendem a apresentar mamas mais densas devido à maior proporção de tecido glandular ativo, enquanto mulheres mais velhas, especialmente após a menopausa, demonstram maior substituição desse tecido por gordura. Essa transição foi considerada pelos autores como um marcador natural do envelhecimento mamário e relevante para o rastreamento do câncer de mama, uma vez que a densidade influencia tanto o risco da doença quanto a sensibilidade dos exames de imagem. Lin et al. (2023) enfatizam que o aumento relativo do tecido adiposo mamário com a idade tem papel central nas transformações fisiológicas e patológicas, pois os adipócitos passam a secretar citocinas e adipocinas inflamatórias, como resistina e interleucinas, capazes de modificar o microambiente tecidual e favorecer o desenvolvimento de doenças como mastite, fibroadenoma e câncer de mama. Ohmaru et al. (2023) ainda destacam que essa inflamação de baixo grau, típica do envelhecimento, é apontada como um dos mecanismos que elevam a susceptibilidade a processos neoplásicos (crescimento anormal e descontrolado de células em um tecido ou órgão, que pode levar à formação de um tumor).

A Tabela 2, desenvolvida por Viana (2016), estabelece valores de densidade mamária e percentual de tecido glandular correspondentes a diferentes faixas etárias de maneira coerente com a tendência fisiológica de redução da densidade das mamas com o envelhecimento, que lhe possibilitou a aplicação uniforme do método de análise termográfica mesmo na ausência de dados diretos sobre a composição tecidual. A autora se baseou em estudos precursores na área e na classificação do Colégio Americano de Radiologia, que define as categorias D, C, B e A segundo a proporção de tecido fibroglandular, partindo da classe mais densa e com maior percentual fibroglandular, D, para a mais adiposa e com a menor porcentagem desse tecido glandular, A. Essa padronização foi necessária para os casos em que os exames de imagem das pacientes não indicavam explicitamente a composição do tecido mamário, permitindo que a análise pudesse prosseguir de forma coerente e comparável entre diferentes idades.

Tabela 2. Faixas de percentuais do tecido glandular mamário com relação à diferentes faixas etárias.

Idade (anos)	Tecido glandular (%)	Classificação Colégio Americano de Radiologia
Até 25	Maior que 90	D
26 - 35	80 - 90	D
36 - 45	75 - 80	D
46 - 60	51 - 75	C
61 - 75	25 - 50	B
Acima de 75	Menor que 25	A

Fonte: Viana (2016)

3.3. MÉTODOS DE MEDIÇÃO DA ADIPOSIDADE CORPORAL

A avaliação da gordura corporal é um dos pilares da análise da composição corporal humana, sendo fundamental para compreender o estado nutricional, o risco metabólico e o impacto de doenças relacionadas à obesidade e ao envelhecimento (Wang, Chen e Eitzman, 2015). Conforme Pray e Riskin, (2023), a quantificação e a distribuição do tecido adiposo podem ser determinadas por diferentes métodos, que variam quanto à precisão, custo, acessibilidade, grau de invasividade e aplicabilidade clínica ou experimental que também dependem da análise, sendo esta total (correspondente ao corpo todo do indivíduo) ou local (referente à uma região específica, como a mama por exemplo). Nesta seção, serão abordados os principais métodos empregados para a análise da gordura corporal investigados na literatura, divididos entre os de natureza antropométrica, elétrica, radiológica e térmica, além de técnicas baseadas em modelagem computacional. Essa organização visa demonstrar a evolução dos métodos de mensuração (desde os mais simples, amplamente utilizados em estudos populacionais, até aqueles que empregam tecnologias de imagem e algoritmos computacionais avançados), ressaltando suas vantagens, limitações e correlações com o presente estudo, que propõe o uso da termografia por infravermelho como ferramenta complementar de análise.

3.3.1. Índice de Massa Corporal (IMC) e medidas antropométricas

Os métodos antropométricos constituem a abordagem mais simples e amplamente utilizada para estimar a gordura corporal. Entre eles, destaca-se o Índice de Massa Corporal (IMC), proposto originalmente por Adolphe Quetelet no século XIX, calculado pela razão entre o peso corporal (em quilogramas) e o quadrado da altura (em metros) (Pray e Riskin, 2023). A Tabela 3 expressa a relação mais usual do IMC estabelecida pela OMS (WHO, 2006).

Tabela 3. Classificação do IMC pela Organização Mundial da Saúde (OMS).

Faixa de IMC (kg/m ²)	Classificação
< 17,0	Magreza moderada a grave (Anorexia)
17,0 – 18,4	Abaixo do peso (magreza)
18,5 – 24,9	Faixa saudável
25,0 – 29,9	Sobrepeso
≥ 30,0	Sobrepeso moderado a grave (Obesidade)

Fonte: Adaptado de WHO (2006)

O IMC é reconhecido pela Organização Mundial da Saúde (OMS) como o principal indicador de triagem populacional para classificar o estado nutricional de indivíduos adultos, sendo considerado sobrepeso o valor entre 25,0 e 29,9 kg/m² e os graus de obesidade iniciando em valores iguais ou superiores a 30 kg/m², conforme a Tabela 3 (WHO, 2006). Apesar de sua ampla utilização, o IMC não distingue massa magra de massa gorda, nem identifica a distribuição regional da gordura, o que pode resultar em classificações imprecisas em casos de alta massa muscular ou redistribuição adiposa, esta última frequente no envelhecimento. Além do IMC, Pray e Riskin (2023) informam que outras medidas antropométricas são utilizadas como indicadores indiretos de gordura corporal, como é o caso da relação cintura-quadril (RCQ ou WHR, “*waist-to-hip ratio*”), a relação cintura-altura (RCA ou WHtH, “*waist-to-height ratio*”), a circunferência da cintura (CC ou WC, “*waist circumference*”), a circunferência do pescoço (CP ou NC, “*neck circumference*”) e o índice de forma corporal (IFC ou ABSI, “*A Body Shape Index*”). Entre esses, a RCQ tem uma frequência de uso semelhante ao IMC, onde a partir do perímetro da cintura e do perímetro do quadril permite estimar o acúmulo de gordura visceral e o risco de doenças metabólicas associadas. Estudos como os de Silva et al. (2006) e Oliveira et al. (2022) demonstram que uma maior RCQ está associada à resistência à insulina, à hipertensão e a distúrbios cardiovasculares. Assim, tais métodos, apesar de limitados pela subjetividade da aferição e pela influência de fatores étnicos e sexuais, permanecem amplamente empregados por sua praticidade, baixo custo e correlação razoável com a adiposidade abdominal.

3.3.2. Análise cutânea por dobras subcutâneas

A avaliação por dobras cutâneas representa outro método antropométrico clássico para estimar o percentual de gordura corporal. Essa técnica baseia-se na hipótese de que a espessura da gordura subcutânea em determinados pontos do corpo é proporcional à gordura total (Davidson et al., 2011). Para sua aplicação, utiliza-se um compasso específico (adipômetro) para medir a espessura de pregas em locais padronizados, como tríceps, subescapular, suprailíaca e coxa. As medições são então inseridas em equações de regressão, como as de Durnin e Womersley e de Jackson e Pollock, que estimam o percentual de gordura corporal total.

Jackson e Pollock (1978) procuraram desenvolver equações generalizadas para estimar a densidade corporal de homens adultos com faixa etária entre 18 e 61 anos, a partir de medidas antropométricas de pregas cutâneas (peito, axila, tríceps, subescapular, abdômen, supra-ilíaca,

coxa), circunferências corporais (da região da cintura e do braço) e idade dos pacientes. Em seu estudo foram calculadas equações de regressão múltipla em diferentes formas (linear, quadrática ou logarítmica da soma de pregas cutâneas (*skinfolds*), com idade e circunferências como co-variáveis), que na fase de validação cruzada, as correlações entre a densidade corporal estimada e a densidade medida apontaram boa consistência e correlações com erro mínimo. Com o mesmo objetivo o estudo de Durnin e Womersley (1974) avaliou 481 indivíduos, de ambos os sexos e com idades entre 16 e 72 anos, utilizando pregas em quatro regiões do corpo e pesagem hidrostática como referência. Os autores verificaram que o uso do logaritmo das espessuras tornava a relação com a densidade corporal mais linear, permitindo o desenvolvimento de equações específicas por sexo e faixa etária, assim elaboraram uma tabela que relaciona a soma das dobras ao percentual de gordura, consolidando um método prático e aplicável em diferentes populações.

Contudo, apesar de ser um método não invasivo e de baixo custo, a análise cutânea depende fortemente da habilidade do avaliador e da calibração do equipamento, apresentando limitações quando aplicado em pessoas obesas, idosas ou com flacidez acentuada (Davidson et al., 2011). Mesmo assim, permanece como uma ferramenta útil para estudos de campo e monitoramento de mudanças corporais em intervenções nutricionais e fisiológicas.


3.3.3. Análise por Bioimpedância (Bioelectric Impedance Analyzer - BIA)

A análise por bioimpedância elétrica (*Bioelectric Impedance Analyzer - BIA*) é um método amplamente adotado por sua praticidade e boa correlação com medidas de composição corporal mais precisas. O princípio da técnica baseia-se na passagem de uma corrente elétrica de baixa intensidade através do corpo: tecidos ricos em água e eletrólitos, como músculos, conduzem melhor a corrente, enquanto o tecido adiposo oferece maior resistência (Kyle et al., 2004). A partir dessa diferença de condutividade, o equipamento de bioimpedância calcula de forma estimada variáveis como o percentual de gordura corporal (*Fat%*), a massa gorda ou massa adiposa (*FM, Fat Mass*), a massa livre de gordura ou massa magra (*FFM, Fat-Free Mass*) e a água corporal total (*TBW, Total Body Water*) do indivíduo, além de possibilitar medições segmentadas, como na região do tronco ou membros (Laffaye et al., 2019).

Dessa maneira, uma balança usual de bioimpedância injeta uma corrente elétrica alternada de baixa intensidade (por exemplo, 50 kHz em aparelhos *single-frequency*) no indivíduo através de eletrodos e mede a impedância complexa *Z* que se opõe ao fluxo dessa corrente. A Figura 9 ilustra um dos meios mais usuais de medição por bioimpedância, sendo da

mão/pulso ao pé/tornozelo, havendo também variações como equipamentos que enviam a corrente elétrica apenas pela extremidade dos pés ou das mão (Kyle et al, 2004).

Figura 9. Posicionamento usual dos eletrodos para a análise corporal por bioimpedância.



Fonte: Adaptado de Kyle et al. (2004)

Conforme Khalil, Mohktar, e Ibrahim (2014), a impedância tem duas componentes mensuráveis: a resistência (R) que seria a oposição pura (perda de energia) associada sobretudo ao conteúdo de água e eletrólitos (no sangue ou em tecidos condutivos como músculos, por exemplo), e a reatância capacitiva (X_c) sendo este o componente capacitivo associado às membranas celulares (efeito de armazenamento de carga). Matematicamente, tem-se a relação descrita na Equação 1:

$$Z = \sqrt{R^2 + X_c^2} \quad (1)$$

Uma aproximação física muito usada nesse tipo de análise é modelar segmentos do corpo (como o braço, a perna ou o tronco) em forma de cilindros homogêneos (Khalil, Mohktar, e Ibrahim, 2014). Assim, para um cilindro condutor, admite-se a Equação 2:

$$R = \rho \cdot \frac{L}{A} \quad (2)$$

onde ρ é a resistividade do tecido ($\Omega \cdot m$), L é o comprimento (m) e A é a área da secção transversal (m^2). Rearranjando, o volume $V = A \cdot L$ aparece como sendo proporcional a L^2/R .

A BIA, por si só, mede a relação de R/X_c para obter TBW e depois a relação de massa magra (FFM) por massa gorda ou massa adiposa (FM). Enquanto a FFM é normalmente considerada com o volume condutor por admitir minerais ósseos e massa celular corporal, a FM é tratada com a porção não condutora de carga elétrica sendo esta última determinada como a diferença entre o peso corporal total (*body weight*, Wt_{Body}) e a FFM, conforme a Equação 3 (Khalil, Mohktar, e Ibrahim, 2014). Em adição a isso, os estudos de Kyle et al. (2004) e Khalil, Mohktar, e Ibrahim (2014) apontam que a água presente no corpo, TBW, é o principal componente da FFM sendo equivalente a 73,2% no caso de pessoal com nível de hidratação normal, assim $TBW = 0,73 \cdot FFM$.

$$FM = Wt_{Body} - FFM \quad (3)$$

A partir da Equação 3 é possível então estabelecer a relação para o percentual de gordural corporal (*Fat%*), sendo esta dada pela Equação 4 a seguir.

$$Fat\% = 100 \cdot \frac{FM}{Wt_{Body}} \quad (4)$$

Por sua portabilidade e rapidez, é uma das técnicas mais utilizadas em clínicas e academias, além de ser considerada segura e não invasiva. Em trabalhos como o realizado por Laffaye et al. (2019), a bioimpedância foi utilizada como ferramenta central para caracterizar a composição corporal dos participantes e serviu como base de comparação para validar modelos de termografia infravermelha voltados à estimativa de gordura corporal. No experimento, a bioimpedância forneceu a base quantitativa necessária das variáveis mencionadas aplicadas no conjunto de indivíduos estudados para validar as relações entre temperatura da pele e distribuição de gordura corporal, permitindo avaliar a eficácia do modelo termográfico em prever a quantidade de massa adiposa nas regiões observadas de forma não invasiva e comparável aos métodos tradicionais.

Já no estudo desenvolvido por Snehalatha et al. (2021), a bioimpedância foi abordada sob uma perspectiva comparativa, destacando-se suas limitações, pois afirmavam que versões de segmentação e multifrequenciais da BIA tendem a superestimar a gordura corporal e que, apesar de seu uso disseminado, o método pode apresentar erros em diferentes faixas etárias e composições físicas. A análise por bioimpedância foi utilizada como referência metodológica para justificar a adoção da termografia associada à inteligência artificial, um método mais acessível, automatizado e livre de contato físico (Snehalatha et al., 2021). Na prática, fabricantes calibram os equipamentos BIA para populações específicas através de métodos de regressão (ou algoritmos próprios), métricas corporais e equações empíricas, o que proporciona variações e/ou limites entre marcas/modelos (Kyle et al., 2004).


3.3.4. Absorciometria Bifotônica de Raios-X (DXA)

A DXA (*Dual-energy X-ray Absorptiometry*) é considerada um dos métodos de referência para avaliação da composição corporal. Originalmente desenvolvida para análise da densidade mineral óssea (densitometria óssea), a técnica foi posteriormente adaptada para quantificar gordura e massa magra corporal total e segmentar essas medidas por regiões anatômicas específicas (Messina et al., 2020). Esse método se baseia nos princípios da atenuação diferencial dos Raios-X ao atravessarem tecidos biológicos com diferentes composições elementares e densidades (IAEA, 2010). Isso acontece pois quando um feixe de Raios-X incide sobre um material, parte da radiação é absorvida ou desviada, e a quantidade de energia remanescente é expressa pela lei exponencial de atenuação apresentada na Equação 5:

$$I = I_0 \cdot e^{-\mu t} \quad (5)$$

onde I_0 é a intensidade inicial do feixe incidente (Wm^{-2}), I é a intensidade transmitida (Wm^{-2}), μ é o coeficiente linear de atenuação do material (cm^{-1}) e t é a espessura do material (cm). Na Figura 10 é possível observar a comparação entre dois indivíduos de sexos diferentes (homem à esquerda e mulher à direita) com massa muscular reduzida, porém apresentando diferentes porcentagens de massa gorda avaliadas através do registro por DXA onde a faixa na região inferior indica a composição da região corporal para a respectiva cor (Messina et al., 2020).

Figura 10. Comparação entre um homem com menor quantidade de massa adiposa (A) e uma mulher com maior quantidade de massa adiposa (B) registrados através de DXA.



Fonte: Adaptado de Messina et al. (2020)


O método DXA utiliza dois feixes de raios-X com diferentes espectros de energia (um de baixa e outro de alta média energética), sendo ambas doses inferiores quando comparadas com a tomografia. Como a atenuação dos Raios-X varia de forma distinta entre os tecidos ósseos e os tecidos moles, a aquisição de imagens em duas faixas de energia permite separar os componentes corporais com base em suas propriedades de absorção (IAEA, 2010). Essa diferenciação permite a determinação precisa da percentagem de gordura total e da distribuição regional da adiposidade, incluindo áreas como tronco, abdômen e mamas.

No estudo conduzido por Salamunes, Stadnik e Neves (2017), o método de Absorciometria por Raios-X de Dupla Energia (DXA) foi caracterizado como um padrão adequado para a avaliação da composição corporal, sendo utilizado para estimar a porcentagem de gordura corporal total, bem como a massa magra e o percentual de gordura de segmentos corporais específicos, incluindo membros superiores, tronco e membros inferiores. A partir disso, o DXA foi essencial tanto para a caracterização da amostra, quanto para a análise estatística e validação dos resultados do estudo, servindo como referência comparativa para validar as relações entre a distribuição de gordura e as variações térmicas superficiais, além de fornecer os valores utilizados para a formação dos grupos de alta e baixa porcentagem de gordura em cada segmento corporal (Salamunes, Stadnik e Neves, 2017).

3.3.5. Tomografia Computadorizada (TC)

A análise por tomografia computadorizada (TC) representa uma abordagem de alta precisão para quantificar o tecido adiposo e analisar sua distribuição anatômica. Nelson et al. (2008) demonstram que essa técnica possibilita identificar a substituição do tecido glandular por gordura nas mamas ao longo do envelhecimento (Figura 11).

Figura 11. Exemplo de digitalização de camadas para diferentes regiões de uma mama por meio de tomografia computadorizada (A) e suas respectivas segmentações (B).



Fonte: Adaptado de Nelson et al. (2008)

A tomografia computadorizada (TC) é caracterizada por MacLean et al. (2020) como um método de imagem médica amplamente utilizado na prática clínica moderna, capaz de produzir representações anatômicas em cortes axiais de alta resolução que permitem a quantificação precisa de estruturas internas, incluindo o tecido adiposo. De forma semelhante ao método DXA, esta técnica baseia-se na emissão de feixes de Raios-X relativamente mais intensos em torno do corpo do indivíduo, que são atenuados de forma diferente conforme a densidade e a composição dos tecidos (Nelson et al., 2008). Dessa maneira, o corpo é então escaneado em cortes sequenciais e as imagens obtidas são reconstruídas digitalmente, resultando em um conjunto tridimensional de dados que podem ser analisados quantitativamente. A partir da atenuação, o equipamento gera mapas de valores em unidades Hounsfield (HU), que representam a densidade radiológica dos materiais. O tecido adiposo, por exemplo, apresenta uma faixa característica de atenuação entre aproximadamente -190 e -30 HU, o que possibilita sua distinção dos demais tecidos corporais (MacLean et al., 2020).

Entretanto, apesar de seus benefícios inquestionáveis, a TC apresenta limitações que podem impactar em sua aplicação prática, na segurança dos pacientes e na eficiência do cuidado em saúde. Esses fatores envolvem aspectos técnico-científicos, operacionais, de interpretação e de impacto biológico, sendo essenciais para uma avaliação crítica dessa tecnologia no contexto clínico contemporâneo (John et al., 2015). Diferentemente de exames radiográficos simples, os protocolos de TC geralmente envolvem altos níveis de radiação ionizante. Conforme apontado por Fred (2004), uma única seção de tomografia computadorizada do tórax fornece uma dose efetiva de radiação equivalente à de cerca de 400 radiografias dessa mesma região do corpo.

Outro ponto crítico diz respeito aos artefatos e limitações de resolução inerentes ao processo de aquisição e reconstrução de imagens. Artefatos (distorções ou erros na imagem) podem surgir por diversas razões, desde movimento do paciente até interferências de objetos metálicos, degradando a qualidade da imagem e dificultando a interpretação correta (Al-Naser e Tafti, 2023). A presença de imperfeições na aquisição de dados limita sobretudo a detecção de estruturas de baixo contraste ou muito pequenas, podendo levar a falsos negativos ou diagnósticos imprecisos. Ajustar parâmetros para mitigar artefatos frequentemente exige compromissos entre qualidade, dose de radiação e tempo de exame.

Há também questões práticas e operacionais que podem limitar a aplicação efetiva da tomografia computadorizada. Equipamentos de TC são caros tanto em aquisição quanto em manutenção e exigem infraestrutura especializada, o que restringe seu acesso em ambientes com recursos limitados (John et al., 2015).

3.3.6. Ressonância Magnética (RM)

A ressonância magnética (RM, ou *Magnetic Resonance Imaging* - MRI) é uma técnica que, diferente da TC, fornece excelente contraste tecidual sem o uso de radiação ionizante, sendo útil especialmente em pacientes que requerem exames repetidos pois permite uma representação anatômica e funcional altamente detalhada de órgãos, tecidos e processos patológicos (Pescatori et al., 2019).

O princípio físico da MRI baseia-se na interação entre campos magnéticos e ondas de rádio com os prótons de hidrogênio presentes no corpo. As diferentes propriedades magnéticas dos prótons de água e gordura, por exemplo, permitem diferenciar os tecidos corporais por meio do contraste entre seus sinais (Küstner et al., 2020). Essa característica é explorada por Marunowski et al. (2021) para identificar e quantificar os compartimentos de gordura corporal. Os autores caracterizaram a MRI como um método altamente reprodutível, seguro e quantitativo para avaliação da composição corporal, capaz de fornecer medidas diretas de adiposidade sem exposição à radiação.

Contudo, o elevado custo, infraestrutura e o tempo de aquisição tornam essa técnica menos acessível para uso contínuo. A manutenção e operação dos aparelhos requerem sistemas magnetos e técnicos especializados, fatores que encarecem o exame e muitas vezes limitam seu acesso em regiões de baixa renda ou em serviços de saúde com recursos restritos (Jimeno, Vaughan e Geethanath, 2022). Além disso, há também a necessidade de alta demanda computacional para automatizar o processo de segmentação com o intuito de minimizar as variações na quantificação de gordura corporal (Küstner et al., 2020). O tempo de aquisição de imagens em RM, por exemplo, é significativamente maior do que em outros métodos, como a tomografia computadorizada, exigindo períodos prolongados de imobilidade do paciente para evitar artefatos de movimento, o que pode diminuir a produtividade de serviços de diagnóstico e limitar o uso em cenários emergenciais (Jimeno, Vaughan e Geethanath, 2022).

Outro conjunto de limitações está relacionado às características físicas e condições dos pacientes. A presença de campos magnéticos intensos torna a RM contraindicada para indivíduos com implantes metálicos ou dispositivos eletrônicos (como marca-passos e desfibriladores) e pode gerar erros significativos de imagem na presença de metais no corpo, prejudicando a interpretação diagnóstica (Alessandro e Paulo, 2024). Além disso, o desconforto do ambiente tubular e restrito pode exigir sedação ou técnicas alternativas, comprometendo a qualidade das imagens ou aumentando o risco operacional.

3.3.7. Termografia por Infravermelho (Infrared Thermography - IRT)

A termografia por infravermelho (Infrared Thermography – IRT) emerge como uma alternativa promissora, segura e não invasiva para análise da gordura corporal. A técnica baseia-se na detecção da radiação térmica emitida naturalmente pela pele, permitindo mapear a temperatura superficial e inferindo características metabólicas dos tecidos subjacentes (Reis et al., 2022). Na análise em seres humanos, esse princípio é idealizado a partir da Equação de Pennes ou Equação de Biotransferência de Calor (*Bioheat Transfer Equation* - BHTE) que, para um cenário clínico usual dedicado a esse tipo de monitoramento onde a taxa volumétrica de geração de calor produzida por fonte externa pode ser atribuída como nula no problema aqui proposto ($Q = 0$) e considerando o equilíbrio térmico incompleto entre o sangue e o tecido ($k = 0$), admite-se a forma presente na Equação 6 (Viana, 2016; Bezerra, 2007; e Pennes, 1948).

$$\rho_t c_t \frac{\partial T}{\partial t} = k_t \nabla^2 T + w_t \rho_b c_b (T_a - T) + Q_m \therefore (\Omega \times \mathbf{T}) \quad (6)$$

onde:

ρ_t = densidade do tecido [kgm^{-3}];

c_t = calor específico do tecido [$\text{Jkg}^{-1}\text{K}^{-1}$];

k_t = condutividade térmica do tecido [$\text{Wm}^{-1}\text{K}^{-1}$];

T = temperatura do tecido [K];

t = tempo [s];

w_t = taxa perfusão sanguínea [ml/s/ml];

ρ_b = densidade do sangue [kgm^{-3}];

c_b = calor específico do sangue [$\text{Jkg}^{-1}\text{K}^{-1}$];

T_a = temperatura do sangue arterial entrando no tecido [K];

Q_m = taxa volumétrica de geração de calor da produção de calor metabólico [Wm^{-3}];


Ω = domínio espacial do problema;

$\mathbf{T}$ = intervalo de tempo de integração.

O modelo de Pennes (1948) é adequado pois considera que o sangue atua como um mecanismo regulador da temperatura, trocando calor com os tecidos principalmente por meio dos vasos de maior calibre, enquanto nos capilares o sangue e o tecido estão em equilíbrio térmico. Já no que diz respeito à análise da gordura corporal, pesquisadores como Jalil (2019) e Salamunes, Stadnik e Neves (2017) confirmam que o tecido adiposo atua como um isolante térmico, assim as áreas com maior concentração de gordura tenderiam a exibir temperaturas superficiais mais baixas em comparação a regiões com menor espessura adiposa.

O processo de aquisição das imagens termográficas requer um equipamento apropriado. A câmera termográfica opera a partir da captação da radiação infravermelha naturalmente emitida por qualquer corpo cuja temperatura esteja acima do zero absoluto. Essa radiação, fora do campo invisível ao olho humano, é focalizada por um sistema óptico sobre um detector sensível capaz de transformar a energia radiante em sinais elétricos, que são convertidos e processados eletronicamente para gerar uma imagem digital colorida, onde cada pixel corresponde a uma medida de temperatura superficial do corpo observado (Bezerra et al., 2012, e Queiroz et al., 2023). A Figura 12 demonstra uma simplificação desse processo.

Figura 12. Esquematisação do método de medição utilizando uma câmera termográfica [4]. Para o registro são consideradas as temperaturas do objeto observado [2], da atmosfera [3] e a parcela refletida pelo ao meio adjacente [1].



Fonte: Adaptado de Araújo (2009)

Araújo (2009) destaca que a radiação captada pela câmera é composta por três parcelas fundamentais: a radiação emitida pelo próprio objeto, a radiação refletida por fontes adjacentes no ambiente e a radiação emitida ou absorvida pela atmosfera. Dessa maneira, a forma usual de escrever a contribuição total (radiação que atinge a câmera) pode ser dada pela Equação 7:

$$W_{tot} = \tau[\varepsilon W_{obj} + (1 - \varepsilon)W_{ref}] + (1 - \tau)W_{atm} \quad (7)$$

onde:

W_{tot} = radiação que um corpo negro emitiria à temperatura do objeto [Wm^{-2}];

T_{ref} = temperatura refletida [K];

T_{atm} = temperatura da atmosfera [K];

ε = emissividade do objeto (0 a 1);


τ = transmitância da atmosfera na trajetória objeto (0 a 1, depende da distância e da umidade);
 W_{ref} = radiação proveniente do meio adjacente a T_{ref} e que é refletida pela superfície do objeto [$Wm^{-1}K^{-1}$];

W_{atm} = radiação emitida pela atmosfera ao longo do caminho (associada à temperatura da atmosfera T_{atm}) [$Wm^{-1}K^{-1}$].

Conforme processamentos como o realizado por Reis et al. (2022), devido às variáveis do ambiente o equipamento utilizado necessita compensar matematicamente cada uma das influências para que os valores das temperaturas exibidas sejam confiáveis. Esse processo é feito por meio de correlações baseadas em parâmetros físicos definidos pelo operador observadas na Figura 12 (Araújo, 2009). No caso da pele humana, a emissividade é próxima de 0,98. Esses parâmetros são ajustados diretamente na câmera ou posteriormente nos softwares de análise (Reis et al., 2023).

Além da aquisição de imagens, a IRT permite também a obtenção de registros de informações de temperaturas em tempo real (método dinâmico), podendo ter aplicabilidade na análise de patologias corporais (Araújo, 2009). A Figura 13 apresenta um processo de registro de termogramas após o resfriamento da região onde foi usada a imersão dos dedos/mãos em água mantida em aproximadamente 15 °C. Apesar de ainda ser considerada uma metodologia complementar, a precisão da IRT vem sendo aprimorada com o avanço de algoritmos de processamento de imagem e modelagem térmica, tornando-a uma ferramenta potencialmente útil para o monitoramento da obesidade e de distúrbios metabólicos (Queiroz et al., 2016).

Figura 13. Diferentes termogramas para a região das mãos de paciente após processo de resfriamento. Da esquerda para a direita, tem-se os registros: imediatamente após o resfriamento; 3,5 min após o resfriamento; e 30 min após o resfriamento.



Fonte: Adaptado de Araújo (2009)

3.4. MODELOS MATEMÁTICOS ESTATÍSTICOS PARA ANÁLISE TERMOGRÁFICA

Além da prática de construção computacional de regiões do corpo humano para simulação e possível implementação dos mais diversos métodos de observação da composição corporal, há também a viabilidade de testes estatísticos nesse meio para atribuir uma validação matemática adequada à técnica empregada (Honório, 2025).

Neste tópico serão abordados os principais métodos estatísticos utilizados na literatura para a análise da adiposidade corporal: testes de normalidade; testes de correlação (paramétricos e não paramétricos); e métodos para visualização da distribuição de dados.

3.4.1. Testes de Normalidade

Modelos estatísticos são representações matemáticas de fenômenos ou processos, usados para analisar, explicar e prever comportamentos de variáveis a partir de dados observados (Razali e Wha, 2011). Eles atendem a certos pressupostos sobre a distribuição da população da qual a amostra foi retirada. O mais importante desses pressupostos é que os dados seguem uma distribuição específica, geralmente a distribuição normal.

A importância dos testes de normalidade está em garantir a validade e a confiabilidade das inferências estatísticas derivadas de diferentes procedimentos (Razali e Wha, 2011). Entre os testes de normalidade mais frequentes na literatura científica, destacam-se o teste de Shapiro-Wilk, o teste de Anderson-Darling e o teste de Kolmogorov-Smirnov.

3.4.1.1. Teste de Shapiro-Wilk (SW)

O teste de normalidade de Shapiro-Wilk (SW), proposto originalmente por Shapiro e Wilk (1965), constitui-se em um dos procedimentos estatísticos mais robustos e amplamente utilizados para avaliar a hipótese de que uma amostra provém de uma distribuição normal. O teste foi desenvolvido com o intuito de formalizar as informações visuais fornecidas por gráficos de probabilidade normal, condensando eventuais desvios da linearidade esperada em uma estatística única e objetiva (Razali e Wha, 2011).

De acordo com os autores originais deste teste, o valor estatístico W é definido como a razão entre o quadrado de uma combinação linear das estatísticas de ordem da amostra e a soma de quadrados dos desvios em torno da média amostral. Formalmente, para uma amostra de tamanho n ordenada $y_1, y_2, \dots, y_n$, o teste é dado pela Equação 8:

$$W = \frac{(\sum_{i=1}^n a_i y_i)^2}{(\sum_{i=1}^n (y_i - \bar{y}))^2}, \quad \text{com } a_i = \frac{m^T V^{-1}}{(m^T V^{-1} V^{-1} m)^{1/2}} \quad (8)$$

Conforme visto na equação acima, $\bar{y}$ é a média amostral e os valores do coeficiente a_i são calculados a partir da matriz de covariância dessas estatísticas de ordem (V) e os valores esperados das estatísticas de ordem de variáveis aleatórias independentes e identicamente distribuídas extraídas de uma distribuição normal padrão $(m_1, \dots, m_n)^T$. Essa formulação torna o teste invariante à escala e à origem, sendo, portanto, adequado para testar a hipótese composta de normalidade (Shapiro e Wilk, 1965). O valor de W varia entre 0 e 1, sendo que valores próximos de 1 indicam conformidade com a normalidade, enquanto valores significativamente menores indicam desvio dessa suposição.

A abrangência da aplicação do teste SW engloba uma vasta gama de aplicações, incluindo na área de anatomia e composição corporal. Bortoli et al. (2022) avaliaram 25 pacientes submetidos a cirurgia bariátrica, avaliados em três momentos (um mês antes, dois e seis meses depois da operação), verificando a distribuição dos dados por SW. Os autores utilizaram testes ANOVA (*Analysis Of Variance*) para as variáveis observadas com distribuição normal e o teste de Friedman para variáveis que rejeitaram a normalidade, comparando estimativas de percentual de gordura corporal por diferentes fórmulas antropométricas com valores obtidos pelo método de bioimpedância (BIA). Já Conti et al. (2025) aplicaram o teste de Shapiro-Wilk para checar a normalidade das variáveis contínuas de composição corporal separadamente por sexo, utilizando também a análise por variância nos casos de normalidade, porém aplicando o teste de Kruskal-Wallis para variáveis com distribuição diferente de normal.

3.4.1.2. Teste de Anderson-Darling (AD)

O teste de normalidade de Anderson-Darling (AD) é outra alternativa para verificar a normalidade em um conjunto de dados. Originalmente proposta por Anderson e Darling (1954), o teste AD parte da hipótese nula de que o conjunto de dados provém de uma população com distribuição normal (Equação 9) contra a hipótese alternativa (Equação 10):

$$H_0: F(x) = F_0(x), \quad \forall x \quad (9)$$

$$H_1: F(x) \neq F_0(x), \quad \text{para ao menos um valor de } x \quad (10)$$

Para as Equações 9 e 10, $F(x)$ representa a função de distribuição empírica dos dados amostrais e $F_0(x)$ a função de distribuição acumulada teórica da normal. Em um tamanho amostral n , o estatístico A^2 mede a discrepância quadrática ponderada entre essas duas funções:

$$A^2 = n \int_{-\infty}^{+\infty} \frac{[F(x) - F_0(x)]^2}{F_0(x)(1 - F_0(x))} (F_0(x)) dF_0(x) \quad (11)$$

O peso do termo denominador da Equação 11 confere maior sensibilidade às caudas da distribuição, tornando o teste mais eficaz na detecção de desvios de normalidade associados a valores extremos, característica que o diferencia de outros testes da classe de Funções de Distribuição Empírica (EDF) (Anderson e Darling, 1954). Conforme Razali e Wha (2011), uma forma discreta utilizada na prática, especialmente em programação, é dada pela Equação 12 com $F_0(x_i)$ sendo o valor da função de distribuição normal teórica correspondente às observações ordenadas crescentemente (x_i) para um dado tamanho amostral n .

$$A^2 = -n - \frac{1}{n} \sum (2i - 1) \{ \log F_0(x_i) - \log(1 - F_0(x_{n+1-i})) \} \quad (12)$$

Além de sua relevância teórica, o teste de normalidade AD tem se mostrado uma ferramenta amplamente aplicável em estudos para assegurar a validade estatística das análises. Por exemplo, Palmas et al. (2024) avaliaram 174 pacientes com câncer colorretal e aplicaram o teste AD antes de decidir entre testes paramétricos ou não paramétricos na comparação de medições ultrassonográficas e tomográficas do músculo reto femoral. De forma semelhante, Fermín-Martínez et al. (2022) utilizaram o Anderson-Darling para examinar a normalidade de variáveis antropométricas e bioquímicas ao desenvolver um estimador de idade biológica, assegurando a robustez de modelos de regressão e análises de sobrevivência. Esses estudos ilustram como o teste AD contribui para a validade das análises estatísticas em diferentes contextos, como clínicos e epidemiológicos por exemplo.

3.4.1.3. Teste de Kolmogorov-Smirnov (KS)

Originalmente idealizado por Kolmogorov (1939) e posteriormente aprimorado por Smirnov (1939), o teste de normalidade Kolmogorov-Smirnov (KS), em termos práticos, mede a diferença máxima entre a distribuição acumulada dos dados observados e a distribuição acumulada teórica esperada. Formalmente, para uma amostra aleatória de tamanho n , com valores ordenados $x_1 \leq \dots \leq x_n$, a estatística T é calculada conforme a Equação (13):

$$T = \sup_x |F^*(x) - F_n(x)| \quad (13)$$

onde:

$F^*(x)$ = Função de Distribuição Hipotética (*Hypothesized Distribution Function*, HDF);

$F_n(x)$ = Função de Distribuição Empírica (*Estimated Distribution Function*, EDF);

$\sup_x$ = “Supremo” (maior diferença absoluta observada).

O teste KS padrão assume que os parâmetros da distribuição teórica (média μ e desvio padrão σ) são conhecidos (Kolmogorov, 1939, e Smirnov, 1939). Contudo, quando os parâmetros são estimados a partir dos dados analisados, o teste pode ter baixo poder (precisão) e taxas de erro significantes. O teste de Lilliefors (LF) é uma versão modificada do KS que o adapta para situações onde μ e σ são estimados a partir da amostra (Razali e Wha, 2011).

Mesmo sendo inferior ao teste de SW, o teste KS apresenta grande aplicabilidade. O estudo de Sena et al. (2022), por exemplo, forneceu valores de referência (percentis) para classificar a adiposidade em adolescentes utilizando o teste KS para confirmar a normalidade nas amostras de dados. Posteriormente, os autores confirmaram a correlação entre as medidas antropométricas e gordura corporal medida, encontrando através do teste de Pearson uma relação diretamente proporcional entre o percentual de massa adiposa e IMCs mais elevados.

3.4.2. Testes de Correlação Estatística

A implementação de testes estatísticos em pesquisas científicas é essencial para conferir rigor metodológico, validar hipóteses e garantir a confiabilidade inferencial dos resultados (Razali e Wha, 2011). A escolha do tipo de teste (paramétricos ou não paramétricos) depende da natureza dos dados (contínuos, ordinais, independentes ou pareados), do cumprimento de pressupostos estatísticos (como normalidade e variância homogênea), do tamanho da amostra e da presença de possíveis *outliers* ou valores atípicos (Intellectus Statistics, 2025).

Testes paramétricos assumem distribuições específicas (geralmente normal) e tendem a ser mais poderosos quando os pressupostos são atendidos. Em cenários que violam esses pressupostos ou com dados em escala ordinal ou distribuição desconhecida, aplicam-se os testes não paramétricos (Marshall, s.d.). Os testes não paramétricos não dependem de pressupostos sobre a forma da distribuição dos dados, baseando-se em classificações ou postos, o que os torna adequados para variáveis ordinais ou nominais, ou ainda para conjuntos de dados que violam a normalidade. Além disso, o objetivo analítico influencia a escolha do tipo de teste a ser empregado (comparar médias, investigar associações ou diferenças entre grupos, investigar variáveis dependentes e independentes, por exemplo). A decisão não se baseia apenas na normalidade, mas também em variância, amostragem, tipo de escala e margem de estudo (independente ou pareado). Assim, conhecer os pressupostos e a finalidade do teste é essencial para selecionar o procedimento estatístico apropriado (Intellectus Statistics, 2025).

3.4.3. Métodos para Visualização da Distribuição de Dados


Além dos testes estatísticos, as representações gráficas (*box-plots*, histogramas, Q-Q plots, curvas KDE, etc) auxiliam na identificação de padrões, assimetrias, multimodalidades e *outliers* que podem comprometer interpretações, sendo também fundamentais para a análise científica (Thrun, Gehlert e Ultsch, 2020). Essas ferramentas facilitam o reconhecimento de propriedades como normalidade, dispersão e presença de múltiplos processos geradores dos dados. Conforme Marshall (s.d.), a etapa exploratória deve anteceder os testes paramétricos ou não paramétricos, garantindo que os pressupostos de normalidade e variância sejam atendidos.

A escolha do tipo de visualização depende da natureza do conjunto de dados, do tamanho da amostra e dos objetivos analíticos. O uso inadequado de parâmetros pode gerar interpretações equivocadas (Thrun, Gehlert e Ultsch, 2020). Dessa forma, a combinação de métodos gráficos e estatísticos amplia a precisão e o rigor das inferências científicas.

4. METODOLOGIA

A metodologia deste trabalho se baseia em uma sequência de atividades semelhantes às já apresentadas na literatura por Araújo (2009), Bezerra et al. (2012) e Queiroz et al. (2023). Serão escolhidas imagens termográficas de pacientes integrantes do Banco de Imagens Termográficas de Mama da UFPE. A seguir, apresenta-se o fluxograma que se pensa ser adequado para finalizar a presente proposta (Figura 14). Esse processo combina duas vertentes principais: a primeira focando na análise do percentual de gordura mamária através de um programa para segmentação de possíveis regiões de gordura nas imagens selecionadas; e um segundo procedimento voltado à implementação de métodos estatísticos com intuito de correlacionar e comparar dados obtidos entre as pacientes estudadas.

Figura 14. Fluxograma com a visão geral idealizada para a metodologia deste trabalho.




Fonte: Autor (2025)

Apresentam-se agora as ferramentas computacionais usadas e/ou desenvolvidas para visualização das etapas acima. A aquisição das imagens (já existentes) foi realizada no Hospital das Clínicas da Universidade Federal de Pernambuco (HC-UFPE) utilizando uma câmera termográfica da marca FLIR Systems, modelo ThermaCAM™ S45 que dispõe de detector do tipo matriz de plano focal (FPA), resolução 320x240 pixels e a amplitude de temperaturas utilizada for de -10°C a +55°C. Nesse processo, foram seguidas as normas especificadas para captura em ambientes monitorados, com temperatura ambiente e distância entre o indivíduo e a câmera devidamente anotados, onde os registros termográficos foram obtidos conforme o protocolo estabelecido por Oliveira (2012). Para o processamento das imagens selecionadas foi realizado um tratamento por meio do *software* FLIR Tools, para extração das matrizes de temperaturas em uma planilha no formato Excel (.csv). Nesse método, cada pixel da imagem se converte em um elemento da matriz que armazena o respectivo valor numérico da temperatura naquele pixel.

A fim de exemplificar o tipo de dado termográfico utilizado ao longo do estudo, apresentam-se, no Apêndice G, imagens IRT correspondentes a cada participante avaliada, organizadas em ordem crescente de idade e acompanhadas de informações referentes à presença ou ausência de patologias mamárias descritas em seus respectivos históricos de prontuário clínico. O conjunto total é composto por imagens de 17 pacientes e 3 voluntárias, sendo todas pacientes identificadas exclusivamente por códigos numéricos. Ressalta-se que os nomes das participantes não foram divulgados e que os números de prontuário foram parcialmente omitidos, de modo a preservar o anonimato e a confidencialidade das informações, em conformidade com os princípios éticos aplicáveis à pesquisa envolvendo seres humanos. Já as três voluntárias presentes foram admitiram a titulação de “Voluntária” conforme a idade em ordem crescente.

A Figura 15 ilustra exemplos de imagens termográficas infravermelhas utilizadas neste trabalho correspondentes a duas voluntárias classificadas como saudáveis, identificadas como ‘Voluntária 2’ (à esquerda) e ‘Voluntária 3’ (à direita). Ambas as imagens foram adquiridas em vista frontal da região torácica e abdominal seguindo o processo já mencionado, apresentando a distribuição espacial da temperatura superficial da pele por meio de uma escala cromática. Assim, os tons mais claros indicam regiões de maior temperatura e tons mais escuros representam regiões de menor temperatura. Para a Voluntária 3, observa-se a presença do cursor de medição posicionado na região da prega inframamária, com o objetivo de evidenciar o valor pontual de temperatura superficial registrado naquele local, igual a 35,8 °C, associado a um tom mais claro, próximo ao branco, na escala termográfica aplicada.

Figura 15. Imagem IRT para as Voluntária 2 (à esquerda) e Voluntária 3 (à direita).



Fonte: Autor (2025)

Ressalta-se que, durante a coleta dos registros termográficos, foram selecionadas as imagens do banco de dados utilizado onde as participantes permaneceram com os braços erguidos, conforme parte do protocolo de exame, o que pode ocasionar o deslocamento natural do tecido mamário e, conseqüentemente, a modificação da conformação anatômica da mama, especialmente na região inframamária. Contudo, essa posição favoreceu um maior contraste térmico entre o contorno corporal e o ambiente ao fundo, possibilitando segmentações mais precisas referentes à delimitação da forma das mamas e do abdômen.

Quanto ao código desenvolvido, a ferramenta de programação fornecida pela *Python Software Foundation* (PSF), criada por Guido van Rossum em 1991, foi utilizada para desenvolver o código de segmentação das imagens. Tal escolha foi realizada pois a linguagem aberta Python incorpora práticas computacionais de alto nível em aplicações de propósito geral, sendo amplamente reconhecida por sua simplicidade e legibilidade, além de ser versátil em áreas científicas que envolvam sistemas neurais, análise estatística e processamentos complexos.

Com tal ferramenta aplicada à interface gratuita de IDE (*Integrated Development Environment*) nomeada PyCharm Community (edição 2024.2.3), fornecida pela companhia JetBrains, foi criado um código computacional capaz de tratar as imagens termográficas adquiridas, reconstruindo as matrizes de temperatura para analisar regiões específicas, a partir da sua variação de temperatura. Conforme a Figura 16, o código idealizado para este trabalho foi dividido em duas etapas principais: a análise estatística dos dados coletados para a comparação entre as regiões de interesse de cada paciente (mamas e abdômen); e a segmentação das termográficas utilizando limares de temperatura.

4.1. ESTIMATIVA DA ADIPOSIDADE POR LIMIAR DE TEMPERATURA


Esta etapa metodológica é referente à segmentação das imagens termográficas das mamas, processo fundamental para a identificação e isolamento das regiões de interesse (ROIs) com diferentes padrões térmicos, potencialmente relacionados à presença de tecido adiposo. Nesta parte do procedimento deste trabalho também foi aplicado a primeira funcionalidade do código de algoritmo próprio desenvolvido em linguagem Python, para manipular e analisar as matrizes de temperatura obtidas das imagens por infravermelho previamente convertidos em planilhas no formato ‘.csv’.

Adicionalmente, durante o processo de segmentação, foram avaliados critérios baseados em limiares estatísticos derivados da própria distribuição térmica dos dados, incluindo limiares definidos por percentis. Dessa forma, optou-se por uma abordagem adaptativa, fundamentada em medidas de tendência central (média, mediana e moda) e na distribuição estatística das temperaturas observadas em cada região segmentada, assegurando maior compatibilidade entre o método de segmentação e o perfil das participantes avaliadas. Essa escolha visou minimizar vieses associados à aplicação de parâmetros externos e reforçar a consistência interna dos resultados obtidos. Ressalta-se que alguns percentuais de limiar previamente empregados na literatura, como aqueles adotados no estudo de Sena et al. (2022), não foram aplicados neste trabalho, pois eram adaptados para grupos populacionais e faixas etárias fora da margem analisada no presente estudo.

Assim, no primeiro passo da análise computacional desta etapa, ao abrir uma imagem, o autor tem acesso às informações dos valores de temperatura máxima e mínima da imagem, sendo possível definir um limiar para excluir as seções que apresentem valores inferiores ao valor estabelecido. Posteriormente, são selecionadas ROIs para observação por meio de elipses (nas mamas) ou retângulos (no abdômen), moldáveis de modo a extrair as informações de cada região. Isso permite a obtenção de informações como o número de pixels presentes na região e os pontos de temperatura mínima e máxima, possibilitando a definição de limiares adicionais para observar as segmentações com temperaturas iguais ou superiores ao valor inserido, assim como aquelas com temperaturas inferiores.

A Figura 16 apresenta um exemplo de imagem aberta através do código produzido, onde ao passar o cursor do *mouse* sobre a imagem é possível observar no canto inferior direito da janela informações, tais como a exata posição do pixel no ponto onde o cursor está posicionado (próximo ao corpo da paciente) como também seu respectivo valor de temperatura.


Figura 16. Exemplo de imagem carregada no código desenvolvido apresentando informações de posição e valor da temperatura para um dado ponto (pixel).



Fonte: Autor (2025)

Após a visualização e pré-processamento assistido da imagem, é então realizado o passo seguinte, onde é fixado um valor de temperatura limiar (sendo 31,0 °C neste exemplo) para remover seções da imagem original irrelevantes à análise (Figura 17).


Figura 17. Região extraída para valores superiores ao limiar (esquerda) e imagem original (direita).



Fonte: Autor (2025)

A Figura 18 demonstra uma situação onde é necessária a rotação da imagem para ajustar a máscara da elipse corretamente à forma da mama e obter a segmentação desejada, onde o resultado dessa execução armazena a informação final para a rotação da imagem.

Figura 18. Seleção da ROI na máscara da elipse (esquerda) e segmentação obtida para a ROI (direita).



Fonte: Autor (2025)

Essa metodologia garante que a seleção da área de estudo ocorra de forma controlada e reprodutível, eliminando ruídos e distorções térmicas oriundas do entorno corporal. Após a extração das máscaras geométricas ajustáveis para delimitar cada região individualmente, as imagens segmentadas foram armazenadas em diretórios específicos para o uso nos testes estatísticos e, posteriormente, foram usadas pela última etapa do método de segmentação para estimar o percentual de área adiposa na região.

Ao final da análise foram estabelecidos limiares de temperatura partindo de medidas de tendência central (média, mediana e moda) para cada seção salva, com o intuito de estimar a possível proporção de áreas frias e quentes dentro da ROI. Foi criada a Tabela 4 para referência do percentual médio de tecido mamário não glandular a partir das relações estabelecidas por Viana (2016) na Tabela 2.

Tabela 4. Relação entre idade e percentual médio de tecido mamário não glandular (%) em mulheres.

Faixa etária por percentual	Percentual médio de tecido mamário não glandular (%)
<i>Até 25 anos</i>	~10,0%
<i>Entre 26 e 35 anos</i>	~15,0%
<i>Entre 36 e 45 anos</i>	~22,5%
<i>Entre 46 e 60 anos</i>	~37,0%
<i>Entre 61 e 75 anos</i>	~62,5%
<i>Acima de 75 anos</i>	~75,0%

Fonte: Autor (2025)

4.2. ANÁLISE ESTATÍSTICA

A etapa estatística deste estudo tem por objetivo assegurar a validade e a robustez das inferências obtidas a partir das temperaturas extraídas das imagens termográficas. Para tanto, foram aplicados testes de normalidade como os de Shapiro–Wilk (SW), Anderson–Darling (AD) e Kolmogorov–Smirnov (KS), previamente discutidos na fundamentação teórica. A aplicação desses testes justifica-se pela necessidade de verificar se os dados seguem uma distribuição normal, uma vez que grande parte dos procedimentos estatísticos paramétricos pressupõe essa condição. Caso a normalidade seja rejeitada, opta-se por testes não paramétricos, como indicado por Marshall (s.d.) e Intellectus Statistics (2025), garantindo a coerência metodológica e o rigor analítico das comparações.

Cada teste possui uma estatística própria, responsável por mensurar o grau de desvio entre a distribuição empírica observada e a distribuição teórica esperada. O estatístico de teste, portanto, é uma medida quantitativa da discrepância, enquanto o p-valor (*p-value*) indica a probabilidade de que tal discrepância ocorra ao acaso, sob a hipótese nula de normalidade. Em termos práticos, valores de p elevados (geralmente superiores a 0,05) indicam que não há evidência suficiente para rejeitar a hipótese nula, enquanto valores inferiores a esse limite sugerem que os dados não seguem uma distribuição normal (Razali e Wha, 2011).

Já o nível de significância (α) representa o limiar adotado para a rejeição da hipótese nula, expressando a probabilidade máxima de erro tipo I, isto é, a chance de rejeitar incorretamente uma hipótese verdadeira (Conti et al., 2025). Neste trabalho, será adotado $\alpha = 0,05$, valor amplamente utilizado em estudos biomédicos e de engenharia, conferindo equilíbrio entre sensibilidade e especificidade na decisão estatística (Intellectus Statistics, 2025). Assim, quando o $p\text{-value} \leq \alpha$, conclui-se que há evidência estatística para rejeitar a normalidade; caso contrário, admite-se que os dados se ajustam à distribuição normal.

Conforme Honório (2025), para uma análise indutiva/inferencial de dados coletados para comparação entre exatamente dois conjuntos de variáveis quantitativas (as temperaturas entre duas mamas, por exemplo) não pareadas (os elementos de cada mama são independentes) existem duas possibilidades de implementação de testes estatísticos: o Teste t para grupos independentes (para conjuntos paramétricos) e o Teste de Mann-Whitney (para conjuntos não paramétricos). Assim, o principal critério para seleção de qual modelo estatístico deve ser aplicado neste trabalho será a validação ou não da normalidade nos conjuntos observados. Isso é adequado pois, diferente dos testes paramétricos, em testes não-paramétricos não podem ser utilizados parâmetros como média e desvio-padrão para comparação entre as populações, uma

vez que a distribuição dos dados nesses casos não obedecem às relações matemáticas esperadas com a média e o desvio-padrão (Marshall, s.d.).

Dessa forma, foi idealizado para esta etapa do estudo o desenvolvimento de um código computacional (em linguagem Python) do qual trata o conjunto de dados coletados para cada região observada através dos testes de normalidade SW, AD e KS e, a partir dessa verificação, é posteriormente implementado o teste estatístico apropriado.

A análise da normalidade foi acompanhada por avaliações visuais complementares, utilizando histogramas, gráficos Q–Q (quantil–quantil) e *box-plots* quando possível, a fim de identificar possíveis outliers que pudessem comprometer a consistência dos resultados. Para isso, foram utilizados diferentes pacotes da linguagem Python, especificamente o NumPy (versão 2.2.2) para a manipulação de *arrays* numéricos e operações matemáticas, o Pandas (versão 2.3.3) para a análise e organização de dados tabulares, o Matplotlib (versão 3.10.8) para a criação e visualização de gráficos, e o SciPy (versão 1.17.0) para a implementação de funções científicas e estatísticas. Dessa forma, foi possível reproduzir curvas normais teóricas e curvas de Estimativa de Densidade Kernel (*Kernel Density Estimation – KDE*) sobre os histogramas dos dados, permitindo uma comparação direta entre a distribuição empírica e os modelos teóricos. A verificação da normalidade permitiu, portanto, uma seleção adequada dos testes estatísticos para a comparação entre grupos de diferentes regiões de uma mesma paciente ou entre a mesma região em pacientes distintas, bem como o delineamento de possíveis correlações entre as temperaturas medidas e parâmetros de composição corporal.

Ademais, a interpretação dos resultados para os testes de normalidade foi realizada levando-se em consideração o tamanho amostral. Há a possibilidade dos testes mencionados apresentarem comportamentos distintos conforme a quantidade de observações disponíveis, podendo, em amostras reduzidas, não detectar desvios relevantes ou, em amostras extensas, identificar diferenças estatisticamente significativas, porém de baixa relevância prática.

Entretanto, nos conjuntos de dados analisados, os testes de normalidade aplicados indicaram, de forma consistente, a rejeição da hipótese de normalidade em todos os casos avaliados, apresentando p-values inferiores ao nível de significância adotado. Em função dessa evidência estatística convergente, optou-se pela utilização de métodos não paramétricos nas análises inferenciais subsequentes, garantindo a adequação do modelo estatístico às características observadas dos dados. Dessa forma, a interpretação dos resultados não se restringiu exclusivamente à significância estatística, sendo também considerada a magnitude das diferenças observadas (por meio de *Box-Plots* e análise das medidas de tendência central), com o objetivo de conferir maior robustez e significado prático às conclusões obtidas.

5. RESULTADOS E DISCUSSÃO


Neste capítulo são apresentados os resultados obtidos a partir das etapas metodológicas descritas, abrangendo a análise estatística das distribuições de temperaturas extraídas das imagens termográficas e o processo de segmentação térmica baseado na aplicação de limiares.

Foram selecionadas 17 pacientes integrantes do Banco de Imagens Termográficas de Mama da UFPE, e 3 voluntárias adicionais. Nenhuma participante apresentava patologias mamárias graves registradas nos exames avaliados, condição necessária para minimizar interferências nos padrões térmicos analisados. Assim, foi possível correlacionar os resultados entre diferentes pacientes sem a influência de alterações térmicas decorrentes de processos patológicos. As matrizes de temperaturas das imagens foram tratadas por códigos computacionais criados neste trabalho, responsáveis pelo processo de análise em cada etapa.

5.1. RESULTADOS OBTIDOS PELOS TESTES ESTATÍSTICOS

A etapa da análise estatística deste trabalho foi primeiramente conduzida pela aplicação dos testes de normalidade SW, AD e KS em cada ROI, utilizando o código computacional apresentado no do Apêndice B. O Gráfico 3 ilustra um exemplo das informações obtidas para os histogramas da mama direita (à esquerda) e mama esquerda (à direita) para a Voluntária 3, sendo possível comparar a suavização KDE dessa distribuição com a curva normal teórica.


Gráfico 3. Histograma e curva normal teórica para a região da mama direita (à esquerda) e mama esquerda (à direita) da Voluntária 3.



Fonte: Autor (2025)

O Gráfico 4 compara os *boxplots* das duas regiões, onde os quartis são mais estreitos na mama direita (à esquerda), indicando menor dispersão entre os valores centrais, porém com *outliers* na parte superior. Na mama esquerda (à direita), a caixa é maior, indicando um intervalo interquartilício maior, ou seja, a distribuição central é um pouco mais dispersa.


Gráfico 4. Bloxplots da mama direita (à esquerda) e da mama esquerda (à direita) da Voluntária 3.



Fonte: Autor (2025)

O uso desses testes distintos justifica-se pelas diferenças no tamanho das amostras e na distribuição dos valores de temperatura extraídos das diferentes regiões analisadas, pois cada método apresenta sensibilidades específicas a desvios. Contudo, o teste não paramétrico de Mann-Whitney foi implementado pois nenhuma das amostras de dados indicou normalidade. O código computacional no Apêndice C aplicou esse teste para verificar se havia diferença estatisticamente significativa entre os valores de temperatura das ROIs distintas. O exemplo do Gráfico 5 apresenta a sobreposição realizada para verificar a correlação entre ROIs.

Gráfico 5. Exemplo de comparação entre as distribuições das curvas KDE das mamas da Voluntária 3.



Fonte: Autor (2025)

A Tabela 5 apresenta de forma completa os resultados das correlações entre mama direita e mama esquerda (MD x ME), mamas e abdômen (MMs x ABD), mama direita e abdômen (MD x ABD) e mama esquerda e abdômen (ME x ABD) de cada paciente. As seções com “Não” correspondem aos cenários onde a correlação foi rejeitada pelo teste não paramétrico e as correlações confirmadas dessa maneira foram destacadas com “Sim”.

Tabela 5. Relação dos resultados de correlação entre ROIs para as pessoas estudadas.

Paciente (Prontuário)	Idade (anos)	Correlação entre as regiões analisadas			
		MD x ME	MMs x ABD	MD x ABD	ME x ABD
1*****4-5	67	Não	Não	Não	Não
1*****5-0	64	Não	Não	Não	Não
1*****4-1	62	Não	Não	Não	Não
1*****5-3	58	Não	Não	Não	Sim
1*****6-5	58	Não	Não	Não	Não
1*****6-5	57	Não	Não	Não	Não
1*****7-9	56	Não	Não	Não	Não
1*****1-0	55	Não	Não	Não	Não
1*****6-8	52	Não	Não	Não	Não
1*****6-3	52	Não	Não	Sim	Não
1*****6-8	47	Não	Não	Não	Não
1*****8-3	42	Não	Não	Não	Não
1*****0-1	40	Não	Não	Não	Não
1*****3-1	40	Não	Não	Não	Não
1*****8-0	34	Não	Não	Não	Sim
1*****5-7	29	Não	Não	Não	Não
1*****8-5	25	Sim	Não	Não	Não
Voluntária 1	48	Não	Não	Não	Não
Voluntária 2	49	Não	Não	Não	Não
Voluntária 3	50	Não	Não	Não	Não

Fonte: Autor (2025)

Embora o mesmo teste ter sido aplicado para todos os casos, apenas quatro situações resultaram em correlações positivas entre as regiões comparadas das quais não apresentaram consistência entre si. O teste também foi realizado para verificar a correlação entre a mesma região de duas participantes diferentes, mas todos os resultados recusaram essa hipótese.

5.2. RESULTADOS OBTIDOS POR LIMIARES E SEGMENTAÇÃO

Para a outra abordagem realizada neste trabalho foi empregada com o objetivo de determinar a proporção entre áreas classificadas como "frias" e "quentes", conforme a distribuição térmica presente na ROI analisada. Foram utilizados limiares por medidas de tendência central (média, mediana e moda) e por percentis (a partir da literatura), além de uma etapa de segmentação automática utilizando o método de Mistura de Gaussianas (*Gaussian Mixture Model – GMM*). Para tal, foi modelado o código computacional do Apêndice A destinado à extração e segmentação das regiões de interesse.

Após a definição do valor de referência, o algoritmo separou automaticamente a imagem em duas regiões principais: uma região de temperaturas iguais ou inferiores ao limiar, potencialmente associadas a tecido adiposo; e outra região de temperaturas superiores ao limiar, possivelmente vinculadas a tecido glandular ou áreas mais vascularizadas. Esse método é viável pois o tecido glandular apresenta maior densidade que o tecido adiposo, proporcionando temperaturas superiores em regiões onde há menor acúmulo de gordura. Posteriormente comparou-se as segmentações para diferentes limiares aplicados. O Gráfico 6 apresenta o modelo de saída nesta etapa correspondente a segmentação obtida a partir da mama direita da Voluntária 3. Nota-se a distribuição de temperaturas e suas respectivas frequências na ROI, além das informações destacadas para os valores de máximo, mínimo, mediada e limiar inserido neste caso. Já Figura 19 compara as diferentes segmentações obtidas para a região mencionada a partir dos diferentes limiares utilizados neste estudo.

Gráfico 6. Histograma e valores de temperaturas para a mama direita da Voluntária 3.





Figura 19. Segmentações obtidas para diferentes limiares aplicados na mama direita da Voluntária 3.




Fonte: Autor (2025)

Além da observação por limiares de temperaturas houve também a adição de um processo de segmentação automática, implementada como uma etapa opcional de análise complementar baseada no modelo probabilístico conhecido por *Gaussian Mixture Model* (GMM). Tal método permite identificar automaticamente agrupamentos (*clusters*) das temperaturas com comportamento estatístico semelhante dentro das regiões de interesse (ROIs).

No código computacional desenvolvido, essa função recebe como entrada o vetor de valores de temperatura determinada pela ROI e o número de clusters definido pelo usuário. Como neste trabalho foi comparada apenas a distribuição de zonas de maior e menor temperaturas. Em todos os casos foi aplicada a existência de apenas 2 clusters, para distinguir as porções mais “frias” das mais “quentes” em cada ROI.

Cada componente do modelo é uma distribuição normal unidimensional ajustada aos dados, representando um possível agrupamento natural dentro da amostra (por exemplo, regiões mais frias e regiões mais quentes da mama). Assim, no pré-processamento dos dados os valores de temperatura válidos são reorganizados em formato vetorial (coluna única), conforme exigido pela biblioteca *scikit-learn* disponível no Python, que realiza o ajuste do modelo probabilístico. Internamente, o GMM utilizou o algoritmo *Expectation-Maximization* (EM), que estima os parâmetros de cada componente gaussiano (médias, variâncias e pesos relativos) de modo a maximizar a probabilidade total dos dados observados. Após o ajuste, cada valor de temperatura foi atribuído ao componente gaussiano mais provável, gerando um rótulo de *cluster* (*labels*) que indica a qual grupo cada pixel pertence. Para a visualização desses resultados, os grupos identificados são plotados sobre o histograma de temperaturas da ROI, com linhas verticais indicando os valores médios e limites pontilhados (mínimo e máximo) de cada *cluster*. O Gráfico 7 apresenta a separação e os limites de cada *cluster* para a distribuição de temperaturas no histograma relacionado à mama direita da Voluntária 3.


Gráfico 7. Histograma e limites de temperatura dos clusters para a mama direita da Voluntária 3.



Fonte: Autor (2025)

Além da relação dos grupos obtidos na distribuição dos dados, esses rótulos gerados são aplicados de volta à máscara da ROI, criando um mapa espacial na forma de uma imagem colorida onde cada cor representa um *cluster* distinto. Essa representação espacial pode ser evidenciada na Figura 20 dentro da área analisada para a mama direita da Voluntária 3, além do gráfico de quantis (QQ-Plot) que confirmou a heterogeneidade dos dados com base numa linha de referência.

Figura 20. Relações gráficas da divisão dos *clusters* pelo método automático (à esquerda) e dispersão dos dados no *QQ-Plot* com linha de referência (à direita) para a mama direita da Voluntária 3.



Fonte: Autor (2025)


Após essa análise, as informações obtidas foram organizadas em tabelas individuais para cada participante deste estudo, conforme o exemplo da Tabela 6 para a Voluntária 3, onde são apresentados os quatro tipos de análises realizadas por limiares de temperatura.

Tabela 6. Relação dos limiares de temperatura e respectivos percentuais para a Voluntária 3.

Análise 1 (limiar: média)			
Região	Temperatura	Parcela Superior	Parcela Inferior
Mama Esquerda	32,97°C	61,65%	38,35%
Mama Direita	33,49°C	30,19%	69,81%
Abdômen	33,15°C	32,16%	67,84%
Análise 2 (limiar: mediana)			
Região	Temperatura	Parcela Superior	Parcela Inferior
Mama Esquerda	33,23°C	50,03%	49,97%
Mama Direita	33,13°C	49,80%	50,20%
Abdômen	32,49°C	50,07%	49,93%
Análise 3 (limiar: moda)			
Região	Temperatura	Parcela Superior	Parcela Inferior
Mama Esquerda	33,69°C	24,87%	75,13%
Mama Direita	31,82°C	96,74%	3,26%
Abdômen	31,65°C	82,79%	17,21%
Análise 4 (limiar: percentil – 37,00%)			
Região	Temperatura	Parcela Superior	Parcela Inferior
Mama Esquerda	32,90°C	63,12%	36,88%
Mama Direita	32,81°C	63,16%	36,84%
Abdômen	32,14°C	63,06%	36,94%

Fonte: Autor (2025)

Para título de comparação, esses resultados ainda foram contrastados com as porcentagens de mulheres com alta e baixa densidade de tecido mamário em função da faixa etária presentes na Figura 1, contudo também não foram evidenciadas relações entre os percentuais. Foram produzidos gráficos para a melhor visualização comparativa entre as parcelas ‘frias’ e ‘quentes’ das ROIs a partir dos limiares, conforme o Gráfico 8 que compara essas parcelas para as três regiões estudadas no caso da Voluntária 3.



Fonte: Autor (2025)

A Tabela 7 descreve a temperatura média e o respectivo percentual da parcela de maior e menor temperatura obtidos pelos *clusters* das ROIs da Voluntária 3 através do método de GMM utilizado. Devido a ausência de dados antropométricos nos prontuários médicos das pacientes, adotou-se a sigla AVGA (Áreas Visíveis de Gordura Acumulada) para distinguir participantes com excesso significativo de massa adiposa daquelas visualmente mais magras.


Tabela 7. Relação dos resultados obtidos por GMM para as ROIs da Voluntária 3.

Análise por GMM - Voluntária 3 - 50 anos (AVGA)		
Região	Temperatura Média (°C) e Porcentagem (%)	
Mama Esquerda	Parcela Superior	Parcela Inferior
	33,57°C (63,87%)	32,37°C (36,13%)
Mama Direita	Parcela Superior	Parcela Inferior
	33,56°C (52,11%)	32,63°C (47,89%)
Abdômen	Parcela Superior	Parcela Inferior
	33,77°C (37,29%)	32,03°C (62,71%)

Fonte: Autor (2025)

Após aplicado o método das Tabelas 6 e Gráfico 8 para todas as participantes, estabeleceram-se a comparação entre o possível percentual de gordura local e a respectiva temperatura para cada limiar em ordem decrescente de idade (Figura 21). Em ambas representações, organizadas na Figura 21 para cada região analisada, foram dispostas as respectivas informações das participantes onde cada ponto das distribuições corresponde a uma participante, seguindo ordem decrescente por idade da esquerda para direita.

Figura 21. Comparações gráficas entre a distribuição das temperaturas (à direita) e dos percentuais (à esquerda) obtidas para as participantes analisadas utilizando os limiares empregados.




Fonte: Autor (2025)

Na Figura 21 apenas a mediana e os percentis mantiveram um padrão claro, sendo esperado pois seguem proporção já estabelecida. Nos gráficos dos *clusters* consideraram-se temperaturas que dividiam os agrupamentos “frios” dos “quentes” em cada caso.

Por fim foi realizada a correlação entre os dados do Apêndice G para as distribuições percentuais obtidas por cada método e a idade das pessoas estudadas, conforme o Apêndice D, por meio do teste de Spearman uma vez que ambas variáveis são quantitativas porém a distribuição de percentuais de temperatura segue uma distribuição não normal. O coeficiente de correlação de Spearman (ρ) mede a força e a direção da associação monotônica entre duas variáveis, isto é, se uma tende a aumentar ou diminuir conforme a outra aumenta (Honório, 2025). Diferente de outras correlações, esta não exige que a relação seja linear, apenas que siga uma tendência consistente (monotônica).

Assim, em cada caso foi produzida uma reta para aproximar a dispersão de dados. As distribuições por percentis apresentadas na Figura 22 foram utilizadas como referência para os demais (Apêndice H) pois foi confirmada sua correlação, contudo nenhuma outra situação para os outros limiares apontou uma possível correlação da distribuição com a idade.

Figura 22. Distribuições percentuais obtidas pelos limiares de percentis para as ROIs estudadas.



Fonte: Autor (2025)

5.3. DISCUSSÃO DOS RESULTADOS OBTIDOS

Sabe-se que a composição da mama se altera com a idade, num processo chamado de liposubstituição. Há também um aumento de gordura visceral com a idade. Porém, os resultados obtidos neste trabalho mostram que a distribuição de gordura corporal não é uniforme entre as diferentes regiões do corpo. Não foram observadas correlações diretas entre as temperaturas superficiais de áreas distintas, como mamas e abdômen. Essa constatação está em conformidade com diversos estudos citados (Wang et al., 2024; Oliveira et al., 2022; Salamunes et al., 2017; Jalil et al., 2019), os quais indicam que fatores anatômicos, hormonais e metabólicos influenciam de forma significativa nas variações térmicas locais.

A tentativa de correlacionar, por exemplo, a distribuição de temperaturas da região mamária com as do abdômen mostrou-se estatisticamente inconsistente, evidenciando que as variações de temperatura são específicas de cada indivíduo e dependentes da composição local. Isso sugere também que a variabilidade anatômica e fisiológica interfere diretamente na resposta térmica observada, inviabilizando a construção de um modelo de estimativa global a partir de uma única região corporal. Os resultados estatísticos apoiam isso, pois os testes de correlação aplicados nas regiões de interesse não indicaram associação significativa entre as porções de distribuição das áreas com temperaturas mais “frias” (possíveis áreas de maior adiposidade) e a idade das pacientes, a partir dos diversos limiares adotados, com exceção à tabela de referência adaptada de Viana (2016) que já relaciona as duas variáveis.

Apesar da aplicação das imagens termográficas do Banco de Imagens Termográficas de Mama da UFPE ter se consolidado na identificação de patologias mamárias por meio de simulação numérica, métodos estatísticos, redes neurais e implementação de inteligência artificial, não foi possível relacionar as temperaturas presentes nas imagens termográficas das mamas com a temperatura (devido à liposubstituição) e com a gordura abdominal. Embora útil para identificar padrões térmicos regionais, a IRT não se mostrou suficiente para estimar de forma confiável o percentual de gordura total ou localizada apenas por temperaturas superficiais, evidenciando a necessidade de dados anatômicos adicionais. Os testes de correlação não revelaram associações significativas entre idade, temperatura e gordura corporal, reforçando o caráter multifatorial da distribuição térmica. Nota-se que a gordura corporal é complexa, dinâmica e individualizada, dificultando a criação de modelos universais baseados apenas em IRT. Isso contribuiu no entendimento da aplicação biomecânica da técnica, destacando seu potencial como ferramenta complementar de triagem e monitoramento quando combinada a métodos estatísticos e modelos computacionais mais robustos.

5.4. SUGESTÕES PARA TRABALHOS FUTUROS

Com base na metodologia e nos resultados aqui obtidos, recomenda-se que estudos futuros ampliem a análise incorporando dados antropométricos (como peso, altura e circunferências corporais) e a verificação do percentual de gordura corporal de cada pessoa a ser estudada por métodos consagrados, como bioimpedância (BIA) ou análise cutânea. Esses dados permitirão validar estatisticamente as relações observadas entre temperatura superficial e adiposidade a partir das imagens por IRT, fortalecendo a confiabilidade dos resultados obtidos por testes de correlação e regressão.

Também se sugere a modelagem tridimensional das regiões de interesse em *softwares* especializados de CFD (como o ANSYS) para realizar simulações térmicas que possibilitem comparar o comportamento da temperatura na superfície do corpo humano e confrontar tais temperaturas simuladas com as registradas experimentalmente. Além disso, recomenda-se explorar o uso de técnicas de aprendizado de máquina (*machine learning*) para identificar padrões térmicos associados à gordura corporal, permitindo automatizar a análise das imagens termográficas e aprimorar a precisão na classificação das regiões de adiposidade.

Essas melhorias integrariam dados físicos, estatísticos e computacionais, tornando as futuras análises mais robustas e contribuindo para o avanço do uso da termografia por infravermelho como ferramenta complementar de avaliação da composição corporal.

REFERÊNCIAS

AL-NASER, Yousif A. e TAFTI, Dawood. CT instrumentation and physics. In: STATPEARLS [Internet]. Treasure Island (FL): StatPearls Publishing, 2022. Disponível em: <https://www.ncbi.nlm.nih.gov/books/NBK597347/>. Acesso em: 24 Jan. 2026.

ALESSANDRO, R. J. e PAULO E. C. Revisão dos processos físicos e técnicos de um exame de ressonância magnética. Revista FT, vol. 29, edição 141, 16 dez. 2024. DOI: 10.69849/revistaft/ar10202412161746. Disponível em: <https://revistaft.com.br/revisao-dos-processos-fisicos-e-tecnicos-de-um-exame-de-ressonancia-magnetica/>. Acesso em: 24 jan. 2026.

AMALRIC, R.; GIRAUD, D.; THOMASSIN, L.; ALTSCHULER, C.; SPITALIER, J. M.. Detection of subclinical breast cancers by infrared thermography. E. F. J. Ring & B. Phillips (Eds.), Recent Advances in Medical Thermology (pp. 575–579). Plenum Press/Springer, 1984. DOI: https://doi.org/10.1007/978-1-4684-7697-2_81

ANDERSON, T. W. e DARLING, D. A. A Test of Goodness of Fit. Journal of the American Statistical Association, 1954, 49(268), 765–769.

ARAÚJO, M. C. Utilização de Câmera por Infravermelho para Avaliação de Diferentes Patologias em Clima Tropical e Uso Conjunto de Sistemas de Banco de Dados para Detecção de Câncer de Mama. Dissertação (Mestrado em Engenharia Mecânica) - Universidade Federal de Pernambuco, Coordenação de Aperfeiçoamento de Pessoal de Nível Superior. Recife, 2009.

BARBOSA, V. A. F. Sistemas inteligentes baseados em deep-wavelet e redes neurais convolucionais para apoio ao diagnóstico de câncer de mama usando imagens termográficas. Tese (Doutorado em Engenharia Mecânica) - Universidade Federal de Pernambuco, Recife, 2022.

BERNARDES, A. Anatomia da mama feminina. In: OLIVEIRA, C. F. D. Manual de ginecologia. Lisboa, Portugal: Permanyer Portugal, v. II, 2011. Cap. 33, p. 167-174.

BEZERRA, L. A.; OLIVEIRA, M. M.; ROCHA, J. O. S.; ROLIM, T. L.; CONCI, AURA. LYRA, P. R. M.; LIMA, R. C. F. Padronização da aquisição de imagens termográficas para estimativa de parâmetros termofísicos de nódulos mamários. VII congresso Nacional de Engenharia Mecânica. CONEM 2012. São Luís - Maranhão - Brasil.

BEZERRA, L. A. Uso de imagens termográficas em tumores mamários para validação de simulação computacional. Dissertação (Mestrado) – Universidade Federal de Pernambuco. CTG. Programa de Pós-Graduação em Engenharia Mecânica . Recife, outubro de 2007.

BORCHARTT, T. B.; CONCI, A.; LIMA, R. C.; RESMINI, R.; SANCHEZ, A. Breast thermography from an image processing viewpoint: A survey. Signal Processing, Elsevier, v. 93, n. 10, p. 2785–2803, 2013.

BORGA, M. The role of imaging in obesity special feature: MRI adipose tissue and muscle composition analysis - a review of automation techniques. Department of Biomedical Engineering and Center for Medical Image Science and Visualization (CMIV), Linköping University, 2018.

BORTOLI, A. M.; BRITO, B. B.; NEVES, L. L. V.; ALMEIDA, R. L.; SANTOS, L.; BARAUNA, V. G.; HARAGUCHI, F. K. Body fat estimated by equations based on anthropometric parameters correlates with bioelectrical impedance in patients undergoing bariatric surgery. Journal of Human Growth & Development, v. 32, n. 3, set./dez. 2022.

CHUDECKA, M. e LUBKOWSKA, A. Thermal maps of young women and men. Infrared Physics & Technology, 2015.

CONTI, P. B. M.; PASCOA, M. A.; RIBEIRO, M. Â. G. O.; GOMEZ, C. C. S; SOUZA, A. P.; CASTILHO, T.; JUNIOR, G. G.; BORGLI, D. S. P.; SAKANO, E.; SEVERINO, S. D.; RIBEIRO, J. D. Assessment of body composition as a predictor of disease severity in patients with COVID-19. Jornal Brasileiro de Pneumologia, v. 51, n. 3, e20240414, 2025.

DAVIDSON, L. E.; WANG, J.; THORNTON, J. C.; KALEEM, Z.; SILVA-PALACIOS, F.; PIERSON, R. N.; HEYMSFIELD, S. B.; GALLAGHER, D. Predicting Fat Percent by Skinfolds in Racial Groups. Medicine & Science in Sports & Exercise, v. 43, n. 4, p. 652-658,

2011. DOI: 10.1249/MSS.0b013e3181ef3f07. Disponível em:
<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3308342/>

DURNIN, J. V. G. A.; WOMERSLEY, J. Body fat assessed from total body density and its estimation from skinfold thickness: measurements on 481 men and women aged from 16 to 72 years. *British Journal of Nutrition*, Cambridge, v. 32, n. 1, p. 77-97, 1974. DOI: 10.1079/BJN19740060.

FERMÍN-MARTÍNEZ, C. A.; MÁRQUEZ-SALINAS, A.; GUERRA, E. C.; ZAVALA-ROMERO, L.; ANTONIO-VILLA, N. E.; FERNÁNDEZ-CHIRINO, L.; SANDOAL-COLIN, E.; BARQUERA-GUEVARA, D. A.; MUÑOZ, A. C.; VARGAS-VÁZQUEA, A.; PAZ-CABRERA, C. D.; RAMÍREZ-GARCÍA, D.; GUTIÉRREZ-ROBLEDO, L. M.; BELLO-CHAVOLLA, O., Y. AnthroAge: a novel biological age estimator based on anthropometry and body composition. *medRxiv*, 2022. DOI: 10.1101/2021.09.23.21263703.

FLETCHER, S. J.; SACCA, P. A.; PISTONE-CREYDT, M.; COLÓ, F. A.; SERRA, M. F.; SANTINO, F. E.; SASSO, C. V.; LOPEZ-FONTANA, C. M.; CARÓN, R. W.; CALVO, J. C.; PISTONE-CREYDT, V. Human breast adipose tissue: characterization of factors that change during tumor progression in human breast cancer. Fletcher et al. *Journal of Experimental & Clinical Cancer Research*, 2017.

FRANK, A. P.; SANTOS, R. S.; PALMER, B. F.; CLEGG, D. J. Determinants of body fat distribution in humans may provide insight about obesity-related health risks. *Journal of Lipid Research*. Vol. 60, 2019.

FRED, Herbert L. Drawbacks and Limitations of Computed Tomography: Views from a Medical Educator. *Texas Heart Institute Journal*, v. 31, n. 4, p. 345–348, 2004. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC548232/>. Acesso em: 24 Jan. 2026.

GLOBAL CANCER OBSERVATORY (GCO). Cancer Today. International Agency for Research on Cancer, World Health Organization. Disponível em: <https://gco.iarc.fr/today/>. Acesso, jan. 2025.

HALLIDAY; RESNICK; WALKER. Fundamentos de Física - Gravitação, Ondas e

Termodinâmica - Volume 2. 10. ed. [S.l.]: LTC, 2016.

HOBBS, W. B. Thermography of the Breast - A Skin Organ. Thermal Assessment of Breast Health, MTP Press, Ltd. Lancaster, England, pp. 37-48, July, 1984.

HOGGING, D. E.; BACKDAHL, J.; THORELL, A.; RYDÉN, M.; ANDERSSON, D. P. Metabolic impact of body fat percentage independent of body mass index in women with obesity remission after gastric bypass. *Obesity Surgery* 30, 1086–1092 (2020).
<https://doi.org/10.1007/s11695-019-04304-6>.

HONÓRIO, H. M. Tutorial Estatístico Canal Pesquisa. Canal Pesquisa, 2022. Disponível em: <https://www.canalpesquisa.com.br/tutorial>. Acesso em: 04 Nov. 2025.

Intellectus Statistics. Choosing the Correct Statistical Test. Nursing Information Technology. Florida Atlantic University, 2025. Disponível em: <https://www.fau.edu/nit/training/intellectus/>. Acesso em: 09 Set. 2025.

International Atomic Energy Agency (IAEA). Dual Energy X-ray Absorptiometry for Bone Mineral Density and Body Composition Assessment. Vienna: International Atomic Energy Agency, 2010. (IAEA Human Health Series, No. 15). 147 p. ISBN 978-92-0-115110-3.

JACKSON, A. S.; POLLOCK, M. L. Generalized equations for predicting body density of men. *British Journal of Nutrition*, Cambridge, v. 40, n. 3, p. 497-504, dec. 1978. DOI: 10.1079/BJN19780152.

JALIL, B et al. A Pilot Study of Infrared Thermography Based Assessment of Local Skin Temperature Response in Overweight and Lean Women during Oral Glucose Tolerance Test. *Journal of Clinical Medicine*. 19 de Fevereiro de 2019.

JetBrains. Make it happen. With code. Disponível em: www.jetbrains.com/company/. Acesso, fev. 2025.

JIMENO, M. M.; VAUGHAN, J. T. e GEETHANATH, S. Superconducting magnet designs and MRI accessibility: a review. Cornell University, maio de 2022. Disponível em:

<https://arxiv.org/abs/2205.08918>. Acesso em: 24 jan. 2026.

JOHN, S.; STOCK, S.; CEREJO, R.; UCHINO, K. Brain imaging using mobile CT: current status and future prospects. *Journal of Neuroimaging*, v. 26, n. 1, p. 5–15, 2015. DOI: 10.1111/jon.12319. Disponível em: https://www.researchgate.net/publication/284559700_Brain_Imaging_Using_Mobile_CT_Current_Status_and_Future_Prospects . Acesso em: 24 Jan. 2026.

KARASTERGIOU, K.; SMITH, S. R.; GREENBERG, A. S.; FRIED, S. K. Sex differences in human adipose tissues – the biology of pear shape. *Biology of Sex Differences*, 2012. Disponível em: <http://www.bsd-journal.com/content/3/1/13>. Acesso em: Jun. 2025.

KHALIL, S. F.; MOHKTAR, M. S. e IBRAHIM, F. The Theory and Fundamentals of Bioimpedance Analysis in Clinical Status Monitoring and Diagnosis of Diseases. *Sensors (Basel)*, v. 14, p. 10895-10928, 2014. DOI: 10.3390/s140610895.

KING, H. H., CAYCE, C. T. e HERRIN, J. Thermography examination of abdominal area skin temperatures in individuals with and without focal-onset epilepsy. University of California San Diego School of Medicine, La Jolla, CA. Original Research, Elsevier Inc. 2017.

KORMAN, P.; KUSY, K.; STRABURZYNSKA-LUPA, A.; SILLERO-QUINTANA, M.; ZAREBSKA, E.; ZIELINSKI, J. Exploring the correlation of skin temperature and body composition in athletes undergoing exhaustive physical exercise. *Journal of Thermal Biology*, 2024.

KOTHARI, C.; DIORIO, C.; DUROCHER F. The Importance of Breast Adipose Tissue in Breast Cancer. The Importance of Breast Adipose Tissue in Breast Cancer. *International Journal of Molecular Sciences*. 11 de Agosto de 2020.

KÜSTNER, T.; HEPP, T.; FISCHER, M.; SCHWARTZ, M.; FRITSCHKE, A.; HÄRING, H. U.; NIKOLAOU, K.; BAMBERG, F.; YANG, B.; SCHICK, F.; GATIDIS, S.; MACHANN, J. Fully automated and standardized segmentation of adipose tissue compartments via deep learning in 3D whole-body MRI of epidemiologic cohort studies. *Radiology: Artificial*

Intelligence, v. 2, n. 6, e200010, 2020. DOI: 10.1148/ryai.2020200010

KYLE, U. G.; BOSAEUS, I.; DE LORENZO, A. D.; DEURENBERG, P.; ELIA, M.; GÓMEZ, J. M.; HEITMANN, B. L.; KENT-SMITH, L.; MELCHIOR, J. C.; PIRLICH, M.; SCHARFETTER, H.; SCHOLS, A. M. W. J.; PICHARD, C. Bioelectrical impedance analysis - Part I: review of principles and methods. *Clinical Nutrition*, v. 23, p. 1226-1243, 2004. DOI: 10.1016/j.clnu.2004.06.004.

LAFFAYE, G.; EPISHEV, V. V.; TETIN, I. A.; KORABLEVA, Y. B.; NAUMOVA, K. A.; ANTONENKO, E. V.; VAVILOV, V. P. Predicting body fat mass by IR thermographic measurement of skin temperature: a novel multivariate model. Taylor & Francis Group. *Quantitative InfraRed Thermography Journal*, 7 de agosto de 2019.

LIN, J.; YE, S.; KE, H.; LIN, L.; WU, X.; GUO, M.; JIAO, B.; CHEN, C.; ZHAO, L. Changes in the mammary gland during aging and its links with breast diseases. *Acta Biochim Biophys Sin - ABBS*, 2023. DOI: <https://doi.org/10.3724/abbs.2023073>.

LEWINE, H. E. Taking aim at belly fat Unlike fat parked on the hips and thighs, fat around the middle produces substances that can create serious health risks. Harvard Health Publishing, Harvard Medical School, 2024. Disponível em: https://www.health.harvard.edu/newsletter_article/taking-aim-at-belly-fat. Acesso em: 20 Abril, 2025.

LUBKOWSKA, A. e CHUDECKA, M. Thermal Characteristics of Breast Surface Temperature in Healthy Women. *International Journal of Environmental Research and Public Health*, 2021.

MACLEAN, M. T.; JEHangIR, Q.; VUJKOVIC, M.; KO, Y.; LITT, H.; BORTHAKUR, A.; SAGRAIYA, H.; ROSEN, M.; MANKOFF, D. A.; SCHNALL, M. D.; SHOU, H.; CHIRINOS, J.; DAMRAUER, S. M.; TORIGIAN, D. A.; CARR, R.; RADER, D. J.; WITSCHHEY, W. R. Quantification of abdominal fat from computed tomography using deep learning and its association with electronic health records in an academic biobank. Perelman School of Medicine, University of Pennsylvania, Philadelphia, PA, USA, 2020. DOI: <https://doi.org/10.1101/2020.09.22.20199844>.

MAIA, C. K. F.; FREITAS, G. M. D.; MONTEIRO, S. S. Anatomia da mama. In: RIBEIRO, R. C.; SALTZ, R. Cirurgia da mama: estética e reconstrutiva. Rio de Janeiro: Revinter, 2006. Cap. 1, p. 03-10.

MANGINE, G. T.; MCDOUGLE, J. M. e FEITO, Y. Relationships Between Body Composition and Performance in the High-Intensity Functional Training Workout “Fran” are Modulated by Competition Class and Percentile Rank. *Frontier Physiology*, 2022. 13:893771. DOI: 10.3389/fphys.2022.893771.

MARSHALL, E. The Statistics Tutor’s Quick Guide to Commonly Used Statistical Tests. StatsTutor Community Project. University of Sheffield, s.d. Disponível em: www.statstutor.ac.uk. Acesso em: 03 Nov. 2025.

MARUNOWSKI, K.; ŚWIĘTOŃ, D.; BZYL, W.; GRZYWIŃSKA, M.; KASZUBOWSKI, M.; BANDOSZ, P.; KHRICHENKO, D.; PISKUNOWICZ, M. MRI-derived subcutaneous and visceral adipose tissue reference values for children aged 6 to under 18 years. *Frontiers in Nutrition*, Lausanne, v. 8, e757274, 2021. DOI: 10.3389/fnut.2021.757274

MASOUDI, S.; ANWAR, S. M.; HARMON, S. A.; CHOYKE, P. L.; TURKBHEY, B.; BAGCI, U. Adipose Tissue Segmentation in Unlabeled Abdomen MRI using Cross Modality Domain Adaptation. *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, 2020.

MENDES, M. S.; SANTOS, I. S.; PONTEL, S. N.; ROSA, S. E.; MELLO, D. B. Correlação entre a Temperatura da Pele e a Composição Corporal: um estudo preliminar. *Pan American Journal Of Medical Thermology*, 2022.

MENECK, F.; SOUZA, L. V.; BRIOSCHI, M. L.; FRANCO, M. C. Emerging evidence for the opposite role of circulating irisin levels and brown adipose tissue activity measured by infrared thermography in anthropometric and metabolic profile during childhood. *Journal of Thermal Biology*, 2021.

MESSINA, C.; ALBANO, D.; GITTO, S.; TOFANELLI, L.; BAZZOCCHI, A.; ULIVIERI, F. M.; GUGLIELMI, G.; SCONFIENZA, L. M. Body composition with dual energy X-ray

absorptiometry: from basics to new tools. *Quantitative Imaging in Medicine and Surgery*, [S. l.], v. 10, n. 8, p. 1687-1698, 2020. DOI: 10.21037/qims.2020.03.02

MINISTÉRIO DA SAÚDE. Boletim Epidemiológico. Cenário da obesidade no Brasil. SECRETARIA DE VIGILÂNCIA EM SAÚDE E AMBIENTE. Vol. 55. 9 abr. 2024.

MOKHTARY, A.; KARAKATSANIS, A. e VALCHIS, A. Mammographic Density Changes over Time and Breast Cancer Risk: A Systematic Review and Meta-Analysis. *Cancers*, 2021, 13, 4805. <https://doi.org/10.3390/cancers13194805>

NELSON, T. R.; CERVIÑO, L. I.; BOONE, J. M.; LINDFORS, K. K. Classification of breast computed tomography data. *American Association of Physicists in Medicine*. Março, 2008.

NOWAK, M. M.; NIEMCZYK, M.; GOLEBIEWSKI, S.; PACZEK, L. Impact of Body Mass Index on All-Cause Mortality in Adults: A Systematic Review and Meta-Analysis. *Journal of Clinical Medicine*, 2024.

OHMARU, A.; MAEDA, K.; ONO, H.; KAMIMURA, S.; IWASAKI, K.; MORI, K.; KAI, M. Age-related change in mammographic breast density of women without history of breast cancer over a 10-year retrospective study. *PeerJ*, 2023. 11:e14836
<http://doi.org/10.7717/peerj.14836>

OLIVEIRA, M. M. Desenvolvimento de protocolo e construção de um aparato mecânico para padronização da aquisição de imagens termográficas de mama. Dissertação (Mestrado em Engenharia Mecânica) - Universidade Federal de Pernambuco, Conselho Nacional de Desenvolvimento Científico e Tecnológico, 2012.

OLIVEIRA, B. B. R.; COELHO, C. G.; BARRETO, S. M.; GIATTI, L.; ARAÚJO, L. F. Body fat distribution and its risk for cardiovascular events in 10 years Brazilian Longitudinal Study of Adult Health (ELSA-Brasil). *Cadernos de Saúde Pública - CSP*, 2022. Programa de Pós-graduação em Saúde Pública, Universidade Federal do Ceará, Fortaleza, Brasil.

PALMAS, F.; MUCARZEL, F.; RICART M.; LLUCH A.; ZABALEGUI, A.; MELIAN, J.; GUERRA, R.; RODRIGUEZ, A.; ROSON, N.; CIUDIN, A.; BURGOS R. Body composition assessment with ultrasound muscle measurement: optimization through the use of semi-

automated tools in colorectal cancer. *Frontiers in Nutrition*, 2024. 11:1372816. doi: 10.3389/fnut.2024.1372816

PENNES, H. H. Analysis of tissue and arterial blood temperatures in the resting human forearm. 1948. *Journal of Applied Physiology* (1985). 1998 Jul; 85(1):5-34. doi: 10.1152/jappl.1998.85.1.5. PMID: 9714612. Disponível em: <https://journals.physiology.org/doi/epdf/10.1152/jappl.1998.85.1.5>. Acesso: 20 out. 2025.

PESCATORI, L. C.; SAVARINO, E.; MAURI, G.; SILVESTRI, E.; CARIATI, M.; SARDANELLI, F.; SCONFENZA, L. M.. Quantification of visceral adipose tissue by computed tomography and magnetic resonance imaging: reproducibility and accuracy. *Radiologia Brasileira*, São Paulo, v. 52, n. 1, p. 1–6, jan./fev. 2019. DOI: <https://doi.org/10.1590/0100-3984.2017.0211>

PRAY, R. e RISKIN, S. The History and Faults of the Body Mass Index and Where to Look Next: A Literature Review. 03 de Novembro, 2023. *Cureus* 15(11): e48230. DOI 10.7759/cureus.48230

Python Software Foundation (PSF). The PSF. Disponível em: www.python.org/psf/mission/. Acesso, fev. 2025.

QUEIROZ, K. F. F. C. Desenvolvimento e implementação de uma ferramenta computacional de uso médico para análise de imagens termográficas. Dissertações (Mestrado - Engenharia Mecânica) – Universidade Federal de Pernambuco, Recife, 2016.

QUEIROZ, K. F. F. C. Integração de ferramentas de simulação computacional e de classificação para análise de patologias mamárias em imagens termográficas. Tese (Doutorado em Engenharia Mecânica) – Universidade Federal de Pernambuco, Recife, 2022.

QUEIROZ, K. F. F. C.; JÚNIOR, J. R. A. Q.; DOURADO, H.; LIMA, R. C. F. Automatic segmentation of region of interest for breast thermographic image classification. *RESEARCH ON BIOMEDICAL ENGINEERING*, v. 39, p. 199-208, 2023.

RAZALI, N. M e WAH, Y. B. Power comparisons of Shapiro-Wilk, Kolmogorov-Smirnov,

Lilliefors and Anderson-Darling tests. Journal of Statistical Modeling and Analytics. Vol.2 No.1, 21-33, 2011. ISBN 978-967-363-157-5

REIS, H. H. T.; BRITO, C. J.; SILLERO-QUINTANA, M.; SILVA, A. G.; FERNÁNDEZ-CUEVAS, I.; CERQUEIRA, M. S.; WERNECK, F. Z.; MARINS, J. C. B. Can Adipose Tissue Influence the Evaluation of Thermographic Images in Adolescents?. International Journal of Environmental Research and Public Health, Março, 2023.

REIS, H. H. T.; BRITO, C. J.; SILVA, A. G.; SILLERO-QUINTANA, M.; REIS, V. E. T.; WERNECK, F. Z.; FERNÁNDEZ-CUEVAS, I.; CERQUEIRA, M. S.; MARINS, J. C. B. Can body mass index influence the skin temperature of adolescents? A preliminary study with the use of infrared thermography. Rev Bras Cineantropom Desempenho Hum, 2022.

RODRIGUES, V. F. S. INFLUÊNCIA DE IMPLANTES DE RETINA EM HUMANOS E FELINOS NOS PERFIS CALCULADOS DE TEMPERATURA E DANO TÉRMICO. Universidade Federal de Pernambuco - Centro de Tecnologia e Geociências. Dissertação (mestrado). Departamento de Engenharia Mecânica. Programa de Pós-Graduação em Engenharia Mecânica (PPGEM). Recife, 2021.

ROMRELL, L. J.; BLAND, K. I. Anatomia da mama. A mama: tratamento compreensivo das doenças benignas e malignas. São Paulo: Manole, 1994.

SAKERS, A.; SIQUEIRA, M. K.; SEALE, P.; VILLANUEVA, C. J. Adipose-tissue plasticity in health and disease. CellPress, Leading Edge, 2022. Vol. 185, 419-446.

SALAMUNES, A. C. C.; STADNIK, A. M. W. e NEVES, E. B. The effect of body fat percentage and body fat distribution on skin surface temperature with infrared thermography. Journal of Thermal Biology, 2017.

SENA, R. P.; SANTOS, I. C.; OLIVEIRA, F. M.; ACENCIO, F. R.; FRANCO, C. B.; BRANCO, B. H. M. Establishing a normative table for classifying body fat percentage in adolescents. Journal of Human Growth and Development, [S. l.], v. 32, n. 1, p. 129-135, 2022. DOI: 10.36311/jhgd.v32.11542.

SHAPIRO, S. S. e WILK, M. B. An analysis of variance test for normality (complete samples). General Electric Go. and Bell Telephone Laboratories, Inc. Biometrika, v. 52, n. 3/4, p. 591–611, 1965.

SHIM, S.; UNKELBACH, J.; LANDSMANN, A.; BOSS, A. Quantitative Study on the Breast Density and the Volume of the Mammary Gland According to the Patient's Age and Breast Quadrant. *Diagnostics* 2023, 13, 3343. <https://doi.org/10.3390/diagnostics13213343>.

SILVA, A.G.M.S.; ZAGAIB, F.G.; AMORIM, L.A.C.; FILHO, J.F.; FORTES, M.S.R.; DANTAS, E.H.M. Estudo de associação entre o padrão de distribuição de gordura corporal e o perfil lipídico de mulheres adultas praticantes de atividade aquática. *Fitness & Performance Journal*, v. 5, nº 3, p. 161-167, 2006.

SILVA, W. S. Inatividade física, comportamento sedentário e obesidade em escolares da Educação Infantil ao Ensino Fundamental. Trabalho de Conclusão de Curso. Faculdade de Filosofia, Ciências e Letras Dom Bosco. Curso de licenciatura em educação física. Resende, 17 de Novembro de 2021.

SMIRNOV, N.V. On the Estimation of the Discrepancy between Empirical Curves of Distributions for Two Independent Samples. *Moscow University Mathematics Bulletin*, 2, 3-26, 1939.

SNEKHALATHA, U.; THANARAJ, K. P.; e SANGAMITHIRAI, K. Computer aided diagnosis of obesity based on thermal imaging using various convolutional neural networks. *Biomedical Signal Processing and Control*. Department of Biomedical Engineering, SRM Institute of Science and Technology. Tamil Nadu, India. 29 de Setembro de 2020.

TAY, S. H.; GOH, H. J.; GOVINDHARAJULU, P.; CHENG, J.; CAMPS, S. G. J. A.; HALDAR, S.; VELAN, S. S.; SUN, L.; LI, Y.; HENRY, C. J.; LEOW, M. K. Brown Fat Activity Determined by Infrared Thermography and Thermogenesis Measurement Using Whole Body Calorimetry (BRIGHT Study). *PHYSIOLOGICAL RESEARCH*. Institute of Physiology of the Czech Academy of Sciences, Prague, Czech Republic, 2020.

THOMASSIN, L et al.. *Proceedings of the Third International Congress of Thermology*. New

York: Plenum Press, 1984. Disponível em: <http://www.taps.org.br/Paginas/cancerarti07.htm>. Acesso em: 1 de Janeiro, 2025.

THRUN, M. C.; GEHLERT, T.; ULTSCH, A. Analyzing the fine structure of distributions. PLOS ONE, v. 15, n. 10, 2020. DOI: 10.1371/journal.pone.0238835.

UNIVERSIDADE FEDERAL DE PERNAMBUCO. Programa de Ações Estratégicas Transversais da Pós-Graduação (PAET-PG) - Sobre. Disponível em: <https://www.ufpe.br/paet-pg>. Acesso, jan. 2025.

VIANA, M. J. A. Reconstrução tridimensional da mama feminina a partir de imagens médicas por infravermelho com auxílio de geometrias substitutas. 2016. 193 f. Tese (Doutorado em Engenharia Mecânica) – Programa de Pós-Graduação em Engenharia Mecânica, Universidade Federal de Pernambuco, Recife, 2016

WANG, H; CHEN, Y. E.; e EITZMAN, D. T. Imaging Body Fat: Techniques and Cardiometabolic Implications. University of Michigan, Department of Internal Medicine, Cardiovascular Research Center, Ann Arbor, Michigan, USA. Arterioscler Thromb Vasc Biol. National Institutes of Health. 2015.

WANG, S.; SHI, H.; LUO, L.; HE, H. Characteristics and correlation of body fat distribution and brachial-ankle pulse wave velocity in adults aged 20–59 years a crosssectional study. BMC Cardiovascular Disorders, 2024. Department of Exercise Physiology, Beijing Sport University, China.

WORLD HEALTH ORGANIZATION (WHO). Moderate and severe thinness, underweight, overweight and obesity. Nutrition Landscape Information System (NLiS). Geneva: World Health Organization, 2006. Disponível em: <https://apps.who.int/nutrition/landscape/help.aspx?helpid=420&menu=0>. Acesso em: 21 out. 2025.

WORLD HEALTH ORGANIZATION (WHO). Obesity and overweight. 2024. Disponível em: www.who.int/news-room/fact-sheets/detail/obesity-and-overweight. Acesso, jan. 2025.

ZWICK, R. K.; GUERRERO-JUAREZ, C. F.; HORSLEY, V.; PLIKUS, M. V. Anatomical, physiological and functional diversity of adipose tissue. Cell Metlab. Jan. 09, 2018.

APÊNDICE A – CÓDIGO PARA EXTRAÇÃO DAS ROIS E SEGMENTAÇÃO

```
import numpy as np
from numpy import isnan
import pandas as pd
import matplotlib.pyplot as plt
from matplotlib.widgets import EllipseSelector
from matplotlib.widgets import RectangleSelector
from tkinter import filedialog, Tk
from sklearn.mixture import GaussianMixture
from scipy.stats import mode, anderson, probplot, shapiro, kstest, norm
import cv2
import os

# Variáveis globais
angC = 0
angD = 0
angE = 0
A1 = None
A2 = None
fig = None
"""Para Elipse"""
ellipse_selector = None
active_ellipse = None # Armazena a elipse ativa no momento
rotated_image = None # Armazena a imagem rotacionada
ellipse_angle = 0 # Ângulo de rotação da imagem
"""Para Quadrado"""
rect_selector = None
active_rectangle = None # Armazena o retângulo ativo no momento
rotated_rect_image = None # Armazena a imagem rotacionada
rectangle_angle = 0 # Ângulo de rotação da imagem
dados_mama_direita = None
dados_mama_esquerda = None
selecionando_mama = None

def load_csv():
    """Função para abrir e carregar um arquivo CSV."""
    root = Tk()
    root.withdraw() # Oculta a janela principal do tkinter
    file_path = filedialog.askopenfilename(filetypes=[("CSV files", "*.csv")])
    root.destroy()
    if not file_path:
        return None
    data = pd.read_csv(file_path, delimiter=';')
    return data.values # Converte para um array numpy

def rotate_image(image, angle):
    """Rotaciona a imagem em torno do seu centro."""
    (h, w) = image.shape[:2]
    center = (w // 2, h // 2)
    rot_matrix = cv2.getRotationMatrix2D(center, angle, 1.0)
    rotated = cv2.warpAffine(image, rot_matrix, (w, h), flags=cv2.INTER_LINEAR)
    return rotated
```

APÊNDICE A (Continuação)

```
def rotate_image(image, angle):
    """Rotaciona a imagem em torno do seu centro."""
    (h, w) = image.shape[:2]
    center = (w // 2, h // 2)
    rot_matrix = cv2.getRotationMatrix2D(center, angle, 1.0)
    rotated = cv2.warpAffine(image, rot_matrix, (w, h), flags=cv2.INTER_LINEAR)
    return rotated

def extract_ellipse_data(image, ellipse_params):
    """
    Extraí os dados da imagem dentro de uma elipse.
    Como a imagem já está rotacionada, a elipse é considerada sem rotação (angle = 0).
    """
    y, x = np.ogrid[:image.shape[0], :image.shape[1]]
    cy, cx, width, height, angle = ellipse_params # angle deverá ser 0
    theta = np.deg2rad(angle)
    # Cálculo genérico; se angle==0, cos(0)=1 e sin(0)=0
    x_rot = (x - cx) * np.cos(theta) + (y - cy) * np.sin(theta)
    y_rot = (y - cy) * np.cos(theta) - (x - cx) * np.sin(theta)
    mask = ((x_rot / (width / 2)) ** 2 + (y_rot / (height / 2)) ** 2) <= 1
    masked_image = np.zeros_like(image, dtype=np.float32)
    masked_image[mask] = image[mask] # Cópia apenas os valores dentro da elipse
    return masked_image, mask

def extract_rectangle_data(image, rect_params):
    """
    Extraí os dados da imagem dentro de um retângulo (sem rotação).
    Espera (cy, cx, width, height, angle).
    """
    cy, cx, width, height, _ = rect_params
    # Converte para coordenadas de canto
    x1 = int(cx - width / 2)
    x2 = int(cx + width / 2)
    y1 = int(cy - height / 2)
    y2 = int(cy + height / 2)
    # Corrige limites se necessário
    x1, x2 = max(0, x1), min(image.shape[1], x2)
    y1, y2 = max(0, y1), min(image.shape[0], y2)
    print(f"Coordenadas corrigidas: x1={x1}, x2={x2}, y1={y1}, y2={y2}")
    # Máscara e imagem extraída
    mask = np.zeros_like(image, dtype=bool)
    mask[y1:y2, x1:x2] = True
    masked_image = np.zeros_like(image)
    masked_image[mask] = image[mask]
    return masked_image, mask

def analyze_region(region, threshold):
    """Analisa a região extraída com base no limiar informado."""
    total_pixels = region.size
    below_threshold = np.sum(region <= threshold)
    above_threshold = np.sum(region > threshold)
    return total_pixels, below_threshold, above_threshold
```

APÊNDICE A (Continuação)

```
def initial_segmentation(image):
    """Mostra a imagem original."""
    plt.figure()
    plt.imshow(image, cmap='jet', vmin=25, vmax=35)
    plt.title("Feche para inserir um limiar de temperatura")
    plt.axis('off')
    plt.show()
    """Faz a segmentação inicial da imagem, caso o usuário deseje."""
    print(f"Temperatura máxima: {np.max(image):.2f}°C".replace('.', ','))
    print(f"Temperatura mínima: {np.min(image):.2f}°C".replace('.', ','))
    print(f"Temperatura média: {(np.max(image) + np.min(image)) / 2:.2f}°C".replace('.', ','))
    print(f"Temperatura mediana: {np.median(image):.2f}°C".replace('.', ','))

    response = input("Deseja estabelecer um limiar inicial para segmentação? (sim/não): ").strip().lower()
    if response == 'sim':
        threshold = float(input("Digite um valor de temperatura como limiar inicial em Celsius: "))
        above_mask = image > threshold
        below_mask = image <= threshold

        # Imagem com pixels acima do limiar
        plt.figure()
        plt.imshow(np.where(above_mask, image, np.nan), cmap='jet', vmin=25, vmax=35)
        plt.title(f'Região com Temperatura > {threshold}°C'.replace('.', ','))
        plt.axis('off')
        plt.show()
        # Imagem com pixels abaixo ou iguais ao limiar
        plt.figure()
        plt.imshow(np.where(below_mask, image, np.nan), cmap='jet', vmin=25, vmax=35)
        plt.title(f'Região com Temperatura <= {threshold}°C'.replace('.', ','))
        plt.axis('off')
        plt.show()

def aplicar_gmm(valores, n_componentes=2):
    """Aplica Gaussian Mixture Model aos dados de temperatura."""
    valores = valores.reshape(-1, 1) # GMM espera dados em formato 2D
    gmm = GaussianMixture(n_components=n_componentes, covariance_type='full', random_state=0)
    gmm.fit(valores)
    labels = gmm.predict(valores)
    return labels.reshape(-1), gmm.means_.flatten(), gmm.covariances_.flatten()

def test_normalidade_e_qqplot(values, region_name):
    # Remove NaNs
    vals = values[~np.isnan(values)]
    if len(vals) < 8:
        print(f'Região {region_name}: dados insuficientes para testes de normalidade.")
        return
    # Anderson-Darling
    result = anderson(vals)
    print(f"\nTeste Anderson-Darling - Região {region_name}")
    print(f"Statistic: {result.statistic:.3f}")
    for sl, cv in zip(result.significance_level, result.critical_values):
        print(f"Significance Level {sl}%: Critical Value {cv:.3f}")

    # Usar o nível de significância de 5% para o veredito
    idx_5 = list(result.significance_level).index(5.0)
    cv_5 = result.critical_values[idx_5]

    if result.statistic < cv_5:
        print("→ Dados provavelmente seguem distribuição normal (não rejeita H0).")
    else:
        print("→ Dados provavelmente NÃO seguem distribuição normal (rejeita H0).")
```

APÊNDICE A (Continuação)

```
# Shapiro-Wilk
stat_shapiro, p_shapiro = shapiro(vals)
print(f"\nTeste Shapiro-Wilk - Região {region_name}")
print(f"Statistic(W): {stat_shapiro:.3f}, p-value: {p_shapiro:.9e}")
if p_shapiro >= 0.05:
    print("→ Dados provavelmente seguem distribuição normal (não rejeita H0).")
else:
    print("→ Dados provavelmente NÃO seguem distribuição normal (rejeita H0).")

# Kolmogorov-Smirnov (contra normal padrão com mesma média e desvio dos dados)
mu, sigma = np.mean(vals), np.std(vals, ddof=1)
stat_ks, p_ks = kstest(vals, 'norm', args=(mu, sigma))
print(f"\nTeste Kolmogorov-Smirnov - Região {region_name}")
print(f"Statistic: {stat_ks:.3f}, p-value: {p_ks:.4f}")
if p_ks > 0.05:
    print("→ Dados provavelmente seguem distribuição normal (não rejeita H0).")
else:
    print("→ Dados provavelmente NÃO seguem distribuição normal (rejeita H0).")

# QQ-Plot
plt.figure()
probplot(vals, dist="norm", plot=plt)
plt.title(f"QQ-Plot da Região {region_name}")
plt.show()

def save_temperature_data(valid_values, region_name):
    """Salva apenas os valores válidos de temperatura como arquivo CSV."""
    root = Tk()
    root.withdraw()
    file_path = filedialog.asksaveasfilename(
        defaultextension=".csv",
        filetypes=[("CSV files", "*.csv")],
        title=f"Salvar dados de temperatura da {region_name}"
    )
    root.destroy()

    if file_path:
        try:
            # Criar DataFrame com apenas os valores válidos
            df = pd.DataFrame({'Temperatura_Celsius': valid_values})
            df.to_csv(file_path, index=False, sep=';')
            print(f"Dados de temperatura salvos em: {file_path}")
            print(f"Total de valores salvos: {len(valid_values)}")
        except Exception as e:
            print(f"Erro ao salvar o arquivo: {e}")
    else:
        print("Operação de salvamento cancelada.")
```

APÊNDICE A (Continuação)

```
"""Etapa de seleção 1"""
def segmentamama(img):
    """Função principal para manipulação e seleção de área."""
    global angD, angE, A1, A2, fig, ellipse_selector, active_ellipse, ellipse_angle,
    rotated_image, dados_mama_direita, dados_mama_esquerda, selecionando_mama

    # Mostra imagem original e faz segmentação inicial
    initial_segmentation(img)

    # Pede limiar inicial e cria imagem segmentada
    threshold = float(input("Digite um valor de temperatura como limiar inicial em Celsius: "))
    above_mask = img > threshold
    segmented_img = np.where(above_mask, img, np.nan)

    # Usa a imagem segmentada como base para seleção
    rotated_image = segmented_img.copy()
    ellipse_angle = 0 # Ângulo inicial

    fig, ax = plt.subplots()
    img_display = ax.imshow(rotated_image, cmap='jet', vmin=25, vmax=35)
    fig.colorbar(img_display, ax=ax)
    plt.title('Use o scroll para rotacionar a imagem; selecione áreas com "e" ou "d"')

    def update_image():
        """Atualiza la exibição da imagem rotacionada."""
        global rotated_image
        rotated_image = rotate_image(segmented_img, ellipse_angle)
        img_display.set_data(rotated_image)
        fig.canvas.draw_idle()

    def on_scroll(event):
        """Rotaciona somente a imagem com o scroll do mouse."""
        global ellipse_angle
        ellipse_angle += event.step # event.step é positivo ou negativo
        update_image()
        print(f"Ângulo da imagem atualizado para: {ellipse_angle}°")

    def on_key(event):
        global angD, angE, ellipse_selector, selecionando_mama
        if event.key == 'e':
            print("Selecionando a área da mama esquerda")
            angE = ellipse_angle # Armazena o ângulo da imagem no momento da seleção
            selecionando_mama = 'esquerda'
            ellipse_selector = create_ellipse_selector(ax, "Área da mama esquerda selecionada.")
        elif event.key == 'd':
            print("Selecionando a área da mama direita")
            angD = ellipse_angle
            selecionando_mama = 'direita'
            ellipse_selector = create_ellipse_selector(ax, "Área da mama direita selecionada.")
```

APÊNDICE A (Continuação)

```
def create_ellipse_selector(ax, message):
    print(message)

    def onselect(eclick, erelease):
        """Ação ao concluir a seleção da elipse."""
        global active_ellipse
        # Calcula o centro, largura e altura da elipse baseada nos pontos selecionados
        cy = (eclick.ydata + erelease.ydata) / 2
        cx = (eclick.xdata + erelease.xdata) / 2
        width = abs(erelease.xdata - eclick.xdata)
        height = abs(erelease.ydata - eclick.ydata)
        # Como a imagem já está rotacionada, a elipse é definida sem rotação (angle = 0)
        active_ellipse = (cy, cx, width, height, 0)
        print("Elipse definida.")

    return EllipseSelector(ax, onselect, interactive=True)

def save_region(event):
    """Salva a região da elipse e exibe a imagem extraída."""
    global active_ellipse, dados_mama_direita, dados_mama_esquerda, selecionando_mama
    if event.key == 'enter' and active_ellipse:
        print("Salvando região da elipse...")
        extracted_data, mask = extract_ellipse_data(rotated_image, active_ellipse)
        valid_mask = mask & (~np.isnan(extracted_data))
        valid_values = extracted_data[valid_mask]

        # Salva os dados conforme a mama selecionada
        if selecionando_mama == 'direita':
            dados_mama_direita = valid_values
            current_extracted_data = extracted_data
        elif selecionando_mama == 'esquerda':
            dados_mama_esquerda = valid_values
            current_extracted_data = extracted_data

        # Exibe a região extraída (mantendo a rotação aplicada)
        plt.figure()
        plt.imshow(extracted_data, cmap='jet', vmin=25, vmax=35)
        plt.title('Região Extraída')
        plt.axis('off')
        plt.show()

        # Exibe estatísticas da região extraída
        print("Área total válida (em pixels):", np.sum(valid_mask))
        print(f"Temperatura máxima: {np.max(valid_values):.2f}°C".replace('.', ','))
        print(f"Temperatura mínima: {np.min(valid_values):.2f}°C".replace('.', ','))
        print(f"Temperatura mediana: {np.median(valid_values):.2f}°C".replace('.', ','))
        print(f"Temperatura média: {np.mean((np.max(valid_values) + np.min(valid_values)) / 2):.2f}°C".replace('.', ','))

        try:
            moda_valor = mode(valid_values, axis=None, keepdims=False).mode
            if not np.isnan(modavalor):
                print(f"Temperatura mais frequente (moda): {float(modavalor):.2f}°C".replace('.', ','))
            else:
                print("Moda não pôde ser calculada (valores nulos ou vazios).")
        except Exception as e:
            print(f"Erro ao calcular a moda: {e}")

    percentis = [5, 10, 15, 20, 22.5, 25, 30, 35, 37, 40, 45, 50, 55, 60, 62.5, 65, 70, 75, 80, 85, 90, 95]
    for p in percentis:
        print(f"Percentil {p:.2f}%: {np.percentile(valid_values, p):.2f}°C".replace('.', ','))

    new_threshold = float(input("Digite um valor de temperatura em Celsius como limiar: "))
    total = np.sum(valid_mask)
    above = np.sum(valid_values > new_threshold)
    below = np.sum(valid_values <= new_threshold)

    print(f"Total de pixels válidos: {total}")
    print(f"Pixels > {new_threshold}°C: {above}".replace('.', ','))
    print(f"Pixels <= {new_threshold}°C: {below}".replace('.', ','))
    print(f"Percentual acima do limiar: {(above / total) * 100:.2f}%".replace('.', ','))
    print(f"Percentual igual e/ou inferior ao limiar: {(below / total) * 100:.2f}%".replace('.', ','))
```

APÊNDICE A (Continuação)

```
response = input("\nDeseja ver as segmentações para o intervalo? (sim/não): ").lower()
if response == 'sim':
    # Cria máscaras para visualização:
    below_mask = (extracted_data <= new_threshold) & valid_mask
    above_mask = (extracted_data > new_threshold) & valid_mask
    fig, axs = plt.subplots(1, 2, figsize=(15, 5))
    # Segmentação igual ou inferior ao limiar:
    axs[0].imshow(np.where(below_mask, extracted_data, np.nan), cmap='jet', vmin=25, vmax=35)
    axs[0].set_title(f'T <= {new_threshold}°C')
    axs[0].axis('off')
    # Segmentação superior ao limiar:
    axs[1].imshow(np.where(above_mask, extracted_data, np.nan), cmap='jet', vmin=25, vmax=35)
    axs[1].set_title(f'T > {new_threshold}°C')
    axs[1].axis('off')
    plt.tight_layout()
    plt.show()

hist_response = input(
    "Deseja ver o histograma de temperaturas para esta região? (sim/não): ").strip().lower()
if hist_response == 'sim':
    plt.figure(figsize=(10, 6))
    plt.hist(valid_values, bins=30, color='cyan', edgecolor='black')
    plt.title('Histograma de Temperaturas na Região Seleccionada')
    plt.xlabel('Temperatura (°C)')
    plt.ylabel('Frequência')
    plt.grid(True, alpha=0.3)
    plt.axvline(np.min(valid_values), color='blue', linestyle='--',
                label=f'Mínimo: {np.min(valid_values):.2f}°C')
    plt.axvline(np.max(valid_values), color='red', linestyle='--',
                label=f'Máximo: {np.max(valid_values):.2f}°C')
    plt.axvline(np.median(valid_values), color='purple', linestyle='--',
                label=f'Mediana: {np.median(valid_values):.2f}°C')
    plt.axvline(new_threshold, color='orange', linestyle='-',
                label=f'Limiar: {new_threshold:.2f}°C')

    plt.legend()
    plt.show()

# Pergunta se deseja salvar apenas os dados de temperatura válidos
save_matrix = input("Deseja salvar os dados de temperatura para esta região? (sim/não): ").strip().lower()
if save_matrix == 'sim':
    save_temperature_data(valid_values, f"mama_{selecionando_mama}")

# Teste de Normalidade e QQ-Plot
test_normalidade_e_qqplot(valid_values, "Mama")

# MultiGaussiana
usar_gmm = input(
    "Deseja aplicar segmentação automática por Gaussian Mixture Model (GMM)? (sim/não): ").strip().lower()
if usar_gmm == 'sim':
    n_componentes = int(input("Quantos clusters deseja usar? (Ex.: 2 ou 3): ")
    labels, medias, variancias = aplicar_gmm(valid_values, n_componentes=n_componentes)

    print("\nResultado da Mistura de Gaussianas:")
    for i in range(n_componentes):
        cluster_size = np.sum(labels == i)
        print(f"Cluster {i + 1}:")
        print(f"  - Média: {medias[i]:.2f}°C")
        print(f"  - Variância: {variancias[i]:.4f}")
        print(f"  - Pixels: {cluster_size} ({(cluster_size / len(labels)) * 100:.2f}%)")

    # Plotagem dos clusters no histograma
    plt.figure(figsize=(10, 6))
    plt.hist(valid_values, bins=30, color='gray', alpha=0.5, label="Distribuição total")
    colors = ['red', 'blue', 'green', 'purple', 'orange']

    for i in range(n_componentes):
        # Valores do cluster atual
        cluster_values = valid_values[labels == i]

        # Estatísticas do cluster
        cluster_min = np.min(cluster_values)
        cluster_max = np.max(cluster_values)
        cluster_mean = medias[i]
```

APÊNDICE A (Continuação)

```
# Linha da média
plt.axvline(cluster_mean, color=colors[i % len(colors)], linestyle='-',
            linewidth=2, label=f'Cluster {i + 1}: Média = {cluster_mean:.2f}°C')

# Linhas de mínimo e máximo
plt.axvline(cluster_min, color=colors[i % len(colors)], linestyle=':',
            linewidth=1.5, alpha=0.7, label=f'Cluster {i + 1}: Mín = {cluster_min:.2f}°C')
plt.axvline(cluster_max, color=colors[i % len(colors)], linestyle=':',
            linewidth=1.5, alpha=0.7, label=f'Cluster {i + 1}: Máx = {cluster_max:.2f}°C')

plt.title('Histograma com Clusters via GMM')
plt.xlabel('Temperatura (°C)')
plt.ylabel('Frequência')
plt.legend()
plt.grid(alpha=0.3)
plt.show()

# Visualização espacial dos clusters
cluster_image = np.full(valid_mask.shape, np.nan)
cluster_image[valid_mask] = labels

plt.figure(figsize=(6, 6))
plt.imshow(cluster_image, cmap='tab10')
plt.title('Distribuição Espacial dos Clusters (GMM)')
plt.axis('off')
plt.colorbar(label='Cluster')
plt.show()

fig.canvas.mpl_connect('scroll_event', on_scroll)
fig.canvas.mpl_connect('key_release_event', on_key)
fig.canvas.mpl_connect('key_release_event', save_region)

plt.show()

# Após fechar a janela, pergunte se deseja analisar as duas mamas juntas
if dados_mama_direita is not None and dados_mama_esquerda is not None:
    resposta = input("Deseja analisar os dados das duas mamas juntas? (sim/não): ").strip().lower()
    if resposta == 'sim':

        combined = np.concatenate([dados_mama_direita, dados_mama_esquerda])
        combined_sorted = np.sort(combined)

        temp_max = np.max(combined_sorted)
        temp_min = np.min(combined_sorted)
        temp_mean = np.mean(combined_sorted)
        temp_median = np.median(combined_sorted)

        try:
            moda_valor = mode(combined_sorted, axis=None, keepdims=False).mode
            if not np.isnan(moda_valor):
                temp_mode = float(moda_valor)
            else:
                temp_mode = None
        except Exception:
            temp_mode = None

        print("\nAnálise combinada das duas mamas:")
        print(f"Temperatura máxima: {temp_max:.2f}°C".replace('.', ','))
        print(f"Temperatura mínima: {temp_min:.2f}°C".replace('.', ','))
        print(f"Temperatura média: {temp_mean:.2f}°C".replace('.', ','))
        if temp_mode is not None:
            print(f"Temperatura mais frequente (moda): {temp_mode:.2f}°C".replace('.', ','))
        else:
            print("Moda não pôde ser calculada.")
        print(f"Temperatura mediana: {temp_median:.2f}°C".replace('.', ','))
```

APÊNDICE A (Continuação)

```
# Teste de Normalidade e QQ-Plot
test_normalidade_e_qqplot(combined_sorted, "Mamas")

# --- Histograma para região combinada ---
plt.figure(figsize=(10, 6))
plt.hist(combined_sorted, bins=30, color='cyan', edgecolor='black')
plt.title('Histograma de Temperaturas - Regiões Combinadas')
plt.xlabel('Temperatura (°C)')
plt.ylabel('Frequência')
plt.grid(True, alpha=0.3)

plt.axvline(temp_min, color='blue', linestyle='--', label=f'Mínimo: {temp_min:.2f}°C')
plt.axvline(temp_max, color='red', linestyle='--', label=f'Máximo: {temp_max:.2f}°C')
plt.axvline(temp_median, color='purple', linestyle='--', label=f'Mediana: {temp_median:.2f}°C')
plt.axvline(temp_mean, color='orange', linestyle='--', label=f'Média: {temp_mean:.2f}°C')
plt.legend()
plt.show()

# Pergunta se deseja salvar os dados combinados
save_combined = input(
    "Deseja salvar os dados de temperatura para as duas mamas combinadas? (sim/não): ").strip().lower()
if save_combined == 'sim':
    save_temperature_data(combined_sorted, "mamas_combinadas")

"""Etapa de seleção 2"""
def segmentamembro(img):
    global angC, A1, A2, fig, rect_selector, active_rectangle, rectangle_angle, rotated_rect_image

    # Mostra imagem original e faz segmentação inicial
    initial_segmentation(img)

    # Pede limiar inferior e cria imagem segmentada
    T_inf = float(input("Digite o limiar inferior de temperatura (°C): "))
    above_mask = img >= T_inf
    segmented_img = np.where(above_mask, img, np.nan)

    # Usa a imagem segmentada como base para seleção
    rotated_image = segmented_img.copy()
    rectangle_angle = 0 # Ângulo inicial

    fig, ax = plt.subplots()
    img_display = ax.imshow(rotated_image, cmap='jet', vmin=25, vmax=35)
    fig.colorbar(img_display, ax=ax)
    plt.title('Use o scroll para rotacionar a imagem; selecione áreas com "c"')

    def update_image():
        """Atualiza a exibição da imagem rotacionada."""
        global rotated_image
        rotated_image = rotate_image(segmented_img, rectangle_angle)
        img_display.set_data(rotated_image)
        fig.canvas.draw_idle()

    def on_scroll(event):
        """Rotaciona somente a imagem com o scroll do mouse."""
        global rectangle_angle
        rectangle_angle += event.step # event.step é positivo ou negativo
        update_image()
        print(f"Ângulo da imagem atualizado para: {rectangle_angle}°")

    def on_key(event):
        global angC, rectangle_selector
        if event.key == 'c':
            print("selecionando a área da região desejada")
            angC = rectangle_angle
            rectangle_selector = create_rectangle_selector(ax, "Área da região selecionada.")
```

APÊNDICE A (Continuação)

```
def create_rectangle_selector(ax, message):
    print(message)

def onselect(eclick, erelease):
    """Ação ao concluir a seleção do retângulo."""
    global active_rectangle
    cy = (eclick.ydata + erelease.ydata) / 2
    cx = (eclick.xdata + erelease.xdata) / 2
    width = abs(erelease.xdata - eclick.xdata)
    height = abs(erelease.ydata - eclick.ydata)
    active_rectangle = (cy, cx, width, height, 0)
    print("Retângulo definido.")

return RectangleSelector(ax, onselect, interactive=True)

def save_region(event):
    """Salva a região do retângulo e exibe a imagem extraída."""
    global active_rectangle
    if event.key == 'enter' and active_rectangle:
        print("Salvando região do retângulo...")
        extracted_data, mask = extract_rectangle_data(rotated_image, active_rectangle)

        # Exibe a região extraída (mantendo a rotação aplicada)
        plt.figure()
        plt.imshow(extracted_data, cmap='jet', vmin=25, vmax=35)
        plt.title('Região Extraída')
        plt.axis('off')
        plt.show()

        # Exibe estatísticas (apenas valores acima do limiar inferior)
        valid_mask = mask & (~np.isnan(extracted_data))
        valid_values = extracted_data[valid_mask]

        print("\nINFORMAÇÕES DA REGIÃO SELECIONADA:")
        print("Área total válida (em pixels):", np.sum(valid_mask))
        print(f"Temperatura máxima: {np.max(valid_values):.2f}°C".replace('.', ','))
        print(f"Temperatura mínima: {np.min(valid_values):.2f}°C".replace('.', ','))
        print(f"Temperatura mediana: {np.median(valid_values):.2f}°C".replace('.', ','))
        print(f"Temperatura média: {np.mean((np.max(valid_values) + np.min(valid_values)) / 2):.2f}°C".replace('.', ','))

        try:
            moda_valor = mode(valid_values, axis=None, keepdims=False).mode
            if not np.isnan(moda_valor):
                print(f"Moda: {float(moda_valor):.2f}°C".replace('.', ','))
        except:
            print("Moda não calculável")

        percentis = [5, 10, 15, 20, 22.5, 25, 30, 35, 37, 40, 45, 50, 55, 60, 62.5, 65, 70, 75, 80, 85, 90, 95]
        for p in percentis:
            print(f"Percentil {p:.2f}%: {np.percentile(valid_values, p):.2f}°C".replace('.', ','))

        # pede limiar superior para análise
        T_sup = float(input("\nDigite o limiar superior de temperatura (°C): "))
        # Calcula distribuição nos intervalos
        below = np.sum(valid_values < T_inf)
        between = np.sum((valid_values >= T_inf) & (valid_values <= T_sup))
        above = np.sum(valid_values > T_sup)
        total = np.sum(valid_mask)

        print(f"\nDISTRIBUIÇÃO DE TEMPERATURAS:")
        print(f"Pixels < {T_inf}°C: {below} ({(below / total) * 100:.2f}%)".replace('.', ','))
        print(f"Pixels entre {T_inf}°C e {T_sup}°C: {between} ({(between / total) * 100:.2f}%)".replace('.', ','))
        print(f"Pixels > {T_sup}°C: {above} ({(above / total) * 100:.2f}%)".replace('.', ','))

        # Pergunta se deseja salvar apenas os dados válidos
        save_matrix = input(
            "\nDeseja salvar os dados de temperatura para esta região? (sim/não): ").strip().lower()
        if save_matrix == 'sim':
            save_temperature_data(valid_values, "barriga")

        response = input("\nDeseja ver as segmentações para os intervalos? (sim/não): ").lower()
        if response == 'sim':
            # Cria máscaras para visualização
            below_mask = (extracted_data < T_inf) & valid_mask
            between_mask = (extracted_data >= T_inf) & (extracted_data <= T_sup) & valid_mask
            above_mask = (extracted_data > T_sup) & valid_mask
```

APÊNDICE A (Continuação)

```
fig, axs = plt.subplots(1, 2, figsize=(15, 5))
axs[0].imshow(np.where(between_mask, extracted_data, np.nan), cmap='jet', vmin=25, vmax=35)
axs[0].set_title(f'{T_inf}°C a {T_sup}°C')
axs[0].axis('off')

axs[1].imshow(np.where(above_mask, extracted_data, np.nan), cmap='jet', vmin=25, vmax=35)
axs[1].set_title(f'> {T_sup}°C')
axs[1].axis('off')

plt.tight_layout()
plt.show()

hist_response = input("\nDeseja ver o histograma? (sim/não): ").lower()
if hist_response == 'sim':
    plt.figure(figsize=(10, 6))
    plt.hist(valid_values, bins=30, color='cyan', edgecolor='black')
    plt.axvline(T_inf, color='blue', linestyle='--', label=f'Limiar Inf.: {T_inf}°C')
    plt.axvline(T_sup, color='red', linestyle='--', label=f'Limiar Sup.: {T_sup}°C')
    plt.title('Distribuição de Temperaturas')
    plt.xlabel('Temperatura (°C)')
    plt.ylabel('Frequência')
    plt.legend()
    plt.grid(alpha=0.3)
    plt.show()

# Teste de Normalidade e QQ-Plot
test_normalidade_e_qqplot(valid_values, "Barriga")

# MultiGaussiana
usar_gmm = input(
    "Deseja aplicar segmentação automática por Gaussian Mixture Model (GMM)? (sim/não): ").strip().lower()
if usar_gmm == 'sim':
    n_componentes = int(input("Quantos clusters deseja usar? (Ex.: 2 ou 3): "))
    labels, medias, variancias = aplicar_gmm(valid_values, n_componentes=n_componentes)

    print("\nRESULTADO DA MISTURA DE GAUSSIANS:")
    for i in range(n_componentes):
        cluster_size = np.sum(labels == i)
        print(f"Cluster {i + 1}:")
        print(f" - Média: {medias[i]:.2f}°C")
        print(f" - Variância: {variancias[i]:.4f}")
        print(f" - Pixels: {cluster_size} ({(cluster_size / len(labels)) * 100:.2f}%)")

    # Plotagem dos clusters no histograma
    plt.figure(figsize=(10, 6))
    plt.hist(valid_values, bins=30, color='gray', alpha=0.5, label="Distribuição total")
    colors = ['red', 'blue', 'green', 'purple', 'orange']

    for i in range(n_componentes):
        # Valores do cluster atual
        cluster_values = valid_values[labels == i]

        # Estatísticas do cluster
        cluster_min = np.min(cluster_values)
        cluster_max = np.max(cluster_values)
        cluster_mean = medias[i]

        # Linha da média
        plt.axvline(cluster_mean, color=colors[i % len(colors)], linestyle='--',
                    linewidth=2, label=f'Cluster {i + 1}: Média = {cluster_mean:.2f}°C')

        # Linhas de mínimo e máximo
        plt.axvline(cluster_min, color=colors[i % len(colors)], linestyle=':',
                    linewidth=1.5, alpha=0.7, label=f'Cluster {i + 1}: Min = {cluster_min:.2f}°C')
        plt.axvline(cluster_max, color=colors[i % len(colors)], linestyle=':',
                    linewidth=1.5, alpha=0.7, label=f'Cluster {i + 1}: Máx = {cluster_max:.2f}°C')

    plt.title('Histograma com Clusters via GMM')
    plt.xlabel('Temperatura (°C)')
    plt.ylabel('Frequência')
    plt.legend()
    plt.grid(alpha=0.3)
    plt.show()
```

APÊNDICE A (Continuação)

```
# Visualização espacial dos clusters
cluster_image = np.full(valid_mask.shape, np.nan)
cluster_image[valid_mask] = labels

plt.figure(figsize=(6, 6))
plt.imshow(cluster_image, cmap='tab10')
plt.title('Distribuição Espacial dos Clusters (GMM)')
plt.axis('off')
plt.colorbar(label='Cluster')
plt.show()

fig.canvas.mpl_connect('scroll_event', on_scroll)
fig.canvas.mpl_connect('key_release_event', on_key)
fig.canvas.mpl_connect('key_release_event', save_region)

plt.show()

def main():
    img = load_csv()
    if img is not None:
        segmentamama(img)
        segmentamembro(img)
    else:
        print("Nenhum arquivo selecionado.")

if __name__ == "__main__":
    main()
```

APÊNDICE B – CÓDIGO PARA TESTES DE NORMALIDADE

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from scipy import stats
from scipy.stats import shapiro, anderson, kstest, norm
from google.colab import files

# Configuração do estilo dos gráficos
plt.style.use('default')
plt.rcParams['figure.figsize'] = (12, 8)
plt.rcParams['font.size'] = 12

def main():
    print("=" * 60)
    print("ANÁLISE DE NORMALIDADE DE DADOS")
    print("=" * 60)

    # 1. Upload do arquivo CSV
    print("\n1. FAZENDO UPLOAD DO ARQUIVO CSV")
    print("-" * 40)

    uploaded = files.upload()

    if not uploaded:
        print("Nenhum arquivo foi selecionado. Execute o código novamente.")
        return

    # Pegar o nome do primeiro arquivo enviado
    filename = list(uploaded.keys())[0]
    print(f"Arquivo '{filename}' carregado com sucesso!")

    try:
        # 2. Ler o arquivo CSV
        print(f"\n2. LENDO O ARQUIVO '{filename}'")
        print("-" * 40)

        # Tentar diferentes separadores
        try:
            df = pd.read_csv(filename)
        except:
            try:
                df = pd.read_csv(filename, sep=';')
            except:
                df = pd.read_csv(filename, sep='\t')

        print(f"Formato do dataset: {df.shape}")
        print(f"Colunas disponíveis: {list(df.columns)}")

        # 3. Selecionar a coluna para análise
        print("\n3. SELECIONANDO COLUNA PARA ANÁLISE")
```

APÊNDICE B (Continuação)

```
print("-" * 40)

# Mostrar as primeiras linhas para referência
print("Primeiras 5 linhas do dataset:")
print(df.head())

# Se houver múltiplas colunas, pedir para escolher
if len(df.columns) > 1:
    print(f"\nColunas disponíveis: {list(df.columns)}")
    coluna = input("Digite o nome da coluna que deseja analisar: ")
else:
    coluna = df.columns[0]

# Extrair os dados
dados = df[coluna].dropna().values # Remove valores NaN
dados_originais = dados.copy()
print(f"\nColuna selecionada: '{coluna}'")
print(f"Número de observações: {len(dados)}")
print(f"Média: {dados.mean():.4f}")
print(f"Desvio padrão: {dados.std():.4f}")
print(f"Valor mínimo: {dados.min():.4f}")
print(f"Valor máximo: {dados.max():.4f}")

# 4. Ordenar os dados em ordem crescente
print(f"\n4. ORDENANDO DADOS EM ORDEM CRESCENTE")
print("-" * 40)

dados_ordenados = np.sort(dados)
print("Primeiros 10 valores ordenados:")
print(dados_ordenados[:10])
print("\nÚltimos 10 valores ordenados:")
print(dados_ordenados[-10:])

# 5. Testes de normalidade
print(f"\n5. TESTES DE NORMALIDADE")
print("-" * 40)

# Shapiro-Wilk Test
print("TESTE DE SHAPIRO-WILK:")
stat_sw, p_sw = shapiro(dados)
print(f"Estatística: {stat_sw:.4f}, p-valor: {p_sw:.4f}")
alpha = 0.05
if p_sw > alpha:
    print("Resultado: NÃO REJEITA normalidade (p > 0.05)")
else:
    print("Resultado: REJEITA normalidade (p ≤ 0.05)")
print("\n" + "-" * 20)

# Anderson-Darling Test
print("TESTE DE ANDERSON-DARLING:")
result_ad = anderson(dados)
print(f"Estatística: {result_ad.statistic:.4f}")
print("Valores críticos:")
for i in range(len(result_ad.critical_values)):
    sl, cv = result_ad.significance_level[i], result_ad.critical_values[i]
```

APÊNDICE B (Continuação)

```
        if result_ad.statistic < cv:
            print(f"{sl}%: {cv:.4f} → NÃO REJEITA normalidade")
        else:
            print(f"{sl}%: {cv:.4f} → REJEITA normalidade")
print("\n" + "-" * 20)
        # Kolmogorov-Smirnov Test
print("TESTE DE KOLMOGOROV-SMIRNOV:")
# Ajustar parâmetros da distribuição normal
mean, std = np.mean(dados), np.std(dados)
stat_ks, p_ks = kstest(dados, 'norm', args=(mean, std))
print(f"Estatística: {stat_ks:.4f}, p-valor: {p_ks:.4f}")
if p_ks > alpha:
    print("Resultado: NÃO REJEITA normalidade (p > 0.05)")
else:
    print("Resultado: REJEITA normalidade (p ≤ 0.05)")

# 6. Gráficos de análise visual
print(f"\n6. ANÁLISE VISUAL DA DISTRIBUIÇÃO")
print("-" * 40)
fig, ((ax1, ax2), (ax3, ax4)) = plt.subplots(2, 2, figsize=(15, 12))

# Histograma com curva normal
n, bins, patches = ax1.hist(dados, bins='auto', density=True, alpha=0.7,
                             color='skyblue', edgecolor='black')

# Adicionar curva normal teórica
xmin, xmax = ax1.get_xlim()
x = np.linspace(xmin, xmax, 100)
p = norm.pdf(x, mean, std)
ax1.plot(x, p, 'k', linewidth=2, label='Distribuição Normal')
ax1.set_title('Histograma com Curva Normal')
ax1.set_xlabel('Valores')
ax1.set_ylabel('Densidade')
ax1.legend()
ax1.grid(True, alpha=0.3)

# QQ Plot
stats.probplot(dados, dist="norm", plot=ax2)
ax2.set_title('Q-Q Plot')
ax2.grid(True, alpha=0.3)

# Boxplot
ax3.boxplot(dados)
ax3.set_title('Boxplot')
ax3.set_ylabel('Valores')
ax3.grid(True, alpha=0.3)

# Gráfico de densidade
ax4.hist(dados, bins='auto', density=True, alpha=0.7,
          color='lightgreen', edgecolor='black', label='Dados')
```

APÊNDICE B (Continuação)

```
# Kernel Density Estimation
from scipy.stats import gaussian_kde
kde = gaussian_kde(dados)
x_vals = np.linspace(min(dados), max(dados), 1000)
ax4.plot(x_vals, kde(x_vals), 'r-', linewidth=2, label='KDE')
ax4.plot(x, p, 'k--', linewidth=2, label='Normal Teórica')
ax4.set_title('Estimativa de Densidade Kernel (KDE)')
ax4.set_xlabel('Valores')
ax4.set_ylabel('Densidade')
ax4.legend()
ax4.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

# 7. Resumo dos resultados
print(f"\n7. RESUMO DOS RESULTADOS")
print("-" * 40)
print(f"Shapiro-Wilk: {'Normal' if p_sw > alpha else 'Não Normal'} (p={p_sw:.4f})")
print(f"Anderson-Darling: Estatística = {result_ad.statistic:.4f}")
print(f"Kolmogorov-Smirnov: {'Normal' if p_ks > alpha else 'Não Normal'} (p={p_ks:.4f})")

print(f"\nRecomendação baseada nos testes:")
if p_sw > alpha and result_ad.statistic < result_ad.critical_values[2] and p_ks > alpha:
    print("Os dados parecem seguir uma distribuição normal")
else:
    print("Os dados NÃO parecem seguir uma distribuição normal")

except Exception as e:
    print(f"Erro ao processar o arquivo: {e}")
    print("Verifique se o arquivo está no formato CSV correto.")

if __name__ == "__main__":
    main()
```

APÊNDICE C – CÓDIGO PARA TESTE DE CORRELAÇÃO MANN-WHITNEY

```
import pandas as pd
from scipy.stats import mannwhitneyu
from google.colab import files
import matplotlib.pyplot as plt
import seaborn as sns

# Upload de dois arquivos CSV (um para cada região, por exemplo: mama e barriga)
uploaded = files.upload()
filenames = list(uploaded.keys())
if len(filenames) != 2:
    print("É necessário enviar exatamente dois arquivos CSV para comparar.")
else:
    # Ler os dois arquivos
    df1 = pd.read_csv(filenames[0])
    df2 = pd.read_csv(filenames[1])
    # Como cada arquivo tem só 1 coluna, pegamos direto
    col1 = df1.columns[0]
    col2 = df2.columns[0]
    sample1 = df1[col1].dropna().values
    sample2 = df2[col2].dropna().values
    print(f"\nArquivo 1: {filenames[0]} → {len(sample1)} valores")
    print(f"Arquivo 2: {filenames[1]} → {len(sample2)} valores")

    # Teste Mann-Whitney U
    stat, p_value = mannwhitneyu(sample1, sample2, alternative="two-sided")
    print("\n=== RESULTADO DO TESTE MANN-WHITNEY U ===")
    print(f"Estatística U = {stat:.2f}")
    print(f"p-valor = {p_value:.5f}")

    alpha = 0.05
    if p_value < alpha:
        print("→ Rejeita H0: Existe diferença significativa entre as amostras.")
    else:
        print("→ Não rejeita H0: Não há diferença significativa entre as amostras.")

    # Mostrar medidas de tendência central
    print("\nResumo descritivo:")
    print(f"Mediana amostra 1 ({filenames[0]}) = {pd.Series(sample1).median():.4f}")
    print(f"Mediana amostra 2 ({filenames[1]}) = {pd.Series(sample2).median():.4f}")

    # Gráfico com curvas KDE
    plt.figure(figsize=(8,5))
    sns.kdeplot(sample1, fill=True, alpha=0.4, label=f"{filenames[0]}", color="blue")
    sns.kdeplot(sample2, fill=True, alpha=0.4, label=f"{filenames[1]}", color="red")

    plt.title("Distribuição KDE das Amostras")
    plt.xlabel("Temperatura (°C)")
    plt.ylabel("Densidade")
```

APÊNDICE C (Continuação)

```
# Coloca legenda fora do gráfico, abaixo
plt.legend(loc="upper center", bbox_to_anchor=(0.5, -0.15), ncol=2, frameon=False)

plt.tight_layout()
plt.show()

# Histograma da primeira amostra
plt.figure(figsize=(8,5))
plt.hist(sample1, bins=30, color="blue", alpha=0.7, edgecolor="black")
plt.title(f"Histograma - {filenames[0]}")
plt.xlabel("Temperatura (°C)")
plt.ylabel("Frequência")
plt.grid(axis="y", linestyle="--", alpha=0.6)
plt.tight_layout()
plt.show()

# Histograma da segunda amostra
plt.figure(figsize=(8,5))
plt.hist(sample2, bins=30, color="red", alpha=0.7, edgecolor="black")
plt.title(f"Histograma - {filenames[1]}")
plt.xlabel("Temperatura (°C)")
plt.ylabel("Frequência")
plt.grid(axis="y", linestyle="--", alpha=0.6)
plt.tight_layout()
plt.show()
```

APÊNDICE D – CÓDIGO PARA TESTE DE CORRELAÇÃO SPEARMAN

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import scipy.stats as stats

# Idades correspondentes às 20 amostras
idade = [67, 64, 62, 58, 58, 57, 56, 55, 52, 52, 50, 49, 48, 47, 42, 40, 40, 34, 29, 25]
# MÉDIA
media = [
    [63.82, 68.74, 10.29], [70.58, 39.00, 38.07], [41.12, 31.26, 46.94], [82.87, 82.56, 54.26],
    [58.45, 61.71, 62.52], [87.63, 63.72, 67.61], [71.60, 77.80, 76.07], [46.09, 49.48, 77.69],
    [54.77, 86.83, 18.00], [15.89, 85.14, 1.47], [69.81, 38.35, 67.84], [40.70, 29.02, 10.88],
    [7.99, 24.04, 41.73], [59.35, 40.28, 14.17], [58.11, 27.36, 23.04], [57.42, 73.37, 50.81],
    [80.78, 78.71, 36.08], [41.67, 35.91, 39.34], [59.02, 52.29, 43.27], [42.76, 18.41, 22.57]
]
# MODA
moda = [
    [31.94, 60.31, 58.14], [32.15, 7.33, 28.42], [33.47, 3.65, 38.52], [30.01, 55.96, 49.54],
    [31.73, 10.47, 45.90], [31.44, 0.57, 36.75], [32.14, 28.75, 18.64], [28.94, 77.63, 6.17],
    [30.90, 3.66, 3.60], [33.65, 22.75, 46.75], [31.82, 75.13, 17.21], [31.85, 14.17, 18.21],
    [34.29, 2.94, 64.59], [29.39, 85.69, 52.37], [34.05, 16.96, 82.68], [30.84, 4.33, 53.70],
    [29.49, 2.33, 35.50], [32.97, 12.85, 58.97], [33.60, 31.69, 43.27], [33.70, 74.79, 18.63]
]
# MEDIANA
mediana = [
    [49.93, 49.32, 50.20], [49.65, 50.16, 50.11], [50.10, 50.16, 49.38], [49.85, 50.33, 49.54],
    [49.91, 50.08, 50.09], [50.04, 50.19, 49.70], [50.07, 50.36, 50.12], [50.01, 49.83, 49.83],
    [49.92, 50.03, 49.78], [50.78, 49.70, 49.56], [50.20, 49.97, 49.93], [50.00, 50.00, 50.14],
    [50.42, 50.04, 50.26], [49.90, 49.96, 49.90], [50.34, 50.06, 49.89], [50.10, 50.10, 50.25],
    [50.15, 49.78, 49.95], [50.24, 50.05, 50.16], [49.72, 49.57, 50.29], [49.75, 50.24, 50.07]
]
# PERCENTIL
percentil = [
    [62.94, 62.14, 62.44], [62.94, 62.47, 62.39], [62.36, 62.76, 62.41], [36.84, 36.84, 36.91],
    [36.85, 36.87, 36.44], [37.25, 36.88, 36.82], [37.22, 37.38, 37.22], [36.97, 36.87, 36.79],
    [37.23, 36.88, 37.25], [36.62, 37.33, 36.88], [36.84, 36.88, 36.94], [37.05, 37.23, 37.39],
    [36.94, 37.34, 37.39], [37.10, 36.81, 37.17], [22.51, 22.55, 22.44], [22.44, 22.48, 22.59],
    [22.40, 22.73, 22.40], [14.94, 15.05, 15.20], [14.75, 15.25, 15.18], [10.08, 9.85, 9.90]
]
# GMM
gmm = [
    [48.59, 30.05, 13.23], [59.98, 23.46, 52.63], [38.81, 26.58, 81.81], [57.61, 75.31, 86.04],
    [43.30, 53.31, 78.30], [74.61, 33.29, 67.61], [39.66, 87.13, 84.27], [48.49, 30.44, 66.24],
    [62.38, 58.19, 76.69], [45.60, 63.84, 51.73], [47.89, 36.13, 62.71], [46.03, 31.18, 63.44],
    [59.65, 40.63, 38.98], [54.20, 24.54, 20.20], [31.69, 38.68, 43.68], [24.95, 54.87, 50.56],
    [72.91, 75.33, 57.11], [24.30, 23.61, 42.14], [52.47, 40.09, 66.20], [34.09, 41.14, 65.64]
]
```

APÊNDICE D (Continuação)

```
# FUNÇÃO DE ANÁLISE E GRÁFICOS
def analisar_metodo(nome_metodo, dados):
    df = pd.DataFrame(dados, columns=["Mama D.", "Mama E.", "Abdômen"])
    df["Idade"] = idade
    print(f"\n=== Análise para o método: {nome_metodo.upper()} ===")
    correlacoes = {}
    for regioao in ["Mama D.", "Mama E.", "Abdômen"]:
        rho, p = stats.spearmanr(df["Idade"], df[regiao])
        correlacoes[regiao] = (rho, p)
        # Interpretação textual automática
        if p < 0.05:
            direcao = "positiva" if rho > 0 else "negativa"
            intensidade = "forte" if abs(rho) >= 0.7 else "moderada" if abs(rho) >= 0.4 else "fraca"
            print(f" - {regiao}: Correlação {direcao} {intensidade} (p={rho:.3f}, p={p:.3f})")
        else:
            print(f" - {regiao}: Sem correlação significativa (p={rho:.3f}, p={p:.3f})")
    # Gráficos
    plt.figure(figsize=(15, 4))
    for i, regioao in enumerate(["Mama D.", "Mama E.", "Abdômen"], 1):
        plt.subplot(1, 3, i)
        plt.scatter(df["Idade"], df[regiao], alpha=0.7)
        m, b = np.polyfit(df["Idade"], df[regiao], 1)
        plt.plot(df["Idade"], m * df["Idade"] + b, color="red")
        plt.title(f"{regiao} x Idade ({nome_metodo})")
        plt.xlabel("Idade (anos)")
        plt.ylabel("Percentual ≤ Limiar")
    plt.tight_layout()
    plt.show()

# EXECUTAR ANÁLISES
for metodo, dados in {
    "Média": media,
    "Moda": moda,
    "Mediana": mediana,
    "Percentil": percentil,
    "GMM": gmm
}.items():
    analisar_metodo(metodo, dados)
```

APÊNDICE E – CÓDIGO PARA GRÁFICOS DE PORCENTAGENS DOS LIMIAR

```
import matplotlib.pyplot as plt
import numpy as np
# Tabelas dos limiares
media = [
    [63.82, 68.74, 10.29],
    [70.58, 39.00, 38.07],
    [41.12, 31.26, 46.94],
    [82.87, 82.56, 54.26],
    [58.45, 61.71, 62.52],
    [87.63, 63.72, 67.61],
    [71.60, 77.80, 76.07],
    [46.09, 49.48, 77.69],
    [54.77, 86.83, 18.00],
    [15.89, 85.14, 1.47],
    [69.81, 38.35, 67.84],
    [40.70, 29.02, 10.88],
    [7.99, 24.04, 41.73],
    [59.35, 40.28, 14.17],
    [58.11, 27.36, 23.04],
    [57.42, 73.37, 50.81],
    [80.78, 78.71, 36.08],
    [41.67, 35.91, 39.34],
    [59.02, 52.29, 43.27],
    [42.76, 18.41, 22.57]
]
moda = [
    [13.2, 60.31, 58.14],
    [3.35, 7.33, 28.42],
    [17.8, 3.65, 38.52],
    [3.81, 55.96, 49.54],
    [37, 10.47, 45.90],
    [6.82, 0.57, 36.75],
    [7.75, 28.75, 18.64],
    [5.02, 77.63, 6.17],
    [9.79, 3.66, 3.6],
    [38.96, 22.75, 46.75],
    [3.26, 75.13, 17.21],
    [4.59, 14.17, 18.21],
    [37.99, 2.94, 64.59],
    [3.1, 85.69, 52.37],
    [26.72, 16.96, 82.68],
    [4.28, 4.33, 53.7],
    [83.84, 2.33, 35.5],
    [53.71, 12.85, 58.97],
    [20.6, 31.69, 43.27],
    [28.8, 74.79, 18.63]
]
```

APÊNDICE E (Continuação)

```
mediana = [  
    [49.93, 49.32, 50.2],  
    [49.65, 50.16, 50.11],  
    [50.1, 50.16, 49.38],  
    [49.85, 50.33, 49.54],  
    [49.91, 50.08, 50.09],  
    [50.04, 50.19, 49.7],  
    [50.07, 50.36, 50.12],  
    [50.01, 49.83, 49.83],  
    [49.92, 50.03, 49.78],  
    [50.78, 49.7, 49.56],  
    [50.2, 49.97, 49.93],  
    [50.0, 50.0, 50.14],  
    [50.42, 50.04, 50.26],  
    [49.9, 49.96, 49.9],  
    [50.34, 50.06, 49.89],  
    [50.1, 50.1, 50.25],  
    [50.15, 49.78, 49.95],  
    [50.24, 50.05, 50.16],  
    [49.72, 49.57, 50.29],  
    [49.75, 50.24, 50.07]  
]  
cluster = [  
    [48.59, 30.05, 13.23],  
    [59.98, 23.46, 52.63],  
    [38.81, 26.58, 81.81],  
    [57.61, 75.31, 86.04],  
    [43.30, 53.31, 78.30],  
    [74.61, 33.29, 67.61],  
    [39.66, 87.13, 84.27],  
    [48.49, 30.44, 66.24],  
    [62.38, 58.19, 76.69],  
    [45.60, 63.84, 51.73],  
    [47.89, 36.13, 62.71],  
    [46.03, 31.18, 63.44],  
    [59.65, 40.63, 38.98],  
    [54.20, 24.54, 20.20],  
    [31.69, 38.68, 43.68],  
    [24.95, 54.87, 50.56],  
    [72.91, 75.33, 57.11],  
    [24.30, 23.61, 42.14],  
    [52.47, 40.09, 66.20],  
    [34.09, 41.14, 65.64]  
]
```

APÊNDICE E (Continuação)

```
percentil = [  
    [62.94, 62.14, 62.44],  
    [62.94, 62.47, 62.39],  
    [62.36, 62.76, 62.41],  
    [36.84, 36.84, 36.91],  
    [36.85, 36.87, 36.44],  
    [37.25, 36.88, 36.82],  
    [37.22, 37.38, 37.22],  
    [36.97, 36.87, 36.79],  
    [37.23, 36.88, 37.25],  
    [36.62, 37.33, 36.88],  
    [36.84, 36.88, 36.94],  
    [37.05, 37.23, 37.39],  
    [36.94, 37.34, 37.39],  
    [37.10, 36.81, 37.17],  
    [22.51, 22.55, 22.44],  
    [22.44, 22.48, 22.59],  
    [22.40, 22.73, 22.40],  
    [14.94, 15.05, 15.20],  
    [14.75, 15.25, 15.18],  
    [10.08, 9.85, 9.9]  
]  
  
# Empacotar todas as tabelas  
tabelas = {  
    "Média": media,  
    "Moda": moda,  
    "Mediana": mediana,  
    "Percentil": percentil,  
    "Cluster": cluster  
}  
  
# Função para plotar os gráficos  
def plot_paciente(idx_paciente, tabelas):  
    limiares = list(tabelas.keys())  
    n_limiares = len(limiares)  
    # Cria figura com 3 subplots (mama dir, mama esq, abdômen)  
    fig, axes = plt.subplots(1, 3, figsize=(15, 5), sharey=True)  
    regioes = ["Mama Direita", "Mama Esquerda", "Abdômen"]  
    for col in range(3):  
        valores = [tabelas[limiar][idx_paciente][col] for limiar in limiares]  
        # barras azuis (parte inferior)  
        axes[col].bar(limiares, valores, color="blue")  
        # completar até 100 com vermelho  
        cima = [100 - v for v in valores]  
        axes[col].bar(limiares, cima, bottom=valores, color="red")  
        axes[col].set_ylim(0, 100)  
        axes[col].set_ylabel("Percentual (%)")  
        axes[col].set_title(regioes[col])  
        axes[col].tick_params(axis='x', rotation=45)  
    plt.suptitle(f"Paciente {idx_paciente+1}", fontsize=16)  
    plt.tight_layout()  
    plt.show()  
    n_pacientes = len(media) # 20 pacientes  
    for i in range(n_pacientes):
```

APÊNDICE E (Continuação)

```
plot_paciente(i, tabelas)
# Função para plotar as curvas
def plot_curvas(tabelas):
    limiares = list(tabelas.keys())
    regioes = ["Mama Direita", "Mama Esquerda", "Abdômen"]
    cores = ["red", "green", "blue", "yellow", "pink"] # uma cor por limiar
    fig, axes = plt.subplots(1, 3, figsize=(18, 5), sharey=True)
    linhas = [] # para armazenar os handles das linhas (para legenda)
    labels = [] # para armazenar os nomes dos limiares
    for col, regioao in enumerate(regioes):
        for i, limiar in enumerate(limiares):
            valores = [tabelas[limiar][p][col] for p in range(len(tabelas[limiar]))]
            linha, = axes[col].plot(range(1, len(valores)+1), valores,
                                    marker="o", linestyle="-", color=cores[i], label=limiar)
            # armazenar apenas uma vez os handles para legenda
            if col == 0:
                linhas.append(linha)
                labels.append(limiar)
            axes[col].set_title(regiao)
            axes[col].set_xlabel("Paciente")
            axes[col].set_ylabel("Percentual (%)")
            axes[col].set_ylim(0, 100)
    # Legenda única abaixo da figura
    fig.legend(linhas, labels, loc="lower center", ncol=len(limiares), fontsize=10)
    plt.suptitle("Distribuição de percentuais por limiar", fontsize=16, y=1.05)
    plt.tight_layout(rect=[0, 0.05, 1, 0.95]) # deixa espaço para a legenda
    plt.show()

# Chamar função
plot_curvas(tabelas)

# Tabelas das temperaturas limiares
media = [
    [33.1, 33.27, 32.73],
    [33.34, 32.9, 32.97],
    [33.76, 33.28, 33.57],
    [31.58, 31.41, 32.2],
    [32.22, 32.4, 32.22],
    [33.3, 32.57, 32.34],
    [33.07, 32.87, 32.63],
    [30.08, 31.41, 30.63],
    [31.55, 32.39, 31],
    [33.43, 33.56, 32.2],
    [33.49, 32.97, 33.15],
    [33.26, 32.91, 33.14],
    [33.86, 33.73, 33.95],
    [30.7, 31.17, 31.09],
    [34.41, 33.63, 33.6],
    [32.23, 32.72, 32.6],
    [29.71, 30.82, 29.82],
    [32.83, 32.62, 32.68],
    [34.12, 34.17, 32.8],
    [33.92, 33.49, 33.96]
]
```

APÊNDICE E (Continuação)

```
moda = [  
    [31.94, 33.19, 33.7],  
    [32.15, 31.84, 32.8],  
    [33.47, 32.2, 33.48],  
    [30.01, 30.94, 32.15],  
    [31.73, 31.16, 31.94],  
    [31.44, 30.22, 31.6],  
    [32.14, 32.27, 31.65],  
    [28.94, 32.02, 28.35],  
    [30.90, 30.57, 31.29],  
    [33.65, 32.73, 33.62],  
    [31.82, 33.69, 31.65],  
    [31.85, 32.13, 34.97],  
    [34.29, 32.79, 34.33],  
    [29.39, 31.73, 31.74],  
    [34.05, 33.45, 35.02],  
    [30.84, 31.01, 32.73],  
    [29.49, 29.36, 29.81],  
    [32.97, 32.21, 33.15],  
    [33.60, 33.9, 33.8],  
    [33.70, 34.36, 33.89]  
]  
mediana = [  
    [32.72, 33.1, 33.61],  
    [33.07, 33.06, 33.17],  
    [33.85, 33.59, 33.6],  
    [30.97, 30.87, 32.15],  
    [32.04, 32.09, 32],  
    [32.46, 32.3, 31.86],  
    [32.81, 32.51, 32.16],  
    [30.19, 31.42, 29.5],  
    [31.47, 31.66, 31.47],  
    [33.74, 33.07, 33.66],  
    [33.13, 33.23, 32.49],  
    [33.59, 33.52, 34.2],  
    [34.47, 34.26, 34.09],  
    [30.43, 31.29, 31.7],  
    [34.33, 33.97, 34.39],  
    [32.13, 32.36, 32.59],  
    [29.11, 30.23, 30.07],  
    [32.93, 32.81, 32.95],  
    [33.99, 34.14, 33.9],  
    [34.02, 34.06, 34.45]  
]
```





APÊNDICE E (Continuação)

```
cluster = [  
    [32.60, 33.29, 32.87],  
    [33.16, 32.54, 33.41],  
    [34.06, 33.16, 34.19],  
    [31.31, 32.08, 33.23],  
    [31.94, 32.25, 32.77],  
    [32.51, 31.87, 32.51],  
    [32.79, 32.59, 32.29],  
    [30.16, 30.91, 30.09],  
    [31.68, 31.54, 32.03],  
    [33.68, 33.04, 33.59],  
    [33.00, 32.94, 32.90],  
    [32.52, 32.99, 34.24],  
    [34.61, 34.13, 33.78],  
    [30.55, 30.84, 31.69],  
    [34.16, 33.84, 34.04],  
    [31.80, 32.68, 32.96],  
    [29.61, 30.57, 30.21],  
    [32.54, 32.69, 32.80],  
    [34.04, 34.03, 34.20],  
    [33.58, 33.91, 34.62]  
]  
percentil = [  
    [33.17, 33.23, 33.75],  
    [33.29, 33.2, 33.46],  
    [34.03, 33.78, 33.73],  
    [30.84, 30.69, 32.04],  
    [31.64, 31.71, 31.84],  
    [32.28, 31.85, 31.56],  
    [32.64, 32.35, 31.95],  
    [29.84, 31.03, 29.05],  
    [31.32, 31.4, 31.33],  
    [33.61, 32.84, 33.45],  
    [32.81, 32.9, 32.14],  
    [33.09, 33.09, 33.91],  
    [34.28, 33.97, 33.98],  
    [30.06, 31.08, 31.49],  
    [33.99, 33.56, 33.38],  
    [31.72, 31.77, 32.13],  
    [28.67, 29.77, 29.59],  
    [32.2, 32.21, 32.07],  
    [33.52, 33.6, 33.34],  
    [33.11, 33.34, 33.68]  
]
```





APÊNDICE E (Continuação)

```
# Função para plotar as curvas
def plot_curvas(tabelas):
    limiares = list(tabelas.keys())
    regioes = ["Mama Direita", "Mama Esquerda", "Abdômen"]
    cores = ["red", "green", "blue", "yellow", "pink"] # uma cor por limiar
    fig, axes = plt.subplots(1, 3, figsize=(18, 5), sharey=True, constrained_layout=True)
    linhas = []
    labels = []
    for col, regioao in enumerate(regioes):
        for i, limiar in enumerate(limiares):
            valores = [tabelas[limiar][p][col] for p in range(len(tabelas[limiar]))]
            linha, = axes[col].plot(
                range(1, len(valores)+1),
                valores,
                marker="o",
                linestyle="-",
                color=cores[i],
                label=limiar
            )
            if col == 0:
                linhas.append(linha)
                labels.append(limiar)
        axes[col].set_title(regiao, fontsize=12)
        axes[col].set_xlabel("Paciente")
        axes[col].set_ylabel("Temperatura (°C)")
    # Título principal mais afastado dos subgráficos
    plt.suptitle("Distribuição de temperaturas por limiar", fontsize=16, y=1.06)
    # Legenda centralizada mais abaixo
    fig.legend(
        linhas, labels,
        loc="upper center",
        bbox_to_anchor=(0.5, -0.01), # mais para baixo
        ncol=len(limiares),
        fontsize=10
    )
    # Forçar os limites do eixo Y
    for ax in axes:
        ax.set_ylim(28, 36)
    plt.show()
# Exemplo de chamada
tabelas = {
    "Média": media,
    "Moda": moda,
    "Mediana": mediana,
    "Percentil": percentil,
    "Cluster": cluster
}
plot_curvas(tabelas)
```




APÊNDICE F – IMAGENS TERMOGRÁFICAS DAS PARTICIPANTES

Idade: 25 anos (Prontuário: 1*****8-5)	Idade: 27 anos (Prontuário: 1*****5-7)
Sem patologia (Histórico de cisto na família)	Histórico sem patologia
	
Idade: 34 anos (Prontuário: 1*****8-0)	Idade: 40 anos (Prontuário: 1*****3-1)
Histórico sem patologia	Histórico sem patologia
	



APÊNDICE F (Continuação)

Idade: 40 anos (Prontuário: 1*****0-7)	Idade: 42 anos (Prontuário: 1*****2-2)
Histórico sem patologia	Sem patologia grave (cisto nas duas mamas)
	
Idade: 47 anos (Prontuário: 1*****6-8)	Idade: 48 anos (Voluntária 1)
Histórico sem patologia	Sem patologia (mas já teve BIRAIDS-2)
	





APÊNDICE F (Continuação)

Idade: 49 anos (Voluntária 2)	Idade: 50 anos (Voluntária 3)
Sem patologia (mas já teve BIRAIDS-3)	Histórico sem patologia
	
Idade: 52 anos (Prontuário: 1*****6-3)	Idade: 52 anos (Prontuário: 1*****6-8)
Histórico sem patologia	Histórico sem patologia
	

APÊNDICE F (Continuação)



APÊNDICE F (Continuação)

Idade: 58 anos (Prontuário: 1*****5-3)	Idade: 62 anos (Prontuário: 1*****4-1)
Histórico sem patologia	Histórico sem patologia
	
Idade: 64 anos (Prontuário: 1*****5-0)	Idade: 67 anos (Prontuário: 1*****4-5)
Histórico sem patologia	Histórico sem patologia
	

APÊNDICE G – RELAÇÃO DOS DADOS COLETADOS POR LIMIAR

Limiar: MÉDIA

Participante		Região: Mama Direita		
Prontuário	Idade	Temperatura (°C)	Parcela ≤ Limiar	AVGA
1*****4-5	67 anos	33,1	63,82 %	N
1*****5-0	64 anos	33,34	70,58 %	S
1*****4-1	62 anos	33,76	41,12 %	S
1*****6-5	58 anos	31,58	82,87 %	S
1*****5-3	58 anos	32,22	58,45 %	S
1*****6-5	57 anos	33,3	87,63 %	S
1*****7-9	56 anos	33,07	71,6 %	S
1*****1-0	55 anos	30,08	46,09 %	S
1*****6-3	52 anos	31,55	54,77 %	S
1*****6-8	52 anos	33,43	15,89 %	N
Voluntária-3	50 anos	33,49	69,81 %	S
Voluntária-2	49 anos	33,26	40,7 %	S
Voluntária-1	48 anos	33,86	7,99 %	N
1*****6-8	47 anos	30,7	59,35 %	S
1*****8-3	42 anos	34,41	58,11 %	S
1*****3-1	40 anos	32,23	57,42 %	S
1*****0-7	40 anos	29,71	80,78 %	S
1*****8-0	34 anos	32,83	41,67 %	N
1*****5-7	29 anos	34,12	59,02 %	S
1*****8-5	25 anos	33,92	42,76 %	S

APÊNDICE G (Continuação)

Limiar: MÉDIA

Participante		Região: Mama Esquerda		
Prontuário	Idade	Temperatura (°C)	Parcela ≤ Limiar	AVGA
1*****4-5	67 anos	33,27	68,74 %	N
1*****5-0	64 anos	32,9	39 %	S
1*****4-1	62 anos	33,28	31,26 %	S
1*****6-5	58 anos	31,41	82,56 %	S
1*****5-3	58 anos	32,4	61,71 %	S
1*****6-5	57 anos	32,57	63,72 %	S
1*****7-9	56 anos	32,87	77,8 %	S
1*****1-0	55 anos	31,41	49,48 %	S
1*****6-3	52 anos	32,39	86,83 %	S
1*****6-8	52 anos	33,56	85,14 %	N
Voluntária-3	50 anos	32,97	38,35 %	S
Voluntária-2	49 anos	32,91	29,02 %	S
Voluntária-1	48 anos	33,73	24,04 %	N
1*****6-8	47 anos	31,17	40,28 %	S
1*****8-3	42 anos	33,63	27,36 %	S
1*****3-1	40 anos	32,72	73,37 %	S
1*****0-7	40 anos	30,82	78,71 %	S
1*****8-0	34 anos	32,62	35,91 %	N
1*****5-7	29 anos	34,17	52,29 %	S
1*****8-5	25 anos	33,49	18,41 %	S

APÊNDICE G (Continuação)

Limiar: MÉDIA

Participante		Região: Abdômen		
Prontuário	Idade	Temperatura (°C)	Parcela ≤ Limiar	AVGA
1*****4-5	67 anos	32,73	10,29 %	N
1*****5-0	64 anos	32,97	38,07 %	S
1*****4-1	62 anos	33,57	46,94 %	S
1*****6-5	58 anos	32,2	54,26 %	S
1*****5-3	58 anos	32,22	62,52 %	S
1*****6-5	57 anos	32,34	67,61 %	S
1*****7-9	56 anos	32,63	76,07 %	S
1*****1-0	55 anos	30,63	77,69 %	S
1*****6-3	52 anos	31	18,00 %	S
1*****6-8	52 anos	32,2	1,47 %	N
Voluntária-3	50 anos	33,15	67,84 %	S
Voluntária-2	49 anos	33,14	10,88 %	S
Voluntária-1	48 anos	33,95	41,73 %	N
1*****6-8	47 anos	31,09	14,17 %	S
1*****8-3	42 anos	33,6	23,04 %	S
1*****3-1	40 anos	32,6	50,81 %	S
1*****0-7	40 anos	29,82	36,08 %	S
1*****8-0	34 anos	32,68	39,34 %	N
1*****5-7	29 anos	33,8	43,27 %	S
1*****8-5	25 anos	33,96	22,57 %	S

APÊNDICE G (Continuação)

Limiar: MEDIANA

Participante		Região: Mama Direita		
Prontuário	Idade	Temperatura (°C)	Parcela $\leq$ Limiar	AVGA
1*****4-5	67 anos	32,72	49,93 %	N
1*****5-0	64 anos	33,07	49,65 %	S
1*****4-1	62 anos	33,85	50,1 %	S
1*****6-5	58 anos	30,97	49,85 %	S
1*****5-3	58 anos	32,04	49,91 %	S
1*****6-5	57 anos	32,46	50,04 %	S
1*****7-9	56 anos	32,81	50,07 %	S
1*****1-0	55 anos	30,19	50,01 %	S
1*****6-3	52 anos	31,47	49,92 %	S
1*****6-8	52 anos	33,74	50,78 %	N
Voluntária-3	50 anos	33,13	50,2 %	S
Voluntária-2	49 anos	33,59	50 %	S
Voluntária-1	48 anos	34,47	50,42 %	N
1*****6-8	47 anos	30,43	49,9 %	S
1*****8-3	42 anos	34,33	50,34 %	S
1*****3-1	40 anos	32,13	50,1 %	S
1*****0-7	40 anos	29,11	50,15 %	S
1*****8-0	34 anos	32,93	50,24 %	N
1*****5-7	29 anos	33,99	49,72 %	S
1*****8-5	25 anos	34,02	49,75 %	S

APÊNDICE G (Continuação)

Limiar: MEDIANA

Participante		Região: Mama Esquerda		
Prontuário	Idade	Temperatura (°C)	Parcela ≤ Limiar	AVGA
1*****4-5	67 anos	33,1	49,32 %	N
1*****5-0	64 anos	33,06	50,16 %	S
1*****4-1	62 anos	33,59	50,16 %	S
1*****6-5	58 anos	30,87	50,33 %	S
1*****5-3	58 anos	32,09	50,08 %	S
1*****6-5	57 anos	32,3	50,19 %	S
1*****7-9	56 anos	32,51	50,36 %	S
1*****1-0	55 anos	31,42	49,83 %	S
1*****6-3	52 anos	31,66	50,03 %	S
1*****6-8	52 anos	33,07	49,7 %	N
Voluntária-3	50 anos	33,23	49,97 %	S
Voluntária-2	49 anos	33,52	50 %	S
Voluntária-1	48 anos	34,26	50,04 %	N
1*****6-8	47 anos	31,29	49,96 %	S
1*****8-3	42 anos	33,97	50,06 %	S
1*****3-1	40 anos	32,36	50,1 %	S
1*****0-7	40 anos	30,23	49,78 %	S
1*****8-0	34 anos	32,81	50,05 %	N
1*****5-7	29 anos	34,14	49,57 %	S
1*****8-5	25 anos	34,06	50,24 %	S

APÊNDICE G (Continuação)

Limiar: MEDIANA

Participante		Região: Abdômen		
Prontuário	Idade	Temperatura (°C)	Parcela ≤ Limiar	AVGA
1*****4-5	67 anos	33,61	50,2 %	N
1*****5-0	64 anos	33,17	50,11 %	S
1*****4-1	62 anos	33,6	49,38 %	S
1*****6-5	58 anos	32,15	49,54 %	S
1*****5-3	58 anos	32	50,09 %	S
1*****6-5	57 anos	31,86	49,7 %	S
1*****7-9	56 anos	32,16	50,12 %	S
1*****1-0	55 anos	29,5	49,83 %	S
1*****6-3	52 anos	31,47	49,78 %	S
1*****6-8	52 anos	33,66	49,56 %	N
Voluntária-3	50 anos	32,49	49,93 %	S
Voluntária-2	49 anos	34,2	50,14 %	S
Voluntária-1	48 anos	34,09	50,26 %	N
1*****6-8	47 anos	31,7	49,9 %	S
1*****8-3	42 anos	34,39	49,89 %	S
1*****3-1	40 anos	32,59	50,25 %	S
1*****0-7	40 anos	30,07	49,95 %	S
1*****8-0	34 anos	32,95	50,16 %	N
1*****5-7	29 anos	33,9	50,29 %	S
1*****8-5	25 anos	34,45	50,07 %	S

APÊNDICE G (Continuação)

Limiar: MODA

Participante		Região: Mama Direita		
Prontuário	Idade	Temperatura (°C)	Parcela ≤ Limiar	AVGA
1*****4-5	67 anos	31,94	13,2 %	N
1*****5-0	64 anos	32,15	3,35 %	S
1*****4-1	62 anos	33,47	17,8 %	S
1*****6-5	58 anos	30,01	3,81 %	S
1*****5-3	58 anos	31,73	37 %	S
1*****6-5	57 anos	31,44	6,82 %	S
1*****7-9	56 anos	32,14	7,75 %	S
1*****1-0	55 anos	28,94	5,02 %	S
1*****6-3	52 anos	30,9	9,79 %	S
1*****6-8	52 anos	33,65	38,96 %	N
Voluntária-3	50 anos	31,82	3,26 %	S
Voluntária-2	49 anos	31,85	4,59 %	S
Voluntária-1	48 anos	34,29	37,99 %	N
1*****6-8	47 anos	29,39	3,1 %	S
1*****8-3	42 anos	34,05	26,72 %	S
1*****3-1	40 anos	30,84	4,28 %	S
1*****0-7	40 anos	29,49	83,84 %	S
1*****8-0	34 anos	32,97	53,71 %	N
1*****5-7	29 anos	33,6	20,6 %	S
1*****8-5	25 anos	33,7	28,8 %	S

APÊNDICE G (Continuação)

Limiar: MODA

Participante		Região: Mama Esquerda		
Prontuário	Idade	Temperatura (°C)	Parcela ≤ Limiar	AVGA
1*****4-5	67 anos	33,19	60,31 %	N
1*****5-0	64 anos	31,84	7,33 %	S
1*****4-1	62 anos	32,2	3,65 %	S
1*****6-5	58 anos	30,94	55,96 %	S
1*****5-3	58 anos	31,16	10,47 %	S
1*****6-5	57 anos	30,22	0,57 %	S
1*****7-9	56 anos	32,27	28,75 %	S
1*****1-0	55 anos	32,02	77,63 %	S
1*****6-3	52 anos	30,57	3,66 %	S
1*****6-8	52 anos	32,73	22,75 %	N
Voluntária-3	50 anos	33,69	75,13 %	S
Voluntária-2	49 anos	32,13	14,17 %	S
Voluntária-1	48 anos	32,79	2,94 %	N
1*****6-8	47 anos	31,73	85,69 %	S
1*****8-3	42 anos	33,45	16,96 %	S
1*****3-1	40 anos	31,01	4,33 %	S
1*****0-7	40 anos	29,36	2,33 %	S
1*****8-0	34 anos	32,21	12,85 %	N
1*****5-7	29 anos	33,9	31,69 %	S
1*****8-5	25 anos	34,36	74,79 %	S

APÊNDICE G (Continuação)

Limiar: MODA

Participante		Região: Abdômen		
Prontuário	Idade	Temperatura (°C)	Parcela ≤ Limiar	AVGA
1*****4-5	67 anos	33,7	58,14 %	N
1*****5-0	64 anos	32,8	28,42 %	S
1*****4-1	62 anos	33,48	38,52 %	S
1*****6-5	58 anos	32,15	49,54 %	S
1*****5-3	58 anos	31,94	45,9 %	S
1*****6-5	57 anos	31,6	36,75 %	S
1*****7-9	56 anos	31,65	18,64 %	S
1*****1-0	55 anos	28,35	6,17 %	S
1*****6-3	52 anos	31,29	3,6 %	S
1*****6-8	52 anos	33,62	46,75 %	N
Voluntária-3	50 anos	31,65	17,21 %	S
Voluntária-2	49 anos	34,97	18,21 %	S
Voluntária-1	48 anos	34,33	64,59 %	N
1*****6-8	47 anos	31,74	52,37 %	S
1*****8-3	42 anos	35,02	82,68 %	S
1*****3-1	40 anos	32,73	53,7 %	S
1*****0-7	40 anos	29,81	35,5 %	S
1*****8-0	34 anos	33,15	58,97 %	N
1*****5-7	29 anos	33,8	43,27 %	S
1*****8-5	25 anos	33,89	18,63 %	S

APÊNDICE G (Continuação)

Limiar: PERCENTIL

Participante		Região: Mama Direita		
Prontuário	Idade	Temperatura (°C)	Parcela ≤ Limiar	AVGA
1*****4-5	67 anos	33,17	62,94 %	N
1*****5-0	64 anos	33,29	62,94 %	S
1*****4-1	62 anos	34,03	62,36 %	S
1*****6-5	58 anos	30,84	36,84 %	S
1*****5-3	58 anos	31,64	36,85 %	S
1*****6-5	57 anos	32,28	37,25 %	S
1*****7-9	56 anos	32,64	37,22 %	S
1*****1-0	55 anos	29,84	36,97 %	S
1*****6-3	52 anos	31,32	37,23 %	S
1*****6-8	52 anos	33,61	36,62 %	N
Voluntária-3	50 anos	32,81	36,84 %	S
Voluntária-2	49 anos	33,09	37,05 %	S
Voluntária-1	48 anos	34,28	36,94 %	N
1*****6-8	47 anos	30,06	37,1 %	S
1*****8-3	42 anos	33,99	22,51 %	S
1*****3-1	40 anos	31,72	22,44 %	S
1*****0-7	40 anos	28,67	22,4 %	S
1*****8-0	34 anos	32,2	14,94 %	N
1*****5-7	29 anos	33,52	14,75 %	S
1*****8-5	25 anos	33,11	10,08 %	S

APÊNDICE G (Continuação)

Limiar: PERCENTIL

Participante		Região: Mama Esquerda		
Prontuário	Idade	Temperatura (°C)	Parcela ≤ Limiar	AVGA
1*****4-5	67 anos	33,23	62,14 %	N
1*****5-0	64 anos	33,2	62,47 %	S
1*****4-1	62 anos	33,78	62,76 %	S
1*****6-5	58 anos	30,69	36,84 %	S
1*****5-3	58 anos	31,71	36,87 %	S
1*****6-5	57 anos	31,85	36,88 %	S
1*****7-9	56 anos	32,35	37,38 %	S
1*****1-0	55 anos	31,03	36,87 %	S
1*****6-3	52 anos	31,4	36,88 %	S
1*****6-8	52 anos	32,84	37,33 %	N
Voluntária-3	50 anos	32,9	36,88 %	S
Voluntária-2	49 anos	33,09	37,23 %	S
Voluntária-1	48 anos	33,97	37,34 %	N
1*****6-8	47 anos	31,08	36,81 %	S
1*****8-3	42 anos	33,56	22,55 %	S
1*****3-1	40 anos	31,77	22,48 %	S
1*****0-7	40 anos	29,77	22,73 %	S
1*****8-0	34 anos	32,21	15,05 %	N
1*****5-7	29 anos	33,6	15,25 %	S
1*****8-5	25 anos	33,34	9,85 %	S


APÊNDICE G (Continuação)

Limiar: PERCENTIL


Participante		Região: Abdômen		
Prontuário	Idade	Temperatura (°C)	Parcela ≤ Limiar	AVGA
1*****4-5	67 anos	33,75	62,44 %	N
1*****5-0	64 anos	33,46	62,39 %	S
1*****4-1	62 anos	33,73	62,41 %	S
1*****6-5	58 anos	32,04	36,91 %	S
1*****5-3	58 anos	31,84	36,44 %	S
1*****6-5	57 anos	31,56	36,82 %	S
1*****7-9	56 anos	31,95	37,22 %	S
1*****1-0	55 anos	29,05	36,79 %	S
1*****6-3	52 anos	31,33	37,25 %	S
1*****6-8	52 anos	33,45	36,88 %	N
Voluntária-3	50 anos	32,14	36,94 %	S
Voluntária-2	49 anos	33,91	37,29 %	S
Voluntária-1	48 anos	33,98	37,39 %	N
1*****6-8	47 anos	31,49	37,17 %	S
1*****8-3	42 anos	33,38	22,44 %	S
1*****3-1	40 anos	32,13	22,59 %	S
1*****0-7	40 anos	29,59	22,4 %	S
1*****8-0	34 anos	32,07	15,2 %	N
1*****5-7	29 anos	33,34	15,18 %	S
1*****8-5	25 anos	33,68	9,9 %	S

APÊNDICE H – DISTRIBUIÇÕES PERCENTUAIS POR LIMIARES

Limiar: Percentil (referência)




Limiar: Pontos intermediários dos clusters por GMM




APÊNDICE H (Continuação)

Limiar: Medianas



Limiar: Modas



APÊNDICE H (Continuação)

Limiar: Médias

