



**UNIVERSIDADE ESTADUAL DO OESTE DO PARANÁ  
CENTRO DE ENGENHARIAS E CIÊNCIAS EXATAS  
PROGRAMA DE PÓS-GRADUAÇÃO EM QUÍMICA**

**CONSTRUÇÃO DE MODELOS DE PREDIÇÃO QSA(P)R COM  
OBJETIVOS AMBIENTAIS E TOXICOLÓGICOS**

**Natalya Aline Barros Ribeiro da Silva**

**Toledo – PR  
2026**



**UNIVERSIDADE ESTADUAL DO OESTE DO PARANÁ  
CENTRO DE ENGENHARIAS E CIÊNCIAS EXATAS  
PROGRAMA DE PÓS-GRADUAÇÃO EM QUÍMICA**

**CONSTRUÇÃO DE MODELOS DE PREDIÇÃO QSA(P)R COM  
OBJETIVOS AMBIENTAIS E TOXICOLÓGICOS**

**Natalya Aline Barros Ribeiro da Silva**

Dissertação apresentada ao Programa de Pós-Graduação em Química da Universidade Estadual do Oeste do Paraná, Unioeste/*Campus* de Toledo, como parte dos requisitos para a obtenção do Título de Mestre em Química.

**Orientador(a): Eduardo Borges de Melo**

**Toledo – PR  
2026**

Ficha de identificação da obra elaborada através do Formulário de Geração Automática do Sistema de Bibliotecas da Unioeste.

DA SILVA, NATALYA ALINE BARROS RIBEIRO  
CONSTRUÇÃO DE MODELOS DE PREDIÇÃO QSA(P)R COM OBJETIVOS  
AMBIENTAIS E TOXICOLÓGICOS / NATALYA ALINE BARROS RIBEIRO DA  
SILVA; orientador EDUARDO BORGES DE MELO. -- Toledo, 2026.  
119 p.

Dissertação (Mestrado Acadêmico Campus de Toledo) --  
Universidade Estadual do Oeste do Paraná, Centro de  
Engenharias e Ciências Exatas, Programa de Pós-Graduação em  
Química, 2026.

1. QSAR. 2. Toxicidade ambiental. 3. POPs. I. DE MELO,  
EDUARDO BORGES, orient. II. Título.

# CONSTRUÇÃO DE MODELOS DE PREDIÇÃO QSA(P)R COM OBJETIVOS AMBIENTAIS E TOXICOLÓGICOS

Natalya Aline Barros Ribeiro da Silva

## Resumo

Esta dissertação teve como objetivo o desenvolvimento de modelos de predição QSAR (Quantitative Structure–Activity Relationship) e QSPR (Quantitative Structure–Property Relationship) aplicados à avaliação de propriedades toxicológicas e ambientais de compostos orgânicos de interesse regulatório. O estudo concentrou-se em três grupos principais de compostos: os compostos per- e polifluoroalquilados (PFAS), pesticidas classificados como poluentes orgânicos persistentes (POPs) e éteres difenílicos substituídos, incluindo derivados polimetoxilados, polihidroxilados, metoxilados policlorados e hidroxilados policlorados. A persistência ambiental, a elevada mobilidade e o potencial tóxico dessas substâncias justificam a necessidade do desenvolvimento de ferramentas computacionais capazes de auxiliar na avaliação de seus riscos de forma rápida, confiável e com menor dependência de ensaios experimentais. O primeiro estudo teve como objetivo desenvolver modelos QSAR para prever parâmetros de toxicidade oral e inalatória de PFAS em ratos e camundongos, utilizando descritores moleculares bidimensionais e regressão por mínimos quadrados parciais (PLS). O segundo estudo concentrou-se no desenvolvimento de modelos QSAR por análise discriminante por mínimos quadrados parciais (PLS-DA) para classificação da toxicidade por contato de pesticidas em abelhas (*Apis mellifera*), permitindo identificar padrões estruturais associados ao potencial ecotoxicológico desses compostos. O terceiro estudo consistiu no desenvolvimento de modelos QSPR para predição do coeficiente de adsorção ao carbono orgânico do solo (LogK<sub>oc</sub>) de éteres difenílicos substituídos. Foram comparados diferentes algoritmos para estimativa dos descritores LogP e LogS, bem como avaliada a aplicação de um descritor híbrido (LogSp), obtido pela combinação entre lipofilicidade e solubilidade em água. Os resultados demonstraram que os descritores baseados em LogP apresentaram melhor desempenho preditivo, destacando-se o algoritmo MLOGP entre os métodos teóricos avaliados. Além disso, os modelos desenvolvidos com o descritor híbrido Original\_LogSp apresentaram desempenho superior aos modelos construídos apenas com descritores individuais, evidenciando que a combinação entre lipofilicidade e solubilidade melhora a representação das propriedades relacionadas à sorção no solo. Os modelos desenvolvidos apresentaram adequada robustez estatística, estabilidade e elevada capacidade preditiva, atendendo aos critérios de validação recomendados para estudos QSAR/QSPR. Os resultados obtidos demonstram o potencial dessas abordagens computacionais como ferramentas de apoio à avaliação toxicológica e ambiental, contribuindo para a compreensão dos mecanismos moleculares relacionados à toxicidade, mobilidade e persistência de contaminantes orgânicos. Dessa forma, esta dissertação fornece modelos preditivos capazes de auxiliar na avaliação de risco, na regulamentação de substâncias químicas e no desenvolvimento de compostos mais seguros, reduzindo a necessidade de ensaios experimentais e favorecendo estratégias mais sustentáveis para a proteção da saúde humana e do meio ambiente.

Palavras-chave: QSAR, Toxicidade ambiental, POPs, PFAS, Pesticidas.

# CONSTRUCTION OF QSAR/QSPR PREDICTION MODELS WITH ENVIRONMENTAL AND TOXICOLOGICAL OBJECTIVES

Natalya Aline Barros Ribeiro da Silva

## Abstract

This dissertation aimed to develop QSAR (Quantitative Structure–Activity Relationship) and QSPR (Quantitative Structure–Property Relationship) predictive models for the assessment of toxicological and environmental properties of organic compounds of regulatory interest. The study focused on three main groups of compounds: per- and polyfluoroalkyl substances (PFAS), pesticides classified as persistent organic pollutants (POPs), and substituted diphenyl ethers, including polymethoxylated, polyhydroxylated, methoxylated polychlorinated, and hydroxylated polychlorinated derivatives. The environmental persistence, high mobility, and toxic potential of these substances highlight the need for computational tools capable of supporting risk assessment in a rapid, reliable manner while reducing the dependence on experimental testing. The first study aimed to develop QSAR models to predict oral and inhalation toxicity parameters of PFAS in rats and mice using two-dimensional molecular descriptors and partial least squares (PLS) regression. The second study focused on developing QSAR models based on partial least squares discriminant analysis (PLS-DA) to classify the contact toxicity of pesticides toward honeybees (*Apis mellifera*), enabling the identification of structural patterns associated with the ecotoxicological potential of these compounds. The third study consisted of developing QSPR models to predict the soil organic carbon sorption coefficient (LogKoc) of substituted diphenyl ethers. Different algorithms for estimating LogP and LogS descriptors were compared, and the application of a hybrid descriptor (LogSp), obtained by combining lipophilicity and water solubility, was evaluated. The results demonstrated that LogP-based descriptors exhibited superior predictive performance, with the MLOGP algorithm showing the best performance among the theoretical methods evaluated. Furthermore, models developed using the hybrid Original\_LogSp descriptor outperformed those based solely on individual descriptors, demonstrating that the combination of lipophilicity and water solubility improves the representation of physicochemical properties associated with soil sorption. The developed models exhibited satisfactory statistical robustness, stability, and high predictive performance, meeting the recommended validation criteria for QSAR/QSPR studies. The results demonstrate the potential of these computational approaches as valuable tools for toxicological and environmental assessment, contributing to the understanding of the molecular mechanisms underlying toxicity, mobility, and persistence of organic contaminants. Therefore, this dissertation provides predictive models that can support risk assessment, chemical regulation, and the development of safer compounds while reducing the need for experimental testing and promoting more sustainable strategies for protecting human health and the environment.

**Keywords:** QSAR, Environmental toxicity, POPs, PFAS, Pesticides

## LISTA DE ABREVIATURAS E SIGLAS

|                  |                                                                                                       |
|------------------|-------------------------------------------------------------------------------------------------------|
| AAC              | – Coeficientes Autoscalados (Autoscaled Coefficients)                                                 |
| ACU              | – Acurácia                                                                                            |
| AD               | – Domínio de Aplicabilidade (Applicability Domain)                                                    |
| ALOGP            | – Algoritmo para cálculo do coeficiente de partição octanol/água                                      |
| ALOGpS           | – Algoritmo para cálculo da solubilidade aquosa                                                       |
| CATS2D           | – Chemically Advanced Template Search 2D                                                              |
| cLogP            | – Coeficiente calculado de partição octanol/água                                                      |
| ESOL             | – Estimativa de Solubilidade (Estimated Solubility)                                                   |
| F                | - Valor da estatística F utilizado para avaliar a significância do modelo                             |
| F crítico        | - Valor crítico da distribuição F utilizado como critério para aceitação da significância estatística |
| F1-Score         | – Média harmônica entre precisão e sensibilidade                                                      |
| Koc              | – Coeficiente de sorção normalizado ao carbono orgânico do solo                                       |
| LC <sub>50</sub> | – Concentração letal para 50% dos organismos                                                          |
| LD <sub>50</sub> | – Dose letal para 50% dos organismos                                                                  |
| LL               | – Interações lipofílicas-lipofílicas                                                                  |
| LNO              | – Leave-N-Out                                                                                         |
| LogKoc           | – Logaritmo do coeficiente de sorção normalizado ao carbono orgânico do solo                          |
| LogKow           | – Logaritmo do coeficiente de partição octanol/água                                                   |
| LogP             | – Logaritmo do coeficiente de partição octanol/água, utilizado como descritor de lipofilicidade       |
| LogS             | – Logaritmo da solubilidade em água                                                                   |
| LogSp            | – Descritor híbrido derivado de LogP e LogS                                                           |
| LOO              | – Leave-One-Out                                                                                       |
| LV               | – Variável Latente (Latent Variable)                                                                  |
| MCC              | – Coeficiente de Correlação de Matthews (Matthews Correlation Coefficient)                            |
| MLOGP            | – Método de cálculo do LogP de Moriguchi                                                              |
| OECD / OCDE      | – Organização para Cooperação e Desenvolvimento Econômico                                             |
| OPS              | – Ordered Predictors Selection                                                                        |
| PCA              | – Análise de Componentes Principais (Principal Component Analysis)                                    |

PFAS – Substâncias Per- e Polifluoroalquiladas (Per- and Polyfluoroalkyl Substances)

PFOS – Perfluorooctano Sulfonato

PFOA – Ácido Perfluorooctanoico

PLS – Mínimos Quadrados Parciais (Partial Least Squares)

PLS-DA – Análise Discriminante por Mínimos Quadrados Parciais (Partial Least Squares Discriminant Analysis)

POPs – Poluentes Orgânicos Persistentes

PRESS – Soma dos Quadrados dos Erros de Predição (Prediction Error Sum of Squares)

$Q^2$  – Coeficiente de validação cruzada

$Q^2_{\text{LOO}}$  – Coeficiente de validação cruzada Leave-One-Out

QSPR – Relação Quantitativa Estrutura–Propriedade (Quantitative Structure–Property Relationship)

QSAR – Relação Quantitativa Estrutura–Atividade (Quantitative Structure–Activity Relationship)

$R^2$  – Coeficiente de determinação

$R^2_{\text{pred}}$  – Coeficiente de determinação preditivo externo

RMSEC – Raiz do Erro Quadrático Médio da Calibração

RMSECV – Raiz do Erro Quadrático Médio da Validação Cruzada

RMSEP – Raiz do Erro Quadrático Médio de Predição

SAR – Relação Estrutura–Atividade (Structure–Activity Relationship)

SMILES – Simplified Molecular Input Line Entry System

VIP – Importância da Variável na Projeção (Variable Importance in Projection)

VL – Variável Latente

y-randomization – Teste de randomização da variável resposta para avaliação de sobreajuste.

## ÍNDICE DE TABELAS

|                                                                                                                                                                     |    |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| Tabela 1 – Compostos químicos avaliados e suas respectivas toxicidades agudas em abelhas (LD <sub>50</sub> em µg/abelha) com as representações SMILES .....         | 28 |
| Tabela 2 – Descritores dos modelos quantitativos .....                                                                                                              | 33 |
| Tabela 3 – Validação interna .....                                                                                                                                  | 34 |
| Tabela 4 – Validação externa .....                                                                                                                                  | 34 |
| Tabela 5 – Algoritmos teóricos empregados para predição dos parâmetros Log P e Log S, com respectivas fontes e referências.....                                     | 41 |
| Tabela 6 – Propriedades físico-químicas calculadas para os compostos analisados neste estudo .....                                                                  | 42 |
| Tabela 7 – Parâmetros estatísticos da validação interna do modelo QSPR para predição do LogKoc .....                                                                | 44 |
| Tabela 8 – Parâmetros estatísticos da validação externa do modelo QSPR desenvolvido para predição do LogKoc .....                                                   | 45 |
| Tabela 9 – Parâmetros estatísticos das regressões univariadas utilizando descritores de LogP e LogS para predição do LogKoc .....                                   | 46 |
| Tabela 10 – Parâmetros estatísticos da validação interna das regressões univariadas utilizando descritores de LogP e LogS para predição do LogKoc .....             | 47 |
| Tabela 11 – Parâmetros estatísticos da validação externa das regressões univariadas utilizando descritores de LogP e LogS para predição do LogKoc .....             | 48 |
| Tabela 12 – Modelos de predição usando os LogP e LogS selecionados, suas respectivas equações QSPR univariadas e métricas de validação interna .....                | 50 |
| Tabela 13 – Parâmetros estatísticos da validação externa dos modelos univariados construídos com diferentes algoritmos de LogP e LogS para predição do LogKoc ..... | 51 |
| Tabela 14 – Descritores selecionados para o Modelo 1 .....                                                                                                          | 54 |
| Tabela 15 – Modelos de predição usando os LogP e LogSw selecionados, suas respectivas equações QSPR univariadas e métricas de validação interna .....               | 57 |

## ÍNDICE DE FIGURAS

|                                                                                                                                            |    |
|--------------------------------------------------------------------------------------------------------------------------------------------|----|
| Figura 1 – Desempenho do modelo de classificação em validação e randomização.....                                                          | 35 |
| Figura 2 – Gráfico de dispersão entre os valores medidos e preditos pelo modelo QSAR .....                                                 | 36 |
| Figura 3 – Desempenho do modelo na etapa de predição .....                                                                                 | 36 |
| Figura 4 – Distribuição dos escores X para os conjuntos de calibração e teste .....                                                        | 37 |
| Figura 5 – Gráfico de dispersão dos valores medidos versus preditos pelo modelo QSAR .....                                                 | 37 |
| Figura 6 – Gráficos obtidos com os testes de validação cruzada LNO (A) e de <i>y-randomization</i> (B) para o Modelo 1 .....               | 53 |
| Figura 7 – Gráficos obtidos com os testes de validação cruzada LNO e de <i>y-randomization</i> para os Modelos 2 (A e B) e 3 (C e D) ..... | 58 |
| Figura 8 – Gráficos obtidos com os testes de validação cruzada LNO e de <i>y-randomization</i> para os Modelos 4 (A e B) e 5 (C e D) ..... | 59 |

## SUMÁRIO

|                                                                                                                                                                |    |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| LISTA DE ABREVIATURAS E SIGLAS .....                                                                                                                           | 5  |
| ÍNDICE DE TABELAS .....                                                                                                                                        | 7  |
| ÍNDICE DE FIGURAS .....                                                                                                                                        | 8  |
| SUMÁRIO .....                                                                                                                                                  | 9  |
| 1. INTRODUÇÃO .....                                                                                                                                            | 9  |
| 2. OBJETIVOS .....                                                                                                                                             | 11 |
| 2.1 Objetivo Geral .....                                                                                                                                       | 11 |
| 2.2 Objetivos específicos .....                                                                                                                                | 11 |
| 3. REVISÃO BIBLIOGRÁFICA .....                                                                                                                                 | 12 |
| 3.1 Químioinformática e Modelagem Molecular .....                                                                                                              | 12 |
| 3.2 Descritores Moleculares e Construção de Modelos QSAR/QSPR .....                                                                                            | 13 |
| 3.3 Validação de Modelos QSAR/QSPR .....                                                                                                                       | 15 |
| 3.4 Poluentes Orgânicos Persistentes (POPs) .....                                                                                                              | 17 |
| 3.5 Compostos Per- e Polifluoroalquilados (PFAS) .....                                                                                                         | 18 |
| 3.6 Pesticidas e Toxicidade para <i>Apis mellifera</i> .....                                                                                                   | 19 |
| 3.7 Éteres Difenílicos Substituídos e Predição do Coeficiente de Adsorção no Solo (LogKoc) .....                                                               | 21 |
| 4. METODOLOGIA .....                                                                                                                                           | 22 |
| 4.1 Estrutura Metodológica .....                                                                                                                               | 22 |
| 4.2 Conjuntos de Dados .....                                                                                                                                   | 23 |
| 5. ESTUDO I – Desenvolvimento de Modelos QSAR para Predição da Toxicidade de Compostos Per- e Polifluoroalquilados (PFAS) em Ratos e Camundongos .....         | 24 |
| 5.1 - Conjunto de dados .....                                                                                                                                  | 24 |
| 5.2 - Cálculo e seleção de descritores .....                                                                                                                   | 24 |
| 5.3 - Construção e validação dos modelos .....                                                                                                                 | 25 |
| 5.4 – Resultados e discussão .....                                                                                                                             | 26 |
| 5.5 – Considerações finais do estudo .....                                                                                                                     | 27 |
| 6. ESTUDO II – Desenvolvimento de Modelos QSAR para Predição da Toxicidade de Pesticidas em <i>Apis mellifera</i> .....                                        | 27 |
| 6.1 - Conjunto de dados .....                                                                                                                                  | 27 |
| 6.2 - Construção e validação dos modelos .....                                                                                                                 | 32 |
| 6.3 - Resultados e discussão .....                                                                                                                             | 33 |
| 6.4 - Considerações finais do estudo .....                                                                                                                     | 38 |
| 7. ESTUDO III – Desenvolvimento de Modelos QSPR para Predição do Coeficiente de Adsorção ao Carbono Orgânico (LogKoc) de Éteres Difenílicos Substituídos ..... | 38 |
| 7.1 Conjunto de dados .....                                                                                                                                    | 38 |
| 7.2 Metodologia .....                                                                                                                                          | 39 |
| 7.2.1 Validação dos modelos .....                                                                                                                              | 40 |
| 7.3 Algoritmos de LogP, LogS e derivação do parâmetro LogSp .....                                                                                              | 41 |
| 7.4 Modelo QSPR inicial .....                                                                                                                                  | 44 |

|                                                                         |    |
|-------------------------------------------------------------------------|----|
| 7.5 - Análise Univariada .....                                          | 45 |
| 7.6 - Análise multivariada .....                                        | 49 |
| 7.7 - Modelos multivariados utilizando o descritor LogSp.....           | 53 |
| 7.7.1 Avaliação univariada do Original_LogSp e New_LogSp .....          | 53 |
| 7.7.2 Modelos multivariados utilizando Original_LogSp e New_LogSp ..... | 55 |
| 7.8 Considerações finais do estudo .....                                | 60 |
| 8. CONCLUSÃO .....                                                      | 61 |
| 9. AGRADECIMENTOS .....                                                 | 62 |
| 10. REFERÊNCIAS.....                                                    | 62 |
| 11. ANEXOS .....                                                        | 66 |
| 11.1 Artigo 1.....                                                      | 66 |
| 11.2 Artigo 2.....                                                      | 98 |

## 1. INTRODUÇÃO

A intensificação das atividades industriais, agrícolas e tecnológicas tem ampliado significativamente a produção e a utilização de substâncias químicas sintéticas em todo o mundo. Embora esses compostos desempenhem papel fundamental no desenvolvimento econômico e na melhoria de diversos processos produtivos, muitos apresentam características que favorecem sua persistência no ambiente, mobilidade entre diferentes compartimentos ambientais, bioacumulação e potencial de provocar efeitos adversos à saúde humana e aos ecossistemas. Em consequência, a identificação e a avaliação dos riscos associados a essas substâncias constituem um dos principais desafios da Química Ambiental e da Toxicologia modernas.

Entre essas substâncias destacam-se os poluentes orgânicos persistentes (POPs), grupo de compostos caracterizado por elevada estabilidade química, resistência aos processos naturais de degradação e capacidade de bioacumulação ao longo da cadeia alimentar. Essas características favorecem sua ampla distribuição ambiental e estão associadas à ocorrência de diversos efeitos adversos sobre organismos vivos, incluindo alterações endócrinas, imunológicas, neurológicas, reprodutivas e metabólicas. Nesse contexto, compreender o comportamento ambiental e toxicológico desses compostos torna-se essencial para subsidiar ações de monitoramento, avaliação de risco e regulamentação ambiental.

A crescente diversidade de compostos químicos produzidos e comercializados torna a caracterização experimental de suas propriedades toxicológicas e ambientais um processo complexo, oneroso e demorado. Além do elevado custo financeiro e da infraestrutura necessária para a realização dos ensaios, muitos estudos dependem da utilização de animais de laboratório. Dessa forma, torna-se necessária a adoção de metodologias alternativas capazes de reduzir o número de experimentos, otimizar recursos e fornecer informações confiáveis para a identificação e a priorização de substâncias potencialmente perigosas.

Nesse cenário, a modelagem molecular e as abordagens computacionais assumem papel cada vez mais importante como ferramentas complementares aos estudos experimentais. Essas metodologias permitem estimar propriedades químicas, físico-químicas, ambientais e toxicológicas a partir das características estruturais das moléculas, contribuindo para reduzir custos, acelerar a obtenção de resultados e ampliar a capacidade de avaliação de compostos químicos. Além disso, fornecem suporte à pesquisa científica, aos processos regulatórios e ao desenvolvimento de substâncias com menor impacto ambiental.

Entre os compostos de maior interesse destacam-se os compostos per- e polifluoroalquilados (PFAS), diferentes classes de pesticidas e os éteres difenílicos substituídos. Apesar de possuírem aplicações distintas, esses grupos compartilham características relacionadas à persistência ambiental e ao potencial de provocar efeitos adversos em organismos vivos. A compreensão dos fatores que influenciam sua toxicidade, mobilidade e comportamento ambiental constitui etapa fundamental para o desenvolvimento de estratégias de avaliação de risco e para a proposição de alternativas mais seguras e sustentáveis.

Diante desse contexto, esta dissertação desenvolve modelos preditivos voltados à avaliação de propriedades toxicológicas e ambientais de diferentes classes de poluentes orgânicos persistentes. Os estudos abrangem a predição da toxicidade de compostos per- e polifluoroalquilados (PFAS) em mamíferos, a avaliação da toxicidade de pesticidas para *Apis mellifera* e a estimativa do coeficiente de sorção no solo (LogK<sub>oc</sub>) de éteres difenílicos substituídos. Embora direcionados a diferentes aplicações, os modelos compartilham uma abordagem

metodológica baseada na modelagem molecular, evidenciando o potencial dessas ferramentas na avaliação de risco químico, na compreensão do comportamento ambiental de compostos persistentes e na priorização de substâncias para estudos experimentais.

Assim, esta pesquisa reúne diferentes aplicações da modelagem molecular em um único estudo, contribuindo para o fortalecimento das metodologias preditivas aplicadas à Química Ambiental e à Toxicologia. Os modelos desenvolvidos oferecem ferramentas robustas para a predição de propriedades toxicológicas e ambientais, fornecendo subsídios para futuras pesquisas, processos regulatórios e estratégias voltadas à proteção da saúde humana e do meio ambiente.

## 2. OBJETIVOS

### 2.1 Objetivo Geral

O objetivo geral deste estudo consiste na construção de modelos de predição QSA(P)R com enfoque ambiental e toxicológico, capazes de fornecer informações quantitativas e qualitativas sobre o comportamento de compostos orgânicos persistentes e seus efeitos sobre organismos e ecossistemas.

Esses modelos têm como finalidade subsidiar a avaliação de risco, apoiar a regulamentação de substâncias químicas e orientar o desenvolvimento de compostos menos nocivos ao meio ambiente e à saúde humana.

### 2.2 Objetivos específicos

Desenvolver modelos de predição de toxicidade oral e de inalação em ratos (*Rattus norvegicus*) e camundongos (*Mus musculus*) de compostos orgânicos per- e polifluoroalquilados (PFAS);

Desenvolver modelos de predição de toxicidade de pesticidas por contato em abelhas (*Apis mellifera*);

Desenvolver modelos QSPR para a predição do coeficiente de sorção no solo (LogKoc) de pesticidas do tipo éteres difenílicos substituídos.

### 3. REVISÃO BIBLIOGRÁFICA

#### 3.1 Químioinformática e Modelagem Molecular

A crescente produção de substâncias químicas e a necessidade de compreender seu comportamento físico-químico, toxicológico e ambiental impulsionaram o desenvolvimento de ferramentas computacionais capazes de auxiliar na caracterização e na predição de propriedades moleculares. Nesse contexto, destaca-se a Químioinformática, área interdisciplinar que integra conhecimentos de Química, Matemática, Estatística e Ciência da Computação para o armazenamento, processamento, análise e interpretação de informações químicas. Por meio dessa abordagem, torna-se possível estabelecer relações entre a estrutura molecular e diferentes propriedades de interesse, fornecendo suporte ao desenvolvimento de modelos preditivos aplicados em diversas áreas da ciência, incluindo Química Ambiental, Toxicologia, Farmácia e desenvolvimento de novos materiais [1–3].

Entre as principais aplicações da Químioinformática encontra-se a modelagem molecular, que utiliza métodos computacionais para representar moléculas e prever suas propriedades químicas, físico-químicas, biológicas e ambientais. Essas metodologias baseiam-se no princípio de que moléculas estruturalmente semelhantes tendem a apresentar propriedades semelhantes, permitindo o estabelecimento de relações matemáticas entre características estruturais e parâmetros experimentais. Dessa forma, torna-se possível estimar propriedades de compostos ainda não avaliados experimentalmente, reduzindo custos, tempo de desenvolvimento e a necessidade de ensaios laboratoriais extensivos [1–3].

Nesse cenário destacam-se os modelos de Relação Quantitativa Estrutura–Atividade (Quantitative Structure–Activity Relationship – QSAR) e Relação Quantitativa Estrutura–Propriedade (Quantitative Structure–Property Relationship – QSPR), amplamente empregados para correlacionar características estruturais de moléculas com atividades biológicas ou propriedades físico-químicas. Enquanto os modelos QSAR são direcionados à predição de atividades biológicas e parâmetros toxicológicos, os modelos QSPR são utilizados para estimar propriedades físico-químicas e ambientais, como solubilidade, coeficiente de partição octanol/água (LogP) e coeficiente de sorção no solo (LogK<sub>oc</sub>). Quando adequadamente desenvolvidos e validados, esses modelos constituem ferramentas importantes para a avaliação de risco químico, estudos ecotoxicológicos, monitoramento ambiental e processos regulatórios [1,3–6].

Os modelos QSAR/QSPR são fundamentados na obtenção de descritores moleculares, que correspondem a representações numéricas capazes de traduzir diferentes características estruturais das moléculas em variáveis quantitativas. Esses descritores podem representar propriedades constitucionais, topológicas, geométricas, eletrônicas, hidrofóbicas ou estéricas, permitindo que algoritmos computacionais identifiquem padrões relacionados à atividade biológica ou à propriedade de interesse. Atualmente, diversos programas especializados possibilitam o cálculo de milhares de descritores moleculares, entre eles Dragon, AlvaDesc e Mordred, ampliando significativamente as possibilidades de construção de modelos preditivos [3–6].

De acordo com Alves et al. (2018), os descritores moleculares constituem a base dos modelos QSAR/QSPR, uma vez que convertem a informação estrutural das moléculas em parâmetros quantitativos passíveis de tratamento estatístico. Em sua forma mais simples, um modelo QSAR pode ser representado por uma regressão linear envolvendo um único descritor molecular. Entretanto, considerando a complexidade dos

fenômenos biológicos e ambientais, a maioria dos modelos atualmente desenvolvidos é multivariada, incorporando simultaneamente diferentes descritores para aumentar a capacidade explicativa e preditiva dos modelos [5].

A construção de modelos QSAR/QSPR compreende diferentes etapas, iniciando-se pela seleção de um conjunto de compostos com propriedades experimentais conhecidas. Em seguida, cada molécula é representada por sua estrutura química, geralmente utilizando a notação Simplified Molecular Input Line Entry System (SMILES), a partir da qual são calculados os descritores moleculares. Posteriormente, esses descritores passam por procedimentos de pré-processamento e seleção de variáveis, reduzindo redundâncias e eliminando informações pouco relevantes para a modelagem estatística. Essa etapa é fundamental para aumentar a robustez dos modelos e minimizar problemas associados à multicolinearidade entre variáveis independentes [3–7].

Entre as metodologias mais utilizadas para seleção de descritores destaca-se o algoritmo Ordered Predictors Selection (OPS), implementado no software QSAR-Modeling. Esse método realiza a seleção ordenada dos descritores com base em sua relevância estatística, utilizando informações provenientes da regressão por mínimos quadrados parciais (Partial Least Squares – PLS). Além da seleção de variáveis, o programa disponibiliza ferramentas para validação cruzada, detecção de valores discrepantes (outliers) e otimização do número de variáveis latentes, contribuindo para a obtenção de modelos mais robustos e confiáveis [7].

Outra ferramenta amplamente empregada na modelagem QSAR é o software Chemoface, que permite a aplicação de diferentes métodos de análise multivariada, incluindo regressão por mínimos quadrados parciais (PLS) e análise discriminante por mínimos quadrados parciais (PLS-DA). Essas metodologias possibilitam tanto a construção de modelos quantitativos quanto a classificação de compostos em diferentes categorias toxicológicas, sendo amplamente utilizadas em estudos de Química Ambiental, Toxicologia e Quimiometria. Além disso, o programa disponibiliza diferentes procedimentos de validação interna e externa, contribuindo para avaliar a robustez, a capacidade preditiva e a aplicabilidade dos modelos desenvolvidos [1,7–8].

O crescente avanço das metodologias de Químioinformática ampliou significativamente a utilização de modelos QSAR/QSPR em pesquisas voltadas à avaliação toxicológica e ambiental. Essas abordagens permitem estimar propriedades de um grande número de compostos em curto intervalo de tempo, reduzindo custos experimentais e contribuindo para a diminuição do uso de animais de laboratório. Dessa forma, os modelos computacionais tornaram-se ferramentas estratégicas para a triagem de substâncias químicas, avaliação de risco, desenvolvimento de novos compostos e apoio à regulamentação ambiental, consolidando-se como uma das principais aplicações da modelagem molecular na pesquisa científica contemporânea [1–3].

### **3.2 Descritores Moleculares e Construção de Modelos QSAR/QSPR**

Os modelos QSAR/QSPR são fundamentados na utilização de descritores moleculares, que consistem em representações numéricas capazes de traduzir diferentes características estruturais das moléculas em variáveis quantitativas. Esses descritores permitem converter informações químicas complexas em dados passíveis de tratamento estatístico, possibilitando o estabelecimento de relações entre a estrutura molecular e

propriedades biológicas, toxicológicas ou físico-químicas de interesse. Dessa forma, os descritores constituem a base para a construção de modelos preditivos, uma vez que representam matematicamente propriedades relacionadas à composição, conectividade, geometria, distribuição eletrônica, hidrofobicidade, polaridade e outros aspectos estruturais das moléculas [3–6].

A obtenção de descritores moleculares inicia-se a partir da representação estrutural dos compostos, geralmente utilizando o sistema SMILES (Simplified Molecular Input Line Entry System), que descreve a estrutura química por meio de uma sequência padronizada de caracteres. Essas representações são processadas em programas especializados capazes de calcular milhares de descritores pertencentes a diferentes categorias, incluindo descritores constitucionais, topológicos, geométricos, eletrônicos, baseados em grafos, autocorrelação e propriedades físico-químicas. O elevado número de variáveis disponíveis amplia a capacidade de descrição das moléculas, porém também aumenta a complexidade estatística da modelagem, tornando necessária a aplicação de procedimentos de seleção de variáveis [3–6].

Segundo Alves et al. (2018), modelos QSAR/QSPR modernos são desenvolvidos utilizando grandes bancos de compostos e milhares de descritores moleculares calculados por diferentes algoritmos computacionais. A utilização de múltiplas classes de descritores permite representar diferentes aspectos estruturais das moléculas e aumenta a probabilidade de identificar relações significativas entre a estrutura química e a propriedade investigada. Entretanto, a presença de descritores redundantes ou altamente correlacionados pode comprometer a robustez e a capacidade preditiva dos modelos, justificando a necessidade de técnicas específicas para seleção das variáveis mais informativas [5].

Diversos programas computacionais foram desenvolvidos para o cálculo de descritores moleculares, destacando-se Dragon, AlvaDesc e Mordred. Entre eles, o Dragon é um dos softwares mais utilizados em estudos QSAR/QSPR, permitindo o cálculo de milhares de descritores derivados de estruturas bidimensionais e tridimensionais. Esses descritores abrangem diferentes classes estruturais e constituem uma importante fonte de informações para o desenvolvimento de modelos preditivos aplicados à Química Ambiental, Toxicologia e Química Medicinal [3–6].

Após o cálculo dos descritores, torna-se necessária a realização de etapas de pré-processamento, destinadas a eliminar variáveis constantes, redundantes ou pouco informativas. Esse procedimento reduz a dimensionalidade das matrizes de dados, melhora a estabilidade estatística dos modelos e minimiza problemas decorrentes da multicolinearidade entre descritores. Além disso, contribui para reduzir o risco de sobreajuste (overfitting), favorecendo o desenvolvimento de modelos com maior capacidade de generalização [5–7].

Entre os métodos empregados para seleção de variáveis destaca-se o algoritmo Ordered Predictors Selection (OPS), implementado no software QSAR-Modeling. Esse algoritmo realiza uma ordenação dos descritores com base em sua relevância estatística, utilizando vetores informativos obtidos a partir da regressão por mínimos quadrados parciais (PLS). A seleção ocorre de forma progressiva, permitindo identificar o conjunto de descritores que proporciona o melhor desempenho estatístico para cada modelo. Além da seleção de variáveis, o programa disponibiliza ferramentas para otimização do número de variáveis latentes, validação cruzada, detecção de valores discrepantes (outliers) e avaliação da robustez dos modelos, tornando-se uma ferramenta amplamente empregada na construção de modelos QSAR/QSPR [7].

A modelagem propriamente dita é geralmente realizada por meio da regressão por mínimos quadrados parciais (Partial Least Squares – PLS), uma das técnicas quimiométricas mais utilizadas em estudos QSAR/QSPR. O método PLS apresenta elevada eficiência na análise de conjuntos de dados contendo grande número de descritores correlacionados, reduzindo a dimensionalidade do sistema por meio da construção de variáveis latentes que maximizam simultaneamente a variância dos descritores e sua correlação com a variável resposta. Essa característica torna o PLS particularmente adequado para problemas envolvendo elevado número de variáveis e relativamente poucas amostras, situação frequentemente encontrada em estudos de modelagem molecular [5,7–8].

Quando o objetivo consiste na classificação dos compostos em categorias distintas, como compostos tóxicos e não tóxicos, utiliza-se a Análise Discriminante por Mínimos Quadrados Parciais (Partial Least Squares Discriminant Analysis – PLS-DA). Essa abordagem adapta os princípios da regressão PLS para problemas de classificação supervisionada, permitindo identificar padrões estruturais associados às diferentes classes e fornecendo modelos capazes de classificar novas moléculas de acordo com suas características químicas. Em estudos ecotoxicológicos e toxicológicos, o PLS-DA tem sido amplamente empregado para classificação de compostos quanto ao potencial tóxico e à identificação dos descritores moleculares mais relevantes para cada classe [1,7–8].

A combinação entre descritores moleculares, técnicas de seleção de variáveis e métodos quimiométricos como PLS e PLS-DA constitui uma das principais estratégias utilizadas atualmente na construção de modelos QSAR/QSPR. Essas abordagens permitem desenvolver modelos robustos, interpretáveis e com elevada capacidade preditiva, contribuindo para a compreensão das relações entre estrutura molecular e propriedades químicas, ambientais e toxicológicas. Além disso, fornecem suporte ao desenvolvimento de novas substâncias químicas, à avaliação de risco e aos processos regulatórios voltados à proteção da saúde humana e do meio ambiente [1,3,5–8].

### **3.3 Validação de Modelos QSAR/QSPR**

A confiabilidade de um modelo QSAR/QSPR depende não apenas de sua capacidade de ajustar adequadamente os dados utilizados na calibração, mas, principalmente, de sua habilidade em realizar previsões confiáveis para compostos não utilizados durante a construção do modelo. Dessa forma, a validação constitui uma etapa indispensável no desenvolvimento de modelos preditivos, permitindo avaliar sua robustez, estabilidade, capacidade de generalização e aplicabilidade em diferentes contextos científicos e regulatórios [1,7–10].

O processo de validação compreende procedimentos destinados a verificar se as relações estabelecidas entre os descritores moleculares e a variável resposta representam um comportamento químico real ou apenas um ajuste estatístico específico ao conjunto de dados utilizado na modelagem. Modelos que apresentam excelente desempenho apenas durante a calibração podem sofrer de sobreajuste (overfitting), perdendo sua capacidade preditiva quando aplicados a novos compostos. Por essa razão, diferentes estratégias de validação interna e externa são empregadas para garantir a confiabilidade dos modelos desenvolvidos [7–10].

A validação interna tem como objetivo avaliar a estabilidade do modelo durante sua construção. Entre os métodos mais empregados destaca-se a validação cruzada (cross-validation), especialmente o procedimento Leave-One-Out (LOO), no qual cada amostra é removida individualmente do conjunto de calibração e posteriormente utilizada para avaliar a capacidade preditiva do modelo construído com as demais observações. Esse procedimento fornece importantes parâmetros estatísticos, como o coeficiente de validação cruzada ( $Q^2$ ), o erro quadrático médio da validação cruzada (RMSECV) e o Prediction Error Sum of Squares (PRESS), amplamente utilizados para verificar a consistência interna dos modelos [7–8].

Outra estratégia frequentemente empregada é a validação Leave-N-Out (LNO), que consiste na remoção simultânea de diferentes subconjuntos de amostras durante sucessivas etapas de validação. Esse procedimento permite avaliar a estabilidade do modelo frente a pequenas alterações no conjunto de dados, fornecendo uma estimativa mais robusta da capacidade preditiva interna e reduzindo a possibilidade de que o desempenho observado seja consequência da distribuição específica das amostras utilizadas na calibração [7–8].

Além dos procedimentos de validação cruzada, recomenda-se a aplicação do teste de y-randomization, utilizado para verificar se a correlação obtida entre os descritores moleculares e a variável resposta ocorreu de maneira significativa ou apenas por acaso. Nesse procedimento, os valores da variável resposta são aleatoriamente reorganizados e novos modelos são construídos utilizando os mesmos descritores moleculares. A obtenção de modelos com baixo desempenho após a randomização confirma que o modelo original apresenta fundamento estatístico consistente e que suas relações estruturais não são decorrentes de correlações aleatórias [7–8].

A validação externa representa uma das etapas mais importantes na avaliação de modelos QSAR/QSPR, pois verifica sua capacidade de realizar previsões para compostos que não participaram do processo de calibração. Para isso, o conjunto de dados é dividido em subconjuntos independentes de calibração e teste, sendo o desempenho avaliado por diferentes parâmetros estatísticos, como o coeficiente de determinação preditivo externo ( $R^2_{pred}$ ), o erro quadrático médio de predição (RMSEP) e os coeficientes propostos por Golbraikh e Tropsha, amplamente utilizados para avaliar a qualidade das previsões externas [8–10].

Além da validação estatística, recomenda-se a determinação do Domínio de Aplicabilidade (Applicability Domain – AD), responsável por definir o espaço químico no qual o modelo pode ser utilizado com segurança. O domínio de aplicabilidade permite identificar moléculas estruturalmente muito diferentes daquelas empregadas durante a calibração, evitando extrapolações inadequadas e aumentando a confiabilidade das previsões. A avaliação do AD normalmente é realizada por meio da análise de alavancagem (leverage) associada aos resíduos de Student, permitindo identificar observações influentes e possíveis valores discrepantes (outliers) [1,8–10].

Para garantir a aceitação internacional dos modelos QSAR/QSPR, a Organização para Cooperação e Desenvolvimento Econômico (OCDE) estabeleceu cinco princípios fundamentais para sua validação e utilização em processos regulatórios. Esses princípios determinam que todo modelo deve apresentar: (i) definição clara do ponto final (endpoint); (ii) algoritmo de modelagem claramente descrito; (iii) domínio de aplicabilidade definido; (iv) medidas apropriadas de desempenho, robustez e capacidade preditiva; e (v) interpretação mecanística sempre que possível. O atendimento a esses critérios aumenta a transparência, a

reprodutibilidade e a credibilidade científica dos modelos, favorecendo sua utilização na avaliação de risco e na regulamentação de substâncias químicas [1,9–10].

Nos últimos anos, a adoção desses procedimentos tornou-se requisito fundamental para estudos de modelagem molecular publicados em periódicos científicos e utilizados por agências regulatórias internacionais. A combinação entre validação interna, validação externa, avaliação do domínio de aplicabilidade e conformidade com os princípios da OCDE permite o desenvolvimento de modelos estatisticamente robustos e cientificamente confiáveis, ampliando sua aplicação em estudos toxicológicos, ambientais e de desenvolvimento de novas substâncias químicas [1,7–10].

### **3.4 Poluentes Orgânicos Persistentes (POPs)**

Os Poluentes Orgânicos Persistentes (POPs) constituem um grupo de substâncias químicas caracterizadas por elevada estabilidade química, resistência aos processos naturais de degradação e capacidade de permanecer no ambiente por longos períodos. Essas características favorecem sua ampla dispersão entre diferentes compartimentos ambientais, incluindo solo, água, sedimentos e atmosfera, permitindo seu transporte por longas distâncias e sua presença mesmo em regiões remotas, distantes das fontes originais de emissão [11–14].

Além de sua persistência ambiental, muitos POPs apresentam elevada lipofilicidade, favorecendo processos de bioacumulação nos tecidos adiposos dos organismos e biomagnificação ao longo das cadeias alimentares. Como consequência, concentrações relativamente baixas presentes no ambiente podem resultar em níveis significativamente maiores em organismos localizados nos níveis tróficos superiores, aumentando o potencial de exposição da fauna silvestre e da população humana [11–14].

Diversos estudos têm demonstrado que a exposição prolongada aos POPs está associada a efeitos adversos sobre organismos terrestres e aquáticos, incluindo alterações endócrinas, imunológicas, reprodutivas, neurológicas e carcinogênicas. Em razão desses riscos, essas substâncias passaram a receber atenção crescente de agências regulatórias internacionais e da comunidade científica, especialmente quanto à necessidade de monitoramento ambiental, avaliação toxicológica e desenvolvimento de estratégias para redução de sua utilização e emissão [12–15].

Reconhecendo os impactos ambientais e os riscos à saúde humana, foi estabelecida, em 2001, a Convenção de Estocolmo sobre Poluentes Orgânicos Persistentes, tratado internacional que visa eliminar ou restringir a produção, o uso e a liberação das substâncias classificadas como POPs. Atualmente, a convenção reúne dezenas de países signatários e contempla um número crescente de compostos químicos, incluindo pesticidas organoclorados, bifenilas policloradas (PCBs), dioxinas, furanos e, mais recentemente, diferentes compostos per- e polifluoroalquilados (PFAS), reconhecidos por sua elevada persistência ambiental [13–15].

Entre os POPs de maior preocupação ambiental destacam-se os compostos per- e polifluoroalquilados (PFAS), amplamente utilizados em aplicações industriais e comerciais devido às suas propriedades hidrofóbicas e oleofóbicas; diversos pesticidas, empregados intensivamente na agricultura para o controle de pragas; e os éteres difenílicos substituídos, grupo de compostos utilizados principalmente como retardantes de chama e intermediários industriais. Apesar das diferenças estruturais e de aplicação, essas classes compartilham características relacionadas à persistência ambiental, ao potencial de transporte, à

bioacumulação e aos possíveis efeitos tóxicos sobre diferentes organismos, justificando sua investigação por meio de modelos computacionais de predição [11–16].

O crescente número de substâncias potencialmente enquadradas como POPs torna inviável a avaliação experimental individual de todos os compostos produzidos e comercializados. Ensaio toxicológicos e ambientais demandam elevados investimentos financeiros, longo tempo de execução e, frequentemente, utilização de animais de experimentação. Nesse contexto, abordagens computacionais baseadas em modelos QSAR/QSPR vêm sendo amplamente empregadas como ferramentas complementares para estimar propriedades físico-químicas, comportamento ambiental e potencial toxicológico de substâncias químicas, contribuindo para programas de monitoramento, avaliação de risco e processos regulatórios [1,3,11–16].

A utilização dessas metodologias está alinhada aos princípios da Química Verde e ao conceito dos 3Rs (Replacement, Reduction and Refinement), uma vez que possibilita reduzir a necessidade de experimentação animal, otimizar recursos laboratoriais e acelerar a triagem de compostos potencialmente perigosos. Dessa forma, os modelos computacionais representam ferramentas estratégicas para apoiar a tomada de decisões em toxicologia ambiental, química regulatória e proteção dos ecossistemas [1,10–16].

### **3.5 Compostos Per- e Polifluoroalquilados (PFAS)**

Os compostos per- e polifluoroalquilados (Per- and Polyfluoroalkyl Substances – PFAS) constituem uma ampla classe de substâncias organofluoradas sintéticas caracterizadas pela presença de cadeias carbônicas totalmente ou parcialmente fluoradas. A elevada energia da ligação carbono-flúor confere a esses compostos notável estabilidade química e térmica, tornando-os altamente resistentes aos processos naturais de degradação química, biológica e fotoquímica. Em razão dessa característica, os PFAS permanecem por longos períodos no ambiente, motivo pelo qual são frequentemente denominados "forever chemicals" ou "substâncias químicas permanentes" [17–20].

Desde a década de 1950, os PFAS vêm sendo amplamente empregados em aplicações industriais e comerciais devido às suas propriedades hidrofóbicas, oleofóbicas e de resistência ao calor. Esses compostos são utilizados na fabricação de espumas de combate a incêndios, revestimentos impermeabilizantes para tecidos e papéis, utensílios de cozinha antiaderentes, embalagens para alimentos, cosméticos, produtos eletrônicos e diversos processos industriais. O uso intensivo e prolongado dessas substâncias resultou em sua ampla dispersão ambiental, sendo atualmente detectadas em águas superficiais e subterrâneas, solos, sedimentos, atmosfera, alimentos, fauna silvestre e amostras biológicas humanas [17–21].

A elevada persistência ambiental dos PFAS está associada à dificuldade de degradação da ligação carbono-flúor, considerada uma das mais fortes da Química Orgânica. Consequentemente, esses compostos apresentam elevado potencial de transporte ambiental, podendo percorrer grandes distâncias por meio da atmosfera e dos sistemas hídricos. Além disso, diversas moléculas dessa classe apresentam capacidade de bioacumulação em organismos vivos, favorecendo a exposição contínua da biota e da população humana mesmo após a interrupção de sua utilização [18–21].

Estudos toxicológicos têm demonstrado que diferentes PFAS podem produzir efeitos adversos em organismos experimentais e em seres humanos. Entre os principais efeitos descritos na literatura destacam-se alterações hepáticas, disfunções endócrinas, alterações imunológicas, comprometimento do desenvolvimento

fetal, distúrbios reprodutivos, alterações metabólicas e aumento do risco para determinadas doenças crônicas. Embora os mecanismos de toxicidade variem entre os diferentes compostos, há consenso de que a exposição prolongada representa uma preocupação crescente para a saúde pública e para os ecossistemas [18–22].

Entre os PFAS mais investigados destacam-se o ácido perfluorooctanoico (PFOA) e o sulfonato de perfluorooctano (PFOS), considerados compostos de referência devido à ampla utilização histórica, elevada persistência e ampla distribuição ambiental. Entretanto, milhares de outros PFAS encontram-se atualmente em produção ou comercialização, muitos deles com informações toxicológicas e ambientais ainda limitadas. Esse cenário evidencia a necessidade do desenvolvimento de estratégias capazes de avaliar rapidamente o potencial tóxico dessas substâncias, especialmente diante da inviabilidade de realização de ensaios experimentais para toda a classe de compostos [17–22].

Nos últimos anos, diferentes órgãos regulatórios passaram a restringir o uso de diversos PFAS devido às evidências acumuladas sobre seus impactos ambientais e toxicológicos. A inclusão de alguns representantes dessa classe na Convenção de Estocolmo reforçou a necessidade de monitoramento ambiental e desenvolvimento de metodologias capazes de subsidiar avaliações de risco e processos regulatórios. Paralelamente, novas gerações de PFAS passaram a ser introduzidas no mercado como possíveis substitutos dos compostos tradicionais, tornando ainda mais necessária a obtenção de informações confiáveis sobre seu comportamento ambiental e perfil toxicológico [19–22].

Nesse contexto, os modelos QSAR têm se consolidado como ferramentas promissoras para estimar propriedades toxicológicas de PFAS a partir de suas características estruturais. Essas abordagens permitem correlacionar descritores moleculares com diferentes desfechos biológicos, possibilitando a triagem inicial de substâncias potencialmente perigosas, a priorização de compostos para estudos experimentais e a redução da utilização de animais em ensaios toxicológicos. Além disso, os modelos computacionais apresentam importante papel na avaliação preliminar de substâncias emergentes, para as quais ainda existem poucos dados experimentais disponíveis [1,5,17–22].

O crescente interesse científico pelos PFAS reflete a necessidade de compreender os fatores estruturais responsáveis por sua persistência ambiental e toxicidade. Nesse sentido, a aplicação de modelos QSAR representa uma abordagem eficiente para investigar as relações entre estrutura molecular e efeitos biológicos, contribuindo para o desenvolvimento de ferramentas preditivas que auxiliem a avaliação de risco ambiental e a tomada de decisões por órgãos regulatórios. Essa abordagem fundamenta um dos eixos desta dissertação, voltado ao desenvolvimento de modelos capazes de prever a toxicidade de diferentes PFAS em organismos mamíferos.

### **3.6 Pesticidas e Toxicidade para *Apis mellifera***

Os pesticidas constituem um dos principais grupos de substâncias químicas utilizados na agricultura moderna para o controle de insetos, plantas daninhas, fungos e outros organismos considerados prejudiciais à produção agrícola. O emprego desses compostos contribuiu significativamente para o aumento da produtividade e da segurança alimentar mundial; entretanto, sua utilização intensiva também resultou em impactos ambientais relevantes, decorrentes da contaminação do solo, da água, do ar e de organismos não alvo [23–26].

Após sua aplicação, os pesticidas podem sofrer processos de transporte, degradação e transformação química, alcançando diferentes compartimentos ambientais. A deriva durante a pulverização, o escoamento superficial (runoff), a lixiviação e a volatilização favorecem a dispersão dessas substâncias para áreas além do local de aplicação, aumentando a exposição de organismos terrestres e aquáticos. Como consequência, diversas espécies não alvo podem entrar em contato com esses compostos, comprometendo a biodiversidade e o equilíbrio dos ecossistemas [23–26].

Entre os organismos mais afetados destacam-se as abelhas, reconhecidas como importantes agentes polinizadores de ecossistemas naturais e agrícolas. Estima-se que uma parcela significativa das espécies vegetais cultivadas e da flora nativa dependa, total ou parcialmente, da polinização realizada por esses insetos. Dessa forma, a manutenção das populações de abelhas possui papel fundamental na conservação da biodiversidade, na produtividade agrícola e na segurança alimentar mundial [24–27].

Dentre as diferentes espécies de abelhas, *Apis mellifera* destaca-se por sua ampla distribuição geográfica, facilidade de manejo e elevada importância econômica e ecológica. Além de sua contribuição para a produção de mel, cera e outros produtos apícolas, essa espécie é considerada um dos principais organismos bioindicadores utilizados em estudos ecotoxicológicos, devido à sua elevada sensibilidade à exposição a diferentes classes de pesticidas [25–28].

A exposição das abelhas aos pesticidas pode ocorrer por diferentes vias, incluindo o contato direto durante a pulverização, o consumo de néctar e pólen contaminados e a ingestão de água proveniente de áreas agrícolas. Dependendo da classe química, da concentração e do tempo de exposição, esses compostos podem provocar efeitos letais e subletais. Entre os efeitos mais frequentemente descritos na literatura destacam-se alterações comportamentais, comprometimento da orientação espacial, redução da capacidade de forrageamento, alterações na comunicação entre indivíduos, diminuição da reprodução e aumento da mortalidade das colônias [24–29].

Nos últimos anos, o declínio observado em populações de polinizadores em diferentes regiões do mundo intensificou as discussões sobre os impactos ambientais associados ao uso indiscriminado de pesticidas. Embora diversos fatores contribuam para esse fenômeno, incluindo perda de habitat, mudanças climáticas, parasitas e doenças, numerosos estudos indicam que a exposição a pesticidas representa um dos principais fatores de estresse para as colônias de abelhas, especialmente quando associada à exposição simultânea a diferentes substâncias químicas [25–29].

A avaliação experimental da toxicidade de pesticidas em abelhas demanda protocolos laboratoriais padronizados, utilização de organismos vivos e elevados custos operacionais, além do tempo necessário para obtenção de resultados confiáveis. Considerando o grande número de ingredientes ativos registrados e o contínuo desenvolvimento de novas moléculas, torna-se inviável avaliar experimentalmente todos os compostos disponíveis. Nesse contexto, ferramentas computacionais baseadas em modelos QSAR vêm sendo amplamente utilizadas para estimar a toxicidade de pesticidas a partir de suas características estruturais, permitindo a identificação preliminar de compostos potencialmente perigosos e auxiliando na priorização de estudos experimentais [1,5,23–29].

Além de reduzir custos e tempo de desenvolvimento, os modelos QSAR contribuem para a aplicação dos princípios dos 3Rs (Replacement, Reduction and Refinement), promovendo a redução do número

de ensaios experimentais com organismos vivos. Essas abordagens representam importante ferramenta de apoio para programas de monitoramento ambiental, avaliação de risco ecológico e desenvolvimento de estratégias regulatórias voltadas à proteção dos polinizadores e da biodiversidade [1,10,23–29].

Dessa forma, compreender os fatores estruturais relacionados à toxicidade de pesticidas em *Apis mellifera* constitui um passo fundamental para o desenvolvimento de modelos preditivos capazes de subsidiar avaliações ecotoxicológicas e contribuir para a utilização mais segura dessas substâncias. Esse contexto fundamenta o segundo eixo desta dissertação, dedicado ao desenvolvimento de modelos QSAR para a predição da toxicidade de pesticidas em abelhas.

### 3.7 Éteres Difenílicos Substituídos e Predição do Coeficiente de Adsorção no Solo (LogKoc)

Os éteres difenílicos substituídos constituem uma importante classe de compostos aromáticos caracterizados pela presença de dois anéis benzênicos ligados por um átomo de oxigênio, podendo apresentar diferentes grupos substituintes, como halogênios, grupos metila, hidroxila e metoxila. Essas modificações estruturais originam moléculas com propriedades físico-químicas distintas, influenciando diretamente seu comportamento ambiental, persistência, mobilidade e potencial de bioacumulação [30–33].

Diversos compostos pertencentes a essa classe são utilizados como intermediários industriais, retardantes de chama, pesticidas ou produtos de transformação ambiental de outras substâncias químicas. Em decorrência de sua estabilidade química e resistência aos processos naturais de degradação, alguns representantes desse grupo podem permanecer por longos períodos no ambiente, despertando crescente interesse em estudos voltados à avaliação de seu destino ambiental e dos riscos associados à sua exposição [30–33].

Após serem liberados no ambiente, os éteres difenílicos substituídos podem distribuir-se entre diferentes compartimentos ambientais, como solo, água, sedimentos e atmosfera. O comportamento desses compostos depende de diversas propriedades físico-químicas, incluindo massa molecular, polaridade, hidrofobicidade, solubilidade em água e coeficiente de partição octanol/água (LogP). Essas características determinam sua mobilidade, persistência e disponibilidade para organismos vivos, influenciando diretamente seu potencial de contaminação ambiental [31–34].

Entre os parâmetros utilizados para descrever o comportamento ambiental de compostos orgânicos destaca-se o coeficiente de adsorção ao carbono orgânico do solo (LogKoc). Esse parâmetro representa a afinidade de uma substância química pela fração orgânica do solo e constitui um dos principais indicadores empregados para estimar a mobilidade de contaminantes em ambientes terrestres. Compostos que apresentam elevados valores de LogKoc tendem a permanecer adsorvidos à matéria orgânica do solo, reduzindo sua mobilidade, enquanto substâncias com baixos valores apresentam maior potencial de lixiviação e transporte para águas superficiais e subterrâneas [32–35].

O conhecimento do LogKoc é fundamental em avaliações de risco ambiental, uma vez que influencia diretamente processos de transporte, biodisponibilidade, persistência e exposição ambiental. Além disso, esse parâmetro é amplamente empregado por órgãos regulatórios para estimar o comportamento de substâncias químicas em diferentes cenários ambientais, subsidiando estudos relacionados ao registro de pesticidas, avaliação de contaminantes e gerenciamento de áreas impactadas [33–35].

A determinação experimental do LogKoc pode ser realizada por diferentes métodos laboratoriais; entretanto, esses procedimentos demandam tempo, infraestrutura especializada e custos elevados, especialmente quando aplicados a um grande número de compostos. Considerando a crescente quantidade de novas substâncias sintetizadas anualmente, torna-se cada vez mais importante o desenvolvimento de metodologias computacionais capazes de estimar esse parâmetro de forma rápida, confiável e economicamente viável [1,5,30–35].

Nesse contexto, os modelos QSPR têm sido amplamente empregados para prever propriedades físico-químicas e ambientais a partir da estrutura molecular dos compostos. Diferentemente dos modelos QSAR, que relacionam estrutura química com atividades biológicas ou toxicológicas, os modelos QSPR estabelecem relações matemáticas entre descritores moleculares e propriedades físico-químicas de interesse, como solubilidade em água (LogS), coeficiente de partição octanol/água (LogP), pressão de vapor, constante da Lei de Henry e coeficiente de adsorção ao carbono orgânico do solo (LogKoc) [3–6,30–35].

Diversos estudos demonstram que propriedades relacionadas à hidrofobicidade e à solubilidade exercem papel determinante na adsorção de compostos orgânicos ao solo. Em consequência, descritores derivados de algoritmos de cálculo de LogP e LogS têm sido frequentemente incorporados aos modelos QSPR para melhorar a capacidade de predição do LogKoc. A integração dessas informações permite representar de forma mais adequada os mecanismos envolvidos na interação entre as moléculas e a matéria orgânica do solo, contribuindo para o desenvolvimento de modelos estatisticamente robustos e com elevada capacidade preditiva [30–35].

O desenvolvimento de modelos QSPR para estimativa do LogKoc representa uma importante ferramenta para estudos ambientais, permitindo prever o comportamento de compostos ainda não avaliados experimentalmente, reduzir custos laboratoriais e auxiliar processos de avaliação de risco ambiental. Além disso, essas abordagens fornecem informações relevantes para programas de monitoramento, desenvolvimento de novos compostos e definição de estratégias regulatórias voltadas à proteção dos recursos naturais. Esse contexto fundamenta o terceiro eixo desta dissertação, dedicado ao desenvolvimento de modelos QSPR para a predição do LogKoc de éteres difenílicos substituídos.

## 4. METODOLOGIA

### 4.1 Estrutura Metodológica

O presente estudo caracteriza-se como uma pesquisa de natureza aplicada, com abordagem quantitativa, fundamentada na utilização de ferramentas de Químioinformática e Quimiometria para o desenvolvimento de modelos preditivos do tipo **QSAR (Quantitative Structure–Activity Relationship)** e **QSPR (Quantitative Structure–Property Relationship)**. A metodologia foi estruturada com o objetivo de investigar relações entre a estrutura molecular de diferentes classes de compostos químicos e propriedades toxicológicas e ambientais de interesse, empregando técnicas estatísticas multivariadas e descritores moleculares obtidos por meio de métodos computacionais.

A pesquisa foi desenvolvida em três estudos independentes, porém metodologicamente integrados. O primeiro estudo teve como objetivo desenvolver modelos QSAR para predição da toxicidade de

compostos per- e polifluoroalquilados (PFAS) em mamíferos. O segundo concentrou-se na construção de modelos QSAR para estimar a toxicidade de pesticidas em *Apis mellifera*, espécie amplamente utilizada como organismo indicador em estudos ecotoxicológicos. O terceiro estudo consistiu no desenvolvimento de modelos QSPR destinados à predição do coeficiente de adsorção ao carbono orgânico do solo (LogKoc) de éteres difenílicos substituídos.

Embora os conjuntos de dados e os desfechos avaliados sejam distintos, todos os modelos foram desenvolvidos seguindo uma metodologia padronizada, compreendendo a obtenção das estruturas moleculares, cálculo de descritores moleculares, pré-processamento dos dados, seleção de variáveis, construção dos modelos, validação estatística e avaliação do domínio de aplicabilidade. Essa padronização metodológica assegurou a comparabilidade entre os estudos e permitiu a utilização de critérios consistentes para avaliação da robustez e da capacidade preditiva dos modelos desenvolvidos.

De maneira geral, o fluxo metodológico adotado nesta pesquisa contemplou as principais etapas empregadas no desenvolvimento dos modelos QSAR/QSPR, conforme apresentado a seguir:

- Seleção dos conjuntos de dados;
- Obtenção das estruturas moleculares;
- Cálculo dos descritores moleculares;
- Pré-processamento dos dados;
- Seleção de descritores;
- Construção dos modelos QSAR/QSPR;
- Validação interna;
- Validação externa;
- Avaliação do domínio de aplicabilidade;
- Interpretação dos modelos.

## 4.2 Conjuntos de Dados

Os conjuntos de dados utilizados neste estudo foram obtidos a partir de bases de dados disponíveis na literatura científica e em bancos de dados públicos amplamente reconhecidos, selecionados de acordo com a disponibilidade de informações experimentais confiáveis para cada propriedade de interesse. Foram considerados apenas compostos que apresentavam valores experimentais consistentes, estruturas moleculares bem definidas e informações suficientes para a construção dos modelos QSAR/QSPR.

Os dados foram organizados em três conjuntos independentes, correspondentes aos diferentes objetivos desta pesquisa. O primeiro conjunto foi composto por substâncias per- e polifluoroalquiladas (PFAS), utilizadas no desenvolvimento de modelos QSAR para predição da toxicidade em mamíferos. O segundo conjunto compreendeu diferentes pesticidas empregados na construção de modelos QSAR destinados à predição da toxicidade em *Apis mellifera*. O terceiro conjunto foi constituído por éteres difenílicos substituídos, utilizados para o desenvolvimento de modelos QSPR voltados à predição do coeficiente de adsorção ao carbono orgânico do solo (LogKoc).

Antes do início da modelagem, todos os conjuntos de dados passaram por uma etapa de pré-processamento de dados, realizado a conferência e organização, visando identificar inconsistências, duplicidades e possíveis registros incompletos. Compostos que apresentavam estruturas indefinidas, ausência de informações experimentais ou incompatibilidades entre as diferentes bases consultadas foram excluídos da análise, garantindo maior confiabilidade aos modelos desenvolvidos.

Posteriormente, cada conjunto foi dividido em subconjuntos de calibração e validação externa, de modo a permitir a construção dos modelos e a avaliação independente de sua capacidade preditiva. A distribuição das amostras foi realizada considerando a representatividade estrutural dos compostos e a distribuição da variável resposta, buscando assegurar que ambos os subconjuntos apresentassem características químicas semelhantes.

As características específicas de cada conjunto de dados, incluindo número de compostos, propriedades avaliadas, fontes de obtenção e critérios de seleção, são descritas nas seções correspondentes aos três estudos desenvolvidos nesta dissertação.

## **5. ESTUDO I – Desenvolvimento de Modelos QSAR para Predição da Toxicidade de Compostos Per- e Polifluoroalquilados (PFAS) em Ratos e Camundongos**

### **5.1 - Conjunto de dados**

O conjunto de dados utilizado neste estudo foi composto por 407 moléculas de compostos per- e polifluoroalquilados (PFAS), selecionadas a partir dos trabalhos de Bhattarai e Gramatica (2010, 2011). Esse conjunto foi subdividido em quatro subconjuntos menores, de acordo com o tipo de teste toxicológico: toxicidade oral ( $LD_{50}$ ) e toxicidade por inalação ( $LC_{50}$ ), ambos avaliados em ratos e camundongos. Para os testes de  $LD_{50}$ , foram considerados 50 compostos para o modelo em ratos e 58 para camundongos, totalizando 108 moléculas. Já para os testes de  $LC_{50}$ , foram selecionadas 144 moléculas para ratos e 155 para camundongos. No entanto, o subconjunto referente à toxicidade por inalação em camundongos passou por uma etapa de depuração, com a remoção de 9 compostos — incluindo substâncias inorgânicas e moléculas com valores negativos de  $LC_{50}$  — reduzindo esse grupo para 146 amostras, conforme também sugerido pelos autores originais. [20-21]

Para cada molécula presente nos quatro conjuntos, foram obtidos os respectivos SMILES (Simplified Molecular Input Line Entry System), que representam de forma simplificada a estrutura química das substâncias. Os dados foram extraídos da base pública PubChem, por meio do número de registro CAS identificado nos estudos originais. Esta etapa foi fundamental para a construção dos modelos preditivos, uma vez que os SMILES são essenciais para a geração de descritores moleculares. As informações reunidas incluíram nome da substância, número CAS, estrutura SMILES e valores de atividade biológica relacionados à toxicidade. [3, 5, 20-22]

### **5.2 - Cálculo e seleção de descritores**

Para a construção dos modelos preditivos, foram utilizados descritores moleculares derivados das estruturas 2D de 407 compostos PFAS, geradas a partir de suas representações SMILES. Esses descritores foram calculados com o uso do programa DRAGON, uma ferramenta amplamente empregada em estudos de

relação estrutura-atividade (SAR/QSAR), capaz de gerar milhares de descritores moleculares com base em estruturas bidimensionais ou tridimensionais, conforme a abordagem definida pelo pesquisador [3, 5-6]. A geração e filtragem inicial dos descritores foi conduzida separadamente para cada subconjunto de dados.

Após essa etapa inicial, as matrizes de descritores resultantes foram processadas no software QSAR Modeling. Primeiramente, realizou-se uma nova filtragem baseada na correlação de Pearson absoluta ( $|r|$ ) entre os descritores e as variáveis dependentes, utilizando limites de corte de 0,1 e 0,2, o que resultou em oito matrizes de dados distintas. Posteriormente, foi feita uma inspeção visual das matrizes para identificar e remover descritores com baixa relevância ou redundância, visando otimizar a qualidade dos modelos preditivos. As matrizes refinadas foram então submetidas ao processo de seleção de variáveis para a modelagem final. [3,5-6]

A seleção de variáveis para a construção dos modelos foi realizada por meio do algoritmo OPS (Ordered Predictor Selection), implementado no programa QSAR Modeling. Esse algoritmo faz uma ordenação dos descritores com base em sua relevância informativa, utilizando vetores informativos, vetores de correlação e vetores de regressão gerados por PLS (Partial Least Squares). A cada passo, os descritores mais relevantes são incorporados ao modelo com base em critérios estatísticos padronizados, como PRESS da validação cruzada (PRESS<sub>cv</sub>), PRESS da calibração (PRESS<sub>cal</sub>), coeficiente de correlação de Pearson da validação cruzada ( $r_{cv}$ ), coeficiente de correlação da calibração ( $r_{cal}$ ), coeficiente de predição ( $Q^2$ ), coeficiente de determinação ( $R^2$ ), erro quadrático médio da validação cruzada (RMSECV) e erro quadrático médio da calibração (RMSEC) [7]. Diversos parâmetros são considerados no processo, incluindo o número de variáveis latentes, tamanho da janela inicial, incremento de variáveis, percentual de análise e método de validação (como o leave-N-out), permitindo refinamentos sucessivos na seleção. Essa etapa é essencial para garantir modelos mais robustos e preditivos.

### 5.3 - Construção e validação dos modelos

Para a construção dos modelos, utilizou-se a regressão por mínimos quadrados parciais (PLS), um método bilinear eficiente na redução da dimensionalidade e no tratamento de multicolinearidade, comum em conjuntos com muitos descritores correlacionados. O PLS transforma os dados em variáveis latentes otimizadas, focando na covariância entre descritores e resposta, o que reduz o sobreajuste e melhora a qualidade preditiva. Os descritores moleculares, extraídos previamente, foram organizados em matrizes processadas nos softwares QSAR Modeling e Chemoface, onde cada modelo foi ajustado com um número específico de variáveis latentes, conforme o subconjunto e a toxicidade avaliada (oral ou inalatória, em ratos e camundongos). A validação dos modelos envolveu cruzamento interno (validação cruzada), análise do coeficiente de determinação ( $R^2$ ) e cálculo do erro médio quadrático para calibração (RMSEC) e validação (RMSECV), assegurando sua precisão e aplicabilidade regulatória. [5, 7-8]

A etapa de validação dos modelos construídos neste estudo seguiu os princípios recomendados pela OCDE para (Q)SARs, assegurando confiabilidade e aplicabilidade regulatória. A validação interna foi realizada com validação cruzada do tipo leave-one-out (LOO), considerando métricas como  $R^2$ ,  $Q^2$ , RMSEC, RMSECV, PRESS, além das estatísticas  $r^2_m$  (média e diferença escaladas), que permitem avaliar a capacidade de ajuste e predição interna dos modelos [7]. Para garantir a robustez, também foi aplicada a validação leave-N-out, onde até 10 amostras foram removidas aleatoriamente com seis repetições para cada valor de N, totalizando

entre 2 e 30% da base. A estabilidade dos modelos foi observada na baixa variação dos valores de  $Q^2$  e RMSECV ao longo das iterações, evidenciando boa consistência dos modelos gerados. Além disso, o teste de y-randomization foi aplicado com 40 aleatorizações, permitindo verificar a ausência de correlação ao acaso entre descritores e variável resposta, garantindo assim a significância estatística dos modelos. [7-8]

A validação externa foi conduzida com a separação aleatória de 20% dos dados para compor o conjunto teste, utilizando o algoritmo do programa Chemoface. As métricas avaliadas incluíram o coeficiente de determinação externo ( $R^2_{pred}$ ), o erro quadrático médio de predição (RMSEP), os coeficientes de inclinação de Golbraikh-Tropsha ( $k$  e  $k'$ ), e as métricas  $r^2_m$  escaladas (média e diferença), seguindo as diretrizes recomendadas por Cherkasov et al. (2014). Modelos com  $R^2_{pred} > 0,6$  e  $Q^2 > 0,5$  são geralmente considerados aceitáveis, conforme os critérios da literatura e os requisitos regulatórios da OCDE [9-10]. A detecção de outliers foi realizada com base em alavancagem (leverage) e resíduos de Student, e amostras identificadas como anômalas foram avaliadas cuidadosamente, sendo removidas apenas quando havia justificativa química ou biológica plausível. A etapa final incluiu a revalidação dos resultados no software Xternal Validation, o qual confirmou a aceitação ou rejeição dos valores preditos, exigindo nova rodada de modelagem quando os critérios não eram atendidos. Essa abordagem abrangente, baseada nos cinco princípios da OCDE, garante que os modelos QSAR desenvolvidos sejam transparentes, reproduzíveis e aplicáveis para fins regulatórios, contribuindo com a avaliação de risco de substâncias químicas de forma ética e eficiente. [1, 9-10]

#### 5.4 – Resultados e discussão

Os modelos QSAR desenvolvidos apresentaram desempenho estatístico satisfatório, com coeficientes de determinação ( $R^2$ ) superiores a 0,80, indicando bom ajuste entre os valores observados e preditos na calibração. A validação cruzada leave-one-out ( $Q^2$ ) variou entre 0,75 e 0,86, evidenciando boa capacidade preditiva interna e robustez, especialmente nos modelos 1 e 3, que exibiram os maiores valores. Os erros quadráticos médios de calibração (RMSEC) e validação cruzada (RMSECV) apresentaram níveis compatíveis com a complexidade dos dados, com destaque para o modelo 1, que demonstrou maior estabilidade. As métricas  $r^2_m$  escaladas, tanto média quanto diferença, confirmaram a qualidade estatística e a confiabilidade dos modelos para predição interna. [5,7]

A robustez dos modelos foi ainda confirmada por testes adicionais de validação interna, como o leave-N-out e o y-randomization, que evidenciaram ausência de correlação por acaso entre as variáveis preditoras, reforçando a confiabilidade das predições. A validação externa também indicou consistência, com valores de  $R^2_{pred}$  entre 0,73 e 0,98, destacando o modelo 1 como o mais preditivo. Os coeficientes de inclinação de Golbraikh-Tropsha ( $k$  e  $k'$ ) permaneceram próximos de 1, indicando linearidade e ausência de viés sistemático entre predições e observações. Embora os modelos 1 e 3 tenham apresentado valores de  $R^2_{pred}$  superiores aos valores de  $Q^2_{LOO}$ , fenômeno conhecido como “Paradoxo de Kubinyi”, isso não compromete sua utilidade, pois reforça que preditividade interna e externa podem não apresentar correlação direta [1]. Assim, os quatro modelos se mostram estatisticamente adequados para predição das toxicidades orais e inalatórias em ratos e camundongos, com potencial aplicação em avaliações toxicológicas e regulatórias.

A interpretação dos modelos revelou que a maioria dos descritores moleculares selecionados pertence a classes baseadas em grafos moleculares, que codificam informações topológicas relevantes, como forma, grau de ramificação e distâncias entre átomos, além de propriedades físico-químicas específicas. Nos modelos relacionados à toxicidade em ratos (modelos 1 e 3), compostos menores e mais polares apresentaram maior toxicidade, com descritores ligados a propriedades eletrônicas exibindo impacto positivo na toxicidade, enquanto descritores associados a propriedades estéricas ou puramente topológicas mostraram efeito negativo. Por outro lado, os modelos para camundongos (modelos 2 e 4) indicaram diferentes padrões, com destaque para o aumento da toxicidade relacionado ao tamanho da cadeia alquilada e à presença de heteroátomos, principalmente na toxicidade oral e inalatória, respectivamente. Ressalta-se ainda a importância do descritor associado à presença de fósforo, que parece limitar a absorção pulmonar desses compostos, configurando-se como uma característica crítica para a toxicidade inalatória em camundongos. [5, 20]

## 5.5 – Considerações finais do estudo

Conclui-se que os modelos QSAR desenvolvidos para prever a toxicidade de PFAS em mamíferos (ratos e camundongos), por vias oral e inalatória, apresentam boa qualidade estatística, robustez e validade interna e externa. Esses modelos, baseados exclusivamente em descritores moleculares 2D obtidos a partir de representações SMILES, demonstram-se confiáveis para a avaliação preliminar do potencial tóxico dessas substâncias, o que é especialmente relevante para aplicações regulatórias e de avaliação de risco ambiental. Além disso, a interpretação dos modelos indica mecanismos de toxicidade consistentes para ratos, enquanto os mecanismos em camundongos apresentam características distintas, refletindo diferenças biológicas entre as espécies. Assim, os quatro modelos constituem ferramentas eficazes para prever a toxicidade de PFAS em mamíferos por importantes vias de exposição, auxiliando na priorização e na tomada de decisão em estudos toxicológicos.

Informações complementares encontram-se no Apêndice A.

## 6. ESTUDO II – Desenvolvimento de Modelos QSAR para Predição da Toxicidade de Pesticidas em *Apis mellifera*

### 6.1 - Conjunto de dados

Para a construção dos modelos preditivos de toxicidade dos pesticidas em abelhas, foi utilizado o método QSAR (Quantitative Structure-Activity Relationship), que relaciona a estrutura molecular dos compostos às suas propriedades biológicas, como a toxicidade. O conjunto de dados inicial foi obtido do banco de dados CROP-CSM: *Crop Compound Search and Match*. [28] (Disponível em: [https://biosig.lab.uq.edu.au/crop\\_csm/](https://biosig.lab.uq.edu.au/crop_csm/). Acesso em: 21 jan. 2025)., contendo informações de 191 pesticidas. Após a etapa de filtragem dos dados, os compostos foram organizados em grupos tóxicos e não tóxicos para a modelagem quantitativa, enquanto o conjunto total foi empregado na modelagem qualitativa. A utilização do QSAR permite prever o potencial tóxico de novos compostos sem a necessidade de testes experimentais diretos, otimizando recursos e reduzindo custos, observados na tabela 1. [1,3]

Tabela 1 – Compostos químicos avaliados e suas respectivas toxicidades agudas em abelhas (LD<sub>50</sub> em µg/abelha) com as representações SMILES.

|    | SMILES                                                                                                                                                                                                                 | LD <sub>50</sub><br>µg/abelha |
|----|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------|
| 1  | <chem>CC1(C(C1C(=O)OC(C#N)C2=CC(=C(C=C2)F)OC3=CC=CC=C3)C=C(Cl)Cl)C</chem>                                                                                                                                              | 9.000                         |
| 2  | <chem>CC1(C(C1C(=O)OC(C#N)C2=CC(=C(C=C2)F)OC3=CC=CC=C3)C=C(Cl)Cl)C</chem>                                                                                                                                              | 9.000                         |
| 3  | <chem>CC1(C(C1C(=O)OC(C#N)C2=CC(=CC=C2)OC3=CC=CC=C3)C=C(Br)Br)C</chem>                                                                                                                                                 | 8.824                         |
| 4  | <chem>CC1(C(C1C(=O)OC(C#N)C2=CC(=CC=C2)OC3=CC=CC=C3)C=C(Cl)Cl)C</chem>                                                                                                                                                 | 8.699                         |
| 5  | <chem>C1[C@@H](O[C@H]([C@@H]([C@H]1OC)O[C@H]1C[C@@H]([C@H]([C@@H](O1)CO)OC)C)O[C@H]1/C=C/C[C@H]2O[C@@]3[C@H](OC(=O)[C@@H]4C=C([C@H](O)[C@H]5OC/C=C\C=C\C[C@H]1C)/[C@@]45O)C2)O[C@H]([C@H]([C=C3)C)[C@H](C)CC)/C</chem> | 8.638                         |
| 6  | <chem>CO[C@@H]1C[C@@H](OC(C)[C@H]1NC)O[C@H]2C(C)O[C@H]([C@H]2OC)O[C@H]3C(C)=CC6C[C@H](OC(=O)[C@H]5C=C(C)[C@H](O)C4OCC(=CC=C[C@H]3C)C45O)CC7(O6)C=CC(C)C(O7)C(C)CC</chem>                                               | 8.553                         |
| 7  | <chem>C1C(OC(=O)C[C@@H]2C(=CC3[C@H]2C=CC2CC(C[C@H]32)OC2OC(C(C(C2OC)OC)OC)C(C(=O)[C@H](C(C1)OC1OC(C(C1)N(C)C)C)C)CC</chem>                                                                                             | 8.538                         |
| 8  | <chem>CCOP(=O)(N=C1SCC(S1)C)OCC</chem>                                                                                                                                                                                 | 8.456                         |
| 9  | <chem>CC1(C(C1C(=O)OC(C#N)C2=CC(=CC=C2)OC3=CC=CC=C3)C=C(C(F)(F)F)Cl)C</chem>                                                                                                                                           | 8.301                         |
| 10 | <chem>C1=C(C=C(C(=C1Cl)N2C(=C(C(=N2)C#N)S(=O)C(F)(F)F)N)Cl)C(F)(F)F</chem>                                                                                                                                             | 8.229                         |
| 11 | <chem>CC1(C(C1C(=O)OC(C#N)C2=CC(=CC=C2)OC3=CC=CC=C3)C=C(Cl)Cl)C</chem>                                                                                                                                                 | 7.854                         |
| 12 | <chem>Fc1c(COC(=O)C2C(C2C=CC)(C)C)c(F)c(F)c(c1F)COC</chem>                                                                                                                                                             | 7.824                         |
| 13 | <chem>CC1=C(C=CC=C1CO(C=O)C2C(C2(C)C)C=C(C(F)(F)F)Cl)C3=CC=CC=C3</chem>                                                                                                                                                | 7.824                         |
| 14 | <chem>CC1(C(C1C(=O)OC(C#N)C2=CC(=CC=C2)OC3=CC=CC=C3)C=C(Cl)Cl)C</chem>                                                                                                                                                 | 7.638                         |
| 15 | <chem>CN1COCN(C1=N[N+](=O)[O-])CC2=CN=C(S2)Cl</chem>                                                                                                                                                                   | 7.620                         |
| 16 | <chem>CC1(C(C1C(=O)OCC2=CC(=CC=C2)OC3=CC=CC=C3)C=C(Cl)Cl)C</chem>                                                                                                                                                      | 7.620                         |
| 17 | <chem>CCCCCCCC(C(C(=O)C2=CC3C(C2CC(=O)O1)CCCC4CC(C4)OC5C(C(C(C(O5)C)OC)OC)C)OC6CCC(C(O6)C)N(C)C</chem>                                                                                                                 | 7.620                         |
| 18 | <chem>CC(C)(C)C1=CC=C(C=C1)CSC2=C(C(=O)N(N=C2)C(C)C)Cl</chem>                                                                                                                                                          | 7.620                         |
| 19 | <chem>CC1=C(C(=O)CC1OC(=O)C2C(C2(C)C)C=C(C)C)CC#C</chem>                                                                                                                                                               | 7.585                         |
| 20 | <chem>[C@@H]12[C@H](CC[C@H]3[C@H]1C=C1C(=O)[C@H](C)[C@H](CCC[C@@H](OC(=O)C[C@H]31)CC)O[C@H]1O[C@@H]([C@H](CC1)N(C)C)C[C@H](O[C@H]1O[C@H]1O[C@H]([C@@H]([C@H]1OC)OCC)OC)C)C2</chem>                                     | 7.573                         |
| 21 | <chem>CC1(C(C1C(=O)OC(C#N)C2=CC(=CC=C2)OC3=CC=CC=C3)C=C(Cl)Cl)C</chem>                                                                                                                                                 | 7.481                         |
| 22 | <chem>CC1(CC2=C(O1)C(=CC=C2)OC(=O)NC)C</chem>                                                                                                                                                                          | 7.444                         |
| 23 | <chem>CC1(C(C1C(=O)OC(C#N)C2=CC(=CC=C2)OC3=CC=CC=C3)C=C(C(F)(F)F)Cl)C</chem>                                                                                                                                           | 7.420                         |
| 24 | <chem>CCOP(=S)(OCC)OC(C(Cl)(Cl)Cl)Cl</chem>                                                                                                                                                                            | 7.398                         |
| 25 | <chem>CN=C(NCC1=CN=C(S1)Cl)N[N+](=O)[O-]</chem>                                                                                                                                                                        | 7.357                         |
| 26 | <chem>OC(C(Cc1ccc(Cl)cc1Cl)n2cncn2)C(C)C</chem>                                                                                                                                                                        | 7.301                         |
| 27 | <chem>CC(C)(C)C(=NOC(=O)NC)CSC</chem>                                                                                                                                                                                  | 7.237                         |
| 28 | <chem>CCOP(=S)(OCC)OC1=NC(=C(C=C1Cl)Cl)Cl</chem>                                                                                                                                                                       | 7.229                         |
| 29 | <chem>CC(C)C(C1=CC=C(C=C1)Cl)C(=O)OC(C#N)C2=CC(=CC=C2)OC3=CC=CC=C3</chem>                                                                                                                                              | 7.222                         |
| 30 | <chem>CC(=CC1C(C1(C)C)C(=O)OCC2=COCC(=C2)CC3=CC=CC=C3)C</chem>                                                                                                                                                         | 7.201                         |
| 31 | <chem>CCOP(=S)(OCC)OC1=NC2=CC=CC=C2N=C1</chem>                                                                                                                                                                         | 7.155                         |
| 32 | <chem>CC(C)C(C1=CC=C(C=C1)OC(F)F)C(=O)OC(C#N)C2=CC(=CC=C2)OC3=CC=CC=C3</chem>                                                                                                                                          | 7.108                         |
| 33 | <chem>COC(=O)C12CC3=C(C1=NN(CO2)C(=O)N(C4=CC=C(C=C4)OC(F)(F)F)C(=O)OC)C=CC(=C3)Cl</chem>                                                                                                                               | 7.097                         |
| 34 | <chem>C1CN(C(=N1)N[N+](=O)[O-])CC2=CN=C(C=C2)Cl</chem>                                                                                                                                                                 | 7.092                         |
| 35 | <chem>CCOP(=S)(OCC)OC1=NOCC(=C1)C2=CC=CC=C2</chem>                                                                                                                                                                     | 7.086                         |
| 36 | <chem>CC1(C(C1C(=O)OC(C#N)C2=CC(=CC=C2)OC3=CC=CC=C3)C=CC(=O)OC(C(F)(F)F)C(F)(F)F)C</chem>                                                                                                                              | 7.076                         |
| 37 | <chem>CCSP(=O)(OCC)OC1=C(C=C(C=C1)Br)Cl</chem>                                                                                                                                                                         | 7.022                         |
| 38 | <chem>CNC(=O)CSP(=S)(OC)OC</chem>                                                                                                                                                                                      | 7.000                         |
| 39 | <chem>CCC1=NC(=CC(=N1)OP(=S)(OC)OC)OCC</chem>                                                                                                                                                                          | 7.000                         |
| 40 | <chem>CC(C)OC1=CC=CC=C1OC(=O)NC</chem>                                                                                                                                                                                 | 6.951                         |
| 41 | <chem>CC1=C(C=CC(=C1)OC(=O)NC)N(C)C</chem>                                                                                                                                                                             | 6.917                         |

|    |                                                                                         |       |
|----|-----------------------------------------------------------------------------------------|-------|
| 42 | <chem>CC1(C(C1C(=O)OC(C#N)C2=CC(=CC=C2)OC3=CC=CC=C3)C(C(Br)(Br)Br)Br)C</chem>           | 6.886 |
| 43 | <chem>CCOP(=S)(OCC)OC1=NC(=NC(=C1)C)C(C)C</chem>                                        | 6.886 |
| 44 | <chem>CNC(=O)OC1=CC=CC2=CC=CC=C21</chem>                                                | 6.854 |
| 45 | <chem>CN(C=O)C(=O)CSP(=S)(OC)OC</chem>                                                  | 6.824 |
| 46 | <chem>COP(=S)(OC)OC1=NC(=C(C=C1Cl)Cl)Cl</chem>                                          | 6.824 |
| 47 | <chem>CC1=C(C=CC(=C1)OP(=S)(OC)OC)[N+](=O)[O-]</chem>                                   | 6.796 |
| 48 | <chem>CC(=NOC(=O)NC)SC</chem>                                                           | 6.796 |
| 49 | <chem>CCOC(=O)CC(C(=O)OCC)SP(=S)(OC)OC</chem>                                           | 6.796 |
| 50 | <chem>CCS(=O)CCSP(=O)(OC)OC</chem>                                                      | 6.757 |
| 51 | <chem>CCCCN(CCCC)SN(C)C(=O)OC1=CC=CC2=C1OC(C2)(C)C</chem>                               | 6.745 |
| 52 | <chem>CCOC(=O)CCN(C(C)C)SN(C)C(=O)OC1=CC=CC2=C1OC(C2)(C)C</chem>                        | 6.721 |
| 53 | <chem>Clc1c(NC(C(=O)OC(c2cc(Oc3ccccc3)ccc2)C#N)C(C)C)ccc(C(F)(F)F)c1</chem>             | 6.699 |
| 54 | <chem>CC(=CC1C(C1(C)C)C(=O)OCC2=C(C(=C(C2F)F)COC(F)F)C#N</chem>                         | 6.699 |
| 55 | <chem>COP(=S)(OC)SCN1C(=O)C2=CC=CC=C2C1=O</chem>                                        | 6.658 |
| 56 | <chem>CC(C)C(C1=CC=C(C=C1)Cl)C(=O)OC(C#N)C2=CC(=CC=C2)OC3=CC=CC=C3</chem>               | 6.638 |
| 57 | <chem>C1(C(C(C(C1Cl)Cl)Cl)Cl)Cl)Cl</chem>                                               | 6.638 |
| 58 | <chem>CC1=CC(=CC(=C1SC)C)OC(=O)NC</chem>                                                | 6.638 |
| 59 | <chem>CCC(C)SP(=O)(N1CCSC1=O)OCC</chem>                                                 | 6.592 |
| 60 | <chem>CNC(=O)ON=C(C(=O)N(C)C)SC</chem>                                                  | 6.585 |
| 61 | <chem>CCOP(=O)(NC(C)C)OC1=CC(=C(C=C1)SC)C</chem>                                        | 6.553 |
| 62 | <chem>CC1=C(C(=C(C(=C1F)F)COC(=O)C2C(C2(C)C)C=C(C(F)(F)F)Cl)F)F</chem>                  | 6.553 |
| 63 | <chem>CCOP(=S)(OCC)SCSCC</chem>                                                         | 6.495 |
| 64 | <chem>CC(C1=CN=C(C=C1)C(F)(F)F)S(=NC#N)(=O)C</chem>                                     | 6.421 |
| 65 | <chem>C1=CC=[N+]2C(=C1)N(C(=C(C2=O)C3=CC(=CC=C3)C(F)(F)F)[O-])CC4=CN=CN=C4</chem>       | 6.409 |
| 66 | <chem>CC(=CC1C(C1(C)C)C(=O)OCN2C(=O)CN(C2=O)CC#C)C</chem>                               | 6.398 |
| 67 | <chem>COP(=S)(OC)SCN1C(=O)C2=CC=CC=C2N=N1</chem>                                        | 6.377 |
| 68 | <chem>O=C(NCc1ccc(Oc2ccc(cc2)C)cc1)c1n(nc(c1Cl)CC)C</chem>                              | 6.328 |
| 69 | <chem>C1=CC(=CC=C1C(C2=CC=C(C=C2)Cl)C(Cl)(Cl)Cl)Cl</chem>                               | 6.268 |
| 70 | <chem>C1=CC=C(C(=C1)C(C2=CC=C(C=C2)Cl)C(Cl)(Cl)Cl)Cl</chem>                             | 6.268 |
| 71 | <chem>CC(C(=O)NC)SCCSP(=O)(OC)OC</chem>                                                 | 6.252 |
| 72 | <chem>CCOC(=O)CCN(CC1=CC=CC=C1)SN(C)C(=O)ON=C(C)SC</chem>                               | 6.097 |
| 73 | <chem>CNC(=O)N(C)C1=NC2=CC=CC=C2S1</chem>                                               | 6.097 |
| 74 | <chem>CCCS(=O)(OCC)OC1=CN(N=C1)C2=CC=C(C=C2)Cl</chem>                                   | 6.021 |
| 75 | <chem>CCOP(=S)(OCC)SCSCC</chem>                                                         | 6.018 |
| 76 | <chem>CC(C)(C)C(=O)C(N1C=CN=C1)OC2=CC=C(C=C2)Cl</chem>                                  | 6.000 |
| 77 | <chem>CNC(=O)OC1=CC=CC(=C1)N=CN(C)C</chem>                                              | 5.991 |
| 78 | <chem>O=C(Oc1cccc(c1)/N=C/N(C)C)NC</chem>                                               | 5.983 |
| 79 | <chem>CCC(C)SP(=O)(OCC)SC(C)CC</chem>                                                   | 5.967 |
| 80 | <chem>CC(=O)NP(=O)(OC)SC</chem>                                                         | 5.921 |
| 81 | <chem>CC(C)(C)C1=CC=C(C=C1)CCOC2=NC=NC3=CC=CC=C32</chem>                                | 5.917 |
| 82 | <chem>Clc1c(/C(=C/Cl)/OP(=O)(OC)OC)cc(Cl)c(Cl)c1</chem>                                 | 5.863 |
| 83 | <chem>CC(C)C1=CC(=CC(=C1NC(=S)NC(C)(C)C)OC2=CC=CC=C2</chem>                             | 5.824 |
| 84 | <chem>C1=CC(=CC(=C1)C(F)(F)F)C(=NNC(=O)NC2=CC=C(C=C2)OC(F)(F)F)CC3=CC=C(C=C3)C#N</chem> | 5.783 |
| 85 | <chem>n1(/C(=N\c2c(C(F)(F)F)cc(cc2)Cl)/COCCC)cncc1</chem>                               | 5.519 |
| 86 | <chem>CC(=NOC(=O)N(C)SN(C)C(=O)ON=C(C)SC)SC</chem>                                      | 5.509 |
| 87 | <chem>CCOP(=S)(OCC)SCSC(C)(C)C</chem>                                                   | 5.387 |

|      |                                                                                      |       |
|------|--------------------------------------------------------------------------------------|-------|
| 88   | <chem>CCCN(CC)CC1COC2(O1)CCC(CC2)C(C)(C)C</chem>                                     | 5.377 |
| 89   | <chem>CCOP(=S)(OCC)SCN1C2=C(C=C(C=C2)Cl)OC1=O</chem>                                 | 5.357 |
| 90   | <chem>CCOC1=NC(=NC(=N1)NC)NC(=O)NS(=O)(=O)C2=CC=CC=C2C(=O)OC</chem>                  | 5.335 |
| 91   | <chem>CCCSP(=O)(OCC)SCCC</chem>                                                      | 5.255 |
| 92   | <chem>CC(C)N(C1=CC=C(C=C1)Cl)C(=O)CSP(=S)(OC)OC</chem>                               | 5.229 |
| 93   | <chem>C1C2C(C(C1Cl)Cl)C3(C(=C(C2(C3Cl)Cl)Cl)Cl)Cl</chem>                             | 5.222 |
| 94   | <chem>C=CC(Cl)Cl</chem>                                                              | 5.180 |
| 95   | <chem>CCC1=NN(C(=C1Cl)C(=O)NCC2=CC=C(C=C2)C(C)(C)C</chem>                            | 5.174 |
| 96   | <chem>C1C2C(COS(=O)O1)C3(C(=C(C2(C3Cl)Cl)Cl)Cl)Cl</chem>                             | 5.107 |
| 97   | <chem>CC(=NC#N)N(C)CC1=CN=C(C=C1)Cl</chem>                                           | 5.092 |
| 98   | <chem>C[N+]1=CC=C(C=C1)C2=CC=[N+](C=C2)C</chem>                                      | 5.033 |
| 99   | <chem>CCCCNC(=O)N1C2=CC=CC=C2N=C1NC(=O)OC</chem>                                     | 5.000 |
| 100  | <chem>C1=CC(=C(C(=C1)Cl)C#N)Cl</chem>                                                | 4.959 |
| #### |                                                                                      |       |
| #    | <chem>CC(C)C(C(=O)OC(C#N)C1=CC(=CC=C1)OC2=CC=CC=C2)NC3=C(C=C(C=C3)C(F)(F)F)Cl</chem> | 4.921 |
| 102  | <chem>CCOC(=O)C1=CC=CC=C1S(=O)(=O)NC(=O)NC2=NC(=CC(=N2)Cl)OC</chem>                  | 4.903 |
| 103  | <chem>CC1=NN(C(=C1C=NOCC2=CC=C(C=C2)C(=O)OC(C)(C)C)OC3=CC=CC=C3)C</chem>             | 4.801 |
| 104  | <chem>CC(C)OC(=O)NC1=CC=CC=C1</chem>                                                 | 4.796 |
| 105  | <chem>CCC1=C(C(=CC=C1)CC)N(COC)C(=O)CCl</chem>                                       | 4.796 |
| 106  | <chem>CN(C)S(=O)(=O)N(C1=CC=CC=C1)SC(F)(Cl)Cl</chem>                                 | 4.796 |
| 107  | <chem>CN(C)C(=O)NC1=CC(=C(C=C1)OC)Cl</chem>                                          | 4.796 |
| 108  | <chem>CC(C)NC1=NC(=NC(=N1)Cl)NC(C)C</chem>                                           | 4.796 |
| 109  | <chem>CC(C(=O)O)OC1=C(C=C(C=C1)Cl)Cl</chem>                                          | 4.796 |
| 110  | <chem>CN(C(=O)NC1=CC(=C(C=C1)Br)Cl)OC</chem>                                         | 4.796 |
| 111  | <chem>CN(C)C(=O)NC1=CC=C(C=C1)OC2=CC=C(C=C2)Cl</chem>                                | 4.796 |
| 112  | <chem>COP(=S)(OC)OC1=CC=C(C=C1)[N+](=O)[O-]</chem>                                   | 4.710 |
| 113  | <chem>C1=CC=C(C=C1)C2=NC(=CC(=N2)Cl)Cl</chem>                                        | 4.699 |
| 114  | <chem>CC(C)(C(=O)OCC=C)OC(=O)C1=C(C=CC(=C1)N2C(=O)C=C(N(C2=O)C)C(F)(F)F)Cl</chem>    | 4.699 |
| 115  | <chem>CC(C)(C)C(C(=CC1=C(C=C(C=C1)Cl)Cl)N2C=NC=N2)O</chem>                           | 4.699 |
| 116  | <chem>CCCOCC(=NC1=C(C=C(C=C1)Cl)C(F)(F)F)N2C=CN=C2</chem>                            | 4.699 |
| 117  | <chem>C1=CC=C(C(=C1)C(C2=CC=C(C=C2)F)(C3=CN=CN=C3)O)Cl</chem>                        | 4.666 |
| 118  | <chem>CCCOP(=S)(OCCC)SCC(=O)N1CCCCC1C</chem>                                         | 4.658 |
| 119  | <chem>C[As](O)(O)=O</chem>                                                           | 4.620 |
| 120  | <chem>CC(C)OP(=S)(OC(C)C)SCCNS(=O)(=O)C1=CC=CC=C1</chem>                             | 4.620 |
| 121  | <chem>CCOC1=NC(=CC2=NC(=NN21)S(=O)(=O)NC3=C(C=CC=C3Cl)Cl)F</chem>                    | 4.602 |
| 122  | <chem>CN(C)C(CSS(=O)(=O)C1=CC=CC=C1)CSS(=O)(=O)C2=CC=CC=C2</chem>                    | 4.587 |
| 123  | <chem>CCSCCSP(=O)(OC)OC</chem>                                                       | 4.573 |
| 124  | <chem>CCOC(=O)CSC1=NC(=NN1C(=O)N(C)C)C(C)C</chem>                                    | 4.569 |
| 125  | <chem>CCCC(CN1C=NC=N1)(C#N)C2=CC=C(C=C2)Cl</chem>                                    | 4.470 |
| 126  | <chem>CC(C)NC1=NC(=NC(=N1)OC)NC(C)C</chem>                                           | 4.444 |
| 127  | <chem>Cn2[n+](C)c(cc2c1cccc1)c3cccc3</chem>                                          | 4.444 |
| 128  | <chem>C1CSC(=NC#N)N1CC2=CN=C(C=C2)Cl</chem>                                          | 4.411 |
| 129  | <chem>C=CCOC(CN1C=CN=C1)C2=C(C=C(C=C2)Cl)Cl</chem>                                   | 4.409 |
| 130  | <chem>CCCN(CCC)C1=C(C=C(C=C1[N+](=O)[O-])S(=O)(=O)N)[N+](=O)[O-]</chem>              | 4.389 |
| 131  | <chem>CC(C(=O)OCC#C)OC1=CC=C(C=C1)OC2=NC=C(C=C2F)Cl</chem>                           | 4.388 |
| 132  | <chem>CC(C(=O)O)OC1=CC=C(C=C1)OC2=NC=C(C=C2F)Cl</chem>                               | 4.388 |
| 133  | <chem>CCCCSP(=O)(SCCCC)SCCCC</chem>                                                  | 4.355 |

|     |                                                                               |       |
|-----|-------------------------------------------------------------------------------|-------|
| 134 | <chem>CC1=CC(=CC(=C1C)C)OC(=O)NC</chem>                                       | 4.320 |
| 135 | <chem>CC(C)(C)C1=CC=C(C=C1)OC2CCCC2OS(=O)OCC#C</chem>                         | 4.320 |
| 136 | <chem>C1(=C(C(=C(C(=C1Cl)Cl)Cl)Cl)Cl)O</chem>                                 | 4.319 |
| 137 | <chem>CC(C)(C=NOC(=O)NC)S(=O)(=O)C</chem>                                     | 4.301 |
| 138 | <chem>CC1=CC(=C(C=C1)N=CN(C)C=NC2=C(C=C(C=C2)C)C)C</chem>                     | 4.301 |
| 139 | <chem>CCC1=C(SC(=N1)NCC)C(=O)NC(C#N)C2=CC=CS2</chem>                          | 4.292 |
| 140 | <chem>CC1=C(N=C(N=C1OC(=O)N(C)C)N(C)C)C</chem>                                | 4.275 |
| 141 | <chem>S(CCCCCCCC)CCO</chem>                                                   | 4.245 |
| 142 | <chem>c1(nc2c(o1)cc(cc2)Cl)Oc1ccc(O[C@H](C(=O)O)C)cc1</chem>                  | 4.229 |
| 143 | <chem>CCOP(=S)(OCC)OC1=NN(C=N1)C2=CC=CC=C2</chem>                             | 4.223 |
| 144 | <chem>C1C[N+](2=CC=CC=C2C3=CC=CC=[N+])31</chem>                               | 4.222 |
| 145 | <chem>CCCCOC(=O)C(C)OC1=CC=C(C=C1)OC2=NC=C(C=C2)C(F)(F)F</chem>               | 4.201 |
| 146 | <chem>C1=CC(=C(C=C1Cl)Cl)C(CN2C=NC=N2)COC(C(F)F)(F)F</chem>                   | 4.201 |
| 147 | <chem>C[n+](1ccc(cc1)c2cc[n+](C)cc2</chem>                                    | 4.143 |
| 148 | <chem>CC#CCOC(C)C1=CC(=C(C=C1)OC)OC</chem>                                    | 4.132 |
| 149 | <chem>CC(COC1=CC=C(C=C1)OC2=CC=CC=C2)OC3=CC=CC=N3</chem>                      | 4.131 |
| 150 | <chem>CC1=C(C(=O)N(N1)C)C(=O)C2=C(C=C(C=C2)C(F)(F)F)S(=O)(=O)C</chem>         | 4.125 |
| 151 | <chem>CN(C)C(=O)C1=C(N=CC=C1)S(=O)(=O)NC(=O)NC2=NC(=CC(=N2)OC)OC</chem>       | 4.119 |
| 152 | <chem>C1=CC(=C(C(=C1)Cl)C(=S)N)Cl</chem>                                      | 4.112 |
| 153 | <chem>CCCCCCC(C)C1=CC(=CC(=C1OC(=O)C=CC)[N+](=O)[O-])[N+](=O)[O-]</chem>      | 4.072 |
| 154 | <chem>CCCOCCN(C1=C(C=CC=C1CC)CC)C(=O)CCl</chem>                               | 4.032 |
| 155 | <chem>CC1=CS(C=C1N(C(C)COC)C(=O)CCl)C</chem>                                  | 4.027 |
| 156 | <chem>CCCN(CCCl)C1=C(C=C(C=C1[N+](=O)[O-])C(F)(F)F)[N+](=O)[O-]</chem>        | 4.018 |
| 157 | <chem>CC(C)OC(=O)NC1=CC(=CC=C1)Cl</chem>                                      | 4.017 |
| 158 | <chem>CCNC1=NC(=NC(=N1)Cl)NCC</chem>                                          | 4.013 |
| 159 | <chem>CC(C)NC1=NC(=NC(=N1)S)NC(C)C</chem>                                     | 4.004 |
| 160 | <chem>CCOC(=O)C1=C(N(N=C1)C)S(=O)(=O)NC(=O)NC2=NC(=CC(=N2)OC)OC</chem>        | 4.000 |
| 161 | <chem>CCNC1=NC(=NC(=N1)Cl)NC(C)(C)C#N</chem>                                  | 4.000 |
| 162 | <chem>C1(=C(C(=C(C(=C1Cl)Cl)Cl)Cl)[N+](=O)[O-]</chem>                         | 4.000 |
| 163 | <chem>Clc2cc(ccc2Oc1cc(C([O-])=O)c(cc1)[N+](O)[O-])C(F)(F)F</chem>            | 4.000 |
| 164 | <chem>CCC1(C(=O)C2=CC=CC=C2C1=O)CC3(CO3)C4=CC(=CC=C4)Cl</chem>                | 4.000 |
| 165 | <chem>C1=CC=C(C(=C1)C(=O)O)S(=O)(=O)NC(=O)NC2=NC(=CC(=N2)OC(F)F)OC(F)F</chem> | 4.000 |
| 166 | <chem>CCOC(=O)C1(C(=O)N(C(=O)O1)C2=CC(=CC(=C2)Cl)Cl)C</chem>                  | 4.000 |
| 167 | <chem>CCC(CC)NC1=C(C=C(C(=C1[N+](=O)[O-])C)C)[N+](=O)[O-]</chem>              | 4.000 |
| 168 | <chem>C1C(C(C(=O)N1)C2=CC=CC(=C2)C(F)(F)F)Cl)CCl</chem>                       | 4.000 |
| 169 | <chem>C1=CC(=C(C(=C1)F)C(=O)NC(=O)NC2=CC(=C(C(=C2F)Cl)F)Cl)F</chem>           | 4.000 |
| 170 | <chem>O=[N+](O-)[O-]c1ccc(O-)[O-]cc1</chem>                                   | 3.955 |
| 171 | <chem>CC1CCCCC1NC(=O)NC2=CC=CC=C2</chem>                                      | 3.921 |
| 172 | <chem>CCCN(CCO1=C(C=C(C=C1Cl)Cl)Cl)C(=O)N2C=CN=C2</chem>                      | 3.850 |
| 173 | <chem>C1=C(C=C(C(=C1Br)O)Br)C#N</chem>                                        | 3.824 |
| 174 | <chem>C1=C(SC(=N1)S(=O)(=O)CCC(=C(F)F)F)Cl</chem>                             | 3.777 |
| 175 | <chem>COC1=C(C=C(C=C1)C(=CC(=O)N2CCOCC2)C3=CC=C(C=C3)F)OC</chem>              | 3.770 |
| 176 | <chem>C1=CC(=C(C2=NC=C(C=C21)Cl)C(=O)O)Cl</chem>                              | 3.742 |
| 177 | <chem>CC1=C(S(=O)(=O)CCO1)C(=O)NC2=CC=CC=C2</chem>                            | 3.742 |
| 178 | <chem>CCCC(=O)OC1=C(C=C(C=C1Br)C#N)Br</chem>                                  | 3.701 |
| 179 | <chem>CCCC(=O)C1=C(C(=C(C=C1C)C)C2CC(=O)C(=C(CC)NOCC)C(=O)C2)C</chem>         | 3.699 |

|     |                                                                           |       |
|-----|---------------------------------------------------------------------------|-------|
| 180 | <chem>CC(C)C1=CC=C(C=C1)NC(=O)N(C)C</chem>                                | 3.699 |
| 181 | <chem>COC1=NC(=NC(=N1)NC(=O)NS(=O)(=O)C2=CC=CC=C2C(F)(F)F)C(F)(F)F</chem> | 3.699 |
| 182 | <chem>CC1=C(C(=CC=C1)C)N(C(C)C(=O)OC)C(=O)COC</chem>                      | 3.699 |
| 183 | <chem>CS(=O)(=O)C1=CC=C(C=C1)C(=O)C2C(=O)CCCC2=O)Cl</chem>                | 3.699 |
| 184 | <chem>CCCCOCCOCCOCC1=CC2=C(C=C1CCC)OCO2</chem>                            | 3.532 |
| 185 | <chem>CCOC(=O)C(C)OC1=CC=C(C=C1)OC2=NC3=C(O2)C=C(C=C3)Cl</chem>           | 3.523 |
| 186 | <chem>CC(C)OC1=NC(=CC(=N1)OCC2=CC=CC=C2C(=COC)C(=O)OC)C(F)(F)F</chem>     | 3.523 |
| 187 | <chem>C1C2=C(C(=C(C(=C2Cl)Cl)Cl)Cl)C(=O)O1</chem>                         | 3.398 |
| 188 | <chem>CC(C)(C)C1=NN(C(=O)O1)C2=C(C=C(C2)NC(=O)N(C)C)Cl</chem>             | 3.301 |
| 189 | <chem>CC1=CC(=NC(=N1)NC(=O)NS(=O)(=O)C2=CC=CC=C2C(=O)OC3COC3)C</chem>     | 3.130 |
| 190 | <chem>COCOCOC1=C(C=CC(=N1)C(F)(F)F)C(=C2C(=O)C3CCC(C3)C2=O)O</chem>       | 3.108 |
| 191 | <chem>CN(C)C(=O)C(C1=CC=CC=C1)C2=CC=CC=C2</chem>                          | 2.614 |

## 6.2 - Construção e validação dos modelos

A modelagem computacional foi conduzida utilizando a técnica de Análise Discriminante por Mínimos Quadrados Parciais (PLS-DA), que possibilita identificar padrões complexos entre descritores moleculares e a toxicidade observada. Essa abordagem facilita a interpretação dos dados e a classificação dos pesticidas segundo sua toxicidade, com base em propriedades químicas e físicas que influenciam diretamente a interação dos compostos com o sistema biológico das abelhas, especialmente seu sistema nervoso e funções vitais como forrageamento e reprodução [1,5]. A validação dos modelos levou em consideração a robustez e a capacidade preditiva para diferentes conjuntos de dados, incluindo testes internos e externos.

Além disso, para contextualizar a relevância biológica e ambiental dos compostos analisados, foram considerados dados toxicológicos tradicionais, como o valor de LD<sub>50</sub> para abelhas, extraídos da literatura e de bases de dados toxicológicos. A dose letal mediana (LD<sub>50</sub>) representa a concentração necessária para causar a morte de 50% das abelhas expostas, e é um parâmetro crucial na avaliação do risco ambiental dos pesticidas [11,26]. O estudo integra essas informações para assegurar que os modelos QSAR reflitam com fidelidade o impacto real dos pesticidas, contribuindo para o desenvolvimento de práticas agrícolas mais sustentáveis e para a proteção das populações de abelhas, fundamentais para a polinização e manutenção da biodiversidade. [22-23]

O estudo quantitativo foi realizado para avaliar a toxicidade por contato, enquanto o modelo qualitativo foi desenvolvido para classificar os compostos em tóxicos e não tóxicos. Segundo Farruggia et al. (2022) [26], a classificação da toxicidade foi estabelecida com base na dose letal mediana (LD<sub>50</sub>), expressa em µg/abelha, para exposição por contato, utilizando-se o valor de 11 µg/abelha como limite de classificação. Assim, foram considerados não tóxicos os compostos com LD<sub>50</sub> > 11 µg/abelha e tóxicos aqueles com LD<sub>50</sub> < 11 µg/abelha, totalizando 91 compostos não tóxicos e 100 compostos tóxicos.

Os descritores moleculares foram obtidos no programa ALVADESC, disponível no ambiente OCHEM (Online Chemical Modeling Environment) (Disponível em: <https://ochem.eu/home/show.do>. Acesso em: 18 fev. 2025.) [4]. Foram calculados descritores baseados em estruturas bidimensionais (2D), incluindo propriedades físico-químicas, índices topológicos, entre outros. Em seguida, os descritores foram organizados

para a construção dos modelos e submetidos à etapa de seleção de variáveis utilizando o programa QSAR Modeling e o método OPS. Como ferramenta de apoio à modelagem, também foi utilizado o programa CHEMOFACE. Os modelos quantitativos foram construídos utilizando a regressão por mínimos quadrados parciais (PLS). Para o estudo qualitativo, foi considerado o conjunto completo de 191 compostos, classificados em tóxicos e não tóxicos, sendo o modelo desenvolvido por meio da técnica de análise discriminante por mínimos quadrados parciais (PLS-DA) no programa CHEMOFACE. Os resultados obtidos foram comparados com as previsões fornecidas pelos servidores BeetoxAI (<https://beetoxai.labmol.com.br/>) e Crop-CSM. [4].

O BeetoxAi (Artificial Intelligence for Bee Toxicity Prediction. 2025. Disponível em: <http://beetoxai.labmol.com.br/>. Acesso em: 17 mar. 2025.) [27] é uma ferramenta que avalia a toxicidade aguda de produtos químicos, como pesticidas, em *Apis mellifera* utilizando como ferramenta modelos de QSAR combinados com algoritmos de aprendizado de máquina, como Random Forest e Redes Neurais Feedforward, para prever os efeitos tóxicos de compostos químicos nas abelhas, fornecendo previsões de toxicidade permitindo assim uma avaliação rápida e precisa do potencial tóxico de substâncias químicas.[27]

Já Crop-CSM ((Disponível em: [https://biosig.lab.uq.edu.au/crop\\_csm/](https://biosig.lab.uq.edu.au/crop_csm/). Acesso em: 21 jan. 2025.)), a fonte da base de dados adotada, utiliza modelos computacionais para prever a toxicidade de diversos compostos químicos, como pesticidas, em abelhas através da inserção da estrutura química do composto. Esta plataforma também utiliza QSAR para estimar os efeitos tóxicos nas abelhas com base em dados experimentais de toxicidade por contato, fornecendo previsões sobre o grau de risco dos compostos para as abelhas.[28]

Para isso selecionamos um novo conjunto de compostos retirados do artigo “*In silico prediction of chemical acute contact toxicity on honey bees via machine learning methods*” [19]. Do conjunto de dados apresentado neste trabalho, 188 compostos não estão listados no BeetoxAi ou Crop-CSM. Assim, este novo conjunto foi selecionado para teste do modelo. [27- 29]

### 6.3 - Resultados e discussão

Na etapa de estudo quantitativo, foram obtidos dois modelos. Os descritores selecionados para cada caso são apresentados na tabela 2. Os descritores selecionados incluem variáveis provenientes dos programas ALVADESC, Mera, Mordred, RDKit, Dragon, PaDEL Descriptor e PyDescriptor. Os descritores pertencem a diversas categorias diferentes: descritores topológicos, físico-químicos, eletrônicos, geométricos e *fingerprints*.

Avaliando os modelos, compreende-se que a presença dos descritores ASA (Qstate) e ATSC (Mordred) mostra que a toxicidade está relacionada com propriedades de superfície e padrões de conectividade.

Tabela 2 – Descritores dos modelos quantitativos.

| MODELO TÓXICO  | MODELO NÃO TÓXICO                                  |
|----------------|----------------------------------------------------|
| Descritores    | Descritores                                        |
| SC-5:(CDK23)   | DISPv                                              |
| VE3sign_D      | torsions_((C,4,0),(C,4,0),(O,2,0),(C,4,0)):(RDKit) |
| ASYM1R:(Mera)  | PDLIB31:(Mera)                                     |
| NDLIB12:(Mera) | minsCl                                             |

|                       |                       |
|-----------------------|-----------------------|
| MATS3se:(MORDRED)     | ATSC3v:(MORDRED)      |
| SssO(ester):(OEstate) | c5AB-4O:(GSFrag)      |
| Gu                    | MATS3m                |
| P_VSA_MR_3            | NDLIB13:(Mera)        |
| E1p                   | VE3sign_X             |
| s4_numRotBonds        | AATSC3i:(MORDRED)     |
| ATSC5p:(MORDRED)      | ATSC3d:(MORDRED)      |
| s2_relPathLength_2    | AATSC8s:(MORDRED)     |
| Mor03m                | EState_VSA4:(MORDRED) |
| CATS3D_08_LL          | R2u+                  |
| H7m                   | SeaC2N3aa:(OEstate)   |
| Kappa3:(RDKit)        | EState_VSA2:(MORDRED) |
| CPSA_PNSA-4:(KrakenX) |                       |
| EState_VSA5:(MORDRED) |                       |
| R7s+                  |                       |

O modelo de compostos tóxicos apresenta valores de validação interna onde o coeficiente de determinação  $R^2$  para o conjunto dos compostos tóxicos igual a 0.822 explicando maior parte da variância de dados com uma alta capacidade de previsão cruzada  $Q^2_{LOO}$  para compostos tóxicos alcançando 0.702, o que sugere uma boa robustez na identificação de toxicidade. Porém, o modelo de compostos não tóxico apresenta um desempenho inferior com  $Q^2_{LOO}$  de 0.584 e um  $\Delta R^2_{LOO}$ -escalado de 0.555 que indica menor estabilidade na precisão da predição. Conforme observado na tabela 3.

Tabela 3 – Validação Interna

| VALIDAÇÃO INTERNA MODELOS REAIS |              |     |            |       |       |             |        |                     |                     |
|---------------------------------|--------------|-----|------------|-------|-------|-------------|--------|---------------------|---------------------|
| Conjunto                        | Ntreinamento | nVL | Informação | R2    | RMSEC | $Q^2_{LOO}$ | RMESCV | Deltar2LOO-escalado | Mediar2LOO-escalado |
| TÓXICO                          | 79           | 4   | 82.00%     | 0.822 | 0.409 | 0.702       | 0.530  | 0.079               | 0.843               |
| NÃO TÓXICO                      | 72           | 3   | 74.00%     | 0.741 | 0.208 | 0.584       | 0.264  | 0.555               | 0.242               |

A tabela 4 nos explica os resultados da validação externa onde os compostos tóxicos apresentam  $R^2_{pred}$  de 0.906 indicando uma boa capacidade de previsão que explicam 90% variância dos dados. O erro médio quadrático de previsão RMSEP é baixo com valor de 0.682,  $Q^2_{LOO}$  (coeficiente de previsão cruzada leave-one-out) é acima de 0,5, reforçando a confiabilidade do modelo que apresenta robustez e estabilidade e boa capacidade de predição. Para os compostos não tóxicos  $R^2_{pred}$  de 0.707 com valores inferiores aos tóxicos indicando inferioridade deste modelo os resultados explicam 70% de variância para os compostos não tóxicos o RMSEP também apresenta valores baixos e boa precisão na predição. Os demais resultados apresentam menor desempenho para o modelo de compostos não tóxicos.

Tabela 4 – Validação Externa


| VALIDAÇÃO EXTERNA |        |              |       |                   |       |       |                      |                      |
|-------------------|--------|--------------|-------|-------------------|-------|-------|----------------------|----------------------|
| Conjunto          | Nteste | $R^2_{pred}$ | RMSEP | Modulo de Tropsha | k     | k'    | Deltar2PRED-escalado | Mediar2PRED-escalado |
| TÓXICO            | 20     | 0.906        | 0.682 | 0.906             | 1.001 | 0.997 | 0.752                | 0.140                |

Em resumo, ambos os modelos apresentaram desempenho satisfatório. Entretanto, o modelo para compostos tóxicos apresentou maior capacidade preditiva e robustez estatística em comparação ao modelo para compostos não tóxicos, que, embora adequado, apresentou desempenho inferior e pode ser aprimorado.

Já no estudo qualitativo foram selecionados os seguintes descritores: SAScore, CATS2D\_02\_DL, WHALES90\_Isol, GATS4m, GGI6, pHLevel1, IVDE, P\_VSA\_LogP\_4, MDEC-14, F01[O-S], RDF110v, VE3sign\_Dz(i), F09[F-CI], F10[O-O], GATS6p, T(P..CI), MATS5e. O modelo obtido com PLA-DA apresenta uma boa capacidade preditiva na discriminação de toxicidade em abelhas com acurácia (ACU) de 88,57%, sensibilidade (SEL) de 88,50% e especificidade (SPE) de 88,50%, indicando um equilíbrio entre a identificação correta de compostos tóxicos e não tóxicos. O coeficiente de Matthews (MCC) é igual a 0,7718 e o F1\_Score é de 0,885, o que ajuda a reforçar a confiabilidade do modelo. O teste de y-randomização demonstra uma queda na ACU para 61% e no MCC para 0,220 que confirmam que o modelo não possui sobreajuste ou correlações aleatórias. Os resultados gerados no programa Chemoface estão disponíveis na figura 1. Na figura 2 temos o gráfico de dispersão que aponta a comparação dos valores medidos e preditos pelo modelo, mostrando os dados de calibração e os resultados da validação cruzada.

| Calibration     | Average | 1       | 2       |
|-----------------|---------|---------|---------|
| n               | 175     | 85      | 90      |
| TP              | 77.5000 | 73      | 82      |
| TN              | 77.5000 | 82      | 73      |
| FP              | 10      | 8       | 12      |
| FN              | 10      | 12      | 8       |
| SPE             | 88.4967 | 91.1111 | 85.8824 |
| SEL             | 88.4967 | 85.8824 | 91.1111 |
| PRE             | 88.6787 | 90.1235 | 87.2340 |
| ACU             | 88.5714 | 88.5714 | 88.5714 |
| F1S             | 0.8854  | 0.8795  | 0.8913  |
| MCC             | 0.7718  | 0.7718  | 0.7718  |
| y-randomization | Average | 1       | 2       |
| n               | 175     | 85      | 90      |
| TP              | 53.4500 | 46.8000 | 60.1000 |
| TN              | 53.4500 | 60.1000 | 46.8000 |
| FP              | 34.0500 | 29.9000 | 38.2000 |
| FN              | 34.0500 | 38.2000 | 29.9000 |
| SPE             | 60.9183 | 66.7778 | 55.0588 |
| SEL             | 60.9183 | 55.0588 | 66.7778 |
| PRE             | 61.1224 | 60.9877 | 61.2570 |
| ACU             | 61.0857 | 61.0857 | 61.0857 |
| F1S             | 0.6080  | 0.5777  | 0.6383  |
| MCC             | 0.2204  | 0.2204  | 0.2204  |

**Figura 1** - Desempenho do modelo de classificação em validação e randomização. Tabela comparativa dos parâmetros de desempenho do modelo na etapa de calibração e no teste de randomização da variável resposta (y-randomization). Os valores apresentados incluem especificidade (SPE), sensibilidade (SEL), precisão (PRE), acurácia (ACU), F1-score (F1S) e coeficiente de correlação de Matthews (MCC). A calibração apresenta desempenho superior em relação à randomização, evidenciando a robustez do modelo.




**Figura 2** - Gráfico de dispersão entre os valores medidos e preditos pelo modelo QSAR. Os círculos pretos representam a calibração, enquanto os triângulos verdes correspondem à validação cruzada. A linha vermelha indica a relação ideal ( $y = x$ ). Observa-se que as previsões estão concentradas nas extremidades, sugerindo possíveis desafios na modelagem para valores intermediários.


Como um segundo teste quanto a capacidade de discriminação, foram utilizados 188 compostos selecionados. Os resultados indicam uma acurácia de 70,74% e o coeficiente MCC de 0.4122 sugerindo uma correlação positiva entre as previsões e os valores reais, a sensibilidade especificidade estão equilibradas com 70.51% o que indica que o modelo consegue diferenciar bem as classes. O F1-Score de 0,7056 mostram uma boa precisão e reconvocação confirmando a capacidade do modelo de realizar classificação coerente. Conforme mostrados na figura 3. Na figura 4 notamos a distribuição dos escores X para os conjuntos de calibração e teste, representados em um gráfico de dispersão ao longo das duas primeiras variáveis latentes (LV1 e LV2) do modelo PLS-DA, indicando as classes 1 e 0. A figura 5 indica o gráfico de dispersão mostrando os dados de calibração e validação cruzada.

| Prediction | Average | 1       | 2       |
|------------|---------|---------|---------|
| n          | 188     | 99      | 89      |
| TP         | 66.5000 | 74      | 59      |
| TN         | 66.5000 | 59      | 74      |
| FP         | 27.5000 | 30      | 25      |
| FN         | 27.5000 | 25      | 30      |
| SPE        | 70.5198 | 66.2921 | 74.7475 |
| SEL        | 70.5198 | 74.7475 | 66.2921 |
| PRE        | 70.6960 | 71.1538 | 70.2381 |
| ACU        | 70.7447 | 70.7447 | 70.7447 |
| F1S        | 0.7056  | 0.7291  | 0.6821  |
| MCC        | 0.4122  | 0.4122  | 0.4122  |

**Figura 3** - Desempenho do modelo na etapa de predição. Tabela apresentando os parâmetros de desempenho do modelo na etapa de predição. Os valores incluem especificidade (SPE), sensibilidade (SEL), precisão (PRE), acurácia (ACU), F1-score (F1S) e coeficiente de correlação de Matthews (MCC). Os resultados indicam um desempenho equilibrado entre as métricas, refletindo a capacidade do modelo em classificar corretamente os dados de teste.



**Figura 4** - Distribuição dos escores X para os conjuntos de calibração e teste. Gráfico de dispersão dos escores X nas duas primeiras variáveis latentes (LV1 e LV2) obtidas no modelo PLS-DA. Os diferentes símbolos representam as classes 1 e 0 nos conjuntos de calibração e teste. A separação dos pontos indica a discriminação entre as classes, refletindo o desempenho do modelo na diferenciação dos grupos.



**Figura 5** - Gráfico de dispersão dos valores medidos versus preditos pelo modelo QSAR. Os círculos pretos representam os dados de calibração, os triângulos verdes correspondem à validação cruzada e os quadrados

azuis indicam os dados do conjunto de teste. A linha vermelha representa a relação ideal ( $y = x$ ). A concentração de pontos nas extremidades sugere dificuldades na modelagem para valores intermediários.

#### 6.4 - Considerações finais do estudo

Os modelos quantitativos desenvolvidos para a predição da toxicidade de pesticidas em abelhas *Apis mellifera* apresentaram boa capacidade preditiva para os compostos tóxicos, com coeficientes de determinação de  $R^2 = 0,822$  na validação interna e  $R^2_{pred} = 0,906$  na validação externa, evidenciando robustez e confiabilidade na identificação desses compostos. Por outro lado, o modelo quantitativo para compostos não tóxicos apresentou desempenho inferior, indicando limitações em sua capacidade preditiva e a necessidade de aperfeiçoamentos para aumentar sua robustez.

O modelo qualitativo baseado em PLS-DA demonstrou eficácia na classificação dos compostos, alcançando acurácia de 88,57% na validação interna e 70,74% na validação externa. A análise de  $y$ -randomization confirmou a ausência de sobreajuste, reforçando a confiabilidade e a consistência estatística dos resultados obtidos.

De modo geral, os modelos desenvolvidos evidenciaram o potencial da metodologia QSAR para a avaliação da toxicidade de pesticidas em *Apis mellifera*. Embora limitações tenham sido observadas no modelo quantitativo para compostos não tóxicos, os resultados obtidos demonstram que a abordagem empregada constitui uma ferramenta promissora para a predição da toxicidade de pesticidas, contribuindo para a redução de ensaios experimentais, para a preservação desses importantes polinizadores e para o desenvolvimento de estratégias mais eficientes de avaliação de risco ambiental e apoio à regulamentação do uso de pesticidas.

### 7. ESTUDO III – Desenvolvimento de Modelos QSPR para Predição do Coeficiente de Adsorção ao Carbono Orgânico (LogKoc) de Éteres Difenílicos Substituídos

#### 7.1 Conjunto de dados

O presente estudo analisou um total de 59 compostos do tipo éteres difenílicos, extraídos do trabalho de [33]. Entre esses derivados, estão incluídos 26 éteres difenílicos polimetoxilados (PMeODEs), 19 polihidroxilados (PHODEs), 7 metoxilados policlorados (MeO-PCDEs) e 7 hidroxilados policlorados (HO-PCDEs). Os autores também disponibilizaram os valores experimentais dos parâmetros LogKoc e LogP (neste estudo referido como LogKow) para cada substância. O LogKoc apresenta uma variação de 1,63 a 4,81 unidades logarítmicas (média de 2,59 e desvio padrão de 0,824), enquanto o LogKow variou de 1,76 a 5,39 (média de 3,39 e desvio padrão de 0,971), indicando ampla diversidade nas propriedades físico-químicas dos compostos avaliados. A amplitude de distribuição dos dados foi de 3,18 unidades logarítmicas para o LogKoc e 3,63 unidades logarítmicas para o LogKow, refletindo uma considerável variação entre os compostos quanto à sorção e à lipofilicidade. Essa diversidade é fundamental para avaliar o desempenho dos modelos QSPR propostos, uma vez que amplia o espectro de propriedades moleculares consideradas na modelagem.

Todas as estruturas bidimensionais dos derivados foram construídas individualmente utilizando o software ChemSketch (ACD/LABS, 2025) [34], a partir do qual representações no formato SMILES (Simplified Molecular Input Line Entry System), que constituem uma forma simplificada de representar moléculas e são

amplamente empregadas nas etapas iniciais da modelagem computacional de representar uma molécula, também amplamente empregada para o início desse processo de modelagem. O ChemSketch, ferramenta gratuita desenvolvida pela ACD/Labs, permite desenhar, visualizar e exportar estruturas químicas de forma prática, incluindo a geração automática dos códigos SMILES, o que otimiza as etapas iniciais de preparação dos dados para análises computacionais e modelagem molecular. [5, 34]

## 7.2 Metodologia

Além da avaliação individual de descritores moleculares tradicionais, como LogP e LogS, este estudo também investigou a aplicabilidade de um descritor misto, o LogSp — definido como o logaritmo da solubilidade corrigido pela partição octanol/água —, proposto como alternativa para melhorar a qualidade preditiva dos modelos QSPR. Esta abordagem visa não apenas aprimorar a correlação com os valores experimentais de LogKoc, mas também aprofundar a compreensão sobre como características físico-químicas combinadas modulam a sorção no solo. Estudos anteriores já indicaram que a escolha do algoritmo utilizado para calcular LogP pode influenciar significativamente o desempenho dos modelos, resultando em previsões com qualidade variada, desde insatisfatórias até excelentes [12,32]. Portanto, a inclusão de diferentes algoritmos e descritores híbridos permite uma análise mais abrangente e criteriosa, contribuindo para o desenvolvimento de modelos mais robustos, com maior aplicabilidade em cenários regulatórios e ambientais.

A análise preditiva consistiu na utilização de ferramentas computacionais para estabelecer relações quantitativas entre a estrutura química das moléculas e o coeficiente de adsorção ao carbono orgânico do solo (LogKoc). Inicialmente, as estruturas químicas representadas por códigos SMILES foram utilizadas para o cálculo dos descritores moleculares no software Dragon 6, que gera diferentes classes de descritores constitucionais, topológicos, geométricos e moleculares, além de diversas fingerprints e fatores de ponderação atômica [3,6]. Neste estudo, os descritores foram obtidos a partir das representações SMILES dos compostos, restringindo a análise às classes que não dependem de informações tridimensionais.

A matriz de descritores gerada foi submetida a uma etapa inicial de filtragem no próprio Dragon, sendo eliminados descritores constantes ou quase constantes, descritores com desvio-padrão inferior a 0,001, colunas contendo valores ausentes e descritores altamente correlacionados entre si ( $r \geq 0,9$ ), mantendo-se apenas um representante de cada grupo correlacionado. Também foi realizada uma inspeção visual para excluir descritores com baixa variabilidade. Ao final dessa etapa foi obtida uma matriz contendo 201 descritores moleculares.

Os descritores previamente selecionados foram então processados no software QSAR-Modeling, desenvolvido em linguagem Java, no qual foi aplicada uma nova etapa de filtragem baseada na correlação entre descritores e variável resposta, utilizando limites de corte definidos conforme as características do conjunto de dados. Em seguida, realizou-se a seleção de variáveis por meio do algoritmo Ordered Predictors Selection (OPS), permitindo identificar os descritores mais relevantes para a construção dos modelos. O programa também incorpora ferramentas quimiométricas para validação, incluindo validação cruzada, leave-N-out, aleatorização do eixo Y (y-randomization) e detecção de outliers, fornecendo suporte para a seleção das variáveis latentes e para a avaliação da robustez dos modelos [7].

Após a seleção das variáveis, os modelos foram construídos utilizando a regressão por mínimos quadrados parciais (PLS). Posteriormente, os resultados foram avaliados no software Chemoface, empregado para análises multivariadas e modelagem quimiométrica. O programa permitiu a realização das validações interna e externa, bem como das análises preditivas, utilizando conjuntos de treinamento e teste, sendo este último composto por aproximadamente 20% das amostras. Os valores preditos foram então comparados aos valores experimentais para avaliação da capacidade preditiva dos modelos [8].

Alves et al. (2018) descrevem que os descritores moleculares constituem representações numéricas das estruturas químicas, permitindo sua utilização por algoritmos computacionais na construção de modelos QSAR/QSPR. Esses algoritmos organizam os descritores em uma matriz de dados, sendo o modelo representado matematicamente pela equação  $y = b + a \cdot x$ , na qual  $y$  corresponde à propriedade de interesse,  $x$  representa os descritores moleculares e  $b$  é um coeficiente determinado pelo algoritmo. Para modelos contendo múltiplos descritores, a equação pode ser expressa como  $y = b + a_1x_1 + a_2x_2 + \dots + a_nx_n$ , sendo os coeficientes estimados por regressão por mínimos quadrados parciais (PLS) [5].

### 7.2.1 Validação dos modelos

Os modelos univariados e multivariados desenvolvidos neste estudo foram submetidos a um rigoroso processo de validação, seguindo protocolos clássicos recomendados para estudos QSPR, que incluem validação interna e validação externa [36,37]. Para isso, o conjunto de dados foi dividido em duas partes: um conjunto de treinamento (training set) contendo 80% dos compostos ( $n=47$ ), utilizado para ajustar e calibrar os modelos; e um conjunto de teste (test set) com 20% dos compostos ( $n=12$ ), reservado para validação externa, permitindo avaliar a capacidade preditiva dos modelos para dados independentes. Os compostos que compuseram o conjunto de teste foram os números 2, 7, 10, 18, 21, 22, 24, 25, 29, 33, 39 e 43, escolhidos para garantir a representatividade da diversidade estrutural e das propriedades químicas do conjunto completo.

Na validação interna, a qualidade do ajuste dos modelos foi avaliada pelo coeficiente de determinação ( $R^2$ ), pelo erro quadrático médio da calibração (RMSEC) e pelo teste F (intervalo de confiança de 95%;  $\alpha = 0,05$ ). A capacidade preditiva interna foi avaliada por meio da validação cruzada do tipo leave-one-out (LOO), utilizando as métricas  $Q^2_{LOO}$  e RMSECV, além dos indicadores Average  $r^2_m(LOO)$ -scaled e  $\Delta r^2_m(LOO)$ -scaled, que fornecem avaliações mais detalhadas da qualidade do modelo [40–42]. Esses testes foram realizados utilizando os softwares QSAR Modeling e XternalValidation 1.0.

Adicionalmente, para os modelos multivariados foram aplicados testes complementares para avaliação da robustez e confiabilidade do modelo. O teste de validação cruzada leave-N-out (LNO) foi realizado com  $N=12$ , envolvendo seis randomizações diferentes para cada  $N$ , garantindo que os resultados fossem consistentes e não dependessem de uma única partição dos dados [36]. Além disso, para descartar a possibilidade de correlações por acaso, foi feito o teste de randomização do vetor  $y$ , com 40 randomizações, seguindo a abordagem proposta por [43]. Nesse teste, esperam-se baixos valores de correlação (menores que 0,3 para  $R^2$  e 0,05 para  $Q^2_{LOO}$ ), confirmando que os modelos obtidos não são frutos de associações aleatórias.

Na validação externa, a qualidade das predições foi avaliada pelo coeficiente de determinação para o conjunto externo ( $R^2_{pred}$ ) e pelo erro quadrático médio de predição (RMSEP). Para aumentar a confiabilidade dos resultados, também foram aplicadas métricas  $R_m^2$  para validação externa, como

Average\_r<sup>2</sup>m(pred)-scaled e  $\Delta r^2m(pred)\text{-scaled}$ . As estatísticas de Golbraikh-Tropsha foram utilizadas para avaliar a adequação do modelo, incluindo os coeficientes angulares (k e k') das regressões entre valores observados e preditos, e a diferença absoluta entre os valores de R<sup>2</sup> das regressões centradas na origem ( $|R^2_0 - R^2_o|$ ) [37,44]. Todos os cálculos de validação externa foram realizados no software Xternal Validation 1.0.

Por fim, para os modelos multivariados, foram obtidas as métricas Average\_r<sup>2</sup>m(overall)-scaled e  $\Delta r^2m(overall)\text{-scaled}$ , que combinam os resultados da validação cruzada LOO e da validação externa. Essas métricas auxiliam na seleção dos melhores modelos entre aqueles com desempenhos similares, garantindo a escolha da modelagem mais robusta e preditiva [45]. Essas métricas também foram obtidas utilizando o software Xternal Validation 1.0.

### 7.3 Algoritmos de LogP, LogS e derivação do parâmetro LogSp

Com o objetivo de avaliar a influência de diferentes métodos de estimativa das propriedades físico-químicas sobre a qualidade dos modelos QSPR, foram selecionados 15 algoritmos para o cálculo dos descritores de lipofilicidade (LogP) e solubilidade em água (LogS). Os valores de LogP foram obtidos a partir das representações SMILES de cada composto, utilizando diferentes plataformas computacionais, conforme apresentado na Tabela 5.

Tabela 5. Algoritmos teóricos empregados para predição dos parâmetros Log P e Log S, com respectivas fontes e referências.

| Algoritmos       | Fonte                                                                                               | Referência                                                                                                      |
|------------------|-----------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------|
| <b>LogP</b>      |                                                                                                     |                                                                                                                 |
| MLOGP            | Dragon 6                                                                                            | Moriguchi et al. (1992)                                                                                         |
| ALOGP            | Dragon 6                                                                                            | Viswanadhan et al. (1993)                                                                                       |
| iLOGP            | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | Daina, Micheling e Zoete (2014)                                                                                 |
| XLOGP3           | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | Cheng et al. (2007)                                                                                             |
| WLOGP            | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | Wildman e Crippen (1999)                                                                                        |
| Silicos-IT_LogP  | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | <a href="https://www.silicos-it.be/">https://www.silicos-it.be/</a>                                             |
| LogPow           | <a href="http://www.ochem.com">http://www.ochem.com</a>                                             | <a href="http://www.ochem.com">http://www.ochem.com</a>                                                         |
| SLogP            | <a href="http://www.ochem.com">http://www.ochem.com</a>                                             | Hou e Xu ( 2002)                                                                                                |
| ALOGPs           | <a href="http://www.vcclab.org">http://www.vcclab.org</a>                                           | Tetko e Tanchuk (2002)                                                                                          |
| miLogP           | <a href="http://www.vcclab.org">http://www.vcclab.org</a>                                           | <a href="https://www.molinspiration.com/services/faq.html">https://www.molinspiration.com/services/faq.html</a> |
| AcLogP           | <a href="https://www.organic-chemistry.org/prog/peo">https://www.organic-chemistry.org/prog/peo</a> | Organic Chemistry Portal, 2026                                                                                  |
| <b>LogS</b>      |                                                                                                     |                                                                                                                 |
| Ali_LogS         | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | Ali et al. (2012)                                                                                               |
| ESOL_LogS        | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | Delaney (2004)                                                                                                  |
| Silicos-IT_LogSw | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | <a href="https://www.silicos-it.be/">https://www.silicos-it.be/</a>                                             |
| ALOGpS           | <a href="http://www.vcclab.org">http://www.vcclab.org</a>                                           | Tetko e Tanchuk (2002)                                                                                          |

Os descritores moleculares relacionados à lipofilicidade (LogP) e à solubilidade em água (LogS) foram calculados utilizando as plataformas Dragon 6, SwissADME, OCHEM, VCCLAB e Property Estimation Online (PEO), que empregam algoritmos baseados em diferentes metodologias, incluindo abordagens

fragmentárias, empíricas, estatísticas e de aprendizado de máquina. A utilização de diferentes algoritmos permitiu comparar o desempenho das estimativas obtidas por cada método e avaliar sua influência na construção dos modelos QSPR.

Os valores de LogP foram calculados por meio dos algoritmos MLOGP, ALOGP, iLOGP, XLOGP3, WLOGP, Silicos-IT LogP, LogPow (Model 4), SLogP, ALOGPs, miLogP e cLogP. Para a estimativa da solubilidade em água (LogS), foram utilizados os algoritmos Ali LogS, ESOL LogS, Silicos-IT LogSw e ALOGpS. A Tabela 5 apresenta as plataformas utilizadas, bem como as respectivas metodologias e referências de cada algoritmo empregado neste estudo.

Os valores calculados para todos os algoritmos de LogP e LogS encontram-se apresentados na Tabela 6, sendo posteriormente utilizados nas análises univariadas e multivariadas para avaliação de sua capacidade preditiva em relação ao coeficiente de adsorção ao carbono orgânico (LogKoc).

Tabela 6 - Propriedades físico-químicas calculadas para os compostos analisados neste estudo.

|    | DRAGON |        |       |       |       |        | SWIS ADME |                  |           |            | OCHEM            |                  |       |        | VCCLAB |        |       | PEO |
|----|--------|--------|-------|-------|-------|--------|-----------|------------------|-----------|------------|------------------|------------------|-------|--------|--------|--------|-------|-----|
| nº | logKow | logKoc | MLOGP | ALOGP | iLOGP | XLOGP3 | WLOGP     | Silicos-IT Log P | Ali Log S | ESOL Log S | Silicos-IT LogSw | logPow (model 4) | SLogP | ALOGPs | ALOGpS | miLogP | cLogP |     |
| 1  | 4.250  | 3.280  | 3.395 | 3.390 | 2.550 | 4.210  | 3.480     | 3.110            | -4.110    | -4.100     | -4.650           | 3.831            | 3.479 | 3.680  | -3.590 | 3.690  | 3.060 |     |
| 2  | 3.920  | 3.080  | 3.054 | 3.374 | 2.810 | 4.090  | 3.490     | 3.060            | -4.180    | -4.050     | -4.790           | 3.776            | 3.487 | 3.560  | -4.110 | 3.720  | 2.990 |     |
| 3  | 3.890  | 2.990  | 3.054 | 3.374 | 2.820 | 3.580  | 3.490     | 3.060            | -3.650    | -3.730     | -4.790           | 3.782            | 3.487 | 3.560  | -4.130 | 3.750  | 2.990 |     |
| 4  | 3.720  | 2.950  | 2.750 | 3.357 | 2.940 | 2.890  | 3.500     | 3.060            | -3.130    | -3.350     | -4.920           | 3.716            | 3.496 | 3.320  | -4.220 | 3.540  | 2.920 |     |
| 5  | 3.680  | 3.020  | 2.750 | 3.357 | 2.990 | 2.890  | 3.500     | 3.060            | -3.130    | -3.350     | -4.920           | 3.728            | 3.496 | 3.380  | -4.220 | 3.560  | 2.920 |     |
| 6  | 3.560  | 2.890  | 2.750 | 3.357 | 3.110 | 3.740  | 3.500     | 3.060            | -4.010    | -3.880     | -4.920           | 3.949            | 3.496 | 3.410  | -4.220 | 3.760  | 2.920 |     |
| 7  | 3.690  | 3.020  | 2.750 | 3.357 | 3.160 | 3.740  | 3.500     | 3.060            | -4.010    | -3.880     | -4.920           | 3.957            | 3.496 | 3.420  | -4.240 | 3.780  | 2.920 |     |
| 8  | 3.620  | 2.740  | 2.750 | 3.357 | 3.160 | 2.660  | 3.500     | 3.060            | -2.890    | -3.200     | -4.920           | 3.962            | 3.496 | 3.440  | -4.240 | 3.810  | 2.920 |     |
| 9  | 3.510  | 2.760  | 2.750 | 3.357 | 3.020 | 3.290  | 3.500     | 3.060            | -3.550    | -3.600     | -4.920           | 3.712            | 3.496 | 3.330  | -4.230 | 3.340  | 2.920 |     |
| 10 | 3.400  | 2.680  | 2.198 | 3.341 | 3.210 | 2.990  | 3.500     | 3.100            | -3.430    | -3.470     | -5.040           | 3.683            | 3.505 | 3.390  | -4.060 | 3.350  | 2.850 |     |
| 11 | 3.350  | 2.710  | 2.198 | 3.341 | 3.300 | 2.860  | 3.500     | 3.100            | -3.290    | -3.390     | -5.040           | 3.934            | 3.505 | 3.480  | -4.110 | 3.590  | 2.850 |     |
| 12 | 3.530  | 2.680  | 2.198 | 3.341 | 3.310 | 2.860  | 3.500     | 3.100            | -3.290    | -3.390     | -5.040           | 3.932            | 3.505 | 3.480  | -4.110 | 3.590  | 2.850 |     |
| 13 | 3.440  | 2.770  | 2.198 | 3.341 | 3.150 | 2.860  | 3.500     | 3.100            | -3.290    | -3.390     | -5.040           | 3.678            | 3.505 | 3.420  | -4.080 | 3.150  | 2.850 |     |
| 14 | 3.260  | 2.700  | 2.198 | 3.341 | 3.410 | 3.710  | 3.500     | 3.100            | -4.180    | -3.930     | -5.040           | 3.895            | 3.505 | 3.480  | -4.110 | 3.770  | 2.850 |     |
| 15 | 3.300  | 2.650  | 2.198 | 3.341 | 3.410 | 3.800  | 3.500     | 3.100            | -4.270    | -3.990     | -5.040           | 3.979            | 3.505 | 3.490  | -4.120 | 3.790  | 2.850 |     |
| 16 | 3.480  | 2.720  | 2.198 | 3.341 | 3.410 | 3.060  | 3.500     | 3.100            | -3.500    | -3.520     | -5.040           | 3.686            | 3.505 | 3.330  | -4.070 | 3.320  | 2.850 |     |
| 17 | 2.730  | 2.320  | 1.660 | 3.325 | 3.410 | 3.340  | 3.510     | 3.150            | -3.990    | -3.770     | -5.160           | 3.493            | 3.513 | 3.260  | -3.780 | 3.350  | 2.780 |     |
| 18 | 2.770  | 2.400  | 1.660 | 3.325 | 3.410 | 3.340  | 3.510     | 3.150            | -3.990    | -3.770     | -5.160           | 3.502            | 3.513 | 3.280  | -3.790 | 3.160  | 2.780 |     |
| 19 | 2.880  | 2.340  | 1.660 | 3.325 | 3.410 | 2.830  | 3.510     | 3.150            | -3.460    | -3.450     | -5.160           | 3.631            | 3.513 | 3.320  | -3.810 | 3.180  | 2.780 |     |
| 20 | 2.750  | 2.390  | 1.660 | 3.325 | 3.410 | 2.830  | 3.510     | 3.150            | -3.460    | -3.450     | -5.160           | 3.702            | 3.513 | 3.320  | -3.810 | 3.580  | 2.780 |     |
| 21 | 2.620  | 2.300  | 1.660 | 3.325 | 3.410 | 2.830  | 3.510     | 3.150            | -3.460    | -3.450     | -5.160           | 3.589            | 3.513 | 3.300  | -3.810 | 3.180  | 2.780 |     |
| 22 | 2.790  | 2.360  | 1.660 | 3.325 | 3.410 | 3.030  | 3.510     | 3.150            | -3.660    | -3.580     | -5.160           | 3.502            | 3.513 | 3.270  | -3.790 | 3.130  | 2.780 |     |
| 23 | 2.760  | 2.260  | 1.660 | 3.325 | 3.410 | 3.030  | 3.510     | 3.150            | -3.660    | -3.580     | -5.160           | 3.597            | 3.513 | 3.280  | -3.800 | 3.350  | 2.780 |     |
| 24 | 2.540  | 2.020  | 1.131 | 3.308 | 3.410 | 3.310  | 3.520     | 3.210            | -4.150    | -3.840     | -5.270           | 3.329            | 3.522 | 3.000  | -4.020 | 3.140  | 2.710 |     |
| 25 | 2.430  | 1.960  | 1.131 | 3.308 | 3.410 | 3.310  | 3.520     | 3.210            | -4.150    | -3.840     | -5.270           | 3.379            | 3.522 | 3.020  | -4.060 | 2.970  | 2.710 |     |
| 26 | 2.250  | 1.800  | 0.610 | 3.292 | 3.410 | 3.280  | 3.530     | 3.290            | -4.310    | -3.910     | -5.380           | 3.195            | 3.530 | 2.950  | -4.150 | 2.950  | 2.640 |     |
| 27 | 3.450  | 2.850  | 2.782 | 3.123 | 3.410 | 2.790  | 3.180     | 2.580            | -3.070    | -3.250     | -4.080           | 3.294            | 3.184 | 3.310  | -3.130 | 3.190  | 2.710 |     |
| 28 | 3.530  | 2.880  | 2.782 | 3.123 | 3.410 | 3.770  | 3.180     | 2.580            | -4.080    | -3.870     | -4.080           | 3.541            | 3.184 | 3.320  | -3.250 | 3.190  | 2.710 |     |

|    |       |       |        |       |       |       |       |       |        |        |        |       |       |       |        |       |       |
|----|-------|-------|--------|-------|-------|-------|-------|-------|--------|--------|--------|-------|-------|-------|--------|-------|-------|
| 29 | 3.320 | 2.980 | 2.782  | 3.123 | 3.410 | 3.350 | 3.180 | 2.580 | -3.650 | -3.610 | -4.080 | 3.571 | 3.184 | 3.320 | -3.310 | 3.210 | 2.710 |
| 30 | 2.910 | 2.590 | 2.214  | 2.855 | 3.410 | 2.740 | 2.890 | 2.060 | -3.440 | -3.280 | -3.510 | 3.063 | 2.890 | 2.560 | -2.740 | 2.690 | 2.360 |
| 31 | 2.830 | 2.680 | 2.214  | 2.855 | 3.410 | 3.060 | 2.890 | 2.060 | -3.770 | -3.480 | -3.510 | 3.066 | 2.890 | 2.570 | -2.770 | 2.720 | 2.360 |
| 32 | 2.870 | 2.520 | 2.214  | 2.855 | 3.410 | 2.740 | 2.890 | 2.060 | -3.440 | -3.280 | -3.510 | 3.162 | 2.890 | 2.570 | -2.790 | 2.690 | 2.360 |
| 33 | 2.610 | 2.480 | 2.214  | 2.855 | 3.410 | 2.010 | 2.890 | 2.060 | -2.680 | -2.820 | -3.510 | 3.189 | 2.890 | 2.580 | -2.870 | 2.730 | 2.360 |
| 34 | 2.540 | 2.310 | 1.407  | 2.588 | 3.410 | 2.010 | 2.600 | 1.560 | -3.110 | -2.880 | -2.940 | 2.467 | 2.596 | 2.040 | -2.620 | 2.200 | 2.020 |
| 35 | 2.650 | 2.210 | 1.407  | 2.588 | 3.410 | 1.670 | 2.600 | 1.560 | -2.750 | -2.670 | -2.940 | 2.466 | 2.596 | 2.050 | -2.640 | 2.210 | 2.020 |
| 36 | 2.400 | 2.190 | 1.407  | 2.588 | 3.410 | 2.190 | 2.600 | 1.560 | -3.290 | -3.000 | -2.940 | 2.671 | 2.596 | 2.070 | -2.650 | 2.160 | 2.020 |
| 37 | 2.510 | 2.230 | 1.407  | 2.588 | 3.410 | 2.820 | 2.600 | 1.560 | -3.950 | -3.390 | -2.940 | 2.686 | 2.596 | 2.050 | -2.670 | 2.180 | 2.020 |
| 38 | 2.720 | 2.280 | 1.407  | 2.588 | 3.410 | 2.390 | 2.600 | 1.560 | -3.500 | -3.120 | -2.940 | 2.670 | 2.596 | 2.190 | -2.600 | 2.430 | 2.020 |
| 39 | 2.240 | 2.050 | 0.619  | 2.321 | 3.410 | 2.030 | 2.300 | 1.070 | -3.550 | -2.960 | -2.360 | 2.091 | 2.301 | 1.660 | -2.650 | 1.960 | 1.670 |
| 40 | 2.330 | 2.240 | 0.619  | 2.321 | 3.410 | 1.320 | 2.300 | 1.070 | -2.810 | -2.510 | -2.360 | 2.107 | 2.301 | 1.580 | -2.720 | 1.660 | 1.670 |
| 41 | 2.110 | 2.020 | 0.619  | 2.321 | 3.410 | 1.810 | 2.300 | 1.070 | -3.320 | -2.820 | -2.360 | 2.082 | 2.301 | 1.600 | -2.710 | 1.720 | 1.670 |
| 42 | 2.190 | 2.040 | 0.619  | 2.321 | 3.410 | 2.030 | 2.300 | 1.070 | -3.550 | -2.960 | -2.360 | 2.108 | 2.301 | 1.700 | -2.630 | 1.940 | 1.670 |
| 43 | 1.790 | 1.690 | -0.153 | 2.053 | 3.410 | 1.670 | 2.010 | 0.590 | -3.600 | -2.800 | -1.790 | 1.819 | 2.007 | 1.430 | -2.690 | 1.330 | 1.670 |
| 44 | 1.950 | 1.760 | -0.153 | 2.053 | 3.410 | 1.670 | 2.010 | 0.590 | -3.600 | -2.800 | -1.790 | 1.849 | 2.007 | 1.390 | -2.750 | 1.460 | 1.330 |
| 45 | 1.760 | 1.630 | -0.912 | 1.786 | 3.410 | 1.320 | 1.710 | 0.110 | -3.660 | -2.660 | -1.210 | 1.610 | 1.712 | 1.290 | -2.700 | 1.170 | 0.980 |
| 46 | 4.700 | 4.200 | 3.586  | 4.038 | 3.410 | 4.470 | 4.140 | 3.680 | -4.580 | -4.470 | -5.410 | 4.479 | 4.141 | 4.430 | -4.690 | 4.400 | 3.590 |
| 47 | 5.090 | 4.630 | 3.842  | 4.703 | 3.410 | 5.220 | 4.790 | 4.300 | -5.360 | -5.120 | -6.010 | 5.063 | 4.794 | 5.080 | -5.110 | 5.300 | 4.200 |
| 48 | 4.950 | 4.310 | 3.842  | 4.703 | 3.410 | 5.000 | 4.790 | 4.300 | -5.130 | -4.980 | -6.010 | 5.075 | 4.794 | 5.080 | -5.130 | 5.300 | 4.200 |
| 49 | 4.860 | 4.290 | 3.842  | 4.703 | 3.410 | 4.970 | 4.790 | 4.300 | -5.100 | -4.960 | -6.010 | 4.864 | 4.794 | 5.050 | -5.280 | 5.100 | 4.200 |
| 50 | 5.210 | 4.720 | 4.091  | 5.367 | 3.410 | 5.120 | 5.450 | 4.930 | -5.250 | -5.240 | -6.620 | 5.525 | 5.448 | 5.540 | -5.690 | 5.440 | 4.800 |
| 51 | 5.390 | 4.810 | 4.091  | 5.367 | 3.410 | 5.470 | 5.450 | 4.930 | -5.620 | -5.460 | -6.620 | 5.511 | 5.448 | 5.550 | -5.690 | 5.440 | 4.800 |
| 52 | 5.110 | 4.580 | 4.091  | 5.367 | 3.410 | 5.120 | 5.450 | 4.930 | -5.250 | -5.240 | -6.620 | 5.523 | 5.448 | 5.540 | -5.690 | 5.440 | 4.800 |
| 53 | 4.140 | 3.450 | 3.322  | 3.787 | 3.410 | 4.150 | 3.840 | 3.180 | -4.480 | -4.280 | -4.700 | 4.298 | 3.838 | 3.930 | -3.590 | 3.870 | 3.320 |
| 54 | 4.410 | 3.620 | 3.586  | 4.452 | 3.410 | 4.900 | 4.490 | 3.800 | -5.250 | -4.930 | -5.320 | 4.443 | 4.491 | 4.520 | -4.020 | 4.500 | 3.920 |
| 55 | 4.500 | 3.690 | 3.586  | 4.452 | 3.410 | 4.680 | 4.490 | 3.800 | -5.030 | -4.790 | -5.320 | 4.457 | 4.491 | 4.550 | -4.010 | 4.500 | 3.920 |
| 56 | 4.330 | 3.500 | 3.586  | 4.452 | 3.410 | 4.650 | 4.490 | 3.800 | -5.000 | -4.770 | -5.320 | 4.401 | 4.491 | 4.610 | -3.990 | 4.470 | 3.920 |
| 57 | 4.810 | 3.980 | 3.842  | 5.116 | 3.410 | 4.760 | 5.140 | 4.430 | -5.110 | -5.020 | -5.920 | 4.969 | 5.145 | 5.100 | -4.600 | 5.130 | 4.530 |
| 58 | 4.960 | 4.210 | 3.842  | 5.116 | 3.410 | 5.150 | 5.140 | 4.430 | -5.510 | -5.270 | -5.920 | 4.954 | 5.145 | 5.080 | -4.640 | 5.130 | 4.530 |
| 59 | 4.740 | 3.920 | 3.842  | 5.116 | 3.410 | 4.760 | 5.140 | 4.430 | -5.110 | -5.020 | -5.920 | 4.965 | 5.145 | 5.530 | -4.680 | 5.130 | 4.530 |

Além da avaliação individual dos descritores LogP e LogS, também foi investigada a aplicabilidade do descritor misto LogSp, definido como o logaritmo da solubilidade em água corrigido pelo coeficiente de partição octanol/água. Esse descritor combina duas propriedades físico-químicas fundamentais relacionadas ao comportamento ambiental dos compostos, permitindo representar simultaneamente características de hidrofobicidade e solubilidade. Segundo a proposta original, essa combinação pode fornecer estimativas mais realistas do LogKoc, parâmetro amplamente utilizado para avaliar a mobilidade e a persistência de compostos orgânicos no solo.

Inicialmente, o LogSp foi calculado utilizando os valores de ALOGPs (LogP) e ALOGpS (LogS), conforme a metodologia originalmente proposta por Tetko e Tanchuk (2002). Entretanto, considerando que os éteres difenílicos substituídos apresentam características estruturais distintas daquelas utilizadas na proposição do descritor original, foi também calculado um novo parâmetro, denominado New\_LogSp, obtido a partir dos algoritmos de LogP e LogS que apresentaram melhor desempenho nas análises univariadas deste estudo.

Equação 1 – Cálculo do descritor New\_LogSp

$$\text{New\_LogSp} = \text{MLogP} - \text{ESOL\_LogS}$$

em que:

- New\_LogSp corresponde ao descritor híbrido desenvolvido neste estudo;
- MLogP representa o descritor de lipofilicidade obtido pelo algoritmo MLogP;
- ESOL\_LogS representa o descritor de solubilidade em água calculado pelo algoritmo ESOL\_LogS.

Dessa forma, tornou-se possível comparar o desempenho do Original\_LogSp e do New\_LogSp na construção dos modelos multivariados para predição do LogKoc

#### 7.4 Modelo QSPR inicial

Com o objetivo de avaliar o desempenho do modelo QSPR inicial para predição do coeficiente de adsorção ao carbono orgânico (LogKoc), foram analisados os parâmetros estatísticos obtidos nas etapas de validação interna e externa. Essas análises permitiram verificar a capacidade de ajuste, a robustez e o potencial preditivo do modelo desenvolvido, fornecendo uma base para as comparações realizadas nas análises univariadas e multivariadas apresentadas nas seções subsequentes.

Os resultados da validação interna demonstram excelente desempenho estatístico do modelo desenvolvido. O modelo foi construído com 47 compostos no conjunto de treinamento e quatro variáveis latentes ( $n_{VL} = 4$ ), sendo capaz de explicar 88,45% da variabilidade total dos dados. O elevado coeficiente de determinação ( $R^2 = 0,975$ ) indica excelente ajuste entre os valores experimentais e os valores preditos pelo modelo, evidenciando forte correlação linear. Além disso, o baixo valor de RMSEC (0,095) demonstra reduzido erro de calibração, confirmando a elevada precisão do ajuste. O teste F apresentou valor de 217,26, significativamente superior ao valor crítico tabelado ( $F = 2,22$ ), confirmando a significância estatística da regressão. A robustez interna também foi comprovada pelos resultados da validação cruzada leave-one-out, que apresentou  $Q^2_{LOO} = 0,973$  e  $RMSECV = 0,104$ , indicando elevada capacidade preditiva interna e baixa variação entre os valores observados e previstos. Adicionalmente, os parâmetros  $\Delta r^2_{LOO}$ -escalado (0,035) e média  $r^2_{LOO}$ -escalado (0,862) permaneceram dentro dos critérios recomendados para modelos QSPR robustos, evidenciando estabilidade e confiabilidade estatística do modelo desenvolvido. Os parâmetros estatísticos obtidos na validação interna são apresentados na Tabela 7.

Tabela 7 – Parâmetros estatísticos da validação interna do modelo QSPR para predição do LogKoc.

| VALIDAÇÃO INTERNA |     |            |       |       |        |           |       |        |                     |                     |
|-------------------|-----|------------|-------|-------|--------|-----------|-------|--------|---------------------|---------------------|
| Ntreinamento      | nVL | Informação | R2    | RMSEC | F      | F crítico | Q2LOO | RMESCV | Deltar2LOO-escalado | mediar2LOO-escalado |
| 47                | 4   | 88.45      | 0.975 | 0.095 | 217.26 | 2.22      | 0.973 | 0.104  | 0.035               | 0.862               |

A validação externa confirmou a elevada capacidade preditiva do modelo para compostos não utilizados durante a etapa de treinamento. Utilizando um conjunto teste composto por 12 moléculas, o modelo

apresentou coeficiente de determinação preditivo extremamente elevado ( $R^2_{\text{pred}} = 0,986$ ), indicando excelente concordância entre os valores experimentais e os valores previstos. O baixo valor de RMSEP (0,091) evidencia reduzido erro de predição e alta precisão do modelo. Os parâmetros de Golbraikh–Tropsha também confirmaram a qualidade estatística da modelagem, uma vez que os coeficientes angulares  $k$  (1,000) e  $k'$  (0,999) permaneceram dentro da faixa considerada ideal (0,85–1,15), demonstrando ausência de desvios sistemáticos significativos entre valores experimentais e previstos. O módulo de Tropsha apresentou valor de 0,001, indicando excelente concordância entre as regressões. Além disso, os parâmetros  $\Delta r^2_{\text{PRED-escalado}}$  (0,010) e média  $r^2_{\text{PRED-escalado}}$  (0,984) reforçam a elevada robustez externa e a excelente capacidade de generalização do modelo, confirmando sua aplicabilidade para a predição do LogKoc de novos compostos estruturalmente relacionados. Os resultados da validação externa são apresentados na Tabela 8.

Tabela 8 – Parâmetros estatísticos da validação externa do modelo QSPR desenvolvido para predição do LogKoc.

| VALIDAÇÃO EXTERNA |                                |       |                   |   |       |                                     |                                      |
|-------------------|--------------------------------|-------|-------------------|---|-------|-------------------------------------|--------------------------------------|
| Nteste            | R <sup>2</sup> <sub>pred</sub> | RMSEP | Módulo de Tropsha | k | k'    | $\Delta r^2_{\text{PRED-escalado}}$ | mediana $r^2_{\text{PRED-escalado}}$ |
| 12                | 0.986                          | 0.091 | 0.001             | 1 | 0.999 | 0.01                                | 0.984                                |

Os resultados obtidos demonstram que o modelo QSPR inicial apresentou excelente desempenho estatístico, elevada robustez e forte capacidade preditiva para estimar os valores de LogKoc dos éteres difenílicos substituídos. Os elevados valores de  $R^2$  e  $Q^2_{\text{LOO}}$ , associados aos baixos erros de calibração (RMSEC) e validação cruzada (RMSECV), evidenciam excelente ajuste aos dados experimentais e elevada estabilidade interna do modelo. Da mesma forma, a validação externa confirmou sua elevada capacidade de generalização, uma vez que o modelo foi capaz de prever, com alta precisão, compostos não utilizados durante a etapa de treinamento. Os parâmetros de Golbraikh–Tropsha permaneceram dentro dos limites recomendados para modelos QSPR confiáveis, confirmando a ausência de desvios sistemáticos significativos entre os valores experimentais e preditos. Além disso, os descritores moleculares selecionados mostraram-se capazes de representar adequadamente os fatores estruturais relacionados à sorção no solo, especialmente aqueles associados à lipofilicidade e à polaridade molecular. Dessa forma, o modelo inicial constitui uma base consistente para a avaliação dos diferentes algoritmos de LogP e LogS e para o desenvolvimento das análises univariadas e multivariadas apresentadas nas seções seguintes.

## 7.5 - Análise Univariada

Foram desenvolvidas análises univariadas utilizando diferentes versões dos coeficientes LogP, LogS e os valores calculados de LogSp, com o objetivo de avaliar individualmente a capacidade preditiva de cada método. Essas análises permitiram verificar a qualidade das predições tanto internamente (utilizando os dados do conjunto de treinamento) quanto externamente (utilizando dados independentes). Para fins de comparação, as regressões univariadas também foram realizadas utilizando os valores experimentais de LogP dos 59 compostos do conjunto de dados, obtidos do estudo de Zhang et al. (2018) [33]. O uso do LogP experimental teve como finalidade servir de referência para avaliar a qualidade das estimativas obtidas pelos diferentes algoritmos teóricos empregados neste estudo.

Todas as regressões univariadas foram avaliadas utilizando os mesmos critérios estatísticos, garantindo uma comparação consistente entre os métodos. A partir dos resultados obtidos, foram selecionados os algoritmos de LogP e LogS que apresentaram melhor desempenho para compor os modelos multivariados. Com base nesses descritores, foi calculado um novo parâmetro, denominado New\_LogSp, posteriormente comparado ao Original\_LogSp, descritor proposto na literatura, com o objetivo de verificar se sua derivação a partir de diferentes algoritmos poderia proporcionar melhorias na predição dos valores de LogKoc para o conjunto de compostos estudado.

Os resultados das regressões univariadas demonstram que os descritores relacionados ao LogP apresentaram melhor desempenho estatístico quando comparados aos modelos baseados em LogS. De maneira geral, os modelos de LogP exibiram coeficientes de determinação superiores a 0,82 tanto para calibração quanto para validação cruzada, associados a baixos valores de RMSEC e RMSECV, indicando elevada capacidade de ajuste e boa robustez interna. Entre os algoritmos avaliados, destacaram-se MLOGP e cLogP, que apresentaram os maiores valores de  $R^2$  e os menores erros associados à modelagem. Esses resultados evidenciam a forte influência da lipofilicidade sobre os valores de LogKoc, indicando que compostos mais hidrofóbicos tendem a apresentar maior afinidade pelas frações orgânicas do solo. Em relação aos modelos baseados em LogS, observou-se desempenho inferior quando comparado aos descritores de LogP, especialmente para os algoritmos Ali Log S e ALOGpS. Entretanto, o modelo baseado em ESOL Log S apresentou resultados estatísticos superiores aos demais descritores de solubilidade, demonstrando que a solubilidade em água também exerce influência relevante sobre os processos de sorção. Esses resultados sugerem que tanto propriedades hidrofóbicas quanto hidrofílicas contribuem para o comportamento ambiental dos éteres difenílicos substituídos, embora a lipofilicidade represente o fator predominante na predição do LogKoc.

Tabela 9 – Parâmetros estatísticos das regressões univariadas utilizando descritores de LogP e LogS para predição do LogKoc

| LOG P e LOG S | $R^2_{cv}$ | $R^2_{cal}$ | RMSECV | RMSEC |                         |
|---------------|------------|-------------|--------|-------|-------------------------|
| MLOGP         | 0.834      | 0.852       | 0.333  | 0.314 | $y = 0.0112x + 1.9428$  |
| ALOGP         | 0.825      | 0.834       | 0.342  | 0.333 | $y = 0.0191x + 2.8604$  |
| ALOGPs        | 0.824      | 0.836       | 0.343  | 0.331 | $y = 0.0168x + 2.8533$  |
| miLogP        | 0.828      | 0.84        | 0.339  | 0.327 | $y = 0.0136x + 3.0082$  |
| cLogP         | 0.841      | 0.851       | 0.326  | 0.316 | $y = 0.0165x + 2.4141$  |
| Ali Log S     | 0.572      | 0.599       | 0.535  | 0.517 | $y = -0.0257x - 3.1754$ |
| ESOL Log S    | 0.775      | 0.788       | 0.388  | 0.376 | $y = -0.0189x - 3.2058$ |
| ALOGpS        | 0.606      | 0.628       | 0.513  | 0.498 | $y = -0.0028x - 3.7184$ |

Os parâmetros estatísticos da validação interna dos modelos univariados são apresentados na Tabela 10. Os resultados demonstram excelente desempenho estatístico para os modelos desenvolvidos com descritores de LogP. Todos os algoritmos avaliados apresentaram elevados coeficientes de determinação, com valores de  $R^2$  variando entre 0,986 e 0,990, associados a baixos valores de RMSEC e RMSECV, indicando reduzidos erros de calibração e validação cruzada. Os valores de  $Q^2_{LOO}$  superiores a 0,98 evidenciam elevada robustez interna e forte capacidade preditiva dos modelos desenvolvidos. Entre os descritores avaliados,

destacaram-se ALOGP, ALOGPs e cLogP, que apresentaram os melhores resultados estatísticos gerais, combinando altos valores de explicação da variabilidade dos dados com baixos erros associados às predições. O modelo baseado em MLOGP, embora tenha apresentado menor porcentagem de informação explicada, destacou-se pela utilização de menor número de variáveis latentes, indicando menor complexidade estrutural e elevada estabilidade estatística.

Os modelos desenvolvidos a partir dos descritores de LogS também apresentaram desempenho satisfatório na validação interna, embora ligeiramente inferior aos modelos baseados em LogP. Os algoritmos Ali Log S, ESOL Log S e ALOGpS apresentaram coeficientes de determinação próximos de 0,990 e baixos valores de RMSEC e RMSECV, demonstrando que a solubilidade em água também desempenha papel relevante na determinação do LogKoc. Entre os modelos de LogS, o ESOL Log S apresentou os melhores resultados gerais, com menores erros de calibração e validação cruzada. De maneira geral, os resultados indicam que tanto a lipofilicidade quanto a solubilidade contribuem significativamente para o comportamento de sorção dos éteres difenílicos substituídos, embora os descritores relacionados ao LogP apresentem desempenho estatístico superior, sugerindo predominância das interações hidrofóbicas sobre os processos de partição no solo.

Tabela 10 – Parâmetros estatísticos da validação interna das regressões univariadas utilizando descritores de LogP e LogS para predição do LogKoc.

|            | Ntreinamento | nVL | Informação | R2      | RMSEC   | Q2LOO   | RMSECV  | Deltar2LOO-<br>escalado | mediar2LOO-escalado |
|------------|--------------|-----|------------|---------|---------|---------|---------|-------------------------|---------------------|
| MLOGP      | 47           | 3   | 79.000%    | 0.98600 | 0.10048 | 0.98100 | 0.11700 | 0.03400                 | 0.90583             |
| ALOGP      | 47           | 7   | 96.350%    | 0.99034 | 0.08366 | 0.98519 | 0.10377 | 0.02846                 | 0.89007             |
| ALOGPs     | 47           | 7   | 95.680%    | 0.98997 | 0.08528 | 0.98432 | 0.10667 | 0.03241                 | 0.86771             |
| miLogP     | 47           | 7   | 95.650%    | 0.98994 | 0.08539 | 0.98448 | 0.10613 | 0.03450                 | 0.86218             |
| cLogP      | 47           | 3   | 96.041%    | 0.99028 | 0.08394 | 0.98501 | 0.10437 | 0.02745                 | 0.89707             |
| Ali Log S  | 47           | 6   | 93.29%     | 0.990   | 0.085   | 0.985   | 0.106   | 0.034                   | 0.875               |
| ESOL Log S | 47           | 7   | 95.79%     | 0.990   | 0.084   | 0.985   | 0.105   | 0.034                   | 0.882               |
| ALOGpS     | 47           | 6   | 92.62%     | 0.990   | 0.084   | 0.985   | 0.104   | 0.031                   | 0.879               |

Os parâmetros estatísticos da validação externa dos modelos univariados são apresentados na Tabela 11. Os resultados demonstram excelente capacidade preditiva para todos os modelos desenvolvidos utilizando descritores de LogP e LogS. Os modelos baseados em LogP apresentaram coeficientes de determinação preditiva ( $R^2_{pred}$ ) variando entre 0,963 e 0,974, associados a baixos valores de RMSEP, indicando elevada concordância entre os valores experimentais e os valores previstos para os compostos do conjunto teste. Entre os algoritmos avaliados, destacaram-se cLogP e ALOGP, que apresentaram os maiores valores de  $R^2_{pred}$  (0,974) e os menores erros de predição, demonstrando maior precisão preditiva. Os modelos também apresentaram coeficientes angulares k e k' muito próximos da unidade, além de módulos de Tropsha extremamente baixos, evidenciando ausência de desvios sistemáticos significativos e elevada confiabilidade estatística das predições externas. O modelo baseado em MLOGP apresentou desempenho ligeiramente inferior em relação aos demais algoritmos, porém manteve excelentes parâmetros estatísticos, reforçando sua robustez e estabilidade preditiva.

Os modelos desenvolvidos a partir dos descritores de LogS também apresentaram elevado desempenho na validação externa, com valores de  $R^2_{pred}$  entre 0,969 e 0,973 e baixos valores de RMSEP. Entre os descritores avaliados, o modelo baseado em ALOGpS apresentou o melhor desempenho preditivo externo, seguido pelos modelos Ali Log S e ESOL Log S. Os baixos valores observados para  $\Delta r^2_{PRED}$ -escalado e os elevados valores de média  $r^2_{PRED}$ -escalado indicam alta estabilidade estatística e boa capacidade de generalização dos modelos. De maneira geral, os resultados demonstram que tanto os descritores relacionados à lipofilicidade quanto aqueles associados à solubilidade em água foram capazes de representar adequadamente os fatores físico-químicos envolvidos na sorção dos compostos ao solo. Entretanto, os modelos baseados em LogP apresentaram desempenho ligeiramente superior, sugerindo que as interações hidrofóbicas exercem influência predominante sobre os valores de LogKoc dos éteres difenílicos substituídos.

Tabela 11 – Parâmetros estatísticos da validação externa das regressões univariadas utilizando descritores de LogP e LogS para predição do LogKoc.

|            | Nteste | R2pred | RMSEP | Modulo de Tropsha | k       | k'      | Deltar2PRED-escalado | mediar2PRED-escalado |
|------------|--------|--------|-------|-------------------|---------|---------|----------------------|----------------------|
| MLOGP      | 12     | 0.963  | 0.085 | 0.00018           | 1.00000 | 0.99895 | 0.0117               | 0.98018              |
| ALOGP      | 12     | 0.974  | 0.077 | 0.00009           | 1.00001 | 0.99927 | 0.0081               | 0.98627              |
| ALOGPs     | 12     | 0.974  | 0.081 | 0.00009           | 0.99999 | 0.99926 | 0.0084               | 0.98569              |
| miLogP     | 12     | 0.972  | 0.083 | 0.00010           | 1.00001 | 0.99923 | 0.0085               | 0.98567              |
| cLogP      | 12     | 0.974  | 0.076 | 0.00009           | 1.00000 | 0.99927 | 0.0082               | 0.98608              |
| Ali Log S  | 12     | 0.970  | 0.083 | 0.00009           | 1.00000 | 0.99925 | 0.00838              | 0.98572              |
| ESOL Log S | 12     | 0.969  | 0.084 | 0.00009           | 1.00001 | 0.99925 | 0.00830              | 0.98596              |
| ALOGpS     | 12     | 0.973  | 0.080 | 0.00009           | 1.00001 | 0.99926 | 0.00820              | 0.98615              |

As análises univariadas demonstraram que os descritores moleculares relacionados à lipofilicidade e à solubilidade em água apresentam elevada capacidade para prever os valores de LogKoc dos éteres difenílicos substituídos. Os modelos desenvolvidos apresentaram elevados coeficientes de determinação, baixos erros de calibração e validação, além de excelente desempenho preditivo externo, evidenciando elevada robustez estatística e confiabilidade das regressões construídas. Os descritores baseados em LogP apresentaram desempenho ligeiramente superior aos modelos derivados de LogS, indicando que as interações hidrofóbicas exercem influência predominante sobre os processos de sorção desses compostos no solo.

Entretanto, os resultados obtidos com os descritores de LogS também demonstram que a solubilidade em água representa um fator relevante na determinação do comportamento ambiental da série estudada. Além disso, os baixos valores observados para os parâmetros de Tropsha e a elevada concordância entre os valores experimentais e previstos confirmam a capacidade de generalização dos modelos desenvolvidos. Com base nesses resultados, foram selecionados os algoritmos que apresentaram melhor desempenho para o cálculo do New\_LogSp, utilizado na construção dos modelos multivariados apresentados na seção seguinte.

Os modelos desenvolvidos foram avaliados por meio de parâmetros de calibração, validação interna e validação externa, permitindo comparar o desempenho das diferentes combinações de descritores moleculares. Como etapa inicial da modelagem multivariada, foram analisados os modelos construídos com os descritores de LogP e LogS selecionados nas análises univariadas, uma vez que esses descritores serviram de

base para o desenvolvimento dos modelos subsequentes e para a obtenção do descritor híbrido New\_LogSp. Os parâmetros estatísticos obtidos para esses modelos são apresentados na Tabela 12.

## 7.6 - Análise multivariada

Após a realização das análises univariadas e da seleção dos algoritmos que apresentaram melhor desempenho para os descritores LogP e LogS, procedeu-se ao desenvolvimento dos modelos multivariados para predição do coeficiente de adsorção ao carbono orgânico (LogKoc). Nesta etapa, buscou-se avaliar o efeito da combinação de diferentes descritores moleculares sobre a capacidade preditiva dos modelos QSPR, bem como investigar a contribuição do descritor híbrido LogSp em comparação aos descritores individuais.

A etapa de calibração multivariada foi realizada utilizando o software QSAR Modeling [7]. Antes da construção dos modelos, foi conduzida uma etapa adicional de redução da dimensionalidade da base de dados. Nessa fase, foram eliminados os descritores moleculares que apresentaram correlação absoluta de Pearson inferior a 0,2 ou 0,1 em relação à variável dependente LogKoc, gerando duas matrizes distintas, contendo 140 e 167 descritores, respectivamente. Esse procedimento permitiu remover descritores com baixa contribuição para a modelagem, reduzindo a redundância das informações e favorecendo a construção de modelos mais robustos.

As matrizes resultantes foram submetidas ao processo de seleção de variáveis utilizando o algoritmo Ordered Predictors Selection (OPS), implementado no software QSAR Modeling. Esse algoritmo ordena os descritores conforme sua relevância para explicar a variabilidade da variável resposta, permitindo selecionar subconjuntos de variáveis com maior poder informativo. A utilização do OPS em conjunto com a regressão por mínimos quadrados parciais (PLS) contribui para a obtenção de modelos estatisticamente consistentes, reduzindo o efeito de descritores redundantes ou pouco informativos.

A construção dos modelos foi realizada por meio da regressão por mínimos quadrados parciais (PLS) [35], método amplamente empregado em estudos QSPR devido à sua capacidade de tratar conjuntos de dados com elevada colinearidade e grande número de descritores. O software QSAR Modeling forneceu informações referentes ao número de variáveis latentes, porcentagem da variância explicada e coeficientes autoescalados, permitindo definir a configuração mais adequada para cada modelo desenvolvido.

Durante todo o processo de modelagem, os descritores moleculares foram submetidos ao autoescalamamento (padronização Z-score), procedimento que consiste na centralização dos dados pela média e posterior divisão pelo desvio-padrão de cada variável [36,39]. Essa etapa garante que todos os descritores apresentem a mesma escala de influência durante a modelagem, evitando que variáveis com maior amplitude numérica exerçam influência desproporcional sobre os modelos desenvolvidos e assegurando um ajuste estatístico equilibrado e confiável.

Os modelos desenvolvidos foram avaliados por meio de parâmetros de calibração, validação interna e validação externa, permitindo comparar o desempenho dos diferentes algoritmos empregados na predição do coeficiente de adsorção ao carbono orgânico (LogKoc). Inicialmente, foram analisados os resultados das regressões univariadas construídas com os diferentes algoritmos de LogP e LogS, com o objetivo de

identificar os descritores de melhor desempenho para as etapas subsequentes da modelagem multivariada. Os parâmetros estatísticos obtidos para esses modelos são apresentados na Tabela 12.

Tabela 12. Modelos de predição usando os LogP e LogS selecionados, suas respectivas equações QSPR univariadas, e métricas de validação interna ( $n= 47$  para todos)

| Algoritmo                   | $R^2_{cal}$ | RMSEC          | F                                 | $Q^2_{LOO}$ | RMSECV         | $Av_r^2(LOO)$ -scaled | $\Delta r^2(LOO)$ -scaled | Equações                                        |
|-----------------------------|-------------|----------------|-----------------------------------|-------------|----------------|-----------------------|---------------------------|-------------------------------------------------|
| <b>LogP</b>                 |             |                |                                   |             |                |                       |                           |                                                 |
| Experimental LogP           | 0.956       | 0.179          | 977.73                            | 0.951       | 0.188          | 0.931                 | 0.036                     | $0.842 \cdot \text{LogP} + 0.014$               |
| AcLogP                      | 0.881       | 0.294          | 333.15                            | 0.871       | 0.306          | 0.751                 | 0.121                     | $0.836 \cdot \text{AcLogP} + 0.482$             |
| ALogP                       | 0.87        | 0.307          | 301.15                            | 0.86        | 0.318          | 0.803                 | 0.099                     | $0.850 \cdot \text{ALogP} - 0.007$              |
| ALOGPs                      | 0.863       | 0.315          | 283.47                            | 0.851       | 0.329          | 0.793                 | 0.101                     | $0.664 \cdot \text{ALOGPs} + 0.686$             |
| iLOGP                       | 0.235       | 0.745          | 13.82                             | 0.170       | 0.778          | 0.045                 | 0.228                     | $0.557 \cdot \text{iLogP} + 1.492$              |
| LogPow                      | 0.839       | 0.342          | 234.50                            | 0.825       | 0.356          | 0.759                 | 0.114                     | $0.788 \cdot \text{LogPow} + 0.055$             |
| miLogP                      | 0.856       | 0.323          | 267.50                            | 0.844       | 0.336          | 0.784                 | 0.105                     | $0.686 \cdot \text{miLogP} + 0.564$             |
| MLOGP                       | 0.848       | 0.332          | 251.05                            | 0.824       | 0.358          | 0.758                 | 0.088                     | $0.654 \cdot \text{MLogP} + 1.404$              |
| Silicos-IT_Log P            | 0.739       | 0.435          | 127.41                            | 0.719       | 0.452          | 0.770                 | 0.116                     | $0.629 \cdot \text{Silicos-IT\_Log P} + 1.134$  |
| SLogP                       | 0.844       | 0.336          | 243.46                            | 0.833       | 0.348          | 0.769                 | 0.116                     | $0.821 \cdot \text{SLogP} + 0.027$              |
| WLOGP                       | 0.845       | 0.335          | 245.32                            | 0.834       | 0.347          | 0.770                 | 0.116                     | $0.822 \cdot \text{WLogP} + 0.024$              |
| XLOGP3                      | 0.834       | 0.346          | 226.08                            | 0.819       | 0.362          | 0.751                 | 0.121                     | $0.679 \cdot \text{XLogP3} + 0.667$             |
| <b>LogSw</b>                |             |                |                                   |             |                |                       |                           |                                                 |
| Ali_LogS                    | 0.667       | 0.491          | 90.14                             | 0.639       | 0.511          | 0.520                 | 0.218                     | $-0.845 \cdot \text{Ali\_LogS} - 0.401$         |
| ESOL_Log S                  | 0.835       | 0.346          | 227.73                            | 0.822       | 0.360          | 0.771                 | 0.128                     | $-0.941 \cdot \text{ESOL\_LogP} - 0.628$        |
| Silicos-IT_LogSw            | 0.611       | 0.531          | 70.68                             | 0.581       | 0.552          | 0.449                 | 0.237                     | $-0.505 \cdot \text{Silicos-IT\_LogSw} + 0.669$ |
| ALOGpS                      | 0.688       | 0.476          | 99.23                             | 0.666       | 0.492          | 0.552                 | 0.214                     | $-0.787 \cdot \text{ALOGpS} - 0.047$            |
| <b>Resultados esperados</b> | $> 0.6$     | Menor possível | Maior 4.05 ( $p=1$ e $n-p-1=45$ ) | $> 0.5$     | Menor possível | $> 0.5$               | $< 0.3$                   |                                                 |

Os resultados da validação interna demonstram que os modelos baseados em descritores de LogP apresentaram desempenho superior aos modelos desenvolvidos com descritores de LogS. Entre os algoritmos avaliados, o LogP experimental apresentou os melhores resultados, com coeficiente de determinação de calibração ( $R^2_{cal} = 0,956$ ) e coeficiente de validação cruzada ( $Q^2_{LOO} = 0,951$ ), associados aos menores valores de erro (RMSEC = 0,179 e RMSECV = 0,188), evidenciando excelente ajuste e elevada robustez do modelo. Outros algoritmos, como AcLogP, ALogP e SLogP, também apresentaram desempenho satisfatório, com valores de  $R^2_{cal}$  superiores a 0,84 e  $Q^2_{LOO}$  acima de 0,82, demonstrando boa capacidade preditiva.

Em contrapartida, o algoritmo iLogP apresentou desempenho inferior aos demais, com baixos valores de  $R^2_{cal}$  e  $Q^2_{LOO}$ , indicando reduzida correlação com os valores experimentais de LogKoc e limitada aplicabilidade para a construção de modelos preditivos. Entre os descritores de LogS, o algoritmo ESOL\_LogS apresentou os melhores resultados, embora inferiores aos obtidos pelos modelos baseados em LogP, enquanto os demais algoritmos exibiram menor capacidade de ajuste e predição. Esses resultados reforçam a influência

da lipofilicidade sobre o comportamento de sorção dos compostos estudados e evidenciam a importância da escolha criteriosa dos descritores moleculares para o desenvolvimento de modelos QSPR robustos.

Entretanto, os parâmetros obtidos na validação interna, embora fundamentais para avaliar o ajuste e a robustez dos modelos, não são suficientes para garantir sua capacidade preditiva. Para que um modelo QSAR/QSPR seja considerado confiável para aplicação prática, é indispensável a realização da validação externa, uma vez que o principal objetivo desses modelos é prever propriedades de compostos que não participaram da etapa de construção. Além disso, embora exista correlação entre os principais parâmetros de validação interna, como  $R^2$  e  $Q^2_{LOO}$ , essa relação não se aplica necessariamente aos parâmetros de validação externa, os quais constituem uma avaliação independente do desempenho preditivo do modelo [46–49].

Os parâmetros estatísticos da validação externa dos modelos desenvolvidos com diferentes descritores de LogP e LogS são apresentados na Tabela 13. Essa etapa teve como objetivo avaliar a capacidade preditiva dos modelos para um conjunto independente de 12 compostos, utilizando métricas como o coeficiente de determinação da predição externa ( $R^2_{pred}$ ), o erro quadrático médio de predição (RMSEP), os coeficientes angulares de Golbraikh–Tropsha ( $k$  e  $k'$ ) e os parâmetros  $Av\_r^2(pred)$ -scaled e  $\Delta r^2(pred)$ -scaled, os quais permitem verificar a robustez e a confiabilidade dos modelos para prever compostos que não participaram da etapa de calibração.

Tabela 13 – Parâmetros estatísticos da validação externa dos modelos univariados construídos com diferentes algoritmos de LogP e LogS para predição do LogKoc.

| Algoritmo            | $n_{teste}$ | $R^2_{pred}$ | RMSEP          | $ R^2_o - R^2_{o'} $ | $k$         | $k'$        | $Av\_r^2(pred)$ -scaled | $\Delta r^2(pred)$ -scaled |
|----------------------|-------------|--------------|----------------|----------------------|-------------|-------------|-------------------------|----------------------------|
| LogP                 |             |              |                |                      |             |             |                         |                            |
| Experimental LogP    | 12          | 0.952        | 0.156          | 0.033                | 0.997       | 0.999       | 0.787                   | 0.083                      |
| AcLogP               | 12          | 0.681        | 0.402          | 0.405                | 0.915       | 0.915       | 0.256                   | 0.256                      |
| ALOGP                | 12          | 0.637        | 0.429          | 0.469                | 0.920       | 1.062       | 0.163                   | 0.219                      |
| ALOGPs               | 12          | 0.685        | 0.400          | 0.068                | 0.912       | 1.078       | 0.357                   | 0.199                      |
| iLOGP                | 12          | -0.422       | 0.850          | 0.286                | 0.782       | 1.223       | 0.008                   | 0.032                      |
| LogPow               | 12          | 0.670        | 0.409          | 0.047                | 0.906       | 1.084       | 0.409                   | 0.122                      |
| miLogP               | 12          | 0.754        | 0.353          | 0.016                | 0.923       | 1.068       | 0.470                   | 0.173                      |
| MLOGP                | 12          | 0.889        | 0.238          | 0.073                | 0.942       | 1.056       | 0.799                   | 0.070                      |
| Silicos-IT_Log P     | 12          | 0.218        | 0.630          | 0.193                | 0.851       | 1.132       | 0.109                   | 0.060                      |
| SLogP                | 12          | 0.523        | 0.492          | 0.263                | 0.900       | 1.080       | 0.121                   | 0.130                      |
| WLOGP                | 12          | 0.525        | 0.491          | 0.264                | 0.900       | 1.079       | 0.122                   | 0.131                      |
| XLOGP3               | 12          | 0.574        | 0.465          | 0.014                | 0.891       | 1.099       | 0.290                   | 0.159                      |
| LogSw                |             |              |                |                      |             |             |                         |                            |
| Ali_LogS             | 12          | 0.231        | 0.625          | 0.167                | 0.872       | 1.097       | 0.000                   | 0.003                      |
| ALOGpS               | 12          | 0.285        | 0.603          | 0.298                | 0.854       | 1.134       | 0.075                   | 0.124                      |
| ESOL_LogS            | 12          | 0.528        | 0.489          | 0.451                | 0.898       | 1.083       | 0.108                   | 0.164                      |
| Silicos-IT_LogSw     | 12          | -0.077       | 0.740          | 0.297                | 0.818       | 1.169       | 0.063                   | 0.045                      |
| Resultados esperados |             | > 0.5        | Menor possível | < 0.3                | 0.85 – 1.15 | 0.85 – 1.15 | > 0.5                   | < 0.3                      |

Os resultados da validação externa demonstram que o modelo baseado no LogP experimental apresentou o melhor desempenho preditivo, com  $R^2_{\text{pred}} = 0,952$  e  $\text{RMSEP} = 0,156$ , atendendo a todos os critérios recomendados para modelos QSPR confiáveis. Os coeficientes angulares  $k$  e  $k'$  permaneceram dentro da faixa considerada ideal (0,85–1,15), enquanto a diferença entre  $R^2_0$  e  $R'^2_0$  foi inferior a 0,3, indicando elevada precisão e excelente capacidade de generalização.

Entre os modelos desenvolvidos com descritores teóricos de LogP, o algoritmo MLOGP destacou-se como o único a atender integralmente todos os critérios estatísticos de validação externa. Embora não tenha apresentado o melhor desempenho na validação interna, esse modelo obteve  $R^2_{\text{pred}} = 0,889$  e  $\text{RMSEP} = 0,238$ , evidenciando elevada capacidade preditiva para compostos não utilizados durante a construção do modelo. Em contrapartida, os demais algoritmos de LogP apresentaram valores de  $R^2_{\text{pred}}$  inferiores a 0,70 e, em alguns casos, maiores discrepâncias entre  $R^2_0$  e  $R'^2_0$ , indicando menor confiabilidade para aplicação em conjuntos independentes.

Os modelos baseados em descritores de LogS apresentaram desempenho inferior ao observado para os descritores de LogP. Entre eles, apenas o algoritmo ESOL\_LogS apresentou o melhor desempenho entre os descritores de LogS, embora ainda inferior ao observado para os modelos baseados em LogP, com  $R^2_{\text{pred}}$  em torno de 0,528. Entretanto, esse modelo não atendeu aos demais critérios estatísticos de validação externa, limitando sua aplicabilidade para a predição dos valores de LogKoc.

Esses resultados reforçam a importância da validação externa em estudos QSPR, uma vez que essa etapa permite avaliar a real capacidade de generalização dos modelos para compostos que não participaram do conjunto de treinamento. Embora a validação interna seja essencial para verificar o ajuste e a robustez inicial dos modelos, somente a validação externa é capaz de confirmar sua aplicabilidade prática e sua confiabilidade para a predição de propriedades ambientais de novas substâncias.

O bom desempenho apresentado pelo algoritmo MLOGP pode ser explicado por sua metodologia de cálculo. O método Moriguchi LogP (MLOGP) baseia-se na soma das contribuições de diferentes fragmentos moleculares para estimar a lipofilicidade dos compostos. Esse algoritmo foi originalmente desenvolvido a partir de um modelo QSPR composto por 13 variáveis descritivas, utilizando um conjunto de dados contendo 1.230 substâncias. Conforme discutido por Mannhold et al. (2009) [50], métodos baseados em fragmentos estruturais tendem a apresentar elevada precisão na estimativa do coeficiente de partição de moléculas neutras. No caso do MLOGP, são considerados grupos funcionais específicos, como insaturações, grupos metila, átomos de cloro e grupos hidroxila, além de relações topológicas entre átomos da molécula. Segundo Todeschini e Consonni (2009) [51], essas características contribuem significativamente para a estimativa de propriedades físico-químicas. Considerando a estrutura dos éteres difenílicos substituídos, é provável que os fragmentos utilizados pelo algoritmo representem adequadamente os fatores estruturais responsáveis pela lipofilicidade desses compostos, justificando o excelente desempenho observado nas análises realizadas.

Com base nesses resultados, o algoritmo MLOGP e o algoritmo ESOL\_LogS, que apresentaram os melhores desempenhos entre os descritores de LogP e LogS, respectivamente, foram selecionados para compor as etapas subsequentes da modelagem. Esses descritores serviram de base para a construção do novo descritor híbrido LogSp e para o desenvolvimento dos modelos multivariados finais.

## 7.7 - Modelos multivariados utilizando o descritor LogSp


Após a avaliação dos descritores individuais de LogP e LogS, foram desenvolvidos novos modelos QSPR incorporando o descritor híbrido LogSp. Nesta etapa, foram avaliadas duas abordagens: a utilização do Original\_LogSp, calculado conforme a proposta de dos Reis, Sampaio e de Melo (2014), e do New\_LogSp, desenvolvido neste estudo a partir dos algoritmos MLogP e ESOL\_LogS, previamente selecionados por apresentarem melhor desempenho nas análises univariadas. O objetivo foi verificar se a utilização de descritores híbridos seria capaz de melhorar a capacidade preditiva dos modelos QSPR para estimativa do LogKoc.

### 7.7.1 Avaliação univariada do Original\_LogSp e New\_LogSp

Por meio da técnica de seleção de variáveis OPS [52], foram escolhidos quatro descritores moleculares, os quais originaram duas variáveis latentes (LVs), responsáveis por acumular 83,47% da variabilidade total dos dados (LV1: 68,86%; LV2: 14,61%). Essas variáveis foram utilizadas na construção do modelo preditivo para o coeficiente de sorção no solo. A validação interna revelou desempenho satisfatório, evidenciado pelos coeficientes de determinação altamente próximos ( $R^2 = 0,817$  e  $Q^2_{\text{LOO}} = 0,777$ ), e pelos baixos valores de erro (RMSEC = 0,364; RMSECV = 0,402). A estatística F obtida (194,44) superou expressivamente o valor crítico tabelado (3,21), considerando um nível de confiança de 95% ( $\alpha = 0,05$ ), demonstrando a elevada significância estatística do modelo de regressão.

$$\text{Log}K_{oc} = 2.941 - 0.188 \cdot (\text{nO}) + 0.149 \cdot (\text{CATS2D}_{07\_LL}) + 0.039 \cdot (\text{CATS2D}_{02\_LL}) + 0.950 \cdot (\text{B05}[\text{O-Cl}]) \quad (1)$$

$n_{\text{training}} = 47$ ;  $R^2 = 0.817$ ; RMSEC = 0.364;  $F_{95\%} = 196.44$  (valor tabelado: 3.21);  $Q^2_{\text{LOO}} = 0.777$ ; RMSECV = 0.402;  $\text{Av}_r^2(\text{LOO})\text{-scaled} = 0.678$ ;  $\Delta r^2(\text{LOO})\text{-scaled} = 0.146$ ;  $n_{\text{test}} = 12$ ;  $R^2_{\text{pred}} = 0.955$ ; RMSEP = 0.151;  $\text{Av}_r^2(\text{pred})\text{-scaled} = 0.837$ ;  $\Delta r^2(\text{pred})\text{-scaled} = 0.088$ ;  $k = 1.002$ ;  $k' = 0.995$ ; módulo = 0.013;  $\text{Av}_r^2(\text{overall})\text{-scaled} = 0.712$ ;  $\Delta r^2(\text{overall})\text{-scaled} = 0.116$



**Figura 6.** Gráficos obtidos com os testes de validação cruzada LNO (A) e de y-randomization (B) para o Modelo 1.

Resultados semelhantes foram observados na validação externa do modelo multivariado, que apresenta um coeficiente de predição ( $R^2_{\text{pred}}$ ) de 0,891 e um erro quadrático médio de predição (RMSEP) de 0,149. Embora esses valores atendam aos critérios estatísticos estabelecidos para modelos QSPR e indiquem

bom desempenho preditivo, o Modelo 1 não supera, em termos de qualidade interna, os melhores modelos univariados baseados em diferentes preditores de LogP e no ESOL\_LogS. No contexto da validação externa, apesar de mostrar boa capacidade de previsão, o modelo ainda se mostra inferior à regressão univariada construída com MLogP, que permanece como referência de melhor desempenho.

Os descritores selecionados pelo método OPS apresentaram os seguintes coeficientes autoescalados em ordem decrescente de importância: |0,419| para B05[O-Cl], |0,314| para nO, |0,282| para CATS2D\_07\_LL e |0,076| para CATS2D\_02\_LL. Como indicado na Tabela 5, todos os descritores selecionados, de alguma forma, refletem a influência da polaridade sobre a variável dependente. Em especial, destaca-se B05[O-Cl], o mais relevante, que representa a presença do padrão estrutural oxigênio-cloro e está associado ao aumento da lipofilicidade molecular. Já o descritor nO, o segundo mais influente, corresponde ao número total de átomos de oxigênio na molécula, geralmente indicando a presença de grupos -OH e -OCH<sub>3</sub>, os quais tendem a reduzir a lipofilicidade. Esses achados reforçam a hipótese de que descritores relacionados à partição óleo/água ou à solubilidade em água podem fornecer informações complementares valiosas e contribuir para a melhoria geral da qualidade preditiva do modelo.

Tabela 14. Descritores selecionados para o Modelo 1.

| Descritor    | Definição                                            | Classe                     | Interpretação                                                                                         |
|--------------|------------------------------------------------------|----------------------------|-------------------------------------------------------------------------------------------------------|
| nO           | Number of Oxygen atoms                               | Constitutional descriptors | Aumento do número de oxigênios reduz LogKoc                                                           |
| CATS2D_07_LL | CATS2D Lipophilic-Lipophilic at lag 07               | CATS2D Fingerprints        | Aumento do número de grupos lipofílicos a sete <i>topological paths</i> de distância aumenta o LogKoc |
| CATS2D_02_LL | CATS2D Lipophilic-Lipophilic at lag 02               | CATS2D Fingerprints        | Aumento do número de grupos lipofílicos a dois <i>topological paths</i> de distância aumenta o LogKoc |
| B05[O-Cl]    | Presence/absence of O - Cl at topological distance 5 | 2D Atom Pairs              | Aumento número de oxigênios e cloro a cinco <i>topological paths</i> aumenta a atividade              |

O descritor nO (número de átomos de oxigênio), pertencente à classe de descritores constitucionais, mostrou que o aumento no número de átomos de oxigênio está relacionado à diminuição do LogKoc, indicando uma possível maior afinidade por fases aquosas.

Os descritores CATS2D\_07\_LL e CATS2D\_02\_LL, da classe de impressões digitais CATS2D, representam interações lipofílicas a diferentes distâncias topológicas (07 e 02, respectivamente). Ambos indicam que a presença de grupos lipofílicos em determinadas distâncias dentro da molécula está associada a um aumento no LogKoc, sugerindo maior afinidade por fases orgânicas ou sólidas.

No descritor B05[O-Cl], da classe de pares atômicos bidimensionais, indica a presença simultânea de átomos de oxigênio e cloro separados por uma distância topológica de cinco ligações. Esse padrão estrutural também está positivamente relacionado ao LogKoc, o que pode estar relacionado à influência conjunta desses elementos na lipofilicidade da molécula.

### 7.7.2 Modelos multivariados utilizando Original\_LogSp e New\_LogSp


Visando avaliar a influência dos dois descritores de partição selecionados por meio das análises multivariadas, os parâmetros MLogP e ESOL\_LogS foram incorporados à matriz de dados do modelo 1, resultando na construção de dois novos modelos. O modelo 2, que incluiu o descritor MLogP, apresenta quatro variáveis latentes (LVs), as quais explicaram conjuntamente 93,71% da variância total dos dados (LV1: 71,96%; LV2: 11,06%; LV3: 7,19%; LV4: 3,50%). Já o modelo 3, com a adição do descritor ESOL\_LogS, também foi composto por quatro LVs, que acumularam 95,81% da variância explicada (LV1: 69,31%; LV2: 10,51%; LV3: 9,44%; LV4: 6,56%). Os resultados dos testes de robustez, referentes à verificação de correlação aleatória, são apresentados na Figura 3.

$$\text{Log}K_{oc} = 1.351 - 0.04*(nO) + 0.052*(CATS2D\_07\_LL) - 0.014*(CATS2D\_02\_LL) + 0.595*(B05[O-Cl]) + 0.557*(MLogP) \quad (2)$$

$n_{\text{training}} = 47$ ;  $R^2 = 0.910$ ;  $RMSEC = 0.255$ ;  $F_{95\%} = 424.67$  (valor tabelado: 2.61);  $Q^2_{\text{LOO}} = 0.876$ ;  $RMSECV = 0.299$ ;  $Av\_r^2(\text{LOO})\text{-scaled} = 0.829$ ;  $\Delta r^2(\text{LOO})\text{-scaled} = 0.058$ ;  $n_{\text{test}} = 12$ ;  $R^2_{\text{pred}} = 0.957$ ;  $RMSEP = 0.146$ ;  $Av\_r^2(\text{pred})\text{-scaled} = 0.903$ ;  $\Delta r^2(\text{pred})\text{-scaled} = 0.003$ ;  $k = 0.968$ ;  $k' = 0.1.031$ ;  $|R^2_0 - R'^2_0| = 0.009$ ;  $Av\_r^2(\text{overall})\text{-scaled} = 0.843$ ;  $\Delta r^2(\text{overall})\text{-scaled} = 0.074$ .

$$\text{Log}K_{oc} = 1.714 - 0.242*(nO) + 0.033*(CATS2D\_07\_LL) - 0.044*(CATS2D\_02\_LL) + 0.307*(B05[O-Cl]) - 0.564*(ESOL\_LogS) \quad (3)$$

$n_{\text{training}} = 47$ ;  $R^2 = 0.917$ ;  $RMSEC = 0.245$ ;  $F_{95\%} = 464.02$  (valor tabelado: 2.61);  $Q^2_{\text{LOO}} = 0.884$ ;  $RMSECV = 0.290$ ;  $Av\_r^2(\text{LOO})\text{-scaled} = 0.839$ ;  $\Delta r^2(\text{LOO})\text{-scaled} = 0.063$ ;  $n_{\text{test}} = 12$ ;  $R^2_{\text{pred}} = 0.936$ ;  $RMSEP = 0.181$ ;  $Av\_r^2(\text{pred})\text{-scaled} = 0.746$ ;  $\Delta r^2(\text{pred})\text{-scaled} = 0.109$ ;  $k = 0.957$ ;  $k' = 1.041$ ;  $|R^2_0 - R'^2_0| = 0.021$ ;  $Av\_r^2(\text{overall})\text{-scaled} = 0.837$ ;  $\Delta r^2(\text{overall})\text{-scaled} = 0.088$ .



**Figura 7.** Gráficos obtidos com os testes de validação cruzada LNO e de y-randomization para os Modelos 2 (A e B) e 3 (C e D).

Os modelos 2 e 3 demonstram melhora significativa na qualidade estatística da validação interna em comparação ao modelo 1. No que diz respeito à validação externa, o modelo 2 apresenta desempenho praticamente equivalente ao modelo original, com um  $R^2_{pred}$  apenas 0,002 unidades superiores, enquanto o modelo 3 apresenta uma ligeira redução de 0,019 unidades nesse parâmetro. Diante da semelhança numérica entre os resultados, foram empregados os critérios adicionais  $Av\_r^2(LOO)$ -scaled e  $\Delta r^2(LOO)$ -scaled, conforme proposto por Roy et al. (2009) [45], para identificar o modelo mais adequado. Com base nessas métricas, conclui-se que tanto o modelo 2 quanto o modelo 3 superam o modelo 1 em termos de qualidade global. No entanto, quando comparados entre si, suas estatísticas permanecem muito próximas: o modelo 2 se destaca levemente na validação interna, enquanto o modelo 3 apresenta vantagem na validação externa. Considerando que a validação externa é, geralmente, o critério mais relevante em modelagem QSPR, os valores de  $R^2_m$  Overall confirmam que o modelo 3 oferece a melhor qualidade global de predição.

Essa superioridade do modelo 3, que incorporou o descritor ESOL\_LogS, é particularmente interessante, já que, isoladamente, esse algoritmo teve desempenho modesto em sua versão univariada. O ESOL\_LogS considera propriedades globais da molécula, como lipossolubilidade, peso molecular e outras variáveis amplamente utilizadas em QSPR, e foi desenvolvido com base em uma base de dados composta por 2874 compostos neutros em pH 7. O modelo foi treinado via regressão linear múltipla (MLR) para prever valores de LogS [53]. Um aspecto relevante é que esse algoritmo foi previamente avaliado para compostos agroquímicos, apresentando bom desempenho, o que pode explicar, em parte, o bom resultado quando utilizado no modelo multivariado.

Esse comportamento ilustra um fenômeno comum em calibração multivariada: descritores que individualmente produzem modelos preditivos fracos podem, quando combinados a outros, gerar modelos

robustos — e o oposto também pode ocorrer [39]. Isso reforça a necessidade de uma análise criteriosa da origem e natureza dos descritores utilizados, principalmente quando se modela propriedades como o LogKoc, que estão intimamente ligadas tanto à partição óleo/água quanto à solubilidade aquosa. Estudos anteriores corroboram essa observação, indicando que a escolha do método teórico de cálculo de propriedades físicoquímicas pode impactar diretamente a performance do modelo, sendo necessária uma avaliação caso a caso. [12]

A Tabela 15 apresenta os resultados das regressões univariadas construídas com ambos os parâmetros (New\_LogSp e Original\_LogSp), contendo os respectivos valores dos testes de validação interna e externa. Os dados revelam que o modelo gerado com New\_LogSp apresenta desempenho estatístico levemente superior em comparação ao modelo baseado no Original\_LogSp, destacando-se, principalmente, pelo valor de  $R^2_{pred}$ , que foi 0,057 unidades maiores. Apesar dessa melhora, ambos os modelos apresentaram limitações em termos de validação externa. O modelo com Original\_LogSp foi reprovado em dois critérios estatísticos fundamentais: Average\_  $r^2m(pred)$ -scaled e o coeficiente angular  $k'$ , comprometendo sua confiabilidade preditiva.

Tabela 15. Modelos de predição usando os LogP e LogSw selecionados, suas respectivas equações QSPR univariadas, e métricas de validação interna

| Equation                                    | - 0.378*Original_LogSp + 0.219 | -0.405*New_LogSp + 0.447 |
|---------------------------------------------|--------------------------------|--------------------------|
| <b>Parâmetro</b>                            |                                |                          |
| <b>Internal validation</b>                  |                                |                          |
| $n_{training}$                              | 47                             | 47                       |
| $R^2$                                       | 0.822                          | 0.879                    |
| <b>RMSEC</b>                                | 0.359                          | 0.296                    |
| $F_{95\%}$ (valor tabelado: 4.05)           | 207.859                        | 326.554                  |
| $Q^2_{Loo}$                                 | 0.809                          | 0.867                    |
| <b>RMSECV</b>                               | 0.372                          | 0.311                    |
| <b>Av_ <math>r^2</math>(LOO)-scaled</b>     | 0.754                          | 0.815                    |
| <b><math>\Delta r^2</math>(LOO)-scaled</b>  | 0.137                          | 0.085                    |
| <b>External validation</b>                  |                                |                          |
| $n_{test}$                                  | 12                             | 12                       |
| $R^2_{pred}$                                | 0.541                          | 0.677                    |
| <b>RMSEP</b>                                | 0.483                          | 0.405                    |
| <b>Av_ <math>r^2</math>(pred)-scaled</b>    | 0.219                          | 0.464                    |
| <b><math>\Delta r^2</math>(pred)-scaled</b> | 0.178                          | 0.268                    |
| <b>k</b>                                    | 0.888                          | 0.894                    |
| <b>k'</b>                                   | 1.099                          | 1.104                    |
| <b> <math>R^2_o - R^2_o</math> </b>         | 0.119                          | 0.044                    |

Por outro lado, o modelo com New\_LogSp falhou apenas no critério  $\Delta r^2m(pred)$ -scaled, indicando um desempenho um pouco mais robusto, embora ainda insuficiente para atender plenamente aos critérios de validação externa adotados neste estudo. Essa diferença de desempenho é coerente com os resultados observados nas análises univariadas anteriores (ver Tabela 4), onde o algoritmo MLogP, um dos componentes do New\_LogSp, demonstrou ser o mais eficaz entre os avaliados, superando o desempenho dos algoritmos ALOGPs e ALOGpS, que compõem o Original\_LogSp.

Com isso embora o New\_LogSp tenha apresentado desempenho estatístico superior ao parâmetro original, ambos os modelos falharam em atender integralmente aos critérios exigidos para validação externa, o que os desqualifica, neste momento, como ferramentas confiáveis para predição de novos compostos. Esses resultados reforçam a importância de validações rigorosas e da escolha criteriosa dos descritores na construção de parâmetros híbridos aplicados em modelos QSAR/QSPR.

Na etapa seguinte, foram avaliados os modelos multivariados 4 e 5, construídos a partir da adição dos parâmetros Original\_LogSp e New\_LogSp, respectivamente, ao conjunto de descritores do modelo 1. O modelo 4 foi composto por três variáveis latentes (LVs), que acumularam 89,69% da variância explicada (LV1: 66,66%; LV2: 12,31%; LV3: 10,72%), enquanto o modelo 5 incorporou quatro LVs, com acúmulo de 94,94% da informação total (LV1: 71,72%; LV2: 10,25%; LV3: 8,17%; LV4: 4,81%).

Os resultados dos testes de validação cruzada por Leave-N-Out (LNO) e do teste de Y-randomization para ambos os modelos são apresentados na Figura 4. Embora os modelos 4 e 5 apresentem uma melhora significativa nos indicadores estatísticos em relação ao modelo base (modelo 1), seus desempenhos ainda são próximos àqueles observados para os modelos 2 e 3, construídos com os parâmetros isolados MLogP e ESOL\_LogS.


Apesar dessa proximidade nos resultados, o modelo 4 se destaca por apresentar os melhores valores para os principais parâmetros estatísticos:  $R^2$ ,  $Q^2_{LOO}$  e  $R^2_{pred}$ , todos superiores a 0,90. Esse desempenho o posiciona como o modelo de maior qualidade entre todos os avaliados neste estudo. Os resultados sugerem que a inclusão do parâmetro Original\_LogSp, mesmo sendo menos eficaz isoladamente nas análises univariadas, contribuiu de forma sinérgica para a construção de um modelo multivariado mais robusto e com excelente capacidade preditiva.

$$\text{Log}K_{oc} = 1.565 - 0.150 \cdot (\text{nO}) + 0.106 \cdot (\text{CATS2D\_07\_LL}) - 0.002 \cdot (\text{CATS2D\_02\_LL}) + 0.327 \cdot (\text{B05[O-Cl]}) - 0.224 \cdot (\text{Original\_LogSp}) \quad (4)$$

$n_{\text{training}} = 47$ ;  $R^2 = 0.946$ ;  $RMSEC = 0.197$ ;  $F_{95\%} = 753.30$  (valor tabelado: 2.84);  $Q^2_{LOO} = 0.928$ ;  $RMSECV = 0.228$ ;  $Av\_r^2(\text{LOO})\text{-scaled} = 0.899$ ;  $\Delta r^2(\text{LOO})\text{-scaled} = 0.042$ ;  $n_{\text{test}} = 12$ ;  $R^2_{\text{pred}} = 0.948$ ;  $RMSEP = 0.162$ ;  $Av\_r^2(\text{pred})\text{-scaled} = 0.858$ ;  $\Delta r^2(\text{pred})\text{-scaled} = 0.012$ ;  $k = 0.971$ ;  $k' = 1.026$ ;  $|R^2_0 - R'^2_0| = 0.010$ ;  $Av\_r^2(\text{overall})\text{-scaled} = 0.901$ ;  $\Delta r^2(\text{overall})\text{-scaled} = 0.056$

$$\text{Log}K_{oc} = 1.278 - 0.076 \cdot (\text{nO}) + 0.038 \cdot (\text{CATS2D\_07\_LL}) - 0.032 \cdot (\text{CATS2D\_02\_LL}) + 0.394 \cdot (\text{B05[O-Cl]}) - 0.314 \cdot (\text{New\_LogSp}) \quad (5)$$

$n_{\text{training}} = 47$ ;  $R^2 = 0.925$ ;  $RMSEC = 0.233$ ;  $F_{95\%} = 518.00$  (valor tabelado: 2.61);  $Q^2_{LOO} = 0.895$ ;  $RMSECV = 0.276$ ;  $Av\_r^2(\text{LOO})\text{-scaled} = 0.854$ ;  $\Delta r^2(\text{LOO})\text{-scaled} = 0.057$ ;  $n_{\text{test}} = 12$ ;  $R^2_{\text{pred}} = 0.884$ ;  $RMSEP = 0.243$ ;  $Av\_r^2(\text{pred})\text{-scaled} = 0.585$ ;  $\Delta r^2(\text{pred})\text{-scaled} = 0.195$ ;  $k = 0.937$ ;  $k' = 1.061$ ;  $|R^2_0 - R'^2_0| = 0.080$ ;  $Av\_r^2(\text{overall})\text{-scaled} = 0.846$ ;  $\Delta r^2(\text{overall})\text{-scaled} = 0.079$



**Figura 8.** Gráficos obtidos com os testes de validação cruzada LNO e de y-randomization para os Modelos 4 (A e B) e 5 (C e D).

A análise dos coeficientes autoescalados do modelo 4 revela que o descritor Original\_LogSp apresenta a maior importância relativa entre as variáveis utilizadas, com valor absoluto de |0.538|, seguido por nO (|0.250|), CATS2D\_07\_LL (|0.202|), B05[O-CI] (|0.145|) e CATS2D\_02\_LL (|0.003|). Considerando os sinais dos coeficientes, compostos com maiores valores de nO e CATS2D\_02\_LL tendem a apresentar menores valores de LogKoc, ou seja, menor retenção no solo. Em contrapartida, compostos com valores mais altos de CATS2D\_07\_LL e B05[O-CI] tendem a apresentar maior retenção, indicando maior afinidade com a matriz orgânica. Essa interpretação está de acordo com a polaridade das estruturas, já que os dois primeiros descritores estão associados a maior polaridade (principalmente nO, o segundo mais relevante), enquanto os dois últimos refletem características de menor polaridade.

Além da qualidade estatística superior, o aspecto mais interessante do modelo 4 está em seu desempenho significativamente melhor em relação ao modelo 5, mesmo considerando que os descritores ALOGPs e ALOGpS, individualmente, não geraram os melhores modelos univariados. Isso sugere que, ao serem combinados, esses dois algoritmos podem ter codificado informações complementares relacionadas ao fenômeno de sorção, dando origem ao descritor Original\_LogSp, que reforça e complementa as informações trazidas pelos demais descritores. Por outro lado, a junção de MLogP e ESOL\_LogS na criação de New\_LogSp pode não ter promovido o mesmo efeito sinérgico, possivelmente por serem construídos a partir de bancos de dados diferentes e não complementares.

Embora o modelo 5 também apresente estatísticas sólidas e seja considerado adequado para fins preditivos, sua confiabilidade é ligeiramente inferior. Isso pode ser observado pelos valores dos parâmetros AveragePred (0,585) e DeltaPred (0,195), que estão próximos de seus limites críticos, sugerindo uma menor robustez.

Outro ponto relevante é a origem dos dados utilizados nos algoritmos. Embora ALOGPs e ALOGpS não tenham produzido os melhores modelos univariados neste estudo, vale destacar que seus bancos de dados de treinamento estão entre os maiores da literatura, com mais de 12.900 compostos, proporcionando uma ampla representação do espaço químico. Essa abrangência pode justificar a boa performance do descritor Original\_LogSp em modelos multivariados, como também já foi observado em estudos anteriores [31], o que motivou seu uso na proposta original do LogSp. [32]

No estudo original, os algoritmos ALOGPs e ALOGpS geraram bons modelos univariados, com valores expressivos de  $R^2$ ,  $Q^2_{\text{LOO}}$  e  $R^2_{\text{pred}}$  (ALOGPs: 0,744, 0,735 e 0,768; ALOGpS: 0,788, 0,782 e 0,708, respectivamente). Esses resultados, atribuídos à diversidade e dimensão do banco de dados utilizado em sua construção [38], contrastam com os do presente estudo, onde MLogP, mesmo treinado com um banco menor, foi o que gerou a melhor validação externa entre os modelos univariados. Embora MLogP tenha apresentado  $R^2_{\text{pred}}$  e  $Q^2_{\text{LOO}}$  inferiores em comparação aos multivariados, seu desempenho próximo à regressão construída com LogKoc experimental o posiciona como o algoritmo mais indicado para uso isolado na predição de LogKoc de éteres difenílicos.

Diversos estudos QSPR para a predição de LogKoc já demonstram que não há um método universalmente superior para a estimativa do LogP. Diferentes algoritmos foram empregados com sucesso, como KOWWIN [54], ACDLogP [55], miLogP [56], XLogP3, entre outros. Inclusive, o próprio MLogP e sua forma quadrática (MLogP<sup>2</sup>) também já foram aplicados com sucesso em diferentes contextos. [54,57]

Apesar disso, mesmo com todo seu desempenho individual, o MLogP não supera a performance global do modelo multivariado obtido com o Original\_LogSp, o único a apresentar os principais parâmetros de validação acima de 0,9. A combinação entre este descritor híbrido e os descritores estruturais permitiu a construção do modelo mais robusto do estudo, revelando a importância da complementaridade das informações na modelagem preditiva. Por outro lado, New\_LogSp não alcançou o mesmo sucesso, possivelmente por ESOL\_LogS não carregar informações químicas capazes de complementar adequadamente o MLogP na composição do descritor.

Outra vantagem do modelo 4: ao contrário dos modelos 2, 3 e 5, ele alcançou sua qualidade superior com apenas três variáveis latentes, o que reforça sua simplicidade, interpretabilidade e robustez. Em geral, modelos QSPR que demandam menor número de variáveis, sejam descritores originais ou projeções latentes, são preferíveis, pois tendem a ser mais estáveis, menos propensos a sobreajuste e mais fáceis de interpretar. Isso está de acordo com os princípios estabelecidos por [58], que recomendam modelos mais parcimoniosos quando estes oferecem desempenho igual ou superior.

Após a realização das análises univariadas e da seleção dos algoritmos que apresentaram melhor desempenho para os descritores LogP e LogS, procedeu-se ao desenvolvimento dos modelos multivariados para predição do coeficiente de

## 7.8 Considerações finais do estudo

Os resultados deste estudo demonstram que a escolha dos algoritmos utilizados para o cálculo dos descritores LogP e LogS influencia diretamente o desempenho dos modelos QSPR desenvolvidos para a

predição do coeficiente de adsorção ao carbono orgânico (LogKoc) de éteres difenílicos substituídos. Os descritores relacionados à lipofilicidade apresentaram melhor desempenho estatístico, indicando que as interações hidrofóbicas exercem papel predominante nos processos de sorção desses compostos no solo. Entre os algoritmos avaliados, o MLOGP destacou-se pela elevada capacidade preditiva, evidenciando que a qualidade da representação das propriedades moleculares é mais importante do que o tamanho da base de dados utilizada para o desenvolvimento do algoritmo.

Os modelos multivariados apresentaram elevada robustez, excelente capacidade preditiva e forte potencial de generalização. A incorporação do descritor híbrido LogSp demonstrou que a combinação entre lipofilicidade e solubilidade em água pode melhorar a representação das propriedades físico-químicas relacionadas ao LogKoc. Entre os descritores avaliados, o Original\_LogSp apresentou o melhor desempenho, indicando que a integração entre propriedades hidrofóbicas e hidrofílicas contribui para aumentar a qualidade das predições.

Os resultados obtidos confirmam a importância da seleção criteriosa dos algoritmos utilizados para estimar os descritores moleculares empregados na modelagem QSPR, uma vez que diferentes métodos podem influenciar significativamente a capacidade preditiva dos modelos. Além disso, os modelos desenvolvidos apresentaram desempenho compatível com sua aplicação na estimativa do comportamento ambiental de compostos orgânicos persistentes, reduzindo a necessidade de ensaios experimentais e contribuindo para avaliações ambientais mais rápidas e economicamente viáveis.

Por fim, este estudo demonstra que a integração de descritores moleculares obtidos por diferentes metodologias constitui uma estratégia promissora para o desenvolvimento de modelos QSPR mais robustos e confiáveis. Os modelos propostos apresentam potencial para auxiliar estudos de avaliação ambiental, monitoramento de contaminantes e processos de tomada de decisão em programas de gerenciamento de risco e regulamentação ambiental.

## 8. CONCLUSÃO

Esta dissertação demonstrou o potencial da modelagem QSAR/QSPR como uma abordagem eficiente para a avaliação de propriedades toxicológicas e ambientais de poluentes orgânicos persistentes, contribuindo para a compreensão dos fatores moleculares que influenciam a toxicidade e o comportamento ambiental desses compostos. Os modelos desenvolvidos apresentaram desempenho estatístico satisfatório, evidenciado por sua robustez, estabilidade e capacidade preditiva, atendendo aos critérios de validação recomendados pelas diretrizes da Organização para a Cooperação e Desenvolvimento Econômico (OCDE).

Os três estudos desenvolvidos permitiram prever a toxicidade oral e inalatória de compostos per- e polifluoroalquilados (PFAS) em mamíferos, identificar padrões estruturais relacionados à toxicidade de pesticidas em abelhas (*Apis mellifera*) e estimar o coeficiente de adsorção ao carbono orgânico do solo (LogKoc) de éteres difenílicos substituídos. Em conjunto, esses resultados evidenciam a capacidade das abordagens QSAR/QSPR em fornecer informações relevantes para a avaliação do risco toxicológico e ambiental de substâncias químicas de interesse regulatório.

Além da elevada capacidade preditiva observada, os modelos possibilitaram identificar os descritores moleculares mais relevantes para cada propriedade estudada, ampliando a compreensão dos mecanismos envolvidos nos processos de toxicidade, mobilidade, persistência e bioacumulação dos compostos avaliados. Dessa forma, esta pesquisa não apenas disponibiliza modelos preditivos confiáveis, mas também fornece subsídios científicos para o desenvolvimento de substâncias químicas mais seguras e ambientalmente sustentáveis.

Os resultados obtidos reforçam a importância da químicaoinformática e das metodologias *in silico* como alternativas complementares aos ensaios experimentais convencionais, possibilitando a redução de custos, do tempo de análise e da utilização de animais em estudos toxicológicos, em consonância com os princípios atuais de sustentabilidade, ética científica e dos 3Rs (Replacement, Reduction and Refinement). Além disso, os modelos desenvolvidos apresentam potencial para aplicação em processos de triagem, priorização e regulamentação de substâncias químicas potencialmente perigosas.

Por fim, esta dissertação amplia a aplicação de modelos QSAR/QSPR nas áreas ambiental e toxicológica, demonstrando que abordagens computacionais adequadamente desenvolvidas e validadas constituem ferramentas confiáveis para a previsão de propriedades químicas, ecotoxicológicas e toxicológicas. Dessa forma, os modelos propostos podem contribuir para a tomada de decisões em processos regulatórios, para o gerenciamento do risco químico e para o desenvolvimento de estratégias voltadas à proteção da saúde humana e do meio ambiente.

## 9. AGRADECIMENTOS

“O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Financiamento 001”.

“This study was financed in part by the Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Finance Code 001”.

## 10. REFERÊNCIAS

- [1] SOSNOWSKA, N.; BULAWSKA, D.; KOWALSKA, T. Towards higher scientific validity and regulatory acceptance of predictive models for PFAS. *Green Chem.*, v. 25, p. 1261, 2023. DOI: <https://doi.org/10.1039/D2GC04341F>.
- [2] ALVES, M. S.; STREIT, L.; PIZZOLATO, T. M. Utilização de modelos *in silico* para avaliação da toxicidade de resíduos de agrotóxicos, fármacos e metabólitos em águas naturais. *Química Nova*, v. 46, n. 9, p. 881–889, 2023. Disponível em: <https://doi.org/10.21577/0100-4042.20230062>. Acesso em: 12 mar. 2025.
- [3] BENFENATI, E. Theory, guidance and applications on QSAR and REACH. 1. ed. Milano: Istituto di Ricerche Farmacologiche “Mario Negri”, 2012.
- [4] ONLINE CHEMICAL MODELING ENVIRONMENT. OCHEM. Disponível em: <https://ochem.eu/home/show.do>. Acesso em: 18 fev. 2025.
- [5] ALVES, V. M.; BRAGA, R. C.; MURATOV, E. N.; ANDRADE, C. H. Químicaoinformática: uma introdução. *Química Nova*, v. 41, n. 2, p. 202–212, 2018. DOI: 10.21577/0100-4042.20170145.

- [6] MAURI, A.; CONSONNI, V.; TODESCHINI, R. Molecular Descriptors. In: Handbook of Computational Chemistry. 1ª ed. Suíça: Springer, 2017. p. 2065-2093. DOI: 10.1007/978-3-319-27282-5\_51. ISBN 978-3-319-27281-8.
- [7] MARTINS, J. P. A.; FERREIRA, M. M. C. Modelagem QSAR: um novo pacote computacional open source para gerar e validar modelos QSAR. Química Nova, v. 36, n. 4, p. 554–560, 2013. DOI: 10.1590/S0100-40422013000400013.
- [8] NUNES, C. A.; FREITAS, M. P.; PINHEIRO, A. C. M.; BASTOS, S. C. Chemoface: a novel free user-friendly interface for chemometrics. Journal of the Brazilian Chemical Society, v. 23, n. 11, p. 2003–2010, 2012. DOI: 10.1590/S0103-50532012005000073.
- [9] ORGANISATION FOR ECONOMIC CO-OPERATION AND DEVELOPMENT – OECD. OECD QSAR Toolbox. 2014. Disponível em: <https://www.oecd.org/en/data/tools/oecd-qsar-toolbox.html>. Acesso em: 12 mar. 2025.
- [10] EUROPEAN CHEMICALS AGENCY – ECHA. European Chemicals Agency (ECHA). 2008. Disponível em: <https://echa.europa.eu/>. Acesso em: 12 mar. 2025.
- [11] CASARETT, L. J.; DOULL, J. Casarett and Doull's Toxicology: The Basic Science of Poisons. Reino Unido: McGraw-Hill, 2001.
- [12] DOS REIS, Ralpho Rinaldo; SAMPAIO, Silvio César; DE MELO, Eduardo Borges. The effect of different log P algorithms on the modeling of the soil sorption coefficient of nonionic pesticides. Water Research, v. 47, n. 15, p. 5751-5759, 2013. Disponível em: <https://doi.org/10.1016/j.watres.2013.06.053>. Acesso em: 27 maio 2025.
- [13] SILVA, N. A. B. R.; MELO, E. B. Análise da toxicidade oral e inalatória de compostos orgânicos per- e polifluoroalquilados em ratos e camundongos utilizando QSAR multivariado. SAR and QSAR in Environmental Research, v. 35, n. 10, p. 877–897, 2024. Disponível em: <https://doi.org/10.1080/1062936X.2024.2417250>. Acesso em: 12 mar. 2025.
- [14] Cheng, W., & Ng, C. A. (2019). Using Machine Learning to Classify Bioactivity for 3486 Per- and Polyfluoroalkyl Substances (PFAS) from the OECD List. Environmental Science & Technology, 53(23), 13970-13980. <https://doi.org/10.1021/acs.est.9b04833>.
- [15] PERSON, A. L. Perfluoroalquil e polifluoroalquil compostos: uma síntese do conhecimento atual [tese]. São Paulo: Escola Politécnica da Universidade de São Paulo, Departamento de Engenharia Química; 2022.
- [16] NIEGOWSKA, M.; PRETTO, P.; PORCEL-RODRIGUEZ, E.; et al. Substâncias perfluoroalquil e polifluoroalquil (PFAS) de possível preocupação no ambiente aquático. Luxemburgo: Publicações da Oficina da União Europeia; 2021. EUR 30710 EN. doi: 10.2760/377564.
- [17] TAN, H.; TANG, S.; YANG, L.; et al. Quantificação global de substâncias perfluoroalquil e polifluoroalquil emergentes e legadas em poeira interna: níveis, perfis e exposição humana. Sci Total Environ. 2024; 927:172132. doi: 10.1016/j.scitotenv.2024.172132.
- [18] DE LA TORRE, A.; NAVARRO, I.; SANZ, P.; et al. Ocorrência e avaliação da exposição humana a substâncias perfluoradas em poeira doméstica de três países europeus. Sci Total Environ. 2019; 685:308–314. doi: 10.1016/j.scitotenv.2019.05.463.
- [19] LAU, C.; ANITOLE, K.; HODES, C.; et al. Ácidos perfluoroalquil: uma revisão dos resultados de monitoramento e toxicologia. Toxicol Sci. 2007; 99:366–394. doi: 10.1093/toxsci/kfm128.
- [20] Bhatarai, B., & Gramatica, P. (2010). Per- and polyfluoro toxicity (LC50 inhalation) study in rat and mouse using QSAR modeling. Chemical Research in Toxicology, 23(3), 528–539. <https://doi.org/10.1021/tx900252h>.
- [21] Bhatarai, B., & Gramatica, P. (2011). Oral LD50 toxicity modeling and prediction of per- and polyfluorinated

chemicals on rat and mouse. *Molecular Diversity*, 15, 467–476. <https://doi.org/10.1007/s11030-010-9268-z>.

[22] WANG, Y.; SUZEK, T.; ZHANG, J.; et al. PubChem BioAssay: atualização de 2014. *Nucleic Acids Res.* 2014; 42:D1075–D1082. doi: 10.1093/nar/gkt978.

[23] CAIRES, S. C.; BARCELOS, D. Colapso das abelhas: possíveis causas e consequências do seu desaparecimento na natureza. *Acta Apícola Brasileira*, 2017. Disponível em: <https://doi.org/10.18378/aab.v5i1.5294>. Acesso em: 29 nov. 2024.

[24] CHIFRE BRANCO, P. R.; O'CONNOR, S.; FELIX, L.; GOULSON, D. Pesticida neonicotinóide reduz o crescimento de colônias de abelhas e a produção de rainhas. *Science*, v. 336, n. 6079, p. 351-352, 2012. DOI: <https://doi.org/10.1126/science.12150>.

[25] UNEP. Pesticide Persistent Organic Pollutants (POPs). Disponível em: <https://www.unep.org/topics/pollution-and-health/persistent-organic-pollutants-pops/pesticide-persistent-organic>. Acesso em: 20 fev. 2025.

[26] FARRUGGIA, F. T.; GARBER, K.; JONES, K.; KYLE, L. et al. Uma análise retrospectiva de dados de toxicidade de pesticidas em abelhas (*Apis*). *PLOS ONE*, v. 17, n. 4, p. e0265962, 2022. Disponível em: <https://doi.org/10.1371/journal.pone.0265962>. Acesso em: 29 nov. 2024.

[27] MOREIRA-FILHO, José T.; BRAGA, Rodolpho C.; LEMOS, Jade Milhomem; ALVES, Vinicius M.; BORBA, Joyce V. V. B.; COSTA, Wesley S.; KLEINSTREUER, Nicole; MURATOV, Eugene N.; ANDRADE, Carolina Horta; NEVES, Bruno J. BeeToxAI: An artificial intelligence-based web app to assess acute toxicity of chemicals to honey bees. *Science of The Total Environment*, v. 865, p. 161003, 2023. Disponível em: <https://doi.org/10.1016/j.scitotenv.2023.161003>. Acesso em: 12 mar. 2025.

[28] BIOLOGICAL SIGNALS LABORATORY – BIOSIG. Crop CSM. Disponível em: [https://biosig.lab.uq.edu.au/crop\\_csm/](https://biosig.lab.uq.edu.au/crop_csm/). Acesso em: 21 jan. 2025.

[29] XU, Xuan; ZHAO, Piaopiao; WANG, Zhiyuan; ZHANG, Xiaoxiao; WU, Zengrui; LI, Weihua; TANG, Yun; LIU, Guixia. In silico prediction of chemical acute contact toxicity on honey bees via machine learning methods. *Toxicology in Vitro*, v. 72, p. 105089, 2021. ISSN 0887-2333. Disponível em: <https://doi.org/10.1016/j.tiv.2021.105089>. Acesso em: 12 mar. 2025

[30] Alharbi, O.M.L. et al., 2018. Health and environmental effects of persistent organic pollutants. *Journal of Molecular Liquids*, 263, pp.442–453. <https://doi.org/10.1016/j.molliq.2018.05.029>

[31] Zhang, X. et al., 2015. Experimental investigation on the soil sorption properties and hydrophobicity of polymethoxylated, polyhydroxylated diphenyl ethers and methoxylated-, hydroxylated-polychlorinated diphenyl ethers. *Chemosphere*, 134, pp.84–90. <https://doi.org/10.1016/j.chemosphere.2015.04.011>

[32] DOS REIS, Ralpho Rinaldo; SAMPAIO, Silvio César; DE MELO, Eduardo Borges. An alternative approach for the use of water solubility of nonionic pesticides in the modeling of the soil sorption coefficients. *Water Research*, v. 53, p. 191-199, 2014. Disponível em: <https://doi.org/10.1016/j.watres.2014.01.023>. Acesso em: 27 maio 2025.

[33] Zhang, X. et al., 2018. QSPR modeling of the logKow and logKoc of polymethoxylated... methoxylated-, hydroxylated-polychlorinated diphenyl ethers. *Journal of Hazardous Materials*, 353, pp.542–551. <https://doi.org/10.1016/j.jhazmat.2018.03.043>

[34] ACD/Labs. ChemSketch Freeware [Internet]; c2025. Available from: <https://www.acdlabs.com/resources/free-chemistry-software-apps/chemsketch-freeware/> [cited 28 May 2025]

[35] Wold, S., Sjöström, M., Eriksson, L., 2001. PLS-regression: a basic tool of chemometrics. *Chemometrics and Intelligent Laboratory Systems*, 58(2), pp.109–130. [https://doi.org/10.1016/S0169-7439\(01\)00155-1](https://doi.org/10.1016/S0169-7439(01)00155-1)

[36] Kiralj, R., Ferreira, M.M.C., 2009. Basic validation procedures for regression models in QSAR and QSPR

studies: Theory and application. *Journal of the Brazilian Chemical Society*, 20(4), pp.770–787.  
<https://doi.org/10.1590/S0103-50532009000400021>

[37] Tropsha, A., Gramatica, P., Gombar, V.K., 2003. The importance of being earnest: validation is the absolute essential for successful application and interpretation of QSPR models. *QSAR & Combinatorial Science*, 22(1), pp.69–77. <https://doi.org/10.1002/qsar.200390007>

[38] Tetko, I.V., Tanchuk, V.Y., 2002. Application of associative neural networks for prediction of lipophilicity in ALOGPS 2.1 program. *Journal of Chemical Information and Computer Sciences*, 42(5), pp.1136–1145.  
<https://doi.org/10.1021/ci025515j>

[39] Dearden, J.C., Cronin, M.T.D., Kaiser, K.L.E., 2009. How not to develop a quantitative structure–activity or structure–property relationship (QSAR/QSPR). *SAR and QSAR in Environmental Research*, 20(3–4), pp.241–266. <https://doi.org/10.1080/10629360902949567>

[40] Gaudio, A.C., Zandonade, E., 2001. Proposition, validation and analysis of QSAR models. *Química Nova*, 24, pp.658–671. <https://doi.org/10.1590/S0100-40422001000500013>

[41] Roy, K., Mitra, I., 2012. On the use of the metric  $rm^2$  as an effective tool for validation of QSAR models in computational drug design and predictive toxicology. *Mini-Reviews in Medicinal Chemistry*, 12, pp.491–504.  
<https://doi.org/10.2174/138955712800493861>

[42] Roy, K. et al., 2013. Some case studies on application of “ $rm^2$ ” metrics for judging quality of QSAR predictions: Emphasis on scaling of response data. *Journal of Computational Chemistry*, 34, pp.1071–1082.  
<https://doi.org/10.1002/jcc.23231>

[43] Eriksson, L. et al., 2003. Multi- and megavariable data analysis part I: Basic principles and applications. *Chemometrics and Intelligent Laboratory Systems*, 87(2), pp.83–96. [https://doi.org/10.1016/S0169-7439\(03\)00035-5](https://doi.org/10.1016/S0169-7439(03)00035-5)

[44] Golbraikh, A. et al., 2003. Rational selection of training and test set for the development of validated QSAR models. *Journal of Computer-Aided Molecular Design*, 17(2–4), pp.241–253.

[45] Roy, P.P. et al., 2009. On two novel parameters for validation of predictive QSAR models. *Molecules*, 14, pp.1660–1701. <https://doi.org/10.3390/molecules14041660>

[46] Wold, S., Eriksson, L., 1998. Statistical validation of QSAR results. In: van de Waterbeemd, H. (Ed.). *Chemometric Methods in Molecular Design*. Weinheim: Wiley-VCH, pp.309–318.

[47] Papa, E., Dearden, J.C., Gramatica, P., 2007. Linear QSAR regression models for the prediction of bioconcentration factors by physicochemical properties and structural theoretical molecular descriptors. *Chemosphere*, 67, pp.351–358. <https://doi.org/10.1016/j.chemosphere.2006.09.079>

[48] Roy, K., 2007. *2D-QSAR: Quantitative structure-activity relationship in drug design*. Weinheim: Wiley-VCH.

[49] Van Drie, J., 2003. Pharmacophore discovery – lessons learned. *Current Pharmaceutical Design*, 9, pp.1649–1664. <https://doi.org/10.2174/1381612033454568>

[50] Mannhold, R., Poda, G.I., Ostermann, C., Tetko, I.V., 2009. Calculation of molecular lipophilicity: State-of-the-art and comparison of log P methods on more than 96,000 compounds. *Journal of Pharmaceutical Sciences*, 98(3), pp.861–893. <https://doi.org/10.1002/jps.21494>

[51] Todeschini, R., & Consonni, V. (2009). *Molecular Descriptors for Chemoinformatics: Volume I: Alphabetical Listing / Volume II: Appendices, References* (2nd ed.). John Wiley & Sons, Alemanha. Collaborators: Mannhold, R., Kubinyi, H., & Folkers, G. ISBN 3527628770, 9783527628773.

[52] Tefilo, R.F., Martins, J.P., Ferreira, M.M.C., 2009. Sorting variables by using informative vectors as a strategy for feature selection in multivariate regression. *Journal of Chemometrics*, 23(1), pp.32–48.

<https://doi.org/10.1002/cem.1192>

[53] Delaney, J.S., 2004. ESOL: Estimating aqueous solubility directly from molecular structure. *Journal of Chemical Information and Computer Sciences*, 44, pp.1000–1005. <https://doi.org/10.1021/ci034243x>

[54] Olguin, C.J.M., Sampaio, S.C., Dos Reis, R.R., 2017. Statistical equivalence of prediction models of the soil sorption coefficient obtained using different log P algorithms. *Chemosphere*, 184, pp.498–504. <https://doi.org/10.1016/j.chemosphere.2017.06.027>

[55] Petrauskas, A.A., Kolovanov, E.A., 2000. ACD/Log P method description. *Perspectives in Drug Discovery and Design*, 19, pp.99–116. <https://doi.org/10.1023/A:1008719622770>

[56] Schüürmann, G. et al., 2014. Prediction of the Sorption of Organic Compounds into Soil: A Comparison of Different Models. *Bulletin of Environmental Contamination and Toxicology*, 92(2), pp.143–147. <https://doi.org/10.1007/s00128-013-1184-3>

[57] Shao, Y. et al., 2014. Integrated QSPR models to predict the soil sorption coefficient for a large diverse set of compounds by using different modeling methods. *Atmospheric Environment*, 88, pp.212–218. <https://doi.org/10.1016/j.atmosenv.2013.12.018>

[58] Wold, S., Sjöström, M., Eriksson, L., 2001. PLS-regression: a basic tool of chemometrics. *Chemometrics and Intelligent Laboratory Systems*, 58(2), pp.109–130. [https://doi.org/10.1016/S0169-7439\(01\)00155-1](https://doi.org/10.1016/S0169-7439(01)00155-1)

## 11. ANEXOS

### 00000011.1 Artigo 1

Análise da toxicidade oral e inalatória de compostos orgânicos per- e polifluoroalquilados em ratos e camundongos utilizando QSAR multivariado

N.A.B.R. da Silva<sup>ab</sup> & E.B. de Melo<sup>ab</sup>

#### Fonte

SAR AND QSAR IN ENVIRONMENTAL RESEARCH, 2024, VOL. 35, NO. 10, PÁGINAS 877–897  
<https://doi.org/10.1080/1062936X.2024.2417250>

© 2024 Informa UK Limited, operando como Taylor & Francis Group

Recebido em 03 de setembro de 2024, Aceito em 09 de outubro de 2024, Publicado online em 18 de outubro de 2024.

<sup>a</sup> Departamento de Química, Universidade Estadual do Oeste do Paraná (UNIOESTE), Toledo, Brasil; <sup>b</sup> Departamento de Farmácia, Laboratório de Química Medicinal e Ambiental Teórica (LQMAT), UNIOESTE, Cascavel, Brasil.

## RESUMO

Compostos orgânicos per- e polifluoroalquilados (PFAS) são substâncias versáteis amplamente utilizadas nas indústrias globais. No entanto, também são poluentes orgânicos persistentes (POPs). Este estudo teve como objetivo desenvolver novos modelos para avaliar a toxicidade oral e inalatória em modelos de ratos e camundongos. Um conjunto de 407 PFAS, extraídos da literatura, foi dividido em quatro grupos com base nos endpoints de interesse. Os modelos foram construídos utilizando apenas descritores estruturais 2D derivados das cadeias SMILES. Os modelos resultantes demonstram uma forte qualidade estatística para todos os endpoints. Eles apresentam um domínio de aplicabilidade (AD) que garante boa confiabilidade e fornecem interpretações

significativas, que são parcialmente apoiadas pela literatura existente. Consequentemente, esses modelos são valiosos para entender como os PFAS exercem seu efeito tóxico em mamíferos e para prever o risco associado a esses importantes agentes químicos industriais.

**Palavras-chave:** PFAS; POPs; toxicidade in sílico; relações quantitativas estrutura-atividade; domínio de aplicabilidade.

## Introdução

Os compostos orgânicos per- e polifluoroalquilados (PFAS) são amplamente utilizados na indústria globalmente. Eles se destacam por suas propriedades hidrofóbicas e lipofóbicas das cadeias carbono-flúor, que possuem tanto extremidades hidrofílicas não-polares quanto polares. Essa característica permite que os PFAS sejam facilmente transportados e adsorvidos em várias superfícies, tornando-os altamente versáteis. São comumente encontrados em produtos como selantes impermeabilizantes, espumas de combate a incêndios, tintas, embalagens de alimentos, roupas, revestimentos de painéis antiaderentes, produtos de higiene pessoal, surfactantes, emulsificantes, entre outros. Suas propriedades de inércia, resistência, estabilidade e durabilidade contribuem para sua resistência à água, manchas e gordura, tornando-os difíceis de substituir. Assim, seu uso continua a se expandir em todos os setores industriais [1–3]. Esses compostos, formados por flúor ligado a cadeias de carbono, foram introduzidos na década de 1950 e, atualmente, estima-se que existam cerca de 5.000 derivados disponíveis [2,4,5].

Esses compostos são classificados como poluentes orgânicos persistentes (POPs). Como possuem ligações carbono-flúor, consideradas as mais fortes da química orgânica, sua estabilidade e persistência ambiental são significativamente altas.

As propriedades físico-químicas dos compostos per- e polifluoroalquilados (PFAS) variam de acordo com seu tamanho e ramificação, o que influencia características como solubilidade em água, mobilidade no solo/água e adsorção ao solo e sedimentos. Os PFAS exibem grande estabilidade, resistência e durabilidade, o que torna sua biodegradação difícil, resultando na acumulação desses compostos no solo, ar e água. Essa persistência leva à exposição contínua de animais e seres humanos a esses produtos químicos, o que contribui para a bioacumulação e toxicidade ambiental em geral [2,3]. Esses compostos têm sido associados a doenças renais, hepáticas e da tireoide, câncer e disfunções nos sistemas imunológico e reprodutivo, especialmente durante a gravidez e o desenvolvimento infantil [2,3,6].

Os efeitos tóxicos desses e de outros produtos químicos em humanos, resultantes da exposição ambiental, podem ser inferidos com base nos resultados observados em determinados testes em animais, como ratos e camundongos. As semelhanças biológicas existentes facilitam a obtenção de dados confiáveis e replicáveis ao controlar variáveis experimentais como idade, sexo e ambiente de exposição. Estudos de toxicidade dérmica, oral e por inalação podem ser realizados se houver risco de exposição por essas vias. Embora controverso, o uso de animais continua sendo necessário para garantir a segurança humana [7–9].

Considerando a importância e a quantidade de diferentes poluentes orgânicos persistentes (POPs) atualmente em uso, a criação de modelos preditivos tornou-se essencial para avaliar os riscos associados a esse tipo de substância química. Uma abordagem comum é realizar modelagem matemática baseada na estrutura química de compostos pré-existentes e um ou mais parâmetros de toxicidade (ou endpoints) avaliados

experimentalmente. Os endpoints são utilizados como variáveis dependentes em modelos de regressão linear ou não linear usando a abordagem QSAR, que envolve correlacionar descritores moleculares derivados das estruturas químicas de um conjunto de dados com os respectivos endpoints. Esses descritores codificam várias propriedades, como carga, polaridade, volume, lipofilia, entre outros. Se obtidos e validados, esses modelos possam ser usados como ferramentas para prever o potencial tóxico de novos compostos químicos [10,11].

Apesar do uso generalizado, os PFAS enfrentam uma crescente regulamentação devido aos seus potenciais efeitos adversos à saúde humana e ao meio ambiente. Muitos países estão implementando restrições e medidas de controle para lidar com essas preocupações, o que destaca a necessidade de um gerenciamento cuidadoso desses compostos [10]. Devido à sua importância industrial, ambiental, toxicológica e regulatória, diversos estudos QSAR/QSPR têm sido conduzidos sobre esses produtos químicos, considerando uma ampla variedade de endpoints (por exemplo, partição octanol-água, citotoxicidade, toxicologia do desenvolvimento, fator de bioconcentração, pressão de vapor, concentração micelar crítica, coeficientes de adsorção interfacial fluido-fluido, entre outros) [10,12–15].

Diante dessa relevância, utilizamos dados sobre toxicidade aguda oral e por inalação em ratos e camundongos para um conjunto de PFAS, com o objetivo de criar modelos QSAR baseados exclusivamente em descritores moleculares derivados das estruturas 2D de um conjunto de 407 PFAS. Nossa meta foi desenvolver modelos fáceis de usar e reproduzíveis, que possam ser aplicados para avaliar e prever o potencial tóxico de outros representantes dessa classe de compostos químicos [8–10].

## **Materiais e Métodos**

### **Conjunto de Dados**

O conjunto de dados selecionado de 407 PFAS foi escolhido a partir da literatura [8,9]. Ele foi subdividido em quatro grupos menores de acordo com o tipo de teste toxicológico realizado. Assim, para os modelos de toxicidade oral ( $LD_{50}$ ), foi construído um subconjunto com 50 amostras ( $LD_{50}$  para ratos, conjunto de dados 1) e outro com 58 amostras ( $LD_{50}$  para camundongos, conjunto de dados 2). Para a toxicidade por inalação ( $LC_{50}$ ), um conjunto teve 144 amostras ( $LC_{50}$  para ratos, conjunto de dados 3) e outro teve 155 amostras ( $LC_{50}$  para camundongos, conjunto de dados 4). O único subconjunto que teve amostras removidas do conjunto de dados original foi o para camundongos. Essa remoção foi necessária devido à presença de compostos inorgânicos e alguns compostos com valores negativos de  $LC_{50}$ , totalizando 9 amostras. Um processo de remoção semelhante também foi implementado por Bhatarai e Gramatica [8,9].

Para cada amostra, as strings SMILES (Simplified Molecular Input Line Entry System) foram extraídas da base de dados PUBCHEM (<https://pubchem.ncbi.nlm.nih.gov/>) [16] utilizando os registros CAS fornecidos pelos estudos originais [8,9]. O conjunto completo de dados é detalhado na Tabela 1. Os subconjuntos estão disponíveis no Material Suplementar.

### **Descritores Moleculares**

Os descritores moleculares foram derivados das representações SMILES (ou seja, apenas das estruturas 2D) de cada composto utilizando o software Dragon 6. Esta ferramenta amplamente utilizada em estudos de

relação estrutura-atividade calcula diversos conjuntos de descritores moleculares, permitindo que os usuários selecionem a abordagem mais apropriada [11,17,18]. Após a realização de todos os cálculos dos descritores moleculares, filtros dentro do Dragon 6 foram aplicados para a redução de variáveis.

É importante observar que Bhatarai e Gramatica [8,9] também utilizaram descritores resultantes da estrutura 3D, o que pode indicar uma relevância importante das propriedades geométricas para a toxicidade dos PFAS. No entanto, neste estudo, optou-se por construir os modelos apenas a partir de descritores baseados nas suas estruturas 2D, por meio de suas respectivas strings SMILES. Essa abordagem permite o uso possível dos modelos apresentados por outras partes interessadas, uma vez que não depende do acesso a métodos de otimização para estruturas tridimensionais, nem da qualidade das geometrias obtidas.

Assim, os descritores moleculares que apresentaram: i) valores constantes ou quase constantes; ii) desvios padrão inferiores a 0,001; iii) pelo menos um valor ausente; iv) correlações em pares  $\geq 0,9$  foram excluídos. Uma inspeção visual também foi realizada para excluir outros descritores que apresentaram baixa variação e que poderiam não ter sido removidos previamente pelo software. Esse processo foi conduzido separadamente para cada subconjunto de dados.

As matrizes filtradas de cada subconjunto foram então processadas no software de modelagem QSAR. O primeiro passo consistiu em uma nova redução por corte utilizando a correção absoluta de Pearson ( $|r|$ ) de 0,1 e 0,2 entre os descritores de cada subconjunto e as respectivas variáveis dependentes, gerando oito matrizes de dados. Finalmente, uma inspeção visual de cada matriz foi conduzida para remover descritores que ainda poderiam apresentar informações pouco relevantes para a obtenção dos modelos. Essas matrizes foram então submetidas à etapa de seleção de variáveis.

Tabela 1. Conjunto de dados e valores experimentais de toxicidade dos parâmetros em estudo.

| CAS<br>RN    | SMILES                                                      | Ratos_p<br>LD <sub>50</sub> (1) | Camundo<br>ngos_pL<br>D <sub>50</sub> (2) | Ratos_<br>pLC <sub>50</sub><br>(3) | Camundo<br>ngos_pL<br>C <sub>50</sub> (4) |
|--------------|-------------------------------------------------------------|---------------------------------|-------------------------------------------|------------------------------------|-------------------------------------------|
| 98-<br>56-6  | <chem>C1=CC(=CC=C1C(F)(F)F)Cl</chem>                        |                                 | 1,200                                     | 3,914                              | 3,956                                     |
| 98-<br>46-4  | <chem>C1=CC(=CC(=C1)[N+](=O)[O-])C(F)(F)F</chem>            |                                 |                                           | 5,342                              | 5,337                                     |
| 98-<br>16-8  | <chem>C1=CC(=CC(=C1)N)C(F)(F)F</chem>                       |                                 | 2,870                                     | 5,564                              | 5,368                                     |
| 98-<br>08-8  | <chem>C1=CC=C(C=C1)C(F)(F)F</chem>                          |                                 | 1,170                                     | 3,315                              | 3,200                                     |
| 920-<br>66-1 | <chem>C(C(F)(F)F)(C(F)(F)F)O</chem>                         |                                 | 2,450                                     | 1,930                              |                                           |
| 918-<br>21-8 | <chem>C(C(C(F)(F)F)(C(F)(F)F)O)(C(F)(F)F)(C(F)(F)F)O</chem> |                                 |                                           | 5,580                              | 5,940                                     |

|           |                                                                |       |       |
|-----------|----------------------------------------------------------------|-------|-------|
| 8942      |                                                                |       |       |
| 7-31-6    | <chem>CC1=C(C2=C(C(=C1F)F)N=C(N2)C(F)(F)F</chem>               | 4,810 |       |
| 8942      |                                                                |       |       |
| 7-30-5    | <chem>COC1=C(C2=C(C(=C1F)F)NC(=N2)C(F)(F)F</chem>              | 4,970 |       |
| 8942      |                                                                |       |       |
| 7-28-1    | <chem>C12=C(C(=C(C(=C1Br)F)Br)F)N=C(N2)C(F)(F)F</chem>         | 4,720 |       |
| 8942      |                                                                |       |       |
| 7-27-0    | <chem>C12=C(C(=C(C(=C1Cl)F)Cl)F)N=C(N2)C(F)(F)F</chem>         | 5,240 |       |
| 8942      |                                                                |       |       |
| 7-15-6    | <chem>C1=C(C2=C(C(=C1F)F)NC(=N2)C(F)(F)F</chem>                | 5,020 |       |
| 8942      |                                                                |       |       |
| 7-09-8    | <chem>C1=C(C=C2C(=C1C(F)(F)F)N=C(N2)C(F)(F)F)Cl</chem>         | 5,240 |       |
| 8942      |                                                                |       |       |
| 6-93-7    | <chem>C1=C(C=C(C2=C1NC(=N2)C(F)(F)F)F</chem>                   | 4,950 |       |
| 813-44-5  | <chem>C(=O)(C(C(F)(F)F)(C(F)(F)F)C(C(F)(F)F)(C(F)(F)F)F</chem> | 5,190 | 4,740 |
| 811-97-2  | <chem>C(C(F)(F)F)F</chem>                                      | 1,833 | 1,778 |
| 79-53-8   | <chem>C(=O)(C(F)(F)F)C(F)(F)Cl</chem>                          | 3,164 |       |
| 79-52-7   | <chem>C(=O)(C(F)(F)Cl)C(F)(Cl)Cl</chem>                        | 2,680 |       |
| 79-38-9   | <chem>C(=C(F)Cl)(F)F</chem>                                    | 2,066 |       |
| 7790-91-2 | <chem>FCI(F)F</chem>                                           | 2,490 |       |
| 7783-66-6 | <chem>FI(F)(F)(F)F</chem>                                      | 5,397 |       |
| 775-40-6  | <chem>C1=CC(C(C(C1(F)F)(F)F)(F)F)(F)F</chem>                   |       | 5,363 |
| 773-82-0  | <chem>C(#N)C1=C(C(=C(C(=C1F)F)F)F)F</chem>                     | 5,440 | 4,490 |

|         |                                                                                    |       |        |       |
|---------|------------------------------------------------------------------------------------|-------|--------|-------|
| 7722    |                                                                                    |       |        |       |
| 7-99-7  | <chem>C1=C(C=C(C(=C1F)F)Cl)C(F)(F)F</chem>                                         |       | 2,919  | 3,080 |
| 76-37-9 | <chem>C(C(C(F)F)(F)F)O</chem>                                                      |       |        | 4,186 |
| 76-21-1 | <chem>C(C(C(C(C(C(C(C(C(=O)O)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F</chem>             | 2,740 |        |       |
| 76-19-7 | <chem>C(C(F)(F)F)(C(F)(F)F)(F)F</chem>                                             |       | 2,020  | 2,240 |
| 76-16-4 | <chem>C(C(F)(F)F)(F)(F)F</chem>                                                    |       | 1,200  | 2,220 |
| 76-15-3 | <chem>C(C(F)(F)Cl)(F)(F)F</chem>                                                   |       | 1,500  |       |
| 76-14-2 | <chem>C(C(F)(F)Cl)(F)(F)Cl</chem>                                                  |       | -0,625 |       |
| 76-13-1 | <chem>C(C(F)(Cl)Cl)(F)(F)Cl</chem>                                                 |       | 0,687  | 2,858 |
| 76-05-1 | <chem>C(=O)(C(F)(F)F)O</chem>                                                      |       | 4,057  | 3,927 |
| 75-89-8 | <chem>C(C(F)(F)F)O</chem>                                                          | 2,620 | 2,328  | 4,538 |
| 75-48-5 | <chem>C(C(F)(F)F)(N(C(C(F)(F)F)(F)F)C(F)(F)F)(F)F</chem>                           |       | 3,440  | 2,980 |
| 75-73-0 | <chem>C(F)(F)(F)F</chem>                                                           |       | 0,180  | 2,480 |
| 75-91-2 | <chem>C/C(=C\C(C(F)(F)F)(C(F)(F)F)O)/CC(C(F)(F)F)(C(F)(F)F)O</chem>                | 4,330 |        |       |
| 75-63-8 | <chem>C(F)(F)(F)Br</chem>                                                          |       | 0,249  | 2,592 |
| 75-73-7 | <chem>COC(=O)C(C(OC)(F)F)(F)F</chem>                                               |       | 3,830  | 5,370 |
| 75-25-9 | <chem>C=C(F)F)(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F</chem>                           |       | 4,130  | 2,880 |
| 75-91-6 | <chem>C(C(C(C(C(F)(F)S(=O)(=O)N)(F)F)(F)F)(F)F)(C(C(C(F)(F)F)(F)F)(F)F)(F)F</chem> | 3,460 |        |       |
| 75-34-7 | <chem>C(C(F)(F)F)(C(F)(F)I)(F)F</chem>                                             |       |        | 2,865 |
| 75-90-2 | <chem>C(C(F)(F)F)N</chem>                                                          |       |        | 4,376 |

|          |                                                                   |       |       |       |
|----------|-------------------------------------------------------------------|-------|-------|-------|
| 7280     |                                                                   |       |       |       |
| 4-49-0   | <chem>C(=C(/C(F)(F)F)\F)(\C(C(F)(F)F)(F)F)/F</chem>               |       | 3,890 | 2,490 |
| 706-79-6 | <chem>C1(=C(C(C(C1(F)F)(F)F)(F)F)Cl)Cl</chem>                     | 2,940 | 2,950 | 5,067 |
| 697-11-0 | <chem>C1(=C(C(C1(F)F)(F)F)F)F</chem>                              |       | 1,480 | 4,300 |
| 692-50-2 | <chem>C(#CC(F)(F)F)C(F)(F)F</chem>                                |       | 3,301 |       |
| 690-39-1 | <chem>C(C(F)(F)F)C(F)(F)F</chem>                                  |       | 1,310 | 2,240 |
| 685-09-6 | <chem>COC(=O)C(=C(F)F)C(F)(F)F</chem>                             |       | 4,140 | 4,320 |
| 684-16-2 | <chem>C(=O)(C(F)(F)F)C(F)(F)F</chem>                              | 2,940 | 2,781 |       |
| 678-77-3 | <chem>C(=O)(C(C(C(C(=O)Cl)(F)F)(F)F)(F)F)Cl</chem>                |       | 5,770 | 6,020 |
| 678-26-2 | <chem>C(C(C(F)(F)F)(F)F)(C(C(F)(F)F)(F)F)(F)F</chem>              |       | 3,380 |       |
| 677-69-0 | <chem>C(C(F)(F)F)(C(F)(F)F)(F)I</chem>                            |       | 2,140 | 3,360 |
| 677-21-4 | <chem>C=CC(F)(F)F</chem>                                          |       |       | 1,739 |
| 675-14-9 | <chem>C1(=NC(=NC(=N1)F)F)F</chem>                                 |       | 4,639 |       |
| 6731     |                                                                   |       |       |       |
| 9-83-9   | <chem>C1=CC(=CC=C1C(F)(F)F)NC(=O)C(F)(F)F</chem>                  |       | 2,390 |       |
| 6720     |                                                                   |       |       |       |
| 5-67-8   | <chem>CCNC1=C(C(=C(C(=C1F)C#N)F)F)C#N</chem>                      |       | 2,980 |       |
| 662-50-0 | <chem>C(=O)(C(C(C(F)(F)F)(F)F)(F)F)N</chem>                       |       | 4,420 | 4,990 |
| 661-97-2 | <chem>C(C(F)(F)F)(C(F)(F)Cl)(F)Cl</chem>                          |       | 2,460 | 2,970 |
| 647-42-7 | <chem>C(CO)C(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)</chem>         |       | 4,490 | 5,110 |
| 647-12-1 | <chem>C(#N)C(C(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)F</chem> |       | 5,450 | 5,040 |

|             |                                                                    |       |       |       |
|-------------|--------------------------------------------------------------------|-------|-------|-------|
| 6397        |                                                                    |       |       |       |
| 9-48-6      | <chem>C(C(C(C(F)(F)F)C(F)(F)F)O)C(=O)O</chem>                      | 2,180 |       |       |
| 6226-25-1   | <chem>C(C(F)(F)F)OS(=O)(=O)C(F)(F)F</chem>                         |       | 2,423 |       |
| 6198        |                                                                    |       |       |       |
| 8-37-2      | <chem>C1=CC(=C(C=C1N)N)OC(C(F)F)(F)F</chem>                        | 2,320 | 2,320 |       |
| 6162        |                                                                    |       |       |       |
| 3-04-9      | <chem>C(C(C(F)(F)F)(Cl)Cl)Cl</chem>                                |       |       | 3,607 |
| 602-94-8    | <chem>C1(=C(C(=C(C(=C1F)F)F)F)F)C(=O)O</chem>                      |       | 4,760 | 4,720 |
| 5819-4-00-6 | <chem>C(=O)(C(C(F)(F)F)(OC(C(C(OC(F)(F)F)(F)F)(F)F)(F)F)F)F</chem> |       |       | 4,960 |
| 5810        |                                                                    |       |       |       |
| 9-34-5      | <chem>C(OC(=C(F)F)C(F)(F)F)F</chem>                                |       | 2,653 |       |
| 5697-3-16-1 | <chem>C1=CC(=O)N(C1=O)C2=C(C(=C(C(=C2F)F)F)N3C(=O)C=CC3=O)F</chem> | 2,310 |       |       |
| 564-11-4    | <chem>C1(C(C(N(C(C1(F)F)(F)F)C(C(F)(F)F)(F)F)(F)F)(F)F</chem>      |       | 1,050 | 5,280 |
| 559-40-0    | <chem>C1(=C(C(C(C1(F)F)(F)F)(F)F)F)F</chem>                        |       | 1,540 | 4,420 |
| 559-11-5    | <chem>C=CC(=O)OCC(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F</chem> | 4,380 | 4,570 | 4,460 |
| 5259        |                                                                    |       |       |       |
| 1-27-2      | <chem>C=CC(=O)OCCC(C(C(C(F)(F)F)(F)F)(F)F)(F)F</chem>              |       | 3,760 | 5,300 |
| 507-55-1    | <chem>C(C(C(F)(F)Cl)(F)F)(F)Cl</chem>                              | 1,610 | 0,807 |       |
| 460-69-5    | <chem>C(C(Cl)Cl)C(F)(F)F</chem>                                    |       |       | 0,842 |
| 460-39-9    | <chem>C(CN)C(F)(F)F</chem>                                         |       |       | 5,275 |
| 460-35-5    | <chem>C(CCl)C(F)(F)F</chem>                                        |       |       | 5,219 |

|          |                                                                      |       |       |       |       |
|----------|----------------------------------------------------------------------|-------|-------|-------|-------|
| 447-14-3 | <chem>C1=CC=C(C=C1)C(=C(F)F)F</chem>                                 | 1,800 |       | 4,296 |       |
| 440-60-8 | <chem>C(C1=C(C(=C(C(=C1F)F)F)F)F)O</chem>                            | 2,340 |       |       |       |
| 434-64-0 | <chem>C1(=C(C(=C(C(=C1F)F)F)F)C(F)(F)F</chem>                        |       |       | 2,316 |       |
| 431-89-0 | <chem>C(C(F)(F)F)(C(F)(F)F)F</chem>                                  |       |       | 1,650 | 2,260 |
| 431-46-9 | <chem>COC(C(F)(F)F)O</chem>                                          |       | 2,370 |       |       |
| 431-21-0 | <chem>C(C(C(F)(F)F)Br)Br</chem>                                      |       |       |       | 1,582 |
| 428-59-1 | <chem>C1(C(O1)(F)F)(C(F)(F)F)F</chem>                                |       |       | 0,990 | 4,700 |
| 4281     |                                                                      |       |       |       |       |
| 8-60-0   | <chem>CC(C1=CC(=CC(=C1)N)C(F)(F)F)O</chem>                           |       | 2,340 |       |       |
| 426-65-3 | <chem>CCOC(=O)C(C(F)(F)F)(F)F</chem>                                 |       |       | 2,990 | 4,220 |
| 425-87-6 | <chem>COC(C(F)Cl)(F)F</chem>                                         | 1,460 |       |       |       |
| 425-38-7 | <chem>C(=O)(C(C(OC(F)(F)F)(F)F)(F)F)F</chem>                         |       |       |       | 4,746 |
| 424-40-8 | <chem>CCOC(=O)C(C(C(C(=O)OCC)(F)F)(F)F)(F)F</chem>                   | 1,770 | 1,850 | 5,358 |       |
| 424-37-3 | <chem>C=COC(=O)C(C(C(C(F)(F)F)(F)F)(F)F)(F)F</chem>                  |       |       | 4,510 | 3,440 |
| 423-54-1 | <chem>C(=O)(C(C(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)N</chem>   |       |       | 5,650 | 5,880 |
| 423-50-7 | <chem>C(C(C(C(F)(F)S(=O)(=O)F)(F)F)(F)F)(C(C(F)(F)F)(F)F)(F)F</chem> |       |       | 5,780 | 6,190 |
| 422-64-0 | <chem>C(=O)(C(C(F)(F)F)(F)F)O</chem>                                 |       |       | 4,025 | 3,893 |
| 422-63-9 | <chem>C(C(C(F)(F)F)(F)F)(O)O</chem>                                  |       | 2,440 |       |       |
| 422-61-7 | <chem>C(=O)(C(C(F)(F)F)(F)F)F</chem>                                 |       |       | 3,300 | 4,010 |
| 422-59-3 | <chem>C(=O)(C(C(F)(F)F)(F)F)Cl</chem>                                |       |       | 3,540 | 4,120 |

|             |                                                                             |       |        |       |
|-------------|-----------------------------------------------------------------------------|-------|--------|-------|
| 422-56-0    | <chem>C(C(C(F)(F)F)(F)F)(Cl)Cl</chem>                                       | 1,610 | 0,736  |       |
| 422-51-5    | <chem>C(C(C(Cl)(Cl)Cl)(F)F)(F)F</chem>                                      |       |        | 1,277 |
| 422-05-9    | <chem>C(C(C(F)(F)F)(F)F)O</chem>                                            | 2,180 |        | 4,176 |
| 421-14-7    | <chem>COC(F)(F)F</chem>                                                     |       | 1,020  | 3,810 |
| 421-06-7    | <chem>C(C(F)(F)F)Br</chem>                                                  |       |        | 2,832 |
| 420-46-2    | <chem>CC(F)(F)F</chem>                                                      |       | -0,808 |       |
| 4151-50-2   | <chem>CCNS(=O)(=O)C(C(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F</chem> | 2,990 |        |       |
| 4143-0-70-0 | <chem>CCOC(=O)C(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F</chem>            |       | 4,700  | 5,120 |
| 407-25-0    | <chem>C(=O)(C(F)(F)F)OC(=O)C(F)(F)F</chem>                                  |       | 2,900  | 3,880 |
| 4072-3-80-6 | <chem>C(Cl)C(C(F)(F)F)(F)F</chem>                                           |       | 1,850  | 2,920 |
| 400-44-2    | <chem>C(=C(/C(F)(F)F)\Cl)\C(F)(F)F</chem>                                   |       | 4,821  |       |
| 3966-0-55-4 | <chem>CC(C(C(C(O)(F)F)(F)F)(F)F)(F)F</chem>                                 | 2,320 |        | 4,344 |
| 392-56-3    | <chem>C1(=C(C(=C(C(=C1F)F)F)F)F)F</chem>                                    |       |        | 3,292 |
| 382-93-4    | <chem>COC(=O)C(C(F)(F)F)F</chem>                                            | 1,200 |        |       |
| 382-21-8    | <chem>C(=C(F)F)(C(F)(F)F)C(F)(F)F</chem>                                    |       | 5,602  |       |
| 382-10-5    | <chem>C=C(C(F)(F)F)C(F)(F)F</chem>                                          |       | 2,061  |       |
| 378-75-6    | <chem>COC(=O)C(C(F)(F)F)(F)F</chem>                                         | 1,410 |        | 3,889 |
| 377-73-1    | <chem>C(=O)(C(C(OC(F)(F)F)(F)F)(F)F)O</chem>                                |       |        | 4,545 |

|             |                                                                       |       |       |       |       |
|-------------|-----------------------------------------------------------------------|-------|-------|-------|-------|
| 377-38-8    | <chem>C(=O)(C(C(C(=O)O)(F)F)(F)F)O</chem>                             |       |       | 5,500 | 6,150 |
| 376-90-9    | <chem>C(C(C(C(CO)(F)F)(F)F)(F)F)O</chem>                              | 2,080 |       |       |       |
| 376-89-6    | <chem>C(#N)C(C(C(C(#N)(F)F)(F)F)(F)F</chem>                           | 1,890 | 2,350 | 6,479 | 6,542 |
| 376-87-4    | <chem>C(=C(F)F)(C(C(C(F)(F)F)(F)F)(F)F)F</chem>                       |       |       | 3,750 | 2,660 |
| 376-73-8    | <chem>C(=O)(C(C(C(C(=O)O)(F)F)(F)F)(F)F)O</chem>                      |       |       | 5,780 | 6,220 |
| 376-72-7    | <chem>C(C(C(C(C(C(=O)O)(F)F)(F)F)(F)F)(F)F</chem>                     | 2,150 |       |       |       |
| 376-53-4    | <chem>C(#N)C(C(C(C(C(#N)(F)F)(F)F)(F)F)(F)F</chem>                    | 1,940 | 2,110 | 6,609 | 6,255 |
| 376-50-1    | <chem>CCOC(=O)C(C(C(C(C(=O)OCC)(F)F)(F)F)(F)F)(F)F</chem>             |       |       | 5,050 | 6,490 |
| 376-27-2    | <chem>COC(=O)C(C(C(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)F</chem> |       |       | 5,170 | 5,240 |
| 376-18-1    | <chem>C(C(C(C(C(C(C(C(C(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)O</chem>    | 1,990 |       |       |       |
| 375-85-9    | <chem>C(=O)(C(C(C(C(C(C(C(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)F)O</chem>     |       |       | 5,130 | 5,010 |
| 375-81-5    | <chem>C(C(C(F)(F)F)(F)F)(C(C(F)F)S(=O)(=O)F)(F)F)(F)F</chem>          |       |       | 5,580 | 5,950 |
| 375-73-5    | <chem>C(C(C(F)F)S(=O)(=O)O)(F)F)(C(F)(F)F)(F)F</chem>                 | 2,840 |       |       |       |
| 375-62-2    | <chem>C(=O)(C(C(C(C(C(F)F)(F)F)(F)F)(F)F)(F)F)F</chem>                |       |       | 4,300 | 4,240 |
| 375-34-8    | <chem>C(C(C(F)F)(F)F)(Cl)Cl)(C(F)(F)F)(Cl)Cl</chem>                   | 2,580 |       |       |       |
| 375-22-4    | <chem>C(=O)(C(C(C(F)F)(F)F)(F)F)(F)F)O</chem>                         |       |       | 4,070 | 4,410 |
| 375-01-9    | <chem>C(C(C(C(F)F)(F)F)(F)F)(F)F)O</chem>                             | 1,740 |       | 3,090 | 4,130 |
| 3736-0-98-8 | <chem>C1(C(C(C1(F)F)(F)F)(F)F)(C(F)(F)F)C(F)(F)F</chem>               |       |       | 1,658 |       |
| 368-66-1    | <chem>C1(=NC(=NC(=N1)C(F)(F)F)C(F)(F)F)C(F)(F)F</chem>                |       |       | 2,309 |       |

|          |                                                                 |       |       |             |
|----------|-----------------------------------------------------------------|-------|-------|-------------|
| 363-72-4 | <chem>C1=C(C(=C(C(=C1F)F)F)F)F</chem>                           | 1,920 |       |             |
| 360-89-4 | <chem>C(=C(/C(F)(F)F)\F)(\C(F)(F)F)/F</chem>                    |       |       | 3,393       |
| 360-58-7 | <chem>CCOC(=C(C(F)(F)F)C(F)(F)F)F</chem>                        |       | 3,140 | 3,692       |
| 360-54-3 | <chem>COC(=O)C(C(F)(F)F)C(F)(F)F</chem>                         |       | 2,850 |             |
| 360-53-2 | <chem>COC(=C(C(F)(F)F)C(F)(F)F)F</chem>                         | 2,300 | 2,300 | 3,782       |
| 359-70-6 | <chem>C(C(F)(F)F)(N(C(C(F)(F)F)(F)F)C(C(F)(F)F)(F)F)(F)F</chem> |       |       | 2,417 2,442 |
| 358-21-4 | <chem>C(C(F)(F)F)(OC(C(F)(F)F)(F)F)(F)F</chem>                  | 1,100 |       | 3,157       |
| 357-26-6 | <chem>C(=C(F)F)(C(C(F)(F)F)(F)F)F</chem>                        |       | 3,300 | 2,500       |
| 356-69-4 | <chem>COC(=O)C(C(OC(F)(F)F)(F)F)(F)F</chem>                     |       | 3,390 | 4,720       |
| 356-62-7 | <chem>C(C(OC(C(C(F)(F)F)(F)F)(F)F)(F)F)(C(F)(F)F)(F)F</chem>    |       | 2,730 | 3,420       |
| 356-42-3 | <chem>C(=O)(C(C(F)(F)F)(F)F)OC(=O)C(C(F)(F)F)(F)F</chem>        |       | 3,230 | 4,150       |
| 356-27-4 | <chem>CCOC(=O)C(C(C(F)(F)F)(F)F)(F)F</chem>                     |       | 3,540 | 4,360       |
| 355-80-6 | <chem>C(C(C(C(C(F)F)(F)F)(F)F)(F)F)O</chem>                     |       | 3,470 | 3,240       |
| 355-75-9 | <chem>C1(=C(C(C(C(C1(F)F)(F)F)(F)F)(F)F)F)F</chem>              |       | 1,620 | 4,610       |
| 355-68-0 | <chem>C1(C(C(C(C(C1(F)F)(F)F)(F)F)(F)F)(F)F)(F)F</chem>         |       | 0,790 | 4,690       |
| 355-63-5 | <chem>C(=C(F)F)(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)F</chem>   |       | 4,420 | 3,150       |
| 355-42-0 | <chem>C(C(C(C(F)(F)F)(F)F)(F)F)(C(C(F)(F)F)(F)F)(F)F</chem>     | 1,830 | 3,590 | 2,790       |
| 355-38-4 | <chem>C(=O)(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)F</chem>       |       | 4,660 | 4,460       |
| 355-25-9 | <chem>C(C(C(F)(F)F)(F)F)(C(F)(F)F)(F)F</chem>                   |       | 2,670 | 2,360       |

|          |                                                      |       |       |       |       |
|----------|------------------------------------------------------|-------|-------|-------|-------|
| 355-02-2 | C1(C(C(C(C(C1(F)F)(F)F)(F)F)(F)F)(C(F)(F)F)F         |       |       | 0,880 | 5,070 |
| 354-58-5 | C(C(Cl)(Cl)Cl)(F)(F)F                                |       |       | 0,159 |       |
| 354-51-8 | C(C(F)(Cl)Br)(F)(F)Br                                |       |       |       | 4,099 |
| 354-34-7 | C(=O)(C(F)(F)F)F                                     |       |       | 2,660 | 4,080 |
| 354-33-6 | C(C(F)(F)F)(F)F                                      |       |       | 1,615 | 1,642 |
| 354-32-5 | C(=O)(C(F)(F)F)Cl                                    |       |       | 3,000 | 4,120 |
| 354-25-6 | C(C(F)(F)Cl)(F)F                                     |       |       | 2,049 | 1,989 |
| 354-06-3 | C(C(F)(F)Br)(F)Cl                                    |       |       |       | 3,227 |
| 350-57-2 | C1=CC=C(C=C1)OC(C(F)F)(F)F                           | 1,590 | 1,730 |       |       |
| 344-07-0 | C1(=C(C(=C(C(=C1F)F)Cl)F)F)F                         | 1,610 |       | 4,622 |       |
| 344-04-7 | C1(=C(C(=C(C(=C1F)F)Br)F)F)F                         |       |       | 3,520 | 3,270 |
| 338-81-8 | C(C(N(C(C(F)(F)F)(F)F)C(C(F)(F)F)(F)F)(C(F)(F)F)(F)F |       |       | 4,230 | 3,400 |
| 338-75-0 | C(C(C(F)(F)F)Cl)Cl                                   |       |       |       | 0,880 |
| 337-28-0 | CCOC(C(C(F)(F)F)(F)F)O                               |       |       | 2,210 |       |
| 336-19-6 | C1(=C(C(C(C(C1(F)F)(F)F)(F)F)(F)F)Cl)Cl              |       |       |       | 5,511 |
| 336-08-3 | C(=O)(C(C(C(C(C(=O)O)(F)F)(F)F)(F)F)(F)F)O           |       |       | 6,030 | 6,380 |
| 335-99-9 | C(C(C(C(C(C(C(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)O         |       |       | 4,340 | 3,680 |
| 335-76-2 | C(=O)(C(C(C(C(C(C(C(C(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)O | 3,960 | 3,670 |       |       |
| 335-67-1 | C(=O)(C(C(C(C(C(C(C(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)O   |       |       | 5,360 | 5,310 |

|             |                                                                                                      |       |       |
|-------------|------------------------------------------------------------------------------------------------------|-------|-------|
| 335-56-8    | <chem>C(C(C(C(F)(F)Br)(F)F)(F)F)(C(C(F)(F)F)(F)F)(F)F</chem>                                         | 3,650 | 3,170 |
| 335-42-2    | <chem>C(=O)(C(C(C(F)(F)F)(F)F)(F)F)F</chem>                                                          | 3,850 | 4,080 |
| 335-36-4    | <chem>C1(C(C(OC1(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F</chem>                                      | 0,910 | 5,930 |
| 335-27-3    | <chem>C1(C(C(C(C(C1(F)F)(F)F)(F)F)(C(F)(F)F)(F)F)(C(F)(F)F)F</chem>                                  | 0,970 | 5,480 |
| 335-21-7    | <chem>C1(C(C(C(C(C1(F)F)(F)F)(F)F)(F)F)(F)F)(C(C(F)(F)F)(F)F)F</chem>                                | 0,870 | 5,380 |
| 335-10-4    | <chem>C(=O)(C(C(F)(F)F)(C(F)(F)F)F)O</chem>                                                          | 4,130 | 4,490 |
| 3122        |                                                                                                      |       |       |
| 4-45-0      | <chem>CCOC(C(F)(F)F)OCC</chem>                                                                       | 2,240 |       |
| 311-89-7    | <chem>C(C(C(F)(F)F)(F)F)(C(N(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)C(C(C(C(F)(F)F)(F)F)(F)F)(F)F</chem> | 1,830 |       |
| 3118-5-69-0 | <chem>C(C(C(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)(O)O</chem>                               | 2,620 |       |
| 3118        |                                                                                                      |       |       |
| 5-68-9      | <chem>CCC12COC(OC1)(OC2)C(C(C(F)(F)F)(F)F)(F)F</chem>                                                | 2,290 |       |
| 3118        |                                                                                                      |       |       |
| 5-67-8      | <chem>CC12COC(OC1)(OC2)C(C(C(F)(F)F)(F)F)(F)F</chem>                                                 | 2,270 |       |
| 3118        |                                                                                                      |       |       |
| 5-66-7      | <chem>CCC12OCC(CO1)(CO2)C(C(F)(F)F)(F)F</chem>                                                       | 2,210 |       |
| 3118        |                                                                                                      |       |       |
| 5-65-6      | <chem>CC12OCC(CO1)(CO2)C(C(F)(F)F)(F)F</chem>                                                        | 2,190 |       |
| 3118        |                                                                                                      |       |       |
| 5-61-2      | <chem>C1CCNC(OCC1)C(F)(F)F</chem>                                                                    | 2,060 |       |
| 3118        |                                                                                                      |       |       |
| 5-59-8      | <chem>C1COC(N1)C(C(F)(F)F)(F)F</chem>                                                                | 2,080 |       |

|           |                                                                             |       |       |       |       |
|-----------|-----------------------------------------------------------------------------|-------|-------|-------|-------|
| 3118      |                                                                             |       |       |       |       |
| 5-53-2    | <chem>C1CNC(N1)C(C(C(F)(F)F)(F)F)(F)F</chem>                                | 2,600 |       |       |       |
| 308-48-5  | <chem>C(C(C(F)(F)F)(F)F)(C(OC(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)</chem> |       | 3,754 | 3,962 |       |
| 307-24-4  | <chem>C(=O)(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)O</chem>                   |       | 4,850 | 4,760 |       |
| 306-83-2  | <chem>C(C(F)(F)F)(Cl)Cl</chem>                                              |       | 0,679 | 0,315 |       |
| 303-04-8  | <chem>C(=C(/C(F)(F)F)\Cl)\C(F)(F)F/Cl</chem>                                |       | 4,163 | 3,952 |       |
| 3018      |                                                                             |       |       |       |       |
| 4-89-5    | <chem>C(CO)NC(C(F)(F)F)(C(F)(F)F)O</chem>                                   | 2,880 |       |       |       |
| 3018      |                                                                             |       |       |       |       |
| 4-88-4    | <chem>CC1C(OC(N1))(C(F)(F)F)C(F)(F)FC2=CC=CC=C2</chem>                      | 3,180 |       |       |       |
| 2946-73-8 | <chem>C1=CC(=CC(=C1)NC(=O)C(F)(F)F)C(F)(F)F</chem>                          | 2,490 |       |       |       |
| 2925      |                                                                             |       |       |       |       |
| 6-79-9    | <chem>C(C(Cl)(Br)Br)(F)(F)F</chem>                                          |       |       | 4,099 |       |
| 2852      |                                                                             |       |       |       |       |
| 3-86-6    | <chem>C(OC(C(F)(F)F)C(F)(F)F)F</chem>                                       | 1,270 | 1,040 | 0,842 | 0,849 |
| 2846      |                                                                             |       |       |       |       |
| 2-90-0    | <chem>C1CNC(N1)C(C(F)(F)F)(F)F</chem>                                       | 2,380 |       |       |       |
| 2721      |                                                                             |       |       |       |       |
| 3-61-2    | <chem>C(C(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F)</chem>            |       | 3,800 | 2,020 |       |
| 2679      |                                                                             |       |       |       |       |
| 9-34-8    | <chem>CN(C)CCNC(C(F)(F)F)(C(F)(F)F)O</chem>                                 | 2,930 |       |       |       |
| 2667      |                                                                             |       |       |       |       |
| 5-46-7    | <chem>C(C(F)(F)F)(OC(F)F)Cl</chem>                                          | 1,410 | 1,380 | 1,081 | 1,041 |

|        |                                                                |       |       |       |
|--------|----------------------------------------------------------------|-------|-------|-------|
| 2644   |                                                                |       |       |       |
| 6-59-3 | <chem>C1CC(OC1)C(C(C(C(F)(F)F)(F)F)(F)F)(F)F</chem>            |       | 0,850 | 6,390 |
| 2409   |                                                                |       |       |       |
| 5-80-5 | <chem>CNC(=S)NNC1=CC(=CC(=C1)C(F)(F)F)C(F)(F)F</chem>          | 2,880 | 3,070 |       |
| 2375   |                                                                |       |       |       |
| 7-42-8 | <chem>C1(=NC(NC1(C(F)(F)F)C(F)(F)F)(C(F)(F)F)C(F)(F)F)N</chem> |       | 3,130 |       |
| 2368   |                                                                |       |       |       |
| -64-1  | <chem>C1=CC=C(C(=C1)C(F)(F)F)NC(=O)C(F)(F)F</chem>             |       | 2,740 |       |
| 2355   |                                                                |       |       |       |
| -43-3  | <chem>C12=C(C(=C(C(=C1F)F)F)F)N=C(N2)C(F)(F)F</chem>           | 4,890 |       |       |
| 2338   |                                                                |       |       |       |
| 4-22-7 | <chem>C1=CC(=C(C(=C1F)F)NS(=O)(=O)C(F)(F)F</chem>              |       | 3,480 |       |
| 2315   |                                                                |       |       |       |
| 2-45-6 | <chem>CNC(=O)NNC1=CC(=CC(=C1)C(F)(F)F)C(F)(F)F</chem>          | 2,150 |       |       |
| 2314   |                                                                |       |       |       |
| -97-8  | <chem>C(F)(F)(F)I</chem>                                       |       | 0,370 | 1,630 |
| 2056   |                                                                |       |       |       |
| 2-79-2 | <chem>COC(=O)C(C(=C(F)F)F)(F)F</chem>                          |       | 4,640 | 4,350 |
| 2043   |                                                                |       |       |       |
| -55-2  | <chem>C(Cl)C(C(C(C(F)(F)F)(F)F)(F)F)(F)F</chem>                |       | 2,990 | 3,340 |
| 2040   |                                                                |       |       |       |
| 4-94-8 | <chem>COC(C(C(F)(F)F)(C(F)(F)F)Br)(F)Br</chem>                 |       | 2,510 |       |
| 1943   |                                                                |       |       |       |
| 0-93-4 | <chem>C=CC(C(C(C(F)(F)F)(F)F)(F)F)(F)F</chem>                  |       | 3,600 | 3,190 |
| 1929   |                                                                |       |       |       |
| -68-6  | <chem>C(#N)C1=C(C(=C(C(=C1F)Cl)C#N)F)F</chem>                  |       | 3,730 |       |
| 1904   |                                                                |       |       |       |
| 1-02-2 | <chem>C(C(F)F)(C(F)F)Cl</chem>                                 |       |       | 0,269 |
| 1835   |                                                                |       |       |       |
| -49-0  | <chem>C(#N)C1=C(C(=C(C(=C1F)F)C#N)F)F</chem>                   |       | 3,550 |       |

|                 |                                                                     |       |       |             |
|-----------------|---------------------------------------------------------------------|-------|-------|-------------|
| 1805<br>-22-7   | <chem>C1(C(C(C(C1(F)F)(F)F)(F)F)(F)F)(C(F)(F)F)F</chem>             |       | 0,820 | 4,800       |
| 1770<br>5-30-5  | <chem>C(C(C(F)F)(Cl)Cl)(F)F</chem>                                  |       |       | 0,823       |
| 1752<br>7-31-0  | <chem>C=CC(=O)OCCC(C(F)(F)F)(F)F</chem>                             |       | 2,940 | 4,820       |
| 1752<br>7-29-6  | <chem>C=CC(=O)OCCC(C(C(C(C(C(F)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F</chem> |       | 4,420 | 5,920       |
| 1599<br>-41-3   | <chem>C(C(F)(F)F)(C(F)(F)Cl)(Cl)Cl</chem>                           | 0,980 |       |             |
| 1570<br>0-73-9  | <chem>CC(=O)C(C(=O)C)C(C(F)(F)F)(C(F)(F)F)O</chem>                  |       | 2,820 |             |
| 1547<br>-36-0   | <chem>C(C(=O)O)C(C(F)(F)F)(C(F)(F)F)O</chem>                        |       | 2,150 |             |
| 1546<br>-95-8   | <chem>C(C(C(C(C(C(C(=O)O)(F)F)(F)F)(F)F)(F)F)(F)F)(F)F</chem>       | 2,380 | 5,050 | 3,960       |
| 151-<br>67-7    | <chem>C(C(F)(F)F)(Cl)Br</chem>                                      |       | 0,833 | 3,304       |
| 1478<br>-61-1   | <chem>C1=CC(=CC=C1C(C2=CC=C(C=C2)O)(C(F)(F)F)C(F)(F)F)O</chem>      | 2,000 |       |             |
| 1384<br>95-42-8 | <chem>C(C(C(F)(F)F)F)(C(C(F)(F)F)(F)F)F</chem>                      | 1,700 | 2,530 | 2,620       |
| 1383<br>8-16-9  | <chem>C(C(OC(F)F)(F)F)(F)Cl</chem>                                  | 1,350 | 1,390 | 1,120 1,357 |
| 1363<br>7-63-3  | <chem>FCI(F)(F)(F)F</chem>                                          |       | 3,029 |             |
| 127-<br>21-9    | <chem>C(=O)(C(F)(F)Cl)C(F)(F)Cl</chem>                              | 3,510 | 4,618 | 4,645       |
| 124-<br>73-2    | <chem>C(C(F)(F)Br)(F)(F)Br</chem>                                   |       | 2,648 | 2,938       |
| 121-<br>17-5    | <chem>C1=CC(=C(C=C1C(F)(F)F)[N+](=O)[O-])Cl</chem>                  | 2,320 | 2,750 |             |

|          |                                                                                      |       |       |
|----------|--------------------------------------------------------------------------------------|-------|-------|
| 116-15-4 | <chem>C(=C(F)F)(C(F)(F)F)F</chem>                                                    | 4,127 | 2,301 |
| 116-14-3 | <chem>C(=C(F)F)(F)F</chem>                                                           | 0,398 | 2,845 |
| 115-25-3 | <chem>C1(C(C(C1(F)F)(F)F)(F)F)(F)F</chem>                                            | 0,210 | 4,320 |
| 1107     |                                                                                      |       |       |
| 0-66-9   | <chem>C(=C(F)F)(C(C(F)(F)F)(F)F)F</chem>                                             | 3,300 | 2,500 |
| 1073     |                                                                                      |       |       |
| 50-42-5  | <chem>C1=C(C(=C(C(=C1Cl)Cl)Cl)Cl)NC(=O)C2(C(C(C(C2(F)F)(F)F)(F)F)(F)F)F</chem>       | 3,140 |       |
| 1073     | <chem>C1=CC(=C(C=C1[N+](=O)[O-])Br)NC(=O)C2(C(C(C(C2(F)F)(F)F)(F)F)(F)F)(F)F</chem>  | 4,720 |       |
| 49-85-9  |                                                                                      |       |       |
| 1059     | <chem>C1=CC(=C(C=C1[N+](=O)[O-])Br)NC(=O)C(C(C(C(F)(F)F)(F)F)(F)F)(C(F)(F)F)F</chem> | 4,640 |       |
| 23-79-3  |                                                                                      |       |       |
| 1059     | <chem>C1=CC(=C(C=C1[N+](=O)[O-])Br)NC(=O)C(C(F)(F)F)(C(F)(F)F)F</chem>               | 3,960 |       |
| 23-30-6  |                                                                                      |       |       |
| 1018     | <chem>CC1C(OC(N1))(C(F)(F)F)C(F)(F)F)CC2=CC=CC=C2</chem>                             | 3,200 |       |
| 34-51-9  |                                                                                      |       |       |
| 0076     |                                                                                      |       |       |
| 37-07-2  | <chem>B(F)(F)F</chem>                                                                | 4,759 |       |
| 0071     |                                                                                      |       |       |
| 26-01-4  | <chem>CC(C(F)(F)F)(Cl)Cl</chem>                                                      |       | 0,223 |
| 0024     |                                                                                      |       |       |
| 18-21-5  | <chem>C(=C(/C(F)(F)F)\Cl)\C(F)(F)F)/Cl</chem>                                        |       | 3,582 |
| 0023     |                                                                                      |       |       |
| 78-02-1  | <chem>C(C(F)(F)F)(C(F)(F)F)(C(F)(F)F)O</chem>                                        |       | 4,363 |

#### Seleção de Variáveis e Construção de Modelos

A seleção de variáveis também foi realizada utilizando o software de modelagem QSAR. Este programa utiliza o método de seleção de preditores ordenados (OPS), que classifica os descritores usando vetores informativos que reorganizam os descritores em matrizes de acordo com o seu grau de importância. Para alcançar esse objetivo, as matrizes passam por regressões utilizando o método dos Mínimos Quadrados Parciais (PLS). Essa abordagem otimiza a qualidade dos modelos, ao mesmo tempo em que reduz o número de descritores, visando identificar o subconjunto ideal que melhor explica e prevê a variável dependente em estudo [19].

Os melhores modelos obtidos também foram construídos utilizando o método de regressão PLS (Mínimos Quadrados Parciais). Esse método é altamente eficaz para estudar modelos com múltiplas variáveis, que podem apresentar alta correlação entre si. Essa abordagem reduz o tamanho do conjunto de dados inicial e combina as informações dos descritores, que são transformadas em variáveis latentes ortogonais (LVs), resultando na otimização da covariância. Em outras palavras, ela reduz a multicolinearidade e o overfitting, que tendem a enviesar os resultados dos modelos, pois somente as informações relevantes são utilizadas, desconsiderando grupos de dados que se apresentam como ruído na análise, garantindo melhor qualidade no processamento desses dados [19].

Finalmente, tanto na etapa de seleção de variáveis quanto na construção dos modelos, os descritores foram autoescalados: o valor de cada descritor foi centralizado pela média, e o resultado foi escalado pela variância. Esse método de pré-processamento é o mais amplamente utilizado em estudos QSAR, pois o intervalo numérico de cada descritor selecionado pode ser bastante diferente. Isso reduz a chance de viés na seleção de variáveis com escalas numéricas maiores, mesmo que sejam matematicamente menos relevantes do que outras com escalas menores, e permite a interpretação dos modelos obtidos [19,20].

A detecção de outliers é utilizada para determinar o impacto de amostras anômalas, garantindo a qualidade do conjunto de treinamento. Quando outliers ou amostras anômalas são identificados, observam-se os valores de influência, leverage e os resíduos de Student, que são indicados em uma tabela mostrando seus números. Amostras com valores de influência ou resíduos de Student que são consideradas suspeitas ou anômalas podem ser removidas. É importante justificar a remoção dessas amostras com explicações químicas ou biológicas e proceder com cautela. Embora a remoção de anomalias possa melhorar a robustez do modelo, é essencial considerar que essa remoção também pode impactar o desempenho do modelo, potencialmente levando a resultados melhores ou piores [19].

### **Validação do Modelo**

Na validação interna, uma série de parâmetros recomendados pela literatura foi utilizada: o coeficiente de determinação ( $r^2$ ), o teste F (intervalo de confiança de 95%,  $\alpha = 0,05$ ), o erro quadrático médio de calibração (RMSEC), a capacidade preditiva interna do modelo por meio da validação cruzada leave-one-out (LOO), o erro quadrático médio da validação cruzada (RMSECV), e os valores médios escalados e de diferença das métricas RmSquare na validação cruzada LOO (Average\_  $r^2m(LOO)$ -scaled e  $\Delta r^2m(LOO)$ -scaled) [21].

A robustez inicial do modelo também é avaliada por meio da validação cruzada leave-one-out, mas a avaliação dessa característica em cada modelo é aprofundada utilizando a validação leave-n-out. Nesse teste, n amostras são selecionadas aleatoriamente para testar a robustez do modelo. Os resultados de cada n variam devido à aleatoriedade, mas se o modelo apresentar boa robustez, não deve haver variação significativa nos

valores de cada  $Q^2_{LNO}$ . Nos conjuntos de treinamento avaliados, até 10 amostras foram removidas e 6 randomizações realizadas para cada um, obtendo-se indicações de estabilidade observadas nos resultados de RMSECV e  $Q^2_{LOO}$  em cada modelo avaliado [19].

Outro teste importante é a verificação da presença de correlação por acaso utilizando o teste de randomização y. Esse processo consiste em dividir o conjunto em grupos de interação e correlacioná-los aleatoriamente entre a variável dependente e os descritores, repetindo o processo até que todos os grupos e amostras sejam excluídos e/ou correlacionados. Esse é o teste de randomização y, no qual podemos determinar o número de randomizações realizadas. No caso dos modelos avaliados, a remoção de 40 randomizações foi considerada, proporcionando uma verificação dos valores de  $r^2$  e  $Q^2_{LOO}$  [19].

Para a validação externa, a atividade biológica dos compostos no conjunto de teste foi prevista usando os modelos desenvolvidos. A avaliação incluiu várias métricas: o coeficiente de determinação da validação externa ( $r^2_{pred}$ ) foi avaliado, juntamente com o erro quadrático médio de previsão (RMSEP), as inclinações de Golbraikh – Tropsha ( $k$  e  $k'$ ), a diferença absoluta entre os coeficientes de determinação da relação linear entre os valores observados e previstos sem interceptação ( $r^2_0$ ), e os valores previstos e observados sem interceptação ( $r'^2_0$ ) ( $|r^2_0 - r'^2_0|$ ), além dos valores Average\_  $r^2_m(pred)$ -scaled e  $\Delta r^2_m(pred)$ -scaled [20]. Essa análise foi realizada utilizando o software Xternal Validation Plus 1.2 (<https://sites.google.com/jadavpuruniversity.in/dtc-lab-software/home>). Após a validação do modelo, a confiabilidade dos modelos foi verificada determinando seus respectivos domínios de aplicabilidade (AD) usando o método de Williams [22], com as equações implementadas em uma planilha Excel interna.

Após a etapa de validação, os modelos aprovados foram interpretados usando seus vetores de regressão autoscalados obtidos por PLS. Esses vetores representam os coeficientes das equações de regressão em uma escala padronizada, permitindo assim atribuir graus de importância a eles e ao impacto da propriedade físico-química codificada no respectivo descritor molecular na determinação do ponto de interesse. Os sinais dos coeficientes indicam se as propriedades codificadas favorecem ou desfavorecem o ponto de interesse [20]. Além disso, os escores de Variável de Influência na Projeção (VIPs) dos mesmos descritores foram avaliados. Esses escores, obtidos em regressões que utilizam métodos de projeção, possam ser usados para seleção de variáveis ou para avaliar a importância dos descritores no modelo final [23]. VIPs > 1 são considerados mais significativos para o modelo. Valores entre 1 e 0,8 correspondem a descritores de importância intermediária. Finalmente, VIPs < 0,8 correspondem a descritores de baixa importância para o modelo [24]. Os valores VIP foram obtidos usando o Chemoface 1.66 [17] (<https://www.ufla.br/chemoface>).

A partir de cada uma das matrizes reduzidas, obteve-se um modelo PLS com robusta qualidade estatística interna para cada variável dependente (Tabelas 2 e 3). De maneira geral, os modelos apresentaram diferenças estatísticas entre si, o que impediu uma comparação direta. Isso era esperado, dadas as significativas diferenças biológicas entre os organismos. Para cada ponto final, todos os modelos acumularam mais de 45% das informações. Apesar de os modelos possuírem números diferentes de descritores moleculares (11, 13 e 15 descritores), as informações relevantes de cada modelo estão codificadas nas variáveis latentes (LVs) obtidas por meio da regressão PLS. Isso reduz o risco de qualquer prejuízo na qualidade dos modelos, pois as LVs diminuem a dimensionalidade dos dados, evitam o overfitting e extraem as informações mais importantes para explicar o ponto final de interesse, eliminando o ruído [20].

Todos os modelos explicaram mais de 85% da variância e previram mais de 79%. Nenhum modelo mostra sobreajuste, pois a maior diferença entre  $r^2$  e  $Q^2_{\text{LOO}}$  foi de 0,095. Os Modelos 1, 3 e 4 contêm outliers, embora esses sejam muito poucos em relação ao total do conjunto de treinamento. Consequentemente, a remoção dessas amostras anômalas não reduziu significativamente a variabilidade estrutural, nem afetou a amplitude dos pontos finais. Os valores dos descritores selecionados, assim como os valores obtidos nas etapas de validação cruzada e validação externa, também estão disponíveis no material suplementar.

Tabela 2. Modelos Obtidos

| Modelo 1 – Ratos Oral  |                                    |                  | Modelo 2 – Camundongos Oral |                                    |                  | Modelo 3 – Ratos Inalação |                                    |                          | Modelo 4 – Camundongos Inalação |                                    |                      |
|------------------------|------------------------------------|------------------|-----------------------------|------------------------------------|------------------|---------------------------|------------------------------------|--------------------------|---------------------------------|------------------------------------|----------------------|
| Descript<br>ors        | Autos<br>caled<br>coeffi<br>cients | Coeffi<br>cients | Descri<br>ptors             | Autos<br>caled<br>coeffi<br>cients | Coeffi<br>cients | Descri<br>ptors           | Autos<br>caled<br>coeffi<br>cients | Coe<br>ffici<br>ent<br>s | Descri<br>ptors                 | Autos<br>caled<br>coeffi<br>cients | Coeff<br>icient<br>s |
| SpPosA<br>_D/Dt        | -0,72<br>4                         | -7,41<br>3       | CATS2<br>D_05_<br>AL        | 0,573                              | 0,343            | J_Dz(p<br>)               | /                                  | 1,6<br>20                | H_Dz(<br>p)                     | 0,742                              | 0,119                |
| X1A                    | -0,47<br>5                         | -23,3<br>52      | ATSC6<br>e                  | 0,397                              | 0,417            | nBM                       | 0,525                              | 0,4<br>47                | PHI                             | -0,771                             | -0,88<br>0           |
| SpMax_<br>EA(dm)       | 0,615                              | 0,560            | VE2_D<br>z(p)               | -0,26<br>1                         | -5,501           | SpMax<br>A_D/<br>Dt       | 0,324                              | 4,5<br>10                | AMW                             | 0,477                              | 0,154                |
| P_VSA_<br>p_2          | 0,345                              | 0,011            | F10[C-<br>F]                | 0,357                              | 0,302            | SpMax<br>4_Bh<br>(m)      | -0,253                             | -0,<br>648               | nO                              | 0,676                              | 0,896                |
| D/Dtr06                | -0,59<br>2                         | -0,02<br>7       | P_VSA<br>_MR_2              | -0,26<br>2                         | -0,004           | SpMA<br>D_B(p)            | 0,337                              | 5,2<br>89                | X3A                             | 0,278                              | 7,295                |
| SpDiam_<br>AEA<br>(dm) | -0,40<br>6                         | -0,76<br>6       | SM12_<br>AEA(ri)            | -0,25<br>3                         | -0,342           | X2Av                      | -0,266                             | -10<br>,68<br>8          | SpMA<br>D_AEA<br>(dm)           | -0,343                             | -4,02<br>3           |
| SpMAD_<br>EA(ri)       | -0,16<br>2                         | -1,59<br>3       | X5A                         | -0,17<br>2                         | -4,579           | SpMA<br>D_EA<br>(ri)      | 0,280                              | 3,6<br>07                | ChiA_<br>X                      | -0,387                             | -259,<br>640         |
| GATS2m                 | -0,26<br>2                         | -0,92<br>2       | Eig07_<br>AEA(d<br>m)       | -0,23<br>2                         | -0,190           | ChiA_<br>X                | -0,204                             | -14<br>0,6<br>05         | Yindex                          | -0,214                             | -0,30<br>3           |
| MATS1v                 | 0,480                              | 3,821            | Eig07_<br>EA(dm<br>)        | 0,190                              | 0,206            | SpMax<br>6_Bh<br>(s)      | -0,338                             | -0,<br>207               | Eta_sh<br>_x                    | 0,546                              | 6,374                |
| SIC2                   | -0,38<br>5                         | -3,02<br>4       | GATS5<br>s                  | -0,21<br>1                         | -0,315           | MATS<br>3m                | -0,066                             | -0,<br>335               | SpMA<br>D_B(p)                  | -0,290                             | -4,48<br>2           |
| Eig10_E<br>A (dm)      | 0,283                              | 0,325            | MATS<br>1v                  | 0,146                              | 1,178            | SpMin<br>1_Bh<br>(s)      | -0,142                             | -0,<br>758               | SM14_<br>AEA<br>(bo)            | -0,309                             | -0,39<br>7           |
| Tind                   | –                                  | 27,87<br>1       | SpMA<br>D_B(m<br>)          | -0,15<br>0                         | -0,883           | GGI5                      | -0,129                             | -0,<br>413               | ATSC5<br>v                      | 0,387                              | 1,099                |

|            |            |             |      |        |                 |                      |       |             |
|------------|------------|-------------|------|--------|-----------------|----------------------|-------|-------------|
| ChiA_<br>X | -0,06<br>5 | -26,61<br>7 | C%   | -0,223 | -0,<br>045      | SpMA<br>D_EA<br>(ri) | 0,175 | 1,847       |
| Tind       | –          | 33,168      | Tind | –      | 129<br>,37<br>4 | nN                   | 0,293 | 1,066       |
|            |            |             |      |        |                 | nTB                  | 0,178 | 0,881       |
|            |            |             |      |        |                 | Tind                 | –     | 267,6<br>67 |

Tabela 3. Resultados da Validação Interna

| <i>Data set</i>                                                 | <i>1</i> | <i>2</i> | <i>3</i> | <i>4</i> | <i>valores de referência</i> |
|-----------------------------------------------------------------|----------|----------|----------|----------|------------------------------|
| <i>n</i> training                                               | 39       | 46       | 111      | 116      |                              |
| Outliers                                                        | 1        | 0        | 5        | 1        |                              |
| nVL                                                             | 6        | 4        | 6        | 9        |                              |
| Informação acumulada                                            | 82,052%  | 45,736%  | 70,928%  | 65,310%  | >0,6                         |
| <i>r</i> <sup>2</sup>                                           | 0,932    | 0,888    | 0,895    | 0,856    | The smallest possible        |
| <i>RMSEC</i>                                                    | 0,244    | 0,284    | 0,536    | 0,519    | Above the tabled value       |
| <i>F</i> ( <i>n</i> , <i>n</i> - <i>p</i> -1, $\alpha = 0.05$ ) | 73,098   | 81,260   | 147,746  | 70,012   | >0,5                         |
| <i>Q</i> <sup>2</sup>                                           | 0,861    | 0,793    | 0,865    | 0,805    | <0,2                         |
| <i>RMESCV</i>                                                   | 0,348    | 0,386    | 0,607    | 0,603    | >0,5                         |
| <i>r</i> <sup>2</sup> - <i>Q</i> <sup>2</sup>                   | 0,071    | 0,095    | 0,03     | 0,051    | <0,1                         |
| $\Delta r^2_{LOO}$ -scaled                                      | 0,054    | 0,093    | 0,092    | 0,132    | <0,2                         |
| $\Delta v_r^2_{LOO}$ -scaled                                    | 0,905    | 0,841    | 0,847    | 0,780    | >0,5                         |

Figura 1 mostra os resultados dos testes de validação cruzada LNO e y-randomization. Esses testes também são considerados medidas importantes para validação interna, pois sustentam a robustez dos modelos obtidos e, no caso do teste y-randomization, permitem verificar a probabilidade das variâncias explicadas e previstas serem espúrias. Com base nos resultados obtidos, pode-se sugerir que todos os modelos são robustos e não apresentam correlação por acaso. Assim, todos os quatro modelos de calibração apresentam qualidade interna adequada para fins de previsão.

Considerando que todos os quatro modelos atenderam aos critérios de qualidade interna, o próximo passo foi realizar a validação externa. Os resultados, apresentados na Tabela 4, confirmam que os modelos apresentaram os resultados esperados, podendo ser considerados aprovados. Contudo, há alguns pontos-chave que merecem destaque. Os Modelos 1 e 3 apresentaram valores de  $r^2_{pred}$  superiores aos de  $Q^2_{LOO}$ . Embora isso possa parecer contraditório, esses resultados se enquadram no bem conhecido 'Paradoxo de Kubinyi', em que não há relação entre a previsibilidade interna e externa; ou seja, um modelo com alta previsibilidade interna pode apresentar baixa previsibilidade externa, e vice-versa [25,26]. Nesse contexto, todos os modelos provaram ser

estatisticamente adequados para fins de previsão e podem ser considerados potencialmente adequados para prever toxicidades orais e de inalação em ratos e camundongos.

A seguir, a confiabilidade das previsões, que indica se os modelos realmente têm potencial como ferramenta para prever o risco toxicológico dos PFAS, foi avaliada pela adequação dos conjuntos de teste aos seus respectivos domínios de aplicabilidade, conforme pode ser observado nas Figuras 2 (Williams plots).

Estatisticamente, não é viável comparar os modelos apresentados aqui com os previamente construídos usando esses conjuntos de dados, especialmente os modelos de Bhatarai e Gramatica [8,9], uma vez que foram construídos utilizando abordagens diferentes. Além disso, os modelos obtidos neste estudo apresentam um maior número de descritores em comparação com os modelos de outros autores. No entanto, como o PLS foi utilizado, esse possível problema é consideravelmente reduzido, uma vez que essa técnica permite a redução do tamanho dos dados, produzindo o número mais adequado de variáveis latentes (VLs) para cada modelo, extraindo assim apenas as informações mais relevantes dos descritores (ou seja, eliminando o ruído).




Figura 1. Resultados dos testes de y-randomization (à esquerda) e validação cruzada leave-n-out (LNO) (à direita).

| Table 4. Resultado da Validação Externa |       |       |       |       |                         |
|-----------------------------------------|-------|-------|-------|-------|-------------------------|
| Data set                                | 1     | 2     | 3     | 4     | valores de referência   |
| $n_{test}$                              | 10    | 12    | 28    | 29    |                         |
| $r^2_{pred}$                            | 0.959 | 0.828 | 0.915 | 0.763 | $>0.5$                  |
| RMSEP                                   | 0.607 | 0.241 | 0.397 | 0.729 | The smallest possible   |
| $ r^2_0 - r'^2_0 $                      | 0.932 | 0.071 | 0.915 | 0.051 | $<0.3$                  |
| $k$                                     | 1.143 | 0.977 | 0.983 | 1.005 | $0.85 \leq k \leq 1.15$ |
| $k'$                                    | 0.870 | 1.015 | 1.009 | 0.961 | $0.85 \leq k \leq 1.15$ |
| $\Delta r^2_{PRED}$ -scaled             | 0.047 | 0.161 | 0.085 | 0.155 | $<0.2$                  |
| $Av\_r^2_{PRED}$ -scaled                | 0.840 | 0.671 | 0.813 | 0.671 | $>0.5$                  |




Figura 2. Gráficos do teste de domínio de aplicabilidade (AD) utilizando a abordagem de Williams. Os pontos brancos correspondem aos compostos do conjunto de treinamento, e os pontos vermelhos correspondem aos compostos do conjunto de teste. Os limites críticos de alavancagem ( $h^*$ ) foram calculados usando a equação

$3 \times (p/n)$ , onde p corresponde ao número de LVs do modelo respectivo, e n ao número de compostos no conjunto de treinamento respectivo.

### Interpretação dos modelos

Os PFAS, liberados no ambiente principalmente por meio de resíduos industriais, são considerados substâncias perigosas devido à sua persistência e aos perigos inerentes. A toxicidade desses compostos está diretamente relacionada às suas propriedades físico-químicas [10,12–15], que são influenciadas pela variação em suas estruturas químicas. Essas estruturas podem ser lineares, ramificadas, curtas ou longas. De acordo com Niegowska et al. [2], isso pode influenciar a adsorção, mobilidade, bioacumulação, bioconcentração e biomagnificação desses compostos. Dentre essas características, os isômeros lineares têm maior probabilidade de se ligar a sedimentos, solo e de serem solubilizados na água, enquanto os ramificados apresentam discrepâncias na bioacumulação em diferentes organismos. Além dessas características, muitos deles são consideravelmente voláteis, o que contribui para a contaminação de vários ecossistemas. Nesse contexto, os humanos estão expostos principalmente por meio de sua dieta de peixes, frutas, ovos e produtos processados, por meio da água potável e por inalação [2]. Isso reforça a necessidade de testes e modelos de previsão que permitam a avaliação do risco desses compostos químicos por meio dessas duas rotas de contato.

A Tabela 5 resume os descritores moleculares selecionados para os modelos validados. Existem 46 descritores diferentes, pertencentes a 11 classes. A maioria (30 descritores, 65,2%) pertence a quatro classes: Índices de adjacência de arestas (9), descritores baseados em matriz 2D (8), autocorrelações 2D (7) e índices constitucionais (6). O restante corresponde a outras classes relacionadas à topologia. No entanto, mesmo com essa variedade de descritores e classes, apenas quatro descritores (Mats1v, SpMAD\_EA(ri), ChiA\_X, SpMAD\_B(p)) são repetidos em múltiplos modelos, mas não foi possível identificar uma relação consistente entre essa ocorrência e os efeitos toxicológicos sob avaliação.

Tabela 5. Descritores moleculares selecionados neste estudo.

| Símbolo  | Descritor                                                                                       | Classe             |
|----------|-------------------------------------------------------------------------------------------------|--------------------|
| F10[C-F] | Frequência de C – F à distância topológica 10                                                   | Pares de átomos 2D |
| ATSC5v   | Autocorrelação centrada de Broto-Moreau de lag 5 ponderada pelo volume de van der Waals         | Autocorrelações 2D |
| ATSC6e   | Autocorrelação centrada de Broto-Moreau de lag 6 ponderada pela eletronegatividade de Sanderson | Autocorrelações 2D |
| GATS2m   | Autocorrelação de Geary de lag 2 ponderada pela massa                                           | Autocorrelações 2D |
| GATS5s   | Autocorrelação de Geary de lag 5 ponderada pelo estado-I                                        | Autocorrelações 2D |
| GGI5     | Índice de carga topológica de ordem 5                                                           | Autocorrelações 2D |
| MATS1v   | Autocorrelação de Moran de lag 1 ponderada pelo volume de van der Waals                         | Autocorrelações 2D |
| MATS3m   | Autocorrelação de Moran de lag 3 ponderada pela massa                                           | Autocorrelações 2D |

|               |                                                                                              |                                   |
|---------------|----------------------------------------------------------------------------------------------|-----------------------------------|
| ChiA_X        | Índice médio tipo Randic da matriz chi                                                       | Descritores baseados em matriz 2D |
| H_Dz(p)       | Índice tipo Harary da matriz de Barysz ponderada pela polarizabilidade                       | Descritores baseados em matriz 2D |
| J_Dz(p)       | Índice tipo Balaban da matriz de Barysz ponderada pela polarizabilidade                      | Descritores baseados em matriz 2D |
| SpMAD_B(m)    | Desvio absoluto médio espectral da matriz de Burden ponderada pela massa                     | Descritores baseados em matriz 2D |
| SpMAD_B(p)    | Desvio absoluto médio espectral da matriz de Burden ponderada pela polarizabilidade          | Descritores baseados em matriz 2D |
| SpMaxA_D/Dt   | Autovalor principal normalizado da matriz distância/desvio                                   | Descritores baseados em matriz 2D |
| SpPosA_D/Dt   | Soma espectral positiva normalizada da matriz distância/desvio                               | Descritores baseados em matriz 2D |
| VE2_Dz(p)     | Coeficiente médio do último autovetor da matriz de Barysz ponderada pela polarizabilidade    | Descritores baseados em matriz 2D |
| SpMax4_Bh(m)  | Maior autovalor nº 4 da matriz de Burden ponderada pela massa                                | Autovalores de Burden             |
| SpMax6_Bh(s)  | Maior autovalor nº 6 da matriz de Burden ponderada pelo estado-I                             | Autovalores de Burden             |
| SpMin1_Bh(s)  | Menor autovalor nº 1 da matriz de Burden ponderada pelo estado-I                             | Autovalores de Burden             |
| CATS2D_05_AL  | CATS2D Aceptor-Lipofílico no lag 05                                                          | CATS 2D                           |
| X1A           | Índice médio de conectividade de ordem 1                                                     | Índices de conectividade          |
| X2Av          | Índice médio de conectividade de valência de ordem 2                                         | Índices de conectividade          |
| X3A           | Índice médio de conectividade de ordem 3                                                     | Índices de conectividade          |
| X5A           | Índice médio de conectividade de ordem 5                                                     | Índices de conectividade          |
| AMW           | Peso molecular médio                                                                         | Índices constitucionais           |
| C%            | Percentual de átomos de carbono                                                              | Índices constitucionais           |
| nBM           | Número de ligações múltiplas                                                                 | Índices constitucionais           |
| nN            | Número de átomos de nitrogênio                                                               | Índices constitucionais           |
| nO            | Número de átomos de oxigênio                                                                 | Índices constitucionais           |
| nTB           | Número de ligações triplas                                                                   | Índices constitucionais           |
| Eig07_AEA(dm) | Autovalor nº 7 da matriz de adjacência de arestas aumentada ponderada pelo momento de dipolo | Índices de adjacência de arestas  |
| Eig07_EA(dm)  | Autovalor nº 7 da matriz de adjacência de arestas ponderada pelo momento de dipolo           | Índices de adjacência de arestas  |
| Eig10_EA(dm)  | Autovalor nº 10 da matriz de adjacência de arestas ponderada pelo momento de dipolo          | Índices de adjacência de arestas  |

|                |                                                                                                                   |                                  |
|----------------|-------------------------------------------------------------------------------------------------------------------|----------------------------------|
| SM12_AEA(ri)   | Momento espectral de ordem 12 da matriz de adjacência de arestas aumentada ponderada pelo integral de ressonância | Índices de adjacência de arestas |
| SM14_AEA(bo)   | Momento espectral de ordem 14 da matriz de adjacência de arestas aumentada ponderada pela ordem de ligação        | Índices de adjacência de arestas |
| SpDiam_AEA(dm) | Diâmetro espectral da matriz de adjacência de arestas aumentada ponderada pelo momento de dipolo                  | Índices de adjacência de arestas |
| SpMAD_AEA(dm)  | Desvio absoluto médio espectral da matriz de adjacência de arestas aumentada ponderada pelo momento de dipolo     | Índices de adjacência de arestas |
| SpMAD_EA(ri)   | Desvio absoluto médio espectral da matriz de adjacência de arestas ponderada pelo integral de ressonância         | Índices de adjacência de arestas |
| SpMax_EA(dm)   | Autovalor principal da matriz de adjacência de arestas ponderada pelo momento de dipolo                           | Índices de adjacência de arestas |
| Eta_sh_x       | Índice ETA x de forma                                                                                             | Índices ETA                      |
| SIC2           | Índice de conteúdo de informação estrutural (simetria de vizinhança de 2ª ordem)                                  | Índices de informação            |
| Yindex         | Índice de Balaban Y                                                                                               | Índices de informação            |
| P_VSA_MR_2     | P_VSA-like na refratividade molar, bin 2                                                                          | Descritores tipo P_VSA           |
| P_VSA_p_2      | P_VSA-like na polarizabilidade, bin 2                                                                             | Descritores tipo P_VSA           |
| D/Dtr06        | Índice de anel distância/desvio de ordem 6                                                                        | Descritores de anéis             |
| PHI            | Índice de flexibilidade de Kier                                                                                   | Índices topológicos              |

---




Figura 3. Comparação entre os valores de VIP e os valores absolutos dos coeficientes autoscalados (AAC) dos quatro modelos obtidos. Na qual as barras azuis representam a importância relativa individual de cada descritor nos modelos QSAR desenvolvidos. As barras laranjas indicam a contribuição percentual acumulada até o respectivo descritor, destacando sua influência conjunta na capacidade preditiva do modelo.

A Figura 3 apresenta uma comparação entre os valores absolutos dos vetores de regressão e os VIPs de cada descritor. Os gráficos revelam uma tendência em que os valores de VIP se alinham com a importância dos vetores de regressão nos modelos. Isso indica que o método de seleção de variáveis identificou efetivamente os descritores relevantes para a previsão dos endpoints de interesse. Além disso, em todos os modelos, a maioria dos descritores selecionados apresenta  $VIP > 0,8$ , demonstrando que os modelos foram construídos com descritores de importância significativa.

Para alcançar uma interpretação significativa do mecanismo de toxicidade, é essencial considerar o significado coletivo dos descritores selecionados para cada modelo. Exceto pelos descritores constitucionais, as outras classes de descritores são baseadas em gráficos moleculares, que codificam informações topológicas. Portanto, características clássicas desse tipo de descritor baseado em gráficos, como forma, grau de ramificação e distância topológica entre átomos, devem ser consideradas na interpretação. Além disso, os esquemas de ponderação de cada descritor também devem ser avaliados. Esses esquemas fornecem informações numéricas sobre propriedades dos átomos e das ligações que não são capturadas por um gráfico molecular simples [28].

A análise utilizando essa abordagem revela um padrão entre os modelos. Para os modelos 1 e 3, que se concentram na toxicidade em ratos, os dados indicam que os PFAS menores e mais polares tendem a ser mais tóxicos para esse animal. Descritores associados a propriedades eletrônicas (como  $p$ ,  $dm$ ,  $s$ ,  $ri$ ) geralmente mostram coeficientes positivos, sugerindo uma correlação positiva com a toxicidade. Em contraste, descritores relacionados às propriedades estéricas ( $m$ ,  $v$ ) ou aqueles baseados apenas em gráficos moleculares predominam com sinais negativos. No modelo 3, esse padrão é reforçado pelos descritores constitucionais  $nBM$  e  $C\%$ . O primeiro favorece o efeito tóxico, o que pode estar relacionado ao aumento da eletronegatividade devido ao aumento no número de elétrons  $\pi$  na estrutura dos PFAS. O segundo, embora classificado classicamente com a lipossolubilidade, também pode indicar um efeito tóxico reduzido devido ao aumento do número de átomos de carbono dos PFAS [29].

A interpretação do modelo 3 está alinhada com as descobertas de Bhatarai e Gramatica [8]. Mesmo com seleção e descritores diferentes, a toxicidade por inalação em ratos tende a aumentar com o número de heteroátomos e diminuir com o aumento da lipossolubilidade. Isso pode ser devido à maior hidratação dos PFAS, o que facilita sua solubilidade. No entanto, esse padrão não foi observado no modelo oral em ratos. Para o modelo 1, uma relação semelhante à do modelo 3 foi encontrada, enquanto Bhatarai e Gramatica [9] propuseram que tanto a eletronegatividade quanto o aumento do tamanho da molécula tendem a aumentar o efeito tóxico via via oral. Embora a primeira característica também possa ser observada no modelo 1, a segunda apresenta uma contradição.

A interpretação para os modelos 2 e 4, relacionados à toxicidade oral e por inalação em camundongos, não segue exatamente os mesmos parâmetros e não parece ter, de acordo com os significados gerais dos descritores, uma relação com as respectivas toxicidades em ratos. Para o modelo 2, características relacionadas à forma e ao tamanho dos PFAS estão presentes na maioria dos descritores que favorecem o efeito tóxico, incluindo um aumento no número de cadeias de alquilfluoradas, informações codificadas nos descritores  $CATS2D\_05\_AL$  (o mais importante do modelo) e  $F10[C-F]$ . Por outro lado, entre os descritores que desfavorecem a atividade, predominam as características eletrônicas, embora o  $ATSC6e$  seja o segundo descritor mais importante.

No modelo 4, a maioria dos descritores também não apresenta uma relação clara com a toxicidade em ratos. Este modelo sugere principalmente que o efeito tóxico por inalação aumenta com o número de átomos e, particularmente, de heteroátomos. Isso indica que o aumento no tamanho do composto e na polaridade (também refletido no terceiro descritor mais importante,  $H\_Dz(p)$ ) potencializa o efeito tóxico. Exceto pelas informações codificadas no descritor molecular  $PHI$ , o  $H\_Dz(p)$  e outros descritores permitem uma interpretação semelhante àquela feita por Bhatarai e Gramatica [8]. No entanto, para o modelo 2, nenhuma relação clara foi identificada com o modelo de Bhatarai e Gramatica [9].

A única exceção para o modelo 4 em relação à toxicidade em ratos parece ser o descritor  $PHI$ , que, de fato, é o mais importante no modelo. Geralmente, esse descritor está relacionado à flexibilidade dos compostos estudados [30], e seu coeficiente negativo indica que PFAS menos flexíveis tendem a ser mais tóxicos. Essa possível relação é apoiada por um resultado previamente descrito por Al-Malah [31], que explorou a relação entre vários descritores moleculares e o transporte de medicamentos através da membrana intestinal de ratos. Nesse estudo, o autor também encontrou que medicamentos menos flexíveis tendem a ser melhor absorvidos. No

entanto, embora essa relação faça sentido, ela pode estar mais relacionada à capacidade do composto de permeabilizar membranas em geral, em vez de alguma semelhança necessária entre as espécies.

## **Conclusão**

Neste estudo, apresentamos os resultados de quatro modelos QSAR para avaliar a toxicidade de PFAS em mamíferos (ratos e camundongos) através de vias de intoxicação oral e por inalação, utilizando descritores moleculares derivados da estrutura 2D calculada por meio de strings SMILES. Esses modelos, desenvolvidos utilizando seleção de variáveis por meio do método OPS e construídos com regressão PLS, apresentam confiabilidade e alta qualidade interna e externa, incluindo robustez e ausência de correlações espúrias. A interpretação dos modelos 1 e 3 (ratos) revela uma relação significativa entre os mecanismos de toxicidade oral e por inalação dos PFAS nesses animais. No entanto, a relação não foi observada nos modelos 2 e 4 (camundongos), exceto por uma possível relação quanto à influência da flexibilidade no ponto final. Apesar do desafio de interpretar cada modelo devido ao número de descritores, nossas interpretações alinham-se parcialmente com modelos previamente publicados. Consequentemente, concluiu-se que os quatro modelos são ferramentas confiáveis para prever a toxicidade de PFAS em mamíferos por meio de duas vias críticas de intoxicação química.

## **Agradecimentos**

Os autores agradecem às seguintes agências de fomento: Fundação Araucária (bolsa 2010/7354); DS/CAPEs (Bolsista M.Sc. N.A.B.R.S.) e Programas PROAP/CAPEs; e PPGQUI-UNIOESTE. Agradecem também ao Laboratório de Teoria de Medicamentos e Quimioinformática (DTC), Universidade de Jadavpur ([http://teqip.jdvu.ac.in/QSAR\\_Tools](http://teqip.jdvu.ac.in/QSAR_Tools); <https://sites.google.com/jadavpuruniversity.in/dtc-lab-software/home>) pela disponibilização de licenças de alguns dos softwares utilizados neste estudo.

## **Declaração de Conflito de Interesse**

Nenhum conflito de interesse potencial foi reportado pelos autores.

## **Financiamento**

O trabalho foi apoiado pela Coordenação de Aperfeiçoamento de Pessoal de Nível Superior, Fundação Araucária, e PPGQUI-UNIOESTE.

## **Referências**

- [1] PERSON, A. L. Perfluoroalquil e polifluoroalquil compostos: uma síntese do conhecimento atual [tese]. São Paulo: Escola Politécnica da Universidade de São Paulo, Departamento de Engenharia Química; 2022.
- [2] NIEGOWSKA, M.; PRETTO, P.; PORCEL-RODRIGUEZ, E.; et al. Substâncias perfluoroalquil e polifluoroalquil (PFAS) de possível preocupação no ambiente aquático. Luxemburgo: Publicações da Oficina da União Europeia; 2021. EUR 30710 EN. doi: 10.2760/377564.
- [3] TAN, H.; TANG, S.; YANG, L.; et al. Quantificação global de substâncias perfluoroalquil e polifluoroalquil emergentes e legadas em poeira interna: níveis, perfis e exposição humana. Sci Total Environ. 2024; 927:172132. doi: 10.1016/j.scitotenv.2024.172132.

- [4] CHENG, W.; NG, C. A. Usando aprendizado de máquina para classificar a bioatividade de 3486 substâncias perfluoroalquil e polifluoroalquil (PFAS) da lista da OECD. *Environ Sci Technol*. 2019; 53:13970–13980. doi: 10.1021/acs.est.9b04833.
- [5] DE LA TORRE, A.; NAVARRO, I.; SANZ, P.; et al. Ocorrência e avaliação da exposição humana a substâncias perfluoradas em poeira doméstica de três países europeus. *Sci Total Environ*. 2019; 685:308–314. doi: 10.1016/j.scitotenv.2019.05.463.
- [6] LAU, C.; ANITOLE, K.; HODES, C.; et al. Ácidos perfluoroalquil: uma revisão dos resultados de monitoramento e toxicologia. *Toxicol Sci*. 2007; 99:366–394. doi: 10.1093/toxsci/kfm128.
- [7] CASARETT, L. J.; DOULL, J. Casarett and Doull's Toxicology: the basic science of poisons. Nova York: McGraw-Hill; 2001.
- [8] BHATTARAI, B.; GRAMATICA, P. Estudo de toxicidade por inalação (LC<sub>50</sub>) de substâncias perfluoroalquil e polifluoroalquil em ratos e camundongos utilizando modelagem QSAR. *Chem Res Toxicol*. 2010; 23:528–539. doi: 10.1021/tx900252h.
- [9] BHATTARAI, B.; GRAMATICA, P. Modelagem de toxicidade oral LD<sub>50</sub> e previsão de substâncias perfluoroalquil e polifluoroalquil em ratos e camundongos. *Mol Divers*. 2011; 15:467–476. doi: 10.1007/s11030-010-9268-z.
- [10] SOSNOWSKA, N.; BULAWSKA, D.; KOWALSKA, T. Rumo a uma maior validade científica e aceitação regulatória dos modelos preditivos para PFAS. *Green Chem*. 2023; 25:1261. doi: 10.1039/D2GC04341F.
- [11] ALVES, V. M.; BRAGA, R. C.; MURATOV, E. N.; et al. Quimioinformática: uma introdução. *Quím Nova*. 2018; 41:202–212. doi: 10.21577/0100-4042.20170145.
- [12] KOWALSKA, D.; SOSNOWSKA, A.; ZDYBEL, S.; et al. Prevendo fatores de bioconcentração (BCFs) para substâncias perfluoroalquil e polifluoroalquil (PFAS). *Chemosphere*. 2024; 364:143146. doi: 10.1016/j.chemosphere.2024.143146.
- [13] CRETON, B.; BARRAUD, E.; NIETO-DRAGHI, C. Previsão da concentração micelar crítica para substâncias perfluoroalquil e polifluoroalquil. *SAR QSAR Environ Res*. 2024; 35:309–324. doi: 10.1080/1062936X.2024.2337011.
- [14] BRUSSEAU, M. L.; VAN GLUBT, S. A influência da estrutura molecular na adsorção de PFAS em interfaces ar-água em soluções de eletrólitos. *Chemosphere*. 2021; 281:130829. doi: 10.1016/j.chemosphere.2021.130829.
- [15] BRUSSEAU, M. L. A influência da estrutura molecular na adsorção de PFAS em interfaces fluido-fluido: utilizando QSPR para prever os coeficientes de adsorção interfaciais. *Water Res*. 2019; 152:148–158. doi: 10.1016/j.watres.2018.12.057.
- [16] WANG, Y.; SUZEK, T.; ZHANG, J.; et al. PubChem BioAssay: atualização de 2014. *Nucleic Acids Res*. 2014; 42:D1075–D1082. doi: 10.1093/nar/gkt978.
- [17] BENFENATI, E. Theory, guidance and applications on QSAR and REACH. 1ª ed. Milano (Itália): Istituto di Ricerche Farmacologiche “Mario Negri”; 2012.
- [18] MAURI, A.; CONSONNI, V.; TODESCHINI, R. Descritores moleculares. In: CRAMER, C.; TRUHLAR, D., editores. *Handbook of computational chemistry*. 1ª ed. Suíça: Springer; 2017. doi: 10.1007/978-3-319-27282-5\_51.

- [19] MARTINS, J. P. A.; FERREIRA, M. M. C. Modelagem QSAR: um novo pacote computacional open source para gerar e validar modelos QSAR. *Quím Nova*. 2013; 36:554–560. doi: 10.1590/S0100-40422013000400013.
- [20] KIRALJ, R.; FERREIRA, M. M. C. Procedimentos básicos de validação para modelos de regressão em estudos QSAR e QSPR: teoria e aplicação. *J Braz Chem Soc*. 2009; 20:770–787. doi: 10.1590/S0103-50532009000400021.
- [21] ROY, K.; KAR, S.; DAS, R. N. Entendendo os fundamentos do QSAR para aplicações em ciências farmacêuticas e avaliação de riscos. 1ª ed. Londres: Academic Press; 2015. ISBN 9780128016336.
- [22] TROPSHA, A.; GRAMATICA, P.; GOMBAR, V. K. A importância de ser sério: a validação é essencial para a aplicação e interpretação bem-sucedida dos modelos QSPR. *QSAR Comb Sci*. 2003; 22:69–77. doi: 10.1002/qsar.200390007.
- [23] FERREIRA, M. M. C. QSAR multivariado. *Rev Soc Bras Quím*. 2002; 13:742–753. doi: 10.1590/S0103-50532002000600004.
- [24] OLAH, M.; BOLOGA, C.; OPREA, T. I. Uma busca automatizada por descritores QSAR biologicamente relevantes. *J Comput Aided Mol Des*. 2004; 18:437–449. doi: 10.1007/s10822-004-4060-8.
- [25] ERIKSSON, L.; JOHANSSON, E.; KETTANEH-WOLD, N.; et al. Análise multivariada e megavariada: princípios básicos e aplicações. Umeå: Umetrics Academy; 2006.
- [26] NUNES, C. A.; FREITAS, M. P.; PINHEIRO, A. C. M.; et al. Chemoface: uma interface nova, gratuita e fácil de usar para quimiometria. *J Braz Chem Soc*. 2012; 23:2003–2010. doi: 10.1590/S0103-50532012005000073.
- [27] VAN DRIE, J. H. Descoberta de farmacóforos: lições aprendidas. *Curr Pharm Des*. 2003; 9:1649–1664. doi: 10.2174/1381612033454568.
- [28] DEVILLERS, J.; BALABAN, A. T. Índices topológicos e descritores relacionados em QSAR e QSPR. Amsterdã: Gordon and Breach Science Publishers; 1999. ISBN 9056992392.
- [29] TODESCHINI, R.; CONSONNI, V. Descritores moleculares para quimiinformática: volume I: listagem alfabética/volume II: apêndices, referências. 2ª ed. Weinheim (Alemanha): John Wiley & Sons. ISBN 3527628770, 9783527628773.
- [30] LASZLO, T. Descritores de flexibilidade molecular para cálculos QSAR. *Rev Chim*. 2004; 55:169–174.
- [31] AL-MALAH, K. I. Previsão da permeabilidade de fármacos em ratos a partir de propriedades moleculares selecionadas dos fármacos. *Int J Pharm Sci Rev Res*. 2011; 7:40–45.

## 00000011.2 Artigo 2

Impacto de diferentes descritores de solubilidade e partição na predição do coeficiente de sorção no solo de éteres difenil substituídos por modelos uni e multivariados.

Chemical Papers, 2026.

DOI: 10.1007/s11696-026-04795-5. <https://link.springer.com/article/10.1007/s11696-026-04795-5>

Natalya Aline Barros Ribeiro da Silva<sup>a,b</sup>, Eduardo Borges de Melo<sup>a,b\*</sup>

<sup>a</sup>Department of Chemistry, Western Paraná State University, (UNIOESTE), 645 Faculdade St, Toledo, Paraná 85903-000, Brazil.

<sup>b</sup>Theoretical Medicinal and Environmental Chemistry Laboratory (LQMAT), UNIOESTE, 2069 Universitária St., Cascavel, Paraná 85819-110, Brazil.

\*E-mail address: [eduardo.b.de.melo@gmail.com](mailto:eduardo.b.de.melo@gmail.com) (E.B. de Melo).


**RESUMO.** Os éteres difenílicos substituídos representam uma importante classe de compostos químicos industriais, sendo utilizados como intermediários de sínteses, pesticidas, fármacos, cosméticos, entre outras aplicações. Porém, apresentam alta estabilidade, e persistência ambiental, podendo ser tóxicos. O coeficiente de sorção ao solo normalizado pelo teor de carbono orgânico (Koc) é um parâmetro importante em avaliações de risco ambiental, e é estritamente relacionado com as características hidrofóbicas ou hidrofílicas de compostos orgânicos. Assim, diversos modelos de predição do LogKoc utilizam LogP ou LogS como descritores moleculares. Estudos já realizados mostraram que a qualidade dos modelos pode variar de acordo com o algoritmo selecionado para obter estas variáveis. Neste estudo, foram avaliados de modo univariado 15 diferentes algoritmos de LogP e 4 de LogS para um conjunto de 59 difenis éteres substituídos. Os algoritmos que apresentaram maior qualidade foram adicionados a um modelo QSPR de previsão de LogKoc independente de Log P, visando avaliar se levariam a melhoria da qualidade preditiva. Além disso, também foi testado se o descritor híbrido LogSp, anteriormente proposto, obtido de duas formas diferentes (modo original e utilizando os LogS e LogP selecionados neste estudo) também poderia melhorar o modelo. Foi possível observar que, ao menos para difenis éteres, o algoritmo MLogP pode ser considerado o algoritmo mais adequado. Entretanto, o melhor modelo foi obtido com LogSp calculado pela abordagem original. Indo de encontro a estudos anteriores, os resultados mostraram que a seleção de LogP ou LogS deve ser cuidadosamente avaliada em estudos de QSPR voltados para predição de LogKoc, assim como fortaleceram o uso de LogSp original como uma alternativa para codificar informações sobre solubilidade nestes mesmos modelos.

**Palavras-chaves:** Difenil-éteres; LogKoc; LogP; LogS; LogSp; QSPR.

## 1. INTRODUÇÃO

Os éteres difenílicos substituídos representam uma classe complexa de compostos orgânicos derivados da estrutura básica do difenil éter. Esses compostos são caracterizados pela presença de grupos funcionais como hidroxilas, metoxilas ou halogênios ligados aos anéis aromáticos, o que lhes confere propriedades físico-químicas específicas, como alta estabilidade, lipofilicidade e persistência ambiental. Além do seu uso tradicional como pesticidas e retardantes de chama, alguns derivados também são utilizados como fármacos e cosméticos (Figura 1). Além disso, também são utilizados como solventes e intermediários da síntese de outros compostos químicos. Uma de suas características, relacionada a sua eficácia na eliminação de pragas, é sua estabilidade química e consequente resistência à degradação natural. No entanto, essa mesma característica também resulta em preocupações ambientais devido à sua capacidade de bioacumulação e biomagnificação nas cadeias alimentares, atingindo regiões distantes de suas fontes de emissão, resultando em concentrações cada vez maiores em predadores de topo, incluindo seres humanos. Por este motivo, eles também são classificados como Poluentes Orgânicos Persistentes (POPs). A exposição a esses compostos está associada a diversos efeitos adversos à saúde, como disfunções endócrinas, neurotoxicidade, imunotoxicidade, efeitos teratogênicos e

carcinogênicos. Além disso, podem interferir no desenvolvimento reprodutivo e causar alterações comportamentais e metabólicas (Alharbi et al., 2018; Zhang et al., 2015).



**Figura 1.** Exemplos de difenil éteres importantes.

Dentre diversos processos que podem ser estudados para avaliar o impacto de POPs no ambiente, a sorção no solo é um processo importante, pois está relacionada com o transporte e o destino destes compostos. Esta propriedade descreve a capacidade de uma substância aderir às partículas de solo, influenciando diretamente sua mobilidade, disponibilidade biológica e persistência. No caso de compostos como os éteres difenílicos substituídos, a sorção está fortemente relacionada à hidrofobicidade e à polaridade, as quais são moduladas pelas características dos substituintes. Estudar a sorção desses compostos é essencial para prever o risco de contaminação de águas subterrâneas pelos mesmos, avaliar sua disponibilidade para organismos do solo, e estimar sua persistência ambiental. Estes aspectos são cruciais na avaliação de impacto ecológico e no desenvolvimento de estratégias de manejo e remediação (Zhang et al., 2015; Dos Reis, Sampaio e de Melo, 2013).

Análises do comportamento e destino de POPs são amplamente estudadas por métodos de *Quantitative Structure–Property Relationship* (QSPR). Estas ferramentas hoje são particularmente relevantes para compostos persistentes e potencialmente tóxicos, pois auxiliam na identificação de substâncias de maior risco, orientam o desenvolvimento de compostos químicos com menor impacto ambiental, e apoiam a formulação de políticas regulatórias mais robustas. O organic carbon normalized soil sorption coeficiente (K<sub>oc</sub>), mais especificamente seu logaritmo (LogK<sub>oc</sub>), é muito utilizado como variável dependente em modelos que buscam auxiliar a antecipar o destino ambiental de substâncias químicas de forma rápida e eficiente, além de reduzir a necessidade de ensaios experimentais (Dos Reis, Sampaio e de Melo, 2013; Dos Reis, Sampaio e de Melo, 2014; Zhang et al., 2018).

Em estudo conduzido por dos Reis, Sampaio e de Melo (2013), estudos univariados entre valores experimentais de LogK<sub>oc</sub> e valores de logaritmo do coeficiente de partição 1-octanol/água (LogP) gerados por diversos algoritmos diferentes foram desenvolvidos para um grupo de pesticidas não iônicos estruturalmente

heterogêneos. Os resultados mostraram que a escolha do algoritmo pode impactar significativamente no resultado, gerando desde modelos ruins até ótimos (Dos Reis, Sampaio e de Melo, 2013). Em outro estudo, os autores também avaliaram exploraram a como o logaritmo da solubilidade em água (LogS), assim como de um descritor misto baseado em LogP e LogS, influenciava na qualidade de predição (Dos Reis, Sampaio e de Melo, 2014).

Neste contexto, neste trabalho foi realizado um extenso estudo QSPR visando avaliar o grau de influência de diferentes parâmetros de LogP e LogS na qualidade de modelos univariados e multivariados com objetivo de prever o LogKoc de um conjunto de 59 difenil éteres previamente avaliados por Zhang et al. (2015). Também foi avaliado se o descritor molecular alternativo logaritmo de solubilidade corrigido pela partição octanol/água (LogS<sub>p</sub>), poderia melhorar a qualidade da predição dos modelos e também a aumentar a compreensão sobre a sorção no solo desta importante classe de compostos orgânicos (Dos Reis, Sampaio e de Melo, 2014).

## 2. MATERIAIS E MÉTODOS

### 2.1 Conjunto de dados

O conjunto de dados publicados por Zhang et al. (2023) é formado por 59 éteres difenílicos substituídos: 26 derivados polimetoxilados (PMeODEs), 19 polihidroxilados (PHODEs), 7 policlorados metoxilados (MeO-PCDEs) e 7 hidroxilados (HO-PCDEs). Os autores também disponibilizaram os valores de LogKoc e LogP experimentais para cada derivado. O intervalo de distribuição para o primeiro parâmetro é de 3.18 unidades logarítmicas (1.63 a 4.81, média de 2.59, desvio padrão de 0.824), enquanto para o segundo, que neste trabalho é denominado LogKow, é de 3.63 unidades logarítmicas (1.76 a 5.39, média de 3.39, desvio padrão de 0.971).

Todas as estruturas 2D dos derivados foram individualmente criadas utilizando o programa ChemSketch (ACD/LABS, 2025), e a partir delas foram geradas suas respectivas representações *Simplified Molecular Input Line Entry System* (SMILES) (Alves et al., 2018). Estes dados estão disponibilizados na Tabela 1.

| ID | Classe | Nome                                   | Smile                                    | Log Koc | LogKow |
|----|--------|----------------------------------------|------------------------------------------|---------|--------|
| 1  | PMeODE | 1'-oxibenzeno                          | <chem>c1ccccc1Oc1ccccc1</chem>           | 3.280   | 4.250  |
| 2  | PMeODE | 1-metoxi-3-fenoxibenzeno               | <chem>COc1cccc(Oc2ccccc2)c1</chem>       | 3.080   | 3.920  |
| 3  | PMeODE | 1-metoxi-4-fenoxibenzeno               | <chem>COc1ccc(cc1)Oc1ccccc1</chem>       | 2.990   | 3.890  |
| 4  | PMeODE | 1-metoxi-2-(3-metoxifenoxi)benzeno     | <chem>COc1ccccc1Oc1ccc(OC)c1</chem>      | 2.950   | 3.720  |
| 5  | PMeODE | 1-metoxi-2-(4-metoxifenoxi)benzeno     | <chem>COc1ccccc1Oc1ccc(cc1)OC</chem>     | 3.020   | 3.680  |
| 6  | PMeODE | 1,1'-oxibis(3-metoxibenzeno)           | <chem>COc1cccc(Oc2cc(ccc2)OC)c1</chem>   | 2.890   | 3.560  |
| 7  | PMeODE | 1-metoxi-3-(4-metoxifenoxi)benzeno     | <chem>COc1cccc(Oc2ccc(cc2)OC)c1</chem>   | 3.020   | 3.690  |
| 8  | PMeODE | 1,1'-oxibis(4-metoxibenzeno)           | <chem>COc1ccc(cc1)Oc1ccc(cc1)OC</chem>   | 2.740   | 3.620  |
| 9  | PMeODE | 1,2-dimetoxi-4-fenoxibenzeno           | <chem>COc1cc(ccc1OC)Oc1ccccc1</chem>     | 2.760   | 3.510  |
| 10 | PMeODE | 2,4-dimetoxi-1-(2-metoxifenoxi)benzeno | <chem>COc1cc(ccc1Oc1ccccc1OC)OC</chem>   | 2.680   | 3.400  |
| 11 | PMeODE | 2,4-dimetoxi-1-(4-metoxifenoxi)benzeno | <chem>COc1cc(ccc1Oc1ccc(cc1)OC)OC</chem> | 2.710   | 3.350  |
| 12 | PMeODE | 1,4-dimetoxi-2-(4-metoxifenoxi)benzeno | <chem>COc1ccc(OC)cc1Oc1ccc(cc1)OC</chem> | 2.680   | 3.530  |
| 13 | PMeODE | 1,2-dimetoxi-4-(2-metoxifenoxi)benzeno | <chem>COc1cc(ccc1OC)Oc1ccccc1OC</chem>   | 2.770   | 3.440  |

|    |          |                                                |                                         |       |       |
|----|----------|------------------------------------------------|-----------------------------------------|-------|-------|
| 14 | PMeODE   | 1,3-dimetoxi-5-(3-metoxifenoxi)benzeno         | COc1cc(cc(Oc2cc(ccc2)OC)c1)OC           | 2.700 | 3.260 |
| 15 | PMeODE   | 1,3-dimetoxi-5-(4-metoxifenoxi)benzeno         | COc1cc(cc(Oc2ccc(cc2)OC)c1)OC           | 2.650 | 3.300 |
| 16 | PMeODE   | 1,2,3-trimetoxi-5-fenoxibenzeno                | COc1c(OC)cc(cc1OC)Oc1ccccc1             | 2.720 | 3.480 |
| 17 | PMeODE   | 1-(2,5-dimetoxifenoxi)-2,3-dimetoxibenzeno     | COc1c(cccc1OC)Oc1cc(ccc1OC)OC           | 2.320 | 2.730 |
| 18 | PMeODE   | 1-(3,4-dimetoxifenoxi)-2,3-dimetoxibenzeno     | COc1c(cccc1OC)Oc1ccc(OC)c(OC)c1         | 2.400 | 2.770 |
| 19 | PMeODE   | 1-(3,4-dimetoxifenoxi)-2,4-dimetoxibenzeno     | COc1cc(ccc1Oc1ccc(OC)c(OC)c1)OC         | 2.340 | 2.880 |
| 20 | PMeODE   | 1-(3,5-dimetoxifenoxi)-2,4-dimetoxibenzeno     | COc1cc(ccc1Oc1cc(cc(c1)OC)OC)OC         | 2.390 | 2.750 |
| 21 | PMeODE   | 2-(3,4-dimetoxifenoxi)-1,4-dimetoxibenzeno     | COc1cc(ccc1OC)Oc1cc(ccc1OC)OC           | 2.300 | 2.620 |
| 22 | PMeODE   | 1,2,3-trimetoxi-5-(2-metoxifenoxi)benzeno      | COc1c(OC)cc(cc1OC)Oc1ccccc1OC           | 2.360 | 2.790 |
| 23 | PMeODE   | 1,2,3-trimetoxi-5-(3-metoxifenoxi)benzeno      | COc1c(OC)cc(cc1OC)Oc1cc(ccc1)OC         | 2.260 | 2.760 |
| 24 | PMeODE   | 5-(2,3-dimetoxifenoxi)-1,2,3-trimetoxibenzeno  | COc1c(OC)cc(cc1OC)Oc1cccc(OC)c1OC       | 2.020 | 2.540 |
| 25 | PMeODE   | 5-(3,4-dimetoxifenoxi)-1,2,3-trimetoxibenzeno  | COc1c(OC)cc(cc1OC)Oc1cc(OC)c(cc1)OC     | 1.960 | 2.430 |
| 26 | PMeODE   | 1,1'-oxibis(3,4,5-trimetoxibenzeno)            | COc1c(OC)cc(cc1OC)Oc1cc(OC)c(OC)c(c1)OC | 1.800 | 2.250 |
| 27 | PHODE    | 2-fenoxifenol                                  | Oc1ccccc1Oc1ccccc1                      | 2.850 | 3.450 |
| 28 | PHODE    | 3-fenoxifenol                                  | Oc1cc(ccc1)Oc1ccccc1                    | 2.880 | 3.530 |
| 29 | PHODE    | 4-fenoxifenol                                  | Oc1ccc(cc1)Oc1ccccc1                    | 2.980 | 3.320 |
| 30 | PHODE    | 2-(3-idroksifenoksi)fenol                      | Oc1ccccc1Oc1cc(O)ccc1                   | 2.590 | 2.910 |
| 31 | PHODE    | 2-(4-idroksifenoksi)fenol                      | Oc1ccccc1Oc1ccc(O)cc1                   | 2.680 | 2.830 |
| 32 | PHODE    | 3,3'-oksidiifenol                              | Oc1cc(ccc1)Oc1cc(O)ccc1                 | 2.520 | 2.870 |
| 33 | PHODE    | 4,4'-oksidiifenol                              | Oc1ccc(cc1)Oc1ccc(O)cc1                 | 2.480 | 2.610 |
| 34 | PHODE    | 2-(2-idroksifenoksi)benzeno-1,4-diol           | Oc1ccc(O)cc1Oc1ccccc1O                  | 2.310 | 2.540 |
| 35 | PHODE    | 2-(4-idroksifenoksi)benzeno-1,4-diol           | Oc1ccc(O)cc1Oc1ccc(O)cc1                | 2.210 | 2.650 |
| 36 | PHODE    | 5-(3-idroksifenoksi)benzeno-1,3-diol           | Oc1cc(cc(O)c1)Oc1cc(O)ccc1              | 2.190 | 2.400 |
| 37 | PHODE    | 5-(4-idroksifenoksi)benzeno-1,3-diol           | Oc1cc(cc(O)c1)Oc1ccc(O)cc1              | 2.230 | 2.510 |
| 38 | PHODE    | 5-fenoxibenzeno-1,2,3-triol                    | Oc1c(O)cc(cc1O)Oc1ccccc1                | 2.280 | 2.720 |
| 39 | PHODE    | 3-(3,4-diidroksifenoksi)benzeno-1,2-diol       | Oc1c(O)cccc1Oc1cc(O)c(O)cc1             | 2.050 | 2.240 |
| 40 | PHODE    | 4-(3,5-diidroksifenoksi)benzeno-1,3-diol       | Oc1cc(O)ccc1Oc1cc(O)cc(O)c1             | 2.240 | 2.330 |
| 41 | PHODE    | 4-(2,5-diidroksifenoksi)benzeno-1,2-diol       | Oc1cc(ccc1O)Oc1cc(O)ccc1O               | 2.020 | 2.110 |
| 42 | PHODE    | 5-(2-idroksifenoksi)benzeno-1,2,3-triol        | Oc1c(O)cc(cc1O)Oc1ccccc1O               | 2.040 | 2.190 |
| 43 | PHODE    | 5-(2,3-diidroksifenoksi)benzeno-1,2,3-triol    | Oc1c(O)cccc1Oc1cc(O)c(O)c(O)c1          | 1.690 | 1.790 |
| 44 | PHODE    | 5-(3,4-diidroksifenoksi)benzeno-1,2,3-triol    | Oc1c(O)cc(cc1O)Oc1cc(O)c(O)cc1          | 1.760 | 1.950 |
| 45 | PHODE    | 5,5'-oksidi(benzeno-1,2,3-triol)               | Oc1c(O)cc(cc1O)Oc1cc(O)c(O)c(O)c1       | 1.630 | 1.760 |
| 46 | MeO-PCDE | 1-kloro-3-(4-metoxifenoksi)benzeno             | Clc1cc(ccc1)Oc1ccc(cc1)OC               | 4.200 | 4.700 |
| 47 | MeO-PCDE | 1-kloro-3-(4-metoxifenoksi)benzeno             | Clc1cc(ccc1Cl)Oc1ccc(cc1)OC             | 4.630 | 5.090 |
| 48 | MeO-PCDE | 1,4-dikloro-2-(4-metoxifenoksi)benzeno         | Clc1ccc(Cl)cc1Oc1ccc(cc1)OC             | 4.310 | 4.950 |
| 49 | MeO-PCDE | 1,2-dikloro-3-(4-metoxifenoksi)benzeno         | Clc1c(cccc1Cl)Oc1ccc(cc1)OC             | 4.290 | 4.860 |
| 50 | MeO-PCDE | 1,4-dikloro-2-(4-kloro-2-metoxifenoksi)benzeno | Clc1ccc(Cl)cc1Oc1ccc(Cl)cc1OC           | 4.720 | 5.210 |
| 51 | MeO-PCDE | 1,2-dikloro-4-(4-kloro-2-metoxifenoksi)benzeno | Clc1cc(ccc1Cl)Oc1ccc(Cl)cc1OC           | 4.810 | 5.390 |
| 52 | MeO-PCDE | 2,4-dikloro-1-(4-kloro-2-metoxifenoksi)benzeno | Clc1cc(Cl)ccc1Oc1ccc(Cl)cc1OC           | 4.580 | 5.110 |
| 53 | HO-PCDE  | 4-(3-klorofenoksi)fenol                        | Oc1ccc(cc1)Oc1cc(Cl)ccc1                | 3.450 | 4.140 |
| 54 | HO-PCDE  | 4-(3,4-diklorofenoksi)fenol                    | Oc1ccc(cc1)Oc1cc(Cl)c(Cl)cc1            | 3.620 | 4.410 |
| 55 | HO-PCDE  | 4-(2,5-diklorofenoksi)fenol                    | Oc1ccc(cc1)Oc1cc(Cl)ccc1Cl              | 3.690 | 4.500 |

|    |         |                                    |                                             |       |       |
|----|---------|------------------------------------|---------------------------------------------|-------|-------|
| 56 | HO-PCDE | 4-(2,3-diclorofenoxi)fenol         | <chem>Oc1ccc(cc1)Oc1ccc(Cl)c1Cl</chem>      | 3.500 | 4.330 |
| 57 | HO-PCDE | 5-cloro-2-(2,5-diclorofenoxi)fenol | <chem>Oc1cc(Cl)ccc1Oc1cc(Cl)ccc1Cl</chem>   | 3.980 | 4.810 |
| 58 | HO-PCDE | 5-cloro-2-(3,4-diclorofenoxi)fenol | <chem>Oc1cc(Cl)ccc1Oc1cc(Cl)c(Cl)cc1</chem> | 4.210 | 4.960 |
| 59 | HO-PCDE | 5-cloro-2-(2,4-diclorofenoxi)fenol | <chem>Oc1cc(Cl)ccc1Oc1ccc(Cl)cc1Cl</chem>   | 3.920 | 4.740 |

## 2.2 Descritores moleculares

### 2.2.1 Algoritmos de LogP e LogS, e derivação do parâmetro LogSp

Na Tabela 2 são apresentados os algoritmos de LogP e LogS selecionados para este trabalho, totalizando 15 diferentes algoritmos. Os valores de LogP de cada algoritmo foram obtidos inserindo os SMILES de cada composto nas fontes apresentadas na tabela. Os valores obtidos são disponibilizados no Material Suplementar, Tabela 2.

| Tabela 2. Algoritmos de LogP e LogS teóricos utilizados neste trabalho e suas fontes. |                                                                                                     |                                                                                                                 |
|---------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------|
| Algoritmos                                                                            | Fonte                                                                                               | Referência                                                                                                      |
| <b>LogP</b>                                                                           |                                                                                                     |                                                                                                                 |
| MLOGP                                                                                 | Dragon 6                                                                                            | Moriguchi et al. (1992)                                                                                         |
| ALOGP                                                                                 | Dragon 6                                                                                            | Viswanadhan et al. (1993)                                                                                       |
| iLOGP                                                                                 | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | Daina, Micheling e Zoete (2014)                                                                                 |
| XLOGP3                                                                                | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | Cheng et al. (2007)                                                                                             |
| WLOGP                                                                                 | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | Wildman e Crippen (1999)                                                                                        |
| Silicos-IT_LogP                                                                       | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | <a href="https://www.silicos-it.be/">https://www.silicos-it.be/</a>                                             |
| LogPow                                                                                | <a href="http://www.ochem.com">http://www.ochem.com</a>                                             | <a href="http://www.ochem.com">http://www.ochem.com</a>                                                         |
| SLogP                                                                                 | <a href="http://www.ochem.com">http://www.ochem.com</a>                                             | Hou e Xu (2002)                                                                                                 |
| ALOGPs                                                                                | <a href="http://www.vcclab.org">http://www.vcclab.org</a>                                           | Tetko e Tanchuk (2002)                                                                                          |
| miLogP                                                                                | <a href="http://www.vcclab.org">http://www.vcclab.org</a>                                           | <a href="https://www.molinspiration.com/services/faq.html">https://www.molinspiration.com/services/faq.html</a> |
| AcLogP                                                                                | <a href="https://www.organic-chemistry.org/prog/peo">https://www.organic-chemistry.org/prog/peo</a> | Organic Chemistry Portal, 2026                                                                                  |
| <b>LogS</b>                                                                           |                                                                                                     |                                                                                                                 |
| Ali_LogS                                                                              | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | Ali et al. (2012)                                                                                               |
| ESOL_LogS                                                                             | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | Delaney (2004)                                                                                                  |
| Silicos-IT_LogSw                                                                      | <a href="http://www.swissadme.ch/">http://www.swissadme.ch/</a>                                     | <a href="https://www.silicos-it.be/">https://www.silicos-it.be/</a>                                             |
| ALOGpS                                                                                | <a href="http://www.vcclab.org">http://www.vcclab.org</a>                                           | Tetko e Tanchuk (2002)                                                                                          |

Outro parâmetro utilizando foi o logaritmo de solubilidade em água corrigido pela partição octanol/água (LogSp). Este descritor misto leva em consideração o fato de que a sorção de um composto químico no solo depende tanto de sua solubilidade em água quanto de sua partição água/matéria orgânica. De acordo com a proposta original, assume-se que seu uso pode gerar resultados de LogKoc mais realistas (Dos Reis, Sampaio e de Melo, 2014). Originalmente foram utilizados os valores de LogP e LogS gerados pelo programa ALOGPS 2.1 (Tetko e Tanchuk, 2002) ou ALOGPs e ALOGpS, respectivamente. Portanto, este método também foi utilizado para derivar o LogSp neste estudo. Porém, levando em consideração que o conjunto de dados é muito diferente

do utilizado originalmente, LogSp também foi calculado utilizando os melhores LogP e LogS identificados neste estudo para explicar e prever o LogKoc dos éteres difenílicos em avaliações univariadas.

### 2.2.2 Outros descritores moleculares

Outras classes de descritores moleculares foram obtidas utilizando o programa Dragon 6 (Mauri et al., 2017; Benfenati, 2012). Esse software realiza a leitura dessas estruturas de diversos formatos químicos e gera diversos descritores moleculares, que incluem informações constitucionais, topológicas, geométricas e moleculares, além de derivar uma série de fingerprints moleculares e usar diversos tipos de fatores de ponderação atômica. Neste estudo, os descritores foram gerados a partir dos respectivos SMILES de cada derivado do conjunto de dados, e por isto limitaram-se a classes que não codificam informações tridimensionais.

A matriz obtida foi submetida a uma etapa de redução de variáveis no mesmo programa, visando remover descritores moleculares que: i) possuísem valores constantes ou quase constantes; ii) apresentassem desvios-padrões inferiores a 0,001; iii) a coluna apresentasse ao menos um valor ausente; iv) entre descritores que apresentassem correlações pareadas  $\geq 0,9$ , um deles foi removido. Também foi realizada uma análise visual para excluir outros descritores que apresentassem baixa variação. Ao final, obteve-se uma matriz com 201 descritores moleculares.

## 2.3 Análises univariadas

Foram realizados estudos univariados dos diferentes LogP, LogS, e dos LogSp calculados, visando avaliar a qualidade de predição interna e externa de método isoladamente. Os resultados foram comparados com uma regressão univariada realizada com o LogP experimental dos 59 compostos, também disponibilizado por Zhang et al. (2018). Todas as regressões foram avaliadas pelos mesmos testes estatísticos. Os melhores LogP e LogS foram selecionados para serem adicionados ao melhor modelo multivariado obtido, e para serem utilizados para calcular um novo LogSp, aqui denominada New\_LogSp, que também foi adicionado ao modelo multivariado. Já o LogSp proposto originalmente, aqui denominado Original\_LogSp, também foi calculado e os processos realizados com New\_LogSp também foram aplicados a ele, visando avaliar se este descritor sempre deve ser utilizado como proposto originalmente ou se pode ser derivado utilizando outros métodos, de acordo com os resultados específicos de um trabalho.

## 2.4 Análise multivariada.

Para a etapa de calibração multivariada foi utilizado o software QSAR Modeling (Martins e Ferreira, 2013). Inicialmente, uma última etapa de redução de variáveis foi realizada através da eliminação dos descritores moleculares com correlação absoluta de Pearson com LogKoc menores que 0.2 (gerando uma matriz de 140 descritores) ou 0.1 (gerando uma matriz de 167 descritores). Esta última etapa visa teve como objetivo remover variáveis que, mesmo apresentando certo grau de variância, não codificavam informações minimamente relevantes para a obtenção de modelos QSPR de interesse.

As matrizes finais foram submetidas ao processo conhecido de seleção de variáveis. O QSAR Modeling programa otimiza a modelagem molecular utilizando o sistema de seleção ordenada de preditores (OPS) (Martins e Ferreira, 2013). um método desenvolvido para seleção utilizando regressão por PLS. As melhores combinações de descritores selecionados foram utilizadas para construção dos modelos também utilizando PLS (Wold et al., 2001). O QSAR Modeling fornece informações sobre a quantidade de informação acumulada por variável latente (LV), e os coeficientes autoescalados de cada modelo obtido, permitindo a identificação de quantas LVs e descritores são necessários para garantir uma máxima variância aliada a máxima redução de dimensão dos dados, um dos objetivos em PLS.

Tanto na seleção de variáveis quanto na construção dos modelos multivariados os descritores moleculares foram autoescalados. Isto decorre do fato de que o intervalo numérico dos diferentes descritores moleculares normalmente utilizados em QSPR geralmente são diversos. Deste modo, deve-se utilizar algum tipo de pré-processamento, sendo o mais utilizado o autoescalamento, ou Z-score. Este processo é feito subtraindo a média do descritor do valor individual da variável para cada amostra, e dividindo o resultado pelo desvio padrão correspondente (Dearden et al., 2009; Kiralj e Ferreira, 2009).

## 2.5 Validação dos modelos

As regressões univariadas e os modelos multivariados obtidos foram então submetidos ao mesmo processo de validação clássico utilizado em QSPR: validação interna e externa (Tropsha et al., 2003; Kiralj e Ferreira, 2009). Para isto, o conjunto de dados foi dividido em training set (80%,  $n=47$ ) e teste set (20%,  $n=12$ ) etapa de validação externa. Para este estudo, foram selecionados os compostos **2, 7, 10, 18, 21, 22, 24, 25, 29, 33, 39 e 43** como conjunto de teste. Este mesmo conjunto foi utilizado para validação de todos os modelos obtidos neste estudo.

Na validação interna, a qualidade da variância explicada foi avaliada utilizando o coeficiente de determinação ( $R^2$ ), o erro quadrático médio da calibração (RMSEC) e a F (intervalo de confiança de 95%,  $\alpha=0,05$ ). A qualidade da variância predita foi testada por validação cruzada leave-one-out (LOO), utilizando as métricas  $Q^2_{LOO}$  e RMSECV e RmSquare aplicadas a validação LOO (Average\_rm<sup>2</sup> (LOO)-scaled e  $\Delta rm^2(LOO)$ -scaled) (Gaudio e Zandonade, 2001; Roy et al., 2013; Roy e Mitra, 2012). Estes testes foram realizados no programa QSAR Modeling e no XternalValidation 1.0 (este último disponível em <http://dtclab.webs.com/software-tools>).

Para os modelos multivariados também foram realizados os testes de avaliação da robustez, utilizando o teste de validação cruzada *leave-N-out* (LNO) ( $N=12$ , com seis aleatorizações para cada  $N$ ) (Kiralj and Ferreira, 2009) e de avaliação da presença de correlação por acaso utilizando o teste de randomização do  $y$  (40 randomizações) usando a abordagem de Eriksson et al. (2003). No primeiro teste espera-se que os valores médios obtidos variem o mínimo possível em relação ao resultado do LOO, enquanto para o segundo regressões traçadas entre os  $R^2$  e os  $Q^2_{LOO}$  e as correlações de Pearson entre os vetores aleatorizados e originais devem ser menores que 0.3 para  $R^2$  e menores que 0.05. Estes testes foram realizados no QSAR Modeling.

Para a validação externa, a qualidade das predições avaliadas utilizando o coeficiente de determinação da validação externa ( $R^2_{pred}$ ) e seu erro quadrático de predição (RMSEP) associado. Para aumentar a

confiabilidade dos resultados obtidos, também foram aplicadas as métricas RmSquare para validação externa, Average\_r<sup>2</sup>m(pred)-scaled e Δr<sup>2</sup>m(pred)-scaled. As estatísticas de Golbraikh-Tropsha também foram utilizadas. Elas incluem os coeficientes angulares das regressões entre os valores observados e preditos (k e k') e a diferença absoluta entre os valores de R<sup>2</sup> das regressões com linha centrada na origem (|R<sup>2</sup><sub>o</sub>-R'<sup>2</sup><sub>o</sub>|) (Golbraikh et al., 2003; Tropsha et al., 2003). Todos os cálculos de validação externa foram realizados com o Xternal Validation 1.0.

Finalmente, foram obtidos para os modelos multivariados as métricas Average\_r<sup>2</sup>m(overall)-scaled e Δr<sup>2</sup>m(overall)-scaled. Seus valores são obtidos combinando os valores reais e preditos da validação cruzada LOO com os da validação externa. Os resultados obtidos têm por objetivo auxiliar na seleção dos melhores modelos entre equivalentes (Roy et al., 2009). Estes valores também foram obtidos utilizando o Xternal Validation 1.0.

### 3. RESULTADOS E DISCUSSÃO

#### 3.1 Regressões univariadas

No desenvolvimento do modelo QSPR para coeficientes de sorção em solo, o valor do logaritmo do coeficiente de partição orgânico-carbono (LogKoc) é utilizado como variável dependente **y**. O LogKoc é um parâmetro fundamental que representa a afinidade de um composto orgânico pelo solo, influenciando diretamente sua mobilidade e persistência no ambiente. A modelagem do LogKoc pode ser aprimorada ao considerar diferentes algoritmos para a derivação teórica de LogP e LogS de compostos de interesse ambiental, como pesticidas, poluentes orgânicos persistentes (POPs) e outros. Estudos realizados anteriormente mostraram que estudos comparativos para a escolha dos algoritmos mais adequados para obtenção de LogP e LogS podem levar a modelos QSPR superiores quanto a predição de LogKoc de compostos orgânicos (dos Reis, Sampaio, e de Melo, 2013, 2014).

Inicialmente foram construídos os modelos univariados com 11 algoritmos de LogP e 4 de LogS. Estes modelos são apresentados na tabela 3, onde também são apresentados os valores limites para cada parâmetro. Pode-se observar que a maioria dos modelos obtidos com os algoritmos de LogP apresentaram resultados adequados tanto para os ajustes dos dados (expressos pelos R<sup>2</sup> > 0.6) quanto para a informação predita internamente (expressos pelos Q<sup>2</sup>LOO > 0.5). A exceção é dada pelo algoritmo iLogP, com qualidade péssima para ambos os parâmetros. Já para os algoritmos de LogS, apesar de seus valores de R<sup>2</sup> e Q<sup>2</sup>LOO também estarem acima dos limites mínimos, três deles se mostraram consideravelmente inferiores aos algoritmos de LogP, enquanto ESOL\_LogS mostrou uma qualidade interna equivalente. Também é importante observar que nenhum algoritmo foi capaz de superar a qualidade estatística do modelo obtido com o LogP experimental.

| <b>Tabela 3.</b> Modelos de predição usando os LogP e LogS selecionados, suas respectivas equações QSPR univariadas, e métricas de validação interna (n= 47 para todos) |                               |       |        |                               |        |                                |                              |                    |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------|-------|--------|-------------------------------|--------|--------------------------------|------------------------------|--------------------|
| Algoritmo                                                                                                                                                               | R <sup>2</sup> <sub>cal</sub> | RMSEC | F      | Q <sup>2</sup> <sub>LoO</sub> | RMSECV | Av_r <sup>2</sup> (LOO)-scaled | Δr <sup>2</sup> (LOO)-scaled | Equações           |
| <b>LogP</b>                                                                                                                                                             |                               |       |        |                               |        |                                |                              |                    |
| Experimental LogP                                                                                                                                                       | 0.956                         | 0.179 | 977.73 | 0.951                         | 0.188  | 0.931                          | 0.036                        | 0.842*LogP + 0.014 |

|                             |       |                |                             |       |                |       |       |                                 |
|-----------------------------|-------|----------------|-----------------------------|-------|----------------|-------|-------|---------------------------------|
| <b>AcLogP</b>               | 0.881 | 0.294          | 333.15                      | 0.871 | 0.306          | 0.751 | 0.121 | 0.836*AcLogP + 0.482            |
| <b>ALogP</b>                | 0.87  | 0.307          | 301.15                      | 0.86  | 0.318          | 0.803 | 0.099 | 0.850*ALOGP – 0.007             |
| <b>ALOGPs</b>               | 0.863 | 0.315          | 283.47                      | 0.851 | 0.329          | 0.793 | 0.101 | 0.664*ALOGPs + 0.686            |
| <b>iLOGP</b>                | 0.235 | 0.745          | 13.82                       | 0.170 | 0.778          | 0.045 | 0.228 | 0.557*iLogP + 1.492             |
| <b>LogPow</b>               | 0.839 | 0.342          | 234.50                      | 0.825 | 0.356          | 0.759 | 0.114 | 0.788*LogPow + 0.055            |
| <b>miLogP</b>               | 0.856 | 0.323          | 267.50                      | 0.844 | 0.336          | 0.784 | 0.105 | 0.686*miLogP + 0.564            |
| <b>MLOGP</b>                | 0.848 | 0.332          | 251.05                      | 0.824 | 0.358          | 0.758 | 0.088 | 0.654*MLogP + 1.404             |
| <b>Silicos-IT_Log P</b>     | 0.739 | 0.435          | 127.41                      | 0.719 | 0.452          | 0.770 | 0.116 | 0.629* Silicos-IT_Log P + 1.134 |
| <b>SLogP</b>                | 0.844 | 0.336          | 243.46                      | 0.833 | 0.348          | 0.769 | 0.116 | 0.821*SLogP + 0.027             |
| <b>WLOGP</b>                | 0.845 | 0.335          | 245.32                      | 0.834 | 0.347          | 0.770 | 0.116 | 0.822*WLogP + 0.024             |
| <b>XLOGP3</b>               | 0.834 | 0.346          | 226.08                      | 0.819 | 0.362          | 0.751 | 0.121 | 0.679*XLogP3 + 0.667            |
| <b>LogSw</b>                |       |                |                             |       |                |       |       |                                 |
| <b>Ali_LogS</b>             | 0.667 | 0.491          | 90.14                       | 0.639 | 0.511          | 0.520 | 0.218 | -0.845*Ali_LogS – 0.401         |
| <b>ESOL_Log S</b>           | 0.835 | 0.346          | 227.73                      | 0.822 | 0.360          | 0.771 | 0.128 | -0.941*ESOL_LogP – 0.628        |
| <b>Silicos-IT_LogSw</b>     | 0.611 | 0.531          | 70.68                       | 0.581 | 0.552          | 0.449 | 0.237 | -0.505*Silicos-IT_LogSw + 0.669 |
| <b>ALOGpS</b>               | 0.688 | 0.476          | 99.23                       | 0.666 | 0.492          | 0.552 | 0.214 | -0.787*ALOGpS – 0.047           |
|                             |       |                |                             |       |                |       |       |                                 |
| <b>Resultados esperados</b> | > 0.6 | Menor possível | Maior 4.05 (p=1 e n-p-1=45) | > 0.5 | Menor possível | > 0.5 | < 0.3 |                                 |

Entretanto, avaliar a qualidade da predição interna e os demais parâmetros de qualidade utilizadas nesta etapa não são suficientes para garantir que o modelo esteja adequado para predição. Somente modelos validados externamente podem ser considerados adequados para fins de previsão e, em sua essência, o objetivo final de qualquer modelo QSAR/QSPR é a sua aplicação na predição de compostos ainda não testados em relação a variável *y* de interesse ou que não tenham sido utilizados na sua obtenção (Wold & Eriksson, 1998; Papa, Dearden & Gramatica, 2007; Roy, 2007) Importante observar que, enquanto os parâmetros principais da validação interna,  $R^2$  e  $Q^2_{LOO}$ , são diretamente relacionados, o mesmo não é verdade para os parâmetros de validação externa, sendo estudo independente, o que pode levar a resultados inferiores ou até consideravelmente superiores do que os obtidos internamente (van Drie, 2003)

Na Tabela 4 são apresentados os resultados da validação externa para as regressões univariadas, assim como os valores limites dos parâmetros utilizados. Surpreendentemente, apenas um algoritmo foi aprovado em todos os critérios estatísticos adotados: MLogP. É interessante observar que este método não apresenta as melhores métricas entre as adotadas para validação interna. Já para LogS, apenas ESOL\_LogS apresenta uma mínima, expressa pelo seu  $R^2_{pred}$ = 0.528, embora tenha sido reprovado em diversos outros parâmetros. Este resultado preliminar ajuda a mostrar a importância da validação externa em estudos QSPR.

| <b>Tabela 4.</b> Parâmetros estatísticos da validação externa dos modelos QSAR construídos com diferentes descritores de LogP e LogS |                                      |                                       |                |                                                 |             |             |                                                    |                                                    |
|--------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------|---------------------------------------|----------------|-------------------------------------------------|-------------|-------------|----------------------------------------------------|----------------------------------------------------|
| <b>Algoritmo</b>                                                                                                                     | <b><math>n_{\text{teste}}</math></b> | <b><math>R^2_{\text{pred}}</math></b> | <b>RMSEP</b>   | <b><math> R^2_0 - R^2_{\text{pred}} </math></b> | <b>k</b>    | <b>k'</b>   | <b><math>\Delta r^2(\text{pred})</math>-scaled</b> | <b><math>\Delta r^2(\text{pred})</math>-scaled</b> |
| <b>LogP</b>                                                                                                                          |                                      |                                       |                |                                                 |             |             |                                                    |                                                    |
| <b>Experimental LogP</b>                                                                                                             | 12                                   | 0.952                                 | 0.156          | 0.033                                           | 0.997       | 0.999       | 0.787                                              | 0.083                                              |
| <b>AcLogP</b>                                                                                                                        | 12                                   | 0.681                                 | 0.402          | 0.405                                           | 0.915       | 0.915       | 0.256                                              | 0.256                                              |
| <b>ALOGP</b>                                                                                                                         | 12                                   | 0.637                                 | 0.429          | 0.469                                           | 0.920       | 1.062       | 0.163                                              | 0.219                                              |
| <b>ALOGPs</b>                                                                                                                        | 12                                   | 0.685                                 | 0.400          | 0.068                                           | 0.912       | 1.078       | 0.357                                              | 0.199                                              |
| <b>iLOGP</b>                                                                                                                         | 12                                   | -0.422                                | 0.850          | 0.286                                           | 0.782       | 1.223       | 0.008                                              | 0.032                                              |
| <b>logPow</b>                                                                                                                        | 12                                   | 0.670                                 | 0.409          | 0.047                                           | 0.906       | 1.084       | 0.409                                              | 0.122                                              |
| <b>miLogP</b>                                                                                                                        | 12                                   | 0.754                                 | 0.353          | 0.016                                           | 0.923       | 1.068       | 0.470                                              | 0.173                                              |
| <b>MLOGP</b>                                                                                                                         | 12                                   | 0.889                                 | 0.238          | 0.073                                           | 0.942       | 1.056       | 0.799                                              | 0.070                                              |
| <b>Silicos-IT_Log P</b>                                                                                                              | 12                                   | 0.218                                 | 0.630          | 0.193                                           | 0.851       | 1.132       | 0.109                                              | 0.060                                              |
| <b>SLogP</b>                                                                                                                         | 12                                   | 0.523                                 | 0.492          | 0.263                                           | 0.900       | 1.080       | 0.121                                              | 0.130                                              |
| <b>WLOGP</b>                                                                                                                         | 12                                   | 0.525                                 | 0.491          | 0.264                                           | 0.900       | 1.079       | 0.122                                              | 0.131                                              |
| <b>XLOGP3</b>                                                                                                                        | 12                                   | 0.574                                 | 0.465          | 0.014                                           | 0.891       | 1.099       | 0.290                                              | 0.159                                              |
| <b>LogSw</b>                                                                                                                         |                                      |                                       |                |                                                 |             |             |                                                    |                                                    |
| <b>Ali_LogS</b>                                                                                                                      | 12                                   | 0.231                                 | 0.625          | 0.167                                           | 0.872       | 1.097       | 0.000                                              | 0.003                                              |
| <b>ALOGpS</b>                                                                                                                        | 12                                   | 0.285                                 | 0.603          | 0.298                                           | 0.854       | 1.134       | 0.075                                              | 0.124                                              |
| <b>ESOL_LogS</b>                                                                                                                     | 12                                   | 0.528                                 | 0.489          | 0.451                                           | 0.898       | 1.083       | 0.108                                              | 0.164                                              |
| <b>Silicos-IT_LogSw</b>                                                                                                              | 12                                   | -0.077                                | 0.740          | 0.297                                           | 0.818       | 1.169       | 0.063                                              | 0.045                                              |
|                                                                                                                                      |                                      |                                       |                |                                                 |             |             |                                                    |                                                    |
| <b>Resultados esperados</b>                                                                                                          |                                      | > 0.5                                 | Menor possível | < 0.3                                           | 0.85 – 1.15 | 0.85 – 1.15 | > 0.5                                              | < 0.3                                              |

O método MLogP, também conhecido como Moriguchi LogP, é um método desenvolvido com base em contribuições de uma série de fragmentos moleculares utilizados para a construção de um modelo QSPR formado por 13 variáveis. Segundo observado por Mannhold et al. (2009), métodos baseados em fragmentos são mais confiáveis para predição do LogP de compostos neutros. Além disso, alguns dos fragmentos utilizados neste algoritmo são exatamente relacionados com insaturações, metilas (-CH<sub>3</sub>), cloreto (-Cl) e substituintes polares (como -OH) além da relação entre subestruturas relacionadas a proximidade entre átomos de O e C (Todeschini & Consonni, 2009). Considerando o scaffold básico e o padrão de substituição dos difenis éteres, isto pode explicar o motivo do resultado superior da equação univariada com MLogP, mesmo com o fato deste algoritmo ter sido treinado com um conjunto de dados pequeno (1230 compostos) em comparação com outros métodos.


### 3.2 ANÁLISE MULTIVARIADA

Utilizando a metodologia de seleção de variáveis OPS (Teofilo, Martins & Ferreira, 2009), foram selecionados quatro descritores moleculares que, por sua vez, deram origem a duas LVs que acumularam 83.47% de informação (LV1: 68.86%; LV2: 14.61%) No modelo construído para a previsão do coeficiente de sorção no solo foram. A validação interna apresenta bons resultados, com coeficientes de determinação praticamente

idênticos ( $R^2 = 0.817$  e  $Q^2_{\text{LOO}} = 0.777$ ), com erros associados muito baixos (RMSEC= 0.364; RMSECV= 0.402). A estatística F calculada (194.44) foi muito superior ao valor crítico da tabela (3.21), a 95% de confiança,  $\alpha = 0,05$ , indicando alta significância estatística do modelo de regressão. Já na figura 2 são apresentados os resultados dos testes de validação cruzada LNO e do teste de Y-randomization.

$$\text{Log}K_{\text{oc}} = 2.941 - 0.188*(\text{nO}) + 0.149*(\text{CATS2D\_07\_LL}) + 0.039*(\text{CATS2D\_02\_LL}) + 0.950*(\text{B05[O-CI]}) \quad (1)$$

$n_{\text{training}} = 47$ ;  $R^2 = 0.817$ ; RMSEC= 0.364;  $F_{95\%} = 196.44$  (valor tabelado: 3.21);  $Q^2_{\text{LOO}} = 0.777$ ; RMSECV= 0.402;  $\text{Av\_}r^2(\text{LOO})\text{-scaled} = 0.678$ ;  $\Delta r^2(\text{LOO})\text{-scaled} = 0.146$ ;  $n_{\text{test}} = 12$ ;  $R^2_{\text{pred}} = 0.955$ ; RMSEP= 0.151;  $\text{Av\_}r^2(\text{pred})\text{-scaled} = 0.837$ ;  $\Delta r^2(\text{pred})\text{-scaled} = 0.088$ ;  $k = 1.002$ ;  $k' = 0.995$ ; módulo= 0.013;  $\text{Av\_}r^2(\text{overall})\text{-scaled} = 0.712$ ;  $\Delta r^2(\text{overall})\text{-scaled} = 0.116$



**Figura 2.** Gráficos obtidos com os testes de validação cruzada LNO (A) e de y-randomization (B) para o Modelo 1.

O mesmo pode ser observado quanto aos resultados da validação externa, que também apresenta  $R^2_{\text{pred}}$  (0.891) e RMSEP (0.149). Embora os resultados sejam considerados bons no que se refere aos critérios estatísticos adotados para modelos QSPR, o modelo 1 não pode ser considerado superior em termos de qualidade interna quanto a maioria dos modelos univariados construídos com os diversos LogP, e com ESOL\_LogS. Já quanto a validação externa, o modelo apresenta uma boa capacidade de predição, porém ainda inferior a regressão univariada com MLogP.

Os descritores selecionados apresentam os seguintes valores absolutos para seus coeficientes autoescalados:  $|0.419|$  para B05[O-CI] >  $|0.314|$  para nO >  $|0.282|$  para CATS2D\_07\_LL >  $|0.076|$  para CATS2D\_02\_LL. Considerando a descrição apresentada na Tabela 5, é interessante observar que, de algum modo, todos codificam a importância da polaridade para descrever a variável dependente de interesse. Pode-se dar algum destaque B05[O-CI], o mais importante, e relacionado diretamente com cloro, que tende a aumentar a lipofilicidade de uma molécula, e nO, o segundo mais importante, que literalmente corresponde ao número de oxigênios em uma molécula (representando principalmente o número de grupos -OCH<sub>3</sub> e -OH), e diretamente relacionado a uma redução da lipofilicidade. Isto fortalece a proposta de se avaliar se os descritores relacionados a partição óleo/água ou solubilidade em água podem inserir novas informações e melhorar a qualidade geral do modelo.

| Tabela 5. Descritores selecionados para o modelo 1 |                                                      |                            |                                                                                                       |
|----------------------------------------------------|------------------------------------------------------|----------------------------|-------------------------------------------------------------------------------------------------------|
| Descritor                                          | Definição                                            | Classe                     | Interpretação                                                                                         |
| nO                                                 | Number of Oxygen atoms                               | Constitutional descriptors | Aumento do número de oxigênios reduz LogKoc                                                           |
| CATS2D_07_LL                                       | CATS2D Lipophilic-Lipophilic at lag 07               | CATS2D Fingerprints        | Aumento do número de grupos lipofílicos a sete <i>topological paths</i> de distância aumenta o LogKoc |
| CATS2D_02_LL                                       | CATS2D Lipophilic-Lipophilic at lag 02               | CATS2D Fingerprints        | Aumento do número de grupos lipofílicos a dois <i>topological paths</i> de distância aumenta o LogKoc |
| B05[O-Cl]                                          | Presence/absence of O - Cl at topological distance 5 | 2D Atom Pairs              | Aumento número de oxigênios e cloro a cinco <i>topological paths</i> aumenta a atividade              |

### 3.3 ANÁLISE MULTIVARIADA COM LogP E LogS SELECIONADOS


Visando avaliar o impacto dos dois descritores de partição selecionados através das análises multivariadas, os parâmetros MLogP e ESOL\_LogS foram adicionados a matriz de dados do modelo 1 para gerar outros dois modelos. O modelo 2, com MLogP, foi formado com quatro LVs que acumularam 93.71% de informação (LV1: 71.96%; LV2: 11.06%; LV3: 7.19%; LV4: 3.50%). Já o modelo 3 também apresenta quatro LVs que acumularam 95.81% de informação (LV1: 69.31%; LV2: 10.51%; LV3: 9.44%; LV4: 6.56%). Os resultados dos testes de robustez de presença de correlação ao acaso são apresentados na Figura 3.

$$\text{LogK}_{oc} = 1.351 - 0.04*(nO) + 0.052*(CATS2D\_07\_LL) - 0.014*(CATS2D\_02\_LL) + 0.595*(B05[O-Cl]) + 0.557*(MLogP) \quad (2)$$

$n_{\text{training}} = 47$ ;  $R^2 = 0.910$ ;  $RMSEC = 0.255$ ;  $F_{95\%} = 424.67$  (valor tabelado: 2.61);  $Q^2_{\text{LOO}} = 0.876$ ;  $RMSECV = 0.299$ ;  $Av\_r^2(\text{LOO})\text{-scaled} = 0.829$ ;  $\Delta r^2(\text{LOO})\text{-scaled} = 0.058$ ;  $n_{\text{test}} = 12$ ;  $R^2_{\text{pred}} = 0.957$ ;  $RMSEP = 0.146$ ;  $Av\_r^2(\text{pred})\text{-scaled} = 0.903$ ;  $\Delta r^2(\text{pred})\text{-scaled} = 0.003$ ;  $k = 0.968$ ;  $k' = 0.1.031$ ;  $|R^2_0 - R'^2_0| = 0.009$ ;  $Av\_r^2(\text{overall})\text{-scaled} = 0.843$ ;  $\Delta r^2(\text{overall})\text{-scaled} = 0.074$ .

$$\text{LogK}_{oc} = 1.714 - 0.242*(nO) + 0.033*(CATS2D\_07\_LL) - 0.044*(CATS2D\_02\_LL) + 0.307*(B05[O-Cl]) - 0.564*(ESOL\_LogS) \quad (3)$$

$n_{\text{training}} = 47$ ;  $R^2 = 0.917$ ;  $RMSEC = 0.245$ ;  $F_{95\%} = 464.02$  (valor tabelado: 2.61);  $Q^2_{\text{LOO}} = 0.884$ ;  $RMSECV = 0.290$ ;  $Av\_r^2(\text{LOO})\text{-scaled} = 0.839$ ;  $\Delta r^2(\text{LOO})\text{-scaled} = 0.063$ ;  $n_{\text{test}} = 12$ ;  $R^2_{\text{pred}} = 0.936$ ;  $RMSEP = 0.181$ ;  $Av\_r^2(\text{pred})\text{-scaled} = 0.746$ ;  $\Delta r^2(\text{pred})\text{-scaled} = 0.109$ ;  $k = 0.957$ ;  $k' = 1.041$ ;  $|R^2_0 - R'^2_0| = 0.021$ ;  $Av\_r^2(\text{overall})\text{-scaled} = 0.837$ ;  $\Delta r^2(\text{overall})\text{-scaled} = 0.088$ .



**Figura 3.** Gráficos obtidos com os testes de validação cruzada LNO e de y-randomization para os Modelos 2 (A e B) e 3 (C e D).

Os modelos 2 e 3 apresentaram uma boa melhora na qualidade estatística da validação interna em relação ao modelo 1. Já a validação externa do modelo 2 apresenta equivalência, com  $R^2_{pred}$  apenas 0.002 unidades acima, enquanto o modelo 3 apresenta uma pequena piora neste sentido, com redução de 0.019 unidades. Considerando alguns resultados numericamente equivalentes, neste ponto foram utilizados os parâmetros  $Av\_r^2(LOO)$ -scaled e  $\Delta r^2(LOO)$ -scaled para selecionar o mais adequado Roy et al. (2009). Considerando os resultados, ambos os modelos 2 e 3 são superiores a qualidade global do modelo 1. Entretanto, quando comparados entre si, ambos apresentam estatísticas muito parecidas, sendo 2 um pouco superior na validação interna e 3 um pouco superior na validação externa. Embora a validação externa talvez seja o ponto mais importante a se considerar, as estatísticas RmSquare Overall ajudam a sanar as dúvidas, confirmando que o modelo 3 apresenta a melhor qualidade global de predição. Esta melhora parece fazer sentido, já informações complementares relacionadas a lipofilicidade foram inseridas no modelo pelo uso de MLogP, o algoritmo que levou a melhor equação univariada.

Já modelo 3, obtido com a adição de ESOL\_LogS, apresenta uma ótima qualidade estatística, porém inesperada no quando comparado com seu respectivo modelo univariado. Este método considera propriedades da molécula completa, incluindo lipossolubilidade, peso molecular, e outras propriedades comumente utilizados em QSPR, e 2874 compostos neutros no pH= 7. Estes dados foram utilizados no treinamento de um modelo de predição de LogS por regressão linear múltipla (MLR). Um ponto interessante sobre este método é que ele foi avaliado perante compostos agroquímicos, e mostrou-se um bom grau de acerto para este tipo de agentes (Delaney, 2004), o que pode explicar em parte o motivo de seu uso gerar um bom modelo multivariado.

Este fenômeno pode ser considerado relativamente comum em calibração multivariada: variáveis que, de modo independente, geram bons modelos, quando combinados com outras variáveis podem gerar modelos ruins,

e vice-versa (Dearden, Cronin & Kaiser, 2009). Isto indica que, ao menos para modelagem de LogKoc, uma propriedade que apresenta grande relação com coeficientes de partição e com solubilidade em água, a escolha no método de derivação teórica destas propriedades deve ser investigada de modo mais aprofundado, caso a caso. Resultados obtidos anteriormente reforçam esta hipótese (dos Reis, Sampaio e de Melo, 2013).

### 3.4 ANÁLISES UNIVARIADAS E MULTIVARIADA COM PARÂMETROS LogSp.

A partir dos resultados obtidos nas etapas anteriores, os algoritmos MLogP e ESOL\_LogS foram selecionados para a obtenção de um parâmetro LogSp específico para este conjunto de dados, denominado New\_LogSp. Além disso, também foi calculado para todos os compostos o parâmetro LogSp conforme proposto originalmente (dos Reis, Sampaio & de Melo, 2014), ou Original\_LogSp, utilizando os algoritmos ALOGPs e ALOGpS.

Na tabela 6 são apresentados as regressões univariadas construídas com estes parâmetros e seus resultados para validação interna e externa. Pode ser observado que New\_LogSp apresenta qualidade estatística levemente superior a regressão univariada obtida com Original\_LogSp, com  $R^2_{pred}$  0.057 unidades superior. Entretanto, este último foi reprovado nas estatísticas Average\_ $r^2m(pred)$ -scaled e  $k'$ , enquanto New\_LogSp foi reprovado apenas no teste  $\Delta r^2m(pred)$ -scaled. No contexto deste estudo, este resultado também faz sentido considerando que MLogP gerou a melhor regressão univariadas (Tabela 6) do que ALOGPs e ALOGpS, respectivamente. Ainda assim, considerando os testes onde as regressões foram reprovadas, ambas não podem ser consideradas adequadas para uso como ferramentas de predição.

| <b>Tabela 6.</b> Modelos de predição usando os LogP e LogSw selecionados, suas respectivas equações QSPR univariadas, e métricas de validação interna |                                |                          |
|-------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------|--------------------------|
| <b>Equation</b>                                                                                                                                       | - 0.378*Original_LogSp + 0.219 | -0.405*New_LogSp + 0.447 |
| <b>Parâmetro</b>                                                                                                                                      |                                |                          |
| <b>Internal validation</b>                                                                                                                            |                                |                          |
| $n_{training}$                                                                                                                                        | 47                             | 47                       |
| $R^2$                                                                                                                                                 | 0.822                          | 0.879                    |
| $RMSEC$                                                                                                                                               | 0.359                          | 0.296                    |
| $F_{95\%}$ (valor tabelado: 4.05)                                                                                                                     | 207.859                        | 326.554                  |
| $Q^2_{Loo}$                                                                                                                                           | 0.809                          | 0.867                    |
| $RMSECV$                                                                                                                                              | 0.372                          | 0.311                    |
| $Av\_r^2(LOO)$ -scaled                                                                                                                                | 0.754                          | 0.815                    |
| $\Delta r^2(LOO)$ -scaled                                                                                                                             | 0.137                          | 0.085                    |
| <b>External validation</b>                                                                                                                            |                                |                          |
| $n_{test}$                                                                                                                                            | 12                             | 12                       |
| $R^2_{pred}$                                                                                                                                          | 0.541                          | 0.677                    |
| $RMSEP$                                                                                                                                               | 0.483                          | 0.405                    |
| $Av\_r^2(pred)$ -scaled                                                                                                                               | 0.219                          | 0.464                    |
| $\Delta r^2(pred)$ -scaled                                                                                                                            | 0.178                          | 0.268                    |
| $k$                                                                                                                                                   | 0.888                          | 0.894                    |

|                    |       |       |
|--------------------|-------|-------|
| $k'$               | 1.099 | 1.104 |
| $ R^2_0 - R'^2_0 $ | 0.119 | 0.044 |


Na sequência, foram avaliados os modelos multivariados 4 e 5 obtidos, respectivamente, com a adição de Original\_LogSp e New\_LogSp ao modelo 1. O modelo 4 foi formado por três VLs que acumularam 89,69% de informação (LV1: 66.66%; LV2: 12.31%; LV3: 10.72%), enquanto o modelo 5 foi formado por quatro VLs que acumularam 94.94% de informação (LV1: 71.72%; LV2: 10.25%; LV3: 8.17%; LV4: 4.81%). Os resultados dos testes de validação cruzada LNO e y-randomization para os modelos 4 e 5 são apresentados na Figura 4. Mesmo considerando a melhoria da qualidade estatística em relação ao modelo original, os valores ainda são próximos aos modelos 2 e 3, os resultados indicam que o uso de LogSp levou a uma melhoria da qualidade de predição. Dentre estes dois modelos, destaca-se 4, que apresenta valores superiores para R<sup>2</sup>, Q<sup>2</sup>LOO e R<sup>2</sup>pred. De todos os modelos obtidos neste estudo, este foi o único que apresenta estes principais parâmetros de qualidade acima de 0.9, e por este motivo pode ser considerado o melhor entre todos.

$$\text{Log}K_{oc} = 1.565 - 0.150 \cdot (nO) + 0.106 \cdot (\text{CATS2D\_07\_LL}) - 0.002 \cdot (\text{CATS2D\_02\_LL}) + 0.327 \cdot (\text{B05[O-Cl]}) - 0.224 \cdot (\text{Original\_LogSp}) \quad (4)$$

$n_{\text{training}} = 47$ ;  $R^2 = 0.946$ ;  $RMSEC = 0.197$ ;  $F_{95\%} = 753.30$  (valor tabelado: 2.84);  $Q^2_{\text{LOO}} = 0.928$ ;  $RMSECV = 0.228$ ;  $\text{Av\_}r^2(\text{LOO})\text{-scaled} = 0.899$ ;  $\Delta r^2(\text{LOO})\text{-scaled} = 0.042$ ;  $n_{\text{test}} = 12$ ;  $R^2_{\text{pred}} = 0.948$ ;  $RMSEP = 0.162$ ;  $\text{Av\_}r^2(\text{pred})\text{-scaled} = 0.858$ ;  $\Delta r^2(\text{pred})\text{-scaled} = 0.012$ ;  $k = 0.971$ ;  $k' = 1.026$ ;  $|R^2_0 - R'^2_0| = 0.010$ ;  $\text{Av\_}r^2(\text{overall})\text{-scaled} = 0.901$ ;  $\Delta r^2(\text{overall})\text{-scaled} = 0.056$

$$\text{Log}K_{oc} = 1.278 - 0.076 \cdot (nO) + 0.038 \cdot (\text{CATS2D\_07\_LL}) - 0.032 \cdot (\text{CATS2D\_02\_LL}) + 0.394 \cdot (\text{B05[O-Cl]}) - 0.314 \cdot (\text{New\_LogSp}) \quad (5)$$

$n_{\text{training}} = 47$ ;  $R^2 = 0.925$ ;  $RMSEC = 0.233$ ;  $F_{95\%} = 518.00$  (valor tabelado: 2.61);  $Q^2_{\text{LOO}} = 0.895$ ;  $RMSECV = 0.276$ ;  $\text{Av\_}r^2(\text{LOO})\text{-scaled} = 0.854$ ;  $\Delta r^2(\text{LOO})\text{-scaled} = 0.057$ ;  $n_{\text{test}} = 12$ ;  $R^2_{\text{pred}} = 0.884$ ;  $RMSEP = 0.243$ ;  $\text{Av\_}r^2(\text{pred})\text{-scaled} = 0.585$ ;  $\Delta r^2(\text{pred})\text{-scaled} = 0.195$ ;  $k = 0.937$ ;  $k' = 1.061$ ;  $|R^2_0 - R'^2_0| = 0.080$ ;  $\text{Av\_}r^2(\text{overall})\text{-scaled} = 0.846$ ;  $\Delta r^2(\text{overall})\text{-scaled} = 0.079$



**Figura 4.** Gráficos obtidos com os testes de validação cruzada LNO e de y-randomization para os Modelos 4 (A e B) e 5 (C e D).

Consultados os coeficientes autoescalados dos modelos, pode-se observar que Original\_LogSp apresenta uma importância consideravelmente maior do que os outros descritores do modelo 4, com  $|0.538|$  para Original\_LogSp,  $|0.250|$  para nO,  $|0.202|$  para CATS2D\_07\_LL,  $|0.145|$  para B05[O-Cl], e  $|0.003|$  para CATS2D\_02\_LL. Além disso, considerando os sinais dos coeficientes, compostos com maiores valores de nO e CATS2D\_02\_LL tendem a levar a compostos com menor LogKoc (ou seja, de ficar menos retido no solo), enquanto compostos com CATS2D\_07\_LL e B05[O-Cl] maiores tendem a ficar mais retidos no solo. Como os dois primeiros estão mais relacionados a uma maior polaridade (especialmente nO, o segundo mais importante do modelo), e os dois últimos a uma menor polaridade, esta interpretação faz sentido no contexto avaliado.

Porém, além da qualidade estatística superior, o resultado mais interessante seja a qualidade superior do modelo 4 em relação a 5, considerando os resultados das regressões univariadas de ALOGPs, ALOGpS, Original\_LogSp e New\_LogSp. É possível que, enquanto as informações codificadas nos dois primeiros tenham se complementado, gerando um descritor Original\_LogSp que pode explicar melhor o fenômeno de sorção, e assim complementando as informações codificadas nos outros descritores, o mesmo não ocorreu quando MLogP e ESOL\_LogS foram combinados, já que, por serem métodos construídos com bancos de dados diferentes, não se complementam. Claro, o modelo 5 também apresenta uma ótima qualidade estatística, e é adequado para fins de predição, porém com uma menor confiabilidade, como pode ser observado pelos valores de AveragePred (0.585) e DeltaPred (0.195) que se encontram próximos de seus respectivos valores de limite.

Outro ponto a considerar é que, mesmo que ALOGpS e ALOGPs não tenham sido os algoritmos que geraram os melhores modelos univariados, é importante lembrar que o banco de dados usado em sua concepção

é dos maiores da literatura (12908 compostos). Isto com certeza resulta em um maior espaço químico sendo representado quando da derivação teórica de LogP e LogS. Resultado semelhante já foi observado em estudo anterior (Zhang et al., 2015) o que justificou o uso destes dois parâmetros para a derivação de Original\_LogSp (dos Reis, Sampaio & de Melo, 2014).

Entretanto, é importante observar que no estudo original ALOGPs e ALOGpS também geraram bons modelos univariados ( $R^2=0.744$ ,  $Q^2_{LOO}=0.735$  e  $R^2_{pred}=0.768$  para o primeiro;  $R^2=0.788$ ,  $Q^2_{LOO}=0.782$  e  $R^2_{pred}=0.708$ ). Isto provavelmente deveu-se ao banco de dados utilizado para desenvolver estes métodos ser consideravelmente maior e estruturalmente diverso (Tetko e Tanchuk, 2002). Esta situação é diferente do presente estudo, em que MLogP, mesmo com um dos menores bancos de dados, foi o que gerou o melhor resultado de validação externa entre os modelos univariados, estando mais próximo do valor de  $R^2_{pred}$  obtido com a regressão construída com o LogKoc experimental. Mesmo que os valores de  $R^2_{pred}$  e  $Q^2_{LOO}$  tenham ficado inferiores, este algoritmo pode ser considerado como o mais adequado para uso individual no cálculo de LogKoc de éteres difenílicos.

Muitos estudos QSPR já realizados para predição de LogKoc indicam que não existe um método mais adequado para derivação do LogP. Já estão descritos modelos com algoritmos como o KOWWIN (Olguín, Sampaio e dos Reis, 2017), ACDLogP (Petrauskas e Kolovanov, 2000), miLogP (Schüürmann et al., 2014), ALOGPs (Olguín et al., 2019), XLogP3 (Olguín, Sampaio e dos Reis, 2017) dentre outros. Da mesma forma, o método MLogP e seu valor ao quadrado, MLogP2, também já foram descritos (Shao et al., 2015; Olguín, Sampaio e dos Reis, 2017). Ainda assim, MLogP não supera, em termos de qualidade global, os resultados da equação multivariada obtida com Original\_LogSp, o único que apresenta os principais parâmetros de validação acima de 0.9. A combinação entre este descritor misto e os descritores relacionados a tipos e combinações de átomos complementaram-se, gerando a melhor qualidade global, mesmo que individualmente ALOGPs e ALOGsP não tenham gerado bons resultados na validação externa de seus modelos univariados. O mesmo não pode ser dito para New\_LogSp, provavelmente porque o ESOL\_LogS não possui as informações químicas adequadas para complementar aquelas presentes em MLogP quando da derivação de New\_LogSp.

Como complemento, existe mais um ponto a se considerar em relação ao modelo 4: diferente dos modelos 2, 3 e 5, foram necessárias apenas três LVs para obter a melhor qualidade estatística. De modo geral, modelos QSPR com menor número de variáveis, sejam descritores inalterados ou variáveis obtidas por métodos de projeção, são mais desejáveis, pois são mais fáceis de interpretar e mais robustos, quando alcança uma performance equivalente ou superior a outros modelos com maior número de LVs/informação, pode indicar que ele modela menos ruído ou informações pouco relevantes (Wold et al., 2001).

#### 4. CONCLUSÃO

Os resultados deste estudo com éteres difenílicos ajudaram a fortalecer a hipótese proposta em estudos anteriores de que a escolha do algoritmo mais adequado para a derivação dos descritores moleculares LogP e LogS afeta o resultado final de um estudo QSPR que possua como objetivo a predição do LogKoc. A qualidade da modelagem realmente precisa ser avaliada caso a caso, com indicações de que a melhor representação de diferentes conjuntos de dados depende não do tamanho do banco de dados utilizado na construção do algoritmo,

mas sim na informação química codificada nos mesmos. Esta conclusão fica clara quando o melhor resultado para os modelos univariados foi obtido com MLogP, um método baseado em fragmentos que utiliza um conjunto de dados pequeno quando comparado com outros métodos.

Da mesma forma, o mesmo não pode ser dito quando se fala de modelos QSPR multivariados. No caso estudados, tudo indica que a interdependência das informações codificadas nos demais descritores utilizados para construção dos modelos inserem algum tipo de ruído na modelagem quando é utilizado MLogP, ao mesmo tempo que complementam as informações codificadas em ESOL\_LogS, levando a um modelo qualidade superior, diferente do esperado.

Finalmente, o uso da abordagem LogSp, anteriormente proposta, parece indicar que a combinação de descritores de LogP e LogS para gerar um descritor misto leva a uma melhoria do desempenho predito global para os modelos QSPR de sorção de solo de éteres difenílicos. Neste caso, o resultado obtido mostra-se alinhado com o que foi observado anteriormente, já que os descritores ALOGPs e ALOGpS, obtidos através do algoritmo ALOGPS 2.1, levou ao melhor modelo em termos de qualidade global de todo o estudo. Assim, a proposta observada de que a escolha do melhor algoritmo para derivação teórica de LogP e/ou LogS para uso na modelagem de LogKoc não deve ser arbitrária, mas sim devem ser avaliados diferentes algoritmos que codificam diferentes tipos de informação química, especialmente quando se considera o quanto parâmetros relacionados a lipofilicidade e hidrofiliicidade são relevantes para esta propriedade de grande interesse ambiental. Estudos a serem realizados com outros conjuntos de dados com LogKoc determinados experimentalmente, estruturalmente congêneres ou não, ajudarão a avaliar de modo mais aprofundado esta hipótese.

## AGRADECIMENTOS

Fundação Araucária (bolsa 2010/7354); DS/CAPES (Bolsa de Mestrado para N.A.B.R.S.) e Programas PROAP/CAPES; PPGQUI-UNIOESTE.

## REFERENCIAS

- Ali, J., 2012. In silico prediction of aqueous solubility using simple QSPR models. *Journal of Chemical Information and Modeling*, 52(9), pp.2301–2309. <https://doi.org/10.1021/ci300447c>
- Alharbi, O.M.L. et al., 2018. Health and environmental effects of persistent organic pollutants. *Journal of Molecular Liquids*, 263, pp.442–453. <https://doi.org/10.1016/j.molliq.2018.05.029>
- Alves, V.M., Braga, R.C., Muratov, E.N., Andrade, C.H., 2018. Quimioinformática: uma introdução. *Química Nova*, 41(2), pp.202–212. <https://doi.org/10.21577/0100-4042.20170145>
- Benfenati, E., 2012. Theory, guidance and applications on QSAR and REACH. 1st ed. Milano, Italy: Istituto di Ricerche Farmacologiche “Mario Negri”.
- Cheng, T. et al., 2007. Computation of octanol water partition coefficients by guiding an additive model with knowledge. *Journal of Chemical Information and Modeling*, 47(6), pp.2140–2148. <https://doi.org/10.1021/ci700257y>
- Daina, A., Michielin, O., Zoete, V., 2014. iLOGP: a simple, robust, and efficient description of n-octanol/water partition coefficient for drug design using the GB/SA approach. *Journal of Chemical Information and Modeling*,

54(12), pp.3284–3301. <https://doi.org/10.1021/ci500467k>

Dearden, J.C., Cronin, M.T.D., Kaiser, K.L.E., 2009. How not to develop a quantitative structure–activity or structure–property relationship (QSAR/QSPR). *SAR and QSAR in Environmental Research*, 20(3–4), pp.241–266. <https://doi.org/10.1080/10629360902949567>

Delaney, J.S., 2004. ESOL: Estimating aqueous solubility directly from molecular structure. *Journal of Chemical Information and Computer Sciences*, 44, pp.1000–1005. <https://doi.org/10.1021/ci034243x>

Eriksson, L. et al., 2003. Multi- and megavariable data analysis part I: Basic principles and applications. *Chemometrics and Intelligent Laboratory Systems*, 87(2), pp.83–96. [https://doi.org/10.1016/S0169-7439\(03\)00035-5](https://doi.org/10.1016/S0169-7439(03)00035-5)

Gaudio, A.C., Zandonade, E., 2001. Proposition, validation and analysis of QSAR models. *Química Nova*, 24, pp.658–671. <https://doi.org/10.1590/S0100-40422001000500013>

Golbraikh, A. et al., 2003. Rational selection of training and test set for the development of validated QSAR models. *Journal of Computer-Aided Molecular Design*, 17(2–4), pp.241–253. <https://doi.org/10.1023/A:1025386326947>

Hou, T., Xu, X., 2002. ADME evaluation in drug discovery. 1. Applications of genetic algorithms to the prediction of blood–brain partitioning of a large set of drugs. *Journal of Molecular Modeling*, 8(12), pp.337–349. <https://doi.org/10.1007/s00894-002-0101-1>

Kiralj, R., Ferreira, M.M.C., 2009. Basic validation procedures for regression models in QSAR and QSPR studies: Theory and application. *Journal of the Brazilian Chemical Society*, 20(4), pp.770–787. <https://doi.org/10.1590/S0103-50532009000400021>

Mannhold, R., Poda, G.I., Ostermann, C., Tetko, I.V., 2009. Calculation of molecular lipophilicity: State-of-the-art and comparison of log P methods on more than 96,000 compounds. *Journal of Pharmaceutical Sciences*, 98(3), pp.861–893. <https://doi.org/10.1002/jps.21494>

Martins, J.P.A., Ferreira, M.M.C., 2013. Modelagem QSAR: um novo pacote computacional open source para gerar e validar modelos QSAR. *Química Nova*, 36(4), pp.554–560. <https://doi.org/10.1590/S0100-40422013000400013>

Mauri, A., Consonni, V., Todeschini, R., 2017. Molecular Descriptors. In: *Handbook of Computational Chemistry*, 1<sup>a</sup> ed., Suíça, pp.2065–2093. [https://doi.org/10.1007/978-3-319-27282-5\\_51](https://doi.org/10.1007/978-3-319-27282-5_51)

Olguin, C.J.M., Sampaio, S.C., Dos Reis, R.R., Remor, M.B., Olguin, C.F.A., 2019. QSPR modelling of the soil sorption coefficient from training sets of different sizes. *SAR and QSAR in Environmental Research*, 30(5), pp.299–311. <https://doi.org/10.1080/1062936X.2019.1586759>

Olguin, C.J.M., Sampaio, S.C., Dos Reis, R.R., 2017. Statistical equivalence of prediction models of the soil sorption coefficient obtained using different log P algorithms. *Chemosphere*, 184, pp.498–504. <https://doi.org/10.1016/j.chemosphere.2017.06.027>

Papa, E., Dearden, J.C., Gramatica, P., 2007. Linear QSAR regression models for the prediction of bioconcentration factors by physicochemical properties and structural theoretical molecular descriptors. *Chemosphere*, 67, pp.351–358. <https://doi.org/10.1016/j.chemosphere.2006.09.079>

Petrauskas, A.A., Kolovanov, E.A., 2000. ACD/Log P method description. *Perspectives in Drug Discovery and Design*, 19, pp.99–116. <https://doi.org/10.1023/A:1008719622770>

- Roy, K., 2007. *2D-QSAR: Quantitative structure-activity relationship in drug design*. Weinheim: Wiley-VCH.
- Roy, K., Mitra, I., 2012. On the use of the metric  $rm^2$  as an effective tool for validation of QSAR models in computational drug design and predictive toxicology. *Mini-Reviews in Medicinal Chemistry*, 12, pp.491–504. <https://doi.org/10.2174/138955712800493861>
- Roy, K. et al., 2013. Some case studies on application of “ $rm^2$ ” metrics for judging quality of QSAR predictions: Emphasis on scaling of response data. *Journal of Computational Chemistry*, 34, pp.1071–1082. <https://doi.org/10.1002/jcc.23231>
- Roy, P.P. et al., 2009. On two novel parameters for validation of predictive QSAR models. *Molecules*, 14, pp.1660–1701. <https://doi.org/10.3390/molecules14041660>
- Sander, T., 2010–2025. OSIRIS Property Explorer [Internet]. Allschwil, Switzerland: Idorsia Pharmaceuticals Ltd; c2010–2025. Available from: <https://www.organic-chemistry.org/prog/peo/> [cited 31 Jul 2025]
- Schüürmann, G. et al., 2014. Prediction of the Sorption of Organic Compounds into Soil: A Comparison of Different Models. *Bulletin of Environmental Contamination and Toxicology*, 92(2), pp.143–147. <https://doi.org/10.1007/s00128-013-1184-3>
- Shao, Y. et al., 2014. Integrated QSPR models to predict the soil sorption coefficient for a large diverse set of compounds by using different modeling methods. *Atmospheric Environment*, 88, pp.212–218. <https://doi.org/10.1016/j.atmosenv.2013.12.018>
- Tefilo, R.F., Martins, J.P., Ferreira, M.M.C., 2009. Sorting variables by using informative vectors as a strategy for feature selection in multivariate regression. *Journal of Chemometrics*, 23(1), pp.32–48. <https://doi.org/10.1002/cem.1192>
- Tetko, I.V., Tanchuk, V.Y., 2002. Application of associative neural networks for prediction of lipophilicity in ALOGPS 2.1 program. *Journal of Chemical Information and Computer Sciences*, 42(5), pp.1136–1145. <https://doi.org/10.1021/ci025515j>
- Tropsha, A., Gramatica, P., Gombar, V.K., 2003. The importance of being earnest: validation is the absolute essential for successful application and interpretation of QSPR models. *QSAR & Combinatorial Science*, 22(1), pp.69–77. <https://doi.org/10.1002/qsar.200390007>
- Van Drie, J., 2003. Pharmacophore discovery – lessons learned. *Current Pharmaceutical Design*, 9, pp.1649–1664. <https://doi.org/10.2174/1381612033454568>
- Viswanadhan, V.N., Reddy, S.R., Bacquet, R.J., Erion, M.D., 1993. Avaliação de métodos utilizados para predição de lipofilicidade: aplicação a nucleosídeos e bases nucleosídicas. *Journal of Computational Chemistry*, 14(9), pp.1026–1036. <https://doi.org/10.1002/jcc.540140903>
- Wang, Y. et al., 2015. In silico model for predicting soil organic carbon normalized sorption coefficient (KOC) of organic chemicals. *Chemosphere*, 119, pp.438–444. <https://doi.org/10.1016/j.chemosphere.2014.07.007>
- Wildman, S.A., Crippen, G.M., 1999. Prediction of physicochemical parameters by atomic contributions. *Journal of Chemical Information and Computer Sciences*, 39(5), pp.868–873. <https://doi.org/10.1021/ci990307l>
- Wold, S., Eriksson, L., 1998. Statistical validation of QSAR results. In: van de Waterbeemd, H. (Ed.). *Chemometric Methods in Molecular Design*. Weinheim: Wiley-VCH, pp.309–318.
- Wold, S., Sjöström, M., Eriksson, L., 2001. PLS-regression: a basic tool of chemometrics. *Chemometrics and Intelligent Laboratory Systems*, 58(2), pp.109–130. [https://doi.org/10.1016/S0169-7439\(01\)00155-1](https://doi.org/10.1016/S0169-7439(01)00155-1)

Zhang, X. et al., 2015. Experimental investigation on the soil sorption properties and hydrophobicity of polymethoxylated, polyhydroxylated diphenyl ethers and methoxylated-, hydroxylated-polychlorinated diphenyl ethers. *Chemosphere*, 134, pp.84–90. <https://doi.org/10.1016/j.chemosphere.2015.04.011>

Zhang, X. et al., 2018. QSPR modeling of the logKow and logKoc of polymethoxylated... methoxylated-, hydroxylated-polychlorinated diphenyl ethers. *Journal of Hazardous Materials*, 353, pp.542–551. <https://doi.org/10.1016/j.jhazmat.2018.03.043>

ACD/Labs. ChemSketch Freeware [Internet]; c2025. Available from: <https://www.acdlabs.com/resources/free-chemistry-software-apps/chemsketch-freeware/> [cited 28 May 2025]

DTC Lab. Software tools [Internet]; c2025. Available from: <http://dtclab.webs.com/software-tools> [cited 29 Jul 2025]

Molinspiration Cheminformatics. Free web services [Internet]. Slovensky Grob, Slovakia; c2025. Available from: <https://www.molinspiration.com> [cited 31 Jul 2025]

Silicos-it. Your partner in computational drug design [Internet]. Belgium; c2025. Available from: <https://www.silicos-it.be/> [cited 31 Jul 2025]

OChem.com. Organic Chemistry Help eMediately [Internet]; c2025. Available from: <https://www.ochem.com/> [cited 31 Jul 2025]