

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO DE CIÊNCIAS BÁSICAS DA SAÚDE
PROGRAMA DE PÓS-GRADUAÇÃO EM NEUROCIÊNCIAS

Gustavo Duarte Soroka

**MEMÓRIA DE TRABALHO MODULAR: MECANISMOS E
APLICAÇÕES NO PROCESSAMENTO DE LINGUAGEM**

Porto Alegre
2026

Gustavo Duarte Soroka

MEMÓRIA DE TRABALHO MODULAR: MECANISMOS E APLICAÇÕES NO PROCESSAMENTO DE LINGUAGEM

Tese apresentada ao Programa de Pós-Graduação em Neurociências do Instituto de Ciências Básicas da Saúde da Universidade Federal do Rio Grande do Sul como requisito parcial para a obtenção do título de doutor em Neurociências.

Orientador(a): Prof. Dr. Marco Aurélio Pires Idiart

Porto Alegre
2026

Agradecimentos

A realização desta tese só foi possível graças ao apoio e à presença de pessoas que caminharam comigo ao longo desta jornada.

Agradeço primeiramente à minha família, que sempre foi meu porto seguro. Pelo incentivo constante, pela compreensão nos momentos de ausência e cansaço, e pelo amor que sustenta e dá sentido a tudo que faço. Sem vocês, nada disso faria sentido.

Ao meu orientador, professor Marco Idiart, deixo minha sincera gratidão. Obrigado pela confiança, paciência, e pelas inúmeras conversas que ampliaram meus horizontes intelectuais. Sua orientação firme, generosa e curiosa foi fundamental não apenas para esta tese, mas para minha formação como pesquisador.

Ao Programa de Pós-Graduação em Neurociências, agradeço pelo ambiente fértil de aprendizado, troca e crescimento. Aqui encontrei colegas, professores e amigos que contribuíram profundamente para minha trajetória científica e pessoal.

Ao Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) e à Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES) pelo apoio financeiro concedido, fundamental para a realização deste trabalho.

Aos meus pais, Maurício e Oni, pelo apoio constante ao longo de toda a minha vida e durante o percurso do doutorado. Ao meu irmão, Vinícius, pelas muitas conversas e discussões sobre ciência que ajudaram a moldar meu pensamento.

E a Iasmin, minha companheira na vida e nas tempestades: obrigado por caminhar ao meu lado. Pelo carinho diário, pelas conversas que acalmaram a mente, pela escuta sensível e pelo amor que me sustentou quando as palavras faltavam. Você esteve presente em cada linha desta tese, mesmo sem aparecer nas páginas.

A todos vocês, meu mais profundo agradecimento.

Resumo

A memória de trabalho e a linguagem são funções cognitivas complexas do ser humano, a primeira definida como o armazenamento de informações por breves períodos de tempo, e a segunda como a capacidade de comunicação através da construção de sentenças com estruturas hierárquicas. Enquanto a primeira é compartilhada por vários outros animais, a segunda é inerentemente humana, abrindo espaço para questionamentos sobre o que no encéfalo dos seres humanos nos permite tal capacidade. Nós hipotetizamos que ambas funções estão relacionadas, sendo necessária então a descrição de um modelo de memória de trabalho que abranja os mecanismos e necessidades da linguagem. Aqui, propomos dois estudos: i) o primeiro define e descreve um modelo computacional de memória de trabalho de múltiplos itens, baseado nas oscilações alfa, teta e gama, que incorpora propriedades de modularidade e dinâmica espacial de ondas viajante; ii) o segundo propõe um processo mecanístico de construção de sentenças com estruturas hierárquicas através do método de agrupamento hierárquico, que poderia ser realizado dentro da arquitetura de memória de trabalho modular. Utilizamos simulações computacionais de redes de neurônios computacionais integra e dispora para mapear e descrever o modelo de memória de trabalho e o treinamento de redes neurais artificiais Transformer para propor a incorporação deste mecanismo de linguagem em uma rede neural. Nossos resultados descrevem um modelo de memória de trabalho de múltiplos itens baseado em oscilações cerebrais que incorpora e descreve pela primeira vez o papel mecanístico das oscilações alfa em prejudicar o armazenamento de informações e um processo mecanístico pelos quais informações podem ser agrupadas e construir representações de estruturas hierárquicas das sentenças. Futuros trabalhos deverão estudar o processo de construção de estrutura hierárquica em arquiteturas modulares com inspiração biológica.

Palavras-chave: memória de trabalho, linguagem, oscilações cerebrais, modularidade, estruturas hierárquicas, redes transformer, agrupamento hierárquico.

Abstract

Working memory and language are complex human cognitive functions: the former is defined as the storage of information for short periods of time, and the latter as the capacity for communication through the construction of sentences with hierarchical structure. While working memory is shared with various other animals, language is inherently human, raising questions about what features of the human brain enable such a capacity. We hypothesize that these two functions are related, making it necessary to describe a working memory model that encompasses the mechanisms and demands of language. Here, we propose two studies: (i) the first defines and describes a computational model of multi-item working memory based on alpha, theta, and gamma oscillations, incorporating properties of modularity and the spatial dynamics of traveling waves; (ii) the second proposes a mechanistic process for constructing sentences with hierarchical structure through the method of hierarchical clustering, which could be implemented within a modular working memory architecture. We use computational simulations of integrate-and-fire neural networks to map and characterize the working memory model, and we train Transformer artificial neural networks to explore how this language mechanism could be incorporated into a neural network. Our results describe a multi-item working memory model based on brain oscillations that, for the first time, mechanistically demonstrates the role of alpha oscillations in impairing information storage, as well as a mechanistic process by which information can be grouped to build hierarchical sentence structure representations. Future work should further investigate the process of hierarchical structure construction within biologically inspired modular architectures.

Keywords: working memory, language, brain oscillations, modularity, hierarchical structures, transformer networks, hierarchical clustering.

SUMÁRIO

LISTA DE FIGURAS	2
LISTA DE TABELAS	3
LISTA DE ABREVIATURAS	5
1 INTRODUÇÃO	7
1.1 Memória de Trabalho	7
1.2 Linguagem	9
1.3 A memória de trabalho como arquitetura para a linguagem	10
2 REFERENCIAL TEÓRICO	11
2.1 Memória de Trabalho	11
2.2 Modularidade e Dinâmica Espacial de Oscilações	13
2.3 Modelos Teóricos e Computacionais	13
2.3.1 Lapique	13
2.3.2 Integra e Dispara	14
2.3.3 Hodgkin & Huxley PFC L5	15
2.3.4 Lisman & Idiart	16
2.3.5 O Bloqueio de Estímulos por Oscilações Alfa de Modelos Computacionais de Memória de Trabalho de Múltiplos Itens	17
2.4 A Linguagem	19
2.4.1 Estruturas Frasais e o Programa Minimalista	20
2.4.2 Regiões de Interesse	21
2.4.3 O modelo de Friederici para o processamento de linguagem	21
2.5 Aprendizado de Máquina	23
2.5.1 Redes Neurais: a inspiração biológica, o perceptron e as limitações iniciais.	23
2.5.2 O Perceptron multi-camadas	25
2.5.3 Otimização, função de perda e treinamento	27
2.5.4 Redes Neurais Transformer	30
2.5.5 Aprendizado não-supervisionado e Agrupamento Hierárquico	31
3 HIPÓTESES E OBJETIVOS	35
3.1 Parte 1	35
3.2 Parte 2	35
4 RESULTADOS	37
5 DISCUSSÃO	72
5.1 Limitações do Modelo	77
6 CONCLUSÃO	78
REFERÊNCIAS	80
APÊNDICE A - HIPÓTESES COMPUTACIONAIS NO ESTUDO DA SINTAXE	85

LISTA DE FIGURAS

2.1	Protocolo de experimentos computacionais no trabalho do papel das oscilações alfa na memória de trabalho.	17
2.2	Sequências de mapas dos parâmetros nas simulações de interferência entre alfa e teta. . .	18
2.3	Diferentes níveis de análise da linguagem	20
2.4	Inspiração biológica para as redes neurais.	24
2.5	O problema XOR para redes neurais de uma camada.	25
2.6	Função de ativação ReLU, definida como $\text{ReLU}(u) = \max(0, u)$	26
2.7	Função sigmoide logística $\sigma(u)$ e sua derivada.	26
2.8	Softmax aplicada a 3 entradas, variando u_1 e mantendo $u_2 = 0, u_3 = 1$	27
2.9	Métrica de distância entre folhas de uma árvore.	29
2.10	Mecanismo de auto-atenção da arquitetura transformer para um vetor e_1	31
5.1	Diferentes modelos de módulos.	76
5.2	Mecanismo de merge.	77
5.3	Agrupamento hierárquico através dos módulos.	77
1	Representação e transformação de informações nas arquiteturas simbólicas vetoriais. . . .	86
2	Modelo de arquitetura simbólica vetorial.	87
3	Modelo com uma arquitetura de multiplexação paralela de combinações de palavras. . . .	88
4	Implementação de oscilações no formalismo das arquiteturas simbólicas vetoriais.	88
5	Múltiplas oscilações implementadas como distorções das representações.	89
6	Detector de representação nas arquiteturas simbólicas vetoriais.	90
7	Agrupamento em representações do Word2Vec	90
8	Distribuição de classes gramaticais em agrupamentos do Word2Vec.	91
9	Distribuição de agrupamentos em quatro classes gramaticais.	92
10	Hipótese do agrupamento hierárquico.	92
11	agrupamento hierárquico em uma rede perceptroniana	93
12	resultados preliminares da rede	94

LISTA DE TABELAS

2.1	Resumo de resultados sobre a modulação de alfa em tarefas envolvendo mais de uma modalidade.	12
2.2	Resumo de estudos de manutenção da memória de trabalho em que há um aumento das oscilações alfa	13
5.1	Comparação entre três modelos de memória de trabalho de múltiplos itens.	73

LISTA DE ABREVIATURAS

ADP Despolarização pós-disparo (Afterdepolarization).

aSTG Giro temporal superior anterior (Anterior Superior Temporal Gyrus).

BA22 Área de Brodmann 22.

BA44 Área de Brodmann 44.

BA45 Área de Brodmann 45.

BA46 Área de Brodmann 46.

BA47 Área de Brodmann 47.

DMS Tarefa de pareamento retardado (Delayed Match to Sample).

ECoG Eletrocorticografia (Electrocorticography).

EEG Eletroencefalografia (Electroencephalography).

ELAN Negatividade anterior esquerda precoce (Early Left Anterior Negativity).

ERP Potencial relacionado a evento (Event-Related Potential).

GABA_A Receptor GABA do tipo A.

GU Gramática Universal.

HC Agrupamento Hierárquico (Hierarchical Clustering).

HH Hodgkin Huxley.

IF Integra e Disparo (Integrate and Fire).

ING Rede gama de interneurônios (Interneuron Network Gamma).

IPL Lobo parietal inferior (Inferior Parietal Lobule).

LAN Negatividade anterior esquerda (Left Anterior Negativity).

MEG Magnetoencefalografia (Magnetoencephalography).

MTMI Memória de Trabalho de Múltiplos Itens.

MUA Atividade multiunitária (Multi-Unit Activity).

N100 Componente N100.

N400 Componente N400.

NP Sintagma nominal (Noun Phrase).

P600 Componente P600.

PFC Córtex pré-frontal (Prefrontal Cortex).

PING Rede gama piramidal-interneurônio (Pyramidal Interneuronal Network Gamma).

pSTG Giro temporal superior posterior (Posterior Superior Temporal Gyrus).

RC Circuito resistor-capacitor.

ReLU Unidade linear retificada (Rectified Linear Unit).

SI Modelo Soroka-Idiart.

SII Córtex somatossensorial secundário (Secondary Somatosensory Cortex).

SVD Decomposição em valores singulares (Singular Value Decomposition).

V1 Área visual primária.

V2 Área visual secundária.

V4 Área visual V4.

vIFG Giro frontal inferior ventral (Ventral Inferior Frontal Gyrus).

VP Sintagma verbal (Verb Phrase).

XOR OU exclusivo (Exclusive OR).

LISTA DE EQUAÇÕES

2.1	Neurônio de Lapique.	14
2.2	Solução da equação do neurônio de Lapique.	14
2.3	Neurônio integra e dispara baseado em corrente	14
2.4	Neurônio integra e dispara baseado em condutância	14
2.5	Mudança nas condutâncias	14
2.6	Decaimento das condutâncias	14
2.7	Neurônio Hodgkin e Huxley	15
2.8	Corrente de vazamento no neurônio Hodgkin e Huxley	15
2.9	Corrente de sódio no neurônio Hodgkin e Huxley	15
2.10	Cinética da corrente de sódio no neurônio Hodgkin e Huxley	15
2.11	Corrente de potássio no neurônio Hodgkin e Huxley	15
2.12	Cinética da corrente de sódio no neurônio Hodgkin e Huxley	15
2.13	Corrente de cálcio de alto limiar no neurônio Hodgkin e Huxley	15
2.15	Cinética da corrente de cálcio de alto limiar no neurônio Hodgkin e Huxley	15
2.16	Corrente catiônica não específica no neurônio Hodgkin e Huxley	16
2.17	Cinética da corrente catiônica não específica no neurônio Hodgkin e Huxley	16
2.18	Corrente hiperpolarizadora tardia no neurônio Hodgkin e Huxley	16
2.19	Cinética da corrente hiperpolarizadora tardia no neurônio Hodgkin e Huxley	16
2.20	Concentração de cálcio no neurônio Hodgkin e Huxley	16
2.21	Relação superfície-volume para a concentração de cálcio no neurônio Hodgkin e Huxley	16
2.22	Métrica O^c /Índice Soroka-Idiart para performance de memória de trabalho de múltiplos itens.	17
2.23	Métrica O_S de sincronia de neurônios da mesma memória.	18
2.24	Métrica O_A de assincronia de neurônios de memórias diferentes.	18
2.25	Função de onda viajante.	19
2.26	Função de ativação de um neurônio no Perceptron.	24
2.27	Perceptron de uma camada.	25
2.28	Perceptron de duas camadas.	25
2.29	Função de ativação ReLU.	26
2.30	Função de ativação sigmoide.	26
2.31	Função de ativação softmax.	26
2.32	Função de perda: erro quadrático médio.	27
2.33	Função de perda: entropia cruzada.	28
2.34	Função de perda: similaridade de cosseno.	28
2.35	Métrica de distância em uma árvore.	29
2.36	Transformação da matriz de distâncias em um vetor unidimensional.	29
2.37	Gradiente Descendente	29
2.38	Gradiente Descendente Estocástico	30
2.43	PCA: conjunto de dados.	32
2.44	PCA: conjunto de dados centralizados em zero.	32
2.45	PCA: matriz de covariância.	32
2.46	PCA: definição de autovetores e autovalores.	32
2.47	PCA: polinômio característico.	32
2.48	PCA: sistema de equações lineares para encontrar autovetores.	32
2.49	PCA: singular values decomposition.	32
2.50	PCA: redução de dimensionalidade.	33
2.51	K-Means: atribuição de agrupamento.	33
2.52	K-Means: função de custo.	33

Capítulo 1

INTRODUÇÃO

A neurociência computacional é um campo multidisciplinar de estudo, tendo como objetivo o estudo do sistema nervoso, funções cerebrais e cognitivas através de modelos teóricos e computacionais. A computação é tratada tanto como objeto de estudo, ou seja, mecanismos, propriedades e fenômenos computacionais do sistema nervoso e arquiteturas inspiradas nele, quanto como método, utilizando-se de algoritmos, programas e simulações computacionais como ferramenta de pesquisa.

Segundo Dayan e Abott, modelos computacionais na neurociência teórica podem assumir uma abordagem descritiva, mecanicista ou interpretativa (DAYAN; ABBOTT, 2005), geralmente descritas como abordagens que têm diferentes perguntas centrais, sendo elas, respectivamente, "o que?", "como?" e "por que?". Por exemplo, modelos descritivos podem se preocupar em resumir uma grande quantidade de dados com o objetivo de ser preciso na sua descrição de **o que** é comportamento dos neurônios; modelos mecanicistas poderiam propor **como** esses neurônios produzem os fenômenos observados com base na fisiologia e na anatomia, e modelos interpretativos tentariam inferir o **porque** de certos fenômenos específicos serem observados da forma como são, e não outras formas ou outros fenômenos. De forma complementar, existe a descrição dos três Níveis de Análise de Marr, que podem ser utilizados na descrição de um modelo computacional (MARR, 1982): Teoria Computacional, Representação e Algoritmo, e Implementação. O primeiro nível diz respeito ao que está sendo computado, o objetivo da computação e as transformações das entidades de informação; o segundo descreve quais as representações de informação e como serão implementadas, por meio de qual algoritmo; e o terceiro nível discute qual o meio físico da informação e das transformações. Existe, ainda, a descrição de um espectro contínuo que pode caracterizar modelos computacionais na neurociência computacional, feita por Basset et al (BASSETT; ZURN; GOLD, 2018). Nele, são expostas três dimensões de propriedades: representação de dados versus teoria, representações elementares até aproximações grosseiras e realismo biológico até descrições fenomenológicas funcionais.

Analogamente, o neurocientista computacional não tem apenas um perfil, mas é oriundo de campos como a biologia, a matemática, a física, a ciência da computação, ciências cognitivas, medicina, engenharias, entre outros. Por natureza, a intersecção destes domínios requer flexibilidade e com frequência envolve escalas físicas diferentes, múltiplas abordagens, níveis de análise e se dispõe em algum ponto do espaço contínuo de propriedades de modelagem computacional. Dois tópicos que envolvem múltiplas camadas de descrição são a memória de trabalho e a linguagem. Em seguida, será descrita uma breve motivação sobre cada um destes tópicos.

1.1 Memória de Trabalho

Segundo o médico e neurocientista Ivan Izquierdo, a memória significa aquisição, formação, conservação e evocação de informações (IZQUIERDO, 2002). A memória pode ser classificada de diversas formas, como por exemplo memória de curta e longa duração, memórias explícitas, procedurais, etc. Quanto a sua função, a memória é dividida em uma memória convencional, no sentido de que a sua função é armazenar informações como um banco de dados, como é o caso das nossas memórias de longa duração, ou na memória de trabalho. A função da memória de trabalho é armazenar informações de forma muito breve, na escala dos segundos e minutos, e tem a característica de não envolver alterações bioquímicas e biofísicas de longa duração. Um indivíduo memoriza um número de telefone por alguns segundos, tempo

suficiente para anotar em algum papel, e poucos minutos depois não recorda mais. Segundo Izquierdo, a memória de trabalho é responsável pelo gerenciamento da realidade, conectando informações de diferentes instantes de tempo, por exemplo um leitor que lê uma linha e precisa da informação de linhas anteriores para compreender o que está escrito.

Diversos modelos cognitivos foram propostos para a memória de trabalho, sendo um dos mais notáveis o modelo de Baddeley e Hitch, também conhecido como modelo multicomponente de memória de trabalho (BADDELEY; HITCH, 1974). Nele, existem três subcomponentes: um executivo central, que seria um controlador de atenção, o laço fonológico e o bloco de rascunhos visuoespacial, que seriam responsáveis por armazenar informações de modalidade auditiva e visual. Em artigos subsequentes se propôs adaptações do modelo, como a adição do componente chamado de buffer episódico (BADDELEY, 2000). Tais modelos são baseados em experimentos psicofísicos como span de dígito, tempo de reação e tarefa de Sternberg, e exploram fenômenos relacionados, como por exemplo o Efeito Tamanho da Palavra, Efeito Primacia e Efeito de Recência.

Ainda mais desafiador que a caracterização cognitiva de fenômenos de memória de trabalho é encontrar e descrever seus correlatos neurais. Um dos fenômenos mais correlacionado com memória de trabalho é a *atividade persistente*, consistindo no aumento persistente da atividade neuronal durante um estímulo, perdurando após o estímulo cessar (CURTIS; D'ESPOSITO, 2003). Outros dois fenômenos eletrofisiológicos correlacionados com a memória de trabalho são potenciais relacionados a eventos (DREW; MCCOLLOUGH; VOGEL, 2006) e oscilações cerebrais (ROUX; UHLHAAS, 2014). Em especial, as oscilações teta foram correlacionadas com a manutenção de informação na memória de trabalho, enquanto as oscilações alfa foram correlacionadas com a inibição de informação na memória de trabalho. O notável trabalho de Dipoppa e Gutkin modela a memória de trabalho como uma série de operações causadas por oscilações cerebrais em uma rede de neurônios capaz de produzir atividade persistente (DIPOPPA; GUTKIN, 2013; DIPOPPA; SZWED; GUTKIN, 2016), utilizando a oscilação teta na operação de manter informações na memória de trabalho e a alfa na operação de limpeza de informações. O modelo propõe que oscilações podem controlar com flexibilidade a dinâmica de uma rede de neurônios de forma que as operações de armazenar, manter e limpar informações sejam possíveis, porém não deixa claro quais os mecanismos responsáveis por esses fenômenos.

O desafio dos autores anteriores é o mesmo de grande parte da neurociência computacional: a integração da cognição aos neurônios, ou seja, como os neurônios produzem a cognição? Essa questão, ainda que básica, é central e não respondida. Em suma, a tarefa é explicar, com neurônios, os fenômenos observados pela neurociência, inclusive aqueles ditos como básicos ou melhor entendidos, como a memória. Fato desconcertante, mas ainda não temos uma compreensão razoável de como informações são representadas no cérebro, onde estão nossas memórias e como isso nos torna indivíduos únicos. O cientista da cognição Christos Papadimitriou elabora essa questão com maestria em seu primeiro parágrafo (PAPADIMITRIOU et al., 2020) propondo uma nova abordagem para esse problema integrativo, chamada de *Assembly Calculus*, um formalismo computacional para a atividade de assembléias de neurônios.

‘How does the brain beget the mind? How do molecules, cells, and synapses effect cognition, behavior, intelligence, reasoning, and language? The remarkable and accelerating progress in neuroscience, both experimental and theoretical-computational, does not seem to bring us closer to an answer: The gap is formidable, and seems to necessitate the development of new conceptual frameworks. As Richard Axel [...] recently put it, “we do not have a logic for the transformation of neural activity into thought and action. I view discerning [this] logic as the most important future direction of neuroscience.” What kind of formal system, embodying and abstracting the realities of neural activity, would qualify as the sought “logic”?’

Nesse sentido, trabalhamos no tópico de memória de trabalho com objetivo de propor mecanismos neuronais para essa função cognitiva, fazendo uma ponte entre a cognição e os neurônios. O modelo computacional Lisman-Idiart, também chamado de buffer teta-gama, faz essa ponte e propõe que a memória de trabalho de múltiplos itens poderia ser gerada pela combinação de duas fontes de excitação neuronal: correntes intrínsecas ativadas pelos disparos dos neurônios, chamada de despolarização pós disparo, e oscilações de frequência teta (LISMAN; IDIART, 1995). Nele, múltiplas informações são armazenadas por padrões espaçotemporais de disparos de neurônios excitados por uma corrente oscilatória teta, gerando oscilações rápidas gama através de interneurônios inibitórios recorrentes. A memória em si é armaze-

nada através da cíclica reativação dos padrões de disparos que, ao coincidir o pico da oscilação teta com o pico da corrente de despolarização por disparo, consegue alcançar o limiar novamente e a cada ciclo teta.

Além da correlação da oscilação teta com a memória de trabalho, a oscilação alfa está fortemente correlacionada com um prejuízo na memória de trabalho e com a inibição de informações irrelevantes para uma dada tarefa (ver Tabelas 1 e 2). Em trabalho recente, exploramos os efeitos de bloqueio de informações das oscilações alfa em uma rede de neurônios de um buffer teta-gama (SOROKA, 2020). Muitas questões ficaram em aberto, como a falta de robustez do modelo, a caracterização do mecanismo de bloqueio, a extensão do fenômeno de bloqueio para o de limpeza de informações e a descrição de outras operações de memória de trabalho, como as utilizadas por Dipopa e Gutkin. Discussões preliminares apontaram para uma adaptação do modelo original, a segregação em diferentes módulos espaciais e incorporação uma dinâmica oscilatória do tipo onda viajante, corroboradas por evidências recentes de que oscilações cerebrais são ondas viajando no espaço (ZHANG; JACOBS, 2015; ZHANG et al., 2018; LUBENOV; SIAPAS, 2009; PATEL et al., 2012). Assim, neste trabalho propomos a descrição completa de um modelo computacional de memória de trabalho que englobe operações de armazenar, manter e limpar informações, utilizando redes de arquitetura modular e uma dinâmica oscilatória através de ondas viajantes.

1.2 Linguagem

A linguagem é talvez a faculdade cognitiva mais complexa do ser humano. Diversos campos de estudo surgiram e se desenvolveram para estudar os seus diferentes aspectos: linguística, sociolinguística, biolinguística, linguística computacional, neurociência, matemática, psicologia, dentre outras. Ainda que muito estudada, pouco se conhece sobre os processos que a produzem no nível neurobiológico. A linguagem é um processo cognitivo que serve de suporte a outros processos cognitivos e, portanto, parece estar numa categoria especial. É através da linguagem que expressamos nossas memórias, percepções e pensamentos. Por essa natureza, a linguagem possui um caráter mais concreto: podemos descrever muito bem o que as palavras são, por mais abstratos que sejam seus significados, o que se opõe às descrições de, por exemplo, pensamentos.¹ Existem três aspectos da linguagem humana que a diferencia da linguagem de outros animais: a recursividade (HAUSER; CHOMSKY; FITCH, 2002), o deslocamento (HOCKETT, 1960), e a atenção conjunta (ZENG, 2023). A primeira diz respeito a capacidade de criar um número infinito de mensagens com um número finito de itens; a segunda é a capacidade de fazer referência à coisas em outro lugar no tempo ou no espaço; e a terceira é a capacidade de produzir expressões que são compartilháveis entre indivíduos.

Um grande debate a respeito da linguagem é se ela é uma capacidade inata ou aprendida, assunto que pode ser traçado desde filósofos antigos, passando pelo desenvolvimento da psicologia no século XX e finalmente aos campos modernos citados no parágrafo anterior. O linguista Noam Chomsky, referência absoluta da linguística moderna, defende a tese de que existe uma Gramática Universal (GU) para a linguagem natural (CHOMSKY; SMITH, 2000) e, após muitas revisões de como seria esta GU, recentemente adotou uma abordagem minimalista (O programa minimalista) (CHOMSKY, 1993) onde considera que a linguagem está baseada em uma única operação mental chamada "merge" que, em princípio, teria bases neurobiológicas. Uma decorrência da ideia que existe uma GU, e que ela é uma propriedade apenas humana, é que haveria um órgão especial onde ela seria implementada e a existência deste órgão é que diferenciaria o ser humano dos outros animais. Primatas superiores e alguns pássaros, por exemplo, apesar de serem capazes de desenvolver comunicação simbólica em algum grau, não conseguem chegar nem de perto na capacidade humana. Assim, esta diferença poderia ser atribuída à falta desta estrutura cerebral. No entanto, apesar das décadas de trabalho e do reconhecimento de muitas áreas no encéfalo que são responsáveis pelo processamento de linguagem, nada semelhante a um órgão da linguagem exclusivo humano foi encontrado. Uma hipótese alternativa, que está ganhando um número cada vez maior de adeptos devido ao sucesso recente das técnicas de Deep Learning, é que o que diferencia o ser humano dos outros animais é apenas a capacidade de aprendizagem de seu encéfalo. Ou seja, não existe órgão especial de linguagem, simplesmente temos um cérebro melhor e mais complexo que é capaz de utilizar técnicas genéricas muito semelhantes ao aprendizado de máquina (por exemplo inferência Bayesiana) para aprender muitas coisas e inclusive desenvolver a faculdade da linguagem.

¹Caro leitor, o que é um pensamento?

Recentemente, em *The Oscillatory Nature of Language* (MURPHY, 2020), Elioth Murphy defende que "habilidades humanas como a linguagem, a matemática e provavelmente outras, na verdade podem ser apenas diferentes manifestações de uma única habilidade fundamental do cérebro humano: a habilidade de organizar e processar informações de acordo com diferentes escalas físicas". Assim, Murphy propõe pela busca de uma propriedade fundamental do cérebro que permita a faculdade da linguagem. De forma complementar, a referência no estudo da neurobiologia da linguagem, Angela Friederici, descreve a linguagem como um sistema biológico cujo uso se baseia em capacidades cognitivas que são parcialmente presentes em outros animais, com exceção da criação de sentenças hierarquicamente estruturadas (FRIEDERICI, 2017). Assim, muitas peças de um quebra-cabeça sobre a linguagem parecem estar dispostas para serem montadas: estrutura, hierarquia, tempo, recursividade e combinação, sem que ainda se mencione como de fato um sistema biológico poderia estar envolvido. Do ponto de vista da neurociência computacional, nosso objetivo é construir uma ponte que conecte as teorias linguísticas às evidências neurobiológicas, utilizando métodos de modelagem computacional, estudando como estruturas hierárquicas de linguagem podem ser construídas e implementadas em redes neurais.

1.3 A memória de trabalho como arquitetura para a linguagem

Como objetivo final, almejamos conectar dois trabalhos específicos em um modelo integrador e novo. Enquanto o primeiro estudo define as bases neurais para o funcionamento da memória de trabalho de múltiplos itens, o segundo propõe um mecanismo pelo qual alguns fenômenos da linguagem poderiam operar utilizando como arquitetura neural a própria memória de trabalho.

Esta tese está organizada em duas partes complementares. Na primeira parte, desenvolve-se e analisa-se um modelo computacional de memória de trabalho modular, fundamentado em princípios e restrições inspirados na biologia, com o objetivo de investigar os mecanismos oscilatórios e dinâmicos do armazenamento de múltiplas informações. A segunda parte dedica-se à proposição de um mecanismo computacional voltado fenômenos relacionados ao processamento da linguagem, em particular à construção de estruturas hierárquicas. Embora esses mecanismos sejam inicialmente testados em redes neurais artificiais, o foco conceitual permanece na formulação de um princípio mecanicista que possa, em última instância, ser implementado em uma arquitetura de memória de trabalho. Dessa forma, as duas partes da tese se articulam ao investigar, sob diferentes níveis de descrição, como restrições neurobiologicamente plausíveis podem informar modelos computacionais de cognição e linguagem.

Capítulo 2

REFERENCIAL TEÓRICO

2.1 Memória de Trabalho

A memória de trabalho é um tipo de memória cuja função é caracterizada pelo armazenamento breve e imediato de informações, de forma a realizar um gerenciamento da realidade (IZQUIERDO, 2002), conectando informações segundo a segundo, minuto a minuto. Os trabalhos feitos por Baddeley e Hitch sugerem que esta função cognitiva é multi-componente, cada um com características e funções próprias (BADDELEY; HITCH, 1974; BASSETT; ZURN; GOLD, 2018; BADDELEY, 2000), sendo eles o executivo central, o laço fonológico, o bloco de rascunhos visuoespacial e o buffer episódico. O executivo central seria um sistema de controle de atenção, enquanto o laço fonológico lidaria com informações fonológicas, o bloco de rascunhos visuoespacial seria responsável por armazenar informações de natureza visual e o buffer episódico seria responsável por integrar informações de natureza visual, fonológica e da memória de longo prazo. De forma interessante, o modelo multicomponente aproxima a memória de trabalho da linguagem ao propor o laço fonológico como um sistema especializado na manutenção de representações fonológicas, ao lado de outros componentes responsáveis pelo processamento de informações visuoespaciais e pela integração com conteúdos provenientes da memória de longo prazo, os quais também podem assumir natureza linguística.

A memória de trabalho é comumente estudada através de fenômenos psicofísicos, tais como os que medem a capacidade de memória, como número de itens armazenados, e o tempo de reação, como a velocidade de resposta se um dado item está na lista armazenada. No geral, a tarefa de armazenar múltiplos itens na memória de trabalho é conhecida como Tarefa de Sternberg (STERNBERG, 1966), a capacidade de memória humana é 7 ± 2 (MILLER, 1956) e o tempo de reação é de 38 ms para cada item na lista (STERNBERG, 1966). Adicionalmente, as evidências mostram que o tempo de reação é linearmente incremental com o número de itens armazenados, sugerindo uma espécie de escaneamento da lista de itens para responder se dado item faz parte da lista.

Na busca de correlatos neurais para os processos subjacentes, um conjunto de oscilações cerebrais foi relacionado com a memória de trabalho. Em especial, falaremos sobre as oscilações teta, gama, alfa e o acoplamento teta-gama.

- As oscilações teta, pertencentes à banda de 4-8Hz, são amplamente observadas no encéfalo humano, de rato e fatias de tecido e foram correlacionadas com a codificação de informações dependentes de fase no hipocampo (JENSEN; SPAAK; ZUMER, 2014). Fenômenos como precessão de fase, compressão temporal e modulação dos disparos de neurônios são observados no contexto de células de lugar (O'KEEFE; RECCE, 1993), além de modulação do poder das oscilações gama (BELLUSCIO et al., 2012; BRAGIN et al., 1995) e sincronização de oscilações gama entre regiões (COLGIN et al., 2009). As oscilações teta já foram correlacionadas com a memória de trabalho, em específico se observou um aumento no poder de teta com número de informações a serem guardadas na memória de trabalho (GEVINS et al., 1997; JENSEN; TESCHE, 2002) tal como uma forma de "gating" cognitivo, em que o aumento de teta é temporalmente relacionado com a Tarefa de Sternberg, decaindo bruscamente com o fim dela e se relacionado com a organização de uma memória de trabalho de múltiplos itens (RAGHAVACHARI et al., 2001).
- As oscilações gama podem ser interpretadas como a sincronização da atividade de populações de neurônios, cuja frequência está entre 30-100Hz. Modelos discutem que sua origem pode vir da

interação local de neurônios inibitórios entre si ou com neurônios excitatórios, sendo sua frequência determinada pela cinética dos canais $GABA_A$ (receptor do ácido gama-aminobutírico do tipo A), ou seja, pelas hiperpolarizações das correntes inibitórias. Esses modelos são chamados de ING e PING (WHITTINGTON et al., 2001), do inglês *Interneuron Network Gamma* e *Pyramidal - Interneuron Network Gamma*, respectivamente. No geral, a atividade de gama é relacionada com o processamento de informação (JENSEN; SPAAK; ZUMER, 2014).

- O acoplamento teta-gama consiste quando a amplitude da oscilação de frequência gama ocorre de forma relacionada com a fase de uma oscilação teta (CANOLTY et al., 2006; COHEN, 2008; ONSLOW; BOGACZ; JONES, 2011; PENNY et al., 2008; TORT et al., 2010), tendo sido observado tanto no córtex (CANOLTY et al., 2006) quanto no hipocampo (MARIS; KAHANA, 2011) e tendo sua força como fator preditivo da performance da memória de trabalho (AXMACHER et al., 2010).
- As oscilações alfa (~ 10 Hz) são o primeiro ritmo cerebral observado em humanos (BERGER, 1929), sendo seu aumento inversamente relacionado com a quantidade de recursos corticais necessários para dada tarefa (GEVINS et al., 1997; BERGER, 1929; MOOSMANN et al., 2003). Autores descrevem a supressão de alfa como uma dessincronização da atividade dos neurônios (que cessam o disparo na frequência de alfa), tendo duração relacionada com a duração de tarefas (KAUFMAN et al., 1990; KAUFMAN et al., 1992; MICHEL; KAUFMAN; WILLIAMSON, 1994). Em uma série de estudos com tarefas sensoriais bimodais, alfa aparece diminuído em regiões relacionadas com a tarefa e aumentado em regiões não relacionadas (ver Tabela 2.1, retirado de (SOROKA, 2020)). Em tarefas de memória de trabalho, o aumento de alfa aparece amplamente relacionado com o período de retenção de informações e sua diminuição com o fim deste período (BUSCH; HERRMANN, 2003; COOPER et al., 2003; HERRMANN; SENKOWSKI; RÖTTGER, 2004; JENSEN et al., 2002; KLIMESCH, 1999; SAUSENG et al., 2005; SCHACK; KLIMESCH, 2002), com seu poder aumentando com o número de itens armazenados (JENSEN et al., 2002; KLIMESCH, 1999; SCHACK; KLIMESCH, 2002). Outros estudos que relacionam o poder de alfa com tarefas de memória de trabalho podem ser vistas na Tabela 2.2, retirado de (SOROKA, 2020).

Estudo	Paradigma de Atenção	Alfa	Método	Localização
(FOXÉ; SIMPSON; AHLFORS, 1998; FU et al., 2001)	Visual vs Auditivo	-	EEG	Eletrodos posteriores
(FOXÉ; SIMPSON; AHLFORS, 1998; FU et al., 2001)	Visual vs Auditivo	+	EEG	Eletrodos posteriores
(BAUER; KENNETT; DRIVER, 2012)	Visual vs Somatossensorial	+	MEG	Eletrodos posteriores
(WITTEKINDT; KAISER; ABEL, 2014)	Visual vs Auditivo	+	EEG	Eletrodos posteriores
(BAUER; KENNETT; DRIVER, 2012)	Visual vs Somatossensorial	+	MEG	Córtex somatossensorial
(GOMEZ-RAMIREZ et al., 2011)	Visual vs Auditivo	+	ECOG	Córtex auditivo
(FREY et al., 2014)	Visual vs Auditivo	-	MEG	Córtex auditivo direito
(BOLLIMUNTA et al., 2008)	Visual vs Auditivo	+	MUA	V2 and V4
(BOLLIMUNTA et al., 2011)	Visual vs Auditivo	-	MUA	V1
(HAEGENS; HÄNDEL; JENSEN, 2011)	Somatossensorial	-	MEG	Córtex somatossensorial

Tabela 2.1: Resumo de resultados sobre a modulação de alfa em tarefas envolvendo mais de uma modalidade. Retirado de (SOROKA, 2020). Em negrito: o estímulo sensorial em que os indivíduos focaram sua atenção durante a tarefa. As abreviações dessa tabela são: EEG, eletroencefalograma; MEG, magnetoencefalograma; ECOG, eletrocorticograma; MUA, multi-unit activity; V1, V2 e V4, áreas do córtex visual.

Estudo	Tarefa	Método	Frequência	Localização
(??)	Sternberg	EEG	7.5 - 14Hz	Córtex occipito-parietal
(JENSEN et al., 2002)	Sternberg	EEG	9-12Hz	Eletrodos posteriores e centrais
(SCHEERINGA et al., 2009)	Sternberg	EEG	7.5-13.7Hz	Eletrodos posteriores
(ROBERTS; HSIEH; RANGA-NATH, 2013)	Sternberg	EEG	9-12Hz	Eletrodos posteriores
(BONNEFOND; JENSEN, 2012)	Sternberg	MEG	8-12Hz	Eletrodos parieto-occipitais
(TALLON-BAUDRY et al., 1998)	DMS Visual	EEG	9-12Hz	Eletrodos occipitais
(HERRMANN; SENKOWSKI; RÖTTGER, 2004)	DMS Visual	EEG	8-12Hz	Eletrodos posteriores
(SAUSENG et al., 2009)	DMS Visual	EEG	8-12Hz	Eletrodos parieto-occipitais
(JOKISCH; JENSEN, 2007)	DMS Visual	MEG	8-13Hz	Lobo occipital
(PALVA et al., 2011)	DMS Visual	MEG	10-14Hz	Córtices occipital, parietal, temporal e frontal
(ROUX et al., 2012)	DMS Visual	MEG	10-14Hz	Córtex pré-motor, PFC esquerdo, IPL
(KAISER et al., 2007)	DMS Auditivo	MEG	9-12Hz	Córtex temporal superior
(HAEGENS et al., 2010)	DMS Somatosensorial	MEG	8-14Hz	Córtex parietal e SII direito
(HSIEH; EKSTROM; RANGA-NATH, 2011)	Ordem Temporal/DMS	EEG	9-12Hz	Eletrodos parietais/occipitais
(MEDENDORP et al., 2007)	Memória Sacádica	MEG	8-12Hz	Eletrodos parietais posteriores e occipitais
(LEIBERG; LUTZENBERGER; KAISER, 2006)	Sternberg Auditiva	MEG	6-12Hz	Eletrodos posteriores, centrais e anteriores esquerdos

Tabela 2.2: Resumo de estudos de manutenção da memória de trabalho em que há um aumento das oscilações alfa. Retirado de (SOROKA, 2020) e originalmente adaptado de (ROUX; UHLHAAS, 2014). Abreviações desta tabela: DMS¹, *delayed match-to-sample*; PFC, córtex pré-frontal; IPL, lobo parietal inferior; SII, córtex somatosensorial secundário.

2.2 Modularidade e Dinâmica Espacial de Oscilações

Dois aspectos físicos e estruturais utilizados na modelagem da memória de trabalho são uma arquitetura espacialmente modular de neurônios e uma dinâmica espacial de ondas viajantes no lugar de oscilações cerebrais. Muitos indícios apontam para uma estrutura topologicamente modular para o encéfalo, possuindo propriedades como mundo-pequeno e redundância de representação, e grande adaptatividade e robustez (MEUNIER; LAMBIOTTE; BULLMORE, 2010). Diversas estruturas mesoscópicas são observadas, incluindo colunas corticais (HORTON; ADAMS, 2005), *island and ocean cells* no córtex entorinal (SUN et al., 2015), o córtex do barril de roedores (MEYER et al., 2013), glomérulos olfativos (MARESH et al., 2008), *patches* e *blobs* no córtex visual primário, entre outros. Estudos observam componentes espaciais em oscilações cerebrais (BURKITT et al., 2000), mais recentemente em relação às oscilações teta no hipocampo do rato (LUBENOV; SIAPAS, 2009) e humano (ZHANG; JACOBS, 2015; PATEL et al., 2012), no neocórtex humano (ZHANG et al., 2018), sendo seus princípios explorados em outros trabalhos (MULLER et al., 2018; GOLOMB; AMITAI, 1997).

2.3 Modelos Teóricos e Computacionais

2.3.1 Lapique

Talvez um dos modelos teóricos mais antigos de um neurônio seja aquele proposto por Louis Lapique em 1907 (ABBOTT, 1999) enquanto estudava o tempo necessário para a contração de um músculo de rã (ou sapo) após o início de um estímulo elétrico. Lapique percebeu que o tempo era menor para estímulos mais fortes e, mais ainda, observou que o comportamento era similar àquele conhecido de alguns componentes elétricos em circuito. Então, propôs que o comportamento da membrana de um neurônio pudesse ser descrita como um circuito RC, uma composição de um resistor e um capacitor. O resistor é um componente elétrico que resiste à passagem de carga elétrica, enquanto capacitor armazena carga elétrica.

O modelo de Lapique serviu de base para um dos modelos mais utilizados na neurociência computacional, chamado de modelo Integra e Dispara. O modelo Integra e Dispara descreve que o potencial de membrana de um neurônio varia de acordo com a equação 2.1, tendo sua solução para uma corrente contínua $I(t) = I$ dada pela equação 2.2. Nestas equações, τ_m é a constante de tempo da integração da membrana, $V(t)$ é o potencial da membrana no tempo t , R é uma constante de resistência e I é a corrente de estimulação. Em adição, se costuma definir um valor arbitrário para limiar de disparo V_{limiar} , de

forma que quando o potencial o alcança, ele é resetado para um valor de repouso $V_{repouso}$, desta forma produzindo uma curva de potencial de membrana análoga a curva de carregamento do circuito RC.

$$\tau_m \frac{dV}{dt} = -V(t) + RI(t) \quad (2.1)$$

$$V(t) = RI(1 - e^{-\frac{t}{\tau_m}}) \quad (2.2)$$

2.3.2 Integra e Dispara

Os modelos do tipo Integra e Dispara são baseados nas equações descritas por Lapique, tendo variações que dão pouca importância para a descrição da morfologia dos neurônios, ou de processos internos, e outras cujas propriedades mencionadas são levadas em conta. A questão é, muitas vezes, o dilema entre custo computacional e o realismo biológico. O modelo integra e dispara do tipo Leaky é do primeiro tipo, também chamado de modelo baseado em correntes, pois modela explicitamente correntes elétricas como no caso do modelo de Lapique. As equações são análogas à equação 2.1, mas também podem ser escritas como (VOGELS; ABBOTT, 2005):

$$\tau_m \frac{dV}{dt} = (V_{rest} - V) + g_{ex}(E_{ex} - V_{rest}) + g_{inh}(E_{inh} - V_{rest}) \quad (2.3)$$

na qual

V = potencial da membrana

V_{rest} = potencial de repouso

τ_m = constante de tempo da integração da membrana

g_{ex} = condutância da corrente excitatória

g_{inh} = condutância da corrente inibitória

E_{ex} = potencial reverso da corrente excitatória

E_{inh} = potencial reverso da corrente inibitória

O outro tipo de modelo são os chamados de modelos baseados em condutâncias, pois modelam explicitamente variações de condutâncias, como por exemplo condutâncias de canais específicos, temos sua equação descrita por (VOGELS; ABBOTT, 2005)

$$\tau_m \frac{dV}{dt} = (V_{rest} - V) + g_{ex}(E_{ex} - V) + g_{inh}(E_{inh} - V) \quad (2.4)$$

em que potenciais pós sinápticos podem ser simulados através de mudanças nas condutâncias

$$g_{ex} \rightarrow g_{ex} + \Delta g_{ex} \quad g_{inh} \rightarrow g_{inh} + \Delta g_{inh} \quad (2.5)$$

e que decaem através das equações

$$\tau_{ex} \frac{dg_{ex}}{dt} = -g_{ex} \quad \tau_{inh} \frac{dg_{inh}}{dt} = -g_{inh} \quad (2.6)$$

sendo

τ_{ex} = constante de decaimento da condutância excitatória

τ_{inh} = constante de decaimento da condutância inibitória

2.3.3 Hodgkin & Huxley PFC L5

O mais famoso destes modelos de condutância é o próprio modelo de Hodgkin & Huxley, cuja descrição extremamente realística tem como objetivo a modelagem da curva do potencial de ação (originalmente de neurônios gigantes de lulas), através de quações que modelam aberturas e fechamentos de canais. Neste trabalho, utilizamos uma variação deste modelo que descreve neurônios pirâmidas pré-frontais da camada L5 (RODRIGUEZ et al., 2018) que exibem um comportamento eletrofisiológico interessante para a memória de trabalho, que é uma despolarização duradoura após os disparos. O modelo em questão descreve canais de vazamento (L), de sódio (Na), de potássio (K), de cálcio (CaL), canais catiônicos não específicos ativados por cálcio (CAN) e uma corrente hiperpolarizadora (I_{AHP}). O potencial de membrana deste modelo é dado por

$$C \frac{dV}{dt} = -(I_L + I_{Na} + I_K + I_{CaL} + I_{CAN} + I_{AHP}) + I_{inj} \quad (2.7)$$

A corrente de vazamento I_L é escrita como

$$I_L = g_L(V - V_L) \quad (2.8)$$

A corrente de sódio é I_{Na} é escrita como

$$I_{Na}(V, h) = g_{Na} m_{\infty}^3(V) h(V - V_{Na}) \quad (2.9)$$

com

$$\begin{aligned} \frac{dh}{dt} &= [h_{\infty}(V) - h]/\tau_h(V) \\ m_{\infty}(V) &= \{1 + \exp[-(V - \theta_m)/\sigma_m]\}^{-1} \\ h_{\infty}(V) &= \{1 + \exp[-(V - \theta_h)/\sigma_h]\}^{-1} \\ \tau_h(V) &= 0.37 + 2.78 * \{1 + \exp[-(V - \theta_{ht})/\sigma_{ht}]\}^{-1} \end{aligned} \quad (2.10)$$

A corrente de potássio I_K é definida como

$$I_K(V, n) = g_K n^4(V - V_K) \quad (2.11)$$

com

$$\begin{aligned} \frac{dn}{dt} &= [n_{\infty}(V) - n]/\tau_n(V) \\ n_{\infty}(V) &= \{1 + \exp[-(V - \theta_n)/\sigma_n]\}^{-1} \\ \tau_n(V) &= 0.37 + 1.85 * \{1 + \exp[-(V - \theta_{nt})/\sigma_{nt}]\}^{-1} \end{aligned} \quad (2.12)$$

A corrente de cálcio de limiar alto I_{CaL} é determinada pelas equações

$$I_{CaL} = \bar{g}_{CaL} x_{CaL}^2(V - V_{CaL}) \quad (2.13)$$

com a variável de ativação x_{CaL} satisfazendo

$$\begin{aligned} \frac{dx_{CaL}}{dt} &= \frac{x_{CaL}^{\infty}(V) - x_{CaL}}{\tau_{CaL}(V)} \\ \tau_{CaL}(V) &= 10^{\alpha_{CaL} + \beta_{CaL} V} \end{aligned} \quad (2.14)$$

$$x_{CaL}^{\infty}(V) = \{1 + \exp[-(V - V_{1/2, CaL})/K_{CaL}]\}^{-1} \quad (2.15)$$

A corrente catiônica não específica ativada por cálcio I_{CAN} tem a seguinte equação

$$I_{CAN} = \bar{g}_{CAN} x_{CAN} (V - V_{CAN}) \quad (2.16)$$

com a ativação x_{CAN} dependendo de concentrações intracelulares de cálcio como

$$\begin{aligned} \frac{dx_{CAN}}{dt} &= \frac{x_{CAN}^{\infty}(Ca) - x_{CAN}}{\tau_{CAN}(Ca)} \\ \tau_{CAN}(Ca) &= \frac{1}{\alpha_{CAN} * Ca + \beta_{CAN}} \\ x_{CAN}^{\infty}(Ca) &= \frac{\alpha_{CAN} * Ca}{\alpha_{CAN} * Ca + \beta_{CAN}}. \end{aligned} \quad (2.17)$$

A corrente hiperpolarizadora tardia I_{AHP} é descrita como

$$I_{AHP} = \bar{g}_{AHP} x_{AHP}^2 (V - V_{AHP}) \quad (2.18)$$

com a ativação x_{AHP} seguinte

$$\begin{aligned} \frac{dx_{AHP}}{dt} &= \frac{x_{AHP}^{\infty}(Ca) - x_{AHP}}{\tau_{AHP}(Ca)} \\ \tau_{AHP}(Ca) &= \frac{1}{\alpha_{AHP} * Ca + \beta_{AHP}} \\ x_{AHP}^{\infty} &= \frac{\alpha_{AHP} * Ca}{\alpha_{AHP} * Ca + \beta_{AHP}}. \end{aligned} \quad (2.19)$$

A concentração de cálcio segue a dinâmica

$$\frac{dCa}{dt} = -\frac{1}{2F} \frac{Surf}{Vol} I_{CaL} + \frac{Ca_0 - Ca}{\tau_{Ca}} \quad (2.20)$$

onde

$$\frac{Surf}{Vol} = r_1^{-1} \left(1 - \frac{r_1}{r_0} + \frac{r_1^2}{3r_0^2} \right)^{-1} \quad (2.21)$$

E I_{inj} sendo uma corrente de injetada externamente.

2.3.4 Lisman & Idiart

Modelos computacionais envolvendo múltiplos neurônios, redes e arquiteturas podem ser utilizados para descrever fenômenos cognitivos ou modelar fenômenos psico-físicos. O Modelo Lisman & Idiart é um modelo computacional que descreve mecanismos de memória de trabalho de múltiplos itens baseados em oscilações cerebrais e em uma propriedade intrínseca dos neurônios chamada de despolarização pós-disparo (ADP), fenômeno análogo a aquele presente no modelo anterior. O modelo propõe que múltiplas informações podem ser armazenadas em uma rede de neurônios que oscila em uma frequência teta (≈ 8 Hz), sendo cada informação armazenada em um ciclo gama (≈ 40). Os ciclos gama são gerados por inibição retrógrada através de interneurônios inibitórios. A manutenção de informações na rede ocorre por uma coincidência de duas correntes sub-limiais: a oscilação teta e a despolarização pós disparo, ambas atingindo seu pico na mesma escala de tempo (a escala do período teta). Uma sequência de itens é armazenada durante o pico de excitação da oscilação teta, onde ocorre a ativação dos padrões de disparos que representam cada uma destas informações. Cada neurônio, após disparar, ativa o fenômeno de ADP, em que uma corrente despolarizadora que possuiu uma curva alfa ² começa a crescer e atinge seu pico no próximo pico da oscilação teta. Assim, a cada período teta, uma cíclica reativação dos mesmos padrões de disparos acontecem pela coincidência dos picos do ADP e do teta. A mesma inibição que cria os ciclos

²Uma curva alfa se assemelha a um potencial pós-sináptico, tendo a característica de decair mais lentamente que o seu crescimento. No caso, o ADP atinge seu pico em um tempo correspondente ao período teta ≈ 200 ms.

gama são responsáveis por gerar pequenos atrasos entre os padrões de disparos e garantir que eles não se misturem, mantendo a identidade de cada informação. O modelo, por envolver oscilações gama aninhadas em uma oscilação teta, ou seja, múltiplos ciclos gama dentro de um ciclo teta, também é conhecido como buffer teta-gama.

O modelo Lisman & Idiart procura explicar dados psicofísicos como a quantidade de informações que pode ser armazenada na memória de trabalho, o número 7 ± 2 , explicado pelo número de ciclos gama que cabe em um ciclo teta, e também o tempo de reação de respostas em tarefas de memória de trabalho, explicado pelo período de um ciclo gama.

2.3.5 O Bloqueio de Estímulos por Oscilações Alfa de Modelos Computacionais de Memória de Trabalho de Múltiplos Itens

Em trabalho recente, estudamos o formalismo de Dipopa e Gutkin em que oscilações são responsáveis por operações de memória de trabalho em uma rede de neurônios (DIOPPA; GUTKIN, 2013; DIOPPA; SZWED; GUTKIN, 2016), ou seja, a aplicação de uma oscilação promove dinâmicas específicas capazes de carregar, manter, bloquear a limpar informações nessas redes, e aplicamos em uma rede do tipo Lisman&Idiart (SOROKA, 2020). Estudamos o mecanismo de bloqueio de informações em um buffer teta-gama através das oscilações alfa, caracterizando os mecanismos pelos quais o bloqueio ocorre e sua dinâmica temporal. Exploramos o efeito de uma oscilação alfa fraca e forte em uma rede mantendo múltiplas informações e mapeamos o comportamento dos disparos de neurônios nos ciclos seguintes da oscilação teta. A dinâmica geral dos experimentos computacionais pode ser vista na figura 2.1, em que um estímulo armazena múltiplas informações em um ciclo teta, seguido de um período em que as informações ficam armazenadas e um período de aplicação da oscilação alfa. Uma das condições de contorno do modelo é que, sendo teta e alfa oscilações aplicadas externamente, a soma de ambas deve respeitar um valor máximo, ou seja, durante o período em que a amplitude de alfa aumenta, ocorre uma diminuição da amplitude de teta.




Figura 2.1: Protocolo de experimentos computacionais no trabalho do papel das oscilações alfa na memória de trabalho. Após alguns ciclos de oscilação teta estímulos são dados à rede e armazenados por mais uma sequência de ciclos, em determinado instante ocorre um desvio da amplitude oscilatória da oscilação teta para a alfa, onde alfa se torna forte e interfere com teta. Efeitos desta interferência no armazenamento da memória são observados nestes ciclos. Retirado de (SOROKA, 2020)

Para a avaliação de tal modelo, uma métrica nova de performance foi desenvolvida, em que se avalia a sincronia dos neurônios que representam uma mesma informação e a assincronia daqueles que representam diferentes informações, para cada ciclo da oscilação teta. Assim, a métrica O^c é dada por

$$O^c = \left[\frac{1}{M} \sum_a O_S^{ac} \right] \left[\frac{2}{M(M-1)} \sum_{a < b} O_A^{abc} \right] \quad (2.22)$$

onde

M = número de memórias armazenadas

a, b = diferentes ensembles

c = ciclo da oscilação

Enquanto o primeiro termo mede a sincronização de neurônios em uma mesma assembleia de neurônios, o segundo termo mede assincronia de neurônios de grupos diferentes. Eles são dados por:

$$O_S^{ac} = \frac{n^{ac}}{N} \left[1 - \left(\sqrt{2} \frac{\sigma^{ac}}{\Delta t} \right)^{\beta_s} \right]_+ \quad (2.23)$$

onde

n^{ac} = número de neurônios do ensemble **a** que dispararam no ciclo **c**

N = número total de neurônios do ensemble **a**

σ^{ac} = desvio padrão dos disparos dos neurônios do ensemble **a** no ciclo **c**

Δt = tempo entre os disparos de dois grupos

β_s = parâmetro que controla a punição da contribuição do aumento da variância

$[x]_+$ = é a função linearmente regularizada

$$O_A^{abc} = \phi \left(\frac{|\langle t^{ac} \rangle - \langle t^{bc} \rangle|}{\Delta t} \right) \quad (2.24)$$

onde

$$\langle t^{ac} \rangle = \frac{1}{n} \sum_i t_i^{ac} \quad \phi(x) = \begin{cases} 0 & \text{if } x = 0 \\ x^{\beta_a} & \text{if } x \in (0, 1) \\ 1 & \text{if } x \geq 1 \end{cases}$$

t_i^{ac} = tempo do disparo do neurônio **1**, do ensemble **a**, no ciclo **c**

n = número de neurônios dentro do ensemble **a**

β_a = parâmetro de controle da não-linearidade de ϕ

Desta forma, o parâmetro de ordem O , nomeado índice SI^3 , é uma proposta de parâmetro de ordem para um buffer de memória de trabalho de múltiplos itens baseado nas oscilações teta-gama, variando entre 0 e 1, sendo 1 o valor de performance máximo da memória de trabalho de múltiplos itens.

Um dos resultados deste trabalho foi o mapeamento da performance do modelo de acordo com alguns parâmetros, como valores de frequência e amplitude das oscilações alfa. A figura 2.2 mostra uma sequência de mapas em que se variou a frequência e amplitude da oscilação alfa e se mediu a performance no modelo em diversos ciclos, sendo o ciclo 6 o ciclo do início do aumento de alfa. As zonas claras mostram conjuntos de parâmetros em que alfa prejudica a memória de trabalho, ou seja, cuja função de bloqueio de informações ocorre com sucesso.




Figura 2.2: Sequências de mapas dos parâmetros nas simulações de interferência entre alfa e teta. A altura do gráfico 3D representa a amplitude relativa de alfa em relação ao total de amplitude oscilatória, e profundidade representa a frequência da oscilação alfa. Observamos que, a partir do aumento da amplitude de alfa no ciclo 6, o espaço dos parâmetros neste mapa e nos seguintes começa a apresentar regiões em que a memória é prejudicada e apagada da rede. Figura retirada de (SOROKA, 2020).

O modelo explora outros mapas e discute que para uma melhor caracterização seria necessário melhorar a robustez do modelo. Assim, o modelo considera que as oscilações são ondas viajantes, em que cada memória seria armazenada por neurônios que receberiam a oscilação com atrasos de fase, como se

³Índice Soroka-Idiart

estivessem em posições espaciais diferentes e a onda viajaria entre eles. Nesse sentido, a função da onda é modelada simplesmente como

$$\text{onda} \sim \text{sen}(kx - \omega t) \quad (2.25)$$

onde

k = número de onda

ω = frequência angular

x = posição do espaço

t = tempo

O trabalho em questão propõe direções para que se considere não só a modelagem de oscilações como ondas viajantes, mas como também redes dispostas no espaço físico, organizadas de forma modular.

2.4 A Linguagem

Um dos primeiros desafios deste trabalho é definir o que é a Linguagem. Ela pode ser vista como um sistema de representação e comunicação de informações que usa palavras combinadas de acordo com regras gramaticais, em que a fala é a expressão que surge naturalmente na forma audível dessa comunicação, já a leitura e a escrita necessitam treinamento formal por anos (BEAR; CONNORS; PARADISO, 2017). Angela Friederici, uma das maiores referências na neurociência da linguagem, utiliza a definição de sistema biológico e cujo uso se baseia em capacidades cognitivas que são parcialmente presentes em outros animais, com exceção da criação de sentenças hierarquicamente estruturadas (FRIEDERICI, 2017). Segundo ela, os humanos nascem para aprender a Linguagem. Isso acontece sem ensino formal ou treino e se torna uma habilidade inerente e automática. Uma das explicações sobre a expertise do uso da Linguagem é que ela deve ser inata, ou seja, além de capacidades presentes no nascimento, os desenvolvimentos tardios na vida seguem um programa biológico, mesmo se necessitarem de estímulos durante períodos críticos (FRIEDERICI, 2017). De forma semelhante, Steven Pinker faz a analogia de que os humanos produzem a Linguagem assim como as aranhas tecem teias, como um instinto (PINKER, 1994). O estudo da Linguagem é multifacetado, se apresentando desde o estudo dos níveis hierárquicos de produção de uma sentença, os órgãos e sistemas que a produzem, a natureza física e os aspectos sociológicos.

Do ponto de vista da linguística, a linguagem pode ser estudada como os sons físicos, seus conjuntos nas linguagens naturais, a construção de palavras, frases e sentenças, os significados e a compreensão. A **fonética** é o estudo dos sons produzidos pela fala humana, onde se descreve quais são esses sons, suas características e como são produzidos. A fala humana envolve a coordenação de mais de 100 músculos, desde o pulmão até a boca, e os sons podem ser divididos quanto as estruturas utilizadas, como por exemplo sons labiais, dentais, alveolares, uvulares, entre outros e suas combinações. Já a **fonologia** estuda como os diferentes sons e fonemas se organizam e se relacionam gramaticalmente em determinada língua, ou seja, o conjunto de sons e sinais de determinada linguagem natural. Esse conjunto de sons pode ser tão distinto em diferentes línguas que o encéfalo humano perde a capacidade de perceber os sons produzidos por outras linguagens naturais por volta do primeiro ano de vida do bebê (KANDEL; SCHWARTZ; JESSELL, 2013), de forma que, para o brasileiro, o mandarim pode ser uma combinação de vários x, sh, ch e, para o japonês, o r e o l são o mesmo som.

A combinação de fonemas em palavras e a classificação destas são objeto de estudo da **morfologia**. Ela estuda não somente como as palavras são formadas mas a relação entre elas. Classificações utilizadas são substantivos, adjetivos, pronomes, preposições, entre outras. A **sintaxe** é o estudo de como palavras são combinadas para formar frases e sentenças, envolvendo a ordem das palavras, as relações gramaticais, concordâncias e estruturas hierárquicas. Diferentes línguas possuem diferentes sintaxes: no português a ordem das palavras determina quem é o sujeito e quem é o objeto de uma sentença, mas no japonês existem partículas justapostas após as palavras que às incubem estas funções na sentença.

A **semântica** é o estudo do significado das palavras, frases e sentenças. Já a **pragmática** é o estudo de como o contexto influencia no significado, levando em conta as interações sociais, relação entre falante e ouvinte, motivações do falante e, em suma, a compreensão da mensagem.



Figura 2.3: Diferentes níveis de análise da linguagem: fonética, fonologia, morfologia, sintaxe, semântica e pragmática.

2.4.1 Estruturas Frasais e o Programa Minimalista

A linguística teórica busca descrever a estrutura do conhecimento linguístico humano — a chamada gramática mental — por meio de modelos formais que expliquem como os falantes produzem e compreendem sentenças. A gramática de uma língua é mais do que uma lista de regras: ela reflete princípios estruturais universais compartilhados por todas as línguas humanas. Dentro desse campo, as gramáticas de estrutura frasal (phrase structure grammars) constituem uma das formas mais influentes de modelar a sintaxe, e serviram como base para o desenvolvimento de teorias modernas, como o Programa Minimalista, formulado por Noam Chomsky a partir da década de 1990.

As gramáticas de estrutura frasal foram inicialmente introduzidas como parte do modelo de gramática gerativa proposto por Chomsky na década de 1950. Nesse modelo, sentenças são descritas por meio de regras hierárquicas de reescrita, que especificam como categorias linguísticas se combinam para formar estruturas maiores. Por exemplo:

$$S \rightarrow NP \ VP$$

$$NP \rightarrow Det \ N$$

$$VP \rightarrow V \ NP$$

Essas regras indicam que uma sentença (S) é composta por um sintagma nominal (NP) seguido por um sintagma verbal (VP), e assim por diante. O resultado é uma árvore sintática, que explicita a estrutura hierárquica da frase. Tais estruturas são fundamentais para capturar fenômenos como ambiguidade e dependências de longo alcance. Esse tipo de gramática foi fundamental tanto para o avanço da linguística formal quanto para aplicações em linguística computacional, como parsing automático.

Apesar do poder descritivo das gramáticas de estrutura frasal, elas carregam um número elevado de regras específicas para cada língua, o que vai contra o princípio de economia cognitiva. A partir dos anos 1990, Chomsky propôs o Programa Minimalista, cujo objetivo é derivar a gramática universal de princípios computacionais mais simples e naturais. O ponto de partida do minimalismo é a ideia de que a linguagem é um órgão mental especializado, moldado pela evolução para ser eficiente e econômico. Assim, busca-se identificar as operações mais básicas capazes de gerar a riqueza estrutural da linguagem humana. A operação central do Programa Minimalista é chamada de Merge, que combina duas unidades sintáticas em uma nova unidade composta:

$$Merge(\alpha, \beta) \rightarrow \{\alpha, \beta\}$$

Com apenas essa operação, é possível construir hierarquias complexas

O Programa Minimalista não busca apenas descrever línguas individuais, mas propor uma teoria da faculdade linguística humana, parte da cognição biológica. Essa abordagem conecta-se diretamente com a neurociência da linguagem, na medida em que sugere operações computacionais elementares que poderiam ser implementadas pelo cérebro humano. Operações como Merge vêm sendo investigadas por

neurocientistas em termos de composição hierárquica e integração sintática, associadas, por exemplo, à ativação da área de Broca (BA 44) (ZACCARELLA; FRIEDERICI, 2017; ZACCARELLA; SCHELL; FRIEDERICI, 2017).

2.4.2 Regiões de Interesse

A anatomia das faculdades da linguagem tem sua origem em dois personagens famosos do século XIX: Paul Broca associa em 1861 porções posteriores do giro frontal inferior do hemisfério esquerdo (áreas de Brodmann 44 e 45, ou apenas BA44 e BA45) à produção da fala, enquanto Carl Wernicke identifica em 1874 uma região situada no giro temporal superior esquerdo (área de Brodmann 22, BA22) como tendo relação com prejuízos na compreensão da fala. Ambos estudaram casos de pacientes com déficits cognitivos em vida, na produção da fala no caso de Broca, e na compreensão no caso de Wernicke e dissecaram os encéfalos pos-mortum, identificando lesões nas respectivas regiões. Os déficits ficaram conhecidos como Afasia de Broca e Afasia de Wernicke, e as regiões de interesse ganharam nome de Área de Broca e Área de Wernicke. Na década de 1960, Norman Geschwind propõe o modelo para o processamento da linguagem Wernicke-Geschwind, em que estabelece:

- a **área de Wernicke** como responsável pela compreensão da linguagem fala e escrito
- a **área de Broca** responsável pela produção da fala
- um feixe de axônios que corre ventralmente no lobo parietal chamado de **fascículo arqueado**, e que conecta as duas áreas acima e transmite informações da compreensão para a produção
- o **giro angular**, porção entre os lobos temporal, parietal e occipital, que integra informações visuais com representações linguísticas

Um modelo mais moderno foi proposto por Gregory Hickok e David Poeppel nos anos 2000, chamado de Modelo das Duas Vias (*Dual Stream Model*), dividindo o processamento da linguagem em duas grandes vias:

- **Via Dorsal:** conecta áreas frontais, como a área de Broca (BA44) e BA46 ao lobo temporal posterior via fascículo arqueado e fascículo longitudinal superior, estando envolvida no mapeamento de sons para a articulação. Exemplos de ações que utilizam esta via são a produção da fala, a imitação e repetição.
- **Via Ventral:** conecta áreas do córtex frontal inferior, como BA45 e BA47, a áreas temporais anteriores e mediais, através do fascículo uncinado e do fascículo da capsula extrema. Esta via seria responsável pelo mapeamento de sons para significado.

Em adição as regiões supracitadas, podemos citar o próprio córtex auditório primário envolvido na percepção de sons, a região adjacente chamada de planum temporale, relacionado com a categorização de sons como sons da fala, regiões do lobo temporal medial e anterior, relacionados com a lexicalização das palavras (como um dicionário) e com a construção de combinações semânticas.

2.4.3 O modelo de Friederici para o processamento de linguagem

Ao longo das últimas décadas uma pesquisadora alemã se destacou pelos seus trabalhos sobre as bases neurais do processamento da linguagem, em especial estudando correlatos neurais para fenômenos linguísticos fonológicos, sintáticos e semânticos. Angela Friederici utiliza métodos de imageamento para mapear os processos neurais que acontecem quando se utiliza a linguagem, conseguindo estudar fenômenos específicos e também integrar em um modelo completo. Em seu livro *Language in our Brain* (FRIEDERICI, 2017), ela propõe o modelo de compreensão da linguagem ouvida, em que o processamento começa por um processo acústico-fonológico, se dividindo em um processamento prosódico e um sintático-semântico. No fim, ocorre interpretação da sentença. No processamento prosódico se observa a intonação frasal e os focos de acentuação. O processamento sintático-semântico começa com a construção da estrutura sintática da frase, se dividindo no processamento das relações semânticas, temáticas e sintáticas, acabando com uma integração.

O correlato neural mais utilizado para os fenômenos subjacentes ao processamento da linguagem são os potenciais relacionados a eventos (ERP's, *event related potentials*), que consistem em uma média de muitos ensaios da atividade eletroencefalográfica, sincronizadas a um evento. Esse evento geralmente é

o ponto inicial de uma tarefa, por exemplo o início da reprodução de uma palavra na forma sonora. A média das atividades permite o cancelamento da atividade ruidosa, ou atividade não correlacionada com a tarefa, e soma as atividades correlacionadas, permitindo isolar regiões e momentos de ativação que estão diretamente relacionadas com determinado processo. Se costuma utilizar como nomenclatura letras maiúsculas que designam o sinal do desvio observado na atividade (**N** para negativity, **P** para positivity), assim como letras que podem designar o momento temporal relativo do desvio ou posição espacial relativa (**E** para early, **L** para left, **A** para anterior), enquanto números designam valor numéricos para os momentos dos desvios (100/400/600 relativos à milissegundos após um evento). Exemplos importantes no processamento da linguagem são

- N100 : um desvio negativo que aparece 100ms após um evento
- ELAN : um desvio negativo que aparece na porção anterior do lobo temporal
- N400: um desvio negativo que aparece por volta dos 400ms após um evento
- P600: um desvio positivo que aparece por volta dos 600ms após um evento

O modelo proposto por Angela Friederici começa com o processamento acústico fonológico dos sinais que chegam ao córtex auditivo. Neste momento, os sons são processados e identificados como sons de fala. Sons de fala são informações especiais que irão percorrer a circuitaria responsável pela linguagem. O próximo fenômeno interessante, que ocorre de forma cedo no processamento, é a construção inicial da estrutura da frase. Segundo a autora, uma das primeiras informações recuperadas do lexicon (o dicionário mental das palavras) é a categoria das palavras, ou seja, a classe gramatical (substantivo, verbo, preposição, ...). Com essa informação, a porção anterior do giro temporal superior (aSTG) e a porção ventral do giro inferior frontal (vIFG) são responsáveis pela ativação de **templates** de estrutura e a checagem se as informações futuras se encaixam nos padrões existentes. Uma sentença como **a menina** ira primeiro ativar um template de **frase determinante** com o determinante **a**, e o template irá esperar um certo tipo de informação a seguir, como um substantivo. Se a informação seguinte viola esses padrões, surge um efeito observado em ERPs chamado de **early left anterior negativity (ELAN)**. Esse ERP reflete a violação da categoria da palavra, que não coincide com aquelas esperadas pelos templates. Nas regiões vizinhas dois fenômenos são destacados: o frontal operculum é responsável por juntar dois objetos (como o Merge Chomskiano) e a área de Broca é responsável pela construção da estrutura sintática frasal. Além disso, a região BA 44 da área de Broca é responsável por operações puramente sintáticas, enquanto a BA 45 é recrutada quando aspectos semânticos estão envolvidos. De forma complementar, a informação também segue posteriormente para a porção posterior do giro temporal superior (pSTS), onde está a área de Wernicke. Nessa região existe uma memória de curto prazo fonológica. Após, a informação segue o caminho dorsal através do giro angular e do fascículo arqueado até a mesma região de Broca. Se propõe, também, a existência de duas memórias de trabalho relacionadas com a linguagem: uma parietal geral e uma frontal específica para aspectos sintáticos.

De forma resumida, o modelo propõe:

1. Processos acústicos e fonológicos (categorização dos sons da fala) acontecem pelos 100ms no córtex auditório primário e no planum temporale, sendo refletidos pelo ERP N100
2. A construção inicial da estrutura sintática acontece entre 120 e 250ms na parte mais ventral do pars opercularis e na parte anterior do giro temporoal superior (aSTG), sendo a parte frontal do operculum responsável por juntar dois elementos e a parte ventral de BA44 responsável pela construção de hierárquica. Nestes processos, o ERP ELAN surge quando há violação sintática.
3. Processamento das relações semânticas, temáticas e sintáticas acontece entre 300 e 500ms. As relações semânticas ocorrem e atribuição de papéis temáticos (quem fez o que com quem?) ocorrem no giro temporal superior esquerdo, no giro temporal medial e nas regiões BA45/BA47 do córtex frontal inferior. Processos envolvendo hierarquias sintáticas complexas ocorrem com o suporte de BA44 e da parte posterior do giro temporal superior esquerdo (pSTG). Sinais relacionados a estes processos são os ERP's LAN e N400.
4. A integração dos diferentes tipos de informação acontece pelos 600ms, refletidos no ERP P600.

2.5 Aprendizado de Máquina

O aprendizado de máquina (*machine learning* em inglês) é um subcampo da inteligência artificial, cujo objetivo é desenvolver métodos e algoritmos capazes de aprender padrões estatísticos de dados e realizar tarefas específicas. Por sua vez, estes métodos podem ser divididos em grupos diferentes:

1. **Aprendizado Supervisionado:** é caracterizado por treinar um modelo com um conjunto de dados que contenham valores de *entrada* $\mathbf{X}$ e *saída* $\mathbf{Y}$, de forma que para cada valor $x_i \in \mathbf{X}$ é possível corrigir ou informar o modelo se ele acertou através do conhecimento do resultado correto $y_i \in \mathbf{Y}$. O objetivo deste tipo de aprendizado é a previsão e inferência de resultados em conjunto de dados não utilizados no treinamento, sendo geralmente chamado de generalização. Este tipo de aprendizado de máquina é utilizado em modelos de regressão e classificação, incluindo redes neurais multicamadas, profundas, recorrentes e convolucionais.
2. **Aprendizado não-Supervisionado:** por sua vez, este tipo de aprendizado de máquina consiste em descobrir padrões escondidos ou latentes de um conjunto de dados de *entrada* $\mathbf{X}$, sem possuir um conjunto de *saídas*. Por sua própria natureza, a correção ou avaliação destes métodos é mais sutil, sendo eles mais aplicados em contextos como análise exploratória de dados e visualização de dados hiperdimensionais. Exemplos são algoritmos de clusterização e análise dos componentes principais.
3. **Aprendizado por Reforço:** este grupo de métodos utiliza o princípio de um agente que pode aprender interagindo com o seu ambiente e que possui um objetivo. Consiste em quatro elementos básicos: uma política (que guia as ações do agente), um sinal de recompensa (que avalia se ações imediatas foram boas ou não), uma função de valor (que avalia se determinadas ações serão boas ou ruins a longo prazo) e por fim um modelo (que descreve virtualmente o ambiente, podendo ser usado para planejar e avaliar ações sem ser necessário aplicar elas). Modelos deste tipo são comumente aplicados em problemas com objetivos claros, como por exemplo modelos que aprendem jogos de tabuleiro e a direção autônoma.

Diferentes autores podem incluir outras categorias nesta classificação de modelos, assim como diferentes áreas podem incluir metodologias presentes do aprendizado de máquina, por exemplo elementos de aprendizado estatístico ou teoria de controle e otimização. Além disto, algoritmos podem incluir mais de um modelo e de diferentes categorias, como por exemplo combinar redes neurais profundas (aprendizado supervisionado) com aprendizado por reforço, ou então o presente trabalho, que combina aprendizado supervisionado com um algoritmo de aprendizado não-supervisionado chamado de *agrupamento hierárquico*.

2.5.1 Redes Neurais: a inspiração biológica, o perceptron e as limitações iniciais.

Um dos marcos em que se atribui a origem das redes neurais artificiais é o trabalho do neurofisiologista Warren McCulloch e do matemático Walter Pitts (MCCULLOCH; PITTS, 1943), em 1943, que descreve um neurônio artificial de uma forma impressionantemente ainda replicada hoje em dia. O neurônio de McCulloch-Pitts (figura 2.4a) é uma descrição matemática de um neurônio biológico, consistindo em um **limiar binário** (dispara ou não) que recebe estímulos binários (0 ou 1), ponderados por pesos fixos (excitatórios e inibitórios). Além dos pesos serem fixos, ou seja, não existe aprendizado, redes de neurônios propostas por eles haviam tempo discreto, sincronizavam as atualizações dos neurônios e implementavam estímulos inibitórios como *impedidores* de disparo. O trabalho seminal descrevia que estas redes poderiam realizar operações lógicas.

Aproximadamente 25 anos depois, o psicólogo Frank Rosenblatt desenvolveu o Perceptron em 1957 (ROSENBLATT, 1957), uma rede neural artificial de uma camada na forma de circuitos eletrônicos, criada inicialmente como um modelo de aprendizado de máquina de percepção visual (figura 2.4b), recriando em muitos aspectos o aparato humano (ROSENBLATT, 1958). Uma matriz de sensores ópticos simulava uma retina, se conectando a uma camada de rede neural que foi treinada a para classificar padrões visuais utilizando um algoritmo de aprendizado adaptativo. O perceptron é considerado a primeira implementação de uma rede neural, utilizando neurônios baseados nos neurônios de McCulloch-Pitts, e sua estrutura pode ser descrita como

1. um vetor de entrada $\mathbf{x} = (x_1, x_2, \dots, x_n)$

2. um vetor de pesos $\mathbf{w} = (w_1, w_2, \dots, w_n)$
3. um termo de limiar ou viés b
4. uma função de ativação (tipo degrau), produzindo uma saída binária ($y \in \{0, 1\}$)
5. a saída é dada por $\hat{y} = \begin{cases} 1, & \text{se } \mathbf{w} \cdot \mathbf{x} + b \geq 0, \\ 0, & \text{caso contrário} \end{cases}$




Figura 2.4: Inspiração biológica para as redes neurais. a) O neurônio de McCulloch-Pitts introduz o modelo matemático e computacional de neurônio biológico que ainda é utilizado hoje em dia: entradas, pesos, limiar de ativação, saídas. b) Rosenblatt utiliza a percepção visual como inspiração para a primeira implementação de redes neurais artificiais com o Perceptron: estrutura de um Perceptron inspirada na estrutura do sistema visual. Imagem retirada de (ROSENBLATT, 1958).

O perceptron clássico conta com um algoritmo de aprendizado supervisionado descrito por

$$\begin{aligned} \text{Atualização dos pesos: } \mathbf{w} &\leftarrow \mathbf{w} + \eta(y - \hat{y})\mathbf{x} \\ \text{Atualização do bias: } b &\leftarrow b + \eta(y - \hat{y}) \end{aligned}$$

em que η é a taxa de aprendizado, y é o rótulo correto para determinada entrada x , $\hat{y}$ é o rótulo previsto pelo modelo. O modelo proposto por Rosenblatt tinha uma limitação que se tornou empecilho para o desenvolvimento do campo de redes neurais nas décadas de 60 e 70: o modelo só resolve problemas linearmente separáveis. Este tópico é interessante e merece uma abordagem geométrica.

Um vetor de entrada consiste em um conjunto de números, estes números podem ser colocados em um espaço hiperdimensional, em que cada componente do vetor determina a posição em uma das dimensões, sendo então uma entrada um ponto neste espaço. O Perceptron com apenas uma camada atua como a função de ativação de um único neurônio, dado por

$$\hat{y} = \sum_i^n W_i x_i + b \quad (2.26)$$

que consiste na equação de um hiperplano, que pode aprender a separar duas classes de dados, uma de cada lado dele. Assim, uma camada de neurônios atua como um hiperplano que aprende a se posicionar de maneira a separar os pontos, sendo uma das condições para a tarefa ser bem sucedida os pontos serem linearmente separáveis. Um dos exemplos canônicos de problema não-linearmente separáveis é a função "ou exclusivo" (XOR): dado uma entrada que contenha dois features binários (0 ou 1), a função XOR retorna um valor de 1 se, e somente se, apenas um dos features possui valor 1. Caso nenhum, ou ambos sejam 1, a função retorna 0. Como são apenas dois features, podemos representar os dados no espaço bidimensional (figura 2.5). De fato, nenhuma reta pode separar os dados que produzem o valor 0 dos dados que produzem o valor 1, demonstrando que o perceptron de uma camada falha em resolver esta tarefa simples.

Em 1969, o cientista cognitivo Marvin Minsky e o matemático Seymour Papert publicaram o livro *Perceptrons* (MINSKY; PAPERT, 1988), lançando críticas ao modelo do perceptron, incluindo o problema descrito pela função XOR e outras limitações. Já se hipotetizava sobre perceptrons de várias camadas,




Figura 2.5: O problema XOR para redes neurais de uma camada. Um problema simples que uma rede neural de uma camada não consegue resolver é a função XOR, que consiste, dadas duas características (features), retorna 1 quando ambas são presentes ou quando nenhuma é presente, e retorna 0 quando apenas uma é presente (esquerda). No meio, observamos a função como um gráfico bidimensional. À direita, a ilustração de que, como uma rede neural ajusta apenas funções lineares, nunca poderia ajustar uma rede que separasse as respostas da função.

mas os métodos capazes de treiná-los ainda estavam por serem desenvolvidos. Tais limitações geraram um dos chamados invernos da IA, um momento de descrença, pouco investimento e motivação no estudo e desenvolvimento desta área. Foi só em 1986 que os psicólogos e cientistas da computação David Rumelhart, Geoffrey Hinton e Ronald Williams publicam o trabalho que introduz o método de retropropagação (*backpropagation*) (RUMELHART; HINTON; WILLIAMS, 1986), capaz de treinar perceptrons com várias camadas.

2.5.2 O Perceptron multi-camadas

A ideia de um modelo perceptron com várias camadas pode ser descrito ao se introduzir uma ou mais camadas extras entre a camada que recebe as entradas e a camada de saída, geralmente levando o nome de camadas ocultas. Além disto, o grande poder computacional dos modelos de várias camadas vem do uso de funções de ativação não-lineares em cada camada. Podemos escrever uma camada perceptron da seguinte forma

$$z = \tilde{W} \tilde{x}, \quad a = f(z) \quad \tilde{x} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}, \quad \tilde{W} = \begin{bmatrix} b_1 & w_{11} & w_{12} & \cdots & w_{1d} \\ b_2 & w_{21} & w_{22} & \cdots & w_{2d} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ b_m & w_{m1} & w_{m2} & \cdots & w_{md} \end{bmatrix} \quad (2.27)$$

em que z é o vetor que computa a ativação de cada neurônio computacional, $\tilde{x}$ é o vetor de entrada contendo um elemento 1, referente aos vieses e $\tilde{W}$ é a matriz de pesos sinápticos que contém em sua primeira coluna os vieses. Na formulação original, o perceptron atribuía valores 0 caso $\tilde{W}\tilde{x} < 0$ e valores 1 caso $\tilde{W}\tilde{x} \geq 0$, equivalente a aplicar a função de ativação tipo degrau (f) em z , gerando o vetor de ativação a . Para estendermos esta descrição para um perceptron de mais camadas, apenas tomamos $\{\tilde{x}, \tilde{W}, f\}$ da descrição acima como $\{\tilde{x}_0, \tilde{W}_0, f_0\}$, e $\{z, a\}$ como $\{z_0, a_0\}$, a ativação dos neurônios da primeira camada, e damos como entrada $\tilde{x}_1$ para uma segunda camada, através dos pesos $\tilde{W}_1$. Assim, um perceptron de duas camadas pode ser descrito como

$$a_1 = f_1(z_1) = f_1(\tilde{W}_1 \tilde{x}_1) = f_1(\tilde{W}_1 a_0) = f_1(\tilde{W}_1 f_0(z_0)) = f_1(\tilde{W}_1 f_0(\tilde{W}_0 \tilde{x}_0)) \quad (2.28)$$

O grande desafio resolvido pelo algoritmo de backpropagation foi conseguir calcular e atualizar as matrizes de pesos sinápticos $\tilde{W}_i$ de um perceptron de várias camadas. Tal método é baseado no cálculo diferencial de funções de várias variáveis, derivando uma função matemática que representa a tarefa da rede neural (a função de custo, ver próxima seção) em relação aos parâmetros da rede (pesos w e vieses b), propagando as contribuições multiplexadas através da regra da cadeia. Para isto, uma das condições necessárias é a diferenciabilidade das funções de ativação $f_0, f_1 \dots f_1$, o que exclui a função degrau do perceptron original. Muitas funções de ativação bem comportadas são utilizadas, como por exemplo

1. ReLU (Rectified Linear Unit): definida como

$$\text{ReLU}(u) = \max(0, u) \quad (2.29)$$

assumindo o valor 0 se $u < 0$ e u se $u > 0$. Esta função não é diferenciável em um único ponto, sendo assim empregados valores arbitrários (por exemplo o valor 0) para sua derivada e imagem no ponto $u = 0$. Fora deste ponto, temos derivada igual a 0 para $u < 0$ e derivada igual a 1 para $u > 0$.




Figura 2.6: Função de ativação ReLU, definida como $\text{ReLU}(u) = \max(0, u)$.

2. Sigmoide: definida como

$$\sigma(u) = \frac{1}{1 + e^{-u}}, \quad (2.30)$$

possuindo formato de 'S', em que $\sigma(-\infty) = 0$, $\sigma(+\infty) = 1$ e sua derivada é dada por $\sigma'(u) = \sigma(u)(1 - \sigma(u))$. Esta função também é conhecida como função logística, e é muito utilizada para converter valores numéricos $\in \mathbb{R}$ em valores entre 0 e 1, podendo ser interpretados como probabilidades. Quando posicionadas na última camada, geralmente indicam a probabilidade de um dado pertencer a uma de duas classes (0,1), sendo a classe cujo valor está mais próximo da ativação. Estes problemas são chamados de classificação binária.




Figura 2.7: Função sigmoide logística $\sigma(u)$ e sua derivada.

3. Softmax: definida como

$$y_i = \text{softmax}(\mathbf{u})_i = \frac{e^{u_i}}{\sum_{j=1}^K e^{u_j}}, \quad i = 1, \dots, K \quad (2.31)$$

$$\text{com } \mathbf{u} = [u_1, u_2, \dots, u_K] \in \mathbb{R}^K, \quad \mathbf{y} = [y_1, y_2, \dots, y_K] \in [0, 1]^K, \quad \sum_{i=1}^K y_i = 1$$

em que y_i indica a probabilidade de um dado u pertencer a classe $i \in K$, ou seja, em problemas de classificação multi-classe. Assim, cada dado u tem a probabilidade de pertencer a cada uma das K classes, sendo a soma destas probabilidade igual 1.




Figura 2.8: Softmax aplicada a 3 entradas, variando u_1 e mantendo $u_2 = 0$, $u_3 = 1$.

2.5.3 Otimização, função de perda e treinamento

O treinamento de uma rede neural moderna consiste em uma sequência de etapas análogas ao treinamento de um perceptron. Podemos descrever estas etapas como:

1. um conjunto de dados $\mathbf{X}$ é alimentado à rede através da camada de entrada
2. os dados passam por sucessivas operações lineares e não lineares a cada camada, chegando por fim à camada de saída
3. a camada de saída consiste em alguma tarefa, que determina a quantidade de dimensões dela
4. nesta tarefa, alguma métrica é computada utilizando a saída da rede e o valor verdadeiro y , como por exemplo a proporção de acertos em uma classificação, ou a soma das distâncias quadradas da previsão da posição de pontos em relação aos pontos corretos
5. o problema de otimização consiste em encontrar os parâmetros da rede neural cujo processamento dos dados garante os valores ótimos na determinada tarefa, podendo ser minimizar algum valor ou maximizá-lo
6. a otimização ocorre quando atualizamos os parâmetros, seguindo algum algoritmo específico, de forma que nos aproximamos da melhor rede neural possível (dentro dos moldes do modelo escolhido) para realizar a determinada tarefa

A otimização é, então, definida por uma função que metrifica a performance do modelo na tarefa, chamada de função de perda, e um algoritmo de atualização dos parâmetros, chamado de algoritmo de otimização. Dois exemplos que podemos citar são:

- *Mean-Squared Error*: utilizado em tarefas de regressão, esta métrica calcula a soma das distâncias dos pontos dos dados à curva regredida, minimizá-la consiste em encontrar os parâmetros da curva de regressão que mais se aproximam, em média, de todos os pontos. Matematicamente,

$$\mathcal{L}_{\text{MSE}}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.32)$$

Em que n é o número de observações da amostra, y_i é o valor correto (true label) da observação, $\hat{y}_i$ é o valor previsto pelo modelo.

- *Cross-Entropy*: utilizada em tarefas de classificação com múltiplas classes. Esta função de perda minimiza a diferença de uma função de probabilidade para as classes prevista pelo modelo e a distribuição verdadeira. Podemos escrever

$$\mathcal{L}_{\text{CE}}(y, \hat{y}) = - \sum_{i=1}^n y_i \log(\hat{y}_i) \quad (2.33)$$

Em que y_i é a classe correta e $\hat{y}_i$ a classe prevista pelo modelo. Geralmente y_i consiste em um vetor do tipo *one-hot* e o vetor $\hat{y}_i$ um vetor previsto com a distribuição de probabilidades discreta para cada classe.

A função de perda depende da tarefa a ser realizada pelo modelo, podendo ser qualquer função monotonicamente crescente. Em especial, uma outra função de perda precisa ser descrita:

- *Cosine Similarity*: a similaridade de cosseno é uma métrica que calcula quão parecidos dois vetores como o ângulo entre eles. Vetores similares são vetores com um ângulo menor, e vetores dissimilares possuem um ângulo maior. Felizmente, tal cálculo pode ser realizado fazendo-se o produto interno dos dois vetores e dividindo o resultado pelo produto da norma deles. Uma função de perda baseada nesta métrica pode ser descrita como

$$\mathcal{L}_{\cos} = \frac{1}{N} \sum_{i=1}^N \left(1 - \frac{\mathbf{y}_i \cdot \hat{\mathbf{y}}_i}{\|\mathbf{y}_i\| \|\hat{\mathbf{y}}_i\|} \right) \quad (2.34)$$

Em que y_i é o vetor correto e $\hat{y}_i$ o vetor previsto pelo modelo. O termo $1 -$ o produto interno vem do fato de querermos maximizar a função e não minimizá-la, assim dispondo desta forma a invertemos e podemos minimizar.

A posição de vetores no seu hiperespaço de representação é amplamente utilizada como um modelo de representação, ou seja, a identidade de um vetor é a posição do espaço para a qual ele aponta. Ao normalizar os vetores, a distância radial neste espaço torna-se irrelevante, e o hiperespaço de representação se torna uma hipersfera. Neste contexto, o ângulo entre os vetores, ou o cosseno deste ângulo (a similaridade de cosseno), torna-se uma métrica que avalia a distância entre eles.

Um dos campos de estudo que utiliza amplamente esta noção é o do processamento de linguagem natural. Palavras são vetores, sua representação está intimamente relacionada com sua posição na hipersfera. Naturalmente, para utilizar esta métrica, é necessário que a saída da rede seja um vetor, e que este vetor esteja relacionado com as palavras. De fato, a arquitetura Transformer (ver seção Transformer) transforma vetores de palavras em novos vetores de palavras. A saída de um *bloco* Transformer com n vetores de entrada são n vetores de saída. Transformações seguintes podem ser utilizadas para gerar uma única métrica para os n vetores de saída.

No caso deste trabalho, utilizamos a arquitetura transformers e não estamos interessado em comparar a representação de vetores individuais, mas a relação entre os vetores de uma da sentença. Através da hipótese de que um algoritmo de agrupamento hierárquico pode construir estrutura sintática da sentença (estrutura em árvore), desejamos comparar se a saída da rede pode ser transformada na árvore correta pelo algoritmo. O algoritmo, por sua vez, utiliza a distância euclidiana entre vetores para formar os agrupamentos (com outras variações de métricas de distância). Uma solução engenhosa é, então, pegar os n vetores de saída, calcular a distância euclidiana par-a-par, produzindo uma matriz de distância $\hat{D}_{n \times n}$. Esta matriz pode, então, ser comparada com uma matriz que represente a estrutura de árvore correta.

Métricas e algoritmos para árvores são um assunto complexo, não tendo muito consenso na comunidade. De fato, testamos diferentes métricas até encontrar uma que capturasse as propriedades dos dados que desejamos: árvores binárias geradas pelo algoritmo de agrupamento hierárquico. A distância entre duas folhas da árvore (duas palavras da sentença) é dada pelo maior valor de *cardinalidade* entre os dois agrupamentos aos quais as folhas pertencem. Cardinalidade, por sua vez, pode ser definida como o tamanho do agrupamento. Por exemplo, se a folha 1 está no agrupamento 1, que contém 2 elementos (folhas), e a folha 4 está no agrupamento 2 que contém 3 elementos, a distância entre a folha 1 e a folha 4 é 3. Não apenas isto, mas a distância de todos elementos do agrupamento 1 e todos elementos do agrupamento 2 será 3. Matematicamente, também podemos definir esta distância como o maior valor entre as alturas das subárvores que contém as folhas mais 1. Sejam C_i, C_j as cardinalidades dos agrupamentos que contém a folha/dado/palavra i e j ; e sejam T_i^h, T_j^h as subárvores que contêm i e j , escrevemos a distância entre i e j , D_{ij} , como

$$D_{ij} = \max(C_i, C_j) = \max(T_i^h, T_j^h) + 1 \quad (2.35)$$

A figura 2.9 ilustra esta métrica de distância com um exemplo, em que na esquerda temos a sentença "A menina viu o gato" e sua estrutura sintática em forma de árvore, no meio temos a matriz de distância D_{ij} entre os pares de palavras e à direita temos a visualização das métricas de cardinalidade $\{C_i, C_j\}$ e altura $\{T_i^h, T_j^h\}$.



Figura 2.9: Métrica de distância entre folhas de uma árvore. Na esquerda temos a sentença "A menina viu o gato" e sua estrutura sintática em forma de árvore, no meio temos a matriz de distância D_{ij} entre os pares de palavras e à direita temos a visualização das métricas de cardinalidade $\{C_i, C_j\}$ e altura $\{T_i^h, T_j^h\}$.

Por fim, para concluir a função de perda, transformamos ambas matrizes de distância verdadeira e prevista $\{D, \hat{D}\}$ em vetores unidimensionais, aplicando as seguintes transformações:

1. pega-se apenas a diagonal superior/inferior da matriz, já que ela é simétrica e os elementos são redundantes (pode-se zerar todos elementos abaixo/a cima da diagonal principal)
2. se achata a matriz, transformando-a em um vetor unidimensional
3. exclui-se todos elementos nulos, o que incluiu os elementos zerados no passo anterior e os elementos da diagonal principal
4. o vetor resultante contém todas as distâncias par-a-par, sendo equivalente à matriz original

A função de perda é, então, aplicada comparando ambos vetores y_i e $\hat{y}_i$ resultantes das matrizes de distância. Podemos escrever

$$y_i = \text{flatten}(\text{triu}(D_{ij}))_{\neq 0} \quad \hat{y}_i = \text{flatten}(\text{triu}(\hat{D}_{ij}))_{\neq 0} \quad (2.36)$$

Em que $\text{triu}()$ é a operação que zera os elementos abaixo da diagonal principal, $\text{flatten}()$ é a operação que achata a matriz e o subscrito $\neq 0$ filtra, mantendo apenas os elementos não-nulos. Para uma sequência de tamanho n palavras, os vetores $\{y_i, \hat{y}_i\}$ possuem tamanho $\binom{n}{2} = \frac{n(n-1)}{2}$.

Uma vez que temos a função de perda customizada, precisamos de um algoritmo que irá atualizar os valores dos parâmetros do modelo, de forma a melhorar a performance na dada tarefa. Este processo é o chamado processo de otimização, baseados no método de retropropagação introduzido em 1986. A retropropagação consiste em derivar a função de perda em relação aos parâmetros do modelo e fazer uma atualização na direção que minimiza esta função. Derivadas parciais capturam a influência de cada parâmetro individualmente para a minimização da função de perda, enquanto a regra da cadeia possibilita calcular as contribuições de parâmetros em camadas distantes da saída.

Os diversos modelos de otimização são:

- **Gradiente Descendente:** o principal modelo de otimização é chamado de gradiente descendente, que justamente descreve o processo do cálculo de derivadas e atualização dos parâmetros na direção que minimiza a função de perda. Para este algoritmo, todo conjunto de dados é utilizado para se calcular o gradiente e, utilizando sua média, se encontra a direção de máxima variação e se atualiza os pesos na direção oposta. Matematicamente,

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t) \quad (2.37)$$

em que θ são os parâmetros a serem ajustado, η a taxa de aprendizado, ∇_{θ} é o operador gradiente e $\mathcal{L}(\theta_t)$ é a função de perda, computada utilizando todos exemplos do conjunto de amostra.

- **Gradiente Descendente Estocástico:** uma variação do primeiro método, consiste em calcular o gradiente utilizando um exemplo de cada vez ao invés de todo conjunto de dados. Algumas vantagens que esta variação traz são: eficiência computacional (faz atualizações com mais frequência, treinamento em tempo real, aprendizagem acelerada no início, escape de mínimos locais, escalabilidade com grandes conjuntos de dados (não precisa carregar todos de uma só vez). Algumas desvantagens são: mais ruído nas atualizações, oscilações no caminho do gradiente, necessita de mais épocas para convergir, sendo esta mais instável.

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t; x_t, y_t) \quad (2.38)$$

em que os parâmetros são os mesmos do método acima, com exceção da função de perda $\mathcal{L}(\theta_t; x_t, y_t)$, computada utilizando apenas um exemplo do junto de amostra.

- **Gradiente Descendente em Batches:** um método intermediário entre os dois últimos, em que se particiona o conjunto de dados em batches, subgrupos, e se calcula a função de perda e a atualização para cada subgrupo, passando pro todos grupos a cada época.

2.5.4 Redes Neurais Transformer

O modelo Transformer foi introduzido em 2017 por pesquisadores da Google, e traz um mecanismo novo de atenção chamado de auto-atenção (ou self-attention, em inglês) (VASWANI et al., 2017) que produz vetores de palavra contextualizados com uma performance melhor e tempo de computação menor do que os modelos estado da arte da época, que eram as redes neurais recorrentes. O modelo, como o nome já sugere, consiste em um bloco de rede neurais que transforma os **vetores de entrada**, ou seja, para cada vetor $e_1, e_2, \dots, e_n$, **vetores de saída** $s_1, s_2, \dots, s_n$ serão produzidos. Em geral, múltiplas camadas de transformer são colocadas em sequência, de forma que ocorre uma transformação recorrente dos vetores. No fim da rede, uma tarefa é posta, geralmente a previsão da próxima palavra em uma sentença ou a previsão de alguma palavra que foi omitida na sentença. As redes, hoje, são as mais poderosas, estando presentes nos modelos generativos de linguagem, como o Chat GPT, o Gemini ou o Claude.

O mecanismo de auto-atenção consiste em produzir para cada vetor de entrada outros três vetores, chamados de Key, Query e Value. Para um dado vetor e_1 de dimensão $1 \times d_k$, pertencente a uma sequência de vetores da entrada da rede, $e_1, e_2, \dots, e_n$, o vetor Query de e_1 , Q_{e1} , é multiplicado pelos vetores Keys de todos vetores da sequência $K_{e1}, K_{e2}, \dots, K_{en}$ (uma matriz $\mathbf{K}^T$ de dimensão $n \times d_k$), de forma a produzir um escalar para cada multiplicação, ou seja, produz um vetor $Q_1 K$ de dimensão $1 \times d_n$ (figura 2.10). Cada componente do vetor pode ser interpretado como a influência (ou importância) de cada vetor da sequência em e_1 . Em seguida, o vetor $Q_{e1} K$ é normalizado através da divisão por $\sqrt{d_k}$ e transformado em uma probabilidade através de uma função softmax. O resultando, ou seja, $\text{softmax}(\frac{Q_{e1} K^T}{\sqrt{d_k}})$ é multiplicado pelo vetor Value de e_1 , V_1 , resultando em um vetor de tamanho $1 \times d_k$. Este último vetor é chamado de auto-atenção de e_1 . A auto-atenção é, então, somada ao valor de e_1 , o que produz o vetor não normalizado s'_1 , o que, normalizando-se, produz s_1 . Todo este processo pode ser escrito como:

$$s'_1 = e_1 + \text{softmax}(\frac{Q_{e1} \mathbf{K}^T}{\sqrt{d_k}}) V \quad s_1 = \frac{e_1 + \text{softmax}(\frac{Q_{e1} \mathbf{K}^T}{\sqrt{d_k}}) V}{\|s'_1\|} \quad (2.39)$$

Podemos, ainda, escrever estas equações de forma matricial, o que utilizando as matrizes de Queries, Keys e Values ($\mathbf{Q}, \mathbf{K}, \mathbf{V}$) nos dá a seguinte equação para a auto-atenção (attention), escrita de tal forma para ser idêntica à (VASWANI et al., 2017):

$$\text{attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}(\frac{\mathbf{Q} \mathbf{K}^T}{\sqrt{d_k}}) \mathbf{V} \quad (2.40)$$

O modelo ainda propõe a utilização de múltiplas instâncias da atenção, chamadas de *heads*. No caso, ao invés de se utilizar um conjunto vetores Queries, Keys e Values da mesma dimensão d_k para cada vetor de entrada, se utilizam vários vetores de dimensão múltipla de h do vetor de entrada, sendo h o




Figura 2.10: Mecanismo de auto-atenção da arquitetura transformer para um vetor e_1 . Para cada vetor e da sequência de entrada $(e_1, e_2, \dots, e_n)$ se produz três novos vetores, chamados de *keys*, *queries* e *values*. O processo de auto-atenção do vetor e_1 consiste em avaliar a importância de cada outro vetor através do produto escalar da *query* de e_1 Q_{e1} pelo vetor *key* dos vetor i K_i . O resultado é normalizado, dividindo-se pela raiz quadrada da dimensão k , e transforma-se em uma probabilidade através da aplicação da função softmax. Em seguida, este vetor resultante é multiplicado pela matriz contendo todos vetores de *values* da sequência, produzindo um vetor em que cada componente possui a contribuição ponderada (pela atenção) das componentes dos vetores *values* de toda a sequência. Esse vetor resultante é adicionado ao vetor original, produzindo uma atualização em sua representação ($e_1 \rightarrow s_1$).

número de heads de atenção. No fim, se concatena cada um dos resultados da atenção para se formar o vetor a ser somado com o vetor de entrada. Desta forma, escrevemos

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O \quad (2.41)$$

onde

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (2.42)$$

E as matrizes W são parâmetros utilizados para projetar os vetores de entrada e criar os vetores Key, Query e Value.

O transformer foi projetado para ser utilizado em conjunto com camadas densamente conectadas de um perceptron, formando então blocos transformer. Vários blocos transformer são postos em sequência, criando a profundidade de uma arquitetura transformer. O modelo BERT, por exemplo, possui 12 camadas, ou seja, 12 blocos transformer, com 8 heads e dimensão $k = 768$. Já o modelo GPT4 possui 120 camadas, um número gritantemente maior e que, fundamentalmente, foge da inspiração biológica.

2.5.5 Aprendizado não-supervisionado e Agrupamento Hierárquico

Dentro dos modelos de aprendizado não-supervisionado, citamos a análise dos componentes principais (PCA) e os algoritmos de agrupamentos (clusterização). O primeiro, consiste em um método de redução de dimensionalidade em que se encontra e prioriza novas dimensões do espaço de características que possuem a maior variância os dados. O segundo são técnicas que buscam agrupar os dados com base em características latentes.

Um dos problemas de se trabalhar com dados hiperdimensionais, ou representações hiperdimensionais, é sua difícil visualização e representação gráfica. Dado um conjunto de dados, em que cada amostra contém p características, se desejarmos fazer um gráfico destes dados, precisaríamos conseguir representar as p dimensões. Como isto não é possível, poderíamos escolher duas ou três das dimensões e representar apenas elas. O problema surge quando temos uma quantidade muito grande de possíveis combinações de dimensões. Por exemplo, combinando duas a duas, um total de $n(n-1)/2$ gráficos poderiam ser gerados. Dados com $p = 10$ teriam 45 possíveis combinações.

O método da análise das componentes principais, então, descobre novas dimensões, chamadas de componentes principais, que são combinações lineares das dimensões existentes e que maximizam a variância dos dados. Ele encontra quais são estas dimensões que mais explicam os dados, e assim pode-se explorar, visualizar ou analisar com outro método, compreendendo que temos uma aproximação da informação total do conjunto de dados. Matematicamente, as componentes principais de um conjunto de dados $\mathbf{X}$ são os autovetores da matriz de covariância destes dados, centralizados em zero. O autovalores de cada autovetor representam a variância explicada por cada componente principal.

Dado o conjunto de dados

$$X = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_n^T \end{bmatrix} \in R^{n \times p} \quad (2.43)$$

centralizamos em zero

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i, \quad \tilde{\mathbf{x}}_i = \mathbf{x}_i - \bar{\mathbf{x}} \quad (2.44)$$

obtemos a matriz de covariância C

$$C = \frac{1}{n} \tilde{X}^T \tilde{X} \in R^{p \times p} \quad (2.45)$$

e calculamos seus autovetores $\mathbf{u}_i$ e autovalores λ_i satisfazendo

$$C\mathbf{u}_i = \lambda_i \mathbf{u}_i \quad (2.46)$$

resolvendo o polinômio característico para encontrar os autovalores λ_i

$$\det(C - \lambda_i I) = 0 \quad (2.47)$$

e resolvendo o sistema de equações lineares para encontrar $\mathbf{u}_i$

$$(C - \lambda_i I)\mathbf{u}_i = 0 \quad (2.48)$$

Alternativamente, é possível encontrar os autovalores e autovetores associados à matriz de covariância através do método **decomposição em valores singulares (SVD, singular value decomposition)**, que consiste em decompor a matrix $\tilde{X}$ em três matrizes

$$\tilde{X} = U\Sigma V^T, \quad (2.49)$$

em que

- $U \in R^{n \times n}$ contém os vetores singulares à esquerda
- $\Sigma \in R^{n \times d}$ é diagonal com os valores singulares
- $V \in R^{d \times d}$ contém os vetores singulares à direita

Neste contexto, os vetores em U são os autovetores e os valores na diagonal de Σ são os autovalores, ordenados conforme a variância explicada dos dados. Pode-se transformar a representação de cada observação do conjunto de dados selecionando os autovetores com maior variância explicada como componentes principais

$$\mathbf{z}_i = U_m^T \tilde{\mathbf{x}}_i \in R^m \quad (2.50)$$

e assim visualizar ou analisar a melhor aproximação dos dados hiperdimensionais em um número menor de dimensões.

Sobre os métodos de Agrupamento, consistem em um conjunto amplo de técnicas que tem por objetivo encontrar subgrupos do conjunto de dados, chamados de agrupamentos. Estes agrupamentos devem possuir dados similares dentro de si, e dissimilares entre agrupamentos, o que de fato depende do conjunto de dados em si. A ideia central é encontrar subgrupos homogêneos dentro do conjunto de dados. Um dos modelos mais utilizando é chamado de Agrupamento K-means, em que se propõe dividir o conjunto de dados em um número K pré-especificado de agrupamentos. Começa-se com os dados distribuídos em seu espaço de representação, escolhendo K valores iniciais para os centroides dos agrupamentos. A partir disto, atribui a cada observação do conjunto de dados o pertencimento ao agrupamento cujo centroide mais próximo e calcula-se o valor do centroide de cada agrupamento utilizando os dados agrupados. Atribui-se novamente cada observação pertencendo ao agrupamento cujo centroide calculado nos dados está mais próximo, recalculando o centroide a partir disto. Repete-se o processo até que haja convergência dos centroides. O objetivo de otimização deste algoritmo é minimizar a variância intra-agrupamento. Matematicamente, podemos escrever

$$c_i = \arg \min_{j \in \{1, \dots, k\}} \|x_i - \mu_j\|^2 \quad (2.51)$$

em que c_i é o índice j do agrupamento atribuído à observação x_i , minimizando a distância com o centroide μ_j . A função de custo pode ser escrita como

$$J = \sum_{i=1}^n \|x_i - \mu_{c_i}\|^2 \quad (2.52)$$

em que x_i é a i ésima observação, μ_{c_i} é o centroide do cluster que x_i pertencer e n é o número total de observações.

Finalmente, podemos descrever o método chamado de Agrupamento Hierárquico. Este método, como o método acima, tem como objetivo formar os grupos de dados de acordo com uma medida de dissimilaridade (por exemplo a distância), fazendo um processo iterativo de agrupar ou desagrupar dados. Duas diferenças em relação ao método acima são: o agrupamento hierárquico não se compromete com um valor K dos agrupamentos e ele produz uma representação em forma de árvore chamada dendrograma. Existem duas variações principais, os chamados agrupamento hierárquico divisivo e agrupamento hierárquico aglomerativo. O primeiro consiste em começar com apenas um agrupamento, em que todas as observações fazem parte, e fazer divisões dos dados propondo mais agrupamentos. Um dos meios de realizar esta divisão de agrupamentos é através do método K-Means, chamado de Bisecting K-Means, em que se propõe primeiramente $K=2$ agrupamentos e se realiza a convergência dos centroides, depois se propõe $K=3$ agrupamentos, e assim por diante.

O segundo método, o agrupamento hierárquico aglomerativo, realiza o processo inverso: começa com todos os dados separados, que formam as folhas do dendrograma, calcula a dissimilaridade entre todos os pares de dados (por exemplo a distância euclidiana aos pares), agrupando aqueles dois que estão mais perto. Diferentes variações do algoritmo alteram a regra de agrupamento, podendo, inclusive, agrupar os dados mais distantes entre si. Essas variações alteram o chamado *linkage* do método, sendo as mais utilizadas:

- Completa: agrupa dados que possuem a maior dissimilaridade.
- Única: agrupa dados que possuem a menor dissimilaridade.

- Média: agrupa dados de acordo com a média da dissimilaridades entre todos pares de dados de um agrupamento e de outro.
- Centróide: agrupa dados de acordo com a dissimilaridade entre o centróide de cada agrupamento

Capítulo 3

HIPÓTESES E OBJETIVOS

3.1 Parte 1

As hipóteses desta parte podem ser descritas como:

- **Hipótese 1:** Oscilações cerebrais desempenham papéis funcionais nos processos de memória de trabalho, em específico a oscilação gama reflete a representação de informação, a oscilação teta organiza múltiplas informações em itens e a oscilação alfa perturba estes processos, impedindo sua manutenção.
- **Hipótese 2:** As oscilações cerebrais são ondas que viajam no espaço, produzindo excitações com diferenças de fases para pontos diferentes do espaço.
- **Hipótese 3:** A função disruptora das oscilações alfa são devido a sua interferência com as oscilações teta, produzindo uma oscilação do tipo batimento com mínimos que coincidem com o pico do fenômeno intracelular de despolarização pós disparo, terminando com a cíclica reativação dos padrões de disparo dos itens de memória.

Seguindo as hipóteses descritas acima, propomos dois objetivos gerais para este trabalho

- **Objetivo:** Estender o modelo neural computacional de arquitetura modular que utiliza oscilações cerebrais e ondas viajantes. Podemos detalhar os seguintes objetivos:
 - mapear e descrever as propriedades das operações de memória de trabalho na rede de arquitetura modular utilizando oscilações cerebrais e ondas viajantes
 - extensão com neurônios biologicamente realistas (equações de Hodgkin Huxley para neurônios do córtex pré-frontal L5)

3.2 Parte 2

As duas perguntas que motivam esta parte do trabalho são:

1. Como o cérebro representa a estrutura da linguagem, relações entre palavras e regras gramaticais?
2. Quais são os mecanismos pelos quais o cérebro processa a estrutura sintática?

para as quais propomos as seguintes hipóteses

- **Hipótese 1:** O cérebro representa a estrutura da linguagem através da representação multiplexada dos constituintes de uma frase (palavras e estruturas).
- **Hipótese 2:** O cérebro realiza o parsing das sentenças através da integração temporal limitada utilizando oscilações cerebrais e armazena e uma rede espacial de arquitetura modular.
- **Hipótese 3:** O algoritmo de agrupamento hierárquico pode ser utilizado para modelar a construção de estrutura sintática frasal, em que cada nível hierárquico representa a aplicação de uma operação linguística merge.

- **Hipótese 4:** Uma rede neural artificial pode ser treinada na tarefa de aprender as representações das palavras de forma que um algoritmo de agrupamento hierárquico produza a árvore sintática correta.

E os objetivos podem ser descritos como

- **Objetivo** Propor um algoritmo computacional simples e plausível para a construção de estrutura hierárquica frasal, conectando a linguística e a neurociência. Em que podemos discriminar
 - treinar uma rede neural artificial na tarefa de construção de estrutura hierárquica frasal através do algoritmo de agrupamento hierárquico
 - propor um modelo teórico de como o algoritmo poderia ser implementado em redes neurais biológicas de memória de trabalho

Capítulo 4

RESULTADOS

- Parte 1: Mechanistic role of alpha oscillations in a computational model of working memory, PLOS ONE.
- Parte 2: Hierarchical clustering as mechanistic process of syntactic structure building in a transformer architecture. (Não submetido)

RESEARCH ARTICLE


Mechanistic role of alpha oscillations in a computational model of working memory

Gustavo Soroka¹✉, Marco Idiart^{1,2}✉, Aline Villavicencio³*

1 Neuroscience Graduate Program, Federal University of Rio Grande do Sul (UFRGS), Porto Alegre, Brazil, **2** Department of Physics, Institute of Physics, Federal University of Rio Grande do Sul (UFRGS), Porto Alegre, Brazil, **3** Department of Computer Science, University of Sheffield, Sheffield, United Kingdom

✉ These authors contributed equally to this work.

* a.villavicencio@sheffield.ac.uk



Abstract

Brain oscillations are believed to be involved in the different operations necessary to manipulate information during working memory tasks. We propose a mechanistic role for the observed inhibition effect of the alpha rhythm based on its interference with the theta rhythm. Using the Lisman-Idiart model for multi-item working memory, we show that the interaction between these two oscillations is capable of creating a long lasting destructive interference that prevents the cyclic reactivation of neuronal ensembles and, as a consequence, memory maintenance. Additionally, to ensure robustness we propose a modular version of the model and implement oscillations as traveling waves. Using this model, we show that the interactions between theta and gamma determine the allocation of multiple memories in distinct modules, while the interference between theta and alpha disrupts the maintenance of the information already stored in them. The effect of alpha in erasing or blocking storage is robust and seems fairly independent of frequency, as long as it stays within the alpha range. This model helps us to understand why the alpha and theta oscillations, which have close frequency bands, could have opposite roles in working memory.

OPEN ACCESS

Citation: Soroka G, Idiart M, Villavicencio A (2024) Mechanistic role of alpha oscillations in a computational model of working memory. PLoS ONE 19(2): e0296217. <https://doi.org/10.1371/journal.pone.0296217>

Editor: Stéphane Charpier, Sorbonne Université UFR de Biologie, FRANCE

Received: July 8, 2023

Accepted: December 8, 2023

Published: February 8, 2024

Copyright: © 2024 Soroka et al. This is an open access article distributed under the terms of the [Creative Commons Attribution License](https://creativecommons.org/licenses/by/4.0/), which permits unrestricted use, distribution, and reproduction in any medium, provided the original author and source are credited.

Data Availability Statement: All relevant data are within the manuscript and associated code available in https://github.com/GustavoSoroka/mechanisticalpha_paper/tree/Revised.

Funding: G.S. and M.I. acknowledge funding from the Brazilian Agencies CAPES (88887.583995/2020-00) and CNPq (311497/2021-7). A.V. received funding from 457 EPSRC (EP/T02450X/1).

Competing interests: The authors have declared that no competing interests exist.

Introduction

Working memory is a putative memory system that incorporates many short-term information storage subsystems [1, 2], and serves as an interface between perception, long term memory and action [3]. In doing so, it contributes to higher cognitive functions such as reasoning, planning, decision-making and language comprehension [4].

Comprehensive models for a working memory system include specific components, or subsystems, to deal with different kinds of information and processes [2, 5, 6]. In particular, for the short-term storage devices that compose the working memory system, most of the proposed models agree that some sort of persistent activity of the neurons involved in storing the information is necessary, but disagree on the underlying physiological mechanism. These models can be divided in roughly two categories: those that favor network mechanisms (e.g. instantaneous attractors due to short-term synaptic changes and continuous attractors or bump models) and models that favor single cell phenomena.

In the last category is the model proposed by Lisman and Idiart [7]. According to this model, incoming information of a sequence of items to be memorized causes the ordered activation of item specific neural ensembles. The firing of these cells changes their intrinsic membrane properties producing a transitory excitability which peaks on a time scale of approximately 120ms after firing. In the absence of external inputs, these labeled cells can be reactivated by a nonspecific (non-informative) oscillatory input, provided that their period corresponds to the characteristic time of transient excitability. Therefore, they should be in the theta range. Another specific requirement of the model is feedback inhibition that prevents the synchronization of the different ensembles, so that the individual items are held active in time multiplexed fashion. A prediction of this model is a phase-amplitude coupling between the slow oscillations in the theta range representing the maintenance signal and the fast oscillations in the gamma range representing the firing of the stored memories. Subsequent studies have explored the theta-gamma mechanism in different models [8, 9] (see [10] for a review).

Another oscillation that has been associated with an active role in cognitive processes, including working memory, is the alpha oscillation, which was the first rhythm observed in humans almost a century ago [11]. Increases in alpha power were related to inhibited activity of areas during working memory maintenance tasks (see [12] for a review). During working memory scanning tasks, where subjects need to hold for a brief period of time several items in memory which are later tested, an increase in alpha power was observed during the retention period while a decrease was observed during the retrieval of information [13–15]. An increase in alpha power related to the number of stored items was also observed [13–15].

A few theories have been used to describe possible roles for the alpha oscillation. The *inhibition-timing hypothesis* proposes that the peaks of alpha constrains time-windows of opportunities for the firing of neurons [16], with the increase of alpha power leading to a decrease of the windows size. The *gating by inhibition hypothesis* supposes that alpha can select the most relevant information to be processed through the blocking of irrelevant information routes [17]. The *oscillatory selection hypothesis* suggests that the information selection could be accomplished by an entrainment between sensory stimulus and brain oscillations [18]. In general, the main functional role addressed for alpha oscillations relates to the inhibition of irrelevant information.

Dippoppa et al. [19, 20] proposed a computational model where brain oscillations act as functional operators of a working memory network, in other words, applying external oscillatory currents to the network allows it to store, maintain, prevent upload and erase information. In the model, oscillations in the beta-gamma range allow the upload of information, oscillations in the alpha range are responsible for erasing the content and preventing new content from being uploaded to the network, while oscillations in the theta range block upload but maintain the current content. However, in their current version of the model the issue of multiple item memory as well as the role of the oscillations phases are not fully explored.

Inspired by Dippoppa et al. [19], in this article we theoretically explore the possibility that oscillations in different frequency bands can play different roles in storage in a model with the characteristics of the Lisman-Idiart short-term memory model [7]. More specifically, we want to explore whether increasing alpha power at the external oscillatory input can disrupt the multiple-item maintenance in the model therefore acting as a gating signal to erase and block memory storage.

The Lisman-Idiart model hinges on three essential elements: neural short-term excitability, concurrent external oscillation, and feedback inhibition. This paper, similar to the work of Dipoppa and Gutkin, [19], fits into the category of theory-based models outlined by Bassett et al. [21]. In other words, we test our hypothesis exploring the potentiality of simple neural models, combining these elements without committing to specific biophysical mechanisms.

As for the network, we consider a modular version where the oscillations, responsible for the maintenance of the activity, sweep the network probing the modules as a traveling wave.

In the following sections we introduce the theta-alpha interference effect and the modular network model, discuss the results and present some conclusion. The mathematical descriptions of the neural models and the technical details about the computational experiments are left to the end in the Materials and Methods section.

The model

Here we present the modular version of the Lisman-Idiart theta-gamma model. The idea is to use space to improve the robustness of the model to noise as well as to enrich the possibilities of memory storage and manipulation. For simplicity we consider that the modules are distributed in a linear fashion (see Fig 1). In each module a short-term theta-gamma memory model is implemented as a network of excitatory neurons and inhibitory interneurons, that can perform multiple information storage through the cyclic reactivation of spatial firing patterns due to the combination of depolarizing currents after an action potential (ADP) and the excitatory drive by an unspecific oscillatory input on the theta-alpha frequency range (6–12Hz). For most of the analysis, we utilize a current-based integrate-and-fire neural model (IF-Model) with an artificial resettable afterspike depolarization (ADP), as initially proposed by Lisman and Idiart [7]. Additionally, as a proof of concept, we employ a more biophysically realistic model proposed by Rodriguez et al. [22] for L5 PFC pyramidal neurons, where the ADP is explained in terms of intrinsic calcium dynamics (high-threshold calcium currents and calcium-activated nonspecific cation current) in a Hodgkin-Huxley conductance based model (HH-Model). See [Materials and methods](#).

In addition we consider that the oscillatory inputs are traveling waves in such a way that each module receives an oscillation with a slightly different phase. The evidence of travelling waves in the brain dates back almost to the first human EEG recording (see [23]), but its




Fig 1. Modular working memory network. The modules are arranged linearly, each one composed by excitatory principal neurons (red circles) and inhibitory interneurons (blue circles). The informational inputs reach all modules synchronously while the unspecific oscillatory inputs (Osc_1 and Osc_2) are traveling waves and therefore, at a given time, the modules have oscillations with different phases. When in storage mode (maintain) a spatial firing pattern is reactivated for each module, producing the cyclic phenomena observed in the rasterplot of Fig 3.

<https://doi.org/10.1371/journal.pone.0296217.g001>

importance has been recently highlighted by experimental work demonstrating that theta propagates in the hippocampus [24–26], and theta and alpha propagate in the neocortex [27]. For a theoretical review see [28].

As in the original Lisman-Idiart Model, each module is capable of coding a number of overlapping firing patterns. But the modular version allows different items to be simultaneously stored in distinct modules that are scanned periodically by the travelling wave. It combines spatial and temporal properties such that the change in the oscillatory frequency input allows a much richer repertoire of operations for manipulating the information held in working memory.

Dipoppa et al [19] proposed four essential operations for a short-term memory model: load, maintain, block and erase. In this paper we show how each one of these operations can be performed in the context of our model, with the exception of the block operation that is not implemented independently but associated with the erase operation.

In other words, we consider that a network is blocked when it cannot hold information. The theta frequency will be responsible for allowing the load and maintain operations to take place and the alpha oscillations will perform the block/erase operations by interfering with the theta oscillations.

Results

Fig 2 illustrates the basic mechanism governing memory maintenance using both the IF-Model and the more intricate HH-Model. Both neuron models receive a sequence of three inputs:




Fig 2. Memory maintenance. The model's memory behavior can be illustrated as follows: a neuron receives an informational input (square pulse) triggering firing, followed by a subthreshold network oscillation that, on its own, doesn't induce firing. If the amplitude of the network oscillation is too low the memory is not maintained. In (A), the neuron is an IF-model with stereotyped ADP, and in (C), it is the HH-model [22] with realistic calcium ADP and AHP. Panels (B) and (D) depict the impact of the oscillation phases due to the modularity of the network for both neuron models.

<https://doi.org/10.1371/journal.pone.0296217.g002>

an informational input sufficient to trigger firing, a subthreshold oscillation capable of sustaining firing in neurons that received the informational input but insufficient to cause firing on its own, and an oscillation unable to maintain firing. We observe that the more realistic neuron models, grounded in experimentally observed currents, replicates the behavior exhibited by the simpler model, Fig 2a. We employed the original set of parameters from Rodriguez et al. [22] for calcium currents (CaL, CAN) and calcium dynamics (Ca2), along with the parameters from Golomb and Amitai [29] for spike currents (Na, K), all without requiring further adjustments (refer to Materials and Methods). By supplying sufficient initial external current to activate after-depolarization (ADP), the HH-Model can be driven by an 8Hz oscillatory subthreshold current (see Fig 2c), demonstrating bistability through firing once per cycle during the oscillatory phase. The HH-Model proposed by Rodriguez et al. [22] exhibits an additional after-hyperpolarization (AHP) current, absent in our IF-Model. The significance of the AHP current lies in its ability to replicate spike irregularities observed in experimental data [22], this is less relevant in the context of the analysis conducted in this paper where the neurons are reactivated in a much lower frequency. Fig 2b and 2d demonstrate how firing can be temporally segregated in both models if the neurons are driven by oscillations with different phases.

Having established, at a qualitative level, the compatibility between the IF-Model and the HH-Model concerning the fundamental mechanism behind our memory model, we now restrict our analysis to the IF-Model. This choice is motivated by its fewer parameters, facilitating a clearer interpretation of the system. Fig 3 illustrates the load operation, that allocates exactly one piece of information per module, when sequential stimuli are fed to the network. On the top we have the input currents of the four stimuli. The currents are Gaussian shaped to




Fig 3. Sequential allocation of items in different modules. On top: four Gaussian stimuli colored and labeled red for A, purple for B, blue for C and green for D. Middle: rasterplot of modules M1, M2, M3 and M4 during two cycles. The excitatory neurons are shown with a red gradient discriminating neurons that codes different stimuli (A-D). Inhibitory neurons are shown in blue. Shaded grey areas indicate the time windows of max neuronal excitability due to the theta wave of (>0.9 max). Bottom: cumulative frequency of the firing of neurons for each module (line style) and each stimulus (color). Label on the right, where $a \in [A, B, C, D]$. Parameters used: $\psi_{osc} = 0.9$ rad/module, $f_r = 50$ Hz, $f_\theta = 8$ Hz, $\phi_i = 0.8$ rad.

<https://doi.org/10.1371/journal.pone.0296217.g003>

account for small asynchronies from the upstream inputs. The activities in each module are represented below with raster plots. The excitatory neurons are shown with a red gradient discriminating neurons that code different stimuli (A-D). Inhibitory neurons are shown in blue. On the bottom, the cumulative frequency for the firing of neurons representing each stimulus for each module are shown. The color code distinguishes each stimulus and the line style distinguishes the modules. Shaded areas represent the peaks of the traveling wave across the network.

In order to better understand the properties of the model after the introduction of the modular structure, we address the question of if there is an optimal delay between stimuli (or an optimal presentation frequency) for the correct allocation of items into different modules. We imagine four items (A through D) being presented to be held in memory at a rate f_γ . This is translated in terms of a sequence of Gaussian input currents to the network (Fig 3 top). The Gaussian shapes of the inputs account for a certain degree of asynchrony in the upstream network representing the items and as a whole the input resembles a bout of gamma oscillations of frequency f_γ (Fig 4a). The informational inputs are fed synchronously to all modules of the network, but they reach each of the modules on a different phase of the unspecific oscillatory input due its propagation speed (v_{osc}). The phase difference between consecutive modules is $\psi_{osc} = 2\pi f_{osc} d / v_{osc}$ where d is the physical distance between the center of two consecutive modules and f_{osc} is the oscillatory frequency, and we make the simplifying assumption that all neurons in a given module are under the same phase. We define the input phase $\phi_{p,m}$ of the p^{th} item in the module m as the phase difference between the positive peak of the oscillation in that module and the item input time

$$\phi_{p,m} = \phi_i - (p-1)\phi_\gamma + (m-1)\psi_{osc}$$




Fig 4. Memory allocation on different modules. A) Definition of f_γ , ψ_{osc} and ϕ_i . Four different stimulus are given equally to all four modules, with a given f_γ frequency, modeled as independent Gaussian currents. ψ_{osc} is the phase difference of the external oscillation of two sequential modules. ϕ_i is the phase difference, in module M1, between the oscillations peak and the first input. B) Map of the f_γ^{Best} for a given set of ϕ_i and ψ_{osc} when the oscillation is in the theta range $f_\theta = 8\text{Hz}$. Blank area represents the condition where the four stimulus were not correctly allocated to the four modules. C) f_γ^{Best} dependency on ψ_{osc} for three values of ϕ_i . Shaded areas show the upper and lower values of f_γ that loaded A, B, C and D in M1, M2, M3 and M4. D) $\psi_{osc} \times \phi_i$ map of the working memory parameter O_s using the f_γ^{Best} during the first three cycles including stimulation (left to right). Three rasterplot samples are shown below in blue, red and green for three different conditions. The map is the mean of 50 repetitions.

<https://doi.org/10.1371/journal.pone.0296217.g004>

where $\psi_\gamma = 2\pi f_{\text{osc}}/f_\gamma$ and ϕ_i is the input phase of the first item in the first module (see Fig 4a). The input phase is positive if the stimulus anticipates the peak. Therefore, to evaluate the success of the load operation in different circumstances, three parameters are available: the presentation frequency of the items f_γ , the phase difference between modules ψ_{osc} and the input phase of the first item in the first module ϕ_i .

We consider that the load operation is successful if items presented in a sequence are distributed in an orderly fashion among the different modules preserving sequence information. The easiest of possible orders is to have each item stored in a different module (Fig 3) so that the first item is represented in the first module, the second in the second, and so forth. The success of the load operation, therefore, depends on an optimal temporal match between the timings of the item inputs and the windows of opportunity defined by the positive phases of the oscillatory drive in each of the different modules. This involves adjusting the f_γ , ψ_{osc} and ϕ_i parameters. We devised a criterion that optimizes f_γ given a choice of ψ_{osc} and ϕ_i . Fig 4b shows a map where the color indicates the optimal values of f_γ^{Best} , and where the blank area is the condition where the four stimuli are never allocated correctly (see Materials and methods). Fig 4c has the same information of Fig 4b, but represented as different curves of $(f_\gamma^{\text{Best}} \times \psi_{\text{osc}})$ for each ϕ_i condition. In Fig 4d we take the f_γ^{Best} for each set of $(\psi_{\text{osc}}, \phi_i)$ and display the multi-item working memory parameter O_s for the three initial cycles including the stimulation (left to right), showing a well defined region for a good working memory performance, exemplified by a rasterplot sample of three different conditions (blue, red and green). O_s is a parameter defined to account for synchronization within modules and asynchronization between modules using only the statistical properties of the neuronal firing in order to evaluate the performance of the multi-item working memory storage (between 0 and 1). S1 Fig shows Fig 4c curve for all ϕ_i conditions and S2 Fig shows Fig 4b and 4c using and alpha oscillation (12 Hz) instead of theta (8Hz).

The next issue is how well the network maintains information stored through time. In the Lisman-Idiart model for multi-item working memory, the combination of the oscillatory current in theta frequency and the membrane after-depolarization current creates a state of neuronal cyclic reactivation (Fig 5a), therefore neurons activated by a stimulus will be perpetually reactivated.

We consider that the maintenance operation is successfully accomplished if three requirements are met: i) all the neurons representing an item are firing with a good degree of synchrony during memory maintenance ii) each item is stored in a different module so neurons from different items fire asynchronously, iii) memory is reactivated in the first cycle of the unspecific oscillation. Using these criteria, we devised an order parameter ($O_s(z)$) that measures the quality of the memory load and maintenance at a given cycle (z) (See Materials and methods). Higher values of $O_s(z)$ indicate better storage. Fig 5b shows that the four items correctly allocated are stably maintained through time by four different modules.

While the power of theta oscillations is correlated with the maintenance of working memory, the power of alpha is thought to actively inhibit irrelevant information on the same tasks. We propose that a possible mechanism for this inhibitory effect is the interference between existing oscillations in the alpha and theta range in the same network. We call it *Oscillatory Interference Hypothesis*. We consider that the combination of alpha and theta frequencies produces a beat, and the cyclic reactivation of the firing patterns proposed in Lisman-Idiart ends up impaired and canceled, resulting in an **erase** operation on the working memory buffer (Fig 6a). In order to measure the correlation between the probability of alpha erasing the stored memories and three different parameters of the system (A_α , α onset and f_α), we first calculate the average value of $O_s(z)$ parameter for the three cycles after alpha onset ($z = 1', 2'$ and $3'$),




Fig 5. Memory maintenance. A) Basic mechanism for maintenance at the neuronal level: the sum of the oscillatory theta input and the intrinsic afterdepolarization current is sufficient for a cyclic reactivation of the neurons once stimulated. B) Four items, one allocated to each module, are stably maintained in time for several theta cycles. The y-axis accounts for the fraction of active neurons of each item that during each cycle ($n_a(z)/N_a$, $a \in [A, B, C, D]$) and the $O_s(z)$ parameter.

<https://doi.org/10.1371/journal.pone.0296217.g005>

then binarized using the values of $O_s < 0.5$ as memory successfully erased ($P_{erase} = 1$) and $O_s > 0.5$ memory not erased ($P_{erase} = 0$) and plotted logistic regression fitting curves. Fig 5b shows that the inhibitory role of alpha was independent of the amplitude and the initial onset, but dependent on the specific frequency within the alpha band.

Discussion

We proposed an adaptation of the Lisman-Idiart model where the neurons are structured in spatial modules and the oscillations are traveling waves. The main reasons for these are (i) to increase the robustness of the model and (ii) to test the gating effect of different external oscillatory inputs. The original model segregated memories through fast-response inhibition, with sequential delays of the firing reactivations [7]. As a result it was unstable to noise and prone to synchronization of neurons belonging to different items. It is important to note that underlying the concept of a multiplexing network, as proposed here, is Singer's Binding by Synchrony hypothesis [30]. This hypothesis posits that the integral representation of an item is achieved through the synchronization of neural ensembles encoding its characteristics. For instance, the simultaneous representation in short-term memory of a blue circle and a red square is achieved through the specific synchronization of neurons corresponding to the accurate combination of shapes and colors. In simpler terms, blue neurons should synchronize with circle neurons, while red neurons should synchronize with square neurons. Consequently, synchronizing the ensembles of both items is damaging as it eliminates phase information, making it impossible to know the color associated with each shape.

With the introduction of network modularity and the oscillatory inputs as traveling waves the model becomes more robust. Recent evidence suggest that oscillations in the hippocampus and neocortex are indeed traveling waves [25–27]. There is also overwhelming experimental evidence that the brain has a modular architecture, where neurons connect together forming micro local networks. The new version of the model, therefore, introduces not only phase but

also space as part of the code. Since lists of items can come in any order we also assume that the modules have enough capacity to represent many items and that a specific item can be represented in different modules. This also solves the problem of storing similar items with overlapping neural representations since they will be active in different modules during multi-item storage.

In the simulated experiments we show that even if four stimuli are given equally to four modules, the excitatory dynamic created by a theta traveling wave allows the correct allocation of one memory item in each module. The optimal frequency to load a sequence of items is related to the speed of the traveling wave, that binds the theta and the gamma oscillations. This frequency is approximately the one in which the gamma period matches the difference in time between the phases of theta oscillations of two sequential modules being smaller as the global inhibition increases. In our model, the stimulus presentation should be interpreted as presented to the neural circuit and not the individual, being preprocessed by other brain regions and temporally compressed before being sent to the working memory system. Recent studies investigating theta and alpha oscillations as traveling waves indicate a phase difference of 2π rad/cm in the rat hippocampus [24], 0.1rad/cm in the human hippocampus [25] and $0.3 - 1.25\text{rad/cm}$ in the human neocortex [27], suggesting that our model would fit better on a human neocortical surface circuit, with a spatial scale of centimeters in and between modules. Our model indicates that there is a wide range of parameter allowing the theta and gamma oscillations to create the multi-item working memory storage. The blank area of the map of Fig 3b represents a more complex condition where more than one item is coded on the same module or the same item is coded by two different modules. Since every module has all the features of the Lisman-Idiart model, they could operate as local short-term buffers in case there is no interaction between modules. Regarding evidence about the role of the direction of propagation of the travelling waves in working memory [27], one possibility is that the coherence of the propagation of the travelling waves could recruit more or less modules, turning on the spatial features or maintaining just the local ones.

We use the same maintenance mechanism proposed on the Lisman-Idiart model, where stimulated neurons present afterdepolarization currents and the sum with the oscillatory theta input allows a cyclic reactivation. So, the same neurons once stimulated will fire again on each theta cycle. The same patterns activated by the stimuli A,B,C and D are repeated on each cycle for the modules M1, M2, M3 and M4.

The Oscillatory Interference Hypothesis showed to be a plausible mechanism for the blocking role of the alpha oscillations. Considering a condition where the alpha and theta oscillations compete for power (similar amplitudes). Alpha was able to disrupt the working memory performance in the model independently of its amplitude (Fig 6b, left panel). The effect also was relatively insensitive to the phase during the onset of alpha (Fig 6b, middle panel). As for the frequency values there is a sharp transition where, for a theta $\simeq 8\text{Hz}$, values of alpha frequency above 10Hz effectively erased the working memory buffer (Fig 6b, right panel). The measures taken used the combination of three cycles to ensure the time needed for the system to show long lasting and stable behaviour.

In our model alpha disrupts working memory by interfering with theta. The result is a beat profile that produces a long lasting period of low amplitude oscillations (Fig 7). Using a condition where both alpha and theta are synchronized at phase = 0 during alpha onset, it is possible to determine which values of alpha (and higher frequency bands) could produce a beat where the valley coincides with the peak of the ADP ($I_{ADP} > 0.85A_{ADP}$). Fig 7 top colored curves shows two of the four beatings (red and green) with minimums (τ_{min}^1 and τ_{min}^2) coinciding with ADP's peak (ADP shown as the bottom curve, peak in bold) for theta = 8Hz . The analytical




Fig 6. Memory erasing. A) Simulation's protocol: Load—Information is loaded in the network; Maintain—Information is maintained by reactivation for four oscillatory cycles; Erase—The onset of alpha oscillations occurs and storage measures are made on the next three cycles. B) Multi-item working memory performance measured by the O_s parameter during the first three theta cycles (1', 2' and 3') after the onset of alpha. The plots show dependency with the amplitude of alpha, the onset theta phase and the alpha frequency. Thick red lines shows the binned mean, where the markers are the bin's center and the shadowed area is the standard deviation.

<https://doi.org/10.1371/journal.pone.0296217.g006>

curve for the τ_{min} is computed as half of the inverse of the beat frequency (see [Materials and methods](#)) and is shown as dashed gray line. The min and max alpha frequency that coincides with the ADP's peak is shown closed to the ADP's curve in black (10.4 Hz and 15.5 Hz, mean value 12.95 Hz). For other values of f_{θ} , the inserted plot shows the dependence between the average value for alpha ($f_{\alpha}^{mean} = \frac{f_{\alpha}^{max} + f_{\alpha}^{min}}{2}$) and theta frequency. This could explain the alpha frequency dependency found during our simulations.

Concerning the potential physiological validity of the derived properties within the IF-Model discussed here, we take initial steps towards a more realistic neural implementation. We showed that, at the fundamental level of memory maintenance, both the IF-Model and the more realistic HH-Model proposed by Rodriguez et al. [22] exhibit similar behavior. The intrinsic currents responsible for the HH-Model's after-spike depolarization (CaL, CAN) produce an effect akin to the IF-Model's more stereotyped ADP current. Both exhibit an asymmetric shape, characterized by a faster rise than decay, with amplitudes falling within the range of approximately 2.5 to 15mV. While Rodriguez et al. characterizes the ADP phenomenon as




Fig 7. Alpha inhibitory mechanism. A) Beat, in red, produced by an theta (8Hz) and alpha oscillation (10 Hz), dashed black lines, starting synchronized with phase = 0. B) Values of alpha (and higher frequency bands) could produce a beat where the valley coincides with the next two theta peaks, for theta = 8Hz. C) Mean possible alpha ($\bar{f}_\alpha = f_\alpha^{\max} - f_\alpha^{\min}$) for other values of f_θ .

<https://doi.org/10.1371/journal.pone.0296217.g007>

an after-burst depolarization, we consider every depolarization that emerges after each spike (See Fig 2). However, much exploration is needed within the broader parameter space of the HH-Model.

Conclusion

In this paper, we discussed a possible mechanism behind the effect that oscillations in the alpha range appear to have in cognitive tasks that demand that subjects disregard parts of the external stimuli. We do it in the light of the theta-gamma model proposed by Lisman-Idiart. In this model memory maintenance depends on two factors. The first is an intrinsic excitability caused by recent activity that tags neurons associated with a given memory. The second is an oscillatory input, in the theta range, that is sub-threshold for neurons that are not part of the memory but can drive the tagged neurons back to activity keeping them in oscillatory persistent activity, since there is a resonance effect between the time course of the excitability and the oscillatory input. According to the logic of the model, memory erasure could be accomplished by either eliminating the neural intrinsic response to firing or by disrupting the oscillatory input that refreshes the memory. We propose that an efficient way to disrupt the oscillation is by gating to the circuit an oscillation in the alpha range that will be superimposed over the existing theta oscillation causing amplitude modulations with the exact time scale to prevent the tagged neurons from refreshing their excitability. Although the same effect could be easily accomplished by reducing the power of the theta oscillations, in this paper we subscribe to the view that oscillations are natural attractors for the biological neural networks and preventing them may be more energetically costly than just combining them [31]. In future work we aim to explore the interplay between oscillations and item similarity in long-term memory. This interaction has the potential to mitigate the impact of noise in the model. Noise disrupts firing patterns, causing neurons that should be firing together to desynchronize and synchronizing those that should not. Recurrent connections play a vital role in counteracting these tendencies, thereby preserving the integrity of neural ensembles that collectively represent the same memory. Once the parameter intervals for the basic IF-Model are established, a

pivotal next step is to find equivalent parameter intervals in more realistic neural models, such as the one proposed by Rodriguez et al. [22], and subsequently compare them with physiologically realistic parameters.

Materials and Methods

Network

We consider a network composed by N neurons, of which N_{ex} are principal excitatory and N_{inh} are inhibitory interneurons. The network is divided in M spatial modules, with N_a/M neurons of each type, $a = ex, inh$. The neural connectivity depends on the modules the neurons belong to, as well as the oscillatory inputs, with sequential oscillatory phase-differences producing the effect of a travelling wave. The stimulus input and the output occur simultaneously for all modules.

Connections

The network has the connectivity matrix presented in the S3 Fig, where the synaptic strengths are randomly generated by a uniform distribution between 0 and W_{type} that depends on the kind of connection.

$$W_{ab} \sim U(0, W_{type}) \quad (1)$$

where W_{ab} is the connection from the presynaptic neuron to the postsynaptic neuron and $U(0, W_{type})$ is a uniformly distributed random number between 0 and W_{type} . W_{type} can be Global (W_{EI}, W_{IE}) or Modular (W_{EE}, W_{EI}, W_{IE}).

Integrate-and-fire neuron model

The neurons are modeled as current based integrate and fire, given by the equation

$$\tau_m \frac{dV}{dt} = -(V - V_r) + \sum_i I_i \quad (2)$$

where V is the membrane potential, V_r is the resting potential, τ_m is the membrane time constant and the last term is the sum over the i input currents. The potential is reset to a hyperpolarized value V_{reset} after passing the firing threshold of $V_{threshold}$ and stays unable to fire again for refractory time of $t_{refractory}$.

The total post-synaptic input received by the neuron “i” due to the firing of other neurons “j” in a given time “t” is

$$I_i^{ps}(t) = \sum_{j=1}^N W_{ij} \sum_{s=1}^{n_j(t)} P(t - t_j^{(s)}) \quad (3)$$

where W_{ij} is the synaptic weight, $n_j(t)$ is the number of spikes fired by the jth neuron up to time t , and $t_j^{(s)}$ are the spike times, and the individual input P is

$$P(t) = H(t) e^{-t/\tau_{psp}} \quad (4)$$

where H represent a Heaviside function. The principal excitatory neurons have an afterdepolarization potential that is reset for each new spike.

$$I_i^{ADP}(t) = A_{ADP} \left(\frac{t - t_i^*}{\tau_{ADP}} \right) e^{-(t - t_i^*)/\tau_{ADP} + 1} H(t - t_i^*) \quad (5)$$

where $t_i^* < t$ is the last spike of cell i before time t . The informational stimulus are modeled as Gaussian pulses

$$I_i^{inf}(t) = A_{inf} \delta_{i \in A} e^{-(t-t_A)^2/(2\sigma_T^2)} \quad (6)$$

where A_{inf} is the input amplitude, t_A the average time the stimulus was presented to the network and $\delta_{i \in A}$ indicates that only neurons linked to the information pattern A receive the inputs. The oscillatory inputs are given by the sinusoidal function

$$I_i^{osc}(t) = A_{osc} \sin(2\pi f_{osc} t + (m_i - 1)\psi_{osc}) \quad (7)$$

where A_{osc} is the amplitude, f_{osc} is the frequency, ψ_{osc} is a phase-shift creating a travelling wave effect and $m_i = 1, 2, \dots, M$ is the module index of the i th neuron. The oscillatory power is modeled as all external oscillations come from the same source, meaning that the total power is a constrain condition for the system.

Noise

We consider only additive noise and introduce it in the simulations as a variability in the firing threshold for each neuron

$$V_{threshold,i} = -50 + \eta_i \quad (8)$$

where

$$\eta_i \sim N(\mu_{noise}, \sigma_{noise})$$

is a normally distributed random variable with mean μ_{noise} and standard deviation σ_{noise} that is drawn independently for each neuron after each new spike. This is a strategy to decrease simulation time, valid for the IF-Model in the regime of low-frequency spiking (< 10 Hz). Within this range, pure white noise added to the threshold is equivalent to more complete treatment of noise as long as its correlation decay time is significantly shorter than the theta oscillation period.

Neurophysiological realistic neuron model

Neuronal model adapted from L5 PFC pyramidal neurons from Rodriguez et al. [22]. Neurons are Hodgkin-Huxley neurons described by

$$C \frac{dV}{dt} = -(I_L + I_{Na} + I_K + I_{CaL} + I_{CAN} + I_{AHP}) + I_{Inj} \quad (9)$$

The Leak current I_L is written as

$$I_L = g_L(V - V_L) \quad (10)$$

The sodium current I_{Na} is defined by

$$I_{Na}(V, h) = g_{Na} m_\infty^3(V) h (V - V_{Na}) \quad (11)$$

with

$$\begin{aligned}\frac{dh}{dt} &= [h_{\infty}(V) - h]/\tau_h(V) \\ m_{\infty}(V) &= \{1 + \exp[-(V - \theta_m)/\sigma_m]\}^{-1} \\ h_{\infty}(V) &= \{1 + \exp[-(V - \theta_h)/\sigma_h]\}^{-1} \\ \tau_h(V) &= 0.37 + 2.78 * \{1 + \exp[-(V - \theta_{ht})/\sigma_{ht}]\}^{-1}\end{aligned}\quad (12)$$

The potassium current I_K is defined by

$$I_K(V, n) = g_K n^4 (V - V_K) \quad (13)$$

with

$$\begin{aligned}\frac{dn}{dt} &= [n_{\infty}(V) - n]/\tau_n(V) \\ n_{\infty}(V) &= \{1 + \exp[-(V - \theta_n)/\sigma_n]\}^{-1} \\ \tau_n(V) &= 0.37 + 1.85 * \{1 + \exp[-(V - \theta_{nt})/\sigma_{nt}]\}^{-1}\end{aligned}\quad (14)$$

The high-threshold calcium current I_{CaL} is determined by the following equations

$$I_{CaL} = \bar{g}_{CaL} x_{CaL}^2 (V - V_{CaL}) \quad (15)$$

with the activation variable x_{CaL} satisfying

$$\begin{aligned}\frac{dx_{CaL}}{dt} &= \frac{x_{CaL}^{\infty}(V) - x_{CaL}}{\tau_{CaL}(V)} \\ \tau_{CaL}(V) &= 10^{\alpha_{CaL} + \beta_{CaL} V} \\ x_{CaL}^{\infty}(V) &= \{1 + \exp[-(V - V_{1/2, CaL})/K_{CaL}]\}^{-1}\end{aligned}\quad (16)$$

The calcium-activated nonspecific cation current I_{CAN} has the following equation

$$I_{CAN} = \bar{g}_{CAN} x_{CAN} (V - V_{CAN}) \quad (17)$$

with the activation x_{CAN} depending on the intracellular calcium concentrations as

$$\begin{aligned}\frac{dx_{CAN}}{dt} &= \frac{x_{CAN}^{\infty}(Ca) - x_{CAN}}{\tau_{CAN}(Ca)} \\ \tau_{CAN}(Ca) &= \frac{1}{\alpha_{CAN} * Ca + \beta_{CAN}} \\ x_{CAN}^{\infty}(Ca) &= \frac{\alpha_{CAN} * Ca}{\alpha_{CAN} * Ca + \beta_{CAN}}.\end{aligned}\quad (18)$$

The hyperpolarizing current I_{AHP} is described by

$$I_{AHP} = \bar{g}_{AHP} x_{AHP}^2 (V - V_{AHP}) \quad (19)$$

where the activation x_{AHP} follows

$$\begin{aligned}\frac{dx_{AHP}}{dt} &= \frac{x_{AHP}^{\infty}(Ca) - x_{AHP}}{\tau_{AHP}(Ca)} \\ \tau_{AHP}(Ca) &= \frac{1}{\alpha_{AHP} * Ca + \beta_{AHP}} \\ x_{AHP}^{\infty} &= \frac{\alpha_{AHP} * Ca}{\alpha_{AHP} * Ca + \beta_{AHP}}.\end{aligned}\quad (20)$$

The calcium concentration dynamics is described by

$$\frac{dCa}{dt} = -\frac{1}{2F} \frac{Surf}{Vol} I_{CaL} + \frac{Ca_0 - Ca}{\tau_{Ca}} \quad (21)$$

where

$$\frac{Surf}{Vol} = r_1^{-1} \left(1 - \frac{r_1}{r_0} + \frac{r_1^2}{3r_0^2} \right)^{-1} \quad (22)$$

The injection current is modeled in three modes as

$$I_{inj} = \begin{cases} A_{event} & \text{if } 20ms < t < 220ms \\ A_{osc}^{delay} \sin(2\pi f_{osc}^{delay} t + \psi_{osc}^{delay}) & \text{if } 220ms \leq t < 1220ms \\ (A_{osc}^{delay}/2) \sin(2\pi f_{osc}^{delay} t + \psi_{osc}^{delay}) & \text{if } 1220ms \leq t \end{cases}$$

The parameters used are summarized in Table 2.

Metrics for loading performance

In order to evaluate the best frequency of stimuli presentation f_γ , for loading information into the network given the parameters (ψ_{osc}, ϕ_i) , we simulated the loading cycle (zero cycle) of our network varying f_γ between 100Hz and 33.33Hz. We then counted the number of activated cells for each item for each module $n_{a,m}$ where $a \in [A, B, C, D]$ and $m \in [M1, M2, M3, M4]$. We consider that, in a first approximation, a frequency is suitable for loading if the order of the stimuli is preserved in the modules. In other words, if the first item is the winner (the most active) in the first module, the second item is the winner in the second module, and so on. Mathematically a binary loading suitability can be written as

$$\ell(f|g) = \prod_i \prod_{j \neq i} H[n_{i,i}(f) - g n_{i,j}(f)] \quad (23)$$

where $H[\cdot]$ is the Heaviside function, the level $g > 1$ is a parameter that controls how bigger the winners must be (for instance, $g = 2$ indicates that the winner has to be at least twice the runner up), and the indexes i, j are numerical indexes representing items and modules considered here in equal number. We assume that the most suitable frequency (the best f_γ) for loading information for a given (ψ_{osc}, ϕ_i) as the average

$$f_\gamma^{\text{Best}}(\psi_\theta, \phi_i|g) = \frac{\sum_f \ell(f|g) f}{\sum_f \ell(f|g)}. \quad (24)$$

When $\sum_f \ell(f|g) = 0$ there is no suitable frequency, at level g , and the result is represented by a blank in Fig 4b.

Metrics for performance maintenance

We developed an order parameter that can account for the storage properties of the system. These are: neurons from a given stored item need to be synchronized, while stay asynchronous with neurons from other items. So, for the z^{th} reactivation cycle and a stored item A , the measure for the synchronization within a memory item is

$$O_A^{Syn}(z) = \frac{n_A(z)}{N_A} \left[1 - \left(\sqrt{2} \frac{\sigma_A(z)}{\Delta t} \right)^{\beta_s} \right]_+ \quad (25)$$

where $n_A(z)$ is the number of active neurons in the ensemble that represents item A at the z^{th} cycle, N_A is the total number of neurons in the ensemble that represents item A , $\sigma_A(z)$ is the standard-deviation of the firing times of the $n_A(z)$ neurons, Δt is the time between the reactivation of two sequential items, β_s is a control parameter that punishes the standard-deviation increase. The measure for asynchronization between two memory items A and B , in the z^{th} cycle is

$$O_{AB}^{Asyn}(z) = \phi \left(\frac{|\langle t_A(z) \rangle - \langle t_B(z) \rangle|}{\Delta t} \right) \quad (26)$$

where

$$\langle t_A(z) \rangle = \frac{1}{n_A(z)} \sum_i t_{A,i}(z)$$

with $t_{A,i}(z)$ the firing times for the individual neurons representing item A and

$$\phi(x) = \begin{cases} 0 & \text{if } x = 0 \\ x^{\beta_a} & \text{if } x \in (0, 1) \\ 1 & \text{if } x \geq 1 \end{cases}$$

where β_a a parameter controlling ϕ 's non linearity.

Our order parameter, therefore, is the multiplicative combination of the average over items of both measures, in a given cycle z ,

$$O_s(z) = \left[\frac{1}{M} \sum_A O_A^{Syn}(z) \right] \left[\frac{2}{M(M-1)} \sum_{A,B>A} O_{AB}^{Asyn}(z) \right] \quad (27)$$

Metrics for erasing performance

In order to assess alpha's capacity of disrupting the stored memories, we performed 1200 simulations randomly varying three alpha parameters: α amplitude (A_α between 0.35 and 0.65 max), α onset (between 0 and 2π rad of θ ongoing oscillatory phase) and α frequency (f_α between 8 and 13Hz). To evaluate alpha's disrupting performance, we first calculate the average value of $O_s(z)$ parameter for the three cycles after alpha onset ($z = 1', 2'$ and $3'$), then binarized using the values of $O_s < 0.5$ as memory successfully erased ($P_{erase} = 1$) and $O_s > 0.5$ memory not erased ($P_{erase} = 0$) and plotted logistic regression fitting curves.

Analytical τ_{min} curve

We computed the analytical τ_{min} curve presented on Fig 6 as the half of the inverse of the beat frequency, which represents half of the beating period or the time to achieve the beating

minimum.

$$\tau_{min} = \frac{1}{2f_{beat}} = \frac{1}{2|f_{\alpha} - f_{\theta}|} \quad (28)$$

Simulations and data analysis

We used Euler's method with step size $dt = 0.01$ ms for solving numerically the neurons differential equations. The simulations were written in C programming language and data analysis and graphic production were made with Python.

Table 1. Overview of parameters. Top: fixed parameters held constant throughout the simulations. Bottom: variable parameters uses more than one value or a range of values.

Fixed Parameters	
Network	$N = 500$
	$N_{ex} = 400$
	$N_{inh} = 100$
	$M = 4$
Neurons	$\tau_{me} = 15$ ms
	$\tau_{mi} = 2$ ms
	$\tau_{ADP} = 140$ ms
	$A_{ADP} = 7$ mV
	$V_{rest} = -60$ mV
	$V_{thresh} = -50$ mV
	$V_{reset} = -70$ mV
	$T_{ref} = 3$ ms
Psp current	$\tau_{ps,e} = 1$ ms
	$\tau_{ps,i} = 10$ ms
Global Synaptic Weights	$W_{EI} = 1.12$
	$W_{IE} = -0.112$
Modular Synaptic Weights	$W_{EE} = 0.70$
	$W_{EI} = 4.5$
	$W_{IE} = -0.8$
O_s Parameter	$\beta_s = 1$
	$\beta_a = 1$
	$\Delta t = 20$ ms
Others	$\sigma_{noise} = 0.5$ mV
	$\mu_{noise} = 0$ mV
	$\sigma_{\gamma} = 4$ ms
	$dt = 0.01$ ms
Variable Parameters	
Oscillations	$f_{\theta} = 4-8$ Hz
	$f_{\alpha} = 8-13$ Hz
	$A_{\theta} = 0.35-0.65$ max
	$A_{\alpha} = 0.35-0.65$ max
	$\psi_{osc} = 0-1.2$ rad/module
	$\phi_i = 0.0-0.8$ rad
	$f_{\gamma} = 1000-33.33$ Hz

<https://doi.org/10.1371/journal.pone.0296217.t001>

Table 2. Parameters for the neural HH-Model from [22].

Membrane Equation	$C = 1\mu F/cm^2$
Leak Current (I_L)	$g_L = 0.05mS/cm^2$ $V_L = -70mV$
Sodium Current (I_{Na})	$g_{Na} = 24mS/cm^2$ $V_{Na} = 55mV$ $\theta_m = -30mV$ $\sigma_m = 9.5mV$ $\theta_h = -53mV$ $\sigma_h = -7mV$ $\theta_{ht} = -40.5mV$ $\sigma_{ht} = -6mV$
Potassium Current (I_K)	$g_K = 3mS/cm^2$ $V_K = -90mV$ $\theta_n = -30mV$ $\sigma_n = 10mV$ $\theta_{nt} = -27mV$ $\sigma_{nt} = -15mV$
High-threshold Calcium Current (I_{CaL})	$\bar{g}_{CaL} = 0.0045mS/cm^2$ $V_{CaL} = 150mV$ $V_{1/2,CaL} = -12mV$ $K_{CaL} = 7mV$ $\alpha_{CaL} = 0.6$ $\beta_{CaL} = -0.02mV^{-1}$
Calcium-activated Nonspecific Cation Current (I_{CAN})	$\bar{g}_{CAN} = 0.025mS/cm^2$ $V_{CAN} = 30mV$ $\alpha_{CAN} = 0.0056\mu M^{-1}ms^{-1}$ $\beta_{CAN} = 0.0125ms^{-1}$
Afterhyperpolarizing Current (I_{AHP})	$\bar{g}_{AHP} = 0.2mS/cm^2$ $V_{AHP} = -90mV$ $\alpha_{AHP} = 0.05\mu M^{-1}ms^{-1}$ $\beta_{AHP} = 0.2ms^{-1}$
Calcium Dynamics (Ca)	$F = 96500C/mol$ $r_0 = 4\mu m$ $r_1 = 0.025\mu m$ $Ca_0 = 0.1\mu M$ $\tau_{Ca} = 100ms$
Injection Current (I_{inj})	$A_{event} = 0.65$ $A_{osc}^{delay} = 0.55$ $f_{osc}^{delay} = 8Hz$ $\psi_{osc}^{delay} = 0rad$
Euler's Time Step	$0.01ms$

<https://doi.org/10.1371/journal.pone.0296217.t002>

Parameters

Parameters are shown in Tables 1 and 2.

Supporting information

S1 Fig. Complementary f_{γ}^{Best} curves. A) f_{γ}^{Best} vs ψ_{osc} for the complete set of ϕ_i . B) Mean between ϕ_i conditions.
(TIF)

S2 Fig. Load operation using alpha. Load operation using alpha 12 Hz instead of theta 8 Hz. Similar plot as Fig 3B and 3C.
(TIF)

S3 Fig. Connectivity specification. A) List of excitatory and inhibitory connections. B) Scheme of Global and Modular connections. C) Connectivity matrix for the network. The y-axis represent the presynaptic neurons and the x-axis the postsynaptic neurons. The excitatory and inhibitory neurons are grouped together for convenience.
(TIF)

Author Contributions

Conceptualization: Gustavo Soroka, Marco Idiart.

Formal analysis: Marco Idiart.

Funding acquisition: Marco Idiart.

Investigation: Gustavo Soroka, Marco Idiart.

Methodology: Gustavo Soroka, Marco Idiart, Aline Villavicencio.

Project administration: Marco Idiart, Aline Villavicencio.

Software: Gustavo Soroka, Marco Idiart.

Supervision: Marco Idiart, Aline Villavicencio.

Validation: Marco Idiart.

Writing – original draft: Gustavo Soroka, Marco Idiart.

Writing – review & editing: Gustavo Soroka, Marco Idiart, Aline Villavicencio.

References

1. Baddeley, A.: Working Memory. Oxford psychology series. Clarendon Press (1986). <https://books.google.com.br/books?id=BFtO-zfULMAC>
2. Baddeley A.D., Hitch G.: Working memory. In: Bower G.H. (ed.) -, *Psychology of Learning and Motivation*, vol. 8, pp. 47–89. Academic Press (1974). <http://www.sciencedirect.com/science/article/pii/S0079742108604521>
3. Baddeley, A.: Working Memory, Thought, and Action. Oxford Psychology Series. OUP Oxford (2007). <https://books.google.com.br/books?id=P2UQAQAIAAJ>
4. Funahashi S.: Prefrontal cortex and working memory processes. *Neuroscience* 139(1), 251–261 (2006). <https://doi.org/10.1016/j.neuroscience.2005.07.003> PMID: 16325345
5. Baddeley A., Papagno C., Vallar G.: When long-term learning depends on short-term storage. *Journal of Memory and Language* 27(5), 586–595 (1988). <http://www.sciencedirect.com/science/article/pii/S0749596X88900289>

6. Baddeley A.: The episodic buffer: a new component of working memory? *Trends in Cognitive Sciences* 4(11), 417–423 (2000). <http://www.sciencedirect.com/science/article/pii/S1364661300015382> PMID: 11058819
7. Lisman J.E., Idiart M.A.P.: Storage of 7 +- short-term memories in oscillatory subcycles. *Science* 267, 1512–1515 (1995) <https://doi.org/10.1126/science.7878473> PMID: 7878473
8. Jensen O., Idiart M., Lisman J.: Physiologically realistic formation of autoassociative memory in networks with theta/gamma oscillations: role of fast nmda channels. *Learning & Memory* (Cold Spring Harbor, N.Y.) 3(2-3), 243–256 (1996). <https://doi.org/10.1101/lm.3.2-3.243> PMID: 10456094
9. Jensen O., Lisman J.E.: An oscillatory short-term memory buffer model can account for data on the Sternberg task. *The Journal of neuroscience: the official journal of the Society for Neuroscience* 18(24), 10688–99 (1998). <http://www.ncbi.nlm.nih.gov/pubmed/9852604> PMID: 9852604
10. Lisman J., Jensen O.: The theta-gamma neural code. *Neuron* 77, 1002–16 (2013). <https://doi.org/10.1016/j.neuron.2013.03.007> PMID: 23522038
11. Berger H.: über das elektroencephalogramm des menschen. *Arch. Psychiatr Nervenkr* 87, 527–570 (1929) <https://doi.org/10.1007/BF01797193>
12. Roux F., Uhlhaas P.J.: Working memory and neural oscillations: alpha – gamma versus theta–gamma codes for distinct WM information? *Trends in Cognitive Sciences* 18(1) (2014). <https://doi.org/10.1016/j.tics.2013.10.010> PMID: 24268290
13. Klimesch W., Doppelmayr M., Schwaiger J., Auinger P., Winkler T.: 'paradoxical' alpha synchronization in a memory task. *Cognitive Brain Research* 7(4), 493–501 (1999). <https://www.sciencedirect.com/science/article/pii/S0926641098000561> PMID: 10076094
14. Jensen O., Gelfand J., Kounios J., Lisman J.E.: Oscillations in the alpha band (9–12 hz) increase with memory load during retention in a short-term memory task. *Cerebral cortex* 12 8, 877–82 (2002) <https://doi.org/10.1093/cercor/12.8.877>
15. Schack B., Klimesch W.: Frequency characteristics of evoked and oscillatory electroencephalic activity in a human memory scanning task. *Neuroscience Letters* 331(2), 107–110 (2002). <http://www.sciencedirect.com/science/article/pii/S0304394002008467> PMID: 12361852
16. Klimesch W., Sauseng P., Hanslmayr S.: Eeg alpha oscillations: The inhibition–timing hypothesis. *Brain Research Reviews* 53(1), 63–88 (2007). <https://doi.org/10.1016/j.brainresrev.2006.06.003> PMID: 16887192
17. Jensen O., Mazaheri A.: Shaping Functional Architecture by Oscillatory Alpha Activity: Gating by Inhibition. *Frontiers in Human Neuroscience* 4(November), 1–8 (2010). <http://journal.frontiersin.org/article/10.3389/fnhum.2010.00186/abstract> PMID: 21119777
18. Schroeder C., Lakatos P.: Low-frequency neural oscillations as instruments of sensory selection. *Trends in neurosciences* 32, 9–18 (2008). <https://doi.org/10.1016/j.tins.2008.09.012> PMID: 19012975
19. Dipoppa M., Gutkin B.S.: Flexible frequency control of cortical oscillations enables computations required for working memory. *Proceedings of the National Academy of Sciences* 110(31), 12828–12833 (2013). <http://www.pnas.org/cgi/doi/10.1073/pnas.1303270110> PMID: 23858465
20. Dipoppa M., Szwed M., Gutkin B.S.: Controlling working memory operations by selective gating: The roles of oscillations and synchrony. *Advances in Cognitive Psychology* 12(4), 209–232 (2016). <https://doi.org/10.5709/acp-0199-x> PMID: 28154616
21. Bassett D. S., Zurn P., & Gold J. I. (2018): On the nature and use of models in network neuroscience. *Nature reviews. Neuroscience*, 19(9), 566–578. <https://doi.org/10.1038/s41583-018-0038-8> PMID: 30002509
22. Rodriguez G, Sarazin M, Clemente A, Holden S, Paz JT, Delord B. Conditional Bistability, a Generic Cellular Mnemonic Mechanism for Robust and Flexible Working Memory Computations. *Journal of Neuroscience* 38(22), 5209–5219 (2018). <https://doi.org/10.1523/JNEUROSCI.1992-17.2017> PMID: 29712783
23. Burkitt G., Silberstein R., Cadusch P., Wood A.: Steady-state visual evoked potentials and traveling waves. *Clinical neurophysiology: official journal of the International Federation of Clinical Neurophysiology* 111, 246–58 (2000). [https://doi.org/10.1016/S1388-2457\(99\)00194-7](https://doi.org/10.1016/S1388-2457(99)00194-7) PMID: 10680559
24. Lubenov E., Siapas A.: Hippocampal theta oscillations are travelling waves. *Nature* 459, 534–9 (2009). <https://doi.org/10.1038/nature08010> PMID: 19489117
25. Zhang H., Jacobs J.: Traveling theta waves in the human hippocampus. *Journal of Neuroscience* 35, 12477–12487 (2015). <https://doi.org/10.1523/JNEUROSCI.5102-14.2015> PMID: 26354915
26. Patel J., Fujisawa S., Berényi A., Royer S., Buzsáki G.: Traveling theta waves along the entire septo-temporal axis of the hippocampus. *Neuron* 75, 410–7 (2012). <https://doi.org/10.1016/j.neuron.2012.07.015> PMID: 22884325

27. Zhang H., Watrous A., Patel A., Jacobs J.: Theta and alpha oscillations are traveling waves in the human neocortex. *Neuron* 98 (2018). <https://doi.org/10.1016/j.neuron.2018.05.019> PMID: 29887341
28. Muller L., Chavane F., Reynolds J., Sejnowski T.: Cortical travelling waves: Mechanisms and computational principles. *Nature Reviews Neuroscience* 19 (2018). <https://doi.org/10.1038/nrn.2018.20> PMID: 29563572
29. Golomb D., & Amitai Y.: Propagating neuronal discharges in neocortical slices: computational and experimental study. *Journal of neurophysiology*, 78 (3), 1199–1211. <https://doi.org/10.1152/jn.1997.78.3.1199> PMID: 9310412
30. Singer W. (1999). Neuronal synchrony: a versatile code for the definition of relations?. *Neuron*, 24(1), 49–125 (1999). [https://doi.org/10.1016/s0896-6273\(00\)80821-1](https://doi.org/10.1016/s0896-6273(00)80821-1) PMID: 10677026
31. Buzsáki, G.: *Rhythms of the Brain* (New York, 2006; online edn, Oxford Academic, 1 May 2009), <https://doi.org/10.1093/acprof:oso/9780195301069.001.0001>

Hierarchical Clustering as Mechanistic Processes of Syntactic Structure Building in a Transformer Architecture .

Gustavo Soroka¹, Lucas Hoff¹, Mateus Guimarães¹, Marco Idiart²

¹ Neuroscience Graduate Program, Federal University of Rio Grande do Sul

² Physics Department, Federal University of Rio Grande do Sul

Abstract

While transformer-based architectures have revolutionized the field of natural language processing, they remain somewhat artificial in the sense that they lack a clear link with traditional linguistic theory and brain-network models. Here we explore how syntactic structure might emerge from a computational perspective in a way that aligns more directly with linguistic frameworks. In particular, we propose that the Merge operation in Noam Chomsky’s Minimalist Program can be modelled as a hierarchical clustering process acting on word-embeddings produced by an artificial neural network. For this, we implemented a custom loss function that compares the tree structure produced with the output of a transformer network through HC with the true label structure. In addition, we compare our simple model to a BERT-base trained in the same task. We study the projected representations through the analysis of the principal components of the output space, comparing conditions with, without, and with only positional encoding. Our results show that the models are able to functionally learn the task and that the projections assume a semi-circular shape in the reduced space, with the first two principal components accumulating more than 80% of the explained variance of the data, and that time emerges in those projections as a sequence of word positions.

1 Introduction

Over the past 60 years, the fields of neuroscience, computer science, and linguistics have developed largely in parallel, each advancing our understanding of human language from distinct perspectives: as a biological system, as a statistical model of natural language data and a formal mathematical object, respectively. Neuroscience investigates the neural circuitry underlying language, including how cognitive language abilities develop in infants and children, the influence of genetic factors, the emergence of language-related disorders, and the localization of language functions in the brain (Friederici, 2017). Linguistics aims to describe human language as a formal, generalized system, often using mathematical structures to model its components (Peregrin, 1990). Computer science, in turn, adopts a more applied approach, seeking to model human language expression, i.e. the natural language data (Takahashi and Tanaka-Ishii, 2019). The integration problem is beautifully stated by Christos Papadimitriou, asking "How does the brain beget the mind? How do molecules, cells and synapses effect cognition, behavior, intelligence, reasoning and language?" (Papadimitriou et al., 2020), later citing Richard Axel "we do not have a logic for the transformation of neural activity into thought and action..." (Axel, 2018).

In an effort to integrate these fields, we propose a research approach that addresses questions about the biology of language by implementing linguistic concepts —specifically syntactic struc-

tures—within artificial neural language models. We hypothesize that the linguistic process of hierarchically building syntactic phrase structures, particularly as captured by the operation of recursive Merge in recent generative theories (Chomsky, 1995; Chomsky et al., 2023; Marcolli et al., 2023), can be modeled through the hierarchical clustering process of word embeddings (Ushioda, 1996). In other words, we ask whether the problem of hierarchical structure building in language could be approached as a problem of identifying the proximity of word embeddings within a high-dimensional projection space. By exploring this idea, we aim to propose simple computational mechanisms that might offer insight into how language could emerge from biological neural circuitry. In Marr’s three levels analysis (Marr, 1982), we propose the hierarchical clustering as an algorithmic process for hierarchical structure building, testing if the modern transformer’s architecture could create the right projection for the phenomenon.

To test our hypothesis, we conducted a series of experiments using Transformer architectures (Vaswani et al., 2017): i) we trained a small neural network to produce output word embeddings such that, through hierarchical clustering, they reconstruct the correct syntactic tree; ii) we used a pretrained BERT model, fine tuning in the same task; iii) we explored the phenomenon of word embedding projection through principal component analysis.

2 Related Work

Several studies have addressed the question of how syntax can be implemented or emerge in transformer networks. Wang and colleagues (Wang et al. (2019)) proposed the Tree Transformers, implementing an extra constraint to attention heads, where each word can only attend to words in the same constituent. Despite the ingenuity of the implementation, the work lacks explainability or visualization, relying on heatmaps of attention and performances by layers. Another study, TreeCoders by D’Istria and Altahhan (arXiv:2411.07218 [cs.CL]) implements a tree-like architecture of transformer’s blocks acting as nodes, rooting information from the sentence input to the end (leaf node). They compare the perplexity of the model in various architectures (i.e. number of decoder layers per node), and

with linear models. Bai and colleagues proposed Syntax-Bert (Bai et al. (2021)), where they integrate syntax trees into a pre-trained Transformer by decomposing the self-attention into multiple networks, each paying attention to different syntax aspects using masking and then aggregated via another attention layer (called topical attention) to produce a updated word representation. This topical attention has query vectors trained for specific tasks, which can select the most appropriate combinations of syntactic features for different tasks. Yoshida et al (2024) proposed Tree-planted Transformers, where they implicitly supervise the attention weights with the syntactic tree in the form of syntactic distance matrix, measured as the number of edges between words, outperforming several other Transformers models, even without explicitly training the syntactic trees.

3 Materials and Methods

3.1 Data Collection and Manipulation

3.1.1 Corpora

The British National Corpus (BNC) (Consortium (2007)) was obtained from "<https://ota.bodleian.ox.ac.uk/repository/xmlui/handle/20.500.12024/2554>" in XML format and imported to a python notebook using NLTK’s BNCCorpusReader function of the nltk.corpus.reader.bnc module.

3.1.2 Data Preprocessing

For the toy model, sentences were parsed using both the SpaCy library and the Berkeley Neural Parser Kitaev and Klein (2018). The resulting parse trees were converted into binary form using NLTK’s NLTK’s Tree.chomsky_normal_form() function and balanced across four structural classes (Figure 3.1.2), yielding 408 samples per class (Figure 2). This procedure was applied to sentences of lengths ranging from 4 to 8 words, resulting in a total of 8,160 sentences. The five most frequent tree structures for each sentence length are shown in Figure 3.

The sentences were converted into a batched tensor of word indices, which served as input to the neural network while the corresponding pairwise-

distance trees were used as the target in the loss function. For the BERT-based model, an additional preprocessing step included tokenization and padding of the word embeddings. Special tokens were excluded from the loss computation.




Figure 1: Overview of data preprocessing.

3.2 Neural Networks

We assess how two different transformer neural networks perform in projecting the word embeddings. The first one is a small and simple network, with embeddings of dimension 64, 2 layers and 2 attention heads, implemented from scratch using Pytorch framework. The second one is a pretrained BERT Devlin et al. (2018) from the HuggingFace Transformers Wolf et al. (2020) python library, named "bert-base-uncased", consisting of embeddings of dimension 786, 12 layers and 8 attention heads. The training of both models were made using Adam optimizer, batches of size 32 and learning rates of 5×10^{-5} for the simple model and 1×10^{-5} for the BERT model.

3.3 Positional Encoding

A critical feature of Transformer models is how they incorporate word-order information. Be-

cause the self-attention mechanism alone does not distinguish which token comes first or last, we add a positional encoding to each word embedding. This ensures the representation carries both the semantic meaning of the word and its position in the sequence. Instead of using the fixed sine-and-cosine positional encodings introduced by Vaswani et al. Vaswani et al. (2017), we use learnable positional embeddings Devlin et al. (2018), implemented as an embedding layer added to each token, according to its position. This gives the model the flexibility to pick up patterns in the data on its own, rather than relying on a predefined way of representing positions.

3.4 Tree Distance

The tree structures were captured as a distance matrix, measured as a pairwise leaf distance. After some testing, we choose the cardinality as the parameter for this metric to avoid ambiguities in the later process of hierarchical clustering. Thus, the distance $D_{i,j}$ between a pair of leaves (i, j) , each belonging to a different subtree T_i and T_j , is the maximum cardinality between the subtrees, i.e., the number of leaves the bigger subtree contains. One feature of this choice is that the distance between a given leaf and all the leaves of a given subtree will be the same.

$$D_{i,j} = \max(|T_i|, |T_j|)$$

The first three trees of Figure 3 (first row), are shown as distance matrices below.

$$\begin{bmatrix} 0 & 3 & 3 & 3 \\ 3 & 0 & 2 & 2 \\ 3 & 2 & 0 & 1 \\ 3 & 2 & 1 & 0 \end{bmatrix} \quad \begin{bmatrix} 0 & 1 & 2 & 2 \\ 1 & 0 & 2 & 2 \\ 2 & 2 & 0 & 1 \\ 2 & 2 & 1 & 0 \end{bmatrix} \quad \begin{bmatrix} 0 & 3 & 3 & 3 \\ 3 & 0 & 1 & 2 \\ 3 & 1 & 0 & 2 \\ 3 & 2 & 2 & 0 \end{bmatrix}$$

3.5 Loss Function

Our loss function evaluates the similarity between the Euclidean distance matrix of the Transformer's output embeddings and the corresponding ground-truth distance matrix. Using cosine similarity as the metric, we assess whether the relative distances between words in the embedding space match those in the target hierarchical structure. Specifically, the output embeddings from the Transformer are first normalized, and their pairwise




Figure 2: Corpus structure A) number of sentences by sentence length; B) number of tree structures (classes) by sentence length. In order to balance data, we choose 408 samples of each sentence size for 4 classes.

Euclidean distance matrix is computed. To avoid redundant entries, only the elements above the main diagonal are retained, forming a flattened tensor. The same procedure is applied to the ground-truth distance matrix.

Let n denote the number of words in a sentence, the resulting tensors thus have shape $(n_{sens}, n(n-1)/2)$, where $n(n-1)/2$ corresponds to the number of unique word pairs. The loss is then defined as one minus the cosine similarity between the predicted and target flattened distance tensors. Mathematically, we express it as:

$$\mathbf{d}_{\text{pred}} = \text{flat}_{i < j} (D_{\text{pred}}(i, j))$$

$$\mathbf{d}_{\text{true}} = \text{flat}_{i < j} (D_{\text{true}}(i, j))$$

$$\mathcal{L} = 1 - \cos(\mathbf{d}_{\text{pred}}, \mathbf{d}_{\text{true}})$$

$$\mathcal{L} = 1 - \frac{\mathbf{d}_{\text{pred}}^\top \mathbf{d}_{\text{true}}}{\|\mathbf{d}_{\text{pred}}\|_2 \|\mathbf{d}_{\text{true}}\|_2}.$$

3.6 Hierarchical Clustering

To recover the hierarchical structure among words, we employed an Agglomerative Hierarchical Clustering (AHC) algorithm using the *centroid linkage* method and the Euclidean distance as the dissimilarity measure. AHC is a bottom-up approach that begins with each element as an individual cluster and iteratively merges the two most similar clusters until all elements belong to a single hierarchy. The resulting structure is represented as a dendrogram, which encodes the nested relationships among clusters.

Distance Metric. Given two data points $\mathbf{x}_i, \mathbf{x}_j \in \mathbb{R}^d$, their Euclidean distance is defined as:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{k=1}^d (x_{ik} - x_{jk})^2}. \quad (1)$$

Centroid Linkage. For clusters A and B containing $|A|$ and $|B|$ elements, their respective centroids are computed as the mean of their constituent vectors:

$$\mathbf{c}_A = \frac{1}{|A|} \sum_{\mathbf{x}_i \in A} \mathbf{x}_i, \quad \mathbf{c}_B = \frac{1}{|B|} \sum_{\mathbf{x}_j \in B} \mathbf{x}_j. \quad (2)$$

The distance between clusters is then given by the Euclidean distance between their centroids:

$$D(A, B) = \|\mathbf{c}_A - \mathbf{c}_B\|_2. \quad (3)$$

Merging Procedure. At each iteration, the two clusters (A, B) that minimize $D(A, B)$ are merged into a new cluster $C = A \cup B$ with centroid:

$$\mathbf{c}_C = \frac{|A|\mathbf{c}_A + |B|\mathbf{c}_B}{|A| + |B|}. \quad (4)$$

Distances between C and any other cluster K are then updated as:

$$D(C, K) = \|\mathbf{c}_C - \mathbf{c}_K\|_2. \quad (5)$$

This process repeats until a single cluster remains, capturing the full hierarchical organization of the data.

3.7 Accuracies

We evaluate the proposed model using two complementary metrics. The first, Tree Accuracy (Acc), assesses whether the entire hierarchical structure reconstructed exactly matches the ground truth tree, giving the proportion of correct tree predictions. This is achieved by converting both trees




Figure 3: Five most common tree structures for each sentence length in the corpus.

into distance matrices and verifying whether the element-wise difference between the predicted and true matrices results in a matrix of all zeros—i.e., whether every pairwise relation between words is correctly recovered. Let $\mathbf{D}_{\text{pred}} \in \mathbb{R}^{n \times n}$ and $\mathbf{D}_{\text{true}} \in \mathbb{R}^{n \times n}$ denote the pairwise distance matrices corresponding to the predicted and ground-truth trees, respectively. We define *Tree Accuracy* as:

$$\text{Acc} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[\mathbf{D}_{\text{pred}}^{(i)} = \mathbf{D}_{\text{true}}^{(i)}], \quad (6)$$

where $\mathbb{I}[\cdot]$ is the indicator function, returning 1 if the condition holds and 0 otherwise, and N is the total number of test sentences.

The second metric, Leaf Pair Distance Accuracy (LPD), quantifies the proportion of correctly predicted pairwise distances between leaves. For a sentence of n words, there are $n(n-1)/2$ unique word pairs, and LPD reflects how many of these pairwise relations were accurately reproduced, therefore:

$$\text{LPD} = \frac{n(n-1)}{2} - \frac{\|\mathbf{D}_{\text{pred}} - \mathbf{D}_{\text{true}}\|_0}{2} \quad (7)$$

where $\|\cdot\|_0$ denotes the ℓ_0 pseudo-norm, i.e., the number of nonzero elements in the matrix, and

the factor $\frac{1}{2}$ accounts for the symmetry of the distance matrix since each pairwise distance appears twice. While Acc is a stricter, all-or-nothing criterion, LPD provides a more graded measure that captures partial correctness.

3.8 Principal Component Analysis

To examine how the model projects information, we applied Principal Component Analysis (PCA) to the word-embedding vectors generated at the network’s output. PCA reduces the high-dimensional embedding space into a lower-dimensional representation while retaining as much of the variance as possible, enabling us to visualize clusters and separations among tokens. We implemented this using the PCA class from `sklearn.decomposition`.

4 Results

Our first result is shown in Figure 4(A,E), where we successfully approximated the word embeddings that were outputted from the toy model

to embeddings whose relative positions in the hyperspace returned corrected syntactic trees during a hierarchical clustering process. We performed a 5-fold cross validation until the training accuracy reached 0.99, with approximately 0.6 of test accuracy and 0.8 of LPD accuracy. Figure 4(B,F) shows the test acc and LPD acc during the training process

for each sentence length, where in Figure 4(C,G) we see no correlation between sentence length and the accuracies. Due to our limit corpus size, we explore if the accuracies were dependent of training size, showing in Figure 4(D,H) a correlation between both.




Figure 4: Standard versus ratio accuracies for each sentence size. A,E shows the loss, training and test accuracies for acc and LDP acc, respectively; B,C shows the accuracy metrics for each sentence length; C,D plot the relation between sentence length and the test accuracies and D,H shows the relation between the test accuracies and the size of the corpus used in training.

Our second result is shown in Figure 5, where we evaluate how a larger pretrained network, specifically BERT, performs on the same task. Given its size, we fine-tuned it on our task for only 50 epochs, reaching approximately 0.93 training accuracy, over 0.80 test accuracy, and 0.90 in LPD accuracy—thereby outperforming the simpler model.




Figure 5: Tree structure task using BERT model. A) Loss, acc and LPD acc for the training and test; B Final values of acc metrics for training and test.

To investigate how learning organizes the positional-aware embeddings (pa-embeddings) in the semantic-positional space so that they reflect the expected linguistic hierarchy, we conducted a new set of experiments where we project the pa-

embeddings onto the first two principal components of their distribution. We call it PC-HC space.

In the experiments we tracked how the pa-embedding distribution evolves in this reduced space during training. The toy network was trained until it reached 0.8 training accuracy (Figure 6A). Before training, the projection shows a mostly symmetrical distribution (Figure 6B), with some initial segregation driven by positional information (as indicated by the colors). After training, the projection transitions into a spiral-like structure, showing a clear inward progression that reflects the temporal organization of the information.(Figure 6C).

We also observe that, as training progresses, an increasing proportion of the variance in the pa-embedding distribution becomes concentrated in the first two principal components, making the reduced space increasingly informative (Figure 6D,E). This growing concentration of explained variance appears to be linked to improvements in the network’s accuracy (Figure 6F).

We also compared the PCA projections of the model with and without positional encoding. In




Figure 6: Projection of word embeddings. A) loss and acc metrics for training and test; B) data distribution in HC-PC space before training; C) data distribution in HC-PC space after training; D) explained variance for the first five principal components before and after training; E) explained variance during training; F) explained variance versus training accuracy.

both cases, the first principal component (PC1) seems to reflect the progression of time in the sequence. However, the model without positional encoding shows a more curved, “bean-shaped” distribution, while the model with positional encoding displays a clearer linear separation along PC1 (Figure 7A,B). This effect is clearer in Figure 7C: although the direction of the curve is arbitrary, the slope indicates how well time is being represented. The version without positional encoding shows only a weak temporal progression, while the learnable positional encoding emphasizes the first few word positions much more strongly. Finally, as shown in Figure 7D, both models are able to fit the training data, but only the version with positional encoding generalizes. The model that uses positional encoding alone (without token embeddings) does not converge, reinforcing the idea that both token identity and positional structure are necessary for learning and generalization.

Finally, in figure 8 we show two examples of sentence trees projected into the HC-PC space (figure 8A,C), where merged centroids and showed as red x’s, and the respective tree structure resulted of the hierarchical clustering of the sentence in this space

(figure 8B,D). It is important to note that the merging in the HC process considers all elements of both clusters in order to calculate the centroids.

5 Discussion

Here, we propose a simple mechanistic procedure to model the hierarchical construction of sentence structure: hierarchical clustering (HC). This unsupervised machine learning algorithm mirrors the linguistic process described in the Minimalist Program and is sufficiently simple to be plausibly implemented in biological neural networks. The present study represents a first attempt to test this hypothesis, using an artificial neural architecture—the transformer—as a training framework. Specifically, the goal was to train word embeddings such that the output of the transformer could be directly processed by the hierarchical clustering algorithm to yield the correct syntactic structures. Model performance was evaluated with two accuracy measures: (i) the standard correct/incorrect classification, and (ii) a proportion of correctly reconstructed pairwise distances, which accounts for partial correctness. We implemented the procedure on a naive, relatively




Figure 7: Projection of embeddings with and without positional encoding. A) projections with positional encoding; B) projections without positional encoding; C) mean value of PC1 for each word position with and without positional encoding; D) accuracies of models with positional encodings, without positional encoding and with only positional encodings.

small model and compared its performance with a pre-trained BERT network. As expected, BERT outperformed the naive model, reflecting its larger scale and extensive pre-training.

Since the HC process relies solely on the Euclidean distance between embeddings, we trained the embeddings by comparing the pairwise Euclidean distance vector produced by the network with the true pairwise tree distances of the sentence’s syntactic structure, using cosine similarity as the loss function. This procedure encourages the network to learn word representations that preserve the relative distances among words as defined by the syntactic tree. A key feature of our implementation was the use of a non-trivial tree distance metric to prevent HC from producing incorrect syntactic structures: we adopted cardinality instead of a simple node or vertex count. Notably, cardinality corresponds to the number of words within a cluster, or equiv-

alently, the number of merge operations, which provides both a natural linguistic interpretation and a plausible pathway for biological implementation. The projection analysis using PCA showed interesting circular pattern, emerging the temporal sequence on the first principal component. Both the first and second principal components increase it’s explained variance, where the others decreased, suggesting that the data is projected into a narrow space in the HC space, with this increased explained variance being related with the improvement on training accuracy. Interestingly, both with and without positional encoding models captures time information, suggesting it’s crucial for coding the sentences structures, which is clear when seeing the data used (the most common classes of the corpus), showing prominent linear sequences. Both with and without positional encoding models were able to train, but only the first was able to gener-




Figure 8: Projected tree structures. A,C) projected structure for two sentences: "it s a bit expensive" and "she was a bit". Blue dots represent words of the sentence, red x's are merged centroid of the clusters and the blue lines connect elements merged in each iteration. B,D) tree structures elucidated by the hierarchical clustering.

alize decently. The condition with only positional encoding was not able to train or generalized.

Two samples of tree structure in the HC-PC space were shown, suggesting that the reduced space can be used to interpreted and visualize structure on the model. Even though the model accuracy is computed using the HC space, the HC-PC is a good approximation, accumulating almost 90% of all the variance of the data distribution. Interestingly, the sentences centroids (final merge) appears centered in the origin of the HC-PC space, although further analysis must be made. This could reflect an optimization process, where the embeddings are being distributed maximizing its separation and the storage capacity of information.

6 Future Work

Future work could further explore the projection of information in reduced spaces, seeking to understand how information from data is internalized by neural networks. Specifically, would be interestingly to see how projected trees in the HC-PC space could be generalized, and statistical analysis could be used in order to elucidate the emergence of structural patterns in that space. Another condition not explored in this study is using the standard positional encoding by fixed sines and cosines, from which could arise different phenomena.

An open question is how biological neural networks could implement this type of algorithm. While our work is still far from uncovering the true biological computations underlying language processing, one possible step toward greater biological plausibility lies in the use of Hopfield networks. Recent studies

have proposed that modern variants of Hopfield networks are analogous to transformer architectures Ramsauer et al. (2020), as they perform key–query operations over memory patterns and state configurations. Applying this framework to the task of syntactic tree discovery could yield a more biologically grounded description of the computations involved in syntactic associations. We hypothesize that mixed states may provide a mechanism for encoding associative information between words and their combinations, and that the correct evolution of a network of Hopfield modules could be interpreted as an emergent hierarchical clustering process.

7 Conclusion

Here, we implemented a phrase structure syntactic parser based on the minimalist operation Merge through the well-known computational algorithm of hierarchical clustering. The key idea is to model the successive Merge phenomena as the clustering process, training a neural network to learn the correct map between the sequence of word tokens to their syntactic representations that could be solvable by the hierarchical clustering and produce the correct syntactic tree. Here, we validate this hypothesis through a naive model based on the transformers architecture and the pre-trained BERT model, and show that a simple, biological plausible mechanism could underpin this linguistic structure building process. We propose a future work research model, which can be view as a next step to a more biological description of how neural networks could implement such processes.

References

- Axel, R. (2018). Q & a. *Neuron*, 99(6):1110–1112.
- Bai, J., Wang, Y., Chen, Y., Yang, Y., Bai, J., Yu, J., and Tong, Y. (2021). Syntax-BERT: Improving pre-trained transformers with syntax trees. In Merlo, P., Tiedemann, J., and Tsarfaty, R., editors, *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume*, pages 3011–3020, Online. Association for Computational Linguistics.
- Chomsky, N. (1995). *The Minimalist Program*. MIT Press, Cambridge, MA.
- Chomsky, N., Seely, T. D., Berwick, R. C., Fong, S., Huybregts, M. A. C., Kitahara, H., McInerney, A., and Sugimoto, Y. (2023). *Merge and the Strong Minimalist Thesis*. Elements in Generative Syntax. Cambridge University Press, Cambridge.
- Consortium, B. (2007). British national corpus, XML edition. Oxford Text Archive.
- Devlin, J., Chang, M., Lee, K., and Toutanova, K. (2018). BERT: pre-training of deep bidirectional transformers for language understanding. *CoRR*, abs/1810.04805.
- Friederici, A. D. (2017). Language in our brain. the origins of a uniquely human capacity. *Cambridge, MA: The MIT Press*.
- Kitaev, N. and Klein, D. (2018). Constituency parsing with a self-attentive encoder. In Gurevych, I. and Miyao, Y., editors, *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 2676–2686, Melbourne, Australia. Association for Computational Linguistics.
- Marcolli, M., Berwick, R. C., and Chomsky, N. (2023). Old and new minimalism: a hopf-algebra comparison. *arXiv preprint arXiv:2306.10270*.
- Marr, D. (1982). *Vision: A Computational Investigation into the Human Representation and Processing of Visual Information*. W. H. Freeman and Company, San Francisco.
- Papadimitriou, C. H., Vempala, S. S., Mitropolsky, D., Collins, M., and Maass, W. (2020). Brain computation by assemblies of neurons. *Proceedings of the National Academy of Sciences*, 117(25):14464–14472.
- Peregrin, J. (1990). On a logical formalization of natural language. *Kybernetika*, 26(4):327–341.
- Ramsauer, H., Schöfl, B., Lehner, J., Seidl, P., Widrich, M., Adler, T., Gruber, L., Holzleitner, M., Pavlović, M., Sandve, G. K., Greiff, V., Kreil, D., Kopp, M., Klambauer, G., Brandstetter, J., and Hochreiter, S. (2020). Hopfield networks is all you need. *arXiv preprint arXiv:2008.02217*. Revised version published at ICLR 2021.

- Takahashi, S. and Tanaka-Ishii, K. (2019). Evaluating computational language models with scaling properties of natural language. *Computational Linguistics*, 45(3):481–511.
- Ushioda, A. (1996). Hierarchical clustering of words and application to nlp tasks. In *Proceedings of the 34th Annual Meeting of the Association for Computational Linguistics*, pages 85–92. Association for Computational Linguistics.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017). Attention is all you need. In *Advances in neural information processing systems 30 (NIPS 2017)*, pages 5998–6008.
- Wang, Y., Lee, H.-Y., and Chen, Y.-N. (2019). Tree transformer: Integrating tree structures into self-attention. In Inui, K., Jiang, J., Ng, V., and Wan, X., editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 1061–1070, Hong Kong, China. Association for Computational Linguistics.
- Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Scao, T. L., Gugger, S., Drame, M., Lhoest, Q., and Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 38–45, Online. Association for Computational Linguistics.
- Yoshida, R., Someya, T., and Oseki, Y. (2024). Tree-planted transformers: Unidirectional transformer language models with implicit syntactic supervision. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 5120–5134, Bangkok, Thailand. Association for Computational Linguistics.

8 Appendix A: data classes

Table 1: Example of sentences of the most common five classe of each lenght, following the order in figure 3.

Length / Class	Class 1	Class 2	Class 3	Class 4	Class 5
Length 4	this completes one step it was no dream what did he mean	a defence of autonomy the rest are excluded the problem of context	the community care plan the non colinear case the parallel plate capacitor	biological and psychological batching and sorting input the resulting equation is	so many people do two hundred pound please how many spots then
Length 5	triangulation has many important uses we now repeat the cycle they lack convincing supporting evidence	selective enforcement of the law these uses are non deictic susanne macgregor and ben pimlott	how might the argument run find the zero potential surface same as that one look	as he himself puts it consider the case of tragedy such changes are relative	the high fliers go elsewhere miocene maple leaf acer trilobatum an international perspective on transition
Lenght 6	problem formulated as a matrix pencil but neither can we impose it morgan and cut down its ambit	his remark goes deeper than that cultural diversity in society and education general practices in the united kingdom	probably is the user to use others say the numbers increase in these set minimum sizes for output	treatment of asympatic carotid artery stenosis limitations of the flody huggins theory only setting the eighth fastest time	in the background here is hegel the sample letter would therefore become the internation politics of the climate change
Length 7	we therefore return to the original form thirdly that it is a male phenomenon it is impossible to divorce the two	a campbell shoplifting the typical female crime the airway became increasingly difficult to maintain a mistake can be expensive as well	norms are therefore ideal standard of behavior they have a well developed nervous system rules refer to these consistencies of behavior	there are two traps for the unwary there are two snags about this approach this is no doubt a remarkable curve	results were corroborated by non parametric tests well it would be worthwhile investigatin anyway you could have kept that quiet anyway
Length 8	we can not jump off our own shadows but i do n t think so now but you just said he was n t	acceptance rates were computed and surveyed every week this specimen is from grayson co kentucky usa for curvature only occurs on the null boundary	then we find at once from and that finally he considers the part education should play i wonder what my brother s doing now	this was anticipated by the discussion in section and tha s no through road there obviously are you bein a go er excuse me	there are of course advantages for the speaker there were family allowances for those with children that s a lot then in n it

9 Appendix B: projections and learning rate




Figure 9: Projections on different learning rates settings: 10^{-2} , 10^{-3} , 10^{-4} , 10^{-5} and 10^{-6} . First column shows accuracies for the first 50 epochs, second shows projections for epoch zero, third for epoch one, fourth for epoch 5, fifth for epoch 10 and the last column shows projections for epoch 50.

Capítulo 5

DISCUSSÃO

A memória de trabalho e a linguagem são os dois objetos de estudos deste trabalho, constituindo funções cognitivas complexas, investigadas por diversos campos científicos, sendo altamente interdisciplinares e com grandes impactos na sociedade. Utilizamos métodos da neurociência computacional e do aprendizado de máquina para modelar os processos de interesse e explorar fenômenos subjacentes. Para a memória de trabalho, propomos um modelo mecanístico para o papel das oscilações alfa na disrupção do armazenamento de múltiplas informações, incorporando uma arquitetura modular e uma dinâmica de onda viajante. Para a linguagem, exploramos modelos teóricos que incorporassem aspectos de arquitetura modular, oscilações cerebrais e propriedades linguísticas da linguagem natural e testamos nossa hipótese utilizando redes neurais modernas e aprendizado de máquina. Apesar de cada trabalho estar em um nível diferente de abstração em relação aos sistemas biológicos, nosso objetivo em ambos é construir uma ponte interdisciplinar para conectar os diferentes campos que se propõe estudar elas: a neurociência, a biologia, psicologia, física, ciência da computação, linguística, entre outras.

Memória de trabalho modular com mecanismos oscilatórios

Na primeira parte, estendemos o modelo amplamente conhecido para a memória de trabalho de múltiplos itens, o modelo **Lisman & Idiart**(LISMAN; IDIART, 1995), que baseia a dinâmica de uma rede que armazena informações no acoplamento das oscilações teta-gama. Incluindo mecanisticamente as oscilações alfa, propondo que estas oscilações possuem um papel disruptivo na memória de trabalho de múltiplos itens ao interferir fisicamente com as oscilações teta. Enquanto as oscilações teta carregam ciclicamente informações armazenadas, produzindo picos cíclicos que permitem a reativação de padrões de disparos subliminarmente excitados por canais neuronais, as oscilações alfa interferem com as teta produzindo um padrão chamado de batimento (termo da física), produzindo períodos que ambas oscilações se somam e períodos em que se subtraem. Nos períodos de subtração, a rede fica com baixa excitabilidade e impede a cíclica reativação dos padrões de disparo, perdendo as memórias armazenadas. Nossa hipótese é motivada por um conjunto extenso de trabalhos que mostram que estas oscilações estão inversamente correlacionadas com a performance em tarefas de memória de trabalho, que estão correlacionadas com processos de atenção e, mais precisamente, de inibir o armazenamento de informações não relevantes (ver tabelas 2.1 e 2.2).

O trabalho é uma continuação da dissertação de mestrado intitulada *Bloqueio de estímulos por oscilações alfa em modelos computacionais de memória de trabalho de múltiplos itens*(SOROKA, 2020) que, em adição, caracterizamos duas propriedades recentemente implementadas, uma arquitetura modular e dinâmica oscilatória de uma onda viajante, e exploramos um conjunto maior de operações de memória de trabalho, incluindo seu carregamento, manutenção e limpeza. A arquitetura modular é uma característica inspirada na própria biologia, que podemos incluir desde aspectos estatísticos de conexão, em que se predominam conexões locais sobre conexões de longo alcance, e mesoestruturas encontradas, como colunas corticais, ilhas de células no córtex entorinal, estruturas em forma de barril em roedores, glomérulos olfativos, patches e blobs do córtex visual primário (ver seção 2.2). Uma das principais consequências da implementação desta propriedade é o aumento de robustez do armazenamento de memórias, estando alinhando com (MEUNIER; LAMBIOTTE; BULLMORE, 2010), o que garantiu condições de explorar um conjunto mais de fenômenos no modelo em relação aos modelos anteriores (LISMAN; IDIART, 1995; SOROKA, 2020). As ondas viajantes se referem a um conjunto relativamente recente de evidências que

mostram que as oscilações cerebrais tem um componente espacial de difícil observação, ou seja, não são estacionárias mas viajam espacialmente no tecido cortical (BURKITT et al., 2000; GOLOMB; AMITAI, 1997; LUBENOV; SIAPAS, 2009; MULLER et al., 2018; PATEL et al., 2012; ZHANG; JACOBS, 2015; ZHANG et al., 2018). Enquanto no trabalho de mestrado incorporamos uma diferença de fase nas oscilações como forma de aumentar a robustez do modelo de manter informações armazenadas, neste trabalho fundamentamos esta característica, combinando-a com uma estrutura modular e encontrando correlatos biológicos (ver próximo parágrafo). De forma complementar, demonstramos que nosso modelo tem funcionamento similar utilizando neurônios abstratos do tipo integra e dispara ou neurônios biologicamente realistas do tipo Hodgkin e Huxley. Um sumário comparativo entre o modelo original, o trabalho de mestrado e o modelo atual é apresentado na tabela 5.1, em que as siglas MTMI, IF e HH representam, respectivamente, memória de trabalho de múltiplos itens, integra e dispara, e Hodgkin Huxley.

Modelo	Lisman-Idiart (LI)	Bloqueio de Estímulos em LI	Soroka-Idiart (SI)
Publicação	(LISMAN; IDIART, 1995)	(SOROKA, 2020)	(SOROKA; IDIART; VILLAVICENCIO, 2024)
Função Cognitiva	MTMI	MTMI	MTMI
Operações de MTMI	Carregar, Manter	Bloquear	Carregar, Manter, Limpar
Oscilações	teta e gama	teta, gama e alfa	teta, gama e alfa
Arquitetura	rede única	rede única	módulos
Dinâmica	oscilações estacionárias	oscilações com diferença de fase	ondas viajantes
Estímulo	segregado	segregado	compartilhado
Modelo Neuronal	IF	IF	IF e HH

Tabela 5.1: Comparação entre três modelos de memória de trabalho de múltiplos itens.

Nosso modelo propõe uma rede que consiste em uma sequência espacial de 4 módulos de neurônios, em que as oscilações viajam através desta sequência. Modelamos, por simplicidade, como oscilações com diferenças de fase. Mostramos que a operação de carregar informações consiste em alocar corretamente uma sequência de estímulos (padrões de excitação) nos módulos, na ordem correta. Os estímulos foram modelados como uma sequência de correntes excitatórias gaussianas na banda da frequência gama (40Hz - 100Hz), e mostramos através de mapas dos parâmetros que o modelo carrega corretamente as informações para todos valores da banda, sendo que o melhor valor f_{γ}^{best} depende da escolha de outros parâmetros, como a velocidade da onda viajante (medida como a diferença de fase Ψ_{osc}) e o início do trem de estímulos (medido pela variável ϕ_i). De forma interessante, nossos resultados se alinham com medidas de diferença de fase de ondas viajantes no tecido neocortical humano (0.3-1.5 rad/cm), em oposição à medidas de diferença de fase no hipocampo humano (0.1 rad/cm) e no hipocampo do rato (2π rad/cm), o que sugere uma escala espacial para o modelo consistente com indícios de que a memória de trabalho são processos neocorticais.

Outros mapas mostram que o modelo armazena com sucesso as informações carregadas durante os ciclos subsequentes, utilizando como métrica uma função customizada para o modelo, chamada de Índice Soroka-Idiart ou apenas O_s . Esta métrica foi desenvolvida devido a natureza peculiar do modelo, em que a performance do armazenamento de múltiplas informações depende da sincronização dos disparos de neurônios de uma mesma memória e dessincronização de neurônios de diferentes memórias. Mostra-se, também, que as memórias são estáveis e mantidas por vários ciclos.

O mecanismo de apagar memórias, ou limpeza, consiste em demonstrar que o fenômeno de interferência oscilatória entre as oscilações alfa e teta é suficiente e robusta para impedir a cíclica reativação dos padrões de disparo dos neurônios. Em um protocolo de experimento, começamos com a rede apenas oscilando na frequência teta e, após 2 ciclos, carregamos informações com o trem de estímulos na frequência gama. Após mais quatro ciclos de manutenção das memórias, transferimos amplitude oscilatória da oscilação teta para a alfa, de forma que ambas somem um valor máximo. Exploramos o espaço de parâmetros variando a frequência da oscilação alfa, a fase de início da transferência de amplitude oscilatória e a amplitude oscilatória relativa de alfa, mostrando que o mecanismo de limpar memórias é robusto, sendo sensível apenas à uma frequência oscilatória alfa mínima que, para um teta de 8Hz, gira em torno dos 9Hz. Isto é, a partir dos 9Hz, alfa apaga memória com altíssima probabilidade, decrescendo logisticamente até 8Hz. Esses resultados avaliaram situações com amplitude oscilatória em torno dos 50% da amplitude máxima (35% - 65%).

Por fim, descrevemos analiticamente como o mecanismo de interferência entre oscilações impede a cíclica reativação dos padrões de disparo. A reativação ocorre quando a soma da corrente oscilatória (a nível da rede) com a corrente de potenciação pós-disparo (ADP, no nível do neurônio) atinge o limiar de disparo de cada neurônio, sendo que ambas possuem picos de excitação (um pico, para o caso do ADP). Durante o processo de interferência, a oscilação teta se torna um batimento, caracterizado pela combinação específica das oscilações que interferem. Este batimento oscila de forma irregular, apresentando picos maiores que outros, que decrescem até um valor mínimo e voltam a crescer. Frequências de alfa se encontram em uma faixa de frequências em que a interferência com o teta produz um batimento em que seu mínimo ocorre na mesma escala de tempo em que ocorre o pico da corrente ADP. Isto é, alfa interfere justamente no período crítico em que o pico da excitação intracelular coincide com o pico da excitação extracelular, impedindo sua reativação e a futura ativação da corrente ADP. Em suma, este processo permite uma rápida, robusta e sistêmica maneira de se apagar um buffer de memórias sem interferir diretamente em nenhum neurônio, deixando-os preparados para futuras memórias.

Agrupamento Hierárquico como mecanismo da linguagem

Na segunda parte, propomos responder a perguntar "como a estrutura frasal de uma sentença é representada e computada pelo cérebro" através da construção de um modelo computacional. Algumas hipóteses e formalismos computacionais diferentes foram testados, estando descritos no Apêndice A, sendo escolhida uma abordagem utilizando redes neurais artificiais para os experimentos finais. O objetivo foi integrar os diferentes campos do conhecimento que abordam o mesmo assunto: neurociência, linguística e ciência da computação. Propomos, então, que o algoritmo de aprendizado não supervisionado de agrupamento hierárquico poderia ser uma implementação da operação linguística Merge, que recursivamente combina informações linguísticas e constrói a estrutura sintática de uma sentença. Tal algoritmo utiliza uma dinâmica simples, em que representações mais similares são combinadas, duas a duas, construindo uma estrutura de agrupamentos em forma de árvore binária. Assim, como um primeiro passo, propomos estudar se esta dinâmica poderia ser implementada em uma rede neural artificial, como uma tarefa treinada em cima de um corpus de linguagem natural.

É importante destacar que a escolha da abordagem do Programa Minimalista para a computação sintática é tanto planejada quanto coincidente: por um lado a operação Merge foi proposta como um mecanismo simples e biologicamente plausível para construção frasal, posicionando-se como base neurobiológica inata da linguagem e sendo um ótimo candidato para investigação experimental e implementação em modelos computacionais, por outro lado a semelhança desta operação com o método do agrupamento hierárquico para construir estruturas em formato de árvores permitiu implementar e analisar tal fenômeno através de métodos já conhecidos. A combinação da estrutura, através da computação preestabelecida do Merge, com o aprendizado de redes neurais, propõe uma ponte entre a teoria linguística e o aprendizado estatístico, sugerindo a adoção de ambos para a descrição dos fenômenos cognitivos estudados.

O modelo de rede neural artificial consistiu em treinar uma rede de arquitetura Transformer na tarefa de produzir as representações contextualizadas das palavras de uma sentença, de forma que fosse possível reconstruir a estrutura sintática em árvore através do algoritmo de agrupamento hierárquico (HC). Para isto, se fez necessário adaptar a tarefa, visto que o algoritmo HC não pode ser escrito como uma função diferenciável e ser implementado diretamente no treinamento como uma função de custo. Assim, escrevemos uma função de custo que mapeia as representações das palavras de tal forma que, no espaço de representação de saída da rede, elas podem ser computadas pelo algoritmo de HC e estruturadas conforme a árvore correta. A função de custo explora o fato de que representações próximas no espaço de representações tendem a ser agrupadas pelo algoritmo de HC, enquanto representações afastadas não. Por isto, minimizamos a similaridade de cosseno entre a matriz de distâncias corretas das árvores sintáticas com a matriz de distância produzida utilizando as representações de saída da rede neural. Tal função é descrita pela equação 2.34. Além disto, para que a minimização da função de custo refletisse em uma correta resolução das árvores sintáticas pelo algoritmo de HC, sem que houvesse ambiguidades, utilizamos uma métrica de distância entre folhas das árvores não convencional. Ao invés de utilizar uma contagem de nós ou vértices, utilizamos a cardinalidade das subárvores que se conectam (equação 2.35). Tal métrica, além de corrigir um problema de ambiguidade, é interessante pois reflete o número de elementos em uma subárvore ou, da perspectiva linguística, o número de palavras em uma estrutura sintática.

Comparamos um modelo simples, composto por apenas duas camadas, duas cabeças de atenção e dimensão 64 com um modelo grande pré-treinado, o BERT, contendo 12 camadas, 8 cabeças de atenção e dimensão 768, mostrando que ambos são capazes de aprender e generalizar, com o modelo maior ultrapassando em performance o menor. Mostra-se que a acurácia de generalização não depende do

tamanho das sentenças, para os tamanhos entre quatro a oito palavras, mas que parece gradualmente aumentar com o aumento do conjunto de treinamento, sugerindo que performances maiores podem ser obtidas se forem utilizados mais dados.

O estudo das projeções dos vetores de palavras no espaço de saída da rede se deu através da análise de componentes principais, em que se mostrou que a projeção em duas componentes tem forma globular antes do treino e semi-circular após. Durante o treino, as duas primeiras componentes principais acumulam a variância explicada dos dados, estando esta acumulação visualmente correlacionada com a acurácia do treino. Para vetores que não possuem informação posicional a projeção assume formato oblongo. Em ambos casos, é possível observar a emergência da informação temporal como a sequência de posições na sentença, mostrando que o modelo captura as informações temporais das estruturas utilizadas.

Diferentemente de outros trabalhos que abordam o aprendizado de sintaxe em redes neurais, nossa abordagem não se propôs a responder "qual é a melhor rede neural que realiza esta tarefa", mas se a dinâmica computacional do HC seria capaz de reconstruir a estrutura, ou seja, a nossa rede neural tem por objetivo realizar o mapeamento das representações para um espaço em que isto é possível.

A partir da validação do mecanismo computacional de construção de estruturas hierárquicas, propõe-se que tal dinâmica pode ser implementada em redes neurais com inspiração biológica, organizadas como módulos de memória de trabalho de múltiplos itens baseados em oscilações cerebrais. Ou seja, uma rede de memória de trabalho de múltiplos itens poderia ser o substrato neural para as computações relacionadas com a construção de estruturas hierárquicas frasais. Cada módulo de uma rede armazena palavras ou itens lexicais do processamento de estrutura. Palavras ou itens similares possuem projeções intersectantes no módulo seguinte. A intersecção mais prevalente é responsável por gerar uma combinação, enquanto as outras não conseguem. O processo se repete até uma única representação estar presente. Cada módulo permanece, então, com a representação de um nível hierárquico, isto é, armazenando os itens pertencentes a um nível. A coleção de todos os módulos nos fornece a estrutura da sentença. Uma extensão desta ideia é abordada abaixo.

Arquitetura da Linguagem: rede de memória de trabalho como o substrato da construção de estruturas hierárquicas

Nesta tese foram descritos dois trabalhos distintos que visam propor a integração entre sistemas de memória e de linguagem. O primeiro, estabelece mecanismos neurais, através das oscilações cerebrais, para descrever os fenômenos de memória de trabalho de múltiplos itens, organizados em módulos de neurônios e com uma dinâmica espacial através de ondas viajantes. O segundo, propõe uma dinâmica de construção de estruturas hierárquicas das sentenças através do algoritmo de agrupamento hierárquico. Ambos trabalhos consistiram na proposição teórica e sua validação através de simulações computacionais, sendo, respectivamente, a simulação de redes de neurônios biologicamente inspiradas e o treinamento de redes neurais artificiais.

A sequência destes trabalhos se dá pela integração das duas proposições, isto é, simular a os fenômenos de linguagem, especificamente de construção de estruturas hierárquicas, dentro de uma rede de memória de trabalho de múltiplos itens. Este capítulo descreverá um modelo teórico, mecanístico, desta integração. Cabe lembrar que, um modelo teórico não presume-se verdadeiro, ou o modelo mais correto, mas se propõe analisar um objeto de estudo de forma simplificada, explorar fenômenos subjacentes e, de forma geral, ser útil. Assim, o modelo a seguir propõe conectar, ainda que de forma breve, a neurociência, a linguística e a modelagem computacional.

Módulos como Níveis Hierárquicos

A primeira suposição que fazemos sobre esta integração é a de que diferentes módulos formam espaços sequenciais de representação as informações de uma sentença, sendo elas as palavras e suas combinações. Os módulos sequenciais no modelo de memória de trabalho representam diferentes itens, como as diferentes palavras de uma sentença, mas neste fenômeno de processamento de linguagem eles representam níveis hierárquicos. Cada módulo representa, de forma atemporal, diferentes itens, podendo então valer três diferentes modelos (figura 5.1):

- cada módulo é formado por submódulos, constituindo uma rede como a propriedade *livre de escala e rede de redes*

- cada módulo é um buffer teta-gama, que é a descrição original do modelo de memória de trabalho de múltiplos itens baseados em oscilações
- cada módulo é uma rede espacial, e não temporal, estando todas informações ativas ao mesmo tempo, sem distinção da ordem temporal




Figura 5.1: Diferentes modelos de módulos.

Considerações a serem feitas são: enquanto as duas primeiras teorias podem ser implementadas diretamente do nosso modelo, a segunda exigiria a descrição de como a rede armazenaria informações de forma estática. Em trabalho recente, se propôs uma transformação entre uma rede que armazena múltiplos itens em sequência para uma que armazena estes itens espacialmente, ainda conseguindo manter a informação da ordem (CRISTIMANN, 2019). Ainda, as propostas de buffers espaciais necessitariam de conexões com convergência temporal, isto é, todos itens são enviados quase ao mesmo tempo, permitindo a combinação de qualquer um com qualquer um e fazendo valer duas propriedades desejadas:

- O agrupamento hierárquico não distingue a ordem temporal
- O Programa Minimalista não supõe tempo na construção de estruturas hierárquicas, assim corrobora com a hipótese de que todos itens coexistem ao mesmo tempo

Independentemente do modelo de módulo de memória, o mecanismo por trás da combinação das palavras é a similaridade espacial, isto é, palavras são combinadas se são similares, pois suas projeções para o próximo módulo irá integrar espacialmente os estímulos e elicitar o disparo de uma estrutura que representa sua combinação. Além disto, podemos descrever a dinâmica da combinação da seguinte forma (figura 5.2):

- palavras ou itens similares possuem projeções que intersectam em módulos vizinhos, estas intersecções elicitam um novo item
- combinações tem limiares de disparo maiores do que palavras sozinhas, tendo a necessidade da sincronia com a onda viajante para sua ativação
- a dinâmica de onda viajante através dos módulos garante que apenas uma combinação seja ativada por módulo (uma operação merge), enquanto palavras sozinhas conseguem disparar fora no pico
- a combinação ativa uma inibição retrógrada, inibindo outras combinações (atrasando elas e tirando de sincronia com o pico da excitação).

Assim, o mecanismo de agrupamento hierárquico pode ser traduzido em termos neurais na dinâmica de integração de informações entre módulos, cada módulo realizando uma combinação, ou seja, uma operação Merge (figura 5.3).




Figura 5.2: Mecanismo de merge.




Figura 5.3: Agrupamento hierárquico através dos módulos.

5.1 Limitações do Modelo

Apesar das contribuições conceituais e computacionais apresentadas, os modelos propostos nesta tese apresentam algumas limitações que delimitam o escopo de suas conclusões. Em primeiro lugar, não foi realizada uma validação empírica direta dos mecanismos propostos por meio de técnicas experimentais como EEG, MEG ou fMRI. Embora os modelos tenham sido construídos com base em evidências previamente reportadas na literatura, especialmente no que diz respeito ao papel das oscilações cerebrais na memória de trabalho, a correspondência entre as dinâmicas simuladas e dados neurofisiológicos permanece uma hipótese mecanística plausível, cuja investigação requer estudos futuros que integrem modelagem e análise de dados experimentais. De forma semelhante, a generalização linguística do modelo computacional proposto para a construção de estruturas sintáticas ainda não foi avaliada em diferentes línguas, corpora de maior escala ou fenômenos sintáticos mais complexos.

Outra limitação refere-se à dependência de arquiteturas de redes neurais artificiais para a implementação do mecanismo computacional investigado. Embora tais arquiteturas permitam explorar a plausibilidade computacional do processo de agrupamento hierárquico, elas não constituem, por si só, modelos biologicamente realistas do funcionamento neural. Além disso, a integração entre os dois eixos principais desta tese, o modelo de memória de trabalho baseado em oscilações cerebrais e o modelo computacional de construção de estruturas sintáticas, permanece em um nível conceitual. Embora tenha sido proposta uma arquitetura teórica que conecta ambos os mecanismos, essa integração não foi implementada em uma simulação computacional única, constituindo uma direção natural para investigações futuras.

Capítulo 6

CONCLUSÃO

O presente trabalho se propõe a criar uma ponte entre os campos da neurociência, da linguística e da ciência da computação no estudo de fenômenos de memória de trabalho e de linguagem.

A primeira parte deste estudo explorou as hipóteses de que as oscilações cerebrais têm papéis funcionais na memória de trabalho, com a oscilação gama refletindo a representação de informação, teta organizando múltiplas informações em itens e a alfa perturbando o armazenamento e manutenção. Estas oscilações teriam, entretanto, um caráter dinâmico, comportando-se como ondas viajantes. Em adição, hipotetizou-se que a função disruptora da oscilação alfa é devido a um fenômeno de interferência física entre esta oscilação e a oscilação teta, impedindo a cíclica reativação dos disparos que representam itens armazenados. Se propôs como objetivo, então, a extensão de um modelo computacional de memória de trabalho, utilizando-se uma arquitetura modular, oscilações como ondas viajantes, estudando os mecanismos e propriedades dos processos de armazenamento (alocação), manutenção e limpeza de rede. Utilizou-se simulações de neurônios abstratos (íntegra e dispara) e biologicamente realistas (Hodgkin Huxley).

Este trabalho estendeu um modelo de memória de trabalho de múltiplos itens baseado nas oscilações cerebrais teta e gama, introduzindo as oscilações alfa de forma mecanística, atribuindo a elas um papel computacional de inibir e limpar redes de memória das informações armazenadas. Através da inclusão de uma dimensão espacial através de módulos de redes, as oscilações cerebrais foram modeladas como ondas viajantes, adaptando o fenômeno de armazenamento de informações para alocação de informações em diferentes módulos com oscilações gama. O fenômeno de manutenção da memória de trabalho seguiu os princípios do modelo original, sendo baseada na reativação cíclica dos padrões de disparo pela soma da excitação da oscilação teta com a excitação da potenciação pós-disparo. A limpeza de informação foi implementada, propondo-se que um fenômeno oscilatório de interferência entre as oscilações alfa e teta produzisse períodos de baixa excitação, em que as reativações dos padrões de disparo fossem prejudicadas e terminadas. Tais fenômenos configuram computações mecanísticas realizadas por redes de neurônios biologicamente inspirados, sendo uma conexão entre a conexão e o nível neural.

A segunda parte deste trabalho muda o objeto de estudo para a linguagem e busca responder "como o cérebro representa a estrutura da linguagem, relações entre palavras e regras gramaticais?" e "quais os mecanismos pelos quais o cérebro processa a estrutura sintática?". Hipotetiza-se que ele represente esta estrutura através de uma multiplexação da informação, ou seja, os diferentes níveis hierárquicos simultaneamente, realizando o parsing das sentenças através da integração temporal limitada causada por oscilações cerebrais, em uma rede espacialmente modular. A hipótese central propõe o processo computacional de agrupamento hierárquico como modelo de construção de estrutura sintática frasal, podendo este ser visto como a recursão da operação linguística Merge sobre itens lexicais. Por fim, se hipotetiza que uma rede neural artificial pode ser treinada na tarefa de aprender as representações das palavras de forma que um algoritmo de agrupamento hierárquico possa produzir a árvore sintática de sentenças. Com isto, teve-se como objetivo a proposição e validação de um algoritmo computacional simples para a construção de estrutura hierárquica frasal, através do treinamento de uma rede neural artificial e da elaboração de um modelo teórico de implementação em redes biologicamente inspiradas.

O algoritmo de agrupamento hierárquico se assemelha a descrição proposta pela teoria linguística Programa Minimalista como dinâmica do mesmo fenômeno, sendo plausivelmente simples de ser implementado em redes neurais. Validamos tal ideia em redes neurais artificiais, propondo que uma rede de arquitetura transformer poderia ser treinada para mapear as representações das palavras de sentenças de um corpus de linguagem natural de forma que o algoritmo reciasse as árvores. Estudamos o fenômeno

como o mapeamento dos vetores de palavra de um espaço de representação para outro, mostrando uma curiosa mudança de formato da distribuição destes vetores com o treinamento. Tais resultados podem ser explorados para o entendimento do funcionamento de grandes modelos de linguagem.

Por fim, propõe-se uma conexão entre as duas funções cognitivas: memória de trabalho e linguagem, descrevendo um modelo teórico de como as computações relacionadas com o fenômeno de construção de estrutura hierárquica em frases poderia acontecer em uma rede de memória. Uma extensão natural deste trabalho é a modelagem de tais computações em uma rede de neurônios biologicamente inspirados, como aqueles utilizados na primeira parte.

É importante salientar que os estudos apresentados nesta tese se concentram na exploração de modelos teóricos e computacionais de funções cognitivas, propondo e analisando seus mecanismos de funcionamento no contexto interno de cada modelo. Embora o modelo de memória de trabalho seja fundamentado em evidências experimentais, trata-se de uma construção teórica cujo objetivo, neste estágio, não é a formulação direta de hipóteses experimentais, mas a proposição de explicações mecanicistas para fenômenos observados e a integração de diferentes linhas de evidência. Desdobramentos experimentais mais diretos deverão aguardar a maturação do modelo e ser conduzidos em colaboração com especialistas nas técnicas experimentais apropriadas. De modo análogo, o modelo de linguagem apresentado propõe um princípio computacional para um processo intrinsecamente complexo e dinâmico, cuja conexão direta com a pesquisa empírica dependerá de avanços futuros na investigação experimental.

REFERÊNCIAS

- ABBOTT, L. F. Lapicque's introduction of the integrate-and-fire model neuron (1907). *Brain Research Bulletin*, v. 50, n. 5-6, p. 303–304, 1999.
- AXMACHER, N.; HENSELER, M. M.; JENSEN, O.; WEINREICH, I.; ELGER, C. E.; FELL, J. Cross-frequency coupling supports multi-item working memory in the human hippocampus. *Proceedings of the National Academy of Sciences*, v. 107, n. 7, p. 3228–3233, 2010.
- BADDELEY, A. The episodic buffer: a new component of working memory? *Trends in Cognitive Sciences*, v. 4, n. 11, p. 417–423, 2000.
- BADDELEY, A. D.; HITCH, G. Working memory. In: BOWER, G. H. (Ed.). *Psychology of Learning and Motivation*. [S.l.]: Academic Press, 1974. v. 8, p. 47–89.
- BASSETT, D. S.; ZURN, P.; GOLD, J. I. On the nature and use of models in network neuroscience. *Nature Reviews Neuroscience*, v. 19, p. 566–578, 2018.
- BAUER, M.; KENNETT, S.; DRIVER, J. Attentional selection of location and modality in vision and touch modulates low-frequency activity in associated sensory cortices. *Journal of Neurophysiology*, v. 107, n. 9, p. 2342–2351, 2012.
- BEAR, M. F.; CONNORS, B. W.; PARADISO, M. A. *Neuroscience: Exploring the Brain*. 4. ed. Philadelphia: Wolters Kluwer, 2017. ISBN 9780781797816.
- BELLUSCIO, M. A.; MIZUSEKI, K.; SCHMIDT, R.; KEMPTER, R.; BUZSAKI, G. Cross-frequency phase-phase coupling between theta and gamma oscillations in the hippocampus. *Journal of Neuroscience*, v. 32, n. 2, p. 423–435, 2012.
- BERGER, H. Über das elektrenkephalogramm des menschen. *Archiv für Psychiatrie und Nervenkrankheiten*, v. 87, p. 527–570, 1929.
- BOLLIMUNTA, A.; CHEN, Y.; SCHROEDER, C. E.; DING, M. Neuronal mechanisms of cortical alpha oscillations in awake-behaving macaques. *Journal of Neuroscience*, v. 28, n. 40, p. 9976–9988, 2008.
- BOLLIMUNTA, A.; MO, J.; SCHROEDER, C. E.; DING, M. Neuronal mechanisms and attentional modulation of corticothalamic alpha oscillations. *Journal of Neuroscience*, v. 31, n. 13, p. 4935–4943, 2011.
- BONNEFOND, M.; JENSEN, O. Alpha oscillations serve to protect working memory maintenance against anticipated distracters. *Current Biology*, v. 22, n. 20, p. 1969–1974, 2012.
- BRAGIN, A.; JANDO, G.; NADASDY, Z.; HETKE, J.; WISE, K.; BUZSAKI, G. Gamma (40-100 hz) oscillation in the hippocampus of the behaving rat. *Journal of Neuroscience*, v. 15, n. 1, p. 47–60, 1995.
- BURKITT, G.; SILBERSTEIN, R.; CADUSCH, P.; WOOD, A. Steady-state visual evoked potentials and travelling waves. *Clinical Neurophysiology*, v. 111, p. 246–258, 2000.
- BUSCH, N. A.; HERRMANN, C. S. Object-load and feature-load modulate eeg in a short-term memory task. *Neuroreport*, v. 14, n. 13, p. 1721–1724, 2003.
- CALMUS, R.; WILSON, B.; KIKUCHI, Y.; PETKOV, C. I. Structured sequence processing and combinatorial binding: neurobiologically and computationally informed hypotheses. *Philosophical Transactions of the Royal Society B: Biological Sciences*, v. 375, n. 1791, p. 20190304, 2020.

- CANOLTY, R. T.; EDWARDS, E.; DALAL, S.; SOLTANI, M.; NAGARAJAN, S.; KIRSCH, H.; BERGER, M. S.; BARBARO, N. M.; KNIGHT, R. T. High gamma power is phase-locked to theta oscillations in human neocortex. *Science*, v. 313, p. 1626–1628, 2006.
- CHOMSKY, N. A minimalist program for linguistic theory. In: HALE, K.; KEYSER, S. J. (Ed.). *The View From Building 20: Essays in Linguistics in Honor of Sylvain Bromberger*. [S.l.]: MIT Press, 1993.
- CHOMSKY, N.; SMITH, N. *New Horizons in the Study of Language and Mind*. Cambridge: Cambridge University Press, 2000.
- COHEN, M. X. Assessing transient cross-frequency coupling in eeg data. *Journal of Neuroscience Methods*, v. 168, p. 494–499, 2008.
- COLGIN, L. L.; DENNINGER, T.; FYHN, M.; HAFTING, T.; BONNEVIE, T.; JENSEN, O.; MOSER, M.-B.; MOSER, E. I. Frequency of gamma oscillations routes flow of information in the hippocampus. *Nature*, v. 462, p. 353–357, 2009.
- COOPER, N. R.; CROFT, R. J.; DOMINEY, S. J. J.; BURGESS, A. P.; GRUZELIER, J. H. Paradox lost? exploring the role of alpha oscillations during externally vs. internally directed attention and the implications for idling and inhibition hypotheses. *International Journal of Psychophysiology*, v. 47, n. 1, p. 65–74, 2003.
- CRISTIMANN, N. M. *Codificação de sequências temporais em padrões espaciais em redes neurais*. Dissertação (Dissertação (Mestrado)) — Universidade Federal do Rio Grande do Sul, 2019.
- CURTIS, C. E.; D'ESPOSITO, M. Persistent activity in the prefrontal cortex during working memory. *Trends in Cognitive Sciences*, v. 7, n. 9, p. 415–423, 2003.
- DAYAN, P.; ABBOTT, L. F. *Theoretical Neuroscience: Computational and Mathematical Modeling of Neural Systems*. Cambridge, MA: MIT Press, 2005. ISBN 0262541858.
- DIPOPPA, M.; GUTKIN, B. S. Flexible frequency control of cortical oscillations enables computations required for working memory. *Proceedings of the National Academy of Sciences*, v. 110, n. 31, p. 12828–12833, 2013.
- DIPOPPA, M.; SZWED, M.; GUTKIN, B. S. Controlling working memory operations by selective gating: The roles of oscillations and synchrony. *Advances in Cognitive Psychology*, v. 12, n. 4, p. 209–232, 2016.
- DREW, T. W.; MCCOLLOUGH, A. W.; VOGEL, E. K. Event-related potential measures of visual working memory. *Clinical EEG and Neuroscience*, v. 37, n. 4, p. 286–291, 2006.
- FOX, J. J.; SIMPSON, G. V.; AHLFORS, S. P. Parieto-occipital 10 hz activity reflects anticipatory state of visual attention mechanisms. *NeuroReport*, v. 9, n. 17, p. 3929–3933, 1998.
- FREY, J. N.; MAINY, N.; LACHAUX, J.-P.; MÜLLER, N.; BERTRAND, O.; WEISZ, N. Selective modulation of auditory cortical alpha activity in an audiovisual spatial attention task. *Journal of Neuroscience*, v. 34, n. 19, p. 6634–6639, 2014.
- FRIEDERICI, A. D. *Language in Our Brain: The Origins of a Uniquely Human Capacity*. Cambridge, MA: MIT Press, 2017. ISBN 9780262038056.
- FU, K.-M. G.; FOX, J. J.; MURRAY, M. M.; HIGGINS, B. A.; JAVITT, D. C.; SCHROEDER, C. E. Attention-dependent suppression of distracter visual input can be cross-modally cued as indexed by anticipatory parieto-occipital alpha-band oscillations. *Cognitive Brain Research*, v. 12, n. 1, p. 145–152, 2001.
- GAYLER, R. W. *Vector Symbolic Architectures Answer Jackendoff's Challenges for Cognitive Neuroscience*. 2004. ArXiv preprint cs/0412059. Disponível em: <<https://arxiv.org/abs/cs/0412059>>.
- GEVINS, A.; SMITH, M. E.; MCEVOY, L.; YU, D. High-resolution eeg mapping of cortical activation related to working memory: Effects of task difficulty, type of processing, and practice. *Cerebral Cortex*, v. 7, n. 4, p. 374–385, 1997.
- GIRAUD, A.-L.; POEPEL, D. Cortical oscillations and speech processing: Emerging computational principles and operations. *Nature Neuroscience*, v. 15, p. 511–517, 2012.

- GOLOMB, D.; AMITAI, Y. Propagating neuronal discharges in neocortical slices: Computational and experimental study. *Journal of Neurophysiology*, v. 78, n. 3, p. 1199–1211, 1997.
- GOMEZ-RAMIREZ, M.; KELLY, S. P.; MOLHOLM, S.; SEHATPOUR, P.; SCHWARTZ, T. H.; FOXE, J. J. Oscillatory sensory selection mechanisms during intersensory attention to rhythmic auditory and visual inputs: A human electrocorticographic investigation. *Journal of Neuroscience*, v. 31, n. 50, p. 18556–18567, 2011.
- HAEGENS, S.; HÄNDEL, B. F.; JENSEN, O. Top-down controlled alpha band activity in somatosensory areas determines behavioral performance in a discrimination task. *Journal of Neuroscience*, v. 31, n. 14, p. 5197–5204, 2011.
- HAEGENS, S.; OSIPOVA, D.; OOSTENVELD, R.; JENSEN, O. Somatosensory working memory performance in humans depends on both engagement and disengagement of regions in a distributed network. *Human Brain Mapping*, v. 31, n. 1, p. 26–35, 2010.
- HAUSER, M. D.; CHOMSKY, N.; FITCH, W. T. The faculty of language: What is it, who has it, and how did it evolve? *Science*, v. 298, n. 5598, p. 1569–1579, 2002.
- HERRMANN, C. S.; SENKOWSKI, D.; RÖTTGER, S. Phase-locking and amplitude modulations of eeg alpha. *Experimental Psychology*, v. 51, n. 4, p. 311–318, 2004.
- HOCKETT, C. F. The origin of speech. *Scientific American*, v. 203, n. 3, p. 88–96, 1960.
- HORTON, J. C.; ADAMS, D. L. The cortical column: A structure without a function. *Philosophical Transactions of the Royal Society B: Biological Sciences*, v. 360, n. 1456, p. 837–862, 2005.
- HSIEH, L.-T.; EKSTROM, A. D.; RANGANATH, C. Neural oscillations associated with item and temporal order maintenance in working memory. *Journal of Neuroscience*, v. 31, n. 30, p. 10803–10810, 2011.
- IZQUIERDO, I. *Memória*. 2. ed. Porto Alegre: Artmed, 2002.
- JENSEN, O.; GELFAND, J.; KOUNIOS, J.; LISMAN, J. E. Oscillations in the alpha band (9–12 hz) increase with memory load during retention in a short-term memory task. *Cerebral Cortex*, v. 12, n. 8, p. 877–882, 2002.
- JENSEN, O.; SPAAK, E.; ZUMER, J. Human brain oscillations: From physiological mechanisms to analysis and cognition. In: *Magnetoencephalography: From Signals to Dynamic Cortical Networks*. Berlin: Springer, 2014. p. 359–404.
- JENSEN, O.; TESCHE, C. Frontal theta activity in humans increases with memory load in a working memory task. *European Journal of Neuroscience*, v. 15, n. 8, p. 1395–1399, 2002.
- JOKISCH, D.; JENSEN, O. Modulation of gamma and alpha activity during a working memory task engaging the dorsal or ventral stream. *Journal of Neuroscience*, v. 27, n. 12, p. 3244–3251, 2007.
- KAISER, J.; HEIDEGGER, T.; WIBRAL, M.; ALTMANN, C. F.; LUTZENBERGER, W. Alpha synchronization during auditory spatial short-term memory. *NeuroReport*, v. 18, n. 11, p. 1129–1132, 2007.
- KANDEL, E. R.; SCHWARTZ, J. H.; JESSELL, T. M. *Principles of Neural Science*. 5. ed. New York: McGraw-Hill, 2013. ISBN 9780071390118.
- KAUFMAN, L.; CURTIS, S.; WANG, J.-Z.; WILLIAMSON, S. J. Changes in cortical activity when subjects scan memory for tones. *Electroencephalography and Clinical Neurophysiology*, v. 82, p. 266–284, 1992.
- KAUFMAN, L.; SCHWARTZ, B.; SALUSTRI, C.; WILLIAMSON, S. J. Modulation of spontaneous brain activity during mental imagery. *Journal of Cognitive Neuroscience*, v. 2, n. 2, p. 124–132, 1990.
- KLIMESCH, W. Eeg alpha and theta oscillations reflect cognitive and memory performance: a review and analysis. *Brain Research Reviews*, v. 29, n. 2–3, p. 169–195, 1999.
- LEIBERG, S.; LUTZENBERGER, W.; KAISER, J. Effects of memory load on cortical oscillatory activity during auditory pattern working memory. *Brain Research*, v. 1120, n. 1, p. 131–140, 2006.

- LISMAN, J. E.; IDIART, M. A. P. Storage of 7 ± 2 short-term memories in oscillatory subcycles. *Science*, v. 267, n. 5203, p. 1512–1515, 1995.
- LUBENOV, E. V.; SIAPAS, A. G. Hippocampal theta oscillations are travelling waves. *Nature*, v. 459, n. 7246, p. 534–539, 2009.
- MARESH, A.; GIL, D. R.; WHITMAN, K. L.; GREER, C. A. Principles of glomerular organization in the human olfactory bulb: implications for odor processing. *PLoS ONE*, v. 3, n. 9, p. e2640, 2008.
- MARIS, E.; KAHANA, M. Spatially distributed patterns of oscillatory coupling between high-frequency amplitudes and low-frequency phases in human iieeg. *NeuroImage*, v. 54, n. 2, p. 836–850, 2011.
- MARR, D. *Vision: A Computational Investigation into the Human Representation and Processing of Visual Information*. San Francisco: W. H. Freeman, 1982. ISBN 0716715678.
- MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, v. 5, p. 115–133, 1943.
- MEDENDORP, W. P.; KRAMER, G. F. I.; JENSEN, O.; OOSTENVELD, R.; SCHOFFELEN, J.-M.; FRIES, P. Oscillatory activity in human parietal and occipital cortex shows hemispheric lateralization and memory effects in a delayed double-step saccade task. *Cerebral Cortex*, v. 17, n. 10, p. 2364–2374, 2007.
- MEUNIER, D.; LAMBIOTTE, R.; BULLMORE, E. T. Modular and hierarchically modular organization of brain networks. *Frontiers in Neuroscience*, v. 4, p. 200, 2010.
- MEYER, H. S.; EGGER, R.; GUEST, J. M.; FOERSTER, R.; REISSL, S.; OBERLAENDER, M. Cellular organization of cortical barrel columns is whisker-specific. *Proceedings of the National Academy of Sciences of the United States of America*, v. 110, n. 47, p. 19113–19118, 2013.
- MICHEL, C. M.; KAUFMAN, L.; WILLIAMSON, S. J. Duration of eeg and meg alpha suppression increases with angle in a mental rotation task. *Journal of Cognitive Neuroscience*, v. 6, n. 2, p. 139–150, 1994.
- MILLER, G. A. The magical number seven, plus or minus two: some limits on our capacity for processing information. *Psychological Review*, v. 63, n. 2, p. 81–97, 1956.
- MINSKY, M.; PAPERT, S. *Perceptrons: An Introduction to Computational Geometry*. Expanded edition. Cambridge, MA: MIT Press, 1988.
- MOOSMANN, M.; RITTER, P.; KRISTEL, I.; BRINK, A.; THEES, S.; BLANKENBURG, F.; TASKIN, B.; OBRIG, H.; VILLRINGER, A. Correlates of alpha rhythm in functional magnetic resonance imaging and near infrared spectroscopy. *NeuroImage*, v. 20, n. 1, p. 145–158, 2003.
- MULLER, L.; CHAVANE, F.; REYNOLDS, J.; SEJNOWSKI, T. Cortical travelling waves: mechanisms and computational principles. *Nature Reviews Neuroscience*, v. 19, n. 5, p. 255–268, 2018.
- MURPHY, E. *The Oscillatory Nature of Language*. Cambridge: Cambridge University Press, 2020.
- O'KEEFE, J.; RECCE, M. L. Phase relationship between hippocampal place units and the eeg theta rhythm. *Hippocampus*, v. 3, n. 3, p. 317–330, 1993.
- ONSLOW, A. C. E.; BOGACZ, R.; JONES, M. W. Quantifying phase–amplitude coupling in neuronal network oscillations. *Progress in Biophysics and Molecular Biology*, v. 105, n. 1–2, p. 49–57, 2011.
- PALVA, S.; KULASHEKHAR, S.; HÄMÄLÄINEN, M.; PALVA, J. M. Localization of cortical phase and amplitude dynamics during visual working memory encoding and retention. *Journal of Neuroscience*, v. 31, n. 13, p. 5013–5025, 2011.
- PAPADIMITRIOU, C. H.; VEMPALA, S. S.; MITROPOLSKY, D.; COLLINS, M.; MAASS, W. Brain computation by assemblies of neurons. *Proceedings of the National Academy of Sciences*, v. 117, n. 25, p. 14464–14472, 2020.
- PATEL, J.; FUJISAWA, S.; BERÉNYI, A.; ROYER, S.; BUZSÁKI, G. Traveling theta waves along the entire septotemporal axis of the hippocampus. *Neuron*, v. 75, n. 3, p. 410–417, 2012.

- PENNY, W. D.; DÜZEL, E.; MILLER, K. J.; OJEMANN, J. G. Testing for nested oscillation. *Journal of Neuroscience Methods*, v. 174, n. 1, p. 50–61, 2008.
- PINKER, S. *The Language Instinct: How the Mind Creates Language*. New York: William Morrow and Company, 1994. ISBN 9780060976514.
- RAGHAVACHARI, S.; KAHANA, M. J.; RIZZUTO, D. S.; CAPLAN, J. B.; KIRSCHEN, M. P.; BOURGEOIS, B.; MADSEN, J. R.; LISMAN, J. E. Gating of human theta oscillations by a working memory task. *Journal of Neuroscience*, v. 21, n. 9, p. 3175–3183, 2001.
- ROBERTS, B. M.; HSIEH, L.-T.; RANGANATH, C. Oscillatory activity during maintenance of spatial and temporal information in working memory. *Neuropsychologia*, v. 51, n. 2, p. 349–357, 2013.
- RODRIGUEZ, G.; SARAZIN, M.; CLEMENTE, A.; HOLDEN, S.; PAZ, J. T.; DELORD, B. Conditional bistability, a generic cellular mnemonic mechanism for robust and flexible working memory computations. *Journal of Neuroscience*, v. 38, n. 22, p. 5209–5219, 2018.
- ROSENBLATT, F. *The perceptron: A perceiving and recognizing automaton*. Ithaca, New York, 1957.
- ROSENBLATT, F. *The Design of an Intelligent Automaton*. Buffalo, NY, 1958.
- ROUX, F.; UHLHAAS, P. J. Working memory and neural oscillations: alpha–gamma versus theta–gamma codes for distinct wm information? *Trends in Cognitive Sciences*, v. 18, n. 1, p. 16–25, 2014.
- ROUX, F.; WIBRAL, M.; MOHR, H. M.; SINGER, W.; UHLHAAS, P. J. Gamma-band activity in human prefrontal cortex codes for the number of relevant items maintained in working memory. *Journal of Neuroscience*, v. 32, n. 36, p. 12411–12420, 2012.
- RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. *Nature*, v. 323, n. 6088, p. 533–536, 1986.
- SAUSENG, P.; KLIMESCH, W.; DOPPELMAYR, M.; PECHERSTORFER, T.; FREUNBERGER, R.; HANSLMAYR, S. Eeg alpha synchronization and functional coupling during top-down processing in a working memory task. *Human Brain Mapping*, v. 26, n. 2, p. 148–155, 2005.
- SAUSENG, P.; KLIMESCH, W.; HEISE, K. F.; GRUBER, W. R.; HOLZ, E.; KARIM, A. A.; GLENNON, M.; GERLOFF, C.; BIRBAUMER, N.; HUMMEL, F. C. Brain oscillatory substrates of visual short-term memory capacity. *Current Biology*, v. 19, n. 21, p. 1846–1852, 2009.
- SCHACK, B.; KLIMESCH, W. Frequency characteristics of evoked and oscillatory electroencephalographic activity in a human memory scanning task. *Neuroscience Letters*, v. 331, n. 2, p. 107–110, 2002.
- SCHEERINGA, R.; PETERSSON, K. M.; OOSTENVELD, R.; NORRIS, D. G.; HAGOORT, P.; BASTIAANSEN, M. C. M. Trial-by-trial coupling between eeg and bold identifies networks related to alpha and theta eeg power increases during working memory maintenance. *NeuroImage*, v. 44, n. 3, p. 1224–1238, 2009.
- SOROKA, G. *Bloqueio de estímulos por oscilações alfa em modelos computacionais de memória de trabalho de múltiplos itens*. Dissertação (Mestrado) — Universidade Federal do Rio Grande do Sul, Porto Alegre, 2020.
- SOROKA, G.; IDIART, M.; VILLAVICENCIO, A. Mechanistic role of alpha oscillations in a computational model of working memory. *PLOS ONE*, v. 19, n. 2, p. e0296217, 2024.
- STERNBERG, S. High-speed scanning in human memory. *Science*, v. 153, n. 3736, p. 652–654, 1966.
- SUN, C.; KITAMURA, T.; YAMAMOTO, J.; MARTIN, J.; PIGNATELLI, M.; KITCH, L. J.; SCHNITZER, M. J.; TONEGAWA, S. Distinct speed dependence of entorhinal island and ocean cells, including respective grid cells. *Proceedings of the National Academy of Sciences*, v. 112, n. 30, p. 9466–9471, 2015.
- TALLON-BAUDRY, C.; BERTRAND, O.; PERONNET, F.; PERNIER, J. Induced gamma-band activity during the delay of a visual short-term memory task in humans. *Journal of Neuroscience*, v. 18, n. 11, p. 4244–4254, 1998.

- TORT, A. B. L.; KOMOROWSKI, R.; EICHENBAUM, H.; KOPELL, N. Measuring phase-amplitude coupling between neuronal oscillations of different frequencies. *Journal of Neurophysiology*, v. 104, n. 2, p. 1195–1210, 2010.
- VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. In: *Advances in Neural Information Processing Systems*. [S.l.]: Curran Associates, Inc., 2017. v. 30.
- VOGELS, T. P.; ABBOTT, L. F. Signal propagation and logic gating in networks of integrate-and-fire neurons. *Journal of Neuroscience*, v. 25, n. 46, p. 10786–10795, 2005.
- WHITTINGTON, M. A.; TRAUB, R. D.; KOPELL, N.; ERMENTROUT, B.; BUHL, E. H. Inhibition-based rhythms: experimental and mathematical observations on network dynamics. *International Journal of Psychophysiology*, v. 38, n. 3, p. 315–336, 2001.
- WITTEKINDT, A.; KAISER, J.; ABEL, C. Attentional modulation of the inner ear: a combined otoacoustic emission and eeg study. *Journal of Neuroscience*, v. 34, n. 30, p. 9995–10002, 2014.
- ZACCARELLA, E.; FRIEDERICI, A. D. The neurobiological nature of syntactic hierarchies. *Neuroscience & Biobehavioral Reviews*, v. 81, p. 205–212, 2017.
- ZACCARELLA, E.; SCHELL, M.; FRIEDERICI, A. D. Reviewing the functional basis of the syntactic merge mechanism for language: a coordinate-based activation likelihood estimation meta-analysis. *Neuroscience & Biobehavioral Reviews*, v. 80, p. 646–656, 2017.
- ZENG, J. Joint attention and its linguistic representation in dialogue: embodiment revisited. *Frontiers in Psychology*, v. 14, p. 1221737, 2023.
- ZHANG, H.; JACOBS, J. Traveling theta waves in the human hippocampus. *Journal of Neuroscience*, v. 35, n. 36, p. 12477–12487, 2015.
- ZHANG, H.; WATROUS, A. J.; PATEL, A.; JACOBS, J. Theta and alpha oscillations are traveling waves in the human neocortex. *Neuron*, v. 98, n. 6, p. 1269–1281, 2018.

HIPÓTESES COMPUTACIONAIS NO ESTUDO DA SINTAXE

Este capítulo abordará o conjunto de hipóteses e modelos testados no estudo da sintaxe. Ao longo deste trabalho, diversos formalismos e modelos foram explorados para testar as hipóteses propostas.

Primeiros Modelos

Sintaxe utilizando arquiteturas simbólicas vetoriais

Quando estabelecemos o problema "como o cérebro organiza e armazena a estrutura hierárquica de sentenças?", formulamos uma primeira hipótese de que "ele combina palavras/informações em novas informações (estruturas sintáticas), escolhendo quais dentre todas as combinações são aquelas corretas". Fomos além e propomos que "ritmos oscilatórios com períodos diferentes podem ser a base física para a combinação de estruturas de diferentes tamanhos, promovendo janelas temporais de integração com diferentes períodos". Esta hipótese, apesar de não ser totalmente nova (MURPHY, 2020; GIRAUD; POEPPEL, 2012) é uma ideia poderosa e de difícil demonstração.

O formalismo das arquiteturas simbólicas vetoriais, pareceu uma escolha interessante e certa para testar nossas hipóteses. Nele, informações são representadas por vetores hiperdimensionais (como, por exemplo, os valores de atividade neuronal (seja lá qual for a medida escolhida) e operações algébricas semi-reversíveis são empregadas para combinar essas informações (Figura 1). Diferentes operações resultam em novas informações com diferentes propriedades, por exemplo a operação de "bundling" combina duas informações mantendo a similaridade da nova informação com as originais, já a operação "binding" resulta em uma nova informação que não possui similaridade com as originais.




Figura 1: Representação e transformação de informações nas arquiteturas simbólicas vetoriais. Palavras são representadas como vetores numéricos hiperdimensionais e operações como o bundling e o binding combinam esses vetores em novos. Cada operação possui propriedades distintas.

Uma das características mais interessantes deste formalismo é a possibilidade de reverter a combinação e retornar às informações originais ou a aproximações das informações originais. Diferentes modelos dentro deste formalismo empregam tipos diferentes de representação (por exemplo binárias ou esparsas),

e possuem operações algébrica distintas, havendo leves variações da propriedades das combinações.

Muitos trabalhos foram desenvolvidos na área da linguagem utilizando o formalismo das arquiteturas simbólicas vetoriais. Trabalhos mais antigos apontam para o poder do formalismo em representar palavras, combinações de palavras, sentenças, responder perguntas e fazer associações utilizando a reversibilidade das combinações (GAYLER, 2004). Em trabalhos mais recentes já se empregou o formalismo em problemas similares ao nosso, envolvendo sintaxe e a construção hierárquica de sentenças (CALMUS et al., 2020).

A figura 2 esquematiza o primeiro modelo teórico deste trabalho, que propôs um mecanismo de construção da estrutura sintática de uma sentença através de uma sequência de camadas de vetores hiperdimensionais que iriam realizar sua combinação através de operações consecutivas (operações VSA, de *vector symbolic architectures*). Essas operações iriam combinar de acordo com períodos de integração, de forma crescente. A primeira camada iria combinar palavras lado a lado, e depois essas combinações iriam ser combinadas até formar uma única representação da frase (Figura 2A). Até aqui, o modelo não distingue se uma combinação é certa ou errada. O modelo, então, propunha fazer uma etapa de descombinar as informações (em termos mais corretos a primeira seria a etapa de codificação e a segunda de decodificação) (Figura 2B). Ao fazer a decodificação, informações vindas da memória de trabalho e memória de longo prazo modulariam a escolha das estruturas sintáticas a serem recuperadas de todas que foram combinadas (como uma seleção). Essas estruturas seriam, então, aquelas combinações corretas e que formariam a estrutura sintática da sentença. A Figura 2C e Figura 2D ilustram a hipótese de que as dimensões dos vetores poderiam ser imaginadas como características semânticas e que a seleção poderia usar como critério a similaridade de duas palavras a serem combinadas. A Figura 2E ilustra a memória de trabalho de múltiplos itens baseada no teta-gama armazenando momentaneamente as palavras e possíveis estruturas combinadas.




Figura 2: Modelo de arquitetura simbólica vetorial. A) Arquitetura da rede em camadas de vetores que realizam consecutivamente operações VSA. Dois outros sistemas, de memória de longo prazo (LTM, *long-term memory*) e memória de trabalho (WM, *working memory*) também estão presentes. B) Simplificação da arquitetura, focando na ideia de codificação e decodificação com seleção das informações. C) O significado das palavras pode ser imaginado partindo de unidades semânticas nos vetores. D) A similaridade entre vetores poderia ser o critério de seleção das combinações na decodificação. E) Memória de trabalho de múltiplos itens baseada no teta-gama armazenando informações da sentença.

Uma variação do modelo original foi considerada, adaptando a arquitetura da rede para explorar a multiplexação de informação (combinações com diferentes granularidades) através de uma arquitetura paralela, como mostrada na figura 3.

O grande desafio destes modelo era sua implementação no formalismo das arquiteturas simbólicas vetoriais, pois neste formalismo as combinações são realizadas de forma discreta, tempo a tempo, ou seja, não existe a noção de integração de estímulos ou janelas temporais (Figura 4a). Nesse sentido,




Figura 3: Modelo com uma arquitetura de multiplexação paralela de combinações de palavras.

modelar uma oscilação cujo efeito é aumentar a probabilidade que dois estímulos sejam integrados juntos e combinados significava criar um fenômeno novo dentro do formalismo. A solução que encontramos para isso foi imaginar que todas informações da sequência tentam se combinar em todos instantes, porém aquelas que, originalmente, estão fora de um pico de oscilação, são distorcidas por um ruído gaussiano, mimetizando oscilações (Figura 4b). Representações distorcidas geram combinações que não podem ser recuperadas, sendo tratadas apenas como ruído. Assim, reformulamos uma dinâmica de combinação de informações apresentadas sequencialmente (Figura 4c) em uma em que não existe explicitamente a sequência (Figure 4d), porém reproduz as mesmas combinações da original. Na figura 4, o eixo y dos gráficos exprime a similaridade das representações com elas mesmas, sendo calculado através da similaridade de cosseno.




Figura 4: Implementação de oscilações no formalismo das arquiteturas simbólicas vetoriais: a) sequências de palavras foram consideradas como não sendo sequenciais; b) modulação gaussiana distorceu as representações, simulando oscilações; c) sequência de palavras distorcidas; d) palavras não sequenciais distorcidas.

De forma complementar, a hipótese de que oscilações de períodos diferentes poderiam gerar combinações hierárquicas foi considerada utilizando a implementação descrita acima (Figura 5). O princípio básico consiste em: oscilações com períodos maiores podem integrar mais informações, e oscilações com períodos menores integram menos. O gráfico de cima mostra um pico de oscilação com três ou quatro representações nele, enquanto no gráfico do meio temos no máximo duas representações em um mesmo pico.




Figura 5: Múltiplas oscilações implementadas como distorções das representações.

Um desafio adicional do formalismo das arquiteturas simbólicas vetoriais é a identificação de quais informações estão sendo representadas e combinadas, havendo necessidade de uma verificação tempo a tempo através do processo inverso da combinação (chamado de recuperação). Este processo tem a seguinte dinâmica: uma combinação de três palavras (tamanho 3), ao ser recuperada, retorna uma das representações que a originou. Por exemplo

- dada a representação da combinação de A com MENINA, $A * MENINA$
 - utilizando a pista "A", recuperamos "MENINA"
 - utilizando a pista "MENINA", recuperamos "A"
- dada a representação da combinação de A com MENINA com VIU, $A * MENINA * VIU$
 - utilizando a pista "A", recuperamos "MENINA * VIU"
 - utilizando a pista "MENINA", recuperamos "A * VIU"
 - utilizando a pista "VIU", recuperamos "A * MENINA"

Na prática, se torna necessária a criação de detectores de representação, em que se aplicam todas pistas possíveis (as palavras da sentença original) e se computa a similaridade de uma dada representação com uma tabela de possíveis representações. Um exemplo de tal sensor é mostrado na figura 6, em que se aplicam todas as pistas da sentença original "A menina viu o gato com o telescópio" na combinação $A * MENINA * VIU$ e se compara o resultado com todas possíveis combinações de tamanho 2. Nota-se que o detector mostrou que a representação ' $A * MENINA * VIU$ ' foi criada utilizando as representações com alto grau de similaridade do gráfico, ou seja, é uma combinação de "A", "MENINA" e "VIU".

Após estes avanços, o formalismo das arquiteturas simbólicas vetoriais foi abandonado à complexidade de implementação, como pode ser observado nos exemplos acima.




Figura 6: Detetor de representação aplicado à combinação "A-menina-viu": utilizando como pista todas as palavras da sentença original se recupera uma representação, que se compara com todas as possíveis representações, elicitando um alto valor de similaridade para "A-menina", "A-viu" e "menina-viu".

Sintaxe como Prioridade

O estudo da representação de palavras como vetores hiperdimensionais, como no caso do formalismo das arquiteturas simbólicas vetoriais, nos introduziu a como redes neurais artificiais modernas usam e processam informação sobre linguagem. Estudando o modelo Word2Vec de 2013 sobre o treinamento de vetores de palavras e nós procuramos testar a hipótese de que o modelo priorizaria informações sintáticas durante seu treinamento quando o tamanho da rede fosse restringido. Isto é, estudamos a hipótese de que uma melhor performance do modelo seria atingida se ele aprendesse prioritariamente informações sobre sintaxe, em contraposição com semântica. Para testar a hipótese, treinamos vetores de palavras de diferentes tamanhos utilizando o modelo do Word2Vec e uma porção do corpus British National Corpus e analisar através da técnica de agrupamento se informações sintáticas haviam sido internalizadas. Testamos a hipótese analisando se o agrupamento juntava os vetores de palavras em grupos de acordo com sua classe gramatical (ex. substantivo, adjetivo, advérbio, verbo, etc.) (Figura 7).




Figura 7: Esquema de análise de informações sintáticas em representações do Word2Vec através do método de agrupamento.

Apesar de inúmeros testes, não conseguimos observar nenhuma tendência do modelo priorizar informações sintáticas ao se restringir o tamanho da representação (E_{size}) através do método de agrupamento

K-Means. Fica claro no exemplo mostrado nas figuras 8 e 9, em que se analisou três ordens de escala de tamanho de representação (2,20 e 200). Na primeira, nós plotamos a distribuição de classes gramaticais em cada um de quatro agrupamentos (clusters), não revelando nenhum padrão de distribuição. Na segunda, representamos a distribuição de cada agrupamento para quatro classes gramaticais (substantivos (NOUN), verbos (VERB), adjetivos (ADJ) e advérbios (ADV)), também não revelando nenhum padrão.




Figura 8: Distribuição de classes gramaticais em agrupamentos do Word2Vec.

Modelo Atual

Construção de Estrutura Sintática através do Agrupamento Hierárquico

Pode-se dizer que os experimentos descritos acima foram cruciais para a construção da nossa hipótese final: **as arquiteturas simbólicas vetoriais** nos introduziram às representações simbólicas de palavras e suas combinações, propondo operações algébricas como intermediadores da transformação destas informações; o **Programa Minimalista** simplifica o problema, propondo que apenas uma operação de combinação é necessária para a combinação sintática destes elementos linguísticos; o **modelo de treinamento de vetores Word2Vec** nos possibilitou uma visão estatística do problema, através da perspectiva connexionista de redes neurais. Esta última, ainda, foi mais importante pois durante sua aplicação utilizamos algoritmos e agrupamento para a análise do modelo.

A hipótese do Agrupamento Hierárquico como mecanismo de formação de sentenças começa com a percepção de que, mecanisticamente, o algoritmo de agrupamento hierárquico se parece muito o que é proposto pela teoria linguística do programa minimalista: uma série de combinações de palavras acontece, aos pares, sendo que novas combinações podem ser combinadas também. Na prática, palavras e combinações são elementos sintáticos que ao se combinar geram outros elementos, construindo uma estrutura de árvore binária. O algoritmo justamente faz isso, cujo resultado é conhecido como dendrograma (Figure 10).

Enquanto na linguística não encontramos um mecanismo claro para a construção da estrutura sintática das sentenças, não havendo consenso entre as teorias de sintaxe (constituency versus dependency parsing), que frequentemente se apoiam em centenas de regras simbólicas (por exemplo, substantivos que se relacionam com adjetivos de determinada forma), o agrupamento hierárquico é agnóstico, combinando os dados de acordo com sua posição relativa. Dados são vetores numéricos, que podem ser imaginados




Figura 9: Distribuição de agrupamentos em quatro classes gramaticais.




Figura 10: Hipótese do agrupamento hierárquico como algoritmo de construir estruturas hierárquicas, na forma de árvores, para sentenças.

como pontos em um espaço hiperdimensional, sendo cada número do vetor a componente de uma dimensão. Os que serão agrupados são aqueles que estão mais próximos em uma dada iteração. A principal variação que existe dentro da técnica distingue algoritmos que começam com um único agrupamento e vão dividindo em menores (algoritmo divisivo) e aquele que começa com todos dados separados e vai agrupando uma a um (algoritmo aglomerativo). Diferentes métricas podem ser usadas para calcular a distância e agrupar vetores.

Desta perspectiva, o problema da sintaxe se torna em arranjar os vetores de palavra dentro de seu espaço de representação de forma que o algoritmo de agrupamento hierárquico consiga formar um dendrograma análogo à sua árvore sintática. Assim, para testar a hipótese de que uma rede neural poderia ser treinada para encontrar este arranjo espacial dos vetores de palavras, propomos um modelo

simples.

Rede Neural Perceptroniana

O primeiro modelo proposto pode ser visto na Figura 11A, enquanto sua visualização em termos de uma simples rede neural na Figura 11B. Consiste em um modelo de treinamento de vetores de palavra com o objetivo de maximizar a performance de um algoritmo de clusterização hierárquica em construir a árvore sintática correta de sentenças.




Figura 11: Caption

O treinamento do modelo consiste em aplicar a seguinte regra de atualização de pesos, ou de forma análoga, de atualização das componentes dos vetores de palavra

$$w_i(t+1) = w_i(t) + \eta \sum_j D_{ij} (w_i - w_j) \quad (1)$$

Em que $w_i(t+1)$ é o vetor que representa a palavra i no tempo $t+1$, $w_i(t)$ no tempo t , η a taxa de aprendizado, o termo somatório $\sum_j$ soma sobre todos os vetores de palavra da sentença, D_{ij} é a matriz de diferenças, que compara as distâncias entre palavras produzidas pelo algoritmo de agrupamento hierárquico com a distância verdadeira e $(w_i - w_j)$ é a diferença entre as representações (calculada elemento a elemento).

O vetor de representação w_i da palavra i é atualizado, adicionando-se um termo ponderado por uma taxa de aprendizado η , que representa a soma das diferenças entre as representações da palavra i (w_i) com as outras palavras (j , w_j), multiplicados pelo termo da matriz de diferenças D_{ij} que indica se a distância destas palavras na árvore prevista está correta ou não. O resultado deste processo é: aquelas palavras que foram colocadas mais próximas na árvore pelo algoritmo de agrupamento, deveriam estar mais longe e suas representações são afastadas. De forma análoga, aquelas palavras que foram postas mais distantes na árvore do que deveriam, são aproximadas pelo regra de aprendizado. Resultados para o treinamento do modelo utilizando três condições são mostradas na figura 12.

Observamos cinco resultados:

1. o modelo treina com sucesso a dada tarefa, mostrado pelas curvas de aprendizado característica do aprendizado de máquina, alcançando valores próximos de 0.9 de acurácia
2. modelos que usam informação posicional performam melhor, dada sua comparação nos gráficos do meio
3. mais dados pioram performance do modelo, mostrados pelos gráficos na direita, o que indica um processo de saturação em alocar os vetores de palavra no hiperespaço;
4. o modelo é pior conforme o número de palavras da sentença, mostrados pelas curvas de diferentes cores
5. poucas representações das palavras se modificam muito, enquanto a maioria delas se modifica pouco, mostrado pelos gráficos de baixo, em que as linhas são a similaridade de cada palavra com ela mesma e em vermelho estão palavras que se modificam muito




Figura 12: Caption

A partir deste ponto, desenvolvemos o modelo apresentado no corpo desta tese.