



UNIVERSIDADE FEDERAL DE PERNAMBUCO
CENTRO DE INFORMÁTICA
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

THIAGO VALENTIM BEZERRA

Título: Avaliação de desempenho e disponibilidade de sistemas da Internet das coisas
médicas: Uma abordagem baseada em modelagem estocástica

Recife

2026

THIAGO VALENTIM BEZERRA

Título: Avaliação de desempenho e disponibilidade de sistemas da Internet das coisas médicas: Uma abordagem baseada em modelagem estocástica

Trabalho apresentado ao Programa de Pós-graduação em Ciência da Computação do Centro de Informática da Universidade Federal de Pernambuco como requisito para obtenção do grau de Tese em Ciência da Computação.

Área de Concentração: Redes de Computadores e Sistemas Distribuídos

Orientador (a): Prof. Dr. Eduardo Antonio Guimarães Tavares.

Coorientador (a): Prof. Dr. Gustavo Rau de Almeida Callou.

Recife

2026

.Catalogação de Publicação na Fonte. UFPE - Biblioteca Central

Bezerra, Thiago Valentim.

Avaliação de desempenho e disponibilidade de sistemas da Internet das coisas médicas: Uma abordagem baseada em modelagem estocástica / Thiago Valentim Bezerra. - Recife, 2026.
163f.: il.

Tese (Doutorado) - Universidade Federal de Pernambuco, Centro de Informática, Programa de Pós-Graduação em Ciências da Computação, 2026.

Orientação: Eduardo Antonio Guimarães Tavares.

Coorientação: Gustavo Rau de Almeida Callou.

Inclui Referências.

1. Avaliação de Desempenho; 2. Hospitais Inteligentes; 3. Internet das Coisas Médicas; 4. Redes de Petri Estocásticas; 5. Disponibilidade. I. Tavares, Eduardo Antonio Guimarães. II. Callou, Gustavo Rau de Almeida. III. Título.

UFPE-Biblioteca Central

Thiago Valentim Bezerra

“Avaliação de desempenho e disponibilidade de sistemas da Internet das coisas médicas: Uma abordagem baseada em modelagem estocástica”

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Ciência da Computação da Universidade Federal de Pernambuco, como requisito parcial para a obtenção do título de Doutor em Ciência da Computação. Área de Concentração: Redes de Computadores e Sistemas Distribuídos

Aprovada em: 24/02/2026.

Orientador: Prof. Dr. Eduardo Antonio Guimarães Tavares

BANCA EXAMINADORA

Prof. Dr. Paulo Romero Martins Maciel
Centro de Informática / UFPE

Prof. Dr. Jamilson Ramalho Dantas
Centro de Informática / UFPE

Prof. Dr. Paulo Antonio Leal Rego
Departamento de Computação / UFC

Prof. Dr. Elias Procópio Duarte Júnior
Departamento de Informática / UFPR

Prof. Dr. Carlos Nuno Bizarro e Silva Laranjeiro
Centro de Informática e Sistemas / Universidade de Coimbra

A meus filhos Rafael, Emanuel e Pedro (in memoriam), à minha esposa, aos meus pais, ao meu irmão e aos meus amigos de toda a vida, com amor e gratidão.

AGRADECIMENTOS

Agradeço, antes de tudo, a Deus, pela vida, pela direção e pela força nos momentos em que pensei em parar. Sem Ele, eu nada seria.

À minha amada esposa, Milena Rodrigues, pela compreensão, pela paciência e por caminhar comigo em cada etapa desta jornada. Obrigado por me lembrar do propósito quando o cansaço apareceu e por transformar os dias difíceis em dias possíveis.

Aos meus filhos, Pedro (In Memoriam), Rafael e Emanuel. Vocês são a minha motivação diária. Penso em vocês todas as manhãs e encontro nisto o impulso para seguir, aprender e melhorar.

Aos meus pais, Damares e Eliézio, pelo esforço incansável, pelos conselhos e por todo o cuidado ao longo da vida, nessa tarefa tão nobre que é ser o alicerce de alguém. Obrigado por acreditarem em mim quando o caminho parecia distante.

Estendo meus agradecimentos aos meus familiares, em especial ao meu irmão, à minha sogra, ao meu sogro e ao meu cunhado e cunhada, que acompanharam esta trajetória, muitas vezes à distância, mantendo a confiança em mim e oferecendo incentivo até o fim.

Sou grato aos colegas que caminharam comigo no Doutorado, pelos aprendizados compartilhados e pelas conversas que viraram ideias. Em especial, aos amigos do MoDCS (UFPE), pelo apoio e companheirismo, e aos amigos do PedaLab (UFRPE), pela parceria, incentivo e ajuda prática nas horas certas. Deixo um agradecimento especial ao Cleunio e Alisson, pela amizade, pelas discussões técnicas que elevaram este trabalho e pela colaboração ao longo de toda a jornada.

Agradeço ao meu orientador, Prof. Dr. Eduardo Tavares, pela orientação e pelos incentivos constantes. Suas revisões criteriosas e seus direcionamentos, em diversas etapas, contribuíram diretamente para a melhoria, a qualidade e a maturidade deste trabalho.

Agradeço, de modo especial, ao Prof. Dr. Gustavo Callou, meu co-orientador, por estar sempre disponível, pelas palavras de incentivo e por acreditar no meu trabalho desde o início. Sou grato pela confiança e pelas oportunidades de crescimento que me ofereceu ao longo do mestrado e do doutorado. Deixo aqui minha admiração e gratidão.

Agradeço a todos que amo, e que me ajudaram nessa tão sonhada conquista.

A todos, minha eterna gratidão.

"Se enxerguei mais longe, foi por estar sobre os ombros de gigantes."

— **Isaac Newton**

RESUMO

Um aspecto da Internet das Coisas (IoT) é permitir que diferentes elementos de um ambiente sejam monitorados remotamente por meio de infraestruturas de rede existentes, promovendo uma integração relevante entre sistemas computacionais diversos. Essa integração geralmente resulta em uma coleta e processamento de dados. De fato, a adoção da IoT pode melhorar a comunicação na coleta e transmissão de dados, especialmente em locais que enfrentam desafios de conectividade. Por exemplo, hospitais têm adotado IoT para coletar e transmitir dados de pacientes para profissionais de saúde, pois pacientes críticos devem ser monitorados de forma ininterrupta. Por outro lado, os sistemas de saúde geralmente exigem alta disponibilidade, na qual a conectividade é um requisito crítico para decisões médicas. Nesses cenários, avaliar o desempenho é necessário para assegurar latências reduzidas, vazão compatível com a carga e ausência de perdas de dados, evitando atrasos em alarmes e nas decisões clínicas. Alguns trabalhos desenvolveram técnicas para avaliar a disponibilidade de sistemas de Internet das Coisas Médicas (IoMT), mas a avaliação conjunta de desempenho e disponibilidade geralmente é negligenciada. Este trabalho apresenta uma abordagem de modelagem baseada em redes de Petri estocásticas (SPN), diagramas de blocos de confiabilidade (RBD) e cadeias de Markov de tempo contínuo (CTMC) para avaliar sistemas IoMT. A técnica proposta avalia a disponibilidade, o tempo de resposta e a vazão em uma arquitetura IoMT. Os resultados experimentais mostram a viabilidade prática da abordagem proposta. Inicialmente, foi realizada a validação do sistema para disponibilidade e desempenho, assegurando a aderência entre modelos e medições. Em seguida, foram executados experimentos de disponibilidade e de performabilidade, bem como um estudo em CTMC para estimar a disponibilidade e o desempenho sob diferentes configurações. Depois, foram apresentados os Estudos de Caso I a IV, que abrangem a comparação de métricas em modelos estendidos, variações de capacidade de processamento na nuvem privada, análise de um hospital com cinco andares, com ampliação proporcional de sensores, switches e VMs em cada piso para verificar se a arquitetura absorve o aumento de carga mantendo alta disponibilidade, e análise fatorial dos principais componentes do sistema. Na etapa posterior, foi aplicado o Estudo de Caso V, que utiliza a métrica de Importância de Disponibilidade para priorizar componentes e propor arquiteturas redundantes. Por fim, foi conduzido o Estudo de Caso VI, no qual se avaliaram os custos das arquiteturas nas camadas IoT e nuvem privada, quantificando custos de aquisição, operação e manutenção para subsidiar decisões técnico-financeiras.

Palavras-chaves: Avaliação de Desempenho. Hospitais Inteligentes. Internet das Coisas Médicas. Redes de *Petri* Estocásticas. Internet das Coisas. Desempenho. Disponibilidade.

ABSTRACT

One of the aspects the Internet of Things (IoT) is that it enables different elements of an environment to be remotely monitored through existing network infrastructures, promoting meaningful integration among diverse computing systems. This integration generally results in data collection and processing. In fact, the adoption of IoT can improve communication for data collection and transmission, especially in places that face connectivity challenges. For example, hospitals have adopted IoT to collect and transmit patient data to healthcare professionals, since critical patients must be monitored continuously. On the other hand, healthcare systems generally require high availability, in which connectivity is a critical requirement for medical decisions. In these scenarios, evaluating performance is necessary to ensure low latency, throughput compatible with the workload, and the absence of data loss, thereby avoiding delays in alarms and clinical decisions. Some previous works have developed techniques to evaluate the availability of Internet of Medical Things (IoMT) systems, but the joint assessment of performance and availability is often neglected. This work presents a modeling approach based on Stochastic Petri Nets (SPN), Reliability Block Diagrams (RBD), and Continuous-Time Markov Chains (CTMC) to evaluate IoMT systems. The proposed technique evaluates availability, response time, and throughput in an IoMT architecture. The experimental results show the practical feasibility of the proposed approach. Initially, the system was validated for availability and performance, ensuring adherence between models and measurements. Next, availability and performability experiments were carried out, as well as a CTMC study to estimate availability and performance under different configurations. Then, Case Studies I to IV are presented, covering metric comparisons in extended models, variations in processing capacity in the private cloud, analysis of a five-floor hospital with proportional expansion of sensors, switches, and VMs on each floor to verify whether the architecture absorbs the increased load while maintaining high availability, and a factorial analysis of the system's main components. In the subsequent stage, Case Study V applied the Availability Importance metric to prioritize components and propose redundant architectures. Finally, Case Study VI evaluated the cost of the architectures across the IoT and private cloud layers, quantifying acquisition, operation, and maintenance costs to support technical-financial decisions.

Keywords: Performance Evaluation. Smart Hospitals. Internet of Medical Things. Stochastic Petri Nets. Internet of Things. Performance. Availability.

LISTA DE FIGURAS

Figura 1 – Arquitetura Básica IoT	30
Figura 2 – Diagrama de Blocos de Confiabilidade em série com 3 componentes.	42
Figura 3 – Exemplo de uma CTMC	44
Figura 4 – Elementos da Rede de Petri	46
Figura 5 – Exemplo do funcionamento de um interruptor modelado em rede de Petri.	47
Figura 6 – Elemento adicional às SPNs que estendem o comportamento das PN.	50
Figura 7 – Semânticas de disparo	51
Figura 8 – SPN representando um único processador em um sistema com memória compartilhada.	52
Figura 9 – Diagrama de blocos de confiabilidade de um sistema em série.	54
Figura 10 – Diagrama de blocos de confiabilidade de um sistema em paralelo.	55
Figura 11 – Exemplo de RBD para um sistema 2-out-of-3.	56
Figura 12 – Diagrama de blocos de confiabilidade de um sistema em ponte.	57
Figura 13 – Diagrama equivalente (em termos de pontos de falha) para o sistema em ponte.	57
Figura 14 – Exemplo de RBD com combinações série e paralelo.	59
Figura 15 – Diagrama de blocos de confiabilidade com redundância de baixo nível.	59
Figura 16 – Diagrama de blocos de confiabilidade com redundância de alto nível.	60
Figura 17 – Metodologia	77
Figura 18 – Arquitetura Básica IoMT.	86
Figura 19 – Modelo RBD da arquitetura IoMT.	88
Figura 20 – Modelo RBD: Camada de Nuvem Privada.	89
Figura 21 – Modelo de Performabilidade.	89
Figura 22 – Modelo SPN integrado de disponibilidade e desempenho.	91
Figura 23 – Arquitetura básica sem redundância.	93
Figura 24 – Modelo CTMC sem redundância.	93
Figura 25 – Modelo sem redundância.	94
Figura 26 – Configuração <i>Cold-standby</i>	95
Figura 27 – Modelo CTMC: redundância em <i>Cold-standby</i>	96
Figura 28 – Modelo <i>Cold standby</i>	97

Figura 29 – Configuração <i>Hot-Standby</i>	98
Figura 30 – Modelo CTMC: redundância em <i>Hot-Standby</i>	98
Figura 31 – Modelo <i>hot standby</i>	100
Figura 32 – Arquitetura Estendida I	101
Figura 33 – Modelo Estendido I	101
Figura 34 – Arquitetura Estendida II	102
Figura 35 – Modelo Estendido II	102
Figura 36 – Arquitetura Estendida III	104
Figura 37 – Modelo Estendido III	105
Figura 38 – Arquitetura Estendida IV	106
Figura 39 – Modelo Estendido IV	106
Figura 40 – Arquitetura Estendida V	107
Figura 41 – Monitoramento de pacientes em um hospital de vários andares usando mo- delo V.	108
Figura 42 – Modelo Estendido V.	109
Figura 43 – Sistema de Avaliação	117
Figura 44 – Redundância de arquiteturas IoMT	125
Figura 45 – Arquitetura 01	133
Figura 46 – Arquitetura 02	133
Figura 47 – Arquitetura 03	134
Figura 48 – Arquitetura 04	135
Figura 49 – Custo total vs. disponibilidade por arquitetura	139

LISTA DE TABELAS

Tabela 1 – Resumo dos protocolos IoMT	35
Tabela 2 – Número de nove equivalentes para disponibilidade	40
Tabela 3 – Importância da Disponibilidade (Figura 2).	42
Tabela 4 – Comparação de confiabilidade entre redundâncias de baixo e alto nível. . .	61
Tabela 5 – Exemplo de fatores e seus respectivos níveis para um experimento de dois fatores.	62
Tabela 6 – Comparação entre este trabalho e trabalhos relacionados (Parte 1 de 2) . .	73
Tabela 7 – Comparação entre este trabalho e trabalhos relacionados (Parte 2 de 2) . .	74
Tabela 8 – Componentes do modelo SPN	110
Tabela 9 – Expressões de guarda	111
Tabela 10 – Fatores e Níveis	120
Tabela 11 – MTTF e MTTR dos componentes do modelo	121
Tabela 12 – Tratamentos e Resultados - Dependabilidade	121
Tabela 13 – Classificação dos efeitos - Confiabilidade	122
Tabela 14 – Fatores e Níveis	122
Tabela 15 – Tratamentos e Resultados - Disponibilidade e Tempo de Resposta. . . .	123
Tabela 16 – Classificação dos efeitos - Confiabilidade e Disponibilidade.	124
Tabela 17 – Redundância de arquiteturas IoMT	124
Tabela 18 – Valores de Disponibilidade, Downtime e Tempo de resposta	127
Tabela 19 – Valores de Tempo de resposta e Vazão	128
Tabela 20 – Disponibilidade (A), tempo de resposta (RT) e vazão na arquitetura sem redundância.	129
Tabela 21 – Disponibilidade (A), tempo de resposta (RT) e vazão na arquitetura com redundância.	129
Tabela 22 – Tratamentos e resultados	130
Tabela 23 – <i>Rank</i> de efeitos	131
Tabela 24 – Resultados de importância de disponibilidade - Rodada I	132
Tabela 25 – Resultados de importância de disponibilidade - Rodada II	133
Tabela 26 – Resultados de importância de disponibilidade - Rodada III	134
Tabela 27 – Resultados de importância de disponibilidade - Rodada IV	134

Tabela 28 – Resultado da disponibilidade das arquiteturas avaliadas.	135
Tabela 29 – Parâmetros de custo	136
Tabela 30 – Custo IoT	137
Tabela 31 – Custo Nuvem	137
Tabela 32 – Custo total	138

LISTA DE ABREVIATURAS E SIGLAS

AMQP *Advanced Message Queuing Protocol*

API Interfaces de Programação de Aplicações

CapEx despesas de capital

CBM manutenção baseada em condição

CoAP *Constrained Application Protocol*

COCOMO *Constructive Cost Model*

CPN Rede de Petri Colorida

CPU Unidade Central de Processamento

CTMC Cadeia de Markov de Tempo Contínuo

DoE *Design of Experiment*

DTMC *Discrete Time Markov Chain*

ECG Eletrocardiograma

ESM *Efficient Scanning Mechanism*

FHIR *Fast Healthcare Interoperability Resources*

GCM monitoramento contínuo de glicose

HL7 *Health Level Seven*

HTTP *Hypertext Transfer Protocol*

i/o Entrada/Saída

ID Importância da Disponibilidade

IDC Importância de Disponibilidade e Custo

IoHT Internet das Coisas na Saúde

IoMT Internet das Coisas Médicas

IoT Internet das Coisas

IPv6 *Internet Protocol version 6*

ISM *Industrial, Scientific, and Medical*

LBRT *Load Balancing scheme for Real-Time monitoring data*

LoRaWAN *Long Range Wide Area Network*

MQTT *Message Queuing Telemetry Transport*

MTA tempo médio de ativação

MTTF tempo médio entre falhas

MTTR tempo médio para reparo

NFC *Near Field Communication*

NS3 Network Simulator 3

OpEx despesas operacionais

PERT *Program Evaluation and Review Technique*

PN Redes de Petri

RAM *Random Access Memory*

RBD Diagrama de Blocos de Confiabilidade

REST *Representational State Transfer*

RFID *Radio-Frequency Identification*

ROI retorno sobre o investimento

RUL estima a vida útil remanescente

SDK *Software Development Kit*

sEMG Eletromiografia de Superfície

SLA Acordo de Nível de Serviço

SPN Rede de Petri Estocástica

TI tecnologia da informação

UDP *User Datagram Protocol*

VM Máquina Virtual

LISTA DE SÍMBOLOS

α	Alfa
β	Beta
θ	Teta
λ	Lambda
μ	Mi
η	Eta
ρ	Rho
π	Pi
Σ	Somatório
$\int$	Integral
∂	Derivada parcial
$\subseteq$	Inclusão
$\in$	Pertence
$\cup$	União de conjuntos
$\cap$	Interseção de conjuntos
$\emptyset$	Conjunto vazio
$\mathbb{N}$	Conjunto dos números naturais

SUMÁRIO

1	INTRODUÇÃO	22
1.1	CONTEXTUALIZAÇÃO	22
1.2	MOTIVAÇÃO	24
1.3	OBJETIVOS	26
1.4	ESTRUTURA DA PROPOSTA DE TESE	28
2	REFERENCIAL TEÓRICO	30
2.1	INTERNET DAS COISAS	30
2.2	INTERNET DAS COISAS MÉDICAS	31
2.2.1	Dispositivos e Interoperabilidade em IoMT	32
2.2.1.1	<i>Sensores e dispositivos</i>	32
2.2.1.2	<i>Middlewares e interoperabilidade</i>	33
2.2.2	Análise Comparativa dos Protocolos de Comunicação IoT em Aplicações de Saúde	34
2.3	AVALIAÇÃO DE DESEMPENHO	37
2.4	AVALIAÇÃO DE DISPONIBILIDADE E CONFIABILIDADE	38
2.4.1	Importância da Disponibilidade	41
2.5	CADEIAS DE MARKOV DE TEMPO CONTÍNUO	42
2.6	REDES DE <i>PETRI</i>	45
2.6.1	Aplicações de redes de <i>Petri</i>	48
2.6.2	Redes de <i>Petri</i> estocásticas	49
2.7	DIAGRAMAS DE BLOCOS DE CONFIABILIDADE	52
2.7.1	Propriedades de Estrutura	53
2.7.2	Funções de Confiabilidade	57
2.7.3	Níveis de redundância	58
2.8	ANÁLISE DE SENSIBILIDADE	61
2.9	CONSIDERAÇÕES FINAIS	63
3	TRABALHOS RELACIONADOS	64
3.1	VISÃO GERAL	64
3.2	DISPONIBILIDADE	64
3.3	<i>DESEMPENHO</i>	66

3.4	CUSTO	69
3.5	COMPARAÇÃO DOS TRABALHOS RELACIONADOS	70
3.6	CONSIDERAÇÕES FINAIS	75
4	METODOLOGIA	76
4.1	CONCEPÇÃO INICIAL	78
4.1.1	Entendimento do sistema	78
4.1.2	Definição das métricas de interesse	78
4.2	CONFIGURAÇÃO DO SISTEMA	79
4.2.1	Configuração experimental do sistema	79
4.2.2	Coleta de dados	80
4.3	MODELAGEM	80
4.3.1	Criação do modelo	80
4.3.2	Validação do modelo	81
4.4	EXPERIMENTAÇÃO - DESIGN OF EXPERIMENT	81
4.4.1	Planejamento de experimentos	81
4.4.2	Execução dos experimentos	82
4.4.3	Criação da classificação de fatores e interações	82
4.5	ANÁLISE DOS RESULTADOS	82
4.5.1	Avaliação dos resultados	82
4.5.2	Apresentação dos resultados	83
4.6	REFINAMENTO DO MODELO	83
4.6.1	Ajustes e proposição de novas arquiteturas	83
4.7	CONSIDERAÇÕES FINAIS	83
5	MODELOS PROPOSTOS	85
5.1	CONSIDERAÇÕES INICIAIS	85
5.2	MODELO DE DISPONIBILIDADE	88
5.3	MODELO DE PERFORMABILIDADE	89
5.4	DISPONIBILIDADE E DESEMPENHO EM MODELOS SPN	90
5.4.1	Modelo CTMC para a quantificação de disponibilidade	92
5.4.2	Modelo CTMC para um sistema sem redundância	92
5.4.3	Modelo CTMC para um sistema com redundância <i>cold standby</i>	95
5.4.4	Modelo CTMC para um sistema com redundância <i>hot standby</i>	98
5.5	MODELO DE PERFORMABILIDADE ESTENDIDO	100

5.5.1	Modelo Estendido I	101
5.5.2	Modelo Estendido II	102
5.5.3	Modelo Estendido III	103
5.5.4	Modelo Estendido IV	105
5.5.5	Modelo Estendido V	106
5.6	ESTIMATIVA DE CUSTO PARA SISTEMAS IOMT	111
5.6.1	Custo IoT	112
5.6.2	Custo da Nuvem	113
5.7	CONSIDERAÇÕES FINAIS	114
6	RESULTADOS EXPERIMENTAIS	116
6.1	CONFIGURAÇÃO DO SISTEMA	117
6.2	VALIDAÇÃO	117
6.2.1	Validação: disponibilidade	117
6.2.2	Validação: desempenho	119
6.3	EXPERIMENTOS	120
6.3.1	<i>Disponibilidade</i>	120
6.3.2	Performabilidade	121
6.4	MODELOS CTMC	124
6.5	PERFORMABILIDADE: MODELOS ESTENDIDOS	126
6.5.1	Estudo de caso I	126
6.5.2	Estudo de caso II	127
6.5.3	Estudo de caso III: Modelo V em escala	128
6.5.4	Estudo de caso IV: Modelo V em escala	130
6.6	ESTUDO DE CASO V	131
6.7	ESTUDO DE CASO VI	135
6.8	CONSIDERAÇÕES FINAIS	139
7	CONCLUSÃO	141
7.1	CONTRIBUIÇÕES	142
7.2	PUBLICAÇÕES	144
7.2.1	Periódicos	144
7.2.2	Periódicos Cooperação	145
7.2.3	Conferências	145
7.2.4	Conferências Cooperação	145

7.2.5	Capítulo de livro	146
7.2.6	Projetos aprovados em órgãos de fomento	147
7.3	LIMITAÇÕES	147
7.4	TRABALHOS FUTUROS	148
	REFERÊNCIAS	150

1 INTRODUÇÃO

Este capítulo inicia com a contextualização do problema em que este trabalho está inserido, conforme mostrado na Seção 1.1. Em seguida, discute-se a motivação para o estudo de sistemas da Internet das Coisas Médicas, conforme apresentado na Seção 1.2. A Seção 1.3 expõe os objetivos geral e específicos deste trabalho. Por fim, a Seção 1.4 apresenta a estrutura da proposta de tese.

1.1 CONTEXTUALIZAÇÃO

A Internet das Coisas (IoT) tem impulsionado avanços em múltiplos domínios, como previsão do tempo, aeronaves remotamente pilotadas, gestão de resíduos, agricultura e hospitais inteligentes, entre diversas outras aplicações relevantes (SORRI; MUSTAFEE; SEPPÄNEN, 2022; PAWAR; BOURGEAU; CHAOUCHI, 2021). O interesse crescente tem se refletido em investimentos substanciais: estimativas apontam que o mercado de IoT alcançará US\$ 771 bilhões em 2026 e, até 2030, poderá haver centenas de bilhões de objetos conectados à Internet (CISCO; INTERNET, 2020). No setor de saúde, esse movimento é ainda mais pronunciado. O investimento global em soluções médicas baseadas em IoT foi de US\$ 217,34 bilhões em 2022, com projeção de chegar a aproximadamente US\$ 960,2 bilhões em 2030 (Precedence Research, 2022).

Nesse contexto, consolidou-se o termo Internet das Coisas Médicas (IoMT) para designar o ecossistema de sensores, dispositivos e aplicações voltados ao monitoramento e ao apoio à decisão clínica. Trata-se de um domínio sensível, pois falhas operacionais podem impactar diretamente a vida do paciente. Por isso, há um esforço contínuo de pesquisa para ampliar os níveis de disponibilidade em IoMT (TANG; XIE, 2021), bem como para garantir o compartilhamento de dados em tempo real com proteção à confidencialidade, o que frequentemente motiva o uso de nuvens privadas.

Em ambientes hospitalares, a integração entre camadas de borda, agregadores locais e nuvem privada precisa lidar com picos de tráfego decorrentes de eventos clínicos e com enlaces sem fio sujeitos a perdas e variações de atraso. Nessas condições, decisões sobre onde processar os dados, como configurar filas e quais mecanismos de redundância adotar têm impacto direto na continuidade do serviço. Antecipar esses efeitos por meio de modelagem estocástica permite comparar alternativas de arquitetura, quantificar ganhos de disponibilidade e estimar o efeito

de políticas de escalonamento sobre a latência fim a fim, reduzindo retrabalho posterior e facilitando a adesão a requisitos clínicos e regulatórios.

A disponibilidade, isoladamente, não descreve o comportamento de interesse em IoMT. Um sistema pode continuar “funcionando”, mas entregar utilidade limitada quando o desempenho se degrada por motivos como contenção de Unidade Central de Processamento (CPU), memória ou Entrada/Saída (i/o) em microcontroladores, Máquina Virtual (VM); filas crescentes em *brokers*; latência, *jitter*, perda de pacotes em enlaces sem fio; retransmissões, *timeouts* por interferência ou distância. Esses fatores elevam os tempos de resposta, reduzem a vazão, aumentam a latência e atrasam alarmes e decisões clínicas.

Por essa razão, a avaliação integrada de disponibilidade e desempenho, denominada performabilidade, oferece um retrato mais fiel do sistema. Com o apoio de modelos estocásticos, essa abordagem permite estudar requisitos não funcionais sob diferentes configurações antes da implementação (MACIEL, 2023). Embora trabalhos relevantes tratem da disponibilidade ou desempenho em IoMT (WAI; AUNG; HTAY, 2019; POKORNI, 2019; RUMAN et al., 2020; ATHIRA et al., 2020), a análise conjunta permanece menos explorada. Esse quadro torna especialmente relevante antecipar, por meio de modelagem, como variações de carga e decisões de capacidade afetam simultaneamente a latência, a taxa de processamento e a continuidade do serviço, evitando ajustes custosos após a implantação (MACIEL, 2023).

No que se refere à relação entre desempenho e disponibilidade em IoMT, as exigências de processamento variam conforme a aplicação e o volume de dados gerados. A heterogeneidade de capacidades, dos sensores à borda até o núcleo da rede, demanda estudos que orientem a escolha de arquiteturas adequadas. Isso inclui requisitos de conectividade, latência e provisão de recursos de computação, de modo a sustentar a carga prevista sem comprometer os níveis de serviço nem reduzir a disponibilidade.

Além disso, como mencionado, cenários típicos de monitoramento apresentam tráfego intermitente e picos associados a eventos clínicos, além de enlaces sem fio sujeitos a perda e variação de atraso; tais fatores reforçam a necessidade de estratégias de redundância, dimensionamento e priorização que sejam avaliadas com base em métricas integradas de performabilidade. Diante desse cenário, é pertinente investigar como configurações alternativas influenciam a disponibilidade e o desempenho em IoMT. Tais investigações oferecem subsídios para projetar sistemas mais confiáveis e eficientes, além de fundamentar decisões de engenharia e gestão de capacidade em ambientes críticos.

Assim, adotar uma visão integrada que combine desempenho e disponibilidade em IoMT

não é apenas conveniente, mas necessário para sustentar níveis de serviço clínico em cenários reais. Essa perspectiva apoia o planejamento de capacidade, a escolha de estratégias de redundância e a priorização de investimentos, articulando requisitos de latência, taxa de processamento e disponibilidade sob diferentes perfis de carga e configurações de infraestrutura. Com isso, projetistas e gestores podem alinhar as decisões técnicas aos objetivos do atendimento em saúde, favorecendo um monitoramento mais eficiente dos pacientes e a melhoria da eficiência operacional.

Após a avaliação da disponibilidade e do desempenho, torna-se necessário considerar uma análise de custos detalhada para compreender as demandas financeiras envolvidas na implantação e na operação de sistemas IoMT. Essa análise é relevante, pois elevar a disponibilidade costuma implicar a incorporação de recursos adicionais e redundâncias, o que impacta diretamente o planejamento financeiro. A estimativa considera toda a arquitetura, desde os sensores até a aplicação em nuvem privada, contemplando a aquisição de dispositivos, a instalação, a integração, a conectividade, a substituição dos componentes e o suporte ao longo do ciclo de vida. Essa quantificação permite comparar alternativas de arquitetura, projetar despesas recorrentes e definir prioridades de investimento, reduzindo o risco de subdimensionamento ou sobredimensionamento. A avaliação abrange custos de aquisição, manutenção e operação.

À medida que mais dispositivos e mecanismos de redundância são integrados ao sistema IoMT, a disponibilidade tende a aumentar; entretanto, isso também produz um crescimento proporcional dos custos operacionais. Assim, buscar um equilíbrio entre a resiliência do sistema e a viabilidade financeira torna-se um objetivo central. Essa abordagem oferece subsídios técnicos e econômicos para o planejamento estratégico e para a adoção de soluções IoMT no contexto da saúde digital.

1.2 MOTIVAÇÃO

A IoMT tem se consolidado como área estratégica na saúde. Diante da rápida evolução tecnológica e do envelhecimento populacional, esses sistemas podem transformar a prestação de cuidados, oferecendo respostas a desafios recorrentes dos serviços de saúde em escala global. Em ambientes hospitalares, o gerenciamento de dispositivos médicos, associado a práticas destinadas a melhorar a qualidade do atendimento ao paciente e a continuidade operacional, tornou-se uma preocupação permanente (DWIVEDI; MEHROTRA; CHANDRA, 2022).

Os sistemas IoMT favorecem ganhos de eficiência e de qualidade, ao viabilizarem a co-

leta contínua, em tempo real, de dados clínicos, permitindo o monitoramento direcionado pelas equipes, o que facilita diagnósticos mais ágeis e precisos, intervenções preventivas e o acompanhamento mais efetivo das terapias (KELLY et al., 2020).

Esses sistemas também impulsionam abordagens de medicina personalizada e saúde preventiva. A coleta de dados granulares sobre o estado clínico e o comportamento possibilita personalizar condutas conforme as necessidades individuais, o que tende a aumentar a efetividade do cuidado. Além disso, a detecção precoce de alterações e a identificação de fatores de risco contribuem para prevenir condições graves e melhorar os indicadores populacionais (JAGADEESWARI et al., 2018).

Para que esse potencial se realize, é indispensável avaliar as propriedades de operação em IoMT, com ênfase no desempenho e na dependabilidade. Essa avaliação considera, de forma coordenada, a disponibilidade, a confiabilidade, a latência, a vazão, a escalabilidade, a resiliência a falhas e a interoperabilidade, de modo a atender às demandas crescentes dos serviços de saúde e, ao mesmo tempo, preservar a privacidade de dados sensíveis (SUBRAMANIAM et al., 2023).

Em contextos hospitalares, a proteção de dados sensíveis e a previsibilidade operacional favorecem arquiteturas com nuvem privada, em que rotas de tráfego, políticas de acesso e janelas de manutenção podem ser controladas com maior granularidade. Esse arranjo facilita o cumprimento de requisitos de latência e reduz a exposição a variabilidades de enlaces externos, o que impacta diretamente a continuidade do monitoramento e a qualidade assistencial ao paciente (TANG; XIE, 2021). Nessa perspectiva, torna-se central quantificar os equilíbrios entre latência, taxa de processamento e disponibilidade ao decidir onde processar dados, como configurar redundância e como distribuir a capacidade entre borda, *gateways* e a camada de nuvem.

A avaliação de desempenho e de disponibilidade em IoMT é particularmente relevante para sustentar níveis de serviço clínico. A escolha de mecanismos de redundância, a estimativa do número de componentes e o acompanhamento contínuo dos níveis de confiabilidade do sistema figuram entre as medidas que mitigam impactos negativos na assistência (RAHIMI; NOR, 2023; YONG et al., 2023).

Além disso, a tomada de decisão em IoMT se beneficia de avaliações integradas que relacionem o desempenho e a disponibilidade, evitando análises isoladas que superdimensionem recursos ou subestimem riscos. Técnicas de modelagem estocástica permitem antecipar os efeitos das variações de carga, falhas e políticas de recuperação, oferecendo estimativas para

planejamento de capacidade, definição de metas de serviço e priorização de investimentos (MACIEL, 2023). Ao combinar métricas de desempenho com medidas de dependabilidade e incorporar estudos de sensibilidade, é possível identificar componentes de maior impacto e orientar intervenções que mantenham níveis de serviço clínico estáveis, mesmo sob condições operacionais adversas (RAHIMI; NOR, 2023; YONG et al., 2023).

Técnicas de modelagem, como redes de Petri estocásticas e diagramas de bloco de confiabilidade, oferecem representações formais para estudar o desempenho e as propriedades de dependabilidade de sistemas IoMT. Esses formalismos apoiam o planejamento, a implementação e a operação, pois permitem explorar cenários, comparar arquiteturas alternativas e embasar decisões de engenharia com base em evidências. Ao empregar tais técnicas, obtém-se uma visão integrada do sistema, o que favorece a gestão de recursos e a manutenção de níveis de serviço adequados para os pacientes e profissionais de saúde.

Além dos requisitos técnicos, a adoção de soluções IoMT depende de um planejamento financeiro claro, com distinção entre despesas de capital e despesas operacionais. No nível de capital, incluem-se a aquisição de sensores, microcontroladores, fontes de alimentação, elementos de rede e servidores da nuvem privada. No nível operacional, incluem-se conectividade, substituição de itens com fim de vida útil, suporte técnico e custos associados a contratos de nível de serviço. Considerar o custo total de propriedade ao longo do ciclo de vida evita superdimensionamentos e permite escalar a infraestrutura de modo incremental, priorizando os pontos de maior criticidade clínica.

Ao explorar cenários com diferentes políticas de redundância, distribuição de carga entre borda e nuvem privada e metas de Acordo de Nível de Serviço (SLA), busca-se um equilíbrio entre resiliência do sistema e a viabilidade orçamentária. Essa perspectiva orienta decisões como a quantidade de réplicas, escolha entre escalabilidade horizontal ou vertical e definição de janelas de manutenção, permitindo que os hospitais planejem investimentos com previsibilidade e sustentem níveis de serviço clínico dentro de limites financeiros realistas.

1.3 OBJETIVOS

Os sistemas IoMT estão transformando a saúde e outros setores ao integrar dispositivos inteligentes e conectados em ambientes complexos, muitas vezes apoiados por nuvens privadas para atender aos requisitos de confidencialidade e governança de dados. Com a expansão dessa adoção, organizações de saúde e empresas enfrentam o desafio de selecionar e geren-

ciar soluções tecnológicas que atendam a necessidades específicas. Esses sistemas envolvem uma ampla gama de dispositivos e sensores, com capacidades distintas e diferentes níveis de desempenho e disponibilidade.

Neste contexto, o principal objetivo deste trabalho é conceber modelos analíticos para estimar, de forma integrada e simultânea, métricas de desempenho e de disponibilidade em sistemas IoMT. Esses modelos permitirão quantificar as métricas de interesse, com foco em apoiar a escolha de configurações adequadas aos requisitos e às demandas desses sistemas. A abordagem proposta adota modelagens como: Rede de Petri Estocástica (SPN), Diagrama de Blocos de Confiabilidade (RBD) e Cadeia de Markov de Tempo Contínuo (CTMC), para avaliar o desempenho e a disponibilidade de sistemas IoMT com suporte de nuvem privada, fornecendo estimativas das métricas de interesse sob diferentes alternativas de arquitetura e parâmetros operacionais, além de uma avaliação de custo. De forma mais específica, os objetivos consistem em:

- Desenvolver cenários IoMT, considerando diferentes tecnologias, para coletar dados de referência sobre métricas de desempenho (tempo de resposta, vazão) e de dependabilidade (disponibilidade, confiabilidade).
- Propor modelos de desempenho e disponibilidade, empregando SPN para estimativas de desempenho e RBD para avaliação de disponibilidade, alinhando hipóteses e parâmetros às características do sistema em estudo. Além da avaliação de disponibilidade utilizando CTMC.
- Dimensionar e comparar níveis de redundância e alternativas de arquitetura em IoMT, quantificando seus efeitos sobre as métricas integradas de desempenho e dependabilidade.
- Validar os modelos propostos, confrontando os resultados com dados experimentais obtidos no sistema IoMT configurado ou em um ambiente de teste equivalente, e documentando discrepâncias e limitações.
- Realizar uma análise de sensibilidade, com *Design of Experiment* (DoE), para identificar os fatores de maior impacto nas métricas de desempenho e dependabilidade e propor uma avaliação de custo para sistemas IoMT, com o objetivo de subsidiar decisões técnico-financeiras sobre capacidade, redundância e alocação de recursos nas camadas IoT e nuvem privada, estimando despesas de aquisição e operação.

- Propor melhorias na arquitetura e na configuração para elevar o desempenho e a disponibilidade do sistema estudado, fundamentadas nas evidências obtidas.

Vale destacar que os modelos em RBD permitem avaliar a disponibilidade da infraestrutura, assumindo a independência entre os componentes e a estrutura estática do sistema. Quando há dependências operacionais ou comportamentos dinâmicos, como a ativação de equipamentos em espera ou o compartilhamento de carga, aplica-se SPN. Na redundância em *standby*, um componente permanece em *standby* e é comutado para ativo quando o principal falha, alterando o regime efetivo de falhas e reparos do conjunto.

No compartilhamento de carga, múltiplos componentes operam simultaneamente, dividindo o trabalho, o que modifica taxas de serviço, formação de filas e políticas de balanceamento de carga. As SPN representam esses mecanismos por meio de lugares e transições temporizadas, permitindo incluir comutação (*switch-over*), prioridades, tempos de reparo e eventuais degradações de desempenho. Dessa forma, avalia-se de modo integrado a disponibilidade, o tempo de resposta e a vazão sob tais interdependências.

Nesses casos, os modelos em SPN também permitem estimar métricas de desempenho, como tempo de resposta e vazão, incorporando falhas e reparos nos componentes da arquitetura. Para aumentar a confiabilidade das estimativas, os modelos serão validados por meio de métodos estatísticos, verificando-se a aderência entre os resultados do modelo e os dados observados no sistema real. Por fim, considera-se, nos modelos SPN, o efeito da introdução de redundâncias na capacidade de processamento, na disponibilidade e no tempo de resposta.

1.4 ESTRUTURA DA PROPOSTA DE TESE

Este capítulo inicial apresenta a contextualização do tema, aprofunda as motivações que orientam a investigação e define o objetivo geral e os objetivos específicos a serem alcançados com a abordagem proposta.

O Capítulo 2 apresenta o referencial teórico necessário à compreensão do trabalho. O texto introduz os conceitos de IoT e, em seguida, de IoMT. Na sequência, apresenta as métricas adotadas para a avaliação, com ênfase em desempenho e dependabilidade. O capítulo também apresenta os formalismos matemáticos utilizados, como SPN, RBD e CTMC, além dos elementos essenciais de análise de sensibilidade.

O Capítulo 3 apresenta os estudos relacionados, destaca soluções propostas na literatura e

identifica as principais lacunas. A organização privilegia trabalhos focados em disponibilidade, desempenho e custo, com atenção especial a aplicações específicas de IoMT.

O Capítulo 4 detalha a metodologia adotada, composta pelas etapas de definição do problema, concepção dos modelos analíticos, validação e planejamento dos experimentos. O capítulo apresenta a estratégia de avaliação empregada para o planejamento experimental e descreve os métodos e técnicas estatísticas utilizados na análise dos resultados.

O Capítulo 5 apresenta os modelos propostos. Inicialmente, o texto traz considerações e conceitos necessários à compreensão das métricas de desempenho e disponibilidade em sistemas ciberfísicos de IoMT. Em seguida, define o propósito de cada modelo e detalha suas estruturas e pressupostos, com vistas à correta aplicação.

O Capítulo 6 reúne os resultados obtidos. Primeiramente, apresenta a validação dos modelos analíticos concebidos. Na sequência, apresenta os experimentos realizados, construídos com base em parâmetros e cenários da literatura, abrangendo análises de desempenho, disponibilidade e custo.

2 REFERENCIAL TEÓRICO

Este capítulo introduz os conceitos básicos necessários à compreensão do trabalho proposto. A Seção 2.1 introduz à sistemas IoT, e a Seção 2.2 apresenta conceitos sobre IoMT. Posteriormente, são discutidos os conceitos de desempenho e de dependabilidade (Seções 2.3 e 2.4). A Seção 2.5 apresenta a definição de Cadeias de Markov. Em seguida, a Seção 2.6 apresenta Redes de Petri (PN). A Seção 2.7 descreve o formalismo RBD. Finalmente, a Seção 2.8 apresenta os conceitos de análise de sensibilidade.

2.1 INTERNET DAS COISAS

A IoT refere-se à conexão de objetos físicos, sensores, dispositivos e sistemas conectados à internet, permitindo a troca de dados e a comunicação entre diferentes elementos de um ambiente. A IoT consiste na integração entre componentes físicos e computacionais capazes de coletar, transmitir, processar e monitorar informações. Nesse contexto, a IoT possibilita o monitoramento remoto de ambientes por meio de infraestruturas de rede existentes, promovendo a integração entre sistemas computacionais distintos e favorecendo a coleta, o acompanhamento e o processamento eficiente dos dados (ISLAM et al., 2022).




Figura 1 – Arquitetura Básica IoT

Uma arquitetura básica de IoT (JARA; ZAMORA; SKARMETA, 2009) é dividida em quatro camadas (Figura 1): dispositivos, comunicação, processamento e apresentação. Os dispositivos realizam a coleta de dados e contemplam, por exemplo, sensores e microcontroladores. A camada de comunicação realiza a transferência de dados usando protocolos padrão, para posterior processamento (RAHMANI et al., 2018). A camada de processamento manipula os dados para executar os serviços do sistema, e a camada de apresentação fornece mecanismos

para a interação do usuário final.

Além disso, a IoT desempenha um papel fundamental em diversas aplicações, abrangendo desde o monitoramento ambiental e o gerenciamento de recursos naturais até a automação industrial e a saúde conectada, entre outras áreas relevantes. Ao possibilitar a conexão e comunicação entre dispositivos em tempo real, a IoT abre caminho para soluções inovadoras e eficientes em uma variedade de setores (AL-FUQAHA et al., 2015).

No contexto da saúde, por exemplo, a IoT facilita o monitoramento remoto de pacientes, a coleta de dados biométricos e o acompanhamento de condições médicas em tempo real. Isso não só melhora a qualidade do atendimento ao paciente, permitindo diagnósticos mais rápidos e precisos, mas também reduz os custos associados aos cuidados de saúde, ao permitir intervenções preventivas e uma gestão mais eficiente dos recursos hospitalares (MOHAMMED et al., 2014).

No entanto, apesar dos benefícios oferecidos pela IoT, também surgem desafios significativos, como questões de interoperabilidade entre dispositivos e infraestruturas heterogêneas, e questões éticas relacionadas ao uso e compartilhamento de informações sensíveis. Portanto, é essencial abordar esses desafios de forma proativa e implementar medidas adequadas para garantir a confiabilidade e a segurança dos sistemas IoT em todas as suas aplicações (MAYER, 2009).

2.2 INTERNET DAS COISAS MÉDICAS

A IoMT representa o conjunto de tecnologias que interconecta dispositivos médicos e sistemas de saúde por meio da Internet, viabilizando a coleta, a transmissão e a análise de dados clínicos para aprimorar a assistência, apoiar o monitoramento de pacientes e otimizar fluxos de trabalho. Essa abordagem integra uma diversidade de dispositivos, como sensores biométricos, plataformas de monitoramento remoto e aplicativos de saúde, em uma rede coerente. A interconexão resultante favorece a comunicação entre pacientes, profissionais e serviços, promovendo uma gestão mais eficiente e personalizada do cuidado (PHILIP et al., 2021).

As soluções em IoMT abrangem uma ampla gama de aplicações com impacto direto na prática clínica. No gerenciamento de doenças crônicas, por exemplo, dispositivos conectados realizam o acompanhamento contínuo de sinais e padrões de saúde, permitindo que as equipes ajustem condutas de modo proativo e personalizado. Essa capacidade tende a melhorar os desfechos clínicos e a qualidade de vida dos pacientes. Além disso, a IoMT contribui para a

eficiência operacional dos serviços de saúde por meio da automação e da aquisição de dados em tempo real, o que favorece a coordenação assistencial, a redução dos tempos de espera e uma maior acurácia diagnóstica (ISLAM et al., 2015; GATOULLAT et al., 2018).

A inovação em saúde tem sido impulsionada por dispositivos inteligentes baseados em IoMT, que vão de *wearables* para atividade física e sinais vitais a dispositivos implantáveis para terapias e administração precisa de medicamentos (ASGHARI; RAHMANI; JAVADI, 2019). A detecção precoce de anomalias clínicas ou de condições ambientais, associada a mecanismos de alerta, habilita intervenções preventivas e melhora a segurança do paciente (FARAHANI et al., 2018). A adoção de monitoramento remoto no pós-alta e em contextos domiciliares fortalece a continuidade do cuidado, o engajamento do paciente e a produtividade da equipe clínica ao redirecionar tempo para atividades de maior valor assistencial (GUBBI et al., 2013).

2.2.1 Dispositivos e Interoperabilidade em IoMT

A camada de dispositivos em IoMT é composta por sensores e nós responsáveis pela aquisição de dados clínicos. A seleção dos itens que a integram depende da aplicação, do tipo de dado, da precisão requerida e das restrições operacionais.

2.2.1.1 Sensores e dispositivos

Entre os sensores frequentemente empregados, destacam-se:

- **Temperatura corporal:** integrados a termômetros inteligentes, *patches* e dispositivos vestíveis para o acompanhamento contínuo de sinais.
- **Batimentos e oximetria de pulso:** presentes em *smartwatches*, *wearables* e oxímetros dedicados, são úteis para triagem e detecção de alterações cardiorrespiratórias.
- **Pressão arterial:** acoplados a manguitos inteligentes e a sistemas de monitoramento domiciliar, com integração a aplicativos e prontuários.
- **Glicose, contínua ou pontual:** medidores tradicionais e sistemas de monitoramento contínuo de glicose (GCM) para acompanhamento do diabetes.
- **Acelerômetros e giroscópios:** embutidos em dispositivos vestíveis para a avaliação da atividade física, detecção de quedas e avaliação de caminhada.

- **Eletrocardiograma (ECG):** vestíveis ou portáteis para a detecção de arritmias e o acompanhamento de pacientes com risco cardiovascular.

2.2.1.2 Middlewares e interoperabilidade

Os *middlewares* da camada de comunicação e processamento em IoMT facilitam a troca de mensagens, a interoperabilidade e o gerenciamento de dados entre aplicações, dispositivos e serviços, abstraindo a heterogeneidade de protocolos e formatos:

- **Mensageria:** *Message Queuing Telemetry Transport* (MQTT), *Constrained Application Protocol* (CoAP) e *Advanced Message Queuing Protocol* (AMQP) para comunicação leve e assíncrona. O CoAP é especialmente adequado para dispositivos com recursos restritos e redes de baixa potência, enquanto o RabbitMQ, amplamente utilizado com AMQP, oferece mecanismos de enfileiramento e roteamento de mensagens em arquiteturas distribuídas. Apache Kafka pode atuar no *backbone* para a ingestão e distribuição de fluxos.
- **Orquestração e gerenciamento de dispositivos:** Microsoft Azure IoT Hub e AWS IoT Core, além de soluções no ecossistema Google Cloud baseadas em *pub/sub*, para conexão, provisionamento e telemetria em larga escala, além de outros ambientes de nuvem.
- **Processamento de eventos e fluxos:** *Stream processing* com Apache Flink, entre outros, para detecção de padrões e geração de alertas em tempo quase real.
- **Bancos de dados para séries temporais:** InfluxDB e TimescaleDB, otimizados para a ingestão e consulta de telemetria.
- **Interfaces de Programação de Aplicações (API) e *Software Development Kit* (SDK):** interfaces de programação com padrões de interoperabilidade em saúde, como *Health Level Seven* (HL7) e o *Fast Healthcare Interoperability Resources* (FHIR), para integração com prontuários e sistemas clínicos.

A seleção do *middleware* e dos componentes de integração deve considerar requisitos de escalabilidade, latência, interoperabilidade e integração com sistemas legados, alinhando-os às políticas institucionais e às restrições clínicas do contexto de aplicação.

2.2.2 Análise Comparativa dos Protocolos de Comunicação IoT em Aplicações de Saúde

Esta seção aborda a análise e comparação dos protocolos de comunicação empregados em sistemas IoT aplicados à saúde, com foco em suas características, benefícios e limitações. Esses protocolos são fundamentais para viabilizar a interação entre dispositivos IoMT, assegurando a troca eficiente e segura de informações críticas em ambientes de saúde. Eles permitem a transmissão de dados sensíveis, como sinais vitais e alertas de emergência, o que é essencial para garantir respostas ágeis e seguras dos profissionais de saúde (KOUTRAS et al., 2020).

Considerando que os dispositivos IoMT são um subconjunto da IoT, sua comunicação se baseia em protocolos específicos da IoT. Entretanto, nem todos os protocolos IoT foram diretamente adaptados para dispositivos IoMT, o que pode limitar as opções para certas aplicações. Portanto, é de grande importância que os projetistas selecionem o protocolo mais adequado para cada cenário, avaliando fatores como desempenho, disponibilidade, alcance de sinal e consumo de energia. A estrutura de comunicação da IoT é tipicamente organizada em camadas, cada uma com funções distintas, a saber: Camada de Dispositivo, Camada de Comunicação e Camada de Aplicação. Compreender as funções e desafios de cada camada é essencial para a eficiência e confiabilidade dos sistemas IoMT, facilitando uma análise comparativa aprofundada das tecnologias empregadas. A Tabela 1 apresenta um resumo das principais diferenças entre essas tecnologias (KOUTRAS et al., 2020).

A **Camada de Percepção** constitui a base dos sistemas IoMT, sendo responsável pela coleta de dados do ambiente físico por meio de sensores, atuadores e dispositivos de borda. Ela capta informações que refletem as condições do ambiente e as transmite para as camadas superiores para processamento. Em sistemas de saúde, essa camada garante a aquisição de dados vitais, como sinais fisiológicos e indicadores de emergência, suportando decisões médicas rápidas e seguras.

Os protocolos que atuam nesta camada são projetados para conectar os dispositivos e assegurar a integridade da coleta de dados. Exemplos incluem: *Radio-Frequency Identification* (RFID) (opera a 13,56 MHz, com alcance de poucos centímetros, ideal para identificação e rastreamento próximos); *Near Field Communication* (NFC) (também a 13,56 MHz, com alcance inferior a 20 cm, frequentemente usado em emparelhamento seguro de dispositivos médicos); Bluetooth/BLE (utiliza a banda de 2,4 GHz, com alcances de 80 a 90 metros, sendo adequado para *wearables* e monitoramento contínuo); ZigBee (opera na banda de 2,4 GHz,

Tabela 1 – Resumo dos protocolos de comunicação IoMT das camadas de percepção, rede e aplicação.

Protocolos IoT	Camada	Frequência	Taxa de Dados	Alcance	Energia	Referências
RFID	Dispositivo	13.56 MHz	106–424 Kbps	20 cm	Muito baixo	(JAVDANI; KASHANIAN, 2018; ALTAWY; YOUSSEF, 2016)
NFC	Dispositivo	13.56 MHz	106–424 Kbps	20 cm	Muito baixo	(AHMADI et al., 2019; PEREZ; DAFONTE; GÓMEZ, 2018)
Bluetooth/BLE	Dispositivo	2.4 GHz	1, 2, 3 Mbps	80–90 m	Baixo	(SANTAGATI; DAVE; MELO-DIA, 2020; GIA et al., 2015)
ZigBee	Dispositivo	2.4 GHz	250 Kbps	100 m	Baixo	(DANG et al., 2019; PASHA; SHAH, 2018)
Z-Wave	Dispositivo	sub-GHz	40 Kbps	30 m	Baixo	(BAGGA; THAKRAL; BAGGA, 2018; PATTNAIK; KUMAR; PAL, 2020)
LoRaWAN	Comunicação	sub-GHz	50 Kbps	3–4 km	Baixo	(MDHAFFAR et al., 2017; CATHERWOOD et al., 2018)
Wi-Fi	Comunicação	2.4–5 GHz	0.1–54 Mbps	80 m	Médio	(FOTOUHI et al., 2016; TAŞ-TAN, 2018)
Ingenu	Comunicação	2.4 GHz	624 Kbps	15 km	Baixo	(CENTENARO et al., 2016; FINNEGAN; BROWN, 2018)
SigFox	Comunicação	868 MHz	100–600 Bps	10–50 km	Baixo	(CENTENARO et al., 2016; FINNEGAN; BROWN, 2018)
6LoWPAN	Comunicação	2.4 GHz	50–250 Kbps	200 m	Baixo	(SU et al., 2019; YACCHIREMA; PALAU; ESTEVE, 2017)
CoAP	Aplicação	N/A	N/A	N/A	N/A	(DUGGAL, 2017; FLURY et al., 2010)
AMQP	Aplicação	N/A	N/A	N/A	N/A	(PATATNAIK; KUMAR; PAL, 2020; MORAES et al., 2019)
MQTT	Aplicação	N/A	N/A	N/A	N/A	(CHEN; KUNZ, 2016; COLLINA et al., 2014)

com opções sub-GHz, atingindo até 100 metros e comumente empregado em redes de sensores de maior cobertura); e Z-Wave (predominantemente em bandas sub-GHz, oferece alcance de até 30 metros em ambientes internos e alta confiabilidade em comunicações de baixa potência) (JAVDANI; KASHANIAN, 2018; ALTAWY; YOUSSEF, 2016).

A eficiência energética é uma característica distintiva da camada de percepção, particularmente importante para dispositivos com restrições de bateria. Sua arquitetura promove a integração e interoperabilidade de uma vasta gama de dispositivos. A seleção do protocolo para esta camada deve ponderar cuidadosamente fatores como alcance, consumo de energia e capacidade de transmissão, considerando as especificidades das aplicações de saúde (AHMADI et al., 2019).

A **Camada de Rede** assume um papel central na comunicação entre os dispositivos de um sistema IoMT, sendo encarregada de gerenciar o tráfego de dados. Essa camada utiliza protocolos que devem satisfazer as necessidades específicas de cada aplicação. Alguns dos protocolos notáveis são: *Long Range Wide Area Network* (LoRaWAN), que oferece comunicação de longo alcance em bandas sub-GHz, com até 15 km em áreas rurais e baixo consumo de energia.

O WiFi opera nas bandas de 2,4 GHz e 5 GHz, fornecendo altas taxas de dados, embora com alcance limitado, tipicamente até 100 metros, o que o torna ideal para redes locais (FOTOUHI et al., 2016; TAŞTAN, 2018). Para longo alcance, o Ingenu opera na banda *Industrial, Scientific, and Medical* (ISM) de 2,4 GHz, proporcionando conexões confiáveis e de baixa potência. De forma complementar, o SigFox trabalha em bandas sub-GHz, projetado para taxas de dados muito baixas, mas com um alcance excepcional de até 50 km em áreas rurais, adequado para aplicações de baixa largura de banda.

Por fim, o 6LoWPAN é uma camada de adaptação que permite o uso do *Internet Protocol version 6* (IPv6) em redes de dispositivos com recursos restritos, especialmente aquelas baseadas no padrão IEEE 802.15.4 (SU et al., 2019; YACCHIREMA; PALAU; ESTEVE, 2017). Nesse contexto, características como operação na banda de 2,4 GHz, baixo consumo de energia e alcance típico de até 100 metros estão associadas à tecnologia de comunicação subjacente, enquanto o 6LoWPAN contribui para a integração eficiente desses dispositivos a redes IP, inclusive em cenários com topologias mesh. Esses protocolos, em sua diversidade, oferecem opções de conectividade que permitem aos sistemas IoMT adaptar-se flexivelmente às exigências particulares de cada aplicação de saúde.

A **Camada de Aplicação** é responsável por apresentar os dados coletados dos pacientes através de plataformas médicas, fornecendo interfaces personalizadas que auxiliam na tomada de decisões diagnósticas. Entre os protocolos mais empregados nesta camada, destacam-se o CoAP. Este é reconhecido pelo seu design leve e eficiente, sendo ideal para dispositivos com recursos limitados (DUGGAL, 2017; FLURY et al., 2010).

Ele suporta comunicação baseada em *Representational State Transfer* (REST) e opera sobre *User Datagram Protocol* (UDP), perfeito para os sistemas que necessitam equilibrar baixa latência e baixo consumo de energia. Em contraste, o AMQP é um protocolo de mensagens robusto, com foco em alta confiabilidade e entrega garantida. É amplamente utilizado em sistemas que demandam comunicação assíncrona e interações entre aplicações distribuídas (PATTNAIK; KUMAR; PAL, 2020; MORAES et al., 2019).

Por fim, o MQTT é um protocolo de mensagens publicar/assinar (publish/subscribe) concebido para ser leve e eficiente (CHEN; KUNZ, 2016; COLLINA et al., 2014). Ele permite a comunicação entre dispositivos IoT, minimizando o uso de largura de banda e os custos de energia, o que o torna ideal para o monitoramento e controle em tempo real de dispositivos IoMT.

2.3 AVALIAÇÃO DE DESEMPENHO

A expansão dos sistemas computacionais em diversos setores tem transformado a maneira como as empresas operam, permitindo melhorias significativas em eficiência, produtividade e inovação. À medida que os sistemas de tecnologia da informação (TI) se tornam mais integrados e complexos, a necessidade de uma avaliação de desempenho robusta e precisa torna-se essencial. A avaliação de desempenho de sistemas é crucial para identificar gargalos, otimizar recursos e garantir que as tecnologias implementadas realmente agreguem valor ao negócio (JAIN, 1991; HENNESSY; PATTERSON, 2011).

Existem diferentes estratégias de medição e ferramentas para avaliar o desempenho dos sistemas. Estas incluem monitoramento em tempo real, testes de carga, *benchmarks* e simulações (GUNTHER, 1997; MENASCE; ALMEIDA, 1998). Cada uma dessas estratégias oferece *insights* específicos sobre como um sistema opera sob diferentes condições, permitindo aos administradores de TI identificar pontos fracos e áreas que necessitam de melhorias. O uso adequado dessas ferramentas e estratégias é fundamental para manter a eficiência e a estabilidade dos sistemas, especialmente em ambientes críticos como bancos, hospitais e grandes corporações (WOODSIDE; FRANKS; PETRIU, 2007).

A qualidade das ferramentas de medição e a precisão dos dados coletados são aspectos fundamentais da avaliação de desempenho. Ferramentas inadequadas ou dados imprecisos podem levar a conclusões erradas, resultando em decisões que podem prejudicar o funcionamento do sistema. Portanto, é importante utilizar ferramentas de medição confiáveis e garantir que os dados sejam precisos e relevantes. Isso melhora a confiança nas avaliações, e assegura que as intervenções feitas com base nesses dados sejam efetivas (LILJA, 2005; MENASCE; ALMEIDA, 2005).

Além das ferramentas de medição, técnicas analíticas como SPN, RBD, Teoria das Filas e Cadeias de Markov desempenham um papel importante na avaliação de desempenho de sistemas. Técnicas que utilizam fórmulas fechadas ou sistemas de equações permitem uma análise detalhada e matemática do comportamento do sistema (TRIVEDI, 2008a; GROSS, 2008). Essas técnicas são especialmente úteis para prever o desempenho, levando em consideração diferentes cargas de trabalho e para entender como as mudanças em um componente do sistema podem afetar o desempenho geral. A aplicação dessas técnicas ajuda a criar modelos preditivos que podem orientar decisões estratégicas sobre upgrades de hardware, mudanças na arquitetura do sistema ou otimizações de software (GERMAN, 2000; MARSAN; AL., 1998;

SAHNER; TRIVEDI; PULIAFITO, 2012).

A teoria das filas é uma abordagem analítica amplamente utilizada para modelar e analisar o desempenho de sistemas de espera, como servidores web, bancos de dados e redes de comunicação (BOLCH et al., 2006). Essa abordagem permite compreender como o sistema se comporta sob diferentes níveis de demanda e estimar os tempos de espera percebidos pelos usuários. Também facilita a identificação de gargalos e apoia as decisões de dimensionamento de recursos. Ao aplicar a teoria das filas, os engenheiros de sistemas podem identificar pontos de congestionamento e implementar soluções para melhorar o fluxo de trabalho e a satisfação do usuário. Essa análise é crucial para garantir que os sistemas possam atender às necessidades dos usuários de maneira eficiente e confiável. A lei de Little (*Little's law*) (MACIEL, 2023) é um teorema comumente utilizado dentro dessa teoria, permitindo a obtenção do tempo médio de resposta de sistemas com base na relação entre o número médio de requisições, representado por " L " e a taxa de chegada de tarefas, representada por " λ " (ver Equação 2.1).

$$R = \frac{L}{\lambda} \quad (2.1)$$

A integração de ferramentas de medição de alta qualidade, técnicas analíticas e a teoria das filas oferece uma abordagem robusta para a avaliação do desempenho dos sistemas. Essa combinação permite uma compreensão abrangente de como os sistemas operam e onde são necessárias melhorias. A capacidade de prever e mitigar problemas antes que eles afetem o desempenho é um dos principais benefícios dessa abordagem integrada, resultando em sistemas mais eficientes e confiáveis (JAIN, 1991; HENNESSY; PATTERSON, 2011).

2.4 AVALIAÇÃO DE DISPONIBILIDADE E CONFIABILIDADE

A dependabilidade de um sistema é importante para garantir sua eficiência e envolve uma variedade de métricas. Este conceito inclui atributos como confiabilidade, segurança, confidencialidade, integridade e manutenibilidade (MACIEL, 2023).

A confiabilidade, elemento fundamental desse conjunto, é a probabilidade de um sistema desempenhar suas funções sem falhas durante um período específico (BERNARDI; MERSEGUER; PETRIU, 2012). Esta é representada pela Equação 2.2.

$$R(t) = P\{T \geq t\}, T \geq 0 \quad (2.2)$$

Onde T é a variável aleatória (não negativa) que representa o tempo até a falha do sistema, e $P\{T < t\}$ é a probabilidade de o sistema falhar antes de t (isto é, a probabilidade de que o tempo até a falha seja menor que t). Equivalentemente, definindo $F(t) = P\{T \leq t\}$, tem-se $P\{T < t\} = F(t)$ para T contínua.

A disponibilidade é a probabilidade de o sistema estar apto a cumprir sua função quando demandado em um instante t (MACIEL, 2023). A disponibilidade em estado estacionário (A), considera a relação entre o tempo médio entre falhas (MTTF) e o tempo médio para reparo (MTTR) do sistema, conforme mostrado na Equação 2.3 (KANOUN; SPAINHOWER, 2008).

$$A = \frac{MTTF}{MTTF + MTTR}, \quad (2.3)$$

$$MTTR = \int_0^{\infty} (1 - M(t)) dt. \quad (2.4)$$

$$MTTF = \int_0^{\infty} R(t) dt, \quad (2.5)$$

A função de distribuição cumulativa $M(t)$ representa a probabilidade de o reparo ser concluído até o instante t (ver Equação 2.4). Por sua vez, a função de confiabilidade $R(t)$ representa a probabilidade de um sistema desempenhar suas funções sem falhas até o instante t (ver Equação 2.5) (EBELING, 2004).

Embora ambas descrevam o comportamento temporal do sistema, elas se referem a fenômenos distintos: $M(t)$ está associada ao processo de reparo, enquanto $R(t)$ está associada ao tempo até a falha. Nesse contexto, a função de confiabilidade pode ser expressa em termos da função de distribuição acumulada do tempo até a falha, denotada por $F(t)$, conforme a Equação 2.6 (EBELING, 2004; MACIEL, 2023):

$$R(t) = 1 - F(t) \quad (2.6)$$

Essa equação indica que a probabilidade de o sistema permanecer em funcionamento, sem falhas, até o instante t é igual a 1 menos a probabilidade acumulada de ocorrência de falha até esse instante.

Downtime é outra métrica e considera a indisponibilidade do sistema (EBELING, 2004; MACIEL, 2023; KANOUN; SPAINHOWER, 2008). Pode-se definir essa métrica como mostrado na Equação 2.7:

$$downtime = (1 - A) \times t. \quad (2.7)$$

Por fim, ressalta-se a categorização da disponibilidade de sistemas computacionais conforme seu nível de disponibilidade, que varia de críticos a não críticos (Federal Aviation Administration, 2020). É possível classificar a disponibilidade de um sistema por meio do número de noves (ÖHMANN; SIMSEK; FETTWEIS, 2014) conforme a Equação 2.8. A Tabela 2 apresenta a relação entre o número de noves da disponibilidade e o respectivo *downtime*, bem como suas categorias correspondentes, considerando um período de um ano (GRAY; SIEWIOREK, 1991).

$$N_9 = (-\log_{10}[1 - A]) \quad (2.8)$$

Tabela 2 – Número de noves equivalentes para disponibilidade

Número de noves	Disponibilidade (%)	Categoria	Downtime (h)
1	90	Não gerenciado	840 horas
2	99	Gerenciado	96 horas
3	99,9	Bem gerenciado	9 horas
4	99,99	Tolerante a falhas	1 hora
5	99,999	Alta disponibilidade	5 minutos
6	99,9999	Muita alta disponibilidade	30 segundos
7	99,99999	Ultra disponibilidade	3 segundos

O MTTR é uma métrica utilizada para medir o tempo médio necessário para reparar um sistema e restaurá-lo ao seu estado normal de funcionamento após uma falha (MODARRES; KAMINSKIY; KRIVTSOV, 2009). Assim como no cálculo do MTTF, é necessário considerar a distribuição estatística dos tempos de reparo (KAPUR; PECHT, 2014). A Equação 2.4 representa o cálculo do MTTR, no qual $M(t)$ é a função de distribuição acumulada do tempo de reparo.

Modelos de dependabilidade são essenciais para a avaliação preliminar de sistemas, podem ser baseados em espaço de estado ou combinatórios, dependendo da complexidade das interações entre os componentes (MACIEL, 2023). Para assegurar a confiabilidade dos sistemas, são empregadas três técnicas principais: prevenção de falhas, remoção de falhas e tolerância a falhas (AVIZIENIS; AL., 2001). A prevenção de falhas envolve a implementação de práticas e métodos projetados para evitar a ocorrência de falhas, garantindo que não haja erros durante a construção do sistema. A remoção de falhas, se refere ao processo de identificação e correção de falhas já existentes no sistema. A tolerância a falhas é a capacidade de um sistema

continuar funcionando corretamente, mesmo na presença de falhas, utilizando redundâncias e mecanismos de recuperação para assegurar a operação contínua (AVIZIENIS; AL., 2001; MACIEL, 2023).

A confiabilidade e a disponibilidade são importantes propriedades para a eficiência de sistemas complexos. A confiabilidade refere-se à capacidade de um sistema operar sem falhas durante um período específico, assegurando que suas funções sejam executadas conforme o esperado. A disponibilidade é a medida da prontidão operacional do sistema, refletindo o tempo em que o sistema está funcional e acessível para uso, o que é essencial para operações contínuas. Juntas, essas propriedades asseguram a eficácia, eficiência e continuidade das operações de um sistema (EBELING, 2004; BERNARDI; MERSEGUER; PETRIU, 2012).

2.4.1 Importância da Disponibilidade

A Importância da Disponibilidade (ID) (FIGUEIRÊDO et al., 2011) é uma técnica aplicada para avaliar como a disponibilidade de um componente individual afeta a disponibilidade geral do sistema. Este método permite identificar os componentes cuja disponibilidade exerce a maior influência sobre o sistema. A ID de um componente i é definida como a variação na disponibilidade total do sistema quando a disponibilidade do componente i é aumentada para o seu valor máximo, ou seja, definida como 1 (KUO; ZUO, 2003). Essa métrica pode ser calculada utilizando a Equação 2.9.

$$ID_i = D_s(1_i, p^i) - D_s(0_i, p^i) \quad (2.9)$$

Nesta equação, ID_i indica a Importância da Disponibilidade do componente i , e D_s denota a disponibilidade geral do sistema. O vetor p^i representa a configuração de disponibilidade com o i -ésimo componente excluído. A notação 0_i corresponde ao caso em que o componente i não está funcionando, enquanto 1_i refere-se ao caso em que ele está operando corretamente.

Como exemplo, considere o RBD da Figura 2 e os valores de disponibilidade apresentados na Tabela 3. Na Seção 2.7 será introduzido o conceito de RBD. A Importância da Disponibilidade do *Componente 1* é calculada como:

$$ID_1^B = 1_1 \times a_2 \times a_3 - 0_1 \times a_2 \times a_3, \quad (2.10)$$

em que a_i é a disponibilidade do componente i .

Em uma estrutura em série, o componente menos disponível (menor a_i) tende a apresentar a maior ID , como se observa na Tabela 3. Em uma estrutura em paralelo, o componente mais disponível tende a concentrar a maior ID (FIGUEIRÊDO et al., 2011).




Figura 2 – Diagrama de Blocos de Confiabilidade em série com 3 componentes.

Tabela 3 – Importância da Disponibilidade (Figura 2).

	Componente 1	Componente 2	Componente 3
Valor de disponibilidade (a_i)	0,80	0,60	0,65
Importância da disponibilidade (ID)	0,39	0,52	0,48

Importância de Disponibilidade e Custo

A Importância de Disponibilidade e Custo (IDC) é uma métrica que relaciona a ID ao custo de aquisição dos componentes. A IDC do componente i pode ser calculada por:

$$IDC_i = ID_i \times \left(1 - \frac{C_i}{C_{\text{sis}}}\right), \quad (2.11)$$

em que IDC_i é o índice proposto de importância conjunta de disponibilidade e custo; ID_i é a importância da disponibilidade do componente i ; C_i é o custo de aquisição do componente i ; e C_{sis} é o custo de aquisição do sistema como um todo.

2.5 CADEIAS DE MARKOV DE TEMPO CONTÍNUO

As CTMC representam um formalismo matemático introduzido por (MARKOV, 1906) que se baseia em espaços de estado para modelar uma variedade de sistemas em diversas áreas. Um modelo de *Markov* pode ser representado por um diagrama de estados discretos, conectados por transições probabilísticas, caracterizando um processo estocástico específico (BOLCH et al., 2006).

Um processo estocástico é caracterizado como uma coleção de variáveis aleatórias ($X(t)$), onde o parâmetro t pertence a um conjunto T . Geralmente, T é definido como o conjunto dos inteiros não negativos, e $X(t)$ representa uma característica mensurável de interesse no tempo t (BOLCH et al., 2006). O conjunto de todos os possíveis valores de $X(t)$ para cada

$t \in T$ é denominado espaço de estados S . Se T for discreto, o processo é classificado como de tempo discreto; caso contrário, é considerado contínuo. Da mesma forma, o espaço de estados S pode ser discreto ou contínuo, resultando em processos estocásticos discretos ou contínuos, respectivamente. Nesta tese, optou-se por não utilizar tempos discretos, concentrando-se em processos estocásticos de tempo contínuo ($T = t : 0 \leq t < \infty$).

Um processo estocástico é dito ser *Markoviano* se (HAVERKORT, 2000),

$$P\{X(t_{k+1}) \leq x_{k+1} | X(t_k) = x_k, X(t_{k-1}) = x_{k-1}, \dots, X(t_1) = x_1, X(t_0) = x_0\} = P\{X(t_{k+1}) \leq x_{k+1} | X(t_k) = x_k\}, \quad (2.12)$$

Para cada $t_0 \leq t_1 \leq \dots \leq t_k \leq t_{k+1}$, um processo estocástico é considerado um processo *Markoviano* somente se o estado futuro depender exclusivamente do estado presente ($X(t_k) = x_k$), sem depender dos estados passados. Por essa razão, esse tipo específico de processo estocástico é também conhecido como "processo sem memória" (*memoryless process*) (HAVERKORT, 2000).

Uma representação gráfica comum de uma CTMC é um diagrama de estados, no qual os vértices denotam os estados e as arestas indicam as transições entre eles. Essas transições entre estados simbolizam a ocorrência de eventos (MACIEL et al., 2011). Os pesos das arestas são atribuídos de acordo com a natureza das variáveis aleatórias utilizadas para representar a duração dos eventos de um sistema. Por exemplo, em uma *Discrete Time Markov Chain* (DTMC), é possível atribuir um valor $0 < p < 1$ ao peso de uma aresta, onde p representa a probabilidade de transição de um estado s_i para s_j . Por outro lado, nas CTMC, o valor atribuído ao peso de uma aresta entre duas transições reflete a taxa na qual ocorre a mudança de estado (BOLCH et al., 2006). Devido à propriedade *Markoviana* (*memoryless*), o tempo entre atividades deve seguir uma distribuição sem memória, e, consequentemente, nas CTMC, adota-se a distribuição exponencial (BOLCH et al., 1998).

A Figura 3 apresenta um exemplo de uma CTMC com quatro estados, utilizado para ilustrar o método de análise subsequente. As letras gregas α , β , λ e θ denotam as taxas associadas à CTMC, enquanto X , Y , W e Z representam os estados.

As CTMC podem ser representadas na forma de matriz (matriz de taxa de transição ou geradora). A matriz geradora Q é composta pelos componentes q_{ii} e q_{ji} , onde q representa a taxa de transição do estado i para o estado j , e $\sum q_{ij} = -q_{ii}$. Portanto, considerando a CTMC da Figura 3 e o espaço de estados $S = X, Y, W, Z = 0, 1, 2, 3$, a matriz geradora Q




Figura 3 – Exemplo de uma CTMC

resultante é:

$$Q = \begin{pmatrix} q_{00} & q_{01} & q_{02} & q_{03} \\ q_{10} & q_{11} & q_{12} & q_{13} \\ q_{20} & q_{21} & q_{22} & q_{23} \\ q_{30} & q_{31} & q_{32} & q_{33} \end{pmatrix} = \begin{pmatrix} -\beta & \beta & 0 & 0 \\ 0 & -\alpha & 0 & 0 \\ \theta & 0 & 0 & -\theta \\ 0 & \lambda & 0 & 0 \end{pmatrix} \quad (2.13)$$

Nesse exemplo, substituem-se $q_{00}, q_{11}, q_{22}, q_{33}, q_{01}, q_{02}, q_{03}, q_{10}, q_{12}, q_{13}, q_{20}, q_{21}, q_{23}, q_{30}, q_{31}, q_{32}$ pelas taxas de saída e pelas transições apropriadas para seus estados.

A análise estacionária de uma CTMC envolve encontrar a probabilidade de o sistema alcançar determinado estado após um longo período de tempo. Essas probabilidades são independentes do estado inicial do sistema e são representadas pelo vetor $\pi = \{\pi_1, \pi_2, \pi_3, \dots, \pi_n\}$, onde π_i é a probabilidade estacionária do estado i (MACIEL, 2023). Por fim, estima-se o cálculo do vetor de probabilidade de acordo com a Equação 2.14.

$$\pi \times Q = 0, \quad \sum_{i \in S} \pi_i = 1 \quad (2.14)$$

Este trabalho utiliza CTMC em um de seus estudos de caso para estimar disponibilidade e desempenho por meio de solução numérica do espaço de estados. Embora SPN seja o formalismo principal na concepção dos modelos, a análise em regime permanente das SPN exige, como etapa intermediária, a geração de uma CTMC equivalente (BOLCH et al., 2006; KLEINROCK, 1975). A partir dessa CTMC, derivada do espaço de estados acessível, obtêm-se as probabilidades estacionárias necessárias ao cálculo das métricas definidas na modelagem.

Dessa forma, as CTMC desempenham um importante papel na modelagem e avaliação de sistemas redundantes e na análise de dependabilidade em diversos contextos, incluindo IoMT. Na IoMT, as CTMC podem avaliar o desempenho de sistemas de monitoramento de

pacientes e analisar a confiabilidade de dispositivos médicos interconectados. Elas permitem a modelagem de métricas de desempenho, como tempo de resposta e taxa de falha, e são particularmente úteis para sistemas com um número limitado de fatores de análise, resultando em um número reduzido de estados possíveis.

Entretanto, para modelos que exigem uma representação mais detalhada e abrangente do sistema IoMT, como aqueles que envolvem múltiplos dispositivos e interações complexas entre eles, outras abordagens, como SPN, podem ser mais apropriadas. Essa abordagem será explorada com mais detalhes a seguir.

2.6 REDES DE *PETRI*

O conceito de PN foi primeiramente apresentado por Carl Adams *Petri* (PETRI, 1962) em sua tese de doutorado na Universidade de Darmstadt, na Alemanha. É uma forma de representar graficamente e matematicamente diversos tipos de processos com características distintas, como: sistemas com recursos paralelos, concorrentes, assíncronos e sistemas não determinísticos (MURATA, 1989). Dessa forma, é possível visualizar o estado do sistema em determinado momento, como também suas transições.

A partir do primeiro formalismo, outras representações foram propostas, permitindo extensões que representassem características que não foram abordadas nos primeiros modelos. Dessa forma, a rede de *Petri* foi adaptada e estendida em diversos segmentos, nas quais redes temporizadas (MERLIN; FARBER, 1976), estocásticas (MARSAN, 1988), de alto nível Rede de Petri Colorida (CPN) (JENSEN, 1989) e orientadas a objetos (JANOUSEK, 1998).

As PN são compostas pelos elementos a seguir:

- Lugares: tem como função o armazenamento de *tokens* os quais são removidos e adicionados à medida que as transições são disparadas. Representam os elementos passivos da rede, pode acontecer de conter mais de um (ou nenhum) *token* dentro do lugar.
- Tokens: o *token* é representado para marcar a atual condição que poderá ser mantida ou pode ser movida pela ocorrência do disparo das transições;
- Transições: são os elementos ativos da rede, em outras palavras, as ações realizadas pelo sistema. O disparo de uma transição faz com que *tokens* sejam consumidos dos lugares de entrada da transição e gerados nos lugares de saídas da transição. Uma transição

se encontra habilitada para disparar se o número de *tokens* presentes nos lugares de entrada da transição são iguais ou superiores ao peso dos arcos de entrada da transição.

- Arcos: o arco faz a conexão dos elementos principais (lugares e transições) que mostram a direção do fluxo. Os arcos conectam apenas os componentes principais intercalando lugar e transição, ou seja, um arco nunca une dois lugares ou duas transições.

Os elementos básicos de uma rede de Petri estão representados na Figura 4.



Figura 4 – Elementos da Rede de Petri

A representação formal de uma PN é a 5-tupla $PN = \{P, T, F, W, M_0\}$ (MURATA, 1989), onde:

- (i) $P = \{p_1, p_2, \dots, p_m\}$ é o conjunto finito de lugares;
- (ii) $T = \{t_1, t_2, \dots, t_n\}$ é o conjunto finito de transições;
- (iii) $F \subseteq (P \times T) \cup (T \times P)$ é o conjunto de arcos;
- (iv) $W : F \rightarrow \{1, 2, 3, \dots\}$ é a função de atribuição de peso aos arcos;
- (v) $M_0 : P \rightarrow \{0, 1, 2, 3, \dots\}$ é a marcação inicial.

O exemplo da Figura 5 representa a modelagem do funcionamento de um interruptor de luz em rede de Petri. Nesse modelo, os lugares representam o estado em que pode se encontrar o funcionamento do interruptor (*Ligado* ou *Desligado*) e as transições representam as ações que alteram o estado do interruptor (*Ligar* ou *Desligar*). Um *token* marca o estado do modelo no lugar correspondente à situação atual do interruptor como mostrado na Figura 5 (a). Considerando que *Ligado* é o estado atual do modelo, a transição *Desligar* ficará habilitada para disparar. Uma vez disparada esta transição, o modelo passa do estado *Ligado* (ver Figura 5 (a)) para o estado *Desligado* (ver Figura 5 (b)).

As PN encontram aplicação em uma ampla variedade de domínios, desde o controle de processos industriais até protocolos de comunicação e sistemas de software. Sua versatilidade




Figura 5 – Exemplo do funcionamento de um interruptor modelado em rede de Petri.

advém da habilidade de representar, de maneira simultânea, as relações de dependência entre eventos e a alocação de recursos, tornando-as uma ferramenta valiosa para analisar a concorrência e as interações em sistemas complexos (FRANCES, 2003; MURATA, 1989).

Um dos aspectos vitais das PN é sua capacidade de capturar a concorrência, uma característica intrínseca em sistemas distribuídos e paralelos. Ao representar as transições como eventos concorrentes, as PN permitem uma análise mais detalhada das dependências temporais e das possíveis condições de corrida em um sistema (MARSAN; CONTE; BALBO, 1984). Essa habilidade é crucial para identificar e resolver problemas associados à simultaneidade de eventos, contribuindo para o desenvolvimento de sistemas mais robustos e eficientes (MARSAN; CONTE; BALBO, 1984; MURATA, 1989).

Adicionalmente, as PN proporcionam uma representação visual fácil de interpretação, facilitando a comunicação entre diversas partes interessadas no desenvolvimento e análise de sistemas. A estrutura visual dessas representações possibilita uma compreensão imediata da dinâmica de sistemas complexos por parte de engenheiros, desenvolvedores e analistas, que conseguem identificar facilmente potenciais gargalos, pontos frágeis e oportunidades de aprimoramento (TRIVEDI, 2008b; MURATA, 1989).

Em redes de comunicação e sistemas distribuídos, as PN mostram-se especialmente eficazes na modelagem de protocolos de comunicação e na gestão de concorrência. Sua habilidade de representar a simultaneidade de eventos e a alocação de recursos torna essa abordagem uma opção natural para analisar o desempenho de sistemas distribuídos, nos quais múltiplos processos podem operar independentemente e interagir entre si (MARSAN et al., 1994; MARSAN; CONTE; BALBO, 1984).

2.6.1 Aplicações de redes de *Petri*

As PN, com sua versatilidade e capacidade de modelagem de sistemas complexos, têm desempenhado um papel fundamental em diversas áreas do conhecimento. Ao longo das últimas décadas, essas estruturas matemáticas têm sido aplicadas em uma variedade de contextos, desde sistemas industriais até aplicações na área da saúde e biologia (GUPTA; SINGH; KUMAWAT, 2022; GUPTA; SINGH; KUMAWAT, 2019).

No campo dos sistemas de controle de processos industriais, as PN têm sido amplamente utilizadas para modelar e analisar o fluxo de operações em linhas de produção, sistemas de manufatura e automação de fábricas. Sua capacidade de representar simultaneamente as interações entre diferentes componentes e o comportamento concorrente dos processos torna-as uma ferramenta valiosa para otimização e planejamento de operações industriais (GUPTA; SINGH; KUMAWAT, 2019; SURAJ; OLAR; BLOSHKO, 2021).

Além disso, as PN desempenham um importante papel na modelagem e análise de protocolos de comunicação em redes de computadores e sistemas de telecomunicações. Ao representar o comportamento dinâmico de sistemas de rede, elas permitem avaliar a eficiência, confiabilidade e escalabilidade desses sistemas, contribuindo para o desenvolvimento de protocolos mais robustos e eficientes (KOUNEV, 2006; BOUKREDERA; ADEL-AISSANOU, 2020).

Na área de sistemas de software, as PN são aplicadas para modelar e analisar sistemas complexos de software, como sistemas embarcados, sistemas distribuídos e sistemas críticos. Sua capacidade de identificar e resolver problemas de concorrência, *deadlock* e *race condition* ajuda a garantir a correta execução dos programas e a evitar falhas de sistema (RAFIEV et al., 2022; SIMON; TEIXEIRA; COSTA, 2022; MACIEL, 2023).

Além disso, as PN encontram aplicações em sistemas de transporte e logística, onde são utilizadas para modelar e otimizar o fluxo de veículos, mercadorias e informações em redes de transporte público, gestão de tráfego e cadeias de suprimentos. Sua capacidade de planejar rotas eficientes, coordenar o fluxo de recursos e prever demandas futuras contribui para melhorar a eficiência e a segurança dos sistemas de transporte e logística (LIST; CETIN, 2004; ZHANG; LU; WU, 2011).

Em sistemas de saúde e medicina, as PN desempenham um papel significativo, contribuindo para a modelagem e análise de processos complexos, como o fluxo de pacientes em hospitais, o planejamento de cirurgias e o monitoramento de epidemias. Essas aplicações destacam a versatilidade e o potencial das PN como uma ferramenta poderosa para auxiliar na tomada de

decisões informadas e na melhoria da eficiência dos sistemas de saúde (HARDY; ROBILLARD, 2004; ZHONG et al., 2010; EFSTRATIA; SALEM; GEORGE, 1996).

2.6.2 Redes de *Petri* estocásticas

As SPNs são uma extensão das Redes de Petri, colocando elementos probabilísticos para modelar sistemas onde o comportamento estocástico é relevante. Em SPN, as transições podem ter tempos de disparo associados a distribuições de probabilidade, geralmente exponenciais, permitindo a análise de sistemas que exibem incertezas temporais e variabilidade no tempo de execução das atividades. Dessa forma, essa abordagem torna as SPNs uma ferramenta adicional para a modelagem de sistemas de eventos discretos complexos, como redes de computadores, sistemas de manufatura e processos logísticos, onde o tempo de resposta e a ocorrência de eventos são influenciados por fatores aleatórios (MARSAN; AL., 1998; BALBO, 2001).

Uma importante diferença entre as duas abordagens consiste na forma como tratam o tempo e a incerteza. As PNs tradicionais não consideram o tempo ou assumem tempos determinísticos para as transições, enquanto as SPNs incorporam tempos de disparo estocásticos, capturando a natureza imprevisível de muitos sistemas reais. Essa distinção permite que as SPNs modelem não apenas a lógica estrutural dos sistemas, mas também seu comportamento temporal e probabilístico, oferecendo uma representação mais realista e detalhada dos processos dinâmicos (MARSAN; AL., 1998; BALBO, 2001).

Formalmente, pode-se definir uma SPN como uma 9-tupla (MACIEL, 2023):

$$SPN = \{P, T, I, O, H, \Pi, G, M_0, Atts\}$$

em que,

- $P = \{p_1, p_2, \dots, p_n\}$ é o conjunto de lugares;
- $T = \{t_1, t_2, \dots, t_m\}$ é o conjunto de transições imediatas e temporizadas, $P \cap T \neq \emptyset$;
- $I \in \mathbb{N}^{n \times m}$ é a matriz que representa os arcos de entrada (que podem ser dependentes de marcações);
- $O \in \mathbb{N}^{n \times m}$ é a matriz que representa os arcos de saída (que podem ser dependentes de marcações);

- $H \in \mathbb{N}^{n \times m}$ é a matriz que representa os arcos inibidores (que podem ser dependentes de marcações);
- $\Pi \in \mathbb{N}^m$ é um vetor que associa o nível de prioridade a cada transição;
- $G \in \mathbb{N}^{n \rightarrow \{\text{true}, \text{false}\}}$ é o vetor que associa uma condição de guarda relacionada à marcação do lugar a cada transição;
- $M_0 \in \mathbb{N}^n$ é o vetor que associa uma marcação inicial de cada lugar (estado inicial).

As SPNs possuem:

- **Arco inibidor:** um arco inibidor conecta um lugar a uma transição e é graficamente representado por uma linha com um círculo branco na extremidade oposta ao lugar. Quando o número de marcas em um lugar é igual ou maior do que a multiplicidade restrita pelo arco, a transição é desativada;
- **Semântica de temporização:** esta tese aborda semânticas de *Single server* e *Infinite server*. Habilitar uma transição imediata de *Single server* permite a absorção de tokens de maneira individual; ou seja, a ocorrência de um novo disparo é condicional à conclusão do atraso anterior. Quanto à semântica de *Infinite server*, a absorção de tokens é realizada em paralelo, de modo que, quando a respectiva transição é habilitada, pode ser disparada (MARSAN et al., 1994).

A seguir, a Figura 6 ilustra o elemento das SPNs que estendem as PN.



Figura 6 – Elemento adicional às SPNs que estendem o comportamento das PN.

Para entender melhor as regras de disparo de transições em PN, é importante conhecer as diferentes semânticas existentes (MARSAN; AL., 1998). *Single-Server*: nessa abordagem, a transição dispara apenas um *token* por ciclo de habilitação. Essa característica impõe a execução sequencial das transições, o que pode levar a um tempo total de execução mais longo na rede. *Infinite server*: Permite o disparo simultâneo de múltiplos *tokens* por ciclo, desde que a quantidade de *tokens* disponíveis atenda à demanda dos arcos de entrada (MACIEL, 2023).




Figura 7 – Semânticas de disparo

A Figura 7 (a) possui um lugar ($P0$) com três *tokens* alimentando a transição ta . Na semântica *Single-Server*, a transição dispara sequencialmente, consumindo apenas um token por vez. Isso significa que, para completar a execução da rede, a transição precisará disparar três vezes, totalizando 3 unidades de tempo (u.t.), como mostrado na Figura 7 (b). Em contraste, a semântica *Infinite-Server* permite que a transição dispare simultaneamente, consumindo todos os tokens disponíveis assim que for habilitada. No mesmo exemplo do lugar com três tokens, a transição *Infinite-Server* consumirá todos os tokens em apenas 1 u.t., o tempo necessário para habilitá-la, conforme ilustrado na Figura 7 (c) (MACIEL, 2023).

Em uma SPN, a alteração da semântica de disparo afeta diretamente o tempo necessário para concluir o processo que a SPN representa, podendo impactar as prioridades de disparo e alterar todo o contexto da rede. Portanto, ao modelar uma SPN, é importante definir corretamente a semântica de disparo, pois uma escolha inadequada pode levar a resultados significativamente diferentes.

As PN oferecem mecanismos para a especificação, análise e verificação de propriedades, garantindo a corretude dos sistemas modelados. A inclusão do fator temporal amplia seu poder analítico, permitindo a obtenção de métricas de avaliação de desempenho, o que viabiliza sua aplicação em sistemas de apoio à decisão (LABADI et al., 2012).

Exemplo de modelagem com SPN

Um sistema multiprocessado simples, no qual o processador requisita e obtém acesso à memória comum, pode ser modelado por meio de SPN. Um processador executa localmente por algum tempo (duração média $1/\lambda$) e, então, solicita acesso à memória compartilhada (o ganho de acesso tem duração média $1/r$). Depois que o acesso é concedido, o tempo médio de

uso da memória comum é $1/\mu$. É possível modelar o comportamento de um único processador interagindo com a memória comum usando a SPN mostrada na Figura 8.

- o **lugar** *Executando* representa o estado local do processador quando está executando;
- o **lugar** *Solicitando* corresponde ao estado do processador quando está pronto para iniciar a solicitação de acesso à memória comum;
- o **lugar** *Acessando* indica o estado em que o processo está usando a memória comum;
- o **lugar** *Memória* representa o estado local da memória comum quando não está em uso;
- a **transição** T_0 modela a ação do processador executando. A taxa dessa transição é λ ;
- a **transição** T_1 representa o processador obtendo acesso à memória comum. A taxa dessa transição é r ;
- a **transição** T_2 representa o processador acessando a memória comum. A taxa dessa transição é μ .




Figura 8 – SPN representando um único processador em um sistema com memória compartilhada.

2.7 DIAGRAMAS DE BLOCOS DE CONFIABILIDADE

O RBD é um modelo combinatório inicialmente proposto como técnica para calcular a confiabilidade de sistemas por meio de diagramas intuitivos de blocos. Os diagramas de blocos fornecem uma descrição gráfica dos componentes e conectores do sistema, que podem ser adotadas para determinar o estado global do sistema, dado o estado de seus componentes.

A estrutura do RBD estabelece a interação lógica entre componentes, definindo quais combinações de elementos em falha e ativos são capazes de sustentar a operação do sistema. Mais especificamente, o sistema é representado por subsistemas ou componentes conectados de acordo com sua função ou relação de confiabilidade (XIE; DAI; POH, 2004). Essa técnica também foi estendida para calcular outras métricas de dependabilidade, como disponibilidade e manutenibilidade (SAHNER; TRIVEDI; PULIAFITO, 2012).

Nos modelos RBD, é possível representar um componente físico no modo operacional por um bloco. Por outro lado, para representar a falha de um componente, remove-se o bloco correspondente ao componente que falhou. Se houver ao menos um caminho conectando os pontos de entrada e saída, o sistema continuará operando adequadamente. Em outras palavras, se blocos suficientes forem removidos em um RBD a ponto de interromper a conexão entre os pontos de entrada e saída, o sistema falha (DISTEFANO; SCARPA; PULIAFITO, 2006; KUO; ZUO, 2003; MACIEL, 2022).

2.7.1 Propriedades de Estrutura

Nesta subseção, apresenta-se o arranjo dos componentes em um sistema e a função de estrutura empregada para determinar se o sistema está funcionando ou não. As funções de estrutura são adotadas para relacionar o estado dos componentes individuais ao estado do sistema. Assume-se que tanto componentes quanto sistema podem estar em funcionamento (1) ou em falha (0).

Definição 2.8.1. O estado do componente i é denotado por x_i como segue:

$$x_i = \begin{cases} 1, & \text{se o componente } i \text{ está funcionando,} \\ 0, & \text{se o componente } i \text{ falhou,} \end{cases} \quad \text{para } i = 1, 2, \dots, n,$$

onde n representa o número de componentes.

Adicionalmente, um vetor $x = (x_1, x_2, \dots, x_n)$ pode ser adotado para representar o estado do sistema considerando esses n valores. A função de estrutura ϕ mapeia o vetor x em 1 ou 0:

Definição 2.8.2. A função ϕ determina o estado do sistema:

$$\phi(x) = \begin{cases} 1, & \text{se o sistema está funcionando,} \\ 0, & \text{se o sistema falhou.} \end{cases}$$

Os blocos (por exemplo, componentes) são geralmente organizados pelos seguintes mecanismos de composição: série, paralelo, ponte, arranjos *k-de-n* ou, ainda, combinações das abordagens anteriores. As linhas a seguir detalham cada um desses métodos de composição.

Sistema em série

A Figura 9 apresenta um diagrama de blocos de confiabilidade de um sistema em série, que só funciona se todos os seus componentes estiverem operando. Portanto, a função de estrutura $\phi(x)$ assume o valor 1 quando $x_1 = x_2 = \dots = x_n = 1$, e 0 caso contrário. Essas relações podem ser representadas de três maneiras, como mostrado a seguir:




Figura 9 – Diagrama de blocos de confiabilidade de um sistema em série.

Definição 2.8.3. A função que determina o estado do sistema em **série** é:

$$\phi(x) = \begin{cases} 1, & \text{se } x_i = 1 \text{ para todo } i = 1, 2, \dots, n, \\ 0, & \text{se existe } i \text{ tal que } x_i = 0, \end{cases}$$

$$\phi(x) = \min(x_1, x_2, \dots, x_n),$$

$$\phi(x) = \prod_{i=1}^n x_i.$$

As três formas de definir a função $\phi(x)$ que representa o sistema em série são equivalentes. Contudo, a terceira opção é a mais adotada pela sua compacidade (LEEMIS, 1995).

Sistema em paralelo

A Figura 10 apresenta um diagrama de blocos de confiabilidade de um sistema em paralelo, que funciona se um ou mais de seus componentes estiverem operando. Portanto, a função de estrutura $\phi(x)$ assume o valor 0 quando $x_1 = x_2 = \dots = x_n = 0$, e 1 caso contrário. Essas relações podem ser representadas de diferentes maneiras, como segue:

Definição 2.8.4. A função que determina o estado do sistema em paralelo é:




Figura 10 – Diagrama de blocos de confiabilidade de um sistema em paralelo.

$$\phi(x) = \begin{cases} 1, & \text{se existe } i \text{ tal que } x_i = 1, \\ 0, & \text{se } x_i = 0 \text{ para todo } i = 1, 2, \dots, n, \end{cases}$$

$$\phi(x) = \max(x_1, x_2, \dots, x_n),$$

$$\phi(x) = 1 - \prod_{i=1}^n (1 - x_i).$$

De modo análogo à definição do sistema em série, as três definições da função $\phi(x)$ são equivalentes. Contudo, a terceira opção é a mais adotada.

Sistema k -out-of- n

Um sistema k -out-of- n funciona se, e somente se, k ou mais de seus n componentes estiverem operando. Assim, os sistemas em série e em paralelo são casos particulares de k -out-of- n . O sistema em série corresponde a n -out-of- n (todos os componentes do sistema devem estar funcionando), enquanto o sistema em paralelo corresponde a 1-out-of- n (pelo menos um componente deve estar funcionando). A função ϕ para um sistema k -out-of- n é definida da seguinte forma:

Definição 2.8.5. A função que determina o estado do sistema k -out-of- n . é:

$$\phi(x) = \begin{cases} 1, & \text{se } \sum_{i=1}^n x_i \geq k, \\ 0, & \text{se } \sum_{i=1}^n x_i < k. \end{cases}$$

A Figura 11 apresenta um exemplo de RBD para um sistema *2-out-of-3*. O diagrama indica que, se pelo menos dois dos três componentes estiverem operando (por exemplo, 1 e 2, ou 1 e 3, ou 2 e 3), então o sistema também está operando. Assim, a função de estrutura $\phi(x)$ para um sistema *2-out-of-3* é: $\phi(x) = 1 - (1 - x_1x_2)(1 - x_1x_3)(1 - x_2x_3)$.




Figura 11 – Exemplo de RBD para um sistema *2-out-of-3*.

Seja p a probabilidade de sucesso de cada bloco. A probabilidade de sucesso do sistema (confiabilidade ou disponibilidade) é

$$\phi(x) = \sum_{i=k}^n \binom{n}{i} p^i (1-p)^{n-i}.$$

Sistema em ponte

Para encontrar a função de estrutura relacionada ao sistema em ponte mostrado na Figura 12, deve-se criar um diagrama de blocos considerando componentes repetidos. Nota-se que o sistema representado naquele arranjo em ponte opera quando, ao menos, conjuntos específicos de componentes estão funcionando (por exemplo, (1, 3, 5); (1, 4); (2, 3, 4); (2, 5)). Portanto, um diagrama de blocos alternativo, equivalente do ponto de vista de falhas, é o apresentado na Figura 13. A função de estrutura correspondente é então dada por $\phi(x) = 1 - (1 - x_1x_3x_5)(1 - x_1x_4)(1 - x_2x_3x_4)(1 - x_2x_5)$.




Figura 12 – Diagrama de blocos de confiabilidade de um sistema em ponte.




Figura 13 – Diagrama equivalente (em termos de pontos de falha) para o sistema em ponte.

2.7.2 Funções de Confiabilidade

Nesta seção, apresentamos as funções de confiabilidade das estruturas anteriores. Para computar a confiabilidade de um sistema, duas suposições devem ser consideradas. A primeira está relacionada ao fato de que os componentes são não reparáveis. As funções de estrutura apresentadas anteriormente podem ser adotadas tanto para sistemas reparáveis quanto não reparáveis, uma vez que tais funções apenas relacionam o estado dos componentes com o estado do sistema. Outra suposição importante está relacionada à independência dos componentes, no sentido de que a falha de um dispositivo não impacta a probabilidade de falha dos demais.

Diferentemente das funções de estrutura, para computar a confiabilidade do sistema, $R(t)$,

um tempo t deve ser considerado. Por exemplo, assumindo falhas independentes, a Equação (2.15) é adotada para computar a confiabilidade de sistemas em série. Portanto, a confiabilidade do sistema não pode ser maior componente de menor confiabilidade.

$$R_s(t) = \prod_{i=1}^n R_i(t) = \exp(-\lambda_s t), \quad (2.15)$$

onde $R_i(t)$ é a probabilidade de que o i -ésimo componente não falhe antes do tempo t ; $\lambda_s = \sum_{i=1}^n \lambda_i$; λ_i é a taxa de falha do i -ésimo componente. Adicionalmente, a confiabilidade de sistemas em paralelo pode ser obtida tomando-se 1 menos a probabilidade de que todos os n componentes falhem (isto é, a probabilidade de que ao menos um componente não falhe). A Equação (2.16) computa a confiabilidade de sistemas em paralelo. Para outros exemplos e fórmulas em forma fechada, o leitor deve consultar (DISTEFANO; SCARPA; PULIAFITO, 2006; KUO; ZUO, 2003).

$$R_s(t) = 1 - \prod_{i=1}^n (1 - R_i(t)) = 1 - \prod_{i=1}^n (1 - e^{-\lambda_i t}). \quad (2.16)$$

Sistemas combinados série-paralelo

Usualmente, sistemas são compostos por arranjos tanto em série quanto em paralelo. Considere o exemplo ilustrado na Figura 14, para computar a confiabilidade do sistema, o diagrama de blocos pode ser analisado por partes. Por exemplo, inicia-se pelo subsistema A (composto por dois componentes em paralelo); em seguida, parte-se para o subsistema em série (analisando as regiões A e B). Por fim, analisa-se o sistema completo para obter a confiabilidade do sistema. Assim, a confiabilidade do sistema é computada como segue:

$$R_A = 1 - (1 - R_2)(1 - R_3)$$

$$R_B = (R_A)(R_3)$$

$$R_S = [1 - (1 - R_B)(1 - R_4)](R_5).$$

2.7.3 Níveis de redundância

A redundância de sistemas pode ser alcançada por duas abordagens distintas: (i) redundância de *baixo nível* e (ii) redundância de *alto nível*. No primeiro caso, consideram-se um ou mais




Figura 14 – Exemplo de RBD com combinações série e paralelo.

componentes em paralelo, enquanto a redundância de alto nível replica todo o sistema. Por exemplo, considere um sistema composto por dois componentes em série (1 e 2) que adota redundância de baixo nível, como mostrado na Figura 15. De forma análoga, a Figura 16 apresenta dois componentes com redundância de alto nível.




Figura 15 – Diagrama de blocos de confiabilidade com redundância de baixo nível.

Uma questão interessante diz respeito a qual método de redundância apresenta os maiores valores de confiabilidade. Não há dúvida de que, para ambos os sistemas redundantes, no caso de falha de um dos componentes 1 ou de ambos os componentes 2, o sistema também falhará. O leitor deve observar que, na redundância de alto nível, o sistema pode falhar se um




Figura 16 – Diagrama de blocos de confiabilidade com redundância de alto nível.

componente 1 e um componente 2 falharem em caminhos distintos. É importante destacar que esse comportamento não ocorre na redundância de baixo nível. Portanto, sistemas com redundância de baixo nível possuem maior confiabilidade do que sistemas com redundância de alto nível.

As linhas a seguir apresentam a confiabilidade para sistemas redundantes de baixo e alto nível. Assuma que ambos os componentes (1 e 2) possuem a mesma confiabilidade R . A confiabilidade da redundância de baixo nível é:

$$R_{\text{baixo}} = \left[1 - (1 - R)^2 \right]^2 = \left[1 - (1 - 2R + R^2) \right]^2 = (2R - R^2)^2.$$

Considerando a redundância de alto nível, a confiabilidade é:

$$R_{\text{alto}} = 1 - (1 - R^2)^2 = 1 - (1 - 2R^2 + R^4) = 2R^2 - R^4.$$

Adicionalmente, a Tabela 4 apresenta uma comparação entre os valores de confiabilidade obtidos para esses dois exemplos, considerando redundância de baixo e alto nível. É possível notar que, quando a confiabilidade dos componentes (R) é maior, a diferença de confiabilidade computada para esses sistemas redundantes distintos é reduzida.

Tabela 4 – Comparação de confiabilidade entre redundâncias de baixo e alto nível.

<i>R</i>	baixo nível	alto nível	diferença
0,8	0,921600000000	0,870400000000	0,051200000000
0,9	0,980100000000	0,963900000000	0,016200000000
0,99	0,999800010000	0,999603990000	0,000196020000
0,999	0,999980000001	0,99996003999	0,000001996002
0,9999	0,99999980000	0,99999960004	0,000000019996

2.8 ANÁLISE DE SENSIBILIDADE

O termo análise de sensibilidade refere-se a uma investigação sistemática da reação das respostas de simulação diante de valores extremos nas entradas do modelo ou de alterações significativas na estrutura do modelo (KLEIJNEN, 1995). Segundo (FRANK, 1978), é um conjunto de métodos empregados para identificar os componentes que mais influenciam uma métrica específica.

A análise de sensibilidade ainda não possui uma definição padronizada. Crick e Hill (CRICK; HILL, 1987) destacam que as técnicas empregadas podem ser classificadas em dois tipos principais: parâmetros importantes, cuja incerteza contribui significativamente para a variação nos resultados, e parâmetros sensíveis, que exercem uma influência marcante nos resultados da avaliação. Existem várias técnicas descritas na literatura para a verificação da sensibilidade, e cada uma pode gerar resultados diferentes.

Durante a análise, o analista classifica os parâmetros de entrada de acordo com sua sensibilidade em relação à métrica avaliada, identificando aqueles que são mais significativos. A identificação dos parâmetros que lideram essa lista é fundamental. Por outro lado, as diferenças na classificação dos parâmetros de menor importância entre diferentes técnicas de análise de sensibilidade não são uma preocupação prática significativa (HAMBY, 1994).

Para a aplicação de forma objetiva de uma análise de sensibilidade, pode-se (IOOSS; LEMAÎTRE, 2015):

- Identificar e priorizar as variáveis de entrada mais influentes;
- Determinar as variáveis de entrada não influentes para fixá-las em valores nominais;
- Mapear o comportamento da métrica em relação aos valores de entrada, especificando um domínio de entrada; calibrar algumas variáveis de entrada utilizando informações já

disponíveis ou restrições do sistema.

Nesta tese, adotou-se uma técnica de análise de sensibilidade, reconhecida e utilizada por diversos estudos e, adequada à avaliação pretendida. O DoE é uma metodologia que orienta o planejamento de experimentos para fornecer resultados apropriados para análise por métodos estatísticos, permitindo conclusões objetivas (MONTGOMERY, 2017).

Os experimentos podem ser descritos como uma ou mais verificações nas quais são aplicadas mudanças nas variáveis de entrada de um sistema para analisar os impactos nas variáveis de saída (MONTGOMERY; RUNGER, 2020). Na técnica DoE, "fator" se refere a uma variável controlável que afeta o resultado. Os valores atribuídos a esses fatores são denominados "níveis", e as variações nas médias dos resultados são chamadas de "efeitos" (MASON; GUNST; HESS, 2003).

Outro ponto essencial no DoE é avaliar os efeitos das interações entre os fatores, ou seja, como diferentes níveis de fatores se combinam para influenciar o resultado final. O design fatorial é uma abordagem comum do DoE, eficiente para experimentos com dois ou mais fatores. Quando os fatores são combinados em um design fatorial, eles são considerados cruzados, permitindo uma análise abrangente das interações entre os fatores.

Tabela 5 – Exemplo de fatores e seus respectivos níveis para um experimento de dois fatores.

Fator B		
Fator A	B_{baixo}	B_{alto}
A_{baixo}	x_1	y_1
A_{alto}	x_2	y_2

O efeito é identificado pela mudança na resposta causada pela alteração do nível de um fator. Essa técnica evita conclusões equivocadas ao considerar as interações entre os fatores, permitindo que o efeito de um fator seja estimado em diferentes níveis de outros fatores (MONTGOMERY, 2017). Quando o efeito está relacionado aos principais fatores do estudo, ele é denominado efeito principal. A Tabela 5 ilustra um exemplo de experimento fatorial com dois fatores (A e B) nos níveis (A_{baixo} , A_{alto} , B_{baixo} , B_{alto}). O efeito principal é a diferença entre a média dos níveis mais altos e mais baixos de cada fator, conforme demonstrado nas Equações 2.17 e 2.18.

$$A = \frac{x_1 + y_1}{2} - \frac{x_2 + y_2}{2} \quad (2.17)$$

$$B = \frac{x_1 + x_2}{2} - \frac{y_1 + y_2}{2} \quad (2.18)$$

A interação entre os fatores (A) e (B) pode ter um impacto significativo. No entanto, em certos casos, a diferença entre os níveis de um fator não corresponde aos níveis do outro fator. Isso pode resultar em uma interação substancial entre eles. A Equação 2.19 descreve esse efeito de interação, onde (A e B) representam a diferença média na diagonal. Em outras palavras, é a metade da diferença entre os efeitos do fator (A) nos dois níveis do fator (B).

A análise dos efeitos principais e suas interações pode fornecer informações importantes sobre o comportamento do sistema. Neste estudo, para avaliar a sensibilidade dos resultados dos experimentos com os modelos, utilizou-se a classificação dos efeitos, que revelou o tamanho e a direção da relação entre os fatores e as métricas avaliadas.

$$AB = \frac{x_2 + y_2}{2} - \frac{x_1 + y_1}{2} \quad (2.19)$$

2.9 CONSIDERAÇÕES FINAIS

Este capítulo apresentou os conceitos fundamentais necessários para o entendimento deste trabalho. Inicialmente, expôs-se o conceito de IoT, destacando sua relevância. Em seguida, abordou-se IoMT; além de uma visão geral e dos benefícios dessa tecnologia, ressaltou-se a influência de seus elementos sobre o desempenho e a disponibilidade.

Na sequência, foram descritos os aspectos de desempenho e de dependabilidade, essenciais para as avaliações realizadas nesta proposta de tese e para trabalhos futuros. Para apoiar a modelagem concebida, apresentaram-se os formalismos CTMC, PN e SPN. Na continuidade, foram introduzidos os conceitos de RBD. Foram revisados os princípios da análise de sensibilidade. Por fim, foram apresentados os conceitos para quantificar o custo de sistemas IoMT e uma breve explicação sobre a importância da disponibilidade.

3 TRABALHOS RELACIONADOS

Este capítulo apresenta trabalhos relacionados na literatura cuja proposta envolve soluções para sistemas IoT e IoMT. Esses estudos foram organizados em seções que destacam aspectos de desempenho, disponibilidade e custo. Ao final, realiza-se uma comparação entre as abordagens encontradas e a proposta deste trabalho.

3.1 VISÃO GERAL

Os sistemas IoMT constituem uma plataforma para monitoramento e apoio ao cuidado de pacientes. Esses sistemas integram dispositivos e sensores médicos, favorecendo o acompanhamento clínico e a coordenação do tratamento, com reflexos na segurança do paciente e na eficiência operacional. Mecanismos de automação permitem ajustar dinamicamente parâmetros de monitoramento conforme as necessidades do paciente, o que contribui para a qualidade assistencial. Além disso, a coleta em tempo real fornece insumos para análises clínicas e decisões informadas pelas equipes de saúde. Observa-se, nos últimos anos, um crescimento de estudos que avaliam desempenho e disponibilidade em IoT e IoMT.

3.2 DISPONIBILIDADE

As distintas demandas por sistemas IoT têm ampliado os desafios relacionados à disponibilidade e à segurança, considerando diferentes aspectos, como a coleta e a transmissão contínuas de dados, a diversidade de dispositivos, as limitações de processamento e energia, a conectividade e a interoperabilidade entre componentes heterogêneos. Shen et al. (SHEN et al., 2022) propõem um mecanismo de avaliação de disponibilidade para IoT com apoio de computação em névoa (*fog computing*). O núcleo da proposta é um modelo em cadeias de Markov que incorpora estados de infecção por *malware* e transições de recuperação, permitindo estimar a fração de tempo em que o serviço permanece operacional sob diferentes taxas de ataque e políticas de contenção. Os autores discutem cenários com variação de carga e de parâmetros de confiabilidade dos nós de névoa, evidenciando que acelerar detecção e reparo reduz o impacto de propagação de falhas lógicas.

Santos et al. (SANTOS et al., 2022) investigam o uso de computação em névoa e de *fog* em

IoT, com o objetivo de maximizar a disponibilidade no contexto de IoMT. O trabalho combina modelos estocásticos de disponibilidade com algoritmos de otimização para selecionar quantidades e posicionamento de componentes de borda e de névoa. Três heurísticas são comparadas quanto ao valor de disponibilidade obtido e ao tempo de convergência. Os resultados sugerem que a alocação distribuída de recursos próximos às fontes de dados atenua pontos únicos de falha e melhora a continuidade do serviço.

Marcozzi et al. (MARCOZZI et al., 2023) apresentam modelos em cadeias de Markov em tempo contínuo para arquiteturas IoT tolerantes a falhas, com blocos de redundância ativa e comutação de reserva. São exploradas configurações série, paralelo e mistas, e calculadas medidas de disponibilidade e indisponibilidade em regime permanente. A análise evidencia ganhos consistentes quando há diversidade de componentes e tempos de reparo reduzidos.

Rahmani et al. (RAHMANI; HOSSEINI, 2022) propõem um método de detecção de falhas para IoMT com redes neurais. Diante de falha em um nó, o mecanismo identifica servidores operacionais e realoca o processamento para o *cluster* ativo, de forma a restabelecer o serviço. O trabalho detalha a arquitetura de decisão, os indicadores monitorados e o fluxo de migração. Embora apresente ganhos na continuidade do serviço, não há análise de sensibilidade para identificar quais parâmetros influenciam mais a recuperação, o que limita a priorização de melhorias.

Santos et al. (SANTOS et al., 2020) descrevem um algoritmo de otimização multiobjetivo apoiado em modelos estocásticos para avaliar o efeito de falhas em um sistema de e-saúde. O procedimento busca compromissos entre disponibilidade e outros requisitos, explorando soluções eficientes e discutindo impactos de diferentes políticas de manutenção. A avaliação é conduzida por simulação e por solução numérica dos modelos, com boa aderência entre os resultados.

Nguyen et al. (NGUYEN et al., 2021b) propõem uma modelagem hierárquica para infraestruturas IoMT, combinando árvores de falhas e cadeias de Markov. A arquitetura avaliada integra nuvem e borda com múltiplos pontos de aquisição de dados. O encadeamento entre modelos permite estimar eventos iniciadores, cortes mínimos e métricas de disponibilidade sob diferentes hipóteses de independência. A abordagem explicita dependências estruturais entre camadas, embora não incorpore métricas de desempenho no mesmo quadro analítico.

Andrade et al. (ANDRADE et al., 2021) apresentam uma avaliação com SPN para IoT com computação em névoa e nuvem, analisando tempo de resposta e disponibilidade em cenários com variação de carga e de recursos. Os resultados indicam influência acentuada

dos componentes de névoa sobre a disponibilidade, pois concentram etapas críticas de pré-processamento. O trabalho, no entanto, não se debruça sobre requisitos específicos de IoMT, o que abre oportunidade de especialização para contextos clínicos.

Lima et al. (LIMA et al., 2024) propõem SPN para análise de recuperação de desastres em IoMT, com foco em identificar os componentes mais relevantes para restaurar o serviço após eventos de grande impacto. O modelo considera tempos de comutação, janelas de indisponibilidade e prioridades de restauração. Os resultados auxiliam a elaborar planos de contingência e a ordenar investimentos em disponibilidade.

Lisboa et al. (LISBOA et al., 2018) propõem uma arquitetura de monitoramento em e-health que utiliza sensores com suporte de nuvem e névoa para analisar a disponibilidade do sistema. O estudo emprega modelos estocásticos para avaliar o impacto de falhas e considera quatro cenários distintos, mostrando que sensores e dispositivos de névoa exercem influência marcante sobre a disponibilidade. A análise de sensibilidade indica que a combinação névoa e nuvem sustenta níveis elevados de disponibilidade.

Silva et al. (SILVA et al., 2022) apresentam modelos em redes de Petri estocásticas para estimar a disponibilidade de redes de sensores sem fio em hospitais inteligentes, considerando falhas de energia e de servidor. Três variantes de modelo são avaliadas, incluindo cenários com redundância de energia e rejuvenescimento de servidor. Os resultados apontam configuração com disponibilidade de 99,64% e redução de 21 horas anuais de indisponibilidade quando comparada ao pior caso. A análise de sensibilidade destaca fonte de alimentação e envelhecimento do servidor como componentes críticos.

3.3 DESEMPENHO

Mallick et al. (MALLICK et al., 2022) apresentam um *framework* baseado em *blockchain* para IoMT que visa reduzir uso de largura de banda e tempo de processamento quando há computação em névoa. A camada de névoa desloca etapas de processamento para a borda, reduzindo tráfego para servidores centrais, enquanto o *blockchain* registra transações e permite auditoria de dados sensíveis. O estudo de caso por simulação indica redução de latência sob taxas de chegada elevadas, e discute o custo computacional do mecanismo de consenso, o que sugere cuidado na escolha de parâmetros de rede.

Santos et al. (SANTOS et al., 2021) utilizam SPN para avaliar sistemas IoT em nuvem, com foco na taxa de transferência. Apesar do foco principal ser desempenho, o formalismo escolhido

favorece a inclusão de falhas e reparos como extensões, o que os autores apontam como caminho para incorporar disponibilidade em trabalhos futuros. O estudo oferece parâmetros de serviço de nuvem que são úteis como referência para calibração de modelos híbridos.

Silva et al. (SILVA et al., 2021) propõem uma rede de filas M/M/c/K para uma infraestrutura Internet das Coisas na Saúde (IoHT) em três camadas (nuvem, névoa e borda), explorando regimes de ocupação, bloqueio por capacidade finita e tempos médios de resposta. O modelo permite comparar configurações de capacidade por camada, evidenciando ganhos quando há balanceamento entre borda e nuvem para cargas variáveis.

El Kafhali et al. (KAFHALI; SALAH, 2019) analisam sistemas IoT com filas M/M/c/K sob comunicação *publish/subscribe* e medem impacto do *broker* no tempo de resposta. Os experimentos mostram que a capacidade e a política do *broker* determinam gargalos sob rajadas de publicação, o que sugere replicação ou particionamento do tópico como contramedida. O estudo busca estimar recursos mínimos para cumprir metas de latência.

Rodrigues et al. (RODRIGUES et al., 2021) utilizam SPN para avaliar tempo de resposta, utilização e taxa de descarte em um sistema IoMT, além de propor um submodelo de disponibilidade e conduzir análise de sensibilidade. As avaliações são separadas, e o submodelo de disponibilidade ainda necessita de validação com dados reais, mas o trabalho já indica quais parâmetros operacionais mais afetam cada métrica.

Djahafi et al. (DJAHAFI; SALMI, 2023) adotam redes de Petri estocásticas para estudar IoT com comunicação *publish/subscribe*, considerando tempos de enfileiramento e serviço no *broker*. A análise mostra que o *broker* se torna elemento de maior influência quando a taxa de publicação cresce mais rápido que a de consumo, sugerindo escalonamento horizontal e controle de *backpressure*.

Ghosh et al. (GHOSH; SAHA; MISRA, 2022) descrevem uma arquitetura IoMT para enlaces com largura de banda limitada, onde um mecanismo de aprendizado de máquina redireciona o processamento para a névoa quando o paciente está em condição crítica. Os testes apontam redução de latência no acompanhamento contínuo, com prioridade para eventos clínicos relevantes, sem saturar o enlace de retorno.

Nakayama et al. (NAKAYAMA; LENZ; NOGUEIRA, 2022) propõem uma arquitetura de comunicação para sistemas IoMT a fim de garantir a continuidade do serviço para pacientes que precisam ser transportados para outra instalação. A arquitetura foca em aumentar a confiabilidade da comunicação e atender às restrições de desempenho. Os autores discutem cenários de mobilidade e perda intermitente de conexão.

Nguyen et al. (NGUYEN et al., 2021a) apresentam análise com redes de recompensa estocásticas para medir efeito de balanceamento de carga no desempenho de sistemas de informação médica. A abordagem permite associar estados do sistema a recompensas, como taxa de processamento, e estimar medidas de longo prazo sob diferentes políticas de distribuição de requisições.

Gupta et al. (GUPTA; CHAURASIYA, 2022) propõem arquitetura IoT baseada em névoa para monitoramento de pacientes, usando redes Bayesianas para reduzir tempo de resposta por meio de inferência local. A avaliação compara a solução com uma abordagem similar apoiada apenas em nuvem, indicando ganhos de latência quando parte do processamento é mantida próximo às fontes de dados.

Ezhilarasi et al. (EZHILARASI et al., 2023) apresentam *framework* em três camadas (IoT, névoa e armazenamento em nuvem) para serviços de saúde, com foco em melhorar a utilização de recursos. O estudo discute políticas de orquestração e direcionamento de tarefas, mostrando cenários em que a distribuição ajustada de carga entre camadas reduz tempos médios de serviço sem sobrecarregar enlaces.

Dighriri (DIGHRIRI, 2023) propõe uma solução de monitoramento remoto em IoMT com processamento na borda, integrando duas aplicações para avaliar a condição clínica em tempo quase real. O foco é reduzir uso de largura de banda e consumo de energia. Em simulação, o método reduz o tráfego em 99% e o consumo de energia em 92% frente a abordagens de referência.

Ilyas et al. (ILYAS et al., 2023) apresentam uma abordagem bidirecional para aprimorar transmissão em tempo real em IoT para saúde, minimizando latência e otimizando uso de rede por meio da seleção eficiente de conexões sensor–gateway e da alocação de tarefas no nó de névoa. Avaliado no iFogSim, o método melhora uso de rede e latência em cerca de 20% a 25% em relação a técnicas existentes.

Khan et al. (KHAN et al., 2022) tratam a alocação dinâmica de recursos e o balanceamento de carga em arquiteturas IoT. O algoritmo, avaliado no iFogSim, supera métodos comparados com reduções de 45% em atraso, 37% em consumo de energia e 25% em uso de banda.

Rocha et al. (ROCHA et al., 2024) propõem um modelo SPN para avaliar a performabilidade de uma arquitetura IoMT multinível com camadas de borda, névoa e nuvem. O modelo estima tempo médio de resposta considerando parâmetros que influenciam a disponibilidade de contêineres e a capacidade de processamento em nuvem. Os resultados mostram que ampliar recursos na nuvem reduz tempo de resposta e taxa de descarte, elevando o desempenho global.

Ilyas et al. (ILYAS et al., 2022) descrevem uma arquitetura híbrida para IoT em saúde com camadas de dispositivo, névoa e nuvem, visando reduzir latência e uso de rede por meio de seleção ótima de nós de névoa, balanceamento dinâmico e alocação de tarefas. Em simulação, os esquemas *Efficient Scanning Mechanisms* (ESMs) e *Load Balancing scheme for Real-Time monitoring data* (LBRT) apresentam ganhos expressivos frente às abordagens correntes.

Hassan et al. (HASSAN et al., 2020) propõem um sistema de monitoramento remoto com computação em névoa para reduzir latência e uso de rede em IoMT. Sinais Eletromiografia de Superfície (sEMG) e ECG são coletados e processados em tempo real, e a avaliação no iFogSim mostra diminuições de latência, tráfego e custo de execução em comparação a arquiteturas exclusivamente em nuvem.

Said e Tolba (SAID; TOLBA, 2021) apresentam uma arquitetura IoMT de larga escala que integra satélites, plataformas de alta altitude e Internet para ampliar cobertura, adotando técnicas de clusterização e priorização de dados. Em simulação com Network Simulator 3 (NS3), os autores reportam reduções de atraso, energia e perda de pacotes, além de incrementos de vazão e de usuários atendidos.

3.4 CUSTO

Dewanti et al. (DEWANTI; SINGGIH, 2019) propõem um modelo de manutenção baseada em condição (CBM) utilizando IoT para reduzir custos em sistemas industriais. O método estima a vida útil remanescente (RUL) por meio de processos gama para orientar decisões de manutenção. Três configurações foram analisadas: sem IoT, com IoT e paradas fixas, e com IoT adaptativa, caracterizada pelo ajuste dinâmico das decisões operacionais com base na degradação observada. As métricas de custo incluem implementação (*hardware*, *software*, infraestrutura de dados) e manutenção (reparo, perda de material, mão de obra, monitoramento e decisões orientadas por dados). Os resultados mostram que a IoT adaptativa reduz manutenções desnecessárias, diminui o custo total e aumenta a produtividade.

Kalmar (KALMAR; KERTESZ, 2018) compara os custos operacionais de aplicações IoT em nuvem utilizando quatro provedores: Azure, Bluemix, AWS e Oracle. O método inclui análise de modelos de precificação e simulação de um cenário de cidade inteligente com controle de semáforos. A validação foi realizada na plataforma IBM Bluemix. As métricas de custo avaliadas referem-se à implementação (número de dispositivos), operação (mensagens enviadas) e infraestrutura (memória, CPU e tempo de uso). Os resultados indicam que Bluemix e AWS

são as opções mais econômicas, enquanto a Oracle apresenta os maiores custos.

Evdokimov et al. (EVDOKIMOV et al., 2019) analisam a estimativa de custos de projetos IoT na fase de projeto, utilizando estimativa paramétrica com os modelos *Constructive Cost Model* (COCOMO) e Pontos de Caso de Uso. O COCOMO calcula custos com base em parâmetros históricos de projetos anteriores, enquanto Pontos de Caso de Uso avaliam casos de uso e fatores técnicos e ambientais, como complexidade e tipo de atores envolvidos. A técnica *Program Evaluation and Review Technique* (PERT) foi aplicada para estimar custos, considerando cenários otimista, pessimista e mais provável. As métricas avaliadas incluem custos de implementação e operação, com ênfase em como a quantidade de dados impacta custos de segurança e manutenção do sistema. Os resultados indicam que os custos são influenciados pela escalabilidade e pela complexidade do projeto; foram usados dados da plataforma Microsoft Azure, incluindo preços de armazenamento e serviços em nuvem.

Jassim et al. (JASSIM et al., 2024) analisam a viabilidade econômica da integração de dispositivos IoT em redes 5G, considerando aspectos técnicos e financeiros. O estudo emprega análise de custo-benefício apoiada pela ferramentas SWOT e dados setoriais. As métricas avaliadas incluem despesas de capital (CapEx), despesas operacionais (OpEx), custos de manutenção, consumo de energia e retorno sobre o investimento (ROI). Os resultados mostram que, embora o investimento inicial seja elevado, há redução significativa dos custos operacionais e de manutenção em setores como cidades inteligentes e saúde. Além disso, o ROI pode superar 40% em áreas como automação industrial. O estudo destaca que a eficiência econômica depende da escala de implantação, dos casos de uso específicos e de políticas regulatórias favoráveis.

3.5 COMPARAÇÃO DOS TRABALHOS RELACIONADOS

As Tabelas 6 e 7 apresentam um resumo comparativo dos trabalhos relacionados em relação a esta tese. A tabela permite contrastar as estratégias de análise e as métricas de interesse de cada estudo. Além disso, indica quais trabalhos avaliam simultaneamente o desempenho e a disponibilidade (coluna *Performabilidade*). Na coluna *Estratégia*, registra-se o formalismo aplicado (p. ex., Cadeias de Markov, SPN, RBD) para o cálculo das métricas. Na coluna *Métricas*, destacam-se os indicadores analisados em cada estudo, como disponibilidade, tempo de resposta e *throughput*, e por fim na coluna *Custo* apresento os trabalhos que analisaram os aspectos financeiros das arquiteturas. A abordagem proposta busca auxiliar projetistas a com-

parar configurações considerando a disponibilidade e o desempenho antes da implementação efetiva da infraestrutura.

Os trabalhos foram classificados de acordo com os principais aspectos abordados para tratar da disponibilidade, do desempenho e do custo em sistemas IoMT. A maioria foca exclusivamente na estimativa de disponibilidade (SHEN et al., 2022; SANTOS et al., 2022; MARCOZZI et al., 2023; RAHMANI; HOSSEINI, 2022; NGUYEN et al., 2021b; SANTOS et al., 2021; ANDRADE et al., 2021; LIMA et al., 2024; LISBOA et al., 2018; SILVA et al., 2022) ou exclusivamente em desempenho (MALLICK et al., 2022; KAFHALI; SALAH, 2017; SILVA et al., 2021; KAFHALI; SALAH, 2019; DJAHAFI; SALMI, 2023; GHOSH; SAHA; MISRA, 2022; NAKAYAMA; LENZ; NOGUEIRA, 2022; GUPTA; CHAURASIYA, 2022; EZHILARASI et al., 2023; DIGHRIRI, 2023; ILYAS et al., 2023; KHAN et al., 2022; ILYAS et al., 2022; HASSAN et al., 2020; SAID; TOLBA, 2021). Por outro lado, um conjunto menor realiza a avaliação conjunta de disponibilidade e desempenho (NGUYEN et al., 2021a; RODRIGUES et al., 2021; ROCHA et al., 2024). É importante destacar que nenhum desses trabalhos realizou uma avaliação de forma integrada e nem fez uma análise de forma simultânea da capacidade de processamento.

Adicionalmente, há uma linha específica dedicada à análise de custos em sistemas IoT, que inclui modelos de manutenção baseada em condição e comparativos de precificação de nuvem (DEWANTI; SINGGIH, 2019; KALMAR; KERTESZ, 2018), bem como estimativas paramétricas em fase de projeto e estudos de viabilidade econômica para integrações em redes 5G (EVDOKIMOV et al., 2019; JASSIM et al., 2024). Esses trabalhos priorizam métricas financeiras como CapEx, OpEx, consumo de energia e ROI, sem realizar avaliação integrada de performance. Observa-se, ainda, que avaliações integradas permanecem menos frequentes e, quando presentes, nem sempre incluem validação em *testbed* real; entre as que consideram explicitamente a capacidade de processamento na análise, destacam-se abordagens baseadas em SPN voltadas à camada de nuvem (ROCHA et al., 2024).

Diferentemente desses estudos, esta tese propõe uma modelagem integrada baseada em SPN e RBD para avaliar, de forma simultânea, o desempenho e a disponibilidade em IoMT com suporte de nuvem privada. São consideradas arquiteturas alternativas e cenários variados, incluindo variações da capacidade de processamento dos dispositivos que compõem o sistema. Realiza-se, também, análise de sensibilidade para destacar os componentes de maior impacto nas métricas avaliadas. Em complemento, esta tese incorpora um modelo de estimativa de custos que decompõe despesas da camada IoT e da infraestrutura de nuvem, permitindo contrastar decisões de engenharia sob restrições financeiras e preencher a lacuna entre estudos

puramente técnicos de performabilidade e investigações focadas apenas em custo. Por fim, os modelos propostos são validados por meio de medições em arquiteturas IoMT reais.

Tabela 6 – Comparação entre este trabalho e trabalhos relacionados (Parte 1 de 2)

Autor	Estratégia	Métricas	Performabilidade	Custo
(SHEN et al., 2022)	Cadeias de Markov	Disponibilidade	Não	Não
(SANTOS et al., 2022)	SPN e otimização	Disponibilidade	Não	Não
(MARCOZZI et al., 2023)	Cadeias de Markov	Disponibilidade	Não	Não
(RAHMANI; HOSSEINI, 2022)	Aprendizado de máquina	Disponibilidade	Não	Não
(SANTOS et al., 2020)	Modelos estocásticos + otimização	Disponibilidade	Não	Não
(NGUYEN et al., 2021b)	Árvore de falhas + Markov	Disponibilidade, Segurança	Não	Não
(SANTOS et al., 2021)	SPN	Throughput	Não	Não
(ANDRADE et al., 2021)	SPN	Tempo de resposta, Disponibilidade	Não	Não
(LIMA et al., 2024)	SPN	Disponibilidade, Recuperação de desastres	Não	Não
(MALLICK et al., 2022)	Simulação + <i>Blockchain</i>	Latência, Largura de banda	Não	Não
(SILVA et al., 2021)	Filas M/M/c/K	Tempo de resposta	Não	Não
(KAFHALI; SALAH, 2019)	Filas M/M/c/K	Tempo de resposta	Não	Não
(RODRIGUES et al., 2021)	SPN	Tempo de resposta, Utilização, Descarte	Sim	Não
(DJAHAFI; SALMI, 2023)	SPN	Tempo de resposta	Não	Não
(GHOSH; SAHA; MISRA, 2022)	Aprendizado de máquina + névoa	Latência	Não	Não
(NAKAYAMA; LENZ; NOGUEIRA, 2022)	Simulação	Manutenção de sessão, Throughput	Não	Não
(NGUYEN et al., 2021a)	Redes de recompensa estocásticas	Tempo de resposta, Throughput	Sim	Não

Tabela 7 – Comparação entre este trabalho e trabalhos relacionados (Parte 2 de 2)

Autor	Estratégia	Métricas	Performabilidade	Custo
(GUPTA; CHAURASIYA, 2022)	Medição + Redes Bayesianas	Tempo de resposta	Não	Não
(EZHILARASI et al., 2023)	Medição	Tempo de resposta, Utilização	Não	Não
(DIGHRIRI, 2023)	Simulação na borda	Largura de banda, Energia	Não	Não
(ILYAS et al., 2023)	Simulação iFogSim	Latência, Uso de rede	Não	Não
(KHAN et al., 2022)	Simulação iFogSim	Atraso, Energia, Largura de banda	Não	Não
(ROCHA et al., 2024)	SPN	Tempo de resposta, Descarte	Sim	Não
(LISBOA et al., 2018)	Modelos estocásticos	Disponibilidade	Não	Não
(SILVA et al., 2022)	SPN	Disponibilidade	Não	Não
(ILYAS et al., 2022)	Simulação	Latência, Uso de rede	Não	Não
(HASSAN et al., 2020)	Simulação iFogSim	Latência, Uso de rede, Custo	Não	Não
(SAID; TOLBA, 2021)	Simulação NS3	Atraso, Energia, Perda, Throughput, Cobertura	Não	Não
(DEWANTI; SINGGIH, 2019)	IoT + Manutenção baseada em condição (CBM) + processos Gama (RUL)	Custo (implementação, manutenção), Produtividade	Não	Sim
(KALMAR; KERTESZ, 2018)	Análise de provedores de nuvem + simulação de cenário	Custo (operação, infraestrutura)	Não	Sim
(EVDOKIMOV et al., 2019)	Estimativa paramétrica (COCOMO) Use Case Points, (PERT)	Custo (implementação, operação)	Não	Sim
(JASSIM et al., 2024)	Análise custo-benefício IoT em 5G (SWOT e dados setoriais)	CapEx, OpEx, Energia, ROI	Não	Sim
Este trabalho	SPN, RBD, CTMC	Disponibilidade, Tempo de resposta e Vazão	Sim	Sim

3.6 CONSIDERAÇÕES FINAIS

Este capítulo apresentou os principais trabalhos relacionados ao tema proposto. Nosso modelo SPN proposto assume um sistema IoMT em uma nuvem privada, considerando os componentes de *software* e *hardware* que compõem a arquitetura (por exemplo, máquina virtual, microcontrolador e sensor). Nossa proposta analisa a interação entre os dispositivos IoMT para estimar conjuntamente o tempo de resposta, a disponibilidade do sistema e o custo.

Além disso, apesar de haver trabalhos que se dedicam à avaliação de disponibilidade ou desempenho individualmente, poucos propõem uma modelagem que aborde simultaneamente essas duas dimensões, além do custo do sistema IoMT. Realizou-se, também, uma análise de sensibilidade para indicar os componentes com maior impacto no desempenho e na disponibilidade do sistema. A proposta também sugere modificações na arquitetura para melhorar a disponibilidade e o tempo de resposta.

As Tabelas 6 e 7 resumem os trabalhos relacionados e apresentam as características da abordagem desta tese. Apresenta-se, nessas tabelas, um comparativo com o intuito de permitir avaliar as diferenças existentes entre este trabalho e contribuições anteriores. Destaca-se que a ausência de modelos matemáticos validados é uma característica predominante nos trabalhos citados, e, adicionalmente, esta tese considera a dimensão de custo das soluções, consolidando uma estimativa separada para despesas de IoT e de nuvem a fim de orientar escolhas de redundância e capacidade sob restrições orçamentárias.

4 METODOLOGIA

Este capítulo descreve a metodologia adotada para a modelagem de custo, disponibilidade e desempenho de sistemas IoMT. Para alcançar esses objetivos, foi estruturado um processo que integra a concepção de modelos, a validação e a experimentação, apoiado por técnicas e ferramentas. A seguir, detalham-se as etapas da metodologia.

A metodologia tem por finalidade articular a criação dos modelos a partir da realização de experimentos de validação e da análise de sensibilidade, de modo a avaliar as métricas de interesse em sistemas IoMT. A partir desses modelos, obtêm-se resultados que auxiliam na seleção de configurações mais adequadas para o sistema em estudo.

As etapas são apresentadas de forma sequencial para orientar a proposição dos modelos e sua validação, com foco na estimativa da disponibilidade e desempenho. O método também fornece suporte ao projetista do sistema na escolha de configurações compatíveis com os níveis de serviço desejados. A proposta é acessível a leitores com conhecimento introdutório em modelagem de sistemas nos formalismos SPN, RBD e CTMC, aplicados ao projeto de soluções IoMT.

As métricas podem ser avaliadas isoladamente ou de forma integrada. Exemplos de métricas consideradas neste trabalho são: (i) tempo de resposta, definido como o intervalo entre a solicitação e a entrega de uma resposta completa; (ii) disponibilidade, correspondente à probabilidade de que o sistema esteja operacional; e (iii) custo, relacionado às demandas de implantação, operação e manutenção do sistema, incluindo aspectos financeiros, infraestrutura, equipamentos e recursos necessários para seu funcionamento.

A Figura 17 mostra as etapas adotadas na metodologia. Nessa figura, estão presentes as fases de concepção, configuração do sistema, modelagem, experimentação, análise dos resultados e refinamento do modelo. O processo está organizado em blocos principais, que sintetizam cada fase, e em blocos auxiliares, que detalham as atividades específicas. Essa estrutura modular facilita a compreensão do fluxo, a visualização do progresso e o acompanhamento sistemático da execução. A seguir, cada fase da metodologia será descrita em detalhes.




Figura 17 – Metodologia

4.1 CONCEPÇÃO INICIAL

A concepção corresponde às atividades de entendimento do sistema e de definição das métricas a serem avaliadas. Na fase de entendimento, o foco é compreender a aplicabilidade e o relacionamento entre os dispositivos que compõem um sistema IoMT. Além disso, essa fase também busca identificar lacunas a partir da revisão da literatura, definir os objetivos da pesquisa e estabelecer os contextos teórico e prático do estudo. Também se definem parâmetros e métricas que representam atributos relevantes para os requisitos do sistema avaliado. O resultado esperado é uma formulação clara e precisa do problema de pesquisa, que servirá de base para as etapas subsequentes.

4.1.1 Entendimento do sistema

Esta atividade busca compreender o sistema IoMT em análise. O escopo inclui a identificação de componentes (sensores, dispositivos de monitoramento, *gateways*, protocolos e serviços de comunicação) e de recursos de suporte (plataformas em nuvem e serviços de borda). Também são levantados requisitos técnicos, tais como capacidade de processamento, armazenamento de dados e conectividade de rede, além de premissas e restrições operacionais que influenciam o projeto e a avaliação do sistema.

4.1.2 Definição das métricas de interesse

Nesta atividade, definem-se as métricas que serão usadas para avaliar o desempenho, a disponibilidade e o custo do sistema IoMT. A seleção é guiada pelos objetivos do estudo e pelos requisitos de nível de serviço, priorizando indicadores objetivamente mensuráveis e comparáveis ao longo do tempo.

Consideram-se, tipicamente, métricas de desempenho, como: (i) tempo de resposta e (ii) vazão. Para disponibilidade e confiabilidade, incluem-se: (iii) disponibilidade operacional, MTTF e (iv) MTTR. Adicionalmente, adota-se a métrica de custo: (v) custo total estimado, que agrega despesas de aquisição, operação e manutenção ao longo do período de análise.

Para cada métrica, são especificadas a definição operacional, o método de medição e a estratégia de coleta (fontes, frequência, janelas de observação e tratamento de *outliers*), assegurando a reprodutibilidade. Estabelecem-se, ainda, valores de referência (*baseline*) e metas

de comparação, de modo a permitir a análise longitudinal e entre configurações.

4.2 CONFIGURAÇÃO DO SISTEMA

A configuração do sistema corresponde às atividades de preparação do ambiente experimental e de coleta de dados. Nessa fase, aplicam-se os conceitos teóricos na prática para construir o ambiente de experimentação, o que envolve a configuração de *hardware* e *software*, a integração de componentes e a instrumentação de medição. A etapa busca assegurar condições controladas e reprodutíveis, de modo a produzir dados confiáveis para análise.

Esta seção está organizada em duas atividades: (i) configuração do ambiente, que abrange a definição da arquitetura, a parametrização dos componentes e a calibração dos sensores, e (ii) coleta de dados, que descreve procedimentos, janelas de observação, frequência de amostragem e protocolos de registro.

Quando o objetivo do projetista for apenas modelar o sistema, sem executar experimentos no ambiente real, é possível seguir diretamente para a modelagem e para o planejamento dos cenários analíticos, omitindo as fases de configuração do sistema e de validação empírica. Nesses casos, os parâmetros devem ser obtidos de fontes confiáveis, claramente documentados e acompanhados das devidas hipóteses e limitações.

4.2.1 Configuração experimental do sistema

Nesta atividade, realiza-se a configuração do sistema IoMT. O escopo abrange o *hardware*, *software* e a infraestrutura de rede necessária ao funcionamento do ambiente experimental. A configuração envolve a montagem e a parametrização dos dispositivos, a definição da arquitetura e dos domínios de rede, a instalação e versão do *software* (sistemas operacionais, *firmware*, serviços e agentes de telemetria) e a integração com plataformas de borda e nuvem.

São descritos, ainda, procedimentos de sincronização temporal, políticas de registro e retenção de *logs*, calibração de sensores e verificação de conectividade ponto a ponto. Por fim, registram-se os procedimentos de ativação do ambiente, as checagens iniciais de funcionamento (conectividade, sincronização de tempo, integridade dos sensores) e as condições de aprovação para iniciar a coleta (pontos de controle, limites e tolerâncias), assegurando a reprodutibilidade.

4.2.2 Coleta de dados

Essa etapa apresenta os métodos e procedimentos utilizados para coletar dados do sistema em funcionamento. Inclui o uso de sensores para monitorar parâmetros específicos, o registro de eventos do sistema e a captura de tráfego de rede. Além disso, coletam-se dados oriundos de estudos prévios e de avaliações de sistemas reais para orientar os modelos. Os dados reunidos são essenciais para a análise de desempenho, a avaliação da disponibilidade e a identificação de possíveis problemas no sistema.

4.3 MODELAGEM

A modelagem corresponde às atividades de criação e validação do modelo. Na fase de modelagem, criam-se representações abstratas do sistema em estudo, envolvendo o desenvolvimento de modelos formais (ex., SPN, RBD e CTMC). O objetivo da modelagem é capturar as relações entre as variáveis relevantes e prever o comportamento do sistema em diferentes configurações.

Os modelos desenvolvidos servem como instrumentos para explorar hipóteses e testar diferentes estratégias. Ainda nesta fase, os modelos são validados por meio de métodos estatísticos, verificando-se a aderência entre o sistema em funcionamento e o comportamento do modelo. Após a validação do modelo, técnicas de DoE são utilizadas para selecionar cenários de estudo e aplicá-los aos modelos desenvolvidos.

4.3.1 Criação do modelo

A etapa de criação do modelo é importante para a análise de disponibilidade, performance e custo em sistemas IoMT. Nessa fase, desenvolvem-se modelos analíticos que representam o comportamento do sistema em diferentes cenários. Esses modelos são construídos com base no entendimento do sistema, nas métricas de interesse e nos dados coletados na etapa anterior.

Além disso, consideram-se as interações entre os componentes para garantir uma representação fiel do funcionamento. O objetivo principal é criar modelos capazes de prever o comportamento do sistema em condições diversas e avaliar o impacto de mudanças na arquitetura ou na configuração sobre desempenho, disponibilidade e custo.

4.3.2 Validação do modelo

Esta etapa envolve a comparação dos resultados obtidos pelo modelo com os dados reais coletados do sistema em operação. Para isso, realizam-se simulações em ambiente controlado, considerando diferentes cenários, como a avaliação da disponibilidade do sistema. Os resultados são analisados e comparados para verificar se o modelo reproduz com precisão o comportamento do sistema real. Caso sejam identificadas inconsistências, o modelo é ajustado e refinado para melhorar sua acurácia; nesse caso, o fluxo retorna à Atividade 3. A validação do modelo é importante para assegurar que as análises subsequentes sejam confiáveis e que as conclusões obtidas sejam válidas.

4.4 EXPERIMENTAÇÃO - DESIGN OF EXPERIMENT

A etapa de experimentos corresponde às atividades de planejamento e execução, além da definição e classificação de fatores e interações. Nesta fase, conduzem-se experimentos para testar hipóteses específicas. Realiza-se o DoE e, posteriormente, executam-se os experimentos, produzindo a classificação dos fatores e suas interações. Durante os experimentos, manipulam-se as variáveis independentes e medem-se os efeitos sobre as variáveis dependentes, seguindo um protocolo experimental predefinido.

4.4.1 Planejamento de experimentos

O planejamento de experimentos é uma fase importante da metodologia, em que se definem os estudos a serem realizados para avaliar a disponibilidade, o desempenho e o custo do sistema IoMT. Nessa etapa, identificam-se os fatores que podem influenciar o desempenho do sistema, bem como os níveis a serem testados. Além disso, elaboram-se planos experimentais que determinam a ordem e a sequência de execução. O objetivo é garantir que os experimentos sejam conduzidos de forma sistemática e que forneçam dados relevantes para a análise posterior.

4.4.2 Execução dos experimentos

Esta fase envolve a realização dos experimentos de acordo com as especificações do planejamento no modelo proposto. Nessa etapa, são obtidas as saídas do modelo para avaliar a disponibilidade e o desempenho do sistema em diferentes condições. É importante garantir que os experimentos sejam conduzidos de forma consistente e controlada, para que os resultados obtidos sejam confiáveis e representativos do comportamento real do sistema.

4.4.3 Criação da classificação de fatores e interações

Após a execução dos experimentos, as medições são analisadas para determinar a importância de cada fator e suas interações nas métricas de interesse do sistema. Esta etapa envolve a elaboração de uma classificação de fatores e interações, na qual os fatores são ordenados com base em seu impacto no sistema. Os resultados são apresentados de forma objetiva, o que permite identificar os principais fatores que influenciam a disponibilidade e o desempenho do sistema.

4.5 ANÁLISE DOS RESULTADOS

A análise dos resultados corresponde às atividades de avaliação e apresentação das evidências obtidas. Na fase de análise, realiza-se a interpretação dos resultados durante os experimentos. Isso envolve a aplicação de técnicas estatísticas para identificar relações significativas nos dados. Em seguida, os resultados são comparados às hipóteses originais e discutidos à luz do contexto teórico e prático da pesquisa.

4.5.1 Avaliação dos resultados

Na fase de avaliação dos resultados, os resultados obtidos durante os experimentos são analisados de forma detalhada. Para isso, é utilizada a técnica estatística DoE, que permite a interpretação dos resultados, aplicando métodos de análise para identificar padrões e correlações relevantes. Durante essa etapa, são identificadas tendências e padrões, permitindo uma compreensão do comportamento do sistema em diferentes condições. Além disso, são avaliados os impactos dos diferentes fatores e interações no desempenho geral do sistema. Se

o resultado dessa atividade não for satisfatório, o fluxo retorna à Atividade 7.

4.5.2 Apresentação dos resultados

Esta etapa envolve a elaboração de relatórios técnicos, gráficos, tabelas e outros recursos visuais para comunicar os principais resultados e as conclusões obtidas durante o estudo. Além disso, essa etapa fornece uma base para a tomada de decisões e para o desenvolvimento de estratégias voltadas à melhoria do desempenho, da confiabilidade e do custo dos sistemas IoMT.

4.6 REFINAMENTO DO MODELO

Na fase de refinamento do modelo, aprimoram-se os modelos desenvolvidos com base nos resultados dos experimentos e nas análises realizadas. Isso pode envolver ajustes de parâmetros, revisão das interações entre componentes ou reavaliação das métricas de interesse. O objetivo é aumentar a precisão e a validade das representações do sistema.

4.6.1 Ajustes e proposição de novas arquiteturas

Na fase de ajustes e proposição de novas arquiteturas, realizam-se revisões e refinamentos no modelo com base nos resultados da validação e do planejamento de experimentos. Isso pode envolver a correção de erros, ajustes de parâmetros e a inclusão de novas variáveis que influenciem o comportamento do sistema IoMT. Complementarmente, avaliam-se alternativas estruturais para o ambiente modelado, com a possibilidade de propor novas arquiteturas, por exemplo, adicionando ou realocando redundâncias, substituindo componentes, alterando o posicionamento entre borda, agregadores e nuvem, ou mudando políticas de escalonamento. Essas alterações são analisadas quanto a disponibilidade, desempenho e custo, e, quando necessário, o fluxo retorna à Atividade 2 para nova rodada de modelagem e experimentação.

4.7 CONSIDERAÇÕES FINAIS

Este capítulo apresentou a metodologia proposta para a modelagem e a avaliação de sistemas IoMT. Inicialmente, detalharam-se os processos necessários à implementação da proposta

deste trabalho. Em seguida, descreveu-se a técnica de planejamento de experimentos, bem como os procedimentos e as técnicas estatísticas utilizadas para a avaliação de desempenho e de disponibilidade dos sistemas IoMT.

5 MODELOS PROPOSTOS

Este capítulo apresenta os modelos concebidos para representar sistemas IoMT. Esses modelos permitem a avaliação de desempenho, disponibilidade e custo. Dessa forma, a Seção 5.1 inicia com uma apresentação dos modelos concebidos. Em seguida, as métricas computadas pelos modelos são apresentadas. Além disso, também são detalhadas as limitações existentes na modelagem proposta.

A Seção 5.2 apresenta o modelo de disponibilidade proposto neste trabalho. Em seguida, são detalhados os componentes dos modelos, bem como as equações para a obtenção das métricas assumidas. Já na Seção 5.3, apresentam-se os modelos de performabilidade propostos em conjunto com as abordagens para obter os valores das métricas utilizadas. A Seção 5.4 apresenta os modelos de desempenho e disponibilidade utilizando CTMC. A Seção 5.5 apresenta os modelos estendidos de performabilidade. Cinco extensões do modelo foram propostas, e cada uma delas incorpora melhorias específicas, desenvolvidas com o objetivo de melhorar as métricas de disponibilidade, tempo de resposta e escalabilidade do modelo a fim de representar sistemas mais complexos. Por fim, a Seção 5.6 apresenta a proposta de estimativa de custos para sistemas IoMT.

5.1 CONSIDERAÇÕES INICIAIS

A arquitetura IoMT inclui aspectos como coleta de dados, processamento, armazenamento e análise de informações fisiológicas, com o objetivo de fornecer aos profissionais de saúde informações em tempo real. Esta seção detalhará os componentes principais da arquitetura, destacando sua capacidade de fornecer uma visão holística do estado de saúde do paciente e facilitar a tomada de decisões clínicas.

A seguir, serão explorados os detalhes da arquitetura IoMT, incluindo suas camadas, componentes e funcionalidades. Além disso, serão discutidos os desafios enfrentados ao projetar e implementar uma arquitetura dessa natureza, bem como as estratégias adotadas para garantir a segurança, escalabilidade e interoperabilidade do sistema. Ao final desta seção, espera-se oferecer uma compreensão da arquitetura IoMT e de seu potencial para transformar a prestação de serviços de saúde.

Uma arquitetura IoMT define um ambiente inteligente que contempla dispositivos ele-

trônicos e sensores para monitorar sinais fisiológicos de pacientes que podem ou não estar hospitalizados. A arquitetura deve permitir que os médicos acessem e analisem os dados dos pacientes em tempo real, tomando decisões mais informadas sobre o cuidado dos pacientes.

Esse ambiente inclui protocolos de comunicação, armazenamento de dados, análise de dados, ferramentas de visualização e outros componentes de *hardware* e *software* para permitir que a equipe médica monitore e gerencie remotamente a saúde do paciente. Além disso, a arquitetura pode coletar dados de várias fontes, como dispositivos vestíveis e móveis, fornecendo uma visão abrangente do estado do paciente.




Figura 18 – Arquitetura Básica IoMT

A Figura 18 representa a arquitetura IoMT adotada neste trabalho, que é baseada em (VISHNU; RAMSON; JEGAN, 2020) e possui 4 camadas. A camada do sensor é composta por sensores que são responsáveis por coletar os dados fisiológicos dos pacientes. A camada de coleta de dados é composta pelos dispositivos, como microcontroladores, que transmitem os dados obtidos pelos sensores por meio da rede pública (ou seja, a Internet). A camada de nuvem privada é responsável por armazenar os dados dos pacientes para avaliações futuras. Essa camada lida com a infraestrutura de computação em nuvem, que inclui as máquinas virtuais adotadas. Uma nuvem privada é necessária, pois os dados dos pacientes são muito sensíveis e devem ser gerenciados e armazenados com segurança pelas unidades de saúde.

Além disso, a arquitetura IoMT pode incorporar sistemas de segurança para proteger os dados dos pacientes contra acessos não autorizados e possíveis violações de privacidade. Essas medidas de segurança podem incluir criptografia de ponta a ponta, autenticação de usuário e monitoramento contínuo de atividades suspeitas na rede. Dessa forma, os profissionais de saúde podem ter a tranquilidade de que as informações confidenciais dos pacientes estão sendo adequadamente protegidas. Vale destacar que o foco deste trabalho não foi avaliar sistemas de segurança.

Uma característica importante da arquitetura IoMT é sua capacidade de escalar de forma flexível para atender às crescentes demandas de dados e usuários. À medida que mais disposi-

tivos são adicionados à rede e mais pacientes são monitorados, a arquitetura deve ser capaz de expandir dinamicamente sua capacidade de processamento, armazenamento e comunicação. Isso garante que o sistema possa lidar com o aumento da carga de trabalho sem comprometer a qualidade do serviço prestado aos pacientes.

Este trabalho propõe um modelo de desempenho no formalismo de redes de *Petri* estocásticas generalizadas. Adotou-se esse formalismo matemático para a representação de equipamentos que compõem a arquitetura IoMT por permitir que o desempenho e a disponibilidade sejam estimados por meio de análise numérica, por exemplo.

A utilização de modelagem de SPN, RBD e CTMC se mostra adequada para a análise de modelos que buscam avaliar aspectos de desempenho e disponibilidade (PETRI, 1962; BOLCH et al., 2006; REISIG, 2013; MACIEL, 2023; XIE; DAI; POH, 2004; SMITH, 2011). As SPNs representam concorrência, contenção de recursos, prioridades e guardas lógicas, o que facilita a modelagem de filas, tempos de processamento e perdas sob falhas e reparos. Contudo, usar exclusivamente SPN para explorar muitas variantes estruturais com diferentes arranjos de redundância pode levar ao crescimento do espaço de estados e à repetição de modelos semelhantes, reduzindo a praticidade na varredura rápida de alternativas arquiteturais.

A CTMC fornece uma base numérica sólida para a solução estacionária e transitória, permitindo calcular a disponibilidade como a soma das probabilidades dos estados operacionais e, quando necessário, métricas dependentes do tempo. Entretanto, modelar diretamente apenas em CTMC tende a reduzir a legibilidade de políticas de escalonamento, regras condicionais e encadeamento entre camadas, aspectos mais transparentes nas SPN. Por sua vez, os RBDs possibilitam a composição rápida de disponibilidade, cálculo de números de noves, *downtime* anual e índices de importância, além de facilitar a comparação de arquiteturas e a priorização de pontos de redundância. Em contrapartida, RBD não captura com fidelidade comportamentos dinâmicos como *standby*, compartilhamento de carga e políticas de reparo, o que motiva a análise dinâmica nas SPN.

Nesta tese, RBD é aplicado para análise estrutural e para orientar a seleção de alternativas com redundância e cálculo de importância de disponibilidade. As SPNs são utilizadas para avaliar a dinâmica fim a fim, estimando tempo de resposta, vazão e perdas sob falhas, reparos e concorrência de requisições. A CTMC é aplicada como base numérica das SPNs e também em um estudo específico, no qual o modelo markoviano é construído diretamente para estimar a disponibilidade sob diferentes configurações. Essa divisão evita limitações de cada formalismo quando usado isoladamente e permite um fluxo de trabalho eficiente: RBD para varredura e

priorização, SPN para validação dinâmica e métricas de desempenho, CTMC para solução matemática e análises complementares quando a formulação markoviana direta é conveniente.

Este trabalho adota a notação do TimeNet (ZIMMERMANN; AL., 2006), onde $E\{\#p\}$ representa o número de tokens esperados no lugar p , e $W(T)$ representa a taxa de disparo associada à transição T . Adicionalmente, a função $\eta : T_{imm} \rightarrow [0, 1]$ mapeia cada transição imediata ($t \in T_{imm}$) para um peso normalizado. Especificamente, os pesos representam a probabilidade de disparo de uma transição em um cenário (BALBO, 2001). As próximas seções apresentam os modelos adotados.

5.2 MODELO DE DISPONIBILIDADE

O desenvolvimento de um modelo de disponibilidade é importante para garantir a confiabilidade de sistemas IoMT. O modelo proposto, baseado em RBD, visa representar o funcionamento do sistema, adotando a arquitetura detalhada na Seção 5.1. Esse sistema IoMT é considerado disponível se todos os seus componentes estiverem em funcionamento. Sendo assim, o modelo RBD permite uma visualização clara de como a falha de qualquer um desses componentes pode impactar a operacionalidade do sistema como um todo. Portanto, a falha de um único componente pode levar à interrupção do sistema, tornando-o não operacional.

A Figura 19 mostra o modelo RBD desenvolvido para representar a arquitetura IoMT adotada neste trabalho. Este modelo considera as quatro camadas principais: a camada de sensores (SNS), responsável pela coleta de dados fisiológicos dos pacientes; a camada de coleta de dados (MCU), que processa e transmite os dados dos sensores; a camada de rede pública (NT), que facilita a comunicação entre os dispositivos médicos e a nuvem privada; e a camada de nuvem privada (CLD), onde os dados dos pacientes são armazenados e processados.




Figura 19 – Modelo RBD da arquitetura IoMT.

Na representação do modelo RBD, foi considerado um único componente para as camadas SNS, MCU e NT, enquanto a camada CLD é representada por um modelo mais detalhado, conforme mostrado na Figura 20. Este modelo mais detalhado inclui componentes de *hardware* (HW), um sistema operacional (OS), um hipervisor (HYP) e uma máquina virtual (VM). Vale

destacar que o modelo CLD pode ser reduzido a um único bloco com um MTTF e um MTTR (BUZACOTT, 1967).




Figura 20 – Modelo RBD: Camada de Nuvem Privada.

5.3 MODELO DE PERFORMABILIDADE

A Figura 21 apresenta o modelo para a avaliação integrada de desempenho e disponibilidade. A métrica de interesse é o tempo de resposta, que contempla o atraso para a camada de nuvem privada receber dados da camada de sensores. A disponibilidade pode ter uma influência significativa no tempo de resposta, pois os componentes do sistema podem falhar.




Figura 21 – Modelo de Performabilidade.

O modelo foi dividido em blocos a fim de auxiliar na explicação. Levando em consideração a arquitetura adotada (Seção 5.1), cada camada possui um bloco de disponibilidade (em vermelho) que abstrai os componentes adotados. O lugar XUp (por exemplo, $psUp$) indica que

a camada (ou componente) está operacional, enquanto o lugar $XDown$ denota a respectiva falha. As transições $tXFailure$ e $tXRestore$ representam a falha e a manutenção de um (ou conjunto de) dispositivo na camada, e os respectivos valores associados correspondem ao MTTF e MTTR do dispositivo.

A disponibilidade do sistema pode ser computada através da expressão $P\{(\#psUp > 0) \text{ AND } (\#pmUp > 0) \text{ AND } (\#pnUp > 0) \text{ AND } (\#pcUP > 0)\}$, e que representa o fato de que se alguma camada não estiver operacional, o sistema falha. O bloco de desempenho (em azul) representa a transmissão de dados. Um token no lugar $pSensor$ indica que os dados foram obtidos por um sensor e são imediatamente (transição $T3$) enviados ao microcontrolador (lugar $pMicro$). O microcontrolador e o sensor estão conectados à mesma placa e, portanto, o respectivo atraso pode ser desconsiderado. A transição $T3$ possui um arco inibidor que não permite a aquisição de dados quando o sensor está inoperante.

O microcontrolador então transmite os dados do paciente pela rede (transição $tProcessingNetwork$), e, em seguida, os dados do sensor são recebidos na nuvem privada (ativação da transição $tProcessingCloud$). O lugar ($pCPC$) representa a capacidade de processamento para receber dados na nuvem privada. Por exemplo, um token limita a capacidade a uma solicitação por vez, e tokens adicionais ($\#pCPC > 1$) permitem a avaliação de lidar com várias requisições simultaneamente.

Similarmente ao sensor, as transições $T1$ e $T2$ verificam se os componentes estão inoperantes. Em caso de falha, a transmissão de dados não é realizada. Quanto aos dados recebidos na nuvem, os dados são perdidos em caso de falha (transição $T2$). Além disso, a Lei de Little (MACIEL, 2023) é adotada para estimar o tempo médio de resposta (R), que é calculado da seguinte forma: $R = \frac{L}{\lambda}$. L é o número médio de mensagens no sistema, e λ é a taxa de processamento. Mais especificamente, $L = E\{\#pSensor\} + E\{\#pMicro\} + E\{\#pNetwork\} + E\{\#pRequestCloud\}$ e $\lambda = E\{\#pRequestCloud\} \times 1/W(tProcessingCloud)$.

5.4 DISPONIBILIDADE E DESEMPENHO EM MODELOS SPN

Esta seção apresenta os modelos propostos de disponibilidade e de desempenho para representar as arquiteturas IoMT previamente descritas. Adota-se uma abordagem hierárquica que combina SPN e CTMC para representar a disponibilidade do sistema.

Os modelos SPNs são aplicados para estimar métricas como tempo de resposta, *throughput*, disponibilidade do sistema e tempo de indisponibilidade do ambiente IoMT. Por sua vez,

os modelos CTMC são utilizados para representar a disponibilidade do sistema, e seus resultados de avaliação são incorporados ao submodelo de disponibilidade em SPN. Essa abordagem hierárquica permite uma avaliação abrangente e precisa do desempenho e da confiabilidade do sistema.

Para melhor compreensão, o modelo (ver Figura 22) é dividido em blocos. Considerando a arquitetura adotada (ver Figura 18), propõe-se uma *camada única de disponibilidade* para representar a disponibilidade global do sistema. Essa camada unificada abstrai a disponibilidade de todos os componentes, consolidando o seu comportamento em um único bloco de disponibilidade (destacado em vermelho). Esse procedimento simplifica a análise sem perder a representação abrangente da disponibilidade do sistema.




Figura 22 – Modelo SPN integrado de disponibilidade e desempenho.

O *bloco de desempenho* (em azul) representa o modelo proposto para avaliar o desempenho do sistema. O número de marcas no lugar $pMaxCapacity$ representa a capacidade máxima do sistema, correspondendo ao número de requisições que o sistema consegue atender simultaneamente. Cada marca representa uma requisição, indicando o limite de requisições ativas que podem ser gerenciadas em dado instante.

A transição $tTimedSensor$ representa o tempo entre medições realizadas pelo sensor, definindo a frequência de coleta e envio de dados para processamento. O disparo dessa transição ($tTimedSensor$) consome token em $pMaxCapacity$ e gera token em $pSensor$. Um token em $pSensor$ indica que um dado foi obtido pelo sensor. O disparo da transição $T3$ gera token no

lugar *pMicro*.

O microcontrolador (*pMicro*) e o sensor (*pSensor*) estão conectados à mesma placa, de modo que o respectivo atraso é considerado desprezível. As transições T_0 , T_2 , T_4 e T_5 são disparadas quando a disponibilidade do sistema está *indisponível*. Essa condição reflete o instante em que o sistema não está operacional, impedindo o processamento adequado das requisições. Como resultado, as requisições são automaticamente descartadas, pois o sistema não possui recursos necessários para atendê-las.

Para representar esse comportamento, associa-se uma *expressão de guarda* a essas transições, validando a condição de indisponibilidade do sistema antes de permitir o disparo. Esse mecanismo garante que as transições ocorram apenas quando o sistema está em estado de falha, evidenciando o impacto direto da indisponibilidade no desempenho global e levando à perda de dados ou requisições durante os períodos de falha. Quando disponível, o microcontrolador transmite os dados do paciente pela rede (transição *tProcessingNetwork*); em seguida, os dados do sensor são recebidos e processados em uma nuvem privada (disparo de *tProcessingCloud*).

5.4.1 Modelo CTMC para a quantificação de disponibilidade

Esta seção apresenta modelos de disponibilidade criados em CTMC para representar a arquitetura IoMT base sob análise. Além disso, são fornecidos os modelos que representam variações da arquitetura de referência considerando servidores redundantes em configurações *hot* e *cold standby*.

Os resultados obtidos com esses modelos são então incorporados ao modelo de disponibilidade baseado em SPN (modelo em vermelho presente na Figura 22), a fim de prover uma avaliação abrangente das arquiteturas IoMT propostas. Os modelos CTMC foram avaliados com o uso da ferramenta Mercury (SILVA et al., 2015), e as equações matemáticas requeridas para a análise foram geradas com o uso do *Mathematica* (WOLFRAM, 2003).

5.4.2 Modelo CTMC para um sistema sem redundância

Um sistema sem redundância opera com apenas um servidor que é responsável por gerenciar todas as tarefas e processos. Nesta configuração base, não há *backup* ou sistema secundário disponível para assumir em caso de falha. Essa abordagem reduz custos e complexidade. No

entanto, ela aumenta o risco de tempo de inatividade e perda de dados, pois qualquer problema de *hardware* ou *software* pode resultar em falha do sistema como um todo. A Figura 23 apresenta esse sistema.




Figura 23 – Arquitetura básica sem redundância.

A Figura 24 mostra o modelo CTMC correspondente que representa o comportamento da configuração anterior. O modelo consiste em dois estados principais: S_0 , que representa o estado operacional no qual o sistema está funcionando corretamente, e S_1 , que representa o estado de falha no qual o sistema se encontra inoperante. As transições entre esses estados dependem de dois parâmetros chave. O primeiro parâmetro, λ , denota a *taxa de falha* do sistema, que é a probabilidade de que o sistema deixe o estado operacional S_0 e entre no estado de falha S_1 .




Figura 24 – Modelo CTMC sem redundância.

O segundo parâmetro, μ , representa a *taxa de reparo* do sistema, indicando a probabilidade de que o sistema seja reparado e retorne ao estado operacional S_0 . A probabilidade do sistema estar operacional aumenta quando a taxa de reparo μ cresce e diminui quando a taxa de falha λ aumenta. De modo análogo, a probabilidade do sistema falhar cresce com o aumento de λ e decresce com a redução de μ . A partir do modelo CTMC apresentado na Figura 24, obtêm-se as probabilidades estacionárias dos estados do sistema:

$$\left\{ \frac{\mu}{\lambda + \mu}, \frac{\lambda}{\lambda + \mu} \right\}.$$

Considerando as taxas de falha λ e de reparo μ , tem-se explicitamente a probabilidade do sistema se encontrar em funcionamento S_0 ou em falha S_1 .

$$S_0 = \frac{\mu}{\lambda + \mu} \quad \text{e} \quad S_1 = \frac{\lambda}{\lambda + \mu}.$$

A Figura 25 apresenta a modelagem combinada com CTMC e SPN para avaliar a disponibilidade de um sistema sem redundância na arquitetura IoMT. Nesse caso, não há servidor de *backup* pronto para assumir em caso de falha, de modo que a recuperação depende do tempo de reparo do sistema.




Figura 25 – Modelo sem redundância.

O modelo CTMC representa os estados de operação e falha do sistema, permitindo a análise de métricas como probabilidade de estados, tempo médio em operação e taxa de falha. Com base nos valores obtidos na avaliação CTMC, esses parâmetros são incorporados ao modelo de disponibilidade em SPN.

O modelo SPN utiliza as probabilidades de estado e as taxas de transição extraídas do CTMC para refinar a análise da disponibilidade da arquitetura IoMT. Contudo, devido à ausência de redundância, a falha do sistema pode resultar em períodos de indisponibilidade até que o reparo seja concluído, o que impacta diretamente a continuidade de operação e a disponibilidade global do sistema.

5.4.3 Modelo CTMC para um sistema com redundância *cold standby*

Nesta arquitetura, um servidor primário (SP) executa todas as operações do sistema, enquanto o servidor secundário (SS) permanece inativo até que seja necessário. O servidor secundário é ativado apenas quando o servidor primário falha ou se torna inacessível, o que caracteriza uma redundância do tipo *cold standby*. A Figura 26 apresenta essa arquitetura de sistema.




Figura 26 – Configuração *Cold-standby*.

A Figura 27 mostra o modelo CTMC criado para representar o sistema utilizando a técnica de redundância *cold standby*. Nessa configuração, o componente redundante permanece inativo até que o componente primário falhe, e essa ativação demanda uma inicialização para, por exemplo, sincronizar os dados.

O CTMC é composto por cinco estados: S_0 , em que o sistema primário está operacional e o componente redundante está inativo; S_1 , em que o sistema primário falha e o componente redundante inicia o processo de ativação, regido pela taxa ρ (por exemplo, a inicialização de uma máquina virtual); S_2 , em que o componente redundante assume a operação, mantendo o sistema funcional; S_3 , em que o componente redundante também falha, resultando em falha total do sistema; e S_4 , que representa o estado em que um ou mais componentes estão em reparo, regido pela taxa de reparo μ .




Figura 27 – Modelo CTMC: redundância em *Cold-standby*.

As transições entre estados são determinadas pelos parâmetros λ , que representa a taxa de falha do sistema, e μ , que indica a taxa de reparo. Especificamente, o sistema transita de S_0 para S_1 à taxa λ , de S_1 para S_2 após o tempo definido pela taxa ρ , de S_2 para S_3 novamente à taxa λ , e de S_1 ou S_3 para S_4 à taxa de reparo μ .

Após a conclusão dos reparos, o sistema retorna ao estado S_0 . Esse modelo mostra como a redundância *cold standby* pode melhorar a disponibilidade em relação à configuração sem redundância, embora o atraso de ativação introduzido pela taxa ρ reduza temporariamente a disponibilidade do sistema.

Com base no modelo CTMC apresentado na Figura 27, obtém-se a equação abaixo, que quantifica a disponibilidade de um sistema com redundância *cold standby*. Essa formulação considera os cinco estados do sistema (S_0, S_1, S_2, S_3, S_4) e incorpora parâmetros críticos, como a taxa de falha λ , a taxa de reparo μ e a taxa de atraso de ativação ρ .

A inclusão de ρ reflete o atraso de inicialização ao colocar o componente redundante em operação após a falha do primário. O resultado evidencia como a redundância *cold* melhora a disponibilidade, ao mesmo tempo em que ressalta o efeito do atraso de ativação, que torna o sistema temporariamente indisponível.

$$\left\{ \begin{array}{l} \frac{\mu^2(\mu + \rho)}{\lambda^2\rho + \lambda\mu(\mu + \rho) + \mu^2(\mu + \rho)}, \quad \frac{\lambda\mu^2}{\lambda^2\rho + \lambda\mu(\mu + \rho) + \mu^2(\mu + \rho)}, \\ \frac{\lambda\mu^2\rho}{(\lambda + \mu)(\lambda^2\rho + \lambda\mu(\mu + \rho) + \mu^2(\mu + \rho))}, \quad \frac{\lambda^2\rho}{\lambda^2\rho + \lambda\mu(\mu + \rho) + \mu^2(\mu + \rho)}, \\ \frac{\lambda^2\mu\rho}{(\lambda + \mu)(\lambda^2\rho + \lambda\mu(\mu + \rho) + \mu^2(\mu + \rho))} \end{array} \right\}$$

A Figura 28 apresenta a estratégia de modelagem adotada combinando CTMC e SPN para avaliar a disponibilidade de um sistema com redundância *cold standby* na arquitetura de IoMT. Nesse arranjo, o servidor de *backup* (redundante) permanece inativo até que o servidor primário falhe. Uma vez ocorrida a falha, o sistema de *backup* precisa realizar o processo de ativação antes de entrar em operação, o que pode introduzir um tempo de recuperação maior do que no arranjo *hot standby*.




Figura 28 – Modelo *Cold standby*.

O modelo CTMC representa os estados de operação, falha e recuperação do sistema, permitindo analisar métricas como probabilidade de estados, tempo médio em operação e taxa de falha. Diferentes estados indicam a operação do sistema primário, a transição para o servidor de *backup* e os períodos de inatividade durante a recuperação. A partir dos valores obtidos na avaliação CTMC, esses parâmetros são incorporados ao modelo de disponibilidade em SPN. O modelo SPN utiliza as probabilidades de estado e as taxas de transição extraídas

do CTMC para quantificar o impacto de disponibilidade sobre o desempenho do sistema IoMT.

5.4.4 Modelo CTMC para um sistema com redundância *hot standby*

O *backup* de sistema operacional em *hot standby* é uma técnica de redundância projetada para assegurar alta disponibilidade. Nesse sistema, o servidor primário (PS) realiza todas as operações do sistema, enquanto o servidor secundário (SS) permanece em estado passivo, porém constantemente sincronizado com o primário. Se ocorrer uma falha no servidor primário, o servidor de *backup* pode iniciar a operação imediatamente, garantindo continuidade do serviço sem interrupção. A Figura 29 apresenta essa configuração de sistema.




Figura 29 – Configuração *Hot-Standby*.

A Figura 30 apresenta o modelo CTMC correspondente que descreve o sistema anterior com a técnica de redundância *hot standby*. O modelo é composto por três estados distintos: S_0 , representando a operação normal do sistema primário; S_1 , representando a falha do sistema primário, quando a operação é assumida pelo sistema redundante; e S_2 , indicando falha do sistema, quando tanto o primário quanto o redundante estão inoperantes.




Figura 30 – Modelo CTMC: redundância em *Hot-Standby*.

As transições entre esses estados são definidas por duas taxas-chave: a taxa de falha λ , que corresponde à probabilidade do sistema falhar, e a taxa de reparo μ , que representa a probabilidade de o sistema ser reparado e retornar ao estado operacional.

A transição de S_0 para S_1 ocorre devido à falha do sistema primário, governada pela taxa λ , enquanto o retorno de S_1 para S_0 dá-se após o reparo, com taxa μ . De forma análoga, a transição de S_1 para S_2 ocorre devido à falha do sistema redundante, também ativada pela taxa de falha λ , e as atividades de reparo restauram o sistema ao estado S_0 com taxa μ .

A técnica de redundância *hot standby* ilustrada nesse modelo garante que o sistema redundante esteja ativo e monitorando continuamente o sistema primário. Isso permite que o redundante assuma a operação imediatamente em caso de falha do primário. Contudo, permanece o risco de falhas simultâneas ou sequenciais de ambos os sistemas, resultando na falha global representada por S_2 .

A equação a seguir é derivada do modelo CTMC apresentado na Figura 30 e descreve o comportamento do sistema sob a configuração *hot standby*. Ela considera as probabilidades de transição entre os três estados S_0 , S_1 e S_2 , incorporando a taxa de falha λ e a taxa de reparo μ . O primeiro termo da equação representa a probabilidade de o sistema estar em operação (S_0), enquanto os termos subsequentes modelam a dinâmica de transições devidas à falha do sistema primário ou do redundante. Além disso, a equação também captura a possibilidade de falha simultânea dos dois sistemas, levando ao estado S_2 . Essa formulação fornece base matemática para avaliar a confiabilidade e a disponibilidade de configurações *hot standby*, destacando os compromissos entre desempenho do sistema e risco de falha total:

$$\left\{ \frac{\mu^2}{\lambda^2 + \lambda\mu + \mu^2}, \quad \frac{\lambda\mu}{\lambda^2 + \lambda\mu + \mu^2}, \quad \frac{\lambda^2}{\lambda^2 + \lambda\mu + \mu^2} \right\}.$$

A Figura 31 apresenta a estratégia de modelagem combinada utilizando CTMC e SPN para avaliar a disponibilidade e o desempenho de um sistema em *hot standby* na arquitetura IoMT. Nesse tipo de configuração, um servidor primário opera ativamente enquanto um servidor secundário permanece em espera, pronto para assumir imediatamente no caso de falha do sistema primário.

O modelo CTMC representa a dinâmica de operação e falha do sistema, permitindo a análise de métricas como probabilidade de estados, tempo médio de operação e taxa de falhas. Com base nos valores obtidos na avaliação CTMC, esses parâmetros são incorporados ao modelo de disponibilidade em SPN. Dessa forma, o modelo SPN utiliza os resultados obtidos via CTMC como parâmetros de entrada para calcular o impacto de disponibilidade sobre o desempenho do sistema.




Figura 31 – Modelo *hot standby*.

5.5 MODELO DE PERFORMABILIDADE ESTENDIDO

Esta seção apresenta os modelos estendidos com base no modelo apresentado na seção anterior, o qual foi devidamente validado (ver Seção 6.2). A partir de agora, todos os modelos subsequentes serão baseados neste modelo validado, servindo para a análise e implementação de cenários mais complexos.

Os modelos propostos têm como principal objetivo demonstrar a aplicabilidade das implementações no tempo de resposta e na disponibilidade dos sistemas. Cada modelo estendido explora diferentes estratégias e configurações que podem ser aplicadas para melhorar o desempenho e a disponibilidade do sistema, especialmente em configurações críticas, onde a eficiência e a confiabilidade são importantes, como sistemas IoMT.

5.5.1 Modelo Estendido I

A Figura 32 representa a arquitetura IoMT, e a Figura 33 representa o modelo proposto, onde a camada de nuvem privada possui apenas uma máquina física e uma máquina virtual para processar as requisições recebidas. O modelo estendido I corresponde ao modelo da Seção 5.3 com a adição da disponibilidade da VM e do HW.




Figura 32 – Arquitetura Estendida I




Figura 33 – Modelo Estendido I

Neste novo modelo, foi acrescentado o estado de falha e reparo de uma máquina virtual (*pvmUp* e *pvmDown*) e um *hardware* (*pcUp* e *pcDown*) específico. Caso o *hardware* venha a falhar, a VM correspondente se tornará inoperante, comprometendo a continuidade das operações que dependem dessa máquina virtual. Essa adição permite uma análise mais detalhada da disponibilidade do sistema, considerando a interdependência entre o *hardware* físico e as VMs que ele suporta.

5.5.2 Modelo Estendido II

A Figura 34 representa a arquitetura IoMT com uma máquina física e duas VMs para aumentar a capacidade de processamento, e a Figura 35 representa o modelo proposto. A parte do modelo que aborda a disponibilidade foi discutida na seção anterior (Seção 5.5.1). Nesta seção, são representadas as funcionalidades adicionais de disponibilidade incorporadas ao modelo, bem como o método para calcular o tempo de resposta.




Figura 34 – Arquitetura Estendida II

Os lugares $pvmUp1$, $pvmUp2$, $pvmDown1$ e $pvmDown2$ denotam os estados operacionais e de falha para as VMs adicionadas ao modelo. Vale destacar que ambas as VMs estão hospedadas na mesma máquina física. Os lugares $pcUp$ e $pcDown$ denotam os estados operacionais e de falha da máquina física. Se a máquina física parar de funcionar, ambas as VMs se tornam indisponíveis. Nesse caso, as transições imediatas $T0$ e $T2$ serão disparadas, o que corresponde a uma rejeição de uma requisição.




Figura 35 – Modelo Estendido II

As transições *tvmFailure1*, *tvmFailure2*, *tvmRestore1* e *tvmRestore2* representam uma falha e um reparo, e seus atrasos correspondem ao MTTF e ao MTTR, respectivamente. Esta modificação visa melhorar o desempenho do sistema, distribuindo a carga de trabalho de forma mais eficaz e proporcionando redundância garantindo, assim, um maior nível de confiabilidade e capacidade de resposta.

A disponibilidade do sistema pode ser estimada como $P\{(\#psUp > 0) \text{ AND } (\#pmUp > 0) \text{ AND } (\#pnUp > 0) \text{ AND } (\#pcUP > 0) \text{ AND } ((\#pvmUp1 > 0) \text{ OR } (\#pvmUp2 > 0))\}$. Se alguma camada não estiver operacional, o sistema falha. O bloco de desempenho (em azul) representa a transmissão de dados.

Neste modelo, o atendimento das requisições ocorre em paralelo em duas máquinas virtuais, acomodando demandas heterogêneas de serviços de saúde que exigem tempos de resposta distintos. Em cenários como detecção de eventos críticos, é preciso atender requisições com maior rapidez, o que justifica distribuir o fluxo entre VMs com capacidades diferentes ou com políticas de atendimento específicas. Assim, as transições *tProcessingCloud1* e *tProcessingCloud2* modelam os atrasos (tempos de resposta) associados ao atendimento em cada VM, enquanto os lugares *pCPC1* e *pCPC2* representam a capacidade disponível, permitindo avaliar múltiplas requisições simultâneas e comparar arranjos de atendimento que priorizam serviços mais urgentes frente a tarefas menos sensíveis à latência.

Essa capacidade de processamento paralelo é projetada para melhorar a eficiência e reduzir os tempos de resposta, permitindo o tratamento simultâneo de requisições. O tempo médio de resposta (R) é calculado por $R = \frac{L}{\lambda}$. Neste modelo, $L = E\{\#pSensor\} + E\{\#pMicro\} + E\{\#pNetwork\} + E\{\#pRequestCloud1\} + E\{\#pRequestCloud2\}$ e $\lambda = (E\{\#pRequestCloud1\} \times (1 / W(tProcessingCloud1))) + (E\{\#pRequestCloud2\} \times (1 / W(tProcessingCloud2)))$. Para as próximas arquiteturas, o cálculo do tempo de resposta será padronizado em todos os modelos, visto que o submodelo de desempenho permanece consistente entre essas arquiteturas.

5.5.3 Modelo Estendido III

A Figura 36 apresenta a arquitetura com três VMs: duas para processar requisições e uma terceira utilizando a técnica de redundância em *cold standby*, que garante que ela se torne operacional caso uma das duas primeiras VMs falhe. Além disso, há uma única máquina física hospedando as VMs. O novo modelo (ver Figura 37) incorpora a técnica de redundância em

cold standby.

Essa técnica envolve a execução simultânea de duas VMs na mesma máquina física. Se uma dessas VMs falhar, uma terceira VM é ativada para garantir que o sistema permaneça operacional. Portanto, quando o módulo principal falha, a ativação do módulo de backup leva algum tempo para ser concluída. Esse intervalo de tempo é chamado de tempo médio de ativação (MTA).




Figura 36 – Arquitetura Estendida III

Como o componente de reserva está desativado, assume-se que ele não falha até se tornar operacional (SHOUMAN, 2003; KUO; ZUO, 2003). Os lugares *pvmUp1*, *pvmUp2*, *pvmUp3*, *pvmDown1*, *pvmDown2* e *pvmDown3* denotam os estados operacionais e de falha para os módulos principais e de reserva, respectivamente.

O módulo de reserva se encontra inicialmente desativado, pois nenhum token está presente nos lugares *pvmUp3* e *pvmDown3*. Quando uma das máquinas principais falham, as transições *ActiveSpare1* e *ActiveSpare2* são acionadas. O valor associado a transição *tActiveSpare1* ou *tActiveSpare2* representa o MTA, e uma marcação no lugar *pWaitSpare* indica que o módulo de reserva não está operacional.

As transições *tvmFailure1*, *tvmFailure2*, *tvmFailure3*, *tvmRestore1*, *tvmRestore2* e *tvmRestore3* representam uma falha e um reparo, e seus valores associados de MTTF e MTTR, respectivamente. O MTTF e o MTTR associados ao módulo principal podem diferir dos valores associados ao módulo de reserva.

A redundância em *cold standby* aumenta a confiabilidade do sistema, proporcionando uma VM de backup que está pronta para assumir tarefas de processamento sem um tempo de inatividade significativo. Essa abordagem garante uma disponibilidade contínua e melhora a resiliência do sistema contra falhas (SOUSA et al., 2017).

A disponibilidade do sistema pode ser estimada como $P(\#psUp > 0) \text{ AND } (\#pmUp > 0) \text{ AND } (\#pnUp > 0) \text{ AND } (\#pcUP > 0) \text{ AND } ((\#pvmUp1 > 0) \text{ OR } (\#pvmUP2 > 0) \text{ OR } (\#pvmUP3 > 0))$.




Figura 37 – Modelo Estendido III

($\#pvmUp3 > 0$)). Se alguma camada não estiver operacional, o sistema falha. O bloco de desempenho (em azul) representa a transmissão de dados.

Neste modelo, o processamento pode ocorrer em paralelo em duas máquinas virtuais diferentes. Essa capacidade de processamento paralelo é projetada para melhorar a eficiência e reduzir os tempos de resposta, permitindo o tratamento simultâneo de requisições.

5.5.4 Modelo Estendido IV

A Figura 38 apresenta a arquitetura adotada, composta por duas máquinas físicas, cada uma hospedando uma VM para processar as requisições. O modelo (ver Figura 39) inclui duas máquinas físicas, cada uma hospedando uma máquina virtual para o processamento de requisições. O processamento das requisições ocorre simultaneamente e, se uma das máquinas falhar, a outra continua processando as requisições.

A falha das máquinas físicas resultará imediatamente na falha de suas respectivas VMs, levando à incapacidade operacional da nuvem privada. As transições *tcFailure*, *tcFailure*, *tcRestore1* e *tcRestore1* representam tanto uma falha quanto um reparo, e seus atrasos correspondem ao MTTF e ao MTTR, respectivamente, das máquinas físicas.

As transições *tvmFailure1*, *tvmFailure2*, *tvmRestore1* e *tvmRestore2* representam uma




Figura 38 – Arquitetura Estendida IV

falha e um reparo, e seus atrasos correspondem ao MTTF e ao MTTR, respectivamente, das máquinas virtuais. A disponibilidade do sistema pode ser estimada como $P\{(\#psUp > 0) \text{ AND } (\#pmUp > 0) \text{ AND } (\#pnUp > 0) \text{ AND } ((\#pvmUp1 > 0) \text{ AND } (\#pcUp > 0)) \text{ OR } ((\#pvmUp2 > 0) \text{ AND } (\#pcUp1 > 0))\}$. Se alguma camada não estiver operacional, o sistema falhará.

Neste modelo, o processamento pode ocorrer em paralelo em duas máquinas virtuais diferentes. Essa capacidade de processamento paralelo é projetada para melhorar a eficiência e reduzir os tempos de resposta, permitindo o tratamento simultâneo de requisições.




Figura 39 – Modelo Estendido IV

5.5.5 Modelo Estendido V

O modelo desta seção foi concebido para escalar e representar um grande número de componentes e pacientes, preservando a simplicidade da formulação e a interpretabilidade dos

resultados. A arquitetura de IoMT adotada organiza o monitoramento de sinais fisiológicos em camadas conceituais. A Figura 40 ilustra o fluxo: os dados dos dispositivos de coleta seguem por redes locais (Wi-Fi/5G) e Internet até a nuvem privada e, em seguida, aos terminais de monitoramento.




Figura 40 – Arquitetura Estendida V

Em cenários de grande porte, como hospitais com múltiplos andares (Figura 41), diversos pacientes são monitorados de forma simultânea. Cada paciente pode portar vários sensores, gerando fluxos individualizados; a infraestrutura precisa suportar a vazão agregada com baixa latência até a nuvem privada.

A consolidação dos dados e sua apresentação em terminais permite que uma estação de enfermagem mantenha uma visão integrada dos pacientes em tempo quase real. Nessa escala, o sucesso da solução depende do bom desempenho e da disponibilidade; falhas ou atrasos no percurso dos dados podem afetar o cuidado prestado.

A Figura 42 apresenta o modelo em SPN proposto para a avaliação conjunta de disponibilidade e desempenho em IoMT, alinhado à arquitetura da Figura 41. O fluxo de dados percorre sensor, microcontrolador, rede e nuvem, sempre condicionado ao estado operacional de cada componente. As métricas de interesse são tempo de resposta, vazão e disponibilidade. Assume-se que, quando um componente falha, as requisições ativas nele são descartadas ime-




Figura 41 – Monitoramento de pacientes em um hospital de vários andares usando modelo V.

diatamente. O sistema é considerado disponível apenas se todas as camadas estiverem operacionais, e modela-se a dependência de que uma máquina virtual requer um *host* ativo para funcionar. Se qualquer camada falhar, o sistema entra em estado de falha. A disponibilidade em regime permanente (A) pode ser estimada como:

$$A = P\{(\#pmUp > 0) \text{ AND } (\#pnUp > 0) \text{ AND } (\#VmUp > 0)\}.$$

O bloco de desempenho (em azul) representa a comunicação entre as camadas da arquitetura. O lugar $pMaxCapacity$ indica a capacidade máxima do sistema, isto é, o número de requisições simultâneas que podem ser tratadas; cada token corresponde a uma requisição ativa. A transição $tTimesensor$ define a frequência de geração de medições, e um token em $pSensor$ indica que um dado está pronto. A transição $tiSensorMicro$ é imediata e dispara apenas quando há evidência de um sensor disponível em $pSensor$; como o sensor e o microcontrolador residem na mesma placa, o atraso local é considerado desprezível.




Figura 42 – Modelo Estendido V.

A transição $tiDiscardDataSensor$ verifica a indisponibilidade na camada de aquisição e, em caso de falha, descarta a requisição; o mesmo padrão vale para as transições $tiDiscardDataMicro$, $tiDiscardDataNetwork$ e $tiDiscardDataCloud$. A transição $tProcessingNetwork$ modela o atraso de transmissão na Internet, e a transição $tProcessingCloud$ representa armazenamento e processamento na máquina virtual. A concorrência em nuvem é limitada pelo lugar $pMaxCapacity$, cujo número de tokens C atua como capacidade máxima de atendimentos simultâneos, cada atendimento consome um token no início e o devolve ao término.

As transições imediatas, prefixadas por “ti”, codificam o fluxo lógico de tokens no caminho de desempenho e são habilitadas por funções de guarda que consultam o estado dos submodelos de disponibilidade. Dessa forma, os dados só avançam quando os componentes requeridos estão operando. Por exemplo, $tiSensorMicro$ dispara apenas na presença de recursos disponíveis, como indicado pela condição $\#pmUp > 0$, permitindo o prosseguimento da requisição para a próxima etapa do processamento.

Quando a condição necessária não é satisfeita, entram em ação as transições de descarte. Mecanismos como $tiDiscardDataSensor$ são habilitados pela condição oposta, por exemplo $\#pmUp = 0$, removendo o token do caminho de processamento e registrando a perda da requisição. Esse padrão de avanço condicionado por guarda e descarte quando há falha se repete ao longo do modelo, mantendo o fluxo dependente do estado operacional dos componentes-chave.

O modelo é escalável porque cada lugar carrega tokens que representam quantidades de componentes e graus de paralelismo. Em $pMaxCapacity$, os tokens C definem vagas de processamento. Nas sub-redes de disponibilidade, tokens N indicam enlaces operacionais, H representam *hosts* ativos e V correspondem a máquinas virtuais em execução. Ao ajustar C , N , H e V , o mesmo modelo descreve desde instalações mínimas até configurações com múltiplos enlaces, servidores e VMs, preservando o acoplamento entre disponibilidade e desempenho e permitindo estimar perdas por descarte, vazão efetiva e tempo de resposta sob diferentes níveis de redundância e capacidade.

A Tabela 8 resume os componentes do modelo, e a Tabela 9 detalha as transições principais, indicando tipo, funções de guarda e lógica de taxas ou atrasos. O conjunto combina transições temporizadas para atividades com duração mensurável e transições imediatas para eventos lógicos, evitando redundâncias na descrição e mantendo a consistência entre os blocos de disponibilidade e desempenho.

Tabela 8 – Componentes do modelo SPN

Tipo	Componentes	Descrição
Lugar	$pMaxCapacity$	Capacidade máxima do sistema
	$pSensor$	Camada do sensor
	$pNetwork$	Camada de rede
	$pRequestCloud$	Camada de nuvem privada
	$psUp, pnUp, HostUp, VmUp$	As camadas de sensor, rede, host e máquina virtual quando estão operacionais
	$psDown, pnDown, HostDown, VmDown$	As camadas de sensor, rede, host e máquina virtual quando não estão operacionais
Transições Temporizadas	$tTimesensor$	Frequência de tempo dos dados coletados do sensor
	$tProcessingNetwork$	Tempo exigido pela rede para transmitir os dados
	$tProcessingCloud$	Tempo necessário para processar uma solicitação
	$tsRestore, tnRestore, thRestore, tvnRestore$	MTTFs para as camadas de sensor, rede, host e máquina virtual
	$tsFailure, tnFailure, thFailure, tvnFailure$	MTTRs para as camadas de sensor, rede, host e máquina virtual
Transições Imediatas	$tiDiscardDataSensor$	Solicitações descartadas do sensor
	$tiDiscardDataMicro$	Solicitações descartadas da Coleta de Dados
	$tiDiscardDataNetwork$	Solicitações descartadas da Rede
	$tiDiscardDataCloud$	Solicitações descartadas da Nuvem Privada
	$tiSensorMicro$	Conexão entre sensor e microcontrolador
	$tiNetworkCloud$	Conexão entre rede e nuvem privada
Tokens	C	Número de tokens representando solicitações
	N	Número de tokens representando a rede
	H	Número de tokens representando o Host
	V	Número de tokens representando Máquinas Virtuais

Tabela 9 – Expressões de guarda

Transição	Tipo	Função de guarda
tTimesensor	Temporizada	-
tProcessingNetwork	Temporizada	-
tProcessingCloud	Temporizada	-
tiDiscardDataSensor	Imediata	(#pmUp=0)
tiSensorMicro	Imediata	(#pmUp>0)
tiDiscardDataMicro	Imediata	(#pmUp=0)
tiDiscardDataNetwork	Imediata	(#pnUp=0)
tiNetworkCloud	Imediata	(#pnUp>0)
tiDiscardDataCloud	Imediata	(#VmUp=0)

5.6 ESTIMATIVA DE CUSTO PARA SISTEMAS IOMT

Hospitais e clínicas médicas estão cada vez mais atentos a mecanismos que garantam a alta disponibilidade de serviços IoMT, dado o caráter crítico dos requisitos de sistemas de saúde (BAUER; ADAMS, 2012; WEI; LIN; KONG, 2011). Nesse contexto, é importante analisar cuidadosamente estratégias que assegurem a disponibilidade e a confiabilidade. Entretanto, para elevar tais métricas de dependabilidade, um fator chave é a adição de redundância aos dispositivos, o que impacta o custo do sistema. Portanto, uma análise de custos também é importante, pois as restrições financeiras frequentemente são determinantes na adoção de tecnologias médicas.

Esta seção apresenta um modelo de estimativa de custo para sistemas IoMT compostos por duas camadas: (i) a camada IoT, que abrange a implantação física dos dispositivos e o processamento local, e (ii) a camada de computação em nuvem, responsável pelo armazenamento, processamento e orquestração de dados. O custo total estimado (CTE) é definido como a soma do custo associado à IoT (C_{IoT}) e do custo associado à nuvem (C_{cloud}), conforme a Equação 5.1.

$$CTE = C_{IoT} + C_{cloud} \quad (5.1)$$

5.6.1 Custo IoT

O custo associado à camada IoT (C_{IoT}) inclui investimentos e despesas recorrentes relacionadas ao *hardware* de borda e à infraestrutura de comunicação implantada em ambientes hospitalares ou clínicos. Essa camada deve sustentar sensoriamento confiável, aquisição precisa de dados e operação contínua. O custo IoT é dividido em Custo Operacional (CO_{IoT}) e Custo de Manutenção (CM_{IoT}), conforme a Equação 5.2.

$$C_{IoT} = CO_{IoT} + CM_{IoT} \quad (5.2)$$

Custo Operacional (CO_{IoT}):

CO_{IoT} representa os investimentos necessários para implantar os recursos IoT em ambientes clínicos. Inclui aquisição de *hardware*, serviços de conectividade, esforço de instalação e atividades de integração com a nuvem. O custo de aquisição IoT (CA_{IoT}) agrega a compra de sensores, microcontroladores, sistemas de alimentação, invólucros de proteção e módulos de comunicação local. O custo de aquisição é dado pela Equação 5.3.

$$CA_{IoT} = \sum_{i=1}^n (CA_{IoT_i}) \quad (5.3)$$

O custo do provedor de conectividade (CPC) representa taxas de assinatura e de uso de redes externas, como soluções 4G, 5G ou FWA. O termo $(HW \times HR)_{CO}$ corresponde ao custo de mão de obra de implementação (*labor cost implementation, LCI*) associado às atividades operacionais, em que HW é o valor da hora de trabalho e HR é o número de horas necessárias para implantar e colocar em operação a infraestrutura IoT. Dessa forma, a expressão completa para CO_{IoT} é dada pela Equação 5.4.

$$CO_{IoT} = \sum_{i=1}^n (CA_{IoT_i}) + CPC_{IoT} + (HW \times HR)_{IoT} \quad (5.4)$$

Custo de Manutenção (CM_{IoT}):

CM_{IoT} reúne as despesas recorrentes com manutenção de dispositivos e obrigações associadas a SLA. Conforme a Equação 5.5, o termo $(HW \times HR)_{CM_IoT}$ representa o custo de mão de obra de manutenção (*labor cost maintenance, LCM*), em que HW é o valor da

hora de trabalho e HR é o número de horas dedicadas a essas intervenções. CS_{IoT} denota o custo de substituição de dispositivos com falha ou obsoletos, e SLA_{IoT} agrega o valor do SLA adotado e possíveis penalidades associadas a acordos de nível de serviço.

$$CM_{IoT} = (HW \times HR)_{CM_IoT} + CS_{IoT} + SLA_{IoT} \quad (5.5)$$

Esses componentes de custo oferecem uma visão estruturada dos gastos na borda IoMT e apoiam um planejamento financeiro mais realista para implantações escaláveis.

5.6.2 Custo da Nuvem

O custo associado à camada de nuvem (C_{cloud}) inclui investimentos e despesas recorrentes relacionados a servidores, armazenamento e infraestrutura de virtualização que suportam aplicações IoMT. Esse custo é dividido em Custo Operacional (CO_{cloud}) e Custo de Manutenção (CM_{cloud}), conforme a Equação 5.6.

$$C_{cloud} = CO_{cloud} + CM_{cloud} \quad (5.6)$$

Custo Operacional (CO_{cloud}):

CO_{cloud} representa os investimentos necessários para implantar e operar recursos de nuvem. Inclui aquisição de servidores e dispositivos de armazenamento, serviços de conectividade e esforço de instalação e configuração. O custo de aquisição de nuvem (CA_{cloud}) considera o valor necessário para a aquisição de todos os componentes físicos da nuvem privada, conforme a Equação 5.7.

$$AC_{cloud} = \sum_{i=1}^n (AC_{cloud_i}) \quad (5.7)$$

O custo de aquisição de cada recurso de nuvem (CA_{cloud_i}) corresponde à compra de servidores e equipamentos auxiliares necessários para suportar serviços de processamento, armazenamento e gerenciamento. O custo do provedor de conectividade para a nuvem (CPC_{cloud}) representa taxas de assinatura e de uso de enlaces externos que conectam a nuvem privada à rede do hospital ou a outros sítios remotos. O fator $(HW \times HR)_{cloud}$ representa o custo de mão de obra de implementação (*labor cost implementation, LCI*) associado à implantação e configuração da infraestrutura em nuvem, em que HW é o valor da hora de trabalho e HR é

o número de horas requerido para essas atividades. Assim, a expressão completa para o custo operacional da nuvem é dada por:

$$CO_{cloud} = \sum_{i=1}^n (CA_{cloud_i}) + CPC_{cloud} + (HW \times HR)_{cloud} \quad (5.8)$$

Custo de Manutenção (CM_{cloud}):

CM_{cloud} reúne as despesas recorrentes com manutenção da infraestrutura em nuvem e questões relacionadas a SLA. Conforme a Equação 5.9, o termo $(HW \times HR)_{CM_cloud}$ representa o custo de mão de obra de manutenção (*labor cost maintenance, LCM*), CS_{cloud} é o custo de substituição de equipamentos de nuvem com falha ou obsoletos, e SLA_{cloud} agrega penalidades ou adicionais associados a acordos de nível de serviço.

$$CM_{cloud} = (HW \times HR)_{CM_cloud} + CS_{cloud} + SLA_{cloud} \quad (5.9)$$

Este modelo de custos auxilia tomadores de decisão e arquitetos de sistemas a realizarem compensações informadas ao projetar sistemas IoMT, permitindo equilibrar confiabilidade, desempenho e restrições financeiras (CALLOU et al., 2010). Ao modelar os componentes individuais da infraestrutura de IoT e da nuvem, torna-se possível otimizar configurações e prever com maior precisão o custo total de propriedade para sistemas inteligentes orientados à área da saúde.

5.7 CONSIDERAÇÕES FINAIS

Este capítulo apresentou os modelos de desempenho e disponibilidade que foram propostos e representam uma das principais contribuições deste trabalho. Inicialmente, foi apresentada a sintaxe matemática para o entendimento das métricas adotadas e, em seguida, foram apresentados os modelos em redes de *Petri* estocásticas generalizadas. Além disso, foi representado o sistema IoMT utilizando CTMC. Esses modelos foram explicados a fim de prover um melhor entendimento a respeito das ações existentes em sistemas IoMT foram modeladas aqui.

Este capítulo também apresentou as métricas de interesse (tempo médio de resposta, vazão e disponibilidade), bem como suas respectivas equações. Os modelos permitem representar sistemas de Internet das coisas médicas a partir de diferentes abordagens, o que pode ser de grande importância para projetistas. Porém, é importante enfatizar que, para a adoção desses

modelos, é necessário um embasamento prévio a respeito do formalismo adotado. Por fim, foram apresentados os conceitos para quantificar o custo de sistemas IoMT.

6 RESULTADOS EXPERIMENTAIS

Este capítulo apresenta os resultados experimentais que demonstram a viabilidade prática tanto dos modelos como da estratégia de modelagem proposta. Os experimentos seguem a metodologia do Capítulo 4, contemplando a validação dos modelos RBD e SPN e a avaliação de diferentes configurações de sistemas IoMT. Inicialmente, na Seção 6.1, descrevem-se o ambiente de avaliação, o protocolo de comunicação e os dispositivos de troca de mensagens considerados na validação dos modelos. Em seguida, a Seção 6.2 reúne as validações dos modelos de disponibilidade e de performabilidade, comparando os resultados do modelo com medições no sistema real.

A Seção 6.3 apresenta um experimento com DoE, usando RBD, para analisar os efeitos de fatores e níveis assumidos neste trabalho. A Seção 6.3.1 apresenta os experimentos quanto a disponibilidade e a Seção 6.3.2 aplica princípio análogo ao modelo de performabilidade. A Seção 6.4 apresenta um estudo que faz uso de CTMC, representando o sistema IoMT com fórmulas fechadas. Na sequência, a Seção 6.5 introduz estudos de caso que estendem o modelo de performabilidade validado. O Estudo de Caso I (Seção 6.5.1) compara métricas de disponibilidade e desempenho a partir dos modelos estendidos (Seção 5.5). O Estudo de Caso II (Seção 6.5.2) avalia o tempo de resposta sob variações no tempo de processamento na nuvem privada.

Para refletir os novos cenários, acrescentam-se dois estudos com o Modelo V (Seção 5.5.5) para o ambiente de escalabilidade. A Seção 6.5.3 investiga o comportamento do sistema ao aumentar progressivamente o número de componentes por camada, observando os impactos na disponibilidade, no tempo de resposta e na vazão. A Seção 6.5.4 investiga os impactos individuais e interativos dos componentes do sistema e da carga de trabalho sobre o desempenho e a disponibilidade por meio do DoE, com o objetivo de identificar quais fatores mais influenciam a disponibilidade, o tempo de resposta e a vazão. A Seção 6.6 apresenta um estudo sobre a importância da disponibilidade, e consequentemente alterando a arquitetura IoMT e a Seção 6.7 apresenta um estudo sobre os custos de sistemas IoMT. Finalmente, a Seção 6.8 discute os resultados segundo as métricas de tempo médio de resposta e disponibilidade.

6.1 CONFIGURAÇÃO DO SISTEMA

A Figura 43 mostra o sistema de avaliação adotado, que consiste em duas máquinas físicas (um cliente e um servidor) e um *switch*. O cliente simula os dados gerados pelo microcontrolador e pelo sensor usando o JMeter (HALILI, 2008), que também é responsável por coletar os dados sobre o tempo de resposta do servidor. Este trabalho adota o protocolo MQTT (STANDARD, 2019) para a comunicação entre o cliente e o servidor (*Host*), uma vez que tal protocolo é comumente adotado para sistemas com recursos computacionais limitados (ALSHAMMARI, 2023).




Figura 43 – Sistema de Avaliação

A máquina cliente utiliza um processador Intel i3-10110U 2.59 GHz com 24 GB de RAM e 500 GB de armazenamento, e o servidor adota um processador AMD Ryzen 5 3500X 3.59 GHz com 16 GB de RAM e 1 TB de armazenamento. Ambas as máquinas utilizam CentOS 7. O Apache Cloudstack foi adotado como plataforma de computação em nuvem privada, e o Mosquitto é utilizado como o *broker* no servidor para a comunicação utilizando o MQTT.

6.2 VALIDAÇÃO

Esta seção apresenta a validação dos modelos concebidos em SPN e RBD. A ideia principal é garantir que os modelos produzam resultados correspondentes ao sistema real. O modelo SPN foi avaliado usando o TimeNet (ZIMMERMANN; AL., 2006), e o Mercury (SILVA et al., 2015) foi adotado para a avaliação do RBD e do CTMC.

6.2.1 Validação: disponibilidade

A validação da disponibilidade considera um modelo RBD composto por um sensor, um microcontrolador, um *switch* e uma nuvem privada em uma disposição em série (Figura 19). A abordagem adotada utiliza injeções de falhas (HSUEH; TSAI; IYER, 1997) na interface de

rede para representar falhas no sistema, e a Tabela 11 apresenta o MTTF e o MTTR de cada componente.

Para cada componente, é criada uma *thread* usando o Algoritmo 6.1 (GOMES et al., 2022), que é um script responsável por injetar falhas. A linha 1 representa o tempo de monitoramento atual (em horas), e a linha 2 corresponde ao período de observação máximo (em horas). Em cada iteração, um tempo até a falha (ttf) é gerado usando a distribuição exponencial (linha 4).

A *thread* aguarda o tempo definido em ttf (linha 5) e, em seguida, a interface de rede é desabilitada (linha 6). Da mesma forma, o algoritmo gera um tempo até o reparo (ttr) (linha 7), aguarda (linha 8) e, em seguida, o componente é restaurado para o estado de funcionamento (linha 9). O *tempoAtual* é incrementado (Linha 10) levando em consideração o tempo decorrido (ou seja, a soma de ttf e ttr). Sempre que o *tempoAtual* for maior ou igual a *tempoMaximo*, a *thread* conclui a execução.

Algoritmo 6.1: Algoritmo de falha e reparo

Data: Nenhum dado de entrada específico

Result: Simulação do comportamento de falhas e reparos

```

1 tempoAtual  $\leftarrow$  0;
2 tempoMaximo  $\leftarrow$  34;
3 while tempoAtual < tempoMaximo do
4   Gerar tempo para falha (TTF);
5   Aguardar (TTF);
6   Interromper operação do sistema;
7   Gerar tempo para reparo (TTR);
8   Aguardar (TTR);
9   Restaurar operação do sistema;
10  Atualizar tempoAtual  $\leftarrow$  tempoAtual + TTF + TTR;
11 end
```

O Algoritmo 6.2 (GOMES et al., 2022) descreve o *script* para monitorar o estado do sistema (disponível ou indisponível). Um *loop* realiza comunicações periódicas com a Interface de rede. Se uma mudança no respectivo estado for detectada, o status do sistema é registrado para estimar a disponibilidade do sistema. O período de observação foi de 34 horas, o que equivale a cerca de 40% de um ano (146 dias), assumindo um fator de aceleração de 100. Em outras palavras, MTTF e MTTR são divididos por 100 para refletir a aceleração nas falhas e reparos.

Algoritmo 6.2: Monitoramento do sistema

Data: Conexão com o sistema
Result: Registro de eventos de falha e reparo

```

1 estadoSistema  $\leftarrow$  operando;
2 while verdadeiro do
3   if conexão estabelecida then
4     if estadoSistema  $\neq$  operando then
5       estadoSistema  $\leftarrow$  operando;
6       Registrar evento de reparo no log;
7     end
8   else
9     if estadoSistema = operando then
10      estadoSistema  $\leftarrow$  não operando;
11      Registrar evento de falha no log;
12    end
13  end
14 end

```

Utilizando os dados coletados e a técnica descrita em (KEESE, 1965), é obtido um intervalo de confiança de 95% [0,99329, 0,99493] para a disponibilidade. O modelo RBD foi avaliado utilizando o Mercury (SILVA et al., 2015), e a disponibilidade é estimada em 0,99470. Uma vez que esse valor está contido no intervalo, não há evidências estatísticas para refutar a equivalência entre o modelo proposto e o sistema real.

6.2.2 Validação: desempenho

Para o desempenho, a abordagem proposta utiliza o modelo SPN apresentado na Figura 21 sem falhas nos componentes. Utilizando a configuração do sistema representado na Figura 43, foram coletadas 30 amostras para estimar os atrasos médios para cada transição temporal e o tempo de resposta do sistema. Tal tamanho de amostra está relacionado ao teorema do limite central (MONTGOMERY; RUNGER, 2010). Os atrasos estimados são de 0,001 s e 0,014133 s para as transições *tProcessingNetwork* e *tProcessingCloud*, respectivamente.

Adotando a análise estacionária (MACIEL, 2023), o modelo proposto obtém 0,01513 s para o tempo de resposta do sistema. Utilizando os dados coletados no sistema real, [0,013962, 0,016305] representa o intervalo de confiança de 95% para o tempo de resposta utilizando a distribuição t de *Student*. Como 0,01513 s está contido no intervalo, não há evidência estatística de que o modelo não represente o sistema real.

6.3 EXPERIMENTOS

Dois experimentos são realizados para avaliar a disponibilidade e o desempenho com uma abordagem de DoE (MONTGOMERY; RUNGER, 2010). Adota-se um planejamento fatorial l^k , em que l é o número de níveis e k é o número de fatores do experimento.

As seguintes seções apresentam os resultados utilizando a classificação dos efeitos. O efeito (MONTGOMERY; RUNGER, 2010) é a mudança na resposta devido a uma alteração no nível do fator. Todas as classificações são apresentadas em ordem decrescente, considerando os valores absolutos de todos os efeitos. Além disso, este trabalho considera os efeitos principais e as interações de segunda ordem, uma vez que as interações de ordem superior geralmente são negligenciadas.

6.3.1 Disponibilidade

Esta seção apresenta o experimento para a avaliação da disponibilidade da arquitetura adotada, utilizando os modelos RBDs concebidos. Para cada componente, um MTTF distinto é considerado a fim de avaliar o respectivo impacto na disponibilidade do sistema. Os MTTR são mantidos constantes.

Tabela 10 – Fatores e Níveis

Fatores	Nível 1	Nível 2
MTTF SNS	44957	67435,5
MTTF MCU	28011	42016,5
MTTF NT	10000	15000,0
MTTF HW	8760	13140,0

A Tabela 10 retrata os fatores adotados (por exemplo, MTTF SNS). O Nível 1 denota o valor real, e o Nível 2 representa um componente melhorado com um aumento de 50% no tempo até a falha. SNS representa o sensor, MCU denota o microcontrolador, NT é a rede e HW é o hardware da nuvem privada. A Tabela 11 mostra os valores de MTTF e MTTR base adotados, os quais são baseados em (TANG et al., 2004; KIM; MACHIDA; TRIVEDI, 2009; Circuit Cellar, 2022). Para cada tratamento (ou seja, uma combinação de níveis de fatores), um modelo é criado (ver a Figura 19) para realizar a análise de disponibilidade.

A Tabela 12 apresenta a disponibilidade do sistema (A) e o tempo de inatividade ($D =$

Tabela 11 – MTTF e MTTR dos componentes do modelo

Módulo	Parâmetros de entrada		
	Componente	MTTF (h)	MTTR (h)
Microcontrolador	MCU	44957,0	5,0
Sensor	SNS	28011,0	5,0
Rede	NT	10000,0	1,0
Nuvem privada	HW	8760,0	1,66
	SO	2893,0	0,25
	KVM	2990,0	1,0
	VM	217,8	0,94

$[1 - A] \times 8760$) para cada tratamento em um ano (8760 horas). A Tabela 13 retrata a classificação de efeitos. HW é o fator mais importante, visto que, ao melhorar seu MTTF, a disponibilidade aumenta em 0,06% (4,5 horas de tempo de inatividade). Outros fatores também têm um efeito significativo e são seguidos pelo microcontrolador, assim como a interação entre o sensor e a rede.

Tabela 12 – Tratamentos e Resultados - Dependabilidade

Tratamento	MTTF SNS (h)	MTTF MCU (h)	MTTF NT (h)	MTTF HW (h)	A	Downtime (h)
1	44957,0	28011,0	10000,0	8760,0	0,9994209	5,0754
2	67435,5	28011,0	10000,0	8760,0	0,9994580	4,7506
3	44957,0	42016,5	10000,0	8760,0	0,9994804	4,5542
4	67435,5	42016,5	10000,0	8760,0	0,9995175	4,2294
5	44957,0	28011,0	15000,0	8760,0	0,9994543	4,7834
6	67435,5	28011,0	15000,0	8760,0	0,9994913	4,4586
7	44957,0	42016,5	15000,0	8760,0	0,9995137	4,2622
8	67435,5	42016,5	15000,0	8760,0	0,9995508	3,9374
9	44957,0	28011,0	10000,0	13140,0	0,9994841	4,5221
10	67435,5	28011,0	10000,0	13140,0	0,9995211	4,1973
11	44957,0	42016,5	10000,0	13140,0	0,9995435	4,0008
12	67435,5	42016,5	10000,0	13140,0	0,9995806	3,6760
13	44957,0	28011,0	15000,0	13140,0	0,9995174	4,2301
14	67435,5	28011,0	15000,0	13140,0	0,9995544	3,9053
15	44957,0	42016,5	15000,0	13140,0	0,9995768	3,7088
16	67435,5	42016,5	15000,0	13140,0	0,9996139	3,3840

6.3.2 Performabilidade

Esta seção apresenta o experimento que quantifica o impacto de diferentes cargas de trabalho no tempo de resposta e na disponibilidade. O modelo SPN da Figura 21 é adotado

Tabela 13 – Classificação dos efeitos - Confiabilidade

Disponibilidade		Downtime	
Fator/Interação	Efeito	Fator/Interação	Efeito
MTTF HW	0,000063	MTTF HW	-0,5533
MTTF MCU	0,000059	MTTF MCU	-0,5212
MTTF SNS	0,000037	MTTF SNS	-0,3248
MTTF NT	0,000033	MTTF NT	-0,2920

para estimar tal influência.

A Tabela 14 apresenta o DoE adotado, considerando 5 fatores. *pSensor* denota a carga de trabalho, que representa o número de mensagens simultâneas transmitidas pelo microcontrolador para a nuvem privada. *psUp*, *pmUp*, *pnUp* e *pcUp* contemplam a presença de redundância (nível 2) ou não (nível 1) em relação ao sensor, microcontrolador, rede e nuvem privada, respectivamente. O nome do fator também indica o lugar no modelo, e o nível denota a marcação (por exemplo, $\#psUP = 2$). Este experimento também adota o MTTF e MTTR da Tabela 11.

Tabela 14 – Fatores e Níveis

Fatores	Nível 1	Nível 2
pSensor	1	5
psUp	1	2
pmUp	1	2
pnUp	1	2
pcUp	1	2

Para cada tratamento, um modelo baseado na Figura 21 é criado, e a análise estacionária é utilizada para estimar a disponibilidade e o tempo de resposta. A Tabela 15 apresenta a disponibilidade do sistema e o tempo de resposta para cada tratamento, e a Tabela 16 apresenta a classificação dos efeitos. *Psensor* é o fator mais importante para o tempo de resposta. Por exemplo, comparando o tratamento 1 (uma mensagem) com o tratamento 2 (5 mensagens simultâneas), o tempo de resposta aumenta em 199%. A nuvem privada é o fator mais importante para a disponibilidade. Por exemplo, ao adicionar um componente sobressalente a este dispositivo (tratamento 17), a disponibilidade do sistema melhorou, reduzindo o tempo de inatividade em aproximadamente 20% (de 4,57 h para 3,62 h).

Comparando os tratamentos 31 e 32, o aumento de carga no 32 piora o tempo de resposta.

Tabela 15 – Tratamentos e Resultados - Disponibilidade e Tempo de Resposta.

Tratamento	pSensor	psUp	pmUp	pnUp	pcUp	Disponibilidade	Tempo de resposta
1	1	1	1	1	1	0,99477030	0,02840677
2	5	1	1	1	1	0,99477029	0,08516914
3	1	2	1	1	1	0,99488092	0,02840835
4	5	2	1	1	1	0,99488092	0,08517690
5	1	1	2	1	1	0,99494783	0,02840930
6	5	1	2	1	1	0,99494783	0,08518161
7	1	2	2	1	1	0,99505847	0,02841088
8	5	2	2	1	1	0,99505847	0,08518938
9	1	1	1	2	1	0,99486976	0,02840817
10	5	1	1	2	1	0,99486976	0,08517614
11	1	2	1	2	1	0,99498039	0,02840975
12	5	2	1	2	1	0,99498039	0,08518391
13	1	1	2	2	1	0,99504732	0,02841071
14	5	1	2	2	1	0,99504732	0,08518861
15	1	2	2	2	1	0,99515797	0,02841229
16	5	2	2	2	1	0,99515797	0,08519638
17	1	1	1	1	2	0,99958689	0,02833791
18	5	1	1	1	2	0,99958689	0,08482677
19	1	2	1	1	2	0,99969805	0,02833948
20	5	2	1	1	2	0,99969804	0,08483450
21	1	1	2	1	2	0,99976528	0,02834043
22	5	1	2	1	2	0,99976528	0,08483918
23	1	2	2	1	2	0,99987646	0,02834200
24	5	2	2	1	2	0,99987646	0,08484691
25	1	1	1	2	2	0,99968684	0,02833931
26	5	1	1	2	2	0,99968683	0,08483374
27	1	2	1	2	2	0,99979801	0,02834088
28	5	2	1	2	2	0,99979800	0,08484147
29	1	1	2	2	2	0,99986525	0,02834183
30	5	1	2	2	2	0,99986525	0,08484615
31	1	2	2	2	2	0,99997644	0,02834340
32	5	2	2	2	2	0,99997644	0,08485388

Tabela 16 – Classificação dos efeitos - Confiabilidade e Disponibilidade.

Tempo de Resposta		Disponibilidade	
Fator/Interação	Efeito	Fator/Interação	Efeito
Psensor	0,056640	pcUp	0,004818
pmUp	0,000007	pmUp	0,000178
Psensor*pmUp	0,000005	psUp	0,000111
psUp	0,000005	pnUp	0,000001
pnUp	0,000004	-	-
Psensor*pnUp	0,000003	-	-

Com taxa de chegada mais alta na camada de aquisição, cresce a concorrência por recursos ao longo do caminho de processamento. Mantida a mesma capacidade de serviço, a utilização se aproxima do limite, elevando o tempo médio em fila e, por consequência, o tempo total de atendimento. No modelo, mais mensagens disputam os mesmos tokens de capacidade, prolongando o ciclo de processamento mesmo com disponibilidade elevada. O comportamento é consistente com os tratamentos iniciais, em que mais medições simultâneas degradaram proporcionalmente o tempo de resposta. Dessa forma, pode-se perceber que a técnica concebida representa uma ferramenta adicional para os projetistas avaliarem a influência de cada componente no desempenho e disponibilidade do sistema.

6.4 MODELOS CTMC

Esta seção apresenta resultados experimentais para demonstrar a viabilidade da técnica de modelagem proposta (Seção 5.4.1) usando CTMC. A Tabela 11 mostra os valores de MTTF e MTTR adotados como parâmetros de entrada nos modelos. A Tabela 17 resume os resultados obtidos para a comparação do desempenho e da disponibilidade das três arquiteturas de sistema IoMT (ver Figura 44).

Tabela 17 – Redundância de arquiteturas IoMT

Arquitetura IoT	Disponibilidade	Downtime	Tempo de resposta	Vazão
Sem redundância	0,99509517	42,966311	0,00000669	3498556,23
Redundância	0,99511988	42,749851	0,00000669	3498643,11
Redundância Hot	0,99997582	0,2118160	0,00000669	3515715,64

Nessa tabela, é apresentada uma comparação das quatro métricas em análise (disponi-

bilidade, *downtime*, tempo de resposta e vazão). Os resultados consideram a arquitetura de referência (sem redundância) e com redundâncias *cold* e *hot*.




Figura 44 – Redundância de arquiteturas IoT

Os resultados de disponibilidade mostram um aumento significativo à medida que a redundância é implementada. Por exemplo, assumindo o sistema sem redundância, o valor de disponibilidade obtido foi 99,509%. Considerando a arquitetura com redundância *cold*, os resultados de disponibilidade melhoraram para 99,511%, enquanto com redundância *hot*, alcançaram 99,99%, garantindo, na prática, a operação contínua do sistema. Isso indica que a redundância *hot* é a abordagem mais eficiente para melhorar a disponibilidade do sistema.

Assumindo os resultados para o tempo de indisponibilidade durante o período de um ano, verifica-se um comportamento de tendência. O tempo de indisponibilidade é mais elevado no sistema sem redundância, em 42,96 horas. No sistema com redundância *cold*, observa-se uma leve redução para 42,74 horas, mas a melhoria mais significativa ocorre com a redundância *hot*, reduzindo o tempo de indisponibilidade para 0,21 horas. Isso significa que a implementação de redundância *hot* praticamente elimina falhas prolongadas do sistema.

Em relação ao tempo de resposta, os valores permanecem constantes nas três abordagens, com um tempo de 0,00000669 horas. Isso sugere que o tempo de resposta não é diretamente impactado pelo tipo de redundância implementada, mantendo um nível eficiente independentemente da arquitetura. Por fim, a vazão, que reflete a taxa de processamento do sistema, também apresenta leves melhorias à medida que a redundância aumenta. No sistema sem redundância, a vazão é de 3498556,23 requisições por segundo. Considerando o sistema com redundância *cold*, a vazão aumenta ligeiramente para 3498643,11 requisições por segundo e, com redundância *hot*, atinge seu pico em 3515715,64 requisições por segundo, indicando o desempenho global do sistema.

6.5 PERFORMABILIDADE: MODELOS ESTENDIDOS

Esta seção apresenta seis estudos que demonstram a aplicabilidade dos modelos propostos estendidos. No Estudo de Caso I, introduzem-se equipamentos redundantes na nuvem privada e comparam-se quatro arquiteturas para elevar a capacidade de processamento e a disponibilidade. O Estudo de Caso II avalia melhorias de hardware para lidar com requisições simultâneas, incluindo variações na capacidade de processamento da nuvem. O Estudo de Caso III analisa um hospital com cinco andares, ampliando proporcionalmente sensores, *switches* e VMs por piso, para verificar se a arquitetura absorve o aumento de carga mantendo alta disponibilidade. O Estudo de Caso IV aplica análise fatorial para mensurar a influência de componentes e carga sobre a disponibilidade, o tempo de resposta e a vazão. No Estudo de Caso V utiliza-se a métrica de Importância de Disponibilidade para priorizar componentes e propor arquiteturas redundantes. Por fim, o Estudo de Caso VI quantifica custos nas camadas IoT e nuvem privada, contemplando aquisição, operação e manutenção para subsidiar decisões técnico-financeiras.

6.5.1 Estudo de caso I

O estudo demonstra a aplicabilidade dos modelos ilustrados na Seção 5.5. A Configuração 01 apresenta a arquitetura processando solicitações com apenas 1 VM e 1 máquina física. A Configuração 02 apresenta o processamento com 2 VMs e 1 máquina física. A Configuração 03 mostra 3 VMs hospedadas em uma única máquina física utilizando a técnica de redundância em *cold standby*. A Configuração 04 exibe 2 VMs hospedadas em diferentes máquinas físicas.

Para obter o valor do MTA para o modelo (ver Figura 37), foi realizado um experimento real no ambiente de nuvem privada. Trinta ciclos de inicialização de uma VM desligada foram realizados para calcular o tempo de inicialização até que ela atingisse seu estado operacional. A média desses tempos foi calculada, resultando em um valor de 20,3 segundos associado à transição $t_{ActiveSpare1}$ e $t_{ActiveSpare2}$. A Tabela 11 mostra os valores base de MTTF e MTTR adotados.

A Tabela 18 apresenta os resultados obtidos para a disponibilidade (D) usando o número de nove ($-\log_{10}[1 - D]$). Por exemplo, assumindo um tempo de inatividade (DT) em horas durante um ano, a arquitetura I tem um tempo de inatividade de 43,62 horas, o que melhora em 40,02 horas a indisponibilidade do sistema em relação à arquitetura IV.

Considerando a avaliação de desempenho, a abordagem proposta utiliza os modelos SPN

Tabela 18 – Valores de Disponibilidade, Downtime e Tempo de resposta

Arquiteturas	D (9s)	DT (h)	TR (s)
Configuração 01	2,30275583	43,626289	0,0284031
Configuração 02	3,18617891	5,7059136	0,0213092
Configuração 03	3,21185992	5,3782896	0,0212802
Configuração 04	3,38618988	3,6000972	0,0213095

Note: D9s = Disponibilidade nº de 9s, DT = Downtime, TR = Tempo de resposta.

apresentados na Seção 5.5. Trinta amostras foram coletadas de um sistema real para estimar os valores associados para cada transição e o tempo de resposta do sistema. Os atrasos estimados são 0,001s e 0,014133s para as transições *tProcessingNetwork* e *tProcessingCloud*, respectivamente. Os resultados indicam (ver Tabela 18) uma melhoria significativa no tempo de resposta ao comparar a Arquitetura I (sem nenhuma redundância) com a Arquitetura II (com redundância de VM). Especificamente, a adição de VMs redundantes na Arquitetura II melhora o desempenho do sistema, reduzindo o tempo de resposta (TR) e garantindo um tratamento mais eficiente das solicitações.

6.5.2 Estudo de caso II

O objetivo é avaliar o impacto no tempo de resposta e na vazão quando ocorre variação no processamento em uma nuvem privada. A adição de componentes de alto desempenho, como *Random Access Memory* (RAM) de maior capacidade e processadores mais rápidos, pode melhorar substancialmente o desempenho das VMs e aumentar a capacidade de lidar com solicitações simultâneas. As arquiteturas da Seção 5.5 serão avaliadas com a variação no tempo de processamento associado às transições *tProcessingNetwork* e *tProcessingCloud* (ver Figura 35). Espera-se um aumento significativo na vazão do sistema, permitindo a escalabilidade necessária para suportar um número maior de usuários simultâneos. Portanto este estudo mostra que melhorias de *hardware* podem melhorar o desempenho dos sistemas IoMT.

A Tabela 19 apresenta os resultados de tempo de resposta e *Throughput* quando ocorre variação no processamento. Ao comparar a Configuração I com a Configuração II, houve uma melhoria significativa nos resultados. Isso ocorre porque a Configuração II inclui redundância no processamento.

Tabela 19 – Valores de Tempo de resposta e Vazão

Arquiteturas	Tempo de resposta (s)		Vazão (r/s)	
	VA	V-50%	VA	V-50%
Configuração 01	0,02840	0,01429	7,040214	138,379848
Configuração 02	0,02130	0,01429	14,07877	270,844189
Configuração 03	0,02128	0,01427	14,13033	272,023996
Configuração 04	0,02130	0,01429	14,0787	270,818737

Note: VA = valor atual, V-50% = valor melhorado em 50%, s = segundos, r/s = requisições por segundo.

6.5.3 Estudo de caso III: Modelo V em escala

O objetivo desse estudo é analisar a relação entre a capacidade de recursos e a confiabilidade em um hospital com cinco andares, aumentando proporcionalmente a quantidade de componentes por piso, por exemplo sensores, *switches* e VMs, para refletir o crescimento da carga. A arquitetura deve absorver esse aumento, mantendo níveis elevados de disponibilidade e continuidade operacional. O estudo demonstra a aplicabilidade do modelo ilustrado na Seção 5.5.5.

Para investigar esse comportamento, conduziu-se um experimento multifatorial. Os principais fatores foram as quantidades de dispositivos nas camadas críticas (sensores, switches e máquinas virtuais), escalonadas em cinco níveis para simular a expansão de um hospital. O Nível 1, que representa a linha de base, contempla a infraestrutura de um andar (10 sensores, 1 switch e 1 VM). Os níveis seguintes refletem a expansão linear, culminando no Nível 5, que simula cinco andares (50 sensores, 5 switches e 5 VMs). As métricas analisadas foram disponibilidade (A), tempo de resposta (RT) e vazão. Neste cenário, considera-se que a disponibilidade do sistema requer que todos os equipamentos estejam funcionais em cada andar; se qualquer componente falhar, o sistema é considerado indisponível.

A Tabela 20 apresenta os resultados para a configuração *sem* redundância. Nessa condição, a disponibilidade diminui à medida que o sistema escala. No Nível 1 (10 sensores, 1 switch e 1 VM), a disponibilidade é 99,13%, decaindo gradualmente até 96,19% no Nível 5. Esse comportamento evidencia a vulnerabilidade da arquitetura sem redundância, pois a adição de componentes amplia a probabilidade de interrupções. Embora o tempo de resposta permaneça em cerca de 3,17 s e a vazão aumente com a escala, a disponibilidade mostra uma tendência de queda.

Tabela 20 – Disponibilidade (A), tempo de resposta (RT) e vazão na arquitetura sem redundância.

Andares	Sensores	Switches	VMs	A	RT (s)	Vazão (req/s)
1	10	1	1	0,99138062	3,19254020	0,03515659
2	20	2	2	0,98380089	3,17428320	0,07109099
3	30	3	3	0,97639950	3,17383837	0,10665543
4	40	4	4	0,96911388	3,17366378	0,14221614
5	50	5	5	0,96191840	3,17355942	0,17777684

A Tabela 21 apresenta os resultados com redundância. Nesse cenário, a disponibilidade mantém-se praticamente constante em torno de 99,89% em todos os níveis, variando de 99,8989% no Nível 1 para 99,8907% no Nível 5, o que corresponde a uma variação de aproximadamente 0,008 ponto percentual. Assim como no primeiro cenário, o tempo de resposta permanece estável, entre 3,173 s e 3,174 s, enquanto a vazão cresce proporcionalmente aos recursos, alcançando 0,3233 req/s no Nível 5.

Tabela 21 – Disponibilidade (A), tempo de resposta (RT) e vazão na arquitetura com redundância.

Andares	Sensores	Switches	VMs	A	RT (s)	Vazão (req/s)
1	20	2	2	0,99898863	3,17428320	0,07109099
2	40	4	4	0,99895308	3,17366378	0,14221614
3	60	6	6	0,99892872	3,17348992	0,21333753
4	80	8	8	0,99891546	3,17340310	0,28445891
5	100	10	10	0,99890721	3,17335119	0,32334815

A comparação entre os cenários evidencia a contribuição da redundância para preservar a disponibilidade. Na arquitetura sem redundância, a disponibilidade cai de 0,9914 (99,14%) no Nível 1 para 0,9619 (96,19%) no Nível 5. Com redundância, a disponibilidade permanece próxima de 0,999 em todos os níveis, variando de 0,99899 no Nível 1 a 0,99891 no Nível 5. Os ganhos absolutos ao introduzir redundância são de 0,0076; 0,0152; 0,0225; 0,0298; e 0,0370 do Nível 1 ao 5, o que corresponde, respectivamente, a 0,76; 1,52; 2,25; 2,98; e 3,70 pontos percentuais. O tempo de resposta mantém-se praticamente constante nos dois cenários, em torno de 3,17 s. Em relação à vazão, a redundância quase dobra a capacidade para um mesmo nível, por exemplo, Nível 1: 0,0711 contra 0,0352 req/s; e Nível 5: 0,3233 contra 0,1778 req/s. Esses resultados indicam que a duplicação de componentes mitiga a degradação observada sem redundância, favorecendo a continuidade do serviço em ambientes de monitoramento em larga escala.

6.5.4 Estudo de caso IV: Modelo V em escala

Para investigar os impactos individuais e interativos dos componentes do sistema e da carga de trabalho sobre o desempenho, conduziu-se um quarto estudo de caso. O objetivo é identificar quais fatores exercem maior influência sobre a disponibilidade, o tempo de resposta e a vazão do sistema. Adota-se uma abordagem de DoE (MONTGOMERY; RUNGER, 2010). O estudo demonstra a aplicabilidade do modelo ilustrado na Seção 5.5.5.

Os fatores correspondem aos lugares do modelo: $pmUp$ (quantidade de sensores ativos), $pnUp$ (quantidade de dispositivos de rede) e $VmUp$ (quantidade de máquinas virtuais para processamento). Cada fator foi avaliado em dois níveis, mínimo e máximo. Para cada tratamento, realizou-se análise em regime permanente no modelo SPN. No modelo proposto, os níveis são definidos pela marcação (*tokens*) desses lugares.

Os valores das transições $tTimesensor$, $tNetwork$ e $tProcessingCloud$ são 1 s, 0,001 s e 0,014133 s, respectivamente. A Tabela 11 apresenta os valores adotados para MTTF e MTTR. A Tabela 22 apresenta a disponibilidade (A), tempo médio de resposta (R) e a vazão por tratamento. A vazão representa o número de requisições por segundo (req/s). Comparando o Tratamento 1, com recursos nos níveis mínimos, ao Tratamento 8, com recursos nos níveis máximos, observa-se um compromisso entre escala e disponibilidade. A disponibilidade decresce de 99,13% (Tratamento 1) para 96,19% (Tratamento 8), o que decorre da topologia em série sem redundância: cada componente adicional introduz um novo ponto potencial de falha, elevando a probabilidade de indisponibilidade. Por outro lado, o tempo de resposta permanece estável, enquanto a vazão é influenciada principalmente pelo fator associado ao sensor.

Tabela 22 – Tratamentos e resultados

Tratamentos	$pmUp$	$pnUp$	$VmUp$	A	R (s)	Vazão (req/s)
1	10	1	1	0,99138062	3,19254020	0,03515659
2	50	1	1	0,97995835	3,19254118	0,17657331
3	10	5	1	0,99098417	3,19225991	0,03516009
4	50	5	1	0,97956655	3,19226108	0,17659095
5	10	1	5	0,97351986	3,17383607	0,03539267
6	50	1	5	0,96230315	3,17383759	0,17775909
7	10	5	5	0,97313053	3,17355794	0,03539623
8	50	5	5	0,96191840	3,17355942	0,17777684

A Tabela 23 apresenta o *rank* de efeitos, quantificando o impacto de cada fator e de suas

interações nas métricas de disponibilidade e desempenho.

Tabela 23 – Rank de efeitos

Disponibilidade		Tempo de resposta		Vazão	
Fator/Interação	Efeito	Fator/Interação	Efeito	Fator/Interação	Efeito
VmUp	0,017754	VmUp	0,018703	pmUp	0,141900
pmUp	0,011320	pnUp	0,000279	VmUp	0,000711
pnUp	0,000390	pmUp	0,000001	pmUp×VmUp	0,000475
pmUp×VmUp	0,000103	pnUp×VmUp	0,000001	pnUp	0,000011

Para a disponibilidade, o número de máquinas virtuais (*VmUp*) aparece como o fator mais influente, com efeito de 0,017754. Isso indica que elevar a capacidade de processamento do nível mínimo ao máximo resulta em um incremento aproximado de 1,77% na disponibilidade. O número de sensores ativos (*pmUp*, efeito de 0,011320) também exerce um papel relevante, sugerindo que a capacidade de processamento e o volume de fontes de dados são determinantes para manter o sistema em operação.

Para o tempo de resposta, *VmUp* também apresenta um maior impacto, com efeito de 0,018703 s, o que indica que aumentar a capacidade de processamento é a principal via para reduzir a latência nesta configuração. O número de dispositivos de rede (*pnUp*) surge como uma influência subsequente, com um efeito menor.

Para a vazão, o número de sensores ativos (*pmUp*) é o fator dominante, com efeito de 0,141900 req/s. Esse resultado sugere que a taxa de geração e envio de dados pelos sensores é o principal motor da capacidade de tratamento de dados do sistema. O número de máquinas virtuais (*VmUp*) e a interação entre sensores e VMs (*pmUp* × *VmUp*) aparecem como fatores de importância secundária.

6.6 ESTUDO DE CASO V

Este estudo possui dois objetivos principais: (i) determinar a influência de cada componente na disponibilidade global de um sistema IoMT e (ii) sugerir e avaliar estratégias voltadas ao aumento da disponibilidade operacional do ambiente. Compreender o papel de cada componente na disponibilidade do sistema é útil para engenheiros, fabricantes e equipes de manutenção, pois revela como a falha de um único elemento pode comprometer o funcionamento de toda

a infraestrutura. Esse tipo de avaliação auxilia na priorização de componentes que requerem melhorias (SI; LIU; CAI, 2009).

Para realizar essa avaliação, aplica-se a técnica de ID explicada no Capítulo 2. Com esse método, todos os elementos que compõem a arquitetura do sistema são analisados para identificar aqueles cuja disponibilidade mais influencia a confiabilidade global do sistema. Além disso, é possível determinar quais componentes proporcionariam os maiores ganhos na disponibilidade do serviço quando sua própria confiabilidade é incrementada. A análise foi conduzida com foco na disponibilidade do sistema. Utilizando os valores de MTTF e MTTR de cada componente, calcularam-se os índices de importância de disponibilidade. A Tabela 24 resume esses índices para a arquitetura base, modelada por RBD e apresentada na Figura 19.

Tabela 24 – Resultados de importância de disponibilidade - Rodada I

Componente	ID	ID normalizado
CLD	0,999610	1,0
SNS	0,994885	0,995272
MCU	0,994818	0,995205
NT	0,994806	0,995194

Os resultados da análise de importância de disponibilidade mostram que o componente CLD (nuvem privada) apresenta a maior influência sobre a disponibilidade global do sistema (0,9996). Os demais componentes (SNS, MCU e NT) também exibem valores elevados, porém ligeiramente inferiores, indicando que falhas nesses elementos têm efeito menor na disponibilidade do sistema.

Com base no ranqueamento estabelecido por essa métrica, arquiteturas alternativas serão desenvolvidas, introduzindo redundância especificamente no componente que mais impacta a disponibilidade. Essa abordagem permite uma avaliação quantitativa de como estratégias de redundância contribuem para melhorar a disponibilidade do sistema IoMT.

Para viabilizar essa avaliação quantitativa e demonstrar o impacto de redundâncias incrementais, foi desenvolvida uma série de arquiteturas alternativas de IoMT. A Arquitetura 01 (Figura 45) estabelece a configuração que incorpora redundância no componente de nuvem privada (CLD), composto por CLD1 e CLD2, além de um único MCU, SNS e NT. Em sequência, foi realizada uma nova rodada de análise para identificar os componentes com maior impacto na disponibilidade do sistema (Tabela 25), com o objetivo de subsidiar a proposta de uma nova arquitetura.




Figura 45 – Arquitetura 01

Tabela 25 – Resultados de importância de disponibilidade - Rodada II

Componente	ID	ID normalizado
SNS	0,999764	1,0
MCU	0,999697	0,999932
NT	0,999683	0,999921
CLD1	0,004902	0,004904
CLD2	0,004902	0,004904

Isso levou ao desenho da Arquitetura 02 (Figura 46), na qual se introduz redundância na camada de sensores (SNS), agora com SNS 1 e SNS 2, mantendo a configuração dos demais elementos.




Figura 46 – Arquitetura 02

Dando continuidade, conduziu-se uma nova análise para apontar quais componentes mais influenciam a disponibilidade do sistema (Tabela 26), visando fundamentar a proposta de uma arquitetura revisada.

Consequentemente, a Arquitetura 03 (Figura 47) foi elaborada com redundância para os microcontroladores (MCU), passando a contar com MCU 1 e MCU 2, além dos sensores e da nuvem já duplicados.

Tabela 26 – Resultados de importância de disponibilidade - Rodada III

Componente	ID	ID normalizado
MCU	0,999875	1,0
NT	0,9998647	0,999988
CLD 1	0,0049037	0,004904
CLD 2	0,0049037	0,004904
SNS 1	0,0001784	0,000178
SNS 2	0,0001784	0,000178




Figura 47 – Arquitetura 03

Por fim, realizou-se uma nova investigação para mapear os componentes com maior efeito sobre a disponibilidade do sistema (Tabela 27), fornecendo subsídios à elaboração de uma arquitetura alternativa.

Tabela 27 – Resultados de importância de disponibilidade - Rodada IV

Componente	ID	ID normalizado
NT	0.999975	1,0
CLD 1	0.004904	0.004904
CLD 2	0.004904	0.004904
SNS 1	0.000178	0.000178
SNS 2	0.000178	0.000178
MCU 1	0.000111	0.000111
MCU 2	0.000111	0.000111

A Arquitetura 04 (Figura 48) estendeu essa abordagem incorporando redundância também para a camada de rede (NT), agora com NT 1 e NT 2, sobre a base de SNS, NT e CLD redundantes.

A Tabela 28 mostra que a redundância implementada melhora progressivamente a dispo-




Figura 48 – Arquitetura 04

nibilidade do sistema nas configurações avaliadas. Em relação à arquitetura base, cujo tempo de inatividade anual é de 46,393 h e a disponibilidade é de 0,994707, a Arquitetura 01 reduz o *downtime* para 3,6260 h, com disponibilidade de 0,999586. As arquiteturas subsequentes mantêm a tendência de redução, atingindo 2,0623 h na Arquitetura 02 e 1,0877 h na Arquitetura 03. A Arquitetura 04 apresenta a maior melhoria, com disponibilidade de 0,999975 (aproximadamente 4,62 “noves”) e apenas 0,2113 h de inatividade anual.

Tabela 28 – Resultado da disponibilidade das arquiteturas avaliadas.

Arquiteturas	Disponibilidade	9's	<i>Downtime</i> (h)
Arquitetura Base	0,994707	2,276339	46,393
Arquitetura 01	0,999586	3,383353	3,6260
Arquitetura 02	0,999764	3,628437	2,0623
Arquitetura 03	0,999875	3,906267	1,0877
Arquitetura 04	0,999975	4,617780	0,2113

6.7 ESTUDO DE CASO VI

Ampliando a análise de disponibilidade realizada para infraestruturas IoMT, esta etapa quantifica os custos totais associados às arquiteturas avaliadas. Essa quantificação financeira considera, de forma sistemática, dois domínios interdependentes: a camada de dispositivos IoT e o ambiente de nuvem privada. O modelo de custos delineado compreende, na camada IoT, o custo de aquisição de dispositivos, o custo do provedor de conectividade, o custo de mão de obra para implementação e integração com a nuvem, além dos custos associados à manutenção e à substituição de componentes.

De forma complementar, o modelo contempla, para a nuvem privada, o custo de aquisição

da infraestrutura, o custo de mão de obra para implantação e manutenção, bem como o custo de substituição de componentes. Essa estimativa, conduzida sob as perspectivas das camadas IoT e de nuvem privada, apoia o planejamento e a tomada de decisão em ambientes IoMT, ao permitir uma visão detalhada dos gastos nas camadas física e virtual da infraestrutura. As equações de estimativa de custo utilizadas nesta análise são apresentadas na Seção 5.6. No escopo desta estimativa, custos diretos atribuídos a contratos de SLA não foram incluídos.

A Tabela 29 apresenta os valores atribuídos a cada parâmetro de custo. Os valores relacionados aos componentes de hardware foram determinados com base em preços de mercado de revendedores e fabricantes autorizados (ETB Tech, 2025; Raspberry Pi Foundation, 2025; Analog Devices, 2025). Os custos de conectividade foram estimados a partir de ofertas comerciais recentes de banda larga nos Estados Unidos (Reuters, 2025). Os custos de mão de obra foram definidos considerando o salário-hora médio para técnicos de tecnologia da informação (Indeed, 2025). Todos esses valores correspondem às referências de preço e custo consultadas em fevereiro de 2026.

Tabela 29 – Parâmetros de custo

Parâmetro	Valor atribuído (USD)
Custo de Aquisição IoT (sensor)	5,41
Custo de Aquisição IoT (Raspberry)	120,00
Custo do Provedor de Conectividade (satélite)	39,99
Custo do Provedor de Conectividade (Internet a cabo)	55,00
Salário-hora (HW)	26,53
Horas requeridas (HR), Arquitetura Base	15
Horas requeridas (HR), Arquitetura 01	20
Horas requeridas (HR), Arquitetura 02	25
Horas requeridas (HR), Arquitetura 03	30
Horas requeridas (HR), Arquitetura 04	35
SLA (IoT e Nuvem)	0,00
Custo de Aquisição (nuvem)	9.713,44

Nas tabelas desta seção, CPC representa o custo do provedor de conectividade, LCI corresponde ao custo de mão de obra de implementação, LCM refere-se ao custo de mão de obra de manutenção e CS representa o custo de substituição de componentes. Nesse contexto, a Tabela 30 mostra que os custos da infraestrutura IoT variam de forma significativa em função do desenho arquitetural adotado. A Arquitetura Base apresenta o menor custo total, de USD 980,11, resultante da combinação dos custos de aquisição, conectividade, implemen-

tação, manutenção e substituição de componentes. À medida que são adicionados recursos redundantes nas camadas de sensor, microcontrolador, rede e conectividade, os custos de aquisição, mão de obra e substituição aumentam progressivamente, fazendo com que o custo total atinja USD 2.240,53 na Arquitetura 04, aproximadamente 2,3 vezes o valor observado para a Arquitetura Base.

Tabela 30 – Custo IoT

Arquiteturas	Custo Operacional			Custo de Manutenção		Total
	Aquisição	CPC	LCI	LCM	CS	
Arquitetura Base (1S + 1M + 1N + 1C)	125,41	39,99	397,95	397,95	18,81	980,11
Arquitetura 01 (1S + 1M + 1N + 2C)	125,41	39,99	530,60	530,60	18,81	1.245,41
Arquitetura 02 (2S + 1M + 1N + 2C)	130,82	39,99	663,25	663,25	19,62	1.516,93
Arquitetura 03 (2S + 2M + 1N + 2C)	250,82	39,99	795,90	795,90	37,62	1.920,23
Arquitetura 04 (2S + 2M + 2N + 2C)	250,82	94,99	928,55	928,55	37,62	2.240,53

Nota: *S*, *M*, *N* e *C* denotam as camadas de sensor, microcontrolador, rede e nuvem privada, respectivamente, e os coeficientes entre parênteses indicam o número de recursos paralelos em cada camada.

A Tabela 31 detalha os custos da infraestrutura de nuvem. A Arquitetura Base apresenta o menor custo total, de USD 11.966,36, resultante da soma do custo de aquisição (USD 9.713,44), da mão de obra de implementação e manutenção, representadas por LCI e LCM, ambas de USD 397,95, e do custo de substituição de componentes (CS), de USD 1.457,01. Nas Arquiteturas 01 a 04, o custo de aquisição sobe para USD 19.426,88 e o custo de substituição dobra para aproximadamente USD 2.914,03, enquanto LCI e LCM aumentam gradualmente em função do esforço adicional de trabalho. Com isso, o custo total da nuvem varia de USD 23.402,11 a USD 24.198,01, aproximadamente o dobro do valor observado para a Arquitetura Base.

Tabela 31 – Custo Nuvem

Arquiteturas	Custo Operacional			Custo de Manutenção		Total
	Aquisição	CPC	LCI	LCM	CS	
Arquitetura Base (1S + 1M + 1N + 1C)	9713,44		397,95	397,95	1.457,01	11.966,36
Arquitetura 01 (1S + 1M + 1N + 2C)	19426,88		530,60	530,60	2.914,03	23.402,11
Arquitetura 02 (2S + 1M + 1N + 2C)	19426,88		663,25	663,25	2.914,03	23.667,41
Arquitetura 03 (2S + 2M + 1N + 2C)	19426,88		795,90	795,90	2.914,03	23.932,71
Arquitetura 04 (2S + 2M + 2N + 2C)	19426,88		928,55	928,55	2.914,03	24.198,01

Nota: *S*, *M*, *N* e *C* denotam as camadas de sensor, microcontrolador, rede e nuvem privada, respectivamente, e os coeficientes entre parênteses indicam o número de recursos paralelos em cada camada.

A Tabela 32 consolida os custos da infraestrutura IoT e da infraestrutura de nuvem, mostrando que a Arquitetura Base oferece o menor custo total estimado, de USD 12.946,47, valor sensivelmente inferior ao das demais alternativas. As Arquiteturas 01 a 04 apresentam custos de nuvem próximos entre si, de modo que as diferenças no custo total decorrem principalmente

da infraestrutura IoT. A Arquitetura 04 registra o maior custo total, de USD 26.438,55, seguida pela Arquitetura 03, com USD 25.852,95, refletindo o aumento progressivo de recursos redundantes nas camadas de sensores, microcontroladores, rede e nuvem.

Tabela 32 – Custo total

Arquiteturas	Custo IoT	Custo da nuvem	Total
Arquitetura Base (1S + 1M + 1N + 1C)	980,11	11.966,36	12.946,47
Arquitetura 01 (1S + 1M + 1N + 2C)	1.245,41	23.402,11	24.647,52
Arquitetura 02 (2S + 1M + 1N + 2C)	1.516,93	23.667,41	25.184,35
Arquitetura 03 (2S + 2M + 1N + 2C)	1.920,23	23.932,71	25.852,95
Arquitetura 04 (2S + 2M + 2N + 2C)	2.240,53	24.198,01	26.438,55

Nota: *S*, *M*, *N* e *C* denotam as camadas de sensor, microcontrolador, rede e nuvem privada, respectivamente, e os coeficientes entre parênteses indicam o número de recursos paralelos em cada camada.

A Figura 49 relaciona o custo total das arquiteturas avaliadas com a disponibilidade. Ao passar da Arquitetura Base para a Arquitetura 01, o custo total aumenta de aproximadamente USD 12,9 mil para cerca de USD 24,6 mil, enquanto a disponibilidade cresce de cerca de 99,47% para aproximadamente 99,96%. A partir desse ponto, as Arquiteturas 02, 03 e 04 mantêm custos em uma faixa estreita, entre aproximadamente USD 25,2 mil e USD 26,4 mil, e produzem ganhos marginais de disponibilidade, com valores variando de cerca de 99,98% até 99,9975%.

O gráfico evidencia um comportamento de retornos decrescentes. A primeira inserção de redundância, representada pela Arquitetura 01, concentra a principal melhoria de disponibilidade por unidade de custo, enquanto acréscimos posteriores elevam o gasto total com benefícios progressivamente menores. Esse resultado auxilia na escolha de uma configuração que equilibre disponibilidade próxima de 100% e viabilidade financeira. Sob essa perspectiva, a Arquitetura 01 já se apresenta como uma alternativa de compromisso relevante, enquanto as arquiteturas seguintes tendem a ser justificadas apenas em cenários nos quais requisitos mais rigorosos de disponibilidade superem o aumento de custo associado.




Figura 49 – Custo total vs. disponibilidade por arquitetura

6.8 CONSIDERAÇÕES FINAIS

Este capítulo apresentou um conjunto de experimentos que demonstram a viabilidade dos modelos formais propostos para sistemas IoMT. Inicialmente, o texto descreve a configuração do ambiente experimental e realizou a validação dos modelos para disponibilidade e desempenho, assegurando aderência entre estimativas analíticas e medições. Em seguida, executou experimentos de disponibilidade e de performabilidade, além de um estudo com CTMC para estimar métricas sob diferentes configurações.

Em seguida, os Estudos de Caso I a IV mostraram, respectivamente, a comparação de métricas em modelos estendidos, o efeito de variações na capacidade de processamento da nuvem privada, a análise de escala em um hospital com cinco andares com ampliação proporcional de sensores, *switches* e VM por piso para verificar se a arquitetura absorve o aumento de carga mantendo alta disponibilidade, e a análise fatorial para identificar os componentes mais influentes sobre tempo de resposta, vazão e disponibilidade.

Na sequência, o Estudo de Caso V aplicou a métrica de Importância de Disponibilidade para priorizar componentes e propor arquiteturas redundantes, quantificando ganhos de disponibilidade obtidos com redundância incremental. Por fim, o Estudo de Caso VI avaliou custos nas camadas IoT e nuvem privada, consolidando aquisição, operação e manutenção e permitindo relacionar custo total com disponibilidade alcançada. Em conjunto, os resultados evidenciam que a abordagem integrada avaliação de desempenho e dependabilidade, identifica componentes de maior impacto, sustenta decisões de redundância e revela equilíbrios entre latência, taxa de processamento, disponibilidade e custo para orientar o projeto e a evolução de arquiteturas

IoMT.

A abordagem proposta contribui para o estado da arte como uma técnica adicional para o projeto de sistemas IoMT. Diferentes projetos podem ser avaliados, levando em consideração a avaliação conjunta de atributos de confiabilidade (por exemplo, MTTF) e desempenho (por exemplo, tempo de resposta).

7 CONCLUSÃO

A implantação de um sistema IoMT demanda uma infraestrutura eficiente que possa garantir confiabilidade e eficiência na coleta e análise de dados para atender aos requisitos estabelecidos. A IoMT é capaz de monitorar e controlar dispositivos de saúde conectados de maneira eficaz, considerando fatores como monitoramento contínuo de sinais vitais, diagnóstico remoto e gestão de dispositivos médicos. A natureza das operações em sistemas de IoT em saúde envolve o processamento e a interpretação de dados em tempo real, exigindo uma abordagem que garanta a disponibilidade contínua do sistema.

Apesar da importância dos sistemas IoMT na área da saúde, alguns aspectos dessas arquiteturas ainda devem ser explorados. A performabilidade, por exemplo, tem sua relevância associada à capacidade do sistema de garantir desempenho, disponibilidade e confiabilidade em diferentes cenários e condições operacionais. Esses sistemas precisam ser capazes de lidar com um grande volume de dados, garantindo tempos de resposta rápidos, enquanto mantêm altos níveis de precisão e segurança nas operações. Os sistemas IoMT na saúde têm o potencial de salvar vidas ao permitir o monitoramento remoto de pacientes, diagnósticos mais precisos e o acesso rápido a informações médicas. Isso pode resultar em intervenções médicas mais rápidas e eficazes, melhorando significativamente os resultados clínicos e a qualidade de vida dos pacientes.

Nesse contexto, esta tese apresentou uma abordagem de modelagem baseada em redes de Petri estocásticas e diagramas de blocos de confiabilidade para avaliar a disponibilidade e o desempenho de arquiteturas IoMT. São adotados RBD para estimar a disponibilidade e o tempo de inatividade do sistema com base nas condições operacionais. Já para a performabilidade, são adotadas redes de Petri estocásticas, as quais permitem a avaliação sob cargas de trabalho com características diversas. Além disso, foi utilizado CTMC para avaliação do sistema IoMT. Modelos foram avaliados para o ambiente em estudo, no qual foi possível realizar o DoE. Os modelos foram validados usando um sistema de teste real, demonstrando que a abordagem fornece estimativas de desempenho e disponibilidade próximas às de um sistema real. Os modelos concebidos tornam possível avaliar diferentes designs de sistemas antes de modificar ou implementar o sistema real ou protótipo.

Os experimentos comprovaram a viabilidade prática da estratégia de modelagem, bem como forneceram análises promissoras para os projetistas de sistemas IoMT. Especialmente

nos sistemas de monitoramento de saúde, é importante examinar as complexidades inerentes a essa tecnologia. Em muitas situações, esses sistemas podem demandar uma quantidade significativa de recursos, especialmente na ausência de políticas de gerenciamento adequadas. Além disso, ao direcionar o foco para os requisitos de desempenho, os sistemas podem enfrentar uma diminuição da eficácia na transmissão de dados.

Além disso, foram apresentados seis estudos de caso. Os resultados demonstram que a adição de equipamentos redundantes na arquitetura melhora tanto a disponibilidade quanto o desempenho. A inclusão de componentes redundantes aumenta a resiliência e a eficiência do sistema, garantindo operação contínua e melhor manejo das tarefas.

O estudo também mostrou que, quando a capacidade de processamento da nuvem privada é aprimorada, observa-se uma redução no tempo de resposta do sistema, permitindo que as requisições sejam atendidas de forma mais ágil. Além disso, o *throughput* também aumenta, o que significa que um maior número de requisições pode ser processado simultaneamente, melhorando a eficiência geral do sistema. Esses ganhos são importantes para garantir a escalabilidade e a capacidade de atender a um volume crescente de usuários, sem comprometer o desempenho.

7.1 CONTRIBUIÇÕES

Esta tese apresentou uma abordagem baseada em modelos estocásticos para avaliar o desempenho e a disponibilidade de arquiteturas IoMT com suporte de nuvem privada. A proposta auxilia na tomada de decisão quanto à seleção e à configuração de componentes sob diferentes cargas de trabalho e permite comparar alternativas de arquitetura antes da implementação em produção. As contribuições específicas deste estudo são as seguintes:

- **Medições:** os resultados das medições de desempenho e os valores estimados podem ser úteis para pesquisas futuras no contexto de Internet das Coisas Médicas;
- **Modelos de desempenho:** modelos analíticos baseados em um formalismo matemático de espaço de estados (redes de *Petri* estocásticas generalizadas) são capazes de expressar operações de envio e recebimento de mensagens. Além disso, esses modelos permitem estimar o tempo médio de resposta;
- **Modelos de disponibilidade:** desenvolveram-se modelos analíticos com RBD para

avaliar confiabilidade e disponibilidade em sistemas complexos, quantificando taxas de falha e confiabilidade de cada bloco e estimando a confiabilidade global. A avaliação considera MTTF e MTTR como variáveis-chave para a disponibilidade. Além disso, emprega-se CTMC para representar estados operacionais e de falha com suas taxas de transição, permitindo obter disponibilidade em regime permanente, tempo de inatividade anual e número de “noves”. Eventos concorrentes e sequenciais são descritos por taxas de transição na CTMC ou por composições em RBD, oferecendo uma visão abrangente do comportamento do sistema em diferentes cenários operacionais.

- **Modelos de performabilidade:** foram desenvolvidos modelos analíticos de performabilidade que combinam desempenho e disponibilidade de sistemas, proporcionando uma visão mais holística da operação de sistemas complexos. Experimentos foram realizados para integrar a disponibilidade e o desempenho, com o objetivo de entender como a disponibilidade pode influenciar o desempenho geral. Em sistemas críticos, a indisponibilidade de componentes essenciais pode levar a tempos de resposta mais longos e uma maior latência, impactando a eficiência. Ao realizar esses experimentos, é possível identificar gargalos e pontos de falha que, uma vez corrigidos, melhoram tanto a disponibilidade quanto o desempenho. Além disso, os modelos de performabilidade ajudam a avaliar a resiliência sob diferentes condições de carga e falhas;
- **Validação dos modelos de desempenho:** os modelos SPN concebidos foram validados por meio da comparação entre os resultados da análise estacionária e os experimentos realizados com sistemas reais;
- **Validação do modelo de disponibilidade:** os modelos de RBD concebidos foram validados por meio da comparação entre os resultados da análise e os experimentos realizados com sistemas reais;
- **Metodologia para avaliação de sistemas IoMT:** a metodologia proposta neste trabalho proporcionou auxílio à tomada de decisões a respeito das características a serem adotadas para sistemas de Internet das Coisas Médicas. A adoção dos modelos SPN concebidos e do planejamento de experimentos permitiu a avaliação de diferentes abordagens;
- **Identificação de fatores e interações mais significativos:** foi realizado um estudo para estimar os efeitos dos principais fatores e interações em sistemas de Internet das

Coisas Médicas em relação ao desempenho e à disponibilidade. Não há relatos de análise semelhante em trabalhos anteriores. Por meio deste estudo, é possível identificar e eliminar fatores e interações menos relevantes, a fim de permitir uma análise mais precisa, sem ruídos, em experimentos que avaliem o tempo médio de resposta e a disponibilidade;

- **Resultados dos experimentos:** esta tese realizou experimentos com os modelos SPN e RBD concebidos. Além disso, parâmetros foram definidos para o estudo de caracterização e *benchmarks* da literatura. Os resultados obtidos possibilitaram uma análise comparativa inédita de sistemas de Internet das Coisas Médicas.
- **Modelagem de custos:** foi realizado uma modelagem de custos específica para sistemas de Internet das Coisas Médicas. A abordagem visa fornecer uma estrutura que permita a estimativa dos custos associados à implementação e operação, contemplando sensores, dispositivos de controle, infraestrutura de rede e nuvem privada. Ao desenvolver essa modelagem, tomadores de decisão e projetistas terão uma ferramenta para avaliar recursos financeiros, contribuindo para a implementação eficiente e sustentável;

7.2 PUBLICAÇÕES

Nesta seção, são apresentados os artigos e projetos concebidos ao longo deste trabalho de pesquisa.

7.2.1 Periódicos

- **Valentim, Thiago;** Callou, Gustavo; França Filho, Cleunio; Tavares, Eduardo. Availability and performance assessment of iomt systems: A stochastic modeling approach. *Journal of Network and Systems Management*, Springer, v. 32, n. 4, p. 95, 2024.
- **Bezerra, Thiago Valentim;** Callou, Gustavo; Airton, Francisco; Tavares, Eduardo. A Modeling-Based Approach for Performance and Availability Assessment of IoMT Systems. *Electronics*, v. 14, p. 1157, 2025. ISSN 2079-9292.

7.2.2 Periódicos Cooperação

- Filho, Cleunio França; Borba, Erick; **Valentim, Thiago**; Nascimento, Erick; Silva, Dailiton; Dantas, Jamilson; Tavares, Eduardo. Smart street lighting systems: performance, energy consumption and availability assessment. *Journal of Reliable Intelligent Environments*, v. 11, p. 19, 2025.

7.2.3 Conferências

- **Valentim, Thiago**; França Filho, Cleunio; Vinícius, Alison; Callou, Gustavo; Tavares, Eduardo. Availability Assessment of Internet of Medical Things Architecture using Private Cloud. *Seminário Integrado de Software e Hardware (SEMISH 2023)*.
- **Valentim, Thiago**; Callou, Gustavo; França Filho, Cleunio; Tavares, Eduardo. A Stochastic Petri Net-Based Approach for Evaluating the Performability of Internet of Medical Things. *Latin-American Symposium on Dependable and Secure Computing (LADC)*, 2024.
- **Bezerra, Thiago**; Vinícius, Marcos; Ciane, Aline; Callou, Gustavo; França, Cleunio; Tavares, Eduardo. An approach based on IoT and machine learning for monitoring patients on healthcare centers. *XXV Simpósio Brasileiro de Computação Aplicada à Saúde (SBCAS 2025)*, 2025. p. 260.

7.2.4 Conferências Cooperação

- Leonardo, W.; Alison Vinicius Gomes da Silva; **Bezerra, T. V.**; Callou, G. R. A.. Análise de Sensibilidade do Serviço Nextcloud Hospedado Em Nuvem Privada. In: *Seminário Integrado de Software e Hardware*, 2025, Maceió. Análise de Sensibilidade do Serviço Nextcloud Hospedado Em Nuvem Privada, 2025.
- Moraes, M. V. V.; Silva, A. C. G.; França, Cleunio; Callou, G. R. A.; Tavares, Eduardo; **Bezerra, T. V.**. Sistemas de Monitoramento de Pacientes Com IoMT e Aprendizado de Máquina Em Cuidados de Saúde. In: *Seminário Integrado de Software e Hardware*, 2025, Maceió. Sistemas de Monitoramento de Pacientes Com Iomt e Aprendizado de Máquina Em Cuidados de Saúde, 2025.

- França, Cleunio; **Valentim, Thiago** ; Borba, E.; Eduardo Tavares. Stochastic Petri Net Modeling For Analysis Of Adaptive Street Lighting Systems. In: 27th IEEE International Conference On High Performance Computing And Communications (HPCC), 2025, Exeter. Stochastic Petri Net Modeling For Analysis Of Adaptive Street Lighting Systems, 2025.
- França, Cleunio; **Bezerra, T. V.** ; Borba, E.; Eduardo Tavares. Predictive Maintenance Strategies For Smart Street Lighting Systems: a Stochastic Modeling. In: IEEE International Smart Cities Conference (ISC2-2025), 2025, Patras. IEEE International Smart Cities Conference (ISC2-2025), 2025.
- Silva, J. D. T.; Moraes, M. V. V.; Carli, R. C.; Callou, G. R. A.; Eduardo Tavares; **Bezerra, T. V.**. Validation Of Predictive Models With Random Forest And Xgboost For Risk Stratification In Stroke Patients. In: XVIII Brazilian Symposium On Bioinformatics, 2025, Fortaleza. XVIII Brazilian Symposium On Bioinformatics (BSB 2025), 2025.
- Leonardo, Wenderson; **Bezerra, Thiago**; Callou, Gustavo. Stochastic Petri Net Models For Availability And Performance Evaluation Of Nextcloud Service Hosted In Apache Cloudstack. In: LADC 2024: 13th Latinamerican Symposium On Dependable And Secure Computing, 2024, Recife Brazil. Proceedings Of The 13th Latin-american Symposium On Dependable And Secure Computing. New York: Acm. P. 165.
- Silva, Alison da; Callou, Gustavo; **Valentim, Thiago**; Dantas, Jamilson. Análise de Desempenho de Servidores de Arquivos Em Nuvem Privada. In: Seminário Integrado de Software e Hardware, 2023, Brasil. Anais do I Seminário Integrado de Software e Hardware (SEMISH 2023), 2023. P. 272.
- França, Cleunio; **Valentim, Thiago**; Callou, G. R. A.; Borba, E.; Tavares, Eduardo. Stochastic Modeling For Performance And Availability Evaluation Of Street Lighting Systems. In: IEEE 9th World Forum On Internet Of Things, 2023, Aveiro. IEEE 9th World Forum On Internet Of Things, 2023.

7.2.5 Capítulo de livro

- **Valentim, Thiago**; Callou, Gustavo; França Filho, Cleunio; Tavares, Eduardo. Cybersecurity for Healthcare Systems in the Internet of Medical Things Era. - Performance and

Availability Models for IoMT Systems: an approach based on CTMC and SPN. Elsevier. ISBN: 9780443274480.

7.2.6 Projetos aprovados em órgãos de fomento

- Edital FACEPE 22/2024: Apoio à Popularização da Ciência na Semana Nacional de Ciência e Tecnologia: Sistema Inteligente de Monitoramento de Pacientes com Integração de IoT, Machine Learning e Sensores: Uma Abordagem para Hospitais Conectados. ARC-0367-1.03/24. Recurso total: R\$ 4.600. Coordenador: **Thiago Valentim Bezerra**;
- Edital FACEPE 10/2023: Apoio à Popularização da Ciência na Semana Nacional de Ciência e Tecnologia: Integrando Ciência, Tecnologia e Saúde: Conhecendo o Monitoramento Inteligente em Ambientes Hospitalares. ARC-0307-1.03/23. Recurso total: R\$ 5.000. Coordenador: **Thiago Valentim Bezerra**;
- Edital FACEPE 05/2023: PET – Programa de Extensão Tecnológica: Monitoramento Inteligente em Ambientes Hospitalares: Utilização de uma plataforma de baixo custo para garantir condições ideais de conforto e segurança, no contexto da Internet das Coisas, em hospitais da Mata Sul de Pernambuco. ARC-0370-1.03/23. Recurso total: R\$ 26.400. Coordenador: **Thiago Valentim Bezerra**. Projeto destaque;
- Edital 33/2024: COMPET Superior FACEPE/SECTI: Abordagem Integrada de IoT, Machine Learning e Sensores para Monitoramento de Pacientes em Ambientes Hospitalares. ARC-0094-1.03/25. Recurso total: R\$ 44.600. Coordenador: **Thiago Valentim**.

7.3 LIMITAÇÕES

Esta pesquisa apresenta limitações alinhadas às escolhas de modelagem e ao escopo experimental. Nos modelos RBD e SPN, adotam-se taxas constantes de falha e de reparo com independência entre eventos, o que pode não refletir variações operacionais reais. Além disso, a modelagem em SPN está sujeita à explosão de estados à medida que se aumentam camadas, dispositivos e interações, o que limita a escala analisável sem técnicas de redução. A validação ocorreu em *testbed* com nuvem privada e conjunto controlado de dispositivos, podendo divergir de ambientes hospitalares de grande porte.

Não foram incluídos arranjos de redundância do tipo *k-out-of-n* nem cenários de recuperação geograficamente distribuída; neste trabalho, foram considerados cenários seriais e estratégias de redundância *hot*, *cold* e *standby*. Esses aspectos permanecem como oportunidades para trabalhos futuros, incluindo o estudo de correlação de falhas entre camadas e a aplicação de técnicas de redução do espaço de estados.

7.4 TRABALHOS FUTUROS

Esta tese investigou aspectos de arquiteturas IoMT, com foco em desempenho e disponibilidade, por meio de modelos SPN, RBD e CTMC, com validações em nuvem privada. Apesar dos avanços, há espaço para extensões relevantes. Pretende-se propor um *índice de tempo de resposta* como técnica alternativa para identificar o dispositivo que mais influencia a latência fim a fim e realizar uma análise mais detalhada dos requisitos de performabilidade, refinando os modelos e a calibração de parâmetros. As linhas abaixo sintetizam direções promissoras.

- **Índice de tempo de resposta:** desenvolver e validar um índice que atribua pesos à contribuição de cada componente para a latência total, permitindo priorizar intervenções e orientar decisões de arquitetura.
- **Desempenho e energia em microcontroladores:** conduzir uma banca de testes para quantificar a relação entre desempenho e consumo energético de microcontroladores sob diferentes cargas. Medir corrente, potência média e energia por amostra, pacote e inferência, derivando modelos energéticos que possam ser acoplados aos modelos analíticos.
- **Desempenho de protocolos de comunicação:** avaliar protocolos usados em IoMT como MQTT, AMQP, CoAP, *Hypertext Transfer Protocol* (HTTP) e *WebSocket* além de camadas de acesso como LoRaWAN, WiFi e 6LoWPAN medindo latência, jitter, vazão, perda, *overhead* por mensagem, eficiência energética e robustez em cenários com variação de carga e condições de rede. Comparar configurações como níveis de QoS no MQTT, tamanho de *payload*, confirmações de entrega e uso de criptografia em ambiente de laboratório e simulação.
- **Aprendizado de máquina e aprendizado profundo na borda:** investigar modelos leves para detecção de quedas e reconhecimento facial em ambientes hospitalares,

avaliando *trade-offs* entre acurácia e latência e reportar métricas como sensibilidade, especificidade, F1 e tempo de inferência.

- **Modelagem preditiva por regressão:** aplicar algoritmos de regressão para estimar risco de eventos clínicos, como AVC, a partir de séries temporais de sinais vitais e variáveis contextuais. Comparar métodos como regressão linear, Ridge/Lasso, Random Forest Regressor e Gradient Boosting, avaliar erro (RMSE, MAE), calibração e utilidade clínica de escores de risco.
- **Otimização multiobjetivo:** formular problemas de projeto que considerem simultaneamente custo, disponibilidade, desempenho e energia, e métodos de otimização para recomendar configurações de sensores, rede, *hosts* e VMs.

REFERÊNCIAS

- AHMADI, H.; ARJI, G.; SHAHMORADI, L.; SAFDARI, R.; NILASHI, M.; ALIZADEH, M. The application of internet of things in healthcare: a systematic literature review and classification. *Universal Access in the Information Society*, Springer, v. 18, n. 4, p. 837–869, 2019.
- AL-FUQAHA, A.; GUIZANI, M.; MOHAMMADI, M.; ALEDHARI, M.; AYYASH, M. Internet of things: A survey on enabling technologies, protocols, and applications. *IEEE communications surveys & tutorials*, IEEE, v. 17, n. 4, p. 2347–2376, 2015.
- ALSHAMMARI, H. H. The internet of things healthcare monitoring system based on mqtt protocol. *Alexandria Engineering Journal*, Elsevier, v. 69, p. 275–287, 2023.
- ALTAWY, R.; YOUSSEF, A. M. Security tradeoffs in cyber physical systems: A case study survey on implantable medical devices. *Ieee Access*, IEEE, v. 4, p. 959–979, 2016.
- Analog Devices. *MAX30102 - Pulse Oximeter and Heart Rate Sensor*. 2025. <<https://www.analog.com/en/products/max30102.html>>. Acesso em: 19 de abril de 2025.
- ANDRADE, E.; NOGUEIRA, B.; JÚNIOR, I. d. F.; ARAÚJO, D. Performance and availability trade-offs in fog-cloud iot environments. *Journal of Network and Systems Management*, Springer, v. 29, p. 1–27, 2021.
- ASGHARI, P.; RAHMANI, A. M.; JAVADI, H. H. S. Internet of things applications: A systematic review. *Computer Networks*, Elsevier, v. 148, p. 241–261, 2019.
- ATHIRA, A.; DEVIKA, T.; VARSHA, K. et al. Design and development of iot based multi-parameter patient monitoring system. In: IEEE. *2020 6th International Conference on Advanced Computing and Communication Systems (ICACCS)*. [S.l.], 2020. p. 862–866.
- AVIZIENIS, A.; AL. et. *Fundamental Concepts of Dependability*. S.l., 2001.
- BAGGA, M.; THAKRAL, P.; BAGGA, T. A study on iot: Model, communication protocols, security hazards & countermeasures. In: IEEE. *2018 Fifth International Conference on Parallel, Distributed and Grid Computing (PDGC)*. [S.l.], 2018. p. 591–598.
- BALBO, G. Introduction to stochastic petri nets. In: *Lectures on Formal Methods and Performance Analysis: First EEF/Euro Summer School on Trends in Computer Science, Bergen Dal, The Netherlands, July 3-7, 2000: Revised Lectures*. S.l.: Springer, 2001. p. 84–155.
- BAUER, E.; ADAMS, R. *Reliability and availability of cloud computing*. [S.l.]: John Wiley & Sons, 2012.
- BERNARDI, S.; MERSEGUER, J.; PETRIU, D. C. Dependability modeling and analysis of software systems specified with uml. *ACM Computing Surveys (CSUR)*, v. 45, n. 1, p. 2, 2012.
- BOLCH, G.; GREINER, S.; MEER, H. de; TRIVEDI, K. *Queueing networks and markov chains: Modeling and performance evaluation with computer science applications* john wiley. New York, NY, 1998.

BOLCH, G.; GREINER, S.; MEER, H. de; TRIVEDI, K. S. *Queueing networks and Markov chains: modeling and performance evaluation with computer science applications*. [S.l.]: John Wiley & Sons, 2006.

BOUKREDERA, D.; ADEL-AISSANOU, K. Modeling and performance analysis of cognitive radio networks using stochastic timed colored petri nets. *Wireless Personal Communications*, Springer, v. 112, n. 3, p. 1659–1687, 2020.

BUZACOTT, J. A. Finding the mtbf of repairable systems by reduction of the reliability block diagram. *Microelectronics Reliability*, Elsevier, v. 6, n. 2, p. 105–112, 1967.

CALLOU, G.; SOUSA, E.; MACIEL, P.; TAVARES, E.; ARAUJO, C.; SILVA, B.; ROSA, N.; MARWAH, M.; SHARMA, R.; SHAH, A. et al. Impact analysis of maintenance policies on data center power infrastructure. In: IEEE. *2010 IEEE international conference on systems, man and cybernetics*. [S.l.], 2010. p. 526–533.

CATHERWOOD, P. A.; STEELE, D.; LITTLE, M.; MCCOMB, S.; MCLAUGHLIN, J. A community-based iot personalized wireless healthcare solution trial. *IEEE journal of translational engineering in health and medicine*, IEEE, v. 6, p. 1–13, 2018.

CENTENARO, M.; VANGELISTA, L.; ZANELLA, A.; ZORZI, M. Long-range communications in unlicensed bands: The rising stars in the iot and smart city scenarios. *IEEE Wireless Communications*, IEEE, v. 23, n. 5, p. 60–67, 2016.

CHEN, Y.; KUNZ, T. Performance evaluation of iot protocols under a constrained wireless access network. In: IEEE. *2016 International Conference on Selected Topics in Mobile & Wireless Networking (MoWNeT)*. [S.l.], 2016. p. 1–7.

Circuit Cellar. *Tips for Predicting Product Reliability*. 2022. Acesso em: 10 set. 2023. Disponível em: <<http://circuitcellar.com/cc-blog/tips-for-predicting-productreliability/>>.

CISCO, T.; INTERNET, A. Cisco: 2020 ciso benchmark report. *Comput. Fraud Secur.*, v. 2020, n. 3, p. 4–4, 2020.

COLLINA, M.; BARTOLUCCI, M.; VANELLI-CORALLI, A.; CORAZZA, G. E. Internet of things application layer protocol analysis over error and delay prone links. In: IEEE. *2014 7th Advanced Satellite Multimedia Systems Conference and the 13th Signal Processing for Space Communications Workshop (ASMS/SPSC)*. [S.l.], 2014. p. 398–404.

CRICK, M.; HILL, M. The role of sensitivity analysis in assessing uncertainty. In: *Uncertainty analysis for performance assessments of radioactive waste disposal systems*. [S.l.: s.n.], 1987.

DANG, L. M.; PIRAN, M. J.; HAN, D.; MIN, K.; MOON, H. A survey on internet of things and cloud computing for healthcare. *Electronics*, MDPI, v. 8, n. 7, p. 768, 2019.

DEWANTI, D.; SINGGIH, M. L. Cost analysis for iot based condition based maintenance to increase productivity. *IPTEK Journal of Proceedings Series*, n. 5, p. 434–440, 2019.

DIGHRIRI, M. Internet of medical things (iotm) based sustainable architecture for health monitoring system. In: IEEE. *2023 1st International Conference on Innovations in High Speed Communication and Signal Processing (IHCSPP)*. [S.l.], 2023. p. 17–20.

- DISTEFANO, S.; SCARPA, M.; PULIAFITO, A. Modeling distributed computing system reliability with drbd. In: IEEE. *2006 25th IEEE Symposium on Reliable Distributed Systems (SRDS'06)*. [S.l.], 2006. p. 106–118.
- DJAHAFI, M.; SALMI, N. Using stochastic petri net modeling for self-adapting publish/subscribe iot systems. In: IEEE. *NOMS 2023-2023 IEEE/IFIP Network Operations and Management Symposium*. [S.l.], 2023. p. 1–4.
- DUGGAL, A. HI7 2. x security. In: *Proceedings of the The 8th Annual HITB Security Conference*. [S.l.: s.n.], 2017.
- DWIVEDI, R.; MEHROTRA, D.; CHANDRA, S. Potential of internet of medical things (iomt) applications in building a smart healthcare system: A systematic review. *Journal of oral biology and craniofacial research*, Elsevier, v. 12, n. 2, p. 302–318, 2022.
- EBELING, C. E. *An Introduction to Reliability and Maintainability Engineering*. S.l.: Tata McGraw-Hill Education, 2004.
- EFSTRATIA, M.; SALEM, A.-B. M.; GEORGE, P. Modelling and analyzing a hospital procedure using a petri-net approach. *International Journal of Computer Science and Engineering*, v. 1, n. 2, 1996.
- ETB Tech. *Supermicro SuperServer SYS-4028GR-TRT*. 2025. Disponível em: site da ETB Tech. Acesso em: 19 de abril de 2025.
- EVDOKIMOV, I. V.; ALALWAN, A. R. J.; TSAREV, R. Y.; YAMSKIKH, T. N.; TSAREVA, O. A.; PUPKOV, A. N. A cost estimation approach for iot projects. In: IOP PUBLISHING. *Journal of Physics: Conference Series*. [S.l.], 2019. v. 1176, n. 4, p. 042083.
- EZHILARASI, M.; KUMAR, A.; SHANMUGAPRIYA, M.; GHANSHALA, A.; GUPTA, A. Integrated healthcare monitoring system using wireless body area networks and internet of things. In: IEEE. *2023 4th International Conference on Innovative Trends in Information Technology (ICITIIT)*. [S.l.], 2023. p. 1–5.
- FARAHANI, B.; FIROUZI, F.; CHANG, V.; BADAROGLU, M.; CONSTANT, N.; MANKODIYA, K. Towards fog-driven iot ehealth: Promises and challenges of iot in medicine and healthcare. *Future generation computer systems*, Elsevier, v. 78, p. 659–676, 2018.
- Federal Aviation Administration. *FAA-HDBK-006D*. 2020. Disponível em: <<https://www.tc.faa.gov/its/worldpac/standards/FAA-HDBK-006D%2010-08-2020GB.pdf>>.
- FIGUEIRÊDO, J.; MACIEL, P.; CALLOU, G.; TAVARES, E.; SOUSA, E.; SILVA, B. Estimating reliability importance and total cost of acquisition for data center power infrastructures. In: IEEE. *2011 IEEE international conference on systems, man, and cybernetics*. [S.l.], 2011. p. 421–426.
- FINNEGAN, J.; BROWN, S. A comparative survey of lpwa networking. *arXiv preprint arXiv:1802.04222*, 2018.
- FLURY, M.; POTURALSKI, M.; PAPADIMITRATOS, P.; HUBAUX, J.-P.; BOUDEC, J.-Y. L. Effectiveness of distance-decreasing attacks against impulse radio ranging. In: *Proceedings of the third ACM conference on Wireless network security*. [S.l.: s.n.], 2010. p. 117–128.

- FOTOUHI, H.; CAUSEVIC, A.; LUNDQVIST, K.; BJÖRKMAN, M. Communication and security in health monitoring systems—a review. In: IEEE. *2016 IEEE 40th annual computer software and applications conference (COMPSAC)*. [S.l.], 2016. v. 1, p. 545–554.
- FRANCES, C. R. L. *Introdução às Redes de Petri*. S.l., 2003.
- FRANK, P. *Introduction to sensitivity analysis*. [S.l.]: Academic Press London, 1978.
- GATOUILLAT, A.; BADR, Y.; MASSOT, B.; SEJDIĆ, E. Internet of medical things: A review of recent contributions dealing with cyber-physical systems in medicine. *IEEE internet of things journal*, IEEE, v. 5, n. 5, p. 3810–3822, 2018.
- GERMAN, R. *Performance Analysis of Communication Systems with Non-Markovian Stochastic Petri Nets*. New York, NY, USA: John Wiley & Sons, Inc., 2000. 456 p.
- GHOSH, A.; SAHA, R.; MISRA, S. Persistent service provisioning framework for iomt based emergency mobile healthcare units. *IEEE Journal of Biomedical and Health Informatics*, IEEE, v. 26, n. 12, p. 5851–5858, 2022.
- GIA, T. N.; JIANG, M.; RAHMANI, A.-M.; WESTERLUND, T.; LILJEBERG, P.; TENHUNEN, H. Fog computing in healthcare internet of things: A case study on ecg feature extraction. In: IEEE. *2015 IEEE international conference on computer and information technology; ubiquitous computing and communications; dependable, autonomic and secure computing; pervasive intelligence and computing*. [S.l.], 2015. p. 356–363.
- GOMES, C.; TAVARES, E.; JUNIOR, M. N. d. O.; NOGUEIRA, B. Cloud storage availability and performance assessment: a study based on nosql dbms. *The Journal of Supercomputing*, Springer, v. 78, n. 2, p. 2819–2839, 2022.
- GRAY, J.; SIEWIOREK, D. P. High-availability computer systems. *Computer*, IEEE, v. 24, n. 9, p. 39–48, 1991.
- GROSS, D. *Fundamentals of queueing theory*. [S.l.]: John wiley & sons, 2008.
- GUBBI, J.; BUYYA, R.; MARUSIC, S.; PALANISWAMI, M. Internet of things (iot): A vision, architectural elements, and future directions. *Future generation computer systems*, Elsevier, v. 29, n. 7, p. 1645–1660, 2013.
- GUNTHER, N. J. *The Practical Performance Analyst: performance-by-design techniques for distributed systems*. [S.l.]: McGraw-Hill, Inc., 1997.
- GUPTA, A.; CHAURASIYA, V. K. Efficient task-offloading in iot-fog based health monitoring system. In: IEEE. *2022 OITS International Conference on Information Technology (OCIT)*. [S.l.], 2022. p. 495–500.
- GUPTA, S.; SINGH, G. P.; KUMAWAT, S. Petri net recommender system to model metabolic pathway of polyhydroxyalkanoates. *International Journal of Knowledge and Systems Science*, IGI Global, v. 10, n. 2, p. 42, April-June 2019. Copyright © 2019, IGI Global. Copying or distributing in print or electronic forms without written permission of IGI Global is prohibited.
- GUPTA, S.; SINGH, G. P.; KUMAWAT, S. Modeling and targeting an essential metabolic pathway of plasmodium falciparum in apicoplast using petri nets. *Applied Mathematics-A Journal of Chinese Universities*, Springer, v. 37, n. 1, p. 91–110, 2022.

HALILI, E. H. *Apache JMeter*. [S.l.: s.n.], 2008.

HAMBY, D. M. A review of techniques for parameter sensitivity analysis of environmental models. *Environmental monitoring and assessment*, Springer, v. 32, p. 135–154, 1994.

HARDY, S.; ROBILLARD, P. N. Modeling and simulation of molecular biology systems using petri nets: modeling goals of various approaches. *Journal of bioinformatics and computational biology*, World Scientific, v. 2, n. 04, p. 619–637, 2004.

HASSAN, S. R.; AHMAD, I.; AHMAD, S.; ALFAIFY, A.; SHAFIQ, M. Remote pain monitoring using fog computing for e-healthcare: An efficient architecture. *Sensors*, MDPI, v. 20, n. 22, p. 6574, 2020.

HAVERKORT, B. R. Markovian models for performance and dependability evaluation. In: SPRINGER. *School organized by the European Educational Forum*. [S.l.], 2000. p. 38–83.

HENNESSY, J. L.; PATTERSON, D. A. *Computer architecture: a quantitative approach*. [S.l.]: Elsevier, 2011.

HSUEH, M.-C.; TSAI, T. K.; IYER, R. K. Fault injection techniques and tools. *Computer*, IEEE, v. 30, n. 4, p. 75–82, 1997.

ILYAS, A.; ALATAWI, M. N.; HAMID, Y.; MAHFOOZ, S.; ZADA, I.; GOHAR, N.; SHAH, M. A. Software architecture for pervasive critical health monitoring system using fog computing. *Journal of Cloud Computing*, Springer, v. 11, n. 1, p. 84, 2022.

ILYAS, A.; MAHFOOZ, S.; MEHMOOD, Z.; ALI, G.; ELAFFENDI, M. Two-way approach for improved real-time transmission in fog-iot-based health monitoring system for critical patients. *Computer Systems Science & Engineering*, v. 46, n. 3, 2023.

Indeed. *IT Technician Salaries in the United States*. 2025. <<https://www.indeed.com/cmp/Information-Technology-1/salaries/IT-Technician>>. Acesso em: 19 de abril de 2025.

IOOSS, B.; LEMAÎTRE, P. A review on global sensitivity analysis methods. *Uncertainty management in simulation-optimization of complex systems: algorithms and applications*, Springer, p. 101–122, 2015.

ISLAM, M. M.; NOORUDDIN, S.; KARRAY, F.; MUHAMMAD, G. Internet of things: Device capabilities, architectures, protocols, and smart applications in healthcare domain. *IEEE Internet of Things Journal*, IEEE, v. 10, n. 4, p. 3611–3641, 2022.

ISLAM, S. R.; KWAK, D.; KABIR, M. H.; HOSSAIN, M.; KWAK, K.-S. The internet of things for health care: a comprehensive survey. *IEEE access*, IEEE, v. 3, p. 678–708, 2015.

JAGADEESWARI, V.; SUBRAMANIASWAMY, V.; LOGESH, R. t. a.; VIJAYAKUMAR, V. A study on medical internet of things and big data in personalized healthcare system. *Health information science and systems*, Springer, v. 6, n. 1, p. 14, 2018.

JAIN, R. *The art of computer systems performance analysis: techniques for experimental design, measurement, simulation, and modeling*. [S.l.]: Wiley New York, 1991. v. 1.

JANOŮŠEK, V. *Modelling Objects by Petri Nets*. Tese (Doutorado) — PhD. thesis, Brno University of Technology, Brno, Czech Republic, 1998.

- JARA, A. J.; ZAMORA, M. A.; SKARMETA, A. F. An architecture for ambient assisted living and health environments. In: SPRINGER. *International Work-Conference on Artificial Neural Networks*. [S.l.], 2009. p. 882–889.
- JASSIM, M. M.; MOSA, M. M.; OKBI, Z. A. I.; ABDULLAH, S. B.; TAHA, S. W.; MIGO, P.; KONDAKOVA, S. Cost-effectiveness analysis of iot deployment in 5g networks. In: IEEE. *2024 36th Conference of Open Innovations Association (FRUCT)*. [S.l.], 2024. p. 493–502.
- JAVDANI, H.; KASHANIAN, H. Internet of things in medical applications with a service-oriented and security approach: a survey. *Health and Technology*, Springer, v. 8, n. 1, p. 39–50, 2018.
- JENSEN, K. Coloured petri nets: A high level language for system design and analysis. In: SPRINGER. *International Conference on Application and Theory of Petri Nets*. [S.l.], 1989. p. 342–416.
- KAFHALI, S. E.; SALAH, K. Efficient and dynamic scaling of fog nodes for iot devices. *The Journal of Supercomputing*, Springer, v. 73, p. 5261–5284, 2017.
- KAFHALI, S. E.; SALAH, K. Performance modelling and analysis of internet of things enabled healthcare monitoring systems. *IET Networks*, Wiley Online Library, v. 8, n. 1, p. 48–58, 2019.
- KALMAR, E. E.; KERTESZ, A. Investigating operational costs of iot cloud applications. In: SPRINGER. *Cloud Infrastructures, Services, and IoT Systems for Smart Cities: Second EAI International Conference, IISSC 2017 and CN4IoT 2017, Brindisi, Italy, April 20–21, 2017, Proceedings 2*. [S.l.], 2018. p. 141–150.
- KANOUN, K.; SPAINHOWER, L. *Dependability Benchmarking for Computer Systems*. S.l.: John Wiley & Sons, 2008. v. 72.
- KAPUR, K. C.; PECHT, M. *Reliability Engineering*. S.l.: John Wiley & Sons, 2014.
- KEESE, W. *A Method of Determining a Confidence Interval for Availability*. [S.l.], 1965.
- KELLY, J. T.; CAMPBELL, K. L.; GONG, E.; SCUFFHAM, P. The internet of things: Impact and implications for health care delivery. *Journal of medical Internet research*, JMIR Publications Toronto, Canada, v. 22, n. 11, p. e20135, 2020.
- KHAN, S.; SHAH, I. A.; TAIRAN, N.; SHAH, H.; NADEEM, M. F. Optimal resource allocation in fog computing for healthcare applications. *Comput. Mater. Contin*, v. 71, n. 3, p. 6147–6163, 2022.
- KIM, D. S.; MACHIDA, F.; TRIVEDI, K. S. Availability modeling and analysis of a virtualized system. In: IEEE. *2009 15th IEEE Pacific Rim International Symposium on Dependable Computing*. [S.l.], 2009. p. 365–371.
- KLEIJNEN, J. P. Sensitivity analysis and optimization in simulation: design of experiments and case studies. In: *Proceedings of the 27th conference on Winter simulation*. [S.l.: s.n.], 1995. p. 133–140.
- KLEINROCK, L. *Queueing systems. Volume I: theory*. [S.l.]: wiley New York, 1975.

KOUNEV, S. Performance modeling and evaluation of distributed component-based systems using queueing petri nets. *IEEE Transactions on Software Engineering*, IEEE, v. 32, n. 7, p. 486–502, 2006.

KOUTRAS, D.; STERGIOPOULOS, G.; DASAKLIS, T.; KOTZANIKOLAOU, P.; GLYNOS, D.; DOULIGERIS, C. Security in iomt communications: A survey. *Sensors*, MDPI, v. 20, n. 17, p. 4828, 2020.

KUO, W.; ZUO, M. J. *Optimal reliability modeling: principles and applications*. [S.l.]: John Wiley & Sons, 2003.

LABADI, K.; BENARBIA, T.; HAMACI, S.; DARCHERIF, A.-M. Petri nets models for analysis and control of public bicycle-sharing systems. *Petri Nets-Manufacturing and Computer Science*, 2012.

LEEMIS, L. M. *Reliability: probabilistic models and statistical methods*. [S.l.]: Prentice-Hall, Inc., 1995.

LILJA, D. J. *Measuring computer performance: a practitioner's guide*. [S.l.]: Cambridge university press, 2005.

LIMA, L. N.; SABINO, A.; BARBOSA, V.; FEITOSA, L.; BRITO, C.; ARAUJO, J.; SILVA, F. A. Dependability analysis and disaster recovery measures in smart hospital systems. *Journal of Reliable Intelligent Environments*, Springer, p. 1–17, 2024.

LISBOA, M. F. F. da S.; SANTOS, G. L.; LYNN, T.; SADOK, D.; KELNER, J.; ENDO, P. T. et al. Modeling the availability of an e-health system integrated with edge, fog and cloud infrastructures. In: IEEE. *2018 IEEE symposium on computers and communications (ISCC)*. [S.l.], 2018. p. 00416–00421.

LIST, G. F.; CETIN, M. Modeling traffic signal control using petri nets. *IEEE Transactions on intelligent transportation systems*, IEEE, v. 5, n. 3, p. 177–187, 2004.

MACIEL, P. *Performance, Reliability, and Availability Evaluation of Computational Systems*. 1st. ed. [S.l.]: CRC Press, 2023.

MACIEL, P.; TRIVEDI, K.; MATIAS, R.; KIM, D. Performance and dependability in service computing: concepts, techniques and research directions. *SIJ: Igi Global*, 2011.

MACIEL, P. R. M. *Performance, reliability, and availability evaluation of computational systems, volume I: performance and background*. [S.l.]: Chapman and Hall/CRC, 2022.

MALLICK, S. R.; GOSWAMI, V.; LENKA, R. K.; SHARMA, S.; BARIK, R. K. Performance evaluation of queueing assisted iomt-fog-blockchain framework for healthcare organizations. In: IEEE. *2022 IEEE 9th Uttar Pradesh Section International Conference on Electrical, Electronics and Computer Engineering (UPCON)*. [S.l.], 2022. p. 1–6.

MARCOZZI, M.; GEMIKONAKLI, O.; GEMIKONAKLI, E.; EVER, E.; MOSTARDA, L. Availability evaluation of iot systems with byzantine fault-tolerance for mission-critical applications. *Internet of Things*, Elsevier, v. 23, p. 100889, 2023.

MARKOV, A. A. Extension of the law of large numbers to dependent quantities. *Izv. Fiz.-Matem. Obsch. Kazan Univ.(2nd Ser)*, v. 15, p. 135–156, 1906.

- MARSAN, M. A. Stochastic petri nets: an elementary introduction. In: SPRINGER. *European Workshop on Applications and Theory in Petri Nets*. [S.I.], 1988. p. 1–29.
- MARSAN, M. A.; AL. et. Modelling with generalized stochastic petri nets. *ACM Sigmetrics Performance Evaluation Review*, ACM Press, New York, NY, USA, v. 26, n. 2, 1998.
- MARSAN, M. A.; BALBO, G.; CONTE, G.; DONATELLI, S.; FRANCESCHINIS, G. *Modelling with generalized stochastic Petri nets*. [S.I.]: John Wiley & Sons, Inc., 1994.
- MARSAN, M. A.; CONTE, G.; BALBO, G. A class of generalized stochastic petri nets for the performance evaluation of multiprocessor systems. *ACM Transactions on Computer Systems (TOCS)*, ACM, v. 2, n. 2, p. 93–122, 1984.
- MASON, R. L.; GUNST, R. F.; HESS, J. L. *Statistical design and analysis of experiments: with applications to engineering and science*. [S.I.]: John Wiley & Sons, 2003.
- MAYER, C. Security and privacy challenges in the internet of things. *Electronic Communications of the EASST*, v. 17, 2009.
- MDHAFFAR, A.; CHAARI, T.; LARBI, K.; JMAIEL, M.; FREISLEBEN, B. Iot-based health monitoring via lorawan. In: IEEE. *IEEE EUROCON 2017-17th international conference on smart technologies*. [S.I.], 2017. p. 519–524.
- MENASCE, D. A.; ALMEIDA, V. A. *Capacity Planning for Web Performance: metrics, models, and methods*. [S.I.]: Prentice-Hall, Inc., 1998.
- MENASCE, D. A.; ALMEIDA, V. A. F. *Performance by Design: Computer Capacity Planning by Example*. S.I.: Prentice Hall PTR, 2005. 462 p.
- MERLIN, P.; FARBER, D. Recoverability of communication protocols—implications of a theoretical study. *IEEE transactions on Communications*, IEEE, v. 24, n. 9, p. 1036–1043, 1976.
- MODARRES, M.; KAMINSKIY, M. P.; KRIVTSOV, V. *Reliability Engineering and Risk Analysis: A Practical Guide*. S.I.: CRC Press, 2009.
- MOHAMMED, J.; LUNG, C.-H.; OCNEANU, A.; THAKRAL, A.; JONES, C.; ADLER, A. Internet of things: Remote patient monitoring using web services and cloud computing. In: IEEE. *2014 IEEE international conference on internet of things (IThings), and IEEE green computing and communications (GreenCom) and IEEE cyber, physical and social computing (CPSCom)*. [S.I.], 2014. p. 256–263.
- MONTGOMERY, D.; RUNGER, G. *Applied Statistics and Probability for Engineers*. [S.I.]: John Wiley & Sons, 2010. ISBN 9780470053041.
- MONTGOMERY, D. C. *Design and analysis of experiments*. [S.I.]: John Wiley & Sons, 2017.
- MONTGOMERY, D. C.; RUNGER, G. C. *Applied statistics and probability for engineers*. [S.I.]: John Wiley & Sons, 2020.
- MORAES, T.; NOGUEIRA, B.; LIRA, V.; TAVARES, E. Performance comparison of IOT communication protocols. In: IEEE. *2019 IEEE International Conference on Systems, Man and Cybernetics (SMC)*. [S.I.], 2019. p. 3249–3254.

MURATA, T. Petri nets: Properties, analysis and applications. *Proceedings of the IEEE*, v. 77, n. 4, p. 541–580, 1989.

NAKAYAMA, F.; LENZ, P.; NOGUEIRA, M. A resilience management architecture for communication on portable assisted living. *IEEE Transactions on Network and Service Management*, IEEE, v. 19, n. 3, p. 2536–2548, 2022.

NGUYEN, T. A.; FE, I.; BRITO, C.; KALIAPPAN, V. K.; CHOI, E.; MIN, D.; LEE, J. W.; SILVA, F. A. Performability evaluation of load balancing and fail-over strategies for medical information systems with edge/fog computing using stochastic reward nets. *Sensors*, MDPI, v. 21, n. 18, p. 6253, 2021.

NGUYEN, T. A.; MIN, D.; CHOI, E.; LEE, J.-W. Dependability and security quantification of an internet of medical things infrastructure based on cloud-fog-edge continuum for healthcare monitoring using hierarchical models. *IEEE Internet of Things Journal*, IEEE, v. 8, n. 21, p. 15704–15748, 2021.

ÖHMANN, D.; SIMSEK, M.; FETTWEIS, G. P. Achieving high availability in wireless networks by an optimal number of rayleigh-fading links. In: IEEE. *2014 IEEE Globecom Workshops (GC Wkshps)*. [S.l.], 2014. p. 1402–1407.

PASHA, M.; SHAH, S. M. W. Framework for e-health systems in iot-based environments. *Wireless Communications and Mobile Computing*, Wiley Online Library, v. 2018, n. 1, p. 6183732, 2018.

PATTNAIK, P. K.; KUMAR, R.; PAL, S. *Internet of Things and Analytics for Agriculture, Volume 2*. [S.l.]: Springer, 2020.

PAWAR, N.; BOURGEOU, T.; CHAOUCHI, H. Study of iot architecture and application invariant functionalities. In: IEEE. *2021 IFIP/IEEE International Symposium on Integrated Network Management (IM)*. [S.l.], 2021. p. 667–671.

PEREZ, M. M.; DAFONTE, C.; GÓMEZ, Á. Traceability in patient healthcare through the integration of rfid technology in an icu in a hospital. *Sensors*, MDPI, v. 18, n. 5, p. 1627, 2018.

PETRI, C. A. Communicating with automata. *Germany: PhD thesis, Technical University Darmstadt*, 1962.

PHILIP, N. Y.; RODRIGUES, J. J.; WANG, H.; FONG, S. J.; CHEN, J. Internet of things for in-home health monitoring systems: Current advances, challenges and future directions. *IEEE Journal on Selected Areas in Communications*, IEEE, v. 39, n. 2, p. 300–310, 2021.

POKORNI, S. J. Reliability and availability of the internet of things. *Vojnotehnicki glasnik/Military Technical Courier*, University of Defence, v. 67, n. 3, p. 588–600, 2019.

Precedence Research. *Internet of Things in Healthcare Market*. 2022. Acesso em: 10 set. 2023. Disponível em: <<https://www.precedenceresearch.com/internet-of-things-in-healthcare-market>>.

RAFIEV, A.; MORRIS, J.; XIA, F.; YAKOVLEV, A.; NAYLOR, M.; MOORE, S.; THOMAS, D.; BRAGG, G.; VOUSDEN, M.; BROWN, A. Practical distributed implementation of very large scale petri net simulations. In: *Transactions on Petri Nets and Other Models of Concurrency XVI*. [S.l.]: Springer, 2022. p. 112–139.

RAHIMI, N. A. W.; NOR, D. M. An automatic streetlight system for energy saving. *Evolution in Electrical and Electronic Engineering*, v. 4, n. 2, p. 165–169, 2023.

RAHMANI, A. M.; GIA, T. N.; NEGASH, B.; ANZANPOUR, A.; AZIMI, I.; JIANG, M.; LILJEBERG, P. Exploiting smart e-health gateways at the edge of healthcare internet-of-things: A fog computing approach. *Future Generation Computer Systems*, Elsevier, v. 78, p. 641–658, 2018.

RAHMANI, A. M.; HOSSEINI, S. Y. Flexible-clustering based on application priority to improve iomt efficiency and dependability. *Sustainability*, MDPI, v. 14, n. 17, p. 10666, 2022.

Raspberry Pi Foundation. *Raspberry Pi 5*. 2025. <<https://www.raspberrypi.com/products/raspberry-pi-5/>>. Acesso em: 19 de abril de 2025.

REISIG, W. *Understanding petri nets*. [S.l.]: Springer, 2013.

Reuters. *Comcast unveils five-year internet price lock*. 2025. <<https://www.reuters.com/business/media-telecom/comcast-unveils-five-year-internet-price-lock-stem-broadband-losses-2025-04-15/>>. Acesso em: 19 de abril de 2025.

ROCHA, F.; NOGUEIRA, B.; GONÇALVES, G.; SILVA, F. A. Smart hospital patient monitoring system aided by edge-fog-cloud continuum: A performability evaluation focusing on distinct sensor sources. *Journal of Network and Systems Management*, Springer, v. 32, n. 4, p. 99, 2024.

RODRIGUES, L.; GONÇALVES, I.; FÉ, I.; ENDO, P. T.; SILVA, F. A. Performance and availability evaluation of an smart hospital architecture. *Computing*, Springer, v. 103, p. 2401–2435, 2021.

RUMAN, M. R.; BARUA, A.; RAHMAN, W.; JAHAN, K. R.; RONI, M. J.; RAHMAN, M. F. lot based emergency health monitoring system. In: IEEE. *2020 International Conference on Industry 4.0 Technology (I4Tech)*. [S.l.], 2020. p. 159–162.

SAHNER, R. A.; TRIVEDI, K.; PULIAFITO, A. *Performance and Reliability Analysis of Computer Systems: An Example-Based Approach Using the SHARPE Software Package*. S.l.: Springer Publishing Company, Incorporated, 2012.

SAID, O.; TOLBA, A. Design and evaluation of large-scale iot-enabled healthcare architecture. *Applied Sciences*, MDPI, v. 11, n. 8, p. 3623, 2021.

SANTAGATI, G. E.; DAVE, N.; MELODIA, T. Design and performance evaluation of an implantable ultrasonic networking platform for the internet of medical things. *IEEE/ACM Transactions on Networking*, IEEE, v. 28, n. 1, p. 29–42, 2020.

SANTOS, G. L.; GOMES, D.; KELNER, J.; SADOK, D.; SILVA, F. A.; ENDO, P. T.; LYNN, T. The internet of things for healthcare: Optimising e-health system availability in the fog and cloud. *International Journal of Computational Science and Engineering*, Inderscience Publishers (IEL), v. 21, n. 4, p. 615–628, 2020.

SANTOS, G. L.; GOMES, D.; SILVA, F. A.; ENDO, P. T.; LYNN, T. Maximising the availability of an internet of medical things system using surrogate models and nature-inspired approaches. *International Journal of Grid and Utility Computing*, Inderscience Publishers (IEL), v. 13, n. 2-3, p. 291–308, 2022.

- SANTOS, L.; CUNHA, B.; FÉ, I.; VIEIRA, M.; SILVA, F. A. Data processing on edge and cloud: a performability evaluation and sensitivity analysis. *Journal of Network and Systems Management*, Springer, v. 29, n. 3, p. 27, 2021.
- SHEN, Y.; SHEN, S.; WU, Z.; ZHOU, H.; YU, S. Signaling game-based availability assessment for edge computing-assisted iot systems with malware dissemination. *Journal of Information Security and Applications*, Elsevier, v. 66, p. 103140, 2022.
- SHOOMAN, M. L. *Reliability of computer systems and networks: fault tolerance, analysis, and design*. [S.l.]: John Wiley & Sons, 2003.
- SI, S.; LIU, F.; CAI, Z. Failure importance analysis models based on bayesian network. In: IEEE. *2009 16th International Conference on Industrial Engineering and Engineering Management*. [S.l.], 2009. p. 151–154.
- SILVA, B.; MATOS, R.; CALLOU, G.; FIGUEIREDO, J.; OLIVEIRA, D.; FERREIRA, J.; DANTAS, J.; LOBO, A.; ALVES, V.; MACIEL, P. Mercury: An integrated environment for performance and dependability evaluation of general systems. In: *Proceedings of industrial track at 45th dependable systems and networks conference, DSN*. [S.l.: s.n.], 2015. p. 1–4.
- SILVA, F. A.; BRITO, C.; ARAÚJO, G.; FÉ, I.; TYAN, M.; LEE, J.-W.; NGUYEN, T. A.; MACIEL, P. R. M. Model-driven impact quantification of energy resource redundancy and server rejuvenation on the dependability of medical sensor networks in smart hospitals. *Sensors*, MDPI, v. 22, n. 4, p. 1595, 2022.
- SILVA, F. A.; NGUYEN, T. A.; FÉ, I.; BRITO, C.; MIN, D.; LEE, J.-W. Performance evaluation of an internet of healthcare things for medical monitoring using m/m/c/k queuing models. *IEEE Access*, IEEE, v. 9, p. 55271–55283, 2021.
- SIMON, D. F.; TEIXEIRA, M.; COSTA, J. P. da. Availability estimation in photovoltaic generation systems using timed petri net simulation models. *International Journal of Electrical Power & Energy Systems*, Elsevier, v. 137, p. 106897, 2022.
- SMITH, D. J. *Reliability, Maintainability and Risk: Practical Methods for Engineers*. S.l.: Elsevier, 2011. 436 p.
- SORRI, K.; MUSTAFEE, N.; SEPPÄNEN, M. Revisiting iot definitions: A framework towards comprehensive use. *Technological Forecasting and Social Change*, Elsevier, v. 179, p. 121623, 2022.
- SOUSA, E.; LINS, F.; TAVARES, E.; MACIEL, P. Cloud infrastructure planning considering different redundancy mechanisms. *Computing*, Springer, v. 99, p. 841–864, 2017.
- STANDARD, O. Mqtt version 5.0. *Retrieved June*, v. 22, p. 2020, 2019.
- SU, C.-R.; HAJIYEV, J.; FU, C. J.; KAO, K.-C.; CHANG, C.-H.; CHANG, C.-T. A novel framework for a remote patient monitoring (rpm) system with abnormality detection. *Health Policy and Technology*, Elsevier, v. 8, n. 2, p. 157–170, 2019.
- SUBRAMANIAM, E. V. D.; SRINIVASAN, K.; QAISAR, S. M.; PŁAWIAK, P. Interoperable iomt approach for remote diagnosis with privacy-preservation perspective in edge systems. *Sensors*, MDPI, v. 23, n. 17, p. 7474, 2023.

- SURAJ, Z.; OLAR, O.; BLOSHKO, Y. The analysis of human oriented system of weighted fuzzy petri nets for the passenger transport logistics problem. In: SPRINGER. *Intelligent and Fuzzy Techniques: Smart and Innovative Solutions: Proceedings of the INFUS 2020 Conference, Istanbul, Turkey, July 21-23, 2020*. [S.l.], 2021. p. 1581–1588.
- TANG, D.; KUMAR, D.; DUVUR, S.; TORBJORNSEN, O. Availability measurement and modeling for an application server. In: IEEE. *International Conference on Dependable Systems and Networks, 2004*. [S.l.], 2004. p. 669–678.
- TANG, S.; XIE, Y. Availability modeling and performance improving of a healthcare internet of things (iot) system. *IoT*, MDPI, v. 2, n. 2, p. 310–325, 2021.
- TAŞTAN, M. Iot based wearable smart health monitoring system. *Celal Bayar University Journal of Science*, Celal Bayar Üniversitesi, v. 14, n. 3, p. 343–350, 2018.
- TRIVEDI, K. S. *Probability & Statistics with Reliability, Queuing and Computer Science Applications*. S.l.: John Wiley & Sons, 2008. 830 p.
- TRIVEDI, K. S. *Probability & statistics with reliability, queuing and computer science applications*. [S.l.]: John Wiley & Sons, 2008.
- VISHNU, S.; RAMSON, S. J.; JEGAN, R. Internet of medical things (iomt)-an overview. In: IEEE. *2020 5th international conference on devices, circuits and systems (ICDCS)*. [S.l.], 2020. p. 101–104.
- WAI, K. T.; AUNG, N. P.; HTAY, L. L. Internet of things (iot) based healthcare monitoring system using nodemcu and arduino uno. *Published in International Journal of Trend in Scientific Research and Development (ijtsrd)*, v. 3, n. 5, p. 755–759, 2019.
- WEI, B.; LIN, C.; KONG, X. Dependability modeling and analysis for the virtual data center of cloud computing. In: IEEE. *2011 IEEE International Conference on High Performance Computing and Communications*. [S.l.], 2011. p. 784–789.
- WOLFRAM, S. *The mathematica book*. [S.l.]: Wolfram Research, Inc., 2003.
- WOODSIDE, M.; FRANKS, G.; PETRIU, D. C. The future of software performance engineering. In: IEEE. *Future of Software Engineering (FOSE'07)*. [S.l.], 2007. p. 171–187.
- XIE, M.; DAI, Y.-S.; POH, K.-L. *Computing system reliability: models and analysis*. [S.l.]: Springer Science & Business Media, 2004.
- YACCHIREMA, D. C.; PALAU, C. E.; ESTEVE, M. Enable iot interoperability in ambient assisted living: Active and healthy aging scenarios. In: IEEE. *2017 14th IEEE annual consumer communications & networking conference (CCNC)*. [S.l.], 2017. p. 53–58.
- YONG, C. T.; HAO, C. V.; RUSKHAN, B.; LIM, S. K. Y.; BOON, T. G.; WEI, T. S.; SHAH, S. B. I. A. An implementation of efficient smart street lights with crime and accident monitoring: A review. *Journal of Survey in Fisheries Sciences*, p. 287–305, 2023.
- ZHANG, X.; LU, Q.; WU, T. Petri-net based applications for supply chain management: an overview. *International Journal of Production Research*, Taylor & Francis, v. 49, n. 13, p. 3939–3961, 2011.

ZHONG, M.; SHI, C.; FU, T.; HE, L.; SHI, J. Study in performance analysis of china urban emergency response system based on petri net. *Safety science*, Elsevier, v. 48, n. 6, p. 755–762, 2010.

ZIMMERMANN, A.; AL. et. Towards version 4.0 of timenet. In: *13th GI/ITG Conference - Measuring, Modelling and Evaluation of Computer and Communication Systems*. [S.l.: s.n.], 2006. p. 1–4.