

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO DE INFORMÁTICA
PROGRAMA DE PÓS-GRADUAÇÃO EM COMPUTAÇÃO

GABRIEL EDUARDO MARTINI

**Classificação do Status Glicêmico a partir
de Hemogramas: Estudo Comparativo de
Estratégias de Aprendizado de Máquina
com Análise de Erros e Interpretabilidade
em Dados Laboratoriais Reais**

Dissertação apresentada como requisito parcial
para a obtenção do grau de Mestre em Ciência da
Computação

Orientador: Profa. Dra. Mariana Recamonde
Mendoza

Porto Alegre
2026

CIP — CATALOGAÇÃO NA PUBLICAÇÃO

Martini, Gabriel Eduardo

Classificação do Status Glicêmico a partir de Hemogramas: Estudo Comparativo de Estratégias de Aprendizado de Máquina com Análise de Erros e Interpretabilidade em Dados Laboratoriais Reais / Gabriel Eduardo Martini. – Porto Alegre: PPGC da UFRGS, 2026.

157 f.: il.

Dissertação (mestrado) – Universidade Federal do Rio Grande do Sul. Programa de Pós-Graduação em Computação, Porto Alegre, BR-RS, 2026. Orientador: Mariana Recamonde Mendoza.

1. Aprendizado de Máquina. 2. Diabetes Mellitus. 3. Hemograma. 4. Classificação. 5. Explicabilidade. I. Recamonde Mendoza, Mariana. II. Título.

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

Reitora: Prof^ª. Marcia Barbosa

Vice-Reitor: Prof^ª. Pedro Costa

Pró-Reitora de Pós-Graduação: Prof^ª. Claudia Wasserman

Diretor do Instituto de Informática: Prof. Luciano Paschoal Gaspary

Coordenador do PPGC: Prof. Gabriel Luca Nazar

Bibliotecário-chefe do Instituto de Informática: Alexsander Borges Ribeiro

RESUMO

O Diabetes Mellitus constitui um dos principais desafios de saúde pública global, sendo o diagnóstico precoce essencial para prevenir complicações e reduzir a progressão da doença. A hemoglobina glicada (A1c) é o exame de referência para classificação do status glicêmico, porém sua disponibilidade é limitada em diversos contextos clínicos. Nesse cenário, o hemograma, amplamente disponível e de baixo custo, surge como uma alternativa potencial para triagem. Este trabalho investiga a hipótese de que parâmetros hematológicos contêm informações associadas ao metabolismo glicêmico, permitindo a classificação de indivíduos em normoglicêmicos, pré-diabéticos e diabéticos por meio de modelos de aprendizado de máquina. Para isso, foi construída uma base com 169.999 registros laboratoriais reais, contendo 23 atributos preditivos derivados do hemograma completo. Foram avaliadas quatro estratégias de modelagem: classificação binária, classificação multiclasse direta, decomposição em subproblemas binários e combinação por *ensemble*. Os experimentos utilizaram validação cruzada aninhada para seleção de hiperparâmetros e avaliação de modelos, com F2-Score como métrica principal, priorizando a redução de falsos negativos. Os resultados indicam que modelos de Redes Neurais Artificiais (MLP) apresentaram o melhor desempenho em todas as tarefas. Na classificação binária (Normal vs. Pré-diabético+Diabético), obteve-se $F2=0,793$ e $Recall=0,824$, evidenciando boa capacidade de detecção de alterações glicêmicas. Por outro lado, a classificação multiclasse apresentou desempenho inferior ($F2$ macro= $0,551$), refletindo a maior dificuldade na distinção entre classes adjacentes. A decomposição em classificadores binários evidenciou que a dificuldade preditiva é proporcional à proximidade entre os limiares diagnósticos de A1c, com maior taxa de erro em regiões limítrofes, especialmente na identificação do pré-diabetes. A análise de interpretabilidade, baseada em importância por permutação e SHAP, identificou Idade, Leucócitos e RDW como os atributos mais relevantes, em concordância com evidências fisiopatológicas associadas a processos inflamatórios e metabólicos. Adicionalmente, a análise de erros permitiu caracterizar limitações do modelo, incluindo maior incidência de classificações incorretas em faixas etárias mais jovens e em regiões próximas aos pontos de corte diagnósticos. Como principais contribuições do estudo, destacam-se: (i) a avaliação sistemática do potencial preditivo do hemograma completo em uma base de larga escala; (ii) a comparação estruturada entre diferentes estratégias de modelagem, evidenciando os limites da classificação multiclasse do pré-diabetes; e (iii) a análise integrada de desempenho, padrões de erro e

interpretabilidade, contribuindo para a compreensão dos limites e aplicações clínicas da abordagem. Os resultados sugerem que o hemograma pode atuar como ferramenta complementar de triagem para alterações glicêmicas, especialmente em contextos com acesso limitado à A1c, embora com limitações na discriminação entre classes adjacentes.

Palavras-chave: Aprendizado de Máquina. Diabetes Mellitus. Hemograma. Classificação. Explicabilidade.

Classification of Glycemic Status from Complete Blood Counts: Evaluation of Machine Learning Strategies in Real Brazilian Laboratory Data

ABSTRACT

Keywords: Machine Learning. Diabetes Mellitus. Complete Blood Count. Classification. Explainability. Diabetes Mellitus is one of the main global public health challenges, and early diagnosis is essential to prevent complications and reduce disease progression. Glycated hemoglobin (A1c) is the reference test for glycemic status classification; however, its availability is limited in several clinical contexts. In this scenario, the complete blood count (CBC), which is widely available and low-cost, emerges as a potential alternative for screening. This work investigates the hypothesis that hematological parameters contain information associated with glycemic metabolism, allowing the classification of individuals as normoglycemic, pre-diabetic, or diabetic through machine learning models. For this purpose, a dataset with 169,999 real laboratory records was built, containing 23 predictive attributes derived from the complete blood count. Four modeling strategies were evaluated: binary classification, direct multiclass classification, decomposition into binary subproblems, and *ensemble* combination. The experiments used nested cross-validation for hyperparameter selection and model evaluation, with F2-Score as the main metric to prioritize the reduction of false negatives. The results indicate that Multilayer Perceptron (MLP) models achieved the best performance in all tasks. In the binary classification (Normal vs. Pre-diabetic+Diabetic), the model obtained $F2=0.793$ and $Recall=0.824$, showing good ability to detect glycemic alterations. In contrast, the multiclass classification presented lower performance (macro $F2=0.551$), reflecting the higher difficulty in distinguishing between adjacent classes. The decomposition into binary classifiers showed that predictive difficulty is proportional to the proximity between A1c diagnostic thresholds, with higher error rates in borderline regions, especially for pre-diabetes identification. The interpretability analysis, based on permutation importance and SHAP, identified Age, Leukocytes, and RDW as the most relevant attributes, in agreement with pathophysiological evidence associated with inflammatory and metabolic processes. In addition, the error analysis characterized model limitations, including a higher incidence of incorrect classifications in younger age groups and in regions close to diagnostic cut-off points. The main contributions are: (i) the systematic evaluation of the predictive potential of the complete blood count on a large-scale dataset; (ii) the

structured comparison between different modeling strategies, showing the limits of multiclass pre-diabetes classification; and (iii) the integrated analysis of performance, error patterns, and interpretability, contributing to the understanding of the limits and clinical applications of the approach. The results suggest that the complete blood count can act as a complementary screening tool for glycemic alterations, especially in contexts with limited access to A1c, although with limitations in the discrimination between adjacent classes..

LISTA DE FIGURAS

Figura 2.1 Faixas de classificação do status glicêmico conforme os valores de A1c.	28
Figura 4.1 <i>Pipeline</i> de limpeza e redução da base de dados, com quantidades de registros em cada etapa.	65
Figura 4.2 Distribuição de classes na base de dados final, conforme critérios de classificação por A1c.	68
Figura 4.3 Distribuição da hemoglobina glicada A1c por sexo (painel A) e por faixa etária (painel B), representada por <i>boxplot</i> . A linha central de cada caixa indica a mediana, a caixa representa o intervalo interquartil (P25-P75). As linhas horizontais tracejadas indicam os limiares diagnósticos de 5,7% e 6,5% (World Health Organization, 2021).	69
Figura 4.4 Prevalência das classes glicêmicas (Normal, Pré-diabetes, Diabetes) por sexo (painel A) e por faixa etária (painel B). Os valores de n indicam o tamanho amostral de cada subgrupo.	70
Figura 4.5 Esquema da validação cruzada aninhada (<i>nested cross-validation</i>) com 10 <i>folds</i> externos e 5 internos, aplicada sobre a partição de treino. O modelo final avaliado no <i>holdout</i> corresponde ao melhor estimador dentre os 10 <i>folds</i> externos.	76
Figura 4.6 Protocolo de treinamento do <i>ensemble</i> (v3 e v4): partição estratificada 80/20, geração de meta-features <i>out-of-fold</i> pelos seis especialistas binários, treinamento do meta-aprendiz e avaliação final exclusiva no conjunto de teste reservado.	84
Figura 4.7 Arquitetura do <i>ensemble</i> v1 (<i>Soft Voting</i> ponderado por F2).	86
Figura 4.8 Arquitetura do <i>ensemble</i> v4 (<i>Stacking</i> HistGBT + <i>passthrough</i>).	87
Figura 5.1 Matriz de confusão detalhada do <i>pipeline</i> vencedor da Tarefa 1 nos dados de teste.	92
Figura 5.2 Análise de erros do <i>pipeline</i> vencedor da Tarefa 1 nos dados de teste. Superior: distribuição das probabilidades preditas para a classe positiva, estratificada por tipo de predição (TP, TN, FN, FP). Inferior-Esquerda: contagem absoluta por tipo de predição. Inferior-Direita: taxas de falsos negativos e falsos positivos em função do limiar de decisão.	93
Figura 5.3 Curvas ROC e Precisão-Recall para todos os 28 <i>pipelines</i> avaliados na Tarefa 1, nos dados de teste. Cada linha corresponde a um <i>pipeline</i> distinto; a diagonal tracejada na curva ROC indica o desempenho de um classificador aleatório.	95
Figura 5.4 Curvas de F2-Score, Precisão e Recall em função do limiar de decisão para os seis <i>pipelines</i> de melhor F2 na Tarefa 1. As linhas verticais tracejadas indicam os limiares ótimo e padrão (0,50).	97
Figura 5.5 Resumo dos valores SHAP para o <i>pipeline</i> vencedor da Tarefa 1.	99
Figura 5.6 Comparação entre o <i>ranking</i> de importância por SHAP e por permutação para o <i>pipeline</i> vencedor da Tarefa 1. Correlação de Spearman $\rho = 0,975$	100
Figura 5.7 Gráficos de cascata SHAP para três predições individuais do <i>pipeline</i> vencedor da Tarefa 1. Cada barra indica a contribuição de um atributo específico para a predição da instância, partindo do valor esperado $E[f(X)]$ até a predição final $f(x)$	101

Figura 5.8 Distribuição dos falsos positivos e falsos negativos do <i>pipeline</i> vencedor da Tarefa 1 por faixa de hemoglobina glicada. A faixa 5,7% corresponde ao limiar Normal/Pré-diabetes definido pela Organização Mundial da Saúde; a faixa 6,5% corresponde ao limiar Pré-diabetes/Diabetes.	102
Figura 5.9 Análise de erros do <i>pipeline</i> vencedor da Tarefa 1 por sexo, nos dados de teste. Esquerda: composição dos erros (corretos, falsos negativos, falsos positivos) por sexo. Direita: taxas de FN e FP por sexo.....	103
Figura 5.10 Análise de erros do <i>pipeline</i> vencedor da Tarefa 1 por faixa etária, nos dados de teste. Esquerda: composição dos erros (corretos, falsos negativos, falsos positivos) por faixa etária. Direita: taxa de falsos negativos clínicos (indivíduos com alteração glicêmica classificados como Normais) por faixa etária.....	104
Figura 5.11 Análise conjunta dos falsos negativos do <i>pipeline</i> vencedor da Tarefa 1 por faixa etária e faixa de hemoglobina glicada, nos dados de teste. Painel esquerdo: contagem absoluta de falsos negativos em cada célula da matriz. Painel direito: taxa de falsos negativos sobre o total de indivíduos com alteração glicêmica em cada célula. A coluna de $A1c < 5,7\%$ é omitida nos valores por ser a faixa correspondente à classe Normal (sem casos positivos verdadeiros). ..	104
Figura 5.12 Matriz de confusão detalhada do <i>pipeline</i> vencedor da Tarefa 2 nos dados de teste.	106
Figura 5.13 Distribuição das probabilidades preditas pelo <i>pipeline</i> vencedor da Tarefa 2, estratificada por classe real (Normal, Pré-diabético, Diabético), nos dados de teste. Cada painel apresenta a distribuição das probabilidades preditas para uma das três classes de saída, com cores indicando a classe real do indivíduo.	107
Figura 5.14 Curvas ROC e Precisão-Recall da Tarefa 2 nos dados de teste.	108
Figura 5.15 Resumo dos valores SHAP para o <i>pipeline</i> vencedor da Tarefa 2 (C1 - MLP + Std + MinMax), considerando as três classes simultaneamente.	110
Figura 5.16 Comparação entre o <i>ranking</i> de importância por SHAP e por permutação para o <i>pipeline</i> vencedor da Tarefa 2. Correlação de Spearman $\rho = 0,889$...	111
Figura 5.17 Gráficos de cascata SHAP para duas predições individuais do <i>pipeline</i> vencedor da Tarefa 2. Cada barra indica a contribuição de um atributo para a predição da instância.....	112
Figura 5.18 Predições do <i>pipeline</i> vencedor da Tarefa 2 por faixa de hemoglobina glicada, estratificadas por classe real (Normal, Pré-diabético, Diabético), nos dados de teste. Cada painel mostra a proporção de predições por classe de saída para cada faixa de A1c. As linhas verticais indicam os limiares de diagnóstico da Organização Mundial da Saúde (5,7% e 6,5%)......	113
Figura 5.19 Análise de erros do <i>pipeline</i> vencedor da Tarefa 2 por sexo, nos dados de teste. Esquerda: composição dos erros por sexo. Direita: taxas de FN e FP por sexo.	114
Figura 5.20 Análise de erros do <i>pipeline</i> vencedor da Tarefa 2 por faixa etária, nos dados de teste. Esquerda: composição dos erros por faixa etária. Direita: taxa de falsos negativos clínicos por faixa etária.....	115
Figura 5.21 Matrizes de confusão detalhadas dos <i>pipelines</i> vencedores dos três subproblemas detalhados da Tarefa 3, nos dados de teste, com contagens absolutas e proporções relativas às linhas (classe real).	118
Figura 5.22 Análise de erros dos <i>pipelines</i> vencedores nos subproblemas Nx D e PDxD da Tarefa 3, nos dados de teste. Cada linha apresenta a distribuição de probabilidades por tipo de predição (esquerda), a contagem por tipo (centro) e as taxas de erro em função do limiar de decisão (direita).	118

Figura 5.23	Curvas ROC e Precisão-Recall para todos os <i>pipelines</i> avaliados no subproblema Nx D (N vs. D) da Tarefa 3, nos dados de teste.	120
Figura 5.24	Resumo dos valores SHAP para os <i>pipelines</i> vencedores dos subproblemas Nx D e PDxD da Tarefa 3, nos dados de teste. Em Nx D a Idade domina com magnitude 3 a 5 vezes superior aos demais; em PDxD as contribuições são mais distribuídas entre Idade, Leucócitos, Hemoglobina e HCM.	122
Figura 5.25	Gráficos de cascata SHAP para instâncias de falso negativo nos subproblemas Nx D e PDxD da Tarefa 3, nos dados de teste.	123
Figura 5.26	Análise de erros por faixa etária dos <i>pipelines</i> vencedores dos subproblemas Nx D e PDxD da Tarefa 3, nos dados de teste. Esquerda: composição dos erros por faixa etária. Direita: taxa de falsos negativos clínicos por faixa etária.	124
Figura 5.27	Matriz de confusão detalhada do <i>ensemble</i> v4 (<i>Stacking</i> com meta-aprendiz <i>HistGradientBoosting</i> e <i>passthrough</i>) nos dados de teste, com contagens absolutas e proporções relativas às linhas (classe real).	129
Figura B.1	Histogramas individuais dos 23 atributos preditivos da base de dados final. Os atributos do hemograma com ocorrência rara (Mielócitos, Metamielócitos, Bastões, Linfócitos Atípicos, Plasmócitos, Blastos e Promielócitos) apresentam distribuição concentrada em zero, refletindo sua baixa incidência clínica em populações sem patologias hematológicas específicas. Esses atributos podem apresentar registros com valores diferentes de zero, porém em proporção tão reduzida em relação aos valores nulos que não são visualmente perceptíveis na escala dos histogramas; a Tabela B.1 reporta os valores máximos observados para cada atributo.	156
Figura B.2	Distribuição dos 21 atributos do hemograma estratificados pelas três classes glicêmicas. Para os atributos cujos três quartis (P25, mediana, P75) valem zero em todas as classes (Mielócitos, Metamielócitos, Bastões, Linfócitos Atípicos, Plasmócitos, Blastos e Promielócitos, identificados pelo sufixo “raro”), o <i>boxplot</i> ficaria apenas em uma linha; nesses casos é apresentado um gráfico de barras com a percentagem de registros não nulos por classe, que constitui a informação clinicamente relevante. Para os demais atributos, o <i>boxplot</i> segue as convenções usuais (mediana, intervalo interquartil e bordas a 1,5 vezes o intervalo interquartil), com os eixos verticais limitados aos percentis 1 e 99 de cada atributo para fins de visualização, sem alterar os dados utilizados.	157

LISTA DE TABELAS

Tabela 2.1 Critérios diagnósticos para classificação do status glicêmico.	27
Tabela 3.1 Resumo de estudos com uso de aprendizado de máquina para predição de diabetes e métricas associadas	61
Tabela 4.1 Atributos preditivos da base de dados, unidades de medida e limites de corte para remoção de <i>outliers</i> . Células vazias nas colunas de operador e limite indicam que o atributo não recebeu filtragem.	66
Tabela 4.2 Tarefas experimentais de classificação definidas neste trabalho.	71
Tabela 4.3 Catálogo de transformações numéricas utilizadas nos <i>pipelines</i> . Cada identificador (P1–P9) é referenciado na Tabela 4.6 para indicar em qual categoria e com quais algoritmos a transformação foi aplicada. Todas as transformações incluem <i>OneHotEncoder</i> para a variável Sexo.	72
Tabela 4.4 Distribuição de classes por tarefa experimental (conforme Tabela 4.2), ordenada pela razão de desbalanceamento.	73
Tabela 4.5 Algoritmos de classificação avaliados neste trabalho, organizados por família algorítmica.	79
Tabela 4.6 Configurações de <i>pipeline</i> por categoria experimental. N representa o número de configurações executadas por tarefa binária. Os identificadores P1–P9 referenciam as transformações numéricas descritas na Tabela 4.3.	79
Tabela 4.7 Composição dos 229 modelos preditivos avaliados, por tarefa.	80
Tabela 4.8 Especialistas binários selecionados para a primeira versão do <i>ensemble</i> (v1), organizados por classe-alvo, com dois classificadores por classe do problema multiclasse.	83
Tabela 4.9 Especialistas binários selecionados para as versões v3 e v4 do <i>ensemble</i> , com algoritmo e família de modelo. Cada especialista corresponde a um subproblema da Tarefa 3.	83
Tabela 4.10 Composição dos especialistas utilizados em cada versão do <i>ensemble</i>	83
Tabela 4.11 Hiperparâmetros do meta-aprendiz <i>HistGradientBoosting</i> na configuração final (v4) do <i>ensemble</i> . Valores otimizados foram selecionados por <i>GridSearchCV</i> com <i>StratifiedKfold</i> de cinco partições e F2-Score macro como função objetivo.	86
Tabela 4.12 Principais bibliotecas utilizadas nos experimentos e suas versões.	88
Tabela 5.1 Desempenho consolidado dos melhores <i>pipelines</i> por tarefa. As colunas F2, <i>Recall</i> , AUC-PR e AUC-ROC referem-se ao conjunto de teste (<i>holdout</i> estratificado de 20%); as duas últimas colunas referem-se à validação cruzada aninhada (média $\pm$ desvio padrão sobre os 10 <i>folds</i> externos).	90
Tabela 5.2 Dez melhores <i>pipelines</i> da Tarefa 1 (N vs. PD+D), ordenados por F2-Score. As colunas F2 a AUC-ROC referem-se ao conjunto de teste (<i>holdout</i> estratificado de 20%); a última coluna refere-se à validação cruzada aninhada (média $\pm$ desvio padrão dos 10 <i>outer folds</i>). Valores em negrito indicam o melhor desempenho em cada métrica.	91
Tabela 5.3 Estabilidade do F2-Score do <i>pipeline</i> vencedor e dos quatro mais próximos da Tarefa 1, nas fases de treino e validação da CV aninhada (10 <i>folds</i> externos) e no conjunto de teste (<i>holdout</i> estratificado de 20%). Valores em negrito indicam o melhor desempenho em cada métrica.	96

Tabela 5.4 Ganho em F2-Score obtido pela otimização do limiar de decisão nos dados de teste, para os seis <i>pipelines</i> apresentados na Figura 5.4. Valores em negrito indicam o melhor desempenho em cada métrica.....	97
Tabela 5.5 Dez atributos mais influentes do <i>pipeline</i> vencedor da Tarefa 1, ordenados pelo valor SHAP.	101
Tabela 5.6 Desempenho do <i>pipeline</i> vencedor da Tarefa 1 estratificado por sexo, nos dados de teste.....	103
Tabela 5.7 Desempenho do <i>pipeline</i> vencedor da Tarefa 1 estratificado por faixa etária, nos dados de teste, com prevalência da classe positiva em cada subgrupo.....	103
Tabela 5.8 Dez melhores <i>pipelines</i> da Tarefa 2 (N vs. PD vs. D), ordenados por F2-Score macro. As colunas F2 a AUC-ROC referem-se ao conjunto de teste (<i>holdout</i> estratificado de 20%); a última coluna refere-se à validação cruzada aninhada (média $\pm$ desvio padrão dos 10 <i>outer folds</i>). Valores em negrito indicam o melhor desempenho em cada métrica.	105
Tabela 5.9 Desempenho por classe do <i>pipeline</i> vencedor da Tarefa 2, nos dados de teste.	106
Tabela 5.10 Dez atributos mais influentes do <i>pipeline</i> vencedor da Tarefa 2, ordenados pelo valor SHAP. A coluna “Rank T1” indica a posição do mesmo atributo na Tarefa 1 para comparação.	111
Tabela 5.11 Desempenho do <i>pipeline</i> vencedor da Tarefa 2 estratificado por sexo, nos dados de teste.....	114
Tabela 5.12 Desempenho do <i>pipeline</i> vencedor da Tarefa 2 estratificado por faixa etária, nos dados de teste.....	115
Tabela 5.13 Desempenho dos seis subproblemas binários da Tarefa 3. As colunas F2 a AUC-ROC referem-se ao conjunto de teste (<i>holdout</i> estratificado de 20%); a última coluna refere-se à validação cruzada aninhada (média $\pm$ desvio padrão dos 10 <i>outer folds</i>). Linhas em destaque correspondem aos subproblemas detalhados nesta seção.	116
Tabela 5.14 Cinco melhores <i>pipelines</i> de cada subproblema detalhado da Tarefa 3, ordenados por F2-Score. As colunas F2 a AUC-ROC referem-se ao conjunto de teste (<i>holdout</i> estratificado de 20%). Valores em negrito indicam o melhor desempenho em cada métrica dentro de cada subproblema.	117
Tabela 5.15 Estabilidade do F2-Score dos <i>pipelines</i> vencedores dos cinco subproblemas da Tarefa 3 (excluindo NxPD+D, já reportado na Seção 5.2), nas fases de treino e validação da validação cruzada aninhada (10 <i>outer folds</i>) e no conjunto de teste.	119
Tabela 5.16 Cinco atributos mais influentes (por SHAP) do <i>pipeline</i> vencedor de cada subproblema da Tarefa 3 (excluindo NxPD+D). O <i>ranking</i> por permutação é indicado entre parênteses.....	121
Tabela 5.17 Desempenho (F2) do <i>pipeline</i> vencedor de cada subproblema da Tarefa 3, estratificado por sexo, nos dados de teste.	123
Tabela 5.18 Evolução das estratégias de agregação investigadas para o <i>ensemble</i> da Tarefa 4. As métricas referem-se ao conjunto de teste. A coluna "Especialistas" indica o conjunto de classificadores binários utilizados (Tabelas 4.8 e 4.9 do Capítulo 4). A linha em destaque (negrito) indica a configuração final adotada.	125
Tabela 5.19 Desempenho per-classe das três principais versões do <i>ensemble</i> (v1, v3 e v4) nos dados de teste. As variantes v2-A e v2-B foram avaliadas apenas em métricas macro por se tratarem de testes iterativos de estratégias de agregação sem retreinamento dos especialistas; seu desempenho macro está reportado na Tabela 5.18.....	125

Tabela 5.20	Coefficientes efetivos da Regressão Logística meta-aprendiz da v3, organizados por especialista binário (linha) e classe-alvo do problema multi-classe (coluna). Os valores correspondem à diferença $\beta_{p_1} - \beta_{p_0}$ entre os coeficientes das duas meta-features de cada especialista, refletindo o impacto efetivo da probabilidade predita pela fronteira binária sobre o escore da classe-alvo. Hiperparâmetros do meta-aprendiz: $C = 100,0$ com <code>class_weight=balanced</code> . Sinal positivo indica contribuição em direção à classe-alvo. Valores em negrito indicam o especialista de maior magnitude para cada classe.	127
Tabela 5.21	Desempenho do <i>ensemble</i> v4 por classe nos dados de teste (<i>holdout</i> estratificado de 20%). A coluna N indica o número de instâncias por classe.	128
Tabela 5.22	Comparação per-classe entre o <i>ensemble</i> v4 e o <i>baseline</i> multiclasse da Tarefa 2.	128
Tabela A.1	Configurações detalhadas dos 28 <i>pipelines</i> de aprendizado de máquina executados por tarefa de classificação nas tarefas binárias (T1 e T3). A Tarefa 2 utiliza variações nos preprocessadores conforme Tabela 4.3.	154
Tabela B.1	Estatísticas descritivas dos 23 atributos preditivos e da variável-alvo A1c na base final ($n = 169.999$). Valores expressos nas unidades de medida originais conforme Tabela 4.1.	155

LISTA DE ABREVIATURAS E SIGLAS

A1c	Hemoglobina Glicada
ADA	<i>American Diabetes Association</i>
ANN	<i>Artificial Neural Networks</i> (Redes Neurais Artificiais)
AUC	Área sob a Curva (<i>Area Under the Curve</i>)
AUC-PR	Área sob a Curva Precisão-Recall
AUC-ROC	Área sob a Curva ROC (<i>Receiver Operating Characteristic</i>)
CAAE	Certificado de Apresentação de Apreciação Ética
CART	<i>Classification and Regression Trees</i>
CBC	Hemograma Completo (<i>Complete Blood Count</i>)
CHCM	Concentração da Hemoglobina Corpuscular Média
CNS	Conselho Nacional de Saúde
CPU	<i>Central Processing Unit</i> (Unidade Central de Processamento)
CV	Validação Cruzada (<i>Cross-Validation</i>)
DM	Diabetes Mellitus
DM1	Diabetes Mellitus Tipo 1
DM2	Diabetes Mellitus Tipo 2
DMG	Diabetes Mellitus Gestacional
DT	Árvore de Decisão (<i>Decision Tree</i>)
EFB	<i>Exclusive Feature Bundling</i>
ENN	<i>Edited Nearest Neighbours</i>
F2	F2-Score ($\beta=2$)
FN	Falso Negativo
FP	Falso Positivo
GOSS	<i>Gradient-based One-Side Sampling</i>

GPJ	Glicose Plasmática em Jejum
GPU	<i>Graphics Processing Unit</i> (Unidade de Processamento Gráfico)
HCM	Hemoglobina Corpuscular Média
HCT	Hematócrito
HDL	Lipoproteína de Alta Densidade (<i>High-Density Lipoprotein</i>)
HGB	Hemoglobina
HGBT	<i>HistGradientBoosting</i>
IA	Inteligência Artificial
IDF	<i>International Diabetes Federation</i>
IMC	Índice de Massa Corporal
KNN	<i>K-Nearest Neighbors</i>
LASSO	<i>Least Absolute Shrinkage and Selection Operator</i>
LDA	Análise Discriminante Linear (<i>Linear Discriminant Analysis</i>)
LDL	Lipoproteína de Baixa Densidade (<i>Low-Density Lipoprotein</i>)
LGBM	<i>LightGBM</i>
LGPD	Lei Geral de Proteção de Dados
LIS	Sistemas de Informação Laboratorial (<i>Laboratory Information System</i>)
LR	Regressão Logística (<i>Logistic Regression</i>)
MCC	Coeficiente de Correlação de Matthews
ML	<i>Machine Learning</i>
MLP	<i>Multilayer Perceptron</i>
MPV	<i>Mean Platelet Volume</i> (Volume Plaquetário Médio; sin. VPM)
NB	<i>Naive Bayes</i>
NLR	<i>Neutrophil-to-Lymphocyte Ratio</i>
OMS	Organização Mundial da Saúde (sin. WHO)

OOF	<i>Out-Of-Fold</i>
OvO	<i>One-vs-One</i>
OvR	<i>One-vs-Rest</i>
PCR	Proteína C Reativa
PDW	<i>Platelet Distribution Width</i>
PLR	<i>Platelet-to-Lymphocyte Ratio</i>
PLT	Plaquetas (<i>Platelets</i>)
PR	Precisão- <i>Recall</i>
PT	<i>PowerTransformer</i>
QT	<i>QuantileTransformer</i>
RBC	Hemácias (<i>Red Blood Cells</i>)
RBF	Função de Base Radial (<i>Radial Basis Function</i>)
RDW	<i>Red Cell Distribution Width</i>
RDW-SD	<i>Red Cell Distribution Width — Standard Deviation</i>
RF	<i>Random Forest</i> (Floresta Aleatória)
RMSE	Raiz do Erro Quadrático Médio (<i>Root Mean Squared Error</i>)
ROC	<i>Receiver Operating Characteristic</i>
ROS	<i>Random Over Sampler</i>
RUS	<i>Random Under Sampler</i>
SGD	<i>Stochastic Gradient Descent</i>
SHAP	<i>SHapley Additive exPlanations</i>
SMOTE	<i>Synthetic Minority Over-sampling Technique</i>
SMOTEENN	<i>SMOTE + Edited Nearest Neighbours</i>
SVM	<i>Support Vector Machine</i>
TCLE	Termo de Consentimento Livre e Esclarecido
TFG	Taxa de Filtração Glomerular

TG	Triglicerídeos
TN	Verdadeiro Negativo
TOTG	Teste Oral de Tolerância à Glicose
TP	Verdadeiro Positivo
VCM	Volume Corpuscular Médio
VPM	Volume Plaquetário Médio (sin. MPV)
WBC	Leucócitos (<i>White Blood Cells</i>)
WHO	<i>World Health Organization</i> (sin. OMS)

SUMÁRIO

1 INTRODUÇÃO	20
2 FUNDAMENTAÇÃO TEÓRICA	25
2.1 Diabetes Mellitus	25
2.1.1 Definição e Epidemiologia	25
2.1.2 Classificação	26
2.1.3 Diagnóstico e Hemoglobina Glicada	27
2.1.4 Pré-diabetes	28
2.2 Hemograma e Parâmetros Hematológicos	29
2.2.1 O Hemograma	29
2.2.2 Parâmetros Hematológicos	29
2.2.2.1 Série Branca (Leucócitos)	29
2.2.2.2 Série Vermelha (Eritrócitos)	30
2.2.2.3 Série Plaquetária	31
2.2.3 Alterações Hematológicas Associadas ao Diabetes	31
2.3 Aprendizado de Máquina Supervisionado	32
2.3.1 Conceitos Fundamentais	32
2.3.2 Algoritmos de Classificação	33
2.3.2.1 Regressão Logística	33
2.3.2.2 Máquinas de Vetores de Suporte	34
2.3.2.3 Árvores de Decisão	34
2.3.2.4 <i>Bagging</i>	35
2.3.2.5 Florestas Aleatórias	35
2.3.2.6 AdaBoost	36
2.3.2.7 <i>Gradient Boosting</i>	36
2.3.2.8 Perceptron Multicamadas (MLP)	37
2.3.3 Estratégias de Classificação Multiclasse	38
2.3.4 Métodos de Aprendizado <i>Ensemble</i>	39
2.4 Pré-processamento de Dados	41
2.4.1 Pré-processamento de Atributos Numéricos	41
2.4.2 O Problema do Desbalanceamento de Classes	42
2.4.3 Técnicas de Reamostragem	43
2.4.3.1 Sobreamostragem	43
2.4.3.2 Subamostragem	43
2.4.3.3 Abordagens Híbridas	44
2.4.4 Aprendizado sensível ao custo	44
2.4.5 Cuidados Metodológicos	45
2.5 Avaliação de Modelos Preditivos	45
2.5.1 Métricas de Desempenho	45
2.5.1.1 Matriz de Confusão	45
2.5.1.2 Acurácia	46
2.5.1.3 Precisão	46
2.5.1.4 <i>Recall</i> (Sensibilidade)	47
2.5.1.5 Especificidade	47
2.5.1.6 F1-Score	47
2.5.1.7 F-beta Score	48
2.5.1.8 AUC-ROC	48
2.5.1.9 AUC-PR	49
2.5.1.10 Médias Multiclasse	49

2.5.2	Validação Cruzada	50
2.5.2.1	<i>k-Fold Cross-Validation</i>	50
2.5.2.2	Validação Cruzada Aninhada.....	50
2.5.2.3	Otimização de Hiperparâmetros	51
2.6	Explicabilidade de Modelos	51
2.6.1	Importância por Permutação	52
2.6.2	SHAP (<i>SHapley Additive exPlanations</i>)	52
3	TRABALHOS RELACIONADOS	54
3.1	Dados clínico-laboratoriais diversos	55
3.2	Dados Hematológicos e exames laboratoriais complementares.....	56
3.3	Dados Hematológicos.....	58
3.4	Classificação Multiclasse e Estratégias de <i>Ensemble</i>	59
3.5	Deteção de Pré-Diabetes com Aprendizado de Máquina	60
3.6	Síntese Crítica da Revisão da Literatura e Justificativa da Proposta	60
4	MATERIAIS E MÉTODOS.....	63
4.1	Base de Dados.....	63
4.1.1	Origem e Coleta dos Dados	63
4.1.2	Crterios de Inclusão, Exclusão e Limpeza.....	64
4.1.3	Atributos Preditivos e Variável-Alvo	65
4.1.4	Aspectos Éticos e Legais	67
4.1.5	Análise Exploratória da Base de dados.....	69
4.1.6	Tarefas de Classificação	69
4.2	Pré-processamento	71
4.2.1	Escalonamento e Transformação de Atributos	71
4.2.2	Balanceamento de Classes	73
4.3	Protocolo Experimental.....	74
4.3.1	Particionamento dos Dados.....	74
4.3.2	Validação Cruzada Aninhada.....	75
4.3.3	Métricas de Avaliação	77
4.4	Estratégias de Classificação	78
4.4.1	Tarefa 1: Classificação Binária	80
4.4.2	Tarefa 2: Classificação Multiclasse Direta.....	81
4.4.3	Tarefa 3: Decomposição Binária.....	81
4.4.4	Tarefa 4: <i>Ensemble</i>	82
4.5	Ambiente Computacional.....	86
5	RESULTADOS	89
5.1	Avaliação Geral dos Resultados.....	89
5.2	Tarefa 1: Classificação Binária (N vs. PD+D)	90
5.2.1	Desempenho dos Modelos	91
5.2.2	Estabilidade e Validação Cruzada Aninhada	96
5.2.3	Otimização do Limiar de Decisão.....	96
5.2.4	Impacto dos Atributos Preditivos.....	98
5.2.4.1	Importância Global	98
5.2.4.2	Interpretabilidade por Instância	100
5.2.5	Análise de Erros.....	102
5.2.5.1	Padrão dos Erros por Faixa de Hemoglobina Glicada	102
5.2.5.2	Análise de Erros por Sexo.....	102
5.2.5.3	Análise de Erros por Faixa Etária	103
5.3	Tarefa 2: Classificação Multiclasse (N vs. PD vs. D).....	105
5.3.1	Desempenho dos Modelos	105
5.3.2	Estabilidade e Validação Cruzada Aninhada	109

5.3.3	Impacto dos Atributos Preditivos.....	109
5.3.3.1	Importância Global	109
5.3.3.2	Interpretabilidade por Instância	112
5.3.4	Análise de Erros.....	112
5.3.4.1	Padrão dos Erros por Faixa de Hemoglobina Glicada	112
5.3.4.2	Análise de Erros por Sexo.....	114
5.3.4.3	Análise de Erros por Faixa Etária	114
5.4	Tarefa 3: Decomposição em Subproblemas Binários	115
5.4.1	Desempenho dos Modelos	116
5.4.2	Estabilidade e Validação Cruzada Aninhada	119
5.4.3	Impacto dos Atributos Preditivos.....	121
5.4.4	Análise de Erros.....	122
5.5	Tarefa 4: <i>Ensemble</i>	123
5.5.1	Composição e Estratégia.....	124
5.5.2	Evolução das Estratégias de Agregação.....	125
5.5.3	Desempenho do Ensemble v4.....	128
5.5.4	Comparação com a Tarefa 2 (Baseline)	128
6	DISCUSSÃO.....	131
6.1	Interpretação dos Resultados.....	131
6.2	Importância dos Parâmetros Hematológicos	136
6.3	Implicações para a Prática Clínica.....	139
7	CONCLUSÃO	144
	REFERÊNCIAS.....	147
	APÊNDICE A — CONFIGURAÇÕES DETALHADAS DOS <i>PIPELINES</i>	154
	APÊNDICE B — CARACTERIZAÇÃO DETALHADA DA BASE DE DADOS	155

1 INTRODUÇÃO

A globalização e suas consequentes mudanças no estilo de vida das pessoas durante as últimas décadas resultaram em alterações nas sociedades, sistemas, meio ambiente e comportamento humano mundial (ZIMMET et al., 2014). O avanço da tecnologia tem sido associado a um aumento nas atividades de lazer digital, como jogos em celulares, computadores, compras online e uso de mídias sociais online (RAMTAHAL et al., 2015). Estilos de vida sedentários e o aumento no consumo de dietas não saudáveis vem resultando em aumento do Índice de Massa Corporal de indivíduos (IMC) e índices de glicose plasmática em jejum (KHAN et al., 2020).

O Diabetes Mellitus é uma doença metabólica caracterizada pelos altos níveis de glicose no sangue (DRITSAS; TRIGKA, 2022). Em indivíduos portadores da doença, o corpo produz de forma ineficiente pouca ou nenhuma insulina, principal hormônio responsável por estabilizar o nível de açúcar no sangue (KHAN et al., 2019). Dependendo do distúrbio na produção de insulina, caracteriza-se o tipo da doença:

- Diabetes Tipo I ou Diabetes Infantil: Quando as células pancreáticas produtoras de insulina são destruídas por um mecanismo autoimune (anticorpos produzidos pelo próprio corpo destroem as células produtoras de insulina) (AAMODT, 2025).
- Diabetes Tipo II: Quando há o aumento da resistência do corpo à insulina, não produzindo o suficiente para atender às necessidades metabólicas. É a principal causa do diabetes em adultos, tendo a obesidade como o principal fator de predisposição para o desenvolvimento da doença (JAMES; STÖCKLI; BIRNBAUM, 2025).
- Diabetes Gestacional: Um tipo de diabetes que se manifesta pela primeira vez durante a gravidez, sendo semelhante ao Diabetes Tipo II (MODZELEWSKI et al., 2022).

Por ser uma doença de evolução progressiva (OSEI-YEBOAH et al., 2024), o diabetes representa um desafio crescente de saúde pública. Segundo a 11ª edição do *IDF Diabetes Atlas*, estimativas apontam que em 2024, aproximadamente 589 milhões de adultos conviviam com diabetes no planeta, com projeção de alcançar 853 milhões até 2050 (International Diabetes Federation, 2025). O custo global associado ao tratamento do diabetes e suas complicações foi estimado em 1 trilhão de dólares em 2024, representando 12% dos gastos mundiais em saúde (International Diabetes Federation, 2025).

O Brasil está entre os dez países com maior prevalência de diabetes no mundo, com o terceiro maior gasto anual em saúde relacionado à doença e suas complicações, estimado em 45,1 bilhões de dólares em 2024 (International Diabetes Federation, 2025).

O diabetes pode ser diagnosticado através da dosagem de glicose no sangue em jejum, durante um teste de tolerância à glicose ou através da Hemoglobina Glicada (A1c) (American Diabetes Association, 2026a). Por ser capaz de apresentar um resumo da estabilidade glicêmica do indivíduo por aproximadamente 90 dias de forma precisa, a dosagem de A1c é o teste padrão-ouro recomendado pela ADA (*American Diabetes Association*) para o diagnóstico da doença (American Diabetes Association, 2026a) (WHO, 2011). Apesar de sua superioridade diagnóstica em termos de conveniência e estabilidade pré-analítica, a dosagem de A1c apresenta sensibilidade inferior no ponto de corte de 6,5% em comparação ao teste oral de tolerância à glicose (TOTG), além de ser suscetível a interferências em condições que alteram o ciclo de vida dos eritrócitos, como anemias e hemoglobinopatias (American Diabetes Association, 2026a). Contudo, embora o TOTG apresente maior sensibilidade, sua aplicação em larga escala é limitada pela complexidade do procedimento, que exige jejum prolongado, ingestão de carga de glicose e coleta de sangue em dois tempos, além de apresentar baixa estabilidade pré-analítica e alta variabilidade intra-individual (American Diabetes Association, 2026a). Ainda assim, A1c possui limitações de maior custo e acesso restrito em diversas regiões do mundo (American Diabetes Association, 2026a). Neste contexto, a utilização de dados provenientes de exames de rotina como o hemograma representa uma alternativa potencialmente viável para a construção de modelos de triagem em populações onde o acesso à dosagem de A1c é restrito.

Muitos esforços são orientados para a melhoria, prevenção e diagnóstico do diabetes. A inteligência artificial (IA) é um dos métodos mais avançados baseados em recursos computacionais (AGLIATA et al., 2023), com aplicações que abrangem desde a triagem de retinopatia até o suporte à decisão clínica e a predição de risco populacional (ELLAHHAM, 2020) (ABRÀMOFF; TARBER et al., 2024). Nos últimos anos, diversos trabalhos publicados demonstram a viabilidade da aplicação de algoritmos de aprendizado de máquina na pesquisa de diabetes a partir de diferentes fontes de dados clínicos e laboratoriais (DAS; SAHA, 2022) (MUJUMDAR; VAIDEHI, 2019) (JOSHI; DHAKAL, 2021) (LAI et al., 2019).

O Hemograma é o exame laboratorial mais solicitado no mundo (HQ LE OH, 2022). Recentemente, publicações apontam reflexos das alterações metabólicas em pa-

râmetros hematológicos. Dentre as comorbidades identificadas em pacientes diabéticos, a anemia frequentemente coincide com distúrbios sanguíneos com Diabetes Mellitus. A inflamação crônica em portadores da doença eleva a contagem de Leucócitos, a relação monócito-linfócitos e a relação do volume médio plaquetário, dados aferidos no Hemograma (TWIG et al., 2013; ZACCARDI et al., 2015). Alterações na morfologia e funções plaquetárias também foram observadas (PAPATHEODOROU et al., 2018). A aplicação de algoritmos de *machine learning* (ML) na análise da correlação entre pacientes diabéticos e dados hematológicos foi recentemente publicada por Mansoori et al. (2023a). Correlações entre o índice glicêmico do paciente e os resultados do Hemograma foram apontados em todos os parâmetros, através do algoritmo de Florestas Aleatórias. Apesar do potencial demonstrado por estas abordagens, a maioria dos estudos utiliza bases de dados restritas, que não estão disponíveis em larga escala nos contextos clínicos, como imagens médicas, exames bioquímicos especializados ou dados extensos de prontuário eletrônico. Neste cenário, o hemograma emerge como uma alternativa estratégica ainda pouco explorada para a construção de modelos preditivos para triagem do diabetes (HQ LE OH, 2022).

O diabetes é frequentemente assintomático (OSEI-YEBOAH et al., 2024). Embora métodos de diagnóstico estejam em constante desenvolvimento, estudos indicam que o tempo entre o início da hiperglicemia e o diagnóstico clínico pode variar de 4 a 7 anos (KABOOTARI et al., 2022). De acordo com a *International Diabetes Federation*, estima-se que aproximadamente 252 milhões de adultos vivem com diabetes não diagnosticado globalmente (International Diabetes Federation, 2025). A intervenção através do diagnóstico precoce da doença, com mudanças no estilo de vida ou uso de medicações, apresenta eficácia na prevenção da evolução do diabetes tipo 2 e suas complicações em adultos (KNOWLER et al., 2002) (American Diabetes Association, 2026b). Apesar do pré-diabetes ser visto como uma fase crítica, estudos apontam que esta condição é reversível (American Diabetes Association, 2026b) e pode servir como um dos principais meios para combater a doença.

Este trabalho investiga a hipótese de que parâmetros hematológicos obtidos exclusivamente a partir do hemograma contêm informações associadas ao metabolismo glicêmico, possibilitando que modelos de aprendizado de máquina sejam capazes de classificar o status glicêmico de indivíduos em normoglicêmicos, pré-diabéticos e diabéticos. A fundamentação para esta hipótese reside nas evidências de que a hiperglicemia crônica induz alterações mensuráveis em parâmetros da série branca, série vermelha e série plaquetária

do hemograma (PAPATHEODOROU et al., 2018).

Neste cenário, o hemograma representa uma fonte estratégica de dados para a construção de modelos preditivos de aprendizado de máquina. Estudos recentes (CARDOZO et al., 2022) (MANSOORI et al., 2023a) demonstram que tais abordagens são viáveis e capazes de revelar correlações relevantes entre parâmetros hematológicos e status glicêmico. Contudo, justifica-se também a necessidade de ampliação da literatura científica com bases de dados de larga escala, explorando técnicas modernas de aprendizado de máquina com ênfase em explicabilidade dos modelos, fator essencial para uso na área da saúde. Do ponto de vista social e ético, a utilização de dados secundários anonimizados garante risco mínimo aos participantes, em conformidade com a Resolução CNS nº 466/12, Resolução nº 510/16 e LGPD (Lei nº 13.709/18). Portanto, este estudo apresenta relevância científica, clínica e social ao propor uma abordagem inovadora e ética na triagem precoce do diabetes.

Apesar da viabilidade demonstrada pela literatura, observam-se lacunas importantes no estado da arte. Primeiramente, a maior parte dos estudos correlatos utiliza bases de dados de porte restrito, com volumes substancialmente inferiores aos disponíveis em sistemas de informação laboratoriais de rotina, conforme detalhado no Capítulo 3, o que limita a generalização dos resultados. Em segundo lugar, poucos trabalhos investigam a classificação do status glicêmico utilizando *exclusivamente* dados do hemograma, sem o auxílio de exames complementares como glicose de jejum, perfil lipídico ou dados clínicos do prontuário. Por fim, não foram identificados estudos que avaliem sistematicamente estratégias de decomposição binária e *ensemble* heterogêneo para o problema multiclasse de classificação do status glicêmico a partir de parâmetros hematológicos.

O objetivo geral deste trabalho é desenvolver e avaliar modelos de aprendizado de máquina capazes de classificar o status glicêmico do paciente com base no valor da Hemoglobina Glicada (A1c) a partir de dados hematológicos, com foco na explicabilidade dos resultados e apoio à prática clínica. Como objetivos específicos, este trabalho investiga estratégias de decomposição binária e *ensemble* heterogêneo de especialistas para a classificação multiclasse do status glicêmico, investiga a explicabilidade dos modelos preditivos, identificando a contribuição individual dos parâmetros hematológicos para a predição de A1c, e analisa os padrões de erro dos modelos por subgrupo demográfico (sexo e faixa etária) e por faixa de A1c, avaliando a equidade e as limitações em diferentes perfis de pacientes. Como validação externa, parte dos resultados apresentados nesta dissertação foi submetida e aprovada, após processo de revisão por pares, no XXVI

Simpósio Brasileiro de Computação Aplicada à Saúde (SBCAS 2026), o que corrobora a metodologia adotada e os achados deste trabalho frente ao estado da arte da literatura científica nacional na área de Computação Aplicada à Saúde.

Este documento está estruturado da seguinte forma: O Capítulo 2 apresenta a fundamentação teórica necessária para a compreensão deste trabalho, abordando conceitos sobre Diabetes Mellitus, hemograma, aprendizado de máquina supervisionado, métricas de avaliação e técnicas de explicabilidade. O Capítulo 3 discute os trabalhos relacionados, posicionando esta pesquisa em relação à literatura existente. O Capítulo 4 descreve os materiais e métodos empregados, incluindo a base de dados, as estratégias de classificação e o protocolo experimental. O Capítulo 5 apresenta os resultados obtidos em cada tarefa de classificação. O Capítulo 6 discute os resultados, a importância dos parâmetros hematológicos e as implicações para a prática clínica. Por fim, o Capítulo 7 sumariza as contribuições deste trabalho, discute suas limitações e aponta direções para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos teóricos necessários para a compreensão deste trabalho. A Seção 2.1 aborda o Diabetes Mellitus, incluindo definição, classificação, diagnóstico e o papel da hemoglobina glicada. A Seção 2.2 descreve o hemograma e os parâmetros hematológicos utilizados como atributos preditivos. A Seção 2.3 apresenta os fundamentos de aprendizado de máquina supervisionado, incluindo os algoritmos de classificação utilizados no trabalho. A Seção 2.4 aborda o tratamento de dados desbalanceados. A Seção 2.5 apresenta as métricas de avaliação de desempenho e as estratégias de validação cruzada. Por fim, a Seção 2.6 as técnicas de explicabilidade de modelos.

2.1 Diabetes Mellitus

2.1.1 Definição e Epidemiologia

O Diabetes Mellitus (DM) é um grupo de doenças metabólicas caracterizadas pela hiperglicemia crônica, resultante de defeitos na secreção de insulina, na ação da insulina ou em ambos (American Diabetes Association, 2026a). A insulina é um hormônio produzido pelas células beta das ilhotas de Langerhans do pâncreas, responsável por facilitar a captação de glicose pelas células do organismo para a produção de energia (JAMES; STÖCKLI; BIRNBAUM, 2025). Quando a produção ou a ação da insulina é comprometida, a glicose acumula-se na corrente sanguínea, resultando em hiperglicemia persistente que, ao longo do tempo, pode causar danos a diversos órgãos e sistemas (PAPATHEODOROU et al., 2018).

Como apresentado na introdução (Capítulo 1), o diabetes representa um dos maiores desafios de saúde pública do século XXI, com estimativas globais da *International Diabetes Federation* projetando crescimento contínuo na prevalência e nos custos associados até 2050 (International Diabetes Federation, 2025). Em complemento a esse panorama, observa-se que a prevalência aumenta progressivamente com a idade, atingindo 23,72% entre adultos com mais de 65 anos (International Diabetes Federation, 2025). Além disso, estima-se que aproximadamente 43% dos adultos com diabetes no mundo permaneçam sem diagnóstico (International Diabetes Federation, 2025), o que reforça a necessidade de estratégias acessíveis de triagem populacional.

A epidemiologia do diabetes apresentou mudanças significativas nas últimas déca-

das. Gregg, Sattar and Ali (2020) demonstraram que, embora a prevalência global tenha aumentado substancialmente, as taxas de complicações graves, como amputações e eventos cardiovasculares, apresentaram redução em países com programas estruturados de detecção precoce e manejo clínico. Contudo, o crescimento absoluto no número de portadores da doença continua exercendo pressão sobre os sistemas de saúde, evidenciando a necessidade de estratégias inovadoras de triagem populacional (International Diabetes Federation, 2025).

2.1.2 Classificação

A ADA classifica o diabetes em três tipos principais, distinguidos pelo mecanismo biológico responsável pela hiperglicemia: o **Diabetes Tipo 1**, de origem autoimune; o **Diabetes Tipo 2**, caracterizado por resistência à insulina; e o **Diabetes Gestacional**, que se manifesta durante a gestação, além de outros tipos específicos decorrentes de condições distintas (diabetes monogênico, induzido por medicamentos ou secundário a doenças pancreáticas) (American Diabetes Association, 2026a).

O **Diabetes Mellitus Tipo 1** (DM1) é uma doença autoimune em que o sistema imunológico destrói as células beta produtoras de insulina no pâncreas (AAMODT, 2025). Essa destruição resulta em deficiência absoluta de insulina, tornando o paciente dependente de aplicações diárias de insulina para sobrevivência. O DM1 representa aproximadamente 5 a 10% de todos os casos de diabetes e apresenta maior incidência na infância e adolescência, embora possa se manifestar em qualquer idade (American Diabetes Association, 2026a). Fatores genéticos e ambientais contribuem para o desenvolvimento da doença, porém os mecanismos desencadeadores da autoimunidade ainda não foram completamente descobertos cientificamente (AAMODT, 2025).

O **Diabetes Mellitus Tipo 2** (DM2) é caracterizado pela resistência à insulina, em que as células do organismo respondem de forma inadequada ao hormônio, combinada com uma deficiência progressiva na secreção de insulina pelas células beta pancreáticas (JAMES; STÖCKLI; BIRNBAUM, 2025). O DM2 representa 90 a 95% de todos os casos de diabetes e está fortemente associado a fatores de risco reversíveis, como obesidade, sedentarismo e dieta inadequada (American Diabetes Association, 2026a). A fisiopatologia envolve múltiplos mecanismos, incluindo a resistência periférica à insulina no tecido muscular e adiposo, o aumento da produção hepática de glicose e a disfunção progressiva das células beta (JAMES; STÖCKLI; BIRNBAUM, 2025). Diferentemente do DM1, o

início do DM2 é frequentemente gradual e assintomático, possibilitando que a doença progrida por anos sem diagnóstico (KABOOTARI et al., 2022).

O **Diabetes Gestacional** (DMG) é definido como qualquer grau de intolerância à glicose diagnosticado pela primeira vez durante a gestação (MODZELEWSKI et al., 2022). Sua fisiopatologia envolve a resistência à insulina induzida por hormônios placentários, combinada com a incapacidade de secreção de insulina. O DMG afeta entre 2 e 10% das gestações e geralmente se resolve após o parto, porém confere risco aumentado de desenvolvimento de DM2 em longo prazo tanto para a mãe quanto para o filho (MODZELEWSKI et al., 2022).

2.1.3 Diagnóstico e Hemoglobina Glicada

O diagnóstico do diabetes pode ser estabelecido por três métodos laboratoriais principais: a dosagem de glicose em jejum (GPJ), o teste oral de tolerância à glicose (TOTG) e a dosagem de hemoglobina glicada (A1c) (American Diabetes Association, 2026a). A Tabela 2.1 apresenta os critérios diagnósticos estabelecidos pela *American Diabetes Association* (ADA) e pela Organização Mundial da Saúde (OMS).

Tabela 2.1 – Critérios diagnósticos para classificação do status glicêmico.

Critério	Normal	Pré-diabetes	Diabetes
Glicose em jejum (mg/dL)	< 100	100–125	≥ 126
TOTG 2h (mg/dL)	< 140	140–199	≥ 200
A1c (%)	< 5,7	5,7–6,4	≥ 6,5

Fonte: Adaptado de American Diabetes Association (2026a) e World Health Organization (2021).


A A1c é formada pela ligação não enzimática e irreversível da glicose à porção N-terminal da cadeia beta da hemoglobina presente nos eritrócitos (EYTH; NAIK, 2024). Como os eritrócitos possuem um tempo de vida médio de 120 dias, a concentração de A1c reflete a média dos níveis de glicose sanguínea nos dois a três meses anteriores à coleta da amostra de sangue, proporcionando uma medida integrada da exposição glicêmica (World Health Organization, 2021).

Além das vantagens logísticas já apresentadas no Capítulo 1, a dosagem de A1c se destaca por não exigir jejum prévio e por apresentar menor variabilidade biológica intra-individual que a glicemia de jejum e o TOTG (American Diabetes Association, 2026a), características que a tornam adequada a programas de triagem em larga escala. Em contrapartida, condições que alteram o ciclo de vida dos eritrócitos, como anemias hemolíticas

e gestação, podem resultar em valores de A1c falsamente elevados ou reduzidos (EYTH; NAIK, 2024).

A Figura 2.1 ilustra a correspondência entre os valores de A1c e a classificação do status glicêmico conforme os critérios da ADA. Essas três categorias (Normal, Pré-diabetes e Diabetes) constituem as classes-alvo do problema preditivo investigado neste trabalho, cuja formalização como variável-alvo é detalhada no Capítulo 4.

Figura 2.1 – Faixas de classificação do status glicêmico conforme os valores de A1c.



Elaborado pelo autor.

2.1.4 Pré-diabetes

O pré-diabetes é um estado metabólico intermediário no qual os níveis de glicose sanguínea encontram-se acima dos valores considerados normais, porém abaixo dos limites diagnósticos para diabetes (American Diabetes Association, 2026a). De acordo com os critérios da ADA, o pré-diabetes é definido por valores de A1c entre 5,7% e 6,4%, glicose em jejum entre 100 e 125 mg/dL ou TOTG de 2 horas entre 140 e 199 mg/dL (American Diabetes Association, 2026a).

A relevância clínica do pré-diabetes reside em dois aspectos fundamentais. Primeiramente, o estado pré-diabético representa uma janela de oportunidade para intervenção, uma vez que modificações no estilo de vida, como dieta adequada e prática regular de atividade física, demonstraram reduzir em até 58% o risco de progressão para DM2 (KNOWLER et al., 2002). Em segundo lugar, o pré-diabetes é amplamente subdiagnosticado, sendo que a maioria dos indivíduos nesta condição desconhece seu status glicêmico (American Diabetes Association, 2026b). A *International Diabetes Federation* estima que aproximadamente 252 milhões de adultos apresentam alguma forma de hiperglicemia intermediária sem diagnóstico (International Diabetes Federation, 2025).

A progressão do pré-diabetes para o DM2 não é inevitável. Estudos demonstraram que intervenções estruturadas podem reverter o estado pré-diabético para o estado de glicose normal (KNOWLER et al., 2002) (American Diabetes Association, 2026b).

Contudo, sem intervenção, estima-se que 5 a 10% dos indivíduos pré-diabéticos progridem para DM2 anualmente (American Diabetes Association, 2026b). Essa característica reversível do pré-diabetes fundamenta a importância de estratégias de detecção precoce com potencial de alcance populacional.

2.2 Hemograma e Parâmetros Hematológicos

2.2.1 O Hemograma

O hemograma, também denominado hemograma completo (*Complete Blood Count*, CBC), é o exame laboratorial mais solicitado na prática clínica mundial (HQ LE OH, 2022). O exame consiste na análise quantitativa e qualitativa das células do sangue periférico, fornecendo informações sobre três linhagens celulares distintas: a série branca (leucócitos), a série vermelha (eritrócitos) e a série plaquetária (trombócitos) (GEORGE-GAY; PARKER, 2003).

A realização do hemograma é amplamente acessível, de baixo custo e executada de forma automatizada por analisadores hematológicos presentes na maioria dos laboratórios de análises clínicas. Os resultados são gerados em minutos e armazenados digitalmente nos sistemas de informação laboratorial (LIS), o que possibilita a disponibilidade de grandes volumes de dados hematológicos em formato estruturado (HQ LE OH, 2022). Essa combinação de acessibilidade, baixo custo e disponibilidade digital torna o hemograma uma fonte potencial de dados para aplicações de aprendizado de máquina na área da saúde.

2.2.2 Parâmetros Hematológicos

Os parâmetros hematológicos aferidos pelo hemograma são organizados em três séries celulares, cada uma refletindo aspectos distintos da composição sanguínea. A seguir, são descritos os principais parâmetros de cada série.

2.2.2.1 Série Branca (*Leucócitos*)

A série branca compreende os leucócitos, células responsáveis pela defesa imunológica do organismo. O hemograma quantifica a contagem total de leucócitos e sua dife-

renciação em subtipos celulares, cuja proporção relativa constitui o leucograma (GEORGE-GAY; PARKER, 2003). Os principais subtipos celulares são:

- **Neutrófilos** (segmentados e bastões): constituem 40 a 70% dos leucócitos circulantes e representam a primeira linha de defesa contra infecções bacterianas. Os segmentados são células maduras, enquanto os bastões são formas jovens cuja elevação indica ativação da medula óssea (GEORGE-GAY; PARKER, 2003).
- **Linfócitos**: constituem 20 a 40% dos leucócitos e são responsáveis pela resposta imune adaptativa, incluindo a produção de anticorpos (linfócitos B) e a imunidade celular (linfócitos T) (GEORGE-GAY; PARKER, 2003).
- **Monócitos**: representam 2 a 8% dos leucócitos circulantes. Atuam na defesa contra infecções por meio da captura e destruição de micro-organismos (GEORGE-GAY; PARKER, 2003).
- **Eosinófilos**: constituem 1 a 4% dos leucócitos e estão envolvidos na resposta a infecções parasitárias e em processos alérgicos (GEORGE-GAY; PARKER, 2003).
- **Basófilos**: representam menos de 1% dos leucócitos e participam de reações alérgicas e inflamatórias por meio da liberação de histamina (GEORGE-GAY; PARKER, 2003).

2.2.2.2 *Série Vermelha (Eritrócitos)*

A série vermelha compreende os eritrócitos (hemácias) e os índices derivados. Os eritrócitos são as células mais abundantes do sangue e possuem como função primária o transporte de oxigênio dos pulmões para os tecidos, por meio da hemoglobina (GEORGE-GAY; PARKER, 2003). Os principais parâmetros avaliados são:

- **Eritrócitos**: contagem total de hemácias por unidade de volume sanguíneo.
- **Hemoglobina** (Hb, HGB): proteína presente nos eritrócitos responsável pelo transporte de oxigênio. Seus valores refletem a capacidade de oxigenação do sangue.
- **Hematócrito** (Ht, HCT): proporção do volume sanguíneo ocupado pelos eritrócitos, expressa em percentual.
- **Hemoglobina Corpuscular Média** (HCM): quantidade média de hemoglobina por eritrócito, expressa em picogramas (pg).
- **Concentração de Hemoglobina Corpuscular Média** (CHCM): concentração média de hemoglobina por volume de eritrócitos, expressa em g/dL.

- **Amplitude de Distribuição dos Eritrócitos (RDW, *Red Cell Distribution Width*):** índice que quantifica a variabilidade no tamanho dos eritrócitos. Valores elevados indicam heterogeneidade no volume eritrocitário (ENGSTRÖM et al., 2014).

2.2.2.3 Série Plaquetária

A série plaquetária avalia os trombócitos, fragmentos celulares originados na medula óssea, essenciais para o processo de hemostasia e coagulação sanguínea (GEORGE-GAY; PARKER, 2003). Os parâmetros avaliados são:

- **Plaquetas (PLT, *Platelets*):** contagem total de trombócitos por unidade de volume sanguíneo.
- **Volume Plaquetário Médio (VPM, *Mean Platelet Volume*, MPV):** tamanho médio das plaquetas, expresso em fentolitros (fL). Plaquetas maiores tendem a ser mais jovens e metabolicamente mais ativas (ZACCARDI et al., 2015).

2.2.3 Alterações Hematológicas Associadas ao Diabetes

Evidências crescentes na literatura demonstram que a hiperglicemia crônica induz alterações mensuráveis nos parâmetros hematológicos, afetando as três séries celulares do hemograma. Essas alterações resultam de mecanismos fisiopatológicos distintos, que incluem inflamação crônica de baixo grau, glicação de proteínas e disfunção endotelial (DOMINGUETI et al., 2016; GIACCO; BROWNLIE, 2010).

Na série branca, o estado inflamatório crônico associado ao diabetes promove elevação na contagem total de leucócitos, particularmente de neutrófilos e monócitos (TWIG et al., 2013). Twig et al. (2013) demonstraram, em estudo com mais de 20.000 participantes, que a contagem de leucócitos apresenta associação independente com o risco de desenvolvimento de DM2, mesmo após ajuste para fatores de confusão tradicionais. A relação monócito-linfócitos também se apresenta alterada em portadores de diabetes, refletindo o estado pró-inflamatório sistêmico da doença (PAPATHEODOROU et al., 2018).

Na série vermelha, a hiperglicemia altera a estrutura da membrana dos eritrócitos, tornando-os mais rígidos e reduzindo seu tempo de vida (WANG et al., 2021). Como consequência, o RDW, parâmetro do hemograma que mede a variabilidade no tamanho dos eritrócitos, apresenta valores elevados em portadores de diabetes (ENGSTRÖM et al., 2014).

Na série plaquetária, o diabetes está associado a alterações na morfologia e na função das plaquetas. Zaccardi et al. (2015) demonstraram que pacientes diabéticos apresentam VPM elevado, indicando maior proporção de plaquetas jovens e metabolicamente ativas, o que contribui para o estado pró-trombótico observado na doença. Papatheodorou et al. (2018) reportaram que as alterações plaquetárias associadas ao diabetes incluem aumento da agregação plaquetária e da expressão de receptores de superfície, mecanismos que contribuem para o risco cardiovascular elevado nesses pacientes.

A existência dessas alterações hematológicas mensuráveis, distribuídas pelas três séries do hemograma, sugere que os parâmetros do hemograma podem conter informações associadas ao metabolismo glicêmico do indivíduo. Essa premissa fundamenta a investigação de modelos preditivos baseados em dados hematológicos para a classificação do status glicêmico.

2.3 Aprendizado de Máquina Supervisionado

2.3.1 Conceitos Fundamentais

O aprendizado de máquina supervisionado é um paradigma de modelagem computacional no qual um algoritmo aprende a mapear um conjunto de variáveis de entrada (atributos ou *features*) para uma variável de saída (rótulo ou classe) a partir de exemplos previamente rotulados (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Formalmente, a tarefa consiste em aprender uma função $y = f(\mathbf{x}|\Theta)$, onde $\mathbf{x}$ representa o vetor de atributos de entrada, y o rótulo esperado e Θ o conjunto de parâmetros internos do modelo, ajustados a partir dos dados de treinamento com o objetivo de minimizar o erro de predição em dados não observados (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Quando a variável de saída y é categórica (pertencente a um conjunto finito de classes), o problema é denominado *classificação*. Quando y é contínua, denomina-se *regressão* (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). A capacidade de generalização do modelo, ou seja, sua habilidade de realizar predições corretas em dados não utilizados durante o treinamento, é o critério fundamental de avaliação de desempenho (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Um conceito central no aprendizado supervisionado é o dilema viés-variância (*bias-variance tradeoff*). Modelos com alta complexidade (muitos parâmetros) tendem a apresentar baixo viés, porém alta variância, ajustando-se excessivamente aos dados de

treinamento (sobreajuste ou *overfitting*). Modelos com baixa complexidade apresentam alto viés, porém baixa variância, falhando em capturar padrões relevantes nos dados (subajuste ou *underfitting*) (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). A seleção de hiperparâmetros e as estratégias de validação cruzada são mecanismos para encontrar o equilíbrio entre viés e variância.

Para avaliar a capacidade de generalização de um modelo, os dados disponíveis são tipicamente divididos em subconjuntos disjuntos. O conjunto de *treinamento* é utilizado para ajustar os parâmetros do modelo. O conjunto de *validação* é utilizado para a seleção de hiperparâmetros e comparação entre configurações. O conjunto de *teste* é reservado para a estimativa final de desempenho, sem participar de nenhuma etapa do processo de modelagem (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). A partição estratificada preserva a proporção de classes em cada subconjunto, o que é particularmente importante em problemas com distribuição desbalanceada entre classes.

2.3.2 Algoritmos de Classificação

A seguir são apresentados os algoritmos de classificação empregados nos experimentos deste trabalho. A descrição foca nos fundamentos conceituais necessários à interpretação dos resultados, não constituindo uma revisão exaustiva da literatura.

2.3.2.1 Regressão Logística

A Regressão Logística (*Logistic Regression*, LR) é um modelo linear de classificação que estima a probabilidade de uma instância pertencer a uma determinada classe por meio da função sigmoide (logística) (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Para um problema binário, a probabilidade da classe positiva é modelada como:

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (2.1)$$

onde $\mathbf{w}$ é o vetor de pesos, b é o termo de viés (*bias*) e $\sigma(\cdot)$ é a função sigmoide. Os parâmetros são estimados por maximização da semelhança, tipicamente otimizada por métodos de gradiente (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Apesar de sua simplicidade, a Regressão Logística apresenta interpretabilidade elevada, pois os coeficientes do modelo indicam diretamente a contribuição de cada atributo para a probabilidade de classificação. A adição de termos de regularização (L_1 , L_2 ou *ElasticNet*) permite con-

trolar o sobreajuste (PEDREGOSA et al., 2011).

2.3.2.2 Máquinas de Vetores de Suporte

As Máquinas de Vetores de Suporte (*Support Vector Machines*, SVM) são algoritmos de classificação que buscam encontrar o hiperplano de separação que maximiza a margem entre as classes distintas de um problema (CORTES; VAPNIK, 1995). A margem é definida como a distância entre o hiperplano de decisão e as instâncias mais próximas de cada classe, denominadas vetores de suporte. A formulação do SVM linear busca resolver o problema de otimização:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)) \quad (2.2)$$

onde C é o parâmetro de regularização que controla o compromisso entre a maximização da margem e a minimização dos erros de classificação (CORTES; VAPNIK, 1995). A variante *LinearSVC* implementa a formulação linear do SVM com otimização baseada em *liblinear*, sendo eficiente para conjuntos de dados de grande dimensionalidade (PEDREGOSA et al., 2011). Para problemas não linearmente separáveis, o SVM pode empregar funções de *kernel* como a Função de Base Radial (*Radial Basis Function*, RBF) ou polinomial, que mapeiam os dados para espaços de maior dimensionalidade, porém com custo computacional mais elevado (CORTES; VAPNIK, 1995).

2.3.2.3 Árvores de Decisão

As Árvores de Decisão (*Decision Tree*, DT) são modelos não paramétricos que realizam a classificação por meio de particionamentos recursivos do espaço de atributos (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). O algoritmo CART (*Classification and Regression Trees*) constrói a árvore selecionando, em cada nó, o atributo e o ponto de corte que maximizam a pureza dos subconjuntos resultantes, medida por critérios como o índice de Gini ou a entropia (BREIMAN et al., 1984; HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

O índice de Gini para um nó t é definido como:

$$G(t) = 1 - \sum_{k=1}^K p_k^2 \quad (2.3)$$

onde p_k é a proporção de instâncias da classe k no nó t e K é o número de classes.

Valores de $G(t)$ próximos de zero indicam alta pureza (predominância de uma classe), enquanto valores próximos de $1 - 1/K$ indicam distribuição uniforme entre classes (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

As Árvores de Decisão apresentam alta interpretabilidade, uma vez que as regras de classificação podem ser visualizadas diretamente na estrutura da árvore. Contudo, são suscetíveis ao sobreajuste quando a profundidade da árvore não é limitada, e apresentam alta variância, sendo sensíveis a pequenas alterações nos dados de treinamento (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). A poda (*pruning*) e a limitação de hiperparâmetros como profundidade máxima (*max_depth*), número mínimo de amostras por folha (*min_samples_leaf*) e número máximo de atributos (*max_features*) são mecanismos para controlar a complexidade do modelo.

2.3.2.4 Bagging

O *Bootstrap Aggregating (Bagging)* é uma técnica de *ensemble* proposta por Breiman (1996) que visa reduzir a variância de modelos instáveis, como as Árvores de Decisão. O método consiste em treinar múltiplos classificadores base em diferentes amostras *bootstrap* (amostras com reposição) do conjunto de treinamento e combinar suas previsões por votação majoritária (classificação) ou média (regressão) (BREIMAN, 1996).

Ao introduzir diversidade entre os classificadores por meio da aleatoriedade na amostragem dos dados, o *Bagging* reduz a variância do modelo final sem aumentar significativamente o viés. A eficácia do *Bagging* é proporcional à instabilidade do classificador base: quanto mais sensível o classificador a perturbações nos dados, maior o benefício da agregação (BREIMAN, 1996).

2.3.2.5 Florestas Aleatórias

As Florestas Aleatórias (*Random Forest*, RF) são uma extensão do *Bagging* proposta por Breiman (2001) que adiciona uma segunda fonte de aleatoriedade ao processo de construção dos classificadores base. Além da amostragem *bootstrap* dos dados, cada nó da árvore de decisão seleciona o melhor ponto de corte a partir de um subconjunto aleatório de atributos de tamanho $m \ll d$, onde d é o número total de atributos (BREIMAN, 2001).

Essa dupla aleatoriedade (dados e atributos) promove maior diversidade entre as árvores individuais, reduzindo a correlação entre suas previsões e resultando em melhor

generalização. A Floresta Aleatória é considerada um algoritmo robusto, com poucos hiperparâmetros críticos, sendo o número de árvores ($n_estimators$) e o número de atributos por nó ($max_features$) os principais (BREIMAN, 2001). Adicionalmente, o algoritmo fornece uma estimativa da importância dos atributos por meio da redução média da impureza (*Mean Decrease Impurity*, MDI) ou pela importância por permutação (BREIMAN, 2001).

2.3.2.6 AdaBoost

O *Adaptive Boosting* (AdaBoost), proposto por Freund and Schapire (1997), é um algoritmo de *ensemble* que combina múltiplos classificadores fracos (*weak learners*) de forma sequencial, ajustando os pesos das instâncias a cada iteração. Instâncias classificadas incorretamente recebem pesos maiores, forçando os classificadores subsequentes a se concentrarem nos exemplos mais difíceis (FREUND; SCHAPIRE, 1997).

A predição final é obtida por votação ponderada, na qual cada classificador recebe um peso proporcional à sua acurácia. O AdaBoost reduz o viés do modelo ao focar progressivamente nos erros de classificação, porém é sensível a ruído nos dados, uma vez que instâncias ruidosas recebem pesos elevados e podem distorcer o treinamento (FREUND; SCHAPIRE, 1997).

2.3.2.7 Gradient Boosting

O *Gradient Boosting* é uma família de algoritmos de *ensemble* que constrói modelos de forma aditiva, ajustando cada novo classificador base aos resíduos (gradientes negativos da função de custo) dos classificadores anteriores (FRIEDMAN, 2001). Formalmente, dado um modelo aditivo $F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta \cdot h_m(\mathbf{x})$, o classificador base h_m é ajustado ao gradiente negativo da função de custo avaliada em F_{m-1} (FRIEDMAN, 2001), onde η é a taxa de aprendizado (*learning rate*) que controla a contribuição de cada classificador base.

Quatro implementações de *Gradient Boosting* são amplamente utilizadas na literatura, diferindo em otimizações de eficiência e funcionalidades adicionais:

- **Gradient Boosting** (scikit-learn): implementação clássica do algoritmo, que ajusta Árvore de Decisão sequencialmente aos resíduos do modelo acumulado (FRIEDMAN, 2001; PEDREGOSA et al., 2011).
- **HistGradientBoosting** (HGBT, scikit-learn): variante inspirada em LightGBM (KE

et al., 2017) e incorporada ao *scikit-learn* (PEDREGOSA et al., 2011) a partir da versão 0.21, que utiliza discretização por histogramas (*histogram binning*) para acelerar o treinamento, agrupando os valores contínuos dos atributos em intervalos discretos e reduzindo a complexidade computacional da busca pelo melhor ponto de corte. Essa abordagem dispensa o escalonamento prévio dos atributos numéricos.

- **XGBoost** (*eXtreme Gradient Boosting*): implementação otimizada que incorpora regularização L_1 e L_2 na função objetivo, tratamento nativo de valores ausentes e paralelização da construção das árvores (CHEN; GUESTRIN, 2016).
- **LightGBM** (LGBM, *Light Gradient Boosting Machine*): implementação que utiliza crescimento por folha (*leaf-wise growth*) em vez de crescimento por nível (*level-wise*), combinado com *Gradient-based One-Side Sampling* (GOSS) e *Exclusive Feature Bundling* (EFB) para otimizar a eficiência em conjuntos de dados de grande porte (KE et al., 2017). Assim como o *HistGradientBoosting*, utiliza *histogram binning* nativo.
- **CatBoost** (*Categorical Boosting*): implementação que introduz *Ordered Target Encoding* para tratamento nativo de variáveis categóricas e *Ordered Boosting* para redução de viés no cálculo dos resíduos (PROKHORENKOVA et al., 2018).

2.3.2.8 Perceptron Multicamadas (MLP)

O Perceptron Multicamadas (*Multi-Layer Perceptron*, MLP) é uma classe de redes neurais artificiais *feedforward* composta por camadas de neurônios interconectados: uma camada de entrada, uma ou mais camadas ocultas (*hidden layers*) e uma camada de saída (GOODFELLOW; BENGIO; COURVILLE, 2016). Cada neurônio computa uma combinação linear ponderada de suas entradas, seguida pela aplicação de uma função de ativação não linear:

$$a_j^{(l)} = g \left(\sum_i w_{ji}^{(l)} a_i^{(l-1)} + b_j^{(l)} \right) \quad (2.4)$$

onde $a_j^{(l)}$ é a ativação do neurônio j na camada l , $w_{ji}^{(l)}$ são os pesos sinápticos, $b_j^{(l)}$ é o viés e $g(\cdot)$ é a função de ativação (GOODFELLOW; BENGIO; COURVILLE, 2016). Funções de ativação comumente utilizadas incluem a ReLU (*Rectified Linear Unit*), definida como $g(z) = \max(0, z)$, e a tangente hiperbólica (GOODFELLOW; BENGIO; COURVILLE, 2016).

O treinamento do MLP é realizado pelo algoritmo de retropropagação (*backpropagation*), que calcula os gradientes da função de custo em relação a cada peso da rede por meio da regra da cadeia, propagando o erro da camada de saída para as camadas anteriores (RUMELHART; HINTON; WILLIAMS, 1986). Os pesos são então atualizados por algoritmos de otimização baseados em gradiente, como o SGD (*Stochastic Gradient Descent*) ou o Adam (*Adaptive Moment Estimation*) (GOODFELLOW; BENGIO; COURVILLE, 2016). Os principais hiperparâmetros incluem o número de camadas ocultas, o número de neurônios por camada, a taxa de aprendizado e o parâmetro de regularização (*alpha*).

2.3.3 Estratégias de Classificação Multiclasse

Diversos algoritmos de classificação, como o SVM e a Regressão Logística, são formulados originalmente para problemas binários (duas classes). Para estendê-los a problemas com $K > 2$ classes, são empregadas estratégias de decomposição (RIFKIN; KLAUTAU, 2004): *One-vs-Rest* e *One-vs-One*.

A estratégia *One-vs-Rest* (OvR), também denominada *One-vs-All*, treina K classificadores binários, cada um discriminando uma classe contra todas as demais. Para uma nova instância, cada classificador produz uma pontuação de confiança, e a classe atribuída é aquela cujo classificador apresenta a maior pontuação (RIFKIN; KLAUTAU, 2004). A vantagem do OvR reside em sua simplicidade e escalabilidade, uma vez que o número de classificadores cresce linearmente com K (RIFKIN; KLAUTAU, 2004).

A estratégia *One-vs-One* (OvO) treina $K(K - 1)/2$ classificadores binários, cada um discriminando um par de classes. A classificação é realizada por votação majoritária entre todos os classificadores (GALAR et al., 2011). Embora demande um maior número de classificadores, cada modelo é treinado com um subconjunto menor dos dados, o que pode ser vantajoso em termos computacionais para determinados algoritmos (GALAR et al., 2011).

Alguns algoritmos, como as Árvore de Decisão, as Florestas Aleatórias e o *Gradient Boosting*, possuem extensão multiclasse nativa, tratando o problema com K classes diretamente em sua formulação, sem necessidade de decomposição (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

2.3.4 Métodos de Aprendizado *Ensemble*

Os métodos de aprendizado *ensemble* combinam as predições de múltiplos classificadores individuais para obter um modelo com desempenho superior ao de qualquer classificador isolado (KUNCHEVA, 2004). A eficácia dos métodos de *ensemble* está fundamentada no princípio de que classificadores diversos, quando combinados de forma adequada, tendem a compensar os erros individuais de cada componente (KUNCHEVA, 2004). Cabe destacar que vários dos algoritmos apresentados na Seção 2.3.2 constituem exemplos consolidados de métodos *ensemble* homogêneos, incluindo o *Bagging* (Seção 2.3.2.4), as Florestas Aleatórias (Seção 2.3.2.5), o AdaBoost (Seção 2.3.2.6) e a família *Gradient Boosting* (Seção 2.3.2.7), com suas variantes *HistGradientBoosting*, XGBoost, LightGBM e CatBoost. As discussões subsequentes desta seção concentram-se em estratégias de combinação aplicáveis à composição de classificadores heterogêneos, exploradas posteriormente na Tarefa 4 deste trabalho.

O *Voting* é uma estratégia de combinação na qual as predições dos classificadores individuais são agregadas por votação. No *hard voting*, a classe atribuída é aquela que recebe o maior número de votos entre os classificadores. No *soft voting*, as probabilidades preditas por cada classificador são ponderadas e somadas, sendo atribuída a classe com maior probabilidade média (KUNCHEVA, 2004). O *soft voting* tende a apresentar desempenho superior quando os classificadores base produzem estimativas de probabilidade calibradas.

No *soft voting* com pesos uniformes, a probabilidade final para cada classe corresponde à média aritmética simples das probabilidades preditas pelos classificadores individuais. Alternativamente, é possível atribuir pesos diferenciados a cada classificador, tipicamente derivados de seu desempenho em um conjunto de validação, como o F2-Score ou a AUC-ROC. Nessa variante, denominada *weighted soft voting*, classificadores com maior desempenho na validação recebem maior influência na decisão final, favorecendo a predição dos componentes mais confiáveis (KUNCHEVA, 2004).

Uma extensão da estratégia *One-vs-One* (descrita na Seção 2.3.3) no contexto de agregação de ensembles é o *Gated One-vs-One*, no qual as contribuições dos classificadores binários são ponderadas pela probabilidade de que a instância pertença ao par de classes em que cada classificador foi treinado. Essa probabilidade conjunta é estimada a partir de classificadores *One-vs-Rest* auxiliares, conforme a formulação de acoplamento em pares (*pairwise coupling*) proposta por Wu, Lin and Weng (2004) e revisada por Galar

et al. (2011). A ponderação mitiga a limitação do *One-vs-One* padrão, na qual todos os classificadores contribuem igualmente mesmo para pares de classes improváveis dado o exemplo de entrada.

O *Stacking* (*Stacked Generalization*), proposto por Wolpert (1992), é uma estratégia de dois níveis na qual as previsões dos classificadores base (primeiro nível) são utilizadas como atributos de entrada para um meta-classificador (segundo nível). O meta-classificador aprende a ponderar otimamente as contribuições de cada classificador base, potencialmente capturando interações e complementaridades entre eles (WOLPERT, 1992).

Para evitar o vazamento de informação entre os classificadores base e o meta-classificador, as previsões de primeiro nível devem ser obtidas por validação cruzada, técnica conhecida como *out-of-fold prediction* (TING; WITTEN, 1999). Nessa técnica, os dados de treinamento são particionados em k *folds* estratificados e, para cada *fold*, os classificadores base são treinados exclusivamente sobre os $k - 1$ *folds* restantes e aplicados ao *fold* retido, produzindo as previsões que compõem as *meta-features*. Dessa forma, cada amostra do conjunto de treinamento recebe *meta-features* geradas apenas por classificadores que não a observaram durante o treinamento.

Duas variações relevantes do *Stacking* afetam o desempenho final. A primeira é a inclusão dos atributos originais no espaço de entrada do meta-classificador, técnica denominada *passthrough* (TING; WITTEN, 1999), que permite ao meta-classificador combinar informações dos classificadores base com os atributos brutos, potencialmente recuperando padrões não capturados pelos classificadores base. A segunda é a escolha do meta-classificador, que pode ser linear (por exemplo, Regressão Logística) ou não-linear (por exemplo, *HistGradientBoosting*), constituindo um compromisso entre interpretabilidade do modelo final e capacidade de capturar interações complexas entre as *meta-features*.

Os *ensembles* podem ser classificados como homogêneos, quando compostos por classificadores do mesmo tipo (como no *Bagging* e no *Boosting*), ou heterogêneos, quando combinam classificadores de famílias distintas. Os *ensembles* heterogêneos exploram a diversidade de indução dos diferentes algoritmos, o que tende a produzir previsões complementares (KUNCHEVA, 2004).

2.4 Pré-processamento de Dados

2.4.1 Pré-processamento de Atributos Numéricos

O escalonamento dos atributos numéricos é uma etapa relevante para algoritmos de aprendizado de máquina sensíveis à escala dos dados, como Regressão Logística, Máquinas de Vetores de Suporte e Redes Neurais, que utilizam medidas baseadas em distância ou otimização por gradiente (PEDREGOSA et al., 2011; HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Algoritmos baseados em particionamento por árvores de decisão, como Florestas Aleatórias e variantes de *Gradient Boosting*, são invariantes à escala e dispensam essa etapa (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). As principais técnicas adotadas neste trabalho são descritas a seguir, com indicação das classes correspondentes da biblioteca *scikit-learn* (PEDREGOSA et al., 2011) utilizadas na implementação dos experimentos.

- **Padronização Z-score** (*StandardScaler*): padroniza cada atributo subtraindo sua média μ e dividindo pelo desvio padrão σ , resultando em distribuição com média zero e variância unitária:

$$x' = \frac{x - \mu}{\sigma} \quad (2.5)$$

onde μ e σ são estimados sobre os dados de treinamento. É adequada quando a distribuição dos atributos é aproximadamente gaussiana (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

- **Normalização Min-Max** (*MinMaxScaler*): aplica transformação linear que mapeia cada atributo para o intervalo $[0, 1]$:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (2.6)$$

onde $x_{\min}$ e $x_{\max}$ são, respectivamente, o valor mínimo e máximo do atributo no conjunto de treinamento. Preserva relações lineares e a forma da distribuição original, mas é sensível à presença de *outliers* (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

- **Transformação por quantis** (*QuantileTransformer*, QT): mapeia os atributos para uma distribuição-alvo (uniforme ou normal) por meio da função de distribuição cumulativa empírica estimada sobre os dados de treinamento. É robusta a *outliers*

e adequada quando a distribuição original é fortemente assimétrica (PEDREGOSA et al., 2011).

- **Transformação de potência** (*PowerTransformer*, PT): aplica transformações paramétricas de potência, como Yeo-Johnson, com o objetivo de aproximar os dados de uma distribuição gaussiana, estabilizando a variância e reduzindo a assimetria. Os parâmetros são estimados sobre os dados de treinamento (PEDREGOSA et al., 2011).

A escolha da técnica depende das características do conjunto de dados e do algoritmo empregado, sendo as transformações mais robustas (QT e PT) particularmente úteis em distribuições assimétricas ou com *outliers*. Em todos os casos, as transformações são ajustadas exclusivamente sobre os dados de treinamento de cada partição da validação cruzada e posteriormente reaplicadas aos dados de validação e teste com os parâmetros estimados, evitando o vazamento de informação entre os conjuntos (PEDREGOSA et al., 2011).

2.4.2 O Problema do Desbalanceamento de Classes

O desbalanceamento de classes ocorre quando a distribuição das instâncias entre as classes do problema de classificação é significativamente desigual, com uma ou mais classes contendo substancialmente mais exemplos que as demais (HE; GARCIA, 2009). Esse fenômeno é frequente em problemas de saúde, onde a prevalência de condições clínicas como doenças crônicas resulta em distribuições assimétricas entre as classes diagnósticas (HICKS et al., 2022).

A maioria dos algoritmos de classificação é projetada para minimizar a taxa de erro global, o que, em cenários desbalanceados, favorece a classe majoritária em detrimento das classes minoritárias (HE; GARCIA, 2009). Como resultado, o modelo pode apresentar acurácia global elevada, porém com baixa capacidade de identificação das classes de maior interesse clínico. Para mitigar esse problema, três abordagens principais são empregadas: reamostragem dos dados, ajuste do custo das classes e utilização de métricas de avaliação adequadas (HE; GARCIA, 2009).

2.4.3 Técnicas de Reamostragem

As técnicas de reamostragem modificam a distribuição das classes no conjunto de treinamento, buscando reduzir ou eliminar o desbalanceamento antes do ajuste do modelo. Essas técnicas podem ser categorizadas em sobreamostragem (*oversampling*), subamostragem (*undersampling*) e abordagens híbridas (HE; GARCIA, 2009).

2.4.3.1 Sobreamostragem

O SMOTE (*Synthetic Minority Over-sampling Technique*), proposto por Chawla et al. (2002), é a técnica de sobreamostragem mais utilizada na literatura. O SMOTE gera instâncias sintéticas da classe minoritária por interpolação linear entre uma instância minoritária e um de seus k vizinhos mais próximos no espaço de atributos. Para cada instância minoritária selecionada, uma nova instância sintética é criada na posição:

$$\mathbf{x}_{\text{novo}} = \mathbf{x}_i + \lambda \cdot (\mathbf{x}_{nn} - \mathbf{x}_i) \quad (2.7)$$

onde $\mathbf{x}_i$ é a instância original, $\mathbf{x}_{nn}$ é um de seus k vizinhos mais próximos da mesma classe e $\lambda \in [0, 1]$ é um valor aleatório (CHAWLA et al., 2002). Ao gerar instâncias por interpolação em vez de simples duplicação, o SMOTE amplia a região de decisão da classe minoritária de forma mais generalizada, reduzindo o risco de sobreajuste em comparação com a duplicação direta (CHAWLA et al., 2002).

O *RandomOverSampler* (ROS) é a técnica mais simples de sobreamostragem, consistindo na duplicação aleatória de instâncias da classe minoritária até atingir a proporção desejada (BATISTA; PRATI; MONARD, 2004). Embora seja computacionalmente eficiente, o ROS é suscetível ao sobreajuste, uma vez que o modelo pode memorizar as instâncias duplicadas (BATISTA; PRATI; MONARD, 2004).

2.4.3.2 Subamostragem

O *RandomUnderSampler* (RUS) realiza a remoção aleatória de instâncias da classe majoritária, reduzindo o conjunto de treinamento até atingir a proporção desejada entre classes (HE; GARCIA, 2009). A principal limitação do RUS é a potencial perda de informações relevantes da classe majoritária, o que pode degradar o desempenho do modelo (BATISTA; PRATI; MONARD, 2004).

O *TomekLinks* é uma técnica de limpeza de fronteira que identifica e remove pares

de instâncias de classes distintas que são mutuamente os vizinhos mais próximos um do outro (TOMEK, 1976; HE; GARCIA, 2009). A remoção desses pares elimina instâncias ambíguas ou ruidosas na região de fronteira de decisão, refinando a separação entre classes. O *TomekLinks* pode ser aplicado isoladamente ou em combinação com técnicas de sobreamostragem (HE; GARCIA, 2009).

2.4.3.3 Abordagens Híbridas

As abordagens híbridas combinam sobreamostragem e subamostragem em sequência, buscando aproveitar os benefícios de ambas (BATISTA; PRATI; MONARD, 2004). O SMOTEENN combina a geração de instâncias sintéticas pelo SMOTE com a limpeza subsequente pelo *Edited Nearest Neighbours* (ENN), que remove instâncias cuja classe difere da classe majoritária entre seus vizinhos mais próximos. Essa etapa de limpeza elimina instâncias sintéticas que possam ter sido geradas em regiões de sobreposição entre classes (BATISTA; PRATI; MONARD, 2004).

O SMOTETomek combina o SMOTE com a remoção de *TomekLinks*, eliminando pares de instâncias de classes opostas que se encontram muito próximas após a sobreamostragem. Essa combinação visa simultaneamente ampliar a representação da classe minoritária e refinar a fronteira de decisão (BATISTA; PRATI; MONARD, 2004).

2.4.4 Aprendizado sensível ao custo

Uma abordagem alternativa à reamostragem de dados é a modificação da função de custo do classificador por meio da ponderação das classes (*class_weight*). Nessa estratégia, as instâncias da classe minoritária recebem pesos maiores na função de custo, penalizando mais fortemente os erros de classificação nessa classe (HE; GARCIA, 2009). A vantagem dessa abordagem é que não modifica o conjunto de treinamento, evitando os riscos associados à geração de instâncias sintéticas. Diversos algoritmos, como a Regressão Logística, o SVM e as variantes de *Gradient Boosting*, suportam a parametrização de *class_weight* em suas implementações (PEDREGOSA et al., 2011).

2.4.5 Cuidados Metodológicos

A aplicação de técnicas de reamostragem para tratamento de desbalanceamento de dados exige atenção a um princípio fundamental: a reamostragem deve ser realizada exclusivamente sobre os dados de treinamento de cada partição da validação cruzada, após a separação dos dados de validação (LEMAÎTRE; NOGUEIRA; ARIDAS, 2017). A aplicação de reamostragem antes da partição dos dados resulta em vazamento de informação (*data leakage*), uma vez que instâncias sintéticas geradas a partir de dados que posteriormente serão utilizados como validação contaminam a estimativa de desempenho (LEMAÎTRE; NOGUEIRA; ARIDAS, 2017). Assim, é importante o uso de ferramentas que encapsulem as etapas de pré-processamento, reamostragem e classificação em uma sequência integrada, garantindo que a reamostragem seja aplicada corretamente apenas aos dados de treinamento em cada *fold* da validação cruzada.

2.5 Avaliação de Modelos Preditivos

Esta seção descreve os principais conceitos relacionados a avaliação de modelos, incluindo métricas de desempenho e estratégias de divisão de dados para fins de estimar a capacidade de generalização dos modelos.

2.5.1 Métricas de Desempenho

A avaliação do desempenho de modelos de classificação requer a utilização de métricas que reflitam adequadamente a capacidade preditiva do modelo em relação ao problema em questão. A escolha da métrica é particularmente importante em problemas com desbalanceamento de classes, onde métricas baseadas exclusivamente na taxa de acerto global podem mascarar o desempenho insatisfatório nas classes minoritárias (HICKS et al., 2022).

2.5.1.1 Matriz de Confusão

A matriz de confusão é a estrutura fundamental para a avaliação de classificadores, organizando as predições do modelo em relação aos rótulos verdadeiros (SOKOLOVA; LAPALME, 2009). Para um problema binário, a matriz é composta por quatro elementos:

- **Verdadeiros Positivos (VP)**: instâncias da classe positiva corretamente classificadas como positivas.
- **Verdadeiros Negativos (VN)**: instâncias da classe negativa corretamente classificadas como negativas.
- **Falsos Positivos (FP)**: instâncias da classe negativa incorretamente classificadas como positivas (erro do tipo I).
- **Falsos Negativos (FN)**: instâncias da classe positiva incorretamente classificadas como negativas (erro do tipo II).

A partir desses quatro elementos, diversas métricas de desempenho podem ser derivadas, cada uma enfatizando diferentes aspectos do comportamento do classificador (SOKOLOVA; LAPALME, 2009).

2.5.1.2 Acurácia

A acurácia mede a proporção de predições corretas em relação ao total de instâncias:

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN} \quad (2.8)$$

Embora intuitiva, a acurácia apresenta limitação significativa em cenários de desbalanceamento de classes. Um classificador que prediz todas as instâncias como pertencentes à classe majoritária pode atingir acurácia elevada, sem identificar corretamente nenhuma instância da classe minoritária (HICKS et al., 2022). Por essa razão, a acurácia isolada é insuficiente para avaliar o desempenho de classificadores em problemas desbalanceados.

2.5.1.3 Precisão

A precisão (*Precision*) mede a proporção de predições positivas que são de fato corretas:

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (2.9)$$

A precisão quantifica a confiabilidade das predições positivas do modelo. Valores elevados de precisão indicam baixa taxa de falsos positivos, o que é relevante em cenários onde o custo de um alarme falso é significativo (SOKOLOVA; LAPALME, 2009).

2.5.1.4 Recall (Sensibilidade)

O *recall*, também denominado sensibilidade ou taxa de verdadeiros positivos, mede a proporção de instâncias positivas que foram corretamente identificadas pelo modelo:

$$Recall = \frac{VP}{VP + FN} \quad (2.10)$$

O *recall* quantifica a capacidade do modelo de detectar as instâncias da classe de interesse. Em contextos de triagem clínica, o *recall* assume relevância particular, pois a não identificação de um caso positivo (falso negativo) pode implicar em atraso no diagnóstico e tratamento (HICKS et al., 2022).

2.5.1.5 Especificidade

A especificidade (*Specificity*), também denominada taxa de verdadeiros negativos, mede a proporção de instâncias negativas que foram corretamente identificadas pelo modelo:

$$Especificidade = \frac{VN}{VN + FP} \quad (2.11)$$

A especificidade quantifica a capacidade do modelo de evitar a classificação incorreta de instâncias negativas como positivas. Em contextos de triagem populacional, valores reduzidos de especificidade resultam em elevada proporção de falsos positivos, comprometendo a eficiência do encaminhamento clínico em função do volume excessivo de testes confirmatórios desnecessários (VICKERS; CALSTER; STEYERBERG, 2016).

2.5.1.6 F1-Score

O F1-Score é a média harmônica entre precisão e *recall*, atribuindo peso igual a ambas as métricas:

$$F_1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}} \quad (2.12)$$

O F1-Score penaliza desempenho desbalanceado entre precisão e *recall*, assumindo valor elevado apenas quando ambas as métricas são simultaneamente altas. É a métrica mais utilizada como alternativa à acurácia em problemas desbalanceados (CHICCO;

JURMAN, 2020).

2.5.1.7 F - β Score

O F - β Score é uma generalização do F1-Score que permite atribuir pesos diferenciados entre precisão e *recall* por meio do parâmetro β (RIJSBERGEN, 1979; SOKOLOVA; LAPALME, 2009):

$$F_{\beta} = (1 + \beta^2) \cdot \frac{\text{Precisão} \cdot \text{Recall}}{(\beta^2 \cdot \text{Precisão}) + \text{Recall}} \quad (2.13)$$

O parâmetro β controla o peso relativo do *recall* em relação à precisão. Quando $\beta > 1$, o *recall* recebe maior peso; quando $\beta < 1$, a precisão é priorizada. No caso particular de $\beta = 1$, a fórmula reduz-se ao F1-Score (SOKOLOVA; LAPALME, 2009).

O caso $\beta = 2$ (F2-Score) é frequentemente utilizado em problemas de triagem clínica, pois atribui ao *recall* peso quatro vezes superior ao da precisão ($\beta^2 = 4$). Essa configuração reflete cenários nos quais o custo de não identificar um caso positivo (falso negativo) é substancialmente superior ao custo de um alarme falso (falso positivo) (HICKS et al., 2022).

2.5.1.8 AUC-ROC

A curva ROC (*Receiver Operating Characteristic*) representa graficamente a relação entre a taxa de verdadeiros positivos (*recall*) e a taxa de falsos positivos ($\frac{FP}{FP+VN}$) para diferentes limiares de decisão do classificador (SOKOLOVA; LAPALME, 2009). A área sob a curva ROC (AUC-ROC) quantifica a capacidade global de discriminação do modelo, variando de 0,5 (classificador aleatório) a 1,0 (classificador perfeito) (SOKOLOVA; LAPALME, 2009).

A AUC-ROC apresenta a vantagem de ser independente do limiar de decisão, avaliando o desempenho do modelo em todo o espectro de compromisso entre sensibilidade e especificidade. Contudo, em cenários de desbalanceamento severo, a AUC-ROC pode superestimar o desempenho do modelo, uma vez que a taxa de falsos positivos é diluída pelo grande número de instâncias negativas (SAITO; REHMSMEIER, 2015).

2.5.1.9 AUC-PR

A curva *Precisão-Recall* (PR) representa graficamente a relação entre precisão e *recall* para diferentes limiares de decisão. A área sob a curva PR (AUC-PR) quantifica o desempenho do modelo com foco na classe positiva (SAITO; REHMSMEIER, 2015).

A AUC-PR é considerada mais informativa que a AUC-ROC em cenários de desbalanceamento de classes, pois é diretamente influenciada pela proporção de falsos positivos em relação ao número de positivos reais, refletindo de forma mais fidedigna a capacidade do modelo de identificar a classe minoritária (SAITO; REHMSMEIER, 2015). Saito and Rehmsmeier (2015) demonstraram que a curva PR revela diferenças de desempenho entre classificadores que são mascaradas pela curva ROC em datasets altamente desbalanceados.

2.5.1.10 Médias Multiclasse

Para estender as métricas binárias a problemas com $K > 2$ classes, três estratégias de agregação são comumente utilizadas (SOKOLOVA; LAPALME, 2009):

- **Macro-average:** calcula a métrica para cada classe individualmente e computa a média aritmética não ponderada. Atribui peso igual a todas as classes, independentemente de sua frequência no conjunto de dados.
- **Micro-average:** agrega as contribuições de todas as classes (somando VP, FP e FN globalmente) antes de calcular a métrica. Atribui maior peso às classes com mais instâncias.
- **Weighted-average:** calcula a média ponderada pela frequência de cada classe, dando maior peso às classes mais representadas.

A escolha da estratégia de agregação depende do objetivo da avaliação. A macro-average é indicada quando se deseja que todas as classes tenham igual importância na avaliação, independentemente de seu tamanho, sendo particularmente relevante em problemas onde as classes minoritárias são de maior interesse clínico (SOKOLOVA; LAPALME, 2009).

2.5.2 Validação Cruzada

A validação cruzada (*cross-validation*) é uma técnica de reamostragem utilizada para estimar o desempenho de generalização de modelos de aprendizado de máquina, aproveitando de forma mais eficiente os dados disponíveis em comparação com a simples divisão em treino e teste (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

2.5.2.1 *k-Fold Cross-Validation*

Na validação cruzada com k folds (*k-fold CV*), o conjunto de dados é particionado em k subconjuntos de tamanho aproximadamente igual. O modelo é treinado k vezes, utilizando $k - 1$ folds para treinamento e o *fold* restante para avaliação. A estimativa de desempenho é a média das k avaliações (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). A variante estratificada (*Stratified k-Fold*) preserva a proporção de classes em cada *fold*, o que é essencial em problemas com desbalanceamento de classes (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

2.5.2.2 Validação Cruzada Aninhada

A validação cruzada aninhada (*nested cross-validation*) é uma extensão da *k-fold CV* que visa eliminar o viés de seleção introduzido quando a otimização de hiperparâmetros e a avaliação de desempenho utilizam os mesmos dados (VARMA; SIMON, 2006). A estrutura aninhada é composta por dois níveis:

- **Loop externo** (k_1 folds): responsável pela estimativa de desempenho. Cada *fold* externo é reservado como conjunto de validação, enquanto os $k_1 - 1$ folds restantes são utilizados para treinamento e otimização de hiperparâmetros.
- **Loop interno** (k_2 folds): responsável pela otimização de hiperparâmetros. Dentro de cada partição de treinamento do *loop* externo, uma segunda validação cruzada é realizada para selecionar a melhor configuração de hiperparâmetros.

A separação em dois níveis garante que os dados utilizados para avaliar o desempenho do modelo (no *loop* externo) nunca participem do processo de seleção de hiperparâmetros (no *loop* interno), produzindo estimativas de generalização sem viés (VARMA; SIMON, 2006). Cawley and Talbot (2010) demonstraram que a avaliação de desempenho sem validação cruzada aninhada pode resultar em estimativas otimistas, particularmente

quando o espaço de hiperparâmetros é amplo.

2.5.2.3 Otimização de Hiperparâmetros

A otimização de hiperparâmetros é o processo de seleção dos valores que controlam o comportamento do algoritmo de aprendizado, como a taxa de aprendizado, a profundidade máxima de árvores ou o número de neurônios (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). As principais estratégias de busca são:

- **Grid Search:** busca exaustiva sobre todas as combinações de valores pré-definidos. Garante a exploração completa do espaço, porém com custo computacional exponencial no número de hiperparâmetros (PEDREGOSA et al., 2011).
- **Random Search:** avalia combinações aleatórias de hiperparâmetros. Apresenta eficiência superior ao *Grid Search* quando apenas um subconjunto dos hiperparâmetros influencia significativamente o desempenho (RASCHKA, 2018).
- **Halving Random Search:** estratégia de eliminação sucessiva que avalia inicialmente um grande número de configurações com poucos dados e progressivamente descarta as configurações de menor desempenho, aumentando os recursos alocados às configurações restantes (LI et al., 2018). Essa abordagem combina a eficiência da busca aleatória com a alocação adaptativa de recursos, reduzindo significativamente o custo computacional da otimização (JAMIESON; TALWALKAR, 2016).

2.6 Explicabilidade de Modelos

A explicabilidade de modelos de aprendizado de máquina refere-se à capacidade de compreender e interpretar os fatores que influenciam as predições do modelo (LUNDBERG; LEE, 2017). Em aplicações na área da saúde, a explicabilidade é um requisito fundamental, uma vez que profissionais de saúde necessitam compreender as razões subjacentes às predições para confiar e adotar modelos preditivos na prática clínica (LUNDBERG; LEE, 2017). Duas abordagens amplamente utilizadas para explicabilidade são a importância por permutação e a análise de SHAP.

2.6.1 Importância por Permutação

A importância por permutação é uma técnica *model-agnostic* (independente do modelo) que estima a contribuição de cada atributo para o desempenho do classificador (BREIMAN, 2001). O procedimento consiste em permutar aleatoriamente os valores de um atributo específico e medir a degradação resultante no desempenho do modelo. Atributos cuja permutação causa maior queda no desempenho são considerados mais importantes para as predições (BREIMAN, 2001).

A vantagem da importância por permutação reside em sua aplicabilidade a qualquer tipo de modelo, sem necessidade de acesso aos parâmetros internos do classificador. Contudo, a técnica apresenta limitações em cenários com atributos altamente correlacionados, nos quais a permutação de um atributo pode ser parcialmente compensada por atributos correlatos, subestimando a importância real de ambos (STROBL et al., 2008).

2.6.2 SHAP (*SHapley Additive exPlanations*)

O SHAP, proposto por Lundberg and Lee (2017), é um *framework* de explicabilidade baseado na teoria dos jogos cooperativos. O método atribui a cada atributo um valor de Shapley, que quantifica sua contribuição marginal para a predição de uma instância específica (LUNDBERG; LEE, 2017).

Formalmente, o valor de Shapley do atributo j para a predição da instância x é definido como a média ponderada da contribuição marginal de j em todas as possíveis coalizões de atributos:

$$\phi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [f(S \cup \{j\}) - f(S)] \quad (2.14)$$

onde N é o conjunto de todos os atributos, S é um subconjunto de atributos sem j , e $f(S)$ é a predição do modelo utilizando apenas os atributos em S (LUNDBERG; LEE, 2017). Os valores SHAP possuem propriedades teóricas desejáveis, incluindo eficiência (a soma dos valores SHAP iguala a diferença entre a predição do modelo e a predição base), simetria e monotonicidade (LUNDBERG; LEE, 2017).

O SHAP pode ser aplicado em dois níveis de análise (LUNDBERG; LEE, 2017):

- **Explicabilidade local:** os valores SHAP individuais indicam a contribuição de cada

atributo para a predição de uma instância específica. Essa análise é tipicamente visualizada por meio de *waterfall plots* ou *force plots*, que decompõem a predição em contribuições aditivas dos atributos.

- **Explicabilidade global:** a média dos valores absolutos de SHAP ($\frac{1}{n} \sum_{i=1}^n |\phi_j^{(i)}|$) para cada atributo em todo o conjunto de dados fornece um *ranking* de importância global. Essa análise é tipicamente visualizada por meio de *summary plots*, que combinam a importância e a direção do efeito de cada atributo.

O SHAP supera a importância por permutação em dois aspectos: oferece explicações tanto locais quanto globais, e atribui contribuições consistentes mesmo na presença de atributos correlacionados, graças às propriedades axiomáticas dos valores de Shapley (LUNDBERG; LEE, 2017).

3 TRABALHOS RELACIONADOS

Este capítulo apresenta uma revisão dos principais trabalhos relacionados à aplicação de modelos de aprendizado de máquina na predição do diabetes e do status glicêmico. O capítulo inicia com estudos baseados em dados clínico-laboratoriais diversos, seguidos por trabalhos que combinam dados hematológicos com exames laboratoriais complementares e, por fim, estudos que utilizam exclusivamente dados hematológicos. Na sequência, são discutidos trabalhos voltados à classificação multiclasse e estudos específicos para detecção de pré-diabetes. Por fim, apresenta-se uma síntese da revisão da literatura e a justificativa da proposta deste trabalho.

A revisão de literatura foi realizada através da pesquisa por publicações correlatas nas bases de dados *Google Scholar* e *PubMed*. Nas bases consultadas, aplicaram-se as *strings* de busca “Diabetes Machine Learning”, “Diabetes Deep Learning”, “machine learning complete blood count diabetes”, “hematological parameters diabetes prediction” e “pre-diabetes screening machine learning”, abrangendo publicações do período de 2018 a 2025. Foram considerados estudos publicados em periódicos com revisão por pares, com foco na classificação do diabetes ou do status glicêmico por meio de aprendizado de máquina, utilizando dados laboratoriais ou hematológicos. Estudos focados exclusivamente em imagens médicas ou dados genômicos foram excluídos. A partir desse processo, 12 estudos foram selecionados para compor esta seção do presente trabalho.

A aplicação de modelos matemáticos e computacionais na predição do diagnóstico de diabetes apresenta um problema amplamente abordado por pesquisas no meio científico e acadêmico. Pesquisas correlatas anteriormente publicadas apresentam uma diversidade de algoritmos de aprendizado de máquina e bases de dados utilizados na tarefa de predição do diagnóstico do Diabetes Mellitus. A hiperglicemia crônica pode induzir alterações mensuráveis nos glóbulos vermelhos (como volume, concentração de Hemoglobina, distribuição de tamanho), assim como em leucócitos e plaquetas, retrato claro da inflamação e outras disfunções frequentemente associadas ao diabetes (PAPATHEODOROU et al., 2018). Estudos realizados entre 2018 e 2025 investigaram a aplicação de modelos de aprendizado de máquina treinados exclusivamente ou majoritariamente com dados hematológicos. Os desdobramentos científicos apresentados pelas pesquisas correlatas fundamentaram escolhas experimentais para este trabalho.

3.1 Dados clínico-laboratoriais diversos

Alhassan et al. (2021) investigou a predição de elevações em A1c em pacientes adultos, utilizando dados de prontuários eletrônicos. Em uma base de dados contendo 18 mil registros de pacientes árabes sem diagnóstico prévio de diabetes, utilizou-se de dados de histórico clínico, exames laboratoriais anteriores, idade e sexo para criação de um modelo de classificação dos pacientes entre normoglicêmicos ou diabéticos. Dados longitudinais foram incorporados ao dataset, como tendências e médias históricas do paciente. O melhor desempenho foi obtido através de um modelo de Redes Neurais, com AUC-ROC de 0,83 e acurácia de 74,6% na previsão de risco elevado de diabetes. O estudo destaca-se por demonstrar que a inclusão do histórico do paciente melhora substancialmente a capacidade preditiva. Como limitação, aponta-se a dificuldade para acessar registros eletrônicos históricos de pacientes.

Um estudo chinês realizado por Wang et al. (2020) analisou 2787 pacientes com diabetes tipo 2, para prever o nível de A1c. Foram coletados 42 parâmetros por paciente, incluindo dados laboratoriais (perfil lipídico, função hepática e renal), dados demográficos e informações sobre o tratamento dos pacientes. Algoritmos de aprendizado de máquina foram aplicados para classificar os pacientes entre diabéticos e normais. Com o uso de *ElasticNet*, foram selecionados 19 atributos mais relevantes, que foram utilizados em um modelo de Florestas Aleatórias, atingindo 79% de sensibilidade e 70% de acurácia na predição do status glicêmico dos pacientes. Os indicadores mais relevantes na classificação foram a duração do diabetes e a quantia de insulina utilizada pelo paciente, demonstrando que o contexto clínico possui forte influência na classificação.

Cheng et al. (2023) buscou identificar os fatores de risco associados ao descontrole de glicose em pacientes diabéticos do tipo 2. Com uma amostra de dados de 647 pacientes de Taiwan, contendo medidas laboratoriais, dados antropométricos e hábitos de vida, foi desenvolvido um modelo de classificação para definir o controle ou não controle de A1c. Diversos algoritmos foram testados, obtendo o melhor desempenho em um modelo de Florestas Aleatórias, com acurácia de 84%. O IMC, o nível de atividade física e o Colesterol HDL foram os atributos com maior correlação preditiva. Como limitação do trabalho, aponta-se a amostra de dados pequena, o que pode afetar a generalização de um modelo. Contudo, o estudo demonstra o potencial de modelos de aprendizado em um contexto clínico.

Além dos trabalhos com dados laboratoriais específicos, diversas pesquisas ex-

ploraram abordagens de aprendizado de máquina para predição de diabetes utilizando combinações de variáveis clínicas diversas. Al-Hussein et al. (2025) apresentaram um modelo híbrido, combinando Florestas Aleatórias e Regressão Logística para aprimorar a predição de A1c em uma população da Arábia Saudita. Com informações demográficas, do estilo de vida e do perfil lipídico de 3000 pacientes, o modelo identificou apenas 4 variáveis ótimas para uso através de *feature selection* (Idade, IMC, Triglicerídeos e Colesterol HDL). Este modelo híbrido chegou a 93% de acurácia, com AUC-ROC de 0,88, superando modelos compostos por apenas um algoritmo. Tao et al. (2023) estimaram a evolução da glicose de pacientes através de uma base de dados com 2.169 pacientes chineses, buscando apresentar a evolução do diabetes após 3 meses de tratamento. Foram testados 16 modelos, obtendo o melhor desempenho com Florestas Aleatórias otimizado, atingindo AUC-ROC de 0,97, apontando a aplicabilidade também no prognóstico e apoio terapêutico.

3.2 Dados Hematológicos e exames laboratoriais complementares

Um estudo publicado por Mansoori et al. (2023b) utilizou uma base de dados de dados composta pela Glicose em Jejum, triglicerídeos e dados hematológicos de mais de 9 mil indivíduos em uma população entre 35 e 65 anos do norte do Irã, com objetivo de analisar a correlação entre diabetes e os dados hematológicos e realizar a predição do diagnóstico do diabetes. Para definição da variável alvo, foram considerados diabéticos os pacientes com glicose superior a 126 mg/dL e foi aplicado o algoritmo SMOTE para balanceamento entre as classes. Foram aplicados os algoritmos de Regressão Logística, Árvores de Decisão e Florestas Aleatórias, criando dois modelos distintos para cada algoritmo. O Modelo I investiga a correlação entre os parâmetros hematológicos e Diabetes Mellitus e o Modelo II investiga a associação entre Glicose/Triglicerídeos e Diabetes Mellitus. Em ambos os modelos, a base de dados foi dividida entre treino e teste (75% / 25%, respectivamente), utilizando parte do *dataset* de treino para validação.

Os autores aplicaram, ainda, o algoritmo de Regressão Logística para avaliação das correlações entre os atributos, apontando correlação em todos os atributos, exceto o CHCM. As maiores correlações ($P < 0,05$) no Modelo I, para Idade, Leucócitos (WBC) e Índice de Agregação Plaquetária (PDW). As correlações do Modelo II apresentaram, além dos atributos já citados, a Idade e Hemácias (RBC). O algoritmo que apresentou maior poder preditivo foi o de Florestas Aleatórias, sendo reportado 83,33% de acurácia

no Modelo I e 97,43% de acurácia no Modelo II Mansoori et al. (2023b). Como ponto crítico, o protocolo experimental apresenta limitações relevantes: a divisão única dos dados sem validação cruzada, a ausência de comparação entre métricas de treino e teste e a não realização de validação externa impedem o descarte de sobreajuste. Os autores reconhecem como limitação a homogeneidade geográfica e cultural da base de dados, declarando explicitamente a impossibilidade de generalização dos resultados a outras populações. Apesar de não utilizar somente dados hematológicos, o trabalho evidencia que parâmetros hematológicos são úteis para detecção de pacientes diabéticos.

Cardozo (2022) realizou uma pesquisa utilizando dados de mais de 60 mil pacientes brasileiros, utilizando exames laboratoriais de rotina com técnicas de aprendizado de máquina para identificar diabéticos não diagnosticados e otimizar a detecção de resultados falso-negativos para glicose de jejum. A tarefa foi tratada em um modelo de regressão para o valor contínuo de A1c e em um modelo de classificação de status glicêmico dos indivíduos, considerando como alvo o resultado da dosagem de A1c, classificando os indivíduos como saudáveis, pré-diabéticos e diabéticos.

A pesquisa foi conduzida a partir de um *framework* de quatro etapas para desenvolvimento dos modelos e predições. Na primeira etapa, realizou-se a coleta dos dados e, na segunda, o pré-processamento. As etapas três e quatro consistem no treinamento dos modelos e validação e performance, respectivamente. Foi coletada uma base de dados de um laboratório da região sul do Brasil, contendo uma amostra de 62.496 pacientes, composto por 47,60% de indivíduos saudáveis, 37,95% de indivíduos em pré-diabetes e 14,45% de indivíduos com diabetes, com idades entre 19 e 99 anos. O *dataset* foi dividido em três subconjuntos de diferentes rótulos, elaborados com base no atributo-alvo (A1c): HPD (*dataset* composto pelas três subcategorias), HN (indivíduos saudáveis e não saudáveis) e ND (indivíduos diabéticos e não diabéticos).

Para ambas as tarefas, foram testados os algoritmos K-Vizinhos mais próximos, Máquinas de Vetores de Suporte, *Naive Bayes*, Florestas Aleatórias e Redes Neurais Artificiais. O melhor desempenho foi obtido combinando-se um modelo de regressão com um modelo de classificação, ambos baseados em Redes Neurais Artificiais, em que primeiro foi estimado o valor de A1c e em seguida categorizado, apresentando 78,1% de sensibilidade e precisão de 78,7%. A classe Pré-Diabetes apresentou erro próximo a 30% em todos os algoritmos, o que pode apresentar uma tendência nas características do conjunto de dados utilizado.

O modelo de regressão também foi utilizado para calcular um fator de ajuste para

resultados de glicose em jejum, elevando em 16,6% a detecção de indivíduos com diabetes oculto e 35% a detecção de pré-diabetes oculto em pacientes com glicose de jejum normal. Os resultados destacam o potencial de modelos de aprendizado de máquina como ferramenta de triagem para o diabetes, evidenciando que há casos em que o teste de glicose de jejum pode falhar. Como observação importante, o *dataset* utilizado neste estudo é composto por dados hematológicos e outros exames laboratoriais de rotina.

Tahir et al. (2024) realizaram um estudo de análise da inflamação sistêmica e parâmetros hematológicos na predição da glicose. Foram analisados mais de 200 mil registros laboratoriais, contendo resultados de A1c, hemogramas, glicose de jejum e Proteína C reativa (PCR). Os modelos preditivos foram desenvolvidos utilizando Análise Discriminante Linear (LDA) para realizar a classificação de status glicêmico. Dois modelos utilizaram apenas marcadores de inflamação, e outros dois modelos combinaram PCR e dados hematológicos. Os modelos combinados apresentaram melhor desempenho, alcançando 89,5% de acurácia na classificação. A análise identificou fatores preditivos importantes, confirmando que há alterações hematológicas induzidas pela hiperglicemia crônica e pela inflamação. Este trabalho destaca-se pela larga base de dados utilizada e pelo desempenho robusto obtido. Como limitação, o uso de dados retrospectivos podem apresentar viés de amostragem, além do modelo (LDA) ter tendência na predição de relações lineares, o que pode impactar na captura de padrões complexos.

3.3 Dados Hematológicos

Li et al. (2024) desenvolveram um modelo para diagnosticar diabetes utilizando exclusivamente dados de hemograma (*blood routine data*). A partir de uma base de dados composta por 1.000 pacientes saudáveis e 1.000 pacientes diabéticos, foram testados os algoritmos *XGBoost*, Florestas Aleatórias, Máquinas de Vetores de Suporte, *Elastic Net* e Regressão Logística. O modelo *XGBoost* apresentou o melhor desempenho, com AUC-ROC de 0,9990 no conjunto de treino e 0,9851 no conjunto de teste. Na validação externa, o modelo apresentou 81,54% de acurácia, evidenciando uma degradação de desempenho quando aplicado a dados de outra origem. A análise de explicabilidade via SHAP identificou a CHCM, o percentual de linfócitos (LY%), o *Red Cell Distribution Width* (RDW-SD) e a HCM como os parâmetros hematológicos mais relevantes para a classificação. Este estudo é particularmente relevante por demonstrar que dados exclusivamente hematológicos possuem capacidade preditiva para o diabetes, embora a diferença

entre o desempenho interno e a validação externa sugira limitações de generalização.

3.4 Classificação Multiclasse e Estratégias de *Ensemble*

A maioria dos trabalhos revisados nas seções anteriores adota uma formulação binária (diabético vs. não diabético). Contudo, a classificação multiclasse do status glicêmico em três classes (saudável, pré-diabético e diabético) apresenta desafios adicionais, como a sobreposição entre classes adjacentes e o desbalanceamento de dados.

Sahid, Babar and Uddin (2024) investigaram a classificação multiclasse do diabetes em três classes (saudável, pré-diabético e diabético) utilizando dados clínicos e laboratoriais de 826 pacientes iraquianos. Os autores aplicaram técnicas de seleção de atributos por filtragem, *wrapper* e métodos embarcados, avaliando os algoritmos SVM, KNN e Regressão Logística com validação cruzada de 10 *folds*. O melhor desempenho foi obtido com SVM utilizando apenas 4 atributos selecionados, atingindo 96,4% de acurácia, 96,8% de precisão e F1-Score de 0,962. Apesar dos resultados expressivos, a base de dados é relativamente pequena e composta por atributos clínicos e bioquímicos (IMC, A1c, HDL, LDL, creatinina), não utilizando dados exclusivamente hematológicos.

Abnoosian, Farnoosh and Behzadi (2023) propuseram um *ensemble* ponderado de múltiplos classificadores para a predição de diabetes em três classes (diabético, pré-diabético e não diabético), utilizando dados clínico-laboratoriais do *Iraqi Patient Dataset of Diabetes*. Os autores avaliaram os algoritmos KNN, SVM, Árvores de Decisão, Florestas Aleatórias, *AdaBoost* e *Naive Bayes*, combinando-os em um modelo de *ensemble* cujos pesos foram definidos com base no AUC-ROC individual de cada classificador. O modelo combinado atingiu 98,87% de acurácia, 98,61% de precisão e AUC-ROC de 0,999. A abordagem demonstra que a combinação ponderada de classificadores pode superar modelos individuais na tarefa multiclasse, embora os dados utilizados sejam clínico-laboratoriais e não hematológicos.

Estes estudos evidenciam que a classificação multiclasse do diabetes é viável com técnicas de seleção de atributos e combinação de classificadores. Apesar disso, nenhum dos trabalhos identificados utilizou estratégias de decomposição binária (como *One-vs-Rest* ou *One-vs-One*) nem *ensembles* compostos por classificadores especializados em subproblemas distintos, abordagens exploradas na presente dissertação.

3.5 Detecção de Pré-Diabetes com Aprendizado de Máquina

A detecção de indivíduos em estado pré-diabético representa um desafio específico para modelos de aprendizado de máquina, uma vez que as alterações biológicas nesta faixa são mais discretas do que as observadas em pacientes com diabetes estabelecido.

Li et al. (2025) desenvolveram um modelo interpretável para predição do risco de pré-diabetes utilizando dados do *China Health and Nutrition Survey* (CHNS), abrangendo 8.277 indivíduos. Através de seleção de atributos por LASSO, foram identificados 9 preditores relevantes: idade, triglicerídeos, colesterol total, IMC, apolipoproteína B, proteína total, WBC, HDL-C e hipertensão. O modelo *XGBoost* apresentou o melhor desempenho, com AUC-ROC de 0,939. A análise SHAP identificou idade, IMC e triglicerídeos como os fatores de maior contribuição. Embora apenas a contagem de leucócitos constitua um parâmetro hematológico entre os 9 selecionados, o estudo demonstra que a detecção de pré-diabetes é viável com dados clínicos acessíveis e reforça a importância de métodos interpretáveis para aplicação em triagem populacional.

É notável que os trabalhos voltados à detecção de pré-diabetes utilizam predominantemente variáveis bioquímicas e clínicas, como glicose de jejum, perfil lipídico e IMC. Durante a revisão da literatura relacionada, não foram identificados estudos que investiguem a detecção de pré-diabetes a partir de dados exclusivamente hematológicos, o que constitui uma lacuna relevante na literatura e uma das contribuições desta dissertação.

3.6 Síntese Crítica da Revisão da Literatura e Justificativa da Proposta

Este capítulo evidencia o crescente interesse na aplicação de modelos de aprendizado de máquina para a predição do diabetes e do status glicêmico. Os estudos revisados abrangem bases de dados de diferentes países e populações, com amostras variando de 647 a mais de 200 mil registros, e empregam algoritmos como Florestas Aleatórias, Redes Neurais Artificiais, *XGBoost* e *Support Vector Machine*, obtendo desempenhos tipicamente na faixa de 80% a 90% de acurácia, métrica em comum entre os trabalhos analisados.

A Tabela 3.1 apresenta uma comparação dos estudos revisados. A análise crítica da literatura permite identificar quatro lacunas principais:

- **Uso exclusivo de dados hematológicos:** A maioria dos trabalhos utiliza combina-

Tabela 3.1 – Resumo de estudos com uso de aprendizado de máquina para predição de diabetes e métricas associadas

Autor	Tipo de Dado	Tarefa	Atributos (Resumo)	Amostra	Melhor Resultado
(ALHASSAN et al., 2021)	Clínicos + Lab.	Binária (A1c elevada)	Idade, IMC, TFG, Glicose, Colesterol, NHDL	18844	MLP: AUC = 0.83, Acc. = 74.6%
(WANG et al., 2020)	Clínicos + Lab.	Classif. (A1c)	42 params → 19 (ElasticNet)	2787	RF: Sens. = 79%, Acc. = 70%
(CHENG et al., 2023)	Clín. + Antrop.	Binária (A1c)	IMC, Atividade física, HDL, Tabagismo	647	RF: Acc. = 84%
(AL-HUSSEIN et al., 2025)	Clín. + Lipídico	Binária (A1c)	Idade, IMC, Triglicerídeos, HDL (4 features)	3000	RF+LR híbrido: Acc. = 93%, AUC = 0.88
(TAO et al., 2023)	Clínicos + Lab.	Classif. (evolução A1c)	Idade, IMC, Glicose, A1c, Creatinina, WBC, PLT, HGB	2169	Ensemble Learning: AUC = 0.97
(MANSOORI et al., 2023b)	Hemat. + Clínicos	Binária (D/ND)	Idade, HGB, HCT, PLT, WBC, RDW, MPV, RBC, VCM, CHCM, TyG	9000	Bootstrap Forest: Acc. = 83.3% / 97.4%
(CARDOZO, 2022)	Hemat. + Lab.	Multiclasse (3 classes) + Regressão	CHCM, HCM, HT, WBC, LIN, MON, PLT, RDW, NEU, VCM, Creatinina, Glicose	62496	ANN: Sens. = 78.1%, Prec. = 78.7%
(TAHIR et al., 2024)	Hemat. + Inflam.	Classif. (status glic.)	CHCM, HCM, VCM, HB, HT, RBC, WBC, PLR, NLR, PCR	208137	LDA: AUC = 0.87, Acc. = 89.5%
(LI et al., 2024)	Hematológicos	Binária (D/ND)	CHCM, LY%, RDW-SD, HCM (hemograma)	6477	XGBoost: AUC = 0.985, Acc. ext. = 81.5%
(SAHID; BABAR; UDDIN, 2024)	Clín. + Bioq.	Multiclasse (3 classes)	IMC, A1c, HDL, LDL, Creatinina (14 → 4)	826	SVM: Acc. = 96.4%, F1 = 0.962
(ABNOOSIAN; FARNOOSH; BEHZADI, 2023)	Clín. + Bioq.	Multiclasse (3 classes)	Dados clínico-laboratoriais (ensemble ponderado)	–	Ensemble: Acc. = 98.9%, AUC = 0.999
(LI et al., 2025)	Clín. + Bioq.	Binária (pré-diabetes)	Idade, TG, CT, IMC, ApoB, TP, WBC, HDL, Hipertensão	8277	XGBoost: AUC = 0.939
Este trabalho	Hematológicos	Multiclasse (3) + Binária + Ensemble	23 parâmetros hematológicos (hemograma + Idade + Sexo)	169999	MLP: F2 = 0.793 (T1); F2 = 0.551 (T2)

ções de dados clínicos, bioquímicos, demográficos e laboratoriais diversos. Apenas o estudo de Li et al. (2024) empregou exclusivamente dados de hemograma (23 parâmetros hematológicos, sem inclusão de idade, glicose ou demais variáveis) para a predição do diabetes, em uma base de 6.477 amostras. Não foram identificados estudos com bases de dados de larga escala (acima de 100 mil registros) utilizando exclusivamente parâmetros hematológicos.

- **Predominância de classificação binária:** A grande maioria dos estudos revisados apresenta o problema como classificação binária (diabético x não diabético). Os trabalhos que abordam classificação multiclasse em três classes (SAHID; BABAR; UDDIN, 2024; ABNOOSIAN; FARNOOSH; BEHZADI, 2023; CARDOZO, 2022) utilizam dados clínico-laboratoriais diversos, e nenhum deles emprega estratégias de decomposição binária (*One-vs-Rest*, *One-vs-One*) ou *ensembles* heterogêneos compostos por classificadores especializados em subproblemas distintos.
- **Deteção de pré-diabetes como classe independente:** A detecção de pré-diabetes é pouco explorada como tarefa específica. Os trabalhos revisados que abordam pré-

diabetes (LI et al., 2025; CARDOZO, 2022) utilizam predominantemente variáveis bioquímicas. Não foram identificados estudos que investiguem a discriminação de indivíduos pré-diabéticos a partir de dados exclusivamente hematológicos.

- **Generalização e explicabilidade:** Os modelos apresentados foram treinados e validados em dados de uma única fonte (hospital, região ou país), característica compartilhada pela presente dissertação, que utiliza dados de um laboratório da região sul do Brasil. Essa limitação é inerente à maioria dos estudos na área, tornando desconhecido o fator de degradação de desempenho quando os modelos são aplicados a outras populações, e reforçando a necessidade de validação externa multicêntrica como etapa futura. Embora alguns trabalhos tenham sua explicabilidade apresentados por técnicas como SHAP e LIME, estas explicações nem sempre são intuitivas. Para aplicação na área da saúde, é essencial garantir tanto a robustez dos modelos quanto a interpretabilidade dos fatores relevantes para cada predição.

Embasado nessa literatura, espera-se que esta pesquisa de dissertação de mestrado possa contribuir originalidade ao validar uma metodologia de aprendizado de máquina utilizando apenas dados hematológicos, a partir de uma base de dados brasileira de larga escala (169.999 registros). Especificamente, esta dissertação endereça as lacunas identificadas ao:

- empregar exclusivamente parâmetros hematológicos como atributos preditivos, avaliando a capacidade discriminativa do hemograma para classificação do status glicêmico;
- investigar cinco estratégias de classificação distintas, incluindo classificação binária, multiclasse direta, decomposição binária e *ensemble* heterogêneo;
- avaliar a detecção de pré-diabetes como tarefa específica, incluindo uma decomposição Pré-diabético x Não Pré-diabético;
- aplicar técnicas de explicabilidade (SHAP e importância por permutação) e análise de erros do modelo por subgrupos demográficos.

4 MATERIAIS E MÉTODOS

Este capítulo descreve os materiais e métodos utilizados no desenvolvimento e avaliação de modelos de aprendizado de máquina para a classificação do status glicêmico a partir de dados hematológicos. O capítulo inicia apresentando a base de dados utilizada, incluindo sua origem, os aspectos éticos envolvidos e o *pipeline* de limpeza e filtragem aplicado aos registros laboratoriais brutos. Na sequência, são descritas as técnicas de pré-processamento, escalonamento de atributos e estratégias de balanceamento de classes utilizadas. O dos experimentos é então detalhado, apresentando a divisão dos dados, a validação cruzada aninhada (*nested cross-validation*) e as métricas de avaliação. Além disso, são apresentadas as estratégias de classificação desenvolvidas, organizadas em quatro tarefas experimentais: classificação binária, classificação multiclasse direta, decomposição em subproblemas binários e *ensemble* heterogêneo. Por fim, é descrito o ambiente computacional utilizado para a execução dos experimentos.

4.1 Base de Dados

O presente estudo caracteriza-se como observacional, retrospectivo e analítico, utilizando dados secundários e totalmente anonimizados, sendo não intervencionista, sem contato com participantes e sem qualquer implicação na conduta clínica.

A qualidade e confiabilidade do conjunto de dados são pontos críticos para o desenvolvimento de modelos de aprendizado de máquina robustos (DINH et al., 2019). O uso de dados reais fornece subsídios relevantes para compreender o perfil laboratorial dos indivíduos e para a associação com o risco do desenvolvimento da doença (GREGG; SATTAR; ALI, 2020). Esta seção descreve o processo de coleta e pré-processamento dos dados utilizados neste trabalho.

4.1.1 Origem e Coleta dos Dados

O conjunto de dados utilizado nesta pesquisa foi obtido em parceria com um laboratório de análises clínicas privado do Rio Grande do Sul, que atua há mais de 50 anos prestando atendimento à população de 10 municípios e 9 hospitais da região. Os registros utilizados correspondem a exames realizados no período de 2017 a 2024, abrangendo

aproximadamente sete anos de coleta laboratorial. A amostra contempla registros provenientes de duas modalidades de atendimento: pacientes ambulatoriais, responsáveis pela maioria dos exames coletados (aproximadamente 80% do total), e pacientes hospitalizados, que correspondem a até 20% dos registros restantes. Essa composição heterogênea aproxima o perfil da base aos cenários reais de aplicação clínica, em que a triagem por hemograma é realizada tanto em rotinas ambulatoriais quanto em contextos hospitalares.

A base de dados bruta extraída do sistema de informações laboratoriais é composta por 1.190.541 registros laboratoriais totalmente anonimizados, contendo resultados de hemograma completo e dosagem de A1c.

4.1.2 Critérios de Inclusão, Exclusão e Limpeza

A Figura 4.1 ilustra o *pipeline* de limpeza e redução da base de dados, com as quantidades de registros em cada etapa.

A base original continha 1.190.541 registros laboratoriais correspondentes a resultados de hemograma completo e dosagem de A1c. Inicialmente, foram removidas todas as instâncias em que pelo menos um desses exames estava ausente, o que ocorre quando hemograma e A1c não são realizados na mesma coleta, reduzindo o número de registros para 230.573. Em seguida, foram excluídas instâncias que apresentavam campos vazios em algum dos parâmetros hematológicos, geralmente decorrentes de falhas de leitura automática ou impossibilidade de dosagem, resultando em 170.021 registros.

Na sequência, foram removidas 10 colunas desnecessárias para a modelagem (identificadores internos, datas de exame e parâmetros do perfil lipídico), e os tipos de dados foram convertidos para *float32* e inteiro, reduzindo o consumo de memória e padronizando a representação numérica.

Adicionalmente, foram removidas 22 instâncias contendo valores extremos considerados fisiologicamente implausíveis. Os limites de corte foram definidos com base na análise exploratória das distribuições individuais de cada parâmetro hematológico, utilizando diagramas de caixa (*boxplots*) para identificar valores discrepantes que poderiam comprometer a modelagem. Os limites de corte aplicados a cada parâmetro são apresentados na Tabela 4.1, na Seção 4.1.3. Após o pré-processamento, o conjunto final passou a conter 169.999 instâncias, correspondentes a 88.580 indivíduos únicos.


4.1.3 Atributos Preditivos e Variável-Alvo

A base final inclui 23 atributos preditivos. Além das variáveis demográficas idade e sexo, foram considerados 21 parâmetros do hemograma completo, organizados em três grupos: série branca, série vermelha e série plaquetária. A Tabela 4.1 apresenta os 23 atributos preditivos utilizados, organizados por série hematológica, com suas respectivas unidades de medida e os limites de corte aplicados na remoção de *outliers*. É importante destacar que parâmetros de ocorrência rara no hemograma (Mielócitos, Metamielócitos, Plasmócitos, Blastos e Promielócitos) foram mantidos na base de dados sem tratamento especial, por constituírem componentes naturais do hemograma completo e estarem presentes nos registros extraídos do sistema laboratorial.

A variável-alvo do problema preditivo é a A1c, expressa em percentual, que sintetiza a média glicêmica do indivíduo nos últimos três meses (EYTH; NAIK, 2024). Valores de A1c são clinicamente utilizados tanto para diagnóstico, quanto para mensurar o risco de desenvolvimento do diabetes, considerando os indivíduos como normais ($A1c < 5,7\%$), pré-diabéticos ($5,7\% \leq A1c < 6,5\%$) ou diabéticos ($A1c \geq 6,5\%$), conforme os critérios da Organização Mundial da Saúde (World Health Organization, 2021).

Cabe destacar que, neste trabalho, o rótulo de cada registro (Normal, Pré-diabetes ou Diabetes) foi atribuído exclusivamente a partir do valor numérico de A1c observado

Figura 4.1 – *Pipeline* de limpeza e redução da base de dados, com quantidades de registros em cada etapa.



Elaborado pelo autor.

Tabela 4.1 – Atributos preditivos da base de dados, unidades de medida e limites de corte para remoção de *outliers*. Células vazias nas colunas de operador e limite indicam que o atributo não recebeu filtragem.

Série	Atributo	Unidade	Op.	Limite
Branca	Leucócitos	/ μ L	$\leq$	200.000
	Mielócitos	/ μ L	$\leq$	2.000
	Metamielócitos	/ μ L	$\leq$	4.000
	Bastões	/ μ L		
	Segmentados	/ μ L	$\leq$	50.000
	Eosinófilos	/ μ L	$\leq$	25.000
	Basófilos	/ μ L	$\leq$	400
	Linfócitos	/ μ L	$\leq$	100.000
	Linfócitos Atípicos	/ μ L	$\leq$	1.700
	Monócitos	/ μ L	$\leq$	10.000
	Plasmócitos	/ μ L	$\leq$	1.000
	Blastos	/ μ L	$\leq$	50.000
	Promielócitos	/ μ L		
Vermelha	Eritrócitos	$\times 10^6$ / μ L	$\leq$	8,8
	Hemoglobina	g/dL	$\geq$	3,0
	Hematócrito	%		
	HCM	pg	$\leq$	140
	CHCM	g/dL	$\leq$	38
	RDW	%		
Plaquetária	Plaquetas	$\times 10^3$ / μ L	$\leq$	1.300
	VPM	fL	$\geq$	3,0
Demográfica	Idade	anos		
	Sexo	categórico (M/F)		
Total		23 atributos (17 com filtragem)		

Elaborado pelo autor.

na coleta correspondente, aplicando-se de forma direta os pontos de corte descritos no parágrafo anterior. Não foram utilizadas informações clínicas adicionais, como diagnóstico médico prévio, glicose em jejum, teste oral de tolerância à glicose ou histórico de tratamento, em função de tais informações não integrarem a base extraída do sistema de informações laboratoriais.

Quatro aspectos complementares merecem registro acerca dessa rotulagem. Primeiramente, cada registro corresponde a uma única medição de A1c, realizada na mesma coleta do hemograma, não representando um diagnóstico clínico confirmado, o qual, conforme as diretrizes da *American Diabetes Association* (American Diabetes Association, 2026a), exige a repetição do exame em dia distinto ou a confirmação por método laboratorial complementar. Em segundo lugar, embora a definição operacional adote os critérios da Organização Mundial da Saúde (World Health Organization, 2021), os pontos de corte de 5,7% e 6,5% são equivalentes aos preconizados pela *American Diabetes Association* (American Diabetes Association, 2026a). Em terceiro lugar, as dosagens de A1c foram

realizadas em equipamento BioRad Variant II por cromatografia líquida de alta eficiência (*High-Performance Liquid Chromatography*, HPLC), com resultados expressos em percentual, sendo a HPLC método analítico amplamente reconhecido como referência para a dosagem de A1c, apresentando baixos coeficientes de variação analítica, e, em função da centralização das dosagens em uma única instalação laboratorial, a variabilidade interlaboratorial é eliminada, tornando pouco expressivas as flutuações pré-analíticas e analíticas como fonte de ruído na rotulagem. Por fim, registros de indivíduos com condições reconhecidamente associadas a interferências na dosagem de A1c, como hemoglobinopatias, anemia ferropriva e doença renal crônica (EYTH; NAIK, 2024), não foram excluídos da base de dados, em função de a extração do sistema laboratorial não contemplar informação clínica complementar que possibilitasse essa identificação. Essas considerações são retomadas na discussão de limitações apresentada no Capítulo 6.


Cabe registrar ainda uma convenção terminológica adotada ao longo desta dissertação. Os rótulos operacionais *Normal* (N), *Pré-diabetes* (PD) e *Diabetes* (D), bem como as formas adjetivadas “normoglicêmico”, “pré-diabético” e “diabético”, são utilizados como referências sintéticas a indivíduos cujos valores de A1c se enquadram nas faixas operacionais descritas no parágrafo anterior, não constituindo categorizações da identidade clínica dos pacientes. Expressões equivalentes em linguagem centrada na pessoa (*person-first language*), como “indivíduos com diabetes”, “indivíduos com pré-diabetes” e “indivíduos normoglicêmicos”, são empregadas de forma intercambiável ao longo do texto sempre que a redação favorece sua adoção, em concordância com as recomendações de comunicação em saúde da *American Diabetes Association* (American Diabetes Association, 2026a).

A distribuição entre classes resultante apresenta desbalanceamento moderado: Normal (N) = 85.170 registros (50,1%), Pré-diabetes (PD) = 49.157 registros (28,9%) e Diabetes (D) = 35.672 registros (21,0%). A Figura 4.2 ilustra a distribuição de registros entre as três classes da variável-alvo.

4.1.4 Aspectos Éticos e Legais

Esta pesquisa foi conduzida em conformidade com os princípios éticos que regem a atividade científica, assegurando a confidencialidade dos dados e a privacidade dos participantes, conforme as Resoluções CNS nº 466/2012 (Brasil. Conselho Nacional de Saúde, 2012) e CNS nº 510/2016 (Brasil. Conselho Nacional de Saúde, 2016), e com a

Figura 4.2 – Distribuição de classes na base de dados final, conforme critérios de classificação por A1c.



Elaborado pelo autor.


Lei Geral de Proteção de Dados (Lei nº 13.709/2018) (Brasil, 2018) e demais normativas aplicáveis. O estudo foi aprovado pelo comitê de ética da Universidade Federal do Rio Grande do Sul, com número CAAE (Certificado de Apresentação para Apreciação Ética) 92847125.8.0000.5347.

A base de dados utilizada é composta exclusivamente por registros laboratoriais secundários, anonimizados de forma irreversível, não contendo quaisquer informações pessoais identificáveis. O risco identificado refere-se unicamente à possibilidade de vazamento de dados, existente a qualquer base de dados armazenada computacionalmente. Tal risco é mitigado pelo armazenamento em nuvem e protocolos de controle de acesso restrito e uso exclusivo para fins de pesquisa. Dessa forma, não há contato direto com participantes e não haverá coleta de dados ou materiais biológicos adicionais, nem qualquer forma de intervenção clínica. Os resultados serão apresentados de forma agregada e estatística, também impossibilitando a identificação individual. Em razão das restrições contratuais e éticas firmadas com o laboratório-fonte, a base de dados completa, ainda que anonimizada, e os scripts utilizados na implementação dos experimentos não foram disponibilizados publicamente neste momento, permanecendo a sua publicação em fase de negociação institucional considerando os requisitos legais aplicáveis e os interesses do laboratório de origem.

4.1.5 Análise Exploratória da Base de dados

Para caracterizar a distribuição da variável-alvo entre subgrupos demográficos e contextualizar a análise de equidade dos capítulos subsequentes, a Figura 4.3 apresenta a distribuição de A1c por sexo (painel A) e por faixa etária (painel B). As distribuições por sexo apresentam sobreposição, com medianas de 5,6% no subgrupo feminino e 5,7% no masculino, e maior dispersão à direita entre os homens. Por faixa etária, observa-se deslocamento progressivo das medianas (5,3%, 5,7% e 6,0% para as faixas <40 anos, 40-60 anos e >60 anos, respectivamente).

Figura 4.3 – Distribuição da hemoglobina glicada A1c por sexo (painel A) e por faixa etária (painel B), representada por *boxplot*. A linha central de cada caixa indica a mediana, a caixa representa o intervalo interquartílico (P25-P75). As linhas horizontais tracejadas indicam os limiares diagnósticos de 5,7% e 6,5% (World Health Organization, 2021).




Elaborado pelo autor a partir da base de dados final (n = 169.999).

A Figura 4.4 apresenta a prevalência das classes glicêmicas nos mesmos subgrupos. A prevalência conjunta de pré-diabetes e diabetes (PD+D) é de 47,9% no subgrupo feminino e 53,5% no masculino, e cresce com a idade (17,6%, 51,2% e 73,5% nas faixas <40 anos, 40-60 anos e >60 anos, respectivamente). Esses padrões fundamentam a interpretação das métricas de equidade reportadas no Capítulo 5 e discutidas no Capítulo 6. A caracterização detalhada dos 23 atributos é apresentada no Apêndice B.

4.1.6 Tarefas de Classificação

No escopo deste estudo, o problema foi modelado como uma tarefa de classificação. Com esta abordagem, o problema preditivo foi dividido em quatro tarefas experimen-

Figura 4.4 – Prevalência das classes glicêmicas (Normal, Pré-diabetes, Diabetes) por sexo (painel A) e por faixa etária (painel B). Os valores de n indicam o tamanho amostral de cada subgrupo.



Elaborado pelo autor a partir da base de dados final ($n = 169.999$).

tais complementares, visando investigar diferentes fronteiras de decisão entre as classes glicêmicas e avaliar a viabilidade e separabilidade de cada divisão.

A **Tarefa 1 (T1)** consiste na classificação binária dos indivíduos em Normal (N) ou Alterado (PD+D), agrupando pré-diabéticos e diabéticos em uma única classe positiva, possibilitando avaliar a capacidade dos modelos em distinguir indivíduos normoglicêmicos dos indivíduos que possuem alguma alteração glicêmica.

A **Tarefa 2 (T2)** aborda a classificação multiclasse direta nas três classes originais (Normal, Pré-diabetes e Diabetes), representando o problema em sua formulação mais completa e desafiadora.

A **Tarefa 3 (T3)** decompõe o problema multiclasse em seis subproblemas binários, cada um isolando uma fronteira de decisão específica entre pares de classes: N vs. PD+D, N vs. D, N vs. PD, N+PD vs. D, PD vs. D e PD vs. N+D. Cabe destacar que o subproblema N vs. PD+D da Tarefa 3 é conceitualmente equivalente à Tarefa 1, por envolver a mesma fronteira de decisão e a mesma distribuição de classes.

A **Tarefa 4 (T4)** propõe a construção de um *ensemble* heterogêneo, combinando os classificadores binários especialistas da Tarefa 3 para resolver o problema multiclasse de forma indireta, por meio de estratégias de agregação.

A Tabela 4.2 apresenta uma visão geral dos experimentos definidos, com o tipo de classificação, as classes envolvidas e o tamanho do conjunto de dados em cada caso.

Os detalhes de implementação de cada tarefa, incluindo os algoritmos avaliados, as categorias experimentais e a construção do *ensemble*, são apresentados na Seção 4.4.

Tabela 4.2 – Tarefas experimentais de classificação definidas neste trabalho.

Tarefa	Tipo	Problema	Classes	Registros
T1	Binária	N vs. PD+D	2	169.999
T2	Multiclasse	N vs. PD vs. D	3	169.999
T3: Nx D	Decomposição	N vs. D	2	120.842
T3: Nx PD	Decomposição	N vs. PD	2	134.327
T3: N+PDx D	Decomposição	N+PD vs. D	2	169.999
T3: PDx D	Decomposição	PD vs. D	2	84.829
T3: PDxN+D	Decomposição	PD vs. N+D	2	169.999
T4	<i>Ensemble</i>	N vs. PD vs. D	3	169.999

Elaborado pelo autor.

Nota: O sexto subproblema da Tarefa 3 (N vs. PD+D) é conceitualmente equivalente à Tarefa 1, conforme discutido na Seção 4.1.6, e por isso não é repetido nesta tabela.

4.2 Pré-processamento

Todo o pré-processamento utilizado na modelagem foi implementado por meio de *pipelines* do *scikit-learn* (PEDREGOSA et al., 2011), garantindo reprodutibilidade, ausência de vazamento de dados e aplicação consistente das transformações. Essa abordagem é fundamental para evitar o vazamento dos dados de teste para o treinamento, uma vez que as transformações são ajustadas exclusivamente nos dados de treino de cada *fold* e posteriormente aplicadas aos dados de validação e teste.

4.2.1 Escalonamento e Transformação de Atributos

A escolha do modelo de escalonamento pode influenciar significativamente o desempenho de diferentes famílias de algoritmos de aprendizado, dado que modelos baseados em distâncias ou gradientes são sensíveis à escala dos atributos, enquanto modelos baseados em árvores de decisão são invariantes às escalas (PEDREGOSA et al., 2011). Diante disso, foram definidas nove transformações numéricas distintas, identificadas por P1–P9, combinando diferentes estratégias de escalonamento. Oito dessas transformações (P1–P8) são aplicadas nas tarefas binárias (T1 e T3), enquanto a Tarefa 2 substitui a transformação P4 por P9 (*PowerTransformer* seguido de *RobustScaler*) em função de particularidades do contexto multiclasse.

Os atributos numéricos foram escalonados por *StandardScaler*, *MinMaxScaler*, *QuantileTransformer* (QT) ou *PowerTransformer* (PT), conforme a configuração de cada experimento. Os fundamentos dessas técnicas são descritos na Seção 2.4.1.

A Tabela 4.3 apresenta o catálogo completo dessas transformações, com seus identificadores (P1–P9), as composições aplicadas, as tarefas em que são utilizadas e o contexto experimental de cada uma (Categorias C1, C2 e C3, descritas na Seção 4.4). Notamos que na Tarefa 2, as transformações P1–P3 utilizam `drop="first"` no *OneHotEncoder*, enquanto as demais utilizam `drop="if_binary"`. A transformação P9 substitui P4 no contexto exclusivo da T2. Os detalhes de implementação (nomes das variáveis no código-fonte) são apresentados no Apêndice A.

Tabela 4.3 – Catálogo de transformações numéricas utilizadas nos *pipelines*. Cada identificador (P1–P9) é referenciado na Tabela 4.6 para indicar em qual categoria e com quais algoritmos a transformação foi aplicada. Todas as transformações incluem *OneHotEncoder* para a variável *Sexo*.

ID	Transformação numérica	Tarefas	Uso (Tab. 4.6)
<i>Compartilhadas entre tarefas binárias e multiclasse</i>			
P1	<i>MinMaxScaler</i>	T1, T2, T3	C1
P2	<i>StandardScaler</i>	T1, T2, T3	C1 e C3 (LinearSVC)
P3	<i>StandardScaler</i> → <i>MinMaxScaler</i>	T1, T2, T3	C1
<i>Exclusivas das tarefas binárias (T1 e T3)</i>			
P4	<i>QuantileTransformer</i> (500q) → <i>StandardScaler</i>	T1, T3	C2 e C3 (MLP)
P5	<i>QuantileTransformer</i> → <i>StandardScaler</i>	T1, T3	C3 (<i>LogReg</i>)
P6	<i>passthrough</i> (sem escalonamento)	T1, T2, T3	C2 (HistGB, LGBM) e C3 (árvores/ <i>boosting</i>)
P7	<i>QuantileTransformer</i> → <i>StandardScaler</i> (esparso)	T1, T3	C3 (<i>LogReg</i> + <i>class_weight</i>)
P8	<i>passthrough</i> (esparso)	T1, T3	C3 (CatBoost)
<i>Exclusiva da tarefa multiclasse (T2)</i>			
P9	<i>PowerTransformer</i> (yeo-johnson) → <i>RobustScaler</i>	T2	C2 (T2)

Elaborado pelo autor.

A variável categórica *Sexo* foi representada por *one-hot encoding* binário, descartando-se uma categoria para resultar em um atributo binário. Essa codificação foi realizada por meio da classe *OneHotEncoder* do *scikit-learn*, com o parâmetro `drop="if_binary"` nas tarefas binárias (T1, T3) e `drop="first"` nos preprocessadores de template da Tarefa 2, evitando a multicolinearidade ao descartar automaticamente uma das categorias. Além disso, todos os atributos numéricos foram previamente convertidos para o tipo *float32*, reduzindo o consumo de memória e padronizando a representação numérica para processamento eficiente.

Os preprocessadores com sufixo “esparso” foram configurados com saída em formato esparso (`sparse_output=True`), otimizando o desempenho de modelos lineares que operam nativamente com matrizes esparsas, como *LinearSVC* e Regressão Logística com penalização via *class_weight*.

4.2.2 Balanceamento de Classes

O desbalanceamento entre classes é um desafio recorrente em problemas de classificação na área da saúde, podendo induzir os modelos a favorecer a classe majoritária em detrimento das classes de maior relevância clínica (HE; GARCIA, 2009). Conforme descrito na Seção 4.1.3, a distribuição entre classes na base de dados final apresenta desbalanceamento moderado: Normal (N) = 85.170 registros (50,1%), Pré-diabetes (PD) = 49.157 registros (28,9%) e Diabetes (D) = 35.672 registros (21,0%).

O grau de desbalanceamento varia significativamente entre as tarefas experimentais definidas neste trabalho, visto que algumas tarefas filtram subconjuntos de classes (reduzindo o tamanho total da base), enquanto outras binarizam por agrupamento de classes (alterando a proporção entre classe majoritária e minoritária). A Tabela 4.4 apresenta a distribuição de classes para cada tarefa, ordenada pela razão de desbalanceamento entre a classe majoritária e a classe minoritária.

Tabela 4.4 – Distribuição de classes por tarefa experimental (conforme Tabela 4.2), ordenada pela razão de desbalanceamento.

Tarefa	Total	Classe Majoritária	Classe Minoritária	Razão
T3: N+PD vs. D	169.999	N+PD: 134.327 (79,0%)	D: 35.672 (21,0%)	3,77:1
T3: PD vs. N+D	169.999	N+D: 120.842 (71,1%)	PD: 49.157 (28,9%)	2,46:1
T3: N vs. D	120.842	N: 85.170 (70,5%)	D: 35.672 (29,5%)	2,39:1
T2: N vs. PD vs. D	169.999	N: 85.170 (50,1%)	D: 35.672 (21,0%)	2,39:1
T3: N vs. PD	134.327	N: 85.170 (63,4%)	PD: 49.157 (36,6%)	1,73:1
T3: PD vs. D	84.829	PD: 49.157 (58,0%)	D: 35.672 (42,0%)	1,38:1
T1: N vs. PD+D	169.999	N: 85.170 (50,1%)	PD+D: 84.829 (49,9%)	1,00:1

Elaborado pelo autor.

A análise da Tabela 4.4 evidencia que a Tarefa 1 (N vs. PD+D) é praticamente balanceada, pois a binarização agrega as classes Pré-diabetes e Diabetes, equilibrando as proporções. Em contrapartida, a tarefa N+PD vs. D apresenta o maior desbalanceamento (3,77:1), com a classe minoritária composta exclusivamente por indivíduos diabéticos contra a maioria combinada de normais e pré-diabéticos. As tarefas filtradas (N vs. D, N vs. PD, PD vs. D) reduzem o tamanho total da base de dados, alterando o volume de instâncias disponíveis para treinamento e a proporção entre classes. Essa variação no grau de desbalanceamento entre as tarefas desenvolvidas justifica a avaliação de diferentes técnicas de reamostragem, realizada na categoria experimental C3 (descrita na Seção 4.4).

Para tratamento do desbalanceamento entre classes, foram avaliadas técnicas de sobreamostragem (SMOTE e ROS), subamostragem (*TomekLinks* e *RUS*), abordagens híbridas (SMOTEENN e SMOTETomek) e penalização via *class_weight* (CHAWLA et

al., 2002; LEMAÎTRE; NOGUEIRA; ARIDAS, 2017). Como alternativa às técnicas de reamostragem, a penalização via *class_weight='balanced'* ajusta automaticamente os pesos das classes de forma inversamente proporcional à sua frequência, aumentando o custo de erros na classe minoritária sem alterar a composição do conjunto de dados.

Todas as técnicas de reamostragem foram aplicadas exclusivamente nos subconjuntos de dados de treinamento, dentro de cada *fold* da validação cruzada, evitando vazamento de informações para os conjuntos de validação ou teste (LEMAÎTRE; NOGUEIRA; ARIDAS, 2017). Essa garantia foi assegurada pela utilização da classe *ImbPipeline* da biblioteca *imbalanced-learn* (LEMAÎTRE; NOGUEIRA; ARIDAS, 2017), que encapsula as etapas de pré-processamento, reamostragem e classificação em um *pipeline* único, aplicando a reamostragem apenas durante o ajuste (*fit*) e não durante a predição (*predict*).

4.3 Protocolo Experimental

Esta seção descreve o protocolo experimental adotado para o treinamento e avaliação dos modelos de aprendizado de máquina, apresentando o particionamento dos dados, a estratégia de validação cruzada aninhada e as métricas de desempenho utilizadas.

4.3.1 Particionamento dos Dados

A base de dados pré-processada foi dividida em 80% para treino e 20% para teste, utilizando a função *train_test_split* do *scikit-learn* (PEDREGOSA et al., 2011) com semente fixa (*random_state=42*) e estratificação pela variável-alvo (*stratify=y*). Essa divisão resultou em 135.999 registros para treino e 34.000 registros para teste, mantendo as proporções originais entre as classes em ambas as partições. O conjunto de treino (80%) foi utilizado tanto para o treinamento quanto para a validação dos modelos, por meio da validação cruzada aninhada descrita na Seção 4.3.2, enquanto o conjunto de teste (20%) foi reservado exclusivamente para a avaliação final, não sendo utilizado em nenhuma etapa de treinamento ou seleção de hiperparâmetros.

Todas as divisões de dados foram estratificadas e mantidas fixas entre os diferentes algoritmos e estratégias de modelagem, garantindo comparabilidade entre os resultados e reprodutibilidade dos experimentos. Para as tarefas que operam sobre subconjuntos

filtrados da base de dados (conforme Tabela 4.4), a divisão treino/teste foi aplicada antes da filtragem, preservando a mesma separação em todas as configurações.

4.3.2 Validação Cruzada Aninhada

A otimização de hiperparâmetros foi realizada exclusivamente nos dados de treino por meio de validação cruzada aninhada (*nested cross-validation*), conforme recomendado por Varma and Simon (2006) e Cawley and Talbot (2010), utilizando 10 *folds* externos para estimativa de desempenho e 5 *folds* internos para seleção dos hiperparâmetros. A utilização de validação cruzada aninhada visa evitar estimativas otimistas de desempenho, que podem ocorrer quando a seleção de hiperparâmetros e a avaliação do modelo compartilham os mesmos dados, introduzindo viés de seleção (CAWLEY; TALBOT, 2010).


O *loop* externo foi implementado com a função *cross_validate* do *scikit-learn*, utilizando 10 *folds* estratificados para estimar o desempenho de generalização de cada configuração de modelo. O particionamento foi feito via *StratifiedKFold*, com parâmetros *shuffle=True* e *random_state=42*. O *loop* interno, composto por 5 *folds* estratificados, utilizou o algoritmo *HalvingRandomSearchCV* (JAMIESON; TALWALKAR, 2016; LI et al., 2018; PEDREGOSA et al., 2011), que implementa a estratégia de *successive halving* (JAMIESON; TALWALKAR, 2016). O algoritmo foi configurado com *n_candidates='exhaust'* e *factor=3*, avaliando progressivamente um número decrescente de candidatos com volumes crescentes de dados. Em cada iteração do *loop* externo, a otimização de hiperparâmetros foi realizada automaticamente sobre a partição de treino correspondente. A métrica de otimização utilizada no *loop* interno foi o F2-Score ($\beta=2$), priorizando a identificação correta da classe positiva (alta sensibilidade), coerente com o objetivo clínico do trabalho.

O parâmetro *min_resources* do *HalvingRandomSearchCV* foi calculado para cada *pipeline*, garantindo que as iterações iniciais do *successive halving* tivessem de amostras suficientes. Para *pipelines* com reamostragem (SMOTE e variantes), o cálculo considerou o parâmetro *k_neighbors* do amostrador, o número de classes e o número de *folds* internos. Para *pipelines* sem reamostragem (baseados em *class_weight*), o cálculo garantiu um mínimo de amostras da classe minoritária por *fold*.

Cada configuração de modelo foi encapsulada em um *ImbPipeline* da biblioteca *imbalanced-learn* (LEMAÎTRE; NOGUEIRA; ARIDAS, 2017), integrando as etapas de pré-processamento, reamostragem (quando aplicável) e classificação em uma estrutura

única, conforme descrito na Seção 4.2.2. A utilização do *ImbPipeline* em substituição ao *Pipeline* padrão do *scikit-learn* foi necessária porque o *Pipeline* convencional não suporta etapas que alteram o número de amostras durante o treinamento, como é o caso das técnicas de reamostragem (SMOTE, SMOTEENN, entre outras). O *ImbPipeline* estende essa funcionalidade, aplicando a reamostragem exclusivamente durante a etapa de treinamento (*fit*) e ignorando-a durante a predição (*predict*), prevenindo o vazamento de dados sintéticos para o conjunto de validação ou teste.

Figura 4.5 – Esquema da validação cruzada aninhada (*nested cross-validation*) com 10 *folds* externos e 5 internos, aplicada sobre a partição de treino. O modelo final avaliado no *holdout* corresponde ao melhor estimador dentre os 10 *folds* externos.



Elaborado pelo autor.

A Figura 4.5 apresenta o esquema da validação cruzada aninhada utilizada neste trabalho. Cabe observar que o modelo selecionado para avaliação no *holdout* foi treinado em aproximadamente 90% dos dados de treino (correspondente a um *fold* externo), sem retreino adicional sobre o conjunto de treino completo (135.999 registros). Uma abordagem alternativa, descrita por Raschka (2018), consiste em realizar uma rodada final de treinamento com o conjunto ótimo de hiperparâmetros, gerando o modelo final com todos os dados disponíveis. Contudo, dado o volume expressivo de amostras utilizadas

neste trabalho, a diferença entre utilizar aproximadamente 122.399 ou 135.999 registros de treino é considerada de impacto reduzido sobre o desempenho final dos modelos.

Adicionalmente, o critério de seleção do melhor modelo entre os 10 *folds* externos baseou-se no maior F2-Score obtido durante a busca interna de hiperparâmetros (*best_score_* do *HalvingRandomSearchCV*). Embora uma alternativa seria selecionar pelo desempenho no *fold* de validação externo, optou-se pelo critério interno por refletir diretamente a qualidade da otimização de hiperparâmetros realizada em cada partição.

4.3.3 Métricas de Avaliação

As principais métricas de avaliação adotadas neste trabalho foram F2-Score ($\beta=2$), Recall e AUC-PR, complementadas por Precisão e AUC-ROC (HICKS et al., 2022; SO-KOLOVA; LAPALME, 2009). As definições formais e fórmulas dessas métricas são apresentadas no Capítulo 2.

O F2-Score foi definido como métrica primária de avaliação, por enfatizar o *recall* sobre a precisão, refletindo o maior custo clínico de falsos negativos em contextos de triagem, onde a não identificação de um indivíduo com alteração glicêmica apresenta consequências mais graves do que um resultado falso positivo (HICKS et al., 2022). Por esse motivo, o F2-Score também foi utilizado como função objetivo na otimização de hiperparâmetros do *loop* interno da validação cruzada aninhada (Seção 4.3.2), garantindo que a seleção dos modelos priorizasse a sensibilidade desde a etapa de *tuning*. Diante do objetivo clínico deste trabalho, voltado à triagem oportunística para apoio ao diagnóstico do diabetes, o F2-Score foi adotado como métrica primária em detrimento de alternativas. O F1-Score atribui peso equivalente à precisão e ao *recall*, não refletindo a assimetria do custo clínico entre falsos negativos e falsos positivos característica de cenários de triagem para diabetes (HICKS et al., 2022). Métricas isoladas, como a especificidade, apesar de apresentarem informações complementares, demonstram-se insuficientes para evidenciar o desempenho do modelo na detecção de casos positivos, objetivo principal desta pesquisa. Ainda, publicações recentes apontam que a avaliação completa de modelos preditivos em saúde pode ser fortalecida pela incorporação de análises de utilidade clínica, como as curvas de decisão (*decision curve analysis*) e o benefício líquido (*net benefit*) (VICKERS; CALSTER; STEYERBERG, 2016) (CALSTER et al., 2025), abordagens apresentadas como direção de trabalho futuro no Capítulo 7.

As métricas secundárias foram coletadas em todos os *folds* externos e no conjunto

de teste, possibilitando uma avaliação complementar do desempenho dos modelos sob diferentes perspectivas. O *Recall* e a Precisão foram incluídos por serem componentes diretos do F2-Score, permitindo diagnosticar o comportamento do modelo em termos de sensibilidade e especificidade das predições. A AUC-PR foi adotada por ser particularmente informativa em cenários de desbalanceamento de classes, enquanto a AUC-ROC avalia a capacidade discriminativa geral do classificador ao longo de todos os limiares de decisão.

Na Tarefa 2 (classificação multiclasse), utilizou-se a média macro (*macro-average*) para todas as métricas, atribuindo peso igual a cada classe independentemente de sua frequência (SOKOLOVA; LAPALME, 2009). Essa abordagem foi adotada para evitar que o desempenho do modelo fosse dominado pelas classes majoritárias, garantindo uma avaliação equitativa do comportamento do classificador em todas as três classes glicêmicas (Normal, Pré-diabetes e Diabetes).

4.4 Estratégias de Classificação

A seleção dos algoritmos buscou contemplar famílias com diferentes tipos de modelagem, possibilitando uma avaliação ampla e comparativa de diferentes vieses indutivos de aprendizado de máquina nas tarefas preditivas desta pesquisa. Foram avaliados 12 algoritmos de classificação, incluindo modelos lineares (Regressão Logística, *LinearSVC*), modelos baseados em árvores (*Decision Tree*, *Random Forest* (BREIMAN, 2001), *Bagging*), métodos de *boosting* (*Gradient Boosting* (FRIEDMAN, 2001), *AdaBoost* (FREUND; SCHAPIRE, 1997), *HistGradientBoosting*, *XGBoost* (CHEN; GUESTRIN, 2016), *LightGBM* (KE et al., 2017), *CatBoost* (PROKHORENKOVA et al., 2018)) e Redes Neurais Artificiais (MLP). A Tabela 4.5 apresenta os 12 algoritmos utilizados, organizados por família, com as respectivas referências e implementações.

Cada configuração de modelo foi encapsulada em um *pipeline* composto por três etapas: escalonamento, reamostragem e classificação, conforme descrito nas Seções 4.2.1 e 4.2.2. Para permitir a análise do impacto de cada etapa do *pipeline*, as configurações foram agrupadas em três categorias experimentais, cada uma isolando um fator de influência sobre o desempenho (Tabela 4.6): (i) transformação numérica, (ii) escolha do algoritmo, e (iii) método de balanceamento.

A categoria **C1: Escalonamento** investiga exclusivamente o efeito das transformações numéricas nos atributos. Nessa categoria, o método de balanceamento é mantido

Tabela 4.5 – Algoritmos de classificação avaliados neste trabalho, organizados por família algorítmica.

Família	Algoritmo	Biblioteca	Referência
Lineares	Regressão Logística	<i>scikit-learn</i>	(PEDREGOSA et al., 2011)
	<i>LinearSVC</i>	<i>scikit-learn</i>	(PEDREGOSA et al., 2011)
Árvores e <i>bagging</i>	<i>Decision Tree</i>	<i>scikit-learn</i>	(PEDREGOSA et al., 2011)
	<i>Random Forest</i>	<i>scikit-learn</i>	(BREIMAN, 2001)
	<i>Bagging</i>	<i>scikit-learn</i>	(PEDREGOSA et al., 2011)
<i>Boosting</i>	<i>Gradient Boosting</i>	<i>scikit-learn</i>	(FRIEDMAN, 2001)
	<i>AdaBoost</i>	<i>scikit-learn</i>	(FREUND; SCHAPIRE, 1997)
	<i>HistGradientBoosting</i>	<i>scikit-learn</i>	(PEDREGOSA et al., 2011)
	<i>XGBoost</i>	<i>xgboost</i>	(CHEN; GUESTRIN, 2016)
	<i>LightGBM</i>	<i>lightgbm</i>	(KE et al., 2017)
	<i>CatBoost</i>	<i>catboost</i>	(PROKHORENKOVA et al., 2018)
Redes neurais	MLP	<i>scikit-learn</i>	(PEDREGOSA et al., 2011)

Elaborado pelo autor.

Tabela 4.6 – Configurações de *pipeline* por categoria experimental. N representa o número de configurações executadas por tarefa binária. Os identificadores P1–P9 referenciam as transformações numéricas descritas na Tabela 4.3.

Categoria	Fator isolado	Preprocessador (Tab. 4.3)	Método de Balanceamento	Famílias de Algoritmos	N
C1: Escalonamento	Transformação numérica	P1, P2, P3 (varia)	SMOTE ($k = 5$)	Decision Tree, Bagging, Logistic Regression, MLP, Gradient Boosting, AdaBoost	11
C2: Algoritmos	Algoritmo	P4 (fixo); P6 para HistGB e LGBM*; P9 na T2	SMOTE ($k = 5$)	Decision Tree, Random Forest, HistGB, XGBoost, LightGBM, CatBoost, Logistic Regression, LinearSVC, MLP	9
C3: Balanceamento	Amostrador / penalização	P6 : DT, Bagging, RF, XGBoost; P8 : CatBoost; P2 : LinearSVC; P7 : Logistic Regression; P4 : MLP	SMOTEENN, SMOTETomek, TomekLinks, ROS, RUS, <i>class_weight</i>	MLP, Logistic Regression, LinearSVC, Decision Tree, Bagging, Random Forest, XGBoost, CatBoost	8
Total executado por tarefa binária					28

* *HistGradientBoosting* e *LightGBM* dispensam escalonamento numérico devido ao *histogram binning* nativo, utilizando **P6** (*passthrough*). O pareamento de preprocessadores em C3 segue a sensibilidade de cada algoritmo à escala dos atributos. ROS = *RandomOverSampler*; RUS = *RandomUnderSampler*. Detalhes completos dos 28 *pipelines* no Apêndice A.

constante (SMOTE com $k = 5$) e variam-se as transformações identificadas por **P1**, **P2** e **P3** na Tabela 4.3. Foram testadas 11 combinações, distribuídas entre os algoritmos incluídos. A categoria **C2: Algoritmos** fornece uma comparação entre diferentes famílias de modelos. Todos os algoritmos recebem o mesmo pré-processamento (transformação **P4** da Tabela 4.3, com exceção de *HistGradientBoosting* e *LightGBM*, que utilizam **P6** por dispensarem escalonamento explícito) e o mesmo método de balanceamento (SMOTE). Essa categoria funciona como *baseline*, isolando o impacto da escolha do algoritmo. Por fim, a categoria **C3: Balanceamento** examina exclusivamente o efeito de diferentes estratégias de tratamento de desbalanceamento. Visando limitar os custos computacionais, um total de oito combinações foram definidas de forma direcionada: cada algoritmo foi pareado com um único método de balanceamento adequado à sua sensibilidade, totalizando

oito combinações (Tabela 4.6, com detalhamento completo no Apêndice A).

A nomenclatura dos *pipelines* adotada neste trabalho reflete diretamente a categoria experimental a que cada configuração pertence e os componentes do *pipeline*, seguindo o formato “(Cx) Algoritmo + Preprocessador + Balanceamento”. O prefixo entre parênteses indica a categoria experimental: (C1) Escalonamento, (C2) Algoritmos ou (C3) Balanceamento. Por exemplo, “(C1) MLP + Std + MinMax” identifica um *pipeline* da categoria C1 composto por *Multilayer Perceptron* com *StandardScaler* seguido de *MinMaxScaler*; “(C3) MLP + Quantile + SMOTEENN” identifica um *pipeline* da categoria C3 com *Multilayer Perceptron*, *QuantileTransformer* e balanceamento SMOTEENN. Essa convenção é utilizada de forma consistente nas tabelas de *ranking* apresentadas no Capítulo 5 e na listagem detalhada do Apêndice A.

Os 28 *pipelines* descritos na Tabela 4.6 referem-se às tarefas binárias (T1 e T3). A Tarefa 2 utiliza o mesmo conjunto de 28 configurações, porém com variações de preprocessadores adaptadas ao contexto multiclasse, conforme descrito na Tabela 4.3. Assim, o conjunto experimental deste trabalho compreende 229 modelos preditivos avaliados, distribuídos pelas quatro tarefas conforme apresentado na Tabela 4.7. Cada um desses modelos foi submetido ao protocolo de validação cruzada aninhada descrito na Seção 4.3.2.

A seguir, estão detalhadas as quatro tarefas experimentais definidas na Seção 4.1.6, apresentando os aspectos específicos de implementação de cada uma.

Tabela 4.7 – Composição dos 229 modelos preditivos avaliados, por tarefa.

Tarefa	Tipo	Cálculo	Modelos
T1	Binária	$28 \text{ pipelines} \times 1 \text{ tarefa}$	28
T2	Multiclasse	$28 \text{ pipelines} \times 1 \text{ tarefa}^*$	28
T3	Decomposição binária	$28 \text{ pipelines} \times 6 \text{ subproblemas}$	168
T4	<i>Ensemble</i>	5 estratégias (v1, v2-A, v2-B, v3, v4)	5
Total			229

Elaborado pelo autor.

* A Tarefa 2 utiliza o mesmo conjunto de 28 *pipelines*, com substituição de P4 por P9 e ajustes pontuais para o contexto multiclasse (Tabela 4.3).

4.4.1 Tarefa 1: Classificação Binária

A Tarefa 1 aborda a classificação binária entre indivíduos Normoglicêmicos, ou Normal, (N) e Alterado (PD+D), agrupando pré-diabéticos e diabéticos em uma única classe positiva, conforme descrito na Seção 4.1.6 e na Tabela 4.2. Foram executados 28

pipelines organizados nas três categorias experimentais (C1, C2 e C3), cada um submetido ao protocolo de validação cruzada aninhada descrito na Seção 4.3.2. As métricas de avaliação foram calculadas sobre o conjunto de teste fixo (20%, 34.000 registros), permitindo a comparação direta entre todas as configurações. Esta tarefa representa o cenário de triagem mais simples, possibilitando avaliar a capacidade dos modelos em distinguir indivíduos normoglicêmicos dos que apresentam alguma alteração no metabolismo da glicose.

4.4.2 Tarefa 2: Classificação Multiclasse Direta

A Tarefa 2 aborda a classificação multiclasse direta nas três classes originais (Normal, Pré-diabetes e Diabetes), utilizando a mesma base de dados e a mesma divisão treino/teste (135.999/34.000) das demais tarefas. Foram executados 28 *pipelines* com o mesmo protocolo experimental da Tarefa 1, porém com variações nos preprocessadores adaptadas ao contexto multiclasse, conforme detalhado na Tabela 4.3. As métricas de desempenho foram calculadas utilizando a média macro (*macro-average*), atribuindo peso igual a cada classe e possibilitando a avaliação do desempenho do modelo em todas as classes, independentemente de seu tamanho. A Tarefa 2 representa o problema em sua formulação mais completa e desafiadora, funcionando como referência principal (*baseline*) para a comparação com o *ensemble* da Tarefa 4.

4.4.3 Tarefa 3: Decomposição Binária

A Tarefa 3 decompõe o problema multiclasse em seis subproblemas binários, cada um isolando uma fronteira de decisão específica entre pares ou agrupamentos de classes, conforme a Tabela 4.2. Os subproblemas incluem três fronteiras *one-vs-one* (N vs. D, N vs. PD e PD vs. D) e três classificadores *one-vs-rest* (N vs. PD+D, N+PD vs. D e PD vs. N+D), completando o esquema OvR para todas as três classes. A inclusão do subproblema PD vs. N+D foi motivada pela necessidade de um classificador OvR dedicado à classe Pré-diabetes, complementando os classificadores OvR para Normal e Diabetes. Para cada subproblema, o conjunto de dados foi filtrado ou binarizado para conter apenas as classes de cada respectivo problema, e os mesmos 28 *pipelines* foram executados com o protocolo padrão de validação cruzada aninhada. A composição e o

grau de desbalanceamento de cada subconjunto resultante são apresentados na Tabela 4.4, evidenciando a variação expressiva entre os subproblemas, de praticamente balanceado (T3: N vs. PD+D, com razão de 1,00:1) até fortemente desbalanceado (T3: N+PD vs. D, com razão de 3,77:1). Essa decomposição possibilita investigar quais fronteiras de decisão são mais simples, teoricamente de fácil separação pelos modelos de aprendizado de máquina, além de fornecer os classificadores especialistas utilizados na construção do *ensemble* da Tarefa 4.

4.4.4 Tarefa 4: *Ensemble*

A Tarefa 4 propõe a construção de um *ensemble* heterogêneo que combina classificadores binários especialistas da Tarefa 3 para resolver o problema multiclasse de forma indireta, conforme descrito na Seção 4.1.6 e na Tabela 4.2. A estratégia tem como premissa que a agregação de especialistas, cada um treinado em uma fronteira de decisão específica, pode superar o desempenho de um classificador multiclasse direto em cenários com classes intermediárias de difícil separação (KUNCHEVA, 2004).

A seleção dos especialistas binários evoluiu ao longo do trabalho. A primeira versão investigada (v1) utilizou seis especialistas selecionados por classe-alvo, com dois classificadores designados para cada uma das três classes do problema multiclasse, conforme apresentado na Tabela 4.8. A segunda versão do *ensemble* (v2) usa os mesmos especialistas da v1, porém implementando estratégias diferentes para a agregação de modelos. As versões subsequentes (v3 e v4) adotaram um critério alternativo, com um classificador por subproblema da Tarefa 3, totalizando seis especialistas que cobrem as seis fronteiras de decisão binárias (N vs. PD+D, N vs. D, N vs. PD, PD vs. D, N+PD vs. D e PD vs. N+D), conforme apresentado na Tabela 4.9. Em ambos os casos, foi selecionado o *pipeline* de melhor desempenho em F2-Score nos *folds* externos da validação cruzada aninhada para cada posição do *ensemble*, garantindo diversidade de algoritmos e preprocessadores entre os especialistas.

Cinco estratégias de agregação foram investigadas de forma iterativa: v1, v2-A, v2-B, v3 e v4. A v1 utilizou votação ponderada por F2-Score (*Soft Voting*) sobre seis especialistas selecionados por classe-alvo (dois por classe), conforme Kuncheva (2004). As variantes v2-A e v2-B exploraram abordagens de correção mínima sem retreinamento dos especialistas, com base em Rifkin and Klautau (2004) e Galar et al. (2011). A v3 reformulou a agregação por *Stacking*, conforme Wolpert (1992), utilizando Regressão

Tabela 4.8 – Especialistas binários selecionados para a primeira versão do *ensemble* (v1), organizados por classe-alvo, com dois classificadores por classe do problema multiclasse.

Classe-alvo	Slot	Algoritmo	Decomposição
Normal	M1	(C1) MLP + Std + MinMax	N vs. PD+D
Normal	M2	(C2) LightGBM	N vs. PD+D
Diabético	M1	(C3) MLP + Quantile + SMOTEENN	N+PD vs. D
Diabético	M2	(C3) Bagging + RUS	N+PD vs. D
Pré-diabético	M1	(C3) MLP + Quantile + SMOTEENN	N vs. PD
Pré-diabético	M2	(C3) Random Forest + SMOTEENN	PD vs. D

Elaborado pelo autor.

Tabela 4.9 – Especialistas binários selecionados para as versões v3 e v4 do *ensemble*, com algoritmo e família de modelo. Cada especialista corresponde a um subproblema da Tarefa 3.

Subproblema	Algoritmo	Família
N vs. PD+D	(C1) MLP + Std + MinMax	<i>Neural Network</i>
N vs. D	(C3) Bagging + RUS	<i>Bagging</i>
N vs. PD	(C3) CatBoost + ClassWeight	<i>Gradient Boosting</i>
PD vs. D	(C3) MLP + Quantile + SMOTEENN	<i>Neural Network</i>
N+PD vs. D	(C3) CatBoost + ClassWeight	<i>Gradient Boosting</i>
PD vs. N+D	(C3) CatBoost + ClassWeight	<i>Gradient Boosting</i>

Elaborado pelo autor.

Logística como meta-aprendiz e uma nova seleção de especialistas (um por subproblema). A v4 estendeu o *Stacking* com um meta-aprendiz não-linear e atributos originais como *passthrough*, conforme Ting and Witten (1999). A comparação quantitativa entre as cinco estratégias é apresentada na Seção 5.5. A composição dos especialistas em cada uma das cinco versões é apresentada na Tabela 4.10.

Tabela 4.10 – Composição dos especialistas utilizados em cada versão do *ensemble*.

Versão	N	Conjunto de especialistas	Observação
v1	6	Tab. 4.8 (2 por classe-alvo)	4 OvR + 2 OvO
v2-A	4	Subset da Tab. 4.8	Apenas os 4 OvR (descarta OvO)
v2-B	6	Tab. 4.8 (2 por classe-alvo)	Mesmos da v1, agregação ponderada
v3	6	Tab. 4.9 (1 por subproblema)	Inclui NxO e PDxN+D não usados na v1
v4	6	Tab. 4.9 (1 por subproblema)	Mesmos especialistas da v3


Elaborado pelo autor.

A configuração final adotada (v4) utiliza *Stacking* com meta-aprendiz *HistGradientBoosting* e *passthrough* dos 23 atributos originais. As meta-features foram geradas por predição *out-of-fold* (OOF) com *StratifiedKfold* de 10 partições sobre o conjunto de treino, produzindo, para cada um dos seis especialistas binários, as probabilidades preditas $P(y = 0)$ e $P(y = 1)$ de sua respectiva fronteira de decisão, totalizando 12 meta-features. Embora ambas as probabilidades sejam complementares em classificadores binários ($P(y = 0) + P(y = 1) = 1$), as duas colunas foram retidas para preservar a representação simétrica do espaço de entrada do meta-aprendiz. Esses valores, con-

catenadas aos atributos originais, compõem o espaço de entrada do meta-aprendiz. Os hiperparâmetros do meta-aprendiz foram otimizados por validação cruzada aninhada no mesmo protocolo descrito na Seção 4.3.2.

O protocolo de geração das meta-features segue o princípio do *Stacked Generalization* proposto por Wolpert (1992). O conjunto de treino (80% da base, 135.999 registros) foi particionado em 10 *folds* estratificados, com `shuffle=True` e semente aleatória fixa (`random_state=42`). Para cada partição ($I_{\text{treino}}, I_{\text{val}}$), os seis classificadores binários especialistas foram treinados exclusivamente sobre os índices I_{treino} e, em seguida, aplicados aos índices I_{val} para produção das probabilidades preditas. Dessa forma, cada amostra x_j do conjunto de treino recebeu suas meta-features geradas somente por especialistas que nunca a haviam observado durante o treinamento, eliminando o risco de vazamento de informação entre os classificadores base e o meta-aprendiz. A Figura 4.6 ilustra o fluxo completo de treinamento e avaliação do *ensemble*.

Figura 4.6 – Protocolo de treinamento do *ensemble* (v3 e v4): partição estratificada 80/20, geração de meta-features *out-of-fold* pelos seis especialistas binários, treinamento do meta-aprendiz e avaliação final exclusiva no conjunto de teste reservado.



Elaborado pelo autor.

A independência entre os dados utilizados em cada etapa do *ensemble* foi garantida em três níveis distintos. No primeiro nível, os classificadores binários especialistas foram treinados e avaliados exclusivamente sobre o conjunto de treino (80%), com validação cruzada *out-of-fold* interna. No segundo nível, o meta-aprendiz foi treinado sobre as meta-features *out-of-fold* e os rótulos do conjunto de treino, mantendo a mesma partição *holdout* original. No terceiro nível, o conjunto de teste (20%, 34.000 registros) foi

reservado desde a partição inicial estratificada (Seção 4.3.1) e não participou de nenhuma etapa de treinamento ou seleção de hiperparâmetros, seja dos classificadores base, seja do meta-aprendiz. Essa separação rigorosa garante que o desempenho reportado no Capítulo 5 reflete a capacidade de generalização do *ensemble* sobre dados não vistos.


A Tarefa 4 funciona como abordagem alternativa ao *baseline* da Tarefa 2 (classificação multiclasse direta), possibilitando avaliar se a decomposição do problema multiclasse em subproblemas binários especializados, seguida de meta-agregação, oferece ganhos em relação ao treinamento direto de um classificador tripartite. A comparação detalhada entre o *ensemble* final e o *baseline* T2 é apresentada na Seção 5.5.

A evolução da v1 para as versões v3 e v4 implicou a reorganização do conjunto de especialistas, motivada por três ajustes identificados durante o desenvolvimento iterativo do *ensemble*. A decomposição N+PD vs. D, utilizada na v1 como classificador *One-vs-Rest* para Diabetes, foi substituída pela decomposição N vs. D, que elimina a classe Pré-diabetes da classe negativa e produz fronteiras de decisão mais nítidas entre os extremos do espectro glicêmico (GALAR et al., 2011). O subproblema PD vs. N+D foi acrescentado para completar o esquema *One-vs-Rest* também para a classe Pré-diabetes, fornecendo ao meta-aprendiz um sinal direto de probabilidade para cada uma das três classes. Adicionalmente, o critério “dois especialistas por classe-alvo” da v1 foi substituído por “um especialista por subproblema” nas versões v3 e v4, alinhando a composição à arquitetura de *Stacking*, que requer um conjunto completo e não-redundante de meta-features cobrindo todas as fronteiras binárias.

As Figuras 4.7 e 4.8 ilustram as arquiteturas das duas principais versões do *ensemble*. A Figura 4.7 apresenta a versão v1, que agrega as predições dos seis especialistas binários (dois por classe-alvo) por meio de *Soft Voting* ponderado pelo F2-Score individual de cada especialista. A Figura 4.8 apresenta a versão v4, que substitui a votação ponderada por *Stacking* não-linear, combinando as doze probabilidades preditas pelos especialistas com os 23 atributos originais (*passthrough*) como entrada para o meta-aprendiz *HistGradientBoosting*.

A Tabela 4.11 apresenta os hiperparâmetros do meta-aprendiz *HistGradientBoosting* na configuração final do *ensemble* (v4), distinguindo os valores fixos dos valores otimizados por busca em grade.

Figura 4.7 – Arquitetura do *ensemble* v1. Os seis classificadores binários especialistas (dois por classe-alvo) produzem probabilidades independentes, que são agregadas por *Soft Voting* ponderado pelo F2-Score individual (w_i) de cada especialista. A classe predita corresponde ao *argmax* da soma ponderada das probabilidades por classe.



Elaborado pelo autor.

Tabela 4.11 – Hiperparâmetros do meta-aprendiz *HistGradientBoosting* na configuração final (v4) do *ensemble*. Valores otimizados foram selecionados por *GridSearchCV* com *StratifiedKFold* de cinco partições e F2-Score macro como função objetivo.

Hiperparâmetro	Valor / Grade de busca	Observação
max_iter	200	Fixo
learning_rate	0,1	Fixo
early_stopping	True	Fixo
validation_fraction	0,1	Fixo
class_weight	'balanced'	Fixo
random_state	42	Fixo (semente global)
max_depth	{3, 4, 5} → 5	Otimizado
min_samples_leaf	{20, 50, 100} → 100	Otimizado


Elaborado pelo autor.

4.5 Ambiente Computacional

Todos os experimentos foram executados em um computador MacBook equipado com processador Apple M4 Pro, utilizando exclusivamente a unidade central de processamento (CPU), sem aceleração por unidade de processamento gráfico (GPU). A linguagem de programação utilizada foi Python 3.13.7, e as principais bibliotecas empregadas estão descritas na Tabela 4.12.

A reprodutibilidade dos experimentos foi assegurada pela fixação de uma semente global (`seed=42`), utilizada em todas as operações estocásticas, incluindo as funções `np.random.seed()` e `random.seed()` e o parâmetro `random_state` de todos os algoritmos e procedimentos de particionamento. A integridade dos dados de entrada

Figura 4.8 – Arquitetura do *ensemble* v4. Os seis classificadores binários especialistas (um por subproblema da Tarefa 3) produzem 12 meta-features (duas probabilidades por especialista), que são concatenadas aos 23 atributos originais (*passthrough*, seta tracejada em azul) para compor o espaço de entrada de 35 dimensões do meta-aprendiz *HistGradientBoosting*. O meta-aprendiz produz a predição multiclasse final.



foi verificada por meio de *hash* do *dataset*, garantindo que todas as execuções partiram do mesmo conjunto de dados original.

O tempo de treinamento foi de aproximadamente duas horas por modelo, considerando a validação cruzada aninhada com 10 *folds* externos e 5 internos, totalizando cerca de 448 horas (aproximadamente 19 dias) de processamento para os 229 modelos avaliados (Tabela 4.7).

Tabela 4.12 – Principais bibliotecas utilizadas nos experimentos e suas versões.

Biblioteca	Versão
<i>scikit-learn</i>	1.7.2
<i>imbalanced-learn</i>	0.14.0
<i>XGBoost</i>	3.1.1
<i>LightGBM</i>	4.6.0
<i>CatBoost</i>	1.2.8
<i>SHAP</i>	0.49.1
<i>pandas</i>	2.3.3
<i>NumPy</i>	2.3.4
<i>matplotlib</i>	3.10.7
<i>seaborn</i>	0.13.2

Elaborado pelo autor.

5 RESULTADOS

Este capítulo apresenta os resultados obtidos na avaliação dos *pipelines* de aprendizado de máquina desenvolvidos no Capítulo 4. A Seção 5.1 fornece uma visão geral consolidada do desempenho das quatro estratégias experimentais reportadas neste capítulo, a Tarefa 1 (classificação binária), a Tarefa 2 (classificação multiclasse direta), a Tarefa 3 (decomposição em subproblemas binários) e a Tarefa 4 (*ensemble* heterogêneo). A Seção 5.2 detalha os resultados da Tarefa 1, abrangendo o desempenho dos modelos, a estabilidade na validação cruzada aninhada, a calibração probabilística, a otimização do limiar de decisão, o impacto dos atributos preditivos (incluindo interpretabilidade por instância) e a análise de erros estratificada por faixa de hemoglobina glicada, por sexo, por faixa etária e por atributos discriminantes. A Seção 5.3 apresenta os resultados da Tarefa 2 (classificação multiclasse direta), contemplando o desempenho dos modelos, o impacto dos atributos preditivos e a análise de erros. A Seção 5.4 descreve a Tarefa 3 (decomposição binária), iniciando por uma visão consolidada dos seis subproblemas e detalhando os três cientificamente mais relevantes, Nx_D, PD_xD e PD_xN+D. A Seção 5.5 apresenta os resultados da Tarefa 4 (*ensemble* heterogêneo), incluindo a composição do *ensemble* a partir dos especialistas binários, a evolução das estratégias de agregação investigadas e a comparação do desempenho final com o *baseline* multiclasse da Tarefa 2.

5.1 Avaliação Geral dos Resultados

Esta seção resume os principais achados do estudo, iniciando pela comparação entre as estratégias binária e multiclasse e enfatizando os desafios associados ao pré-diabetes, que motivam o uso de classificadores binários especializados. A Tabela 5.1 consolida o desempenho dos melhores *pipelines* por tarefa, com métricas extraídas dos dados de teste (holdout) e do fold independente da validação cruzada aninhada conduzida durante o treinamento. Para esclarecer a leitura das tabelas apresentadas nas próximas seções, recorda-se que os *pipelines* seguem a nomenclatura definida no Capítulo 4 (Tabela 4.6), em que o prefixo entre parênteses indica a categoria experimental: **(C1) Escalonamento** compreende variações de transformações numéricas com o pré-processador explicitado no próprio nome do *pipeline*; **(C2) Algoritmos** compreende a comparação entre famílias de modelos com pré-processamento padrão da categoria, correspondente à transformação P4 da Tabela 4.3 para algoritmos sensíveis à escala e ao *passthrough* P6

(sem escalonamento) para algoritmos baseados em árvores, como *HistGradientBoosting*, *LightGBM* e *CatBoost*; e **(C3) Balanceamento** compreende a comparação de estratégias de tratamento do desbalanceamento. Cabe destacar que a categoria C2 inclui *pipelines* sem escalonamento explícito para os algoritmos baseados em árvores, possibilitando a avaliação do impacto da ausência de transformação numérica sobre o desempenho preditivo.

Tabela 5.1 – Desempenho consolidado dos melhores *pipelines* por tarefa. As colunas F2, *Recall*, AUC-PR e AUC-ROC referem-se ao conjunto de teste (*holdout* estratificado de 20%); as duas últimas colunas referem-se à validação cruzada aninhada (média $\pm$ desvio padrão sobre os 10 *folds* externos).

Tarefa	Problema	Pipeline vencedor	Teste (<i>holdout</i> 20%)				CV aninhada (<i>outer folds</i>)	
			F2	Recall	AUC-PR	AUC-ROC	F2 Treino ($\pm$ dp)	F2 Valid. ($\pm$ dp)
T1	N vs. PD+D	MLP (Std+MinMax)	0,793	0,824	0,780	0,801	0,763 $\pm$ 0,016	0,763 $\pm$ 0,018
T2	N vs. PD vs. D	MLP (Std+MinMax)	0,551	0,556	0,571	0,756	0,548 $\pm$ 0,003	0,545 $\pm$ 0,005
T3-NxD	N vs. D	MLP (QT+SMOTEENN)	0,770	0,877	0,686	0,852	0,782 $\pm$ 0,003	0,769 $\pm$ 0,007
T3-NxPD	N vs. PD	MLP (QT+SMOTEENN)	0,750	0,847	0,616	0,764	0,753 $\pm$ 0,003	0,747 $\pm$ 0,009
T3-PDxD	PD vs. D	MLP (QT+SMOTEENN)	0,697	0,762	0,592	0,681	0,700 $\pm$ 0,007	0,688 $\pm$ 0,011
T3-N+PDxD	N+PD vs. D	MLP (QT+SMOTEENN)	0,650	0,851	0,456	0,780	0,666 $\pm$ 0,002	0,647 $\pm$ 0,005
T3-PDxD+N	PD vs. N+D	MLP (QT+SMOTEENN)	0,671	0,850	0,417	0,677	—	—
T4	N vs. PD vs. D	Stacking (HGBT+PT)	0,551	0,557	—	0,766	—	—

Fonte: Elaborado pelo autor.

A tabela evidencia a superioridade recorrente dos modelos baseados em Redes Neurais Artificiais (MLP). A diferença entre o F2 médio de treino e o F2 médio de validação na CV aninhada variou de 0,000 (T1) a 0,019 (T3-N+PDxD), e o desvio padrão entre os *outer folds* de validação variou de 0,005 a 0,018. A Tarefa 1 apresentou o maior F2 entre todas as configurações avaliadas (0,793), seguida pelo subproblema NxD da Tarefa 3 (0,770) e pelo subproblema NxPD da Tarefa 3 (0,750). As configurações com menor F2 foram a Tarefa 2 multiclasse (0,551) e o subproblema N+PDxD da Tarefa 3 (0,650). O *pipeline* vencedor da Tarefa 1 e da Tarefa 2 foi o (C1) MLP + Std + MinMax, enquanto todos os subproblemas da Tarefa 3 tiveram como melhor configuração o (C3) MLP + Quantile + SMOTEENN.

5.2 Tarefa 1: Classificação Binária (N vs. PD+D)

Nesta seção são apresentados os resultados da Tarefa 1, de classificação binária entre indivíduos Normoglicêmicos e indivíduos com alteração glicêmica (Pré-diabéticos

ou Diabéticos), abrangendo o desempenho dos *pipelines*, a estabilidade na validação cruzada, a calibração probabilística, a otimização do limiar de decisão, o impacto dos atributos preditivos e a análise de erros por subgrupo.

5.2.1 Desempenho dos Modelos

A Tarefa 1 investiga o desempenho dos modelos ao detectar indivíduos com alteração glicêmica, sem diferenciar entre as classes Pré-diabético e Diabético, a partir exclusivamente de parâmetros hematológicos do hemograma. O modelo para T1 (binário) apresentou desempenho elevado nos dados de teste ($F2 = 0,793$; $Recall = 0,824$; $AUC-PR = 0,780$; $AUC-ROC = 0,801$), indicando que o hemograma contém informações suficientes para distinguir, com bom poder preditivo, indivíduos normais daqueles com alteração glicêmica inicial ou estabelecida (pré-diabetes ou diabetes). Complementarmente, o *pipeline* vencedor apresenta especificidade de 0,629, classificando corretamente como Normal aproximadamente 63% dos indivíduos sem alteração glicêmica. A diferença observada em relação ao *Recall* (0,824) reflete a opção deliberada pela priorização da sensibilidade, conforme justificado na Seção 4.3.3, resultando em taxa de falsos positivos de aproximadamente 37%, característica relevante para a interpretação do modelo em cenários de triagem populacional, discutida no Capítulo 6. A Tabela 5.2 apresenta os dez *pipelines* de melhor desempenho na Tarefa 1, ordenados pelo F2-Score nos dados de teste (holdout).

Tabela 5.2 – Dez melhores *pipelines* da Tarefa 1 (N vs. PD+D), ordenados por F2-Score. As colunas F2 a AUC-ROC referem-se ao conjunto de teste (*holdout* estratificado de 20%); a última coluna refere-se à validação cruzada aninhada (média $\pm$ desvio padrão dos 10 *outer folds*).

Valores em negrito indicam o melhor desempenho em cada métrica.


Pipeline	Teste (<i>holdout</i> 20%)						CV aninhada F2 Valid. ($\pm dp$)
	F2	Recall	Precision	F1	AUC-PR	AUC-ROC	
(C1) MLP + Std + MinMax	0,793	0,824	0,689	0,750	0,780	0,801	0,763 $\pm$ 0,017
(C2) CatBoost	0,762	0,778	0,706	0,740	0,782	0,801	0,762 $\pm$ 0,005
(C2) Random Forest	0,762	0,777	0,706	0,740	0,780	0,799	0,760 $\pm$ 0,005
(C3) CatBoost + ClassWeight	0,761	0,775	0,708	0,740	0,784	0,803	0,762 $\pm$ 0,005
(C2) LightGBM	0,760	0,775	0,707	0,739	0,782	0,800	0,761 $\pm$ 0,005
(C1) AdaBoost + MinMax	0,760	0,775	0,705	0,739	0,777	0,797	0,760 $\pm$ 0,007
(C2) MLP	0,758	0,772	0,709	0,739	0,781	0,801	0,761 $\pm$ 0,006
(C2) XGBoost	0,757	0,770	0,712	0,740	0,785	0,803	0,759 $\pm$ 0,005
(C2) HistGradientBoosting	0,757	0,769	0,711	0,739	0,786	0,804	0,760 $\pm$ 0,004
(C1) Gradient Boosting + MinMax	0,757	0,769	0,712	0,739	0,784	0,803	0,760 $\pm$ 0,005

Fonte: Elaborado pelo autor.

Entre os dez *pipelines* de melhor desempenho da Tarefa 1, a variação do F2-Score foi de 0,793 a 0,757, uma amplitude de apenas 3,6 pontos percentuais. Oito dos dez

melhores *pipelines* utilizam algoritmos baseados em árvores com *boosting* ou *bagging* (CatBoost, LightGBM, HistGBT, XGBoost, AdaBoost, Florestas Aleatórias), enquanto as duas configurações restantes são baseadas em Redes Neurais Artificiais do tipo MLP, incluindo o *pipeline* vencedor.

Figura 5.1 – Matriz de confusão detalhada do *pipeline* vencedor da Tarefa 1 ((C1) MLP + Std + MinMax) nos dados de teste, com contagens absolutas e proporções relativas às linhas (classe real).




Fonte: Elaborado pelo autor.

A matriz de confusão do *pipeline* vencedor, apresentada na Figura 5.1, mostra que o modelo consegue identificar 82,4% dos indivíduos com alteração glicêmica apenas a partir dos parâmetros hematológicos, correspondendo a 13.983 verdadeiros positivos de um total de 16.966 indivíduos com alteração glicêmica no conjunto de teste. A mesma figura revela que 2.983 indivíduos com alteração glicêmica foram classificados como Normais (17,6% de falsos negativos), e 6.317 indivíduos Normais foram classificados como tendo alteração glicêmica (37,1% de falsos positivos na classe Normal).

A Figura 5.2 apresenta a análise de erros do *pipeline* vencedor em três painéis complementares, sendo que o painel esquerdo mostra que as distribuições de probabilidade dos verdadeiros positivos e dos falsos positivos se sobrepõem na região entre 0,4 e 0,7, enquanto os verdadeiros negativos e os falsos negativos se concentram abaixo de 0,5. O painel central confirma as contagens da matriz de confusão: 13.983 verdadeiros posi-

Figura 5.2 – Análise de erros do *pipeline* vencedor da Tarefa 1 nos dados de teste. Superior: distribuição das probabilidades previstas para a classe positiva, estratificada por tipo de predição (TP, TN, FN, FP). Inferior-Esquerda: contagem absoluta por tipo de predição. Inferior-Direita: taxas de falsos negativos e falsos positivos em função do limiar de decisão.




Fonte: Elaborado pelo autor.

vos (TP), 10.717 verdadeiros negativos (TN), 2.983 falsos negativos (FN) e 6.317 falsos positivos (FP). O painel direito apresenta as taxas de falsos negativos e falsos positivos em função do limiar de decisão, que é o valor de probabilidade acima do qual o modelo classifica uma instância como positiva (PD+D) e abaixo do qual classifica como Normal. O limiar padrão utilizado pelo *scikit-learn* é 0,50, porém a redução desse limiar aumenta o *Recall* (mais indivíduos com alteração glicêmica são detectados) ao custo de maior taxa de falsos positivos, enquanto a elevação do limiar produz o efeito inverso. No painel direito da Figura 5.2, observa-se que as curvas de FN e FP se cruzam em um valor de limiar inferior a 0,50, indicando que o limiar padrão produz uma taxa de falsos positivos proporcionalmente mais elevada do que a taxa de falsos negativos para este problema.

A Figura 5.3 apresenta as curvas ROC e Precisão-*Recall* de todos os 28 *pipelines* avaliados na Tarefa 1 nos dados de teste. Na curva ROC, observa-se uma separação em dois grupos distintos: 23 *pipelines* baseados em *ensemble*, MLP e Regressão Logística formam um agrupamento compacto com AUC-ROC entre 0,793 e 0,804 (amplitude de 0,011), enquanto os 5 *pipelines* baseados em Árvores de Decisão individuais ficam isolados com AUC-ROC entre 0,633 e 0,641. Na curva Precisão-*Recall*, a variação entre os 23 *pipelines* do grupo superior é mais acentuada (AUC-PR de 0,757 a 0,785, amplitude de 0,028), indicando que essa curva discrimina melhor as diferenças de desempenho entre *pipelines* competitivos do que a curva ROC. Na curva Precisão-*Recall* do *pipeline* vencedor, a queda de Precisão é gradual até *Recall* $\approx$ 0,70 (Precisão $\approx$ 0,736), e se intensifica a partir de *Recall* $\approx$ 0,75 (Precisão $\approx$ 0,718), com a taxa de queda passando de $-0,09$ por unidade de *Recall* para $-0,58$ na região entre 0,80 e 0,90 de *Recall*. O ponto operacional do *pipeline* vencedor com o limiar padrão de 0,50 (*Recall* = 0,824; Precisão = 0,689) localiza-se na região em que a queda de Precisão já se encontra acelerada, operando com Precisão inferior a 0,70 em troca de sensibilidade elevada.

Figura 5.3 – Curvas ROC e Precisão-Recall para todos os 28 *pipelines* avaliados na Tarefa 1, nos dados de teste. Cada linha corresponde a um *pipeline* distinto; a diagonal tracejada na curva ROC indica o desempenho de um classificador aleatório.



Fonte: Elaborado pelo autor.

5.2.2 Estabilidade e Validação Cruzada Aninhada

A estabilidade dos resultados da Tarefa 1 foi confirmada pela validação cruzada aninhada (10 *folds* externos), na qual o F2 de 0,793 no conjunto de teste apresenta-se consistente com a estatística dos *outer folds* de validação ($0,763 \pm 0,018$).

Tabela 5.3 – Estabilidade do F2-Score do *pipeline* vencedor e dos quatro mais próximos da Tarefa 1, nas fases de treino e validação da CV aninhada (10 *folds* externos) e no conjunto de teste (*holdout* estratificado de 20%). Valores em negrito indicam o melhor desempenho em cada métrica.

Pipeline	F2 Treino CV ($\pm dp$)	F2 Valid. CV ($\pm dp$)	F2 Teste
(C1) MLP + Std + MinMax	$0,763 \pm 0,016$	$0,763 \pm 0,018$	0,793
(C2) CatBoost	$0,763 \pm 0,001$	$0,762 \pm 0,005$	0,762
(C3) CatBoost + ClassWeight	$0,764 \pm 0,002$	$0,762 \pm 0,005$	0,761
(C2) MLP	$0,765 \pm 0,004$	$0,761 \pm 0,006$	0,758
(C2) LightGBM	$0,764 \pm 0,003$	$0,761 \pm 0,005$	0,760

Fonte: Elaborado pelo autor.


A Tabela 5.3 demonstra que a diferença entre F2 de treino e validação permaneceu inferior a 0,020 na Tarefa 1, indicando ausência de sobreajuste (*Overfitting*) relevante. O F2 observado no conjunto de teste (0,793) é 0,030 superior à média de validação da validação cruzada aninhada (0,763), o que é esperado no protocolo da validação cruzada aninhada, dado que o modelo final avaliado no teste foi treinado sobre a totalidade dos dados de treino (80% do *dataset*), enquanto cada *outer fold* da validação cruzada aninhada utilizou aproximadamente 72% do *dataset* para treinamento, conforme descrito por Varma and Simon (2006). Observa-se ainda que o modelo vencedor da Tarefa 1 é um *pipeline* da categoria *Template*, composto por MLP com StandardScaler e normalização Min-Max, enquanto os *pipelines* da categoria *Experimental* (com QuantileTransformer e SMOTEENN) obtiveram desempenho superior nos subproblemas binários da Tarefa 3, conforme detalhado na Seção 5.4.

5.2.3 Otimização do Limiar de Decisão

Esta subseção apresenta uma análise *post-hoc* realizada após a conclusão dos experimentos, com o objetivo de avaliar o ganho potencial em F2-Score caso o limiar de decisão padrão (0,50) fosse substituído pelo limiar que maximiza o F2. Todos os resultados reportados nas demais seções deste capítulo foram obtidos com o limiar padrão de 0,50, e os limiares ótimos apresentados nesta subseção foram calculados sobre o con-

junto de teste exclusivamente para fins de análise de potencial de melhoria, não tendo sido utilizados na avaliação dos modelos. A incorporação da otimização de limiar ao protocolo experimental, com seleção do limiar ótimo nos dados de validação e avaliação subsequente no conjunto de teste, constitui uma oportunidade de trabalho futuro para a obtenção de desempenho preditivo ainda superior ao reportado neste trabalho, conforme pode ser observado na Figura 5.4.

Figura 5.4 – Curvas de F2-Score, Precisão e *Recall* em função do limiar de decisão para os seis *pipelines* de melhor F2 na Tarefa 1. As linhas verticais tracejadas indicam os limiares ótimo e padrão (0,50).



Fonte: Elaborado pelo autor.

Tabela 5.4 – Ganho em F2-Score obtido pela otimização do limiar de decisão nos dados de teste, para os seis *pipelines* apresentados na Figura 5.4. Valores em negrito indicam o melhor desempenho em cada métrica.

Pipeline	F2 (thr = 0,50)	Limiar ótimo	F2 ótimo	Ganho (pp)
(C1) MLP + Std + MinMax	0,793	0,221	0,851	+5,8
(C3) CatBoost + ClassWeight	0,761	0,157	0,851	+9,0
(C2) MLP	0,758	0,177	0,851	+9,3
(C2) XGBoost	0,757	0,171	0,852	+9,4
(C2) HistGradientBoosting	0,757	0,157	0,852	+9,5
(C1) Gradient Boosting + MinMax	0,757	0,184	0,851	+9,4

Fonte: Elaborado pelo autor.

A Tabela 5.4 mostra que, para o *pipeline* vencedor em F2 na configuração padrão, o limiar ótimo observado é 0,221, com F2 correspondente de 0,851, um ganho de 5,8

pontos percentuais em relação ao F2 padrão de 0,793. Entre os dez *pipelines* de maior F2, o ganho médio obtido pela otimização do limiar é de 8,9 pontos percentuais, e todos os *pipelines* convergem para F2 ótimo na faixa de 0,850 a 0,852, o que reduz a amplitude máxima entre eles de 3,6 para apenas 0,2 pontos percentuais. Os limiares ótimos situam-se na faixa de 0,157 a 0,306, todos substancialmente abaixo do valor padrão de 0,50. Em complemento à abordagem de otimização adotada neste trabalho, baseada na maximização do F2-Score sobre o intervalo contínuo de limiares de decisão, publicações recentes recomendam a substituição do limiar padrão pela prevalência da classe positiva observada no conjunto de treinamento, abordagem denominada *q*-classification* (O'BRIEN; ISHWARAN, 2019) (LYU; ISHWARAN, 2023). Essa heurística aproxima o classificador da decisão ótima de Bayes sob distribuições marginalmente equilibradas e apresenta vantagens reportadas em termos de equidade entre subgrupos com prevalências distintas. Na Tarefa 1, a prevalência da classe positiva (PD+D) corresponde a aproximadamente 49,9% (Seção 4.1.3), de forma que o limiar derivado por essa regra coincidiria, na prática, com o limiar padrão de 0,50, configurando um cenário em que a abordagem se torna pouco distinguível do procedimento de referência. A aplicação dessa heurística é potencialmente mais informativa nos subproblemas com classes acentuadamente desbalanceadas (Tarefa 3), constituindo uma direção complementar de avaliação a ser explorada em trabalhos subsequentes.


5.2.4 Impacto dos Atributos Preditivos

5.2.4.1 Importância Global

A importância de atributos por permutação analisada sobre o melhor modelo da Tarefa 1 identificou Idade como o atributo mais relevante, com magnitude de importância 5,6 vezes superior ao segundo colocado. A análise de valores SHAP (Figura 5.5) confirmou Idade e Leucócitos como os atributos de maior contribuição nas predições, em plena concordância com a importância por permutação.

No painel SHAP da Figura 5.5, observa-se que valores altos de Idade (pontos vermelhos) deslocam a predição para a classe positiva (PD+D), enquanto valores baixos (pontos azuis) deslocam a predição para a classe Normal; o mesmo padrão direcional ocorre para os Leucócitos. Para os Linfócitos, o padrão direcional é o mesmo observado para Idade e Leucócitos, com valores altos de Linfócitos associados a valores SHAP posi-

Figura 5.5 – Resumo dos valores SHAP para o *pipeline* vencedor da Tarefa 1 ((C1) MLP + Std + MinMax). No painel esquerdo, cada ponto representa uma instância do conjunto de teste, com cor indicando o valor do atributo (vermelho = valor alto, azul = valor baixo) e posição horizontal indicando o impacto sobre a predição. No painel direito, a magnitude média absoluta da contribuição SHAP de cada atributo.




Fonte: Elaborado pelo autor.

tivos, e para o Sexo o impacto é bimodal, com distribuição concentrada em torno de zero. A Figura 5.6 compara as importâncias estimadas por SHAP e por permutação, revelando um coeficiente de correlação de Spearman de $\rho = 0,975$ entre os dois *rankings*.

A Tabela 5.5 apresenta os dez atributos mais influentes da Tarefa 1, ordenados pelo valor SHAP, com as respectivas posições em cada método. A Idade concentrou mais de 60% da importância SHAP total dos dez atributos mais relevantes, sendo seguida pelos Leucócitos (10,7%), Linfócitos (10,4%) e Sexo (8,8%). A maior divergência de posição entre SHAP e permutação ocorreu em Eritrócitos (9ª posição em SHAP, 11ª em permutação), enquanto os quatro primeiros atributos (Idade, Leucócitos, Linfócitos, Sexo) mantêm exatamente o mesmo *ranking* nos dois métodos.

Figura 5.6 – Comparação entre o *ranking* de importância por SHAP e por permutação para o *pipeline* vencedor da Tarefa 1. Correlação de Spearman $\rho = 0,975$.

Comparação SHAP vs Permutation Importance
(Spearman $\rho = 0.975$)



Fonte: Elaborado pelo autor.

5.2.4.2 Interpretabilidade por Instância

A Figura 5.7 apresenta explicações SHAP individuais para três predições do *pipeline* vencedor da Tarefa 1, uma predição corretamente classificada como positiva, uma predição incorreta do tipo falso negativo e uma predição incorreta do tipo falso positivo.



Na Figura 5.7a, um indivíduo de 72 anos com 14.400 Leucócitos obteve predição $f(x) = 0,385$, com as contribuições positivas dominantes vindas da Idade (+0,19), dos Leucócitos (+0,09), dos Linfócitos (+0,05) e do MPV (+0,03). Na Figura 5.7b, um indivíduo de 43 anos com 1.017 Linfócitos obteve predição $f(x) = -0,305$ e foi incorretamente classificado como Normal, sendo a Idade baixa a principal contribuição negativa (-0,15), acompanhada dos Linfócitos (-0,09), dos Leucócitos (-0,07) e do Sexo (-0,04). Na Figura 5.7c, um indivíduo de 75 anos com RDW 17,4 e Hemoglobina 12,5 obteve predição $f(x) = 0,261$ e foi incorretamente classificado como tendo alteração glicêmica, sendo a Idade elevada a maior contribuição positiva isolada (+0,22), seguida pelo RDW alto (+0,05).

Tabela 5.5 – Dez atributos mais influentes do *pipeline* vencedor da Tarefa 1, ordenados pelo valor SHAP.

Atributo	SHAP	Permutação	Rank SHAP	Rank Perm.
Idade	0,21161	0,19288	1	1
Leucócitos	0,03683	0,01333	2	2
Linfócitos	0,03569	0,01135	3	3
Sexo	0,03021	0,00712	4	4
HCM	0,02628	0,00665	5	6
RDW	0,02092	0,00666	6	5
MPV	0,01891	0,00427	7	7
CHCM	0,01594	0,00354	8	8
Eritrócitos	0,01165	0,00157	9	11
Hemoglobina	0,00675	0,00178	10	9

Fonte: Elaborado pelo autor.

Figura 5.7 – Gráficos de cascata SHAP para três predições individuais do *pipeline* vencedor da Tarefa 1. Cada barra indica a contribuição de um atributo específico para a predição da instância, partindo do valor esperado $E[f(X)]$ até a predição final $f(x)$.



(c) Falso Positivo.

Fonte: Elaborado pelo autor.


5.2.5 Análise de Erros

Para concluir a análise dos resultados para a Tarefa 1, investigamos os erros cometidos pelo modelo do pipeline vencedor com relação a valores de A1c, idade e sexo.

5.2.5.1 Padrão dos Erros por Faixa de Hemoglobina Glicada

A Figura 5.8 apresenta a distribuição dos falsos positivos e falsos negativos do *pipeline* vencedor da Tarefa 1 por faixa de hemoglobina glicada, permitindo observar o comportamento do modelo próximo aos limiares de diagnóstico da Organização Mundial da Saúde. Os erros do modelo concentram-se nas faixas imediatamente próximas ao limiar 5,7% de A1c, que separa as classes Normal e Pré-diabético na definição adotada neste trabalho.

Figura 5.8 – Distribuição dos falsos positivos e falsos negativos do *pipeline* vencedor da Tarefa 1 por faixa de hemoglobina glicada. A faixa 5,7% corresponde ao limiar Normal/Pré-diabetes definido pela Organização Mundial da Saúde; a faixa 6,5% corresponde ao limiar Pré-diabetes/Diabetes.



5.2.5.2 Análise de Erros por Sexo

A Tabela 5.6 apresenta as métricas de desempenho do *pipeline* vencedor da Tarefa 1 estratificadas por sexo.


Conforme ilustrado na Figura 5.9, o *Recall* observado para o subgrupo masculino (0,785) é ligeiramente superior ao do subgrupo feminino (0,773), enquanto o AUC-ROC segue o padrão inverso, com valor mais elevado para o subgrupo feminino (0,819 vs. 0,766). A taxa de falsos negativos é de 22,7% para mulheres e 21,5% para homens, uma diferença de 1,2 ponto percentual.

Tabela 5.6 – Desempenho do *pipeline* vencedor da Tarefa 1 estratificado por sexo, nos dados de teste.

Sexo	N	Acurácia	F2	Recall	AUC-ROC	FN rate
Feminino	87 299	0,746	0,761	0,773	0,819	0,227
Masculino	48 700	0,702	0,765	0,785	0,766	0,215

Fonte: Elaborado pelo autor.

Figura 5.9 – Análise de erros do *pipeline* vencedor da Tarefa 1 por sexo, nos dados de teste. Esquerda: composição dos erros (corretos, falsos negativos, falsos positivos) por sexo. Direita: taxas de FN e FP por sexo.



Fonte: Elaborado pelo autor.

5.2.5.3 Análise de Erros por Faixa Etária

A Tabela 5.7 apresenta o desempenho do *pipeline* vencedor estratificado por três faixas etárias, acompanhado da prevalência de alteração glicêmica na amostra de teste em cada faixa.


Tabela 5.7 – Desempenho do *pipeline* vencedor da Tarefa 1 estratificado por faixa etária, nos dados de teste, com prevalência da classe positiva em cada subgrupo.

Faixa	N	Prev.	Acurácia	Recall	F2	FN rate
<40	8 991	0,18	0,819	0,127	0,149	0,873
40–60	13 408	0,51	0,657	0,786	0,749	0,214
>60	11 601	0,73	0,735	0,988	0,926	0,012

Fonte: Elaborado pelo autor. A prevalência refere-se à proporção de indivíduos com alteração glicêmica no respectivo subgrupo do conjunto de teste.

O *Recall* do *pipeline* vencedor varia de 0,127 na faixa <40 anos a 0,988 na faixa >60 anos, com F2-Score correspondente variando de 0,149 a 0,926. A taxa de falsos negativos é de 87,3% na faixa <40 anos, 21,4% na faixa 40–60 anos e 1,2% na faixa >60 anos, conforme apresentado também na Figura 5.10. A prevalência da classe positiva (PD+D) no conjunto de teste é de 18% na faixa <40 anos, 51% na faixa 40–60 anos e

Figura 5.10 – Análise de erros do *pipeline* vencedor da Tarefa 1 por faixa etária, nos dados de teste. Esquerda: composição dos erros (corretos, falsos negativos, falsos positivos) por faixa etária. Direita: taxa de falsos negativos clínicos (indivíduos com alteração glicêmica classificados como Normais) por faixa etária.



Fonte: Elaborado pelo autor.

73% na faixa >60 anos.

A Figura 5.11 apresenta a distribuição conjunta dos falsos negativos do *pipeline* vencedor da Tarefa 1 por faixa etária e por faixa de A1c, complementando a análise por faixa etária isolada da Tabela 5.7.




Figura 5.11 – Análise conjunta dos falsos negativos do *pipeline* vencedor da Tarefa 1 por faixa etária e faixa de hemoglobina glicada, nos dados de teste. Painel esquerdo: contagem absoluta de falsos negativos em cada célula da matriz. Painel direito: taxa de falsos negativos sobre o total de indivíduos com alteração glicêmica em cada célula. A coluna de A1c < 5,7% é omitida nos valores por ser a faixa correspondente à classe Normal (sem casos positivos verdadeiros).

Fonte: Elaborado pelo autor.

A faixa etária inferior a 40 anos concentra taxas de falsos negativos entre 82% e 89% em todas as faixas de A1c acima do limiar de 5,7% (5,7–6,5%, 6,5–8,0%, 8,0–10,0% e >10,0%). A faixa de 40 a 60 anos apresenta taxas entre 14% e 26%, e a faixa acima de 60 anos abaixo de 2%, replicando em escala detalhada o padrão monotônico observado na análise por faixa etária isolada (Tabela 5.7). A discussão das implicações deste padrão para a aplicabilidade clínica do modelo é retomada na Seção 6.3.

5.3 Tarefa 2: Classificação Multiclasse (N vs. PD vs. D)

Nesta seção são apresentados os resultados da Tarefa 2, de classificação multiclasse direta entre as três classes Normal, Pré-diabético e Diabético, abrangendo o desempenho dos *pipelines*, a estabilidade na validação cruzada aninhada, o impacto dos atributos preditivos e a análise de erros por subgrupo.

5.3.1 Desempenho dos Modelos

O melhor modelo para a Tarefa 2 (multiclasse) apresentou desempenho inferior ao observado na Tarefa 1 nos dados de teste, com $F2 = 0,551$ macro, $Recall = 0,556$ macro, $Precision = 0,545$ macro, $AUC-PR = 0,571$ e $AUC-ROC = 0,756$. Quanto à especificidade, sua interpretação no cenário multiclasse demanda abordagem por classe, derivável diretamente da matriz de confusão. Os padrões de erro apresentados nas seções subsequentes evidenciam que a classe Pré-diabético concentra simultaneamente os maiores volumes de falsos positivos e falsos negativos, reflexo da sobreposição biológica com as classes adjacentes do espectro glicêmico. O *pipeline* vencedor é o mesmo da Tarefa 1, o (C1) MLP + Std + MinMax, o que confirma a consistência dessa configuração como a de melhor desempenho global entre as avaliadas neste trabalho. A Tabela 5.8 apresenta os dez *pipelines* de melhor desempenho na Tarefa 2, ordenados pelo F2-Score macro nos dados de teste, com a respectiva estimativa de F2 na validação cruzada aninhada, na última coluna da tabela.

Tabela 5.8 – Dez melhores *pipelines* da Tarefa 2 (N vs. PD vs. D), ordenados por F2-Score macro. As colunas F2 a AUC-ROC referem-se ao conjunto de teste (*holdout* estratificado de 20%); a última coluna refere-se à validação cruzada aninhada (média $\pm$ desvio padrão dos 10 *outer folds*). Valores em negrito indicam o melhor desempenho em cada métrica.

Pipeline	Teste (<i>holdout</i> 20%)						CV aninhada
	F2	Recall	Precision	F1	AUC-PR	AUC-ROC	F2 Valid. ($\pm dp$)
(C1) MLP + Std + MinMax	0,551	0,556	0,545	0,546	0,571	0,756	0,475 $\pm$ 0,060
(C2) LightGBM	0,547	0,550	0,540	0,543	0,570	0,756	0,541 $\pm$ 0,006
(C2) Random Forest	0,546	0,548	0,541	0,544	0,568	0,756	0,540 $\pm$ 0,006
(C1) Gradient Boosting + MinMax	0,544	0,551	0,536	0,538	0,566	0,753	0,537 $\pm$ 0,006
(C2) HistGradientBoosting	0,544	0,546	0,540	0,542	0,573	0,758	0,539 $\pm$ 0,005
(C1) Bagging + Std	0,544	0,545	0,539	0,541	0,563	0,752	0,537 $\pm$ 0,007
(C3) Bagging + RUS	0,543	0,550	0,536	0,536	0,556	0,745	0,536 $\pm$ 0,006
(C1) Bagging + MinMax	0,543	0,544	0,538	0,540	0,559	0,749	0,536 $\pm$ 0,007
(C1) Bagging + Std + MinMax	0,542	0,544	0,537	0,540	0,559	0,749	0,536 $\pm$ 0,007
(C3) XGBoost + SMOTETomek	0,542	0,547	0,533	0,536	0,567	0,754	0,536 $\pm$ 0,005

Fonte: Elaborado pelo autor.

A amplitude de F2 entre os dez melhores *pipelines* da Tarefa 2 foi de apenas 0,9 ponto percentual (de 0,551 a 0,542), indicando estabilidade no desempenho das configurações mais bem posicionadas. Contudo, diferentemente da Tarefa 1, na qual a variação de AUC-ROC entre os top-10 era de 0,011, na Tarefa 2 a AUC-ROC apresenta variação de 0,013 (de 0,745 a 0,758), e a AUC-PR varia de 0,556 a 0,573, sugerindo que as métricas baseadas em probabilidade são ligeiramente mais dispersas no problema multiclasse.


Tabela 5.9 – Desempenho por classe do *pipeline* vencedor da Tarefa 2, nos dados de teste.

Classe	F2	Recall	Precision
Normal	0,669	0,648	0,768
Pré-diabético	0,437	0,443	0,417
Diabético	0,547	0,578	0,449
Macro	0,551	0,556	0,545

Fonte: Elaborado pelo autor.

A Tabela 5.9 detalha o desempenho por classe do *pipeline* vencedor nos dados de teste. Entre as três classes do problema, o melhor F2 foi obtido para a classe Normal (0,669), seguida da classe Diabético (0,547) e, por último, da classe Pré-diabético (0,437). A classe Normal apresenta a maior Precisão (0,768), enquanto a classe Pré-diabético obteve tanto o menor *Recall* (0,443) quanto a menor Precisão (0,417), concentrando a principal dificuldade preditiva do problema multiclasse.


Figura 5.12 – Matriz de confusão detalhada do *pipeline* vencedor da Tarefa 2 ((C1) MLP + Std + MinMax) nos dados de teste, com contagens absolutas e proporções relativas às linhas (classe real).



Fonte: Elaborado pelo autor.

A matriz de confusão da Figura 5.12 mostra que a classe Pré-diabético apresentou taxa de erro de 55,7%, com dispersão bidirecional para as classes vizinhas, com 56,5% dos erros direcionados para Diabético e 43,5% para Normal. Além disso, 23,6% dos indivíduos normais e 28,9% dos diabéticos foram classificados como Pré-diabético, o que evidencia que a confusão é bidirecional, com a classe Pré-diabético tanto perdendo instâncias para as classes vizinhas quanto recebendo instâncias incorretamente classificadas a partir delas. Conforme será discutido na Subseção 5.3.4.1, os erros de classificação concentram-se nas faixas de hemoglobina glicada próximas aos limiares de diagnóstico (5,7% e 6,5%), onde as classes são adjacentes na escala contínua de A1c e os perfis hematológicos dos indivíduos de classes vizinhas são mais semelhantes entre si. Em termos de risco clínico, os 3.334 falsos negativos ($PD \rightarrow N$, 2.386; $D \rightarrow N$, 948) representam 19,6% dos indivíduos com alteração glicêmica no conjunto de teste, correspondendo a instâncias que o modelo classificou como Normal quando na realidade apresentavam pré-diabetes ou diabetes.

Figura 5.13 – Distribuição das probabilidades previstas pelo *pipeline* vencedor da Tarefa 2, estratificada por classe real (Normal, Pré-diabético, Diabético), nos dados de teste. Cada painel apresenta a distribuição das probabilidades previstas para uma das três classes de saída, com cores indicando a classe real do indivíduo.




Fonte: Elaborado pelo autor.

A Figura 5.13 apresenta a distribuição das probabilidades previstas pelo *pipeline* vencedor para cada uma das três classes de saída, estratificada pela classe real do indivíduo. No painel esquerdo (P(Normal)), as distribuições das três classes reais apresentam separação parcial, com os indivíduos realmente Normais concentrados em probabilidades mais altas (0,40 a 0,80) e os indivíduos Diabéticos concentrados em probabilidades mais baixas (0,10 a 0,30), enquanto os Pré-diabéticos se distribuem de forma intermediária. No painel central (P(Pré-diabético)), observa-se elevada sobreposição entre as três classes reais, com as distribuições de Normal, Pré-diabético e Diabético concentradas na mesma faixa de probabilidade (0,20 a 0,45), o que evidencia a dificuldade do modelo em atribuir probabilidades discriminativas para a classe Pré-diabético. No painel direito

(P(Diabético)), a separação entre classes é parcial, com os indivíduos Diabéticos concentrados em probabilidades mais altas e os Normais em probabilidades mais baixas, mas com sobreposição na região central (0,20 a 0,40) onde os Pré-diabéticos também se acumulam.

Figura 5.14 – Curvas ROC e Precisão-Recall da Tarefa 2, nos dados de teste. Linha superior: curvas *macro-average* dos cinco *pipelines* de melhor desempenho. Linha inferior: curvas *one-vs-rest* por classe (Normal, Pré-diabético, Diabético) do *pipeline* vencedor ((C1) MLP + Std + MinMax).



Fonte: Elaborado pelo autor.

A Figura 5.14 apresenta, na linha superior, as curvas ROC e Precisão-Recall *macro-average* dos cinco *pipelines* de melhor desempenho na Tarefa 2, e, na linha inferior, as curvas *one-vs-rest* por classe do *pipeline* vencedor. O AUC-ROC macro do *pipeline* vencedor foi de 0,756 e o AUC-PR macro foi de 0,571, valores consistentemente inferiores aos observados na Tarefa 1 (AUC-ROC = 0,801; AUC-PR = 0,780). Nas curvas *one-vs-rest* por classe (painéis inferiores), a classe Normal apresenta a melhor discriminação (AUC-ROC = 0,801; AUC-PR = 0,619), seguida da classe Diabético (AUC-ROC = 0,791; AUC-PR = 0,496), enquanto a classe Pré-diabético apresenta as curvas mais próximas da diagonal (AUC-ROC = 0,676; AUC-PR = 0,416).

5.3.2 Estabilidade e Validação Cruzada Aninhada

O F2 macro do *pipeline* vencedor nos dados de teste (0,551) é 0,076 superior à média de validação da validação cruzada aninhada ($0,475 \pm 0,060$). A diferença entre o F2 médio de treino ($0,566 \pm 0,063$) e o F2 médio de validação ($0,475 \pm 0,060$) na validação cruzada aninhada foi de 0,091, valor superior ao observado na Tarefa 1 (0,000) e acompanhado de desvio padrão elevado entre *folds* (0,060), o que evidencia maior variabilidade no desempenho do modelo multiclasse entre as diferentes partições dos dados. Assim como na Tarefa 1, o F2 de teste superior à média de validação da validação cruzada aninhada é esperado pelo fato de o modelo final ter sido treinado sobre a totalidade dos dados de treino (80% do *dataset*), enquanto cada *outer fold* utilizou aproximadamente 72%, conforme descrito por Varma and Simon (2006). Os valores de F2 macro em validação cruzada aninhada para os dez *pipelines* de melhor desempenho da Tarefa 2 estão consolidados na Tabela 5.8 (coluna “F2 Valid.”), permitindo comparar a estabilidade entre as configurações.


5.3.3 Impacto dos Atributos Preditivos

5.3.3.1 Importância Global

A transição do problema binário (Tarefa 1) para o problema ternário (Tarefa 2) altera o perfil de relevância dos atributos preditivos, uma vez que o modelo passa a discriminar simultaneamente três classes com fronteiras de decisão sobrepostas. No problema ternário da Tarefa 2, o RDW, que ocupava a 6ª posição na Tarefa 1, ocupa a 13ª posição por SHAP na Tarefa 2 (e a 5ª por permutação, a maior divergência entre os dois métodos), enquanto atributos da série vermelha, como Hemoglobina e Hematócrito, ganham maior contribuição. A Figura 5.15 apresenta o resumo dos valores SHAP e Figura 5.16 apresenta a comparação entre os dois métodos de importância.

A Tabela 5.10 apresenta os dez atributos mais influentes na Tarefa 2 com suas respectivas posições nos dois métodos e a comparação com a Tarefa 1. A Idade permanece como o atributo mais relevante em ambos os métodos (1ª posição), mas sua contribuição SHAP relativa diminui de 0,212 na Tarefa 1 para 0,142 na Tarefa 2, enquanto atributos como Hemoglobina (de 10ª para 7ª) e Hematócrito (ausente do top-10 na T1, 8ª na T2) ganham posições. Contudo, a correlação entre os rankings de importância foi menor na


Figura 5.15 – Resumo dos valores SHAP para o *pipeline* vencedor da Tarefa 2 (C1 - MLP + Std + MinMax), considerando as três classes simultaneamente.



Fonte: Elaborado pelo autor.

Tarefa 2 ($\rho = 0,889$) do que na Tarefa 1 ($\rho = 0,975$), e a maior divergência ocorreu no RDW (13ª posição por SHAP vs. 5ª por permutação, diferença de 8 posições), o que evidencia que a complexidade adicional do problema ternário introduz maior discordância entre os métodos de explicabilidade.

Figura 5.16 – Comparação entre o *ranking* de importância por SHAP e por permutação para o *pipeline* vencedor da Tarefa 2. Correlação de Spearman $\rho = 0,889$.



Fonte: Elaborado pelo autor.

Tabela 5.10 – Dez atributos mais influentes do *pipeline* vencedor da Tarefa 2, ordenados pelo valor SHAP. A coluna “Rank T1” indica a posição do mesmo atributo na Tarefa 1 para comparação.


Atributo	SHAP	Permutação	Rank SHAP	Rank Perm.	Rank T1
Idade	0,14212	0,16467	1	1	1
Leucócitos	0,05400	0,02191	2	2	2
Linfócitos	0,03717	0,01223	3	4	3
HCM	0,03619	0,01008	4	6	5
Sexo	0,02700	0,01504	5	3	4
MPV	0,02356	0,00563	6	8	7
Hemoglobina	0,02156	0,00608	7	7	10
Hematócrito	0,01871	0,00433	8	11	—
Monócitos	0,01664	0,00441	9	10	—
Segmentados	0,01440	0,00098	10	14	—

Fonte: Elaborado pelo autor.

5.3.3.2 Interpretabilidade por Instância

A Figura 5.17 apresenta explicações SHAP individuais para duas predições do *pipeline* vencedor da Tarefa 2, uma predição corretamente classificada como Diabético e uma predição incorreta (falso negativo, Diabético classificado como Normal).

Figura 5.17 – Gráficos de cascata SHAP para duas predições individuais do *pipeline* vencedor da Tarefa 2. Cada barra indica a contribuição de um atributo para a predição da instância.



(a) Verdadeiro Positivo (Diabético→Diabético).

(b) Falso Negativo (Diabético→Normal).

Fonte: Elaborado pelo autor.


Na Figura 5.17a, um indivíduo de 70 anos com 3.050 Linfócitos e 7.400 Leucócitos obteve predição $f(x) = 0,484$ para a classe Diabético, com as contribuições positivas dominantes vindas da Idade (+0,22), dos Linfócitos (+0,08) e do MPV (+0,04). Na Figura 5.17b, um indivíduo de 23 anos com 5,74 Eritrócitos obteve predição $f(x) = -0,188$ e foi incorretamente classificado como Normal, sendo a Idade baixa a principal contribuição negativa (-0,27), seguida dos Eritrócitos (+0,04) e dos Linfócitos (+0,03) como contribuições positivas insuficientes para compensar o efeito dominante da Idade. O contraste entre os dois casos evidencia que a Idade é o atributo com maior capacidade de deslocar a predição em ambas as direções, tanto contribuindo para a classificação correta de indivíduos idosos quanto induzindo erros em indivíduos jovens.

5.3.4 Análise de Erros

5.3.4.1 Padrão dos Erros por Faixa de Hemoglobina Glicada

A Figura 5.18 apresenta a distribuição dos erros do *pipeline* vencedor da Tarefa 2 por faixa de A1c, estratificada pelas três classes reais. No painel superior esquerdo (indivíduos realmente Normais), observa-se que a classificação correta como Normal predo-

Figura 5.18 – Predições do *pipeline* vencedor da Tarefa 2 por faixa de hemoglobina glicada, estratificadas por classe real (Normal, Pré-diabético, Diabético), nos dados de teste. Cada painel mostra a proporção de predições por classe de saída para cada faixa de A1c. As linhas verticais indicam os limiares de diagnóstico da Organização Mundial da Saúde (5,7% e 6,5%).



Fonte: Elaborado pelo autor.


mina nas faixas de A1c mais baixas (<5,4%) e diminui progressivamente à medida que a A1c se aproxima do limiar de 5,7%, onde uma parcela crescente de indivíduos Normais é incorretamente classificada como Pré-diabético. No painel superior direito (indivíduos realmente Pré-diabéticos), os erros ocorrem em ambas as direções ao longo de toda a faixa de A1c entre 5,7% e 6,5%, com parcelas comparáveis de predições incorretas para Normal e para Diabético. No painel inferior (indivíduos realmente Diabéticos), a classificação correta como Diabético predomina nas faixas de A1c mais altas (>7,0%), enquanto nas faixas próximas ao limiar de 6,5% uma parcela dos indivíduos Diabéticos é classificada como Pré-diabético. O pico de falsos positivos (36,6%) está concentrado na faixa 5,4 a 5,7%, imediatamente abaixo do limiar Normal/Pré-diabético (5,7%), enquanto o maior

índice de falsos negativos (25,1%) ocorre na faixa 5,7 a 6,0%, logo acima desse mesmo limiar.

5.3.4.2 Análise de Erros por Sexo

A análise das diferenças de desempenho preditivo por sexo apresentou F2 macro de 0,562 (feminino) vs. 0,512 (masculino), com diferença de 5,0 pontos percentuais e AUC-ROC macro de 0,771 vs. 0,720, conforme a Tabela 5.11 e a Figura 5.19. Na Figura 5.19, o painel direito mostra que a taxa de falsos negativos é comparável entre os subgrupos, enquanto a taxa de falsos positivos é mais elevada no subgrupo masculino, o que contribui para o menor F2 observado nesse subgrupo.

Figura 5.19 – Análise de erros do *pipeline* vencedor da Tarefa 2 por sexo, nos dados de teste. Esquerda: composição dos erros por sexo. Direita: taxas de FN e FP por sexo.



Fonte: Elaborado pelo autor.

Tabela 5.11 – Desempenho do *pipeline* vencedor da Tarefa 2 estratificado por sexo, nos dados de teste.


Sexo	N	F2 Macro	Bal. Acc.	AUC-ROC Macro
Feminino	87 424	0,562	0,569	0,771
Masculino	48 575	0,512	0,523	0,720

Fonte: Elaborado pelo autor.

5.3.4.3 Análise de Erros por Faixa Etária

O F2 macro na Tarefa 2 variou de 0,369 na faixa <40 anos a 0,497 na faixa 40–60 anos, com redução para 0,400 na faixa >60 anos, conforme a Tabela 5.12. A taxa de falsos negativos clínicos, apresentada na Figura 5.20, foi de 95,6% na faixa <40 anos, 53,8% na

Figura 5.20 – Análise de erros do *pipeline* vencedor da Tarefa 2 por faixa etária, nos dados de teste. Esquerda: composição dos erros por faixa etária. Direita: taxa de falsos negativos clínicos por faixa etária.



Fonte: Elaborado pelo autor.

Tabela 5.12 – Desempenho do *pipeline* vencedor da Tarefa 2 estratificado por faixa etária, nos dados de teste.

Faixa	N	Acurácia	Bal. Acc.	F2 Macro	AUC-ROC Macro
<40	9 010	0,815	0,371	0,369	0,713
40–60	13 395	0,514	0,501	0,497	0,696
>60	11 595	0,456	0,423	0,400	0,655

Fonte: Elaborado pelo autor.

faixa 40–60 anos e 29,4% na faixa >60 anos. Na Tarefa 2, o F2 macro na faixa >60 anos (0,400) é inferior ao da faixa 40–60 anos (0,497), o que contrasta com a Tarefa 1 onde o desempenho aumentava de forma progressiva com a faixa etária, e está associado à maior dificuldade do modelo ternário em distinguir entre as classes Pré-diabético e Diabético na faixa etária com maior prevalência de ambas as condições.

5.4 Tarefa 3: Decomposição em Subproblemas Binários

Nesta seção são apresentados os resultados da Tarefa 3, na qual o problema multiclasse é decomposto em seis subproblemas binários com fronteiras de decisão distintas, abrangendo o desempenho consolidado, a estabilidade na validação cruzada aninhada, o impacto dos atributos preditivos e a análise de erros por subgrupo.

5.4.1 Desempenho dos Modelos

A estratégia implementada na Tarefa 3 avalia seis fronteiras de decisão, e, como esperado, as tarefas envolvendo classes mais distintas (N vs. D; N vs. PD) apresentaram os maiores F2-Scores, enquanto as fronteiras mais próximas (PD vs. D; N+PD vs. D) apresentaram os menores. Modelos com SMOTEENN foram os melhores nos modelos da Tarefa 3 (5 de 6 subproblemas), superando configurações com outras técnicas de balanceamento (*class_weight*, *Random Undersampling*), com ganhos de 1,2 a 4,4 p.p. em F2 e 6,2 a 8,9 p.p. em *Recall*. A exceção foi o subproblema NxPD+D, cujo *pipeline* vencedor é da categoria *Template* (MLP com Std+MinMax), e cujos resultados completos foram apresentados na Seção 5.2 como Tarefa 1. Em cada subproblema foram avaliados os mesmos 28 *pipelines* descritos no Capítulo 4, totalizando 168 configurações treinadas e avaliadas na Tarefa 3.

Tabela 5.13 – Desempenho dos seis subproblemas binários da Tarefa 3. As colunas F2 a AUC-ROC referem-se ao conjunto de teste (*holdout* estratificado de 20%); a última coluna refere-se à validação cruzada aninhada (média $\pm$ desvio padrão dos 10 *outer folds*). Linhas em destaque correspondem aos subproblemas detalhados nesta seção.

Subproblema	Descrição	Pipeline	Teste (<i>holdout</i> 20%)					CV aninhada F2 Valid. ($\pm$ dp)
			F2	Recall	Prec.	AUC-PR	AUC-ROC	
NxD	N vs. D	MLP (QT+SMOTEENN)	0,770	0,877	0,517	0,686	0,852	0,769 $\pm$ 0,007
NxPD	N vs. PD	MLP (QT+SMOTEENN)	0,750	0,847	0,513	0,616	0,764	0,747 $\pm$ 0,009
PDxD	PD vs. D	MLP (QT+SMOTEENN)	0,697	0,762	0,518	0,592	0,681	0,688 $\pm$ 0,011
PDxN+D	PD vs. N+D	MLP (QT+SMOTEENN)	0,671	0,850	0,364	0,417	0,677	0,669 $\pm$ 0,005
N+PDxD	N+PD vs. D	MLP (QT+SMOTEENN)	0,650	0,851	0,335	0,456	0,780	0,647 $\pm$ 0,005
NxPD+D [†]	N vs. PD+D	MLP (Std+MinMax)	0,793	0,824	0,689	0,780	0,801	0,763 $\pm$ 0,018

[†] Equivalente à Tarefa 1; resultados detalhados na Seção 5.2.

Fonte: Elaborado pelo autor.

A Tabela 5.13 consolida o desempenho dos seis subproblemas nos dados de teste e na validação cruzada aninhada. A hierarquia de F2 segue a ordem NxPD+D (0,793) > NxD (0,770) > NxPD (0,750) > PDxD (0,697) > PDxN+D (0,671) > N+PDxD (0,650), com o maior Recall registrado no subproblema NxD (0,877) e a maior AUC-ROC também no NxD (0,852). Os subproblemas que envolvem classes nos extremos do espectro de hemoglobina glicada (NxD, com A1c < 5,7% vs. A1c $\geq$ 6,5%) obtiveram F2 e AUC-ROC superiores aos que envolvem classes adjacentes na escala (PDxD, com A1c entre 5,7% e 6,5% vs. A1c $\geq$ 6,5%). Os subproblemas NxPD e N+PDxD são reportados apenas nesta tabela consolidada, e os resultados completos encontram-se nos respectivos notebooks oficiais.

As subseções seguintes apresentam os resultados detalhados de três subproblemas de maior relevância para a pesquisa: NxD (fronteira mais facilmente separável entre Nor-

mal e Diabético), PDxD (fronteira mais difícil, entre as classes adjacentes Pré-diabético e Diabético) e PDxN+D (avaliação do isolamento da classe Pré-diabético como classe positiva frente a uma classe composta por Normal e Diabético).

Tabela 5.14 – Cinco melhores *pipelines* de cada subproblema detalhado da Tarefa 3, ordenados por F2-Score. As colunas F2 a AUC-ROC referem-se ao conjunto de teste (*holdout* estratificado de 20%). Valores em negrito indicam o melhor desempenho em cada métrica dentro de cada subproblema.


Subproblema	Pipeline	Teste (<i>holdout</i> 20%)					
		F2	Recall	Precision	F1	AUC-PR	AUC-ROC
NxD	(C3) MLP + Quantile + SMOTEENN	0,770	0,877	0,517	0,651	0,686	0,852
NxD	(C1) MLP + Std + MinMax	0,746	0,809	0,570	0,669	0,698	0,854
NxD	(C3) Bagging + RUS	0,746	0,807	0,574	0,671	0,690	0,852
NxD	(C3) CatBoost + ClassWeight	0,745	0,809	0,565	0,665	0,698	0,852
NxD	(C2) XGBoost	0,738	0,800	0,564	0,661	0,695	0,849
PDxD	(C3) MLP + Quantile + SMOTEENN	0,697	0,762	0,518	0,617	0,592	0,681
PDxD	(C1) MLP + Std + MinMax	0,659	0,700	0,533	0,605	0,595	0,680
PDxD	(C3) Random Forest + SMOTEENN	0,630	0,667	0,517	0,582	0,565	0,656
PDxD	(C3) Bagging + RUS	0,623	0,642	0,557	0,596	0,603	0,689
PDxD	(C2) MLP	0,618	0,637	0,551	0,591	0,601	0,682
PDxN+D	(C3) MLP + Quantile + SMOTEENN	0,671	0,850	0,364	0,510	0,417	0,677
PDxN+D	(C3) Random Forest + SMOTEENN	0,670	0,841	0,369	0,513	0,413	0,673
PDxN+D	(C3) CatBoost + ClassWeight	0,640	0,768	0,384	0,512	0,420	0,681
PDxN+D	(C1) AdaBoost + MinMax	0,615	0,721	0,387	0,503	0,393	0,663
PDxN+D	(C1) MLP + Std + MinMax	0,613	0,709	0,398	0,510	0,426	0,682

Fonte: Elaborado pelo autor.

A Tabela 5.14 apresenta os cinco *pipelines* de melhor desempenho em cada um dos três subproblemas detalhados. O (C3) MLP + Quantile + SMOTEENN (MLP com QuantileTransformer e SMOTEENN) é o vencedor nos três subproblemas, com vantagem de 2,4 pontos percentuais sobre o segundo colocado em NxD, 3,8 em PDxD e apenas 0,1 em PDxN+D. A amplitude de F2 entre os cinco melhores *pipelines* varia de 3,2 pontos percentuais em NxD a 7,9 em PDxD, indicando que a fronteira PDxD é não apenas a de menor desempenho absoluto, mas também a de maior dispersão entre configurações. Esse resultado reforça o padrão observado nas Tarefas 1 e 2, nas quais o *pipeline* da categoria *Template* (MLP com Std+MinMax) foi o vencedor nos problemas de maior complexidade estrutural, enquanto o *pipeline* da categoria *Experimental* (MLP com QuantileTransformer e SMOTEENN) obteve melhor desempenho nos subproblemas binários decompostos da Tarefa 3.

A Figura 5.21 apresenta as matrizes de confusão detalhadas dos *pipelines* vencedores dos três subproblemas. No subproblema NxD (Figura 5.21a), o modelo classificou corretamente 86,9% dos indivíduos Diabéticos (24.795 TP) e 67,3% dos Normais (45.827 TN), com 3.742 falsos negativos (13,1%) e 22.309 falsos positivos (32,7%). No subproblema PDxD (Figura 5.21b), a confusão é mais equilibrada: 75,0% dos Diabéticos fo-


Figura 5.21 – Matrizes de confusão detalhadas dos *pipelines* vencedores dos três subproblemas detalhados da Tarefa 3, nos dados de teste, com contagens absolutas e proporções relativas às linhas (classe real).



Fonte: Elaborado pelo autor.

ram corretamente identificados (21.411 TP), mas apenas 49,2% dos Pré-diabéticos foram classificados corretamente como negativos (19.329 TN), com 50,8% de falsos positivos (19.996). No subproblema PDxN+D (Figura 5.21c), o Recall para Pré-diabéticos foi de 85,0% (33.428 TP), porém acompanhado de 61,1% de falsos positivos (59.048) na classe composta N+D, resultando de precisão mais baixa entre todos os subproblemas (0,364).

Figura 5.22 – Análise de erros dos *pipelines* vencedores nos subproblemas Nx D e PDx D da Tarefa 3, nos dados de teste. Cada linha apresenta a distribuição de probabilidades por tipo de predição (esquerda), a contagem por tipo (centro) e as taxas de erro em função do limiar de decisão (direita).



Fonte: Elaborado pelo autor.

A Figura 5.22 permite comparar a distribuição de probabilidades entre a fronteira mais fácil (Nx D) e a mais difícil (PDx D). No subproblema Nx D (Figura 5.22a), as dis-

tribuições de verdadeiros positivos e verdadeiros negativos apresentam separação visível, com os TP concentrados em probabilidades altas ($>0,5$) e os TN em probabilidades baixas ($<0,3$). No subproblema PDxD (Figura 5.22b), as distribuições se sobrepõem na faixa de 0,3 a 0,7, com os quatro tipos de predição (TP, TN, FP, FN) coexistindo na mesma região de probabilidade, o que evidencia a dificuldade do modelo em estabelecer uma fronteira de decisão entre Pré-diabético e Diabético. Nos painéis direitos de ambas as figuras, as curvas de taxa de FN e taxa de FP em função do limiar de decisão se cruzam em aproximadamente 0,78 no Nx D e 0,66 no PDxD, indicando que o ponto de equilíbrio entre os dois tipos de erro exige um limiar superior ao padrão de 0,50 em ambos os subproblemas, com o PDxD apresentando taxas de erro mais elevadas no ponto de cruzamento.

A Figura 5.23 apresenta as curvas ROC e Precisão-*Recall* do subproblema Nx D, que obteve a maior AUC-ROC (0,852) e a segunda maior AUC-PR (0,686) entre os seis subproblemas. As demais curvas ROC e PR dos subproblemas PDxD e PDxN+D apresentam comportamento progressivamente menos favorável, com AUC-ROC de 0,681 e 0,677 respectivamente, conforme os valores reportados na Tabela 5.13.

5.4.2 Estabilidade e Validação Cruzada Aninhada


Tabela 5.15 – Estabilidade do F2-Score dos *pipelines* vencedores dos cinco subproblemas da Tarefa 3 (excluindo NxPD+D, já reportado na Seção 5.2), nas fases de treino e validação da validação cruzada aninhada (10 *outer folds*) e no conjunto de teste.

Subproblema	F2 Treino CV ($\pm dp$)	F2 Valid. CV ($\pm dp$)	F2 Teste	Δ Treino-Valid.
NxD	0,782 $\pm$ 0,003	0,769 $\pm$ 0,007	0,770	0,013
NxPD	0,753 $\pm$ 0,003	0,747 $\pm$ 0,009	0,750	0,006
PDxD	0,700 $\pm$ 0,007	0,688 $\pm$ 0,011	0,697	0,012
PDxN+D	0,681 $\pm$ 0,002	0,669 $\pm$ 0,005	0,671	0,012
N+PDxD	0,666 $\pm$ 0,002	0,647 $\pm$ 0,005	0,650	0,019

Fonte: Elaborado pelo autor.

A Tabela 5.15 apresenta a estabilidade do F2-Score nas fases de treino e validação da validação cruzada aninhada para os cinco subproblemas da Tarefa 3 (excluindo NxPD+D, já reportado na Seção 5.2). A diferença entre F2 de treino e validação variou de 0,006 (NxPD) a 0,019 (N+PDxD), permanecendo abaixo de 0,020 em todos os subproblemas, o que confirma ausência de sobreajuste. O desvio padrão entre *folds* de validação variou de 0,005 a 0,011, valores na mesma faixa observada na Tarefa 1 ($\pm 0,018$) e substancialmente inferiores aos da Tarefa 2 ($\pm 0,060$), indicando que os subproblemas binários da Tarefa 3 apresentam maior estabilidade entre partições do que o problema multiclasse.

Figura 5.23 – Curvas ROC e Precisão-Recall para todos os *pipelines* avaliados no subproblema NxN (N vs. D) da Tarefa 3, nos dados de teste.



Fonte: Elaborado pelo autor.

5.4.3 Impacto dos Atributos Preditivos

A Tabela 5.16 apresenta os cinco atributos mais influentes de cada subproblema, segundo os valores SHAP, com a posição correspondente no *ranking* por permutação indicada entre parênteses. A Idade ocupa a 1ª posição em três dos cinco subproblemas (NxD, NxPD e PDxD), mas cede o 1º lugar para Leucócitos nos subproblemas N+PDxD e PDxN+D, nos quais a discriminação entre classes adjacentes na escala de A1c depende de atributos diferentes do fator etário. Hemoglobina aparece entre os cinco mais relevantes em três subproblemas (N+PDxD, PDxD e PDxN+D), mas está ausente do top-5 em NxD e NxPD. Segmentados aparece exclusivamente nos subproblemas N+PDxD (4ª posição) e PDxN+D (2ª posição), ambos envolvendo a classe Pré-diabético como parte da fronteira de decisão. As maiores divergências entre os *rankings* de SHAP e permutação ocorreram nos atributos Eritrócitos (3ª posição por SHAP vs. 21ª por permutação no NxD), Hematócrito (5ª vs. 23ª no N+PDxD) e Segmentados (2ª vs. 15ª no PDxN+D), evidenciando que a concordância entre os dois métodos varia conforme a fronteira de decisão.

Tabela 5.16 – Cinco atributos mais influentes (por SHAP) do *pipeline* vencedor de cada subproblema da Tarefa 3 (excluindo NxPD+D). O *ranking* por permutação é indicado entre parênteses.


Rank	NxD	NxPD	N+PDxD	PDxD	PDxN+D
1	Idade (1)	Idade (1)	Leucócitos (1)	Idade (2)	Leucócitos (3)
2	Leucócitos (2)	Linfócitos (2)	Idade (2)	Leucócitos (1)	Segmentados (15)
3	Eritrócitos (21)	RDW (3)	Hemoglobina (5)	Hemoglobina (5)	Idade (1)
4	Linfócitos (7)	CHCM (7)	Segmentados (3)	HCM (4)	Linfócitos (22)
5	HCM (5)	Eritrócitos (6)	Hematócrito (23)	RDW (10)	Hemoglobina (16)

Fonte: Elaborado pelo autor.

A Figura 5.24 contrasta os resumos SHAP das fronteiras mais fácil (NxD) e mais difícil (PDxD). No subproblema NxD (Figura 5.24a), a Idade apresenta contribuição SHAP com magnitude 3 a 5 vezes superior à do segundo atributo (Leucócitos), dominando a predição de forma concentrada. No subproblema PDxD (Figura 5.24b), a Idade permanece como o atributo mais influente, mas as contribuições de Leucócitos, Hemoglobina e HCM são proporcionalmente maiores, indicando que a discriminação entre Pré-diabético e Diabético depende de um conjunto mais amplo de parâmetros hematológicos.

A Figura 5.25 compara instâncias de falso negativo nos dois subproblemas. No FN do NxD (Figura 5.25a), um indivíduo Diabético de 51 anos com HCM=101 foi incorretamente classificado como Normal, com HCM contribuindo $-0,13$, Leucócitos $-0,11$ e Hemoglobina $-0,10$. No FN do PDxD (Figura 5.25b), um indivíduo Diabético com

Figura 5.24 – Resumo dos valores SHAP para os *pipelines* vencedores dos subproblemas Nx D e PDxD da Tarefa 3, nos dados de teste. Em Nx D a Idade domina com magnitude 3 a 5 vezes superior aos demais; em PDxD as contribuições são mais distribuídas entre Idade, Leucócitos, Hemoglobina e HCM.



Fonte: Elaborado pelo autor.


CHCM=32,5 foi incorretamente classificado como Pré-diabético, com CHCM contribuindo $-0,17$, HCM $-0,14$ e Leucócitos $-0,12$. Em ambos os casos, os atributos que mais contribuíram para a classificação incorreta são da série vermelha e branca do hemograma, mas a combinação específica de atributos varia conforme a fronteira de decisão.

5.4.4 Análise de Erros

A Tabela 5.17 apresenta o F2 estratificado por sexo para os cinco subproblemas. O subproblema PDxD apresenta a maior disparidade entre subgrupos (6,3 pontos percentuais, $F2=0,725$ feminino vs. $0,788$ masculino), enquanto o subproblema PDxN+D apresenta disparidade nula ($F2=0,850$ para ambos os subgrupos). Nos demais subproblemas, a diferença variou de 1,2 (NxPD) a 2,9 pontos percentuais (N+PDxD), com o subgrupo masculino obtendo F2 superior em todos os casos.

A Figura 5.26 apresenta a análise de erros por faixa etária dos subproblemas Nx D e PDxD. No subproblema Nx D (Figura 5.26a), o padrão é semelhante ao observado na Tarefa 1, com taxa de falsos negativos alta na faixa <40 anos e desempenho progressivamente melhor nas faixas mais elevadas. No subproblema PDxD (Figura 5.26b), a taxa de falsos negativos é elevada em todas as faixas etárias, com menor variação entre os subgrupos.

Figura 5.25 – Gráficos de cascata SHAP para instâncias de falso negativo nos subproblemas Nx D e PDxD da Tarefa 3, nos dados de teste.



(a) FN no Nx D (Diabético → Normal).

(b) FN no PDxD (Diabético → Pré-diabético).

Fonte: Elaborado pelo autor.

Tabela 5.17 – Desempenho (F2) do *pipeline* vencedor de cada subproblema da Tarefa 3, estratificado por sexo, nos dados de teste.

Subproblema	F2 Feminino	F2 Masculino	Δ (pp)
NxD	0,862	0,879	1,7
NxPD	0,834	0,846	1,2
N+PDxD	0,829	0,858	2,9
PDxD	0,725	0,788	6,3
PDxN+D	0,850	0,850	0,0


Fonte: Elaborado pelo autor.

Os classificadores binários especializados apresentados nesta seção constituem a base para a composição do *ensemble* heterogêneo da Tarefa 4, cujos resultados são apresentados na Seção 5.5.


5.5 Tarefa 4: *Ensemble*

Esta seção apresenta os resultados da Tarefa 4, na qual seis classificadores binários especialistas da Tarefa 3 são combinados em um *ensemble* heterogêneo para resolver o problema multiclasse de classificação do status glicêmico. A seção abrange a composição do *ensemble* e a estratégia geral de agregação, a evolução das quatro versões de meta-agregação investigadas, o desempenho da configuração final (v4) por classe e a comparação direta com o *baseline* multiclasse da Tarefa 2.

Figura 5.26 – Análise de erros por faixa etária dos *pipelines* vencedores dos subproblemas NxD e PDxD da Tarefa 3, nos dados de teste. Esquerda: composição dos erros por faixa etária. Direita: taxa de falsos negativos clínicos por faixa etária.



(a) NxD (N vs. D).



(b) PDxD (PD vs. D).

Fonte: Elaborado pelo autor.

5.5.1 Composição e Estratégia

O *ensemble* heterogêneo é composto por seis classificadores binários especialistas, cada um treinado em um dos subproblemas da Tarefa 3 (N vs. PD+D, N vs. D, N vs. PD, PD vs. D, N+PD vs. D e PD vs. N+D). A configuração de cada especialista, incluindo algoritmo, família de modelo e métricas individuais nos dados de teste, encontra-se na Tabela 4.9 apresentada no Capítulo 4. A diversidade entre os especialistas é evidenciada pela presença de três famílias distintas: Redes Neurais (MLP), *Bagging* e *Gradient Boosting* (CatBoost).

Na primeira versão investigada (v1), os especialistas foram selecionados por classe-alvo, com dois classificadores designados para cada uma das três classes do problema multiclasse, conforme apresentado na Tabela 4.8 e consolidado na Tabela 4.10 do Capítulo 4. Nas versões subsequentes (v3 e v4), os especialistas foram re-selecionados sob um critério distinto, com um classificador por subproblema da Tarefa 3, totalizando os mesmos seis especialistas. A re-seleção foi motivada pela necessidade de prover ao meta-

aprendiz do *Stacking* um conjunto completo de meta-features cobrindo todas as fronteiras de decisão entre as três classes, em vez de apenas as fronteiras associadas a duas classes-alvo, seguindo o princípio de cobertura completa de fronteiras binárias adotado em arquiteturas de *Stacking* (WOLPERT, 1992; RIFKIN; KLAUTAU, 2004).

5.5.2 Evolução das Estratégias de Agregação

Quatro estratégias de agregação foram investigadas de forma iterativa, partindo de votação ponderada simples (v1) e culminando em *Stacking* não-linear com *passthrough* (v4). A Tabela 5.18 consolida o desempenho das cinco configurações avaliadas, ordenadas pela ordem cronológica de desenvolvimento. A Tabela 5.19 detalha o desempenho das três principais versões (v1, v3 e v4) estratificado por classe, possibilitando acompanhar a evolução do *ensemble* em cada classe do problema multiclasse.

Tabela 5.18 – Evolução das estratégias de agregação investigadas para o *ensemble* da Tarefa 4. As métricas referem-se ao conjunto de teste. A coluna "Especialistas" indica o conjunto de classificadores binários utilizados (Tabelas 4.8 e 4.9 do Capítulo 4). A linha em destaque (negrito) indica a configuração final adotada.

Versão	Estratégia	Especialistas	F2 macro	Recall macro	Precision macro	AUC-ROC
v1	<i>Soft Voting</i> ponderado por F2	v1 (2 por classe-alvo)	0,535	0,544	0,547	0,756
v2-A	<i>One-vs-Rest only</i>	v1 (2 por classe-alvo)	0,463	0,522	0,518	0,714
v2-B	<i>Gated One-vs-One</i>	v1 (2 por classe-alvo)	0,486	0,534	0,521	0,752
v3	<i>Stacking</i> (Reg. Logística)	v3/v4 (1 por subproblema)	0,545	0,554	0,537	0,763
v4	<i>Stacking</i> (HistGBT + <i>passthrough</i>)	v3/v4 (1 por subproblema)	0,551	0,557	0,543	0,766

Fonte: Elaborado pelo autor.

Tabela 5.19 – Desempenho per-classe das três principais versões do *ensemble* (v1, v3 e v4) nos dados de teste. As variantes v2-A e v2-B foram avaliadas apenas em métricas macro por se tratarem de testes iterativos de estratégias de agregação sem retreinamento dos especialistas; seu desempenho macro está reportado na Tabela 5.18.

Versão	Classe	N	F2	Recall	Precision	AUC-ROC
v1	Normal	17.034	0,583	0,544	0,813	0,800
	Pré-diabético	9.832	0,506	0,547	0,390	0,659
	Diabético	7.134	0,516	0,540	0,437	0,786
v3	Normal	17.034	0,673	0,653	0,767	0,803
	Pré-diabético	9.832	0,394	0,389	0,413	0,673
	Diabético	7.134	0,569	0,619	0,431	0,794
v4	Normal	17.034	0,670	0,649	0,769	0,804
	Pré-diabético	9.832	0,427	0,429	0,420	0,677
	Diabético	7.134	0,555	0,594	0,441	0,796

Fonte: Elaborado pelo autor.

A análise por classe da Tabela 5.19 revela o padrão de evolução do *ensemble*: entre v1 e v3, o F2 das classes extremas (Normal e Diabético) aumentou consistentemente

(Normal: +8,7 pp; Diabético: +5,3 pp), refletindo o efeito da inclusão do especialista N vs. D e da reorganização por subproblema (descrita na Seção 4.4.4). A classe Pré-diabético, por outro lado, apresentou redução de F2 entre v1 e v3 (−11,2 pp), acompanhada, contudo, de aumentos em Precision (+2,3 pp) e AUC-ROC (+1,4 pp), indicando que o desempenho elevado de Recall da v1 estava sustentado por classificações pouco discriminativas, provavelmente em decorrência da ausência de um classificador *One-vs-Rest* dedicado ao Pré-diabetes. A transição de v3 para v4 preservou os ganhos nas classes extremas e recuperou parte do F2 do Pré-diabetes (+3,3 pp), com acréscimos simultâneos em Recall (+4,0 pp), Precision (+0,8 pp) e AUC-ROC (+0,4 pp), consequências da adoção do meta-aprendiz não-linear (*HistGradientBoosting*) e do *passthrough* dos atributos originais.

A versão v1 utilizou *Soft Voting* com ponderação por F2-Score sobre seis especialistas selecionados por classe-alvo, conforme Kuncheva (2004), alcançando F2 macro de 0,535 e AUC-ROC de 0,756. Esta configuração serviu como ponto de partida para as iterações subsequentes.

As versões v2-A e v2-B mantiveram os mesmos seis especialistas binários da v1 (Tabela 4.8), variando exclusivamente a estratégia de agregação das predições, sem retreinamento dos modelos base. A versão v2-A adotou estratégia *One-vs-Rest only* (OvR-only), descartando os classificadores *One-vs-One* e estimando a probabilidade da classe Pré-diabetes como resíduo, conforme a formulação $P(\text{PD}) = 1 - P(\text{N}) - P(\text{D})$, com base em Rifkin and Klautau (2004). A versão v2-B (*Gated One-vs-One*) manteve os classificadores OvO, porém ponderou suas contribuições pela probabilidade conjunta dos pares de classes, estimada a partir dos classificadores OvR, conforme Galar et al. (2011) e Wu, Lin and Weng (2004). Ambas as variantes apresentaram F2 macro inferior ao da v1 (0,463 e 0,486, respectivamente), indicando que abordagens de correção mínima sem retreinamento dos especialistas eram insuficientes para superar o desempenho da votação ponderada original.

A versão v3 substituiu a votação por *Stacking*, conforme Wolpert (1992), utilizando Regressão Logística como meta-aprendiz e re-selecionando os especialistas para incluir um classificador por subproblema da Tarefa 3 (incluindo Nx D e PDxN+D, não utilizados na v1). As meta-features foram geradas por predição *out-of-fold* com *StratifiedKFold* de 10 partições. A v3 alcançou F2 macro de 0,545 e AUC-ROC de 0,763, superando a v1 em ambas as métricas e tornando-se a primeira versão a aproximar-se do desempenho do *baseline* T2.

A análise dos coeficientes da Regressão Logística meta-aprendiz da v3, reportada na Tabela 5.20, evidencia que cada classe do problema multiclasse recebe contribuições coerentes com a composição binária de cada especialista. Para a classe Normal, todos os seis especialistas apresentam coeficiente efetivo negativo, indicando que probabilidades elevadas da classe positiva de cada fronteira binária reduzem o escore atribuído à classe Normal, com maior magnitude para os especialistas NxPD+D ($-1,205$), NxD ($-0,861$) e PDxN+D ($-0,829$). Para a classe Pré-diabético, o especialista PDxN+D apresenta o coeficiente positivo de maior magnitude ($+1,529$), seguido de NxPD ($+0,815$) e do especialista N+PDxD com coeficiente negativo de $-0,804$, padrão que evidencia a centralidade das fronteiras que isolam o pré-diabetes em relação a indivíduos normais ou diabéticos. Para a classe Diabético, os especialistas NxD ($+1,223$) e N+PDxD ($+0,965$) apresentam as maiores contribuições positivas, ambos com a classe Diabético como classe positiva da fronteira binária. Esta distribuição interpretável dos pesos constitui uma vantagem específica do meta-aprendiz linear da v3 em relação ao meta-aprendiz não-linear da v4 (*HistGradientBoosting*), no qual a contribuição de cada especialista é menos diretamente acessível por meio dos parâmetros do modelo.

Tabela 5.20 – Coeficientes efetivos da Regressão Logística meta-aprendiz da v3, organizados por especialista binário (linha) e classe-alvo do problema multiclasse (coluna). Os valores correspondem à diferença $\beta_{p_1} - \beta_{p_0}$ entre os coeficientes das duas meta-features de cada especialista, refletindo o impacto efetivo da probabilidade predita pela fronteira binária sobre o escore da classe-alvo. Hiperparâmetros do meta-aprendiz: $C = 100,0$ com `class_weight=balanced`. Sinal positivo indica contribuição em direção à classe-alvo. Valores em negrito indicam o especialista de maior magnitude para cada classe.

Especialista	Normal	Pré-diabético	Diabético
NxPD+D	$-1,205$	$+0,623$	$+0,582$
NxD	$-0,861$	$-0,362$	$+1,223$
NxPD	$-0,548$	$+0,815$	$-0,267$
PDxD	$-0,400$	$-0,276$	$+0,676$
N+PDxD	$-0,162$	$-0,804$	$+0,965$
PDxN+D	$-0,829$	$+1,529$	$-0,700$

Elaborado pelo autor.

A versão v4 manteve a arquitetura de *Stacking* da v3, porém substituiu o meta-aprendiz linear (Regressão Logística) por *HistGradientBoosting* e adicionou os 23 atributos originais como *passthrough* ao espaço de entrada do meta-aprendiz, conforme Ting and Witten (1999). Esta configuração alcançou F2 macro de 0,551 e AUC-ROC de 0,766, sendo adotada como configuração final do *ensemble* heterogêneo deste trabalho.

5.5.3 Desempenho do Ensemble v4

O *ensemble* v4 apresentou F2 macro de 0,551, *Recall* macro de 0,557, Precisão macro de 0,543 e AUC-ROC de 0,766 nos dados de teste (34.000 registros). A Tabela 5.21 apresenta o desempenho do *ensemble* v4 estratificado por classe.

Tabela 5.21 – Desempenho do *ensemble* v4 por classe nos dados de teste (*holdout* estratificado de 20%). A coluna N indica o número de instâncias por classe.

Classe	N	F2	Recall	Precision	AUC-ROC
Normal	17.034	0,670	0,649	0,769	0,804
Pré-diabético	9.832	0,427	0,429	0,420	0,677
Diabético	7.134	0,555	0,594	0,441	0,796

Fonte: Elaborado pelo autor.

O desempenho mais elevado é observado na classe Normal (F2=0,670; AUC-ROC=0,804), com alta precisão (0,769) refletindo a baixa proporção de falsos positivos para essa classe. A classe Diabético apresenta F2=0,555 e *Recall* de 0,594, indicando que o *ensemble* consegue identificar a maioria dos indivíduos diabéticos do conjunto de teste. A classe Pré-diabético apresenta o menor F2 (0,427), refletindo a sobreposição da classe intermediária com as classes adjacentes (Normal e Diabético) no espaço de atributos, o que é consistente com os resultados observados nos subproblemas binários da Tarefa 3 envolvendo a classe Pré-diabetes.

5.5.4 Comparação com a Tarefa 2 (Baseline)

O desempenho do *ensemble* v4 foi comparado ao *baseline* da Tarefa 2 ((C1) MLP + Std + MinMax), classificador multiclasse direto. A Tabela 5.22 apresenta a comparação direta entre as duas abordagens, por classe e em termos de média macro.

Tabela 5.22 – Comparação per-classe entre o *ensemble* v4 e o *baseline* multiclasse da Tarefa 2 ((C1) MLP + Std + MinMax). Valores positivos em Δ indicam ganho do *ensemble* v4 sobre o *baseline*.

Classe	F2 T2	F2 v4	Δ F2 (pp)	AUC-ROC T2	AUC-ROC v4	Δ AUC (pp)
Normal	0,669	0,670	+0,1	0,800	0,804	+0,4
Pré-diabético	0,437	0,427	-1,0	0,659	0,677	+1,8
Diabético	0,547	0,555	+0,8	0,786	0,796	+1,0
Macro	0,551	0,551	-0,03	0,756	0,766	+0,97


Fonte: Elaborado pelo autor.

O *ensemble* v4 iguala o *baseline* T2 em F2 macro ($\Delta=-0,03$ pp, dentro do intervalo de confiança bootstrap) e supera T2 em AUC-ROC (+0,97 pp). A análise por classe

revela ganhos do *ensemble* sobre o *baseline* em duas das três classes em F2 (+0,1 pp em Normal e +0,8 pp em Diabético) e em todas as três classes em AUC-ROC (+0,4 pp em Normal, +1,8 pp em Pré-diabético e +1,0 pp em Diabético). A única classe na qual o *ensemble* apresenta F2 inferior ao *baseline* é Pré-diabético (−1,0 pp), embora o ganho em AUC-ROC nessa classe (+1,8 pp) indique melhor capacidade de discriminação probabilística pelo *ensemble*.

O resultado consolidado demonstra que o *ensemble* heterogêneo, mesmo com complexidade computacional adicional decorrente do treinamento de seis especialistas e do meta-aprendiz, oferece uma alternativa viável ao classificador multiclasse direto, com ganho consistente em AUC-ROC e desempenho equivalente em F2 macro.

Figura 5.27 – Matriz de confusão detalhada do *ensemble* v4 (*Stacking* com meta-aprendiz *HistGradientBoosting* e *passthrough*) nos dados de teste, com contagens absolutas e proporções relativas às linhas (classe real).



Elaborado pelo autor.

A Figura 5.27 apresenta a matriz de confusão do *ensemble* v4 nos dados de teste. O padrão de erros segue o mesmo perfil observado no *baseline* multiclasse direto da Tarefa 2 (Figura 5.12), com a classe Pré-diabético concentrando a maior dificuldade preditiva e dispersão bidirecional para as classes vizinhas (Normal e Diabético). A simetria do padrão de confusão entre o classificador multiclasse direto e o *ensemble* reforça a interpretação de que a sobreposição biológica entre estágios adjacentes do espectro glicêmico constitui o fator limitante intrínseco do problema, independentemente da estratégia de modelagem adotada.

Algumas limitações da análise apresentada nesta seção devem ser consideradas. A análise de explicabilidade do meta-aprendiz v4 (importância das meta-*features* via SHAP), a análise de erros estratificada por subgrupo (sexo, faixa etária, faixa de hemoglobina glicada) e a análise de otimização do limiar de decisão deste *ensemble* não foram

conduzidas neste trabalho e podem ser apontadas como direções de pesquisa. O próximo capítulo discute os achados apresentados neste capítulo à luz da fundamentação teórica e dos trabalhos relacionados, apresentando a interpretação dos atributos mais influentes, a comparação com estudos correlatos e as implicações do desempenho observado para a aplicabilidade prática da abordagem.

6 DISCUSSÃO

Este capítulo discute os principais achados apresentados no Capítulo 5, consolidando conforme a fundamentação teórica (Capítulo 2) e os trabalhos relacionados (Capítulo 3). A Seção 6.1 apresenta a interpretação dos resultados, comparando o desempenho entre as estratégias de classificação, contextualizando-os em relação à literatura e verificando a hipótese de pesquisa. A Seção 6.2 discute a importância dos parâmetros hematológicos identificados pelos métodos de explicabilidade e a concordância entre métodos. Por fim, a Seção 6.3 aborda as implicações para a prática clínica, incluindo a aplicabilidade como ferramenta de triagem, as disparidades por subgrupo demográfico e as limitações observadas.

6.1 Interpretação dos Resultados

Conforme descrito no Capítulo 4, o F2-Score ($\beta=2$) foi adotado como métrica primária de avaliação em todas as tarefas, em razão do maior custo clínico dos falsos negativos no contexto de triagem. Os resultados discutidos neste capítulo utilizam o F2-Score como referência central de comparação.

Os resultados experimentais (Seção 5.1, Tabela 5.2 e seguintes) revelaram uma hierarquia consistente de desempenho entre as estratégias de classificação avaliadas: o F2-Score reduz à medida que as fronteiras de decisão se aproximam dos limiares diagnósticos de A1c (5,7% e 6,5%). A formulação binária agregada da Tarefa 1 (N vs. PD+D) e os subproblemas da Tarefa 3 que envolvem classes nos extremos do espectro (Nx D, NxPD) apresentaram o melhor desempenho, enquanto subproblemas com fronteiras entre classes adjacentes (PDxD, PDxN+D e N+PDxD) e a classificação multiclasse direta da Tarefa 2 concentraram a maior dificuldade preditiva. Essa hierarquia indica que a dificuldade preditiva é proporcional à proximidade entre os limiares diagnósticos de A1c que separam as classes.

A comparação entre a Tarefa 1 e a Tarefa 2 (Seção 5.3) evidencia que a formulação binária é mais eficaz do que a multiclasse para a classificação do *status* glicêmico a partir de dados hematológicos. A análise por classe na Tarefa 2 (Tabela 5.9) confirma que o Pré-diabetes concentra a principal dificuldade preditiva, com mais da metade dos indivíduos pré-diabéticos classificados incorretamente em dispersão bidirecional para as classes vizinhas. As distribuições de probabilidade predita para essa classe sobrepõem-se às das

classes Normal e Diabético, o que evidencia a dificuldade do modelo em atribuir probabilidades distintas. Esse padrão é compatível com o observado por Cardozo et al. (2022), que reportou taxa de erro de aproximadamente 30% para a classe pré-diabética utilizando dados hematológicos combinados com exames laboratoriais adicionais. Este trabalho, ao utilizar exclusivamente parâmetros do hemograma, confirma e amplia essa limitação, indicando que as alterações hematológicas associadas ao estado pré-diabético são quantitativamente insuficientes para permitir discriminação confiável pelo hemograma isolado.

A estratégia de decomposição implementada na Tarefa 3 (Seção 5.4) permitiu isolar as fronteiras de decisão entre pares de classes, revelando que os subproblemas com classes mais distantes no espectro de A1c (NxD, separando indivíduos com $A1c < 5,7\%$ daqueles com $A1c \geq 6,5\%$) apresentam F2 e AUC-ROC superiores aos que envolvem classes vizinhas (PDxD, separando A1c entre 5,7% e 6,5% daqueles com $A1c \geq 6,5\%$). O *pipeline* vencedor (MLP com QuantileTransformer e SMOTEENN, categoria C3, Tabela 4.6) foi o melhor em cinco dos seis subproblemas binários, indicando que o tratamento combinado de sobreamostragem e limpeza de instâncias ruidosas é particularmente eficaz quando classes específicas são isoladas e a sobreposição entre elas é o fator limitante. A Tarefa 4 utilizou esses seis classificadores binários especialistas para construir um *ensemble* heterogêneo via *Stacking* não-linear com *passthrough* (v4), conforme Wolpert (1992) e Ting and Witten (1999). A configuração final do *ensemble* (Seção 5.5, Tabela 5.22) igualou o desempenho do *baseline* multiclasse direto da Tarefa 2 em F2 macro e o superou marginalmente em AUC-ROC, demonstrando que a decomposição do problema multiclasse em subproblemas binários especializados, seguida de meta-agregação, oferece uma alternativa viável ao classificador multiclasse direto.

Os valores obtidos em treino, validação e teste são semelhantes nas tarefas binárias, indicando boa estabilidade preditiva e ausência de sobreajuste. A diferença entre o F2 médio de treino e o F2 médio de validação na validação cruzada aninhada permaneceu abaixo de 0,020 em todas as tarefas binárias (variando de 0,000 na Tarefa 1 a 0,019 na Tarefa 3 N+PDxD), valor consistente com os critérios de generalização adequada descritos por Cawley and Talbot (2010) e Raschka (2018). Na Tarefa 2, contudo, a diferença treino-validação foi de 0,091 (F2 treino = 0,566 vs. F2 validação = 0,475), acompanhada de desvio padrão elevado entre *folds* ($\pm 0,060$), evidenciando maior variabilidade e potencial sobreajuste no cenário multiclasse. Em ambos os casos, o F2 observado no conjunto de teste foi superior à média de validação da validação cruzada aninhada, o que é esperado no protocolo adotado, dado que o modelo final foi treinado sobre a totalidade dos dados

de treino (80% do *dataset*), enquanto cada *outer fold* utilizou aproximadamente 72%, conforme descrito por Varma and Simon (2006). A robustez metodológica proporcionada pela validação cruzada aninhada com 10 *folds* externos e 5 internos contrasta com estudos como o de Mansoori et al. (2023a), que reportou acurácia de 97,4% sem evidência de protocolo equivalente de validação, sugerindo possível sobreajuste aos dados de treino.

Dentre os 12 algoritmos avaliados (Capítulo 4, Tabela 4.5), o *pipeline* baseado em Rede Neural Artificial do tipo MLP foi o vencedor em todas as tarefas avaliadas: MLP com StandardScaler e MinMaxScaler (categoria C1) na Tarefa 1 e na Tarefa 2, e MLP com QuantileTransformer e SMOTEENN (categoria C3) em todos os subproblemas da Tarefa 3. A convergência dos dez melhores *pipelines* da Tarefa 1 em uma faixa estreita de F2 (0,757 a 0,793) sugere a existência de um teto de desempenho imposto pela capacidade discriminativa intrínseca do espaço de *features* hematológicas. Esse resultado contrasta com a literatura recente, na qual algoritmos baseados em árvore predominam: Li et al. (2024) reportaram XGBoost como melhor modelo, Mansoori et al. (2023a) obtiveram melhor desempenho com Florestas Aleatórias, e Al-Hussein et al. (2025) utilizaram um híbrido de Florestas Aleatórias com Regressão Logística. A superioridade da MLP no presente trabalho sugere que as interações não-lineares entre parâmetros hematológicos são melhor capturadas por redes neurais do que por *ensembles* de árvores, possivelmente em função da dimensionalidade baixa do espaço de *features* (23 atributos), que favorece arquiteturas densas com poucas camadas.

A análise dos *pipelines* vencedores aponta uma interação entre a estratégia de pré-processamento e a complexidade da tarefa. Nas tarefas de maior complexidade estrutural (Tarefa 1 binária agregada e Tarefa 2 multiclasse), o *pipeline* vencedor (MLP com StandardScaler e MinMaxScaler, categoria C1) obteve o melhor desempenho, enquanto nos subproblemas binários da Tarefa 3, o *pipeline* vencedor (MLP com QuantileTransformer e SMOTEENN, categoria C3) foi superior em cinco dos seis casos. Essa observação sugere que, quando as classes agregam variabilidade (como na Tarefa 1, onde PD e D são unificados), um pré-processamento simples é suficiente para que o algoritmo capture os padrões discriminativos, ao passo que, quando classes específicas são isoladas e a sobreposição entre elas é o fator limitante, o tratamento avançado de desbalanceamento e normalização torna-se necessário. Esse *trade-off* entre complexidade do pré-processamento e formulação do problema não foi reportado nos trabalhos relacionados, embora Tahir et al. (2024) tenham demonstrado que um modelo linear (LDA) com *features* ricas (marcadores inflamatórios e hematológicos) alcançou 89,5% de acurácia, ilustrando um *trade-off* fun-

damentalmente diferente: modelo simples com *features* ricas vs. modelo complexo com *features* limitadas.

A análise *post-hoc* de otimização do limiar de decisão (Seção 5.2.3, Tabela 5.4) revelou que os limiares ótimos para a Tarefa 1 situam-se substancialmente abaixo do valor padrão de 0,50 utilizado nos experimentos. Após a otimização, os dez melhores *pipelines* convergem para um patamar de F2 praticamente equivalente, com amplitude máxima de apenas 0,2 ponto percentual, eliminando as diferenças entre algoritmos. Este resultado indica que os modelos aprendem *rankings* de probabilidades úteis, mas que o limiar padrão de 0,50 é subótimo para a distribuição de classes deste problema. A otimização do limiar não foi integrada ao protocolo experimental (os limiares ótimos foram calculados sobre o conjunto de teste exclusivamente para fins de análise), constituindo uma direção de trabalho futuro com potencial concreto de elevação do F2 da Tarefa 1.

O presente trabalho constitui o maior estudo identificado na literatura que utiliza exclusivamente parâmetros hematológicos para classificação do *status* glicêmico, com 169.999 registros. O único outro estudo com dados exclusivamente hematológicos, conduzido por Li et al. (2024), utilizou uma base de 6.477 amostras (3.398 de pacientes diabéticos e 3.079 de controles saudáveis) e obteve AUC-ROC de 0,9851 no conjunto de teste interno. Numa validação externa conduzida exclusivamente em 932 amostras de pacientes diabéticos de um hospital independente, a acurácia obtida foi de 81,54%, indicando queda de sensibilidade em amostra externa. O presente trabalho obteve AUC-ROC de 0,801 na Tarefa 1, valor inferior ao reportado por Li et al. (2024) no teste interno, porém avaliado em um *dataset* aproximadamente 26 vezes maior, o que produz uma estimativa de desempenho mais realista e menos suscetível à variabilidade amostral. A degradação observada por Li et al. (2024) na validação externa reforça o risco de generalização compartilhado pelo presente trabalho, cuja base provém de uma única fonte laboratorial da região sul do Brasil.

A comparação com estudos que utilizam painéis bioquímicos mais amplos contextualiza o desempenho obtido neste trabalho. Cardozo et al. (2022) obtiveram 78,1% de sensibilidade utilizando dados hematológicos combinados com exames laboratoriais complementares em 62.496 pacientes brasileiros, valor compatível com o *Recall* de 0,824 obtido na Tarefa 1 deste trabalho com dados exclusivamente hematológicos. Contudo, estudos com *features* ainda mais ricas reportam desempenho substancialmente superior: Sahid, Babar and Uddin (2024) alcançaram 96,4% de acurácia com dados clínicos e bioquímicos, e Abnoosian, Farnoosh and Behzadi (2023) reportaram 98,87% de acurácia

com *ensemble* ponderado. Esses valores elevados devem ser interpretados com cautela, pois foram obtidos em *datasets* pequenos (826 e aproximadamente 1.000 registros, respectivamente), cenário em que o risco de sobreajuste é elevado. O *trade-off* é claro: o uso exclusivo do hemograma oferece maior acessibilidade e reprodutibilidade, ao custo de menor desempenho absoluto em comparação com painéis bioquímicos completos.

Conforme discutido na Seção 3.6, este trabalho endereça as quatro lacunas identificadas na revisão da literatura: (i) estudo de larga escala com dados exclusivamente hematológicos, superando em mais de 80 vezes o tamanho amostral do único estudo comparável; (ii) investigação de múltiplas estratégias de classificação, incluindo decomposição binária e *ensemble* heterogêneo, abordagens não encontradas nos trabalhos revisados; (iii) avaliação da detecção de pré-diabetes a partir de hemograma, lacuna específica identificada na literatura; e (iv) análise de explicabilidade com dois métodos (SHAP e permutação) combinada com avaliação de desempenho por subgrupos demográficos, visando investigar aspectos de equidade dos modelos, contribuição não reportada nos estudos correlatos. O custo dessa contribuição é o desempenho absoluto inferior ao de estudos que utilizam *features* bioquímicas complementares, consequência esperada e deliberada da restrição ao hemograma como única fonte de dados preditivos.

Os resultados permitem a verificação da hipótese de pesquisa formulada no Capítulo 1. A primeira parte da hipótese, de que os parâmetros do hemograma contêm informação associada ao metabolismo glicêmico e possibilitam a classificação de indivíduos por modelos de aprendizado de máquina, foi confirmada pelos resultados da Tarefa 1 ($F2 = 0,793$, $Recall = 0,824$) e do subproblema NxPD da Tarefa 3 ($Recall = 0,877$), demonstrando que o hemograma contém informação suficiente para distinguir indivíduos normoglicêmicos daqueles com alteração glicêmica, com sensibilidade superior a 82% na formulação binária. A segunda parte da hipótese, de que o estado pré-diabético pode ser detectado a partir de dados hematológicos de rotina, foi confirmada com ressalvas. O subproblema NxPD da Tarefa 3 obteve $F2 = 0,750$ e $Recall = 0,847$, demonstrando que o hemograma permite identificar indivíduos pré-diabéticos quando a pergunta é formulada como distinção binária em relação a indivíduos normais. Contudo, a detecção do pré-diabetes apresenta limitações quando o problema envolve fronteiras próximas no espectro de A1c (PDxD: $F2 = 0,697$; PDxN+D: $F2 = 0,671$) e na classificação multiclasse simultânea ($F2$ por classe = 0,437 na Tarefa 2, com confusão bidirecional e probabilidades não-discriminativas). Esses resultados indicam que o hemograma contém informação suficiente para a detecção binária do pré-diabetes frente a indivíduos normais, porém a

discriminação entre pré-diabetes e diabetes, e a classificação simultânea das três classes, permanecem como desafios para os quais o hemograma isolado apresenta capacidade preditiva limitada.

As limitações observadas na detecção do pré-diabetes possuem interpretação biológica. As alterações hematológicas induzidas pela hiperglicemia crônica, como a glicação da membrana eritrocitária, a inflamação de baixo grau refletida na contagem de leucócitos e a maior ativação plaquetária refletida no aumento do VPM (PAPATHEODOROU et al., 2018), são graduais e contínuas ao longo do espectro de A1c. O pré-diabetes representa um estágio intermediário cujas alterações hematológicas são quantitativamente menores do que as observadas no diabetes estabelecido, o que explica tanto o bom desempenho na discriminação NxPD (onde a diferença em relação a indivíduos normais é detectável) quanto a maior dificuldade na discriminação PDxD (onde as diferenças entre os dois estágios de alteração glicêmica são mais sutis). Além disso, os limiares diagnósticos de A1c de 5,7% e 6,5% (American Diabetes Association, 2026a) impõem fronteiras discretas a um fenômeno biológico contínuo, o que se reflete na concentração de erros de classificação nas faixas imediatamente adjacentes a esses limiares, conforme demonstrado na análise de erros por faixa de hemoglobina glicada apresentada no Capítulo 5.

6.2 Importância dos Parâmetros Hematológicos

A análise de explicabilidade revelou que a Idade foi o atributo mais influente em todas as tarefas avaliadas, concentrando mais de 60% da importância SHAP total dos dez atributos mais relevantes na Tarefa 1 (SHAP = 0,212, magnitude 5,6 vezes superior ao segundo colocado). Na Tarefa 3, a Idade ocupa a 1ª posição em três dos cinco subproblemas analisados (NxPD, PDxD e PDxN+D), cedendo o 1º lugar para Leucócitos apenas nos subproblemas NxPD e PDxD. Esse resultado é clinicamente esperado, uma vez que a idade constitui o principal fator de risco para o diabetes mellitus tipo 2 (International Diabetes Federation, 2025). Contudo, a Idade não é um parâmetro hematológico, e sim uma variável demográfica incluída no conjunto de atributos preditivos. Essa distinção é relevante para a interpretação dos resultados: o modelo aprende parcialmente o risco de desenvolvimento da doença associado à idade, e não somente nos padrões intrinsecamente hematológicos. A remoção da Idade do conjunto de atributos possivelmente reduziria o desempenho global, porém permitiria avaliar a contribuição genuinamente hematológica dos demais parâmetros. Li et al. (2024), que não incluíram a Idade como atributo predi-

tivo, obtiveram CHCM, LY%, RDW-SD e HCM como os parâmetros mais relevantes, o que sugere que, na ausência da Idade, a importância é redistribuída para índices eritrocitários e diferenciais leucocitários.

A importância dos atributos variou conforme a fronteira de decisão avaliada, evidenciando que diferentes mecanismos hematológicos dominam diferentes segmentos do espectro glicêmico. O RDW, 6º atributo mais relevante na Tarefa 1, caiu para a 13ª posição por SHAP na Tarefa 2, enquanto atributos da série vermelha como Hemoglobina (de 10ª para 7ª) e Hematócrito (ausente do top-10 na T1, 8ª na T2) ganharam posições. Na Tarefa 3, Leucócitos assumiram a 1ª posição nos subproblemas que envolvem a classe Pré-diabético composta com outras classes (N+PDxD e PDxN+D), e Segmentados apareceram exclusivamente nesses mesmos subproblemas (4ª e 2ª posição, respectivamente). Esse achado, não reportado nos trabalhos relacionados, sugere que a discriminação entre classes extremas do espectro glicêmico (NxD) depende predominantemente da Idade, enquanto a discriminação de fronteiras adjacentes requer um conjunto mais amplo de parâmetros hematológicos, possivelmente refletindo diferentes vias fisiopatológicas associadas a cada estágio da progressão glicêmica.

A concordância entre os métodos de explicabilidade diminuiu com a complexidade da tarefa. O coeficiente de Spearman entre os *rankings* de SHAP e permutação foi de $\rho = 0,975$ na Tarefa 1, de $\rho = 0,889$ na Tarefa 2, e apresentou divergências ainda maiores em subproblemas específicos da Tarefa 3: Eritrócitos (3ª posição por SHAP vs. 21ª por permutação no NxD), Hematócrito (5ª vs. 23ª no N+PDxD) e Segmentados (2ª vs. 15ª no PDxN+D). Essas divergências indicam que, em problemas com fronteiras de decisão mais complexas, os dois métodos avaliam a importância dos atributos sob perspectivas diferentes: o SHAP mede a contribuição de cada atributo para a predição individual, enquanto a permutação mede o quanto o desempenho do modelo é afetado quando os valores de cada atributo são embaralhados. A utilização conjunta de ambos os métodos, conforme realizada neste trabalho, permite identificar atributos cuja importância varia conforme o método empregado e evitar interpretações baseadas em uma única perspectiva.

Os atributos hematológicos mais relevantes possuem respaldo fisiopatológico na literatura. Os Leucócitos, consistentemente entre os dois atributos mais importantes em todas as tarefas, refletem o estado de inflamação crônica de baixo grau induzido pela hiperglicemia, conforme descrito por Papatheodorou et al. (2018). Twig et al. (2013) demonstraram, em um grupo de 24.897 indivíduos, que contagens de leucócitos acima de 6.900 células/mm³ estão associadas a risco 52% maior de desenvolvimento de diabetes

tipo 2. O RDW, que reflete a heterogeneidade no tamanho dos eritrócitos, está associado ao estresse oxidativo e à glicação da membrana eritrocitária em indivíduos com hiperglicemia (ENGSTRÖM et al., 2014). As alterações em Hemoglobina e HCM são compatíveis com as modificações estruturais dos eritrócitos induzidas pela glicação crônica da membrana celular (WANG et al., 2021). Plaquetas e MPV, presentes no top-10 em todas as tarefas, refletem a maior ativação plaquetária observada no diabetes, com meta-análise demonstrando MVP significativamente elevado em indivíduos com diabetes tipo 2 (ZACCARDI et al., 2015).

A análise de explicabilidade por instância, por meio de gráficos de cascata SHAP, revelou padrões consistentes nos erros de classificação. Os falsos negativos da Tarefa 1 apresentaram tipicamente indivíduos jovens nos quais a Idade contribuiu negativamente para a predição (exemplo: indivíduo de 43 anos com contribuição da Idade de $-0,15$), enquanto os falsos positivos corresponderam a indivíduos idosos saudáveis nos quais a Idade elevada contribuiu positivamente (exemplo: indivíduo de 75 anos com contribuição de $+0,22$) apesar do perfil glicêmico normal. Esses exemplos demonstram como a dominância da Idade pode induzir erros sistemáticos em subgrupos demográficos específicos, o que será aprofundado na análise de disparidades por faixa etária na Seção 6.3.

A comparação com os achados de explicabilidade reportados nos trabalhos relacionados evidencia a dependência populacional e metodológica da importância de atributos. Li et al. (2024) identificaram CHCM, LY%, RDW-SD e HCM como os parâmetros mais relevantes em uma população chinesa (6.477 amostras coletadas em instituições de Heilongjiang e da Mongólia Interior), enquanto o presente trabalho, em uma população brasileira de 169.999 registros, identificou Leucócitos, Linfócitos, HCM e RDW como os parâmetros do hemograma de maior importância preditiva na Tarefa 1, havendo convergência parcial em HCM e RDW. Li et al. (2025) incluíram a contagem de leucócitos entre nove preditores selecionados por LASSO para detecção de pré-diabetes, corroborando a relevância desse parâmetro. Tahir et al. (2024) utilizaram marcadores inflamatórios derivados (NLR, PLR), ausentes do hemograma padrão deste trabalho, que demonstraram alta capacidade discriminativa. As diferenças nos *rankings* de importância entre estudos reforçam a necessidade de validação da interpretação dos modelos em diferentes populações antes de qualquer generalização clínica.

6.3 Implicações para a Prática Clínica

Os resultados obtidos posicionam a abordagem desenvolvida neste trabalho como uma ferramenta de triagem populacional, e não como instrumento diagnóstico. O *Recall* de 0,824 na Tarefa 1 indica que o modelo é capaz de identificar 82,4% dos indivíduos com alteração glicêmica (pré-diabetes ou diabetes) a partir exclusivamente dos parâmetros do hemograma. Em um cenário de triagem, essa sensibilidade permite que o modelo funcione como um filtro aplicado a hemogramas de rotina, sinalizando pacientes para investigação subsequente por meio do teste de hemoglobina glicada (A1c), sem substituir o diagnóstico clínico. Esse posicionamento atende aos critérios clássicos de triagem populacional estabelecidos por Wilson and Jungner (1968), segundo os quais um teste de triagem deve ser acessível, de baixo custo e com sensibilidade suficiente para minimizar a proporção de casos não detectados. Complementarmente, a análise do desempenho do modelo sob a perspectiva de saúde pública demanda atenção explícita ao compromisso entre falsos negativos e falsos positivos. A sensibilidade de 0,824 é acompanhada por uma especificidade de 0,629, configurando um cenário em que aproximadamente 17,6% dos indivíduos com alteração glicêmica não são detectados e 37,1% dos indivíduos normoglicêmicos são sinalizados incorretamente como suspeitos. Em programas de triagem populacional, esse perfil tende a privilegiar a sensibilidade em detrimento da especificidade, alinhando-se à orientação adotada neste trabalho, porém demandando volume relevante de encaminhamentos para investigação confirmatória complementar. Publicações recentes em literatura especializada (VICKERS; CALSTER; STEYERBERG, 2016) (CALSTER et al., 2025) apontam que a avaliação completa de modelos preditivos em saúde pode ser fortalecida por medidas de utilidade clínica, como o benefício líquido (*net benefit*) e a análise de curvas de decisão, capazes de incorporar explicitamente o custo relativo entre falsos positivos e falsos negativos em diferentes limiares de decisão. A incorporação dessas análises ao protocolo deste trabalho oportuniza uma direção promissora de aprofundamento, conforme apresentado no Capítulo 7.

O hemograma é o exame laboratorial mais solicitado globalmente e está disponível em formato digital no LIS da maioria dos laboratórios. Essa ubiquidade torna viável a integração de um modelo preditivo como o desenvolvido neste trabalho em três cenários principais: (i) atenção primária, onde o hemograma é frequentemente solicitado, mas a A1c nem sempre é incluída na rotina de rastreamento; (ii) serviços de emergência, onde o hemograma é realizado como exame de rotina, mas a A1c não é parte do protocolo de

atendimento; e (iii) contextos com acesso limitado à A1c, como laboratórios de menor porte ou regiões remotas. Em todos esses cenários, o modelo possibilitaria uma triagem de pacientes, aproveitando dados já disponíveis para sinalizar indivíduos que se beneficiariam de investigação glicêmica complementar. Em comparação com a triagem universal por A1c, na qual todos os pacientes seriam submetidos à dosagem do exame independentemente de indicação clínica prévia, a abordagem desenvolvida apresenta vantagens em termos de viabilidade de coleta dos preditores. Os 23 atributos utilizados pelos modelos (21 parâmetros hematológicos, idade e sexo) são integralmente derivados de dados já presentes no hemograma de rotina e no cadastro do paciente, não demandando coleta adicional, processamento laboratorial específico ou custo incremental por indivíduo avaliado. Esse perfil caracteriza a abordagem como uma estratégia de triagem oportunística e direcionada, em que o exame de hemograma, frequentemente solicitado por motivos clínicos diversos, passa a também sinalizar indivíduos com maior risco de alteração glicêmica, otimizando o uso dos recursos do sistema de saúde. Publicações em literatura especializada apontam que estratégias de triagem oportunísticas e direcionadas demonstram-se mais custo-efetivas que abordagens universais em cenários de prevalência intermediária da doença (GILLIES et al., 2008) (KAHN et al., 2010), oportunizando a alocação racional de recursos diagnósticos confirmatórios. A avaliação formal de custo-efetividade da estratégia desenvolvida neste trabalho, comparada à triagem universal por A1c, é apresentada como direção de trabalho futuro no Capítulo 7.

Soma-se a esse perfil oportunístico a composição predominantemente ambulatorial da amostra (aproximadamente 80%), conforme descrito na Seção 4.1.1. Embora a base provenha de um único laboratório, essa predominância reduz o viés associado a populações exclusivamente hospitalares, tipicamente compostas por indivíduos com maior carga de comorbidades e quadros agudos, aproximando o perfil dos registros utilizados ao da população atendida em rotinas de atenção primária. Essa característica fortalece o potencial de generalização dos modelos para o cenário clínico primário, ainda que a validação externa em coortes específicas de atenção primária permaneça como direção de trabalho futuro, conforme apresentado no Capítulo 7.

A análise de erros por faixa de hemoglobina glicada demonstrou que os erros de classificação concentram-se nas faixas imediatamente adjacentes aos limiares diagnósticos de A1c. Na Tarefa 1, os erros se concentram na região próxima ao limiar de 5,7% (que separa Normal de Pré-diabético), enquanto na Tarefa 2, o pico de falsos positivos (36,6%) localiza-se na faixa 5,4 a 5,7% e o maior índice de falsos negativos (25,1%) na

faixa 5,7 a 6,0%. Esse padrão é clinicamente esperado, uma vez que os limiares de A1c de 5,7% e 6,5% adotados pela OMS e pela ADA (American Diabetes Association, 2026a) representam convenções diagnósticas aplicadas a uma variável biológica contínua. Indivíduos com valores de A1c próximos a esses limiares apresentam perfis bioquímicos e hematológicos transicionais, nos quais a ambiguidade do modelo espelha a ambiguidade clínica dessas faixas.

O achado mais relevante da análise de equidade é a disparidade de desempenho por faixa etária. Na Tarefa 1 (Seção 5.2.5.3), a taxa de falsos negativos cresce drasticamente conforme a faixa etária diminui, atingindo valores próximos de 90% na faixa abaixo de 40 anos. Na Tarefa 2 (Seção 5.3.4.3), o mesmo padrão se intensifica: a taxa de falsos negativos clínicos em jovens aproxima-se da totalidade dos casos, indicando que a classificação multiclasse e a faixa etária inferior compõem o cenário de pior desempenho preditivo. Esses valores indicam que o modelo é ineficaz para a detecção de alterações glicêmicas em indivíduos jovens. Três fatores podem contribuir para essa limitação: (i) a prevalência de alteração glicêmica no conjunto de teste é de apenas 18% na faixa abaixo de 40 anos, contra 73% na faixa acima de 60 anos, o que induz o modelo a aprender o padrão majoritário de cada faixa; (ii) indivíduos jovens com diabetes são predominantemente portadores de diabetes tipo 1 ou diabetes tipo 2 de início precoce, condições cujo perfil hematológico pode diferir do diabetes tipo 2 clássico predominante na amostra; e (iii) os valores de referência hematológicos variam com a idade, o que pode confundir o modelo. Qualquer implantação clínica desta abordagem deve incluir um alerta explícito para pacientes com idade inferior a 40 anos, ou incorporar estratificação por faixa etária com modelos específicos.

A análise conjunta dos falsos negativos por faixa etária e por faixa de A1c, apresentada na Figura 5.11 do Capítulo 5, possibilitou avaliar especificamente o fator (ii) acima, verificando se os falsos negativos em indivíduos jovens estariam concentrados em faixas de A1c muito elevadas, perfil sugestivo de diabetes tipo 1. Os dados não corroboram essa concentração específica: a taxa de falsos negativos em indivíduos com até 40 anos mantém-se uniformemente alta, entre 82% e 89%, em todas as faixas de A1c acima de 5,7%, indicando que a limitação preditiva nessa faixa etária é estrutural e não específica a um subgrupo clínico identificável pela combinação de idade e A1c. Esse resultado reforça os fatores (i) e (iii) como explicações preponderantes da disparidade observada, mantendo o fator (ii) como hipótese clínica plausível, porém não diretamente verificável com os dados disponíveis na ausência de rotulagem do tipo de diabetes.

As disparidades de desempenho por sexo (Seções 5.2.5.2, 5.3.4.2 e 5.4.4) mostram um padrão crescente conforme a complexidade da tarefa: praticamente nula na Tarefa 1, moderada na Tarefa 2 (com vantagem para o subgrupo feminino), e máxima no subproblema PDxD da Tarefa 3 (com vantagem para o subgrupo masculino). Essa inversão entre tarefas sugere que o efeito de sexo não é uniforme e depende das classes sob comparação. Embora essas diferenças não atinjam a amplitude observada na estratificação por idade, devem ser monitoradas em eventuais implantações clínicas. Ressalta-se que nenhum dos doze trabalhos relacionados revisados no Capítulo 3 realizou análise de equidade por subgrupo demográfico. A importância dessa análise em algoritmos aplicados à saúde é evidenciada por Obermeyer et al. (2019), que demonstraram a existência de viés racial em algoritmos utilizados na gestão de saúde populacional, o que configura a análise de equidade realizada neste trabalho como uma contribuição original ao campo.

Os resultados indicam que a formulação binária (N vs. PD+D) é a mais adequada para aplicação clínica entre as estratégias avaliadas. A Tarefa 1 apresentou o maior F2 (0,793), a maior estabilidade (diferença treino-validação = 0,000) e o menor risco de falsos negativos clínicos totais (17,6% no conjunto de teste). Em contraste, o modelo multiclasse da Tarefa 2 classificou 19,6% dos indivíduos com alteração glicêmica como Normais, representando um risco clínico mais elevado. A decomposição binária da Tarefa 3 é útil como ferramenta de pesquisa, por permitir a compreensão das fronteiras de decisão e a identificação dos atributos mais relevantes em cada segmento do espectro glicêmico, mas não oferece vantagem para implantação clínica direta. A abordagem recomendada é, portanto, um sistema binário de triagem que classifique os indivíduos como “com alerta de alteração glicêmica” ou “sem alerta”, sinalizando os primeiros para investigação complementar por A1c.

As limitações identificadas ao longo deste trabalho devem ser consideradas no contexto de qualquer proposta de aplicação clínica. Em primeiro lugar, todos os dados utilizados provêm de um único laboratório da região sul do Brasil, o que limita a generalização para outras populações e regiões. Em segundo lugar, os dados são retrospectivos, o que introduz potencial viés de seleção. Em terceiro lugar, a utilização da A1c como rótulo de classificação está sujeita a interferências de condições que afetam tanto a A1c quanto o hemograma, como hemoglobinopatias, anemia ferropriva e doença renal crônica. Em quarto lugar, o espaço de atributos é restrito a 23 parâmetros hematológicos, excluindo marcadores bioquímicos (glicose, perfil lipídico) e inflamatórios (PCR, NLR, PLR) que demonstraram capacidade discriminativa em outros estudos (TAHIR et al., 2024). Por

fim, não foi realizada validação prospectiva em contexto clínico real. Essas limitações são endereçadas como direções de trabalho futuro no Capítulo 7.

A essas limitações soma-se um aspecto inerente ao processo de rotulagem adotado: as classes utilizadas para treinamento e avaliação dos modelos foram derivadas de uma única medição laboratorial de A1c por indivíduo, não correspondendo a um diagnóstico clínico confirmado, que exige a repetição do exame em dia distinto ou a confirmação por método laboratorial complementar (American Diabetes Association, 2026a). Indivíduos com valores de A1c próximos aos limiares diagnósticos (5,7% e 6,5%) podem, portanto, ter sido rotulados em classes que não refletem seu *status* glicêmico clinicamente confirmado. Embora essa decisão metodológica seja consistente com a natureza retrospectiva da base de dados e com a indisponibilidade de informação clínica complementar no sistema de informações laboratoriais, ela reforça o posicionamento dos modelos como ferramentas de triagem oportunística, e não como instrumentos diagnósticos.

Acrescenta-se que a natureza transversal da base de dados limita a interpretação causal dos achados. Como cada registro corresponde a uma única observação no tempo, não é possível distinguir, nos pacientes diabéticos identificados, se os padrões hematólogicos detectados precedem o desenvolvimento da doença ou refletem alterações decorrentes da progressão clínica e do manejo terapêutico ao longo do tempo. Essa característica configura uma limitação clássica em estudos baseados em dados secundários, comum a abordagens observacionais sem acompanhamento longitudinal, e implica que os modelos desenvolvidos identificam associações estatísticas robustas entre parâmetros do hemograma e o *status* glicêmico, sem permitir inferência sobre a direção causal dessas relações. A investigação dessa direção causal, por meio de delineamentos longitudinais, é apresentada como direção de trabalho futuro no Capítulo 7.

7 CONCLUSÃO

O hemograma, exame de rotina amplamente disponível e de baixo custo, demonstra conter informação suficiente para a triagem de alterações glicêmicas por meio de modelos de aprendizado de máquina, com sensibilidade superior a 82% na formulação binária. Os resultados e contribuições desta pesquisa avançam o conhecimento na interseção entre aprendizado de máquina e saúde, abrindo perspectivas para a detecção do diabetes e do pré-diabetes em contextos onde a hemoglobina glicada não é rotineiramente disponível.

Os experimentos demonstram, conjuntamente, que o hemograma carrega traços do metabolismo glicêmico suficientes para identificar a presença de alteração glicêmica, mas insuficientes para discriminar com precisão estágios adjacentes da progressão da doença. Esse padrão é consistente entre as estratégias de classificação investigadas e reflete o caráter biologicamente contínuo do espectro normoglicêmico-pré-diabético-diabético, no qual classes vizinhas compartilham características hematológicas sobrepostas. A análise de explicabilidade reforça essa interpretação ao identificar atributos cuja relevância preditiva alinha-se a mecanismos fisiopatológicos consolidados na literatura, como a inflamação crônica de baixo grau, a glicação eritrocitária e a ativação plaquetária (PAPATHEODOROU et al., 2018).

As principais contribuições deste trabalho são: a avaliação da viabilidade preditiva do hemograma em uma base de 169.999 registros, escala superior à observada nos estudos correlatos; a investigação inédita da detecção do estado pré-diabético a partir de dados exclusivamente hematológicos; a comparação sistemática entre quatro estratégias de modelagem (classificação binária, multiclasse direta, decomposição em subproblemas binários e *ensemble*) aplicadas ao mesmo problema; e a integração da explicabilidade à avaliação por subgrupos demográficos, prática não documentada nos estudos correlatos revisados. Parte destes resultados foi submetida e aprovada, após revisão por pares, no SBCAS 2026.

Do ponto de vista prático, os resultados posicionam a abordagem desenvolvida como uma ferramenta de triagem, aplicável em cenários de atenção primária, serviços de emergência e contextos com acesso limitado à A1c. A formulação binária configura-se como a estratégia de maior aplicabilidade clínica, ao apresentar o melhor compromisso entre sensibilidade na detecção de alterações glicêmicas, estabilidade entre subgrupos demográficos e menor risco de falsos negativos.

Algumas limitações devem ser consideradas na interpretação dos resultados. Todos os dados provêm de um único laboratório da região sul do Brasil, o que limita a generalização para outras populações. Os dados são retrospectivos, introduzindo potencial viés de seleção. A utilização da A1c como rótulo de classificação está sujeita a interferências de condições como hemoglobinopatias e anemia, que também afetam parâmetros hematológicos. O espaço de atributos é restrito a 23 parâmetros, excluindo marcadores bioquímicos e inflamatórios que demonstraram capacidade discriminativa em outros estudos. Adicionalmente, a rotulagem das classes foi derivada de uma única medição de A1c por indivíduo, sem a confirmação diagnóstica por segundo exame preconizada pelas diretrizes clínicas (American Diabetes Association, 2026a), o que reforça o posicionamento dos modelos como ferramenta de triagem oportunística. A disparidade de desempenho por faixa etária é severa em indivíduos mais jovens, e não foi realizada validação prospectiva em cenário clínico real.

Como direções de trabalho futuro, seria relevante conduzir validação externa multicêntrica, utilizando dados de outras regiões e populações para avaliar a generalização dos modelos. Do ponto de vista de aplicação, a validação prospectiva em cenário clínico real, particularmente na atenção primária, seria essencial para avaliar a viabilidade prática da triagem oportunística por hemograma. A integração com LIS possibilitaria a automatização da triagem em larga escala.

A construção de modelos estratificados por faixa etária, ou a incorporação de alertas explícitos para pacientes com idade inferior a 40 anos, possibilitaria mitigar a principal limitação identificada. A incorporação da otimização do limiar de decisão ao protocolo de validação cruzada constitui uma melhoria metodológica concreta. A complementação da avaliação de desempenho por meio de medidas de utilidade clínica, como a análise de curvas de decisão (*decision curve analysis*) e o benefício líquido (*net benefit*), possibilitaria quantificar o ganho prático do modelo em diferentes limiares de decisão e custos relativos entre falsos positivos e falsos negativos (VICKERS; CALSTER; STEYERBERG, 2016) (CALSTER et al., 2025). A exploração de limiares operacionais de A1c alternativos aos critérios diagnósticos consolidados (5,7% e 6,5%) constitui uma direção complementar de investigação metodológica. Em particular, a adoção de pontos de corte deslocados, ajustados especificamente ao contexto de triagem oportunística e mantidos em distinção dos critérios diagnósticos da Organização Mundial da Saúde e da *American Diabetes Association*, permitiria avaliar o impacto da redefinição operacional das classes sobre o desempenho preditivo dos modelos, especialmente no segmento intermediário do es-

pectro glicêmico, oportunizando maior sensibilidade na detecção de indivíduos sob risco ou maior estabilidade do desempenho entre subgrupos demográficos. A investigação de atributos complementares, como marcadores bioquímicos e razões hematológicas inflamatórias, permitiria avaliar o ganho incremental em relação ao hemograma exclusivo.

Estudos longitudinais, com acompanhamento da progressão glicêmica dos indivíduos ao longo do tempo, permitiriam avaliar a capacidade dos modelos em detectar transições entre classes glicêmicas. A avaliação de custo-efetividade da triagem oportunística por hemograma, comparada à triagem tradicional por A1c, forneceria evidências para a eventual incorporação desta abordagem em protocolos clínicos. Evidências em estudos prévios sustentam que estratégias de triagem oportunísticas e direcionadas tendem a apresentar custo-efetividade superior à triagem universal em cenários de prevalência intermediária da doença (GILLIES et al., 2008) (KAHN et al., 2010), oportunizando a alocação racional dos recursos do sistema de saúde e fundamentando a investigação aqui proposta como direção promissora de aprofundamento. Adicionalmente, a geração de dados sintéticos a partir da amostra utilizada constituiria uma alternativa promissora para viabilizar a disponibilização pública da base sob as restrições éticas e contratuais identificadas, oportunizando a reprodutibilidade do trabalho por outras equipes de pesquisa e a validação independente dos achados aqui apresentados. A avaliação do desempenho preditivo em cenários de hemograma simplificado, com subconjuntos reduzidos de atributos compatíveis com equipamentos automatizados básicos ou serviços laboratoriais de menor complexidade, constituiria uma direção complementar relevante para a aplicabilidade clínica da abordagem. A análise de explicabilidade reportada na Seção 5.2.4 oferece evidência preliminar de que os seis atributos do diferencial leucocitário manual (Mielócitos, Metamielócitos, Promielócitos, Blastos, Plasmócitos e Linfócitos Atípicos) apresentam contribuição SHAP nula nas predições do *pipeline* vencedor, sinalizando que sua ausência em hemogramas automatizados sem revisão microscópica não comprometeria substancialmente o desempenho. O retreinamento dos modelos sobre subconjuntos correspondentes ao hemograma básico (séries vermelha, branca e plaquetária sem diferencial leucocitário) e ao hemograma com diferencial automatizado permitiria quantificar o impacto efetivo dessa redução e fundamentar recomendações para implantação em contextos de atenção primária com infraestrutura laboratorial limitada.

REFERÊNCIAS

- AAMODT, K. I. The pathophysiology, presentation and classification of Type 1 diabetes. **Diabetes, Obesity and Metabolism**, Wiley, 2025.
- ABNOOSIAN, K.; FARNOOSH, R.; BEHZADI, M. H. Prediction of diabetes disease using an ensemble of machine learning multi-classifier models. **BMC Bioinformatics**, BioMed Central, v. 24, n. 1, p. 337, 2023.
- ABRÀMOFF, M. D.; TARBER, R. et al. Artificial intelligence for diabetes care: current and future prospects. **The Lancet Diabetes & Endocrinology**, Elsevier, 2024.
- AGLIATA, A. et al. Machine learning as a support for the diagnosis of type 2 diabetes. **International Journal of Molecular Sciences**, v. 24, n. 7, p. 6775, 2023.
- AL-HUSSEIN, F. et al. A hybrid approach to enhance HbA1c prediction accuracy while minimizing the number of associated predictors: A case-control study in saudi arabia. **PLoS One**, v. 20, n. 6, p. e0326315, jun. 2025.
- ALHASSAN, Z. et al. Improving current glycated hemoglobin prediction in adults: Use of machine learning algorithms with electronic health records. **JMIR Med. Inform.**, JMIR Publications Inc., v. 9, n. 5, p. e25237, may 2021.
- American Diabetes Association. Diagnosis and classification of diabetes: Standards of care in diabetes—2026. **Diabetes Care**, American Diabetes Association, v. 49, n. Supplement_1, p. S27–S49, 2026.
- American Diabetes Association. Prevention or delay of diabetes and associated comorbidities: Standards of care in diabetes—2026. **Diabetes Care**, American Diabetes Association, v. 49, n. Supplement_1, p. S50–S66, 2026.
- BATISTA, G. E. A. P. A.; PRATI, R. C.; MONARD, M. C. A study of the behavior of several methods for balancing machine learning training data. **ACM SIGKDD Explorations Newsletter**, ACM, v. 6, n. 1, p. 20–29, 2004.
- Brasil. **Lei nº 13.709, de 14 de agosto de 2018 — Lei Geral de Proteção de Dados Pessoais (LGPD)**. 2018. Available from Internet: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/113709.htm>.
- Brasil. Conselho Nacional de Saúde. **Resolução nº 466, de 12 de dezembro de 2012**. 2012. Aprova as diretrizes e normas regulamentadoras de pesquisas envolvendo seres humanos. Available from Internet: <<https://conselho.saude.gov.br/resolucoes/2012/Reso466.pdf>>.
- Brasil. Conselho Nacional de Saúde. **Resolução nº 510, de 7 de abril de 2016**. 2016. Dispõe sobre as normas aplicáveis a pesquisas em Ciências Humanas e Sociais. Available from Internet: <<https://conselho.saude.gov.br/resolucoes/2016/Reso510.pdf>>.
- BREIMAN, L. Bagging predictors. **Machine Learning**, Springer, v. 24, n. 2, p. 123–140, 1996.
- BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001.

BREIMAN, L. et al. **Classification and Regression Trees**. Belmont, CA: Wadsworth, 1984. ISBN 978-0412048418.

CALSTER, B. V. et al. Evaluation of performance measures in predictive artificial intelligence models to support medical decisions: overview and guidance. **The Lancet Digital Health**, v. 7, n. 12, p. 100916, 2025.

CARDOZO, G. **Um modelo computacional utilizando técnicas de machine learning e exames laboratoriais de rotina na triagem e apoio ao diagnóstico de diabetes mellitus**. 2022. <<https://repositorio.ufsc.br/handle/123456789/244403>>. Accessed: 2025-7-28. Available from Internet: <<https://repositorio.ufsc.br/handle/123456789/244403>>.

CARDOZO, G. et al. Use of machine learning and routine laboratory tests for diabetes mellitus screening. **Biomed Res Int**, v. 2022, p. 8114049, 2022.

CAWLEY, G. C.; TALBOT, N. L. C. On over-fitting in model selection and subsequent selection bias in performance evaluation. **Journal of Machine Learning Research**, v. 11, p. 2079–2107, 2010. Available from Internet: <<https://www.jmlr.org/papers/v11/cawley10a.html>>.

CHAWLA, N. V. et al. SMOTE: Synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002.

CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. [S.l.: s.n.], 2016. p. 785–794.

CHENG, Y.-L. et al. Using machine learning for the risk factors classification of glycemic control in type 2 diabetes mellitus. **Healthcare (Basel)**, v. 11, n. 8, abr. 2023.

CHICCO, D.; JURMAN, G. The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. **BMC Genomics**, v. 21, p. 6, 2020.

CORTES, C.; VAPNIK, V. Support-vector networks. **Machine Learning**, Springer, v. 20, n. 3, p. 273–297, 1995.

DAS, S.; SAHA, S. K. Diabetic retinopathy detection and classification using cnn tuned by genetic algorithm. **Multimedia Tools and Applications**, Springer, v. 81, n. 6, p. 8007–8020, 2022. ISSN 1573-7721. Available from Internet: <<https://doi.org/10.1007/s11042-021-11824-w>>.

DINH, A. et al. A data-driven approach to predicting diabetes and cardiovascular disease with machine learning. **BMC Medical Informatics and Decision Making**, v. 19, n. 1, p. 211, 2019.

DOMINGUETI, C. P. et al. Diabetes mellitus: The linkage between oxidative stress, inflammation, hypercoagulability and vascular complications. **Journal of Diabetes and its Complications**, Elsevier, v. 30, n. 4, p. 738–745, 2016.

DRITSAS, E.; TRIGKA, M. Data-driven machine-learning methods for diabetes risk prediction. **Sensors (Basel)**, v. 22, n. 14, p. 5304, 2022.

- ELLAHHAM, S. Artificial intelligence: The future for diabetes care. **The American Journal of Medicine**, v. 133, n. 8, p. 895–900, 2020. ISSN 0002-9343. Available from Internet: <<https://www.sciencedirect.com/science/article/pii/S0002934320303399>>.
- ENGSTRÖM, G. et al. Red cell distribution width, haemoglobin A1c and incidence of diabetes mellitus. **Journal of Internal Medicine**, Wiley, v. 276, n. 2, p. 174–183, 2014.
- EYTH, E.; NAIK, R. J. Hemoglobin A1c. **StatPearls**, StatPearls Publishing, 2024. Available from Internet: <<https://www.ncbi.nlm.nih.gov/books/NBK549816/>>.
- FREUND, Y.; SCHAPIRE, R. E. A decision-theoretic generalization of on-line learning and an application to boosting. **Journal of Computer and System Sciences**, v. 55, n. 1, p. 119–139, 1997.
- FRIEDMAN, J. H. Greedy function approximation: A gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001.
- GALAR, M. et al. An overview of ensemble methods for binary classifiers in multi-class problems: Experimental study on one-vs-one and one-vs-all schemes. **Pattern Recognition**, v. 44, n. 8, p. 1761–1776, 2011.
- GEORGE-GAY, B.; PARKER, K. Understanding the complete blood count with differential. **Journal of PeriAnesthesia Nursing**, Elsevier, v. 18, n. 2, p. 96–114, 2003.
- GIACCO, F.; BROWNLEE, M. Oxidative stress and diabetic complications. **Circulation Research**, American Heart Association, v. 107, n. 9, p. 1058–1070, 2010.
- GILLIES, C. L. et al. Different strategies for screening and prevention of type 2 diabetes in adults: cost effectiveness analysis. **BMJ**, v. 336, n. 7654, p. 1180–1185, 2008.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. Cambridge, MA: MIT Press, 2016. Available from Internet: <<https://www.deeplearningbook.org/>>.
- GREGG, E. W.; SATTAR, N.; ALI, M. K. The changing face of diabetes complications. **The Lancet Diabetes & Endocrinology**, v. 8, n. 6, p. 537–547, 2020.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2. ed. New York: Springer, 2009.
- HE, H.; GARCIA, E. A. Learning from imbalanced data. **IEEE Transactions on Knowledge and Data Engineering**, IEEE, v. 21, n. 9, p. 1263–1284, 2009.
- HICKS, S. A. et al. On evaluation metrics for medical applications of artificial intelligence. **Scientific Reports**, v. 12, p. 5979, 2022.
- HQ LE OH, T. D. V. Formation and evaluation of complete blood count proficiency testing program. **Hematol Rep**, v. 14, n. 2, p. 73–84, 2022.
- International Diabetes Federation. 11th edition of the IDF Diabetes Atlas: global, regional, and national diabetes prevalence estimates for 2024 and projections for 2050. **The Lancet Diabetes & Endocrinology**, 2025. IDF Diabetes Atlas, 11th edition.
- JAMES, D. E.; STÖCKLI, J.; BIRNBAUM, M. J. Insulin resistance in type 2 diabetes mellitus. **Nature Reviews Endocrinology**, Nature Publishing Group, 2025.

JAMIESON, K.; TALWALKAR, A. Non-stochastic best arm identification and hyperparameter optimization. In: **Proceedings of the 19th International Conference on Artificial Intelligence and Statistics (AISTATS)**. [s.n.], 2016. p. 240–248. Available from Internet: <<https://proceedings.mlr.press/v51/jamieson16.html>>.

JOSHI, R. D.; DHAKAL, C. K. Predicting type 2 diabetes using logistic regression and machine learning approaches. **Int J Environ Res Public Health**, v. 18, n. 14, p. 7346, 2021.

KABOOTARI, M. et al. Prevalence and associated factors of delayed diagnosis of type 2 diabetes mellitus in a tertiary hospital: A retrospective cohort study. **Diabetes, Metabolic Syndrome and Obesity**, v. 15, p. 3877–3886, 2022.

KAHN, R. et al. Age at initiation and frequency of screening to detect type 2 diabetes: a cost-effectiveness analysis. **The Lancet**, v. 375, n. 9723, p. 1365–1374, 2010.

KE, G. et al. LightGBM: A highly efficient gradient boosting decision tree. In: **Advances in Neural Information Processing Systems 30**. [s.n.], 2017. p. 3146–3154. Available from Internet: <<https://papers.nips.cc/paper/6907-lightgbm-a-highly-efficient-gradient-boosting-decision-tree>>.

KHAN, M. A. B. et al. Epidemiology of type 2 diabetes - global burden of disease and forecasted trends. **Journal of Epidemiology and Global Health**, v. 10, n. 1, p. 107–111, mar 2020.

KHAN, R. M. M. et al. From pre-diabetes to diabetes: Diagnosis, treatments and translational research. **Medicina (Kaunas)**, v. 55, n. 9, p. 546, 2019. Available from Internet: <<https://doi.org/10.3390/medicina55090546>>.

KNOWLER, W. C. et al. Reduction in the incidence of type 2 diabetes with lifestyle intervention or metformin. **New England Journal of Medicine**, v. 346, n. 6, p. 393–403, 2002.

KUNCHEVA, L. I. **Combining Pattern Classifiers: Methods and Algorithms**. [S.l.]: John Wiley & Sons, 2004.

LAI, H. et al. Predictive models for diabetes mellitus using machine learning techniques. **BMC Endocr Disord**, v. 19, n. 1, p. 101, 2019. Available from Internet: <<https://doi.org/10.1186/s12902-019-0436-6>>.

LEMAÎTRE, G.; NOGUEIRA, F.; ARIDAS, C. K. Imbalanced-learn: A Python toolbox to tackle the curse of imbalanced datasets in machine learning. **Journal of Machine Learning Research**, v. 18, n. 17, p. 1–5, 2017. Available from Internet: <<https://www.jmlr.org/papers/v18/lemaître17a.html>>.

LI, H. et al. Machine learning-based prediction of diabetic patients using blood routine data. **Methods**, Academic Press, v. 229, p. 156–162, 2024.

LI, L. et al. Hyperband: A novel bandit-based approach to hyperparameter optimization. In: **Journal of Machine Learning Research**. [s.n.], 2018. v. 18, n. 185, p. 1–52. Available from Internet: <<https://www.jmlr.org/papers/v18/li18a.html>>.

LI, X. et al. Interpretable machine learning method to predict the risk of pre-diabetes using a national-wide cross-sectional data: evidence from CHNS. **BMC Public Health**, BioMed Central, v. 25, n. 1, p. 1145, 2025.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems**. Curran Associates, 2017. v. 30, p. 4765–4774. Available from Internet: <<https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>>.

LYU, J.; ISHWARAN, H. Commentary: To classify means to choose a threshold. **The Journal of Thoracic and Cardiovascular Surgery**, v. 165, n. 4, p. 1443–1445, 2023.

MANSOORI, A. et al. Prediction of type 2 diabetes mellitus using hematological factors based on machine learning approaches: A cohort study analysis. **Sci Rep**, v. 13, p. 663, 2023. Available from Internet: <<https://doi.org/10.1038/s41598-022-27340-2>>.

MANSOORI, A. et al. Prediction of type 2 diabetes mellitus using hematological factors based on machine learning approaches: a cohort study analysis. **Sci. Rep.**, Springer Science and Business Media LLC, v. 13, n. 1, p. 663, jan. 2023.

MODZELEWSKI, R. et al. Gestational diabetes mellitus-recent literature review. **Journal of Clinical Medicine**, v. 11, n. 19, p. 5736, 2022.

MUJUMDAR, A.; VAIDEHI, V. Diabetes prediction using machine learning algorithms. **Procedia Computer Science**, v. 165, p. 292–299, 01 2019.

OBERMEYER, Z. et al. Dissecting racial bias in an algorithm used to manage the health of populations. **Science**, American Association for the Advancement of Science, v. 366, n. 6464, p. 447–453, 2019.

O'BRIEN, R.; ISHWARAN, H. A random forests quantile classifier for class imbalanced data. **Pattern Recognition**, v. 90, p. 232–249, 2019.

OSEI-YEBOAH, J. et al. Diabetes mellitus, the fastest growing global public health concern: Early detection should be focused. **Health Science Reports**, v. 7, n. 3, p. e2004, 2024.

PAPATHEODOROU, K. et al. Complications of diabetes 2017. **J Diabetes Res**, v. 2018, p. 3086167, 2018.

PEDREGOSA, F. et al. Scikit-learn: Machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011. Available from Internet: <<https://www.jmlr.org/papers/v12/pedregosa11a.html>>.

PROKHORENKOVA, L. et al. CatBoost: Unbiased boosting with categorical features. In: **Advances in Neural Information Processing Systems 31**. [s.n.], 2018. p. 6638–6648. Available from Internet: <<https://proceedings.neurips.cc/paper/2018/hash/14491b756b3a51daac41c24863285549-Abstract.html>>.

RAMTAHAL, R. et al. Prevalence of self-reported sleep duration and sleep habits in type 2 diabetes patients in south trinidad. **Journal of Epidemiology and Global Health**, v. 5, n. 4 Suppl 1, p. S35–S43, dec. 2015. Epub 2015 Jun 11.

RASCHKA, S. Model evaluation, model selection, and algorithm selection in machine learning. **arXiv preprint arXiv:1811.12808**, 2018. Available from Internet: <<https://arxiv.org/abs/1811.12808>>.

RIFKIN, R.; KLAUTAU, A. In defense of one-vs-all classification. **Journal of Machine Learning Research**, v. 5, p. 101–141, 2004. Available from Internet: <<https://www.jmlr.org/papers/v5/rifkin04a.html>>.

RIJSBERGEN, C. J. van. **Information Retrieval**. 2. ed. London: Butterworth-Heinemann, 1979.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, Nature Publishing Group, v. 323, n. 6088, p. 533–536, 1986.

SAHID, M. A.; BABAR, M. U. H.; UDDIN, M. P. Predictive modeling of multi-class diabetes mellitus using machine learning and filtering iraqi diabetes data dynamics. **PLOS ONE**, Public Library of Science, v. 19, n. 5, p. e0300785, 2024.

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. **PLoS ONE**, v. 10, n. 3, p. e0118432, 2015.

SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. **Information Processing & Management**, v. 45, n. 4, p. 427–437, 2009.

STROBL, C. et al. Conditional variable importance for random forests. **BMC Bioinformatics**, v. 9, p. 307, 2008.

TAHIR, A. et al. Fingerprinting hyperglycemia using predictive modelling approach based on low-cost routine CBC and CRP diagnostics. **Sci. Rep.**, Nature Publishing Group, v. 14, n. 1, p. 1090, jan. 2024.

TAO, X. et al. Predicting three-month fasting blood glucose and glycated hemoglobin changes in patients with type 2 diabetes mellitus based on multiple machine learning algorithms. **Sci. Rep.**, Springer Science and Business Media LLC, v. 13, n. 1, p. 16437, sep. 2023.

TING, K. M.; WITTEN, I. H. Issues in stacked generalization. **Journal of Artificial Intelligence Research**, v. 10, p. 271–289, 1999.

TOMEK, I. Two modifications of CNN. **IEEE Transactions on Systems, Man, and Cybernetics**, SMC-6, n. 11, p. 769–772, 1976.

TWIG, G. et al. White blood cells count and incidence of type 2 diabetes in young men. **Diabetes Care**, American Diabetes Association, v. 36, n. 2, p. 276–282, 2013.

VARMA, S.; SIMON, R. Bias in error estimation when using cross-validation for model selection. **BMC Bioinformatics**, v. 7, p. 91, 2006.

VICKERS, A. J.; CALSTER, B. V.; STEYERBERG, E. W. Net benefit approaches to the evaluation of prediction models, molecular markers, and diagnostic tests. **BMJ**, v. 352, p. i6, 2016.

WANG, J. et al. Status of glycosylated hemoglobin and prediction of glycemic control among patients with insulin-treated type 2 diabetes in North China: a multicenter observational study. **Chinese Medical Journal**, v. 133, n. 1, p. 17–24, 2020.

WANG, Y. et al. The relationship between erythrocytes and diabetes mellitus. **Journal of Diabetes Research**, Hindawi, v. 2021, p. 6656062, 2021.

WHO. **Use of glyated haemoglobin (HbA1c) in diagnosis of diabetes mellitus — who.int**. 2011. <[https://www.who.int/publications-detail-redirect/use-of-glycated-haemoglobin-\(-hba1c\)-in-diagnosis-of-diabetes-mellitus](https://www.who.int/publications-detail-redirect/use-of-glycated-haemoglobin-(-hba1c)-in-diagnosis-of-diabetes-mellitus)>. [Accessed 23-01-2024]. Available from Internet: <[https://www.who.int/publications/i/item/use-of-glycated-haemoglobin-\(-hba1c\)-in-diagnosis-of-diabetes-mellitus](https://www.who.int/publications/i/item/use-of-glycated-haemoglobin-(-hba1c)-in-diagnosis-of-diabetes-mellitus)>.

WILSON, J. M. G.; JUNGNER, G. **Principles and Practice of Screening for Disease**. Geneva: World Health Organization, 1968. (Public Health Papers, 34). Available from Internet: <<https://iris.who.int/handle/10665/37650>>.

WOLPERT, D. H. Stacked generalization. **Neural Networks**, v. 5, n. 2, p. 241–259, 1992.

World Health Organization. **Use of Glycated Haemoglobin (HbA1c) in Diagnosis of Diabetes Mellitus**. 2021. Available from Internet: <[https://www.who.int/publications-detail-redirect/use-of-glycated-haemoglobin-\(-hba1c\)-in-diagnosis-of-diabetes-mellitus](https://www.who.int/publications-detail-redirect/use-of-glycated-haemoglobin-(-hba1c)-in-diagnosis-of-diabetes-mellitus)>.

WU, T.-F.; LIN, C.-J.; WENG, R. C. Probability estimates for multi-class classification by pairwise coupling. **Journal of Machine Learning Research**, Microtome Publishing, v. 5, p. 975–1005, 2004. Available from Internet: <<https://www.jmlr.org/papers/v5/wu04a.html>>.

ZACCARDI, F. et al. Platelet mean volume, distribution width, and count in type 2 diabetes, impaired fasting glucose, and metabolic syndrome: a meta-analysis. **Diabetes/Metabolism Research and Reviews**, Wiley, v. 31, n. 4, p. 402–410, 2015.

ZIMMET, P. Z. et al. Diabetes: a 21st century challenge. **The Lancet Diabetes & Endocrinology**, v. 2, n. 1, p. 56–64, 2014. ISSN 2213-8587. Available from Internet: <<https://www.sciencedirect.com/science/article/pii/S2213858713701128>>.

APÊNDICE A — CONFIGURAÇÕES DETALHADAS DOS PIPELINES

Este apêndice apresenta as configurações detalhadas dos 28 *pipelines* de aprendizado de máquina executados neste trabalho. A Tabela A.1 lista cada *pipeline* com sua categoria experimental (C1, C2 ou C3, conforme definido na Seção 4.4), o preprocessor utilizado, o método de reamostragem e o algoritmo classificador.

Os 28 *pipelines* foram executados em todas as tarefas binárias (T1 e T3, incluindo todos os seis subproblemas de T3) com a mesma estrutura. A Tarefa 2 utiliza variações nos preprocessadores conforme a Tabela 4.3. Foram definidos originalmente 34 *pipelines*, porém 6 configurações baseadas em KNN foram excluídas em função do custo computacional proibitivo ($O(n^2)$) para o volume de dados utilizado.

Tabela A.1 – Configurações detalhadas dos 28 *pipelines* de aprendizado de máquina executados por tarefa de classificação nas tarefas binárias (T1 e T3). A Tarefa 2 utiliza variações nos preprocessadores conforme Tabela 4.3.

#	<i>Pipeline</i>	Cat.	Preprocessador	<i>Sampler</i>	Classificador
1	(C1) MLP + Std + MinMax	C1	<i>StandardScaler</i> + <i>MinMaxScaler</i>	SMOTE ($k=5$)	MLP
2	(C1) Decision Tree + Std	C1	<i>StandardScaler</i>	SMOTE ($k=5$)	<i>Decision Tree</i>
3	(C1) Decision Tree + Std + MinMax	C1	<i>StandardScaler</i> + <i>MinMaxScaler</i>	SMOTE ($k=5$)	<i>Decision Tree</i>
4	(C1) Decision Tree + MinMax	C1	<i>MinMaxScaler</i>	SMOTE ($k=5$)	<i>Decision Tree</i>
5	(C1) Bagging + MinMax	C1	<i>MinMaxScaler</i>	SMOTE ($k=5$)	<i>Bagging</i> (DT)
6	(C1) Bagging + Std	C1	<i>StandardScaler</i>	SMOTE ($k=5$)	<i>Bagging</i> (DT)
7	(C1) Bagging + Std + MinMax	C1	<i>StandardScaler</i> + <i>MinMaxScaler</i>	SMOTE ($k=5$)	<i>Bagging</i> (DT)
8	(C1) Gradient Boosting + MinMax	C1	<i>MinMaxScaler</i>	SMOTE ($k=5$)	<i>Gradient Boosting</i>
9	(C1) AdaBoost + MinMax	C1	<i>MinMaxScaler</i>	SMOTE ($k=5$)	AdaBoost
10	(C1) Logistic Regression + Std	C1	<i>StandardScaler</i>	SMOTE ($k=5$)	<i>Logistic Regression</i>
11	(C1) Logistic Regression + MinMax	C1	<i>MinMaxScaler</i>	SMOTE ($k=5$)	<i>Logistic Regression</i>
12	(C2) Decision Tree	C2	<i>RobustScaler</i> + <i>QuantileTransformer</i>	SMOTE ($k=5$)	<i>Decision Tree</i>
13	(C2) Random Forest	C2	<i>RobustScaler</i> + <i>QuantileTransformer</i>	SMOTE ($k=5$)	<i>Random Forest</i>
14	(C2) HistGradientBoosting	C2	<i>passthrough</i>	SMOTE ($k=5$)	<i>HistGradientBoosting</i>
15	(C2) XGBoost	C2	<i>RobustScaler</i> + <i>QuantileTransformer</i>	SMOTE ($k=5$)	XGBoost
16	(C2) LightGBM	C2	<i>passthrough</i>	SMOTE ($k=5$)	LightGBM
17	(C2) CatBoost	C2	<i>RobustScaler</i> + <i>QuantileTransformer</i>	SMOTE ($k=5$)	CatBoost
18	(C2) Logistic Regression	C2	<i>RobustScaler</i> + <i>QuantileTransformer</i>	SMOTE ($k=5$)	<i>Logistic Regression</i>
19	(C2) LinearSVC	C2	<i>RobustScaler</i> + <i>QuantileTransformer</i>	SMOTE ($k=5$)	LinearSVC
20	(C2) MLP	C2	<i>RobustScaler</i> + <i>QuantileTransformer</i>	SMOTE ($k=5$)	MLP
21	(C3) Logistic Regression + Quantile + ClassWeight	C3	<i>QuantileTransformer</i> (esparso)	<i>class_weight</i>	<i>Logistic Regression</i>
22	(C3) LinearSVC + Std + ROS	C3	<i>StandardScaler</i>	ROS	LinearSVC
23	(C3) MLP + Quantile + SMOTEENN	C3	<i>RobustScaler</i> + <i>QuantileTransformer</i>	SMOTEENN	MLP
24	(C3) Decision Tree + TomekLinks	C3	<i>passthrough</i>	<i>TomekLinks</i>	<i>Decision Tree</i>
25	(C3) Bagging + RUS	C3	<i>passthrough</i>	RUS	<i>Bagging</i> (DT)
26	(C3) Random Forest + SMOTEENN	C3	<i>passthrough</i>	SMOTEENN	<i>Random Forest</i>
27	(C3) XGBoost + SMOTETomek	C3	<i>passthrough</i>	SMOTETomek	XGBoost
28	(C3) CatBoost + ClassWeight	C3	<i>passthrough</i> (esparso)	<i>class_weight</i>	CatBoost

Elaborado pelo autor.

APÊNDICE B — CARACTERIZAÇÃO DETALHADA DA BASE DE DADOS

Este apêndice apresenta a caracterização detalhada dos 23 atributos preditivos da base de dados final ($n = 169.999$), em complemento à análise exploratória da Seção 4.1.5. A Tabela B.1 apresenta as estatísticas descritivas (média, mediana, desvio padrão, mínimo, máximo e quartis) de cada atributo numérico. A Figura B.1 apresenta os histogramas individuais dos 23 atributos, evidenciando a forma das distribuições e a ocorrência de parâmetros raros do hemograma. A Figura B.2 apresenta *boxplots* dos atributos do hemograma estratificados pelas três classes glicêmicas (Normal, Pré-diabetes, Diabetes), permitindo visualizar diferenças sistemáticas entre as classes.


Tabela B.1 – Estatísticas descritivas dos 23 atributos preditivos e da variável-alvo A1c na base final ($n = 169.999$). Valores expressos nas unidades de medida originais conforme Tabela 4.1.

Atributo	n	Média	Mediana	DP	Mín	P25	P75	Máx
Leucócitos	169.999	6950,07	6600,00	2122,39	1100,00	5500,00	8000,00	81500,00
Mielócitos	169.999	0,36	0,00	9,88	0,00	0,00	0,00	1164,00
Metamielócitos	169.999	0,22	0,00	7,87	0,00	0,00	0,00	1358,00
Bastões	169.999	7,51	0,00	83,42	0,00	0,00	0,00	9920,00
Segmentados	169.999	3922,76	3614,00	1656,46	-2107,00	2840,00	4625,00	39705,00
Eosinófilos	169.999	208,22	161,00	206,12	0,00	101,00	251,00	9380,00
Basófilos	169.999	32,93	30,00	24,77	0,00	15,00	46,00	356,00
Linfócitos	169.999	2236,31	2139,00	812,18	0,00	1724,00	2635,00	71802,00
Linfócitos Atípicos	169.999	0,68	0,00	14,70	0,00	0,00	0,00	1472,00
Monócitos	169.999	541,05	514,00	189,93	0,00	414,00	636,00	5995,00
Plasmócitos	169.999	0,01	0,00	1,01	0,00	0,00	0,00	261,00
Blastos	169.999	0,01	0,00	2,51	0,00	0,00	0,00	990,00
Promielócitos	169.999	0,00	0,00	0,56	0,00	0,00	0,00	202,00
Eritrócitos	169.999	4,57	4,56	0,48	1,29	4,27	4,87	8,16
Hemoglobina	169.999	13,84	13,80	1,44	3,90	13,00	14,80	22,50
Hematócrito	169.999	40,66	40,60	4,02	12,10	38,20	43,20	68,00
HCM	169.999	89,20	89,30	4,98	47,50	86,40	92,10	137,50
CHCM	169.999	34,04	34,10	0,88	25,20	33,50	34,60	37,10
RDW	169.999	13,54	13,40	1,11	9,10	12,90	13,90	39,30
Plaquetas	169.999	239,23	232,00	65,19	0,00	195,00	275,00	1212,00
VPM	169.999	9,34	9,20	1,14	5,00	8,50	10,00	15,30
Idade	169.999	52,14	53,00	17,54	0,00	40,00	65,00	109,00
A1C	169.999	6,13	5,60	1,54	2,30	5,30	6,20	18,40

Elaborado pelo autor.

Figura B.1 – Histogramas individuais dos 23 atributos preditivos da base de dados final. Os atributos do hemograma com ocorrência rara (Mielócitos, Metamielócitos, Bastões, Linfócitos Atípicos, Plasmócitos, Blastos e Promielócitos) apresentam distribuição concentrada em zero, refletindo sua baixa incidência clínica em populações sem patologias hematológicas específicas. Esses atributos podem apresentar registros com valores diferentes de zero, porém em proporção tão reduzida em relação aos valores nulos que não são visualmente perceptíveis na escala dos histogramas; a Tabela B.1 reporta os valores máximos observados para cada atributo.


Distribuição dos 23 atributos preditivos da base (n = 169.999)



Elaborado pelo autor.

Figura B.2 – Distribuição dos 21 atributos do hemograma estratificados pelas três classes glicêmicas. Para os atributos cujos três quartis (P25, mediana, P75) valem zero em todas as classes (Mielócitos, Metamielócitos, Bastões, Linfócitos Atípicos, Plasmócitos, Blastos e Promielócitos, identificados pelo sufixo “raro”), o *boxplot* ficaria apenas em uma linha; nesses casos é apresentado um gráfico de barras com a percentagem de registros não nulos por classe, que constitui a informação clinicamente relevante. Para os demais atributos, o *boxplot* segue as convenções usuais (mediana, intervalo interquartílico e bordas a 1,5 vezes o intervalo interquartílico), com os eixos verticais limitados aos percentis 1 e 99 de cada atributo para fins de visualização, sem alterar os dados utilizados.

Distribuição dos atributos do hemograma por classe glicêmica



Elaborado pelo autor.