

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO DE INFORMÁTICA
PROGRAMA DE PÓS-GRADUAÇÃO EM COMPUTAÇÃO

GABRIELA BELLARDINELLI OLIVEIRA

***Fairness* em Modelos de Classificação para
Dados Tabulares de Saúde: Uma
Comparação Experimental Multimétrica de
Métodos de Mitigação de Viés**

Dissertação apresentada como requisito parcial
para a obtenção do grau de Mestre em Ciência da
Computação

Orientador: Prof^a. Dr^a. Mariana Recamonde
Mendoza

Porto Alegre
2026

CIP — CATALOGAÇÃO NA PUBLICAÇÃO

Oliveira, Gabriela Bellardinelli

Fairness em Modelos de Classificação para Dados Tabulares de Saúde: Uma Comparação Experimental Multimétrica de Métodos de Mitigação de Viés / Gabriela Bellardinelli Oliveira. – Porto Alegre: PPGC da UFRGS, 2026.

159 f.: il.

Dissertação (mestrado) – Universidade Federal do Rio Grande do Sul. Programa de Pós-Graduação em Computação, Porto Alegre, BR-RS, 2026. Orientador: Mariana Recamonde Mendoza.

1.

Fairness. 2. Mitigação de viés. 3. Aprendizado de máquina. 4. Métodos *in-processing*. 5. Dados de Saúde. I. Recamonde Mendoza, Mariana. II. Título.

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

Reitora: Prof^a. Marcia Cristina Bernardes Barbosa

Vice-Reitor: Prof. Pedro de Almeida Costa

Pró-Reitora de Pós-Graduação: Prof^a. Claudia Wasserman

Diretor do Instituto de Informática: Prof. Luciano Paschoal Gaspar

Coordenador do PPGC: Prof. Gabriel Luca Nazar

Bibliotecário-chefe do Instituto de Informática: Alexsander Borges Ribeiro

SUMÁRIO

LISTA DE ABREVIATURAS E SIGLAS	5
LISTA DE SÍMBOLOS	6
LISTA DE FIGURAS	8
LISTA DE TABELAS	10
RESUMO	13
ABSTRACT	14
1 INTRODUÇÃO	15
2 FUNDAMENTAÇÃO TEÓRICA	20
2.1 Aprendizado de máquina	20
2.1.1 Problema de classificação binária em aprendizado supervisionado	20
2.1.2 <i>Underfitting</i> , <i>overfitting</i> e regularização	21
2.1.3 Algoritmos de aprendizado supervisionado	22
2.1.4 <i>Pipeline</i> de desenvolvimento de modelos	25
2.1.5 Métricas de desempenho	26
2.1.6 Validação cruzada	27
2.2 Fundamentos de <i>fairness</i> e viés em aprendizado de máquina	28
2.3 Critérios e métricas de <i>fairness</i>	29
2.3.1 Paridade Estatística/Demográfica	31
2.3.2 Matriz de Confusão	32
2.3.3 <i>Fairness</i> individual	33
2.3.4 Relações entre métricas e instabilidade	34
2.3.5 Valores ideais para métricas de <i>fairness</i>	35
2.4 Métodos de mitigação de viés	35
2.4.1 Métodos <i>pre-processing</i> de mitigação de viés	36
2.4.1.1 <i>Reweighting</i>	36
2.4.1.2 <i>Disparate Impact Remover</i>	36
2.4.2 Métodos <i>in-processing</i> de mitigação de viés	37
2.4.2.1 <i>Grid Search Reduction</i>	37
2.4.2.2 <i>Prejudice Remover</i>	38
2.4.2.3 <i>FairGBM</i>	39
2.4.2.4 <i>Adversarial Debiasing</i>	40
2.4.2.5 <i>Wasserstein Fair Classification</i>	40
2.5 Base estatística para comparações múltiplas: Friedman–Holm	41
2.5.1 Teste de Friedman	41
2.5.2 Procedimento de Holm	43
3 TRABALHOS RELACIONADOS	44
4 METODOLOGIA	50
4.1 Métricas de avaliação	50
4.2 Métodos avaliados e configurações experimentais	52
4.2.1 Modelos de referência sem mitigação (<i>baselines</i>)	52
4.2.2 Métodos de mitigação de viés e hiperparâmetros	53
4.3 <i>Pipeline</i> experimental	55
4.3.1 Divisão estratificada dos dados e padronização	55
4.3.2 Procedimento de treinamento e avaliação	56
4.4 Estratégia de análise e interpretação dos resultados	56
4.4.1 Agregação dos resultados e medidas relativas	57
4.4.2 Elegibilidade	59
4.4.3 Análise estatística	60

4.5 Conjunto de dados analisados	61
4.5.1 Caracterização qualitativa e pré processamento aplicado	61
4.5.2 Caracterização quantitativa	64
5 RESULTADOS	67
5.1 Avaliação dos <i>baselines</i>: diagnóstico de desempenho e <i>fairness</i>	67
5.1.1 Desempenho preditivo dos modelos	68
5.1.2 Análise de <i>fairness</i> dos modelos	69
5.1.3 Discussão	72
5.2 RQ1 — Quais métodos e tipos de intervenção apresentam maior efeito global de mitigação em <i>fairness</i>, em comparação ao <i>baseline</i>?	73
5.2.1 Métricas de paridade estatística (Categoria A)	74
5.2.2 Métricas de <i>fairness</i> individual (Categoria B)	75
5.2.3 Métricas de matriz de confusão (Categoria C)	77
5.2.4 Discussão	81
5.3 RQ2 — Os resultados de mitigação observados na análise global se mantêm quando restrita aos conjuntos com disparidade relevante e estratificada por categoria de métrica?	83
5.3.1 Métricas de paridade estatística (Categoria A)	84
5.3.2 Métricas de <i>fairness</i> individual (Categoria B)	86
5.3.3 Métricas de matriz de confusão (Categoria C)	89
5.3.4 Discussão	92
5.4 RQ3 — Como a intensidade do viés no <i>baseline</i> influencia o efeito de mitigação obtido pelos métodos?	94
5.4.1 Discussão	101
5.5 RQ4 — Como o sentido do viés afeta o ganho de <i>fairness</i> obtido pelos métodos?	102
5.5.1 Discussão	108
5.6 RQ5 — Qual é o <i>trade-off</i> entre desempenho preditivo e ganho em <i>fairness</i> obtido pelos métodos de mitigação?	109
5.6.1 Discussão	113
6 CONCLUSÃO	116
6.1 Limitações	121
6.2 Trabalhos futuros	122
REFERÊNCIAS	124
APÊNDICE A — RESULTADOS ESTATÍSTICOS COMPLEMENTARES	131
A.1 Resultados de análise pós-hoc de efeitos globais	131
A.2 Resultados de análise pós-hoc considerando conjuntos elegíveis por categoria de métrica	133
APÊNDICE B — DISTRIBUIÇÃO POR QUADRANTES DO <i>TRADE-OFF</i> ENTRE <i>FAIRNESS</i> E DESEMPENHO	136
B.1 Categoria A — paridade estatística	136
B.2 Categoria B — <i>fairness</i> individual	136
B.3 Categoria C — matriz de confusão	137
APÊNDICE C — RESULTADOS COMPLEMENTARES DE DESEMPENHO PREDITIVO	139
APÊNDICE D — RESULTADOS COMPLEMENTARES: INTENSIDADE, SENTIDO E <i>TRADE-OFF</i> ENTRE DESEMPENHO E <i>FAIRNESS</i>	146
D.1 Estatística descritiva detalhada	146
D.2 Estatística descritiva de <i>trade-off</i> por categoria	156
D.3 Estatística descritiva de <i>trade-off</i> por método	157

LISTA DE ABREVIATURAS E SIGLAS

DFBA	<i>Differential Fairness Bias Amplification</i> (amplificação de viés em <i>fairness</i> diferencial)
DI	<i>Disparate Impact</i> (impacto díspar)
ERR	<i>Error Rate</i> (taxa de erro)
FDR	<i>False Discovery Rate</i> (taxa de falsa descoberta)
FDRD	<i>False Discovery Rate Difference</i> (diferença de taxa de falsa descoberta)
FN	<i>False Negative</i> (falso negativo)
FNR	<i>False Negative Rate</i> (taxa de falsos negativos)
FNRD	<i>False Negative Rate Difference</i> (diferença de taxa de falsos negativos)
FP	<i>False Positive</i> (falso positivo)
FPR	<i>False Positive Rate</i> (taxa de falsos positivos)
GEI	<i>Generalized Entropy Index</i> (índice de entropia generalizada)
IQR	<i>Interquartile Range</i> (intervalo interquartil)
TN	<i>True Negative</i> (verdadeiro negativo)
TP	<i>True Positive</i> (verdadeiro positivo)
TPR	<i>True Positive Rate</i> (taxa de verdadeiros positivos)

LISTA DE SÍMBOLOS

$\mathcal{D}$	Conjunto de dados rotulados
$\mathcal{A}$	Domínio (conjunto de valores) do atributo sensível
$\mathbb{R}^d$	Espaço de <i>features</i> de dimensão d
x_i	Vetor de <i>features</i> da i -ésima instância
y_i	Rótulo verdadeiro da i -ésima instância
$\hat{y}_i$	Rótulo predito da i -ésima instância
Y	Variável aleatória do rótulo verdadeiro
$\hat{Y}$	Variável aleatória da predição do classificador
A	Atributo sensível (protegido)
a, a_i, a_j	Valores do atributo sensível
S	<i>Score</i> contínuo produzido pelo modelo
s_i	<i>Score</i> da i -ésima instância
w	Vetor de pesos do modelo
b	Termo de viés (<i>bias</i>)
f_θ	Função preditora parametrizada por θ
θ	Vetor de parâmetros do modelo
τ	Limiar de decisão
$\mathcal{L}$	Função de perda
$\Omega(\theta)$	Termo de regularização (penalização de complexidade)
λ	Parâmetro de regularização ou multiplicador de Lagrange
η	Taxa de aprendizado ou parâmetro de penalização
z	Preditor linear (combinação linear pré-ativação)
net	Entrada efetiva de um neurônio
f	Função de ativação de um neurônio

w_{jl}	Peso da conexão entre os neurônios j e l
δ_l	Termo de erro do neurônio l no <i>backpropagation</i>
t	Índice de iteração do treinamento
m^*	Valor ideal de uma métrica de <i>fairness</i>
$d(m)$	Distância ao valor ideal (aditiva ou multiplicativa)
$\delta(m)$	Distância ao ideal com sinal (sem módulo)
$u(m)$	Distância ao ideal em unidades normalizadas
S_m	Escala robusta da métrica (intervalo interquartil)
Δ_{fair}	Efeito de mitigação em <i>fairness</i>
Δ_{F1}	Efeito de mitigação em desempenho (F_1)
r_{fair}	Efeito relativo (fração removida do viés)
ξ	Termo de estabilização no cálculo de r_{fair}
k	Número de tratamentos (métodos comparados)
n	Número de blocos (conjuntos de dados)
r_{ij}	<i>Rank</i> do tratamento j no bloco i
$R_{\cdot j}$	<i>Rank</i> médio do tratamento j
χ^2	Distribuição qui-quadrado
$p_{(i)}^{\text{Holm}}$	p -valor ajustado pelo procedimento de Holm
M	Número de hipóteses testadas (comparações pós-hoc)
α	Nível de significância

LISTA DE FIGURAS

Figura 1.1 Taxonomia dos métodos de mitigação de viés segundo o estágio do <i>pipeline</i> de aprendizado de máquina em que atuam.	17
Figura 2.1 Desenho esquemático de rede neural artificial de múltiplas camadas.	24
Figura 2.2 Matriz de confusão para classificação binária.	26
Figura 4.1 Diagrama esquemático do <i>pipeline</i> aplicado nos experimentos realizados. São realizadas 10 repetições de validação cruzada com 3 <i>folds</i>	55
Figura 4.2 Distribuição do rótulo alvo por grupo sensível.	65
Figura 4.3 Conjunto Obesity: Distribuição de <i>weight</i> por grupo sensível e por variável resposta.	66
Figura 5.1 Distância do <i>baseline</i> para o valor ideal por métrica de <i>fairness</i>	69
Figura 5.2 Distância ao ideal no <i>baseline</i> (d_{baseline}) por métrica, decomposta pelos componentes do <i>baseline</i> (LR/RF; <i>aware/unaware</i>).	70
Figura 5.3 Efeito de mitigação em <i>fairness</i> (Δ_{fair}) por tipo de intervenção nas métricas de paridade estatística.	74
Figura 5.4 Efeito de mitigação em <i>fairness</i> (Δ_{fair}) por método nas métricas de paridade estatística.	75
Figura 5.5 Efeito de mitigação em <i>fairness</i> (Δ_{fair}) por categoria nas métricas de <i>fairness</i> individual.	76
Figura 5.6 Efeito de mitigação em <i>fairness</i> (Δ_{fair}) por método nas métricas de <i>fairness</i> individual.	77
Figura 5.7 Efeito de mitigação em <i>fairness</i> (Δ_{fair}) por categoria nas métricas baseadas em matriz de confusão.	78
Figura 5.8 Efeito de mitigação em <i>fairness</i> (Δ_{fair}) por método nas métricas baseadas em matriz de confusão.	79
Figura 5.9 Efeito de mitigação na categoria A por tipo de intervenção.	84
Figura 5.10 Efeito de mitigação na categoria A por método de mitigação.	86
Figura 5.11 Efeito de mitigação na categoria B por tipo de intervenção.	87
Figura 5.12 Efeito de mitigação na categoria B por método de mitigação.	89
Figura 5.13 Efeito de mitigação na categoria C por tipo de intervenção.	90
Figura 5.14 Efeito de mitigação na categoria C por método de mitigação.	93
Figura 5.15 Intensidade e direção do viés no <i>baseline</i> em relação ao impacto díspar.	96
Figura 5.16 Intensidade e direção do viés no <i>baseline</i> em relação à amplificação de viés.	97
Figura 5.17 Intensidade e direção do viés no <i>baseline</i> em relação a consistência.	98
Figura 5.18 Intensidade e direção do viés no <i>baseline</i> em relação ao índice de entropia generalizada.	98
Figura 5.19 Intensidade e direção do viés no <i>baseline</i> em relação a diferença da taxa de falsos negativos.	99
Figura 5.20 Intensidade e direção do viés no <i>baseline</i> em relação a diferença da taxa de falsa descoberta.	100
Figura 5.21 Intensidade e direção do viés no <i>baseline</i> em relação a diferença da taxa de erro.	100
Figura 5.22 Direção do viés no <i>baseline</i> e resultado de mitigação no impacto díspar.	104
Figura 5.23 Direção do viés no <i>baseline</i> e resultado de mitigação na amplificação de viés.	105

Figura 5.24 Direção do viés no <i>baseline</i> e resultado de mitigação na diferença da taxa de falso negativo.....	106
Figura 5.25 Direção do viés no <i>baseline</i> e resultado de mitigação na diferença da taxa de falsa descoberta.	107
Figura 5.26 Direção do viés no <i>baseline</i> e resultado de mitigação na diferença da taxa de erro.....	107
Figura 5.27 Fronteira de Pareto entre desempenho preditivo e ganho em <i>fairness</i> nas métricas de paridade estatística (categoria A).	110
Figura 5.28 Fronteira de Pareto entre desempenho preditivo e ganho em <i>fairness</i> nas métricas de <i>fairness</i> individual (categoria B).	111
Figura 5.29 Fronteira de Pareto entre desempenho preditivo e ganho em <i>fairness</i> nas diferenças de taxa de falsos negativos e de falsa descoberta (categoria C).	112
Figura 5.30 Fronteira de Pareto entre desempenho preditivo e ganho em <i>fairness</i> na diferença da taxa de erro.	113
Figura B.1 Distribuição por quadrantes do <i>trade-off</i> entre desempenho preditivo e ganho em <i>fairness</i> nas métricas de paridade estatística (categoria A).....	136
Figura B.2 Distribuição por quadrantes do <i>trade-off</i> entre desempenho preditivo e ganho em <i>fairness</i> nas métricas de <i>fairness</i> individual (categoria B).....	137
Figura B.3 Distribuição por quadrantes do <i>trade-off</i> entre desempenho preditivo e ganho em <i>fairness</i> nas métricas baseadas em matriz de confusão (categoria C)..	138

LISTA DE TABELAS

Tabela 3.1 Comparação dos trabalhos relacionados quanto ao escopo experimental e ao protocolo de análise, incluindo o presente trabalho como última linha. A coluna <i>Etapas</i> indica em quais etapas do <i>pipeline</i> os métodos de mitigação avaliados atuam: <i>pre-processing</i> (Pre), <i>in-processing</i> (In) e <i>post-processing</i> (Post). A coluna <i>Fairness</i> discrimina o uso de métricas de grupo (Grupo) e/ou individuais (Individual).	48
Tabela 4.1 Métricas utilizadas, com o identificador do <i>cluster</i> de origem segundo Majumder et al. (2022) e a categoria adotada neste trabalho. O identificador na coluna ID <i>Cluster</i> corresponde ao agrupamento empírico de métricas de comportamento semelhante definido naquele estudo. A consistência aparece sem identificador (–) porque a formulação aqui adotada, baseada nas previsões, difere da empregada por aqueles autores, baseada nos rótulos verdadeiros, não se associando a nenhum <i>cluster</i> daquele estudo.	51
Tabela 4.2 Resumo dos métodos de mitigação de viés e hiperparâmetros adotados.	54
Tabela 4.3 Descrição dos conjuntos de dados, com definição do atributo protegido, rótulo favorável e composição amostral.	64
Tabela 5.1 Estatísticas de desempenho preditivo do <i>baseline</i> .	68
Tabela 5.2 Estatísticas de desempenho preditivo do <i>baseline</i> por conjunto de dados.	68
Tabela 5.3 Distância ao ideal $d(m)$ no <i>baseline</i> por métrica e conjunto de dados. Categorias: A (paridade estatística), B (fairness individual) e C (matriz de confusão). Valores acima do limiar são acompanhados do sentido do viés: U = contra o grupo não privilegiado; P = contra o grupo privilegiado; (✓) = elegível sem sentido direcional (categoria B). Valores abaixo do limiar não recebem marcação — indica distância nula.	71
Tabela 5.4 Cobertura por categoria de métricas de <i>fairness</i> . As categorias são A (paridade estatística), B (fairness individual) e C (matriz de confusão). <i>Elegíveis</i> indica quantos conjuntos de dados ultrapassam o limiar de disparidade ($d(m) \geq d_{\min}$) para cada métrica; <i>Eleg. cat.</i> é o número de conjuntos de dados elegíveis em pelo menos uma métrica da categoria (união); <i>Cobertura</i> é a fração correspondente do total de conjuntos de dados.	72
Tabela 5.5 Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.	79
Tabela 5.6 Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.	80
Tabela 5.7 Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.	85
Tabela 5.8 Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.	86
Tabela 5.9 Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.	87
Tabela 5.10 Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.	89
Tabela 5.11 Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.	91
Tabela 5.12 Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.	91
Tabela 5.13 Distribuição de conjuntos de dados por direção do viés (U/P) e categoria de padrão.	103
Tabela A.1 Resultados consolidados do pós-hoc vs <i>Baseline</i> (por categoria). Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.	131
Tabela A.2 Pós-hoc vs <i>Baseline</i> (por experimento) — Amplificação de viés. Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.	132

Tabela A.3 Pós-hoc vs <i>Baseline</i> (por experimento) — Impacto Díspar. Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.	132
Tabela A.4 Pós-hoc vs <i>Baseline</i> (por experimento) — Consistência. Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.	132
Tabela A.5 Pós-hoc vs <i>Baseline</i> (por experimento) — Diferença de Taxa de Falsa Descoberta. Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.	132
Tabela A.6 Resultados consolidados do pós-hoc vs <i>Baseline</i> (por categoria). Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.	133
Tabela A.7 Pós-hoc vs <i>Baseline</i> (por experimento) — Impacto Díspar. Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.	133
Tabela A.8 Pós-hoc vs <i>Baseline</i> (por experimento) — Amplificação de viés. Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.	133
Tabela A.9 Resultados consolidados do pós-hoc vs <i>Baseline</i> (por categoria). Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.	134
Tabela A.10 Pós-hoc vs <i>Baseline</i> (por experimento) — Consistência. Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.	134
Tabela A.11 Resultados consolidados do pós-hoc vs <i>Baseline</i> (por categoria). Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.	134
Tabela A.12 Pós-hoc vs <i>Baseline</i> (por experimento) — Diferença de Taxa de Falsa Descoberta. Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.	135
Tabela C.1 Estatísticas de desempenho por experimento e conjunto — Heart Disease	139
Tabela C.2 Estatísticas de desempenho por experimento e conjunto — Aids	140
Tabela C.3 Estatísticas de desempenho por experimento e conjunto — Obesity	141
Tabela C.4 Estatísticas de desempenho por experimento e conjunto — Arrhythmia ...	142
Tabela C.5 Estatísticas de desempenho por experimento e conjunto — Mental	143
Tabela C.6 Estatísticas de desempenho por experimento e conjunto — Diabetes.....	144
Tabela D.1 Distância ao ideal no <i>baseline</i> (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica amplificação de viés . $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobrecorreção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.	146
Tabela D.2 Distância ao ideal no <i>baseline</i> (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica impacto díspar . $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobrecorreção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.	147
Tabela D.3 Distância ao ideal no <i>baseline</i> (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica consistência . $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobrecorreção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.	149
Tabela D.4 Distância ao ideal no <i>baseline</i> (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica índice de entropia generalizada . $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobrecorreção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.	150

Tabela D.5 Distância ao ideal no <i>baseline</i> (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica diferença da taxa de falsos negativos . $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobre-correção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.	152
Tabela D.6 Distância ao ideal no <i>baseline</i> (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica diferença da taxa de falsa descoberta . $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobre-correção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.	153
Tabela D.7 Distância ao ideal no <i>baseline</i> (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica diferença da taxa de erro . $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobre-correção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.	154
Tabela D.8 Resumo de <i>trade-off</i> por categoria: Amplificação de viés. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	156
Tabela D.9 Resumo de <i>trade-off</i> por categoria: Impacto Díspar. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	156
Tabela D.10 Resumo de <i>trade-off</i> por categoria: Consistência. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	156
Tabela D.11 Resumo de <i>trade-off</i> por categoria: Índice de Entropia Generalizada. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	156
Tabela D.12 Resumo de <i>trade-off</i> por categoria: Diferença de Taxa de Falsos Negativos. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	157
Tabela D.13 Resumo de <i>trade-off</i> por categoria: Diferença de Taxa de Falsa Descoberta. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	157
Tabela D.14 Resumo de <i>trade-off</i> por categoria: Diferença de Taxa de Erro. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	157
Tabela D.15 Resumo de <i>trade-off</i> por método: Amplificação de viés. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	157
Tabela D.16 Resumo de <i>trade-off</i> por método: Impacto Díspar. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	158
Tabela D.17 Resumo de <i>trade-off</i> por método: Consistência. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	158
Tabela D.18 Resumo de <i>trade-off</i> por método: Índice de Entropia Generalizada. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	158
Tabela D.19 Resumo de <i>trade-off</i> por método: Diferença de Taxa de Falsos Negativos. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	159
Tabela D.20 Resumo de <i>trade-off</i> por método: Diferença de Taxa de Falsa Descoberta. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	159
Tabela D.21 Resumo de <i>trade-off</i> por método: Diferença de Taxa de Erro. $\Delta_{\text{fair}} > 0$ indica melhoria de <i>fairness</i> ; $\Delta_{F1} > 0$ indica melhoria de desempenho.	159

RESUMO

O uso de aprendizado de máquina (AM) em aplicações da área da saúde, como diagnóstico, predição de risco e apoio à decisão clínica, vem crescendo rapidamente, trazendo preocupação com vieses algorítmicos que possam reproduzir ou amplificar desigualdades entre grupos de pacientes. Embora a literatura de *fairness* tenha proposto diversas técnicas de mitigação, ainda há lacunas sobre o comportamento relativo dessas abordagens, especialmente quanto às estratégias *in-processing*, que incorporam critérios de equidade diretamente no processo de aprendizado. Este trabalho tem como objetivo comparar de forma sistemática métodos de mitigação de viés em tarefas de classificação binária, com ênfase em abordagens *in-processing*, situando-os em relação a modelos de referência (*baselines*) sem mitigação e a técnicas *pre-processing*, sob um protocolo experimental controlado. Foram avaliados sete métodos de mitigação aplicados a seis conjuntos de dados da área da saúde, considerando métricas de *fairness* de grupo e individual, além do desempenho preditivo. A análise foi organizada em torno de cinco perguntas de pesquisa, abrangendo o efeito global de mitigação, a robustez dos resultados em conjuntos com disparidade relevante, a influência da intensidade e do sentido do viés no *baseline* sobre os ganhos obtidos e o *trade-off* entre desempenho e equidade. A validação estatística empregou o teste de Friedman com pós-hoc de Holm. Os resultados indicam que os maiores ganhos de mitigação concentram-se nas métricas de paridade estatística, em especial no Impacto Díspar, no qual os métodos *in-processing* apresentaram efeito mediano positivo e estatisticamente significativo. As métricas de *fairness* individual exibiram predominantemente degradação ou ausência de efeito, e as métricas baseadas em matriz de confusão apresentaram comportamento ruidoso, sugerindo redistribuição de erros entre grupos. Quanto ao *trade-off*, a perda de desempenho associada à mitigação é frequente: ganhos simultâneos de equidade e desempenho são raros e dependem do conjunto de dados, e métodos com maiores ganhos em paridade estatística tendem a degradar outras dimensões de *fairness*, sobretudo a individual. Nenhum método se mostrou universalmente dominante, e a elevada variabilidade entre conjuntos reforça a necessidade de definir previamente as dimensões de equidade prioritárias e avaliar as abordagens caso a caso. Esses achados contribuem para o entendimento das vantagens e limitações dos métodos *in-processing* e oferecem subsídios para a sua aplicação em projetos práticos de AM em contextos sensíveis.

Palavras-chave: *Fairness*. Mitigação de viés. Aprendizado de máquina. Métodos *in-processing*. Dados de Saúde.

Fairness in Machine Learning: A Multi-Metric Experimental Comparison of Bias Mitigation Methods on Healthcare Data

ABSTRACT

The use of machine learning (ML) models in healthcare applications, such as diagnosis, risk prediction, and clinical decision support, has grown rapidly, raising concerns that algorithmic biases may reproduce or amplify inequalities among patient groups. Although the fairness literature has proposed several mitigation techniques, gaps remain regarding the relative behavior of these approaches, especially for in-processing strategies, which incorporate equity criteria directly into the learning process. This work systematically compares bias mitigation methods, with an emphasis on in-processing approaches, situating them in relation to baseline models without mitigation and to pre-processing techniques, under a controlled experimental protocol. Seven mitigation methods were evaluated across six healthcare datasets, considering group and individual fairness metrics, alongside predictive performance. The analysis addressed five research questions, covering the overall effect of mitigation, the robustness of results on datasets with relevant disparity, how the intensity and direction of baseline bias affect the gains obtained, and the trade-off between performance and equity. Statistical validation used the Friedman test with Holm post-hoc correction. The results indicate that the largest mitigation gains are concentrated in statistical parity metrics, particularly in Disparate Impact, where in-processing methods showed a positive and statistically significant median effect. Individual fairness metrics predominantly exhibited degradation or no effect, and confusion-matrix-based metrics displayed noisy behavior, suggesting a redistribution of errors across groups. As for the trade-off, performance loss associated with mitigation is frequent: simultaneous gains in equity and performance are rare and dataset-dependent, and methods with larger gains in statistical parity tend to degrade other fairness dimensions, particularly the individual one. No method proved to be universally dominant, and the high variability across datasets reinforces the need to define the priority equity dimensions in advance and to evaluate the approaches on a case-by-case basis. These findings contribute to the understanding of the advantages and limitations of in-processing methods and support their application in practical ML projects in sensitive contexts.

Keywords: Fairness. Bias mitigation. Machine Learning. In-processing methods. Health data.

1 INTRODUÇÃO

Existe um crescente uso de sistemas de IA em diversos domínios, tanto por iniciativas privadas quanto por aplicações no setor público (Organization for Economic Cooperation and Development, 2026; Stanford University Human-Centered Artificial Intelligence, 2025; Ayinaddis, 2025). Essa difusão inclui domínios críticos, nos quais decisões automatizadas podem afetar diretamente o bem-estar e as oportunidades de indivíduos. Exemplos recorrentes são o uso de modelos para concessão de crédito e empréstimos (Mukerjee et al., 2002) e para detecção de fraude financeira (Aros et al., 2024). Na área da saúde, técnicas de aprendizado de máquina também têm sido empregadas como suporte à tomada de decisão, como na detecção precoce de deterioração clínica (Muralitharan et al., 2021), na predição de sepse (Vegt et al., 2023), na predição de condições cardiovasculares a partir de sinais clínicos (Hannun et al., 2019) e em diagnóstico por imagem (Litjens et al., 2017).

Nesse contexto, a disseminação e o uso apropriado desses sistemas dependem não apenas de desempenho preditivo, mas também de segurança e confiança por parte de indivíduos e organizações (Tun et al., 2025). Contudo, evidências empíricas mostram que sistemas de IA podem apresentar vieses discriminatórios contra pessoas ou grupos, comprometendo a legitimidade de sua adoção em cenários sensíveis. Em particular, algoritmos podem assimilar padrões discriminatórios presentes nos dados e em práticas institucionais, reforçando ou intensificando formas já existentes de discriminação (Gordon et al., 2022). Além disso, a caracterização do que constitui “viés” frequentemente envolve uma dimensão normativa e contextual, dependente de valores sociais, do período histórico e do domínio de aplicação, o que adiciona complexidade ao desenvolvimento de soluções com resultados mais justos.

Entre os casos mais discutidos na literatura, o sistema COMPAS, utilizado no sistema de justiça norte-americano para pontuação de risco de reincidência, apresentou evidências de disparidades raciais: pessoas pretas foram quase duas vezes mais propensas a serem classificadas como alto risco sem reincidir, em comparação a pessoas brancas (Angwin et al., 2016). Na área da saúde, um exemplo amplamente citado envolve um algoritmo utilizado no sistema de saúde norte-americano que adotava custos de saúde como *proxy* de necessidade clínica. Como pacientes pretos tendem a gerar custos menores do que pacientes brancos para um mesmo nível de morbidade, o algoritmo subestimava sua necessidade e, conseqüentemente, reduzia sua probabilidade de receber recursos adicio-

nais de atenção. Em termos práticos, para a mesma necessidade de cuidado, pacientes pretos geravam custos médios anuais aproximadamente US\$ 1.801 menores (Obermeyer et al., 2019). Por fim, diferenças de desempenho também foram reportadas em modelos clínicos preditivos. Em particular, para modelos de predição de mortalidade em UTI, foram observadas diferenças de erro com respeito a gênero e tipo de seguro; e, para modelos de predição de readmissão psiquiátrica, foram detectadas diferenças de erro com respeito ao tipo de seguro, com discussão de variações entre grupos raciais (Chen; Szolovits; Ghassemi, 2019).

Esses casos ilustram manifestações de vies que podem ser analisadas segundo diferentes critérios, como sua origem e o estágio do *pipeline* em que emergem. Taxonomias amplamente adotadas na literatura — como a proposta por Mehrabi et al. (2019), que estrutura as fontes de vies a partir das interações entre usuário, dados e algoritmo — auxiliam a compreender, de forma mais sistemática, os mecanismos que conduzem à produção e à amplificação de disparidades em sistemas de aprendizado de máquina. A seguir, são apresentados exemplos ilustrativos de origens de vies seguindo a taxonomia de Mehrabi et al. (2019), sem pretensão de esgotar as categorias existentes.

No âmbito de vieses associados à relação entre *dados e algoritmo*, destaca-se o vies de mensuração, que ocorre quando atributos ou variáveis resposta são definidos ou medidos de modo a distorcer o fenômeno de interesse, frequentemente por meio de *proxies*. Esse tipo de vies pode, inclusive, envolver erros de mensuração diferenciais entre grupos. Ainda nessa relação, os vieses de amostragem e de representação surgem quando o processo de coleta não é adequadamente aleatorizado ou não reflete a diversidade da população, resultando em modelos que sub-representam subgrupos relevantes ou deixam de capturar especificidades do contexto de aplicação. Já no âmbito da interação entre *algoritmo e usuário*, o vies algorítmico refere-se a distorções introduzidas pelo próprio processo de modelagem e decisão, associadas à lógica do algoritmo, às escolhas de otimização e à forma como o modelo generaliza a partir dos dados. Por fim, no âmbito da relação entre *usuário e dados*, o vies histórico descreve assimetrias presentes nos dados como reflexo de desigualdades pré-existentes, enquanto o vies populacional ocorre quando a distribuição de características dos usuários observados difere substancialmente daquela da população-alvo que se pretende modelar.

Uma prática frequentemente adotada, e muitas vezes de forma equivocada, é simplesmente remover do conjunto de variáveis características do usuário que podem estar associadas a tratamentos desiguais (por exemplo, sexo ou raça), sob a suposição de que

isso impediria resultados discriminatórios. Entretanto, essa estratégia tende a ser ineficaz, pois outras variáveis podem capturar indiretamente a mesma informação (isto é, atuar como *proxies*), preservando correlações relevantes para o modelo (Pedreshi; Ruggieri; Turini, 2008; Dwork et al., 2012). Além disso, ao excluir essas características, pode-se dificultar a mensuração e o diagnóstico de disparidades entre grupos, criando uma falsa sensação de neutralidade e desestimulando a adoção de abordagens mais sistemáticas de avaliação e mitigação (Selbst et al., 2019).

A área de estudo de *fairness* em IA, inserida no contexto mais amplo de *trustworthy AI*, investiga como sistemas de aprendizado de máquina podem ser desenvolvidos e utilizados de modo a atender requisitos normativos e sociotécnicos, incluindo transparência, privacidade e segurança, e, em particular, a prevenção e a redução de resultados discriminatórios (Kaur et al., 2022). Um dos eixos centrais dessa área é o desenvolvimento de métodos para mensurar e mitigar disparidades, frequentemente organizados de acordo com o estágio do *pipeline* de aprendizado de máquina em que são aplicados. De forma geral, essas abordagens são classificadas em: *pre-processing*, quando atuam sobre os dados antes do treinamento; *in-processing*, quando incorporam critérios de mitigação diretamente no processo de aprendizado do modelo; e *post-processing*, quando ajustam as previsões após o treinamento. A Figura 1.1 ilustra essa organização, indicando o estágio do *pipeline* em que cada classe de método atua.

Figura 1.1 – Taxonomia dos métodos de mitigação de viés segundo o estágio do *pipeline* de aprendizado de máquina em que atuam.



Fonte: A autora

Um dos desafios recorrentes na literatura de *fairness* é a existência de múltiplas definições formais e métricas que capturam noções distintas do que constitui um resultado enviesado. Isso se deve, em grande parte, ao fato de que o viés pode ter origens diversas e ser dependente do contexto de aplicação. Como consequência, avaliações frequentemente se concentram em subconjuntos específicos de métricas e em um número limitado

de cenários, dificultando comparações diretas entre métodos (Hort et al., 2023; Friedler et al., 2018). Em particular, métricas de grupo — que comparam resultados agregados entre subpopulações definidas por um atributo sensível — predominam nas avaliações empíricas, enquanto métricas individuais — que verificam se indivíduos semelhantes recebem tratamento semelhante, independentemente de pertencimento a grupos — são consideravelmente menos exploradas (Majumder et al., 2022). Além disso, os resultados reportados são altamente sensíveis ao conjunto de dados utilizado (Friedler et al., 2018; Chen et al., 2023; Ganesh et al., 2024) e, com frequência, concentram-se em poucos *benchmarks*, o que limita a extrapolação de conclusões para domínios e características de dados mais diversos.

Para além dos critérios de avaliação, a adoção de métodos de mitigação também depende do *trade-off* que essas técnicas impõem ao desempenho preditivo. Em aplicações reais, decisões sobre incorporar tais métodos tendem a considerar simultaneamente ganhos em métricas de *fairness* e variações em desempenho, mas essa relação é frequentemente apresentada apenas para um recorte restrito de métricas e conjuntos de dados, o que dificulta compreender a consistência desses *trade-offs* em diferentes cenários.

Diante dessas limitações, métodos *in-processing* têm recebido atenção crescente, em parte por incorporarem a mitigação diretamente no processo de aprendizado, sem exigir uma etapa explícita de transformação dos dados anterior ao treinamento (Hort et al., 2023; Caton; Haas, 2020). Além disso, esses métodos permitem integrar critérios de mitigação por meio de mecanismos de otimização e regularização (Hort et al., 2023; Caton; Haas, 2020), tendendo a preservar a estrutura dos dados de entrada. Por outro lado, abordagens *pre-processing* continuam entre as mais empregadas, pois em geral são mais fáceis de adotar e podem ser combinadas com diferentes algoritmos de aprendizado (Kamiran; Calders, 2012; Mehrabi et al., 2019), ainda que atuem de forma indireta sobre o comportamento do modelo.

Nesse cenário, torna-se relevante conduzir comparações sob um protocolo experimental controlado, no qual decisões de modelagem sejam mantidas constantes entre métodos. Em particular, ao fixar o mesmo pré-processamento, codificação e critério de decisão, ao incluir tanto modelos de referência sem mitigação quanto abordagens de *pre-processing*, e ao empregar validação estatística formal das diferenças observadas, torna-se possível contextualizar de forma mais clara o comportamento relativo de métodos *in-processing* e seus *trade-offs* sob múltiplas métricas e diferentes conjuntos de dados.

Assim, o objetivo deste trabalho é comparar sistematicamente métodos de mitiga-

ção de viés, com foco em abordagens *in-processing*, e situá-los em relação a modelos de referência (*baselines*) e a técnicas *pre-processing* sob um protocolo experimental controlado. Para isso, são avaliados sete métodos de mitigação em seis conjuntos de dados da área da saúde, considerando métricas de *fairness* de grupo e individual, além de métricas de desempenho preditivo. O escopo do trabalho restringe-se a problemas de classificação binária com um atributo sensível também binário e está organizado em torno das seguintes perguntas de pesquisa:

- RQ1:** Quais métodos e tipos de intervenção apresentam maior efeito global de mitigação em *fairness*, em comparação ao *baseline*?
- RQ2:** Os resultados de mitigação observados na análise global se mantêm quando restrita aos conjuntos com disparidade relevante e estratificada por categoria de métrica?
- RQ3:** Como a intensidade do viés no *baseline* influencia o efeito de mitigação obtido pelos métodos?
- RQ4:** Como o sentido do viés afeta o ganho de *fairness* obtido pelos métodos?
- RQ5:** Qual é o *trade-off* entre desempenho preditivo e ganho em *fairness* obtido pelos métodos de mitigação?

O restante deste trabalho está organizado da seguinte forma. O Capítulo 2 traz a fundamentação teórica necessária para contextualizar o trabalho, abrangendo conceitos de aprendizado de máquina, métricas e definições de *fairness* em IA, e métodos de mitigação de viés, com ênfase em abordagens *in-processing*. O Capítulo 3 discute os trabalhos relacionados. O Capítulo 4 descreve a metodologia experimental adotada. O Capítulo 5 apresenta e discute os resultados obtidos, organizados em torno de cada pergunta de pesquisa. Por fim, no Capítulo 6 são expostas as conclusões e perspectivas para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo reúne os fundamentos teóricos necessários à compreensão do estudo comparativo conduzido neste trabalho. A avaliação de métodos de mitigação de viés requer, de um lado, os conceitos de aprendizado de máquina supervisionado que descrevem os modelos de classificação considerados e, de outro, a formalização das noções de *fairness* empregadas para mensurar desigualdades entre grupos e entre indivíduos. A esses fundamentos somam-se os próprios métodos de mitigação avaliados e o instrumental estatístico que dá suporte à comparação de desempenho entre eles.

O capítulo inicia com a revisão dos conceitos de aprendizado de máquina supervisionado relevantes ao estudo, com ênfase no problema de classificação binária, nos algoritmos de classificação que servem de base aos métodos avaliados (modelos lineares, métodos baseados em árvores e redes neurais), no *pipeline* de desenvolvimento de modelos e nas métricas de desempenho preditivo. Na sequência, são apresentados os fundamentos de *fairness* e as origens do viés em aprendizado de máquina, seguidos da formalização dos critérios e das métricas de *fairness* adotados, organizados nas categorias de paridade estatística, métricas derivadas da matriz de confusão e *fairness* individual. Em seguida, descrevem-se os métodos de mitigação de viés avaliados, abrangendo abordagens de *pre-processing* e de *in-processing*. Por fim, apresenta-se a base estatística para comparações múltiplas, fundamentada no teste de Friedman e no procedimento de Holm.

2.1 Aprendizado de máquina

Esta seção tem como objetivo a apresentação de tópicos fundamentais de aprendizado de máquina necessários para sustentar as escolhas de modelagem e avaliação adotadas ao longo do trabalho.

2.1.1 Problema de classificação binária em aprendizado supervisionado

Considere um conjunto de dados rotulados $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$, em que $x_i \in \mathbb{R}^d$ denota o vetor de *features* e $y_i \in \{0, 1\}$ a classe alvo. Em um problema de classificação binária com algoritmos de aprendizado supervisionado, busca-se aprender uma função preditora $f_\theta : \mathbb{R}^d \rightarrow \mathbb{R}$, cujo valor é utilizado para definir a classe predita para novas

instâncias por meio de uma regra de decisão (Faceli et al., 2011; Hastie; Tibshirani; Friedman, 2009). A decisão discreta é usualmente obtida por meio de um limiar τ , de acordo com a regra

$$\hat{y}_i = \mathbf{1}[f_\theta(x_i) \geq \tau] \quad (2.1)$$

em que $\mathbf{1}[\cdot]$ denota a função indicadora, que assume valor 1 quando a condição é satisfeita e 0 caso contrário. Assim, a instância x_i é classificada como pertencente à classe positiva quando o *score* ultrapassa o limiar definido.

De modo geral, f_θ pode assumir formas lineares ou não lineares. Durante o treinamento, os parâmetros θ são estimados a partir dos dados, frequentemente minimizando-se uma função de custo que quantifica a discrepância entre os rótulos verdadeiros e as saídas do modelo. Uma formulação genérica é a minimização do risco empírico:

$$\min_{\theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(y_i, f_\theta(x_i)), \quad (2.2)$$

em que $\mathcal{L}(\cdot)$ é uma função de perda apropriada à tarefa (Shalev-Shwartz; Ben-David, 2014). Essa formulação abrange uma ampla classe de algoritmos baseados em otimização, embora alguns métodos, como árvores de decisão e algoritmos baseados em vizinhança, adotem estratégias distintas de aprendizado.

2.1.2 *Underfitting*, *overfitting* e regularização

Ao conseguir atribuir rótulos a instâncias nunca vistas com desempenho adequado, diz-se que o modelo apresenta capacidade de generalização. Quando essa capacidade é limitada, dois comportamentos são tipicamente observados: *underfitting* e *overfitting* (Faceli et al., 2011).

O *underfitting* ocorre quando o modelo é simples demais (ou insuficientemente ajustado) e, portanto, incapaz de capturar padrões relevantes presentes nos dados, resultando em erro elevado inclusive no conjunto de treinamento. Por outro lado, o *overfitting* ocorre quando o modelo é complexo demais e passa a se ajustar excessivamente ao conjunto de treinamento, aprendendo variações específicas (ruído) em vez do padrão subjacente; nesse caso, observa-se desempenho elevado no treinamento, mas uma degradação em dados de teste.

Uma forma comum de controlar esse mecanismo é por meio de regularização, na

qual se adiciona um termo à função de custo durante o treinamento, penalizando soluções excessivamente complexas. Em termos gerais, obtém-se:

$$\min_{\theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(y_i, f_{\theta}(x_i)) + \lambda \Omega(\theta), \quad (2.3)$$

em que $\Omega(\theta)$ quantifica complexidade (por exemplo, penalizações ℓ_2 ou ℓ_1) e $\lambda \geq 0$ controla a intensidade da penalização.

2.1.3 Algoritmos de aprendizado supervisionado

Existem diversos algoritmos de aprendizado de máquina supervisionado, cada um com suas vantagens e com viés indutivo associado ao seu modo de funcionamento. De forma geral, esses algoritmos podem ser organizados em diferentes famílias, como modelos lineares e métodos baseados em árvores, que diferem na forma de representar os dados e de lidar com ruído e incerteza. A seguir, apresentam-se brevemente os algoritmos utilizados neste trabalho, com foco em sua intuição e no tipo de saída produzida (Faceli et al., 2011).

No caso de modelos lineares, um mecanismo amplamente empregado para classificação é a regressão logística. Esse método combina os atributos de entrada por meio de pesos (e um termo de viés) e utiliza a função de custo *log-loss* (também conhecida como entropia cruzada binária) para medir o ajuste do modelo, dada por:

$$J(w, b) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right]. \quad (2.4)$$

Em cada iteração, o objetivo é minimizar esse custo ajustando os parâmetros do modelo. Para isso, pode-se empregar um método de otimização como o gradiente descendente, que atualiza os parâmetros na direção oposta ao gradiente da função de custo (isto é, na direção de maior redução de J). A cada passo, os pesos são ajustados e o custo é recalculado, dando início a uma nova iteração. Ao final, a regressão logística produz uma estimativa de probabilidade para a classe positiva por meio de uma função sigmoide aplicada a um preditor linear:

$$z^{(i)} = w^{\top} x^{(i)} + b, \quad \hat{p}^{(i)} = \sigma(z^{(i)}) = \frac{1}{1 + e^{-z^{(i)}}}. \quad (2.5)$$

A decisão binária é obtida aplicando-se um limiar τ à probabilidade estimada.

Em contraste com essa parametrização linear, métodos baseados em árvores realizam particionamentos sucessivos do espaço de atributos, permitindo capturar relações não lineares por meio de regras de decisão. Nessa abordagem, o espaço de entrada é particionado recursivamente por meio de testes sequenciais, formando um grafo acíclico com estrutura de árvore enraizada, no qual cada nó interno representa uma regra de decisão e cada caminho da raiz até uma folha corresponde a uma sequência de particionamentos dos dados. A divisão se inicia no nó raiz e segue por nós de decisão, que separam iterativamente as instâncias em subconjuntos mais homogêneos em relação ao rótulo. O ponto em que as divisões cessam e uma decisão final é atribuída é denominado folha (tipicamente por maioria de classe, no caso de classificação).

Em árvores de classificação, o critério de divisão do nó pode ser definido de diferentes formas; dois critérios amplamente utilizados são o ganho de informação e o índice de Gini. O ganho de informação baseia-se na entropia como medida de impureza: para cada atributo candidato, avalia-se a redução esperada de entropia obtida após o particionamento (isto é, a entropia do nó pai menos a entropia ponderada dos nós filhos). De modo similar, o índice de Gini mede a impureza de um nó; valores menores indicam partições mais homogêneas e, portanto, divisões potencialmente mais informativas.

Embora árvores individuais sejam intuitivas e flexíveis, uma abordagem comum para aumentar robustez é combiná-las em um modelo *ensemble*. Assim, uma variação amplamente utilizada são as florestas aleatórias (*Random Forest*) (Breiman, 2001). Nesse caso, múltiplas árvores são treinadas sobre diferentes amostras do conjunto de treinamento obtidas por *bootstrap* (em um processo denominado *bagging*, de *bootstrap aggregating*), e a cada divisão considera-se apenas um subconjunto aleatório de atributos candidatos. Ao final, a predição é obtida por agregação das árvores (por exemplo, voto majoritário em classificação), o que tende a reduzir variância e tornar o desempenho mais robusto.

Outra família de *ensembles* baseados em árvores opera por *boosting*, no qual modelos fracos são combinados de forma sequencial, sendo cada novo modelo treinado para corrigir os erros residuais dos anteriores. Em particular, o *gradient boosting* sobre árvores de decisão (*Gradient Boosted Decision Trees*, GBDT) (Friedman, 2001) ajusta, a cada iteração t , uma nova árvore h_t ao gradiente negativo da função de perda avaliado nas predições acumuladas:

$$F_t(x) = F_{t-1}(x) + \eta h_t(x), \quad (2.6)$$

em que η é a taxa de aprendizado e F_0 é uma inicialização adequada. Diferentemente das florestas aleatórias, nas quais as árvores são treinadas de forma independente, o *gradient boosting* constrói o *ensemble* de modo aditivo e direcionado, o que frequentemente resulta em desempenho preditivo superior em dados tabulares (Hastie; Tibshirani; Friedman, 2009). Essa formulação é o classificador subjacente ao método FairGBM (Cruz et al., 2023), apresentado na seção de métodos de mitigação.


As redes neurais artificiais constituem outra família de algoritmos de aprendizado supervisionado, inspirada, de forma simplificada, no funcionamento dos sistemas neurais biológicos. Uma rede é formada por unidades de processamento elementares, os neurônios, que executam operações simples e são interligadas por conexões ponderadas, podendo ser organizadas em múltiplas camadas, conforme esquematizado na Figura 2.1. Embora cada neurônio realize um processamento individualmente limitado, a composição de muitas unidades ao longo de sucessivas camadas permite que a rede represente funções complexas e não lineares. O termo aprendizado profundo (*deep learning*) designa o emprego de redes com várias camadas intermediárias, capazes de aprender representações progressivamente mais complexas dos dados (Faceli et al., 2011).

Emulando, de forma abstrata, o papel das sinapses biológicas, cada neurônio recebe um conjunto de valores de entrada, representados pelo vetor x , aos quais associa pesos ajustáveis, representados pelo vetor w . A entrada efetiva da unidade é obtida pela combinação dos valores de entrada com os respectivos pesos, acrescida de um termo de viés b :

$$net = \sum_j w_j x_j + b, \quad (2.7)$$

em que a soma percorre as entradas do neurônio, w_j é o peso associado à entrada x_j e b é o termo de viés. O valor net é então submetido a uma função de ativação f , que define a saída da unidade, $y = f(net)$. Essa função pode assumir diferentes formas — como a

Figura 2.1 – Desenho esquemático de rede neural artificial de multiplas camadas.



Fonte: adaptado de Faceli et al. (2011).

linear, a sigmoide e a *ReLU* (*rectified linear unit*) — e o uso de ativações não lineares é o que permite à rede representar relações complexas entre entradas e saídas; sua escolha influencia também a dinâmica do treinamento.

O treinamento de redes com múltiplas camadas tornou-se viável com o algoritmo de retropropagação do erro (*backpropagation*), que opera em duas fases. Na fase *forward*, os valores de entrada são propagados camada a camada: cada neurônio calcula sua entrada efetiva a partir das saídas da camada anterior e de seus pesos, aplica a função de ativação e transmite o resultado às camadas seguintes, até a camada de saída. Na fase *backward*, a saída produzida é comparada à saída desejada, e o erro resultante é propagado no sentido inverso, ajustando-se os pesos de acordo com sua contribuição para esse erro. Para uma conexão que transmite o sinal x_j da unidade j à unidade l , a atualização do peso correspondente pode ser expressa como

$$w_{jl}(t+1) = w_{jl}(t) + \eta \delta_l x_j, \quad (2.8)$$

em que t indexa a iteração do treinamento, η é a taxa de aprendizado e δ_l é o termo de erro associado à unidade l . Para os neurônios da camada de saída, δ_l deriva diretamente da diferença entre a saída produzida e a saída esperada. Já para os neurônios das camadas intermediárias, que não dispõem de um valor-alvo explícito, o *backpropagation* estima δ_l a partir dos termos de erro das unidades da camada seguinte, ponderados pelos pesos das conexões correspondentes — o que caracteriza a propagação do erro no sentido reverso.

2.1.4 Pipeline de desenvolvimento de modelos

De forma geral, a construção e avaliação de uma função preditora segue um *pipeline* composto por etapas que organizam o tratamento de dados, o treinamento e a mensuração de desempenho preditivo. Embora a composição exata varie conforme o algoritmo e o protocolo experimental, um fluxo típico inclui:

1. **Definição do protocolo de avaliação:** escolha do esquema de particionamento dos dados (por exemplo, divisão treino-teste ou validação cruzada), determinando quais amostras serão usadas para ajuste e quais serão reservadas para avaliação.
2. **Pré-processamento:** adequação do conjunto de dados ao modelo, incluindo limpeza, tratamento de valores ausentes e codificação de variáveis quando necessário.

3. **Transformações dependentes dos dados:** aplicação de procedimentos que estimam parâmetros a partir do conjunto de treino (por exemplo, padronização via *z-score*). Para evitar *data leakage*, tais parâmetros devem ser ajustados apenas no treino e aplicados posteriormente aos dados de teste/validação.
4. **Treinamento:** ajuste dos parâmetros do modelo com base no conjunto de treino, segundo a função de custo definida.
5. **Avaliação:** geração de previsões em dados não vistos (*fold* de teste ou conjunto de teste) e cálculo das métricas de desempenho adotadas.

Ressalta-se que nem todas as etapas são obrigatórias em todos os cenários; por exemplo, o ajuste de escala é frequentemente relevante para modelos lineares, mas pode ser dispensável em métodos baseados em árvores.

2.1.5 Métricas de desempenho

Na etapa de avaliação de desempenho, múltiplas métricas podem ser usadas no contexto da classificação. A matriz de confusão é uma tabela que organiza as contagens dos valores preditos pelo classificador ($\hat{y}$) em comparação aos rótulos reais (y). Para um problema binário, ela é composta por quatro componentes — verdadeiro positivo (TP), falso positivo (FP), verdadeiro negativo (TN) e falso negativo (FN) — organizados conforme a Figura 2.2: TP e TN correspondem às previsões corretas (rótulo predito coincide com o real), enquanto FP e FN correspondem aos dois tipos de erro.

Figura 2.2 – Matriz de confusão para classificação binária.

		Valor predito ($\hat{y}$)	
		$\hat{y} = 1$	$\hat{y} = 0$
Valor real (y)	$y = 1$	TP	FN
	$y = 0$	FP	TN

Fonte: A autora

Essas contagens são calculadas a partir das decisões $\hat{y}$, as quais dependem do limiar τ adotado para discretizar o *score* predito pelo classificador. A partir da matriz de confusão, definem-se métricas como a acurácia, que representa a taxa de acerto global do

modelo, e a precisão e revocação (para a classe positiva), definidas como:

$$\text{Precisão} = \frac{TP}{TP + FP}, \quad \text{Revocação} = \frac{TP}{TP + FN}. \quad (2.9)$$

O F_1 -score é a média harmônica entre precisão e revocação:

$$F_1 = \frac{2 \cdot \text{Precisão} \cdot \text{Revocação}}{\text{Precisão} + \text{Revocação}}. \quad (2.10)$$

Ao utilizar F_1 , enfatiza-se o compromisso entre precisão e revocação, sendo uma métrica especialmente útil em cenários com desbalanceamento de classes.

2.1.6 Validação cruzada

A validação cruzada é uma das estratégias mais utilizadas para avaliar modelos de aprendizado de máquina e tem como objetivo obter uma estimativa mais estável e confiável do desempenho de generalização. Esse objetivo é alcançado ao repetir o treinamento e a avaliação em diferentes partições do conjunto de dados, reduzindo a dependência do resultado em relação a uma única divisão entre treino e teste.

De forma geral, o procedimento segue as seguintes etapas:

1. **Divisão:** o conjunto de dados é particionado em k partes (*folds*) aproximadamente do mesmo tamanho.
2. **Iteração:** em cada iteração, um *fold* é usada como teste, enquanto os $k - 1$ *folds* restantes são utilizadas para treino.
3. **Avaliação:** calcula-se a métrica de interesse em cada *fold* e, ao final, os valores são agregados (por exemplo, por média ou mediana) para cada métrica considerada (precisão, revocação, acurácia, etc.).

Entre extensões do método, destaca-se a validação cruzada estratificada, que busca manter proporções semelhantes de classes em cada *fold* (e, quando necessário, pode também considerar outros atributos). Além disso, a validação cruzada repetida executa múltiplas rodadas de validação cruzada *k-fold* com diferentes particionamentos aleatórios e agrega os resultados, reduzindo ainda mais a variabilidade da estimativa.

2.2 Fundamentos de *fairness* e viés em aprendizado de máquina

Quando se trata do contexto de aprendizado de máquina, o viés pode se manifestar de diversas formas ao longo do *pipeline* de desenvolvimento de modelos. De maneira geral, tais vieses podem emergir em diferentes etapas do processo de coleta, anotação, modelagem e uso dos dados. Em tarefas de anotação, por exemplo, diferenças demográficas entre anotadores tem impacto tanto em julgamentos subjetivos quanto em tarefas consideradas objetivas, resultando em padrões sistemáticos de rotulagem (Haliburton et al., 2025). Em domínios que não envolvem interação humana direta, como sensoriamento remoto, vieses de natureza sensorial e de construção do dado são amplamente documentados, sendo frequentemente tratados por meio de métodos de aprendizado de máquina com o objetivo de reduzir incertezas e distorções de medição (Zhang et al., 2022).

No nível do aprendizado estatístico, o fenômeno de *shortcut learning* evidencia como correlações espúrias presentes nos dados, quando privilegiadas pelo procedimento de aprendizado, podem induzir modelos a depender de pistas não causais, resultando em baixa robustez e fraca capacidade de generalização, especialmente sob cenários de mudança de distribuição (Geirhos et al., 2020). Entretanto, no contexto de *fairness*, o conceito de viés assume uma formulação específica, referindo-se a disparidades sistemáticas nas decisões, no desempenho ou nos impactos de um modelo entre grupos definidos por atributos sensíveis (por exemplo, sexo, raça, idade) (Friedman; Nissenbaum, 1996; Barocas; Hardt; Narayanan, 2023). Essas disparidades podem se manifestar, por exemplo, como diferenças nas taxas de erro entre subgrupos populacionais, como observado em avaliações de sistemas comerciais de classificação de gênero (Buolamwini; Gebru, 2018). Em outros contextos, decisões algorítmicas podem gerar ciclos de retroalimentação, como no planejamento de patrulhamento policial baseado em localizações onde crimes são registrados, resultando em impactos distributivos desiguais e na amplificação de desigualdades pré-existentes (Ensign et al., 2018).

Por sua vez, atributos sensíveis (ou atributos protegidos) correspondem a características de indivíduos ou grupos que, por razões sociais, legais ou éticas, não devem justificar tratamento desigual em sistemas de decisão algorítmica (Barocas; Hardt; Narayanan, 2023; Mehrabi et al., 2019).

Todos os mecanismos de origem de viés apresentados até aqui não implicam, necessariamente, ausência de justiça. Ainda que o viés se refira à presença de assimetrias sistemáticas nos dados, nas decisões ou no desempenho de modelos, o termo *fairness* tem

sido empregado como um conceito normativo para avaliar as consequências práticas do uso de sistemas de aprendizado de máquina sobre indivíduos e grupos. Nesse sentido, a presença ou ausência de *fairness*, mesmo diante de um sistema enviesado, depende de fatores temporais, contextuais e dos objetivos da aplicação.

Em determinados contextos, a própria detecção de vieses pode ser mobilizada com o propósito de promover equidade e reduzir desigualdades estruturais, em vez de simplesmente eliminar toda diferenciação entre grupos (Barocas; Hardt; Narayanan, 2023; Hardt; Price; Srebro, 2016; Mehrabi et al., 2019). Em políticas públicas, esse princípio se manifesta em sistemas de priorização e alocação de recursos, como em programas de assistência social (Noriega; Pentland, 2018) e na triagem de chamadas em serviços de proteção à infância (Chouldechova et al., 2018).

2.3 Critérios e métricas de *fairness*

Muitas métricas de *fairness* já foram propostas. Em essência, essas métricas representam definições matemáticas que traduzem conceitos de justiça, frequentemente abstratos. Para trazer maior clareza a esse vasto conjunto de métricas, diferentes formas de categorização foram sugeridas (Mehrabi et al., 2019; Caton; Haas, 2020). A classificação mais ampla distingue entre:

- Métricas baseadas em grupos (*Group-based metrics*)
- Métricas individuais (*Individual metrics*)

Além disso, há esforços no sentido de segmentar ainda mais essas métricas, de modo a facilitar sua compreensão e seleção em diferentes contextos. Uma das formas de classificação considera três critérios principais (Caton; Haas, 2020; Barocas; Hardt; Narayanan, 2023):

- Independência: estabelece que o resultado não deve apresentar correlação com o atributo sensível, isto é, $R \perp A$.
- Separação: define que o resultado não deve correlacionar com o atributo sensível, condicionando também à variável resposta, isto é, $R \perp A|Y$.
- Suficiência: estabelece que a variável resposta deve ser independente do atributo sensível, dado um escore, isto é, $Y \perp A|R$.

Com base nesses critérios, foram sugeridas as seguintes categorias de métricas (Caton; Haas, 2020):

- Métricas baseadas em grupos:
 - Paridade: definida como a probabilidade de obtenção de um resultado positivo nos grupos. Relaciona-se ao critério de independência.
 - Matriz de confusão: fundamenta-se na ideia de que o desempenho deve ser uniforme entre os grupos, utilizando métricas derivadas da matriz de confusão (como taxa de falsos positivos, entre outras). Relaciona-se, predominantemente, ao critério de separação, embora métricas específicas dessa categoria possam estar associadas à suficiência (conforme discutido adiante).
 - Calibração: reúne métricas que analisam a probabilidade de pertencer à classe positiva, dado um escore e o grupo. Está associada ao critério de suficiência. Intuitivamente, avalia o quão bem o modelo está calibrado dentro de cada grupo, exigindo que a qualidade da calibração seja equivalente entre eles.
 - Escores: incluem métricas baseadas no valor médio do escore atribuído pelo modelo, considerando a classe e o grupo do indivíduo. Diferem da calibração, pois partem do rótulo real para avaliar os escores, enquanto as métricas de calibração partem do escore para o rótulo real em cada grupo.
- Métricas individuais e contrafactuais: abrangem métricas de *fairness* que consideram comparações de distribuição em nível individual, podendo também incluir avaliações paralelas em nível de grupo.

Com frequência, os três critérios que fundamentam as métricas de *fairness* — independência, separação e suficiência — não podem ser satisfeitos simultaneamente, exceto em casos particulares, como classificadores perfeitos ou cenários em que o atributo sensível é completamente independente do rótulo (Barocas; Hardt; Narayanan, 2023; Chouldechova, 2016; Kleinberg; Mullainathan; Raghavan, 2017). Como consequência, a melhora em um desses critérios pode implicar, inevitavelmente, deterioração em métricas associadas a outro conceito.

Para garantir maior transparência e reprodutibilidade na interpretação das métricas, as subseções a seguir apresentam o detalhamento de algumas das métricas representativas das categorias de paridade, matriz de confusão e *fairness* individual. Quando uma métrica não é explicitamente classificada por Caton and Haas (2020), sua alocação é feita

com base no critério formal ao qual ela se relaciona — independência, separação ou suficiência — ou em sua forma operacional. Ao final, são discutidas relações de instabilidade entre métricas e os valores ideais adotados como referência neste trabalho.

2.3.1 Paridade Estatística/Demográfica

Paridade estatística é uma das concepções centrais de *fairness*, que fundamenta diversas métricas de grupo. De acordo com esse princípio, a probabilidade de um indivíduo obter um resultado positivo deve ser a mesma entre os diferentes grupos.

$$\Pr(\hat{Y} = \text{pos_label} \mid A = \text{unprivileged}) = \Pr(\hat{Y} = \text{pos_label} \mid A = \text{privileged}) \quad (2.11)$$

Impacto díspar: O impacto díspar (*disparate impact* — DI) é baseado no conceito de paridade estatística e corresponde à razão entre a probabilidade de obtenção de um resultado positivo pelo grupo não privilegiado e aquela do grupo privilegiado. Esse conceito é amplamente utilizado no contexto jurídico dos Estados Unidos, especialmente nas *Uniform Guidelines on Employee Selection Procedures*, sendo conhecido como a regra dos quatro quintos (*four-fifths rule*).

$$\frac{\Pr(\hat{Y} = 1 \mid A = \text{unprivileged})}{\Pr(\hat{Y} = 1 \mid A = \text{privileged})} \quad (2.12)$$

Amplificação de viés em *fairness* diferencial: A amplificação de viés em *fairness* diferencial (*Differential Fairness Bias Amplification* — DFBA) se fundamenta em dois conceitos propostos por Foulds and Pan (2018): o *fairness diferencial* (DF) e a extensão do DF para quantificar *amplificação de viés*.

O DF, dado pela Equação (2.13), avalia a razão entre as probabilidades de um mesmo resultado em diferentes grupos, quantificando a desigualdade. Essa medida é descrita como relacionada à noção de paridade estatística, porém em uma forma mais geral, pois impõe limites multiplicativos sobre razões de probabilidades entre grupos (incluindo categorias interseccionais) e para múltiplos valores de saída (Islam et al., 2023; Foulds; Pan, 2018). Por esse motivo, apesar de não estar categorizada por Caton and Haas (2020), será no presente estudo classificada como uma métrica de paridade, apesar das diferenças operacionais presentes.

$$e^{-\varepsilon} \leq \frac{P_{M,\theta}(M(x) = y \mid a_i, \theta)}{P_{M,\theta}(M(x) = y \mid a_j, \theta)} \leq e^{\varepsilon}. \quad (2.13)$$

A noção de amplificação de viés, que completa o conceito de amplificação de viés, parte do princípio de que a desigualdade já presente nos dados não deve ser acentuada pelo modelo. Assim, define-se a amplificação como a diferença entre o DF estimado para as predições do modelo e aquele estimado a partir dos rótulos reais (Islam et al., 2023):

$$\text{amplificação de viés} = \varepsilon(\hat{Y}) - \varepsilon(Y), \quad (2.14)$$

onde $\varepsilon(V)$ denota o menor valor de ε que satisfaz a condição de DF da Eq. (2.13) ao substituir $\hat{Y}$ por $V \in \{\hat{Y}, Y\}$. Nesse sentido, amplificação de viés > 0 indica amplificação de viés e amplificação de viés < 0 indica redução de viés em relação ao padrão presente nos rótulos.

Embora o DF e, conseqüentemente, o cálculo de amplificação de viés possam ser estimados diretamente por probabilidades derivadas de contagens, esse procedimento pode gerar instabilidade em grupos pequenos (por exemplo, por contagens nulas e divisões por zero). Para mitigar esse problema, os autores propõem versões suavizadas, introduzindo *smoothing* (por exemplo, via suavização Dirichlet em estimativas de probabilidade), de modo a estabilizar o cálculo em cenários com esparsidade (Foulds; Pan, 2018; Islam et al., 2023).

2.3.2 Matriz de Confusão

Diferença da taxa de falsos negativos: A diferença de taxa de falsos negativos (*false negative rate difference* — FNRD) compara, entre grupos, a fração de instâncias positivas que são classificadas incorretamente como negativas. Para um grupo, a taxa de falsos negativos é definida por:

$$\text{FNR} = \frac{FN}{TP + FN} = \Pr(\hat{Y} = 0 \mid Y = 1). \quad (2.15)$$

Assim, a diferença entre o grupo não privilegiado e o privilegiado é dada por:

$$\text{FNRD} = \text{FNR}_{A=\text{unprivileged}} - \text{FNR}_{A=\text{privileged}}. \quad (2.16)$$

Diferença da taxa de erro: A diferença da taxa de erro compara a taxa de erro

global entre os grupos privilegiado e não privilegiado. A taxa de erro de um grupo corresponde à fração de classificações incorretas (falsos positivos e falsos negativos) em relação ao total de instâncias desse grupo:

$$ERR = \frac{FP + FN}{P + N} \quad (2.17)$$

A diferença de taxa de erro é definida como:

$$ERR_{A=\text{unprivileged}} - ERR_{A=\text{privileged}} \quad (2.18)$$

O valor ideal é 0, indicando igualdade de taxa de erro entre os grupos.

Diferença da taxa de falsa descoberta: A diferença de taxa de falsa descoberta (*false discovery rate difference* — FDRD) compara, entre grupos, a fração de predições positivas que são incorretas. Para um grupo, a taxa de falsa descoberta é definida por:

$$\text{FDR} = \frac{FP}{TP + FP} = \Pr(Y = 0 \mid \hat{Y} = 1). \quad (2.19)$$

Assim, a diferença entre o grupo não privilegiado e o privilegiado é dada por:

$$\text{FDRD} = \text{FDR}_{A=\text{unprivileged}} - \text{FDR}_{A=\text{privileged}}. \quad (2.20)$$

Embora esta métrica não seja destacada como subcategoria própria em Caton and Haas (2020), ela é baseada na matriz de confusão do ponto de vista operacional. Além disso, por ser equivalente (via complemento) à comparação de *positive predictive value* (PPV) entre grupos, a FDRD está relacionada ao critério de suficiência (paridade preditiva). Note-se, contudo, que essa relação é formulada sobre a decisão binária $\hat{Y}$ (isto é, sobre predições positivas), enquanto as métricas de calibração/*test fairness* são formuladas sobre o escore contínuo S condicionando em $S = s$.

2.3.3 Fairness individual

Consistência: Mede o grau em que indivíduos semelhantes recebem tratamento semelhante. Para isso, cada instância é comparada com seus k vizinhos mais próximos, e a consistência é definida como a proporção de vizinhos que apresentam o mesmo rótulo de saída (Zemel et al., 2013).

$$C(x_i) = \frac{1}{k} \sum_{x_j \in N_k(x_i)} \mathbf{1}(y_j = y_i) \quad (2.21)$$

Índice de entropia generalizado: O índice de entropia generalizado (*generalized entropy index* — GEI) (Speicher et al., 2018) é definido como uma medida de desigualdade que compara o benefício atribuído a cada instância em relação à média. Em particular, considera-se um vetor de benefícios $b = (b_1, \dots, b_n)$, definido por uma função adequada à noção de *fairness* adotada, e sua média μ .

$$\mathcal{E}(\alpha) = \begin{cases} \frac{1}{n\alpha(\alpha-1)} \sum_{i=1}^n \left[\left(\frac{b_i}{\mu} \right)^\alpha - 1 \right], & \alpha \neq 0, 1, \\ \frac{1}{n} \sum_{i=1}^n \frac{b_i}{\mu} \ln \frac{b_i}{\mu}, & \alpha = 1, \\ -\frac{1}{n} \sum_{i=1}^n \ln \frac{b_i}{\mu}, & \alpha = 0. \end{cases} \quad (2.22)$$

Esse tipo de métrica se destaca por ser uma forma de medir o viés e ainda assim garantir algumas propriedades como anonimidade e invariância à população. Além disso, ainda possibilita a decomposição para uma comparação intergrupos (*between-group*) e intragrupo (*within-group*), a partir de uma partição da população em grupos.

O coeficiente de variação é um índice de medida de desigualdade relacionado ao GEI. Em particular, para $\alpha = 2$, vale que E_2 é proporcional ao quadrado do coeficiente de variação, de modo que $CV = \sqrt{2E_2}$. O parâmetro α controla a sensibilidade do índice a diferentes partes da distribuição.

2.3.4 Relações entre métricas e instabilidade

Algumas métricas baseadas em razões, como o impacto díspar, podem apresentar instabilidade no cálculo (Caton; Haas, 2020). Esse problema se torna mais evidente em conjuntos de dados desbalanceados, nos quais determinadas subamostras podem não conter instâncias de um dos grupos, resultando em divisão por zero.

Além disso, há métricas ou pares de métricas que partem do mesmo conceito, diferenciando-se apenas pela forma de comparação entre grupos. Um exemplo é a paridade estatística, que pode ser mensurada como razão (impacto díspar) ou como diferença entre grupos (diferença de paridade estatística). Nessas situações, optar pela forma mais estável pode ser uma alternativa relevante.

2.3.5 Valores ideais para métricas de *fairness*

De forma geral, métricas de *fairness* não possuem regras práticas de valores ou tolerâncias atualmente estabelecidas, seja por boas práticas ou por legislação. Assim como métricas amplamente utilizadas em projetos de aprendizado de máquina para avaliar desempenho preditivo, os valores de referência para métricas de *fairness* ainda dependem fortemente do contexto do projeto e do impacto esperado da funcionalidade (Barr et al., 2025; Luo et al., 2025; Saleiro et al., 2019).

Uma regra simples, embora restrita, é considerar que métricas expressas em diferenças têm como valor ideal 0, enquanto métricas em forma de razão possuem como valor ideal 1. Esses seriam os casos de viés nulo sob a perspectiva da métrica em questão. Algumas métricas baseadas em razões, como a consistência, apresentam particularidades. Embora também tenham como valor ideal 1, não se baseiam em comparações entre grupos (Zliobaite, 2015).

Uma etapa adicional de análise envolve refletir sobre qual valor pode ser considerado justo e buscar estabelecer limiares seguros. O impacto díspar, por exemplo, já foi associado ao valor de 0.8, utilizado pelo *U.S. Department of Labor* no documento *Uniform Guidelines on Employee Selection Procedures*. Apesar de esse limite ter sido definido em um contexto específico, tornou-se uma referência amplamente difundida no campo de *fairness*. Além disso, essa tolerância foi estendida como boa prática para outras métricas baseadas em razões, enquanto o limite de 0.1 tem sido adotado como referência para métricas formuladas em diferenças (Wang et al., 2025; Majumder et al., 2022).

2.4 Métodos de mitigação de viés

Uma abordagem frequentemente adotada para eliminar vieses em aprendizado de máquina é a estratégia *fairness through unawareness* (Barocas; Hardt; Narayanan, 2023), que consiste em remover os atributos sensíveis do processo de modelagem. Essa estratégia, contudo, apresenta limitações, pois o viés pode persistir nos resultados por meio de variáveis *proxy* correlacionadas com esses atributos (Mehrabi et al., 2019). Em contraste, sistemas que preservam atributos sensíveis são denominados *aware*.

Esta seção tem como propósito a apresentação dos métodos de mitigação de viés explorados no presente trabalho. Na literatura, esses métodos são normalmente organizados em três tipos, conforme a etapa do *pipeline* em que atuam: *pre-processing* (inter-

venção sobre os dados antes do treinamento), *in-processing* (intervenção durante o treinamento) e *post-processing* (ajuste das predições após o treinamento) (Mehrabi et al., 2019; Caton; Haas, 2020). Neste trabalho, são avaliados métodos dos dois primeiros tipos, por serem mais diretamente integráveis ao *pipeline* experimental adotado.

2.4.1 Métodos *pre-processing* de mitigação de viés

Esta seção apresenta os métodos *pre-processing* de mitigação de viés, isto é, aqueles que atuam sobre os dados antes do treinamento do modelo.

2.4.1.1 *Reweighting*

O *Reweighting* (Kamiran; Calders, 2012) atribui pesos às instâncias do conjunto de dados e utiliza esses pesos durante o treinamento, de modo a enfatizar observações sub-representadas e atenuar observações super-representadas. Os pesos são definidos em função da combinação entre o atributo sensível e o rótulo (isto é, dependem de $(A = a, Y = y)$), buscando reduzir a associação entre A e Y no conjunto reponderado, sem alterar diretamente as *features* nem os rótulos.

2.4.1.2 *Disparate Impact Remover*

O *Disparate Impact Remover* (Feldman et al., 2015) modifica os atributos do conjunto de dados (com exceção do atributo sensível) com o objetivo de reduzir impacto díspar. A transformação preserva a ordenação das instâncias dentro de cada grupo, buscando limitar efeitos adversos sobre a capacidade preditiva.

O pré-processamento é realizado por grupo e por atributo, por meio de uma transformação baseada em quantis. Para cada quantil, os grupos são alinhados a uma distribuição-alvo definida pela mediana entre grupos no espaço de quantis, e as instâncias são ajustadas por interpolação parcial, controlada pelo nível de reparo $\lambda \in [0, 1]$.

Uma limitação do método é que ele não se aplica diretamente a atributos não ordenáveis, pois depende de CDF/quantis para definir o mapeamento e para preservar a ordenação intra-grupo.

2.4.2 Métodos *in-processing* de mitigação de viés

Esta seção tem como propósito apresentar os métodos *in-processing* de mitigação de viés, isto é, aqueles cuja premissa consiste na intervenção direta no processo de treinamento dos modelos.

2.4.2.1 Grid Search Reduction

O *Grid Search Reduction* (Agarwal et al., 2018) aborda o problema de aprendizado justo por meio da reformulação do treinamento como uma sequência de problemas de classificação *cost-sensitive*, nos quais os custos de decisão incorporam penalizações induzidas por restrições de *fairness* formuladas como desigualdades lineares em momentos condicionais. De forma geral, tais restrições podem ser escritas como

$$M\mu(Q) \leq c, \quad (2.23)$$

onde $\mu(Q)$ denota o vetor de momentos (médias condicionais de quantidades como taxa de predição positiva) associado a um classificador Q , formulado no espaço de distribuições sobre classificadores base, e M e c codificam a família de restrições considerada (por exemplo, paridade estatística ou *equalized odds*).

A incorporação dessas restrições é realizada por meio de multiplicadores de Lagrange $\lambda \geq 0$, resultando no Lagrangiano empírico

$$L(Q, \lambda) = \widehat{\text{err}}(Q) + \lambda^\top (M\widehat{\mu}(Q) - \widehat{c}). \quad (2.24)$$

Esse Lagrangiano define um problema *primal-dual* (ou de ponto de sela), no qual Q busca minimizar o erro empírico sob penalizações associadas às violações de *fairness*, enquanto λ controla a intensidade dessas penalizações.

Na variante de *grid search*, seleciona-se uma grade discreta de valores para λ e, para cada ponto da grade, computa-se a melhor resposta do jogador Q por meio de uma chamada a um *cost-sensitive learner*. Esse procedimento gera um conjunto de classificadores candidatos, explorando diferentes pontos de *trade-off* entre desempenho e violação das restrições. Como a busca é conduzida sobre uma discretização do espaço de multiplicadores, não há garantia de recuperar o ponto ótimo do problema restrito, especialmente quando a grade é grosseira ou quando a dimensionalidade de λ é elevada.

Por construção, o objeto-alvo do método é um classificador aleatorizado: a solução é representada por uma distribuição Q sobre classificadores base, o que permite alcançar combinações de erro e *fairness* potencialmente inalcançáveis por um único classificador determinístico. Em aplicações práticas, pode-se ainda selecionar *a posteriori* um classificador determinístico dentre os candidatos gerados, ao custo de possível perda de otimalidade no *trade-off*.

Uma limitação relevante do *grid search* é a escalabilidade, pois o custo computacional cresce rapidamente com o número de restrições e com a cardinalidade do atributo sensível, tornando a busca em grade impraticável quando λ é de alta dimensão. Em contrapartida, o método é *model-agnostic*, uma vez que requer apenas acesso *black-box* a um *cost-sensitive learner*, sem demandar modificações internas no classificador base.

Por fim, existe uma variante relacionada, denominada *Exponentiated Gradient Reduction*, que substitui a busca em grade por uma dinâmica *no-regret* para atualização iterativa de λ , via atualizações multiplicativas. Essa abordagem tende a ser mais escalável e, em geral, mais fiel à resolução do problema de ponto de sela do que a discretização baseada em *grid search*.

2.4.2.2 Prejudice Remover

No método *Prejudice Remover* (Kamishima et al., 2012), adiciona-se um termo de regularização à função objetivo do modelo com o intuito de mitigar vieses associados ao conceito de "preconceito indireto". Em particular, o método busca penalizar a dependência estatística entre a variável de decisão $\hat{Y}$ e o atributo sensível A , mesmo quando A não é utilizado explicitamente no processo de decisão. Esse termo de regularização é definido a partir do *normalized prejudice index* (NPI), baseado na informação mútua entre $\hat{Y}$ e A :

$$\text{NPI}(\hat{Y}, A) = \frac{\sum_{a \in \mathcal{A}} \Pr(A = a) \sum_{\hat{y} \in \{0,1\}} \Pr(\hat{Y} = \hat{y} \mid A = a) \log \left(\frac{\Pr(\hat{Y} = \hat{y} \mid A = a)}{\Pr(\hat{Y} = \hat{y})} \right)}{\min\{H(\hat{Y}), H(A)\}}. \quad (2.25)$$

O regularizador é integrado a um modelo de regressão logística e ponderado por um parâmetro η , que controla a intensidade da penalização. Como o índice de preconceito não é diretamente otimizável, o autor propõe: (i) substituir a variável de decisão discreta por saídas probabilísticas do modelo; e (ii) aproximar as distribuições marginal e condicional $\Pr(\hat{Y} = \hat{y})$ e $\Pr(\hat{Y} = \hat{y} \mid A = a)$ por médias empíricas no conjunto de dados. Com

isso, o termo de preconceito torna-se uma função contínua e diferenciável dos parâmetros do modelo:

$$R_{\text{PR}}(\mathcal{D}, \theta) = \sum_{a \in \mathcal{A}} \frac{n_a}{N} \left[\bar{p}_a \log \left(\frac{\bar{p}_a}{\bar{p}} \right) + (1 - \bar{p}_a) \log \left(\frac{1 - \bar{p}_a}{1 - \bar{p}} \right) \right], \quad (2.26)$$

onde $p_i := \Pr(\hat{Y} = 1 \mid x_i; \theta)$, $\bar{p} := \frac{1}{N} \sum_{i=1}^N p_i$ e $\bar{p}_a := \frac{1}{n_a} \sum_{i:a_i=a} p_i$.

A função objetivo torna-se:

$$\min_{\theta} \mathcal{L}_{\text{LR}}(\mathcal{D}, \theta) + \eta R_{\text{PR}}(\mathcal{D}, \theta) + \lambda \|\theta\|_2^2. \quad (2.27)$$

O *Prejudice Remover* é um método *in-processing* clássico e amplamente adotado como *baseline* em estudos empíricos de *fairness*, estando disponível em toolkits amplamente utilizados, como o AIF360.

2.4.2.3 FairGBM

O *FairGBM* (Cruz et al., 2023) incorpora restrições de *fairness* ao treinamento de modelos baseados em *gradient boosted decision trees* por meio de uma formulação *in-processing*. O método reformula o aprendizado como um problema de otimização sob restrições baseadas em métricas de *fairness*, no qual se busca simultaneamente minimizar a perda preditiva do modelo e limitar disparidades entre grupos sensíveis.

Esse problema de otimização se vale do uso de multiplicadores de Lagrange e, devido ao caráter não diferenciável das métricas de *fairness*, adota uma formulação *proxy-Lagrangiana* (Cotter et al., 2018). Nessa formulação, são usadas de forma assimétrica duas versões da restrição. Para viabilizar a otimização via gradiente, substituem-se as taxas binárias (baseadas em funções indicadoras) por *proxies* diferenciáveis baseadas em funções suaves derivadas da entropia cruzada, definidas como funções contínuas do score do modelo. Do outro lado, a restrição original — definida a partir das taxas clássicas da matriz de confusão — é preservada como critério para mensurar a violação efetiva de *fairness*.

A etapa descendente do algoritmo, responsável pela atualização do modelo, minimiza a *proxy-Lagrangiana*, combinando o custo com as restrições *proxy*. Em contrapartida, a etapa ascendente utiliza a restrição original de *fairness* para atualizar os multiplicadores de Lagrange, ajustando o peso das restrições de acordo com a violação observada. Essa separação rompe a estrutura de um jogo estritamente de soma zero, mas permite

tratar restrições de *fairness* não diferenciáveis com garantias teóricas de viabilidade (e otimalidade) aproximadas.

2.4.2.4 Adversarial Debiasing

No *Adversarial Debiasing* (Zhang; Lemoine; Mitchell, 2018), utiliza-se o conceito de redes adversariais para mitigar vieses durante o processo de treino. Enquanto a rede principal é treinada para prever a variável resposta, a rede adversária utiliza esse resultado para prever o atributo sensível A . Para isso, o gradiente proveniente do adversário é empregado com sinal invertido na atualização dos parâmetros do preditor, de modo que o preditor minimize a perda da tarefa principal e, simultaneamente, maximize a perda do adversário, reduzindo a informação sobre A contida na saída do modelo. A equação apresenta o problema de minimização e maximização de perdas:

$$\min_{\theta} \max_{\phi} \mathbb{E}_{(X,Y,A)} [\text{Loss}(f_{\theta}(X), Y) - \lambda \cdot \text{Loss}(g_{\phi}(f_{\theta}(X)), A)] \quad (2.28)$$

Esse método pode empregar diferentes noções de *fairness*. Na prática, isso é determinado por como o adversário é construído e por quais variáveis ele recebe como entrada. Para *Demographic Parity* o adversário recebe apenas $\hat{Y}$; para *Equalized Odds*, recebe $(\hat{Y}, Y)$; e, para *Equality of Opportunity*, restringe-se o treinamento do adversário aos exemplos com $Y = y$. O hiperparâmetro λ controla o *trade-off* entre desempenho e mitigação de viés, e o método está disponível em diferentes *toolkits*, como o AIF360.

2.4.2.5 Wasserstein Fair Classification

O método *Wasserstein Fair Classification* (Jiang et al., 2019) busca superar limitações de abordagens *fairness-aware* que dependem da escolha de um limiar para binarizar predições. Em particular, em vez de impor paridade demográfica sobre a decisão binária $\hat{Y} = \mathbf{1}[S > \tau]$ para um τ específico, o método adota o critério de paridade demográfica forte (SDP, do inglês *Strong Demographic Parity*), definido diretamente sobre o *score* contínuo S . Nesse enquadramento, exige-se que a distribuição de S seja igual entre grupos (isto é, $p(S | A)$ invariável em relação a A), o que, por construção, implica paridade para qualquer valor de τ .

Para quantificar violações desse critério, o artigo define a disparidade demográfica forte entre pares (SPDD, do inglês *Strong Pairwise Demographic Disparity*) como uma medida da violação de SDP entre pares de grupos, baseada na expectativa (em τ) da

diferença nas taxas positivas induzidas por τ :

$$\text{SPDD} = \sum_{a \in \mathcal{A}} \sum_{\substack{a' \in \mathcal{A} \\ a' \neq a}} \mathbb{E}_{\tau \sim \mathcal{U}([0,1])} |\mathbb{P}(S_a > \tau) - \mathbb{P}(S_{a'} > \tau)|. \quad (2.29)$$

Na versão *in-processing*, o método treina uma regressão logística com um termo de regularização que penaliza o custo de alinhar as distribuições de *scores* de cada grupo a um baricentro Wasserstein-1 (Agueh; Carlier, 2011). Na prática, adiciona-se ao custo um termo $\sum_a W_1(\hat{p}_{S_a}, \hat{p}_{\bar{S}})$, o qual atua como uma limitação relacionada à SPDD e promove a aproximação de SDP:

$$J_{W_1}(\theta) = \alpha J_D(\theta) + (1 - \alpha) \beta \sum_{a \in \mathcal{A}} W_1(\hat{p}_{S_a}, \hat{p}_{\bar{S}}), \quad (2.30)$$

onde

$$J_D(\theta) = \frac{1}{N} \sum_{n=1}^N [-y_n \log s_n - (1 - y_n) \log(1 - s_n)], \quad s_n = \sigma(\theta^\top w_n) = \frac{1}{1 + e^{-\theta^\top w_n}}. \quad (2.31)$$

2.5 Base estatística para comparações múltiplas: Friedman–Holm

Esta seção tem como objetivo apresentar a fundamentação dos testes estatísticos utilizados neste estudo, com ênfase no teste de Friedman para comparação entre múltiplos métodos e no procedimento de Holm para correção de comparações múltiplas.

2.5.1 Teste de Friedman

O teste de Friedman (Friedman, 1937) é um teste não paramétrico, cujas premissas incluem: (i) independência entre blocos, (ii) comparações pareadas dentro de cada bloco e (iii) uma observação por tratamento em cada bloco, caracterizando um delineamento em blocos completos. Sob H_0 , para cada bloco i , as distribuições associadas aos k tratamentos são idênticas.

Considerando as hipóteses

$$\begin{aligned} H_0 : \tau_1 = \cdots = \tau_k \quad & \text{(não há efeito de tratamento)} \\ H_1 : \exists j \neq j' \text{ tal que } \tau_j \neq \tau_{j'} \quad & \text{(ao menos um tratamento difere)} \end{aligned} \quad (2.32)$$

Dado um total de n blocos, as k observações são ordenadas separadamente em cada bloco, do menor ao maior, e recebem *ranks* intra-bloco. No contexto de aprendizado de máquina, pode-se interpretar os n blocos como os conjuntos de dados, e as observações como o resultado (agregado por conjunto de dados) de uma métrica avaliada para cada método. Em caso de empates, atribui-se a cada observação o *rank* médio correspondente às posições empatadas.

A estatística de teste S é definida pela Equação 2.33:

$$S = \frac{12n}{k(k+1)} \sum_{j=1}^k \left(R_{.j} - \frac{k+1}{2} \right)^2, \quad (2.33)$$

em que a soma dos *ranks* do tratamento j é dada por $R_j = \sum_{i=1}^n r_{ij}$ e o *rank* médio por $R_{.j} = R_j/n$. Quando há empates, é usual empregar a correção apropriada na estatística (ou, alternativamente, ajustar a aproximação assintótica), de modo a preservar o nível do teste.

Em termos interpretativos, S quantifica a dispersão dos *ranks* médios $R_{.j}$ em torno do valor esperado sob H_0 , $(k+1)/2$. Assim, quanto mais próximos estiverem os *ranks* médios entre si, menor tende a ser S .

Para a tomada de decisão, rejeita-se H_0 quando $S \geq s_\alpha$, em que s_α é o valor crítico determinado a partir da distribuição nula de S (na cauda superior). Para n suficientemente grande, a distribuição de S é frequentemente aproximada por uma qui-quadrado com $k-1$ graus de liberdade, e a decisão é baseada em:

$$S \geq \chi_{k-1, 1-\alpha}^2, \quad (2.34)$$

em que $\chi_{k-1, 1-\alpha}^2$ denota o quantil de ordem $1-\alpha$ da distribuição qui-quadrado com $k-1$ graus de liberdade.

2.5.2 Procedimento de Holm

O procedimento de Holm (Holm, 1979) é um método sequencial do tipo *step-down* para ajuste de múltiplas comparações, cujo objetivo é controlar a taxa de erro por família de testes (*family-wise error rate*, FWER). Seja M o número de hipóteses testadas (por exemplo, $M = k - 1$ quando se comparam k métodos contra um único controle). Após ordenar os p-valores como $p_{(1)} \leq \dots \leq p_{(M)}$, cada p-valor ordenado $p_{(i)}$, para $i = 1, \dots, M$, é comparado ao limiar $\frac{\alpha}{M-i+1}$.

Enquanto $p_{(i)}$ for inferior ao limiar correspondente, rejeita-se a hipótese associada e prossegue-se para o próximo teste. Caso, para algum i , verifique-se $p_{(i)}$ maior ou igual ao limiar, a hipótese correspondente não é rejeitada e o procedimento é interrompido, implicando que nenhuma das hipóteses subsequentes é rejeitada.

De forma equivalente, o ajuste pode ser expresso por meio dos p-valores ajustados de Holm, definidos por

$$p_{(i)}^{\text{Holm}} = \max_{t \leq i} \left\{ (M - t + 1) p_{(t)} \right\}, \quad i = 1, \dots, M, \quad (2.35)$$

com truncamento para garantir pertencimento ao intervalo unitário:

$$p_{(i)}^{\text{Holm}} = \min\{p_{(i)}^{\text{Holm}}, 1\}. \quad (2.36)$$

3 TRABALHOS RELACIONADOS

Os estudos de *fairness* em aprendizado de máquina ganharam tração ao longo da década de 2010 (Mehrabi et al., 2019; Caton; Haas, 2020; Barocas; Hardt; Narayanan, 2023), acompanhados por um aumento expressivo no número de métricas e algoritmos propostos. Apesar desse avanço, ainda não há consenso sobre a eficácia relativa desses métodos, nem sobre como escolhas de protocolo experimental (por exemplo, *splits*, pré-processamento e hiperparâmetros) afetam as conclusões, o que compromete a comparabilidade e a reprodutibilidade dos resultados. Dado o caráter multiobjetivo da mitigação de vieses, uma vertente relevante da literatura concentra-se em *benchmarks* empíricos que comparam métodos sob diferentes métricas e caracterizam o *trade-off* entre utilidade e *fairness*. Nesta seção, discutem-se trabalhos alinhados aos objetivos desta pesquisa, com ênfase em (i) *surveys* e revisões que organizam o espaço de métodos e métricas, e (ii) estudos empíricos comparativos (*benchmarks*) que avaliam sistematicamente técnicas de mitigação em diferentes configurações experimentais.

Nesse contexto, Raftopoulos et al. (2025) apresentam uma revisão ampla sobre modelos *fairness-aware*, complementando-a com um *benchmark* empírico. Enquanto Friedler et al. (2018), Biswas and Rajan (2020), Chen et al. (2023), Han et al. (2024), Ganesh et al. (2024) conduzem avaliações empíricas comparativas, em geral no contexto de *fairness* de grupo, contrastando intervenções de *pre-processing*, *in-processing* e *post-processing* com um modelo de referência sem mitigação. Esses estudos evidenciam ganhos potenciais de *fairness* em relação a esse referencial, frequentemente acompanhados de *trade-offs* com desempenho preditivo; mas também apontam limitações relevantes, ausência de métodos dominantes e forte sensibilidade às configurações experimentais.

O estudo de Friedler et al. (2018) propõe um protocolo experimental, aplicado a classificadores, para avaliação comparativa de intervenções *fairness-aware* de *pre-processing*, *in-processing* e *post-processing*, analisando conjuntamente *fairness*, desempenho e a sensibilidade dos resultados a escolhas do *pipeline*. Utiliza cinco conjuntos de dados reais, provenientes de *benchmarks* consolidados na literatura de *fairness* e aprendizado de máquina, abrangendo domínios distintos. Os algoritmos foram avaliados por meio de múltiplas repetições de *hold-out*, de forma a capturar a variabilidade associada ao processo de amostragem. Emprega-se um conjunto de métricas de desempenho e *fairness* (sob noções de *fairness* de grupo), e os resultados indicam que parte dessas métricas produz

informações frequentemente redundantes. Como contraponto, o estudo não avalia noções de *fairness* individual, isto é, o princípio de que indivíduos similares deveriam receber decisões similares (Dwork et al., 2011).

Dentre os principais achados das comparações empíricas, destaca-se a alta dependência das configurações experimentais, em particular das variações nos *splits* treino-teste e das etapas de pré-processamento, que exercem impacto significativo tanto nas métricas de *fairness* quanto nas de desempenho. Adicionalmente, os resultados evidenciam sensibilidade à parametrização e ao critério priorizado (por exemplo, priorização de acurácia versus impacto díspar em algumas variantes), influenciando as conclusões sobre o viés mitigado. Não foi observada dominância consistente entre os algoritmos avaliados.

Já Raftopoulos et al. (2025) apresentam uma extensa revisão de métodos *fairness-aware*, organizando as abordagens por diferentes famílias, incluindo variantes de modelos clássicos. Além disso, realizam uma comparação empírica de um subconjunto dessas estratégias, delimitado no estudo por razões práticas. O *pipeline* experimental utiliza validação cruzada em 10 *folds* e adota, para todos os modelos, os valores padrões de hiperparâmetros, limitação destacada no estudo. Os conjuntos de dados utilizados são *benchmarks* conhecidos no contexto de estudos de aprendizado de máquina, como Titanic e Adult Income (Becker; Kohavi, 1996). Como principal métrica de desempenho, o estudo usa acurácia; como observação metodológica, isso pode ser pouco informativo em cenários desbalanceados. Para avaliar *fairness*, são utilizadas métricas voltadas à diferença de paridade estatística e métricas derivadas da matriz de confusão. A comparação dos algoritmos não inclui *baseline* de referência sem tratamento de *fairness*, e se concentra principalmente na comparação de médias e desvios padrão das estratégias.

Dentre os achados, mantém-se a conclusão de que não há uma estratégia universal para mitigar efeitos de vieses. Uma das análises centrais do estudo é o *trade-off* entre desempenho e *fairness*. Os autores apontam que essa escolha nem sempre é inevitável, havendo conjuntos em que se observa melhoria simultânea de desempenho e *fairness*. Em geral, técnicas ensemble tendem a apresentar *trade-offs* mais favoráveis, enquanto AdaFair aparece associado a restrições mais rígidas de *fairness*, o que pode comprometer parte do desempenho.

Han et al. (2024) conduziram um estudo comparativo abrangente envolvendo 14 conjuntos de dados, com o objetivo de estabelecer um *benchmark* padronizado para a avaliação de métodos de mitigação de viés do tipo *in-processing* para *group fairness*. O principal enfoque do trabalho foi o desenvolvimento de um código *open source* extensí-

vel e orientado à pesquisa, capaz de viabilizar a comparação sistemática de técnicas de *fairness* sob configurações experimentais unificadas.

Entre os principais achados, os autores observaram que o método baseado em HSIC apresentou o melhor equilíbrio entre utilidade e *fairness*, a partir da análise de curvas normalizadas que relacionam métricas de desempenho e métricas de equidade, tomando como referência o modelo ERM. Em contraste, métodos baseados em *adversarial debiasing* demonstraram comportamento significativamente mais instável, com elevada variabilidade nos resultados e maior dificuldade de controle do *trade-off* por meio de hiperparâmetros.

Além disso, um dos focos centrais da análise foi a avaliação da estabilidade dos métodos ao longo do processo de treinamento. Os resultados indicam que, de forma geral, em dados tabulares e de imagem, as métricas de *fairness* apresentam maior instabilidade quando comparadas às métricas de desempenho; no experimento com dados de texto, os autores reportam um padrão distinto, com instabilidade mais pronunciada nas curvas de utilidade em relação ao que se observa nos demais cenários. O estudo também discute estratégias práticas para mitigação dessa instabilidade, como a interrupção do treinamento associada ao decaimento da taxa de aprendizado.

Biswas and Rajan (2020) conduzem um estudo empírico sobre viés, mitigação e *trade-offs* entre *fairness* e desempenho em modelos de aprendizado de máquina publicados no Kaggle ¹. Para isso, constroem um *benchmark* a partir de *kernels* selecionados sob critérios mínimos de qualidade, extraíndo o melhor modelo de cada *kernel*, totalizando 40 modelos em 5 conjuntos de dados. A avaliação considera acurácia e F1, além de sete métricas de *fairness* que incluem medidas de grupo e individuais, comparando sete mitigadores *pre-processing*, *in-processing* e *post-processing* sob *holdout* repetido (70/30, 10 repetições).

Entre os achados, Biswas and Rajan (2020) mostram que escolhas de hiperparâmetros e decisões do *pipeline* voltadas a desempenho podem alterar substancialmente os resultados de *fairness*, e que diferentes métricas podem capturar efeitos distintos ou contraditórios, reforçando a necessidade de avaliação multi-métrica. Os autores também reportam maior variabilidade em impacto díspar, *equalized odds difference* e *average odds difference* ao longo das repetições e destacam que o perfil de *fairness* pode mudar conforme o atributo protegido. Em geral, métodos de pós-processamento aparecem com frequência como os mais efetivos para reduzir viés, porém com perdas de desempenho;

¹ <https://www.kaggle.com/>

como limitações, o estudo depende de modelos selecionados via curadoria/popularidade da plataforma e não explora de forma sistemática inferência estatística e decomposições por direção e intensidade do viés.

Chen et al. (2023) conduzem uma avaliação empírica extensa de abordagens de mitigação de viés, com foco no impacto em *fairness* e no *trade-off* com desempenho. O estudo considera 11 métricas de desempenho e adota, para *fairness* de grupo, as métricas diferença de paridade estatística, *average odds difference*, *equal opportunity difference* e diferença na taxa de erro. Os experimentos são realizados em cinco *benchmarks* amplamente utilizados, implementados no toolkit IBM AIF360 (Adult, COMPAS, German, Bank e MEPS), considerando diferentes atributos protegidos.

A configuração experimental compara 17 métodos de mitigação (*pre-processing*, *in-processing* e *post-processing*), repetidos 50 vezes sob *holdout* aleatório (70/30). Para análise, os autores utilizam testes estatísticos não paramétricos, medidas de tamanho de efeito e correlação de Spearman. Em termos agregados, observam queda em métricas de desempenho, em média, em 53% dos cenários. Na análise por regiões de *trade-off* (*win-win / good trade-off*), *Reweighting* apresenta a maior proporção de casos em regiões favoráveis. Ainda assim, os autores reforçam que não há um método universalmente superior, sendo necessária avaliação caso a caso; além disso, o ganho de *fairness* não é garantido, com ocorrência de perda simultânea de *fairness* e desempenho em 25% dos cenários. Como limitação, as métricas de *fairness* avaliadas restringem-se a critérios de grupo, sem contemplar *fairness* individual; adicionalmente, a inferência estatística em cenários com múltiplas comparações e repetição de *holdout* pode ser sensível a suposições de independência e a controle de multiplicidade, caso não explicitados no protocolo.

Expandindo o protocolo do *benchmark* FFB de Han et al. (2024), Ganesh et al. (2024) avaliam sete métodos *in-processing* (treinados por gradiente) em sete conjuntos de dados tabulares, investigando sistematicamente a sensibilidade desses mitigadores a escolhas do *pipeline* de treinamento. As métricas centrais do estudo são paridade demográfica (*demographic parity*) para *fairness* e acurácia para desempenho, com análises adicionais usando *equalized odds* e *equal opportunity*. Motivado por evidências de instabilidade em métodos *in-processing*, o trabalho caracteriza como variações de sementes aleatórias, parâmetros de controle do mitigador e hiperparâmetros de treinamento/modelagem (p.ex., *learning rate*, *batch size* e arquitetura MLP) alteram substancialmente os *trade-offs* observados, podendo favorecer diferentes algoritmos sob diferentes configurações.

A Tabela 3.1 apresenta uma síntese dos trabalhos relacionados, bem como seus

principais achados e limitações.

Tabela 3.1 – Comparação dos trabalhos relacionados quanto ao escopo experimental e ao protocolo de análise, incluindo o presente trabalho como última linha. A coluna *Etapas* indica em quais etapas do *pipeline* os métodos de mitigação avaliados atuam: *pre-processing* (Pre), *in-processing* (In) e *post-processing* (Post). A coluna *Fairness* discrimina o uso de métricas de grupo (Grupo) e/ou individuais (Individual).

Ref.	Conjuntos de dados / Domínio	Etapas	Fairness	Análise estatística	Decomposição do viés	Hiperparâmetros
Friedler et al. (2018)	5 / consolidados (vários domínios)	Pre+In+Post	Grupo	Não documentada	Não	Padrões
Biswas and Rajan (2020)	5 / consolidados (Kaggle)	Pre+In+Post	Grupo + Individual	Não	Não	Ajustados para desempenho (Kaggle)
Chen et al. (2023)	5 / consolidados (AIF360)	Pre+In+Post	Grupo	Mann–Whitney, Spearman (sem controle de multiplicidade)	Não	Padrões (sem <i>tuning</i> sistemático)
Han et al. (2024)	14 / consolidados (tabular, imagem e texto)	In	Grupo	Curvas normalizadas (não formal)	Não	Configurações do protocolo FFB
Ganesh et al. (2024)	7 / consolidados (tabulares)	In	Grupo	Não	Não	Variações sistemáticas (sensibilidade)
Raftopoulos et al. (2025)	? / consolidados	Pre+In+Post	Grupo	Não (média $\pm$ dp)	Não	Padrões (limitação destacada)
Presente trabalho	6 / saúde	Pre+In	Grupo + Individual	Friedman+Holm	Sim (intensidade, sentido, <i>trade-off</i>)	Padrões dos estudos de origem

Em síntese, os trabalhos revisados incluem *surveys* e *benchmarks* empíricos que caracterizam *trade-offs* entre *fairness* e desempenho, tipicamente com um conjunto res- trito de métricas de *fairness* (predominantemente de grupo) e com foco em aspectos espe- cíficos do protocolo experimental, como padronização de *splits* ou sensibilidade a hiper- parâmetros. Além disso, em parte desses estudos, a análise estatística e a decomposição dos resultados por fatores que influenciam o *trade-off* (por exemplo, direção do viés e sua intensidade, em termos de magnitude do efeito) não são exploradas de forma sistemática.

Diferindo desses estudos, o presente trabalho realiza uma comparação mais am- pla em termos de métricas, incorporando medidas de desempenho e de *fairness*, tanto de grupo quanto individual. Adicionalmente, o trabalho inclui análises complementares sobre direção (sinal) e intensidade do viés, quantificada pela magnitude do efeito. Além

disso, busca-se ampliar a cobertura metodológica ao incluir famílias de mitigação menos frequentes em *benchmarks* recentes, como abordagens *in-processing* baseadas em *reductions*, e ao explicitar a comparação entre estratégias *pre-* e *in-processing* sob um protocolo comum. Por fim, ao considerar conjuntos de dados em domínios pouco explorados por *benchmarks* clássicos, com ênfase em aplicações na área da saúde, o estudo fornece evidências comparativas adicionais para contextos e distribuições distintas das bases tradicionalmente utilizadas.

4 METODOLOGIA

Este trabalho investiga a efetividade de diferentes métodos de mitigação de vies aplicados a modelos de classificação, considerando de forma conjunta a redução de desigualdades entre grupos sensíveis e o impacto dessas intervenções no desempenho do modelo. Para isso, foi conduzido um estudo experimental comparativo envolvendo múltiplos conjuntos de dados, modelos de referência e estratégias de mitigação de diferentes tipos, organizados em um *pipeline* experimental padronizado. Este capítulo detalha todos os materiais e métodos envolvidos na metodologia desenvolvida na pesquisa, os quais estão disponíveis em repositório público¹. O capítulo inicia com a apresentação das métricas de avaliação selecionadas, abrangendo medidas de *fairness* e de desempenho preditivo. Na sequência, são descritos os modelos de referência (*baselines*) e os métodos de mitigação analisados, o *pipeline* experimental adotado, a estratégia de análise e interpretação dos resultados e, por fim, os conjuntos de dados empregados nos experimentos.

4.1 Métricas de avaliação

A avaliação dos modelos foi conduzida a partir de dois eixos complementares: *fairness* e desempenho preditivo. As métricas de *fairness* permitem identificar e mensurar desigualdades sistemáticas entre grupos definidos por atributos sensíveis, bem como disparidades em nível individual, enquanto as métricas de desempenho preditivo capturam a capacidade discriminativa e a qualidade global das predições. A análise conjunta desses dois eixos é central neste estudo, uma vez que métodos de mitigação de vies frequentemente induzem *trade-offs* entre redução de desigualdades e desempenho preditivo.

A seleção das métricas de *fairness* buscou equilibrar abrangência e interpretabilidade, evitando tanto um conjunto excessivamente redundante quanto uma cobertura restrita a poucos conceitos. Para orientar essa escolha, foram consideradas (i) as categorias descritas na Seção 2.3 (Caton; Haas, 2020) e (ii) os agrupamentos (*clusters*) validados empiricamente por Majumder et al. (2022). Os *clusters* foram utilizados como referência para assegurar diversidade e sensibilidade das medidas escolhidas, sem a pretensão de reproduzir integralmente a taxonomia do estudo. Dos sete *clusters* reportados pelos autores, cinco foram contemplados neste trabalho. Ressalta-se, contudo, que esses *clusters* não necessariamente coincidem com as categorias, as quais têm finalidade organizacional

¹<<https://github.com/gabrieloliveira/fairness-healthcare>>

e não implicam correspondência direta com agrupamentos empíricos.

Dentro desse enquadramento, adotou-se como regra prática selecionar uma métrica para cada uma de três categorias priorizadas: paridade estatística, métricas baseadas na matriz de confusão e *fairness* individual, escolhidas por sua maior representatividade em estudos prévios (Hort et al., 2023). Além disso, foram priorizadas métricas que explicitam a direção do viés, por fornecerem uma informação adicional útil para interpretação dos resultados. Por esse motivo, por exemplo, optou-se pela diferença na taxa de falsos negativos, em detrimento de métricas agregadas como *average odds difference*, cuja direção não é explicitamente associada a um tipo de erro específico. Ainda no conjunto selecionado, incluiu-se a métrica de consistência proposta por Zemel et al. (2013), que avalia se instâncias semelhantes recebem classificações semelhantes por parte do modelo. Embora Majumder et al. (2022) empreguem uma variação dessa métrica calculada a partir dos rótulos verdadeiros, neste trabalho adota-se a formulação original, baseada nas predições do classificador, uma vez que o interesse reside em avaliar o comportamento do modelo treinado. A Tabela 4.1 apresenta as métricas selecionadas para a avaliação de *fairness*.

Tabela 4.1 – Métricas utilizadas, com o identificador do *cluster* de origem segundo Majumder et al. (2022) e a categoria adotada neste trabalho. O identificador na coluna ID *Cluster* corresponde ao agrupamento empírico de métricas de comportamento semelhante definido naquele estudo. A consistência aparece sem identificador (–) porque a formulação aqui adotada, baseada nas predições, difere da empregada por aqueles autores, baseada nos rótulos verdadeiros, não se associando a nenhum *cluster* daquele estudo.

Métrica	ID <i>Cluster</i>	Categoria
Diferença na taxa de erro	0	Matriz de confusão
Amplificação de viés sob <i>fairness</i> diferencial (DFBA)	1	Paridade estatística
Impacto díspar	4	Paridade estatística
Diferença na taxa de falsos negativos	4	Matriz de confusão
Diferença na taxa de falsa descoberta	3	Matriz de confusão
Índice de Entropia Generalizado	2	<i>Fairness</i> individual
Consistência	–	<i>Fairness</i> individual

Para o desempenho preditivo adotou-se o F1-Score como métrica principal, definido como a média harmônica entre precisão e revocação. A escolha decorre da baixa sensibilidade da acurácia a cenários de desbalanceamento de classes, frequentes nos conjuntos avaliados. Acurácia, precisão e revocação são reportadas adicionalmente nas tabelas para completude, mas a análise comparativa entre métodos e a avaliação de *trade-off*

concentram-se no F1-Score.

4.2 Métodos avaliados e configurações experimentais

Esta seção apresenta os modelos e métodos considerados nos experimentos, incluindo modelos de referência (*baselines*) e métodos de mitigação de viés. Os modelos de referência servem como ponto de comparação para avaliar desempenho e níveis de viés, enquanto os métodos de mitigação (incluindo estratégias de *pre-processing* e *in-processing*) permitem analisar a efetividade das intervenções e os *trade-offs* associados à sua aplicação.

4.2.1 Modelos de referência sem mitigação (*baselines*)

Como *baselines* adotaram-se Regressão Logística (LR) e Floresta Aleatória (*Random Forests*, RF). A LR foi escolhida por ser o classificador base de vários métodos de mitigação avaliados, aumentando o controle entre comparações; a RF complementa o conjunto com um modelo não linear, capaz de capturar padrões mais complexos. Ambos têm número reduzido de hiperparâmetros e baixa sensibilidade à otimização em comparação com algoritmos mais complexos, como redes neurais.

Os hiperparâmetros da LR foram definidos com o objetivo de desviar o mínimo possível do classificador base utilizado nos métodos de mitigação: $C = 1$ e regularizador Ridge (L2). Para a RF, foram controlados apenas para reduzir o risco de *overfitting*: profundidade máxima de 20, 200 árvores e critério de divisão *gini*.

Cada algoritmo é avaliado em duas configurações quanto ao uso do atributo sensível: na configuração *aware*, o atributo sensível é incluído como variável preditora; na configuração *unaware*, ele é removido do conjunto de entrada. A combinação de dois algoritmos e duas estratégias resulta em quatro configurações de *baseline*: Regressão Logística *aware* (BLRA), Regressão Logística *unaware* (BLRU), Floresta Aleatória *aware* (BRFA) e Floresta Aleatória *unaware* (BRFU). Essas quatro configurações são referenciadas coletivamente como os modelos de referência ao longo deste trabalho.

4.2.2 Métodos de mitigação de viés e hiperparâmetros

A escolha dos métodos de mitigação considerou a etapa do *pipeline* experimental em que cada abordagem atua. O trabalho concentra-se nos métodos de *in-processing*, que incorporam critérios de *fairness* diretamente ao processo de aprendizado; por essa razão, a maior parte dos métodos avaliados pertence a essa categoria. Os métodos de *pre-processing*, que atuam sobre os dados antes do treinamento, foram incluídos em menor número, como contraponto: representam uma família de intervenção consolidada na literatura e permitem comparar os métodos de *in-processing* a uma abordagem de natureza distinta. Já os métodos de *post-processing*, que ajustam as previsões após o treinamento, não foram contemplados, por uma delimitação de escopo: parte dessas abordagens requer uma partição adicional dos dados para esse ajuste, o que reduziria o volume disponível para o treinamento — limitação relevante diante da baixa volumetria de alguns dos conjuntos analisados.

A seleção, dentro dessas categorias, considerou (i) a inclusão de algoritmos consolidados e amplamente utilizados como referência em avaliações empíricas; e (ii) a incorporação de abordagens mais recentes, ainda menos presentes como *benchmarks* comparativos. Neste trabalho, “recorrência em *benchmarks* comparativos” refere-se à frequência com que um método é adotado como referência em estudos empíricos na literatura (Hort et al., 2023). Além disso, buscou-se cobrir mecanismos distintos de mitigação dentro de uma mesma etapa do *pipeline*.

Com base nesses critérios, em *pre-processing* foram adotados o *Disparate Impact Remover* (Feldman et al., 2015) e o *Reweighting* (Kamiran; Calders, 2012), utilizados como referências representativas e bem estabelecidas desse tipo de intervenção. Para *in-processing*, empregaram-se algoritmos consolidados, como *Prejudice Remover* (Kamishima et al., 2012), *Adversarial Debiasing* (Zhang; Lemoine; Mitchell, 2018) e *Grid Search Reduction* (Agarwal et al., 2018), bem como abordagens mais recentes, como *Wasserstein Fair Classification* (Jiang et al., 2019) e *FairGBM* (Cruz et al., 2023). Para cada método, adotaram-se as configurações de hiperparâmetros reportadas como mais relevantes em seus estudos de origem. Os métodos de mitigação de viés selecionados e os hiperparâmetros empregados nos experimentos estão sumarizados na Tabela 4.2.

Optou-se por não realizar otimização extensiva de hiperparâmetros por método e conjunto de dados. Essa decisão se apoia em duas considerações. Primeiro, no contexto específico de *fairness*, há evidências de que a superioridade aparente de um método de

mitigação pode decorrer dos parâmetros de avaliação adotados, e não da técnica em si (Ganesh et al., 2024). Segundo, a inclusão de buscas extensivas aumentaria substancialmente a dimensionalidade do espaço experimental — já composto por sete métricas de *fairness*, seis conjuntos de dados, direção do viés e múltiplos métodos — dificultando a atribuição dos efeitos observados ao mecanismo de mitigação propriamente dito. Ao adotar os hiperparâmetros reportados nos estudos de origem, o protocolo mantém uma configuração uniforme e reproduzível, concentrando a análise nos eixos centrais do trabalho. Reconhece-se, contudo, que essa escolha pode subestimar o desempenho de métodos mais sensíveis à configuração de hiperparâmetros.


Tabela 4.2 – Resumo dos métodos de mitigação de viés e hiperparâmetros adotados.

Categoria	Método	ID	Hiperparâmetros / Configuração
Pre-processing	Disparate Impact Remover + Regressão Logística	EDL	repair_level=0.8; awareness=True; estimator=LogisticRegression(C=1.0, penalty=l2)
	Reweighting + Regressão Logística	ERL	-
In-processing	Prejudice Remover	IP	eta=15
	Grid Search Reduction (Demographic Parity) Regressão Logística (aware)	IGLA	constraints=DemographicParity; constraint_weight=0.5; grid_size=20; grid_limit=2; loss=ZeroOne; drop_prot_attr=False; estimator=LogisticRegression(C=1.0, penalty=l2)
	Grid Search Reduction (Demographic Parity) Regressão Logística (unaware)	IGLU	constraints=DemographicParity; constraint_weight=0.5; grid_size=20; grid_limit=2; loss=ZeroOne; drop_prot_attr=True; estimator=LogisticRegression(C=1.0, penalty=l2)
	Adversarial Debiasing	IAD	num_epochs=100; batch_size=128; classifier_num_hidden_units=200; adversary_loss_weight=0.1; debias=True
	Wasserstein Fair Classification (Wasserstein-1)	IW	alpha=0.5; beta=100; lr=0.1; max_iter=2000; distance=wasserstein-1; solver=line; delta=0.005; barycenter=True; bary_every=100000; bary_bins=50; bary_reg=1e-2; bary_max_iter=1000; bary_n_samples=200; init_from_lr=True; awareness=True
	FairGBM	IFG	n_estimators=100; max_depth=3; awareness=True

4.3 Pipeline experimental

A Figura 4.1 apresenta um diagrama esquemático do *pipeline* construído para aplicação dos modelos e métodos descritos na Seção 4.2. Partindo dos conjuntos de dados já pré-processados (isto é, submetidos a etapas de limpeza, tratamento de valores ausentes e codificação de variáveis categóricas, detalhadas para cada conjunto na Seção 4.5.1), são realizadas, de forma sequencial, as seguintes etapas principais: divisão estratificada das amostras, treinamento dos modelos e avaliação dos modelos.

Figura 4.1 – Diagrama esquemático do *pipeline* aplicado nos experimentos realizados. São realizadas 10 repetições de validação cruzada com 3 *folds*.



Fonte: A autora

4.3.1 Divisão estratificada dos dados e padronização

A divisão dos dados para treinamento e teste é feita com base na estratégia de validação cruzada e considera simultaneamente a variável resposta e o grupo do atributo sensível, de forma que a proporção da interseção desses atributos seja preservada em cada *fold*. Com exceção dos métodos baseados em árvores (*baseline* Floresta Aleatória e método *in-processing* FairGBM), os demais passam ainda por um processo de padronização

para ajuste de escalas. Os conjuntos de teste são padronizados utilizando o fator de escala estimado a partir dos dados de treino, a fim de evitar o fenômeno de *data leakage* (Kapoor; Narayanan, 2023).

4.3.2 Procedimento de treinamento e avaliação

O processo de treinamento dos modelos é conduzido de acordo com o tipo do método de mitigação de viés considerado. No *pipeline* de *pre-processing*, cada conjunto de treino é inicialmente submetido ao método de mitigação e, em seguida, utilizado para o treinamento de um classificador base, a Regressão Logística. Posteriormente, os conjuntos de teste correspondentes são aplicados ao modelo treinado para a extração dos resultados.

No *pipeline* que contempla os métodos de *in-processing* e os modelos de *baseline*, cada conjunto de treino é utilizado diretamente no treinamento do modelo correspondente, no qual os critérios de mitigação de viés, quando aplicáveis, são incorporados ao próprio processo de aprendizado. Em ambos os casos, os resultados reportados são obtidos exclusivamente a partir dos conjuntos de teste.

Para cada modelo treinado utilizando os *folds* de treinamento e a estratégia selecionada (*baseline*, mitigação *pre-processing* ou mitigação *in-processing*), executa-se a avaliação utilizando o *fold* de teste e as métricas apresentadas na Seção 4.1. Para aumentar a robustez das estimativas, foi aplicado um processo de validação cruzada com 3 *folds* e 10 repetições, totalizando 30 execuções por método. A escolha por uma quantidade reduzida de *folds* decorre da baixa volumetria de alguns conjuntos de dados. Com menos partições, cada subconjunto contém mais amostras, reduzindo o risco de que classes raras fiquem ausentes em alguma delas, um problema comum em bases desbalanceadas.

As sementes aleatórias foram fixadas na divisão dos conjuntos, nos algoritmos de aprendizado de máquina e nos métodos de mitigação de viés, de modo a garantir reprodutibilidade dos resultados.

4.4 Estratégia de análise e interpretação dos resultados

Esta seção descreve a estratégia adotada para organizar e interpretar os resultados de forma comparável entre conjuntos de dados, preservando o sentido do viés (quando

aplicável) e introduzindo critérios de elegibilidade por categoria de métrica para focalizar a interpretação em cenários com afastamento relevante do ideal, evitando a diluição de resultados e a subestimação do impacto das intervenções.

4.4.1 Agregação dos resultados e medidas relativas

Para garantir comparabilidade entre métodos e conjuntos de dados, as métricas são analisadas a partir de valores agregados em nível de conjunto de dados. Em particular, a caracterização do viés no *baseline* é realizada da seguinte forma: para cada par (conjunto de dados, métrica), os resultados do *baseline* são agregados por meio da mediana, computada sobre *folds*, repetições e também sobre os diferentes modelos de referência considerados como *baseline*. Assim, obtém-se um valor robusto por par conjunto de dados e métrica, reduzindo o efeito de flutuações pontuais.

Ao longo do trabalho, as métricas de *fairness* são interpretadas em relação a um valor matematicamente ideal denotado por m^* (por exemplo, $m^* = 0$ para métricas baseadas em diferenças e $m^* = 1$ para métricas baseadas em razões). Define-se uma função de distância ao ideal $d(\cdot)$ que depende da natureza da métrica:

$$d(m) = \begin{cases} |m - m^*|, & \text{(distância aditiva)} \\ \max\left(\frac{m}{m^*}, \frac{m^*}{m}\right) - 1, & \text{(distância multiplicativa; métricas de razão)} \end{cases} \quad (4.1)$$

onde a distância multiplicativa é empregada para métricas de razão (neste estudo, o impacto díspar) para capturar desvios relativos de forma simétrica em torno do ideal, isto é, penalizando igualmente variações acima e abaixo de m^* (por exemplo, 0,8 e $1/0,8 = 1,25$ quando $m^* = 1$). Essa escolha é consistente com medidas simétricas baseadas em razões/*log-ratio* na literatura (Botchkarev, 2019) e com a interpretação multiplicativa subjacente a critérios de referência para impacto díspar, como a *four-fifths rule* (U.S. Equal Employment Opportunity Commission, n.d.), sendo também adequada para métricas definidas em $[0, \infty)$.

Com essa definição, o efeito percebido em *fairness* ao aplicar um método de mitigação é medido pela redução da distância ao ideal em comparação ao *baseline*:

$$\Delta_{\text{fair}} = d(m_{\text{baseline}}) - d(m_{\text{método}}), \quad (4.2)$$

de modo que $\Delta_{\text{fair}} > 0$ indica aproximação ao valor ideal (melhora de *fairness*) e, ao contrário, $\Delta_{\text{fair}} < 0$ indica afastamento (piora de *fairness*).

De forma análoga, o efeito do método de mitigação de viés sobre o desempenho preditivo é definido como a diferença entre o valor obtido pelo método e pelo *baseline* para a métrica considerada. Embora essa definição seja válida para qualquer métrica de desempenho, apresenta-se a seguir o caso do F1-score, utilizado como métrica principal:

$$\Delta_{F1} = F1_{\text{método}} - F1_{\text{baseline}}. \quad (4.3)$$

Complementarmente, para permitir uma interpretação normalizada da magnitude da mitigação em relação ao viés inicial, adota-se também o efeito relativo (fração removida), derivado de Δ_{fair} , com normalização pelo desvio inicial observado no *baseline*:

$$r_{\text{fair}} = \frac{\Delta_{\text{fair}}}{d_{\text{baseline}} + \xi} = 1 - \frac{d_{\text{método}}}{d_{\text{baseline}} + \xi}$$

em que ξ representa um termo pequeno introduzido para garantir estabilidade numérica nos casos em que $d_{\text{baseline}} \approx 0$.

Quando a análise requer o *sentido* do viés (isto é, em qual grupo o impacto é desfavorável), utiliza-se a variação em comparação ao valor ideal sem a operação de módulo,

$$\delta(m) = m - m^*, \quad (4.4)$$

em conjunto com convenções específicas por métrica: para o impacto díspar, $DI < 1$ indica viés desfavorável ao grupo não privilegiado e $DI > 1$ ao privilegiado. Para a amplificação de viés, que não possui sentido intrínseco por mensurar a amplificação em relação aos dados de treino, adota-se o sentido identificado pelo impacto díspar no mesmo conjunto de dados. Já em diferenças de taxas derivadas da matriz de confusão, adota-se a convenção *unprivileged* – *privileged*, de modo que valores positivos indicam que o grupo não privilegiado apresenta taxa mais elevada naquele tipo de erro — seja de falsos negativos, falsa descoberta ou erro global —, caracterizando desvantagem para esse grupo (sentido U, *unprivileged*); valores negativos indicam o oposto (sentido P, *privileged*) (Barocas; Hardt; Narayanan, 2023; Bellamy et al., 2018). Em ambos os casos, o sentido U denota desvantagem para o grupo não privilegiado, embora o mecanismo subjacente difira entre categorias: na categoria A, a desvantagem se manifesta como menor acesso ao resultado positivo; na categoria C, como maior incidência de erros de classificação.

Neste trabalho, a designação de grupo privilegiado e não privilegiado é definida *a priori*, com base em conhecimento de domínio: homens (para gênero e sexo), pessoas brancas (para raça) e pessoas heterossexuais (para orientação sexual) são tratados como grupo privilegiado. Essa definição é independente dos valores observados nas métricas e é mantida fixa ao longo de toda a análise, de modo que o sentido do viés (U ou P) reflete a direção da disparidade em relação a essa convenção.

Para a análise de *trade-off* entre desempenho preditivo e *fairness*, adota-se uma visualização em quadrantes definidos pelos sinais de Δ_{fair} e Δ_{F1} . A combinação desses sinais delimita quatro regiões: (i) $\Delta_{\text{fair}} > 0$ e $\Delta_{F1} \geq 0$ (*win-win*), indicando ganho simultâneo em *fairness* e desempenho; (ii) $\Delta_{\text{fair}} > 0$ e $\Delta_{F1} < 0$ (*trade-off*), indicando ganho em *fairness* com custo em desempenho; (iii) $\Delta_{\text{fair}} < 0$ e $\Delta_{F1} \geq 0$, indicando piora em *fairness* com manutenção ou ganho de desempenho; e (iv) $\Delta_{\text{fair}} < 0$ e $\Delta_{F1} < 0$ (*lose-lose*), indicando degradação em ambos os eixos. Complementarmente, utiliza-se a fronteira de Pareto para identificar os métodos não dominados nesse espaço bidimensional, isto é, métodos cuja melhora em um dos eixos só pode ser obtida à custa de piora no outro.

4.4.2 Elegibilidade

Não há consenso na literatura quanto a limiares universais que determinem quando uma métrica de *fairness* está “suficientemente próxima” do ideal, ou quando uma dada diferença representa, de forma consistente, menor impacto discriminatório. Por isso, neste trabalho adota-se um critério de elegibilidade fundamentado em uma escala de referência específica por métrica, que combina a variabilidade observada no *baseline* — para as métricas de distância aditiva — com uma convenção comumente adotada na literatura de *fairness* no caso do impacto díspar.

Para cada métrica, calcula-se $d(m)$ pela Eq. 4.1 e define-se uma escala de referência S_m , específica da métrica. Para as métricas de distância aditiva, adota-se o intervalo interquartil da distribuição de $d(m)$ entre os conjuntos de dados no *baseline*:

$$S_m = Q_{0,75}(d(m)) - Q_{0,25}(d(m)). \quad (4.5)$$

Para o Impacto Díspar, cuja distância é multiplicativa, adota-se um valor de referência fixo $S_{DI} = 0,25$, calibrado para que $u(DI) = 1$ corresponda à regra dos quatro quintos

(Feldman et al., 2015) — isto é, $DI = 0,80$ ou $DI = 1,25$. Essa escolha ancora o limiar de elegibilidade em uma convenção estabelecida na literatura de *fairness*, preservando a comparabilidade de $u(m)$ entre métricas. A distância ao ideal é então expressa em unidades normalizadas:

$$u(m) = \frac{d(m)}{S_m}. \quad (4.6)$$

A quantidade $u(m)$ é adimensional e indica quantas vezes a distância ao ideal supera a escala de referência S_m : $u(m) = 1$ corresponde a uma distância equivalente a S_m , e $u(m) = 0,5$ a metade dessa escala. Considera-se uma métrica *elegível* para caracterizar viés quando $u(m) \geq 0,5$, critério que evita interpretar como viés relevante variações muito pequenas, potencialmente pouco informativas.

Algumas análises são realizadas em termos globais e outras considerando a elegibilidade e categorias de métricas, sendo elas: (A) paridade estatística; (B) *fairness* individual ; e (C) métricas derivadas da matriz de confusão.

Na análise estratificada por sentido da RQ4, cada par (conjunto de dados, categoria) recebe um rótulo direcional e uma elegibilidade consolidados a partir das métricas elegíveis da categoria. O sentido é herdado da métrica direcional de maior afastamento normalizado ao ideal, isto é, de maior $u(m)$, entre elas; a elegibilidade é positiva quando ao menos uma métrica direcional da categoria é elegível no conjunto, propagando-se às demais métricas daquela categoria. Essa consolidação evita uma análise excessivamente subdividida e complexa, uma vez que sinais opostos ou variações de elegibilidade entre métricas de uma mesma categoria gerariam estratos pequenos e de leitura difícil, ao custo de uma métrica eventualmente ser reportada com sinal distinto do observado em sua direção própria, ou contar como elegível com distância ao ideal abaixo do limiar.

4.4.3 Análise estatística

Na análise estatística descritiva, adotaram-se como medidas-síntese a mediana e o intervalo interquartil (IQR). Para as métricas de desempenho preditivo, reportaram-se adicionalmente os valores mínimo e máximo.

Para a análise estatística inferencial, os *baselines* foram consolidados em um único valor de referência. Para cada conjunto de dados, esse controle foi obtido calculando-se a mediana dos resultados das quatro configurações de *baseline* (BLRA, BLRU, BRFA e BRFU) ao longo de todos os 30 *splits* (*fold* × repetição), resultando em um único valor por

par (conjunto de dados, métrica). Para os demais métodos, os resultados também foram agregados por conjunto de dados ao longo dos *folds* e repetições via mediana, de modo a obter uma estimativa única por método e conjunto de dados.

Como a comparação envolve múltiplos métodos avaliados nos mesmos conjuntos de dados, foi aplicado o teste não paramétrico de Friedman (Friedman, 1937), tratando cada conjunto de dados como um bloco pareado (Demšar, 2006). A partir das estimativas agregadas, os métodos foram ordenados em *rankings* dentro de cada conjunto de dados. O teste avalia a hipótese nula de que não há diferença entre os métodos, ou seja, que seus *rankings* médios são equivalentes.

Para identificar diferenças em relação ao *baseline* e controlar a *family-wise error rate* (FWER), foram realizadas comparações pós-hoc em relação a esse controle, com ajuste para múltiplas comparações por meio do procedimento de Holm (Holm, 1979). Para cada método j , testou-se a hipótese nula de que não há diferença entre o método e o *baseline*. Tanto o teste de Friedman quanto as comparações pós-hoc baseiam-se em *ranks* atribuídos por conjunto de dados, definidos a partir da divergência de cada resultado em relação ao valor ideal de cada métrica (Tabela 4.1). O procedimento de Holm foi aplicado para ajustar os valores de p dessas comparações.

4.5 Conjunto de dados analisados

Esta seção apresenta os conjuntos de dados analisados, incluindo sua caracterização qualitativa e etapas de pré-processamento, bem como uma análise quantitativa de volumetria, distribuição dos rótulos e desbalanceamentos entre grupos sensíveis.

4.5.1 Caracterização qualitativa e pré processamento aplicado

Heart Disease: O conjunto de dados *Heart Disease* (Janosi Andras; Detrano, 1989), amplamente utilizado em estudos de *fairness* e disponibilizado pelo repositório UCI, tem como objetivo identificar a presença de doença cardíaca. Embora os rótulos originais indiquem diferentes níveis de severidade (variando de 1 a 4), o problema foi reformulado como uma tarefa de classificação binária, na qual se considera a presença de qualquer nível. A mitigação de viés foi conduzida com base no atributo sensível considerado, sexo, representado pela variável "sex". Além desse atributo, o conjunto contém 14

variáveis categóricas e numéricas que descrevem condições clínicas dos pacientes, como pressão arterial em repouso, tipo de dor no peito e colesterol sérico. Instâncias com valores faltantes em quaisquer atributos foram removidas, procedimento que teve impacto desprezível na volumetria total dos dados.

Diabetes: O conjunto de dados *Diabetes* (Islam et al., 2019) contém informações clínicas e demográficas de pacientes de Bangladesh, com o objetivo de detectar a presença de diabetes em estágios iniciais. Duas dessas variáveis correspondem a atributos sensíveis, gênero e idade. Na análise de justiça algorítmica, o atributo sensível considerado foi o gênero, representado pela variável "*gender*". As demais variáveis representam sintomas comumente associados ao diabetes, como fraqueza, perda de peso e visão turva. No pré-processamento, foi realizada a binarização das variáveis categóricas, de modo a viabilizar o processamento pelos modelos de aprendizado de máquina.

Aids: O conjunto de dados *Aids* (Hammer et al., 1996) é disponibilizado pelo repositório UCI cujo objetivo é a classificação do desfecho clínico de pacientes infectados pelo vírus HIV. O conjunto contempla variáveis demográficas, comportamentais, clínicas, biomarcadores laboratoriais e histórico de tratamento. Entre os atributos disponíveis estão: uso prévio de drogas, escore de Karnofsky (medida de funcionalidade clínica) e contagem de células CD4 no *baseline*, entre outros. Durante o pré-processamento, a variável "*time*" — que representa o tempo até o desfecho clínico — foi removida, devido à sua alta correlação com o rótulo de saída (óbito). A exclusão visa reduzir o risco de vazamento de informação, uma vez que indivíduos que faleceram tendem a apresentar valores significativamente menores para essa variável. No contexto da análise de justiça algorítmica, o atributo sensível considerado foi a orientação sexual, representada pela variável "*homo*". Embora também estivessem disponíveis variáveis como gênero e raça, a escolha desse atributo se deve à sua baixa frequência em conjuntos públicos (Simson; Fabrmehrabi2019is; Kern, 2024; Liu et al., 2025), o que permite ampliar a diversidade nas análises de *fairness* e explorar dimensões menos comuns de viés algorítmico.

Mental: O conjunto de dados *Mental* ((OSMI), 2014) reúne respostas de pesquisas anuais sobre saúde mental entre profissionais de tecnologia. Neste estudo, foi utilizada a edição de 2014. A variável de "*treatment*" foi adotada como variável resposta. As variáveis "*timestamp*", "*state*" e "*comments*" não foram utilizadas (as duas últimas pelo baixo nível de preenchimento, inferior a 40%). No pré-processamento, a variável "*work interfere*", relacionada à percepção de interferência de questões de saúde mental no trabalho,

teve seus valores faltantes preenchidos com o valor “*Missing*”, de modo a preservar informação potencialmente relevante. Em seguida, essa variável foi transformada por *one-hot encoding*. A variável de país, de alta cardinalidade, foi agrupada por continente e também convertida em variáveis binárias. No contexto da análise de justiça algorítmica, o atributo sensível considerado foi o gênero. Seus valores foram padronizados e binarizados, definindo-se o grupo positivo como homens cis, enquanto o grupo negativo agregou mulheres cis, pessoas trans, indivíduos não binários e respostas indefinidas. Por fim, outras variáveis categóricas também foram convertidas via *one-hot encoding*, incluindo “*no employees*”, “*coworkers*”, “*supervisor*” e “*leave*”.

Arrhythmia: O conjunto de dados Arrhythmia (Guvenir H.; Quinlan, 1997) é disponibilizado pelo repositório UCI cuja tarefa consiste em identificar a presença de arritmia cardíaca. Para este estudo, os diferentes tipos de arritmia foram agregados em uma única formulação de classificação binária, distinguindo indivíduos com e sem arritmia. O conjunto contempla atributos demográficos, clínicos e eletrocardiográficos, mantidos na numeração original. No contexto da análise de justiça algorítmica, o atributo sensível considerado foi o gênero. Durante o pré-processamento, a variável 13, correspondente ao ângulo vetorial do complexo QRS no plano horizontal, foi removida devido ao baixo nível de preenchimento, inferior a 17%. Por sua vez, as variáveis 10, 11, 12 e 14, também associadas a medidas eletrocardiográficas e com preenchimento superior a 95%, tiveram seus valores faltantes imputados pela mediana.

Obesity: O conjunto de dados Obesity (Palechor; Manotas, 2019), disponibilizado pelo repositório UCI, tem por tarefa classificar níveis de obesidade de indivíduos, a partir de atributos comportamentais e físicos. Aproximadamente 23% dos dados foram coletados via plataforma online; o restante foi gerado sinteticamente com Weka (Witten; Frank; Hall, 2011) e SMOTE (Chawla et al., 2002). Originalmente com sete níveis (de peso insuficiente a obesidade tipo III), a variável resposta foi redefinida para identificar apenas os dois mais severos (obesidade tipo II e III) — formulação com impacto díspar de 1,12, em contraste com 1,00 quando incluídos os três níveis de obesidade, configurando tarefa mais adequada à investigação de viés. Adotou-se gênero (*gender*) como atributo sensível. Alguns dos atributos presentes incluem peso, histórico familiar e hábitos de consumo de vegetais, entre outros. As variáveis ordinais “*calc*”(consumo de bebida alcoólica) e “*caec*”(consumo alimentar entre refeições) tiveram seus níveis (*no*, *sometimes*, *frequently*, *always*) mapeados para escala discreta de 0 a 3 conforme frequência crescente. A

variável "*mtrans*"(meio de transporte), por não apresentar relação ordinal, foi convertida por *one-hot encoding*.

O *encoding* dos atributos sensíveis em todos os conjuntos citados seguiu um padrão uniforme. Para os atributos gênero e sexo, indivíduos do sexo masculino foram representados como classe positiva. No caso de raça, a classe positiva correspondeu a pessoas não brancas. Já em relação à orientação sexual, indivíduos homossexuais foram codificados como pertencentes à classe positiva.

4.5.2 Caracterização quantitativa

Na caracterização dos conjuntos de dados utilizados, observa-se que *Heart Disease*, *Arrhythmia* e *Diabetes* apresentam menos de 1.000 instâncias, o que os torna potencialmente mais suscetíveis a desbalanceamentos entre grupos sensíveis e a variações nas distribuições das variáveis. Em contraste, os conjuntos *Mental*, *Obesity* e *Aids* possuem maior volumetria, com número de instâncias superior a 1.000. A Tabela 4.3 apresenta a distribuição do número de instâncias por conjunto de dados.

Tabela 4.3 – Descrição dos conjuntos de dados, com definição do atributo protegido, rótulo favorável e composição amostral.

Conjunto de dados	Rótulo favorável	Taxa fav. (%)	<i>N</i>	Atributo protegido	Privilegiado	Desprivilegiado
Heart Disease (Janosi Andras; Detrano, 1989)	Sem doença cardíaca	54	297	Sex	Masculino	Feminino
Aids (Hammer et al., 1996)	Sem óbito	76	2139	Homo	Heterossexual	Homossexual
Obesity (Palechor; Manotas, 2019)	Sem obesidade severa	71	2111	Gender	Masculino	Feminino
Arrhythmia (Guvénir H.; Quinlan, 1997)	Sem arritmia	54	452	Sex	Masculino	Feminino
Mental ((OSMI), 2014)	Sem tratamento	49	1241	Gender	Masculino	Feminino
Diabetes (Islam et al., 2019)	Sem diabetes	38	520	Gender	Masculino	Feminino

Os conjuntos de dados tem como rótulo a presença de uma condição ou doença, sendo, portanto, esperado certo grau de desbalanceamento entre as classes. Alguns conjuntos foram mais afetados por esse problema, apresentando proporção de instâncias positivas inferior a 0,4: Aids (0,24). Os demais conjuntos apresentam distribuições mais

equilibradas, com proporções situadas aproximadamente entre 0,4 e 0,6: Diabetes (0,61), Arrhythmia (0,45), Heart (0,46), Mental (0,49) e Obesity (0,46).

Ao segmentar a proporção do rótulo alvo em cada conjunto de dados, identifica-se uma camada adicional de desbalanceamento associada ao grupo sensível. A Figura 4.2 apresenta a proporção de instâncias com rótulo positivo, destacando com contorno preto as barras correspondentes aos grupos interpretados como desprivilegiados (mulheres, pessoas pretas e homossexuais). Observa-se que alguns conjuntos, como Aids, embora apresentem desbalanceamento global do rótulo (0,24), exibem proporções semelhantes entre os grupos sensíveis (0,26 para o grupo desprivilegiado e 0,21 para o privilegiado). Em contrapartida, conjuntos como *Heart* apresentam comportamento inverso: apesar de uma distribuição global mais equilibrada, manifestam forte assimetria entre grupos, com 0,26 de casos positivos no grupo desprivilegiado, em contraste com 0,55 no privilegiado. De modo geral, além do conjunto *Heart*, os conjuntos Mental (0,69 no grupo desprivilegiado e 0,45 no privilegiado) e Diabetes (0,44 no grupo desprivilegiado e 0,90 no privilegiado) também evidenciam desequilíbrios entre grupos sensíveis na variável resposta. O conjunto *Obesity* apresenta o cenário mais equilibrado, com proporções próximas entre grupos (0,45 no desprivilegiado e 0,46 no privilegiado).





Figura 4.2 – Distribuição do rótulo alvo por grupo sensível

Fonte: A autora

Uma abordagem comumente adotada consiste na omissão de atributos sensíveis. Entretanto, ainda é possível identificar a presença de variáveis proxy. De forma geral, persistem correlações residuais entre as variáveis preditoras e os grupos sensíveis, uma vez que as distribuições dessas variáveis tendem a diferir entre os grupos. Essa relação pode ser observada no conjunto Obesity na Figura 4.3, que apresenta a distribuição da variável *weight* (peso) segundo o atributo sensível (*gender*) e o rótulo alvo. Conforme a Figura 4.3a, observa-se que as distribuições de *weight* diferem entre os grupos de *gender*. Já a segmentação por rótulo alvo 4.3b indica que a distribuição de *weight* também varia

entre as classes, com maior concentração de instâncias positivas em valores mais elevados dessa variável.



(a) Distribuição de *weight* por *gender* (b) Distribuição de *weight* por variável resposta

Figura 4.3 – Conjunto Obesity: Distribuição de *weight* por grupo sensível e por variável resposta.

Fonte: A autora

5 RESULTADOS

Este capítulo apresenta os resultados obtidos a partir da metodologia descrita no Capítulo 4, organizados de forma a responder às perguntas de pesquisa formuladas. Inicialmente, realiza-se uma análise diagnóstica dos modelos *baseline*, contemplando as disparidades observadas em cada conjunto de dados. Em seguida, os resultados são apresentados de acordo com cada pergunta de pesquisa:

- A **RQ1** – *Quais métodos e tipos de intervenção apresentam maior efeito global de mitigação em fairness, em comparação ao baseline?* será discutida na Seção 5.2.
- A **RQ2** – *Os resultados de mitigação observados na análise global se mantêm quando restrita aos conjuntos com disparidade relevante e estratificada por categoria de métrica?* será abordada na Seção 5.3.
- A **RQ3** – *Como a intensidade do viés no baseline influencia o efeito de mitigação obtido pelos métodos?* será avaliada na Seção 5.4.
- A **RQ4** – *Como o sentido do viés afeta o ganho de fairness obtido pelos métodos?* será discutida na Seção 5.5.
- A **RQ5** – *Qual é o trade-off entre desempenho preditivo e ganho em fairness obtido pelos métodos de mitigação?* será analisada na Seção 5.6.

5.1 Avaliação dos *baselines*: diagnóstico de desempenho e *fairness*

Esta seção apresenta os resultados do *baseline*, composto pelos quatro modelos de referência: BLRA e BLRU (regressão logística *aware* e *unaware*, respectivamente) e BRFA e BRFU (floresta aleatória *aware* e *unaware*, respectivamente). A partir desses resultados, caracteriza-se o perfil das disparidades observadas em cada conjunto de dados, identificando quais métricas apresentam desvio relevante e, quando aplicável, o sentido do viés. Essa caracterização fundamenta as análises estratificadas apresentadas nas perguntas de pesquisa.

5.1.1 Desempenho preditivo dos modelos

A mediana global de F1-Score, considerando todos os conjuntos de dados e modelos *baselines*, é 0,76 (Tabela 5.1), com dispersão interquartil de 0,20 e valores entre 0,39 e 0,99. Acurácia e precisão apresentam medianas próximas (aproximadamente 0,80), enquanto a revocação é inferior (0,74). Em termos de conjuntos de dados individuais (Tabela 5.2), cinco dos seis conjuntos analisados apresentam F1-Score maior ou igual a 0,70. O conjunto Aids apresenta o menor desempenho em termos de F1-Score (0,39). Resultados complementares por conjunto de dados e algoritmo utilizado no *baseline* são expostos no Apêndice C.

Tabela 5.1 – Estatísticas de desempenho preditivo do *baseline*.

Métrica	Mediana	IQR	Mínimo	Máximo
Acurácia	0,8061	0,1472	0,7017	0,9943
F1-Score	0,7660	0,2084	0,3910	0,9904
Precisão	0,8042	0,2103	0,6258	0,9904
Revocação	0,7403	0,2073	0,2816	0,9952

Tabela 5.2 – Estatísticas de desempenho preditivo do *baseline* por conjunto de dados.

Métrica	Conjunto	Mediana	IQR	Mínimo	Máximo
Acurácia	Arrhythmia	0,7667	0,0941	0,6133	0,8675
	Mental	0,7017	0,0266	0,6513	0,7488
	Diabetes	0,9481	0,0753	0,8391	1,0000
	Heart Disease	0,8283	0,0606	0,7273	0,8889
	Aids	0,7840	0,0130	0,7644	0,8050
	Obesity	0,9943	0,0043	0,9886	1,0000
F1-Score	Arrhythmia	0,7273	0,0992	0,5797	0,8462
	Mental	0,7048	0,0267	0,6494	0,7586
	Diabetes	0,9569	0,0629	0,8660	1,0000
	Heart Disease	0,8046	0,0624	0,6824	0,8817
	Aids	0,3910	0,0485	0,3077	0,4633
	Obesity	0,9904	0,0072	0,9803	1,0000
Precisão	Arrhythmia	0,7669	0,1168	0,5797	0,9298
	Mental	0,7056	0,0322	0,6512	0,7760
	Diabetes	0,9612	0,0498	0,8796	1,0000
	Heart Disease	0,8415	0,0871	0,7250	0,9355
	Aids	0,6258	0,0641	0,5326	0,7321
	Obesity	0,9904	0,0190	0,9673	1,0000
Revocação	Arrhythmia	0,7029	0,1014	0,5217	0,8551
	Mental	0,7017	0,0301	0,5981	0,7895
	Diabetes	0,9531	0,0756	0,7850	1,0000


Continua na próxima página

Tabela 5.2 – continuação

Métrica	Conjunto	Mediana	IQR	Mínimo	Máximo
	Heart Disease	0,7778	0,0914	0,5957	0,9333
	Aids	0,2816	0,0430	0,2069	0,3448
	Obesity	0,9952	0,0097	0,9614	1,0000

5.1.2 Análise de *fairness* dos modelos

Em termos de *fairness*, a Figura 5.1 apresenta a distância ao ideal no *baseline* (d_{baseline}), conforme definida na Equação 4.1, por métrica. Cada ponto representa um conjunto de dados, com o valor do *baseline* obtido pela mediana sobre *folds*, repetições e os quatro modelos de referência (conforme a Seção 4.4.1). As medidas-resumo (mediana e IQR) indicam a variabilidade entre conjuntos.


Figura 5.1 – Distância do *baseline* para o valor ideal por métrica de *fairness*.

Fonte: A autora

Observa-se maior distância ao ideal em impacto díspar, com ampla margem sobre as demais métricas. Em um patamar intermediário, consistência e índice de entropia generalizada apresentam distâncias semelhantes entre si. A amplificação de viés situa-se em patamar inferior, com distâncias próximas às das métricas baseadas em diferenças na matriz de confusão, que apresentam as menores distâncias em termos absolutos. Conforme definido na Seção 4.1 de métricas de avaliação, as métricas são organizadas em três categorias: A (paridade estatística), que avalia disparidades entre grupos; B (*fairness* individual), que mede consistência no nível individual; e C (matriz de confusão), que compara taxas condicionais de classificação entre grupos.

A Figura 5.2 decompõe o *baseline* em seus quatro componentes (BLRU, BLRA, BRFU, BRFA) para verificar se as distâncias ao ideal variam conforme o algoritmo ou o uso do atributo sensível. Em impacto díspar, nota-se maior variabilidade entre componentes e valores sistematicamente maiores para as variantes *aware* em comparação às *unaware* – isto é, modelos que incluem o atributo sensível exibem maiores distâncias ao ideal nessa métrica. Para as demais métricas, não se observa um padrão consistente de separação entre componentes *aware* e *unaware*, e a decomposição preserva a ordenação observada na análise agregada.

Figura 5.2 – Distância ao ideal no *baseline* (d_{baseline}) por métrica, decomposta pelos componentes do *baseline* (LR/RF; *aware/unaware*).



Fonte: A autora

A Tabela 5.3 apresenta, para cada métrica de *fairness*, a distância ao ideal $d(m)$ (conforme a Equação 4.1) observada no *baseline* de cada conjunto de dados, juntamente com o limiar mínimo de elegibilidade $d_{\min} = 0,5 \cdot S_m$ (conforme a Equação 4.6). Um conjunto de dados é considerado elegível quando $d(m) \geq d_{\min}$, e a elegibilidade é determinada no nível da categoria: basta que ao menos uma métrica da categoria ultrapasse o limiar para que o conjunto seja incluído na análise de todas as métricas daquela categoria. Essa definição permite avaliar o efeito de mitigação de forma comparável dentro de cada grupo de métricas.

Tabela 5.3 – Distância ao ideal $d(m)$ no *baseline* por métrica e conjunto de dados. Categorias: A (paridade estatística), B (fairness individual) e C (matriz de confusão). Valores acima do limiar são acompanhados do sentido do viés: U = contra o grupo não privilegiado; P = contra o grupo privilegiado; (✓) = elegível sem sentido direcional (categoria B). Valores abaixo do limiar não recebem marcação — indica distância nula.

Cat.	Métrica	Ideal	$d_{\min}$	Arrhythmia	Mental	Diabetes	Heart Disease	Aids	Obesity
A	Impacto Díspar	1,0	0,17	0,79 ^U	0,54 ^P	1,00 ^P	1,09 ^U	0,76 ^P	0,13
	Amplificação de viés	≤ 0	0,04	0,09✓	0,06✓	0,01	—	0,34✓	0,01
B	Consistência	1,0	0,07	0,26✓	0,27✓	0,09✓	0,14✓	0,12✓	0,05
	Índice de Entropia Generalizada	0,0	0,05	0,10✓	0,15✓	0,01	0,09✓	0,13✓	—
C	Diferença de Taxa de Falsos Negativos	0,0	0,06	0,13 ^U	0,16 ^P	—	0,03	0,11 ^P	0,01
	Diferença de Taxa de Falsa Descoberta	0,0	0,03	0,04 ^U	0,15 ^P	0,01	0,05 ^U	0,08 ^P	—
	Diferença de Taxa de Erro	0,0	0,02	0,02 ^P	0,05 ^P	0,01	0,07 ^P	0,02 ^U	0,01

O sentido do viés é determinado com base na designação *a priori* dos grupos privilegiado e não privilegiado, conforme definido na Seção 4.4.1 de agregação dos resultados. Na categoria A (paridade estatística), todos os cinco conjuntos elegíveis apresentam disparidade em impacto díspar, com sentido variando entre conjuntos: Diabetes, Aids e Mental exibem viés contra o grupo privilegiado (P), enquanto Heart Disease e Arrhythmia exibem viés contra o grupo não privilegiado (U). Para amplificação de viés, apenas Mental, Diabetes e Aids ultrapassam individualmente o limiar.

Na categoria B (*fairness* individual), que não possui sentido direcional, cinco conjuntos são elegíveis — Arrhythmia, Mental, Diabetes, Heart Disease e Aids — e todos apresentam desvio em consistência, enquanto em índice de entropia generalizada o conjunto Diabetes não atinge o limiar individualmente. Na categoria C (matriz de confusão), quatro conjuntos são elegíveis — Arrhythmia, Mental, Heart Disease e Aids — com sentido que pode variar entre as métricas da categoria para um mesmo conjunto: por exemplo, Heart Disease apresenta sentido U em Diferença de Taxa de Falsa Descoberta e P em Diferença de Taxa de Erro.

Nenhum conjunto concentra disparidade em uma única categoria; todos apresentam desvio elegível em pelo menos duas das três categorias de métricas analisadas. O conjunto Obesity, cujo *baseline* atinge desempenho próximo ao teto (F1-Score = 0,99; Acurácia = 0,99), não ultrapassa o limiar de elegibilidade em nenhuma métrica de *fairness*, sendo excluído das análises de sensibilidade à elegibilidade por categoria de métrica (RQ2) e ao sentido do viés (RQ4), e mantido nas análises globais (RQ1, RQ3 e RQ5).

A Tabela 5.4 resume, para cada categoria, a proporção de conjuntos de dados elegíveis em relação ao total avaliado, consolidando o número efetivo de observações

disponíveis para as análises estratificadas das perguntas de pesquisa seguintes.

Tabela 5.4 – Cobertura por categoria de métricas de *fairness*. As categorias são A (paridade estatística), B (fairness individual) e C (matriz de confusão). *Elegíveis* indica quantos conjuntos de dados ultrapassam o limiar de disparidade ($d(m) \geq d_{\min}$) para cada métrica; *Eleg. cat.* é o número de conjuntos de dados elegíveis em pelo menos uma métrica da categoria (união); *Cobertura* é a fração correspondente do total de conjuntos de dados.

Categoria	Métrica	Elegíveis	Eleg. cat.	Cobertura (%)
A	Impacto Díspar	5	5	83,3
	Amplificação de viés	3		
B	Consistência	5	5	83,3
	Índice de Entropia Generalizada	4		
C	Diferença de Taxa de Falsos Negativos	3	4	66,7
	Diferença de Taxa de Falsa Descoberta	4		
	Diferença de Taxa de Erro	4		

5.1.3 Discussão

Os resultados dos *baseline* indicam que a maioria dos conjuntos de dados possuem F1-score estável para a análise de mitigação de viés. Entretanto, observamos que o desempenho preditivo adequado não implica ausência de disparidades, reforçando a necessidade de avaliação explícita de *fairness*.

A decomposição do *baseline* — agregado pela mediana sobre os quatro modelos de referência (BLRA, BLRU, BRFA e BRFU), conforme a Seção 4.4.1 — mostra uma assimetria concentrada no impacto díspar: as variantes *aware* apresentam distâncias ao ideal sistematicamente maiores do que as *unaware*. A concentração desse efeito em uma métrica da categoria A (paridade estatística) sugere que a inclusão explícita do atributo sensível se traduz mais visivelmente em disparidades de taxa de seleção entre grupos do que em consistência individual ou em diferenças de taxa de erro condicional. Como o *baseline* é agregado por mediana sobre esses componentes, a assimetria é absorvida na referência sem descaracterizar as análises subsequentes; o comportamento homogêneo dos componentes nas demais métricas reforça essa adequação.

O sentido do viés no *baseline* (Tabela 5.3) varia entre conjuntos: Diabetes, Aids e Mental exibem viés contra o grupo privilegiado (P), enquanto Heart Disease e Arrhythmia exibem viés contra o não privilegiado (U). Essa assimetria motiva a análise estratificada por sentido na RQ4, evitando que agregações entre conjuntos com direções opostas pos-

sam ocultar comportamentos distintos.

Em termos de cobertura (Tabela 5.4), as categorias A e B apresentam o maior número de conjuntos elegíveis ($N = 5$); a categoria C, com $N = 4$, acompanha as menores distâncias absolutas observadas em suas métricas. Esse comportamento é compatível com a natureza operacional das três categorias. Impacto díspar é uma razão entre taxas de seleção, e sua distância ao ideal é multiplicativa ($\max(DI, 1/DI) - 1$), de modo que desvios proporcionais modestos entre grupos já produzem razões afastadas da paridade — a mesma sensibilidade que motiva o limiar operacional da regra dos quatro quintos (Feldman et al., 2015; Barocas; Hardt; Narayanan, 2023). Já as métricas da categoria C — diferença de taxa de falsos negativos, diferença de taxa de falsa descoberta e diferença de taxa de erro — são diferenças de proporções condicionais à matriz de confusão, limitadas ao intervalo $[-1, 1]$ e, em magnitude, ao nível das próprias taxas de erro, que são baixas quando o desempenho preditivo é razoável. Nos conjuntos avaliados, essas condições se sobrepõem e explicam as menores distâncias absolutas observadas na categoria C em relação à categoria A. No contexto da saúde, contemplado pelos conjuntos avaliados, ainda assim assimetrias nessas taxas têm implicações diretas: um grupo sistematicamente mais afetado por falsos negativos pode ter condições não detectadas, enquanto um grupo mais afetado por falsa descoberta pode ser submetido a intervenções desnecessárias — o que justifica investigar separadamente os efeitos de mitigação nessa categoria, mesmo quando as distâncias absolutas são modestas.

5.2 RQ1 — Quais métodos e tipos de intervenção apresentam maior efeito global de mitigação em *fairness*, em comparação ao *baseline*?

Esta seção investiga em que medida os métodos de mitigação reduzem as disparidades de *fairness* diagnosticadas na Seção 5.1, comparando os métodos e seus tipos de intervenção (*pre-processing* ou *in-processing*) de forma global sobre os seis conjuntos de dados. Os resultados são organizados por categoria de métricas em dois níveis: (i) comparação entre tipos de intervenção e (ii) comparação entre métodos individuais. Em cada nível, as distribuições de efeito de mitigação (Δ_{fair}) são reportadas por meio de medianas e intervalos interquartis calculados sobre os conjuntos de dados, e complementadas por evidência estatística quando aplicável. Quando o teste de Friedman não atinge significância ($p < 0,05$), os contrastes pós-hoc não são interpretados.

Principais achados. No agregado, os métodos *in-processing* concentram o maior


efeito global de mitigação nas métricas de paridade estatística, com suporte estatístico em impacto díspar e amplificação de viés, enquanto o *pre-processing* apresenta diferenciação mais modesta em relação ao *baseline*. Os maiores ganhos em impacto díspar concentram-se nos métodos de *reductions* (IGLA e IGLU). Nas métricas de *fairness* individual e de matriz de confusão não se observa suporte estatístico consistente para ganho no agregado, o que também motiva as análises estratificadas a partir da RQ2.

5.2.1 Métricas de paridade estatística (Categoria A)

Ao analisar o impacto díspar e a amplificação de viés por tipo de método, a Figura 5.3 evidencia que as maiores medianas de mitigação em *fairness* (Δ_{fair}) ocorrem em métodos *in-processing*. Em impacto díspar, *in-processing* apresenta $\tilde{\Delta}_{\text{fair}} = 0,272$, magnitude aproximadamente cinco vezes maior do que a de *pre-processing* ($\tilde{\Delta}_{\text{fair}} = 0,049$). Para amplificação de viés, *pre-processing* apresenta mediana de Δ_{fair} ligeiramente negativa ($-0,011$), indicando ausência de ganho agregado.

O teste de Friedman indica diferenças significativas entre tipos de método de mitigação para impacto díspar ($p = 0,006$) e amplificação de viés ($p = 0,022$), conforme Tabela 5.5. Os resultados pós-hoc com correção de Holm são reportados no Apêndice A.1: para impacto díspar, $p_{\text{Holm}} = 0,0015$ (*in-processing*) e $p_{\text{Holm}} = 0,1241$ (*pre-processing*); para amplificação de viés, $p_{\text{Holm}} = 0,0433$ (*in-processing*) e $p_{\text{Holm}} = 0,6136$ (*pre-processing*).

Figura 5.3 – Efeito de mitigação em *fairness* (Δ_{fair}) por tipo de intervenção nas métricas de paridade estatística.




Fonte: A autora

Na análise por método de mitigação restrita às métricas baseadas em paridade estatística (Figura 5.4), para impacto díspar observa-se maior heterogeneidade entre os mé-

todos. As maiores mitigações são observadas nos métodos de *reductions* IGLA ($\tilde{\Delta}_{\text{fair}} = 0,344$) e IGLU ($\tilde{\Delta}_{\text{fair}} = 0,307$), seguidos por IP ($\tilde{\Delta}_{\text{fair}} = 0,267$) e IW ($\tilde{\Delta}_{\text{fair}} = 0,191$). Entre os demais *in-processing*, IAD apresenta efeito modesto ($\tilde{\Delta}_{\text{fair}} = 0,054$) e IFG apresenta mediana próxima de zero ($\tilde{\Delta}_{\text{fair}} = -0,007$). No *pre-processing*, os dois métodos divergem: enquanto ERL atinge $\tilde{\Delta}_{\text{fair}} = 0,200$, comparável a IP e IW, EDL apresenta mediana negativa ($\tilde{\Delta}_{\text{fair}} = -0,020$).

Figura 5.4 – Efeito de mitigação em *fairness* (Δ_{fair}) por método nas métricas de paridade estatística.



Fonte: A autora

O teste de Friedman (Tabela 5.6) indica variação global significativa entre métodos para impacto díspar ($p = 0,002$). Nas comparações pós-hoc com correção de Holm, reportadas no Apêndice A.1, IGLA ($p_{\text{Holm}} = 0,010$), IGLU ($p_{\text{Holm}} = 0,010$) e IP ($p_{\text{Holm}} = 0,025$) apresentam contrastes significativos em relação ao *baseline*, enquanto IW apresenta p-valor limítrofe ($p_{\text{Holm}} = 0,051$).


Já para a amplificação de viés, os valores de Δ_{fair} são mais homogêneos entre os métodos, com EDL exibindo efeito negativo ($\tilde{\Delta}_{\text{fair}} = -0,048$). A estatística de Friedman é significativa ($p = 0,022$; Tabela 5.6), mas nenhum contraste pareado sobrevive à correção de Holm — ainda que IW ($p_{\text{Holm}} = 0,070$) e ERL ($p_{\text{Holm}} = 0,082$) fiquem mais próximos do limiar de $\alpha = 0,05$ (Apêndice A.1).

5.2.2 Métricas de fairness individual (Categoria B)

Para as métricas de *fairness* individual (Figura 5.5), a consistência apresenta medianas de Δ_{fair} próximas de zero para ambos os tipos de método, com *pre-processing* exibindo mediana ligeiramente negativa ($-0,010$) e *in-processing* próxima de zero ($-0,001$).

O teste de Friedman não indica diferenças entre tipos de intervenção ($p = 0,846$), conforme reportado na Tabela 5.5. No índice de entropia generalizada, ambos os tipos de método apresentam $\Delta_{\text{fair}} < 0$, indicando aumento da distância ao ideal. Ainda assim, o teste de Friedman não indica diferenças entre tipos de método ($p = 0,069$).

Figura 5.5 – Efeito de mitigação em *fairness* (Δ_{fair}) por categoria nas métricas de *fairness* individual.




Fonte: A autora

Na análise por método (Figura 5.6), a consistência apresenta variação expressiva entre os métodos, e o teste de Friedman indica diferenças estatisticamente significativas ($p = 0,029$; Tabela 5.6). No *pre-processing*, EDL apresenta mediana de Δ_{fair} positiva (0,007), enquanto ERL exibe o maior efeito negativo entre todos os métodos ($\tilde{\Delta}_{\text{fair}} = -0,062$). Entre os *in-processing*, IAD apresenta mediana positiva (0,006), IGLU ($-0,012$) e IFG ($-0,013$) apresentam medianas negativas e IW mantém mediana mais próxima de zero (0,002). A significância detectada no teste global, no entanto, não se sustenta no pós-hoc: nenhuma comparação pareada com o *baseline* atinge significância após correção de Holm, com p-valores ajustados $\geq 0,560$ (Apêndice A.1).

Para o índice de entropia generalizada, observa-se $\Delta_{\text{fair}} \leq 0$ na maioria dos métodos, com maior efeito negativo em IGLU ($\tilde{\Delta}_{\text{fair}} = -0,025$), seguido por IW ($-0,016$), IP ($-0,016$) e IGLA ($-0,014$). O teste de Friedman indica p-valor próximo ao limiar convencional, sem atingir significância ($p = 0,051$; Tabela 5.6), de modo que os contrastes pós-hoc não são interpretados.

Figura 5.6 – Efeito de mitigação em *fairness* (Δ_{fair}) por método nas métricas de *fairness* individual.



Fonte: A autora



5.2.3 Métricas de matriz de confusão (Categoria C)

A Figura 5.7 reporta os resultados para métricas baseadas em matriz de confusão. Para a diferença da taxa de falsos negativos, ambos os tipos de intervenção apresentam $\Delta_{\text{fair}} > 0$, porém o teste de Friedman não indica diferenças ($p = 0,513$). Nas duas métricas restantes, diferença da taxa de falsa descoberta e diferença da taxa de erro, observa-se mediana de $\Delta_{\text{fair}} < 0$, indicando piora (aumento da distância ao ideal). Para a diferença da taxa de falsa descoberta, o teste de Friedman indica diferenças significativas entre tipos de intervenção ($p = 0,006$); no entanto, as comparações pós-hoc com correção de Holm não evidenciam significância estatística em relação ao *baseline*, com $p_{\text{Holm}} = 1$ para *pre-processing* e para *in-processing* (Apêndice A.1).

Na análise por método (Figura 5.8), observa-se maior variabilidade entre os resultados. Para diferença da taxa de falsos negativos, a maioria dos métodos apresenta $\Delta_{\text{fair}} > 0$, com exceção de EDL e IAD ($\Delta_{\text{fair}} < 0$). O maior efeito de mitigação de viés é observado em IP ($\tilde{\Delta}_{\text{fair}} = 0,040$). Ainda assim, o teste de Friedman não indica variação global significativa entre métodos ($p = 0,307$; Tabela 5.6).



Para diferença da taxa de falsa descoberta, predomina $\Delta_{\text{fair}} \leq 0$ (Tabela 5.6), com os maiores efeitos negativos concentrados em IGLA ($\tilde{\Delta}_{\text{fair}} = -0,095$), IP ($-0,091$) e IGLU ($-0,084$). Nessa métrica, IP destaca-se pela maior dispersão entre métodos (IQR = 0,177), cerca do dobro da observada em IGLA (0,093) e quase o triplo da observada em IGLU (0,065). O teste global é significativo (Friedman $p = 0,013$), mas nenhum contraste pós-hoc sobrevive à correção de Holm, com p-ajustado igual a 1,00 para todos

Figura 5.7 – Efeito de mitigação em *fairness* (Δ_{fair}) por categoria nas métricas baseadas em matriz de confusão.



Fonte: A autora

Figura 5.8 – Efeito de mitigação em *fairness* (Δ_{fair}) por método nas métricas baseadas em matriz de confusão.



(c) Diferença da taxa de erro.

Fonte: A autora

os métodos (Apêndice A.1).

Por fim, para diferença da taxa de erro, os efeitos são de magnitude reduzida (nenhum método com mediana inferior a $-0,010$) e o teste global não atinge significância (Friedman $p = 0,487$; Tabela 5.6). Os métodos IFG ($\tilde{\Delta}_{\text{fair}} = 0,005$) e ERL ($\tilde{\Delta}_{\text{fair}} = 0,001$) são os únicos métodos com mediana positiva.

Tabela 5.5 – Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.

Métrica	Categoria	p -valor	Mediana Δ_{fair}	IQR(Δ_{fair})
Diferença de Taxa de Erro	Pre-Processing	0,607	-0,0061	0,0145
	In-Processing		-0,0071	0,0088
Amplificação de viés	Pre-Processing	0,022	-0,0110	0,0506
	In-Processing		0,0605	0,0622
Diferença de Taxa de Falsa Descoberta	Pre-Processing	0,006	-0,0308	0,0250
	In-Processing		-0,0643	0,0597

Continua na próxima página

Tabela 5.5 – continuação

Métrica	Categoria	<i>p</i> -valor	Mediana Δ_{fair}	IQR(Δ_{fair})
Consistência	Pre-Processing	0,846	-0,0195	0,0447
	In-Processing		-0,0016	0,0184
Índice de Entropia Generalizada	Pre-Processing	0,069	-0,0031	0,0102
	In-Processing		-0,0165	0,0182
Impacto Díspar	Pre-Processing	0,006	0,0490	0,1176
	In-Processing		0,2722	0,1405
Diferença de Taxa de Falsos Negativos	Pre-Processing	0,513	0,0110	0,0211
	In-Processing		0,0264	0,0650

Tabela 5.6 – Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.

Métrica	Método	Categoria	p -valor	Mediana Δ_{fair}	IQR(Δ_{fair})
Diferença de Taxa de Erro	EDL	Pre-Processing	0,487	-0,0093	0,0171
	ERL			0,0013	0,0116
	IAD	In-Processing		-0,0053	0,0198
	IGLA			-0,0098	0,0161
	IGLU			-0,0028	0,0214
	IFG			0,0053	0,0160
	IP			-0,0054	0,0292
	IW			-0,0037	0,0092
Amplificação de viés	EDL	Pre-Processing	0,022	-0,0484	0,1452
	ERL			0,0605	0,0622
	IAD	In-Processing		0,0416	0,0590
	IGLA			0,0416	0,0560
	IGLU			0,0416	0,0299
	IFG			0,0037	0,0411
	IP			0,0198	0,0559
	IW			0,0605	0,0622
Diferença de Taxa de Falsa Descoberta	EDL	Pre-Processing	0,013	-0,0087	0,0616
	ERL			-0,0539	0,0367
	IAD	In-Processing		-0,0312	0,0547
	IGLA			-0,0952	0,0938
	IGLU			-0,0845	0,0654
	IFG			0,0085	0,0459
	IP			-0,0911	0,1778
	IW			-0,0328	0,0733
Consistência	EDL	Pre-Processing	0,029	0,0073	0,0034
	ERL			-0,0626	0,0769
	IAD	In-Processing		0,0060	0,0026
	IGLA			-0,0019	0,0173
	IGLU			-0,0126	0,0275

Continua na próxima página

Tabela 5.6 – continuação

Métrica	Método	Categoria	p -valor	Mediana Δ_{fair}	IQR(Δ_{fair})
Índice de Entropia Generalizada	IFG		0,051	-0,0132	0,0204
	IP			-0,0032	0,0304
	IW			0,0025	0,0130
	EDL	Pre-Processing		-0,0020	0,0111
	ERL			-0,0045	0,0145
	IAD	In-Processing		-0,0017	0,0100
	IGLA			-0,0141	0,0206
	IGLU			-0,0251	0,0161
	IFG			0,0004	0,0088
	IP			-0,0162	0,0312
	IW			-0,0165	0,0303
Impacto Díspar	EDL	Pre-Processing	0,002	-0,0203	0,2365
	ERL			0,2009	0,2077
	IAD	In-Processing		0,0540	0,1619
	IGLA			0,3448	0,2219
	IGLU			0,3073	0,1703
	IFG			-0,0070	0,0267
	IP			0,2679	0,2647
	IW			0,1918	0,2705
Diferença de Taxa de Falsos Negativos	EDL	Pre-Processing	0,307	-0,0216	0,0537
	ERL			0,0268	0,0568
	IAD	In-Processing		-0,0060	0,0062
	IGLA			0,0010	0,0899
	IGLU			0,0094	0,1049
	IFG			0,0110	0,0136
	IP			0,0404	0,0564
	IW			0,0237	0,0456

5.2.4 Discussão

Os resultados globais revelam duas assimetrias relevantes: entre tipos de intervenção em métricas de paridade estatística e entre métodos individuais nas demais categorias. A ausência de suporte estatístico consistente nas categorias B e C no agregado motiva as análises estratificadas conduzidas a partir da RQ2.

A assimetria de mitigação entre os tipos de intervenção permite uma interpretação relacionada ao ponto de intervenção de cada abordagem. Um sistema que emprega apenas *pre-processing* permanece suscetível à introdução de viés durante o treinamento, uma vez que o classificador pode aprender correlações residuais entre covariáveis e o atributo sensível — funcionando como *proxies* da associação que a transformação dos dados

pretendia eliminar. Métodos *in-processing*, por outro lado, incorporam restrições ou penalizações diretamente na função objetivo, mantendo o vínculo entre critério de *fairness* e processo de otimização durante todo o treinamento. Essa diferença de mecanismo é compatível com o padrão observado: *in-processing* atinge suporte estatístico em paridade estatística, ao passo que *pre-processing* apresenta diferenciação mais modesta em relação ao *baseline*.

Ao detalhar os resultados por método dentro da categoria de paridade estatística, observa-se que os métodos de *reductions* (IGLA e IGLU) concentram os maiores ganhos em impacto díspar. Como IGLA e IGLU implementam o mesmo procedimento de *Grid Search Reduction* sob os mesmos hiperparâmetros, a diferença entre eles é compatível com o papel da disponibilidade do atributo sensível na otimização das restrições de *fairness*. Nesse cenário, a variante *aware* (IGLA) apresenta Δ_{fair} ligeiramente superior à *unaware* (IGLU), sugerindo que o acesso ao atributo sensível tende a favorecer a mitigação quando o objetivo é reduzir disparidades de paridade estatística.

A vantagem dos métodos de *reductions* é coerente com sua concepção algorítmica. Neste experimento, o *Grid Search Reduction* foi configurado com restrição de paridade demográfica, incidindo diretamente sobre a taxa de predição positiva por grupo, $P(\hat{Y} = 1 | A = a)$ — a mesma grandeza subjacente ao impacto díspar. Esse alinhamento entre restrição e métrica direciona o classificador a reduzir a disparidade entre grupos durante o treinamento. Os demais métodos *in-processing* visam paridade por mecanismos distintos: IP regulariza a informação mútua sobre escores contínuos, IW alinha distribuições de escores via distância de Wasserstein, e IAD delega a imposição a um adversário — método cuja instabilidade de otimização é documentada na literatura (Han et al., 2024). A hierarquia de efeitos observada neste estudo é compatível com essa gradação de mecanismos, embora a sensibilidade dos resultados à configuração experimental, documentada em estudos comparativos (Friedler et al., 2018), indique que essa ordenação não deve ser generalizada sem cautela.

Cabe notar, porém, que os mesmos métodos de *reductions* apresentam os maiores efeitos negativos em diferença da taxa de falsa descoberta e em índice de entropia generalizada (Seção 5.2), indicando que os ganhos em paridade estatística coexistem com piora em outras dimensões de *fairness*. Ainda assim, essa evidência deve ser interpretada no contexto desta avaliação ($N = 6$ conjuntos de dados e configuração experimental fixa), e não como garantia universal: a vantagem do regime *aware* pode depender da qualidade do atributo sensível, do grau de correlação com as covariáveis e da forma como as restrições

são operacionalizadas pelo método.

Para *fairness* individual, o panorama é distinto conforme a métrica. Em consistência, o que importa é *qual* método se emprega: não há diferença entre tipos ($p = 0,846$), mas há variação significativa entre métodos individuais (Friedman $p = 0,029$). A maioria dos métodos apresenta efeito mediano próximo de zero, em linha com o fato de que a consistência (Equação 2.21) é uma agregação local sobre vizinhanças no espaço de atributos e nenhum dos métodos avaliados tem alvo explícito sobre similaridade local entre predições. ERL destoa do conjunto com efeito mediano negativo consistente entre conjuntos ($\tilde{\Delta}_{\text{fair}} = -0,062$); como o cálculo da consistência no *aif360* não condiciona ao atributo protegido, uma hipótese compatível é que a reponderação das amostras por (A, Y) do *Reweighting* produza predições mais heterogêneas em vizinhanças mistas em A do que as regularizações globais empregadas pelos demais métodos. A verificação dessa hipótese exigiria análise local não conduzida neste trabalho. Para o índice de entropia generalizada, todos os métodos apresentam $\tilde{\Delta}_{\text{fair}} < 0$, sem que nenhum contraste pós-hoc se diferencie do *baseline*. Esses achados indicam que ganhos em paridade estatística não se traduzem automaticamente em ganhos em *fairness* individual.

A RQ2 retoma essas assimetrias sob o recorte de elegibilidade, verificando se os padrões observados no agregado persistem quando a análise é restrita aos conjuntos com disparidade relevante e estratificada por categoria de métrica.

5.3 RQ2 — Os resultados de mitigação observados na análise global se mantêm quando restrita aos conjuntos com disparidade relevante e estratificada por categoria de métrica?

Nesta seção, os resultados de mitigação de viés são analisados considerando apenas os conjuntos de dados cujo *baseline* ultrapassou o limiar de elegibilidade na categoria correspondente (conforme definido na metodologia e aplicado na Seção 5.1). Esse recorte concentra a comparação em cenários com espaço real para mitigação, reduzindo a influência de casos próximos ao ideal que tenderiam a diluir os efeitos na análise global. O número de conjuntos elegíveis varia entre categorias (Tabela 5.4): $N = 5$ para as categorias A e B, e $N = 4$ para a categoria C.

Os resultados são apresentados em dois níveis: (i) comparação entre tipos de intervenção (*pre-processing* e *in-processing*) dentro de cada categoria de métrica e (ii) comparação entre métodos de mitigação individuais. Para cada recorte, reportam-se medianas,


dispersão (IQR) e os testes estatísticos associados, permitindo avaliar se a eficácia observada na análise global (RQ1) se mantém no recorte elegível e se há diferenças sistemáticas entre as três categorias de métricas.

Principais achados. O recorte por elegibilidade preserva, em linhas gerais, o diagnóstico da análise global: o *in-processing* mantém a vantagem em paridade estatística, com suporte pós-hoc. O recorte torna visíveis, contudo, dois efeitos ausentes no agregado — contraste significativo em relação ao *baseline* para IW e ERL em amplificação de viés, e heterogeneidade entre métodos mais acentuada em consistência, com ERL concentrando a maior degradação.

5.3.1 Métricas de paridade estatística (Categoria A)

Na amostra elegível definida na Seção 5.1 ($N = 5$ conjuntos: Aids, Arrhythmia, Diabetes, Heart Disease e Mental) para a categoria A, observa-se maior efeito de mitigação em paridade estatística para métodos *in-processing* nas duas métricas (Figura 5.9). Em impacto díspar, a mediana de Δ_{fair} é 0,300 para *in-processing* e 0,074 para *pre-processing*. O teste de Friedman indica diferença entre tipos de intervenção ($p = 0,015$; Tabela 5.7). Na comparação pós-hoc versus o *baseline* com correção de Holm, *in-processing* apresenta contraste significativo em relação ao *baseline* ($p_{\text{Holm}} = 0,004$), enquanto *pre-processing* não atinge o limiar ($p_{\text{Holm}} = 0,171$; Apêndice A.2).

Figura 5.9 – Efeito de mitigação na categoria A por tipo de intervenção.



Fonte: A autora

Para amplificação de viés, *pre-processing* apresenta mediana $\Delta_{\text{fair}} < 0$, indicando piora descritiva nessa métrica, ao passo que *in-processing* apresenta mediana positiva (0,077; Tabela 5.7). O teste de Friedman também sugere diferença significativa entre tipos de intervenção ($p = 0,022$). No pós-hoc com correção de Holm, *in-processing* apresenta

contraste significativo em relação ao *baseline* ($p_{\text{Holm}} = 0,026$), mas *pre-processing* não atinge o limiar ($p_{\text{Holm}} = 0,624$; Apêndice A.2).


Tabela 5.7 – Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.

Métrica	Categoria	p -valor	Mediana Δ_{fair}	IQR(Δ_{fair})
Impacto Díspar	Pre-Processing	0,015	0,0741	0,1401
	In-Processing		0,3003	0,1111
Amplificação de viés	Pre-Processing	0,022	-0,0221	0,0601
	In-Processing		0,0775	0,0679

Na análise segmentada por método, os efeitos para a categoria A alinham-se aos achados anteriores. Para impacto díspar, observa-se maior heterogeneidade entre métodos, com $\Delta_{\text{fair}} > 0$ na maior parte dos casos (Figura 5.10). As exceções são EDL e IFG, que apresentam medianas próximas de zero ou negativas. As maiores medianas de Δ_{fair} concentram-se novamente nos métodos de *reductions* (IGLA e IGLU). O teste de Friedman indica diferença significativa entre métodos ($p = 0,009$; Tabela 5.8) e, na comparação pós-hoc versus o *baseline* com correção de Holm, IGLA e IGLU apresentam os menores p-valores ajustados ($p_{\text{Holm}} = 0,031$, empatados), seguidos por IP e IW ($p_{\text{Holm}} = 0,045$, empatados); os demais métodos não atingem o limiar adotado (Apêndice A.2).

Para amplificação de viés, os efeitos são mais homogêneos, com $\Delta_{\text{fair}} > 0$ para a maioria dos métodos, com exceção de EDL (Figura 5.10; Tabela 5.8). O teste de Friedman indica diferença entre métodos ($p = 0,022$). Na comparação pós-hoc versus o *baseline* com correção de Holm, IW ($p_{\text{Holm}} = 0,037$) e ERL ($p_{\text{Holm}} = 0,045$) apresentam contrastes significativos em relação ao *baseline*; os demais métodos não atingem o limiar adotado (Apêndice A.2).

Figura 5.10 – Efeito de mitigação na categoria A por método de mitigação.



Fonte: A autora

Tabela 5.8 – Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.

Métrica	Método	Categoria	p -valor	Mediana Δ_{fair}	IQR(Δ_{fair})
Impacto Díspar	EDL	Pre-Processing	0,009	-0,0769	0,2775
	ERL			0,2851	0,1901
	IAD	In-Processing		0,0733	0,1622
	IGLA			0,3526	0,0348
	IGLU			0,3353	0,1040
	IFG			-0,0072	0,0355
	IP			0,2912	0,2856
	IW			0,2326	0,2575
Amplificação de viés	EDL	Pre-Processing	0,022	-0,0969	0,1613
	ERL			0,0775	0,0679
	IAD	In-Processing		0,0434	0,0378
	IGLA			0,0434	0,0378
	IGLU			0,0434	0,0378
	IFG			0,0074	0,0523
	IP			0,0397	0,0613
	IW			0,0775	0,0679


5.3.2 Métricas de *fairness* individual (Categoria B)

Para a categoria B, a análise considera os $N = 5$ conjuntos elegíveis nesta categoria, com exclusão de Obesity — portanto, Aids, Arrhythmia, Diabetes, Heart Disease e Mental. Para consistência (Figura 5.11; Tabela 5.9), ambos os tipos de intervenção apresentam medianas de Δ_{fair} negativas ou próximas de zero (*pre-processing*: $-0,037$; *in-processing*: $-0,004$), indicando ausência de ganho agregado. O teste de Friedman não sugere diferença significativa entre tipos de intervenção ($p = 0,449$), de modo que os

contrastes pós-hoc não são interpretados.

Para o índice de entropia generalizada (Figura 5.11; Tabela 5.9), observa-se degradação descritiva em ambos os tipos de intervenção, com medianas $\Delta_{\text{fair}} < 0$ (*pre-processing*: $-0,0035$; *in-processing*: $-0,0184$). O teste de Friedman apresenta $p = 0,074$, não indicando evidência para diferença entre tipos de intervenção.

Figura 5.11 – Efeito de mitigação na categoria B por tipo de intervenção.



Fonte: A autora

Tabela 5.9 – Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.


Métrica	Categoria	p -valor	Mediana Δ_{fair}	IQR(Δ_{fair})
Consistência	Pre-Processing	0,449	-0,0379	0,0411
	In-Processing		-0,0046	0,0194
Índice de Entropia Generalizada	Pre-Processing	0,074	-0,0035	0,0133
	In-Processing		-0,0184	0,0098

Examinando agora a categoria B segmentada por método, para consistência (Figura 5.12; Tabela 5.10), observa-se heterogeneidade expressiva entre os métodos, com o teste de Friedman indicando diferença estatisticamente significativa ($p = 0,008$). Descritivamente, apenas EDL (*pre-processing*) e IAD (*in-processing*) apresentam $\tilde{\Delta}_{\text{fair}} > 0$ (0,008 e 0,005, respectivamente). Entre os demais métodos, ERL concentra a degradação mais acentuada ($\tilde{\Delta}_{\text{fair}} = -0,084$); nos métodos *in-processing* restantes, a degradação é modesta: IGLU ($-0,023$), IFG ($-0,014$), IP ($-0,009$), IGLA ($-0,006$) e IW ($-0,0006$). Apesar da significância global, nenhum contraste individual atinge significância pós-hoc com correção de Holm (p -valores ajustados $\geq 0,816$; Apêndice A.2).

Para o índice de entropia generalizada (Figura 5.12; Tabela 5.10), predomina $\Delta_{\text{fair}} < 0$ na maioria dos métodos, com exceção de EDL (mediana 0,0003). A maior degradação mediana é observada em IP ($\tilde{\Delta}_{\text{fair}} = -0,0303$), seguido de IGLU ($\tilde{\Delta}_{\text{fair}} =$

$-0,0253$). O teste de Friedman não indica variação global entre métodos ($p = 0,055$), embora o p-valor esteja próximo do limiar adotado.

Figura 5.12 – Efeito de mitigação na categoria B por método de mitigação.



Fonte: A autora

Tabela 5.10 – Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.

Métrica	Método	Categoria	p -valor	Mediana Δ_{fair}	IQR(Δ_{fair})
Consistência	EDL	Pre-Processing	0,008	0,0081	0,0026
	ERL			-0,0848	0,0540
	IAD	In-Processing		0,0050	0,0019
	IGLA			-0,0061	0,0195
	IGLU			-0,0232	0,0248
	IFG			-0,0142	0,0233
	IP			-0,0093	0,0342
	IW			-0,0006	0,0147
Índice de Entropia Generalizada	EDL	Pre-Processing	0,055	0,0003	0,0133
	ERL			-0,0053	0,0158
	IAD	In-Processing		-0,0027	0,0126
	IGLA			-0,0193	0,0194
	IGLU			-0,0253	0,0004
	IFG			-0,0007	0,0110
	IP			-0,0303	0,0322
	IW			-0,0218	0,0255

5.3.3 Métricas de matriz de confusão (Categoria C)



Para a categoria C, além do conjunto Obesity, o conjunto Diabetes não apresentou desvio detectável no *baseline* para as métricas desta categoria, resultando em $N = 4$ conjuntos elegíveis (Arrhythmia, Mental, Heart Disease e Aids). Na diferença da taxa de falsos negativos, observa-se maior efeito descritivo para *in-processing*, com mediana $\Delta_{\text{fair}} = 0,050$ (Figura 5.13; Tabela 5.11). Contudo, o teste de Friedman não sugere diferença estatisticamente significativa entre os tipos de intervenção ($p = 0,174$), de modo

que não se procede com a análise pós-hoc.

Em diferença da taxa de falsa descoberta, as medianas são negativas para ambos os tipos, indicando degradação descritiva; o efeito é mais acentuado em *in-processing* (mediana $\Delta_{\text{fair}} = -0,069$) do que em *pre-processing* (mediana $-0,029$; Tabela 5.11). O teste de Friedman indica diferença significativa entre tipos de intervenção ($p = 0,039$); contudo, no pós-hoc com correção de Holm, nenhum dos tipos se distingue do *baseline* ($p_{\text{Holm}} = 1,000$ em ambos). A diferença apontada pelo *omnibus* reflete, portanto, o contraste entre *pre-processing* ($-0,029$) e *in-processing* ($-0,069$), que não integra o plano pós-hoc (restrito a comparações com o *baseline*).

Por fim, em diferença da taxa de erro, os efeitos são próximos de zero em ambos os tipos, com medianas de $\Delta_{\text{fair}} = -0,002$ para *in-processing* e $0,001$ para *pre-processing*. O teste de Friedman não sugere diferença entre tipos de intervenção ($p = 1,000$; Tabela 5.11).

Figura 5.13 – Efeito de mitigação na categoria C por tipo de intervenção.



Fonte: A autora

Tabela 5.11 – Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.

Métrica	Categoria	<i>p</i> -valor	Mediana Δ_{fair}	IQR(Δ_{fair})
Diferença de Taxa de Falsos Negativos	Pre-Processing	0,174	0,0166	0,0128
	In-Processing		0,0501	0,0257
Diferença de Taxa de Falsa Descoberta	Pre-Processing	0,039	-0,0290	0,0355
	In-Processing		-0,0699	0,0839
Diferença de Taxa de Erro	Pre-Processing	1,000	0,0015	0,0153
	In-Processing		-0,0024	0,0154

Examinando agora a categoria C segmentada por método (Figura 5.14), em diferença da taxa de falsos negativos observa-se $\Delta_{\text{fair}} > 0$ para a maioria dos métodos, com destaque para IP (mediana $\tilde{\Delta}_{\text{fair}} = 0,064$; Tabela 5.12). Ainda assim, o teste de Friedman não indica evidência de diferença global entre métodos ($p = 0,644$), de modo que os resultados pós-hoc não são interpretados.

Para diferença da taxa de falsa descoberta, predomina $\Delta_{\text{fair}} < 0$ na maioria dos métodos, com as maiores degradações medianas concentradas em IGLA ($-0,084$), IGLU ($-0,078$), IP ($-0,076$) e IW ($-0,074$; Tabela 5.12). ERL apresenta degradação intermediária ($-0,053$), enquanto IAD ($-0,018$) e IFG ($-0,013$) apresentam degradação modesta; EDL é o único método com mediana não-negativa (0,001). O teste de Friedman não indica evidência de diferença global entre os métodos ($p = 0,191$). Nesta métrica, IP apresenta a maior variabilidade entre os métodos (IQR = 0,150).

Por fim, em diferença da taxa de erro, os efeitos são pequenos, com medianas próximas de zero (aproximadamente no intervalo $[-0,01, 0,01]$), e o teste de Friedman não indica evidência de diferença global entre métodos ($p = 0,618$; Tabela 5.12).

Tabela 5.12 – Resultados consolidados do teste de Friedman. Δ_{fair} = efeito de mitigação.

Métrica	Método	Categoria	p -valor	Mediana Δ_{fair}	IQR(Δ_{fair})
Diferença de Taxa de Falsos Negativos	EDL	Pre-Processing	0,644	-0,0110	0,0716
	ERL			0,0575	0,0431
	IAD	In-Processing		-0,0076	0,0685
	IGLA			0,0321	0,0899
	IGLU			0,0412	0,0867
	IFG			0,0156	0,0086
	IP			0,0641	0,0415
	IW			0,0480	0,0385
Diferença de Taxa de Falsa Descoberta	EDL	Pre-Processing	0,191	0,0015	0,0650
	ERL			-0,0539	0,0154
	IAD	In-Processing		-0,0185	0,0717

Continua na próxima página

Tabela 5.12 – continuação

Métrica	Método	Categoria	p -valor	Mediana Δ_{fair}	IQR(Δ_{fair})
Diferença de Taxa de Erro	IGLA		0,618	-0,0846	0,1475
	IGLU			-0,0787	0,0894
	IFG			-0,0131	0,0722
	IP			-0,0762	0,1506
	IW			-0,0746	0,0830
	EDL	Pre-Processing		-0,0098	0,0224
	ERL			0,0064	0,0174
	IAD	In-Processing	0,618	-0,0014	0,0198
	IGLA			-0,0021	0,0147
	IGLU			0,0057	0,0144
	IFG			-0,0028	0,0202
	IP			0,0018	0,0162
	IW			-0,0014	0,0272



5.3.4 Discussão

Embora o recorte por elegibilidade preserve, em linhas gerais, o diagnóstico da análise global (RQ1), ele torna visíveis dois efeitos que não emergiam no agregado. O primeiro refere-se à amplificação de viés por método: enquanto na RQ1 nenhum método individual atingia significância pós-hoc, a análise restrita aos conjuntos elegíveis revela contraste significativo em relação ao *baseline* para IW ($p_{\text{Holm}} = 0,037$) e ERL ($p_{\text{Holm}} = 0,045$). IW e ERL apresentam as maiores medianas positivas de $\tilde{\Delta}_{\text{fair}}$ em amplificação de viés tanto na análise global (0,060 para ambos, acima de qualquer outro método) quanto no recorte elegível (0,077 para ambos); o recorte elegível não cria o contraste, mas o torna suficientemente consistente entre conjuntos para atravessar a correção de Holm.

O segundo efeito refere-se à consistência: o teste de Friedman por método torna-se mais forte no recorte elegível ($p = 0,008$ versus $p = 0,029$ em RQ1), com a degradação mediana de ERL se acentuando ($\tilde{\Delta}_{\text{fair}} = -0,084$ versus $-0,062$ em RQ1). A heterogeneidade entre métodos e suas possíveis raízes mecânicas são discutidas a seguir.

O comportamento da consistência por método apresenta-se com uma ordenação marcada. Entre os métodos com maiores ganhos em impacto díspar (IGLA, IGLU, IP e IW), apenas IW mantém Δ_{fair} próximo de zero em consistência ($-0,0006$); IGLA ($-0,006$), IP ($-0,009$) e IGLU ($-0,023$) apresentam efeitos negativos sobre o viés em magnitude crescente, e ERL registra o pior valor ($-0,084$). Essa degradação é coerente com a incompatibilidade formal entre *fairness* de grupo e individual (Xu; Strohmer,

Figura 5.14 – Efeito de mitigação na categoria C por método de mitigação.



Fonte: A autora

2024), mas não se alinha a nenhuma categorização disponível *a priori*: ERL e EDL são ambos *pre-processing* e ocupam extremos opostos em consistência ($-0,084$ e $+0,008$, respectivamente), descartando o tipo de intervenção como eixo explicativo isolado; ERL e IW são ambos *aware* e também ocupam extremos da degradação, descartando o grau de *awareness*. Como a amostra restringe a análise a conjuntos com disparidade detectável, essa ordenação caracteriza a eficácia condicional dos métodos — isto é, sob condições em que há margem real para mitigação. Uma caracterização mecanística precisa dessa degradação fica além do alcance desta análise.

A assimetria entre *in-processing* e *pre-processing* em paridade estatística, mesmo restrita a conjuntos com disparidade detectável, reforça a leitura da RQ1: *in-processing* mantém vínculo direto entre critério de *fairness* e função objetivo durante o treinamento, enquanto *pre-processing* permanece suscetível a *proxies* residuais aprendidos pelo classificador. Na matriz de confusão, a coexistência de ganhos descritivos em diferença da taxa de falsos negativos com degradações em diferença da taxa de falsa descoberta é compatível com a incompatibilidade formal entre critérios de *fairness*: como os métodos avaliados buscam predominantemente paridade demográfica (independência), a redistribuição de erros entre dimensões associadas a critérios distintos (separação e suficiência) é esperada quando as taxas de prevalência diferem entre grupos (Chouldechova, 2016; Kleinberg; Mullainathan; Raghavan, 2017). Vale observar, ainda, que o teste de Friedman em diferença da taxa de falsa descoberta aponta diferença significativa entre tipos de intervenção ($p = 0,039$) sem que qualquer um deles se distinga do *baseline* no pós-hoc ($p_{\text{Holm}} = 1,000$ para ambos): a variação captada pelo teste global provém do contraste entre *pre-processing* e *in-processing*, e não de uma melhora relativa ao controle. A RQ3 (Seção 5.4) avança nessa direção, examinando como a intensidade do viés no *baseline* modula o efeito de mitigação em nível de conjunto de dados e métrica individual.

5.4 RQ3 — Como a intensidade do viés no *baseline* influencia o efeito de mitigação obtido pelos métodos?

A presente seção investiga o impacto da intensidade do viés presente no conjunto de dados sobre a mitigação alcançada pelos métodos, complementando os resultados anteriormente observados nas Seções 5.2 e 5.3. Assim, enquanto as análises precedentes avaliaram o efeito de mitigação de forma agregada — global (RQ1) ou considerando conjuntos de dados elegíveis por categoria de métrica (RQ2) — esta seção examina a relação

entre a magnitude do viés no *baseline* (d_{baseline}) e o efeito de mitigação (Δ_{fair}) em nível de conjunto de dados e métrica individual. O objetivo é verificar se os métodos são mais eficazes quando o viés no *baseline* é mais intenso, ou se, ao contrário, cenários de maior viés impõem desafios adicionais que limitam ou reverterem os ganhos de *fairness*.

Principais achados. A relação entre a intensidade do viés no *baseline* e o efeito de mitigação não é única; distinguem-se três perfis. Em impacto díspar e na diferença da taxa de falsos negativos, a mitigação escala positivamente com d_{baseline} . Na consistência, o efeito é determinado pelo método, e não pela intensidade do viés. No índice de entropia generalizada e na diferença da taxa de falsa descoberta predomina uma tendência de degradação de *fairness*, acentuada nos conjuntos de maior viés no caso da diferença da taxa de falsa descoberta.


Para cada métrica, os resultados são apresentados em gráficos de dispersão nos quais o eixo horizontal corresponde a d_{baseline} (distância ao ideal no *baseline*, conforme definido no Capítulo 4 – Metodologia) e o eixo vertical a Δ_{fair} . Cada ponto representa um conjunto de dados, e os painéis são segmentados por método. Para complementar a leitura absoluta, a discussão desta seção recorre também ao efeito relativo $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$, permitindo comparar a eficácia de mitigação entre métricas com escalas distintas de d_{baseline} . Os valores numéricos de d_{baseline} , Δ_{fair} e r_{fair} podem ser consultados nas tabelas do Apêndice D.1.

Para o impacto díspar (Figura 5.15), a maioria dos métodos apresenta maior mitigação absoluta nos conjuntos que exibiram maior viés no *baseline*. Três métodos fogem a esse padrão. EDL apresenta degradação de *fairness* em três conjuntos — Mental ($\Delta_{\text{fair}} = -0,304$), Diabetes ($\Delta_{\text{fair}} = -0,122$) e Heart Disease ($\Delta_{\text{fair}} = -0,076$) — além de mitigação de viés reduzida nos demais. IFG exhibe Δ_{fair} próximo de zero na maior parte dos conjuntos, com exceção de Aids ($\Delta_{\text{fair}} = 0,610$), único caso de mitigação expressiva. IAD apresenta comportamento misto: degradação acentuada de *fairness* em Mental ($\Delta_{\text{fair}} = -0,635$), mas mitigação nos conjuntos de maior d_{baseline} , como Aids ($\Delta_{\text{fair}} = 0,680$) e Diabetes ($\Delta_{\text{fair}} = 0,196$).

Para os demais métodos — ERL, IGLA, IGLU, IP e IW — observa-se uma tendência positiva entre d_{baseline} e Δ_{fair} . Nos conjuntos de dados de faixa intermediária (Arrhythmia, Mental e Heart Disease, com d_{baseline} entre 0,403 e 0,545), IGLA e IGLU apresentam Δ_{fair} entre 0,279 e 0,383. Nos conjuntos de maior viés — Aids ($d_{\text{baseline}} = 1,010$) e Diabetes ($d_{\text{baseline}} = 0,988$) — a mitigação tende a ser mais elevada, embora com variação entre métodos: IW, por exemplo, atinge o maior Δ_{fair} em Aids (0,802), enquanto IP se destaca

em Diabetes (0,612).


Figura 5.15 – Intensidade e direção do viés no *baseline* em relação ao impacto díspar.



Fonte: A autora

Para a amplificação de viés (Figura 5.16), entre os conjuntos elegíveis nessa métrica (Aids, Mental e Arrhythmia), apenas Aids apresenta d_{baseline} acima de 0,200 ($d_{\text{baseline}} = 0,458$). Nesse grupo de menor viés, ERL e IW mitigam integralmente a distância ao ideal em Mental e Arrhythmia ($\Delta_{\text{fair}} = d_{\text{baseline}}$, isto é, $r_{\text{fair}} = 1,000$). Entretanto, IGLA e IGLU, apesar de seguirem o mesmo padrão nos conjuntos de menor viés, mostram mitigação de viés muito reduzida em Aids ($\Delta_{\text{fair}} = 0,004$ e $0,038$, respectivamente), o que enfraquece a hipótese de escalabilidade para esses métodos nessa métrica. No conjunto de maior viés, os métodos com maior mitigação foram IW ($\Delta_{\text{fair}} = 0,446$; $r_{\text{fair}} = 0,974$) e ERL ($\Delta_{\text{fair}} = 0,370$; $r_{\text{fair}} = 0,809$), este último com queda sensível em relação a Mental e Arrhythmia, onde atingiu $r_{\text{fair}} = 1,000$.

Figura 5.16 – Intensidade e direção do viés no *baseline* em relação à amplificação de viés.




Fonte: A autora

O método IAD apresenta $\Delta_{\text{fair}} = -0,509$ em Mental (Tabela D.1), e IP atinge $\Delta_{\text{fair}} \approx -1,000$ em Diabetes — a maior degradação de *fairness* observada em todo o experimento para esta métrica (Figura 5.16). Esses resultados sugerem que, para a amplificação de viés, a relação entre intensidade do viés e mitigação é positiva apenas para um subconjunto de métodos, sendo acompanhada de degradações em outros.

Para a consistência (Figura 5.17), os efeitos de mitigação de viés variam consideravelmente entre os métodos, com Δ_{fair} abrangendo desde $-0,156$ (ERL em Aids) até $+0,061$ (EDL em Arrhythmia), apesar de os valores de d_{baseline} variarem entre $0,089$ e $0,274$ (Tabela D.3). ERL apresenta degradação de *fairness* em todos os conjuntos de dados, com efeitos particularmente acentuados em Aids ($\Delta_{\text{fair}} = -0,156$; $r_{\text{fair}} = -1,568$) e Mental ($\Delta_{\text{fair}} = -0,094$; $r_{\text{fair}} = -0,368$), sugerindo que a transformação de atributos amplifica a inconsistência entre previsões de indivíduos próximos. EDL, em contraste, apresenta Δ_{fair} positivo em todos os conjuntos, com o maior efeito em Arrhythmia ($0,061$; $r_{\text{fair}} = 0,223$). IFG e IGLU também tendem a valores negativos na maioria dos conjuntos, enquanto IAD e IW apresentam efeitos mistos e de baixa magnitude. Não se identifica uma relação monotônica consistente entre d_{baseline} e Δ_{fair} : cada método mantém sinal estável entre conjuntos (ERL sempre degrada, EDL sempre melhora) e a variação entre conjuntos para um mesmo método é pequena frente à distância entre métodos — o padrão é determinado predominantemente pelo método, e não pelo conjunto de dados.

No índice de entropia generalizada (Figura 5.18), os métodos não apresentam maior mitigação nos conjuntos de maior viés no *baseline*; pelo contrário, observa-se degradação de *fairness* ($\Delta_{\text{fair}} < 0$) na maioria dos métodos. IGLU apresenta os maiores


Figura 5.17 – Intensidade e direção do viés no *baseline* em relação a consistência.



Fonte: A autora

valores negativos, com $\Delta_{\text{fair}} = -0,07$ em Diabetes. IP e IW também degradam nos conjuntos de maior d_{baseline} , com Δ_{fair} entre $-0,036$ e $-0,040$ (Tabela D.4). EDL e ERL também apresentam pontos negativos, indicando que a degradação nessa métrica não está restrita a métodos específicos.

Figura 5.18 – Intensidade e direção do viés no *baseline* em relação ao índice de entropia generalizada.




Fonte: A autora

Para as métricas baseadas na matriz de confusão, o viés no *baseline* é, em geral, mais reduzido do que nas categorias anteriores, o que limita o espaço disponível para mitigação em termos absolutos e, conseqüentemente, para a análise comparativa entre conjuntos. Considerando a diferença da taxa de falsos negativos (Figura 5.19), os três conjuntos com maior d_{baseline} são Mental (0,160), Aids (0,142) e Arrhythmia (0,139). Neles, ERL,

IGLA, IGLU, IP e IW apresentam mitigação do viés em pelo menos dois dos três conjuntos, com Δ_{fair} variando entre 0,035 e 0,114 (Tabela D.5); entre esses cinco métodos, a mediana de r_{fair} por método situa-se entre 0,425 e 0,511 (mediana global $\approx 0,489$), ou seja, em torno de metade do viés removido. Para os demais métodos, os resultados são mais instáveis: EDL, por exemplo, mitiga o viés em Arrhythmia ($\Delta_{\text{fair}} = 0,090$), mas degrada *fairness* em Mental ($\Delta_{\text{fair}} = -0,077$); IAD degrada expressivamente em Mental ($\Delta_{\text{fair}} = -0,192$).

Figura 5.19 – Intensidade e direção do viés no *baseline* em relação a diferença da taxa de falsos negativos.




Fonte: A autora

Para a diferença da taxa de falsa descoberta (Figura 5.20), observa-se uma tendência de degradação de *fairness* na maioria dos métodos. Nos conjuntos com maior d_{baseline} — Arrhythmia (0,141), Mental (0,130) e Heart Disease (0,106) — a degradação é substancial em vários métodos: IGLA atinge $\Delta_{\text{fair}} = -0,282$ em Heart Disease e $-0,138$ em Arrhythmia; IGLU, $-0,214$ em Heart Disease; IP, $-0,219$ em Heart Disease e $-0,138$ em Arrhythmia; e IW, $-0,2061$ em Heart Disease (Tabela D.6). Aids, com d_{baseline} inferior (0,068), apresenta degradação de *fairness* mais moderada na maioria dos métodos, com exceção de IFG ($\Delta_{\text{fair}} = -0,127$). De modo geral, os resultados sugerem que, para esta métrica, a mitigação não acompanha a intensidade do viés no *baseline* — pelo contrário, conjuntos de maior viés tendem a sofrer maior degradação.

Para a diferença da taxa de erro (Figura 5.21), d_{baseline} varia entre 0,023 (Aids) e 0,080 (Heart Disease), e os efeitos são ainda mais discretos, com a maioria dos valores de Δ_{fair} situados entre $-0,05$ e $+0,05$. Heart Disease, com o maior d_{baseline} , é o conjunto que mais consistentemente apresenta mitigação do viés: ERL ($\Delta_{\text{fair}} = 0,042$), IP (0,025)


Figura 5.20 – Intensidade e direção do viés no *baseline* em relação a diferença da taxa de falsa descoberta.



Fonte: A autora

e IW (0,025) atingem os maiores efeitos positivos (Tabela D.7). Nos demais conjuntos, os resultados são instáveis e próximos de zero. Dois casos de degradação de *fairness* se destacam: IAD em Mental ($\Delta_{\text{fair}} = -0,029$) e, sobretudo, IP em Diabetes ($\Delta_{\text{fair}} = -0,13$), que representa o maior efeito negativo observado nesta métrica.

Figura 5.21 – Intensidade e direção do viés no *baseline* em relação a diferença da taxa de erro.



Fonte: A autora

5.4.1 Discussão

A análise descritiva da RQ3 distingue três perfis de resposta à intensidade do viés no *baseline*. No primeiro, a mitigação escala positivamente com d_{baseline} , como se observa no impacto díspar — métrica que concentra os maiores níveis de d_{baseline} — e, em menor amplitude, na diferença da taxa de falsos negativos. No segundo, a intensidade do viés deixa de governar o efeito: na consistência, ERL e EDL respondem em direções opostas em todos os conjuntos, de modo que o padrão observado se explica pelo método adotado, e não pela intensidade do viés no *baseline*. No terceiro, a mitigação é substituída por uma tendência comum à degradação de *fairness*: no índice de entropia generalizada e na diferença da taxa de falsa descoberta, a maioria dos métodos afasta-se do ideal — com magnitudes crescentes nos conjuntos de maior d_{baseline} na diferença da taxa de falsa descoberta, e distribuída ao longo de toda a faixa de d_{baseline} no índice de entropia generalizada.

Dentro do primeiro perfil, dois comportamentos específicos da amplificação de viés merecem destaque. Primeiro, a escala positiva com d_{baseline} restringe-se a ERL e IW; IP (em Diabetes) e IAD (em Mental) apresentam degradação de *fairness*, de modo que a relação entre d_{baseline} e Δ_{fair} depende do método. Segundo, o contraste que distingue ERL e IW entre si emerge apenas no conjunto de maior viés: em Mental e Arrhythmia, $r_{\text{fair}} = 1,000$ é atingido pela maior parte dos métodos (quatro de oito em Mental, sete de oito em Arrhythmia), refletindo sobretudo o *baseline* reduzido nessas duas bases; em Aids ($d_{\text{baseline}} = 0,458$), porém, IW preserva eficácia quase integral ($r_{\text{fair}} \approx 0,974$) enquanto ERL apresenta queda sensível ($r_{\text{fair}} \approx 0,809$), diferença que revela estabilidade desigual entre os dois métodos em cenários de viés substantivo. No segundo perfil, a consistência reforça esse achado em outro eixo: ERL degrada *fairness* em todos os conjuntos e EDL melhora em todos. Assim, o efeito segue determinado pelo método, independentemente de d_{baseline} .

Nas métricas de categoria C, o perfil dominante combina escala positiva na diferença da taxa de falsos negativos com degradação crescente na diferença da taxa de falsa descoberta. Embora d_{baseline} seja reduzido em ambas (até 0,160 para diferença da taxa de falsos negativos), os métodos que mitigam essa métrica removem em torno de metade do viés (r_{fair} mediano por método entre 0,425 e 0,511, mediana global $\approx 0,489$; Tabela D.5), patamar comparável ao observado no impacto díspar. A coexistência entre mitigação de viés na diferença da taxa de falsos negativos e degradação de *fairness* em falsa descoberta, já identificada em RQ1 e RQ2, ganha aqui uma dimensão adicional: intensifica-se

nos conjuntos de maior viés, sugerindo que a redistribuição de erros entre tipos de disparidade é mais pronunciada quando o viés no *baseline* é mais intenso. A diferença da taxa de erro apresenta efeitos discretos e sem padrão claro em relação à intensidade do viés.

Cabe notar que a análise desta seção é de natureza descritiva e que a identificação de tendências depende da amplitude dos valores de d_{baseline} em cada métrica. Enquanto o impacto díspar apresenta d_{baseline} entre 0,105 e 1,010, oferecendo margem ampla para observar variações no efeito de mitigação, as métricas de categoria C concentram-se em faixas estreitas — entre 0,008 e 0,080 para a diferença da taxa de erro, por exemplo —, o que limita a distinção entre efeito real e variabilidade experimental. Nesses casos, a leitura complementar por r_{fair} torna-se necessária: por normalizar Δ_{fair} pela magnitude de d_{baseline} , permite contrastar a fração do viés removida entre métricas com faixas de intensidade muito distintas.

5.5 RQ4 — Como o sentido do viés afeta o ganho de *fairness* obtido pelos métodos?

Esta seção investiga se o sentido do viés no *baseline* — contra o grupo não-privilegiado (U) ou contra o grupo privilegiado (P) — influencia o resultado de mitigação de viés dos métodos avaliados. A análise é restrita às métricas das categorias A (paridade) e C (baseados em matriz de confusão), que, por mensurarem disparidades entre grupos, admitem a identificação de um sentido de viés.

Principais achados. O sentido do viés não é o fator determinante do sucesso da mitigação: em todas as métricas há conjuntos de mesmo sentido com respostas opostas a um mesmo método, indicando que as características de cada conjunto de dados pesam mais do que a direção do viés. O sentido influencia, em alguns métodos, a magnitude do efeito — não se ele será de mitigação ou de degradação de viés. A diferença da taxa de falsa descoberta permanece resistente à mitigação independentemente do sentido.

A análise de cada métrica é discutida orientada a contraste entre os sentidos (U e P), com uma leitura qualitativa, que busca padrões claros de favorecimento. O critério principal é a diferença entre o maior valor de r_{fair} em um sentido e o menor no outro — quanto um lado supera o outro em seus extremos —, aplicado aos métodos que mitigam vieses em conjuntos de ambos os sentidos para identificar a direção da assimetria sem ranquear métodos; optou-se por ele em detrimento de uma diferença de medianas dado o pequeno número de conjuntos por sentido em cada métrica (entre um e três). Complementarmente, a concentração de degradação de *fairness* em um dos sentidos é usada para

caracterizar assimetrias de comportamento. Declara-se uma tendência direcional apenas quando a assimetria é nítida; nos demais casos, o perfil é caracterizado como baixo ou instável.

Conforme detalhado na Seção 4.4.1, nesta análise cada par (conjunto de dados, categoria) recebe um sentido único e uma elegibilidade consolidados, herdados das métricas elegíveis da categoria. Por isso, a Tabela 5.13 pode atribuir a uma métrica um sentido ou uma elegibilidade distintos dos observados em sua direção própria na Tabela 5.3, que preserva a granularidade por métrica usada no diagnóstico.

A Tabela 5.13 apresenta a distribuição dos conjuntos de dados por sentido de viés em cada métrica, considerando apenas os conjuntos elegíveis conforme o critério de elegibilidade definido na Seção 4. Com $n_U = 1$ (Arrhythmia) para métricas baseadas em matriz de confusão, o critério pontual de assimetria reduz-se à comparação desse único valor com os extremos em P, o que limita a leitura direcional.


Tabela 5.13 – Distribuição de conjuntos de dados por direção do viés (U/P) e categoria de padrão

Categoria	Métrica	Total	U (não-priv.)	P (priv.)	Sem direção	Inelegível
A	Amplificação de viés	6	2	3	0	1
A	Impacto Díspar	6	2	3	0	1
A	— Total A —	6	2	3	0	1
C	Diferença de Taxa de Erro	6	1	3	0	2
C	Diferença de Taxa de Falsa Descoberta	6	1	3	0	2
C	Diferença de Taxa de Falsos Negativos	6	1	3	0	2
C	— Total C —	6	1	3	0	2

Na avaliação do impacto díspar, a Figura 5.22 apresenta o efeito relativo de mitigação (r_{fair}), segmentado pela direção do viés no *baseline*. Dos seis conjuntos de dados, cinco foram elegíveis: dois com viés contra o grupo não-privilegiado (U — Arrhythmia e Heart Disease) e três com viés contra o grupo privilegiado (P — Aids, Mental e Diabetes); Obesity permaneceu inelegível (Tabela 5.13). Os métodos IGLA, IGLU, IP, IW e ERL mitigam o viés em todos os cinco conjuntos. Os métodos de *reductions* inclinam-se para U: no IGLA, o máximo em U ($r_{\text{fair}} = 0,835$) supera o mínimo em P (Aids, 0,064) em 0,771, enquanto o sentido inverso é praticamente nulo. Já o ERL inclina-se para P: o máximo (0,646) excede o mínimo em U em 0,486, enquanto o máximo em U e o mínimo em P quase coincidem (0,289 e 0,288). No IW, Aids e Mental (P) superam os dois conjuntos em U, mas Diabetes ($r_{\text{fair}} = 0,075$) destoa e fica abaixo de toda a faixa em U, produzindo leituras pontuais contraditórias; caracteriza-se, portanto, como tendência baixa para P sem assimetria nítida. O IP é o único método aproximadamente simétrico,

com faixas de r_{fair} quase sobrepostas (0,544–0,606 em U; 0,353–0,619 em P). Os demais métodos (IAD, EDL, IFG) apresentam degradação de *fairness* em ao menos um conjunto, sem vínculo consistente com a direção do viés.


Figura 5.22 – Direção do viés no *baseline* e resultado de mitigação no impacto díspar.



Fonte: A autora

Na métrica amplificação de viés (Figura 5.23), a distribuição de elegibilidade é a mesma do impacto díspar: dois conjuntos com viés U (Arrhythmia e Heart Disease) e três com viés P (Aids, Mental e Diabetes), conforme Tabela 5.13. Os métodos IGLA, IGLU, IW e ERL mitigam os vieses nos cinco conjuntos, e a aplicação do critério pontual de assimetria revela perfis distintos. Em conjuntos com viés U, todos atingem $r_{\text{fair}} = 1,000$ nos dois conjuntos, assim, a assimetria é determinada inteiramente pelo valor em Aids dentro do grupo P. Os métodos de *reductions* inclinam-se para U: a diferença entre o máximo em U e o mínimo em P atinge 0,992 no IGLA, por exemplo; no sentido inverso a diferença é nula, já que o máximo em P também é 1,000 (Mental e Diabetes). O ERL apresenta apenas tendência baixa para U (diferença pontual 0,191), com Aids ainda acima de 0,800. O IW é aproximadamente simétrico, com r_{fair} próximo de 1,000 em todos os conjuntos. Entre os métodos que degradam *fairness* em ao menos um conjunto, IP e IAD também exibem inclinação para U, com os dois conjuntos em U saturados em $r_{\text{fair}} = 1,000$: o método IP degrada *fairness* em Mental e Diabetes em P, com Diabetes ($r_{\text{fair}} = -12,904$) como o caso extremo da métrica, e o IAD degrada severamente apenas Mental ($r_{\text{fair}} = -4,573$). EDL e IFG apresentam padrões mistos, sem vínculo consistente com a direção do viés.


Figura 5.23 – Direção do viés no *baseline* e resultado de mitigação na amplificação de viés.



Fonte: A autora

Na diferença de taxa de falsos negativos (Figura 5.24), apenas quatro conjuntos foram elegíveis: um com viés U (Arrhythmia) e três com viés P (Mental, Aids e Heart Disease), conforme a Tabela 5.13. Apenas ERL e IW mitigam o viés nos quatro conjuntos elegíveis, apresentando perfil análogo. As diferenças pontuais nos dois sentidos são próximas (0,375 contra 0,278 no ERL; 0,266 contra 0,195 no IW), configurando apenas tendência baixa para P. Entre os métodos que degradam *fairness* em ao menos um conjunto, o EDL é o único caso claro de tendência para U: Arrhythmia ($r_{fair} = 0,652$) supera todos os três conjuntos em P ($\leq 0,087$). Já os métodos IGLA e IGLU apresentam perfil instável com valores máximos semelhantes (IGLA: 0,502 e 0,544; IGLU: 0,511 e 0,620), mas com Heart Disease degradando *fairness* severamente em P ($-0,457$ no IGLA; $-0,678$ no IGLU). Semelhantemente, IAD, IFG e IP não exibem direção clara: o IP tem efeito em Mental e Aids ligeiramente acima do observado para Arrhythmia, mas Heart Disease com valor em $-0,457$, por exemplo.

Figura 5.24 – Direção do viés no *baseline* e resultado de mitigação na diferença da taxa de falso negativo.



Fonte: A autora

Na diferença de taxa de falsa descoberta (Figura 5.25), quatro conjuntos foram elegíveis: Arrhythmia com viés U e Mental, Aids e Heart Disease com viés P (Tabela 5.13). Diferentemente das métricas anteriores, o cenário predominante é de degradação de *fairness*: nenhum método mitiga o viés nos quatro conjuntos elegíveis e, dentre os 32 pares método–conjunto, 25 apresentam $r_{fair} < 0$. Apenas o EDL exibe tendência direcional relativamente clara: mitiga o viés em Mental e Heart Disease (P) e degrada *fairness* em Arrhythmia (U), configurando tendência baixa para P com Aids ($r_{fair} = -0,378$) como exceção intragrupo. O ERL degrada *fairness* nos quatro conjuntos em magnitudes próximas (r_{fair} entre $-0,215$ e $-0,757$), sem tendência de favorecimento. O IFG exibe tendência baixa para U: o único valor em U (Arrhythmia, $r_{fair} = 0,383$) supera todos os três em P (máximo em Heart Disease, $0,044$), mas Mental e Aids permanecem com *fairness* degradado ($-0,237$ e $-1,844$). Os demais métodos apresentam perfis instáveis: o IAD mitiga o viés em Arrhythmia e Mental e degrada *fairness* Heart Disease e Aids; IGLA, IGLU, IP e IW degradam *fairness* em Arrhythmia e registram em Heart Disease os valores mais severos.


Figura 5.25 – Direção do viés no *baseline* e resultado de mitigação na diferença da taxa de falsa descoberta.



Fonte: A autora

Por fim, na diferença de taxa de erro (Figura 5.26), quatro conjuntos foram elegíveis: Arrhythmia com viés U e Heart Disease, Aids e Mental com viés P (Tabela 5.13). Os valores de $d_{baseline}$ dessa métrica estão entre os menores da categoria C, conforme caracterização das distâncias ao ideal por métrica na Seção 5.1, o que se reflete em efeitos absolutos de pequena magnitude. Em seis dos oito métodos, todos os valores em P superam o valor em Arrhythmia (U); nos outros dois (IAD e IW), apenas Mental rompe essa ordenação. Três métodos exibem tendência direcional mais clara para P: ERL, IGLU e IP. Os métodos EDL, IGLA e IFG apresentam tendência baixa para P: todos os valores em P superam U, mas ao menos um conjunto em P permanece negativo — Mental no IGLA ($-0,149$), por exemplo. Já os métodos IAD e IW são instáveis: a degradação de *fairness* em Mental ($r_{fair} = -0,638$ e $-1,122$, respectivamente) supera a observada em Arrhythmia, rompendo a ordenação direcional.

Figura 5.26 – Direção do viés no *baseline* e resultado de mitigação na diferença da taxa de erro.



Fonte: A autora

5.5.1 Discussão

O achado central desta seção é que o sentido do viés não é o fator determinante do sucesso ou fracasso da mitigação. Em todas as métricas analisadas, observam-se conjuntos de mesmo sentido com respostas opostas a um mesmo método: o IAD, por exemplo, mitiga o viés em Aids e Diabetes (ambos P) no impacto díspar, mas o degrada Mental (também P) com $r_{\text{fair}} = -1,165$. Os métodos de *reductions* mitigam o viés em Mental e Diabetes na métrica de amplificação de viés com remoção "completa" ($r_{\text{fair}} = 1,000$), entretanto caem para $r_{\text{fair}} = 0,008$ (IGLA) e $0,084$ (IGLU) em Aids. Esse padrão se repete ao longo das cinco métricas, indicando que as características específicas de cada conjunto de dados exercem influência mais forte sobre o resultado do que a direção do viés.

Isso não significa que o sentido seja irrelevante. Na categoria A, alguns métodos exibem tendências consistentes. Os métodos *reductions* apresentam tendência clara de maior mitigação para U no impacto díspar, com diferenças pontuais marcadas entre os sentidos. O ERL exibe a tendência oposta para P no impacto díspar, sustentada também na diferença da taxa de erro — ainda que, na amplificação de viés, essa assimetria não se mantenha. Essas inclinações, no entanto, se manifestam como diferenças de magnitude — não como diferença entre mitigação e degradação. Em nenhum caso o sentido, isoladamente, determina se o método mitigará ou degradará um dado conjunto. Na categoria C, o quadro é mais heterogêneo: na diferença de taxa de erro, três métodos (ERL, IGLU e IP) apresentam tendência clara para P e outros três (EDL, IGLA e IFG), tendência baixa no mesmo sentido; nas diferenças de taxa de falsa descoberta e de falsos negativos predominam perfis instáveis e degradação de *fairness*, com tendências isoladas.

Na prática, métodos que se mostram robustos a ambos os sentidos — como o IP no impacto díspar — oferecem maior previsibilidade. Em contraste, métodos com assimetria acentuada entre sentidos, como o ERL na mesma métrica, podem demandar validação adicional quando aplicados a conjuntos de dados cujo sentido de viés difere daquele em que apresentaram melhor desempenho.

Cabe destacar também que a diferença de taxa de falsa descoberta se distingue das demais métricas: é a única em que nenhum método mitiga todos os conjuntos elegíveis, e a degradação de *fairness* ocorre de forma generalizada independentemente do sentido. Esse resultado reforça o achado de seções anteriores de que métricas da categoria C baseadas em taxas condicionais são particularmente resistentes à mitigação de viés, e sugere que essa resistência independe da direção do viés.

5.6 RQ5 — Qual é o *trade-off* entre desempenho preditivo e ganho em *fairness* obtido pelos métodos de mitigação?

Esta seção integra os dois eixos centrais avaliados neste estudo — desempenho preditivo ($\Delta_{\text{F1-Score}}$) e mitigação de viés (Δ_{fair}) — analisando em que medida ganhos em *fairness* ocorrem à custa de perdas de desempenho, ou se há configurações em que ambos melhoram simultaneamente. Para cada métrica, os resultados são apresentados em duas leituras complementares: (i) a fronteira de Pareto, que destaca regiões para as quais não existe outra alternativa simultaneamente melhor em desempenho e em ganho de *fairness*; e (ii) a distribuição por quadrantes, que resume a proporção de casos em regimes *win-win* (ganho em ambos), *trade-off* (ganho de *fairness* com perda de desempenho), *win-lose* e *lose-lose*. Essa síntese permite comparar categorias e configurações de forma diretamente interpretável, evidenciando quais métodos tendem a oferecer melhor equilíbrio entre utilidade e mitigação e em quais métricas esse equilíbrio é mais difícil de alcançar.

Principais achados. O custo em desempenho preditivo da mitigação não é uniforme e depende fortemente da métrica de *fairness*: nas métricas de mitigação mais expressiva, como o impacto díspar, o *trade-off* — ganho de *fairness* com perda de desempenho — é o regime dominante, e os cenários *win-win* são raros e dependentes do conjunto de dados. Os métodos organizam-se por faixa de exigência — IFG preserva o desempenho com mitigação modesta; ERL oferece o melhor equilíbrio em paridade estatística, porém com a maior degradação em consistência; IGLA e IP entregam os maiores ganhos, com o IGLA na posição mais eficiente em impacto díspar. A elevada variabilidade entre conjuntos de dados indica que essas faixas representam tendências medianas, não garantias.

No impacto díspar, a maioria dos métodos opera no quadrante de *trade-off*, com ganho de *fairness* acompanhado de perda de desempenho. Dentre os métodos com mitigação mediana acima de 0,100, dois se destacam na fronteira de Pareto (Figura 5.27): IGLA e ERL. O IGLA apresenta a mitigação mais intensa ($\Delta_{\text{fair}} = 0,344$), com um custo de desempenho de $\Delta_{\text{F1-Score}} = -0,028$; esse custo é inferior ao de outros métodos com mitigação de magnitude similar, como o IGLU ($\Delta_{\text{fair}} = 0,307$, porém com $\Delta_{\text{F1-Score}} = -0,046$) e o IP ($\Delta_{\text{fair}} = 0,267$, $\Delta_{\text{F1-Score}} = -0,038$). Já o ERL oferece mitigação intermediária ($\Delta_{\text{fair}} = 0,200$) com a menor perda de desempenho entre os métodos de mitigação expressiva ($\Delta_{\text{F1-Score}} = -0,015$), sendo mais eficiente que o IW, que atinge mitigação semelhante ($\Delta_{\text{fair}} = 0,191$) com custo quase duas vezes maior ($\Delta_{\text{F1-Score}} = -0,028$). Os


métodos EDL e IFG não apresentaram mitigação relevante nessa métrica (medianas de Δ_{fair} entre $-0,020$ e $-0,007$). IAD apresenta efeito modesto ($\Delta_{\text{fair}} = 0,054$), distante dos métodos de maior mitigação. Cabe notar que o IGLU é estritamente dominado pelo IGLA nessa métrica: entrega mitigação inferior ($0,307$ vs. $0,344$) com custo de desempenho 60% maior ($-0,046$ vs. $-0,028$).

Nos pontos individuais por conjunto de dados (Figura B.1a, Apêndice B), observa-se que a maioria se concentra no quadrante de *trade-off*, mas há casos isolados de *win-win* — como pontos de IW e IFG com $\Delta_{\text{F1-Score}} > 0$ e $\Delta_{\text{fair}} > 0,4$ — e de *lose-lose*, incluindo um ponto extremo do IAD com $\Delta_{\text{fair}} \approx -0,6$ e $\Delta_{\text{F1-Score}} \approx -0,04$.

Em amplificação de viés (Figura 5.27), o padrão de *trade-off* se repete para a maioria dos métodos, com magnitudes de mitigação mais modestas do que no impacto díspar. O ERL se destaca como o método de melhor relação custo-benefício entre aqueles com maior mitigação, com $\Delta_{\text{fair}} = 0,060$ e $\Delta_{\text{F1-Score}} = -0,015$; o IW atinge a mesma mitigação ($0,060$), porém com custo maior ($\Delta_{\text{F1-Score}} = -0,028$). O EDL apresenta mediana no quadrante *lose-lose* ($\Delta_{\text{fair}} = -0,048$; $\Delta_{\text{F1-Score}} = -0,006$), indicando degradação simultânea em ambos os eixos. O IFG mantém desempenho ($\Delta_{\text{F1-Score}} = +0,003$), mas com mitigação praticamente nula ($\Delta_{\text{fair}} = 0,003$).

Já entre os métodos *in-processing*, IGLA e IGLU apresentam a mesma mediana de mitigação ($0,041$), porém o IGLU exige custo de desempenho 60% maior ($\Delta_{\text{F1-Score}} = -0,046$ vs. $-0,028$), reforçando o padrão de ineficiência relativa do IGLU observado no impacto díspar.

Figura 5.27 – Fronteira de Pareto entre desempenho preditivo e ganho em *fairness* nas métricas de paridade estatística (categoria A).



Fonte: A autora


Na métrica de consistência (Figura 5.28), os efeitos de mitigação de viés variam substancialmente entre os métodos. ERL apresenta a maior degradação de *trade-off*

($\Delta_{\text{fair}} = -0,062$; $\Delta_{\text{F1-Score}} = -0,015$), posicionando-se no quadrante *lose-lose*. IGLU ($\Delta_{\text{fair}} = -0,012$; $\Delta_{\text{F1-Score}} = -0,046$) e IFG ($\Delta_{\text{fair}} = -0,013$; $\Delta_{\text{F1-Score}} = +0,003$) também degradam a métrica de consistência. Em contraste, EDL ($\Delta_{\text{fair}} = +0,007$; $\Delta_{\text{F1-Score}} = -0,006$) e IAD ($\Delta_{\text{fair}} = +0,006$; $\Delta_{\text{F1-Score}} = -0,003$) apresentam medianas levemente positivas no eixo de *fairness*, com custos de desempenho reduzidos. A fronteira de Pareto nessa métrica é composta por IAD e EDL, que oferecem mitigação de viés modesta com custos controlados, em contraste com a maioria dos métodos *in-processing* que degradam tanto o desempenho quanto a consistência.

No índice de entropia generalizada (Figura 5.28), praticamente nenhum método apresentou melhoria mediana de *fairness*: todos os valores de Δ_{fair} são negativos ou nulos, configurando um cenário predominante de *lose-lose*. A degradação mais acentuada ocorre no IGLU ($\Delta_{\text{fair}} = -0,025$; $\Delta_{\text{F1-Score}} = -0,046$), seguido do IP ($-0,016$; $-0,038$) e do IGLA ($-0,014$; $-0,028$). O IFG é o único método que se mantém próximo da origem ($\Delta_{\text{fair}} = 0,000$; $\Delta_{\text{F1-Score}} = +0,003$), constituindo sozinho a fronteira de Pareto. Esse resultado indica que os métodos projetados para mitigar viés de grupo tendem a aumentar a desigualdade individual medida por essa métrica, e que o grau dessa degradação acompanha o custo de desempenho do método: a correlação entre $|\Delta_{\text{F1-Score}}|$ e $|\Delta_{\text{fair}}|$ é visível na disposição dos métodos ao longo de uma diagonal do quadrante *lose-lose*.

No gráfico de quadrantes (Figura B.2b, Apêndice B), a grande maioria dos pontos individuais por conjunto de dados se distribui nos quadrantes inferiores (*lose-lose* e ganho apenas de desempenho), com raros pontos acima da linha $\Delta_{\text{fair}} = 0$. Isso confirma que a piora nessa métrica não é um artefato da mediana, mas um padrão consistente entre conjuntos de dados.

Figura 5.28 – Fronteira de Pareto entre desempenho preditivo e ganho em *fairness* nas métricas de *fairness* individual (categoria B).




Fonte: A autora

Na métrica de diferença de taxa de falsos negativos (Figura 5.29), a fronteira de Pareto contém três métodos com perfis distintos. O IP oferece a mitigação de viés mais intensa ($\Delta_{\text{fair}} = 0,040$), porém com custo elevado de desempenho ($\Delta_{\text{F1-Score}} = -0,038$). O método ERL apresenta mitigação de viés intermediária ($\Delta_{\text{fair}} = 0,026$) com custo moderado ($\Delta_{\text{F1-Score}} = -0,015$). O IFG, por sua vez, apresenta ganho em ambos os eixos ($\Delta_{\text{fair}} = 0,011$; $\Delta_{\text{F1-Score}} = +0,003$), embora com mitigação de viés de baixa magnitude.

No gráfico de quadrantes (Figura B.3a, Apêndice B), essa métrica exibe uma das dispersões mais acentuadas entre conjuntos de dados: mesmo métodos com mediana positiva, como IP e ERL, apresentam pontos individuais nos quadrantes *lose-lose* e de ganho apenas de desempenho, sugerindo que a capacidade de mitigar diferenças de falsos negativos é fortemente dependente do contexto.

A métrica de diferença de taxa de falsa descoberta (Figura 5.29) apresenta um padrão inverso ao do impacto díspar: os métodos com maior mitigação de viés em paridade estatística são precisamente os que mais degradam essa métrica. As piores medianas são de IGLA ($\Delta_{\text{fair}} = -0,095$), IP ($-0,091$) e IGLU ($-0,084$), todos com Δ_{fair} negativos expressivos e acompanhados de perdas de desempenho entre $-0,028$ e $-0,046$. O IFG é novamente o único método com ganho de desempenho ($\Delta_{\text{F1-Score}} = +0,003$) e sem degradação em *fairness*, constituindo sozinho a fronteira de Pareto; a mitigação de viés, entretanto, é de baixa magnitude.

Figura 5.29 – Fronteira de Pareto entre desempenho preditivo e ganho em *fairness* nas diferenças de taxa de falsos negativos e de falsa descoberta (categoria C).




Fonte: A autora

Na Diferença de taxa de erro (Figura 5.30), os efeitos de mitigação são de magnitude reduzida para todos os métodos, com $|\Delta_{\text{fair}}|$ inferior a 0,010 em todos os casos. O IFG é o único com mediana levemente positiva ($\Delta_{\text{fair}} = +0,005$; $\Delta_{\text{F1-Score}} = +0,003$). Os demais métodos apresentam Δ_{fair} próximo de zero ou levemente negativo, com custos

de desempenho que variam de $-0,006$ (EDL) a $-0,046$ (IGLU). Dado que as magnitudes no eixo de *fairness* são muito inferiores às perdas no eixo de desempenho, a análise dessa métrica é dominada pelo custo operacional de cada método, e não pelo seu efeito de mitigação.

Figura 5.30 – Fronteira de Pareto entre desempenho preditivo e ganho em *fairness* na diferença da taxa de erro.



Fonte: A autora

5.6.1 Discussão

Os resultados da análise de *trade-off* evidenciam que o custo de desempenho preditivo associado à mitigação de viés não é uniforme entre métodos e depende fortemente da métrica de *fairness* considerada. De um ponto de vista operacional, a escolha de método pode ser orientada pelo nível de mitigação de viés requerido pelo sistema.

Na faixa de menor exigência, o IFG se destaca por ser o método que mais frequentemente preserva o desempenho preditivo ($\Delta_{F1-Score}$ mediano de $+0,003$), com mitigação de viés positiva — embora modesta — em quatro das sete métricas avaliadas (amplificação de viés, diferença de taxa de falsos negativos, diferença de taxa de falsa descoberta e diferença de taxa de erro). Essa combinação torna o IFG a escolha de menor custo operacional, adequada quando o requisito de *fairness* é brando.

Na faixa intermediária, o ERL oferece o melhor equilíbrio entre mitigação de viés e preservação de desempenho preditivo nas métricas de paridade estatística. Esse método se posiciona na fronteira de Pareto em três métricas — impacto díspar ($\Delta_{fair} = 0,200$), amplificação de viés ($0,060$) e diferença de taxa de falsos negativos ($0,026$) — com um custo de desempenho preditivo consistente de $\Delta_{F1} \approx -0,015$, inferior ao de todos os

métodos *in-processing* com mitigação de viés comparável ou superior. Cabe notar, porém, que o ERL apresenta a maior degradação em consistência entre todos os métodos ($\Delta_{\text{fair}} = -0,062$), indicando que a transformação de atributos que favorece a paridade de grupo compromete a similaridade de predição entre indivíduos próximos. Esse *trade-off* entre categorias de *fairness* deve ser considerado ao eleger o ERL como método de referência.

Quando o requisito de *fairness* é mais elevado, IGLA e IP são os métodos que entregam os maiores ganhos de mitigação de viés. O IGLA, em particular, é o método mais eficiente nessa faixa: atinge $\Delta_{\text{fair}} = 0,344$ no impacto díspar com custo menor que o IGLU ($\Delta_{F1\text{-Score}} = -0,028$ vs. $-0,046$) e menor que o IP ($-0,028$ vs. $-0,038$), apesar de o IP superar o IGLA na diferença de taxa de falsos negativos ($0,040$ vs. $0,001$).

O posicionamento favorável do IGLA na fronteira de Pareto do impacto díspar é coerente com a concepção do *Grid Search Reduction*: ao varrer uma grade de multiplicadores de Lagrange, o método gera múltiplos classificadores candidatos e seleciona o de menor erro sujeito à restrição de *fairness*, explorando de forma sistemática o espaço de *trade-off* entre acurácia e paridade (Agarwal et al., 2018). A comparação com o IGLU — variante *unaware* do mesmo método — indica que a varredura, por si só, não basta: IGLU atinge uma faixa de mitigação de viés equivalente ($\Delta_{\text{fair}} = 0,307$), mas com custo de desempenho preditivo consideravelmente maior ($\Delta_{F1} = -0,046$ vs. $-0,028$), sendo estritamente dominado pelo IGLA; na ausência deste, o IGLU ocuparia o topo da fronteira. A vantagem observada parece depender, portanto, tanto do mecanismo de varredura quanto do acesso ao atributo sensível durante o treinamento. Os demais métodos *in-processing* com mitigação de viés relevante em impacto díspar — IP, IW e IAD — encontram um único ponto nesse espaço para cada configuração de hiperparâmetro, o que pode contribuir para seu posicionamento menos favorável quando avaliados sob a mesma configuração experimental.

Os métodos EDL e IAD, por sua vez, apresentam perfis mistos. O EDL posiciona-se no quadrante *lose-lose* em três métricas de paridade estatística e matriz de confusão, com mitigação de viés mediana negativa e IQR elevado; contudo, na consistência, EDL apresenta efeito levemente positivo, sendo um dos poucos métodos que não degradam essa métrica. O IAD apresenta mitigação de viés modesta em impacto díspar ($\Delta_{\text{fair}} = 0,054$) com custo de desempenho preditivo baixo ($\Delta_{F1} = -0,003$), e efeito levemente positivo em consistência ($\Delta_{\text{fair}} = +0,006$); em nenhuma métrica, contudo, o IAD se posiciona na fronteira de Pareto entre os métodos de maior mitigação de viés.

Por fim, os gráficos de distribuição por quadrantes (Apêndice B) mostram que,

para um mesmo método, os resultados individuais por conjunto de dados se distribuem por dois ou três quadrantes distintos. Essa variabilidade é mais acentuada nas métricas em que a mitigação de viés mediana é menor (consistência, Diferença de taxa de erro, índice de entropia generalizada), onde a dispersão entre conjuntos de dados é da mesma ordem de grandeza ou superior ao efeito mediano. Nas métricas com mitigação de viés mais expressiva (impacto díspar), a maioria dos pontos individuais se concentra no quadrante de *trade-off*, mas casos de *win-win* e *lose-lose* coexistem dependendo do conjunto de dados. Isso reforça que as faixas de custo-benefício descritas acima representam tendências medianas e não garantias; a escolha final de método deve considerar o contexto específico do conjunto de dados em uso.

6 CONCLUSÃO

Este trabalho investigou a efetividade de métodos de mitigação de viés, com ênfase em abordagens *in-processing*, aplicados a modelos de classificação em seis conjuntos de dados de saúde. A avaliação considerou conjuntamente a redução de disparidades entre grupos sensíveis e o impacto dessas intervenções no desempenho preditivo, por meio de um *pipeline* experimental padronizado e uma estratégia de análise que contemplou a magnitude, a intensidade, o sentido do viés e os *trade-offs* entre mitigação e desempenho. A seguir, são retomados os principais achados e suas implicações.

A análise diagnóstica do *baseline* revelou que todos os conjuntos de dados apresentam disparidades em ao menos duas das três categorias de métricas avaliadas, sem um grupo sistematicamente desfavorecido: em alguns conjuntos o viés incide sobre o grupo não privilegiado, em outros sobre o privilegiado. O impacto díspar foi a métrica com maior desvio absoluto em relação ao ideal, enquanto as métricas baseadas na matriz de confusão apresentaram os menores desvios.

Na análise global de mitigação, as métricas de paridade estatística (categoria A) concentraram os maiores efeitos, com destaque para o impacto díspar, no qual o tipo *in-processing* apresentou efeito mediano positivo e estatisticamente significativo; em amplificação de viés, o suporte pós-hoc também foi observado para o tipo *in-processing*, ainda que com magnitude menor. As métricas de *fairness* individual (categoria B), apesar de desvio absoluto inicial relevante, resultaram predominantemente em degradação ou ausência de efeito: no índice de entropia generalizada esse padrão foi universal — nenhum método apresentou efeito positivo mediano —, enquanto na consistência a degradação predominou com exceções pontuais em EDL e IAD, os únicos métodos com mitigação positiva nessa categoria. As métricas baseadas na matriz de confusão (categoria C) exibiram um comportamento ruidoso, com coexistência de mitigação na diferença na taxa de falsos negativos e degradação na diferença na taxa de falsa descoberta, sugerindo redistribuição de erros entre componentes da matriz e não redução global do viés nessa categoria.

A estratificação por elegibilidade confirmou a robustez desses padrões e revelou sinais latentes que a inclusão de conjuntos próximos ao ideal havia diluído: IW e ERL passaram a exibir mitigação estatisticamente significativa no pós-hoc para a amplificação de viés; no ERL, contudo, essa significância coexiste com a intensificação da degradação em consistência, indicando que, nesse método, ganhos em paridade e custos em *fairness*

individual concentram-se nos mesmos cenários.

A análise por intensidade do viés identificou três regimes de resposta. O primeiro, de escalonamento positivo, manifestou-se no impacto díspar e na diferença na taxa de falsos negativos: maior viés inicial correspondeu a maior mitigação absoluta, com r_{fair} mediano em torno de 0,5 nas duas métricas — fração comparável do viés inicial removida, apesar das escalas distintas de d_{baseline} . Esse escalonamento estendeu-se à amplificação de viés de modo condicionado ao método: ERL e IW escalaram positivamente com o viés inicial, enquanto IP e IAD apresentaram degradação em conjuntos específicos. O segundo regime, de heterogeneidade extrema entre métodos, concentrou-se na consistência: EDL e ERL ocuparam polos opostos — o primeiro mitigando e o segundo degradando todos os conjuntos —, com os demais métodos distribuídos entre esses dois extremos. O terceiro regime, de escalonamento reverso, ocorreu no índice de entropia generalizada e na diferença na taxa de falsa descoberta, métricas em que maior viés inicial correspondeu a maior degradação.

A análise por sentido do viés indicou que as características específicas de cada conjunto de dados exercem maior influência sobre a mitigação do que a direção do viés em si: conjuntos com o mesmo sentido apresentaram respostas opostas ao mesmo método, enquanto a direção influenciou predominantemente a magnitude do efeito. O IP destacou-se como o método com maior equilíbrio entre os dois sentidos do viés — contra o grupo não privilegiado (U) e contra o privilegiado (P) —, com faixas de r_{fair} quase sobrepostas no impacto díspar.

A análise de *trade-off* evidenciou que o regime dominante é de mitigação mediante perda de desempenho, sendo cenários *win-win* pontuais e restritos a pares específicos de método e conjunto de dados. Três faixas operacionais emergiram: o IFG como opção de custo mínimo, sendo o único método que preservou o desempenho; o ERL como alternativa de mitigação moderada com a melhor taxa de câmbio em paridade, porém com degradação expressiva em consistência; e o IGLA como opção de mitigação intensa no impacto díspar, com custos documentados em outras categorias de *fairness*. O IGLU não atingiu a fronteira de Pareto em nenhuma das sete métricas avaliadas, sendo consistentemente dominado pela variante *aware*.

A integração dos resultados permite destacar três eixos transversais às perguntas de pesquisa. O primeiro eixo retoma resultados consolidados na literatura — a tensão entre *fairness* de grupo e individual (Xu; Strohmmer, 2024) e a incompatibilidade formal entre separação e suficiência (Chouldechova, 2016; Kleinberg; Mullainathan; Raghavan,

2017) — e os situa em um quadro mais amplo: o *trade-off* entre mitigação e custo não se restringe à relação entre *fairness* e desempenho preditivo, mas se manifesta também no interior do próprio *fairness*. Constitui, possivelmente, o achado mais relevante deste trabalho. Os quatro métodos com maiores ganhos em impacto díspar — IGLA, IGLU, IP e IW — concentraram também as maiores degradações no índice de entropia generalizada; entre eles, IGLA, IGLU e IP estenderam esse padrão à diferença na taxa de falsa descoberta, com perdas adicionais — ainda que modestas — em consistência. Esse padrão foi consistente nas análises global, por elegibilidade e de *trade-off*, indicando que a otimização de paridade estatística entre grupos não se traduz em ganhos — e frequentemente se traduz em perdas — em *fairness* individual e em métricas baseadas na matriz de confusão. A concentração dos ganhos em paridade é coerente com o desenho dos algoritmos avaliados: os métodos *reductions* foram configurados com restrição de paridade demográfica, incidindo diretamente sobre a taxa de predição positiva por grupo, enquanto os demais métodos *in-processing* visam paridade por mecanismos indiretos — regularização de informação mútua (IP), alinhamento de distribuições de escores (IW) ou adversário discriminativo (IAD). Contudo, o fato de essas métricas também apresentarem os maiores desvios iniciais no *baseline* pode ter contribuído para amplificar os efeitos absolutos observados, dado que havia maior margem disponível para redução.

No interior da categoria C, a coexistência de ganhos em diferença na taxa de falsos negativos com degradação em diferença na taxa de falsa descoberta é compatível com a incompatibilidade formal entre os critérios de separação e suficiência, corroborada empiricamente por Friedler et al. (2018). Adicionalmente, a análise por intensidade indicou que essa redistribuição se intensifica nos conjuntos com maior viés do *baseline*, sugerindo que a tensão empírica entre critérios se acentua justamente nos cenários em que haveria maior margem para mitigação. De modo análogo, a degradação de *fairness* individual mediante ganhos de paridade reflete a tensão entre *fairness* de grupo e individual, cuja extensão varia conforme o mecanismo de intervenção.

O segundo eixo diz respeito ao perfil comparativo dos métodos. Os métodos *reductions* e o IP concentraram os maiores efeitos em impacto díspar, com suporte estatístico e robustez nas análises por intensidade e sentido do viés; o IP destacou-se adicionalmente pela estabilidade entre sentidos de viés nessa métrica, propriedade que, contudo, não se preservou nas métricas da categoria C. No interior dos métodos *reductions*, a variante *aware* (IGLA) dominou sistematicamente a *unaware* (IGLU): maior mitigação em impacto díspar com menor custo de desempenho, posicionando-se na fronteira de Pareto,

enquanto o IGLU não atingiu essa fronteira em nenhuma das métricas avaliadas.

A vantagem observada parece decorrer da combinação entre o mecanismo de *Grid Search Reduction* (Agarwal et al., 2018) — que varre sistematicamente o espaço de *trade-off* entre paridade e desempenho — e o acesso ao atributo sensível durante o treinamento, e não de cada fator isoladamente. O IP, também *aware*, não exibe a mesma dominância na fronteira; o IGLU, apesar de partilhar o *Grid Search* com o IGLA, tampouco chega a ela. Essa leitura questiona a utilidade prática da abordagem *unaware* nesse formato, ao menos nas configurações avaliadas.

O método IW apresentou perfil distinto: mitigação de viés mais modesta em impacto díspar, porém resultados positivos em um conjunto mais amplo de métricas simultaneamente — amplificação de viés (com suporte estatístico na análise por elegibilidade) e diferença na taxa de falsos negativos —, com degradação mínima em consistência e concentrada no índice de entropia generalizada, configurando-se como alternativa relevante quando se busca equilíbrio entre múltiplas dimensões. O IFG e o IAD ocuparam uma faixa de mitigação mais modesta em paridade, com resultados ruidosos — comportamento coerente, no caso do IAD, com a instabilidade de otimização de abordagens adversariais reportada por Han et al. (2024). O IFG, entretanto, foi o único método que preservou o desempenho preditivo, obtendo mitigação positiva em quatro das sete métricas, o que o posiciona como opção para cenários com requisitos moderados de *fairness* e prioridade na preservação do desempenho.

Os métodos *pre-processing* apresentaram perfis opostos: o ERL obteve a melhor taxa de câmbio em paridade, com a pior degradação em consistência entre todos os métodos; o EDL, inversamente, figurou entre os poucos métodos com mitigação positiva em consistência, ao custo de degradação em impacto díspar e amplificação de viés. Essa complementaridade indica que a comparação agregada por tipo de intervenção obscurece diferenças relevantes entre métodos de uma mesma etapa.

O terceiro eixo refere-se ao papel das características dos dados e corrobora a sensibilidade da mitigação de viés ao conjunto utilizado, já documentada em estudos comparativos (Friedler et al., 2018). A intensidade do viés inicial modulou a magnitude da mitigação de viés de forma heterogênea entre métricas, enquanto a direção do viés influenciou a magnitude dos efeitos sem determinar sucesso ou fracasso. Entretanto, essas análises foram conduzidas de forma descritiva, com um número limitado de conjuntos de dados, o que restringe generalizações. A variabilidade observada — em que o mesmo método pode ocupar quadrantes distintos de *trade-off* dependendo do conjunto de da-

dos — reforça que tendências medianas não constituem garantias de comportamento em aplicações específicas.

Do ponto de vista metodológico, este trabalho contribui com um *pipeline* experimental padronizado para avaliação comparativa de métodos de mitigação de viés, integrando validação cruzada repetida e critério quantitativo de elegibilidade baseado na intensidade do viés do *baseline*. Propõe-se ainda uma formulação que expressa métricas de *fairness* de naturezas distintas — diferenças e razões, com valores ideais e escalas próprios — em um espaço comum de distância ao valor ideal, tornando os efeitos de mitigação diretamente comparáveis e agregáveis entre métricas e conjuntos de dados. Soma-se a esses elementos uma estratégia de análise progressiva — da visão global à segmentação por elegibilidade, intensidade, sentido e *trade-off* —, capaz de identificar padrões que seriam diluídos em avaliações agregadas.

Do ponto de vista empírico, os resultados oferecem evidências de que o *trade-off* entre dimensões de *fairness* é tão relevante quanto o *trade-off* entre *fairness* e desempenho, dado que métodos que otimizam paridade estatística frequentemente degradam métricas individuais e baseadas na matriz de confusão. Adicionalmente, a dominância da variante *aware* sobre a *unaware* nos métodos *reductions* questiona a vantagem prática de abordagens *unaware* nesse formato, e a identificação de nichos operacionais distintos — IFG para preservação de desempenho, IW para equilíbrio entre dimensões — complementa a visão de que não há método universalmente superior.

Em termos de recomendações práticas, a escolha do método beneficia-se de três decisões prévias. A primeira é a definição de quais dimensões de *fairness* são prioritárias, dado que ganhos em paridade estatística frequentemente coexistem com degradação em *fairness* individual e em métricas da matriz de confusão; sem essa definição, o ganho em uma categoria pode ser anulado pela perda em outra. A segunda é a tolerância a perdas de desempenho preditivo, que define a faixa operacional: IFG para preservação do desempenho com mitigação de viés mínima, ERL para mitigação moderada com a melhor taxa de câmbio em paridade — acompanhada, porém, da maior degradação em consistência —, e IGLA para mitigação de viés intensa em paridade estatística com custo controlado, acompanhada de degradação em outras dimensões de *fairness*. A terceira é o grau de conhecimento disponível sobre o conjunto de dados: quando o diagnóstico prévio é limitado, métodos mais estáveis entre sentidos de viés (IP no impacto díspar) ou entre múltiplas dimensões (IW) oferecem maior previsibilidade. Recomenda-se, adicionalmente, que a aplicação de qualquer método seja precedida por um diagnóstico do

baseline análogo ao conduzido na RQ0, de modo a identificar as categorias com margem real para mitigação e evitar intervenções cujo efeito se confunda com a proximidade do ideal.

6.1 Limitações

Este estudo apresenta algumas limitações que devem ser consideradas na interpretação dos resultados. A avaliação foi conduzida com seis conjuntos de dados do domínio de saúde, todos com atributos sensíveis binários, o que restringe a generalização dos achados para outros domínios ou configurações com múltiplos grupos sensíveis. Não foram incluídos métodos *post-processing*, de forma que a comparação se limitou a abordagens *pre-processing* e *in-processing*. Optou-se por não realizar otimização extensiva de hiperparâmetros dos métodos de mitigação de viés, conforme justificado na metodologia; embora isso preserve a comparabilidade entre abordagens, limita a exploração do potencial individual de cada método. As análises por intensidade e sentido do viés foram conduzidas de forma descritiva, o que permite identificar tendências, mas não estabelecer relações causais ou generalizáveis.

Outra limitação diz respeito à operacionalização binária do atributo sensível. Em todos os conjuntos de dados, a análise separa um grupo privilegiado de um grupo não privilegiado, e este último agrega subgrupos heterogêneos — no conjunto Mental, por exemplo, reúne mulheres cis, pessoas trans, indivíduos não binários e respostas indefinidas. Como consequência, eventuais disparidades entre esses subgrupos não são capturadas, e os achados não devem ser interpretados como representativos de cada subgrupo isoladamente. Essa restrição também impede a análise de atributos sensíveis de natureza contínua, como a idade (que figura entre os atributos sensíveis do conjunto Diabetes, embora não tenha sido adotada na análise), cuja incorporação exigiria discretização em faixas ou noções de *fairness* definidas sobre variáveis contínuas. Em ambos os casos, uma avaliação mais ampla exigiria redefinir o atributo protegido e as próprias métricas de *fairness* — que pressupõem grupos binários — em todos os experimentos, o que extrapola o escopo deste trabalho..

Por fim, os resultados comportam uma leitura ética que transcende sua dimensão técnica. Conforme evidenciado ao longo das análises, o *trade-off* entre dimensões de *fairness* indica que a priorização de um critério sobre outro não é uma decisão resolvível pela otimização, mas um juízo de valor externo aos dados (Xu; Strohmmer, 2024); soma-se

a isso o fato de que parte da mitigação observada na categoria C corresponde à redistribuição de erros entre grupos, e não à sua eliminação. Disso decorre uma ressalva quanto ao uso dos achados: por constituírem uma comparação metodológica conduzida sobre conjuntos de dados públicos, os resultados não configuram validação para uso clínico, e as tendências medianas reportadas — sujeitas à variabilidade entre conjuntos de dados — não substituem a validação prospectiva e específica ao contexto de aplicação.

6.2 Trabalhos futuros

Os resultados deste trabalho apontam algumas direções para investigações futuras. A análise por intensidade e sentido do viés, conduzida aqui de forma descritiva, pode ser aprofundada com delineamentos experimentais específicos que permitam isolar o efeito dessas características sobre a mitigação de viés. A exploração sistemática de hiperparâmetros dos métodos de mitigação de viés constitui outra direção relevante, especialmente para métodos com maior dimensionalidade de *tuning*, como os métodos *reductions* e o *Adversarial Debiasing*, que possuem margem para otimização do *trade-off* entre *fairness* e desempenho. A inclusão de métodos *post-processing* permitiria uma comparação mais completa entre as três etapas de intervenção. Além disso, a extensão da avaliação para conjuntos de dados com atributos sensíveis não binários e para outros domínios de aplicação contribuiria para ampliar a generalidade dos achados. Por fim, a investigação de estratégias de composição — por exemplo, combinando *pre-processing* com *in-processing* — pode ser uma via para mitigar de viés simultaneamente diferentes dimensões de *fairness*, atenuando os *trade-offs* intra-*fairness* documentados neste trabalho.

O aprofundamento dos achados descritivos por meio de delineamentos de inferência causal constitui outra direção relevante. As análises conduzidas neste trabalho são predominantemente estatísticas, identificando associações entre métodos, características dos conjuntos de dados e efeitos sobre métricas de *fairness*; um desdobramento natural consiste em traduzir esses padrões em hipóteses sobre seus mecanismos subjacentes, avaliadas por intervenções controladas. A dominância da variante *aware* sobre a *unaware* nos métodos *reductions*, por exemplo, poderia ser examinada por delineamentos que isolem o acesso ao atributo sensível durante o treinamento, mantendo fixo o mecanismo de varredura; já a heterogeneidade dos efeitos entre conjuntos de dados poderia ser investigada com cenários sintéticos em que o desbalanceamento entre grupos e a magnitude inicial do viés são controlados. Esse enfoque permitiria atribuir efeito — e não apenas associação

— a fatores específicos do método ou dos dados.

De forma complementar, uma avaliação que vá além da operacionalização binária do atributo sensível — desdobrando o grupo não privilegiado em seus subgrupos e incorporando atributos de natureza contínua, como a idade — permitiria investigar disparidades que a abordagem adotada não captura. Por fim, a investigação de estratégias de composição — por exemplo, combinando *pre-processing* com *in-processing* — pode ser uma via para mitigar de viés simultaneamente diferentes dimensões de *fairness*, atenuando os *trade-offs* intra-*fairness* documentados neste trabalho.

REFERÊNCIAS

- AGARWAL, A. et al. A reductions approach to fair classification. **arXiv preprint arXiv:1803.02453**, 2018. Available from Internet: <<https://arxiv.org/abs/1803.02453>>.
- AGUEH, M.; CARLIER, G. Barycenters in the wasserstein space. **SIAM Journal on Mathematical Analysis**, v. 43, n. 2, p. 904–924, 2011. Available from Internet: <<https://doi.org/10.1137/100805741>>.
- ANGWIN, J. et al. **Machine Bias — ProPublica**. 2016. Available from Internet: <<https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>>.
- AROS, L. H. et al. Financial fraud detection through the application of machine learning techniques: a literature review. **Humanities and Social Sciences Communications**, v. 11, n. 1, p. 1130, 2024. Available from Internet: <<https://doi.org/10.1057/s41599-024-03606-0>>.
- AYINADDIS, S. G. Artificial intelligence adoption dynamics and knowledge in smes and large firms: A systematic review and bibliometric analysis. **Journal of Innovation Knowledge**, v. 10, n. 3, p. 100682, 2025. ISSN 2444-569X. Available from Internet: <<https://www.sciencedirect.com/science/article/pii/S2444569X25000320>>.
- BAROCAS, S.; HARDT, M.; NARAYANAN, A. **Fairness and Machine Learning: Limitations and Opportunities**. [S.l.]: MIT Press, 2023.
- BARR, C. J. S. et al. **A Review of Fairness and A Practical Guide to Selecting Context-Appropriate Fairness Metrics in Machine Learning**. 2025. Available from Internet: <<https://arxiv.org/abs/2411.06624>>.
- BECKER, B.; KOHAVI, R. **Adult**. UCI Machine Learning Repository, 1996. Also known as Census Income dataset. Available from Internet: <<https://archive.ics.uci.edu/dataset/2/adult>>.
- BELLAMY, R. K. E. et al. **AI Fairness 360: An Extensible Toolkit for Detecting, Understanding, and Mitigating Unwanted Algorithmic Bias**. 2018. Available from Internet: <<https://arxiv.org/abs/1810.01943>>.
- BISWAS, S.; RAJAN, H. Do the Machine Learning models on a crowd sourced platform exhibit bias? An empirical study on model fairness. In: **Proceedings of the 28th ACM Joint European Software Engineering Conference and Symposium on the Foundations of Software Engineering (ESEC/FSE '20)**. New York, NY, USA: Association for Computing Machinery, 2020. p. 642–653. ISBN 978-1-4503-7043-1. Available from Internet: <<https://doi.org/10.1145/3368089.3409704>>.
- BOTCHKAREV, A. A new typology design of performance metrics to measure errors in machine learning regression algorithms. **Interdisciplinary Journal of Information, Knowledge, and Management**, Informing Science Institute, v. 14, p. 045–076, 2019. ISSN 1555-1237. Available from Internet: <<http://dx.doi.org/10.28945/4184>>.
- BREIMAN, L. Random forests. **Machine learning**, Springer, v. 45, n. 1, p. 5–32, 2001.

BUOLAMWINI, J.; GEBRU, T. Gender shades: Intersectional accuracy disparities in commercial gender classification. In: FRIEDLER, S. A.; WILSON, C. (Ed.). **Proceedings of the 1st Conference on Fairness, Accountability and Transparency**. PMLR, 2018. (Proceedings of Machine Learning Research, v. 81), p. 77–91. Available from Internet: <<https://proceedings.mlr.press/v81/buolamwini18a.html>>.

CATON, S.; HAAS, C. **Fairness in Machine Learning: A Survey**. 2020. Available from Internet: <<https://arxiv.org/abs/2010.04053>>.

CHAWLA, N. V. et al. Smote: Synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002.

CHEN, I. Y.; SZOLOVITS, P.; GHASSEMI, M. **Can AI Help Reduce Disparities in General Medical and Mental Health Care?** 2019. 167-179 p. Available from Internet: <www.amajournalofethics.org>.

CHEN, Z. et al. A comprehensive empirical study of bias mitigation methods for machine learning classifiers. **arXiv**, abs/2207.03277, 2023. Available from Internet: <<https://arxiv.org/abs/2207.03277>>.

CHOULDECHOVA, A. **Fair prediction with disparate impact: A study of bias in recidivism prediction instruments**. 2016. Available from Internet: <<https://arxiv.org/abs/1610.07524>>.

CHOULDECHOVA, A. et al. A case study of algorithm-assisted decision making in child maltreatment hotline screening decisions. In: FRIEDLER, S. A.; WILSON, C. (Ed.). **Proceedings of the 1st Conference on Fairness, Accountability and Transparency**. PMLR, 2018. (Proceedings of Machine Learning Research, v. 81), p. 134–148. Available from Internet: <<https://proceedings.mlr.press/v81/chouldechova18a.html>>.

COTTER, A. et al. **Optimization with Non-Differentiable Constraints with Applications to Fairness, Recall, Churn, and Other Goals**. 2018. Available from Internet: <<https://arxiv.org/abs/1809.04198>>.

CRUZ, A. F. et al. Fairgbm: Gradient boosting with fairness constraints. **arXiv preprint arXiv:2209.07850**, 2023. Available from Internet: <<https://arxiv.org/abs/2209.07850>>.

DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. **Journal of Machine Learning Research**, v. 7, p. 1–30, 2006.

DWORK, C. et al. **Fairness Through Awareness**. 2011. Available from Internet: <<https://arxiv.org/abs/1104.3913>>.

DWORK, C. et al. Fairness through awareness. **Proceedings of the 3rd Innovations in Theoretical Computer Science Conference (ITCS)**, p. 214–226, 2012. Available from Internet: <<https://doi.org/10.1145/2090236.2090255>>.

ENSIGN, D. et al. Runaway feedback loops in predictive policing. In: FRIEDLER, S. A.; WILSON, C. (Ed.). **Proceedings of the 1st Conference on Fairness, Accountability and Transparency**. PMLR, 2018. (Proceedings of Machine Learning Research, v. 81), p. 160–171. Available from Internet: <<https://proceedings.mlr.press/v81/ensign18a.html>>.

FACELI, K. et al. **Inteligência artificial: uma abordagem de aprendizado de máquina**. Rio de Janeiro: LTC, 2011. ISBN 9788521618805.

FELDMAN, M. et al. **Certifying and removing disparate impact**. 2015. Available from Internet: <<https://arxiv.org/abs/1412.3756>>.

FOULDS, J. R.; PAN, S. An intersectional definition of fairness. **CoRR**, abs/1807.08362, 2018.

FRIEDLER, S. A. et al. **A comparative study of fairness-enhancing interventions in machine learning**. 2018. Available from Internet: <<https://arxiv.org/abs/1802.04422>>.

FRIEDMAN, B.; NISSENBAUM, H. Bias in computer systems. **ACM Trans. Inf. Syst.**, Association for Computing Machinery, New York, NY, USA, v. 14, n. 3, p. 330–347, jul. 1996. ISSN 1046-8188. Available from Internet: <<https://doi.org/10.1145/230538.230561>>.

FRIEDMAN, J. H. Greedy function approximation: A gradient boosting machine. **The Annals of Statistics**, Institute of Mathematical Statistics, v. 29, n. 5, p. 1189 – 1232, 2001. Available from Internet: <<https://doi.org/10.1214/aos/1013203451>>.

FRIEDMAN, M. The use of ranks to avoid the assumption of normality implicit in the analysis of variance. **Journal of the American Statistical Association**, v. 32, p. 675–701, 1937.

GANESH, P. et al. **Different Horses for Different Courses: Comparing Bias Mitigation Algorithms in ML**. 2024. Available from Internet: <<https://arxiv.org/abs/2411.11101>>.

GEIRHOS, R. et al. Shortcut learning in deep neural networks. **CoRR**, abs/2004.07780, 2020.

GERDON, F. et al. Social impacts of algorithmic decision-making: A research agenda for the social sciences. **Big Data and Society**, SAGE Publications Ltd, v. 9, 1 2022. ISSN 20539517.

GUVENIR H., A. B. M. H.; QUINLAN, R. **Arrhythmia**. 1997. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5BS32>.

HALIBURTON, L. et al. Uncovering labeler bias in machine learning annotation tasks. **AI and Ethics**, v. 5, p. 2515–2528, 2025. Available from Internet: <<https://doi.org/10.1007/s43681-024-00572-w>>.

HAMMER, S. M. et al. **A Trial Comparing Nucleoside Monotherapy with Combination Therapy in HIV-Infected Adults with CD4 Cell Counts from 200 to 500 per Cubic Millimeter**. 1996. 1081-1090 p. Available from Internet: <<https://www.nejm.org/doi/full/10.1056/NEJM199610103351501>>.

HAN, X. et al. **FFB: A Fair Fairness Benchmark for In-Processing Group Fairness Methods**. 2024. Available from Internet: <<https://arxiv.org/abs/2306.09468>>.

HANNUN, A. Y. et al. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. **Nature Medicine**, v. 25, n. 1, p. 65–69, 2019. Epub 2019-01-07.

HARDT, M.; PRICE, E.; SREBRO, N. Equality of opportunity in supervised learning. 10 2016. Available from Internet: <<http://arxiv.org/abs/1610.02413>>.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2. ed. [S.l.]: Springer, 2009. ISBN 9780387848570.

HOLM, S. A simple sequentially rejective multiple test procedure. **Scandinavian Journal of Statistics**, v. 6, p. 65–70, 1979.

HORT, M. et al. **Bias Mitigation for Machine Learning Classifiers: A Comprehensive Survey**. 2023. Available from Internet: <<https://arxiv.org/abs/2207.07068>>.

ISLAM, M. M. F. et al. Likelihood prediction of diabetes at early stage using data mining techniques. **Computer Vision and Machine Intelligence in Medical Image Analysis**, 2019. Available from Internet: <<https://api.semanticscholar.org/CorpusID:202835967>>.

ISLAM, R. et al. Differential fairness: An intersectional framework for fair ai. **Entropy**, v. 25, n. 4, 2023. ISSN 1099-4300. Available from Internet: <<https://www.mdpi.com/1099-4300/25/4/660>>.

JANOSI ANDRAS, S. W. P. M.; DETRANO, R. **Heart Disease**. 1989. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C52P4X>.

JIANG, R. et al. Wasserstein fair classification. **arXiv preprint arXiv:1907.12059**, 2019. Available from Internet: <<https://arxiv.org/abs/1907.12059>>.

KAMIRAN, F.; CALDERS, T. Data preprocessing techniques for classification without discrimination. Springer-Verlag, Berlin, Heidelberg, v. 33, n. 1, p. 1–33, oct. 2012. ISSN 0219-1377. Available from Internet: <<https://doi.org/10.1007/s10115-011-0463-8>>.

KAMISHIMA, T. et al. **Fairness-Aware Classifier with Prejudice Remover Regularizer**. 2012. Available from Internet: <<http://www.kamishima.net>>.

KAPOOR, S.; NARAYANAN, A. Leakage and the reproducibility crisis in machine-learning-based science. **Patterns**, v. 4, n. 9, p. 100804, 2023. ISSN 2666-3899. Available from Internet: <<https://www.sciencedirect.com/science/article/pii/S2666389923001599>>.

KAUR, D. et al. Trustworthy artificial intelligence: A review. **ACM Comput. Surv.**, Association for Computing Machinery, New York, NY, USA, v. 55, n. 2, jan. 2022. ISSN 0360-0300. Available from Internet: <<https://doi.org/10.1145/3491209>>.

KLEINBERG, J.; MULLAINATHAN, S.; RAGHAVAN, M. Inherent Trade-Offs in the Fair Determination of Risk Scores. In: PAPADIMITRIOU, C. H. (Ed.). **8th Innovations in Theoretical Computer Science Conference (ITCS 2017)**. Dagstuhl, Germany: Schloss Dagstuhl – Leibniz-Zentrum für Informatik, 2017. (Leibniz International Proceedings in Informatics (LIPIcs), v. 67), p. 43:1–43:23. ISBN 978-3-95977-029-3. ISSN 1868-8969. Available from Internet: <<https://drops.dagstuhl.de/entities/document/10.4230/LIPIcs.ITCS.2017.43>>.

LITJENS, G. et al. A survey on deep learning in medical image analysis. **Medical Image Analysis**, v. 42, p. 60–88, 2017. ISSN 1361-8415. Available from Internet: <<https://doi.org/10.1016/j.media.2017.07.005>>.

LIU, M. et al. A scoping review and evidence gap analysis of clinical ai fairness. **npj Digital Medicine**, v. 8, p. 360, 2025.

LUO, L. et al. **EARN Fairness: Explaining, Asking, Reviewing, and Negotiating Artificial Intelligence Fairness Metrics Among Stakeholders**. 2025. Available from Internet: <<https://arxiv.org/abs/2407.11442>>.

MAJUMDER, S. et al. **Fair Enough: Searching for Sufficient Measures of Fairness**. 2022. Available from Internet: <<https://arxiv.org/abs/2110.13029>>.

MEHRABI, N. et al. A survey on bias and fairness in machine learning. **CoRR**, abs/1908.09635, 2019.

MUKERJEE, A. et al. Multi-objective evolutionary algorithms for the risk-return trade-off in bank loan management. **International Transactions in Operational Research**, v. 9, 03 2002.

MURALITHARAN, S. et al. Machine learning–based early warning systems for clinical deterioration: Systematic scoping review. **J Med Internet Res**, v. 23, n. 2, p. e25187, Feb 2021. ISSN 1438-8871. Available from Internet: <<https://www.jmir.org/2021/2/e25187>>.

NORIEGA, A.; PENTLAND, A. P. Algorithmic fairness and efficiency in targeting social welfare programs at scale. In: **Bloomberg Data for Good Exchange Conference (D4GX 2018)**. [s.n.], 2018. Available from Internet: <<https://api.semanticscholar.org/CorpusID:166226514>>.

OBERMEYER, Z. et al. **Dissecting racial bias in an algorithm used to manage the health of populations**. 2019. Available from Internet: <<https://www.science.org>>.

Organization for Economic Co-operation and Development. **AI Use by Individuals Surges Across the OECD as Adoption by Firms Continues to Expand**. 2026. Accessed: 2026-02-04. Available from Internet: <<https://www.oecd.org/en/about/news/announcements/2026/01/ai-use-by-individuals-surges-across-the-oecd-as-adoption-by-firms-continues-to-expand.html>>.

(OSMI), O. S. M. I. **OSMI Mental Health in Tech Survey 2014**. [S.l.]: Open Sourcing Mental Illness, 2014. <<https://osmihelp.org/research>>. Original data collection by OSMI; dataset commonly distributed via Kaggle mirror.

PALECHOR, F. M.; MANOTAS, A. d. I. H. Dataset for estimation of obesity levels based on eating habits and physical condition in individuals from colombia, peru and mexico. **Data in Brief**, Elsevier, v. 25, p. 104344, 2019.

PEDRESHI, D.; RUGGIERI, S.; TURINI, F. Discrimination-aware data mining. In: . New York, NY, USA: Association for Computing Machinery, 2008. (KDD '08), p. 560–568. ISBN 9781605581934. Available from Internet: <<https://doi.org/10.1145/1401890.1401959>>.

RAFTOPOULOS, G. et al. A comprehensive review and benchmarking of fairness-aware variants of machine learning models. **Algorithms**, v. 18, 07 2025.

SALEIRO, P. et al. **Aequitas: A Bias and Fairness Audit Toolkit**. 2019. Available from Internet: <<https://arxiv.org/abs/1811.05577>>.

SELBST, A. D. et al. Fairness and abstraction in sociotechnical systems. In: **Proceedings of the Conference on Fairness, Accountability, and Transparency**. New York, NY, USA: Association for Computing Machinery, 2019. (FAT* '19), p. 59–68. ISBN 9781450361255. Available from Internet: <<https://doi.org/10.1145/3287560.3287598>>.

SHALEV-SHWARTZ, S.; BEN-DAVID, S. **Understanding Machine Learning: From Theory to Algorithms**. [S.l.]: Cambridge University Press, 2014. ISBN 9781107057135.

SIMSON, J.; FABRMEHRABI2019IS, A.; KERN, C. Unveiling the blindspots: Examining availability and usage of protected attributes in fairness datasets. In: **European Workshop on Algorithmic Fairness (EWAF) 2024, CEUR Workshop Proceedings**. [s.n.], 2024. Available from Internet: <https://ceur-ws.org/Vol-3908/paper_31.pdf>.

SPEICHER, T. et al. A unified approach to quantifying algorithmic unfairness: Measuring individual group unfairness via inequality indices. In: **Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining**. New York, NY, USA: Association for Computing Machinery, 2018. (KDD '18), p. 2239–2248. ISBN 9781450355520. Available from Internet: <<https://doi.org/10.1145/3219819.3220046>>.

Stanford University Human-Centered Artificial Intelligence. **The 2025 AI Index Report**. [S.l.], 2025. Accessed: 2026-02-04. Available from Internet: <<https://hai.stanford.edu/ai-index/2025-ai-index-report>>.

TUN, H. M. et al. Trust in artificial intelligence-based clinical decision support systems among health care workers: Systematic review. **Journal of Medical Internet Research**, v. 27, p. e69678, 2025.

U.S. Equal Employment Opportunity Commission. **Questions and Answers to Clarify and Provide a Common Interpretation of the Uniform Guidelines on Employee Selection Procedures**. n.d. Acesso em: 16 fev. 2026. Available from Internet: <<https://www.eeoc.gov/laws/guidance/questions-and-answers-clarify-and-provide-common-interpretation-uniform-guidelines>>.

VEGT, A. H. van der et al. Deployment of machine learning algorithms to predict sepsis: systematic review and application of the SALIENT clinical AI implementation framework. **Journal of the American Medical Informatics Association**, v. 30, n. 7, p. 1349–1361, 2023.

WANG, H. et al. Evaluating fairness of machine learning prediction of prolonged wait times in emergency department with interpretable extreme gradient boosting. **PLOS Digital Health**, Public Library of Science, v. 4, n. 3, p. 1–15, 03 2025. Available from Internet: <<https://doi.org/10.1371/journal.pdig.0000751>>.

WITTEN, I. H.; FRANK, E.; HALL, M. A. **Data Mining: Practical Machine Learning Tools and Techniques**. [S.l.]: Morgan Kaufmann, 2011.

XU, S.; STROHMER, T. **On the (In)Compatibility between Group Fairness and Individual Fairness**. 2024. Available from Internet: <<https://arxiv.org/abs/2401.07174>>.

ZEMEL, R. et al. Learning fair representations. In: DASGUPTA, S.; MCALLESTER, D. (Ed.). **Proceedings of the 30th International Conference on Machine Learning**. Atlanta, Georgia, USA: PMLR, 2013. (Proceedings of Machine Learning Research, 3), p. 325–333. Available from Internet: <<https://proceedings.mlr.press/v28/zemel13.html>>.

ZHANG, B. H.; LEMOINE, B.; MITCHELL, M. Mitigating unwanted biases with adversarial learning. **arXiv preprint arXiv:1801.07593**, 2018. Available from Internet: <<https://arxiv.org/abs/1801.07593>>.

ZHANG, H. et al. A sensor bias correction method for reducing the uncertainty in the spatiotemporal fusion of remote sensing images. **Remote Sensing**, v. 14, n. 14, 2022. ISSN 2072-4292. Available from Internet: <<https://www.mdpi.com/2072-4292/14/14/3274>>.

ZLIOBAITE, I. On the relation between accuracy and fairness in binary classification. **CoRR**, abs/1505.05723, 2015.

APÊNDICE A — RESULTADOS ESTATÍSTICOS COMPLEMENTARES

Este apêndice reúne resultados estatísticos adicionais que complementam as análises apresentadas nas Seções 5.2 e 5.3. O objetivo é disponibilizar, para fins de transparência e reprodutibilidade, as tabelas completas dos testes aplicados e das comparações *post-hoc* correspondentes.

A.1 Resultados de análise pós-hoc de efeitos globais

As tabelas desta seção complementam os achados globais reportados na Seção 5.2, detalhando as comparações *post-hoc* entre métodos e o *baseline* para cada métrica. Por concisão, são incluídas apenas as métricas com evidência de significância estatística no teste de Friedman; métricas sem significância (p -valor $> 0,05$) são omitidas.

Tabela A.1 – Resultados consolidados do pós-hoc vs *Baseline* (por categoria). Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.

Métrica	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
Diferença de Taxa de Erro	Pre-Processing	2,17	1,0000	-0,0061	0,0145
	In-Processing	2,17	1,0000	-0,0071	0,0088
Amplificação de viés	Pre-Processing	2,50	0,6136	-0,0110	0,0506
	In-Processing	1,17	0,0433	0,0605	0,0622
Diferença de Taxa de Falsa Descoberta	Pre-Processing	2,17	1,0000	-0,0308	0,0250
	In-Processing	2,83	1,0000	-0,0643	0,0597
Consistência	Pre-Processing	2,17	1,0000	-0,0195	0,0447
	In-Processing	2,00	1,0000	-0,0016	0,0184
Índice de Entropia Generalizada	Pre-Processing	2,00	1,0000	-0,0031	0,0102
	In-Processing	2,67	1,0000	-0,0165	0,0182
Impacto Díspar	Pre-Processing	2,17	0,1241	0,0490	0,1176
	In-Processing	1,00	0,0015	0,2722	0,1405
Diferença de Taxa de Falsos Negativos	Pre-Processing	2,00	0,2819	0,0110	0,0211
	In-Processing	1,67	0,2482	0,0264	0,0650

Tabela A.2 – Pós-hoc vs *Baseline* (por experimento) — Amplificação de viés. Correção de Holm;
 $\Delta_{\text{rank}} < 0$ indica método melhor que controle.

Métrica	Método	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
Amplificação de viés	EDL	Pre-Processing	6,67	0,5986	-0,0484	0,1452
	ERL		3,42	0,0820	0,0605	0,0622
	IAD	In-Processing	4,67	0,2800	0,0416	0,0590
	IGLA		4,42	0,2557	0,0416	0,0560
	IGLU		4,25	0,2460	0,0416	0,0299
	IFG		5,67	0,5986	0,0037	0,0411
	IP		5,67	0,5986	0,0198	0,0559
	IW		3,25	0,0708	0,0605	0,0622

Tabela A.3 – Pós-hoc vs *Baseline* (por experimento) — Impacto Díspar. Correção de Holm;
 $\Delta_{\text{rank}} < 0$ indica método melhor que controle.

Métrica	Método	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
Impacto Díspar	EDL	Pre-Processing	6,83	0,6733	-0,0203	0,2365
	ERL		4,50	0,1156	0,2009	0,2077
	IAD	In-Processing	6,17	0,5986	0,0540	0,1619
	IGLA		2,75	0,0107	0,3448	0,2219
	IGLU		2,75	0,0107	0,3073	0,1703
	IFG		7,33	0,6733	-0,0070	0,0267
	IP		3,33	0,0252	0,2679	0,2647
	IW		3,83	0,0510	0,1918	0,2705

Tabela A.4 – Pós-hoc vs *Baseline* (por experimento) — Consistência. Correção de Holm;
 $\Delta_{\text{rank}} < 0$ indica método melhor que controle.

Métrica	Método	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
Consistência	EDL	Pre-Processing	3,00	0,7207	0,0073	0,0034
	ERL		7,17	1,0000	-0,0626	0,0769
	IAD	In-Processing	2,67	0,5601	0,0060	0,0026
	IGLA		4,67	1,0000	-0,0019	0,0173
	IGLU		6,17	1,0000	-0,0126	0,0275
	IFG		6,83	1,0000	-0,0132	0,0204
	IP		5,83	1,0000	-0,0032	0,0304
	IW		3,67	1,0000	0,0025	0,0130

Tabela A.5 – Pós-hoc vs *Baseline* (por experimento) — Diferença de Taxa de Falsa Descoberta.
Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.

Métrica	Método	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
Diferença de Taxa de Falsa Descoberta	EDL	Pre-Processing	3,17	1,0000	-0,0087	0,0616
	ERL		5,50	1,0000	-0,0539	0,0367
	IAD	In-Processing	4,00	1,0000	-0,0312	0,0547
	IGLA		7,33	1,0000	-0,0952	0,0938

In-Processing

Continua na próxima página

Tabela A.5 – continuação

Métrica	Método	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
	IGLU		7,33	1,0000	-0,0845	0,0654
	IFG		3,67	1,0000	0,0085	0,0459
	IP		6,17	1,0000	-0,0911	0,1778
	IW		5,17	1,0000	-0,0328	0,0733

A.2 Resultados de análise pós-hoc considerando conjuntos elegíveis por categoria de métrica

As tabelas desta seção complementam os achados específicos para conjuntos de dados elegíveis — isto é, aqueles em que a distância ao ideal atinge $u(m) \geq 0,5$, conforme o critério definido no Capítulo 4 —, relativos à análise da Seção 5.3.

Tabela A.6 – Resultados consolidados do pós-hoc vs *Baseline* (por categoria). Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.

Métrica	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
Impacto Díspar	Pre-Processing	2,20	0,1714	0,0741	0,1401
	In-Processing	1,00	0,0044	0,3003	0,1111
Amplificação de viés	Pre-Processing	2,60	0,6241	-0,0221	0,0601
	In-Processing	1,00	0,0269	0,0775	0,0679

Tabela A.7 – Pós-hoc vs *Baseline* (por experimento) — Impacto Díspar. Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.

Métrica	Método	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
Impacto Díspar	EDL	Pre-Processing	7,40	0,7290	-0,0769	0,2775
	ERL		4,40	0,1293	0,2851	0,1901
	IAD	In-Processing	5,80	0,4480	0,0733	0,1622
	IGLA		3,00	0,0316	0,3526	0,0348
	IGLU		3,00	0,0316	0,3353	0,1040
	IFG		7,00	0,7290	-0,0072	0,0355
	IP		3,40	0,0459	0,2912	0,2856
	IW		3,40	0,0459	0,2326	0,2575

Tabela A.8 – Pós-hoc vs *Baseline* (por experimento) — Amplificação de viés. Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.

Métrica	Método	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
	EDL	Pre-Processing	7,00	0,5334	-0,0969	0,1613
	ERL		3,10	0,0456	0,0775	0,0679

Continua na próxima página

Amplificação de viés

Tabela A.8 – continuação

Métrica	Método	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
	IAD	In-Processing	4,60	0,2119	0,0434	0,0378
	IGLA		4,30	0,1837	0,0434	0,0378
	IGLU		4,10	0,1702	0,0434	0,0378
	IFG		5,80	0,5334	0,0074	0,0523
	IP		5,80	0,5334	0,0397	0,0613
	IW		2,90	0,0375	0,0775	0,0679

Tabela A.9 – Resultados consolidados do pós-hoc vs *Baseline* (por categoria). Correção de Holm;
 $\Delta_{\text{rank}} < 0$ indica método melhor que controle.

Métrica	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
Consistência	Pre-Processing	2,40	1,0000	-0,0379	0,0411
	In-Processing	2,00	1,0000	-0,0046	0,0194
Índice de Entropia Generalizada	Pre-Processing	1,80	1,0000	-0,0035	0,0133
	In-Processing	2,80	1,0000	-0,0184	0,0098

Tabela A.10 – Pós-hoc vs *Baseline* (por experimento) — Consistência. Correção de Holm;
 $\Delta_{\text{rank}} < 0$ indica método melhor que controle.

Métrica	Método	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
Consistência	EDL	Pre-Processing	2,20	0,8161	0,0081	0,0026
	ERL		8,40	1,0000	-0,0848	0,0540
	IAD	In-Processing	2,80	1,0000	0,0050	0,0019
	IGLA		4,60	1,0000	-0,0061	0,0195
	IGLU		6,20	1,0000	-0,0232	0,0248
	IFG		6,40	1,0000	-0,0142	0,0233
	IP		6,20	1,0000	-0,0093	0,0342
	IW		3,80	1,0000	-0,0006	0,0147

Tabela A.11 – Resultados consolidados do pós-hoc vs *Baseline* (por categoria). Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.

Métrica	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
Diferença de Taxa de Falsos Negativos	Pre-Processing	1,50	0,0771	0,0166	0,0128
	In-Processing	1,75	0,0786	0,0501	0,0257
Diferença de Taxa de Falsa Descoberta	Pre-Processing	2,25	1,0000	-0,0290	0,0355
	In-Processing	2,75	1,0000	-0,0699	0,0839
Diferença de Taxa de Erro	Pre-Processing	2,00	1,0000	0,0015	0,0153
	In-Processing	2,00	1,0000	-0,0024	0,0154

Tabela A.12 – Pós-hoc vs *Baseline* (por experimento) — Diferença de Taxa de Falsa Descoberta.
Correção de Holm; $\Delta_{\text{rank}} < 0$ indica método melhor que controle.


Métrica	Método	Categoria	Rank médio	p (Holm)	Mediana Δ_{fair}	IQR(Δ_{fair})
Diferença de Taxa de Falsa Descoberta	EDL	Pre-Processing	2,75	1,0000	0,0015	0,0650
	ERL		5,50	1,0000	-0,0539	0,0154
	IAD	In-Processing	3,75	1,0000	-0,0185	0,0717
	IGLA		7,00	1,0000	-0,0846	0,1475
	IGLU		7,00	1,0000	-0,0787	0,0894
	IFG		5,00	1,0000	-0,0131	0,0722
	IP		5,25	1,0000	-0,0762	0,1506
	IW		6,00	1,0000	-0,0746	0,0830

APÊNDICE B — DISTRIBUIÇÃO POR QUADRANTES DO *TRADE-OFF* ENTRE *FAIRNESS* E DESEMPENHO

Este apêndice apresenta a distribuição por quadrantes do *trade-off* entre desempenho preditivo ($\Delta_{F1-Score}$) e ganho em *fairness* (Δ_{fair}) para todas as métricas avaliadas na RQ5 (Seção 5.6).

B.1 Categoria A — paridade estatística


Figura B.1 – Distribuição por quadrantes do *trade-off* entre desempenho preditivo e ganho em *fairness* nas métricas de paridade estatística (categoria A).



Fonte: A autora

B.2 Categoria B — *fairness* individual



Figura B.2 – Distribuição por quadrantes do *trade-off* entre desempenho preditivo e ganho em *fairness* nas métricas de *fairness* individual (categoria B).



Fonte: A autora

B.3 Categoria C — matriz de confusão

Figura B.3 – Distribuição por quadrantes do *trade-off* entre desempenho preditivo e ganho em *fairness* nas métricas baseadas em matriz de confusão (categoria C).



Fonte: A autora

APÊNDICE C — RESULTADOS COMPLEMENTARES DE DESEMPENHO PREDITIVO

Tabela C.1 – Estatísticas de desempenho por experimento e conjunto — Heart Disease

Métrica	Método	Mediana	IQR	Mín	Máx
Acurácia	BLRA	0,8384	0,0404	0,7778	0,8788
	BLRU	0,8283	0,0581	0,7677	0,8788
	BRFA	0,8182	0,0606	0,7273	0,8889
	BRFU	0,8182	0,0480	0,7475	0,8788
	EDL	0,8485	0,0505	0,7576	0,8889
	ERL	0,8182	0,0682	0,7576	0,8889
	IAD	0,8232	0,0404	0,7071	0,8889
	IFG	0,8081	0,0657	0,7374	0,8788
	IGLA	0,7879	0,0404	0,6970	0,8384
	IGLU	0,7828	0,0808	0,6768	0,8586
	IP	0,7626	0,0505	0,6768	0,8182
	IW	0,7980	0,0505	0,7273	0,8687
F1-Score	BLRA	0,8144	0,0556	0,7250	0,8750
	BLRU	0,8023	0,0664	0,7356	0,8632
	BRFA	0,8022	0,0599	0,6824	0,8817
	BRFU	0,7932	0,0583	0,6914	0,8667
	EDL	0,8214	0,0623	0,6667	0,8866
	ERL	0,7953	0,0792	0,7273	0,8675
	IAD	0,8048	0,0768	0,6882	0,8736
	IFG	0,7891	0,0703	0,6988	0,8667
	IGLA	0,7668	0,0545	0,6591	0,8298
	IGLU	0,7564	0,0849	0,6279	0,8421
	IP	0,7431	0,0796	0,6053	0,8000
	IW	0,7850	0,0672	0,7097	0,8478
Precisão	BLRA	0,8537	0,0749	0,7660	0,9211
	BLRU	0,8500	0,0771	0,7500	0,9231
	BRFA	0,8218	0,0919	0,7250	0,9211
	BRFU	0,8248	0,0900	0,7451	0,9355
	EDL	0,8588	0,0867	0,7708	1,0000
	ERL	0,8313	0,0848	0,7333	0,9474
	IAD	0,8332	0,0927	0,6957	0,9500
	IFG	0,8145	0,0871	0,7021	0,8889
	IGLA	0,7676	0,0600	0,6667	0,8649
	IGLU	0,7712	0,1022	0,6538	0,9091
	IP	0,7594	0,0804	0,6400	0,8710
	IW	0,7664	0,0815	0,6852	0,9000
Revocação	BLRA	0,7936	0,0723	0,6170	0,9333
	BLRU	0,7825	0,0929	0,6596	0,9333
	BRFA	0,7889	0,1180	0,5957	0,9111
	BRFU	0,7667	0,1020	0,5957	0,9111
	EDL	0,7778	0,1056	0,5106	0,9556
	ERL	0,7778	0,0730	0,6596	0,9333

Continua na próxima página

Tabela C.1 – continuação

Métrica	Método	Mediana	IQR	Mín	Máx
	IAD	0,7556	0,1243	0,6170	0,9333
	IFG	0,7778	0,1168	0,6170	0,9111
	IGLA	0,7556	0,0953	0,6170	0,8889
	IGLU	0,7390	0,1278	0,5745	0,8723
	IP	0,7284	0,1500	0,4894	0,8889
	IW	0,8000	0,0889	0,6809	0,9333

Tabela C.2 – Estatísticas de desempenho por experimento e conjunto — Aids

Métrica	Método	Mediana	IQR	Mín	Máx
Acurácia	BLRA	0,7847	0,0147	0,7686	0,8050
	BLRU	0,7854	0,0147	0,7686	0,8050
	BRFA	0,7840	0,0133	0,7658	0,7938
	BRFU	0,7833	0,0133	0,7644	0,7980
	EDL	0,7840	0,0130	0,7504	0,7994
	ERL	0,7819	0,0144	0,7602	0,8050
	IAD	0,7742	0,0095	0,5344	0,7980
	IFG	0,7770	0,0144	0,7630	0,8008
	IGLA	0,7840	0,0130	0,7672	0,8050
	IGLU	0,7819	0,0137	0,7532	0,8050
	IP	0,7840	0,0112	0,7616	0,8065
	IW	0,7840	0,0137	0,7588	0,8022
F1-Score	BLRA	0,3919	0,0404	0,3154	0,4633
	BLRU	0,3919	0,0417	0,3167	0,4633
	BRFA	0,3874	0,0495	0,3077	0,4411
	BRFU	0,3927	0,0509	0,3333	0,4528
	EDL	0,4029	0,0334	0,3270	0,4875
	ERL	0,3717	0,0517	0,2905	0,4591
	IAD	0,4211	0,0445	0,3429	0,4857
	IFG	0,3923	0,0530	0,3429	0,5086
	IGLA	0,3880	0,0464	0,2969	0,4633
	IGLU	0,3783	0,0476	0,3167	0,4633
	IP	0,3791	0,0369	0,3333	0,4435
	IW	0,4131	0,0457	0,3435	0,4797
Precisão	BLRA	0,6235	0,0638	0,5435	0,7321
	BLRU	0,6258	0,0628	0,5435	0,7193
	BRFA	0,6282	0,0614	0,5402	0,6935
	BRFU	0,6229	0,0665	0,5326	0,6849
	EDL	0,6156	0,0556	0,4778	0,7097
	ERL	0,6272	0,0744	0,5147	0,7500
	IAD	0,5645	0,0348	0,3035	0,6415
	IFG	0,5805	0,0463	0,5234	0,6951
	IGLA	0,6163	0,0582	0,5435	0,7059
	IGLU	0,6174	0,0551	0,4839	0,7089
	IP	0,6326	0,0756	0,5172	0,7432
	IW	0,6268	0,0748	0,5056	0,7000

Continua na próxima página

Tabela C.2 – continuação

Métrica	Método	Mediana	IQR	Mín	Máx
Revocação	BLRA	0,2824	0,0340	0,2197	0,3448
	BLRU	0,2816	0,0352	0,2197	0,3448
	BRFA	0,2874	0,0450	0,2069	0,3353
	BRFU	0,2816	0,0474	0,2370	0,3448
	EDL	0,3006	0,0362	0,2312	0,3908
	ERL	0,2688	0,0535	0,2023	0,3391
	IAD	0,3401	0,0560	0,2414	0,7011
	IFG	0,2997	0,0450	0,2414	0,4253
	IGLA	0,2853	0,0401	0,1954	0,3448
	IGLU	0,2767	0,0388	0,2197	0,3448
	IP	0,2701	0,0273	0,2241	0,3237
	IW	0,3103	0,0398	0,2356	0,3736

Tabela C.3 – Estatísticas de desempenho por experimento e conjunto — Obesity

Métrica	Método	Mediana	IQR	Mín	Máx
Acurácia	BLRA	0,9929	0,0025	0,9886	0,9972
	BLRU	0,9929	0,0025	0,9886	0,9972
	BRFA	0,9972	0,0043	0,9886	1,0000
	BRFU	0,9972	0,0025	0,9915	1,0000
	EDL	0,9858	0,0064	0,9758	0,9901
	ERL	0,9929	0,0014	0,9886	0,9972
	IAD	0,9929	0,0057	0,6378	1,0000
	IFG	0,9972	0,0028	0,9886	1,0000
	IGLA	0,9851	0,0053	0,9759	0,9929
	IGLU	0,9858	0,0039	0,9787	0,9929
	IP	0,9900	0,0057	0,9830	0,9957
	IW	0,9943	0,0028	0,9886	0,9986
F1-Score	BLRA	0,9881	0,0042	0,9809	0,9952
	BLRU	0,9881	0,0042	0,9809	0,9952
	BRFA	0,9951	0,0073	0,9803	1,0000
	BRFU	0,9951	0,0042	0,9853	1,0000
	EDL	0,9758	0,0109	0,9598	0,9834
	ERL	0,9881	0,0025	0,9809	0,9952
	IAD	0,9881	0,0095	0,6177	1,0000
	IFG	0,9952	0,0048	0,9809	1,0000
	IGLA	0,9752	0,0087	0,9604	0,9881
	IGLU	0,9764	0,0064	0,9649	0,9881
	IP	0,9833	0,0093	0,9717	0,9928
	IW	0,9904	0,0047	0,9809	0,9976
Precisão	BLRA	0,9810	0,0094	0,9673	0,9952
	BLRU	0,9833	0,0094	0,9673	0,9952
	BRFA	1,0000	0,0049	0,9903	1,0000
	BRFU	0,9952	0,0049	0,9855	1,0000
	EDL	0,9691	0,0126	0,9364	0,9950
	ERL	0,9810	0,0093	0,9673	0,9904

Continua na próxima página

Tabela C.3 – continuação

Métrica	Método	Mediana	IQR	Mín	Máx
Revocação	IAD	0,9810	0,0237	0,4478	1,0000
	IFG	0,9952	0,0096	0,9716	1,0000
	IGLA	0,9538	0,0134	0,9279	0,9764
	IGLU	0,9581	0,0123	0,9364	0,9764
	IP	0,9673	0,0226	0,9493	0,9857
	IW	0,9833	0,0081	0,9673	0,9952
	BLRA	0,9952	0,0097	0,9855	1,0000
	BLRU	0,9952	0,0097	0,9855	1,0000
	BRFA	0,9903	0,0097	0,9614	1,0000
	BRFU	0,9903	0,0097	0,9710	1,0000
	EDL	0,9879	0,0217	0,9420	1,0000
	ERL	0,9952	0,0097	0,9855	1,0000
	IAD	0,9903	0,0048	0,8261	1,0000
	IFG	0,9952	0,0085	0,9758	1,0000
	IGLA	1,0000	0,0048	0,9952	1,0000
	IGLU	1,0000	0,0048	0,9952	1,0000
	IP	0,9952	0,0048	0,9903	1,0000
	IW	1,0000	0,0048	0,9903	1,0000

Tabela C.4 – Estatísticas de desempenho por experimento e conjunto — Arrhythmia

Métrica	Método	Mediana	IQR	Mín	Máx
Acurácia	BLRA	0,7219	0,0342	0,6133	0,8212
	BLRU	0,7219	0,0381	0,6400	0,8013
	BRFA	0,8140	0,0530	0,7533	0,8675
	BRFU	0,8200	0,0497	0,7467	0,8675
	EDL	0,6722	0,1362	0,4503	0,7815
	ERL	0,7133	0,0525	0,6133	0,7947
	IAD	0,7483	0,0598	0,6026	0,8212
	IFG	0,8200	0,0430	0,7550	0,8609
	IGLA	0,7010	0,0449	0,5933	0,7483
	IGLU	0,7000	0,0500	0,5667	0,7483
	IP	0,6788	0,0481	0,5960	0,7285
	IW	0,7010	0,0502	0,6133	0,7815
F1-Score	BLRA	0,6864	0,0503	0,5797	0,7939
	BLRU	0,6868	0,0643	0,5902	0,7794
	BRFA	0,7826	0,0578	0,7059	0,8462
	BRFU	0,7863	0,0555	0,6780	0,8413
	EDL	0,6296	0,0719	0,2078	0,7556
	ERL	0,6791	0,0664	0,5797	0,7669
	IAD	0,7266	0,0603	0,6071	0,7907
	IFG	0,7882	0,0562	0,7143	0,8511
	IGLA	0,6643	0,0616	0,5674	0,7206
	IGLU	0,6618	0,0589	0,5455	0,7101
	IP	0,6415	0,0487	0,5344	0,7027
	IW	0,6513	0,0608	0,5672	0,7481

Continua na próxima página

Tabela C.4 – continuação

Métrica	Método	Mediana	IQR	Mín	Máx
Precisão	BLRA	0,7091	0,0375	0,5797	0,8387
	BLRU	0,7155	0,0543	0,6087	0,7910
	BRFA	0,8293	0,0564	0,7424	0,9153
	BRFU	0,8190	0,0718	0,7538	0,9298
	EDL	0,6833	0,2499	0,4533	1,0000
	ERL	0,7023	0,0574	0,5797	0,7969
	IAD	0,7357	0,0840	0,5484	0,8500
	IFG	0,8305	0,0556	0,7465	0,8824
	IGLA	0,6829	0,0423	0,5556	0,7627
	IGLU	0,6968	0,0597	0,5270	0,7627
	IP	0,6581	0,0648	0,5634	0,7333
	IW	0,7053	0,0600	0,5846	0,7925
Revocação	BLRA	0,6522	0,0833	0,5362	0,7536
	BLRU	0,6667	0,0833	0,5217	0,7681
	BRFA	0,7464	0,0833	0,6087	0,8551
	BRFU	0,7536	0,0725	0,5797	0,8261
	EDL	0,7029	0,3913	0,1159	1,0000
	ERL	0,6739	0,0688	0,5362	0,7391
	IAD	0,7101	0,0580	0,4928	0,8261
	IFG	0,7609	0,0978	0,6522	0,8696
	IGLA	0,6377	0,0688	0,4928	0,7101
	IGLU	0,6377	0,0797	0,5507	0,7101
	IP	0,6232	0,0543	0,5072	0,7536
	IW	0,6087	0,0797	0,5072	0,7101

Tabela C.5 – Estatísticas de desempenho por experimento e conjunto — Mental

Métrica	Método	Mediana	IQR	Mín	Máx
Acurácia	BLRA	0,7122	0,0314	0,6594	0,7409
	BLRU	0,7086	0,0344	0,6522	0,7385
	BRFA	0,6985	0,0242	0,6683	0,7488
	BRFU	0,6977	0,0264	0,6513	0,7409
	EDL	0,7110	0,0307	0,6643	0,7554
	ERL	0,7001	0,0356	0,6473	0,7367
	IAD	0,6856	0,0465	0,4237	0,7361
	IFG	0,6844	0,0309	0,5545	0,7150
	IGLA	0,6932	0,0447	0,6232	0,7295
	IGLU	0,6687	0,0294	0,6111	0,7246
	IP	0,6590	0,0338	0,5714	0,7167
	IW	0,6804	0,0254	0,6256	0,7150
F1-Score	BLRA	0,7054	0,0265	0,6617	0,7366
	BLRU	0,7067	0,0302	0,6494	0,7366
	BRFA	0,7014	0,0260	0,6762	0,7586
	BRFU	0,7017	0,0236	0,6522	0,7465
	EDL	0,7054	0,0255	0,6650	0,7469
	ERL	0,6944	0,0291	0,6340	0,7348

Continua na próxima página

Tabela C.5 – continuação

Métrica	Método	Mediana	IQR	Mín	Máx
Precisão	IAD	0,6818	0,0571	0,4133	0,7361
	IFG	0,6953	0,0530	0,3185	0,7179
	IGLA	0,6944	0,0415	0,6287	0,7268
	IGLU	0,6642	0,0250	0,5939	0,7136
	IP	0,6964	0,0173	0,6380	0,7153
	IW	0,6495	0,0291	0,5840	0,6878
	BLRA	0,7212	0,0428	0,6560	0,7713
	BLRU	0,7121	0,0408	0,6512	0,7760
	BRFA	0,6967	0,0244	0,6651	0,7477
	BRFU	0,7004	0,0316	0,6577	0,7500
	EDL	0,7203	0,0434	0,6591	0,7842
	ERL	0,7039	0,0442	0,6400	0,7637
	IAD	0,7150	0,0428	0,4554	0,7674
	IFG	0,6839	0,0306	0,6279	0,7220
	IGLA	0,7022	0,0486	0,6188	0,7514
	IGLU	0,6933	0,0463	0,6154	0,7513
	IP	0,6396	0,0672	0,5471	0,7277
	IW	0,7177	0,0361	0,6421	0,7898
Revocação	BLRA	0,6938	0,0347	0,6316	0,7464
	BLRU	0,6993	0,0379	0,5981	0,7381
	BRFA	0,7048	0,0405	0,6651	0,7895
	BRFU	0,7048	0,0274	0,6459	0,7751
	EDL	0,6976	0,0275	0,6364	0,7416
	ERL	0,6897	0,0405	0,5885	0,7286
	IAD	0,6507	0,1250	0,2952	0,8995
	IFG	0,7010	0,0778	0,2057	0,7608
	IGLA	0,6786	0,0490	0,5837	0,7095
	IGLU	0,6405	0,0490	0,5598	0,6938
	IP	0,7589	0,1258	0,6029	0,8900
	IW	0,5895	0,0263	0,5072	0,6333

Tabela C.6 – Estatísticas de desempenho por experimento e conjunto — Diabetes

Métrica	Método	Mediana	IQR	Mín	Máx
Acurácia	BLRA	0,9222	0,0177	0,8902	0,9595
	BLRU	0,8728	0,0287	0,8391	0,8966
	BRFA	0,9769	0,0231	0,9595	1,0000
	BRFU	0,9711	0,0215	0,9480	1,0000
	EDL	0,9220	0,0175	0,8902	0,9595
	ERL	0,8902	0,0204	0,8439	0,9195
	IAD	0,9135	0,0864	0,6069	0,9595
	IFG	0,9598	0,0230	0,9368	0,9942
	IGLA	0,8555	0,0395	0,8150	0,9138
	IGLU	0,8295	0,1077	0,6358	0,8908
	IP	0,8006	0,0433	0,7414	0,9080
	IW	0,9049	0,0217	0,8728	0,9364

Continua na próxima página

Tabela C.6 – continuação

Métrica	Método	Mediana	IQR	Mín	Máx
F1-Score	BLRA	0,9365	0,0153	0,9100	0,9671
	BLRU	0,8942	0,0206	0,8660	0,9167
	BRFA	0,9810	0,0183	0,9668	1,0000
	BRFU	0,9766	0,0169	0,9569	1,0000
	EDL	0,9362	0,0153	0,9100	0,9671
	ERL	0,9073	0,0181	0,8683	0,9352
	IAD	0,9306	0,0614	0,7444	0,9668
	IFG	0,9677	0,0192	0,9484	0,9953
	IGLA	0,8786	0,0304	0,8519	0,9282
	IGLU	0,8506	0,0994	0,6866	0,9116
	IP	0,8583	0,0264	0,8254	0,9286
	IW	0,9216	0,0205	0,8900	0,9469
Precisão	BLRA	0,9429	0,0328	0,9091	0,9717
	BLRU	0,9163	0,0230	0,8796	0,9677
	BRFA	0,9811	0,0250	0,9541	1,0000
	BRFU	0,9813	0,0161	0,9386	1,0000
	EDL	0,9429	0,0299	0,9091	0,9717
	ERL	0,9249	0,0210	0,8857	0,9794
	IAD	0,9297	0,1409	0,6188	0,9900
	IFG	0,9802	0,0189	0,9369	1,0000
	IGLA	0,9109	0,0341	0,8440	0,9583
	IGLU	0,9033	0,0521	0,7340	0,9462
	IP	0,7647	0,0370	0,7039	0,8889
	IW	0,9492	0,0338	0,9091	0,9800
Revocação	BLRA	0,9252	0,0253	0,8785	0,9720
	BLRU	0,8692	0,0458	0,7850	0,9252
	BRFA	0,9906	0,0187	0,9533	1,0000
	BRFU	0,9812	0,0282	0,9346	1,0000
	EDL	0,9296	0,0275	0,8785	0,9720
	ERL	0,8879	0,0533	0,8131	0,9439
	IAD	0,9439	0,0351	0,8585	1,0000
	IFG	0,9672	0,0373	0,9252	0,9907
	IGLA	0,8598	0,0342	0,8037	0,9065
	IGLU	0,7991	0,1358	0,6262	0,9159
	IP	0,9813	0,0257	0,9439	1,0000
	IW	0,8879	0,0350	0,8318	0,9720

APÊNDICE D — RESULTADOS COMPLEMENTARES: INTENSIDADE, SENTIDO E *TRADE-OFF* ENTRE DESEMPENHO E *FAIRNESS*

Este apêndice reúne resultados complementares às análises de intensidade do viés no *baseline* (Seção 5.4), sentido do viés (Seção 5.5) e *trade-off* entre desempenho preditivo e ganho em *fairness* (Seção 5.6). São apresentadas as tabelas detalhadas de d_{baseline} , Δ_{fair} e r_{fair} por método e conjunto de dados — referenciadas tanto na análise de intensidade quanto na de sentido — e as distribuições por quadrantes correspondentes às fronteiras de Pareto reportadas.

D.1 Estatística descritiva detalhada

Tabela D.1 – Distância ao ideal no *baseline* (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica **amplificação de viés**. $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobrecorreção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
EDL	Aids	0,4583	0,0639	0,1394
	Mental	0,1113	-0,2129	-1,9131
	Diabetes	0,0775	-0,1216	-1,5695
	Heart Disease	0,0434	-0,0969	-2,2296
	Arrhythmia	0,0397	0,0397	1,0000
	Obesity	0,0000	0,0000	0,0000
ERL	Aids	0,4583	0,3707	0,8090
	Mental	0,1113	0,1113	1,0000
	Diabetes	0,0775	0,0775	1,0000
	Heart Disease	0,0434	0,0434	1,0000
	Arrhythmia	0,0397	0,0397	1,0000
	Obesity	0,0000	0,0000	0,0000
IAD	Aids	0,4583	0,3479	0,7591
	Mental	0,1113	-0,5091	-4,5737
	Diabetes	0,0775	0,0775	1,0000
	Heart Disease	0,0434	0,0434	1,0000
	Arrhythmia	0,0397	0,0397	1,0000
	Obesity	0,0000	0,0000	0,0000
IFG	Aids	0,4583	0,3432	0,7488
	Mental	0,1113	0,0074	0,0663

Continuação da Tabela D.1

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
IGLA	Diabetes	0,0775	-0,0089	-0,1148
	Heart Disease	0,0434	0,0434	1,0000
	Arrhythmia	0,0397	-0,0289	-0,7274
	Obesity	0,0000	0,0000	0,0000
	Aids	0,4583	0,0040	0,0087
	Mental	0,1113	0,1113	1,0000
	Diabetes	0,0775	0,0775	1,0000
IGLU	Heart Disease	0,0434	0,0434	1,0000
	Arrhythmia	0,0397	0,0397	1,0000
	Obesity	0,0000	0,0000	0,0000
	Aids	0,4583	0,0389	0,0848
	Mental	0,1113	0,1113	1,0000
	Diabetes	0,0775	0,0775	1,0000
	Heart Disease	0,0434	0,0434	1,0000
IP	Arrhythmia	0,0397	0,0397	1,0000
	Obesity	0,0000	0,0000	0,0000
	Aids	0,4583	0,2821	0,6156
	Mental	0,1113	-0,0179	-0,1606
	Diabetes	0,0775	-0,9997	-12,9045
	Heart Disease	0,0434	0,0434	1,0000
	Arrhythmia	0,0397	0,0397	1,0000
IW	Obesity	0,0000	0,0000	0,0000
	Aids	0,4583	0,4468	0,9749
	Mental	0,1113	0,1113	1,0000
	Diabetes	0,0775	0,0775	1,0000
	Heart Disease	0,0434	0,0434	1,0000
	Arrhythmia	0,0397	0,0397	1,0000
	Obesity	0,0000	0,0000	0,0000

Tabela D.2 – Distância ao ideal no *baseline* (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica **impacto díspar**. $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobrecorreção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
EDL	Aids	1,0103	0,1549	0,1533
	Diabetes	0,9882	-0,1226	-0,1241
	Mental	0,5454	-0,3040	-0,5573
	Heart Disease	0,5347	-0,0769	-0,1438
	Arrhythmia	0,4030	0,2015	0,5000
	Obesity	0,0000	0,0000	0,0000

Continua na próxima página

Continuação da Tabela D.2

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
ERL	Obesity	0,1055	0,0363	0,3442
	Aids	1,0103	0,6529	0,6462
	Diabetes	0,9882	0,2851	0,2885
	Mental	0,5454	0,3068	0,5624
	Heart Disease	0,5347	0,0860	0,1609
	Arrhythmia	0,4030	0,1167	0,2895
	Obesity	0,1055	0,0227	0,2148
IAD	Aids	1,0103	0,6806	0,6737
	Diabetes	0,9882	0,1969	0,1993
	Mental	0,5454	-0,6359	-1,1658
	Heart Disease	0,5347	0,0733	0,1371
	Arrhythmia	0,4030	0,0347	0,0860
	Obesity	0,1055	-0,0061	-0,0575
IFG	Aids	1,0103	0,6109	0,6047
	Diabetes	0,9882	-0,0846	-0,0856
	Mental	0,5454	-0,0072	-0,0132
	Heart Disease	0,5347	0,0089	0,0167
	Arrhythmia	0,4030	-0,0266	-0,0659
	Obesity	0,1055	-0,0069	-0,0651
IGLA	Aids	1,0103	0,0646	0,0640
	Diabetes	0,9882	0,5596	0,5663
	Mental	0,5454	0,3717	0,6815
	Heart Disease	0,5347	0,3526	0,6595
	Arrhythmia	0,4030	0,3369	0,8359
	Obesity	0,1055	0,0811	0,7682
IGLU	Aids	1,0103	0,1749	0,1731
	Diabetes	0,9882	0,5395	0,5459
	Mental	0,5454	0,3833	0,7027
	Heart Disease	0,5347	0,3353	0,6270
	Arrhythmia	0,4030	0,2793	0,6930
	Obesity	0,1055	0,0811	0,7682
IP	Aids	1,0103	0,5301	0,5247
	Diabetes	0,9882	0,6122	0,6195
	Mental	0,5454	0,1926	0,3532
	Heart Disease	0,5347	0,2912	0,5446
	Arrhythmia	0,4030	0,2445	0,6066
	Obesity	0,1055	0,0617	0,5842
IW	Aids	1,0103	0,8021	0,7939
	Diabetes	0,9882	0,0750	0,0759

Continua na próxima página

Continuação da Tabela D.2

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
	Mental	0,5454	0,4084	0,7488
	Heart Disease	0,5347	0,2326	0,4351
	Arrhythmia	0,4030	0,1509	0,3744
	Obesity	0,1055	0,0224	0,2121

Tabela D.3 – Distância ao ideal no *baseline* (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica **consistência**. $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobrecorreção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
EDL	Arrhythmia	0,2745	0,0613	0,2232
	Mental	0,2563	0,0065	0,0254
	Heart Disease	0,1162	0,0091	0,0783
	Aids	0,0997	0,0081	0,0816
	Diabetes	0,0899	0,0052	0,0574
	Obesity	0,0374	0,0015	0,0398
ERL	Arrhythmia	0,2745	-0,0404	-0,1473
	Mental	0,2563	-0,0944	-0,3685
	Heart Disease	0,1162	-0,0848	-0,7304
	Aids	0,0997	-0,1564	-1,5682
	Diabetes	0,0899	-0,0067	-0,0742
	Obesity	0,0374	0,0099	0,2632
IAD	Arrhythmia	0,2745	0,0050	0,0181
	Mental	0,2563	0,0050	0,0196
	Heart Disease	0,1162	0,0101	0,0870
	Aids	0,0997	-0,0157	-0,1575
	Diabetes	0,0899	0,0069	0,0767
	Obesity	0,0374	0,0077	0,2068
IFG	Arrhythmia	0,2745	-0,0142	-0,0519
	Mental	0,2563	-0,0122	-0,0474
	Heart Disease	0,1162	-0,0556	-0,4783
	Aids	0,0997	-0,0355	-0,3558
	Diabetes	0,0899	0,0034	0,0381
	Obesity	0,0374	-0,0089	-0,2381
IGLA	Arrhythmia	0,2745	-0,0232	-0,0844
	Mental	0,2563	0,0024	0,0092
	Heart Disease	0,1162	-0,0172	-0,1478
	Aids	0,0997	0,0157	0,1575
	Diabetes	0,0899	-0,0061	-0,0675

Continua na próxima página

Continuação da Tabela D.3

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
IGLU	Obesity	0,0374	0,0030	0,0809
	Arrhythmia	0,2745	-0,0268	-0,0977
	Mental	0,2563	-0,0020	-0,0078
	Heart Disease	0,1162	-0,0232	-0,2000
	Aids	0,0997	0,0142	0,1421
	Diabetes	0,0899	-0,0327	-0,3633
	Obesity	0,0374	0,0027	0,0734
IP	Arrhythmia	0,2745	-0,0421	-0,1532
	Mental	0,2563	0,0029	0,0113
	Heart Disease	0,1162	-0,0313	-0,2696
	Aids	0,0997	0,0121	0,1210
	Diabetes	0,0899	-0,0093	-0,1029
	Obesity	0,0374	0,0051	0,1373
IW	Arrhythmia	0,2745	-0,0109	-0,0398
	Mental	0,2563	0,0108	0,0422
	Heart Disease	0,1162	-0,0091	-0,0783
	Aids	0,0997	0,0056	0,0563
	Diabetes	0,0899	-0,0006	-0,0068
	Obesity	0,0374	0,0062	0,1645

Tabela D.4 – Distância ao ideal no *baseline* (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica **índice de entropia generalizada**. $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobrecorreção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
EDL	Mental	0,1502	0,0003	0,0021
	Aids	0,1327	0,0026	0,0196
	Arrhythmia	0,1293	-0,0107	-0,0828
	Heart Disease	0,0889	0,0052	0,0584
	Diabetes	0,0279	-0,0116	-0,4158
	Obesity	0,0028	-0,0043	-1,5112
ERL	Mental	0,1502	-0,0036	-0,0243
	Aids	0,1327	-0,0005	-0,0040
	Arrhythmia	0,1293	-0,0195	-0,1505
	Heart Disease	0,0889	-0,0053	-0,0599
	Diabetes	0,0279	-0,0309	-1,1088
	Obesity	0,0028	-0,0006	-0,2265
	Mental	0,1502	-0,0146	-0,0970

Continua na próxima página

Continuação da Tabela D.4

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
	Aids	0,1327	0,0011	0,0086
	Arrhythmia	0,1293	0,0039	0,0299
	Heart Disease	0,0889	-0,0027	-0,0300
	Diabetes	0,0279	-0,0115	-0,4128
	Obesity	0,0028	-0,0006	-0,2273
IFG	Mental	0,1502	-0,0007	-0,0045
	Aids	0,1327	-0,0022	-0,0163
	Arrhythmia	0,1293	0,0311	0,2404
	Heart Disease	0,0889	-0,0069	-0,0780
	Diabetes	0,0279	0,0089	0,3177
	Obesity	0,0028	0,0014	0,4988
IGLA	Mental	0,1502	-0,0090	-0,0599
	Aids	0,1327	0,0008	0,0057
	Arrhythmia	0,1293	-0,0284	-0,2199
	Heart Disease	0,0889	-0,0193	-0,2169
	Diabetes	0,0279	-0,0492	-1,7674
	Obesity	0,0028	-0,0043	-1,5289
IGLU	Mental	0,1502	-0,0253	-0,1682
	Aids	0,1327	0,0001	0,0008
	Arrhythmia	0,1293	-0,0254	-0,1966
	Heart Disease	0,0889	-0,0250	-0,2812
	Diabetes	0,0279	-0,0702	-2,5192
	Obesity	0,0028	-0,0040	-1,4014
IP	Mental	0,1502	0,0144	0,0959
	Aids	0,1327	0,0001	0,0009
	Arrhythmia	0,1293	-0,0366	-0,2828
	Heart Disease	0,0889	-0,0303	-0,3407
	Diabetes	0,0279	-0,0321	-1,1514
	Obesity	0,0028	-0,0020	-0,7206
IW	Mental	0,1502	-0,0401	-0,2672
	Aids	0,1327	0,0016	0,0118
	Arrhythmia	0,1293	-0,0368	-0,2849
	Heart Disease	0,0889	-0,0113	-0,1270
	Diabetes	0,0279	-0,0218	-0,7827
	Obesity	0,0028	0,0000	0,0132

Tabela D.5 – Distância ao ideal no *baseline* (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica **diferença da taxa de falsos negativos**. $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobrecorreção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
EDL	Mental	0,1603	-0,0773	-0,4824
	Aids	0,1428	-0,0307	-0,2154
	Arrhythmia	0,1391	0,0908	0,6529
	Heart Disease	0,0997	0,0087	0,0876
	Diabetes	0,0413	-0,0568	-1,3744
	Obesity	0,0077	-0,0125	-1,6397
ERL	Mental	0,1603	0,1140	0,7115
	Aids	0,1428	0,0683	0,4782
	Arrhythmia	0,1391	0,0468	0,3366
	Heart Disease	0,0997	0,0058	0,0583
	Diabetes	0,0413	-0,0057	-0,1368
	Obesity	0,0077	0,0068	0,8900
IAD	Mental	0,1603	-0,1923	-1,1996
	Aids	0,1428	0,0667	0,4673
	Arrhythmia	0,1391	-0,0051	-0,0367
	Heart Disease	0,0997	-0,0101	-0,1017
	Diabetes	0,0413	-0,0070	-0,1684
	Obesity	0,0077	-0,0025	-0,3266
IFG	Mental	0,1603	-0,0120	-0,0750
	Aids	0,1428	0,0218	0,1524
	Arrhythmia	0,1391	0,0155	0,1112
	Heart Disease	0,0997	0,0157	0,1577
	Diabetes	0,0413	0,0005	0,0128
	Obesity	0,0077	0,0066	0,8654
IGLA	Mental	0,1603	0,0873	0,5446
	Aids	0,1428	-0,0057	-0,0397
	Arrhythmia	0,1391	0,0699	0,5023
	Heart Disease	0,0997	-0,0456	-0,4576
	Diabetes	0,0413	-0,1059	-2,5616
	Obesity	0,0077	0,0077	1,0000
IGLU	Mental	0,1603	0,0995	0,6209
	Aids	0,1428	0,0112	0,0787
	Arrhythmia	0,1391	0,0712	0,5115
	Heart Disease	0,0997	-0,0676	-0,6780
	Diabetes	0,0413	-0,0751	-1,8158
	Obesity	0,0077	0,0077	1,0000

Continua na próxima página

Continuação da Tabela D.5

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
IP	Mental	0,1603	0,0857	0,5349
	Aids	0,1428	0,0698	0,4891
	Arrhythmia	0,1391	0,0583	0,4194
	Heart Disease	0,0997	-0,0456	-0,4576
	Diabetes	0,0413	0,0225	0,5447
	Obesity	0,0077	0,0066	0,8654
IW	Mental	0,1603	0,0833	0,5194
	Aids	0,1428	0,0608	0,4259
	Arrhythmia	0,1391	0,0353	0,2535
	Heart Disease	0,0997	0,0058	0,0583
	Diabetes	0,0413	0,0121	0,2936
	Obesity	0,0077	0,0077	1,0000

Tabela D.6 – Distância ao ideal no *baseline* (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica **diferença da taxa de falsa descoberta**. $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobrecorreção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
EDL	Arrhythmia	0,1414	-0,0647	-0,4574
	Mental	0,1306	0,0303	0,2319
	Heart Disease	0,1067	0,0290	0,2715
	Aids	0,0689	-0,0261	-0,3783
	Diabetes	0,0426	0,0086	0,2029
	Obesity	0,0223	-0,0416	-1,8624
ERL	Arrhythmia	0,1414	-0,0794	-0,5614
	Mental	0,1306	-0,0282	-0,2157
	Heart Disease	0,1067	-0,0556	-0,5211
	Aids	0,0689	-0,0522	-0,7576
	Diabetes	0,0426	-0,0759	-1,7816
	Obesity	0,0223	-0,0167	-0,7469
IAD	Arrhythmia	0,1414	0,0130	0,0919
	Mental	0,1306	0,0384	0,2942
	Heart Disease	0,1067	-0,0501	-0,4692
	Aids	0,0689	-0,0590	-0,8564
	Diabetes	0,0426	-0,0459	-1,0759
	Obesity	0,0223	-0,0165	-0,7384
IFG	Arrhythmia	0,1414	0,0543	0,3837
	Mental	0,1306	-0,0310	-0,2376

Continua na próxima página

Continuação da Tabela D.6

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
IGLA	Heart Disease	0,1067	0,0048	0,0449
	Aids	0,0689	-0,1270	-1,8440
	Diabetes	0,0426	0,0277	0,6496
	Obesity	0,0223	0,0122	0,5479
	Arrhythmia	0,1414	-0,1385	-0,9795
	Mental	0,1306	-0,0306	-0,2345
	Heart Disease	0,1067	-0,2822	-2,6434
	Aids	0,0689	-0,0160	-0,2318
	Diabetes	0,0426	-0,1210	-2,8387
	Obesity	0,0223	-0,0694	-3,1067
	Arrhythmia	0,1414	-0,1079	-0,7631
	Mental	0,1306	-0,0495	-0,3790
IGLU	Heart Disease	0,1067	-0,2142	-2,0071
	Aids	0,0689	-0,0321	-0,4658
	Diabetes	0,0426	-0,1211	-2,8400
	Obesity	0,0223	-0,0610	-2,7302
IP	Arrhythmia	0,1414	-0,1385	-0,9794
	Mental	0,1306	0,0093	0,0715
	Heart Disease	0,1067	-0,2193	-2,0547
	Aids	0,0689	-0,0139	-0,2018
	Diabetes	0,0426	-0,2371	-5,5632
	Obesity	0,0223	-0,0437	-1,9560
IW	Arrhythmia	0,1414	-0,0966	-0,6827
	Mental	0,1306	-0,0057	-0,0434
	Heart Disease	0,1067	-0,2061	-1,9309
	Aids	0,0689	-0,0527	-0,7649
	Diabetes	0,0426	-0,0129	-0,3032
	Obesity	0,0223	-0,0121	-0,5406

Tabela D.7 – Distância ao ideal no *baseline* (d_{baseline}) e redução absoluta após mitigação (Δ_{fair}) para a métrica **diferença da taxa de erro**. $r_{\text{fair}} = \Delta_{\text{fair}}/d_{\text{baseline}}$ indica a fração do viés removida (valores > 1 indicam sobrecorreção). Valores positivos de Δ_{fair} indicam redução do viés; valores negativos indicam aumento. Linhas ordenadas por d_{baseline} decrescente dentro de cada método.

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
EDL	Heart Disease	0,0809	-0,0180	-0,2219
	Mental	0,0463	-0,0017	-0,0374
	Arrhythmia	0,0325	-0,0334	-1,0302
	Diabetes	0,0309	-0,0002	-0,0075
	Aids	0,0234	0,0074	0,3147

Continua na próxima página

Continuação da Tabela D.7

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
ERL	Obesity	0,0084	-0,0169	-2,0000
	Heart Disease	0,0809	0,0424	0,5245
	Mental	0,0463	0,0111	0,2389
	Arrhythmia	0,0325	0,0009	0,0278
	Diabetes	0,0309	-0,0142	-0,4589
	Aids	0,0234	0,0017	0,0708
	Obesity	0,0084	-0,0042	-0,4962
IAD	Heart Disease	0,0809	0,0201	0,2478
	Mental	0,0463	-0,0295	-0,6387
	Arrhythmia	0,0325	-0,0063	-0,1952
	Diabetes	0,0309	-0,0223	-0,7199
	Aids	0,0234	0,0035	0,1490
	Obesity	0,0084	-0,0042	-0,4957
IFG	Heart Disease	0,0809	0,0051	0,0634
	Mental	0,0463	-0,0108	-0,2328
	Arrhythmia	0,0325	-0,0185	-0,5706
	Diabetes	0,0309	0,0105	0,3394
	Aids	0,0234	0,0146	0,6226
	Obesity	0,0084	0,0055	0,6580
IGLA	Heart Disease	0,0809	0,0170	0,2104
	Mental	0,0463	-0,0069	-0,1499
	Arrhythmia	0,0325	-0,0127	-0,3914
	Diabetes	0,0309	-0,0608	-1,9684
	Aids	0,0234	0,0027	0,1155
	Obesity	0,0084	-0,0168	-1,9962
IGLU	Heart Disease	0,0809	0,0205	0,2536
	Mental	0,0463	0,0108	0,2344
	Arrhythmia	0,0325	-0,0063	-0,1926
	Diabetes	0,0309	-0,0653	-2,1122
	Aids	0,0234	0,0006	0,0254
	Obesity	0,0084	-0,0154	-1,8290
IP	Heart Disease	0,0809	0,0250	0,3084
	Mental	0,0463	0,0031	0,0679
	Arrhythmia	0,0325	-0,0318	-0,9806
	Diabetes	0,0309	-0,1296	-4,1912
	Aids	0,0234	0,0005	0,0213
	Obesity	0,0084	-0,0112	-1,3295
IW	Heart Disease	0,0809	0,0250	0,3084
	Mental	0,0463	-0,0519	-1,1227

Continua na próxima página

Continuação da Tabela D.7

Método	Conjunto de dados	d_{baseline}	Δ_{fair}	r_{fair}
	Arrhythmia	0,0325	-0,0068	-0,2092
	Diabetes	0,0309	-0,0060	-0,1933
	Aids	0,0234	0,0039	0,1664
	Obesity	0,0084	-0,0014	-0,1667

D.2 Estatística descritiva de *trade-off* por categoria

Tabela D.8 – Resumo de *trade-off* por categoria: Amplificação de viés. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
Pre-Processing	6	-0,0110	0,0553	-0,0063	0,0242
In-Processing	6	0,0514	0,0323	-0,0246	0,0419

Tabela D.9 – Resumo de *trade-off* por categoria: Impacto Díspar. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
Pre-Processing	6	0,0554	0,1288	-0,0063	0,0242
In-Processing	6	0,2721	0,1329	-0,0246	0,0419

Tabela D.10 – Resumo de *trade-off* por categoria: Consistência. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
Pre-Processing	6	-0,0193	0,0465	-0,0063	0,0242
In-Processing	6	-0,0004	0,0186	-0,0246	0,0419

Tabela D.11 – Resumo de *trade-off* por categoria: Índice de Entropia Generalizada. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
Pre-Processing	6	-0,0021	0,0115	-0,0063	0,0242
In-Processing	6	-0,0135	0,0201	-0,0246	0,0419

Tabela D.12 – Resumo de *trade-off* por categoria: Diferença de Taxa de Falsos Negativos. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
Pre-Processing	6	0,0128	0,0190	-0,0063	0,0242
In-Processing	6	0,0242	0,0460	-0,0246	0,0419

Tabela D.13 – Resumo de *trade-off* por categoria: Diferença de Taxa de Falsa Descoberta. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
Pre-Processing	6	-0,0314	0,0205	-0,0063	0,0242
In-Processing	6	-0,0629	0,0644	-0,0246	0,0419

Tabela D.14 – Resumo de *trade-off* por categoria: Diferença de Taxa de Erro. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
Pre-Processing	6	-0,0013	0,0143	-0,0063	0,0242
In-Processing	6	-0,0083	0,0099	-0,0246	0,0419

D.3 Estatística descritiva de *trade-off* por método

Tabela D.15 – Resumo de *trade-off* por método: Amplificação de viés. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Método	Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
EDL	Pre-Processing	6	-0,0484	0,1452	-0,0066	0,0270
ERL		6	0,0605	0,0622	-0,0159	0,0294
IAD	In-Processing	6	0,0416	0,0590	-0,0034	0,0169
IFG		6	0,0037	0,0411	0,0037	0,0168
IGLA		6	0,0416	0,0560	-0,0288	0,0467
IGLU		6	0,0416	0,0299	-0,0463	0,0418
IP		6	0,0198	0,0559	-0,0384	0,0724
IW		6	0,0605	0,0622	-0,0288	0,0431

Tabela D.16 – Resumo de *trade-off* por método: Impacto Díspar. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Método	Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
EDL	Pre-Processing	6	-0,0203	0,2365	-0,0066	0,0270
ERL		6	0,2009	0,2077	-0,0159	0,0294
IAD	In-Processing	6	0,0540	0,1619	-0,0034	0,0169
IFG		6	-0,0070	0,0267	0,0037	0,0168
IGLA		6	0,3448	0,2219	-0,0288	0,0467
IGLU		6	0,3073	0,1703	-0,0463	0,0418
IP		6	0,2679	0,2647	-0,0384	0,0724
IW		6	0,1918	0,2705	-0,0288	0,0431

Tabela D.17 – Resumo de *trade-off* por método: Consistência. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Método	Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
EDL	Pre-Processing	6	0,0073	0,0034	-0,0066	0,0270
ERL		6	-0,0626	0,0769	-0,0159	0,0294
IAD	In-Processing	6	0,0060	0,0026	-0,0034	0,0169
IFG		6	-0,0132	0,0204	0,0037	0,0168
IGLA		6	-0,0019	0,0173	-0,0288	0,0467
IGLU		6	-0,0126	0,0275	-0,0463	0,0418
IP		6	-0,0032	0,0304	-0,0384	0,0724
IW		6	0,0025	0,0130	-0,0288	0,0431

Tabela D.18 – Resumo de *trade-off* por método: Índice de Entropia Generalizada. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Método	Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
EDL	Pre-Processing	6	-0,0020	0,0111	-0,0066	0,0270
ERL		6	-0,0045	0,0145	-0,0159	0,0294
IAD	In-Processing	6	-0,0017	0,0100	-0,0034	0,0169
IFG		6	0,0004	0,0088	0,0037	0,0168
IGLA		6	-0,0141	0,0206	-0,0288	0,0467
IGLU		6	-0,0251	0,0161	-0,0463	0,0418
IP		6	-0,0162	0,0312	-0,0384	0,0724
IW		6	-0,0165	0,0303	-0,0288	0,0431

Tabela D.19 – Resumo de *trade-off* por método: Diferença de Taxa de Falsos Negativos. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Método	Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
EDL	Pre-Processing	6	-0,0216	0,0537	-0,0066	0,0270
ERL		6	0,0268	0,0568	-0,0159	0,0294
IAD	In-Processing	6	-0,0060	0,0062	-0,0034	0,0169
IFG		6	0,0110	0,0136	0,0037	0,0168
IGLA		6	0,0010	0,0899	-0,0288	0,0467
IGLU		6	0,0094	0,1049	-0,0463	0,0418
IP		6	0,0404	0,0564	-0,0384	0,0724
IW		6	0,0237	0,0456	-0,0288	0,0431

Tabela D.20 – Resumo de *trade-off* por método: Diferença de Taxa de Falsa Descoberta. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Método	Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
EDL	Pre-Processing	6	-0,0087	0,0616	-0,0066	0,0270
ERL		6	-0,0539	0,0367	-0,0159	0,0294
IAD	In-Processing	6	-0,0312	0,0547	-0,0034	0,0169
IFG		6	0,0085	0,0459	0,0037	0,0168
IGLA		6	-0,0952	0,0938	-0,0288	0,0467
IGLU		6	-0,0845	0,0654	-0,0463	0,0418
IP		6	-0,0911	0,1778	-0,0384	0,0724
IW		6	-0,0328	0,0733	-0,0288	0,0431

Tabela D.21 – Resumo de *trade-off* por método: Diferença de Taxa de Erro. $\Delta_{\text{fair}} > 0$ indica melhoria de *fairness*; $\Delta_{\text{F1}} > 0$ indica melhoria de desempenho.

Método	Categoria	n	Mediana Δ_{fair}	IQR(Δ_{fair})	Mediana Δ_{F1}	IQR(Δ_{F1})
EDL	Pre-Processing	6	-0,0093	0,0171	-0,0066	0,0270
ERL		6	0,0013	0,0116	-0,0159	0,0294
IAD	In-Processing	6	-0,0053	0,0198	-0,0034	0,0169
IFG		6	0,0053	0,0160	0,0037	0,0168
IGLA		6	-0,0098	0,0161	-0,0288	0,0467
IGLU		6	-0,0028	0,0214	-0,0463	0,0418
IP		6	-0,0054	0,0292	-0,0384	0,0724
IW		6	-0,0037	0,0092	-0,0288	0,0431